

CONSULTORES EDITORIALES:

SEBASTIÁN DORMIDO BENCOMO

Departamento de Informática y Automática

UNIVERSIDAD NACIONAL DE EDUCACIÓN A DISTANCIA

LUIS JOYANES AGUILAR

Departamento de Lenguajes, Sistemas Informáticos e Ingeniería del Software

UNIVERSIDAD PONTIFICIA DE SALAMANCA. Campus Madrid

SISTEMAS DISTRIBUIDOS CONCEPTOS Y DISEÑO

Tercera edición

GEORGE COULOURIS

Queen Mary and Westfield College

University of London, and Cambridge University

JEAN DOLLIMORE

Queen Mary and Westfield College

University of London

TIM KINDBERG

Hewlett-Packard Laboratoires, Palo Alto

Traducción:

José Belarmino Pulido Junquera

Benjamín Sahelices Fernández

Jesús María Vegas Hernández

Universidad de Valladolid

Coordinadores de la traducción:

Pablo de la Fuente Redondo

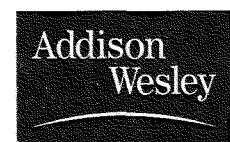
Cesar Llamas Bello

Universidad de Valladolid

Revisión técnica:

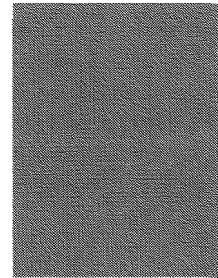
Sebastián Dormido Bencomo

Universidad Nacional de Educación a Distancia



Madrid • México • Santa Fe de Bogotá • Buenos Aires • Caracas • Lima • Montevideo • San Juan
San José • Santiago • São Paulo • Reading, Massachusetts • Harlow, England

Datos de catalogación bibliográfica	
COULOURIS, G.; DOLLIMORE, J.; KINDBERG, T.	
SISTEMAS DISTRIBUIDOS. Conceptos y diseño.	
Tercera edición	
PEARSON EDUCACIÓN, S. A., Madrid, 2001	
ISBN: 84-7829-049-4	
Materia: Informática: 681.3	
Formato 195 x 250	
Páginas: 744	



No está permitida la reproducción total o parcial de esta obra ni su tratamiento o transmisión por cualquier medio o método, sin autorización escrita de la Editorial.

DERECHOS RESERVADOS

© 2001 respecto a la primera edición en español por:

PEARSON EDUCACIÓN, S. A.
Ribera del Loira, 28
28042 Madrid (España)

GEORGE COULOURIS, JEAN DOLLIMORE, TIM KINDBERG
SISTEMAS DISTRIBUIDOS. Conceptos y diseño. Tercera edición

ISBN: 84-7829-049-4

Depósito legal: M. 45.496-2003

ADDISON WESLEY es un sello editorial autorizado de PEARSON EDUCACIÓN, S. A.

Traducido de:

Distributed Systems Concepts and Design, Third Edition

© Addison Wesley Publishers Limited 1990, 1994

© Pearson Education Limited 2001

ISBN 0-201-61918-0

Edición en español:

Equipo editorial:

Editor: Andrés Otero

Asistente editorial: Ana Isabel García

Equipo de producción:

Director: José Antonio Clares

Técnico: Diego Marín

Diseño de cubierta: Mario Guindel y Yann Boix

Composición: COPIBOOK, S. L.

Impreso en Imprenta Fareso, S. A.

IMPRESO EN ESPAÑA - PRINTED IN SPAIN



Este libro ha sido impreso con papel y tintas ecológicos

CONTENIDO

PRÓLOGO	XIII
Objetivos y audiencia	XIII
Organización del libro	XIV
Referencias	XIV
Cambios en esta edición	XV
Reconocimientos	XV
Sitio web	XVI
1. CARACTERIZACIÓN DE LOS SISTEMAS DISTRIBUIDOS	1
1.1. Introducción	2
1.2. Ejemplos de sistemas distribuidos	3
1.2.1. Internet	3
1.2.2. Intranets	4
1.2.3. Computación móvil y ubicua	5
1.3. Recursos compartidos y Web	7
1.3.1. El World Wide Web	8
1.4. Desafíos	15
1.4.1. Heterogeneidad	15
1.4.2. Extensibilidad	17
1.4.3. Seguridad	18
1.4.4. Escalabilidad	19
1.4.5. Tratamiento de fallos	20
1.4.6. Concurrencia	21
1.4.7. Transparencia	22
1.5. Resumen	24
Ejercicios	25
2. MODELOS DE SISTEMA	27
2.1. Introducción	28
2.2. Modelos arquitectónicos	28
2.2.1. Capas de software	29
2.2.2. Arquitecturas de sistema	31
2.2.3. Variaciones en el modelo de cliente-servidor	34

2.2.4. Interfaces y objetos.....	40
2.2.5. Requisitos de diseño para arquitecturas distribuidas.....	41
Ejercicios.....	
3. REDES E INTERCONEXIÓN DE REDES.....	61
3.1. Introducción.....	62
3.1.1. Las redes y los sistemas distribuidos.....	62
2.2.5. Requisitos de diseño para arquitecturas distribuidas.....	41
Ejercicios.....	

4.6.2. Comunicación con streams.....	149
4.7. Resumen.....	150
Ejercicios.....	151
5. OBJETOS DISTRIBUIDOS E INVOCACIÓN REMOTA.....	155
5.1. Introducción.....	156
5.1.1. Interfaces.....	157
5.2. Comunicación entre objetos distribuidos.....	159
5.2.1. El modelo de objetos.....	159
5.2.2. Objetos distribuidos.....	161
5.2.3. El modelo de objetos distribuido.....	161
5.2.4. Cuestiones de diseño para RMI.....	163
5.2.5. Implementación de RMI.....	166
5.2.6. Compactación automática de memoria.....	171
5.3. Llamada a un procedimiento remoto.....	172
5.3.1. Caso de estudio Sun RPC.....	173
5.4. Eventos y notificaciones.....	175
5.4.1. Los participantes en una notificación de eventos distribuida.....	178
5.4.2. Especificación de eventos distribuidos de Jini.....	180
5.5. El caso de estudio Java RMI.....	182
5.5.1. Construcción de programas clientes y servidores.....	184
5.5.2. Diseño e implementación de Java RMI.....	188
5.6. Resumen.....	189
Ejercicios.....	190
6. SOPORTE DEL SISTEMA OPERATIVO.....	193
6.1. Introducción.....	194
6.2. El nivel de sistema operativo.....	195
6.3. Protección.....	198
6.4. Procesos e hilos.....	199
6.4.1. Espacios de direcciones.....	200
6.4.2. Creación de un proceso nuevo.....	202
6.4.3. Hilos.....	205
6.5. Comunicación e invocación.....	216
6.5.1. Prestaciones de la invocación.....	217
6.5.2. Operación asíncrona.....	224
6.6. Arquitectura del sistema operativo.....	226
6.7. Resumen.....	230
Ejercicios.....	231
7. SEGURIDAD.....	235
7.1. Introducción.....	236
7.1.1. Amenazas y ataques.....	238
7.1.2. Seguridad de las transacciones electrónicas.....	240
7.1.3. Diseño de sistemas seguros.....	242
7.2. Visión general de las técnicas de seguridad.....	244
7.2.1. Criptografía.....	244
7.2.2. Usos de la criptografía.....	245
7.2.3. Certificados.....	248
7.2.4. Control de acceso.....	250
7.2.5. Credenciales.....	252
7.2.6. Cortafuegos.....	254
7.3. Algoritmos criptográficos.....	254

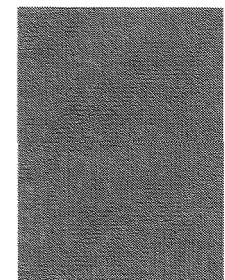
7.3.1. Algoritmos de clave secreta (simétricos).....	258
<u>7.3.2. Algoritmos de clave pública (asimétricos)</u>	<u>261</u>
7.4. Firmas digitales.....	264
7.4.1. Firmas digitales con claves públicas.....	265
7.4.2. Firmas digitales con MAC	266
7.5. Resumen	267
Ejercicios	268

7.3.1. Algoritmos de clave secreta (simétricos).....	258
7.3.2. Algoritmos de clave pública (asimétricos).....	261
7.3.3. Protocolos criptográficos híbridos.....	264
7.4. Firmas digitales.....	264
7.4.1. Firmas digitales con claves públicas.....	265
7.4.2. Firmas digitales con MAC	266
7.5. Resumen	267
Ejercicios	268

10.3.3. El algoritmo de Berkeley	374
10.3.4. El protocolo del tiempo de red	375
10.4. Tiempo lógico y relojes lógicos	377
10.5. Estados globales	381
10.5.1. Estados globales y cortes consistentes	382
10.5.2. Predicados de estado global, estabilidad, seguridad y vitalidad	384
10.5.3. El algoritmo de <i>instantánea</i> de Chandy y Lamport	385
10.6. Depuración distribuida	389
10.6.1. Observación de estados globales consistentes	390
10.6.2. Evaluando <i>posiblemente</i> ϕ	392
10.6.3. Evaluando sin duda alguna ϕ	393
10.6.4. Evaluando <i>definitivamente</i> ϕ y <i>sin duda alguna</i> ϕ en sistemas síncronos	394
10.7. Resumen	395
Ejercicios	395
11. COORDINACIÓN Y ACUERDO	399
11.1. Introducción	400
11.1.1. Suposiciones sobre fallos y detectores de fallos	401
11.2. Exclusión mutua distribuida	403
11.2.1. Algoritmos para la exclusión mutua	404
11.3. Elecciones	411
11.4. Comunicación por multidifusión	415
11.4.1. Multidifusión básica	417
11.4.2. Multidifusión fiable	417
11.4.3. Multidifusión ordenada	421
11.5. Consenso y sus problemas relacionados	428
11.5.1. Definición del modelo del sistema y del problema	429
11.5.2. Consenso en un sistema síncrono	432
11.5.3. El problema de los generales bizantinos en un sistema síncrono	433
11.5.4. Imposibilidad en sistemas asíncronos	436
11.6. Resumen	439
Ejercicios	439
12. TRANSACCIONES Y CONTROL DE CONCURRENCIA	443
12.1. Introducción	444
12.1.1. Sincronización sencilla (sin transacciones)	444
12.1.2. Modelo de fallos para transacciones	446
12.2. Transacciones	447
12.2.1. Control de concurrencia	451
12.2.2. Recuperabilidad de transacciones abortadas	455
12.3. Transacciones anidadas	457
12.4. Bloqueos	459
12.4.1. Bloqueos indefinidos	466
12.4.2. Incrementando la concurrencia en esquemas de bloqueo	469
12.5. Control optimista de la concurrencia	472
12.6. Ordenación por marcas de tiempo	476
12.7. Comparación de métodos para el control de concurrencia	483
12.8. Resumen	484
Ejercicios	485
13. TRANSACCIONES DISTRIBUIDAS	491
13.1. Introducción	492
13.2. Transacciones distribuidas planas y anidadas	492

13.2.1. El coordinador de una transacción distribuida.....	493	16. MEMORIA COMPARTIDA DISTRIBUIDA	605
13.3. Protocolos de consumación atómica.....	495	16.1. Introducción.....	606
13.3.1. El protocolo de consumación en dos fases.....	496	16.1.1. DSM frente a paso de mensajes	607
13.3.2. Protocolo de consumación en dos fases para transacciones anidadas.....	499	16.1.2. Aproximaciones a la implementación de DSM	608
13.4. Control de concurrencia en transacciones distribuidas.....	503	16.2. Cuestiones de diseño e implementación	610
13.4.1. Bloqueo.....	503	16.2.1. Estructura	610
13.4.2. Control de concurrencia con ordenación de marcas temporales	504	16.2.2. Modelo de sincronización	612
13.4.3. Control de concurrencia optimista	505	16.2.3. Modelo de consistencia	612
13.5. Interbloqueos distribuidos.....	506	16.2.4. Opciones de actualización	616
13.6. Recuperación de transacciones.....	513	16.2.5. Granularidad	617
13.6.1. Registro histórico	515	16.2.6. <i>Thrashing</i> (fustigamiento)	619
13.6.2. Versiones sombra	518	16.3. Consistencia secuencial e Ivy	619
13.6.3. La necesidad de entradas del estado de la transacción y lista de intenciones en un archivo de recuperación	519	16.3.1. El modelo de sistema	619
13.6.4. Recuperación del protocolo de consumación en dos fases	520	16.3.2. Invalidación de escritura	621
13.7. Resumen	523	16.3.3. Protocolos de invalidación	622
Ejercicios	524	16.3.4. Un algoritmo de gestión distribuida dinámico	624
14. REPLICACIÓN	527	16.3.5. <i>Thrashing</i>	626
14.1. Introducción	528	16.4. Liberación de consistencia y Munin	626
14.2. Modelo de sistema y comunicación en grupo	530	16.4.1. Accesos a memoria	627
14.2.1. Modelo del sistema	530	16.4.2. Consistencia relajada	629
14.2.2. Comunicación en grupo	533	16.4.3. Munin	630
14.3. Servicios tolerantes a fallos	538	16.5. Otros modelos de consistencia	632
14.3.1. Replicación pasiva (primario-respaldo)	541	16.6. Resumen	633
14.3.2. Replicación activa	543	Ejercicios	634
14.4. Servicios con alta disponibilidad	545	17. EL CASO DE ESTUDIO CORBA	637
14.4.1. La arquitectura cotilla	545	17.1. Introducción	638
14.4.2. El sistema Bayou y la aproximación de la transformación operacional	554	17.2. CORBA RMI	638
14.4.3. El sistema de archivos Coda	556	17.2.1. Ejemplo de cliente y servidor CORBA	641
14.5. Transacciones con datos replicados	563	17.2.2. La arquitectura de CORBA	644
14.5.1. Arquitecturas para transacciones replicadas	564	17.2.3. Lenguaje de definición de interfaz de CORBA	647
14.5.2. Replicación de copias disponibles	566	17.2.4. Referencias a objetos remotos en CORBA	651
14.5.3. Particiones en la red	568	17.2.5. Correspondencia con el lenguaje en CORBA	652
14.5.4. Copias disponibles con validación	569	17.3. Servicios de CORBA	653
14.5.5. Métodos de consenso con quórum	570	17.3.1. El servicio de nombres de CORBA	654
14.5.6. El algoritmo de la partición virtual	572	17.3.2. Servicio de eventos de CORBA	657
14.6. Resumen	575	17.3.3. Servicio de notificación de CORBA	658
Ejercicios	576	17.3.4. Servicio de seguridad de CORBA	660
15. SISTEMAS MULTIMEDIA DISTRIBUIDOS	579	17.4. Resumen	661
15.1. Introducción	580	Ejercicios	661
15.2. Características de los datos multimedia	583	18. ESTUDIO DEL CASO: MACH	665
15.3. Gestión de la calidad de servicio	585	18.1. Introducción	666
15.3.1. Negociación de la calidad de servicio	587	18.1.1. Objetivos y principales características del diseño	667
15.3.2. Control de admisión	593	18.1.2. Repaso de las principales abstracciones de Mach	668
15.4. Gestión de recursos	594	18.2. Puertos, nombres y protección	669
15.4.1. Planificación de recursos	594	18.3. Tareas e hilos	671
15.5. Adaptación de caudales	596	18.4. Modelo de comunicación	672
15.5.1. Escalado	596	18.4.1. Mensajes	672
15.5.2. Filtrado	597	18.4.2. Puertos	674
15.6. Caso de estudio: el servidor de video Tiger	598	18.4.3. Mach_msg	675
15.7. Resumen	602	18.5. Implementación de la comunicación	676
Ejercicios	602	18.5.1. Gestión transparente de mensajes	676

18.5.2. Extensibilidad: protocolos y gestores de dispositivos	678
---	-----



PRÓLOGO

Esta tercera edición de nuestro libro de texto llega en un momento en el que los sistemas distribuidos, particularmente el Web y otras aplicaciones y servicios basados en Internet, aparecen con un vigor sin precedentes por su interés e importancia. El libro pretende proporcionar comprensión, y conocimiento, sobre los principios y la práctica que subyace en el diseño de los sistemas distribuidos, tanto basados en Internet como de cualquier otro tipo. Se proporciona información con suficiente profundidad como para permitir que los lectores evalúen sistemas existentes o diseñen otros nuevos. Los casos de estudios que se detallan esclarecen los conceptos de cada tema importante.

Las técnicas de sistemas distribuidos desarrolladas durante las últimas dos o tres décadas, tales como la comunicación entre procesos y la invocación remota, nomenclatura distribuida, seguridad criptográfica, sistemas de archivos distribuidos, replicación de datos y mecanismos de transacciones distribuidas, proporcionan la infraestructura de ejecución sobre la que se apoyan las aplicaciones de redes de computadoras de hoy en día.

El desarrollo de sistemas distribuidos confía cada vez más en el soporte del *middleware* mediante el uso de marcos de software que proporcionan abstracciones como objetos compartidos y servicios distribuidos, incluyendo comunicación segura, autenticación y control de acceso, código móvil, transacciones y mecanismos de almacenamiento persistente.

En un futuro cercano, las aplicaciones distribuidas posibilitarán una cooperación más inmediata entre los usuarios por medio de datos replicados y flujos de datos multimedia, dando soporte a la movilidad del usuario y de los dispositivos empleando redes inalámbricas y un funcionamiento en red espontáneo.

Los programadores de sistemas y aplicaciones distribuidas se benefician actualmente de un amplio abanico de lenguajes, herramientas y entornos útiles. Lo cual permite que tanto estudiantes como desarrolladores profesionales construyan aplicaciones distribuidas que funcionen.

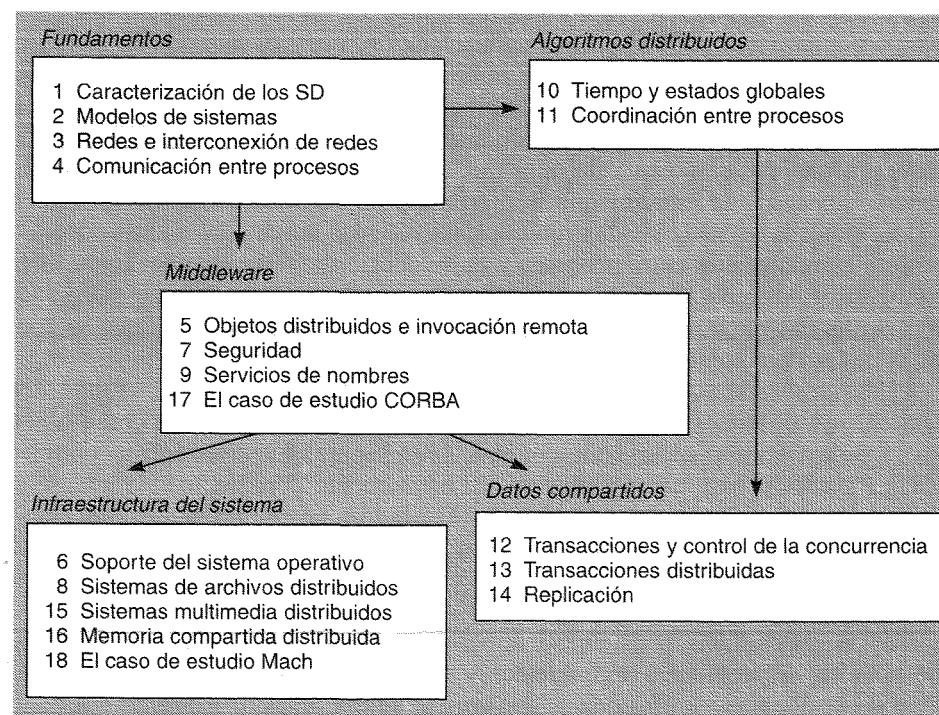
OBJETIVOS Y AUDIENCIA

Se pretende que el libro sea útil en cursos de graduación y de postgrado de carácter introductorio. También puede utilizarse como texto de autoestudio. En él tomamos una aproximación descendente, mostrando los temas que habrá que resolver en el diseño de los sistemas distribuidos y describiendo aproximaciones acertadas en forma de modelos abstractos, algoritmos y casos de estudio detallados sobre sistemas ampliamente usados. El campo se cubre con suficiente profundidad y amplitud como para permitir a los lectores continuar el estudio de la mayoría de los trabajos de investigación que se publican sobre sistemas distribuidos.

Intentamos que la materia sea suficientemente accesible a los estudiantes que tienen ya un conocimiento básico sobre programación orientada a objetos, sistemas operativos y arquitectura elemental de computadores. El libro incluye aquellos aspectos de redes de computadores que son relevantes a los sistemas distribuidos, incluyendo las tecnologías subyacentes a Internet, y redes de área extendida, área local e inalámbricas. Los algoritmos e interfaces que se presentan a lo largo del libro se encuentran escritos en Java o, en algún caso, ANSI C. Para brevedad y claridad de la presentación, también se utiliza pseudo-código derivado de Java y C.

ORGANIZACIÓN DEL LIBRO

El siguiente diagrama muestra los capítulos del libro bajo las cinco áreas de interés principales. Se pretende que el diagrama proporcione una guía de la estructura del libro e indique también de recorridos alternativos de lectura recomendables para aquellos instructores, y lectores, que deseen lograr una comprensión de los diversos campos del diseño de los sistemas distribuidos:



REFERENCIAS

La existencia del World Wide Web ha cambiado la forma en que cualquier libro como éste debe hacer mención de las fuentes documentales, incluyendo los artículos sobre investigación, especificaciones técnicas y estándares. Muchas de ellas están ahora disponibles en el Web; incluso algunas sólo están disponibles ahí. Por razones de brevedad y legibilidad, emplearemos una forma de referencia especial al material web y que se asemeja lejanamente a un URL: las referencias como [\[www.omg.org\]](http://www.omg.org) y [\[www.rsasecurity.com\]](http://www.rsasecurity.com) se refieren a documentación disponible en el Web.

Pueden buscarse en la lista de referencias al final de libro, aunque el URL completo sólo se puede obtener en la versión en línea de la lista de referencias en el lugar web del libro: www.cdk3.net/references, donde están en forma de enlaces vivos. Ambas versiones de la lista de referencias incluyen una explicación más detallada de este esquema.

Capítulos extendidos y reelaborados:

- 1 Caracterización de los SD
- 3 Redes e Interconexión de Redes
- 4 Comunicación entre Procesos
- 5 Objetos Distribuidos e Invocación Remota
- 7 Seguridad
- 10 Tiempo y estados globales
- 14 Replicación
- 2 Modelos de Sistemas
- 11 Coordinación y Acuerdo
- 15 Sistemas Multimedia Distribuidos
- 17 El Caso de Estudio CORBA

Capítulos completamente nuevos:

- 6 Soporte de Sistemas Operativos
- 8 Sistemas de Archivos Distribuidos
- 9 Servicios de Nombres
- 12 Transacciones y Control de la Concurrencia
- 13 Transacciones Distribuidas
- 16 Memoria Compartida Distribuida
- 18 El Caso de Estudio Mach

Capítulos actualizados:

CAMBIOS EN ESTA EDICIÓN

Esta tercera edición aparece aproximadamente seis años después de la segunda. En la tabla superior se resume el trabajo realizado. Los capítulos introductorios y algunos otros han sido modificados profundamente y se han incluido nuevos capítulos para reflejar perspectivas y direcciones novedosas. En otros capítulos se aprecia una profunda reorganización, que afecta a las cuestiones tratadas, la profundidad con que se cubren y la ubicación del material. Hemos condensado el material antiguo para introducir temas nuevos. Algunas materias han sido desplazadas a un plano más prominente para reflejar su nuevo nivel de importancia. Los casos de estudio eliminados de la segunda edición pueden encontrarse en el lugar web del libro como ya se ha comentado.

RECONOCIMIENTOS

Expresamos nuestro agradecimiento a los muchos cursos de estudiantes del College Queen Mary and Westfield College cuyas contribuciones en los seminarios y disertaciones nos han ayudado a producir esta nueva edición, así como las útiles sugerencias de muchos profesores de otros lugares. Kohei Honda probó el material preliminar en sus clases en el QMW y de ello resultaron algunos comentarios particularmente valiosos.

Los que se citan a continuación cedieron su tiempo desinteresadamente para revisar una parte sustancial del borrador final, de lo que se obtuvieron mejoras importantes: Ángel Álvarez, Dave Bakken, John Barton, Simon Boggis, Brent Callaghan, Keith Clarke, Kurt Jensen y Roger Prowse.

Queremos agradecer también a quienes dieron su permiso para emplear su material o sugirieron ciertos temas para su inclusión en este libro: Tom Berson, Antoon Bosselaers, Ralph Herrtwich,

CARACTERIZACIÓN DE LOS SISTEMAS DISTRIBUIDOS

- 1.1. Introducción
- 1.2. Ejemplos de sistemas distribuidos
- 1.3. Recursos compartidos y Web
- 1.4. Desafíos
- 1.5. Resumen

Un sistema distribuido es aquel en el que los componentes localizados en computadores, conectados en red, comunican y coordinan sus acciones únicamente mediante el paso de mensajes. Esta definición lleva a las siguientes características de los sistemas distribuidos: concurrencia de los componentes, carencia de un reloj global y fallos independientes de los componentes.

Proporcionamos tres ejemplos de sistemas distribuidos:

- Internet.
- Una intranet, que es una porción de Internet gestionada por una organización.
- La computación móvil y ubicua.

Compartir recursos es uno de los motivos principales para construir sistemas distribuidos. Los recursos pueden ser administrados por servidores y accedidos por clientes o pueden ser encapsulados como objetos y accedidos por otros objetos clientes. Se analiza el Web como un ejemplo de recursos compartidos y se introducen sus principales características.

Los desafíos que surgen en la construcción de sistemas distribuidos son la heterogeneidad de sus componentes, su carácter abierto, que permite que se puedan añadir o reemplazar componentes, la seguridad y la escalabilidad, que es la capacidad para funcionar bien cuando se incrementa el número de usuarios, el tratamiento de los fallos, la concurrencia de sus componentes y la transparencia.

Frederik Hirsch, Bob Hopgood, Ajay Kshemkalyan, Roger Needham, Mikael Petterson, Rick Schantz y David Wheeler.

Damos las gracias al Departamento de Ciencias de la Computación del Queen Mary and West-

Jean Dollimore

Tim Kindberg

Londres & Palo Alto, junio 2000

<authors@cdk3.net>

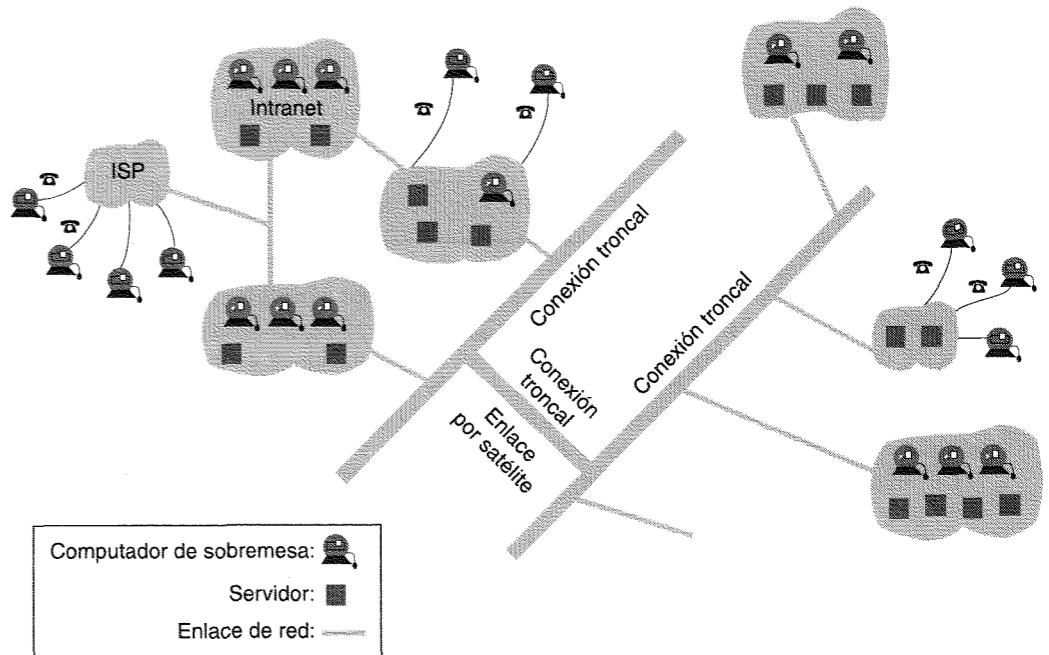


Figura 1.1. Una porción típica de Internet.

de software definidas como ficheros, bases de datos y objetos de datos de todos los tipos. Incluye la secuencia de imágenes que sale de una cámara de vídeo digital y la conexión de audio que representa una llamada de teléfono móvil.

El propósito de este capítulo es transmitir una visión clara de la naturaleza de los sistemas distribuidos y de los retos que deben ser considerados para asegurar que se alcanzan con éxito. La Sección 1.2 presenta algunos ejemplos fundamentales de sistemas distribuidos, los componentes de los que están formados y sus objetivos. La Sección 1.3 explora el diseño de sistemas de recursos compartidos en el contexto del World Wide Web. La Sección 1.4 describe los desafíos fundamentales a los que deben enfrentarse los diseñadores de sistemas distribuidos: heterogeneidad, carácter abierto, seguridad, escalabilidad, gestión de fallos, concurrencia y la necesidad de transparencia.

1.2. EJEMPLOS DE SISTEMAS DISTRIBUIDOS

Nuestros ejemplos están basados en redes de computadores conocidos y utilizados ampliamente: Internet, intranets y la tecnología emergente basada en dispositivos móviles. Se han elegido para proporcionar ejemplos del amplio rango de servicios y aplicaciones que son soportados por redes de computadores y para comenzar la discusión de las cuestiones técnicas que entraña su implementación.

1.2.1. INTERNET

Internet es una vasta colección de redes de computadores de diferentes tipos interconectados. La Figura 1.1 muestra una porción típica de Internet. Programas ejecutándose en los computadores conectados a ella interactúan mediante paso de mensajes, empleando un medio común de comuni-

cación. El diseño y la construcción de los mecanismos de comunicación Internet (los protocolos Internet) es una realización técnica fundamental, que permite que un programa que se está ejecutando en cualquier parte dirija mensajes a programas en cualquier otra parte.

Internet es también un sistema distribuido muy grande. Permite a los usuarios, donde quiera que estén, hacer uso de servicios como el World Wide Web, el correo electrónico, y la transferencia de ficheros (de hecho, a veces se confunde incorrectamente el Web con Internet). El conjunto de servicios es abierto, puede ser extendido por la adición de servidores y nuevos tipos de servicios. La figura nos muestra una colección de intranets, subredes gestionadas por compañías y otras organizaciones. Los proveedores de servicios de Internet (ISP¹) son empresas que proporcionan enlaces de módem y otros tipos de conexión a usuarios individuales y pequeñas organizaciones, permitiéndolas el acceso a servicios desde cualquier parte de Internet, así como proporcionando servicios como correo electrónico y páginas web. Las intranets están enlazadas conjuntamente por conexiones troncales (*backbones*). Una conexión o red troncal es un enlace de red con una gran capacidad de transmisión, que puede emplear conexiones de satélite, cables de fibra óptica y otros circuitos de gran ancho de banda.

En Internet hay disponibles servicios multimedia, que permiten a los usuarios el acceso a datos de audio y vídeo, incluyendo música, radio y canales de televisión y mantener videoconferencias. La capacidad de Internet para mantener los requisitos especiales de comunicación de los datos multimedia es actualmente bastante limitada porque no proporciona la infraestructura necesaria para reservar capacidad de la red para flujos individuales de datos. En el Capítulo 15 se discute la necesidad de sistemas distribuidos multimedia.

La implementación de Internet y los servicios que mantiene ha implicado el desarrollo de soluciones prácticas para muchas cuestiones de sistemas distribuidos (incluyendo la mayoría de las definidas en la Sección 1.4). Nosotros destacaremos esas soluciones a lo largo del libro, señalando su ámbito y sus limitaciones cuando sea apropiado.

1.2.2. INTRANETS

Una intranet es una porción de Internet que es, administrada separadamente y que tiene un límite que puede ser configurado para hacer cumplir políticas de seguridad local. La Figura 1.2 muestra una intranet típica. Está compuesta de varias redes de área local (LANs) enlazadas por conexiones backbone. La configuración de red de una intranet particular es responsabilidad de la organización que la administra y puede variar ampliamente, desde una LAN en un único sitio a un conjunto de LANs conectadas perteneciendo a ramas de la empresa u otra organización en diferentes países.

Una intranet está conectada a Internet por medio de un encaminador (*router*), lo que permite a los usuarios hacer uso de servicios de otro sitio como el Web o el correo electrónico. Permite también acceder a los servicios que ella proporciona a los usuarios de otras intranets. Muchas organizaciones necesitan proteger sus propios servicios frente al uso no autorizado por parte de usuarios maliciosos de cualquier lugar. Por ejemplo, una empresa no querrá que la información segura esté accesible para los usuarios de organizaciones competidoras, y un hospital no querrá que los datos sensibles de los pacientes sean revelados. Las empresas también quieren protegerse a sí mismas de que programas nocivos, como los virus, entren y ataquen los computadores de la intranet y posiblemente destrocen datos valiosos.

El papel del *cortafuegos* es proteger una intranet impidiendo que entren o salgan mensajes no autorizados. Un cortafuegos se implementa filtrando los mensajes que entran o salen, por ejemplo de acuerdo con su origen o destino. Un cortafuegos podría permitir, por ejemplo, sólo aquellos mensajes relacionados con el correo electrónico o el acceso web para entrar o salir de la intranet que protege.

¹ ISP es el acrónimo de Internet Service Providers.

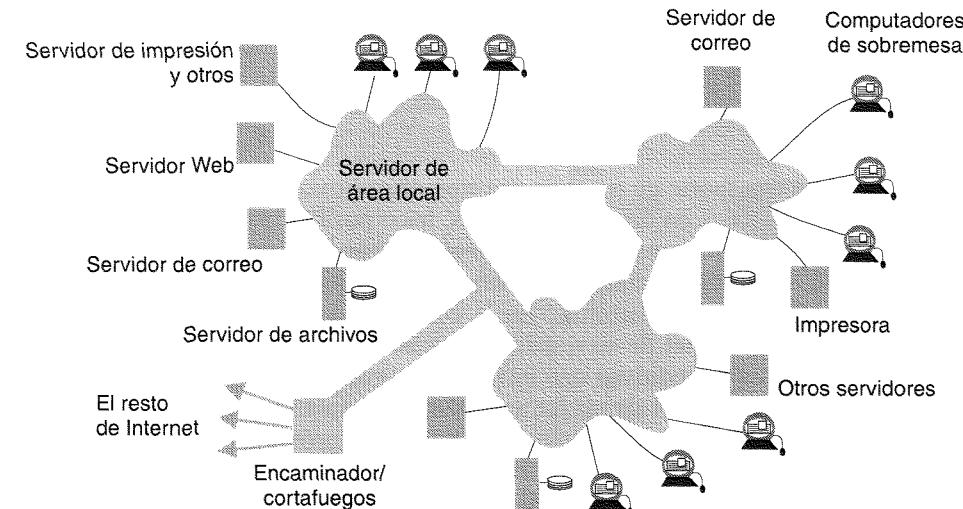


Figura 1.2. Una intranet típica.

Algunas organizaciones no desean conectar sus redes internas a Internet. Por ejemplo, la policía y otras agencias para la seguridad y la vigilancia de la ley prefieren disponer de algunas redes internas que están aisladas del mundo exterior, y el Servicio Nacional de Salud del Reino Unido ha tomado la opción de que los datos médicos sensibles relacionados con los pacientes sólo pueden ser protegidos adecuadamente manteniéndolos en una red interna separada físicamente. Algunas organizaciones militares desconectan sus redes internas de Internet en tiempos de guerra. Pero incluso dichas organizaciones desearán beneficiarse del amplio rango de aplicaciones y software de sistemas que emplean los protocolos de Internet. La solución que se adopta en tales organizaciones es realizar una intranet como se ha indicado, pero sin conexiones a Internet. Tal intranet puede prescindir de cortafuegos, o, dicho de otro modo, dispone del cortafuegos más efectivo posible, la ausencia de cualquier conexión física a Internet.

Los principales temas relacionados con el diseño de componentes para su uso en intranets son:

- Los servicios de ficheros son necesarios para permitir a los usuarios compartir datos, el diseño de éstos se discutirá en el Capítulo 8.
- Los cortafuegos tienden a impedir el acceso legítimo a servicios, cuando se precisa compartir recursos entre usuarios externos e internos, los cortafuegos deben ser complementados con el uso de mecanismos de seguridad más refinados, que se verán en el Capítulo 7.
- El coste de instalación y mantenimiento del software es una cuestión importante. Estos costes pueden ser reducidos utilizando arquitecturas de sistema como redes de computadores y clientes ligeros, descritos en el Capítulo 2.

1.2.3. COMPUTACIÓN MÓVIL Y UBICUA

Los avances tecnológicos en la miniaturización de dispositivos y en redes inalámbricas han llevado cada vez más a la integración de dispositivos de computación pequeños y portátiles en sistemas distribuidos. Estos dispositivos incluyen:

- Computadores portátiles.
- Dispositivos de mano (*handheld*), entre los que se incluyen asistentes digitales personales (PDA), teléfonos móviles, buscapersonas y videocámaras o cámaras digitales.

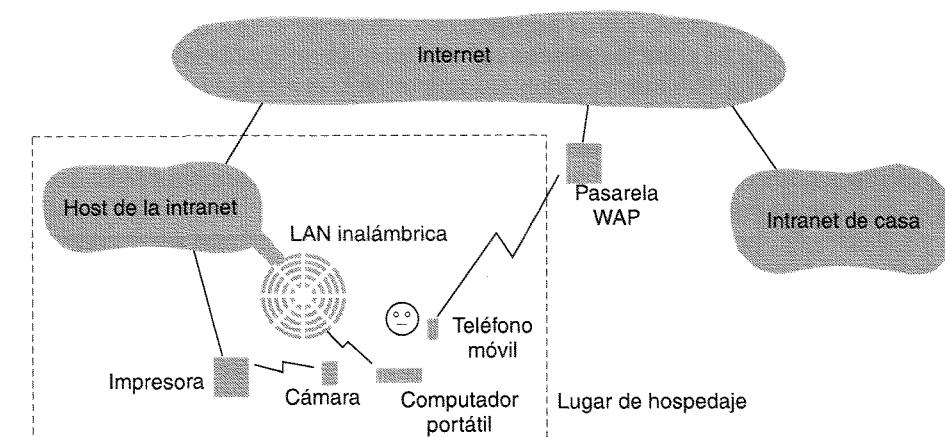
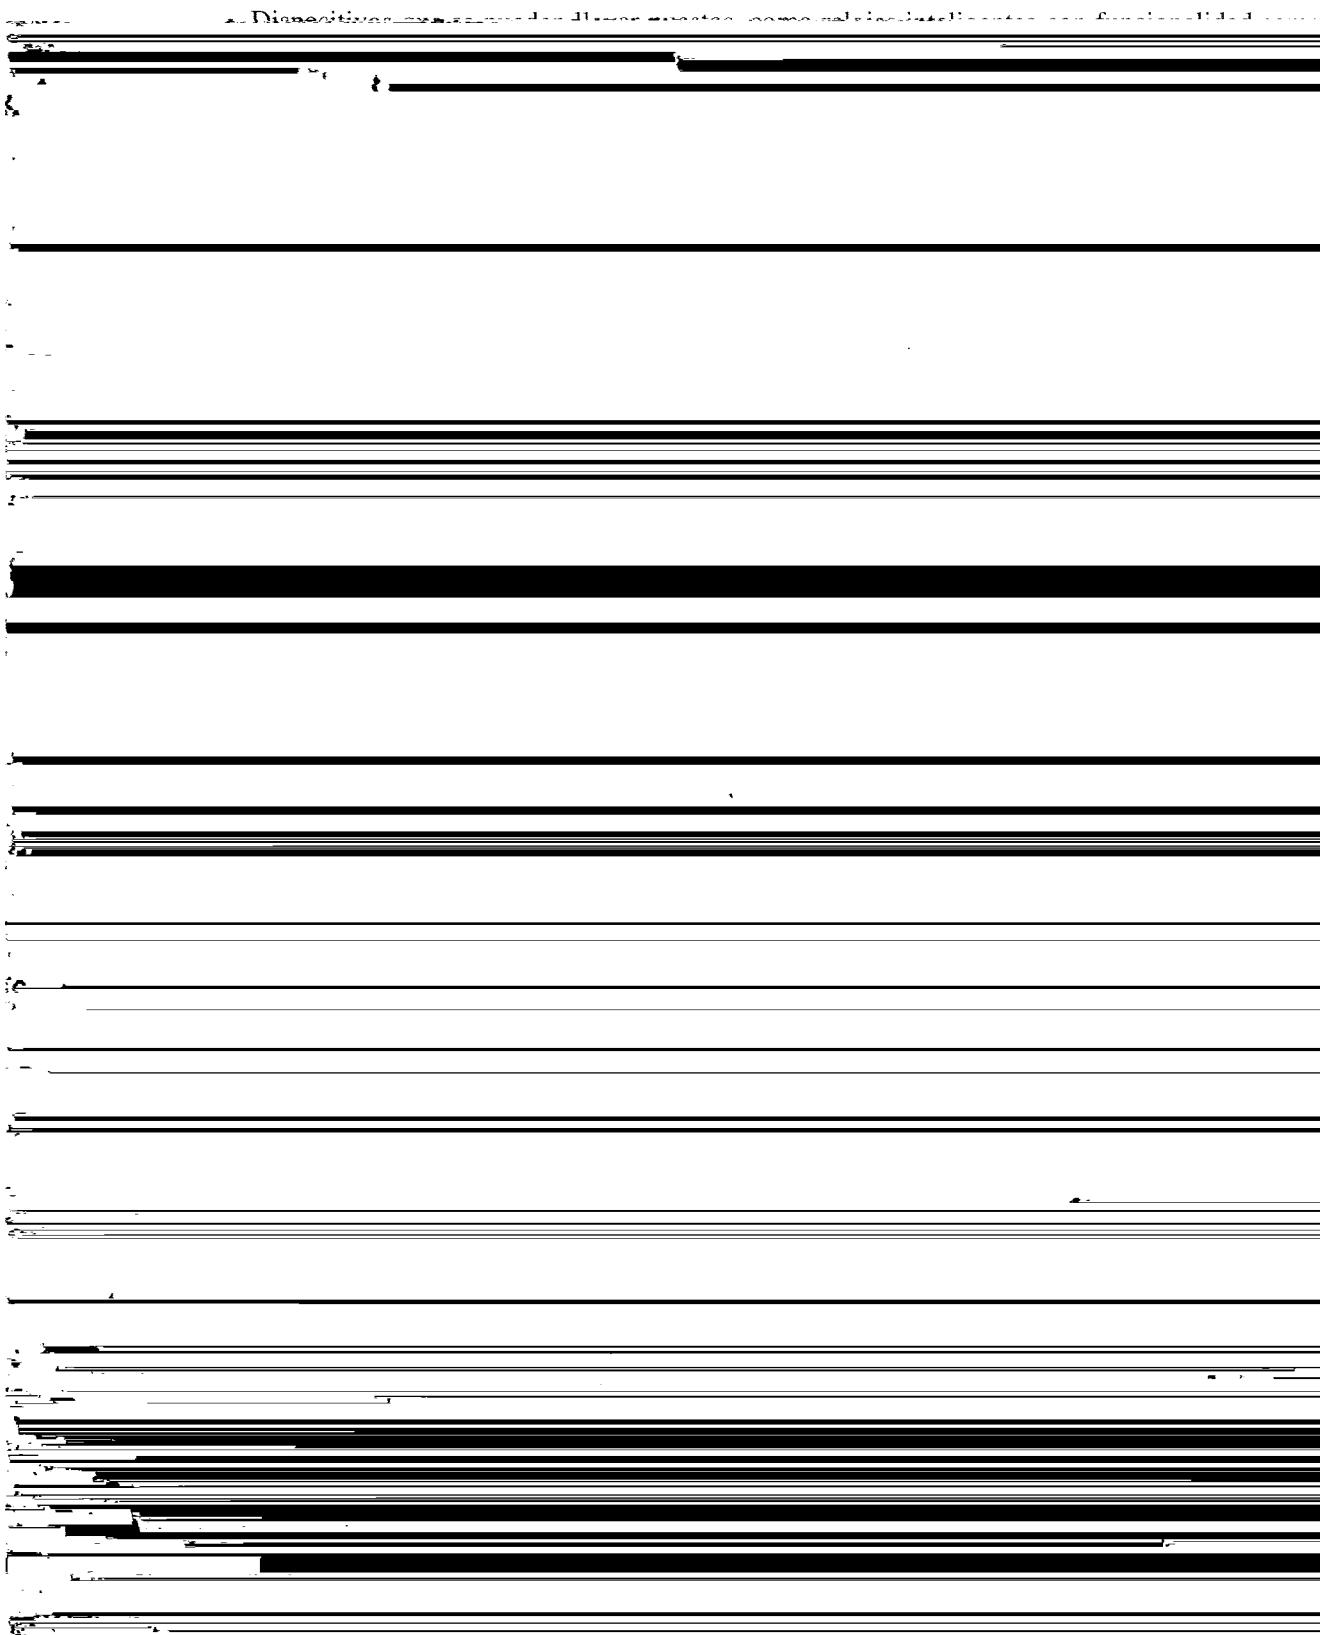


Figura 1.3. Dispositivos portátiles y de mano en un sistema distribuido.

desde un computador portátil a la misma impresora utilizando la red inalámbrica y enlaces cableados de Internet a la impresora.

La computación móvil y ubicua plantea temas significativos sobre el sistema [Milojicic y otros 1999, p. 266, Weiser 1993]. La Sección 2.2.3 presenta una arquitectura para computación móvil y esboza los temas que se plantean desde ella, incluyendo cómo realizar el descubrimiento de recursos en un entorno anfitrión, eliminando la necesidad de que los usuarios reconfiguren sus dispositivos móviles a medida que se mueven, ayudándoles a arreglárselas con la conectividad limitada cuando viajan, y proporcionándoles garantías de privacidad y seguridad a ellos y a los entornos que visitan.

1.3. RECURSOS COMPARTIDOS Y WEB

Los usuarios están tan acostumbrados a los beneficios de compartir recursos que pueden pasar por alto su significado. Normalmente compartimos recursos hardware como impresoras, recursos de datos como ficheros, y recursos con una funcionalidad más específica como máquinas de búsqueda.

Considerado desde el punto de vista de la provisión de hardware, se comparten equipos como impresoras y discos para reducir costes. Pero es mucho más significativo para los usuarios compartir recursos de alto nivel que forman parte de sus aplicaciones y su trabajo habitual y sus actividades sociales. Por ejemplo, los usuarios están preocupados con compartir datos en forma de una base de datos compartida o un conjunto de páginas web, no los discos o los procesadores sobre los que están implementados. Igualmente, los usuarios piensan en términos de recursos como una máquina de búsqueda o un conversor de monedas, sin considerar el servidor o servidores que los proporcionan.

En la práctica, los patrones de compartir recursos varían mucho en su alcance y cuán estrechamente trabajan juntos los usuarios. En un extremo, una máquina de búsqueda en el Web proporciona una función para los usuarios en todo el mundo, los usuarios no necesitan establecer contacto con los demás directamente. En el otro extremo, en un sistema de trabajo *cooperativo mantenido por computador* (CSCW, *computer-supported cooperative working*), un grupo de usuarios que colaboran directamente entre ellos comparte recursos como documentos en un grupo pequeño y cerrado. El patrón de compartir y la distribución geográfica de los usuarios particulares determina qué mecanismos debe proporcionar el sistema para coordinar sus acciones.

Utilizamos el término *servicio* para una parte diferente de un sistema de computadores que gestiona una colección de recursos relacionados y presenta su funcionalidad a los usuarios y aplicaciones. Por ejemplo, accedemos a ficheros compartidos mediante el servicio de ficheros, enviamos documentos a las impresoras a través del servicio de impresión, compramos regalos a través de un servicio de pago electrónico. El único acceso que tenemos al servicio es mediante un conjunto de operaciones que él ofrece. Por ejemplo, un servicio de ficheros proporciona las operaciones de *lectura, escritura y borrado* en los ficheros.

El hecho de que los servicios limiten el acceso a los recursos a un conjunto bien definido de operaciones es una práctica habitual en la ingeniería de software. Pero también refleja la organización física de los sistemas distribuidos. Los recursos en un sistema distribuido están encapsulados físicamente con los computadores y sólo pueden ser accedidos desde otros computadores a través de comunicación. Para que se compartan de forma efectiva, cada recurso debe ser gestionado por un programa que ofrece una interfaz de comunicación permitiendo que se acceda y actualice el recurso de forma fiable y consistente.

El término *servidor* es probablemente familiar para la mayoría de los lectores. Se refiere a un programa en ejecución (un *proceso*) en un computador en red que acepta peticiones de programas que se están ejecutando en otros computadores para realizar un servicio y responder adecuadamente. Los procesos solicitantes son llamados *clientes*. Las peticiones se envían a través de mensajes desde los clientes al servidor y las contestaciones se envían mediante mensajes desde el servidor a los clientes. Cuando un cliente envía una petición para que se realice una operación, decimos que el cliente *invoca una operación* del servidor. Se llama *invocación remota* a una interacción completa entre un cliente y un servidor, desde el instante en el que el cliente envía su petición hasta que recibe la respuesta del servidor.

El mismo proceso puede ser tanto un cliente como un servidor, puesto que los servidores a veces invocan operaciones en otros servidores. Los términos *cliente* y *servidor* se aplican a los roles desempeñados en una única solicitud. Ambos son distintos, en muchos aspectos, los clientes son activos y los servidores pasivos, los servidores se están ejecutando continuamente, mientras que los clientes sólo lo hacen el tiempo que duran las aplicaciones de las que forman parte.

Hay que señalar que por defecto los términos *cliente* y *servidor* se refieren a *procesos* no a los computadores en las que se ejecutan, aunque en lenguaje coloquial dichos términos se refieren también a los propios computadores. Otra distinción que se discutirá en el Capítulo 5, es que en un sistema distribuido escrito en un lenguaje orientado a objetos, los recursos pueden ser encapsulados como objetos y accedidos por objeto clientes, en cuyo caso hablaremos de un *objeto cliente* que invoca un método en un *objeto servidor*.

Muchos sistemas distribuidos, aunque no todos, pueden ser construidos completamente en forma de clientes y servidores que interactúan. El World Wide Web, el correo electrónico y las impresoras en red concuerdan con este modelo. En el Capítulo 2 se verán alternativas a los sistemas cliente-servidor.

Un navegador (*browser*) es un ejemplo de cliente. El navegador se comunica con el servidor web para solicitarle páginas. A continuación se examina el Web con más detalle.

1.3.1. EL WORLD WIDE WEB

El World Wide Web [www.w3.org I, Berners-Lee 1991] es un sistema en evolución para publicar y acceder a recursos y servicios a través de Internet. Utilizando el software de un navegador web, fácilmente disponible como Netscape o Internet Explorer, los usuarios utilizan el Web para recuperar y ver documentos de muchas clases, para escuchar secuencias de audio y ver secuencias de vídeo, y para interactuar con un conjunto ilimitado de servicios.

El Web comenzó su vida en el centro europeo para la investigación nuclear (CERN), Suiza, en 1989 como un vehículo para el intercambio de documentos entre una comunidad de físicos, conec-

tados a Internet [Berners-Lee 1999]. Una característica fundamental del Web es que proporciona una estructura *hipertexto* entre los documentos que almacena, reflejando los requisitos de los usuarios para organizar su conocimiento. Esto significa que los documentos tienen *enlaces*, referencias a otros documentos y recursos, también almacenados en la red.

Es fundamental para la experiencia del usuario en el Web que cuando encuentra una imagen determinada o una parte de texto en un documento, esto estará acompañado de enlaces a documentos relacionados y otros recursos. La estructura de los enlaces puede ser arbitrariamente compleja y el conjunto de recursos que puede ser añadido es ilimitado, la «telaraña» (web) de enlaces está por consiguiente repartida por todo el mundo (world-wide). Bush [1945] concibió las estructuras hipertextuales hace 50 años; el desarrollo de Internet fue lo que propició la manifestación de esta idea en una escala mundial.

El Web es un sistema *abierto*: puede ser ampliado e implementado en nuevas formas sin modificar su funcionalidad existente (véase la Sección 1.4.2). Primero, su operación está basada en estándares de comunicación y en documentos estándar que están publicados libremente e implementados ampliamente. Por ejemplo, existen muchos tipos de navegador, cada uno de ellos implementados en muchos casos sobre diferentes plataformas; y existen muchas implementaciones de servidores web. Cualquier navegador conforme puede recuperar recursos de cualquier servidor conforme. Por lo tanto los usuarios pueden tener acceso a los navegadores en la mayoría de los dispositivos que utilizan, desde un PDA a computadores portátiles.

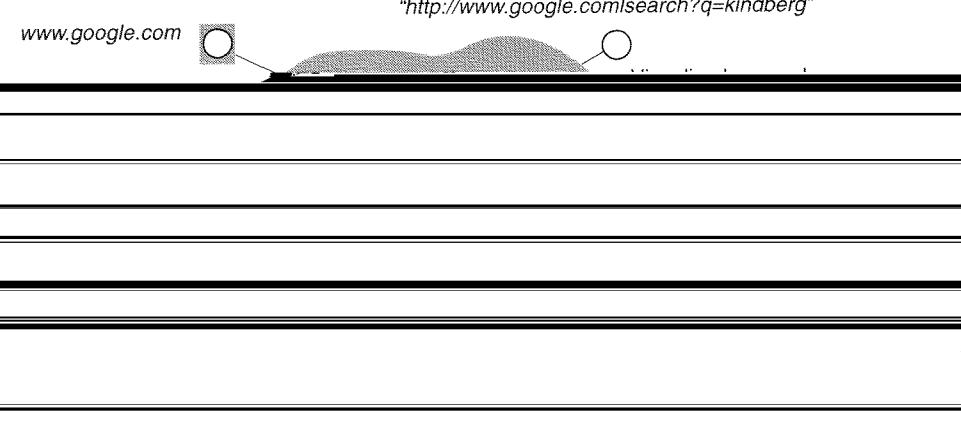
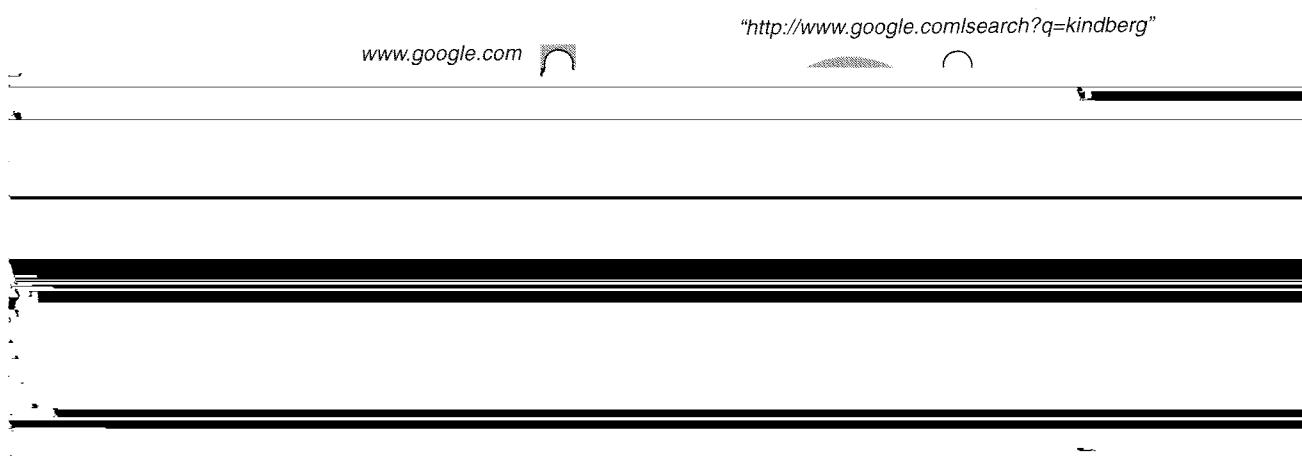
Segundo, el Web es abierto respecto a los tipos de recursos que pueden ser publicados y compartidos en él. En su forma más simple, un recurso es una página web o algún otro tipo de *contenido* que puede ser almacenado en un fichero y presentado al usuario, como ficheros de programa, de imágenes, de sonido y documentos en formato PostScript o PDF. Si alguien inventa, por ejemplo, un nuevo formato de almacenamiento de imágenes, las imágenes en dicho formato pueden ser publicadas inmediatamente en el Web. Los usuarios necesitan un medio de ver imágenes en este nuevo formato, pero los navegadores están diseñados para acomodar la nueva funcionalidad de presentación en forma de aplicaciones *colaboradoras* y conectores (*plug-ins*).

El Web se ha desarrollado más allá de estos recursos de datos sencillos para abarcar servicios como la compra electrónica de regalos. Ha evolucionado sin cambiar su arquitectura básica. El Web está basado en tres componentes tecnológicos de carácter estándar básicos:

- El lenguaje de etiquetado de hipertexto (HTML, *Hypertext Markup Language*) es un lenguaje para especificar el contenido y el diseño de las páginas que son mostradas por los navegadores.
- Localizadores Uniformes de Recursos (URL, *Uniform Resource Locator*) que identifican documentos y otros recursos almacenados como parte del Web. El Capítulo 9 examina otros identificadores web.
- Una arquitectura de sistema cliente-servidor, con reglas estándar para interacción (el protocolo de transferencia hipertexto-HTTP, *HyperText Transfer Protocol*) mediante la cual los navegadores y otros clientes obtienen documentos y otros recursos de los servidores web. La Figura 1.4 muestra algunos servidores web, y navegadores que les hacen peticiones. Una característica importante es que los usuarios puedan localizar y gestionar sus propios servidores web en cualquier parte de Internet.

A continuación se detallan estos componentes y se explica la operación de los navegadores y servidores web cuando un usuario localiza páginas web y selecciona los enlaces que contiene.

◊ **HTML.** El lenguaje de etiquetado de hipertexto [www.w3.org II] se utiliza para especificar el texto e imágenes que forman el contenido de una página web, y para especificar cómo serán formateados para la presentación al usuario. Una página web contiene elementos estructurados como cabeceras, párrafos, tablas e imágenes. HTML se utiliza también para especificar enlaces y qué recursos están asociados con ellos.



El navegador registra la asociación entre el texto mostrado del enlace y el URL contenido en la etiqueta `<A HREF...>`, en este caso:

`http://www.cdk3.net/WebExample/moon.html`

Cuando el usuario selecciona el texto, el navegador localiza el recurso identificado por el correspondiente URL y se lo presenta. En el ejemplo, el recurso es un fichero HTML que especifica una página sobre la Luna.

◊ **URLs.** El propósito de un URL [www.w3.org III] es identificar un recurso de tal forma que permita al navegador localizarlo. Los navegadores examinan los URLs con el fin de buscar los recursos correspondientes de los servidores web. A veces el usuario teclea un URL en el navegador. Habitualmente, el navegador busca el URL correspondiente cuando el usuario hace clic en un enlace o selecciona uno de sus enlaces anotados (*bookmarks*), o cuando el navegador busca un recurso insertado en una página web, como una imagen.

Cada URL, en su forma global, tiene dos componentes:

esquema: localización-específica-del-esquema.

El primer componente, el *esquema*, declara qué tipo de URL es. Se precisan los URLs para especificar posiciones de una variedad de recursos y también para especificar una variedad de protocolo de comunicación para recuperarlos. Por ejemplo, `mailto:joe@anISP.net` identifica la dirección de correo de un usuario; `ftp://ftp.downloadIt.com/software/aProg.exe` identifica un fichero que será recuperado utilizando el Protocolo de Transferencia de Ficheros (FTP, *File Transfer Protocol*) en lugar de HTTP, utilizado con más frecuencia. Otros ejemplos de esquemas son `nntp` (utilizado para especificar un grupo de noticias de Usenet), y `telnet` (utilizado para hacer log in en un computador).

El Web es abierto con respecto a los tipos de recursos que pueden ser utilizados para acceder, mediante los designadores de esquema de los URLs. Si alguien inventa un nuevo tipo de recurso llamémoslo *artefacto*, quizás con su propio esquema de direccionamiento para localizar artefactos y su propio protocolo para acceder a ellos, entonces la gente puede comenzar a utilizar URLs de la forma *artefacto*:.... Como es lógico, los navegadores deben disponer de la capacidad para utilizar el nuevo protocolo *artefacto*, pero esto se puede conseguir añadiendo una aplicación colaboradora o un conector.

Los URLs de HTTP son los más utilizados para localizar recursos utilizando el protocolo estándar HTTP. Un URL HTTP tiene dos tareas importantes que hacer: identificar qué servidor Web mantiene el recurso, e identificar cuál de los recursos del servidor es el solicitado. En la Figura 1.4 se ven tres servidores haciendo peticiones por recursos gestionados por tres servidores web. El web en la parte superior está realizando una consulta a una máquina de búsqueda. El del medio solicita la página por defecto de otro sitio web. El de la parte inferior solicita una página que está especificada completamente, con la inclusión de un nombre de recorrido relativo para el servidor. Los ficheros para un servidor web determinado se localizan en uno o más subdirectorios del sistema de ficheros del servidor, y cada recurso es identificado por el nombre del recorrido del fichero (*path name*) relativo al servidor.

En general, los URLs de HTTP son de la forma:

`http://nombredelservidor [:puerto] [/nombredelpathdelservidor] [?argumentos]`

en el que los elementos entre corchetes son opcionales. Un URL de HTTP siempre comienza con «`http://`» seguido por un nombre del servidor, expresado como un nombre del Servicio de Nombres de Dominio (DNS, *Domain Name Service*) (véase la Sección 9.2). El nombre DNS del servidor

está seguido opcionalmente por el nombre del «puerto» en el que el servidor escucha las solicitudes (véase el Capítulo 4). Después viene un nombre de recorrido opcional del recurso del servidor. Si éste no aparece se solicita la página web por defecto del servidor. Por último, el URL finaliza opcionalmente con un conjunto de argumentos, por ejemplo, cuando un usuario envía las entradas en una forma como una página de consulta de una máquina de búsqueda.

Considérense los URLs:

`http://www.cdk3.net/`
`http://www.w3.org/Protocols/Activity.html`
`http://www.google.com/search?q=kindberg`

Pueden ser separados de la forma siguiente:

Nombre del servidor de DNS	Ruta en el servidor	Argumentos
www.cdk3.net	(por defecto)	(ninguno)
www.w3.org	Protocols/Activity.html	(ninguno)
www.google.com	search	q=kindberg

El primer URL indica la página por defecto proporcionada por `www.cdk3.net`. El siguiente identifica un fichero en el servidor `www.w3.org`, cuyo nombre de recorrido es `Protocols/Activity.html`. El tercer URL especifica una consulta a una máquina de búsqueda. El recorrido identifica un programa llamado `search` y la cadena de caracteres después del carácter `?` codifica los argumentos para este programa, en este caso especifica la cadena de búsqueda. Se discutirán los URL que indican programas con más detalle cuando se analicen características más avanzadas.

Los lectores pueden haber observado también la presencia de un ancla al final de un URL, un nombre procedido por un `#` como `#referencias`, que indica un punto dentro de un documento. Las anclas no son parte de los URLs sino que están definidas como una parte de la especificación HTML. Únicamente los navegadores interpretan anclas, para colocar en pantalla páginas web a partir de un punto determinado. Los navegadores siempre recuperan páginas web completas de los servidores, no partes de ellas indicadas por anclas.

Publicación de un recurso: Mientras el Web tiene un modelo claro para recuperar un recurso a partir de su URL, el método para publicar un recurso en el Web todavía es difícil de manejar y normalmente precisa intervención humana. Para publicar un recurso en el Web, un usuario debe colocar, en primer lugar, el correspondiente fichero en un directorio al que pueda acceder el servidor web. Conocido el nombre de un servidor *S* y un nombre de recorrido *P* que el servidor puede reconocer, el usuario puede construir el URL de la forma `http://S/P`. El usuario coloca este URL en un enlace de un documento existente o distribuye el URL a otros usuarios, por ejemplo mediante correo electrónico.

Existen unas ciertas convenciones para nombres de recorrido que los servidores reconocen. Por ejemplo, un nombre de recorrido comenzando por `~juan` está por convención en un subdirectorio `public-html` del usuario juan. De forma similar, un nombre de recorrido que termina en un nombre de directorio en lugar de un único fichero se refiere a un fichero en ese directorio llamado `index.html`.

Huang y otros [2000] proporcionan un modelo para insertar contenido en el Web con la mínima intervención humana. Esto es particularmente relevante allí donde los usuarios necesitan extraer contenido de una variedad de dispositivos, como cámaras, para su publicación en páginas web.

◊ **HTTP.** El protocolo de transferencia hipertexto [www.w3.org IV] define las formas en las que los navegadores y otros tipos de clientes interaccionan con los servidores web. En el Capítulo 4 se

verá HTTP con más detalle, pero aquí se esbozan sus principales características (restringiendo la discusión a la recuperación de recursos en ficheros):

Interacciones petición-respuesta: HTTP es un protocolo de petición-respuesta. El cliente envía un mensaje de petición al servidor que contiene el URL del recurso solicitado. (El servidor sólo precisa la parte del URL que sigue al propio nombre DNS del servidor.) El servidor localiza el nombre de recorrido y, si existe, devuelve el contenido del fichero en un mensaje de respuesta al cliente. En caso contrario, devuelve un mensaje de error.

Tipos de contenido: los navegadores no son necesariamente capaces de manejar o hacer buen uso de cualquier tipo de contenido. Cuando un navegador hace una petición, incluye una lista de los tipos de contenido que prefiere, por ejemplo, en principio puede ser capaz de sacar en pantalla imágenes en formato *GIF* pero no en *JPEG*. El servidor puede ser capaz de tener esto en cuenta cuando devuelve el contenido al navegador. El servidor incluye el tipo de contenido en el mensaje de respuesta de forma que el navegador sabrá cómo procesarlo. Las cadenas de caracteres que indican el tipo de contenido se llaman tipos MIME, y están estandarizados en el RFC 1521 [Borenstein y Freed 1993]. Por ejemplo, si el contenido es de tipo *text/html* entonces el navegador interpretará el texto como HTML y lo mostrará en pantalla; si el contenido es de tipo *image/GIF* el navegador lo tratará como una imagen en formato *GIF*, si el contenido es de tipo *application/zip* entonces los datos están comprimidos en formato *zip* y el navegador lanzará una aplicación externa para descomprimirlos. El conjunto de acciones que un navegador tomará para un tipo de contenido dado es configurable, y los lectores deben preocuparse de comprobar estos defectos en sus propios navegadores.

Un recurso por solicitud: en la versión 1.0 de HTTP (que es la versión más utilizada en el momento en que se escribe esto), el cliente solicita un recurso por cada petición HTTP. Si una página web contiene nueve imágenes, por ejemplo, el navegador realizará un total de diez peticiones separadas para obtener el contenido completo de la página. Los navegadores normalmente hacen varias peticiones concurrentemente, para reducir el retardo total para el usuario.

Control de acceso simple: por defecto, cualquier usuario con una conexión de red a un servidor web puede acceder a cualquiera de los recursos publicados. Si los usuarios desean restringir el acceso a un recurso, pueden configurar el servidor para plantear un desafío a cualquier usuario que lo pida. Los usuarios correspondientes deben probar entonces que tienen derecho para acceder al recurso, por ejemplo tecleando una contraseña (*password*).

◊ **Características más avanzadas, servicios y páginas dinámicas.** Hasta ahora hemos descrito cómo los usuarios pueden publicar páginas Web y otros contenidos almacenados en ficheros en el Web. El contenido puede cambiar en el tiempo, pero es lo mismo para cualquiera. Sin embargo, mucha de la experiencia de los usuarios del Web es la de los servicios con los que el usuario puede interactuar. Por ejemplo, cuando se compra algo en una tienda electrónica, el usuario rellena con frecuencia un *formulario web* para proporcionar sus detalles personales o para especificar exactamente lo que se desea comprar. Un formulario web es una página que contiene instrucciones para el usuario y elementos para la introducción de datos como campos de texto y cajas de comprobación. Cuando un usuario envía el formulario (normalmente pulsando un botón o una tecla de *retorno* (*return*)), el navegador envía una petición HTTP a un servidor web, que contiene los valores enviados por el usuario.

Puesto que el resultado de la petición depende de los datos introducidos por el usuario, el servidor debe *procesar* dichos datos. Por tanto, el URL o su componente inicial representa un *programa* en el servidor, no un archivo. Si los datos introducidos por el usuario son pocos, entonces son enviados como el componente final del URL, siguiendo a un carácter `?` (en el resto de los casos son

enviados como datos adicionales en la petición). Por ejemplo, una solicitud que contenga el URL

enviados como datos adicionales en la petición). Por ejemplo, una solicitud que contenga el URL siguiente llama a un programa llamado *search* en www.google.com y especifica una consulta para

herramientas que asistirían a los usuarios que procesaran recursos web *masivamente*, tal como ocurre al buscar y recopilar listas de enlaces relacionados.

Existe una necesidad creciente de intercambio de muchos tipos de datos estructurados en el Web, pero HTML se encuentra limitado en que no es extensible a aplicaciones más allá de la «inspección» de la información. HTML consta de un conjunto estático de estructuras tales como los párrafos, que se limitan a indicar la forma en que se presentan los datos a los usuarios. Más recientemente se ha diseñado el Lenguaje de Marcado Extensible (*Extensible Markup Language, XML*) [www.w3.org VI] como medio de representar datos en formularios estándar, estructurados, y específicos para cada aplicación. Pongamos por ejemplo que XML se emplee para describir las características de ciertos dispositivos y para describir información personal almacenada acerca de los usuarios. XML es un metalenguaje de descripción de datos, lo cual hace que los datos sean intercambiables entre aplicaciones. El Lenguaje Extensible de Hojas de Estilo (*Extensible Stylesheet Language, XSL*) [www.w3.org VII] se emplea para declarar cómo serán presentados a los usuarios los datos almacenados en el formato XML. Por ejemplo, empleando dos hojas de estilo diferentes, la misma información sobre un usuario concreto podría presentarse en una página web bien gráficamente bien como una simple lista.

Como arquitectura del sistema, el Web plantea problemas de escala. Los servidores web más populares pueden experimentar muchos *accesos* por segundo, y como resultado la respuesta a los usuarios se ralentiza. El Capítulo 2 describe el empleo de memorias (caché) en los visualizadores y de servidores *proxy* para aliviar estos efectos. A pesar de ello la arquitectura cliente-servidor del Web implica que no hay medios eficientes para mantener a los usuarios al día con las últimas versiones de las páginas. Los usuarios tienen que presionar el botón de *recarga* de su navegador para asegurar que poseen la última información, y éstos se ven forzados a comunicarse con los servidores para comprobar si la copia local del recurso es válida aún.

Finalmente, una página web no siempre es una interfaz de usuario satisfactoria. Los elementos de diálogo definidos para HTML son limitados, y los diseñadores incluyen a menudo en la páginas web, pequeñas aplicaciones, o applets, o bien muchas imágenes para darles una función y apariencia más aceptable. Consecuentemente el tiempo de carga se incrementa.

1.4. DESAFÍOS

Los ejemplos de la Sección 1.2 pretenden ilustrar el alcance de los sistemas distribuidos y sugerir las cuestiones que aparecen en su diseño. Aunque se encuentran sistemas distribuidos por todas partes, su diseño es aún bastante simple y quedan todavía grandes posibilidades de desarrollar servicios y aplicaciones más ambiciosas. Muchos de los desafíos que se discuten en esta sección están ya resueltos, pero los futuros diseñadores necesitan estar al tanto y tener cuidado de considerarlos.

1.4.1. HETEROGENEIDAD

Internet permite que los usuarios accedan a servicios y ejecuten aplicaciones sobre un conjunto heterogéneo de redes y computadores. Esta heterogeneidad (es decir, variedad y diferencia) se aplica a todos los siguientes elementos:

- Redes.
- Hardware de computadores.
- Sistemas operativos.
- Lenguajes de programación.
- Implementaciones de diferentes desarrolladores.

A pesar de que Internet consta de muchos tipos de redes diferentes (como vimos en la Figura 1.1), sus diferencias se encuentran enmascaradas dado que todos los computadores conectados a éste utilizan los protocolos de Internet para comunicarse una con otra. Por ejemplo, un computador conectado a Ethernet tiene una implementación de los protocolos de Internet sobre Ethernet, así un computador en un tipo de red diferente necesitará una implementación de los protocolos de Internet para esa red. El Capítulo 3 explica cómo se implementan los protocolos de Internet sobre una variedad de redes diferentes.

Los tipos de datos, como los enteros, pueden representarse de diferente forma en diferentes clases de hardware por ejemplo, hay dos alternativas para ordenar los bytes en el caso de los enteros. Hay que tratar con estas diferencias de representación si se va a intercambiar mensajes entre programas que se ejecutan en diferente hardware.

Aunque los sistemas operativos de todas los computadores de Internet necesitan incluir una implementación de los protocolos de Internet, no todas presentan necesariamente la misma interfaz de programación para estos protocolos. Por ejemplo, las llamadas para intercambiar mensajes en UNIX son diferentes de las llamadas en Windows NT.

Lenguajes de programación diferentes emplean representaciones diferentes para caracteres y estructuras de datos como cadenas de caracteres y registros. Hay que tener en cuenta estas diferencias si queremos que los programas escritos en diferentes lenguajes de programación sean capaces de comunicarse entre ellos.

Los programas escritos por diferentes programadores no podrán comunicarse entre sí a menos que utilicen estándares comunes, por ejemplo para la comunicación en red y la representación de datos elementales y estructuras de datos en mensajes. Para que esto ocurra es necesario concertar y adoptar estándares (como así lo son los protocolos de Internet).

◊ **Middleware.** El término *middleware* se aplica al estrato software que provee una abstracción de programación, así como un enmascaramiento de la heterogeneidad subyacente de las redes, hardware, sistemas operativos y lenguajes de programación. CORBA, el cual se describe en los Capítulos 4, 5 y 17, es un ejemplo de ello. Algun middleware, como Java RMI (véase el Capítulo 5) sólo se soporta en un único lenguaje de programación. La mayoría de middleware se implementa sobre protocolos de Internet, enmascarando éstos la diversidad de redes existentes. Aun así cualquier middleware trata con las diferencias de sistema operativo y hardware. El cómo se obtiene esto es el tema principal del Capítulo 4.

Además de soslayar los problemas de heterogeneidad, el middleware proporciona un modelo computacional uniforme al alcance de los programadores de servidores y aplicaciones distribuidas. Los posibles modelos incluyen invocación sobre objetos remotos, notificación de eventos remotos, acceso remoto mediante SQL y procesamiento distribuido de transacciones. Por ejemplo, CORBA proporciona invocación sobre objetos remotos, lo que permite que un objeto en un programa en ejecución en un computador invoque un método de un objeto de un programa que se ejecuta en otro computador. La implementación oculta el hecho de que los mensajes se transmiten en red en cuanto al envío de la petición de invocación y su respuesta.

◊ **Heterogeneidad y código móvil.** El término *código móvil* se emplea para referirse al código que puede ser enviado desde un computador a otro y ejecutarse en éste, por eso los applets de Java son un ejemplo de ello. Dado que el conjunto de instrucciones de un computador depende del hardware, el código de nivel de máquina adecuado para correr en un tipo de computador no es adecuado para ejecutarse en otro tipo. Por ejemplo, los usuarios de PC envían a veces archivos ejecutables agregados a los correos electrónicos para ser ejecutados por el destinatario, pero el receptor bien pudiera no ser capaz de ejecutarlo, por ejemplo, sobre un Macintosh o un computador con Linux.

La aproximación de *máquina virtual* provee un modo de crear código ejecutable sobre cualquier hardware: el compilador de un lenguaje concreto generará código para una máquina virtual

en lugar de código apropiado para un hardware particular, por ejemplo el compilador Java produce código para la máquina virtual Java, la cual sólo necesita ser implementada una vez para cada tipo de máquina con el fin de poder lanzar programas Java. Sin embargo, la solución Java no se puede aplicar de modo general a otros lenguajes.

1.4.2. EXTENSIBILIDAD

La extensibilidad de un sistema de cómputo es la característica que determina si el sistema puede ser extendido y reimplementado en diversos aspectos. La extensibilidad de los sistemas distribuidos se determina en primer lugar por el grado en el cual se pueden añadir nuevos servicios de compartición de recursos y ponerlos a disposición para el uso por una variedad de programas cliente.

No es posible obtener extensibilidad a menos que la especificación y la documentación de las interfaces software clave de los componentes de un sistema estén disponibles para los desarrolladores de software. Es decir, que las interfaces clave estén *publicadas*. Este procedimiento es similar a una estandarización de las interfaces, aunque a menudo puentea los procedimientos oficiales de estandarización, que por lo demás suelen ser lentos y complicados.

Sin embargo, la publicación de interfaces sólo es el punto de arranque de la adición y extensión de servicios en un sistema distribuido. El desafío para los diseñadores es hacer frente a la complejidad de los sistemas distribuidos que constan de muchos componentes diseñados por personas diferentes.

Los diseñadores de los protocolos de Internet presentaron una serie de documentos denominados «Solicitudes de Comentarios» (*Request For Comments*), o RFC, cada una de las cuales se conoce por un número.

Las especificaciones de los protocolos de Internet fueron publicados en esta serie a principios de los años ochenta, seguido por especificaciones de aplicaciones que corrieran sobre ellos, tales como transferencia de archivos, correo electrónico y *telnet* a mediados de los años ochenta. Esta práctica continúa y forma la base de la documentación técnica sobre Internet. Esta serie incluye discusiones así como especificaciones de protocolos. Se puede obtener copias en [\[www.ietf.org\]](http://www.ietf.org). Así la publicación de los protocolos originales de comunicación de Internet ha posibilitado que se construyera una enorme variedad de sistemas y aplicaciones sobre Internet. Los documentos RFC no son el único modo de publicación. Por ejemplo, CORBA está publicado a través de una serie de documentos técnicos, incluyendo una especificación completa de las interfaces de sus servicios. Véase [\[www.omg.org\]](http://www.omg.org).

Los sistemas diseñados de este modo para dar soporte a la compartición de recursos se etiquetan como *sistemas distribuidos abiertos* (*open distributed systems*) para remarcar el hecho de ser extensibles. Pueden ser extendidos en el nivel hardware mediante la inclusión de computadores a la red y en el nivel software por la introducción de nuevos servicios y la reimplementación de los antiguos, posibilitando a los programas de aplicación la compartición de recursos. Otro beneficio más, citado a menudo, de los sistemas abiertos es su independencia de proveedores concretos.

En resumen:

- Los sistemas abiertos se caracterizan porque sus interfaces están publicadas.
- Los sistemas distribuidos abiertos se basan en la provisión de un mecanismo de comunicación uniforme e interfaces públicas para acceder a recursos compartidos.
- Los sistemas distribuidos abiertos pueden construirse con hardware y software heterogéneo, posiblemente de diferentes proveedores. Sin embargo, la conformidad con el estándar publicado de cada componente debe contrastarse y verificarse cuidadosamente si se desea que el sistema trabaje correctamente.

1.4.3. SEGURIDAD

Sistemas distribuidos suelen tener más restricciones en los sistemas distribuidos, porque el sistema trabaje correctamente.

1.4.3. SEGURIDAD

Sistemas distribuidos suelen tener más restricciones en los sistemas distribuidos, porque el sistema trabaje correctamente.

importancia. La seguridad de los recursos de información tiene tres componentes: confidencialidad (protección contra el descubrimiento por individuos no autorizados); integridad (protección contra

Fecha	Computadores	Servidores web
Diciembre de 1979	188	0
Julio de 1989	130.000	0
Julio de 1999	56.218.000	5.560.866

Figura 1.5. Computadores en Internet.

1.4.4. ESCALABILIDAD

Los sistemas distribuidos operan efectiva y eficientemente en muchas escalas diferentes, desde pequeñas intranets a Internet. Se dice que un sistema es *escalable* si conserva su efectividad cuando ocurre un incremento significativo en el número de recursos y el número de usuarios. Internet proporciona un ejemplo de un sistema distribuido en el que el número de computadores y servicios experimenta un dramático incremento. La Figura 1.5 muestra el número de computadores y servicios en Internet durante 20 años, desde 1979 hasta 1999, y la Figura 1.6 muestra el creciente número de computadores y servidores web durante los 16 años de historia del Web hasta 1999, véase [info.isoc.org].

El diseño de los sistemas distribuidos escalables presenta los siguientes retos:

Control del coste de los recursos físicos: según crece la demanda de un recurso, debiera ser posible extender el sistema, a un coste razonable, para satisfacerla. Por ejemplo, la frecuencia con la que se accede a los archivos de una intranet suele crecer con el incremento del número de usuarios y computadores. Debe ser posible añadir servidores para evitar el embottellamiento que aparece cuando un solo servidor de archivos ha de manejar todas las peticiones de acceso a éstos. En general, para que un sistema con n usuarios fuera escalable, la cantidad de recursos físicos necesarios para soportarlo debiera ser como máximo $O(n)$, es decir proporcional a n . Por ejemplo, si un solo servidor de archivos pudiera soportar 20 usuarios, entonces 2 servidores del mismo tipo tendrán capacidad para 40 usuarios. Aunque parezca una meta obvia, no es tan fácil lograrlo en la práctica, según se mostrará en el Capítulo 8.

Control de las pérdidas de prestaciones: considere la administración de un conjunto de datos cuyo tamaño es proporcional al número de usuarios o recursos del sistema, sea por ejemplo la tabla con la relación de nombres de dominio de computadores y sus direcciones Internet suscitado por el Sistema de Nombres de Dominio (*Domain Name System*), que se emplea principalmente para averiguar nombres DNS tales como www.amazon.com. Los algoritmos que emplean estructuras jerárquicas se comportan mejor frente al crecimiento de la escala que los algoritmos que emplean estructuras lineales. Pero incluso con estructuras jerárquicas un incremento en tamaño traerá consigo pérdidas en prestaciones: el tiempo que lleva acceder a datos estructurados jerárquicamente es $O(\log n)$, donde n es el tamaño del conjunto de datos. Para que un sistema sea escalable, la máxima pérdida de prestaciones no debiera ser peor que esta medida.

Fecha	Computadores	Servidores web	Porcentaje (%)
Julio de 1993	1.776.000	130	0,008
Julio de 1995	6.642.000	23.500	0,4
Julio de 1997	19.540.000	1.203.096	6
Julio de 1999	56.218.000	6.598.697	12

Figura 1.6. Comparación entre Computadores y Servidores web en Internet.

Prevención de desbordamiento de recursos software: un ejemplo de pérdida de escalabilidad se

Prevención de desbordamiento de recursos software: un ejemplo de pérdida de escalabilidad se muestra en el tipo de número usado para las direcciones Internet (direcciones de computadores

2. Los archivos con datos pueden escribirse en una pareja de discos de forma que si uno está deteriorado el otro seguramente está en buen estado.

Simplemente eliminar un mensaje corrupto es un ejemplo de atenuar un fallo (pudiera retransmitirse de nuevo). Probablemente el lector se dará cuenta de que las técnicas indicadas para ocultar los fallos no tienen garantía de funcionamiento las peores situaciones; por ejemplo, los datos en el segundo disco pudieran también estar corrompidos, o el mensaje bien pudiera no llegar a tiempo no importa cuantas veces se retransmita.

Tolerancia de fallos: la mayoría de los servicios en Internet exhiben fallos; es posible que no sea práctico para ellos pretender detectar y ocultar todos los fallos que pudieran aparecer en una red tan grande y con tantos componentes. Sus clientes pueden diseñarse para tolerar ciertos fallos, lo que implica que también los usuarios tendrán que tolerarlos generalmente. Por ejemplo, cuando un visualizador web no puede contactar con un servidor web no hará que el cliente tenga que esperar indefinidamente mientras hace sucesivos intentos; informará al usuario del problema, dándole la libertad de intentarlo más tarde.

Recuperación frente a fallos: la recuperación implica el diseño de software en el que, tras una caída del servidor, el estado de los datos pueda reponerse o retractarse (*roll back*) a una situación anterior. En general, cuando aparecen fallos los cálculos realizados por algunos programas se encontrarán incompletos y al actualizar datos permanentes (archivos e información ubicada en almacenamiento persistente) pudiera encontrarse en un estado inconsistente. La recuperación se describirá en el Capítulo 13.

Redundancia: puede lograrse que los servicios toleren fallos mediante el empleo redundante de componentes. Considere los siguientes ejemplos:

1. Siempre deberá haber al menos dos rutas diferentes entre cualesquiera dos *routers* (encaminadores) en Internet.
2. En el Sistema de Nombres de Dominio, cada tabla de nombres se encuentra replicada en dos servidores diferentes.
3. Una base de datos puede encontrarse replicada en varios servidores para asegurar que los datos siguen siendo accesibles tras el fallo de cualquier servidor concreto; los servidores pueden diseñarse para detectar fallos entre sus iguales; cuando se detecta algún error en un servidor se redirigen los clientes a los servidores restantes.

El diseño de técnicas eficaces para mantener réplicas actualizadas de datos que cambian rápidamente sin una pérdida excesiva de prestaciones es un reto; en el Capítulo 14 se discutirán varias aproximaciones a él.

Los sistemas distribuidos proporcionan un alto grado de disponibilidad frente a los fallos del hardware. La *disponibilidad* de un sistema mide la proporción de tiempo en que está utilizable. Cuando falla algún componente del sistema distribuido sólo resulta afectado el trabajo relacionado con el componente defectuoso. Así como cuando un computador falla el usuario puede desplazarse a otro, también puede iniciarse un proceso de servicio en otra ubicación.

1.4.6. CONCURRENCIA

Tanto los servicios como las aplicaciones proporcionan recursos que pueden compartirse entre los clientes en un sistema distribuido. Existe por lo tanto una posibilidad de que varios clientes intenten acceder a un recurso compartido a la vez. Por ejemplo, una estructura de datos que almacena licitaciones de una subasta puede ser accedida muy frecuentemente cuando se aproxima el momento de cierre.

El proceso que administra un recurso compartido puede atender las peticiones de cliente una por una en cada momento, pero esta aproximación limita el ritmo de producción del sistema (*throughput*). Por esto los servicios y aplicaciones permiten, usualmente, procesar concurrentemente múltiples peticiones de los clientes. Más concretamente, suponga que cada recurso se encapsula en un objeto y que las invocaciones se ejecutan en hilos de ejecución concurrentes (*threads*). En este caso es posible que varios *threads* estuvieran ejecutando concurrentemente el contenido de un objeto, en cuyo caso las operaciones en el objeto pueden entrar en conflicto entre sí y producir resultados inconsistentes. Por ejemplo, sean dos ofertas que concurren a una subasta como «Pérez:122\$» y «Rodríguez:111\$» y las operaciones correspondientes se entrelazan sin control alguno, estas ofertas se pueden almacenar como «Pérez:111\$» y «Rodríguez:122\$».

La moraleja de esta historia es que cada objeto que represente un recurso compartido en un sistema distribuido debe responsabilizarse de garantizar que opera correctamente en un entorno concurrente. De este modo cualquier programador que recoge una implementación de un objeto que no está concebido para su aplicación en un entorno distribuido deberá realizarlas modificaciones necesarias para que sea seguro su uso en un entorno concurrente.

Para que un objeto sea seguro en un entorno concurrente, sus operaciones deben sincronizarse de forma que sus datos permanezcan consistentes. Esto puede lograrse mediante el empleo de técnicas conocidas como los semáforos, que se usan en la mayoría de los sistemas operativos. Esta cuestión y su extensión a conjuntos de objetos compartidos se discutirá en los Capítulos 6 y 12.

1.4.7. TRANSPARENCIA

Se define transparencia como la ocultación al usuario y al programador de aplicaciones de la separación de los componentes en un sistema distribuido, de forma que se perciba el sistema como un todo más que como una colección de componentes independientes. Las implicaciones de la transparencia son de gran calado en el diseño del software del sistema.

El Manual de Referencia ANSA (ANSA Reference Manual) [ANSA 1989] y el Modelo de Referencia para el Procesamiento Distribuido Abierto (RM-ODP: Reference Model for Open Distributed Processing) de la Organización Internacional de Estándares [ISO 1992] identifican ocho formas de transparencia. Hemos reproducido las definiciones originales de ANSA, remplazando su transparencia de migración por nuestra propia transparencia de movilidad, de mayor alcance:

Transparencia de acceso que permite acceder a los recursos locales y remotos empleando operaciones idénticas.

Transparencia de ubicación que permite acceder a los recursos sin conocer su localización.

Transparencia de concurrencia que permite que varios procesos operen concurrentemente sobre recursos compartidos sin interferencia mutua.

Transparencia de replicación que permite utilizar múltiples ejemplares de cada recurso para aumentar la fiabilidad y las prestaciones sin que los usuarios y los programadores de aplicaciones necesiten su conocimiento.

Transparencia frente a fallos que permite ocultar los fallos, dejando que los usuarios y programas de aplicación completen sus tareas a pesar de fallos del hardware o de los componentes software.

Transparencia de movilidad que permite la reubicación de recursos y clientes en un sistema sin afectar la operación de los usuarios y los programas.

Transparencia de prestaciones que permite reconfigurar el sistema para mejorar las prestaciones según varía su carga.

Transparencia al escalado que permite al sistema y a las aplicaciones expandirse en tamaño sin cambiar la estructura del sistema o los algoritmos de aplicación.

Las dos más importantes son la transparencia de acceso y la transparencia de ubicación; su presencia o ausencia afecta principalmente a la utilización de recursos distribuidos. A veces se les da el nombre conjunto de *transparencia de red*.

Como ilustración de la transparencia de acceso, considere una interfaz gráfica de usuario basada en carpetas, donde los contenidos de las carpetas se observan igual ya sean éstas locales o remotas. Otro ejemplo pudiera ser el de una interfaz de programación de aplicaciones [API] para archivos que emplea las mismas operaciones para acceder a éstos ya sean locales o remotos (véase el Capítulo 8). Como ejemplo de carencia de transparencia de acceso, considere un sistema distribuido que no permite acceder a los archivos de un computador remoto a menos que se emplee el programa «ftp».

Los nombres de recursos web o URLs son transparentes a la ubicación dado que la parte del URL que identifica el nombre del dominio del servidor web se refiere a un nombre de computador en un dominio, más que a una dirección en Internet. Sin embargo, un URL no es transparente a la movilidad, porque una página web dada no puede moverse a un nuevo lugar en un dominio diferente sin que todos los enlaces anteriores a esta página sigan apuntando a la página original.

En general, los identificadores como los URLs que incluyen los nombres de dominio en los computadores contravienen la transparencia de replicación. Aunque el DNS permite que un nombre de dominio se refiera a varios computadores, sólo se escoge uno de ellos cuando se utiliza un nombre. Ya que un esquema de replicación generalmente necesita ser capaz de acceder a todos los computadores del grupo, sería necesario acceder a cada entrada del DNS por nombre.

Como ilustración de la presencia de transparencia de red, considere el uso de una dirección de correo electrónico como *Pedro.Picapiedra@piedradura.com*. La dirección consta de un nombre de usuario y un nombre de dominio. Observe que a pesar de que los programas de correo aceptan nombres de usuario para usuarios locales, añaden el nombre del dominio. El envío de correo a un usuario no implica el conocimiento de su ubicación física en la red. Tampoco el procedimiento de envío de un mensaje de correo depende de la ubicación del receptor. En resumen, el correo electrónico en Internet proporciona ambas cosas: transparencia de ubicación y transparencia de acceso (en definitiva, transparencia de red).

La transparencia frente a fallos puede ilustrarse también en el contexto del correo electrónico, el cual eventualmente se envía, incluso aunque los servidores o los enlaces de comunicaciones fallen. Los fallos se enmascaran intentando retransmitir los mensajes hasta que se envían satisfactoriamente, incluso si lleva varios días. El middleware convierte generalmente los fallos de redes y procesos en excepciones del nivel de programación (para una explicación véase el Capítulo 5).

Para ilustrar la transparencia a la movilidad, considere el caso de los teléfonos móviles. Supongamos que ambos, el emisor y el receptor, viajan en tren por diferentes partes del país, moviéndose de un entorno (célula) a otro. Veamos al terminal del emisor como un cliente y al terminal del receptor como un recurso. Los dos usuarios telefónicos no perciben el desplazamiento de sus terminales (el cliente y el recurso) entre dos células.

La transparencia oculta y difumina anónimamente los recursos que no son relevantes directamente para la tarea entre manos de los usuarios y programadores de aplicaciones. Por ejemplo, en general es deseable que el uso de ciertos dispositivos físicos sea intercambiable. Por ejemplo, en un sistema multiprocesador, la identificación del procesador en que se ejecuta cada proceso es irrelevante. Aún puede que la situación sea otra: por ejemplo, un viajero que conecta un computador portátil a una red local, en cada oficina que visita hace uso de servicios locales como el correo, utilizando diferentes servidores en cada ubicación. Incluso dentro de un edificio, es normal preparar las cosas para imprimir cada documento en una impresora concreta: generalmente la más próxi-

ma. También para un programador que desarrolla programas paralelos, no todos los procesadores son anónimos. Él o ella pudiera estar interesado en qué procesadores utilizar para la tarea, o al menos cuántos y su topología de interconexión.

1.5. RESUMEN

Los sistemas distribuidos están por todas partes. Internet permite que los usuarios de todo el mundo accedan a sus servicios donde quiera que estén situados. Cada organización administra una intranet, que provee servicios locales y servicios de Internet a los usuarios locales y habitualmente proporciona servicios a otros usuarios de Internet. Es posible construir pequeños sistemas distribuidos con computadores portátiles y otros dispositivos computacionales pequeños conectados a una red inalámbrica.

La compartición de recursos es el principal factor que motiva la construcción de sistemas distribuidos. Recursos como impresoras, archivos, páginas web o registros de bases de datos se administran mediante servidores del tipo apropiado. Por ejemplo los servidores web administran páginas y otros recursos web. Los recursos son accedidos por clientes, por ejemplo, los clientes de los servidores web se llaman normalmente visualizadores o navegadores web.

La construcción de los sistemas distribuidos presenta muchos desafíos:

Heterogeneidad: debe construirse desde una variedad de diferentes redes, sistemas operativos, hardware de computador y lenguajes de programación. Los protocolos de comunicación de Internet enmascaran las diferencias entre redes y el middleware puede tratar con las diferencias restantes.

Extensibilidad: los sistemas distribuidos deberían ser extensibles, el primer paso es la publicación de las interfaces de sus componentes, pero la integración de componentes escritos por diferentes programadores es un auténtico reto.

Seguridad: se puede emplear encriptación para proporcionar una protección adecuada a los recursos compartidos y mantener secreta la información sensible cuando se transmite un mensaje a través de la red. Los ataques de denegación de servicio son aún un problema.

Escalabilidad: un sistema distribuido es escalable si el coste de añadir un usuario es una cantidad constante en términos de recursos que se deberán añadir. Los algoritmos empleados para acceder a los datos compartidos deberían evitar cuellos de botella y los datos deberían estar estructurados jerárquicamente para dar los mejores tiempos de acceso. Los datos frecuentemente accedidos pudieran estar replicados.

Tratamiento de fallos: cualquier proceso, computador o red puede fallar independientemente de los otros. En consecuencia cada componente necesita estar al tanto de las formas posibles en que pueden fallar los componentes de los que depende y estar diseñado para tratar apropiadamente con cada uno de estos fallos.

Concurrencia: la presencia de múltiples usuarios en un sistema distribuido es una fuente de peticiones concurrentes a sus recursos. Cada recurso debe estar diseñado para ser seguro en un entorno concurrente.

Transparencia: el objetivo es que ciertos aspectos de la distribución sean invisibles al programador de aplicaciones de modo que sólo necesite ocuparse del diseño de su aplicación particular. Por ejemplo, no debe ocuparse de su ubicación o los detalles sobre cómo se accede a sus operaciones por otros componentes, o si será replicado o migrado. Incluso los fallos de las redes y los procesos pueden presentarse a los programadores de aplicaciones en forma de excepciones, aunque deban de ser tratados.

EJERCICIOS

- 1.1. Proponga cinco tipos de recursos hardware y cinco tipos de recursos software o de datos que puedan compartirse útilmente. Proponga ejemplos de su uso compartido tal y como ocurre en la práctica en los sistemas distribuidos.
- 1.2. ¿Cómo podría sincronizarse los relojes de dos computadores unidos por una red local, sin hacer uso de una referencia temporal externa? ¿Qué factores limitarían la precisión del procedimiento propuesto? ¿Cómo podrían sincronizarse los relojes de un mayor número de computadores conectados a Internet? Discuta la precisión de este procedimiento.
- 1.3. Un usuario llega a una estación de ferrocarril que no conoce, portando un PDA capaz de conectarse a una red inalámbrica. Sugiera cómo podría proporcionársele al usuario información sobre los servicios locales y las comodidades en la estación, sin necesidad de insertar el nombre de la estación o sus características. ¿Qué dificultades técnicas hay que superar?
- 1.4. ¿Cuáles son las ventajas y desventajas de HTML, URL y HTTP como tecnologías de base para la consulta y visualización de información? ¿Son algunas de estas tecnologías adecuadas como plataforma de cómputo cliente-servidor en general?
- 1.5. Tome World Wide Web como ejemplo para ilustrar el concepto de compartición de recursos, cliente y servidor.
Los recursos en World Wide Web y otros servicios se dirigen mediante URL. ¿Qué significan las siglas URL? Proporcione ejemplos de tres tipos de recursos web a los que pueda darse un nombre URL.
- 1.6. Dé un ejemplo de URL.
Enumere los tres componentes principales de un URL, indicando cómo se delimitan e ilustre cada uno a partir de un ejemplo.
¿Hasta qué límite es transparente la ubicación en URL?
- 1.7. Un programa servidor escrito en un lenguaje (por ejemplo C++) proporciona un objeto BURBUJA al que se pretende que accedan clientes que pudieran estar escritos en un lenguaje diferente (por ejemplo Java). Los computadores clientes y servidores pueden tener hardware diferente, pero todas están conectadas a Internet. Describa los problemas debidos a cada uno de los cinco aspectos de la heterogeneidad que necesitan resolverse para permitir que un objeto cliente invoque un método sobre el objeto servidor.
- 1.8. Un sistema distribuido abierto permite la adición de nuevos servicios de compartición de recursos como el objeto BURBUJA del Ejercicio 1.7 y que sean accesibles por una variedad de programas cliente. Discuta en el contexto de este ejemplo, hasta dónde las necesidades de extensibilidad difieren de las de heterogeneidad.
- 1.9. Suponga que las operaciones del objeto BURBUJA están separadas en dos categorías: operaciones públicas disponibles para todos los usuarios y operaciones protegidas disponibles sólo para ciertos usuarios conocidos por un nombre concreto. Presente todos los problemas relacionados con la operación de garantizar que sólo los usuarios con nombre conocido puedan acceder a la operación protegida. Suponiendo que el acceso a una operación protegida da información que no debiera revelarse al resto de los usuarios. ¿Qué más problemas aparecen?
- 1.10. El servicio INFO admite un conjunto de recursos potencialmente muy grande, cada uno de los cuales puede ser accedido por usuarios de Internet mediante una clave (en forma de

MODELOS DE SISTEMA

- 2.1. Introducción
- 2.2. Modelos arquitectónicos
- 2.3. Modelos fundamentales
- 2.4. Resumen

Un modelo arquitectónico de un sistema distribuido trata sobre la colocación de sus partes y las relaciones entre ellas. Algunos ejemplos pueden ser el modelo cliente-servidor y el modelo de procesos «de igual a igual» (*peer to peer*). El modelo cliente-servidor admite varias modificaciones debido a:

- La partición de datos o la replicación en servidores cooperativos.
- El uso de caché para los datos en clientes y servidores proxy.
- El uso de código y agentes móviles.
- Los requisitos para añadir o eliminar dispositivos móviles de forma conveniente.

Los modelos fundamentales están implicados en una descripción más formal de las propiedades que son comunes en todos los modelos arquitectónicos.

No hay un tiempo global en un sistema distribuido, por lo que los relojes en las diferentes computadores no tienen necesariamente el mismo tiempo en una que en otra. Toda comunicación entre procesos se realiza por medio de mensajes. La comunicación mediante mensajes sobre una red puede verse afectada por retrasos, puede sufrir variedad de fallos y es vulnerable a los ataques a la seguridad. Estas cuestiones se consideran en tres modelos:

- El modelo de interacción trata de las prestaciones y de la dificultad de poner límites temporales en un sistema distribuido, por ejemplo para la entrega de mensajes.
- El modelo de fallos intenta dar una especificación precisa de los fallos que se pueden producir en los procesos y en los canales de comunicación. Define comunicación fiable y procesos correctos.
- El modelo de seguridad discute sobre las posibles amenazas para los procesos y los canales de comunicación. Introduce el concepto de canal seguro, que lo es frente a dichas amenazas.

2.1. INTRODUCCIÓN

Los sistemas pensados para trabajar en entornos reales deben diseñarse para funcionar correctamente en el rango de circunstancias más amplio posible y considerando todas las dificultades y amenazas (en el cuadro que viene a continuación se describen algunos ejemplos). La discusión y los ejemplos del Capítulo 1 sugieren que sistemas distribuidos de tipos diferentes comparten importantes propiedades subyacentes y dan lugar a problemas de diseño comunes. En este capítulo se presentan las propiedades y temas de diseño comunes para los sistemas distribuidos bajo la forma de modelos descriptivos. Cada modelo está pensado para proporcionar una descripción abstracta, simplificada pero consistente, de cada aspecto relevante del diseño de un sistema distribuido.

Un modelo arquitectónico define la forma en que los componentes de los sistemas interactúan uno con otro y en cómo están vinculados con la red de computadores subyacente. En la Sección 2.2, describimos la estructura de niveles del software de sistema distribuido y los principales modelos arquitectónicos que determinan las ubicaciones y las interacciones de los componentes. Discutimos las variantes del modelo cliente-servidor, incluyendo aquellas que se deben al empleo de código móvil. Tenemos en cuenta las características de un sistema distribuido en el que se puedan añadir o quitar dispositivos móviles a conveniencia. Finalmente, contemplamos los requisitos generales de diseño para los sistemas distribuidos.

En la Sección 2.3, presentamos tres modelos fundamentales que ayudan a localizar los problemas clave para los diseñadores de sistemas distribuidos. Su propósito es especificar las cuestiones, dificultades y amenazas que deben resolverse para desarrollar sistemas distribuidos que realicen correctamente, de forma fiable y segura sus tareas. Los modelos fundamentales proporcionan vistas abstractas de aquellas características de los sistemas distribuidos que afectan a sus características de confianza, corrección, fiabilidad y seguridad.

◊ **Dificultades y amenazas para los sistemas distribuidos.** Algunos de los problemas con los que se deben encarar los diseñadores de sistemas distribuidos son:

Modos de utilización muy variables: Las partes componentes de los sistemas están sujetas a grandes variaciones en la carga de trabajo; por ejemplo, algunas páginas web son accedidas varios millones de veces al día. Algunas partes de un sistema pueden estar desconectadas, o débilmente conectadas en algún momento; por ejemplo cuando están incluidos en un sistema de computadores móviles. Algunas aplicaciones tienen requisitos especiales para comunicaciones de gran ancho de banda y baja latencia, por ejemplo las aplicaciones multimedia.

Amplio rango de entornos: Un sistema distribuido se debe acomodar a hardware, sistemas operativos y redes heterogéneas. Las redes pueden variar mucho en sus prestaciones, de hecho las redes sin cable trabajan a una fracción de la velocidad de las redes locales. Se deben soportar sistemas de escalado muy diferente, desde decenas hasta millones de computadores.

Problemas internos: Reloj no sincronizados, actualizaciones conflictivas de datos, muchas formas de fallos en hardware y software implicando a componentes individuales de un sistema.

Amenazas externas: Ataques a la integridad y el secreto de los datos, denegación de servicio.

2.2. MODELOS ARQUITECTÓNICOS

La arquitectura de un sistema es su estructura en términos de componentes especificados por separado. El objetivo global es asegurar que la estructura satisfará las demandas presentes y previsibles sobre él. El diseño arquitectónico de un edificio tiene aspectos similares y determina no sólo su apariencia, sino también su estructura general y su estilo arquitectónico (gótico, neoclásico, moderno), proporcionando un marco de referencia consistente para el diseño.

En esta sección, describiremos los principales modelos arquitectónicos empleados en los sistemas distribuidos: los estilos arquitectónicos de los mismos. Construimos nuestros modelos arquitectónicos en torno a los conceptos de proceso y objeto introducidos en el Capítulo 1. Un modelo arquitectónico de un sistema distribuido simplifica y abstrae, inicialmente, las funciones de los componentes individuales de dicho sistema y posteriormente considera:

- La ubicación de los componentes en la red de computadores, buscando definir patrones utilizable para la distribución de datos y carga de trabajo.
- Las interrelaciones entre los componentes, es decir, sus papeles funcionales y los patrones de comunicación entre ellos.

Una simplificación inicial se obtiene clasificando los procesos entre *servidores, clientes e iguales*, siendo estos últimos procesos que cooperan y se comunican de forma simétrica para realizar una tarea. Esta clasificación de procesos identifica las responsabilidades de cada uno y ayuda, por tanto, a valorar sus cargas de trabajo y a determinar el impacto de los fallos en cada uno de ellos. Los resultados de este análisis pueden ser utilizados para especificar la distribución de los procesos de una forma que concuerde con los objetivos de prestaciones y fiabilidad del sistema resultante.

Se pueden construir otros sistemas dinámicos como variaciones del modelo cliente servidor:

- La posibilidad de mover código de un proceso a otro permite que un proceso delegue tareas en otro; por ejemplo, los clientes pueden descargar código de los servidores y ejecutarlo localmente. Los objetos y el código al que acceden puede reubicarse para reducir los retardos de acceso y minimizar el tráfico de la comunicación.
- Algunos sistemas distribuidos se diseñan para permitir que los computadores y otros dispositivos móviles se añadan o eliminen sin incidencias, permitiendo el descubrimiento de servicios disponibles y el ofrecer sus servicios a otros.

Existen varios patrones utilizados ampliamente para la distribución del trabajo en un sistema distribuido y que tienen un impacto importante en las prestaciones y efectividad del sistema resultante. La ubicación actual de los procesos que conforman un sistema distribuido sobre una red de computadores está también influenciada por muchas características detalladas de prestaciones, fiabilidad, seguridad y coste. Los modelos arquitectónicos descritos aquí pueden proporcionar sólo una versión simplificada de los patrones de distribución más importantes.

2.2.1. CAPAS DE SOFTWARE

El término *arquitectura de software* se refería inicialmente a la estructuración del software como capas o módulos en un único computador y más recientemente en términos de los servicios ofrecidos y solicitados entre procesos localizados en el mismo o diferentes computadores. Esta vista orientada a proceso y a servicio puede expresarse en términos de capas de servicio.

Esta visión se presenta en la Figura 2.1 y se desarrolla con detalle creciente en los Capítulos 3 al 6. Un servidor es un proceso que acepta peticiones de otros procesos. Un servicio distribuido puede proveerse desde uno o más procesos servidor, es interactuando entre cada uno de ellos, y con los procesos clientes, para mantener una visión de los recursos del servicio consistente con el sistema. Por ejemplo, un servicio de tiempo de red está implementada en Internet basado en el Protocolo de Tiempo de Red (NTP, *Network Time Protocol*) mediante procesos servidor, corriendo sobre máquinas de Internet, que proporcionan el tiempo actual a cualquier cliente que lo solicite y ajuste su versión del tiempo actual como resultado de las interacciones con los otros.

La Figura 2.1 muestra términos importantes como *plataforma* y *middleware*, que definimos a continuación:

◊ **Plataforma.** El nivel de hardware y las capas más bajas de software se denominan, a menudo, plataforma para sistemas distribuidos y aplicaciones. Estas capas más bajas proporcionan servi-

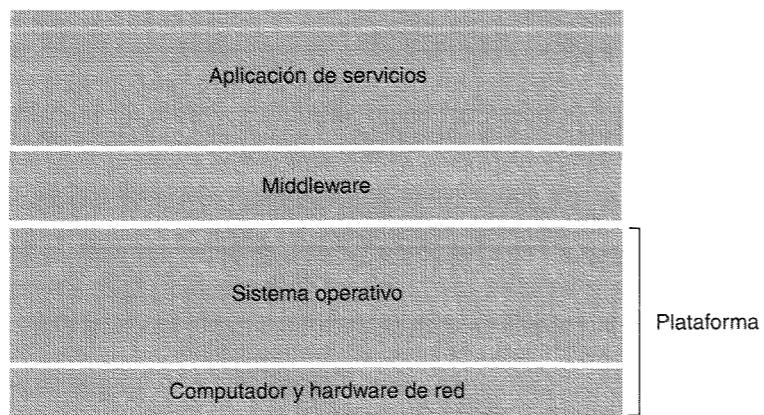


Figura 2.1. Capas de servicio software y hardware en los sistemas distribuidos.

cios a las que están por encima de ellas, y que son implementadas independientemente en cada computador, proporcionando una interfaz de programación del sistema a un nivel que facilita la comunicación y coordinación entre procesos. Windows para Intel x86, Sun OS para Sun SPARC, Solaris para Intel x86, Mac Os para Power PC, Linux para Intel x86 son los principales ejemplos.

◊ **Middleware.** Se definió en la Sección 1.4.1 como una capa de software cuyo propósito es enmascarar la heterogeneidad y proporcionar un modelo de programación conveniente para los programadores de aplicaciones. Se representa mediante procesos u objetos en un conjunto de computadores que interactúan entre sí para implementar mecanismos de comunicación y de recursos compartidos para aplicaciones distribuidas. El middleware se ocupa de proporcionar bloques útiles para la construcción de componentes software que puedan trabajar con otros en un sistema distribuido. En particular, mejora el nivel de las actividades de comunicación de los programas de aplicación soportando abstracciones como: procedimiento de invocación remota, comunicación entre un grupo de procesos, notificación de eventos, replicación de datos compartidos y transmisión de datos multimedia en tiempo real. Las comunicaciones entre grupos se considerarán en el Capítulo 4 y se tratarán con detalle en los Capítulos 11 y 14. La notificación de eventos se describirá en el Capítulo 5. La replicación de datos se discutirá en el Capítulo 14 y los sistemas multimedia en el Capítulo 15.

Los paquetes de llamadas a procedimientos remotos como Sun RPC (descrito en el Capítulo 5) y sistemas de comunicación en grupo como ISIS (Capítulo 14) fueron de los primeros, y son actualmente los ejemplos de middleware más ampliamente utilizados. Entre los productos y estándares de middleware orientados al objeto están CORBA (*Common Object Request Broker Architecture* de OMG), invocación de objetos remotos en Java (RMI, *Remote Method Invocation*), Modelo Común de Objetos Distribuidos de Microsoft (DCOM) y el Modelo de Referencia para Proceso Distribuido Abierto de la ISO/ITU-T (RM-ODP, *Reference Model for Open Distributed Processing*). CORBA y Java RMI serán descritos en los Capítulos 5 y 17, y se pueden encontrar detalles sobre DCOM y RM-ODP en Redmond [1997] y Blair y Stefani [1997].

El middleware también puede proporcionar servicios para su uso en los programas de aplicación. Existen servicios de infraestructuras ligadas fuertemente al modelo de programación distribuida que proporciona el middleware. Por ejemplo, CORBA ofrece una variedad de servicios que proporcionan a las aplicaciones funciones que incluyen la gestión de nombres, seguridad, transacciones, almacenamiento persistente y notificación de eventos. Alguno de los servicios de CORBA se analizarán en el Capítulo 17. Los servicios de la capa superior de la Figura 2.1 son servicios específicos del dominio que utiliza el middleware, sus operaciones de comunicación y sus propios servicios.

Limitaciones del middleware: Muchas aplicaciones distribuidas dependen enteramente de los servicios proporcionados por el middleware disponible, para soportar sus necesidades de comunicación y de compartir datos. Por ejemplo, una aplicación adecuada para el modelo cliente-servidor, como una base de datos de nombres y direcciones, puede basarse en middleware que proporcione sólo invocación de métodos remoto.

Se ha conseguido mucho en la simplificación de la programación de los sistemas distribuidos mediante el desarrollo del soporte de middleware, aunque algunos aspectos de la confiabilidad de los sistemas precisan soporte al nivel de aplicación.

Consideremos la transferencia de mensajes grandes de correo electrónico desde el servidor de correo del emisor hacia el del receptor. A primera vista es un uso sencillo del protocolo de transmisión de datos TCP (se verá en el Capítulo 3). Pero, contemplemos el problema de un usuario que intente transferir un fichero muy grande sobre una red potencialmente poco fiable. TCP proporciona algo de detección y corrección de errores, pero no puede resolver los problemas de interrupciones importantes de red. El servicio de transferencia de correo añade otro nivel de tolerancia a fallos, manteniendo un registro de progreso y reanudando la transmisión, utilizando una nueva conexión TCP, si la primera falla.

Un trabajo clásico de Saltzer, Reed y Clarke [Saltzer y otros, 1984] presenta un apunte similar y valioso sobre el diseño de sistemas distribuidos, que ellos llaman «el argumento final». Parafraseándolos:

Algunas funciones relacionadas con la comunicación pueden implementarse completamente y de forma fiable sólo con el conocimiento y la ayuda de cómo es la aplicación en los puntos finales del sistema de comunicación. Por tanto, proporcionar dicha función como una característica del sistema de comunicación no siempre es sensato. (Una versión incompleta de la función proporcionada por el sistema de comunicación puede ser a veces útil como una mejora de prestaciones).

Pudiera pensarse que su argumento va en contra de la idea de que todas las actividades de comunicación pueden abstraerse de la programación de aplicaciones mediante la introducción de las capas de middleware adecuadas.

El núcleo de su argumento es que el funcionamiento correcto de los programas distribuidos depende de las comprobaciones, mecanismos de corrección de errores y medidas de seguridad en muy distintos niveles, algunos de los cuales requieren acceso a datos del espacio de direcciones de la aplicación. Cualquier intento de realizar comprobaciones únicamente con el sistema de comunicación garantizará sólo una parte de la corrección exigida. Es muy probable, entonces, que se esté duplicando trabajo en los programas de aplicación, malgastando esfuerzo en la programación, y lo que es más importante, añadiendo una complejidad innecesaria y realizando cómputos redundantes.

No hay aquí espacio suficiente para detallar más sus argumentos, y se recomienda fuertemente la lectura del trabajo citado, que está lleno de ejemplos ilustrativos. Recientemente, uno de los autores originales señala que los beneficios sustanciales que trajo este argumento al diseño de Internet están en peligro por los recientes movimientos hacia la especialización de los servicios de red para satisfacer los requisitos de las aplicaciones actuales [www.reed.com].

2.2.2. ARQUITECTURAS DE SISTEMA

La división de responsabilidades entre los componentes del sistema (aplicaciones, servidores y otros procesos) y la ubicación de los componentes en los computadores en la red, es quizás el aspecto más evidente del diseño de un sistema distribuido. Sus implicaciones fundamentales están en las prestaciones, fiabilidad y seguridad del sistema resultante. En esta sección, se esbozan los principales modelos arquitectónicos sobre los cuales se basa esta distribución de responsabilidades.

En un sistema distribuido, los procesos con responsabilidades bien definidas interactúan con los otros para realizar una actividad útil. En esta sección, nuestra atención se enfocará en la colocación

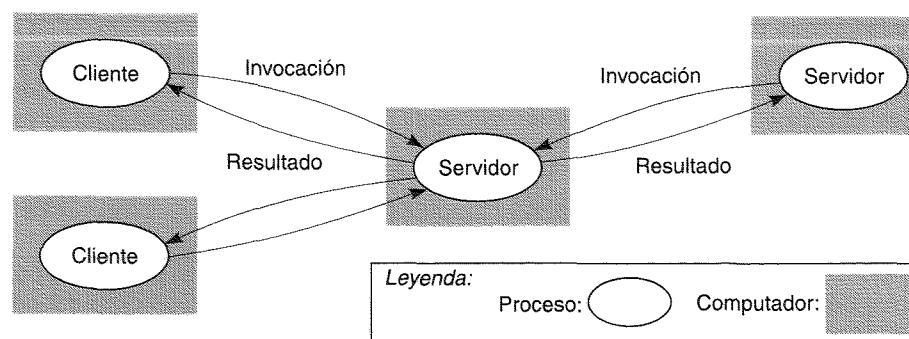


Figura 2.2. Clientes que invocan a servidores individuales.

de los procesos, ilustrada en la Figura 2.2, mostrando la disposición de los procesos (elipses) en los computadores (cajas grises). Utilizamos los términos *invocación* y *resultado* para etiquetar los mensajes, aunque se podrían haber etiquetado igualmente como *solicitud* y *respuesta*.

Los principales tipos de modelos arquitectónicos están ilustrados en las Figuras 2.2 a la Figura 2.5 y se describen a continuación.

◊ **Modelo cliente-servidor.** Es la arquitectura que se cita más a menudo cuando se discuten sistemas distribuidos. Históricamente es la más importante, y continúa siendo la más ampliamente utilizada. La Figura 2.2 muestra la sencilla estructura sobre la que interaccionan los procesos clientes con los procesos servidores individuales, en computadores separados, con el fin de acceder a los recursos compartidos que ellos gestionan.

Los servidores pueden, a su vez, ser clientes de otros servidores, como se indica en la figura. Por ejemplo, un servidor web es, a veces, un cliente de un servidor de ficheros local que gestiona los ficheros en los que están almacenadas las páginas web. Los servidores web y la mayoría del resto de los servicios de Internet son clientes del servicio DNS, que traduce Nombres de Dominio de Internet en direcciones de red. Otro ejemplo relacionado con web son los *buscadores*, que permiten a los usuarios buscar resúmenes de la información disponible en las páginas web de los sitios de Internet. Estos resúmenes están realizados por programas llamados *escaladores* (*crawlers*) web, que se ejecutan en segundo plano en el sitio del buscador utilizando peticiones HTTP para acceder a los servidores web a través de Internet. Por tanto, una máquina de búsqueda es tanto un cliente como un servidor: responde a las consultas del navegador de los clientes y ejecuta web crawlers que actúan como clientes de otros servidores web. En este ejemplo, las tareas del servidor (responder a las consultas de usuarios) y las tareas de crawler (hacer peticiones a otros servidores web) son totalmente independientes; hay muy poca necesidad de sincronizarlas y pueden ejecutarse concurrentemente. De hecho, un buscador típico debiera incluir mucho hilos (*threads*) de ejecución concurrente, algunos sirviendo a sus clientes y otros ejecutando crawlers web. En el Ejercicio 2.4, se invita al lector a considerar el único tema de sincronización que se presenta en un buscador concurrente del tipo descrito aquí.

◊ **Servicios proporcionados por múltiples servidores.** Los servicios pueden implementarse como distintos procesos de servidor en computadores separados interaccionando, cuando es necesario, para proporcionar un servicio a los procesos clientes (véase la Figura 2.3). Los servidores pueden dividir el conjunto de objetos en los que está basado el servicio y distribuirlos entre ellos mismos, o pueden mantener copias replicadas de ellos en varias máquinas. Estas dos opciones se ilustran en los ejemplos siguientes.

El Web proporciona un ejemplo típico de partición de datos en el que cada servidor web administra su propio conjunto de recursos. Un usuario puede emplear un navegador para acceder al recurso en cualquiera de los servidores.

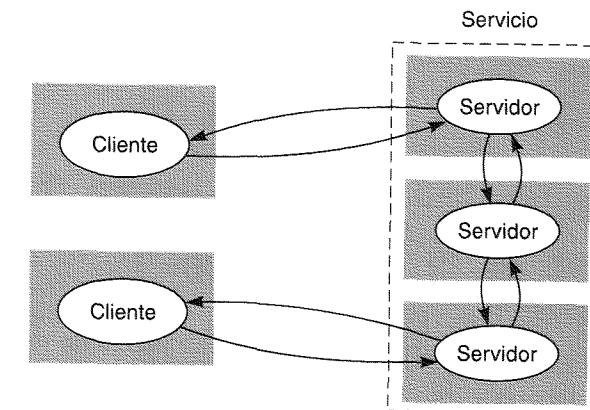


Figura 2.3. Un servicio proporcionado por múltiples servidores.

La replicación se utiliza para aumentar las prestaciones y disponibilidad y para mejorar la tolerancia a fallos. Proporciona múltiples copias consistentes de datos en proceso que se ejecutan en diferentes computadores. Por ejemplo, el servicio web proporcionado por *altavista.digital.com* se encuentra redirigido hacia varios servidores con la base de datos replicada en memoria.

Otro ejemplo de un servicio basado en datos replicados es el servicio de Información de Red de Sun (NIS, *Network Information Service*), que se utilizaría en una red de área local (LAN) cuando los usuarios entran en el sistema. Cada servidor NIS tiene su propia réplica del archivo de contraseñas que contiene una lista de los nombres de usuario y las claves de acceso criptografiadas. En el Capítulo 14 se discutirán con detalle las técnicas de replicación.

◊ **Servidores proxy y cachés.** Una caché es un almacén de objetos de datos utilizados recientemente, y que se encuentra más próximo que los objetos en sí. Al recibir un objeto nuevo en un computador se añade al almacén de la caché, reemplazando, si fuera necesario, algunos objetos existentes. Cuando se necesita un objeto en un proceso cliente, el servicio caché comprueba inicialmente la caché y le proporciona el objeto de una copia actualizada. Si no, se buscará una copia actualizada. Las cachés pueden estar ubicadas en cada cliente o en un servidor proxy que puede compartirse desde varios clientes.

Las cachés se utilizan intensivamente en la práctica. Los navegadores web mantienen una caché de las páginas visitadas recientemente, y de otros recursos web, en el sistema local de ficheros del cliente; entonces utilizan una petición especial HTTP para comprobar si dichas páginas han sido actualizadas en el servidor antes de sacarlas en pantalla. Los servidores proxy para el web (véase la Figura 2.4) proporcionan una caché compartida de recursos web a las máquinas cliente de uno o más sitios. El propósito de los servidores proxy es incrementar la disponibilidad y prestaciones del servicio, reduciendo la carga en redes de área amplia y en servidores web. Los servidores proxy pueden desempeñar otros roles, por ejemplo, pueden ser utilizados para acceder a servidores web remotos a través de un cortafuegos.

◊ **Procesos «de igual a igual».** En esta arquitectura todos los procesos desempeñan tareas semejantes, interactuando cooperativamente como iguales para realizar una actividad distribuida o cómputo sin distinción entre clientes y servidores. En este modelo, el código en los procesos parejos o «iguales» mantiene la consistencia de los recursos y sincroniza las acciones a nivel de la aplicación cuando es necesario. La Figura 2.5 muestra un ejemplo con tres instancias de esta situación; en general, n procesos parejos podrán interactuar entre ellos, dependiendo el patrón de comunicación de los requisitos de la aplicación.

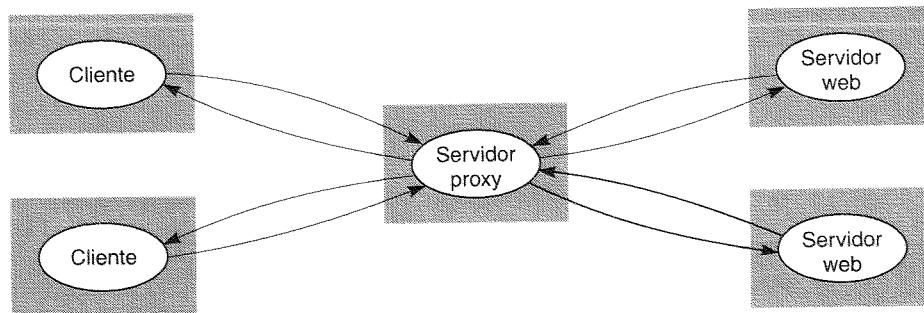


Figura 2.4. Un servidor proxy de tipo web.

La eliminación del proceso servidor reduce los retardos de comunicación entre procesos al acceder a objetos locales. Considérese una aplicación de *pizarra* distribuida que permite que usuarios en varios computadores vean y modifiquen interactivamente un dibujo que se comparte entre ellos (Floyd y otros [1997] es un ejemplo). Esto puede implementarse con un proceso de aplicación en cada sitio y que se basa en capas de middleware para realizar notificación de eventos y comunicación a grupos para indicar a todos los procesos de la aplicación de los cambios en el dibujo. Esto proporciona, a los usuarios de objetos distribuidos compartidos, una respuesta interactiva mejor de la que se puede obtener con una arquitectura basada en servidor.

2.2.3. VARIACIONES EN EL MODELO DE CLIENTE-SERVIDOR

Podemos distinguir distintas variaciones del modelo cliente-servidor, dependiendo de la consideración de los factores siguientes:

- El uso de código móvil y agentes móviles.
- Las necesidades de los usuarios de computadores de coste bajo y con recursos hardware limitados, que son muy sencillos de manejar.
- El requisito de añadir o eliminar de una forma conveniente dispositivos móviles.

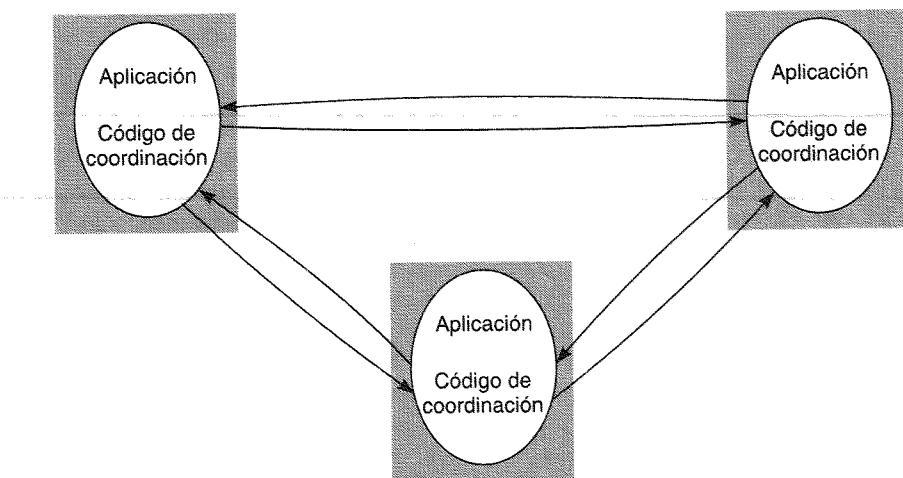
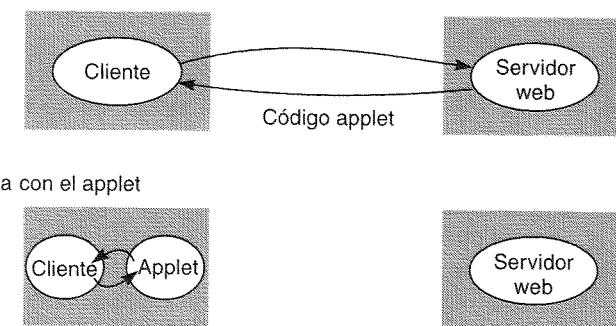


Figura 2.5. Una aplicación distribuida basada en procesos de igual a igual.

a) La petición del cliente origina la descarga del código del applet



b) El cliente interacciona con el applet



Figura 2.6. Applets de tipo web.

◊ **Código móvil.** En el Capítulo 1 se introdujo el concepto de código móvil. Los applets son el ejemplo más conocido y más ampliamente extendido de código móvil; un usuario que ejecute un navegador y que seleccione un enlace con un *applet*, cuyo código esté almacenado en un servidor web, descargará el código en el navegador y se ejecutará allí (tal y como se ve en la Figura 2.6). Una ventaja de ejecutar el código descargado localmente es que puede proporcionar una buena respuesta interactiva puesto que no sufre ni de los retardos ni de la variabilidad del ancho de banda asociados con la comunicación en red.

Acceder a los servicios significa ejecutar código que pueda invocar sus operaciones. Algunos servicios están probablemente tan estandarizados que podemos acceder a ellos mediante una aplicación existente y bien conocida, el Web es el ejemplo más común, pero incluso en este caso, algunos sitios web utilizan funcionalidades que no se encuentran en los navegadores estándar y precisan la descarga de código adicional. Este código adicional puede, por ejemplo, comunicar con el servidor. Consideremos una aplicación donde se necesite que los usuarios dispongan de información actualizada según se hagan cambios en el origen de los datos en el servidor. Esto no se puede conseguir mediante las interacciones normales con el servidor web, que siempre se inician por parte del cliente. La solución es utilizar software adicional que trabaja de una forma a la que a veces se refiere como modelo *push*, donde el servidor, en lugar del cliente, es el que inicia las interacciones.

Por ejemplo, un corredor de bolsa puede proporcionar un servicio personalizado para notificar a los usuarios los cambios en las cotizaciones; para utilizar dicho servicio, cada usuario deberá haber descargado un *applet* especial, que recibe las actualizaciones del servidor del corredor, las presenta en pantalla al usuario y quizás realiza operaciones automáticas de compra y venta, desencadenadas por las condiciones prefijadas por el usuario y almacenados localmente en el computador del mismo.

En el Capítulo 1 se ha mencionado que el código móvil es una amenaza potencial de seguridad para los recursos locales en el computador destino. Es así que, los navegadores proporcionan un acceso restringido a los recursos locales, siguiendo un esquema como el que se verá en la Sección 7.1.1.

◊ **Agentes móviles.** Un agente móvil es un programa en ejecución (lo que incluyé tanto código como datos) que se traslada de un computador a otro en la red realizando una tarea para alguien; por ejemplo, recolectando información, y retornando eventualmente con los resultados. Un agente móvil puede hacer muchas solicitudes a los recursos locales de los sitios que visita, por ejemplo, accediendo a anotaciones individuales en una base de datos. Si se compara esta arquitectura con un cliente estático que realiza solicitudes de algunos recursos, transfiriendo posiblemente

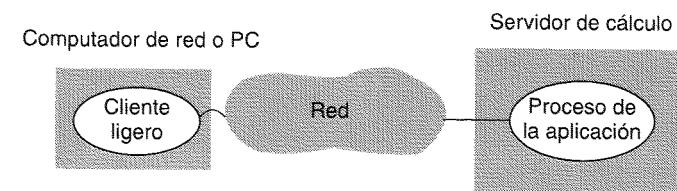
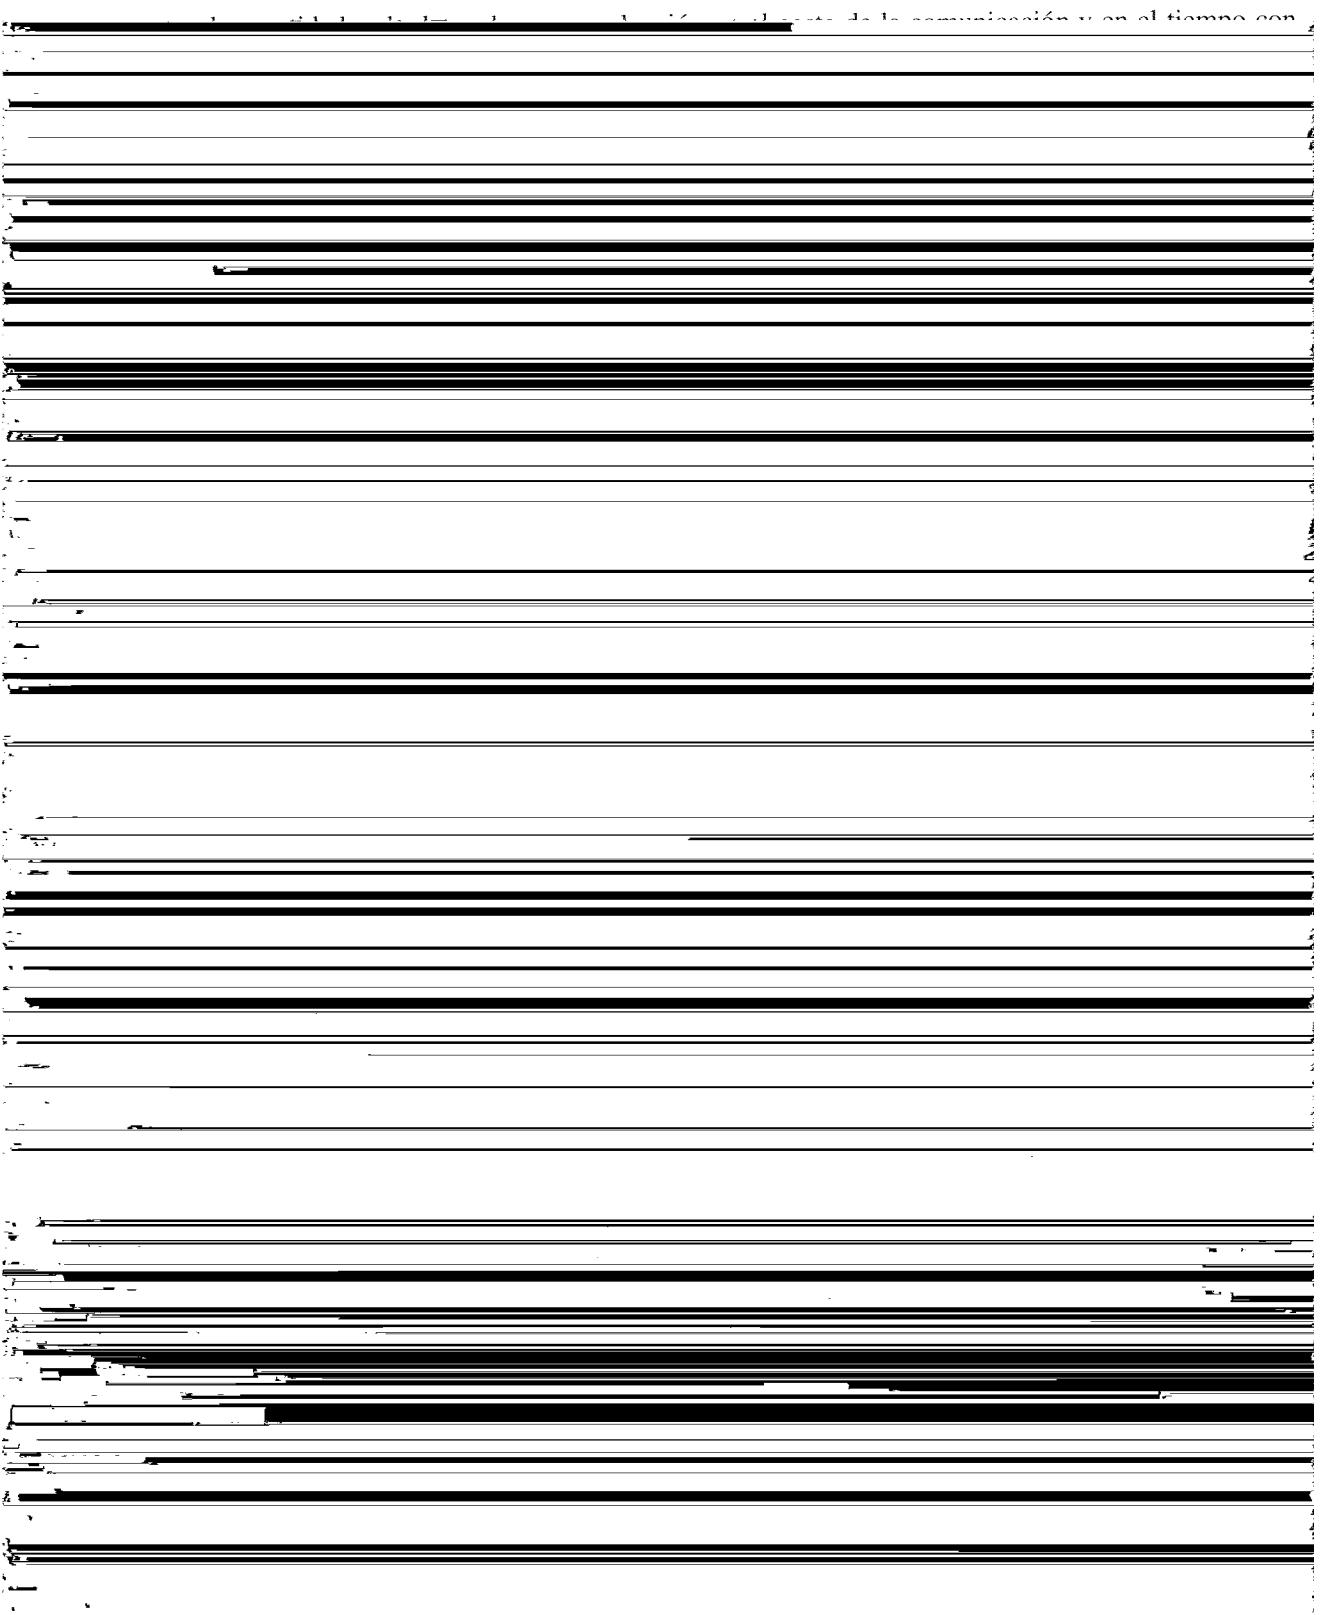


Figura 2.7. Clientes ligeros y servidores de cálculo.

vectorial entre el cliente ligero y los procesos de aplicación, padeciendo latencias tanto de red como de sistema operativo.

Implementaciones de clientes ligeros: Los sistemas de clientes ligeros son sencillos en concepto y sus implementaciones son inmediatas en algunos entornos. Por ejemplo, la mayoría de las variantes de UNIX incluyen el sistema de ventanas X-11 que se describe en el recuadro sombreado de la página siguiente.

Existen varios puntos en el flujo de las operaciones gráficas que se precisan para soportar una interfaz gráfica de usuario en los que se puede establecer la frontera entre cliente y servidor. X11 establece la frontera a nivel de las primitivas gráficas para dibujar líneas y formas y para el manejo de ventanas. El producto *WinFrame* de Citrix [www.citrix.com] es una implementación comercial del concepto de cliente ligero, utilizada ampliamente, que funciona de una forma similar. Este producto proporciona un cliente ligero que puede ejecutarse en una gran variedad de plataformas y soporta un entorno (*desktop*) que proporciona acceso interactivo a las aplicaciones corriendo en máquinas Windows NT. Otras aproximaciones incluyen los sistemas de computadores de red virtual (*Teleporting* y *Virtual Network Computer*, VNC) desarrollados en los laboratorios AT&T de Cambridge, Inglaterra [Richardson y otros, 1998]. VNC establece la frontera en el nivel de operaciones de píxeles en pantalla y mantiene el contexto gráfico para los usuarios cuando éstos se mueven entre computadores.

◊ **Dispositivos móviles y enlace espontáneo a red.** Como ya se ha explicado en el Capítulo 1, el mundo está cada vez más poblado de dispositivos de cómputo pequeños y portátiles, incluyendo computadores portátiles, dispositivos de mano como asistentes personales digitales (PDA), teléfonos móviles y cámaras digitales, computadores que se pueden llevar encima como relojes y dispositivos insertados en aparatos de hogar como en lavadoras. Muchos de estos dispositivos permiten su conexión a una red sin cable, de rango metropolitano o más grandes (GSM, CDPD), cientos de metros (Wavelan), o unos pocos metros (Blue Tooth, infrarrojos y HomeRF). Las redes de rango más pequeño tienen anchos de banda del orden de hasta 10 megabits/segundo; GSM promete anchos de banda del orden de cientos de kilobits/segundo.

Con la integración apropiada en nuestros sistemas distribuidos, estos dispositivos dan soporte para la computación móvil (véase la Sección 1.2.3), en la que los usuarios llevan sus dispositivos móviles entre los entornos de red y se benefician de los servicios locales y remotos según se mueven. La forma de distribución que integra dispositivos móviles y otros dispositivos en una red determinada se describe quizás mejor por el término *enlace a red espontáneo*. Este término se utiliza para abarcar aplicaciones que implican conexión de dispositivos tanto móviles como fijos de una forma más informal de lo que ha sido hasta ahora. Los dispositivos insertados en aparatos proporcionan servicios a los usuarios y a otros dispositivos parecidos, los dispositivos transportables como PDA proporcionan al usuario acceso a los servicios en su posición actual, así como a servicios globales como el Web.

◇ **El sistema de ventanas X-11.** El sistema de ventanas X-11 [Scheifler y Gettys 1986] es un proceso que gestiona la pantalla y los dispositivos interactivos de entrada (teclado, ratón) del computador en la que se ejecuta. X-11 proporciona una amplia biblioteca de procedimientos (el protocolo X-11) para mostrar en pantalla y modificar objetos gráficos en ventanas así como para la creación y modificación de las ventanas.

Al sistema X-11 se le referencia como un proceso *servidor de ventanas*. Los clientes del servidor son los programas de aplicación con los que el usuario interactúa normalmente. Los programas cliente comunican con el servidor invocando operaciones del protocolo X-11, éstas incluyen operaciones para dibujar texto y objetos gráficos en ventanas. Los clientes no tienen por qué ubicarse en el mismo computador que el servidor, puesto que los procedimientos del servidor se invocan siempre utilizando un mecanismo RPC. El servidor de ventanas X-11 tiene, por tanto, las propiedades fundamentales de un cliente ligero. (X-11 invierte la terminología cliente-servidor. El servidor X-11 debe su nombre a los servicios de representación gráfica que proporciona a los programas de aplicación, mientras el software del cliente ligero se llama así por referencia al uso que hace de programas de aplicación ejecutándose en un servidor de cómputo.)

En el Capítulo 1 se vio el caso de un usuario visitando una organización que actúa como anfitrión. En la Figura 2.8 se ve otro ejemplo de conexión espontánea a la red, en ella se puede observar una red inalámbrica que cubre una estancia de un hotel. Los sistemas de alta fidelidad de la habitación dan servicio de música, en el que los usuarios pueden dirigir cualquier combinación de selecciones musicales hacia los altavoces de la habitación o el baño, o a los auriculares inalámbricos. El sistema de alarma da un servicio de despertador mediante el servicio de música. El TV/PC (televisión más caja añadida) sirve tanto de televisión como de PC. Permite acceder al Web (mediante la pasarela del hotel a Internet), incluyendo una interfaz basada en el Web para todos los servicios del hotel. Proporciona un servicio de visualización para las imágenes que el usuario ha almacenado en su cámara digital o videocámara. También puede servir al usuario sus aplicaciones favoritas, bajo cierto coste de arrendamiento.

La figura muestra los dispositivos que el usuario ha llevado a la suite del hotel: un computador portátil, una cámara digital y una agenda portátil (PDA), cuyas posibilidades a través de infrarrojos le permiten actuar como un *controlador universal* (similar al control remoto de una televisión pero que se puede utilizar para controlar varios dispositivos en la habitación del hotel, incluyendo el servicio de iluminación y de música).

Aunque algunos de los dispositivos del hotel, como impresoras y máquinas de venta automáticas no suelen ser portátiles, existe un requisito para presentarlas con la mínima intervención humana. Su conexión a la red y el acceso a los servicios de red deben ser posibles sin que sea preciso notificarlo previamente o realizar cualquier gestión administrativa previa.

Las características esenciales de la conexión a red espontánea son:

Conexión fácil a la red local: los enlaces sin cable eliminan la necesidad de cableado preinstalado y eliminan el inconveniente y las cuestiones de fiabilidad que rodean a los conectores y enchufes. Sólo existen aquellos enlaces que pueden mantenerse aunque haya movimiento (en trenes, aviones, coches, bicicletas o barcos). Un dispositivo colocado en un nuevo entorno de red se reconfigura de modo transparente para conectarse allí; el usuario no tiene que introducir los nombres o direcciones de los servicios locales para obtenerlo.

Integración fácil con servicios locales: los dispositivos que se encuentran insertados (y moviéndose) entre redes existentes de dispositivos descubren automáticamente qué servicios se proporcionan, sin acciones especiales de configuración por el usuario. En el ejemplo del hotel,

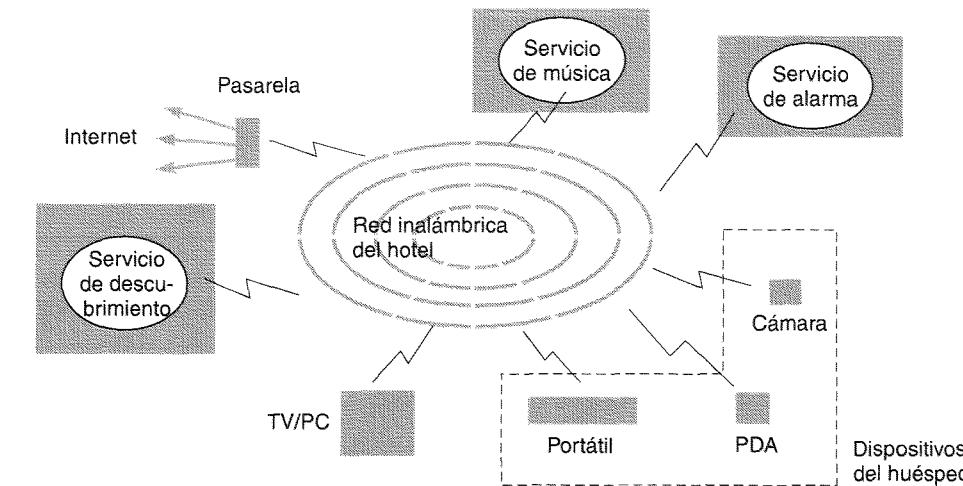


Figura 2.8. Intercomunicación espontánea en un hotel.

la cámara digital del huésped descubre servicios de visualización, como los de TV/PC, automáticamente, de modo que el huésped puede enviar las imágenes almacenadas de la cámara a la pantalla.

El enlace a red espontáneo conlleva algunas características de diseño significativas. Primero, está el reto de dar soporte a una conexión e integración adecuadas. Por ejemplo, los algoritmos de direccionamiento y rutado de Internet suponen que los computadores están ubicados en una subred particular. Si un computador se mueve a otra subred requiere otra dirección de Internet. En el Capítulo 3 se discute una aproximación a este problema.

Para usuarios móviles se presentan otras cuestiones. Éstos ven limitada su conectividad cuando viajan, y la naturaleza espontánea de su conexión incrementa los problemas de seguridad.

Conectividad limitada: los usuarios no siempre están conectados cuando se desplazan. Por ejemplo, al viajar en un tren por un túnel pueden estar desconectados eventualmente de su red inalámbrica. También pueden desconectarse durante largos períodos de tiempo en zonas sin cobertura o cuando el permanecer conectado sea demasiado costoso. El tema es aquí cómo puede el sistema dar soporte a un usuario para que siga trabajando mientras está desconectado. Este punto se discutirá en el Capítulo 14.

Seguridad y privacidad: en un escenario como el del huésped de un hotel se presentan muchas cuestiones de seguridad y privacidad personal. El hotel y sus huéspedes son vulnerables a los ataques de seguridad de los empleados y de otros huéspedes del hotel, que intenten conexiones inalámbricas de formas no supervisadas. Algunos sistemas siguen las direcciones físicas de los usuarios a medida que éstos se mueven (como los sistemas basados en «insignias activas» [Want y otros 1992]), y esto puede amenazar la privacidad de los usuarios. Por último, una instalación que permite a los usuarios acceder a su intranet mientras se mueven puede exponer los datos, que se supone permanecen detrás del cortafuegos de la intranet, o pueden abrir la intranet a ataques del exterior.

Servicios de detección: El enlace espontáneo a red necesita procesos clientes ejecutándose en los dispositivos portátiles, y otros aparatos, para acceder a los servicios de las redes a las que están conectados. Pero en un mundo de dispositivos que realizan diversas funciones, ¿cómo pueden conectarse los clientes a los servicios que necesitan para completar sus tareas habituales? Vamos a detallar esto en el contexto de un ejemplo específico: al volver al hotel, nuestro huésped desea ver

Tanto si adoptamos una arquitectura cliente-servidor estática o el modelo orientado a objetos, más dinámico, esbozado en el párrafo anterior, la distribución de responsabilidades entre procesos y entre computadores sigue siendo un aspecto importante del diseño. En el modelo arquitectónico tradicional, las responsabilidades se reservan estáticamente (un servidor de ficheros, por ejemplo, es sólo responsable de los ficheros, no de las páginas web, sus proxies u otros tipos de objetos). Pero en el modelo orientado a objetos los nuevos servicios, y en algunos casos los nuevos tipos de objeto, pueden ser instanciados e inmediatamente estar disponibles para la invocación.

2.2.5. REQUISITOS DE DISEÑO PARA ARQUITECTURAS DISTRIBUIDAS

Los factores que motivan la distribución de objetos y procesos en un sistema distribuido son numerosos y de considerable significado. La idea de compartir se logró, por vez primera, en los sistemas de tiempo compartido de los años sesenta con la utilización de archivos compartidos. Los beneficios de la compartición fueron reconocidos rápidamente y se explotaron en sistemas operativos como Oracle para permitir que los procesos compartieran recursos, dispositivos (capacidad de almacenamiento para ficheros, impresoras, secuencias de audio y de vídeo) y procesos de aplicación para compartir objetos de aplicación.

La llegada de potencia de cómputo barata, en forma de chips de microprocesador, eliminó la necesidad de compartir los procesadores centrales. La disponibilidad de redes de computadores de prestaciones medias y la continua necesidad de compartir recursos de hardware relativamente costosos como impresoras y almacenamiento en disco condujeron al desarrollo de los sistemas distribuidos de los años setenta y ochenta. Hoy, el compartir recursos se da por descontado. Pero compartir datos en gran escala de forma efectiva continúa siendo un reto mayor; con datos que cambian (y la mayoría de los datos cambian en el tiempo), aparece la posibilidad de actualizaciones concurrentes y conflictivas. El control de las actualizaciones concurrentes en datos compartidos es el tema de los Capítulos 12 y 13.

◊ **Temas de prestaciones.** Los retos que surgen de la distribución de recursos aumentan la necesidad de gestión de las actualizaciones concurrentes. Los temas de prestaciones que se presentan por las limitadas capacidades del proceso y comunicación de los computadores y las redes se consideran bajo los siguientes epígrafes:

Capacidad de respuesta (Responsiveness): Los usuarios de aplicaciones interactivas necesitan rapidez y consistencia en las interfaces, pero, a menudo, los programas cliente necesitan acceder a recursos compartidos. Cuando está implicado un servicio remoto, la velocidad a la que se genera la respuesta está determinada no sólo por la carga y prestaciones del servidor y la red sino también por los retardos de todos los componentes software implicados, la comunicación entre los sistemas operativos del cliente y del servidor y los servicios *middleware* (soporte para invocación remota, por ejemplo) así como el código del proceso que implementa el servicio.

En resumen, la transferencia de datos entre los procesos y la conmutación del control es relativamente lenta, incluso cuando los procesos residen en el mismo computador. Para obtener buenos tiempos de respuesta, los sistemas deben estar compuestos de relativamente pocas capas de software y la cantidad de datos transferidos entre el cliente y el servidor debe ser pequeña.

Estas cuestiones se pueden ver en las prestaciones de los visualizadores web clientes, donde se obtiene una respuesta más rápida cuando se accede localmente a páginas e imágenes de la caché, por lo que se encuentran almacenadas en la aplicación cliente. El acceso a páginas de texto remotas se produce con una rapidez razonable porque son pequeñas, pero las imágenes gráficas se retrasan mucho más por el volumen de datos implicado.

Productividad (Throughput): Una medida tradicional de prestaciones para computadores es la productividad, la rapidez a la que se realiza el trabajo computacional. La capacidad de un sistema

distribuido para realizar el trabajo para todos sus usuarios es importante. Y depende de las velocidades de proceso de los clientes y los servidores y de las tasas de transferencia de datos. Los datos que están localizados en un servidor remoto deben transferirse del proceso servido al proceso cliente.

distribuido para realizar el trabajo para todos sus usuarios es importante. Y depende de las velocidades de proceso de los clientes y los servidores y de las tasas de transferencia de datos. Los datos que están localizados en un servidor remoto deben transferirse del proceso servido al proceso cliente.

se deterioran significativamente, por lo que no se puede decir que proporcionen calidad de servicio. La calidad de servicio se aplica tanto a los sistemas operativos como a las redes. Cada recurso crítico debe reservarse para las aplicaciones que requieren QoS y deben ser los gestores de los recursos los que proporcionen las garantías. Las solicitudes de reserva que no se puedan cumplir se rechazan. Estos temas se considerarán además en el Capítulo 15.

◊ **Uso de caché y de replicación.** Los temas de prestaciones esbozados anteriormente resultan ser, a menudo, los principales obstáculos para el correcto lanzamiento de los sistemas distribuidos, aunque se han hecho nuevos progresos en el diseño de los sistemas, que los superan utilizando replicación y caché. La Sección 2.2.2 introdujo la caché y los servidores web proxy, sin discutir cómo las copias de los recursos en la caché pueden mantenerse actualizadas cuando se actualiza el recurso en el servidor. Para favorecer a diferentes aplicaciones se utiliza una variedad de protocolos de consistencia de caché; por ejemplo, en el Capítulo 8 se detallarán los protocolos utilizados por dos diseños diferentes de servidores de archivos. Aquí esbozamos el protocolo de caché de web que forma parte del protocolo HTTP, que se describirá en la Sección 4.4.

Protocolo de caché de web: Tanto las cachés de los navegadores web como de los servidores proxy responden a las solicitudes a los servidores web. Por tanto, una solicitud del cliente puede ser satisfecha por una respuesta en la caché del navegador o del servidor proxy entre él y el servidor web. El protocolo de consistencia de caché puede configurarse para proporcionar a los navegadores copias recientes (razonablemente actualizadas) de los recursos controlados por el servidor de web. Pero, para permitir prestaciones, disponibilidad y operación desconectada, puede relajarse la condición de actualización.

Un navegador o un proxy pueden *validar* una respuesta de la caché comprobando con el servidor web original para ver si estaba actualizada. Si la comprobación falla, el servidor devuelve una copia actualizada, que se guardará en la caché en lugar de la antigua. Cada navegador y cada proxy validan las respuestas de la caché cuando los clientes solicitan los recursos correspondientes. Pero, no necesitan realizar una validación si la respuesta almacenada está suficientemente actualizada. Incluso aunque los servidores web conozcan cuándo se ha actualizado un recurso, no lo notifica al navegador o proxy con caché, para poder hacer esto el usuario necesitaría mantener un registro de cada navegador y cada proxy interesado en cada uno de sus recursos. Para permitir que un navegador o un proxy determinen si sus respuestas almacenadas están obsoletas, los servidores web asignan tiempos de expiración aproximada a sus recursos, estimados, por ejemplo, desde la última vez que fueron actualizados. Un tiempo de expiración puede resultar incorrecto, dado que un recurso web puede actualizarse en cualquier instante. Cuando un servidor web responde a una solicitud, el tiempo de expiración del recurso y el tiempo actual del servidor se adjuntan a la respuesta.

Cada navegador y proxy almacena el tiempo de expiración y el del servidor junto con la respuesta que se almacena en la caché. Esto permite que un navegador o proxy que reciban futuras solicitudes calculen si la respuesta almacenada en la caché está obsoleta. Esto se calcula comparando su edad con el tiempo de expiración. La *edad* de una respuesta es la suma del tiempo en el que la respuesta fue guardada en la caché y el tiempo del servidor. Hay que señalar que este cálculo no depende de que los relojes del servidor web y del navegador o proxy estén de acuerdo entre sí.

◊ **Aspectos de fiabilidad.** La fiabilidad es un requisito en la mayoría de los dominios de aplicación. Es crucial no sólo en actividades de control y gobierno, en las que la vida puede estar en juego, sino también en muchas aplicaciones comerciales, incluyendo las de comercio en Internet, que han experimentado un notable crecimiento, en las que la seguridad y solidez financiera de los participantes depende de la fiabilidad de los sistemas sobre los que operan. En la Sección 2.1 se ha definido la fiabilidad de los sistemas informáticos como *corrección, seguridad y tolerancia a fallos*. Aquí se discute el impacto arquitectónico de las necesidades de seguridad y tolerancia a fallos, dejando la descripción de las técnicas relevantes para su consecución para más adelante en el

libro. El desarrollo de técnicas para comprobar y asegurar la corrección de los programas distribuidos y concurrentes es un tema de investigación actual e importante. A pesar de presentar resultados prometedores, sólo algunos de éstos se encuentran suficientemente maduros para su implantación en aplicaciones reales.

Tolerancia frente a fallos: Las aplicaciones estables deben continuar funcionando correctamente en presencia de fallos en el hardware, el software y las redes. La fiabilidad se consigue introduciendo redundancia; proporcionando múltiples recursos de modo que el software de sistema y aplicación pueda ser reconfigurado y seguir realizando sus tareas en presencia de fallos. La redundancia es costosa y existen límites a la amplitud en que puede ser empleada; en consecuencia también hay límites en el grado de tolerancia que puede obtenerse.

A nivel arquitectónico, la redundancia precisa el empleo de varios computadores donde lanzar cada proceso componente del sistema y múltiples caminos de comunicación sobre los que transmitir los mensajes. Los datos y los procesos pueden replicarse donde quiera que sea necesario para proporcionar el debido nivel de tolerancia a fallos. Una forma usual de redundancia es la presencia de varias réplicas de los datos en diferentes computadores; en tanto en cuanto uno cualquiera de los computadores continúe funcionando, se podrá acceder a los datos. Algunas aplicaciones críticas, tales como los sistemas de control de tráfico aéreo, precisan un alto nivel de garantías en cuanto a la tolerancia frente a fallos, lo que implica un alto coste de mantenimiento de la actualización de las múltiples réplicas existentes. En el Capítulo 14 se discute esta materia más profundamente.

Para hacer fiables los protocolos de comunicación se emplean otras técnicas. Por ejemplo, los mensajes se retransmiten hasta que se ha recibido un mensaje de reconocimiento. La fiabilidad de los protocolos subyacentes a RMI se cubren en los Capítulos 4 y 5.

Seguridad: El impacto arquitectónico de los requisitos de seguridad afecta a la necesidad de ubicar los datos y otros recursos sensibles sólo en aquellos computadores equipados de un modo eficaz contra ataques. Por ejemplo, una base de datos de un hospital alojará registros con un componente sensible sobre los pacientes y sólo ciertos empleados podrán acceder a ellos, mientras que otros componentes de los mismos registros pueden estar disponibles más ampliamente. No sería apropiado construir un sistema en el que al acceder a los datos de un paciente se descargara el registro completo de éste en el computador de sobremesa del usuario, dado que el computador típico de sobremesa no constituye un entorno seguro, y los usuarios podrían lanzar programas para acceder o actualizar cualquier parte de los datos almacenados en su computador personal. En la Sección 2.3.3 se presenta un modelo de seguridad que trata con requisitos amplios para la seguridad, el Capítulo 7 describirá las técnicas disponibles para obtenerlo.

2.3 MODELOS FUNDAMENTALES

Todos los modelos de sistemas anteriores, aunque bien diferentes, comparten algunas propiedades fundamentales. En particular, todos ellos se componen de procesos que se comunican unos con otros mediante el envío de mensajes en una red de computadores. Todos los modelos comparten los requisitos de diseño dados en la sección previa, y que conciernen principalmente a las características de prestaciones y fiabilidad de los procesos y las redes, y a la seguridad de los recursos en el sistema. En esta sección, presentamos modelos basados en las propiedades fundamentales que nos permiten ser más específicos sobre las características y los riesgos de fallos y seguridad que puedan exhibir.

En general, un modelo contiene solamente aquellos ingredientes esenciales que necesitamos para comprender y razonar sobre algunos aspectos del comportamiento del sistema. Un modelo de sistema debe tratar las siguientes cuestiones:

- ¿Cuáles son las entidades principales en el sistema?
- ¿Cómo interactúan?
- ¿Cuáles son las características que afectan su comportamiento individual y colectivo?

El objetivo de un modelo es:

- Hacer explícitas todas las premisas relevantes sobre los sistemas que estamos modelando.
- Hacer generalizaciones respecto a lo que es posible o no, dadas las premisas anteriores. Las generalizaciones pueden tomar la forma de algoritmos de propósito general o de propiedades deseables que se garantizan. Las garantías surgirán del análisis lógico y, cuando sea pertinente, de la prueba matemática.

Hay mucho que ganar si conocemos lo que hacen y de lo que dependen nuestros diseños, y de lo que no. Así podremos decidir si un diseño funcionará si intentamos implementarlo en un sistema particular: sólo necesitamos preguntarnos si nuestras premisas son válidas en ese sistema. A la vez, aclarando y explicitando nuestras premisas, podemos esperar demostrar propiedades del sistema empleando técnicas matemáticas. Estas propiedades valdrán para cualquier sistema que concuerde con nuestras premisas. Finalmente, al abstraer sólo entidades y características esenciales del sistema (y no detalles, como el hardware) podemos arrojar luz sobre nuestra comprensión de estos sistemas.

Los aspectos de los sistemas distribuidos que queremos capturar en nuestros modelos fundamentales están destinados a ayudarnos a discutir y razonar sobre:

Interacción: el cómputo ocurre en los procesos; los procesos interaccionan por paso de mensajes, lo que deviene en comunicación (esto es, flujo de información) y coordinación (sincronización y ordenamiento de actividades) entre procesos. En el análisis y diseño de los sistemas distribuidos trataremos especialmente con estas interacciones. El modelo de interacción debe reflejar hechos como que la comunicación tiene lugar con retrasos, que a menudo son de considerable duración, y la precisión con que la pueden coordinarse procesos independientes está limitada por esos retrasos y por la dificultad de mantener la misma noción de tiempo en todos los computadores de un sistema distribuido.

Fallo: la correcta operación de un sistema distribuido se ve amenazada allá donde aparezca un fallo en cualquiera de los computadores sobre el que se ejecuta (incluyendo fallos de software) o en la red que los conecta. Nuestro modelo define y clasifica los fallos. Esto nos da la base para el análisis de los efectos potenciales de los fallos y para el diseño de sistemas que tolerando fallos de cualquier tipo puedan seguir funcionando correctamente.

Seguridad: la naturaleza modular de los sistemas distribuidos y su extensibilidad los expone a ataques tanto de agentes externos como internos. Nuestro modelo de seguridad define y clasifica los modos en que pueden tener lugar tales ataques, y proporciona una base para el análisis de las amenazas a un sistema con el fin de diseñar sistemas capaces de resistirse a ellas.

Para discutir y razonar más fácilmente, los modelos presentados en este capítulo están necesariamente simplificados, omitiéndose muchos detalles de los sistemas reales. Su relación con los sistemas del mundo real y la solución que esos modelos nos ayudan a traer a colación, en ese contexto, son el tema principal de este libro.

2.3.1. MODELO DE INTERACCIÓN

La discusión de arquitecturas de sistemas de la Sección 2.2 indica que los sistemas distribuidos se componen de muchos procesos, y que interactúan de formas complejas. Por ejemplo:

- Múltiples procesos servidores pueden cooperar entre sí para proporcionar un servicio; los ejemplos mencionados anteriormente son el Servicio de Nombres de Dominio, que parte y

replica sus datos en los servidores a lo largo de Internet; y el Servicio de Información en Red

replica sus datos en los servidores a lo largo de Internet; y el Servicio de Información en Red de Sun, que mantiene copias replicadas de los archivos de contraseñas en varios servidores de una red de área local.

~~Un conjunto de procesos similares pueden cooperar entre sí para la ejecución de un algoritmo.~~

similar, pero con estrictas restricciones de tiempo real.

La mayoría de los programadores estarán familiarizados con el concepto de *algoritmo*: secuencia de pasos que hay que seguir para realizar un cómputo deseado. Los programas simples están controlados por algoritmos en los que los pasos son estrictamente secuenciales. El comportamiento del programa y el estado de las variables del programa está determinado por aquéllos. Tal programa se ejecuta como un proceso aislado. Los sistemas distribuidos compuestos de varios procesos, tales como los delineados anteriormente, son más complejos. Su comportamiento y el estado puede describirse mediante un *algoritmo distribuido*: una definición de los pasos que hay que llevar a cabo por cada uno de los procesos de que consta el sistema, *incluyendo los mensajes de transmisión entre ellos*. Los procesos transmiten mensajes de uno a otro para transferir información y coordinar su actividad.

La tasa con que procede cada proceso y la temporización de la transmisión de los mensajes entre ellos no puede predecirse, en general. También es difícil describir todos los estados de un algoritmo distribuido, dado que éste debe tratar con los fallos de uno, o más, de los procesos invo-

- La fluctuación (*jitter*) es la variación en el tiempo invertido en completar el reparto de una serie de mensajes. La fluctuación es importante para los datos multimedia. Éste es el caso que si se reproducen muestras de audio consecutivas a un ritmo variable el sonido presentará graves distorsiones.

◊ **Relojes de computadores y eventos de temporización.** Cada computador de un sistema distribuido tiene su propio reloj interno; los procesos locales obtienen de él, el valor del tiempo actual. Ésta es la forma en que dos procesos en ejecución sobre dos computadores diferentes asocian marcas (o sellos) temporales a sus eventos. Sin embargo, incluso si dos procesos leen sus relojes a la vez, sus relojes locales proporcionarán valores de tiempo diferentes. Esto ocurre porque los relojes presentan derivas con respecto al tiempo perfecto y, más importante, sus tasas de deriva difieren de una a otra. El término *tasa de deriva del reloj* alude a la proporción en que el reloj de un computador difiere del reloj de referencia perfecto. Incluso, si los relojes de todos los computadores de un sistema distribuido se ponen en hora a la vez, a partir de un tiempo sus relojes variarán en una magnitud significativa a menos que se apliquen correcciones.

Hay varias aproximaciones a la corrección de los tiempos del reloj de los computadores. Así, podría utilizarse receptores de radio para obtener lecturas de tiempo de un GPS con aproximaciones cercana al microsegundo. Pero los receptores GPS no operan dentro de los edificios, ni se justifica el coste para cada computador. En su lugar, un computador dotado de una fuente de tiempo precisa, como un GPS, sí que podría enviar mensajes de temporización a otros computadores de la red. La concordancia final entre los tiempos de los relojes locales está, por supuesto, afectada por retardos variables en los mensajes. Para una discusión más detallada de la deriva del reloj y sincronización del reloj, véase el Capítulo 11.

◊ **Dos variantes del modelo de interacción.** En un sistema distribuido es difícil establecer cotas sobre el tiempo que debe tomar la ejecución de un proceso, el reparto de un mensaje o la deriva del reloj. Tenemos dos modelos simples que parten de posiciones extremas y opuestas: el primero tiene en cuenta una fuerte restricción sobre el tiempo; en el segundo no se hace ninguna presuposición.

Sistemas distribuidos síncronos: Hadzilacos y Toueg [1994] definen un sistema distribuido síncrono como aquel en el que se establecen los siguientes límites:

- El tiempo de ejecución de cada etapa de un proceso tiene ciertos límites inferior y superior conocidos.
- Cada mensaje transmitido sobre un canal se recibe en un tiempo limitado conocido.
- Cada proceso tiene un reloj local cuya tasa de deriva sobre el tiempo real tiene un límite conocido.

Es posible sugerir valores parecidos para los límites superior e inferior del tiempo de ejecución de un proceso, el retardo de mensajes y las tasas de deriva de relojes en un sistema distribuido. Pero es difícil obtener valores realistas y además dar garantías sobre los valores elegidos. A menos que podamos garantizar los límites, cualquier diseño basado en los valores elegidos no será fiable. Sin embargo, pudiera ser útil modelar un algoritmo como un sistema síncrono para dar una idea de cómo se comportará en un sistema distribuido real. En un sistema síncrono, es posible utilizar tiempo límite (*timeouts*), por ejemplo para detectar el fallo de un proceso, tal y como se muestra en la sección que trata del modelo de fallo.

Se pueden construir sistemas distribuidos síncronos. Esto requiere que los procesos implementen tareas con requisitos de recursos conocidos, para los que se pueda garantizar ciclos suficientes de procesador y capacidad de red; y que se provea a estos procesos de relojes con tasas de deriva limitada.

Sistemas distribuidos asíncronos: muchos sistemas distribuidos, por ejemplo Internet, son de gran utilidad aun sin ser sistemas síncronos. En consecuencia necesitamos un modelo alternativo: un sistema distribuido asíncrono es aquel en que no existen limitaciones sobre:

- La velocidad de procesamiento (por ejemplo, un paso de un proceso puede requerir tan sólo un picosegundo y otro un siglo; lo único que podemos decir es que cada paso se tomará un tiempo arbitrariamente largo).
- Los retardos de transmisión de mensaje (por ejemplo, al repartir un mensaje de un proceso A a otro B puede tardar un tiempo cero o bien varios años. En otras palabras, un mensaje puede recibirse tras un tiempo arbitrariamente largo).
- Las tasas de deriva de reloj (de nuevo, la tasa de deriva de reloj es arbitraria).

El modelo asíncrono no presupone nada sobre los intervalos de tiempo involucrados en cualquier ejecución. Éste es exactamente el modelo de Internet, en él no hay límite intrínseco en la carga del servidor o la red (en consecuencia no se sabe cuánto tomará, por ejemplo, transferir un archivo usando ftp). A veces un mensaje de correo puede tomarse varios días en llegar. El recuadro de la página siguiente ilustra la dificultad de llegar a un acuerdo en un sistema distribuido asíncrono.

Aun así con estas premisas se pueden resolver algunos problemas de diseño. Por ejemplo, a pesar de que el Web no siempre puede proveer una respuesta en un límite de tiempo razonable, los navegadores se diseñan para permitir que los usuarios realicen otras tareas mientras están a la espera. Cualquier solución válida para un sistema distribuido asíncrono es válida también para un sistema síncrono.

Los sistemas distribuidos reales son frecuentemente asíncronos a causa de la necesidad de los procesos de compartir procesadores y de los canales de comunicación de compartir la red. Por ejemplo, si demasiados procesos de índole desconocida comparten un procesador, no habrá garantías sobre las prestaciones resultantes de ninguno de ellos. Pero existen muchos problemas de diseño que no pueden ser resueltos para un sistema asíncrono que pueden resolverse cuando se tienen en cuenta algunos aspectos temporales. La necesidad de que cada elemento de un flujo de datos multimedia se reparta antes de un tiempo límite es un problema de este tipo. Para problemas como éste se requiere un modelo síncrono. El recuadro de más adelante ilustra la imposibilidad de sincronizar los relojes en un sistema asíncrono.

◊ **Ordenamiento de eventos.** En muchos casos, nos interesa saber si un evento (enviar o recibir un mensaje) en un proceso ocurrió antes, después o concurrentemente con otro evento en algún otro proceso. La ejecución de un sistema puede describirse en términos de los eventos y su ordenación aun careciendo de relojes precisos.

Por ejemplo, considere el siguiente conjunto de intercambios entre un pequeño grupo de usuarios X, Y, Z y A de una lista de correo:

1. El usuario X envía un mensaje con el tema *Reunión*.
2. Los usuarios Y y Z responden con un mensaje con el tema *Re: Reunión*.

En tiempo real, se envía primero el mensaje de X, Y lo lee y responde; Z lee ambos mensajes, el de X y la respuesta de Y y entonces envía otra respuesta, que hace referencia a los dos anteriores. Pero debido a los retardos independientes en el reparto de los mensajes, los mensajes pudieran haber sido repartidos como se muestra en la Figura 2.9, y algunos usuarios podrían ver estos mensajes en el orden equivocado, por ejemplo, el usuario A podría ver:

Bandeja de entrada:		
De	Asunto	Elemento
23	Z	Re: Reunión
24	X	Reunión
25	Y	Re: Reunión

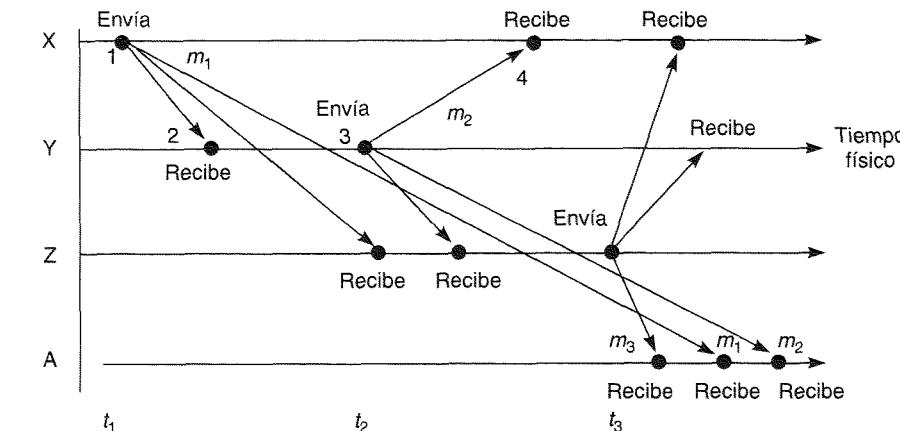


Figura 2.9. Ordenamiento real en el tiempo de los eventos.

◊ **Acuerdo en Pimientolandia.** Dos divisiones del ejército de Pimientolandia «Manzana» y «Naranja», se encuentran acampadas en lo alto de dos colinas adyacentes. Por otro lado a lo largo del valle entre ambas están los invasores Tontortones Azules. Las divisiones de Pimientolandia se encuentran seguras tanto en cuanto permanezcan en sus campamentos, y puedan enviar mensajeros con seguridad a través del valle para comunicarse. Las divisiones de Pimientolandia necesitan ponerse de acuerdo sobre cuál de ellas encabezará la carga contra los Tontortones Azules, y cuándo tendrá lugar. Incluso en una Pimientolandia asíncrona, es posible acordar sobre quién conducirá la carga. Por ejemplo, cada división comunica el número de sus efectivos, y el que tenga más atacará primero (si están empatados, la división Manzana gana sobre la Naranja). Pero, ¿cuándo deben cargar? Desafortunadamente, en una Pimientolandia asíncrona, los mensajeros se desplazan con una velocidad muy variable. Pongamos que, Manzana envía un mensajero con el texto «¡Carguen!». Naranja podría no recibir el mensaje hasta, digamos, tres horas; o bien pudiera ser que fueran cinco minutos. En una Pimientolandia síncrona, aun existiría un problema de coordinación, pero las divisiones saben de ciertas restricciones útiles: cada mensaje toma al menos *min* minutos y a lo más *max* minutos en llegar. Si la división que conduce la carga envía un mensaje «¡Carguen!», esperaría durante *min* minutos y entonces cargaría. La otra división esperaría durante 1 minuto tras recibir el mensaje y cargaría a continuación. Está garantizado que su carga ocurrirá siempre en segundo lugar, pero no más tarde de (*max* - *min* + 1) minutos.

Si los relojes de los computadores de X, Y y Z pudieran sincronizarse, podría utilizarse el tiempo asociado localmente a cada mensaje enviado. Por ejemplo, los mensajes *m*₁, *m*₂ y *m*₃ llevarían los tiempos *t*₁, *t*₂ y *t*₃ donde *t*₁ < *t*₂ < *t*₃. Los mensajes recibidos se mostrarían a los usuarios según este ordenamiento temporal. Si los relojes están sincronizados aproximadamente la temporización ocurriría en el orden correcto.

Como los relojes de un sistema distribuido no pueden sincronizarse de manera perfecta, Lamport [1987] propuso un modelo de *tiempo lógico* que pudiera utilizarse para ordenar los eventos de procesos que se ejecutan en computadores diferentes de un sistema distribuido. El tiempo lógico permite inferir el orden en que se presentan los mensajes sin recurrir a relojes. Se presenta en detalle en el Capítulo 10, aunque aquí bosquejaremos cómo pueden aplicarse algunos aspectos del ordenamiento lógico a nuestro problema de ordenamiento de correos electrónicos.

Es obvio que los mensajes se reciben después de su envío, así podemos admitir un ordenamiento lógico para los pares de sucesos que se muestran en la Figura 2.9; por ejemplo, considerando sólo los eventos relativos a X e Y:

X envía m_1 antes de que Y reciba m_1 ; Y envía m_2 antes de que X reciba m_2 .

También sabemos que las respuestas se reciben después de que se reciben los mensajes, de modo que tenemos el siguiente ordenamiento lógico para Y:

Y recibe m_1 antes de enviar m_2 .

El tiempo lógico lleva esta idea más lejos asignando un número a cada evento, que se corresponde con su ordenamiento lógico, de modo que los últimos eventos tendrán números mayores que los primeros. Como ejemplo, en la Figura 2.9 se consignan los números 1 a 4 en los eventos en X e Y.

2.3.2. MODELO DE FALLO

En un sistema distribuido pueden fallar tanto los procesos como los canales de comunicación; esto es, podrían apartarse de lo que se considera el comportamiento correcto o deseable. El modelo de fallo define las formas en que puede ocurrir el fallo para darnos una comprensión de los efectos de los fallos. Hadzilacos y Toueg [1994] proponen una taxonomía que distingue entre los fallos de procesos y los fallos de canales de comunicación. Éstos se presentan bajo los encabezamientos: fallos por omisión, fallos arbitrarios y fallos de temporización.

Este modelo de fallo se utilizará a lo largo del libro. Éste es el caso de:

- En el Capítulo 4, donde presentamos las interfaces Java de la comunicación de tipo *datagrama* y *stream*, que proporcionan diferentes grados de fiabilidad.
- El Capítulo 4 en el que presentamos el protocolo petición-respuesta, que subyace a RMI. Sus características de fallo dependen de las características de fallo tanto de los procesos como de los canales de comunicación. El protocolo puede construirse mediante comunicación basada en datagramas o streams. La elección podrá decidirse en función de la simplicidad de la implementación, las prestaciones y la fiabilidad.
- El Capítulo 13 donde se presenta el protocolo de realización en dos fases (*two-phase commit*) para transacciones. Está diseñado para completarse en presencia de fallos bien definidos de los procesos y de los canales de comunicación.

◊ **Fallos por omisión.** Las faltas clasificadas como *fallos por omisión* se refieren a casos en los que los procesos o los canales de comunicación no consiguen realizar acciones que se suponen que pueden hacer.

Fallos por omisión de procesos: El principal fallo por omisión de un proceso es el fracaso o ruptura accidentada del procesamiento (*crash*). Cuando decimos que un proceso se rompe queremos decir que ha parado y no ejecutará ningún paso de programa más. El diseño de servicios que puedan sobrevivir en presencia de fallos se puede simplificar si asumimos que los servicios de los que depende fracasan limpiamente; es decir, los procesos de los que depende o funcionan correctamente o se detienen. Otros procesos pueden ser capaces de detectar tales fracasos por el hecho de que los procesos rotos fallan repetidamente en responder a los mensajes de invocación. Desgraciadamente, este método de detección de rupturas descansa en el uso de *timeouts*; es decir un método en el cual un proceso otorga un período fijo de tiempo para que algo ocurra. En un sistema asíncrono un timeout puede indicar tan sólo que un proceso no responde; puede que se haya roto o sea lento, o que los mensajes no hayan llegado.

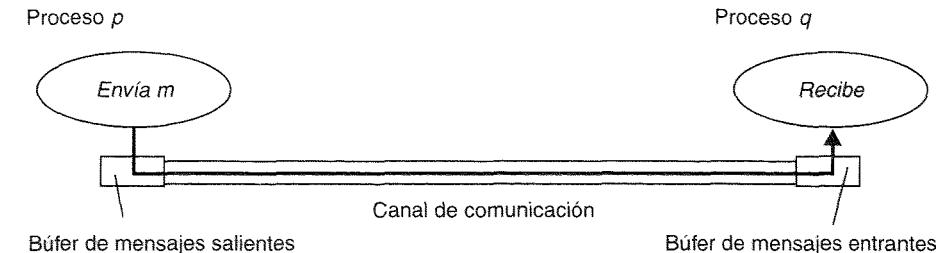


Figura 2.10. Procesos y canales.

La rotura de un proceso se denomina *fallo-parada* (*fail-stop*) si los otros procesos pueden detectar con certeza que el proceso ha fracasado. El comportamiento *fallo-parada* puede producirse en un sistema síncrono si el proceso utiliza timeouts para detectar cuando los otros procesos fallan en la respuesta y está garantizado que los mensajes llegan. Por ejemplo, si los procesos *p* y *q* están programados para que *q* responda a un mensaje de *p*, y el proceso *p* no ha recibido respuesta del proceso *q* en un tiempo máximo medido por el reloj local de *p*, entonces el proceso *p* puede concluir que el proceso *q* ha fallado. El recuadro próximo ilustra la dificultad de detectar los fallos en un sistema asíncrono o de llegar a un acuerdo en presencia de fallos.

Fallos por omisión de comunicaciones: Considere las primitivas de comunicación *envía* y *recibe*. Un proceso *p* realiza un *envía* insertando el mensaje *m* en su búfer de mensajes salientes. El canal de comunicación transporta *m* al búfer de mensajes entrantes de *q*. El proceso *q* realiza un *recibe* tomando *m* de su búfer de mensajes entrantes y repartiéndolo (véase la Figura 2.10). Los búferes entrante y saliente se proporcionan usualmente desde el sistema operativo.

El canal de comunicación produce un fallo de omisión si no transporta un mensaje desde el búfer de mensajes salientes de *p* al búfer de mensajes entrantes de *q*. A esto se denomina «perder mensajes» y su causa suele ser la falta de espacio en el búfer de recepción de alguna pasarela de entre medias, o por un error de red, detectable por una suma de chequeo de los datos del mensaje. Hadzilacos y Toueg [1994] se refieren a la pérdida de mensajes entre el proceso emisor y el búfer de mensajes de salida como *fallos por omisión de envío*; la pérdida de mensajes entre el búfer de mensajes de entrada y el proceso receptor como *fallos por omisión de recepción*; y la pérdida de mensajes entre los búferes como *fallos por omisión del canal*. En la Figura 2.11 se clasifican los fallos por omisión junto con los fallos arbitrarios.

◊ **Detección de fallos.** En el caso de las divisiones de Pimientolandia acampadas en la cumbre de las colinas (véase la página 49), suponga que los Tontorrones Azules son, después de todo, suficientemente fuertes como para atacar y vencer a cualquier división mientras está acampada (es decir, que cualquiera de ambas puede fallar). Suponga aún más, mientras se encuentran invictas, las divisiones envían mensajeros regularmente para comunicar su estado. En un sistema asíncrono, ninguna división puede distinguir si la otra ha sido derrotada o si es que el tiempo que emplean los mensajeros en cruzar el valle entre ambas es un poco largo. En una Pimientolandia síncrona, una división puede tener por cierto si la otra ha sido derrotada, por la ausencia del puntual mensajero. Sin embargo, la otra división pudiera haber sido derrotada justo después de haber enviado su último mensajero.

◊ **Imposibilidad de alcanzar un acuerdo en presencia de fallos.** Hemos estado presuponiendo que los mensajeros de Pimientolandia siempre se las arreglan para cruzar el valle de alguna forma; pero supongamos ahora que los Tontorrones Azules pueden capturar cualquier

mensajero e impedir que llegue. (Supondremos que, para los Tontorrones Azules, es imposible realizar un lavado de cerebro a los mensajeros para que den el mensaje falso; los Tontorrones no estaban al tanto de sus precursores, los traicioneros bizantinos.) ¿Podrán las divisiones Manzana y Naranja enviar mensajes de modo que puedan ponerse de acuerdo en decidir cargar contra los Tontorrones, o siquiera rendirse a la vez? Desafortunadamente, como probó el teórico pimentonés Ringo el Grande, en estas circunstancias las divisiones no pueden garantizar el decidir consistentemente qué hacer. Para convencerse de esto, suponga el contrario, que las divisiones manejan un protocolo Pimientón que permite lograrlo. Cada uno propone «¡Carguen!» o «¡Ríndanse!» y el resultado es que ambos deciden ponerse de acuerdo en uno u otro curso de acción. Ahora considere el último mensaje enviado en cualquier secuencia del protocolo. El mensajero que lo lleva podría haber sido capturado por los Tontorrones Azules. De modo que el resultado debiera ser el mismo tanto si el mensaje llega como si no: podemos prescindir de él. Ahora apliquemos el mismo argumento al mensaje final que resta. Pero, aplicaríamos este argumento de nuevo al mensaje y así hasta que no nos quedara nada de él! Esto muestra que no puede existir ningún protocolo que garantice el acuerdo entre las divisiones de Pimientolandia si los mensajeros pueden ser capturados.

Clase de fallo	Afecta a	Descripción
Fallo-parada	Proceso	El proceso para y permanece parado. Otros procesos pueden detectar este estado.
Ruptura	Proceso	El proceso para y permanece parado. Otros procesos pueden no ser capaces de detectar este estado.
Omisión	Canal	Un mensaje insertado en el búfer de mensajes salientes nunca llega al búfer de mensajes entrantes del otro extremo.
Omisión de envío	Proceso	Un proceso completa <i>envía</i> , pero el mensaje no es colocado en su búfer de mensajes salientes.
Omisión de recepción	Proceso	El mensaje es colocado en la cola de mensajes del proceso, pero el proceso no lo recibe.
Arbitrario (Bizantino)	Proceso o canal	El proceso/canal presenta un comportamiento arbitrario: puede enviar/transmitir arbitrariamente mensajes en instantes arbitrarios, cometer omisiones; un proceso puede parar o realizar un paso incorrecto.

Figura 2.11. Fallos por omisión y fallos arbitrarios.

Los fallos pueden categorizarse según su severidad. Todos los fallos que hemos descrito hasta el momento son *benignos*. La mayoría de los fallos de los sistemas distribuidos son de esta clase. Los fallos benignos incluyen fallos por omisión así como fallos de temporización y fallos de prestaciones.

◊ **Fallos arbitrarios.** El término *arbitrario*, o fallo *bizantino*, se emplea para describir la peor semántica de fallo posible, en la que puede ocurrir cualquier tipo de error. Por ejemplo, un proceso podría cargar valores equivocados en su área de datos, o podría responder un valor incorrecto a una petición.

Un fallo arbitrario en un proceso es aquel en el que se omiten pasos deseables para el procesamiento o se realizan pasos no intencionados de procesamiento. En consecuencia los fallos arbitrarios en los procesos no pueden detectarse observando si el proceso responde a las invocaciones, dado que podría omitir arbitrariamente la respuesta.

Los canales de comunicación sufren fallos arbitrarios; por ejemplo: los contenidos de un mensaje pueden estar corrompidos o se pueden repartir mensajes no existentes, o incluso algunos

Clase de fallo	Afecta a	Descripción
Reloj	Proceso	El reloj local del proceso excede el límite de su tasa de deriva sobre el tiempo real.
Prestaciones	Proceso	El proceso excede el límite sobre el intervalo entre dos pasos.
Prestaciones	Canal	La transmisión de un mensaje toma más tiempo que el límite permitido.

Figura 2.12. Fallo de temporización.

mensajes auténticos pueden repartirse más de una vez. Los fallos arbitrarios de los canales de comunicación son raros porque el software de comunicación es capaz de reconocerlos y rechazar los mensajes fallidos. Por ejemplo, para detectar mensajes corrompidos empleamos sumas de chequeo, y podemos emplear números de secuencia para detectar mensajes no existentes y mensajes duplicados.

◊ **Fallos de temporización.** Los fallos de temporización se aplican en los sistemas distribuidos síncronos donde se establecen límites en el tiempo de ejecución de un proceso, en el tiempo de reparto de un mensaje y en la tasa de deriva de reloj. Los fallos de temporización se muestran en la Figura 2.12. Cualquiera de estos fallos puede ocasionar que las respuestas no estuvieran disponibles para los clientes en un intervalo de tiempo dado.

En un sistema distribuido asíncrono, un servidor sobrecargado podría responder demasiado lentamente, pero no podemos decir que haya habido un fallo de temporización dado que no se ha ofrecido ninguna garantía al respecto.

Los sistemas operativos de tiempo real se diseñan con vistas a proporcionar garantías de temporización, pero son más complejos de diseñar y pueden requerir hardware redundante. La mayoría de los sistemas operativos de propósito general, como UNIX, no tienen que cumplir restricciones de tiempo real.

La temporización es particularmente relevante en los computadores multimedia con canales de audio y vídeo. La información de vídeo puede requerir la transferencia de una gran cantidad de datos. El reparto de tal cantidad de información, sin fallos de temporización, puede exigir demandas especiales tanto en el sistema operativo como en el sistema de comunicación.

◊ **Enmascaramiento de fallos.** Cada componente de un sistema distribuido se construye generalmente a partir de un conjunto de componentes ya existentes. Es posible construir servicios fiables con componentes que presenten fallos. Por ejemplo, múltiples servidores que alojen réplicas de datos pueden continuar prestando un servicio aunque uno de ellos se rompa. El conocimiento de las características de fallo de un componente puede permitirnos crear un nuevo servicio diseñado para enmascarar los fallos del primero. Un servicio *enmascara* un fallo, bien, ocultándolo completamente o convirtiéndolo en otro tipo de fallo más aceptable. Un ejemplo de este último es el cómo se utilizan las sumas de chequeo para enmascarar los mensajes corrompidos, convirtiendo un fallo arbitrario en un fallo por omisión. Veremos en los Capítulos 3 y 4 que los fallos por omisión pueden ocultarse empleando un protocolo que retransmita los mensajes que no alcanzan su destino. El Capítulo 14 presenta el enmascaramiento mediante replicación. Incluso la ruptura de procesos puede enmascaramarse, remplazando el proceso y restaurando su memoria de la información almacenada en el disco sobre su predecesor.

◊ **Fiabilidad y comunicación uno a uno.** Aunque un canal de comunicación básico pueda presentar fallos por omisión como los descritos anteriormente, es posible utilizarlo para construir un servicio de comunicación que enmascare algunos de esos fallos.

El término *comunicación fiable* se define en términos de validez e integridad, definidos como sigue:

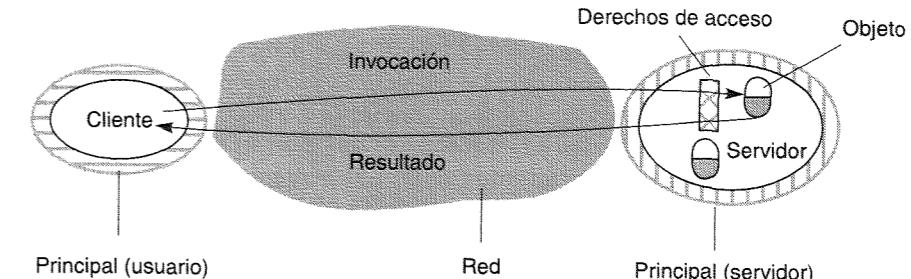
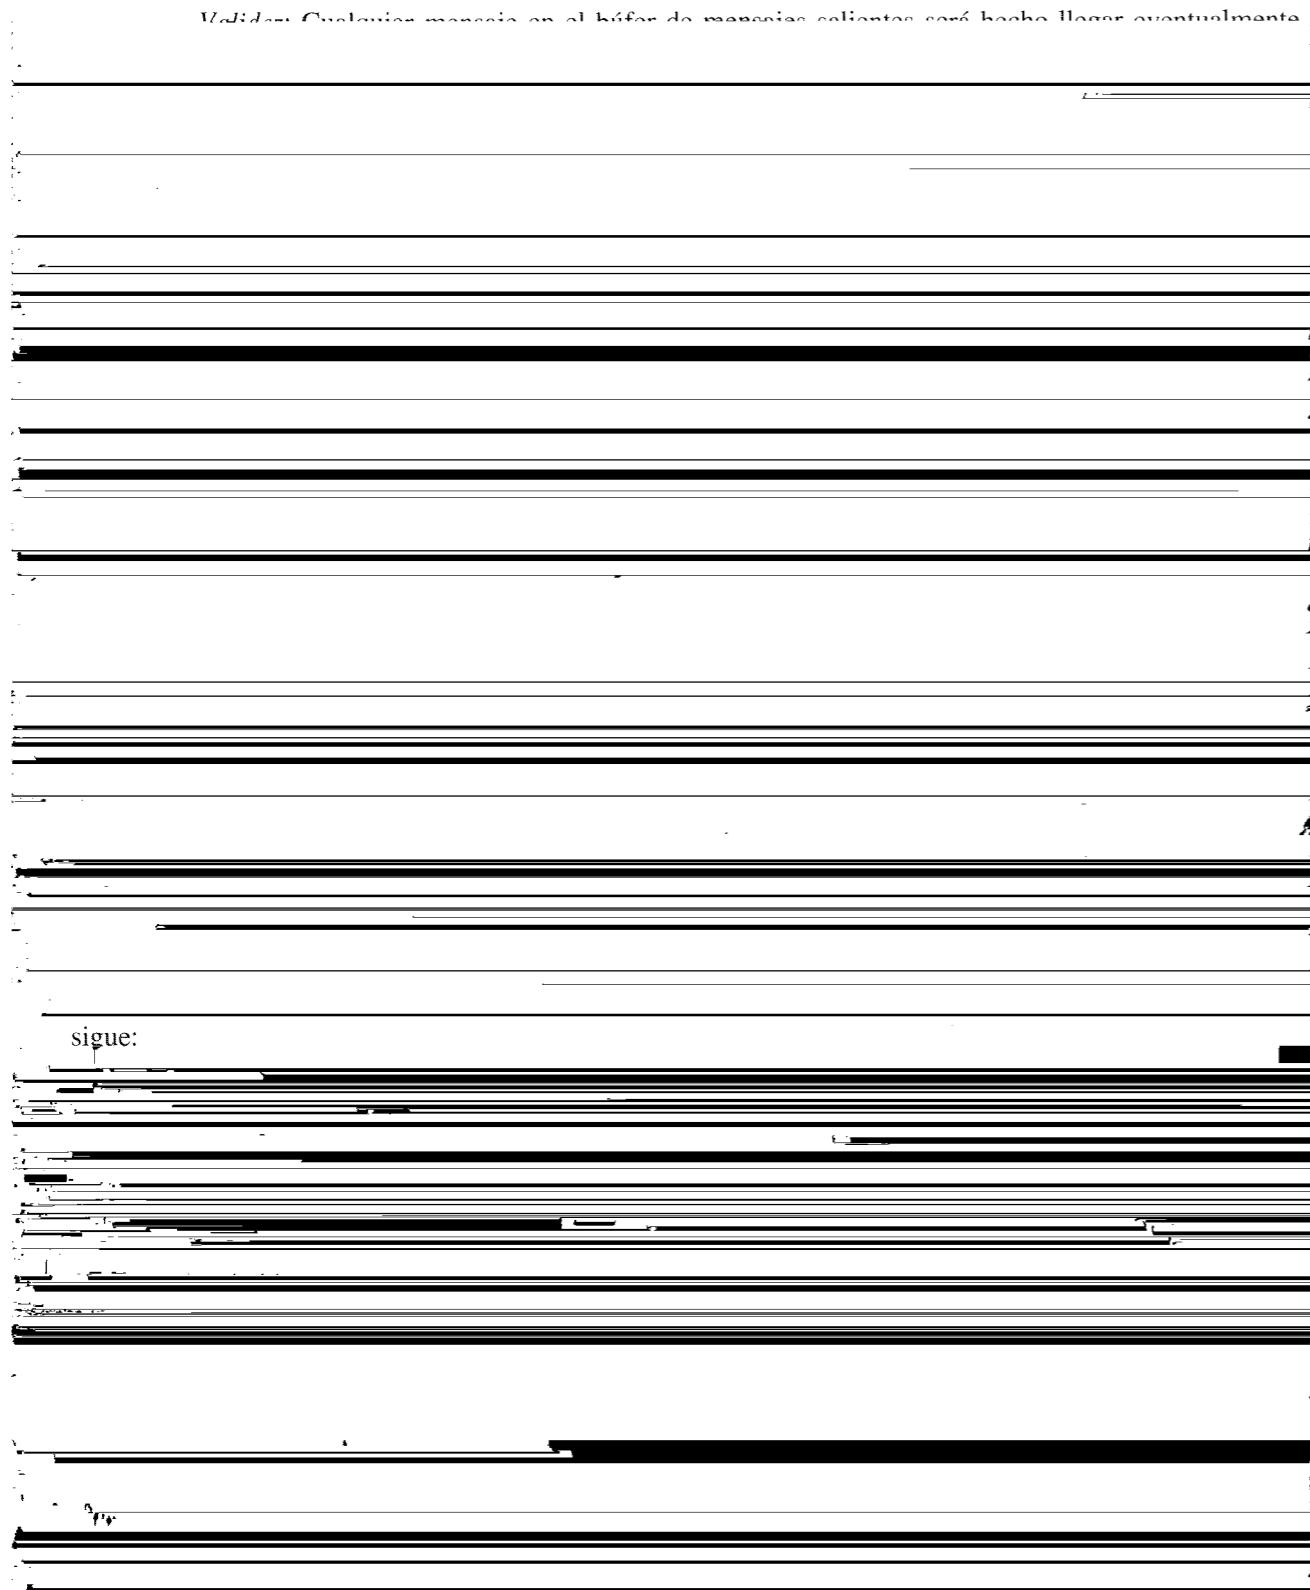


Figura 2.13. Objetos y principales.

Los sistemas distribuidos se despliegan y usan, probablemente, en tareas propensas a ser objetivo de ataques externos por usuarios hostiles. Esto es especialmente cierto en aplicaciones que tratan con transacciones financieras, confidenciales o con información clasificada o cualquier otra información cuya privacidad e integridad sea crucial. La integridad se ve amenazada por las violaciones de seguridad así como por fallos de la comunicación. Es así que sabemos que probablemente habrá ataques a los procesos de los que se componen tales aplicaciones y a los mensajes que viajan entre los procesos. Pero, ¿cómo podemos analizar estas amenazas para identificarlas y derrotarlas? La siguiente discusión presenta un modelo para el análisis de amenazas de seguridad.

◊ **El enemigo.** Para modelar amenazas de seguridad, postulamos que el enemigo (también conocido como adversario) es capaz de enviar cualquier mensaje a cualquier proceso y también de leer o copiar cualquier mensaje entre un par de procesos, como se muestra en la Figura 2.14. Tales ataques pueden cometerse simplemente utilizando un computador conectado a una red para lanzar un programa que lea los mensajes de la red dirigidos a otros computadores de la misma red, o un programa que genere mensajes que realicen peticiones falsas a servicios dando a entender que provienen de usuarios autorizados. El ataque puede provenir de un computador legítimamente conectado a la red o también de alguna conectada de forma no autorizada.

Las amenazas de un enemigo potencial se discutirán según los siguientes apartados: *amenazas a procesos, amenazas a los canales de comunicación y denegación de servicio*.

Amenazas a procesos: Cualquier proceso diseñado para admitir peticiones puede recibir un mensaje de cualquier otro proceso del sistema distribuido, y bien pudiera no ser capaz de determinar la identidad del emisor. Los protocolos de comunicación como IP incluyen la dirección del computador origen de cada mensaje, pero no es problema para un enemigo el generar un mensaje con una dirección fuente falsa. Esta carencia de conocimiento fiable del origen de un mensaje es una amenaza al correcto funcionamiento, tanto de los servidores como de los clientes, tal y como se explica a renglón seguido:

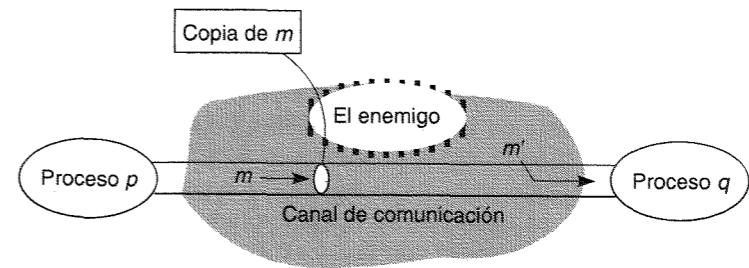


Figura 2.14. El enemigo.

Servidores: dado que un servidor puede recibir invocaciones de muchos clientes diferentes, no necesariamente puede determinar la identidad del principal que se halla tras cualquier invocación particular. Incluso si un servidor requiere la inclusión de la identidad del principal en cada invocación, un enemigo podría generar una invocación con una identidad falsa. Sin un conocimiento fiable de la identidad del emisor, un servidor no puede decir si realizar la operación o rechazarla. Por ejemplo, un servidor de correo pudiera no saber si el usuario tras una invocación que recupera un correo de un buzón particular está autorizado para ello, o si era una petición de un enemigo.

Clientes: cuando un cliente recibe el resultado de una invocación de un servidor, no necesariamente puede decir si la fuente del mensaje resultado es del servidor que se pretendía o de un enemigo, quizás uno que esté suplantando (*spoofing*) el servidor de correo. Entonces el cliente pudiera recibir un resultado no relacionado con la invocación original, tal como un correo falso (uno que no esté en el buzón de correo del usuario).

Amenazas a los canales de comunicación: Un enemigo puede copiar, alterar o insertar mensajes según viajan a través de la red y sus pasarelas intermedias. Tales ataques presentan una amenaza a la privacidad y a la integridad de la información según ésta viaja a través de la red, y a la integridad del sistema. Por ejemplo, un mensaje resultado que contenga un correo de un usuario pudiera ser visto por otro usuario o podría ser convertido en algo bastante diferente.

Otra forma de ataque es la pretensión de hacer acopio de mensajes para volver a enviarlos más tarde, haciendo posible volver a usar el mismo mensaje una y otra vez. Por ejemplo, alguien podría beneficiarse de un mensaje en el que se invoca una petición de transferencia de dinero de una cuenta bancaria a otra.

Todas estas amenazas pueden vencerse empleando *canales seguros*, como los que se describen más adelante y que se basan en la criptografía y la autenticación.

◊ **Vencer amenazas de seguridad.** Aquí presentamos las técnicas principales en que se basan los sistemas seguros. El Capítulo 7 discute el diseño y la implementación de sistemas distribuidos seguros con cierto detalle.

Criptografía y secretos compartidos: Suponga que un par de procesos (por ejemplo un cliente y un servidor concretos) comparten un secreto; es decir, ningún proceso del sistema distribuido aparte de ellos conoce este secreto. Entonces, si se intercambia un mensaje entre estos dos procesos e incluye información que demuestra el conocimiento, por parte del emisor, de este secreto compartido, tenemos que el receptor podrá estar seguro de quién es el que ha emitido el mensaje. Obviamente, es preciso tener cuidado para que el secreto compartido no sea revelado a un enemigo.

La *criptografía* es la ciencia de mantener los mensajes seguros, y la *encriptación* es el proceso de trastocar el mensaje de modo que quede oculto el contenido. La criptografía moderna se basa en algoritmos de encriptación que emplean claves secretas (números grandes difíciles de deducir) para transformar los datos, de forma que sólo se pueda revertir el proceso con la clave de desencriptado correspondiente.

Autenticación: El uso de los secretos compartidos y la encriptación presenta la base de los mensajes de *autenticación*, probando las identidades proporcionadas por sus emisores. La técnica básica de autenticación consiste en incluir en un mensaje un fragmento encriptado que contenga suficiente contenido del mensaje como para garantizar su autenticidad. La porción de autenticación de una petición a un servidor de archivos, pongamos que para leer parte de un archivo, podría incluir una representación de la identidad del principal solicitante, la identidad del archivo y la fecha y hora de la petición, todo encriptado con una clave secreta que comparten el servidor de archivos y el proceso solicitante. El servidor lo desencriptaría y comprobaría que se corresponde con los detalles no encriptados que se especifican en la petición.

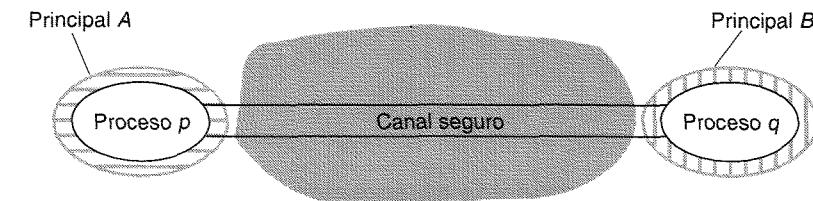


Figura 2.15. Canales seguros.

Canales seguros: La encriptación y la autenticación se emplean para construir canales seguros en forma de capa de servicio sobre los servicios de comunicación existentes. Un canal seguro es un canal de comunicación que conecta un par de procesos, cada uno de los cuales actúa en representación de un principal, según se muestra en la Figura 2.15. Un canal seguro presenta las siguientes propiedades:

- Cada proceso conoce bien la identidad del principal en cuya representación se ejecuta otro proceso. De este modo si un cliente y un servidor se comunican vía un canal seguro, el servidor conoce la identidad del principal tras las invocaciones y puede comprobar sus derechos de acceso antes de realizar una operación. Esto permite que el servidor proteja sus objetos correctamente y permite al cliente estar seguro de estar recibiendo resultados de un servidor que actúa de *buena fe*.
- Un canal seguro asegura la privacidad y la integridad (protección contra la manipulación) de los datos transmitidos por él.
- Cada mensaje incluye un sello de carácter temporal, de tipo físico o lógico, para prevenir el reenvío o la reordenación de los mensajes.

La construcción de canales seguros se discutirá con detalle en el Capítulo 7. Los canales seguros se han convertido en una importante herramienta práctica para asegurar el comercio electrónico y la protección de la comunicación. Las redes privadas virtuales (VPN, que se verán en el Capítulo 3) y el protocolo de capa de sockets segura (SSL, *Secure Sockets Layer*) son ejemplos de canales seguros.

◊ **Otras posibilidades de amenaza de un enemigo.** La Sección 1.4.3 presentó brevemente dos amenazas de seguridad, los ataques de denegación de servicio y el despliegue de código móvil. Veamos otra vez este tipo de ataques desde el punto de vista de las posibilidades que se le ofrecen al enemigo de dificultar las actividades de los procesos:

Denegación de servicio: ésta es una forma de ataque en la que el enemigo interfiere con las actividades de los usuarios autorizados mediante un número excesivo de invocaciones sin sentido sobre servicios o la red, lo que resulta en una sobrecarga de los recursos físicos (ancho de banda, capacidad de procesamiento del servidor). Tales ataques suelen tener el fin de retrasar o impedir las acciones de los otros usuarios. Por ejemplo, podría desconectarse la operación de las cerraduras electrónicas de una edificación por medio de un ataque que sature el computador que las controla con peticiones inválidas.

Código móvil: el código móvil despierta nuevos e interesantes problemas para cualquier proceso que reciba y ejecute código de programas proveniente de algún otro sitio, tal como los anexos a los correos electrónicos mencionados en la Sección 1.4.3. Tal código podría jugar fácilmente el papel de caballo de Troya, pretendiendo cumplir con un objetivo inocente pero, de hecho, incluyendo código que accede o modifica los recursos que están disponibles legítimamente para los procesos del host, pero no para el creador del código. Los métodos mediante los

cuales es posible llevar a cabo tales ataques son muchos y variados, en consecuencia el entorno del host debe construirse cuidadosamente para evitarlos. Muchas de estas cuestiones han sido tenidas en cuenta en Java y otros sistemas de código móvil, pero la historia reciente sobre el tema muestra la desnudez de algunas debilidades bastante embarazosas. Esta cuestión muestra la necesidad de realizar un análisis riguroso sobre el diseño de todos los sistemas seguros.

◇ **Aplicaciones de los modelos de seguridad.** Pudiera pensarse que obtener sistemas distribuidos seguros debiera ser un asunto evidente que implica el control del acceso a los objetos según permisos de acceso predefinidos y el empleo de canales de comunicación seguros. Desgraciadamente, no siempre es éste el caso. El empleo de técnicas de seguridad como la encriptación y el control de acceso conlleva un coste de procesamiento y administración sustancial. El modelo de seguridad esquematizado anteriormente da las bases del análisis y el diseño de sistemas seguros en los que se mantienen los costes al mínimo; pero las amenazas a un sistema distribuido se presentan desde muchos flancos, y se hace necesario un análisis cuidadoso de estas amenazas, que pudieran provenir de todas las fuentes posibles en el entorno de red del sistema, el entorno físico y el entorno humano. Este análisis involucra la construcción de un *modelo de amenazas* que tabula todas las formas de ataque a las que se encuentra expuesto el sistema y una evaluación de los riesgos y consecuencias de cada uno. La efectividad y el coste de las técnicas de seguridad necesarias pueden entonces ser contrapesadas con las amenazas.

2.4. RESUMEN

La mayoría de los sistemas distribuidos se componen de una o más variedades de modelos de arquitectura. El modelo cliente-servidor es el más usado; el Web y otros servicios Internet tales como ftp, news y mail así como el DNS se basan en este modelo, así como el sistema local de archivos y otros más. Los servicios como DNS que tienen un número de usuarios grande y tratan con una gran cantidad de información se basan en múltiples servidores, el uso de particiones sobre los datos y la replicación para facilitar la disponibilidad y la tolerancia frente a fallos. El uso de caché en los clientes y servidores *proxy* se encuentra ampliamente extendido para mejorar las prestaciones de un servicio. En el modelo de procesos de igual a igual, los procesos de aplicaciones distribuidas se comunican uno con otro directamente sin emplear servidores intermediarios.

La posibilidad de mover código de un proceso a otro ha desembocado en algunas variantes del modelo cliente-servidor. El ejemplo más común de esto es el *applet* cuyo código es aportado por un servidor web para ejecutarse en un cliente, proporcionando funcionalidades no disponibles en el cliente y la mejora de ciertas prestaciones debido a la proximidad con el cliente.

La existencia de computadores portátiles, PDA y otros dispositivos digitales y su integración en los sistemas distribuidos permite que los usuarios accedan a servicios locales y de Internet, aunque estén lejos de su computador de sobremesa. La presencia de dispositivos de computación con posibilidades de comunicación inalámbrica en aparatos cotidianos como las máquinas lavadoras o las alarmas antirrobo les permite dar servicios accesibles desde una red inalámbrica en el hogar. Una característica de los dispositivos móviles de los sistemas distribuidos es que pueden estar conectados o desconectados impredeciblemente, conduciendo a requisitos de descubrimiento de servicios mediante los que los servidores móviles puedan ofrecer sus servicios y los clientes móviles buscarlos.

Hemos presentado modelos de interacción, fallo y seguridad que identifican las características comunes de los componentes básicos con que se construyen los sistemas distribuidos. El modelo de interacción tiene que ver con las prestaciones de los procesos y los canales de comunicación, y con la ausencia de un reloj global. También define un sistema asíncrono como uno en el que no hay límites en el tiempo de ejecución de un proceso, el tiempo de reparto de un mensaje, y la deriva de los relojes; siendo así como se comporta Internet.

El modelo de fallo clasifica los fallos de los procesos y los canales de comunicación básicos en un sistema distribuido. El enmascaramiento es una técnica con la que se construye un servicio más fiable sobre otro menos fiable, de modo que se enmascaran algunos fallos que exhibe este último. En particular, se puede construir un servicio de comunicación fiable desde un canal de comunicación básico simplemente enmascarando sus fallos. Por ejemplo, sus fallos por omisión pueden enmascararse mediante la retransmisión de los mensajes perdidos. La integridad es una propiedad de la comunicación fiable, y requiere que un mensaje al ser recibido sea idéntico al que se envió, amén de que no sea recibido dos veces. La validez es otra propiedad; requiere que cualquier mensaje puesto en el búfer de mensajes de salida se reparta eventualmente al búfer de mensajes entrantes.

El modelo de seguridad identifica las posibles amenazas a los procesos y los canales de comunicación en un sistema distribuido abierto. Algunas de estas amenazas se relacionan con la integridad: los usuarios malintencionados pueden modificar o repetir los mensajes. Otros amenazan su privacidad. Otra cuestión de seguridad es la autenticación del principal (usuario o servidor) en cuyo nombre se envía un mensaje. Los canales seguros emplean técnicas criptográficas para asegurar la integridad y la privacidad de los mensajes y para autenticar pares de principales en una comunicación.

EJERCICIOS

- 2.1. Describa e ilustre la arquitectura cliente-servidor de una de las principales aplicaciones de Internet (por ejemplo el Web, email o netnews).
- 2.2. Para las aplicaciones discutidas en el Ejercicio 2.1 indique cómo cooperan los servidores al proveer un servicio.
- 2.3. ¿Cómo están involucradas, en el particionado y/o replicación (o el uso de caché) de los datos de ciertos servidores, las aplicaciones discutidas en el Ejercicio 2.1?
- 2.4. Un motor de búsqueda es un servidor web que ofrece a los clientes la oportunidad de buscar en ciertos índices almacenados y (concurrentemente) lanzar varios escaladores web para construir y actualizar estos índices. ¿Cuáles son los requisitos de sincronización entre estas actividades concurrentes?
- 2.5. Sugiera algunas aplicaciones para un modelo entre pares, distinguiendo entre casos en los que el estado de todos necesita ser idéntico y casos que demandan menos consistencia.
- 2.6. Tabule los tipos de recursos locales que son vulnerables a un ataque por un programa no fiable que se descarga de un lugar remoto y se ejecuta en un computador local.
- 2.7. Dé ejemplos de aplicaciones donde sea beneficioso emplear código móvil.
- 2.8. ¿Qué factores afectan el modo de comportamiento de una aplicación que accede a los datos compartidos administrados por un servidor? Describa los remedios disponibles y discuta su utilidad.
- 2.9. Distinga entre búfer y caché.
- 2.10. Dé algunos ejemplos de fallos en el hardware y el software de un sistema distribuido que puedan o no ser tolerados mediante el uso de redundancia. ¿En qué punto podemos asegurar que el empleo de redundancia, cuando sea adecuado, hace que el sistema sea tolerante frente a fallos?

- 2.11. Considere un servidor simple, que realiza peticiones de clientes, sin acceder a otros servidores. Explique por qué no es posible en general establecer un límite al tiempo que invierte un servidor en responder una petición de un cliente. ¿Qué habría que hacer para que el servidor fuera capaz de ejecutar respuestas dentro de un tiempo acotado? ¿Es práctica esta opción?
- 2.12. Para cada uno de los factores que contribuye al tiempo que se invierte en la transmisión de un mensaje entre dos procesos sobre un canal de comunicación, enumere qué medidas habría que emplear para acotar su contribución al tiempo total. ¿Por qué estas medidas no se incluyen en los sistemas distribuidos de propósito general actuales?
- 2.13. El servicio del Protocolo de Tiempo de Red se puede utilizar para sincronizar relojes de computadores. Explique por qué, incluso con este servicio, no se puede garantizar un límite para la diferencia de tiempo entre dos relojes.
- 2.14. Considere dos servicios de comunicación para utilizarse en sistemas distribuidos asíncronos. En el servicio A, los mensajes pueden perderse, duplicarse o retrasarse y la suma de chequeo sólo se aplica a las cabeceras. En el servicio B, los mensajes pueden perderse, retrasarse o distribuirse demasiado rápido para que el receptor pueda recibirlas, pero aquellos que llegan lo hacen en buenas condiciones.

Describa las clases de fallo que se presentan en cada servicio. Clasifique sus características según su efecto sobre la validez y la integridad. ¿Puede el servicio B, tal y como se ha descrito, ser un servicio de comunicación fiable?

- 2.15. Considere un par de procesos X e Y que emplean el servicio de comunicación B del Ejercicio 2.14 para comunicarse entre sí. Suponga que X es un cliente e Y un servidor y que una *invocación* consta de un mensaje de X a Y, tras lo cual Y obtiene resultado, seguido por un mensaje de respuesta de Y a X. Describa las clases de fallos que pueden presentarse en una invocación.
- 2.16. Suponga que una lectura básica de disco puede leer a veces valores que difieren de los escritos. Indique el tipo de fallo presentado por una lectura básica de disco. Sugiera cómo puede enmascararse este fallo para producir una forma diferente de fallo benigno. Ahora sugiera cómo enmascarar el fallo benigno.
- 2.17. Defina la propiedad de integridad de la comunicación fiable e indique todas las amenazas posibles a la integridad para los usuarios y para los componentes del sistema. ¿Qué medidas pueden tomarse para garantizar la propiedad de integridad en presencia de cada una de estas fuentes de ataques?
- 2.18. Describa las posibles ocurrencias de cada uno de los principales tipos de amenazas a la seguridad (amenazas a procesos, amenazas a canales de comunicación y denegación de servicio) que pueden acontecer en Internet.

3

REDES E INTERCONEXIÓN DE REDES

- 3.1. Introducción
- 3.2. Tipos de redes
- 3.3. Fundamentos de redes
- 3.4. Protocolos Internet
- 3.5. Casos de estudio: Ethernet, LAN inalámbrica y ATM
- 3.6. Resumen

Los sistemas distribuidos utilizan redes de área local, redes de área extendido e interredes para comunicarse. Las prestaciones, fiabilidad, escalabilidad, movilidad y calidad del servicio de las redes subyacentes influyen en el comportamiento de los sistemas distribuidos. Los cambios en las necesidades de los usuarios han producido la irrupción de las redes inalámbricas y las redes de altas prestaciones con calidad de servicio garantizada.

Los fundamentos en los que se basan las redes de computadores incluyen las capas de protocolos, el intercambio de paquetes, el encaminamiento y el flujo de datos. Las técnicas de interconexión de redes hacen posible que se puedan combinar redes heterogéneas para que funcionen como una sola. Internet es el mejor ejemplo de esto; sus protocolos son casi universalmente utilizados en los sistemas distribuidos. Los modos de direccionamiento y encaminamiento usados en Internet han experimentado el impacto de su enorme crecimiento. Tanto es así que ahora se encuentran en proceso de revisión para que puedan soportar el crecimiento futuro y para poder cumplir con los requerimientos de movilidad, seguridad y calidad de servicio demandados.

El diseño de tecnologías específicas de redes se ilustra en los casos de estudio: Ethernet, Modo de Transferencia Asíncrono (ATM, *Asynchronous Transfer Mode*) y el estándar IEEE 802.11 de red inalámbrica.

3.1. INTRODUCCIÓN

Las redes utilizadas por los sistemas distribuidos están compuestas por *medios de transmisión* variados, que incluyen el cable coaxial, la fibra óptica y los canales inalámbricos; *dispositivos hardware*, como *routers*, *switches*, *bridges*, *hubs*, repetidores e interfaces de red; y *componentes software*, entre los que se encuentran las pilas de protocolos, los gestores de comunicaciones y los controladores de dispositivos. Todos estos elementos influyen en la funcionalidad resultante y en las prestaciones disponibles para los sistemas distribuidos y los programas de aplicación que se ejecutan sobre las redes. Llamamos *subsistema de comunicaciones* a la colección de componentes hardware y software que proporcionan las capacidades de comunicación para un sistema distribuido. A cada una de los computadores y de los otros dispositivos que utilizan la red para comunicarse entre sí los denominaremos *hosts*. El término *nodo* se utilizará para referirse a cualquier computador o dispositivo de intercambio asociado a una red.

Internet es un subsistema de comunicaciones singular que proporciona comunicación entre todos los hosts que están conectados a él. Internet está construido a partir de muchas *subredes* empleando una variedad de tecnologías de red distintas en cada caso. Una subred es un conjunto de nodos interconectados, que emplean la misma tecnología para comunicarse entre ellos. La infraestructura de Internet comprende tanto la arquitectura como los componentes hardware y software que hacen posible la integración con éxito de diversas subredes en un único servicio de comunicaciones.

El diseño de un subsistema de comunicaciones está fuertemente influenciado por las características de los sistemas operativos utilizados en los computadores que componen el sistema distribuido, además de por las redes que los interconectan. En este capítulo estudiaremos el impacto de las tecnologías de red en los subsistemas de comunicaciones; los sistemas operativos serán considerados en el Capítulo 6.

Este capítulo está orientado a proporcionar un repaso introductorio de las redes de computadores desde el punto de vista de los requisitos de comunicaciones que los sistemas distribuidos plantean. Aquellos lectores que no estén familiarizados con las redes de computadores deberían considerarlo como soporte para el resto de los contenidos presentados en este libro, ya que encontrarán que este capítulo ofrece un resumen extenso de todos aquellos aspectos de las redes de computadores que son particularmente relevantes para los sistemas distribuidos.

Las redes de computadores fueron concebidas poco después de la invención del computador. Los fundamentos teóricos del intercambio de paquetes fueron descritos en un informe por Leonard Kleinrock [1961]. En 1962, J. C. R. Licklider y W. Clark, que participaban en el desarrollo del primer sistema de tiempo compartido en el MIT en los primeros años sesenta, publicaron un informe en el que se discutía el potencial de la computación interactiva y de la comunicación sobre redes de área extensa, que presagiaba en algunos aspectos a Internet [DEC 1990]. En 1964, Paul Baran produjo un esquema de un diseño práctico de redes de área extensa fiables y efectivas [Baran 1964]. Se puede encontrar más material y enlaces sobre la historia de las redes de computadores e Internet en las siguientes fuentes: [www.isoc.org, Comer 1995, Kurose and Ross 2000].

En el resto de esta sección se presentarán los requisitos de comunicación de los sistemas distribuidos. Daremos un repaso de los tipos de redes en la Sección 3.2 y una introducción a los fundamentos de las redes en la Sección 3.3. La Sección 3.4 tratará específicamente de Internet. Este capítulo concluye con la Sección 3.5 con casos de estudio detallados sobre Ethernet, ATM e IEEE 802.11 (WaveLAN).

3.1.1. LAS REDES Y LOS SISTEMAS DISTRIBUIDOS

Las primeras redes de computadores fueron diseñadas para satisfacer unos pocos, y relativamente sencillos, requisitos de aplicación del tipo transferencia de archivos, conexión a sistemas remotos,

correo electrónico y servicios de noticias. El consiguiente desarrollo de los sistemas distribuidos, sobre el que se asientan los programas de aplicación distribuidos que permiten compartir archivos y otros recursos, ha puesto más alto el estándar de prestaciones que satisfagan las necesidades de las aplicaciones interactivas.

Más recientemente, con el crecimiento y comercialización de Internet y la aparición de muchos modos nuevos de uso, se han impuesto requisitos más exigentes en cuanto a fiabilidad, escalabilidad, movilidad, seguridad y calidad de servicio. En esta sección, definiremos y describiremos la naturaleza de cada uno de estos requisitos.

◊ **Prestaciones.** Los parámetros indicadores de las prestaciones de las redes más interesantes para nuestros propósitos son aquellos que afectan a la velocidad con la que los mensajes individuales pueden ser transferidos entre dos computadores interconectados. Éstos son la latencia y la tasa de transferencia punto a punto.

La *latencia* es el intervalo de tiempo que ocurre entre la ejecución de la operación de envío y el instante en que los datos comienzan a estar disponibles en el destino. Puede ser considerada como el tiempo necesario para enviar un mensaje vacío.

La *tasa de transferencia de datos* es la velocidad a la cual se pueden transferir datos entre dos computadores en red, una vez que la transmisión ha sido iniciada; normalmente es medida en bits por segundo.

A partir de estas definiciones, el tiempo requerido por una red para transferir un mensaje de l bits de longitud entre dos computadores es:

$$\text{Tiempo de transmisión del mensaje} = \text{latencia} + \frac{\text{longitud}}{\text{tasa de transferencia}}$$

La ecuación anterior es válida para mensajes cuya longitud no excede un máximo que viene determinado por la tecnología de red subyacente. Los mensajes más largos tendrán que ser segmentados y el tiempo de transmisión será la suma del tiempo de transmisión de cada segmento.

La tasa de transferencia de una red viene determinada principalmente por sus características físicas, mientras que la latencia estará determinada básicamente por las sobrecargas del software, los retrasos en el encaminamiento y una componente estadística derivada de los conflictos en el uso de los canales de transmisión. Muchos de los mensajes transferidos entre los procesos que forman parte de los sistemas distribuidos son de pequeño tamaño; por lo que la latencia es a menudo tan importante como la tasa de transferencia a la hora de determinar las prestaciones.

El *ancho de banda total del sistema* de una red es una medida de la productividad (*throughput*), del volumen de tráfico que puede ser transferido a través de la red en un intervalo de tiempo dado. En muchas de las tecnologías de red local, como Ethernet, se utiliza toda la capacidad de transmisión de la red en cada transmisión y el ancho de banda es igual a la tasa de transferencia. En cambio, en la mayoría de las redes de área extensa los mensajes pueden ser transmitidos simultáneamente sobre varios canales diferentes, de modo que el ancho de banda no guarda una relación directa con la tasa de transferencia. Las prestaciones de las redes se deterioran con situaciones de sobrecarga; cuando existen demasiados mensajes en la red al mismo tiempo. El efecto preciso de la sobrecarga en la latencia, la tasa de transferencia y el ancho de banda de una red depende esencialmente de la tecnología de la red.

Considérense ahora las prestaciones de una comunicación cliente-servidor. El tiempo necesario para transmitir un pequeño mensaje de solicitud y recibir una respuesta pequeña en una red local poco cargada entre sistemas PC o UNIX estándar es generalmente de milisegundos. En comparación, el intervalo de tiempo necesario para invocar una operación en un objeto del nivel de aplicación cargado en memoria local de un proceso en ejecución es inferior a un microsegundo. Esto es, a pesar de los avances en las prestaciones de las redes, el tiempo necesario para acceder a recursos compartidos en la misma red local es más de 1.000 veces mayor que el necesario para acceder a

controlar el uso de recursos del otro lado del cortafuegos por parte de los usuarios dentro de la organización.

Un cortafuegos se ejecuta sobre un *gateway* o pasarela, un computador que se coloca en el punto de entrada de la red interna de una organización. El cortafuegos recibe y filtra todos los mensajes que viajan desde o hacia la organización. Está configurado de acuerdo con la política de seguridad de la organización para permitir que ciertos mensajes entrantes y salientes pasen a través de él, y para rechazar los demás. Volveremos sobre este tema en la Sección 3.4.8.

Para permitir que las aplicaciones distribuidas se puedan mover más allá de las restricciones impuestas por los cortafuegos existe la necesidad de producir un entorno seguro de red en el cual pueda diseminarse un gran número de aplicaciones distribuidas, con autenticación extremo a extremo, privacidad y seguridad. Esta forma de seguridad más detallada y más flexible puede ser conseguida mediante técnicas de criptografía. Éstas se aplican normalmente en un nivel por encima del subsistema de comunicaciones, y se tratarán con más detalle en el Capítulo 7. Los casos excepcionales como la necesidad de proteger componentes de la red como routers contra accesos no autorizados y la necesidad de disponer de enlaces seguros para dispositivos móviles y otros nodos externos que les posibiliten participar en la red interna segura (concepto de red privada virtual o *virtual private network*, VPN) son tratados en la Sección 3.4.8.

◊ **Movilidad.** En el Capítulo 2, presentamos los requisitos que se derivaban de la necesidad de soportar computadores portátiles y dispositivos digitales de mano en los sistemas distribuidos, y mencionamos la necesidad de disponer de redes inalámbricas que permitieran la comunicación continua con esos dispositivos. Pero las consecuencias de la movilidad van más allá de la necesidad de una red inalámbrica. Los dispositivos móviles se desplazan frecuentemente entre distintos lugares y se conectan en puntos de conexión variados. Los modos de direccionamiento y encaminamiento de Internet y de otras redes fueron desarrollados antes de la llegada de los dispositivos móviles, y aunque los mecanismos actuales han sido adaptados y extendidos para soportar cierta movilidad, el esperado crecimiento futuro del uso de los dispositivos móviles harán necesarias nuevas extensiones.

◊ **Calidad de servicio.** En el Capítulo 2, definimos calidad de servicio como la capacidad de cumplir con las restricciones temporales cuando se transmiten y se procesan flujos de datos multimedia en tiempo real. Esto impone unas condiciones más importantes a las redes de computadores. Las aplicaciones que transmiten datos multimedia requieren tener garantizado un ancho de banda y unos límites de latencia en los canales que utilizan. Algunas aplicaciones varían sus demandas dinámicamente y especifican tanto la calidad de servicio aceptable mínima como la óptima deseada. El modo en que se satisfacen y se mantienen esas garantías es el tema tratado en el Capítulo 15.

◊ **Multidifusión (*multicasting*).** La mayoría de las comunicaciones en los sistemas distribuidos se hacen entre pares de procesos, pero a menudo existe también la necesidad de establecer comunicaciones uno a muchos. Aunque esto puede ser simulado enviando mensajes a varios destinos, resulta más costoso de lo necesario, y no posee la característica de tolerancia a fallos requerida por las aplicaciones. Por estas razones, muchas tecnologías de red soportan la transmisión simultánea de mensajes a varios receptores.

3.2. TIPOS DE REDES

Aquí presentaremos los principales tipos de redes utilizados para soportar los sistemas distribuidos: *redes de área local*, *redes de área amplia*, *redes de área metropolitana*, *redes inalámbricas* e *interredes* (comunicación entre redes).

Algunos de los nombres utilizados para nombrar tipos de redes son confusos ya que parece referirse exclusivamente a la extensión física (local, amplia, metropolitana) cuando también hacen referencia a las tecnologías de transmisión física y a los protocolos de bajo nivel. Éstos son diferentes para las redes locales y amplias, aunque alguna tecnología de red desarrollada recientemente como ATM (*Asynchronous Transfer Mode*) resulta adecuada para ambos casos. Las redes inalámbricas también soportan transmisiones de área local y amplia.

Cuando hablamos de comunicación entre redes, por interredes nos referiremos a aquellas redes compuestas de varias redes interconectadas e integradas para proporcionar un único medio de comunicación de datos. Internet es el ejemplo de interred más típico; actualmente está compuesta por cientos de miles de redes de área local, amplia y metropolitana. Describiremos su implementación con algún detalle en la Sección 3.4.

◊ **Redes de área local.** Las redes de área local (*local area networks*) llevan mensajes a velocidades relativamente altas entre computadores conectados a un único medio de comunicaciones: un cable de par trenzado, un cable coaxial o uno de fibra óptica. Un *segmento* es una sección de cable que da servicio a un departamento o a una planta de un edificio y que puede tener varios computadores conectados. Dentro de un segmento no se necesita encaminar mensajes, ya que el medio físico proporciona una conexión directa entre todos los computadores conectados a él. El ancho de banda del segmento se reparte entre los computadores conectados al mismo. Las redes de área local mayores, tales como las que abarcan un campus o un edificio de oficinas, están compuestas de varios segmentos interconectados por conmutadores (*switches*) o concentradores (*hubs*) (véase la Sección 3.3.7). En las redes de área local, el ancho de banda total del sistema es grande y la latencia pequeña, excepto cuando el tráfico de mensajes es muy alto.

En los años 70 se desarrollaron varias tecnologías de redes de área local: Ethernet, *token rings* y *slotted rings*. Cada una de ellas proporciona una solución efectiva y de altas prestaciones, pero Ethernet se ha impuesto como la tecnología dominante para las redes de área amplia. Fue producida originalmente en los primeros años 70 con un ancho de banda de 10 Mbps (millones de bits por segundo) y ha sido extendida a 100 Mbps y a 1 Gbps (gigabits por segundo) en versiones más recientes. Describiremos los principios de funcionamiento de Ethernet en la Sección 3.5.1.

Existe una gran cantidad de redes de área local instaladas, sirviendo en casi todos los entornos de trabajo con dos o más computadores personales o estaciones de trabajo. Sus prestaciones son, en general, adecuadas para la implementación de sistemas y aplicaciones distribuidas. La tecnología Ethernet carece de las garantías necesarias sobre latencia y ancho de banda necesarias para las aplicaciones multimedia. ATM fue desarrollada para ocupar esa demanda, pero su costo ha impedido su implantación en las redes de área local. En su lugar, se han implantado redes Ethernet de alta velocidad que resuelven estas limitaciones de un modo satisfactorio, aunque no sean tan efectivas como ATM.

◊ **Redes de área extensa.** Las redes de área amplia (*wide area networks*) pueden llevar mensajes entre nodos que están a menudo en diferentes organizaciones y quizás separados por grandes distancias, pero a una velocidad menor que las redes LAN. Pueden estar situadas en diferentes ciudades, países o continentes. El medio de comunicación está compuesto por un conjunto de circuitos de enlazados mediante computadores dedicados, llamados *routers* o encaminadores. Éstos gestionan la red de comunicaciones y encaminan mensajes o paquetes hacia su destino. En la mayoría de las redes, las operaciones de encaminamiento introducen un retardo en cada punto de la ruta, por lo que la latencia total de la transmisión de un mensaje depende de la ruta seguida y de la carga de tráfico en los distintos segmentos que atraviese. En las redes actuales, estas latencias pueden ser tan importantes como 0,1 ó 0,5 segundos. Se pueden encontrar estimaciones actuales sobre Internet en [www.mids.org]. La velocidad de las señales electrónicas en la mayoría de los medios es cercana a la velocidad de la luz, y esto impone un límite inferior a la latencia de las transmisiones para las transmisiones de larga distancia. Por ejemplo, el tiempo necesario para que una señal

electrónica viaje desde Europa a Australia es aproximadamente de 0,13 segundos y cualquier transmisión que sea encaminada a través de un satélite geoestacionario está sujeta a un retardo de propagación de aproximadamente 0,20 segundos.

Los anchos de banda disponibles en las conexiones a través de Internet varían mucho. En algunos países, se pueden alcanzar velocidades de hasta 1 ó 2 Mbps, pero también son usuales velocidades de 10 a 100 Kbps.

◊ **Redes de área metropolitana.** Las redes de área metropolitana (*metropolitan area networks*) se basan en el gran ancho de banda de los cableados de cobre y de fibra óptica recientemente instalados en pueblos y ciudades para la transmisión de video, voz y otros tipos de datos; cuyas longitudes abarcan hasta unos 50 kilómetros de distancia. Este cableado puede explotarse para proporcionar tasas de transferencia compatibles con las necesidades de los sistemas distribuidos. Varias han sido las tecnologías utilizadas para implementar el encaminamiento en las redes MAN, desde Ethernet hasta ATM. IEEE ha publicado la especificación 802.6 [IEEE 1994], diseñada expresamente para satisfacer las necesidades de las redes MAN, cuyas implementaciones están en marcha. Se podría decir que las redes MAN están en su infancia pero están cerca de alcanzar las características de las redes LAN, aunque pudiendo cubrir mayores distancias que éstas.

Las conexiones de línea de suscripción digital, DSL (*digital subscriber line*), y los módem de cable disponibles en algunas ciudades son un ejemplo de esto. DSL utiliza generalmente conmutadores ATM (véase la Sección 3.5.3) colocados en intercambiadores telefónicos para encaminar datos digitales sobre par trenzado (el mismo cable de cobre que se utiliza para las conexiones telefónicas) hacia la casa o la oficina de los subscriptores a velocidades entre 0,25 y 6,0 Mbps. El uso de par trenzado para las conexiones del subscriptor DSL limita la distancia al conmutador a 1,5 kilómetros. Una conexión de módem por cable utiliza una señalización análoga sobre el cable coaxial de televisión para conseguir velocidades de 1,5 Mbps con un alcance superior que DSL.

◊ **Redes inalámbricas.** La conexión de los dispositivos portátiles y de mano necesitan redes de comunicaciones inalámbricas (*wireless networks*), según se presentó en el Capítulo 2. Recientemente han surgido muchas tecnologías de comunicaciones inalámbricas digitales. Algunas, como la IEEE 802.11 (*WaveLAN*) ofrecen transmisiones de datos entre 2 y 11 Mbps sobre 150 metros, son verdaderas redes LAN inalámbricas, (*wireless local area networks*, WLAN) diseñadas para ser utilizadas en lugar de las redes LAN. Otras están diseñadas para conectar dispositivos móviles a otros dispositivos móviles o fijos muy próximos, por ejemplo para comunicarse con impresoras o con otros computadores de mano o de escritorio. Estas redes se denominan *redes de área personal inalámbricas* (*wireless personal area networks*, WPAN), y ejemplos de las mismas son los enlaces infrarrojos que se incluyen en muchos computadores de mano y portátiles y la tecnología de radio de baja potencia BlueTooth [www.bluetooth.com], que ofrece transmisiones de datos entre 1 y 2 Mbps hasta 10 metros. Muchas redes de telefonía móvil están basadas en tecnologías de redes inalámbricas, incluida la red europea mediante el Sistema Global para Comunicaciones Móviles, GSM (*Global System for Mobile Communication*), utilizada en la mayoría de los países del mundo. En los Estados Unidos, la mayoría de los teléfonos móviles están actualmente basados en la análoga red de radio celular AMPS, sobre la cual se encuentra la red digital de comunicaciones de Paquetes de Datos Digitales Celular, CDPD (*Cellular Digital Packet Data*). Las redes de teléfonos móviles están diseñadas para trabajar sobre áreas amplias (generalmente países o continentes enteros) basándose en conexiones de radio celulares; y por lo tanto, ofrecen posibilidades de conexión a Internet a los dispositivos móviles en grandes áreas. Las redes celulares mencionadas anteriormente ofrecen tasas de datos relativamente bajas, de 9,6 a 19,2 kbps, aunque las redes que les sucederán están siendo planeadas con tasas de transmisión entre 128 y 384 kbps para células de unos cuantos kilómetros, y de 2 Mbps para células más pequeñas.

Dado el restringido ancho de banda disponible y las otras limitaciones de los dispositivos portátiles, tales como pantallas pequeñas, se ha desarrollado un conjunto de protocolos llamado

Protocolo de Aplicación Inalámbrico WAD (Wireless Application Protocol), especialmente para

3.3. FUNDAMENTOS DE REDES

Las bases de las redes de computadores es la técnica de la conmutación de paquetes, desarrollada en los primeros años sesenta. La conmutación de paquetes fue un cambio radical y un paso más allá de las redes de telecomunicación conmutadas que utilizaban los teléfonos y los telégrafos, explotando la capacidad de los computadores de almacenar información mientras está en tránsito. Esto posibilita que paquetes con diferentes destinos comparten un mismo enlace de comunicaciones. Los paquetes se ponen en cola en un búfer y se transmiten cuando el enlace está disponible. La comunicación es asíncrona, ya que los mensajes llegan a sus destinos después de un retardo variable que depende del tiempo que tardaron los paquetes en viajar a través de la red.

3.3.1. TRANSMISIÓN DE PAQUETES

En la mayoría de las aplicaciones de las redes de computadores se necesita transmitir unidades de información o *mensajes*: secuencias de ítems de datos de longitud arbitraria. Antes de que un mensaje sea transmitido es dividido en *paquetes*. La forma más simple de paquete es una secuencia de datos binarios (una secuencia de bits o bytes) de una longitud determinada, junto a la suficiente información para identificar los computadores origen y destino. Los paquetes tienen una longitud limitada:

- Porque así cada computador en la red puede reservar el espacio de almacenamiento suficiente para almacenar el paquete más largo que pueda recibir.
- Para evitar los retardos que podrían ocurrir si se estuviera esperando a que los canales estuvieran libres el tiempo suficiente para enviar un mensaje grande sin dividir.

3.3.2. FLUJOS DE DATOS

Existen excepciones a la comunicación basadas en mensajes. Ya vimos en el Capítulo 2 que las aplicaciones multimedia se basan en la transmisión de flujos, o *caudales*, de datos de audio y vídeo a tasas garantizadas y con latencias limitadas. Estos caudales difieren substancialmente del tipo de tráfico basado en mensajes para los que fue diseñada la transmisión de paquetes. Los caudales de audio y vídeo necesitan anchos de banda mucho mayores que otras formas de comunicación en los sistemas distribuidos.

La transmisión de un caudal de vídeo en tiempo real necesita un ancho de banda de 1,5 Mbps si los datos están comprimidos, o de 120 Mbps si no lo están. Además, el flujo es continuo, al contrario que el tráfico intermitente generado por la típica interacción cliente-servidor. El *tiempo de ejecución* en un elemento multimedia es el tiempo en el cual debe mostrarse (para un elemento de vídeo) o convertirse a audio (para un ejemplo de sonido). Por ejemplo, en un caudal de vídeo con una tasa de 24 marcos por segundo, el marco N tiene que ser ejecutado $N/24$ segundos después del comienzo. Los elementos que lleguen a su destino después de su tiempo de ejecución no son útiles y deben desecharse por el proceso receptor.

La entrega a tiempo de estos flujos de datos depende de la disponibilidad de conexiones con una calidad de servicio garantizada; se deben garantizar el ancho de banda, la latencia y la fiabilidad. Se debe poder establecer un canal desde el origen hasta el destino del caudal multimedia, con una ruta predefinida a través de la red, en el que se reserven en cada nodo perteneciente al mismo un conjunto de recursos apropiados para amortiguar cualquier irregularidad en el flujo de datos a través del canal. Los datos pueden, entonces, pasar a través del canal desde el emisor al receptor a una tasa especificada.

Las redes ATM (véase la Sección 3.5.3) están diseñadas específicamente para proporcionar altos anchos de banda y bajas latencias y para soportar calidad de servicio reservando recursos de la red. El protocolo IPv6 es un nuevo protocolo de Internet que será utilizado en la década próxima (véase la Sección 3.4.4), que incluye la posibilidad de que cada paquete IP que forme parte de un caudal de tiempo real sea identificado como tal y sea tratado separadamente de cualquier otro tipo de datos en el nivel de red.

Los subsistemas de comunicación que proporcionan calidad de servicio garantizada necesitan poder reservar *a priori* recursos de red y forzar esas reservas. El Protocolo de Reserva de Recursos RSVP (*Resource Reservation Protocol*) [Zhang y otros 1993] posibilita a las aplicaciones la negociación de una reserva de ancho de banda para los caudales de tiempo real. El Protocolo de Transporte de Tiempo Real RTP (*Real Time Transport Protocol*) [Schulzrinne y otros 1996] es un protocolo de transferencia de la capa de aplicación que incluye en cada paquete consideraciones sobre el tiempo de ejecución y otras necesidades de sincronización. La disponibilidad de implementaciones efectivas de estos protocolos en Internet dependerá de cambios substanciales en las capas de transporte y de red. El Capítulo 15 tratará en detalle las necesidades de las aplicaciones multimedia.

3.3.3. ESQUEMAS DE CONMUTACIÓN

Una red se compone de un conjunto de nodos conectados a través de circuitos. Para transmitir información entre dos nodos cualquiera se necesita un sistema de conmutación. A continuación vamos a definir los cuatro tipos de conmutación que se utilizan en las redes de computadores.

◊ **Difusión.** La difusión (*broadcast*) es una técnica de transmisión que no involucra conmutación alguna. Toda información es transmitida a todos los nodos, y depende de los receptores decidir si el mensaje va dirigido a ellos o no. Algunas tecnologías de red LAN como Ethernet se basan en la difusión. Las redes inalámbricas están basadas necesariamente en la difusión, ya que en ausencia de circuitos fijos la difusión llega a todos los nodos agrupados en la misma *celda*.

◊ **Conmutación de circuitos.** Hace algún tiempo, las redes telefónicas eran las únicas redes de telecomunicaciones. Su modo de operar era simple de entender: cuando el emisor marcaba un número, el par de hilos de cobre que iba desde su teléfono hasta la centralita era conectado automáticamente al par de hilos que llevaba al teléfono del receptor. En las llamadas a larga distancia el proceso era similar, sólo que las conexiones eran realizadas a través de muchos conmutadores. A este sistema se le denomina como el sistema telefónico plano antiguo (*plain old telephone system*, POTS). Es una típica red de *conmutación de circuitos*.

◊ **Conmutación de paquetes.** El advenimiento de los dispositivos de conmutación y de la tecnología digital trajo nuevas posibilidades a las telecomunicaciones, básicamente capacidad de procesamiento y de almacenamiento. Esto hizo posible construir redes de comunicaciones de un modo muy diferente. Este nuevo tipo de redes de comunicaciones se denomina de *almacenamiento y reenvío* (*store-and-forward network*). En lugar de iniciar y destruir conexiones para construir circuitos, una red de almacenamiento y reenvío solamente envía paquetes desde el origen hacia el destino. En cada nodo de conmutación se encuentra un computador (allá donde varios circuitos se conectan). Los paquetes que llegan a un nodo se almacenan en la memoria del computador de ese nodo y luego son procesados por un programa que les envía hacia su destino eligiendo uno de los circuitos salientes que llevará al paquete a otro nodo que estará más cerca del destino que el nodo anterior.

Realmente no existe nada nuevo en este modo de trabajar: el sistema postal es una red de almacenamiento y reenvío para las cartas, donde el procesamiento es realizado por humanos o por máquinas en las oficinas de clasificación. Pero los paquetes de datos pueden ser almacenados y procesados por los computadores lo suficientemente rápido como para crear la ilusión de una transmisión instantánea. Al menos, eso era lo que parecía hasta que la gente (incluidos los ingenie-

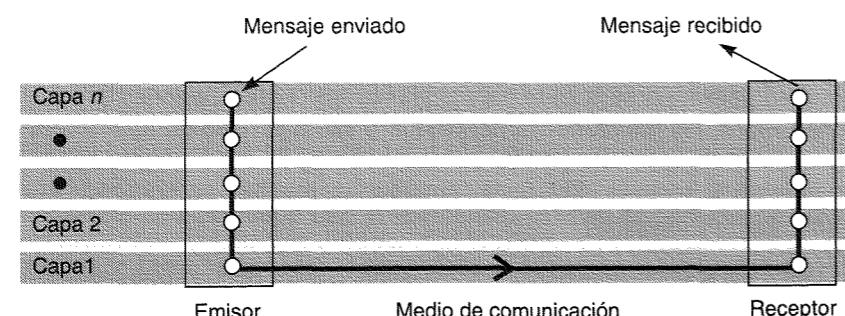


Figura 3.2. Capas conceptuales de un protocolo software.

correspondiente módulo del protocolo de transporte en el computador destino recibirá el paquete de su módulo del protocolo de nivel de red y realizará las transformaciones inversas para regenerar el mensaje antes de entregárselo al proceso receptor.

◊ **Protocolos a capas.** El software de red está organizado en una jerarquía de capas. Cada capa presenta una interfaz a las capas que se colocan sobre ella que extiende las propiedades del sistema de comunicaciones subyacente. Cada capa se representa por un módulo en cada uno de los computadores conectados a la red. La Figura 3.2 ilustra la estructura y el flujo de datos cuando se transmite un mensaje utilizando la pila de protocolos. Cada módulo aparece comunicarse directamente con el módulo del mismo nivel en otro computador en la red, aunque en realidad los datos no son transmitidos directamente entre los módulos de los protocolos del mismo nivel. En lugar de esto, cada capa de software de red se comunica con los protocolos que están por encima y por debajo de él mediante llamadas a procedimientos.

En el lado del emisor, cada capa (excepto la superior o *capa de aplicación*) acepta ítems de datos en una formato específico de la capa superior, y después de procesarlos, los transforma para encapsularlos según el formato especificado por la capa inferior a la que se los pasa para su procesamiento. La Figura 3.3 ilustra este proceso tal y como se aplica en las cuatro capas superiores del conjunto de protocolos OSI. La figura muestra las cabeceras de los paquetes que tienen la mayoría de los datos relacionados con la red, aunque por claridad se han omitido las colas que se encuentran en algunos tipos de paquetes; también se supone que el mensaje de la capa de aplicación a transmitir es más pequeño que el tamaño máximo admisible por la capa de red subyacente. En caso contrario, debería encapsularse en varios paquetes de la capa de red. En el lado del receptor, las transformaciones de conversión se aplican en las capas inferiores antes de que el mensaje se propaga

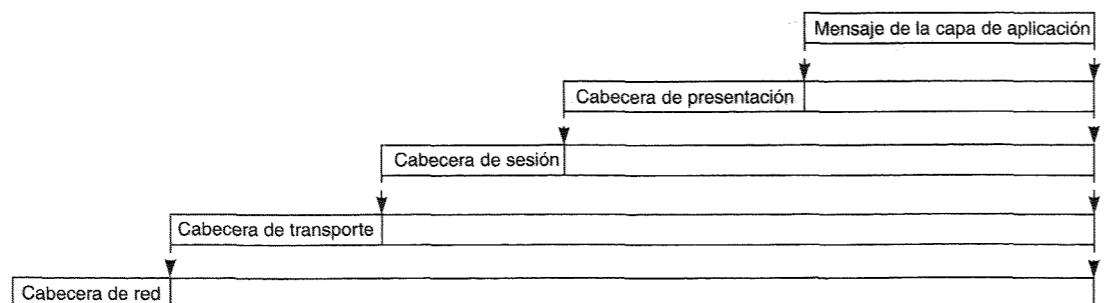


Figura 3.3. La encapsulación según se aplica en los protocolos multicapa.

que hacia arriba. El tipo de protocolo de la capa superior se incluye en la cabecera de cada capa para posibilitar en cada nivel de la pila del receptor la selección correcta de los componentes software que deben tratar los paquetes.

De este modo cada capa proporciona un servicio a la capa superior y extiende el servicio proporcionado por la capa inferior. En el nivel base se encuentra la *capa física*. Está implementada por un medio de comunicación (cables de cobre o fibra óptica, comunicaciones por satélite o transmisiones de radio) y por circuitos correspondientes que colocan señales en el medio de comunicación en el nodo emisor y las detectan en el nodo receptor. En el nodo receptor los ítems de datos son recibidos y pasan a través de la jerarquía de módulos de software, transformándose en cada capa hasta que estén en una forma adecuada para poder ser transferidos al siguiente proceso receptor.

◊ **Conjuntos de protocolos.** Al conjunto completo de capas de protocolos se le denomina *conjunto de protocolos* o *pila de protocolos*, plasmando con ello la estructura de capas. La Figura 3.4 muestra una pila de protocolos que conforma el Modelo de Referencia para la *Interconexión de Sistemas Abiertos* (*Open System Interconnection*, OSI) de siete capas adoptado por la Organización Internacional de Estándares (*International Standard Organization*, ISO) [ISO 1992]. El Modelo de Referencia OSI fue adoptado para favorecer el desarrollo de estándares de protocolos que pudieran satisfacer los requisitos de los sistemas abiertos.

El propósito de cada nivel en el Modelo de Referencia OSI se resume en la Figura 3.5. Como su nombre indica, es un marco de trabajo para la definición de protocolos y no una definición de un conjunto determinado de ellos. Los protocolos que sigan el modelo OSI deben incluir al menos un protocolo específico en cada una de las siete capas que el modelo define.

Los protocolos por capas proporcionan beneficios substanciales al simplificar y generalizar las interfaces software para el acceso a los servicios de comunicación de las redes, aunque también implican costos significativos en prestaciones. La transmisión de un mensaje de la capa de aplicación vía la pila de protocolos con N capas normalmente involucra N transferencias de control a las capas relevantes en la pila, una de las cuales es una entrada del sistema operativo, y realiza N copias de los datos como parte del mecanismo de encapsulación. Todas estas sobrecargas producen que la tasa de transferencia entre los procesos de aplicación sea mucho menor que el ancho de banda disponible.

La Figura 3.5 incluye ejemplos de protocolos utilizados en Internet, aunque la implementación de Internet no sigue el modelo OSI en dos aspectos. Primero, las capas de aplicación, presentación

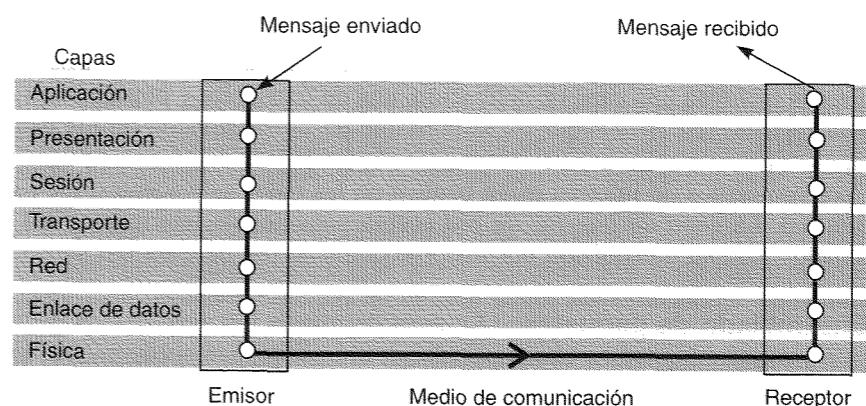


Figura 3.4. Capas de protocolos en el modelo de protocolos de *Interconexión de Sistemas Abiertos* (OSI).

Capa	Descripción	Ejemplos
Aplicación	Protocolos diseñados para responder a los requisitos de comunicación de aplicaciones específicas, a menudo definiendo la interfaz a un servicio.	HTTP, FTP, SMTP, CORBA IIOP
Presentación	Los protocolos de este nivel transmiten datos en una representación de datos de red independiente de las utilizadas comúnmente en los computadores, que pueden ser distintas. Si se necesitara, la encriptación también se llevaría a cabo en este nivel.	SSL, Representación de datos CORBA
Sesión	En este nivel se implementa la fiabilidad y la adaptación, tales como la detección de fallos y la recuperación automática.	
Transporte	Este es el nivel más bajo en el que se gestionan mensajes (en lugar de paquetes). Los mensajes son dirigidos a los puertos de comunicaciones asociados a los procesos. Los protocolos de esta capa pueden ser orientados a conexión o no.	TCP, UDP
Red	Transfiere paquetes de datos entre computadores en una red específica. En una WAN o en una interred esto implica la generación de una ruta de paso a través de los routers. En una LAN simple no se necesita encaminamiento.	IP, circuitos virtuales ATM
Enlace de datos	Es responsable de la transmisión de paquetes entre nodos que están conectados directamente por un enlace físico. En una transmisión WAN será entre pares de routers o entre un router y un host. En las LANs es entre cualquier par de hosts.	MAC de Ethernet, transferencia de celdas ATM, PPP
Físico	Los circuitos y el hardware que dirigen la red. Transmite secuencias de datos binarios mediante señales binarias, utilizando modulación en amplitud o en frecuencia de las señales eléctricas (en los circuitos de cables), señales ópticas (en los circuitos de fibra óptica) u otras señales electromagnéticas (en los circuitos de radio o microondas).	Señalización de banda-base Ethernet, ISDN

Figura 3.5. Resumen del protocolo OSI.

y sesión no son claramente distinguibles en la pila de protocolos de Internet. En su lugar, las capas de aplicación y presentación están implementadas o en una única capa de software intermedio (*middleware*), o separadamente dentro de cada aplicación. De esta guisa, CORBA implementa las invocaciones entre objetos y las representaciones de datos en una biblioteca middleware que se incluye en cada proceso de aplicación (véase el Capítulo 17 para más detalles sobre CORBA). Los navegadores web y otras aplicaciones que requieren canales seguros emplean la capa de sockets seguros (*Secure Sockets Layer*, SSL) (véase el Capítulo 7) como una biblioteca de procedimientos de una manera similar.

Segundo, la capa de sesión está integrada con la de transporte. Los conjuntos de protocolos interredes incluyen una capa de aplicación, una de transporte y otra de interred. La capa de interred es una capa de red *virtual* que es responsable de la transmisión de los paquetes de la interred al computador destino. El *paquete interred* es la unidad de datos transmitidos sobre la red.

Los protocolos de interred están ocultos en las redes subyacentes, tal y como se muestra en la Figura 3.6. La *capa de interfaz de red* acepta paquetes de interredes y los convierte en paquetes adecuados para su transmisión por los protocolos de red de cada red subyacente.

◇ **Ensamblado de paquetes.** La tarea de dividir los mensajes en paquetes antes de la transmisión y reensamblarlos en el computador destino se realiza normalmente en la capa de transporte.

Los paquetes del protocolo de la capa de red están compuestos por una *cabecera* y por un *campo de datos*. En la mayoría de las tecnologías de red, el campo de datos es de longitud variable, aunque tenga un límite llamado la *unidad máxima de transferencia*, (*maximum transfer unit*, MTU). Si la longitud del mensaje excede la MTU de la capa de red, debe ser fragmentado en tro-

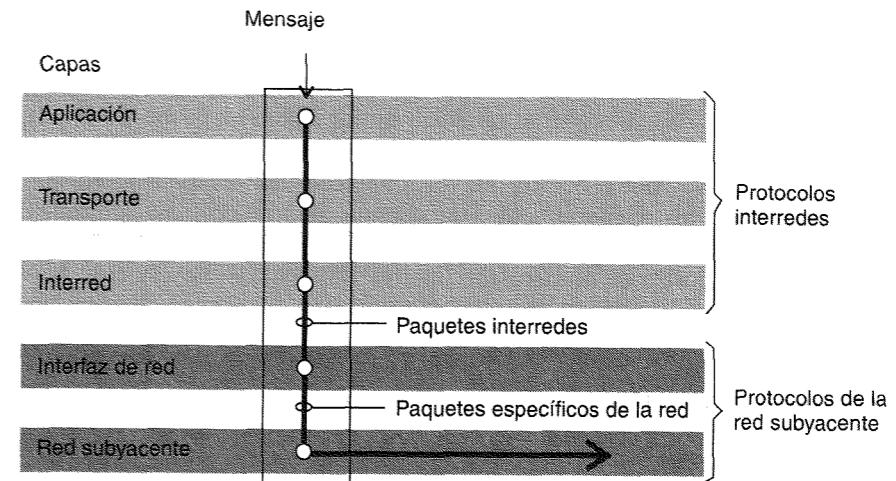


Figura 3.6. Capas de interredes.

zos de tamaño apropiado, y debe ser identificado con una secuencia de números para utilizarla en el reensamblado, y transmitido en múltiples paquetes. Por ejemplo, la MTU de Ethernet es de 1.500 bytes; por lo que no se puede transmitir más que esta cantidad de datos en un solo paquete Ethernet.

La MTU del protocolo IP, que es el utilizado como protocolo de la capa de red en Internet, es inusualmente grande: 64 kbytes (en la práctica se suele utilizar sólo 8 kbytes, ya que algunos nodos no son capaces de gestionar paquetes tan grandes). Independientemente de la MTU adoptada para los paquetes IP, aquellos que sean mayores que la MTU de Ethernet deberán ser fragmentados para su transmisión sobre Ethernet.

◇ **Puertos.** La tarea de la capa de transporte es la de proporcionar un servicio de transporte de mensajes independiente de la red entre pares de *puertos* de red. Los puertos son puntos de destino para la comunicación dentro de un computador definidos por software. Los puertos se asocian a procesos, permitiendo, de este modo, la comunicación de un proceso con otro. Los detalles específicos de la abstracción de los puertos puede variar para proporcionar propiedades adicionales útiles. Nosotros describiremos aquí el direccionamiento de puertos según se da en Internet y en la mayoría de las otras redes. El Capítulo 4 tratará sobre el uso de los puertos.

◇ **Direccionamiento.** La capa de transporte es responsable de la entrega de los mensajes en el destino utilizando para ello una *dirección de transporte*, compuesta por la dirección de red de un computador y por un número de puerto. Una dirección de red es un identificador numérico que identifica de forma única a un computador y posibilita su localización por parte de los nodos responsables del encaminamiento de los datos. En Internet todos los computadores tienen asignado un número IP, que identifica tanto al computador como a la subred a la que está conectada, haciendo posible que los datos sean encaminados a ella desde cualquier otro nodo según se describe en las siguientes secciones. En las redes Ethernet no existen nodos encaminadores; cada host es responsable de reconocer y recuperar los paquetes a él dirigidos.

En Internet existen normalmente varios puertos en cada computador con números bien conocidos, cada uno reservado para dar un servicio de Internet, como HTTP o FTP. Los puertos bien conocidos y las definiciones de los servicios están registrados por una autoridad central [www.iana.org]. Para acceder a un servicio en un determinado host, se envía una petición al puerto correspondiente en el host. Algunos servicios, como FTP, reservan entonces otro puerto nuevo

(con un número privado) y envían el número del nuevo puerto al cliente. El cliente utiliza el nuevo

(con un número privado) y envían el número del nuevo puerto al cliente. El cliente utiliza el nuevo puerto para establecer una conexión TCP, sobre la que se realiza el resto de una transacción o de otra conexión. Otros servicios, como HTTP, realizan todas sus transacciones a través de puertos bien

por nuevos servicios y por procesos nuevos, que necesitan reservar puertos en los que recibir mensajes de los servidores. Generalmente, un sistema distribuido tiene múltiples servidores, que además son distintos dependiendo del tiempo y de las organizaciones. Obviamente, no resulta adecuada una reserva de host o de números de puertos fijos para esos servicios. La solución al problema en el que los clientes localizan servidores arbitrarios en un sistema distribuido se trata en la subsección sobre enlaces del Capítulo 5.

◊ **Entrega de paquetes.** Existen dos aproximaciones a la hora de entregar paquetes por parte de la capa de red:

Entrega de paquetes tipo datagrama: el término *datagrama* se refiere a la semejanza que existe entre este modo de entrega y aquel en el que se entregan los telegramas y las cartas. La característica esencial de los datagramas de red es que la entrega de cada paquete es un proceso de un paso, no requiere ninguna preparación y una vez que el paquete ha sido entregado, la red no

logía de circuitos virtuales más importante en uso es ATM; y como ya hemos mencionado (en la Sección 3.3.3), tiene una baja latencia de transmisión de paquetes, lo que es una consecuencia directa de la utilización de los circuitos virtuales. La necesidad de la fase de establecimiento del circuito produce, sin embargo, un pequeño retraso antes de que cualquier paquete pueda llegar a su destino.

La distinción entre la entrega de paquetes por datagramas y por circuitos virtuales no debe confundirse con un par de mecanismos similares que existen en la capa de transporte (transmisión orientada a conexión y no orientada a conexión). Trataremos este apartado en la Sección 3.4.6, en el contexto de los protocolos de transporte de Internet UDP (sin conexión) y TCP (orientado a conexión). Aquí solamente hacemos notar que cada uno de esos modos de transmisión puede ser implementado sobre cualquier tipo de capa de red.

3.3.5. ENCAMINAMIENTO

El encaminamiento es una función necesaria en todas redes excepto en aquellas redes LAN, como Ethernet, que proporcionan conexiones directas entre todos los pares de hosts conectados. En las redes grandes se emplea un *encaminamiento adaptativo*: se reevalúan periódicamente las mejores rutas para comunicar dos puntos de red, teniendo en cuenta el tráfico actual y cualquier fallo como conexiones rotas o routers caídos.

La entrega de los paquetes a sus destinos en una red como la mostrada en la Figura 3.7 es una responsabilidad colectiva de los routers situados en los puntos de conexión. A menos que los hosts origen y destino se encuentren en la misma LAN, el paquete tendrá que ser transmitido en una serie de saltos, pasando a través de los routers. La determinación de las rutas para la transmisión de los paquetes a su destino es responsabilidad del *algoritmo de encaminamiento*, implementado por un programa en la capa de red de cada nodo.

Un algoritmo de encaminamiento tiene dos partes:

1. Tomar decisiones que determinen la ruta seguida por cada paquete que viaja por la red. En las capas de red de conmutación de circuitos como las redes X.25, y del tipo *frame-relay* como las redes ATM, la ruta se determina cuando se establece un circuito virtual o una conexión. En las capas de red de conmutación de paquetes como IP se fija separadamente para cada paquete, y el algoritmo debe ser particularmente simple y eficiente para que no degrade las prestaciones de la red.

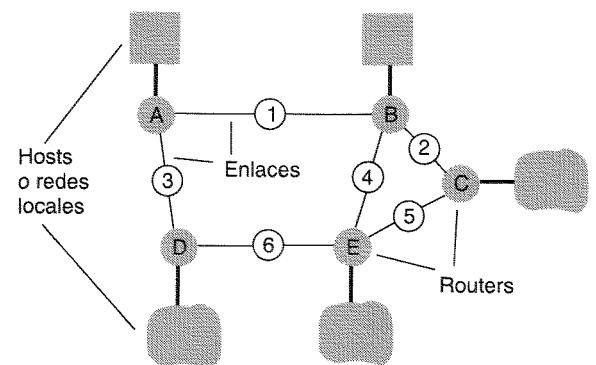
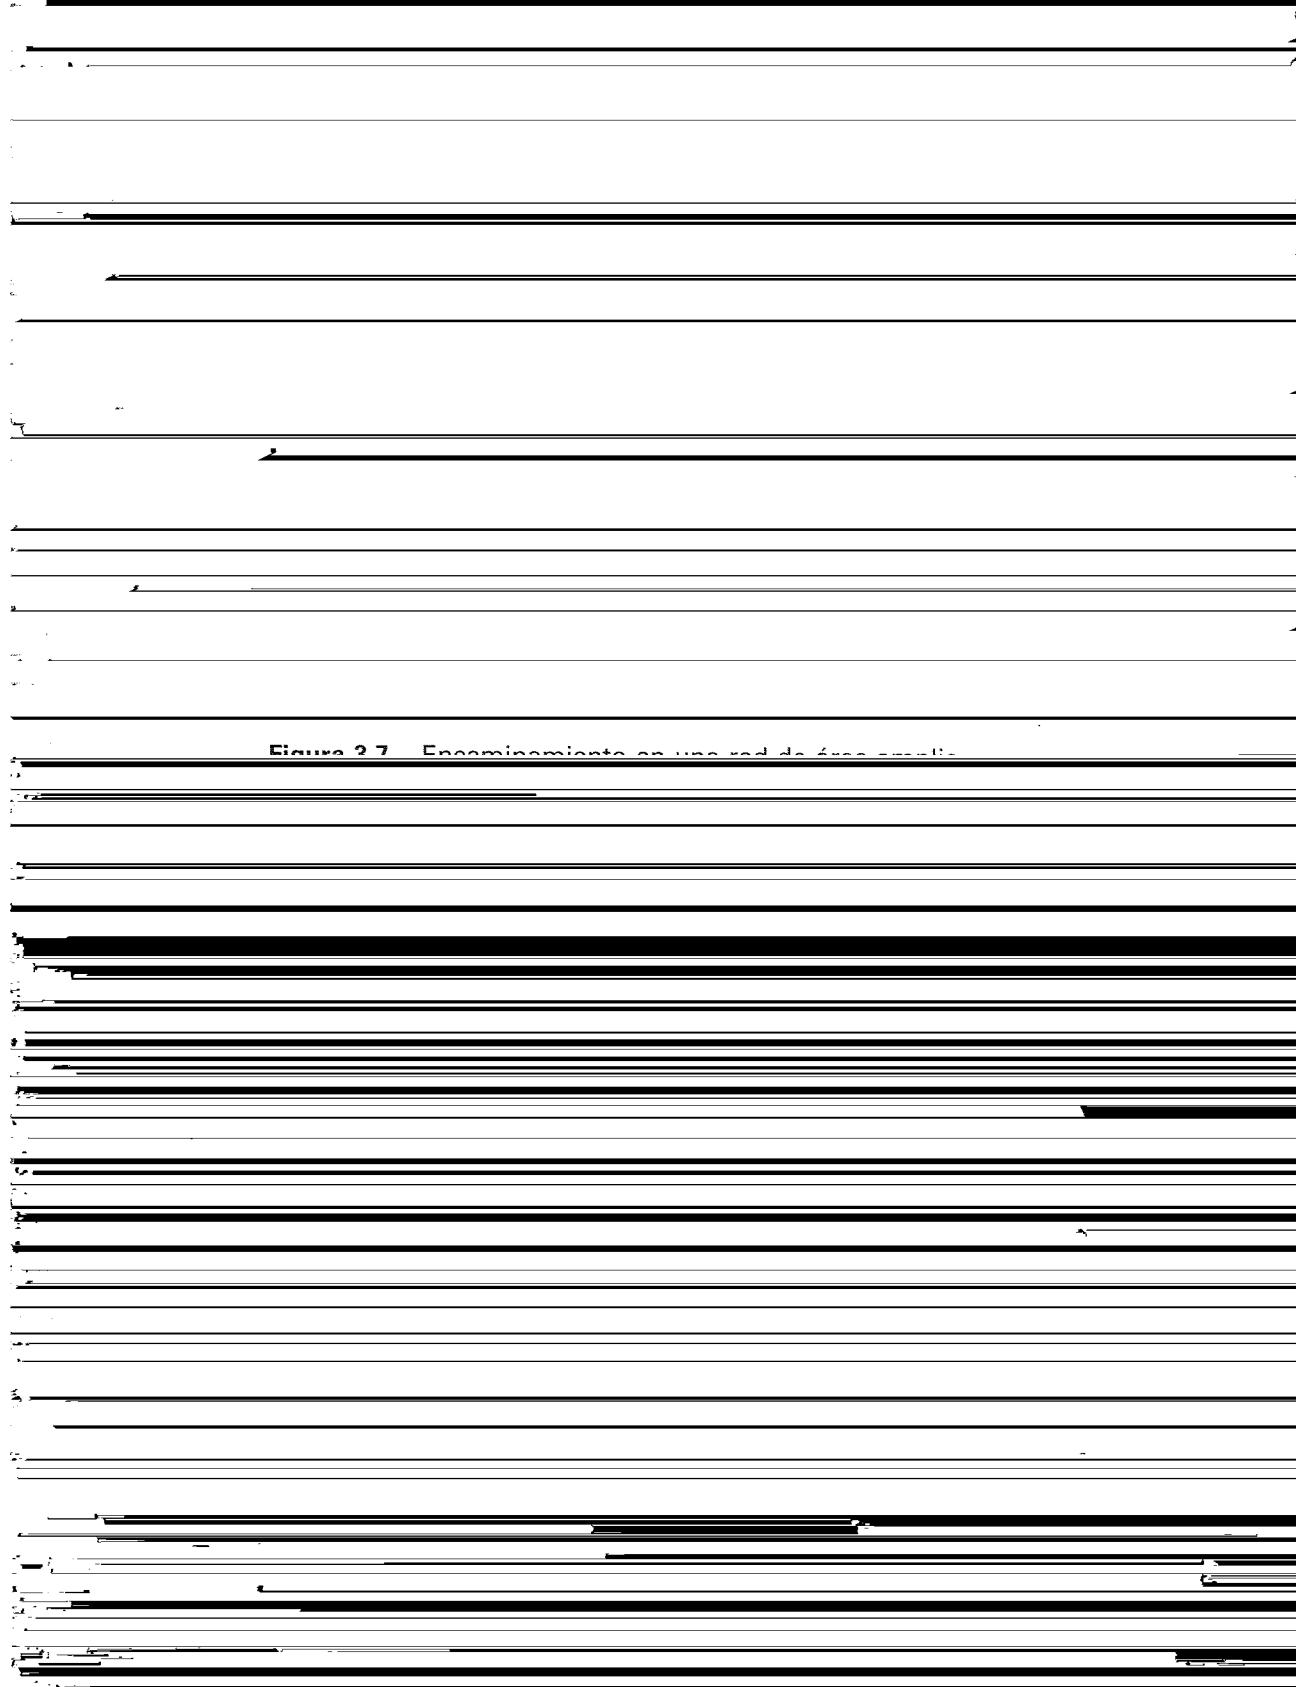


Figura 3.7. Encaminamiento en una red de área amplia.



Las tablas de encaminamiento contienen una entrada por cada posible destino, en la que se muestra el siguiente *salto* que debe dar el paquete hacia su destino final. Cuando un paquete llega a un router, se extrae su dirección destino y se busca en la tabla de encaminamiento. La entrada resultante identifica el enlace de salida que tiene que ser utilizado para encaminar el paquete hacia su destino.

Por ejemplo, cuando un paquete dirigido hacia C es entregado al router A, éste examina la entrada para C en su tabla de encaminamiento. Esta entrada muestra que el paquete debería ser encaminado hacia B por el enlace etiquetado como 1. El paquete llega entonces a B y siguiendo el mismo procedimiento que el utilizado en la tabla de encaminamiento de B, se determina que la ruta de salida de C para ese paquete es el enlace 2. Cuando el paquete llega a C, la entrada de la tabla indica *local* en lugar de un número de enlace. Esto indica que el paquete debe ser entregado en el host local.

Consideremos ahora el modo en que se construyen las tablas de encaminamiento y cómo se mantienen cuando se producen fallos en la red. Es decir, el modo en que se ejecuta la segunda fase del algoritmo de encaminamiento referido anteriormente. Dado que cada tabla de encaminamiento especifica un único salto para cada ruta, la construcción o reparación de la información de encaminamiento puede llevarse a cabo de modo distribuido. Un router intercambia información sobre la red con sus nodos vecinos enviando un resumen de su tabla de encaminamiento utilizando para ello un *protocolo de información de encaminamiento* (*router information protocol*, RIP). Las acciones desarrolladas en un router como consecuencia del protocolo RIP pueden describirse de manera informal como sigue:

1. *Periódicamente y siempre que cambie la tabla local*, enviar la tabla (de manera resumida) a todos los vecinos accesibles. Esto es, enviar un paquete RIP conteniendo una copia de la tabla con cada enlace saliente no caído.
2. *Cuando se recibe una tabla de un router vecino*, si la tabla recibida muestra un nuevo destino, o una ruta mejor (menos costosa) a un destino existente, entonces modificar la tabla local añadiendo la nueva ruta. Si la tabla fue recibida por el enlace n y da un coste diferente que la tabla local para la ruta que comienza con el enlace n , entonces reemplazar el coste en la tabla local con el nuevo coste. Esto es así porque la tabla nueva fue enviada desde un router más cercano al destino relevante y está por lo tanto más autorizado respecto de las rutas que pasan a través de él.

Este algoritmo se describe de manera más precisa en el programa en pseudocódigo mostrado en la Figura 3.9, donde Tr es la tabla recibida desde otro router y Tl es la tabla local. Ford y Fulkerson [1962] han demostrado que los pasos descritos anteriormente son suficientes para asegurar que las

Envía: Cada t segundos, o cuando cambia Tl , enviar Tl por cada enlace saliente no caído.

Recibe: Siempre que se reciba una tabla Tr por el enlace n :

```

para todas las filas  $Rr$  en  $Tr$  {
    si ( $Rr.enlace \neq n$ ){
         $Rr.coste = Rr.coste + 1;$ 
         $Rr.enlace = n;$ 
        si ( $Rr.destino$  no está en  $Tl$ ) añadir  $Rr$  a  $Tl$ ; // añadir un nuevo destino a  $Tl$ 
        // si no para todas las filas de  $Rl$  en  $Tl$ 
        si ( $Rr.destino = Rl.destino$  y
            ( $Rr.coste < Rl.coste$  o  $Rl.enlace = n$ ))  $Rl = Rr$ ;
            //  $Rr.coste < Rl.coste$ : el nodo remoto es una ruta mejor
            //  $Rl.enlace = n$ : el nodo remoto está más autorizado
    }
}
}
```

Figura 3.9. Pseudocódigo del algoritmo de encaminamiento RIP.

tablas de encaminamiento convergerán en las mejores rutas para cada destino siempre que se dé

tablas de encaminamiento convergerán en las mejores rutas para cada destino siempre que se dé algún cambio en la red. La frecuencia t con la que se propagan las tablas, incluso si no se producen cambios, está diseñada para asegurar que se mantiene una estabilidad, por ejemplo, en el caso de

capacidad, el rendimiento total tiende a caer como resultado de las pérdidas de paquetes, a menos que se controlen los enlaces cargados en exceso.

En lugar de permitir que los paquetes viajen sin más por la red hasta que llegan a los nodos sobrecargados, donde tendrán que ser desecharados, sería mejor almacenarlos en nodos anteriores a los sobrecargados, hasta que la congestión se reduzca. Esto incrementará los retardos de los paquetes, pero no se degradará significativamente el rendimiento de la red. Bajo el nombre de «control de la congestión» se agrupan las técnicas que se diseñan para controlar este aspecto.

En general, el control de la congestión se consigue informando a los nodos a lo largo de la ruta de que se ha producido la congestión, y que, en consecuencia, debería reducirse su tasa de transmisión de paquetes. Para los nodos intermedios, esto implicará el almacenamiento de los paquetes entrantes en cada búfer por un período largo. Para los hosts que son fuente de los paquetes, el resultado quizás sea que los paquetes sean puestos en colas antes de su transmisión, o que se bloquee el proceso que está generándolos hasta que la red pueda admitir los paquetes.

Todas las capas de red basadas en datagramas, incluyendo IP y Ethernet, basan el control del tráfico en métodos de extremo a extremo. Esto es, el nodo emisor debe reducir la tasa a la que transmite los paquetes basándose exclusivamente en la información que recibe del nodo receptor. La información sobre la congestión puede ser enviada al nodo emisor mediante la transmisión explícita de paquetes especiales (llamados paquetes de estrangulamiento, o *choke packets*) que solicitan una reducción en la tasa de transmisión, o mediante la implementación de un protocolo de control de la transmisión específico (de lo cual toma su nombre el protocolo TCP, cuyo mecanismo se explicará en la Sección 3.4.6), o por la observación de la ocurrencia de las pérdidas de paquetes (si el protocolo es uno de aquellos en el que cada paquete es reconocido).

En algunas redes basadas en circuitos virtuales, la información sobre la congestión puede recibirse en todos los nodos, cada uno de los cuales actuará en consecuencia. Aunque ATM utiliza circuitos virtuales, se basa en la gestión de la calidad de servicio (véase la Sección 3.5.3 y el Capítulo 15) para asegurar que cada circuito puede soportar el tráfico requerido.

3.3.7. INTERCONEXIÓN DE REDES

Existen muchas tecnologías de red con diferentes protocolos de red, enlace y nivel físico. Las redes locales se construyen con tecnologías Ethernet y ATM, las redes de área amplia se construyen sobre otras análogas y con redes de telefonía digital de distintos tipos, enlaces de satélite y redes ATM de área amplia. Los computadores individuales y las redes locales están conectadas a Internet o a intranets mediante módems, enlaces ISDN y conexiones DSL.

Para construir una red integrada (una interred) debemos integrar muchas subredes, cada una de las cuales se basa en una de esas tecnologías de red. Para hacer esto posible se necesita:

1. Un esquema de direccionamiento unificado que posibilite que los paquetes sean dirigidos a cualquier host conectado en cualquier subred.
2. Un protocolo que defina el formato de los paquetes interred y las reglas según las cuales serán gestionados.
3. Componentes de interconexión que encaminen paquetes hacia su destino en términos de dirección interred, transmitiendo los paquetes utilizando subredes con tecnologías de red variadas.

En Internet, la primera condición está resuelta por la utilización de las direcciones IP, el protocolo referido en la segunda condición es el protocolo IP y la tercera condición está soportada por unos componentes llamados *Routers de Internet*. El protocolo IP y el direccionamiento IP están descritos con detalle en la Sección 3.4. Aquí describiremos las funciones de los routers de Internet y algunos otros componentes que se usan para conectar a las redes.

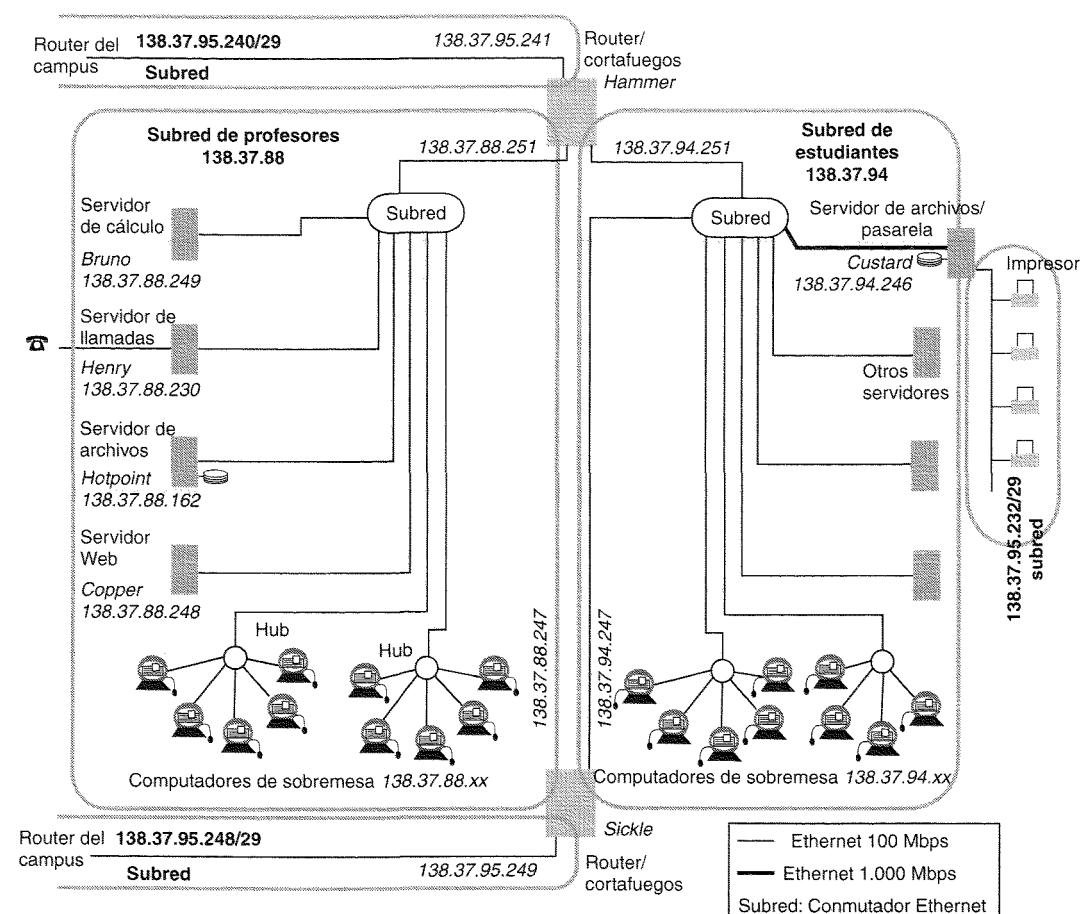


Figura 3.10. Visión simplificada de la red de Informática del QMW.

La Figura 3.10 muestra una pequeña parte de la *intranet* del *Queen Mary and Westfield College* (QMW) de la Universidad de Londres. Muchos de los detalles que muestra serán explicados en las secciones posteriores. Ahora vamos a fijarnos en que la figura contiene varias subredes interconectadas mediante routers. Las subredes aparecen recuadradas; existen cinco de ellas, tres de las cuales comparten la red IP 138.37.95 (utilizando el esquema de encaminamiento entre dominios sin clases descrito en la Sección 3.4.3). Las direcciones numéricas son direcciones IP y se explicarán más adelante. Los routers están colocados entre varias subredes y tienen una dirección IP por cada una a las que están conectados (las direcciones están colocadas junto a los enlaces).

Los routers (con nombre de host *hammer* y *sickle*) son, de hecho, computadores de propósito general que también atienden a otros fines. Uno de ellos es de servir como cortafuegos; el papel de un cortafuegos está estrechamente ligado con la función de encaminamiento, como describiremos más adelante. La subred 138.37.95.232/29 no está conectada con el resto de la red a nivel IP. Solamente el servidor de archivos *custard* puede acceder a ella para proporcionar servicios de impresión en las impresoras conectadas a la subred, a través de un proceso servidor que gestiona y controla el uso de las mismas.

Todos los enlaces de la Figura 3.10 son Ethernet. El ancho de banda de la mayoría de ellos es 100 Mbps, excepto uno que es de 1.000 Mbps, ya que lleva un gran volumen de tráfico entre el

gran número de computadores utilizados por los estudiantes y *custard*, el servidor de archivos que alberga todos sus archivos.

En la parte de la red mostrada hay dos comutadores Ethernet y varios concentradores Ethernet. Ambos tipos de componentes resultan transparentes para los paquetes IP. Un concentrador Ethernet es un medio sencillo de conectar juntos distintos segmentos de cable Ethernet, formando una única red Ethernet para el protocolo de red. Todos los paquetes Ethernet recibidos por el concentrador son retransmitidos a todos los segmentos. Un comutador Ethernet conecta varias redes Ethernet, encaminando los paquetes entrantes sólo a la red Ethernet a la que está conectada el host destino.

◊ **Routers.** Hemos comentado anteriormente que el encaminamiento es necesario en todas las redes excepto en aquellas en las que, como Ethernet y las inalámbricas, todos los hosts están conectados por un medio de transmisión único. La Figura 3.7 mostraba una red con cinco routers conectados por seis enlaces. En una interred, los routers pueden enlazarse mediante conexiones directas, tal y como sucede en la Figura 3.7, o bien pueden estar interconectados a través de subredes, siendo éste el caso de *custard* en la Figura 3.10. En ambos casos, los routers son los responsables de reenviar los paquetes de interred que les llegan hacia las conexiones salientes correctas según se explicó anteriormente, para lo cual se mantienen las tablas de encaminamiento.

◊ **Puentes.** Los puentes (*bridges*) enlazan redes de distintos tipos. Algunos puentes comunican varias redes, y se les denomina puentes/routers porque también efectúan funciones de encaminamiento. Por ejemplo, la red del QMW incluye una conexión troncal (*backbone*) de fibra óptica (*Fibre Distributed Data Interface*, FDDI), no mostrada en la Figura 3.10, que está conectada a las subredes Ethernet de la figura mediante puentes/routers.

◊ **Concentradores.** Los concentradores (*hubs*) son un modo apropiado para conectar hosts y extender los segmentos de Ethernet y otras tecnologías de redes locales de difusión. Tienen varios conectores (generalmente entre 4 y 64), a los que se pueden conectar hosts. También pueden ser utilizados para eludir las limitaciones de distancia en un único segmento y proporcionar un modo de añadir hosts adicionales.

◊ **Comutadores.** Un comutador (*switch*) lleva a cabo una función similar a la que desarrolla un router, pero restringida a redes locales, normalmente Ethernet. Según esto, pueden interconectar distintas redes Ethernet separadas, encaminando los paquetes entrantes a la red de salida apropiada. Efectúan su tarea en el nivel del protocolo Ethernet. Comienzan sin ningún conocimiento sobre la interred, y van construyendo sus tablas de encaminamiento basándose en la observación del tráfico, complementando la falta de información con la difusión de solicitudes de información.

La ventaja de los comutadores sobre los concentradores es que pueden separar el tráfico entrante y transmitirlo sólo hacia la red de salida relevante, reduciendo la congestión en las otras redes a las que están conectados.

◊ **Túneles.** Los puentes y los routers transmiten paquetes de interred sobre una variedad de redes subyacentes, pero se da una situación en la cual el protocolo de red puede quedar oculto para los protocolos superiores sin tener que utilizar un protocolo especial de interred. Cuando un par de nodos conectados a dos redes separadas necesitan comunicarse a través de algún otro tipo de red o sobre un protocolo extraño, pueden hacerlo construyendo un protocolo soterrado o de *túneling* (*tunneling*). En la Figura 3.11 se muestra el propósito de los túneles, donde se utiliza para posibilitar la migración de Internet al recientemente aprobado protocolo IPv6. El protocolo IPv6 está designado a reemplazar a la versión actual de IP, IPv4, con la que es incompatible. (Tanto IPv4 como IPv6 son descritos en la Sección 3.4.) Durante el período de transición a IPv6 existirán islas de IPv6 en el mar de IPv4. En la figura, A y B son esas islas. En los límites de las islas los paquetes IPv6 son encapsulados en paquetes IPv4 y transportados de ese modo sobre las redes IPv4 intervinientes.

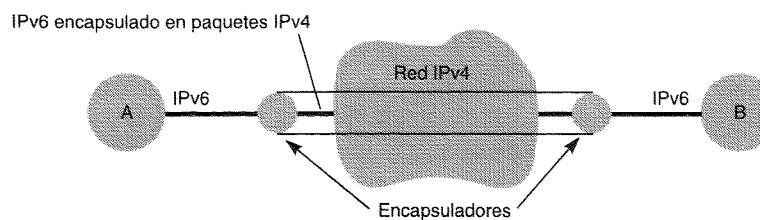


Figura 3.11. Empleo de túneles para la migración a IPv6.

Por lo tanto, un protocolo túnel es una capa de software que transmite paquetes a través de un entorno de red extraño. Por ejemplo, el protocolo MobileIP transmite paquetes IP a hosts móviles en cualquier sitio de Internet construyendo un túnel a ellos desde la red considerada la base de los hosts móviles. Los nodos de red intervenientes no necesitan ser modificados para gestionar el protocolo MobileIP. El protocolo IP de multidifusión se maneja de un modo similar, llegando a los pocos routers que soportan el encaminamiento de la multidifusión IP para determinar las rutas, pero transmitiendo paquetes IP a través de las otras rutas utilizando direcciones IP estándares. El protocolo PPP para la transmisión de paquetes IP sobre enlaces serie es otro ejemplo de ello.

La analogía siguiente explica la razón de la elección de la terminología y proporciona otro modo de pensar sobre el túnel. Un túnel en una montaña posibilita que una carretera la atraviese y puedan circular los automóviles allá donde de otro modo sería imposible. La carretera es continua y el túnel es transparente para las aplicaciones (o automóviles). La carretera es el mecanismo de transporte, y el túnel posibilita que funcione en un entorno extraño.

3.4. PROTOCOLOS INTERNET

Aquí describiremos las principales características del conjunto de protocolos TCP/IP y discutiremos sus ventajas y limitaciones cuando se utilizan en sistemas distribuidos.

Internet surgió después de dos décadas de investigación y desarrollo de redes de área amplia en los Estados Unidos, comenzando en los primeros años setenta con ARPANET, la primera red de computadores a gran escala desarrollada [Leinet y otros 1997]. Una parte importante de esa investigación fue el desarrollo del conjunto de protocolos TCP/IP. TCP es el acrónimo de *Transmisión Control Protocol* (protocolo de control de la transmisión), e IP se refiere a *Internet Protocol* (protocolo de Internet). La extensa adopción de TCP/IP y de los protocolos de aplicación de Internet en las redes de investigación nacionales, y más recientemente en las redes comerciales de muchos países, ha posibilitado que las redes nacionales puedan ser integradas en una sola interred que ha crecido de forma extremadamente rápida hasta alcanzar su tamaño actual, con más de 60 millones de hosts. Existen muchos servicios de aplicación y protocolos de nivel de aplicación (mencionados entre paréntesis en la siguiente lista) basados en TCP/IP, incluyendo el Web (HTTP), el correo electrónico (SMTP, POP), las redes de noticias (NNTP), la transferencia de archivos (FTP), y la conexión remota (Telnet). TCP es un protocolo de transporte; puede ser utilizado para soportar aplicaciones directamente sobre él, o se le pueden superponer capas adicionales de protocolos para proporcionar características adicionales. Por ejemplo, HTTP es usualmente transportado directamente por TCP, pero cuando se requiere seguridad en la comunicación entre extremos, se coloca sobre él el protocolo *Secure Sockets Layer* (SSL) (descrito en la Sección 7.6.3) para conseguir canales seguros sobre los que enviar los mensajes HTTP.

Los protocolos Internet fueron desarrollados principalmente para soportar aplicaciones simples de área amplia entre computadores dispersos geográficamente, tales como la transferencia de archi-

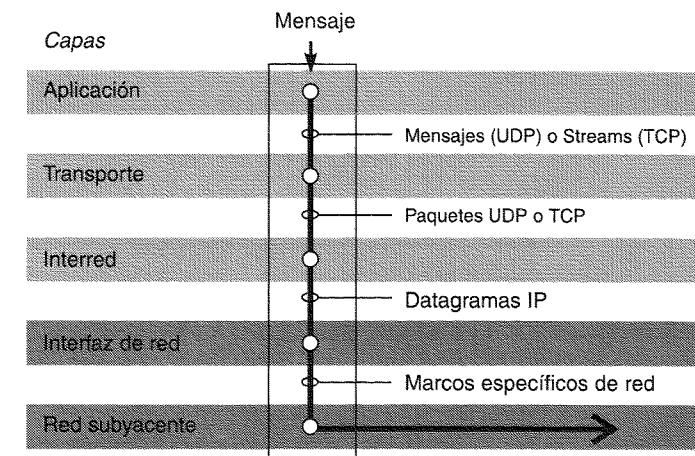


Figura 3.12. Capas TCP/IP.

vos y el correo electrónico, involucrando comunicaciones con latencias relativamente grandes; pero se han mostrado lo suficientemente eficientes como para soportar los requisitos de muchas aplicaciones distribuidas tanto en redes de área local como de área amplia, y ahora son utilizados casi universalmente en los sistemas distribuidos. La estandarización resultante de los protocolos de comunicación ha producido inmensos beneficios. Las únicas excepciones significativas a la adopción generalizada de la comunicación TCP/IP son:

- La utilización de WAP en las aplicaciones de los dispositivos móviles.
- Protocolos especiales para soportar aplicaciones multimedia basadas en flujos.

En la Figura 3.12 se muestra el caso general de las capas de protocolos interred de la Figura 3.6, trasladado al caso específico de Internet. Existen dos protocolos de transporte, TCP (*Transport Control Protocol*) y UDP (*User Datagram Protocol*). TCP es un protocolo fiable orientado a conexión, mientras que UDP es un protocolo de datagramas que no garantiza fiabilidad en la transmisión. El protocolo interred IP (*Internet Protocol*) es el protocolo de *red* subyacente de la red virtual Internet; esto es, los datagramas proporcionan un mecanismo de transmisión básico para Internet y otras redes TCP/IP. Hemos puesto en cursiva a la palabra *red* en la frase anterior porque no es la única capa de red involucrada en las comunicaciones de Internet. Esto se debe a que los protocolos Internet están soportados usualmente por otra tecnología de red, como Ethernet, la cual proporciona una capa de red física que posibilita que los computadores conectados a la misma red intercambien datagramas. La Figura 3.13 muestra la encapsulación de paquetes que se da en la transmisión de mensajes vía TCP sobre una red Ethernet. Las etiquetas en las cabeceras indican el tipo de protocolo de la capa superior, y son necesarias para que la pila de protocolos receptor desembale correctamente los paquetes. En la capa TCP, el número de puerto del receptor sirve para un propósito semejante, haciendo posible que el componente de software TCP en el host receptor pase el mensaje al correspondiente proceso de la capa de aplicación.

Las especificaciones de TCP/IP [Postel 1981a; 1981b] no especifican las capas por debajo de la capa de datagramas interred; los paquetes IP en la capa interred son transformados en paquetes correspondientes para la transmisión sobre casi cualquier combinación de redes subyacentes o enlaces de datos.

Por ejemplo, IP funcionó inicialmente sobre ARPANET, que constaba de hosts y de una versión temprana de routers (llamados PSE) conectados por enlaces de datos de larga distancia. Hoy en día se utiliza sobre casi todo tipo de tecnología de red conocida, incluida ATM, redes de área

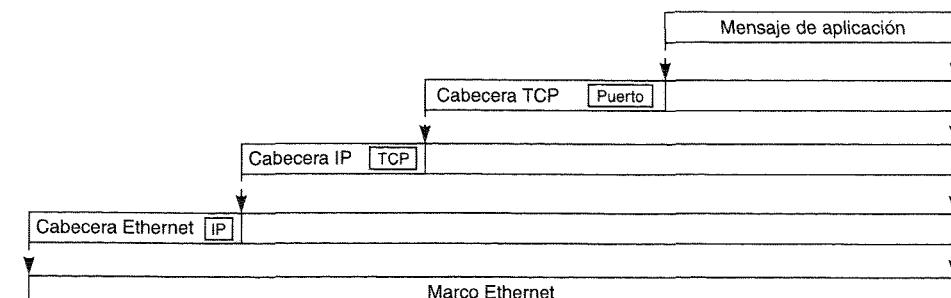


Figura 3.13. Encapsulamiento de un mensaje cuando se transmite vía TCP sobre Ethernet.

local como Ethernet y redes Token Ring. IP se encuentra implementado sobre líneas serie y circuitos telefónicos vía el protocolo PPP [Parker 1992], haciendo posible su utilización en las comunicaciones con módem y otros enlaces serie.

El éxito de TCP/IP se basa en su independencia de la tecnología de transmisión subyacente, haciendo posible construir interredes a partir de varias redes y enlaces de datos heterogéneos. Los usuarios y los programas de aplicación perciben una única red virtual que soporta TCP y UDP, y los constructores de TCP y UDP ven una única red IP virtual, ocultando la diversidad de medios de transmisión. Esta visión es la mostrada en la Figura 3.14.

En las dos secciones siguientes describiremos el esquema de direccionamiento IP y el protocolo IP. El sistema de nombres de dominio (*Domain Name System*, DNS), que es el encargado de la traducción en direcciones IP de nombres de dominio como www.amazon.com, hpl.hp.com, stanford.edu y qmw.ac.uk, con los que los usuarios de Internet están tan familiarizados, será presentado en la Sección 3.4.7 y descrito con más profundidad en el Capítulo 9.

La versión de IP actualmente en uso en Internet es IPv4 (desde enero de 1984), y ésta es la versión que nosotros describiremos en las siguientes dos secciones. Pero el rápido crecimiento en el uso de Internet condujo a la publicación de la especificación de una nueva versión (IPv6) que resuelve las limitaciones de direccionamiento de IPv4 y añade nuevas características para satisfacer nuevos requisitos. Describiremos IPv6 en la Sección 3.4.4. Dada la gran cantidad de software que está afectado por el cambio, la migración gradual a IPv6 está planeada para ser llevada a cabo en un período de 10 años o más.

3.4.1. DIRECCIONAMIENTO IP

Quizás uno de los aspectos que ofrecieron un mayor desafío en el diseño de los protocolos de Internet fue la construcción de esquemas de nombres y de direccionamiento para los hosts que pudieran permitir el encaminamiento de los paquetes IP a sus destinos. El esquema utilizado debía satisfacer los siguientes requisitos:

- Debería ser universal: cualquier host debería ser capaz de enviar paquetes a cualquier otro host en Internet.
- Debería ser eficiente en el uso del espacio de direccionamiento: es imposible predecir el tamaño último de Internet y el número de redes y de hosts a considerar. El espacio de direccionamiento debe ser repartido cuidadosamente para asegurarse que las direcciones no se agotan. Entre 1978-1982, cuando se comenzaron a desarrollar las especificaciones para los protocolos TCP/IP, se consideró que con 2^{32} , o lo que es aproximadamente lo mismo, con 4.000 millones de hosts direccionables (aproximadamente la población del mundo en esa

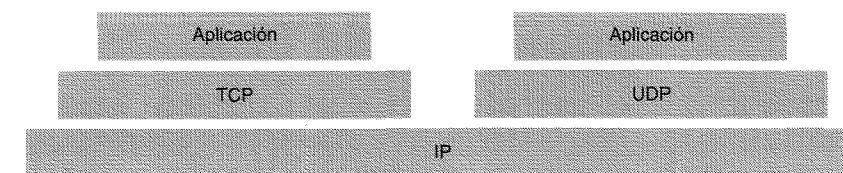


Figura 3.14. Visión conceptual del programador de una interred TCP/IP.

época) se tendrían suficientes direcciones. Se ha demostrado que esta estimación se quedó corta por dos razones:

- La tasa de crecimiento de Internet ha excedido por mucho todas las predicciones.
- El espacio de direccionamiento ha sido reservado y utilizado mucho menos eficientemente de lo esperado.
- El esquema de direccionamiento debe conducir por sí mismo al desarrollo de un esquema de encaminamiento flexible y eficiente, pero las direcciones no deben contener mucha más información de la estrictamente necesaria para que los paquetes sean encaminados a su destino.

El esquema elegido asigna una dirección IP a cada host en Internet; un número de 32 bits formado por un identificador de red, que identifica de forma única a una de las subredes de Internet, y por un identificador de host, que identifica de manera inequívoca al host conectado a esa subred. Esta dirección se coloca en los paquetes IP y es utilizada para encaminarlos al destino.

El diseño adoptado para el espacio de direccionamiento de Internet se muestra en la Figura 3.15. Existen cuatro clases de direcciones Internet: A, B, C y D. La clase D se reservada para las comunicaciones de multidifusión (*multicasting*), que se implementa sólo sobre algunos routers y sobre la que trataremos en la Sección 4.5.1. La clase E contiene un rango de direcciones no asignadas, que están reservadas para usos futuros.

Las direcciones Internet de 32 bits contienen un identificador de red y un identificador de host, normalmente escritos como una secuencia de cuatro números decimales separados por puntos. Cada número representa uno de los cuatro bytes u *octetos* de la dirección IP. Los valores permitidos para cada clase de dirección de red son los indicados en la Figura 3.16.

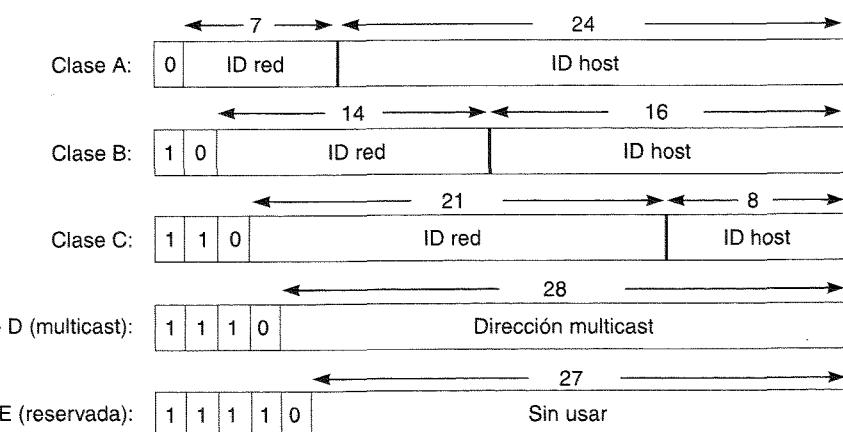


Figura 3.15. Estructura de las direcciones Internet, mostrando los tamaños de los campos en bits.

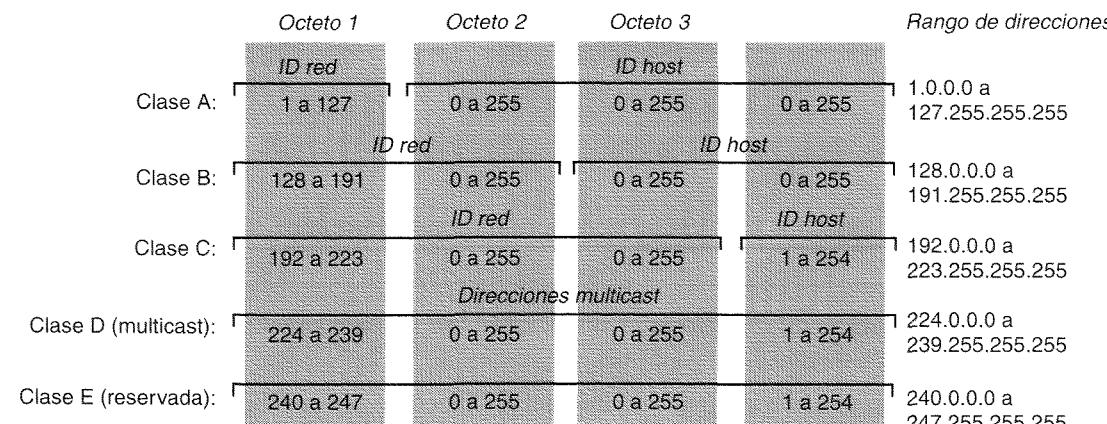


Figura 3.16. Representación decimal de las direcciones Internet.

Se diseñaron tres clases de direcciones para satisfacer los requisitos de los distintos tipos de organizaciones. Las direcciones de Clase A, con una capacidad de 2^{24} hosts en cada subred, están reservadas para grandes redes como la norteamericana NSFNet y otras redes nacionales de área amplia. Las direcciones de Clase B se reservan para organizaciones que gestionan redes con más de 255 computadores, y las direcciones de Clase C se dedican al resto de redes.

Las direcciones Internet con los bits del identificador de host a 0 y todo a 1 (en binario) se utilizan para propósitos especiales. Las direcciones con el identificador de host a 0 se utilizan para referirse a *este host*, y un identificador de host con todos los bits a 1 se utiliza para indicar que se debe difundir un mensaje (*broadcast*) a todos los hosts conectados a la red especificada en la parte del identificador de red de la dirección.

Los identificadores de red son asignados a las organizaciones con redes conectadas a Internet por el *Internet Network Information Center* (NIC). Los identificadores de los hosts para los computadores de cada red conectado a Internet son asignados por el administrador de la red en cuestión. Dado que las direcciones de host incluyen un identificador de red, cualquier computador que esté conectado a más de una red debe tener una dirección de red para cada una de ellas, y siempre que un computador se mueva a una red diferente, debe cambiar su dirección Internet. Estos requisitos pueden conducir a sobrecargas administrativas considerables, por ejemplo en el caso de computadores portátiles.

En la práctica, el esquema de reserva de direcciones IP no se ha mostrado muy efectivo. La principal dificultad es que el administrador de la red no puede predecir fácilmente el crecimiento futuro de sus necesidades de direcciones de host y tienen que sobreestimarlas, solicitando una dirección de Clase B en caso de duda. Alrededor de 1990 ya resultó evidente que según la tasa de reservas en ese momento, el NIC iba a agotar las direcciones IP hacia 1996. Entonces se tomaron dos decisiones. La primera fue el inicio del desarrollo de un nuevo protocolo IP y un nuevo esquema de direccionamiento, cuyo resultado ha sido la especificación de IPv6. La segunda decisión fue modificar radicalmente el modo en que eran reservadas las direcciones IP. El uso del espacio de direcciones IP se volvió más efectivo con un nuevo esquema de reserva y de encaminamiento llamado *encaminamiento interdominio sin clases* (*classless interdomain routing*, CIDR). Describiremos el CIDR en la Sección 3.4.3.

La Figura 3.10 mostraba una parte de la red del Departamento de Informática del *Queen Mary and Westfield College*, en la Universidad de Londres (nombre de dominio: *dcs.qmw.ac.uk*). La red incluye varias subredes del tamaño de las de la Clase C (utilizando CIDR para subdividir una red de Clase B, según se describe en la Sección 3.4.3) en el rango 138.37.88-138.37.95, enlazadas por

routers. Los routers gestionan la entrega de los paquetes IP a todas las subredes. También manejan el tráfico entre las subredes y desde las subredes hacia el resto del mundo.

3.4.2. EL PROTOCOLO IP

El protocolo IP es el encargado de transmitir datagramas desde un host a otro, si fuera necesario, vía routers intermedios. El formato completo de los paquetes IP es bastante complejo, y sus componentes principales se muestran en la Figura 3.17. Existen varios campos en la cabecera, no mostrados en el diagrama, que se utilizan para la transmisión y en los algoritmos de encaminamiento.

IP proporciona un servicio de entrega que se puede describir como *no fiable* o como el *mejor posible, best-effort*, porque no existe garantía de entrega. Los paquetes se pueden perder, ser duplicados, sufrir retrasos o ser entregados en un orden distinto al original, pero esos errores surgen sólo cuando las redes subyacentes fallan o cuando los búferes en el destino están llenos. La única comprobación de errores realizada por IP es la suma de comprobación, *checksum*, de la cabecera, que es asequible de calcular y asegura que no se han detectado alteraciones en los datos bien de direccionamiento o bien de gestión del paquete. No existe comprobación de errores en los datos, lo que evita sobrecargas cuando se cruzan routers, confiando en las comprobaciones para detectar errores de los protocolos de nivel superior, TCP y UDP (un ejemplo práctico del argumento extremo a extremo (Sección 2.2.1).

La capa IP coloca los datagramas IP en paquetes de red adecuados para ser transmitidos por la red subyacente (que podría ser, por ejemplo, Ethernet). Cuando un datagrama IP es mayor que la MTU de la red subyacente, se divide en el origen en paquetes más pequeños y se reensamblan en su destino final. Los paquetes pueden seguir siendo fragmentados para adecuarse a las características de las distintas redes que cruzan en su camino desde el origen al destino. (Cada paquete tiene un identificador de fragmento que hace posible el ensamblado de los paquetes que llegan desordenados.)

La capa IP debe insertar una dirección *física* de red del destino del mensaje antes de confiarlo a la capa inferior. Esta dirección la obtiene del módulo de resolución de direcciones en la capa de Interfaz de Red Internet, que se describe en la siguiente subsección.

◇ **Resolución de direcciones.** El módulo de resolución de direcciones es el responsable de la conversión de las direcciones Internet a direcciones de la red, para una red subyacente dada (a veces llamadas direcciones físicas). Por ejemplo, si la red fuera una red Ethernet, el módulo de resolución de direcciones convertiría las direcciones Internet de 32 bits a direcciones Ethernet de 48 bits.

Esta traducción es dependiente de la tecnología de red utilizada:

- Algunos hosts están conectados directamente a commutadores de paquetes Internet, con lo que los paquetes IP pueden ser encaminados hacia ellos sin traducción de direcciones.
- Algunas redes de área local permiten que las direcciones de red sean asignadas a los hosts de forma dinámica, y las direcciones pueden ser elegidas de manera que coincidan con la porción del identificador del host de la dirección Internet, de esta forma la traducción es tan sencilla como la extracción del identificación del host de la dirección IP.

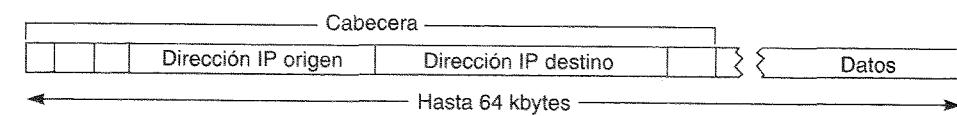
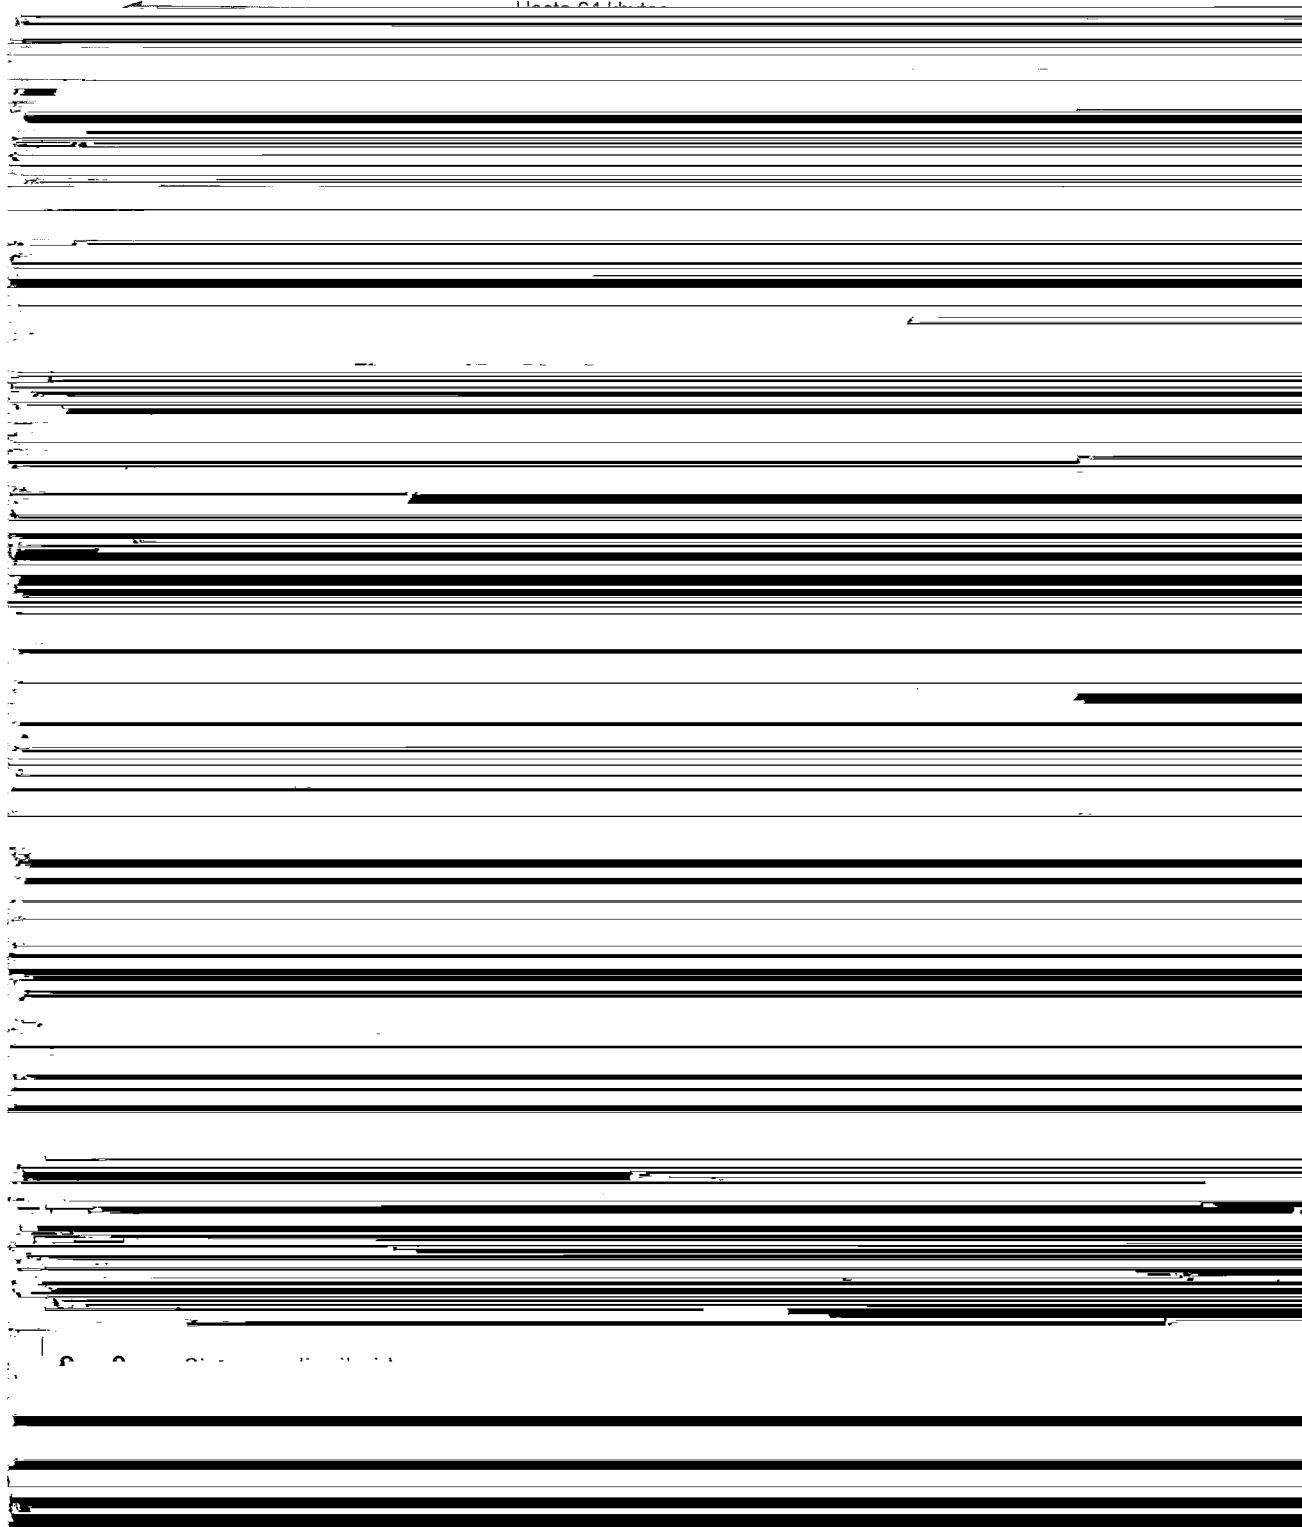


Figura 3.17. Plantilla de un paquete IP.



mayoría de las grandes organizaciones como universidades y grandes compañías son consideradas como AS, y normalmente incluyen varias áreas. La intranet del campus mostrada en la Figura 3.10 es un AS y la porción del mismo mostrada es un área. Cada AS representado en el mapa topológico tiene un área troncal. La colección de routers que conectan las áreas no troncales con la troncal y los enlaces que interconectan esos routers se conocen como la conexión troncal o la columna dorsal de la red. Los enlaces troncales (*backbone*) son de un ancho de banda mayor y suelen estar replicados para mayor fiabilidad. Esta estructura jerárquica se utiliza principalmente para la gestión de recursos y el mantenimiento de los componentes. No afecta al encaminamiento de los paquetes IP.

◊ **Protocolos de encaminamiento.** El primer algoritmo de encaminamiento utilizado en Internet, el RIP-1, es una versión del algoritmos de vector de distancias descrito en la Sección 3.3.5. El algoritmo RIP-2 (descrito en el RFC 1388 [Malkin 1993]) fue desarrollado a partir del anterior para cumplir algunos requisitos adicionales, incluyendo el encaminamiento entre dominios sin clases, un mejor encaminamiento multidifusión y la necesidad de autenticar los paquetes RIP para prevenir ataques a los routers.

Como la escala de Internet ha aumentado y la capacidad de los routers ha crecido, existe una tendencia hacia la adopción de algoritmos que no se vean limitados por la convergencia lenta y la potencial inestabilidad propias de los algoritmos de vectores de distancias. Este movimiento condujo a los algoritmos del tipo de estado de enlace mencionados en la Sección 3.3.5, en concreto al algoritmo OSPF (*open shortest path first*). Este protocolo está basado en un algoritmo de búsqueda de caminos de Dijkstra [1959] y ha demostrado converger mucho más rápidamente que el algoritmo RIP.

Debemos hacer notar que la adopción de nuevos algoritmos de encaminamiento en los routers IP puede llevarse a cabo de forma incremental. Un cambio en el algoritmo de encaminamiento implica una nueva versión del protocolo RIP, y un nuevo número de versión que será llevado por todos los paquetes RIP. El protocolo IP no cambia cuando se introduce un nuevo protocolo RIP. Cualquier router RIP encaminará correctamente los paquetes que le lleguen por una ruta, si no óptima, si razonable, independientemente de la versión de RIP que utilice. Pero para que los routers cooperen en la actualización de sus tablas de encaminamiento deben utilizar un algoritmo similar. Para este propósito se definieron las áreas topológicas anteriormente referidas. Dentro de cada área se aplica un único algoritmo de encaminamiento y los routers dentro de un área cooperan para mantener las tablas de encaminamiento. Todavía son habituales los routers que sólo soportan RIP-1, y coexisten con los routers que utilizan RIP-2 y OSPF, ya que los nuevos protocolos incorporan la compatibilidad hacia atrás.

En 1993, observaciones empíricas [Floyd y Johnson 1993] demostraron que los intercambios de información entre los routers RIP que se producen cada 30 segundos producían una periodicidad en las prestaciones de las transmisiones IP. La latencia media para las trasmisiones de paquetes IP mostraba un pico cada 30 segundos. El origen de este efecto fue asociado al comportamiento de los routers que ejecutaban el protocolo RIP y se encontró que cuando recibían un paquete RIP, demoraban la transmisión de cualquier paquete IP entrante hasta que la tabla de encaminamiento estuviera actualizada según los paquetes RIP recibidos. Esto producía que los routers ejecutaran las acciones RIP a trompicones. La corrección recomendada fue que el período de actualización tomara un valor aleatorio entre 15 y 45 segundos.

◊ **Routers por defecto.** Hasta ahora, nuestra discusión sobre los algoritmos de encaminamiento ha hecho suponer que cada router mantiene una tabla de encaminamiento completa mostrando la ruta a cualquier destino (subred o host conectado directamente) en Internet. A la escala actual de Internet esto es claramente imposible (el número de destinos probablemente haya superado ya el millón y crece rápidamente).

ción para obtener la dirección del host destino en la red subyacente. La capa IP utiliza ARP para conseguir la dirección de red del destino y entonces encomienda a la red subyacente la transmisión de los paquetes.

Si la capa IP del emisor descubre que el destino está en una red diferente, debe enviar el mensaje al router local. Utiliza ARP para conseguir la dirección de red de la pasarela o del router y la utiliza para que la red subyacente transmita el paquete. Las pasarelas y routers están conectados a dos o más redes y tienen varias direcciones Internet, una para cada red a la que están conectados.

◊ **Encaminamiento interdominio sin clases (CIDR).** La carencia de direcciones IP a la que nos referímos en la Sección 3.4.1 condujo a la introducción en 1996 de este modo de reserva de direcciones y de gestión de las entradas en las tablas de encaminamiento. El principal problema era la escasez de direcciones de la Clase B, aquéllas para las subredes con más de 255 hosts conectados, mientras que se encontraban disponibles muchas de las direcciones de la Clase C. La solución CIDR (*Classless interdomain routing*) para este problema es reservar un bloque de direcciones C contiguas para aquellas subredes que necesitaban más de 255 direcciones. El esquema CIDR también hacía posible la división del espacio de una dirección de Clase B en múltiples subredes.

El agrupamiento de direcciones de Clase C suena como un paso fácil de realizar, pero a menos que sea acompañado de un cambio en el formato de las tablas de encaminamiento, tendrá un gran impacto en el tamaño de las tablas de encaminamiento y en la eficiencia de los algoritmos que las gestionan. El cambio adoptado fue añadir un campo de *máscara* a las tablas de encaminamiento. La máscara es un patrón de bits utilizado para seleccionar la porción de las direcciones IP que será comparada con las entradas de la tabla de encaminamiento. Esto posibilita que las direcciones host/subred ocupen cualquier parte de la dirección IP, proporcionando más flexibilidad que la aportada por las clases A, B y C. De ahí el nombre de encaminamiento entre dominios *sin clases*. Una vez más, estos cambios en los routers se realizan de modo incremental, por lo que algunos routers utilizarán CIDR y otros utilizarán los viejos algoritmos basados en clases.

Esto funciona porque los nuevos rangos de direcciones de Clase C reservados se asignan módulo 256, de modo que cada rango representa un número íntegro de direcciones de subred de tamaño del de las de Clase C. En el otro extremo, algunas subredes también utilizan CIDR para subdividir el rango de direcciones en una red, de Clase A, B o C. Si la colección de subredes es conectada al resto del mundo únicamente por routers CIDR, entonces el rango de direcciones IP utilizadas dentro de la colección puede ser reservado en subredes individuales en bloques determinados por una máscara binaria de cualquier tamaño.

Por ejemplo, un espacio de direcciones de Clase C puede dividirse en 32 grupos de 8 hosts. La Figura 3.10 contiene un ejemplo de la utilización de CIDR para partir la subred 138.37.95 del tamaño de las de la Clase C en varios grupos de ocho direcciones de hosts que son encaminados de forma diferente. Los grupos separados se expresan mediante la notación 138.37.95.232/29, 138.37.95.248/29, etc. La porción /29 de esas direcciones indica que la máscara de 32 bits asociada tiene 29 unos y 3 ceros al final.

3.4.4. IP VERSIÓN 6

También se buscó una solución más duradera a las limitaciones de direccionamiento de IPv4, lo que condujo al desarrollo y la adopción de una nueva versión del protocolo IP con un espacio de direccionamiento mayor. La IETF se dio cuenta en los primeros años noventa de los problemas que se podrían plantear con las direcciones de 32 bits, e inició un proyecto para el desarrollo de una nueva versión del protocolo IP. En 1994 el IETF adoptó IPv6 y recomendó una estrategia de migración hacia él.

La Figura 3.18 muestra el esquema de las cabeceras IPv6. No nos proponemos cubrir los detalles de su construcción. Aquellos lectores que estén interesados en ellos pueden consultar el

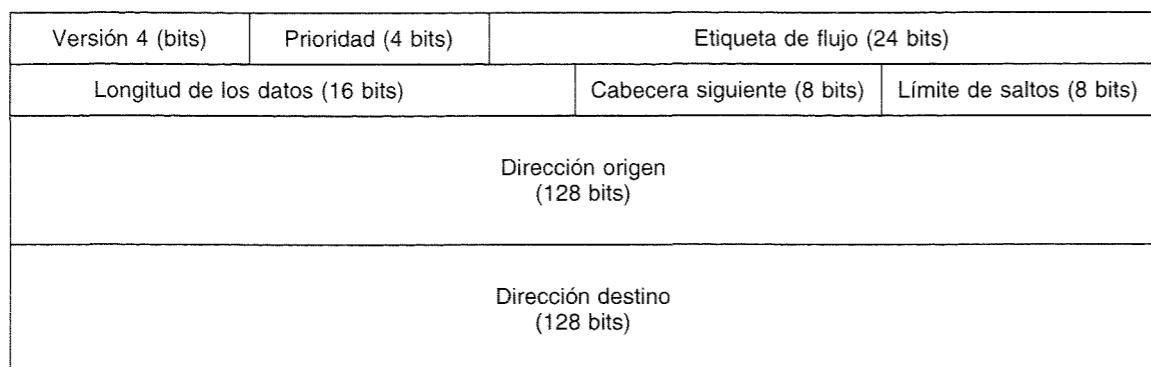


Figura 3.18. Esquema de la cabecera IPv6.

material introductorio de Tanenbaum [1996] o Stallings [1998a], y a Huitema [1998] en el caso de buscar la narración del proceso de diseño de IPv6 y los planes de implantación. Nosotros mostraremos aquí los principales avances implicados por la utilización de IPv6.

Espacio de direccionamiento: las direcciones IPv6 son de 128 bits (16 bytes). Esto proporciona un número realmente astronómico de entidades direccionables: 2^{128} , o aproximadamente 3×10^{38} . Tanenbaum calcula que esto es suficiente para asignar 7×10^{23} direcciones IP por metro cuadrado en toda la superficie de la tierra. De manera más moderada, Huitema calcula que, suponiendo que las direcciones IP sean asignadas de manera tan ineficiente como los números de teléfono, a cada metro cuadrado de la superficie de la Tierra (ya sea tierra o mar) le tocan 1.000 direcciones IP.

El espacio de direccionamiento IPv6 está particionado. No podemos detallar aquí el modo en que se realizan las particiones, pero incluso una de las más pequeñas (una de las cuales podría albergar todo el espacio IPv4, haciendo una correspondencia una a una) es más grande que el espacio total de IPv4. Muchas de las particiones (representando el 72 % del total) están reservadas para funciones todavía no definidas. Dos de las mayores particiones (cada una abarcando 1/8 del espacio de direccionamiento) se reservan para propósitos generales y serán asignadas a nodos normales. Una de ellas está pensada para estar organizada de acuerdo con las localizaciones geográficas de los nodos, y la otra según los detalles organizativos. Esto permite dos estrategias alternativas al agrupamiento de las direcciones para propósitos de encaminamiento (queda por ver cuál será más eficiente o más popular).

Velocidad de encaminamiento: se ha reducido la complejidad de la cabecera básica IPv6 y por lo tanto del procesamiento requerido en cada nodo. No se aplican sumas de comprobación de errores al contenido del paquete (supone carga), y los paquetes no se pueden fragmentar una vez que han comenzado su viaje. Lo primero se considera aceptable ya que los errores se pueden detectar en los niveles más altos (TCP incluye una comprobación de errores de la carga), y lo último se consigue basándose en un mecanismo para determinar la MTU mínima antes de enviar los paquetes.

Tiempo real y otros servicios especiales: los campos de *prioridad* y de *etiqueta de flujo* están relacionados con estos temas. Los flujos multimedia y otras secuencias de datos de tiempo real pueden transmitirse como parte de un flujo identificado. El campo prioridad se puede utilizar junto con el campo de etiqueta de flujo, o de manera independiente, para especificar que ciertos paquetes específicos tienen que ser gestionados más rápidamente o con mayor fiabilidad que otros. Los valores de prioridad en el rango 0 a 8 son para aquellas transmisiones que pueden ser ralentizadas sin producir efectos desastrosos en la aplicación que soportan. Los valores

del 8 al 15 se reservan para aquellos paquetes cuya entrega depende del tiempo. Estos paquetes deben ser entregados rápidamente o deben ser desecharados, ya que la entrega fuera de tiempo no sirve.

Las etiquetas de flujo sirven para reservar recursos que permitan cumplir con los requisitos de sincronización de los flujos de datos de tiempo real, tales como transmisiones de audio o vídeo en directo. El Capítulo 15 trata estos requisitos y los métodos para la reserva de los recursos para ellos. Por supuesto, los routers y los enlaces de transmisión en Internet tienen unos recursos limitados y el concepto de reserva de éstos para ciertos usuarios y aplicaciones no había sido previamente considerado. El uso de estas posibilidades de IPv6 dependerá del desarrollo de métodos adecuados para la realización y la gestión de las reservas de los recursos.

Evolución futura: la clave para el desarrollo de una futura evolución es el campo de *cabecera siguiente*. Si es distinto de cero, define el tipo de una extensión de la cabecera que está incluida en el paquete. Existen actualmente distintos tipos de extensiones de cabecera que proporcionan datos adicionales para servicios especiales como son los siguientes: información para routers, definición de la ruta, gestión de fragmentos, autenticación, información de la encriptación e información para la gestión en destino. Cada tipo de extensión de cabecera tiene un tamaño específico y un formato definido. Se irán definiendo nuevas extensiones de cabecera según se vayan presentando nuevas necesidades. Si existe alguna extensión de cabecera, sigue a la cabecera básica y precede la carga, e incluye su propio campo de cabecera siguiente, haciendo posible el encadenamiento de múltiples extensiones de cabecera.

Multidifusión (multicast) y monodifusión (anycast): tanto IPv4 como IPv6 soportan la transmisión de paquetes IP a múltiples destinos utilizando para ello una única dirección destino (una del rango reservado para este propósito). Los routers IP son los responsables de encaminar los paquetes a todos los hosts que se han suscrito al grupo identificado por la dirección relevante. Se pueden encontrar más detalles sobre la multidifusión IP en la Sección 4.5.1. Además de esto, IPv6 aporta un nuevo modo de transmisión denominado monodifusión, *anycast*. Este servicio entrega un paquete a al menos uno de los hosts suscritos a la dirección indicada.

Seguridad: hasta ahora, las aplicaciones Internet que precisan autenticación o una transmisión de datos privada tenían que conseguirla mediante el uso de técnicas de criptografía en la capa de aplicación. Según el punto de vista del argumento extremo a extremo este es el lugar adecuado para ello. Si la seguridad es implementada en el nivel IP entonces los usuarios y los desarrolladores dependen de la corrección del código que está implementado en cada uno de los routers a lo largo del camino, y deben confiar en los routers y en los otros nodos intermedios para gestionar las claves criptográficas.

La ventaja de implementar la seguridad en el nivel IP es que entonces puede ser utilizada sin necesidad de implementaciones conscientes de la seguridad en los programas de aplicación. Por ejemplo, los administradores de sistemas pueden implementar un cortafuegos y aplicar la seguridad a todas las comunicaciones externas sin tener que asumir el costo de encriptación en las comunicaciones internas. Los routers también pueden utilizar los mecanismos de seguridad en el nivel IP para autenticar los mensajes de actualización de las tablas de encaminamiento que intercambian entre ellos.

La seguridad en IPv6 se implementa en las cabeceras de extensión de *autenticación* y de *encriptación de la carga*. Éstas implementan características similares al concepto de canal seguro presentado en la Sección 2.3.3. La carga se encripta y/o firma digitalmente si fuera necesario. En IPv4 también se dispone de posibilidades similares utilizando un túnel IP entre routers o hosts que implementen la especificación IPSec (véase el RFC 2411 [Thayer 1998]).

◊ **Migración desde IPv4.** Las consecuencias de un cambio en su protocolo básico son profundos para la infraestructura existente de Internet. IP se procesa en la pila de protocolos TCP/IP en

todos los hosts y en el software de todos los routers. Las direcciones IP son manejadas por muchas aplicaciones y programas de utilidad. Todos estos elementos necesitan actualizarse para soportar la nueva versión de IP. Pero el cambio se hace inevitable dado el venidero agotamiento del espacio de direcciones IPv4, y el grupo de trabajo del IETF responsable del IPv6 ha definido una estrategia de migración, que esencialmente consiste en la obtención de *islas* de routers y hosts IPv6 comunicados mediante túneles, que progresivamente se irán juntando en islas mayores. Como ya hemos dicho, los routers y hosts IPv6 no deberían tener dificultad en gestionar un tráfico mixto, ya que las direcciones IPv4 están incluidas en el espacio IPv6.

La teoría de esta estrategia puede ser técnicamente sólida, pero el avance de su implementación está siendo muy lento, quizás porque las razones económicas están en contra suya. Nosotros tenemos que confiar en que la comunidad de Internet llegará a estar suficientemente motivada por la inminente restricción en el crecimiento de Internet, como para realizar las inversiones necesarias para actualizar los protocolos software de routers y hosts, modificar las aplicaciones y cualquier otra consecuencia de la migración.

3.4.5. IP MÓVIL

Los computadores móviles, tales como portátiles y computadores de mano, se conectan a Internet en diferentes localizaciones según se mueven. En la oficina un portátil puede conectarse a una red Ethernet local, llegando a Internet a través de un router, o quizás puede estar conectado a Internet en cualquier otro sitio vía un teléfono móvil mientras está en un coche o en el tren. El usuario deseará disponer de acceso a servicios como el correo electrónico y el Web en cualquiera de esas situaciones.

El simple acceso a servicios no hace imprescindible que un computador móvil retenga una única dirección, y puede adquirir una nueva dirección IP en cada lugar; éste es el propósito del Protocolo de Configuración Dinámica de Host (*Dynamic Host Configuration Protocol*, DHCP), el cual hace posible que un computador recién conectado adquiera del servidor DHCP una dirección IP temporal y las direcciones de los recursos locales tales como un servidor de nombres de dominio, DNS. También necesitará descubrir qué servicios locales (tales como impresión, entrega de correo, etc.) están disponibles en el sitio que visita. Los servicios de exploración son un tipo de servicios de nombres que asisten a este proceso de descubrimiento; y se describen en el Capítulo 9.

En el portátil existen muchos archivos y demás recursos a los cuales pueden necesitar acceder otros, o el portátil pudiera estar ejecutando una aplicación distribuida como un servicio de monitoreo compartido que recibe notificaciones de eventos concretos tales como que los recursos que un usuario reserva sobrepasa un umbral predeterminado. Si un computador móvil debe permanecer accesible a los clientes y aplicaciones de recursos compartidos, cuando se mueve entre redes locales y redes inalámbricas, debe conservar una dirección IP única, pero el encaminamiento IP está basado en las subredes. Las subredes son ubicaciones físicas, y el encaminamiento correcto de paquetes hacia ellas depende de su localización en la red.

Una solución al problema anterior es el IP móvil. La solución se implementa de forma transparente, de modo que la comunicación IP continúa normalmente cuando un computador se mueve entre subredes en localizaciones diferentes. Se basa en la reserva permanente de una dirección IP normal para cada host móvil en una subred en su dominio *casa*.

Cuando el host móvil está conectado a su base, los paquetes se encaminan hacia él de modo habitual. Cuando está conectado a Internet en cualquier otro sitio, dos procesos agentes toman la responsabilidad de reencaminar. Estos agentes son el agente de casa (*home agent*, HA) y el agente foráneo (*foreign agent*, FA). Estos procesos discurren sobre computadores en el sitio base y en la ubicación actual del host móvil.

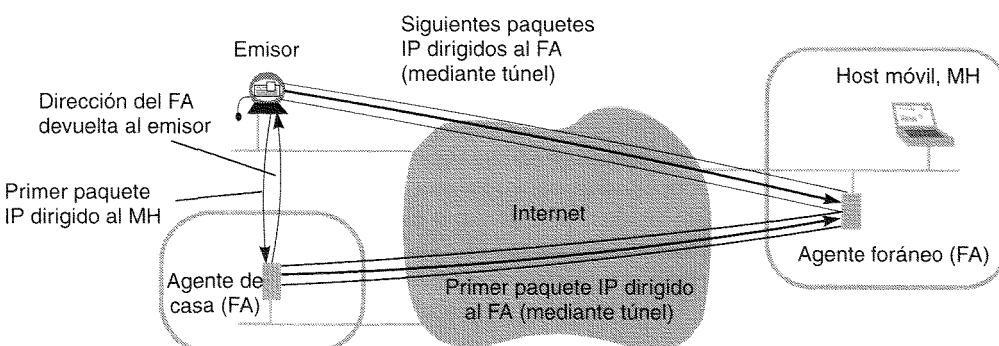


Figura 3.19. Mecanismo de encaminamiento de IP móvil.

El HA es el responsable de almacenar el conocimiento actualizado de la localización del host móvil (la dirección IP en la que se le puede encontrar). Esto se realiza con la colaboración del host móvil mismo. Cuando un host móvil deja su casa, debe informar al HA y el HA se da cuenta de la ausencia del host móvil. Durante la ausencia se comportará como un *proxy*; y para poder hacerlo, les dice a los routers locales que borren cualquier registro que guardaran sobre la dirección IP del host móvil. Mientras el HA actúa como proxy, responderá a las solicitudes ARP referidas a la dirección IP del host móvil con su propia dirección de red como si fuera la dirección de red del host móvil.

Cuando el host móvil llega a un nuevo sitio, informa al FA de ese sitio. El FA le asigna una dirección IP provisional, una dirección IP nueva temporal en la subred local. Entonces el FA contacta con el HA proporcionándole la dirección IP base del host móvil y la dirección que se ha reservado para él.

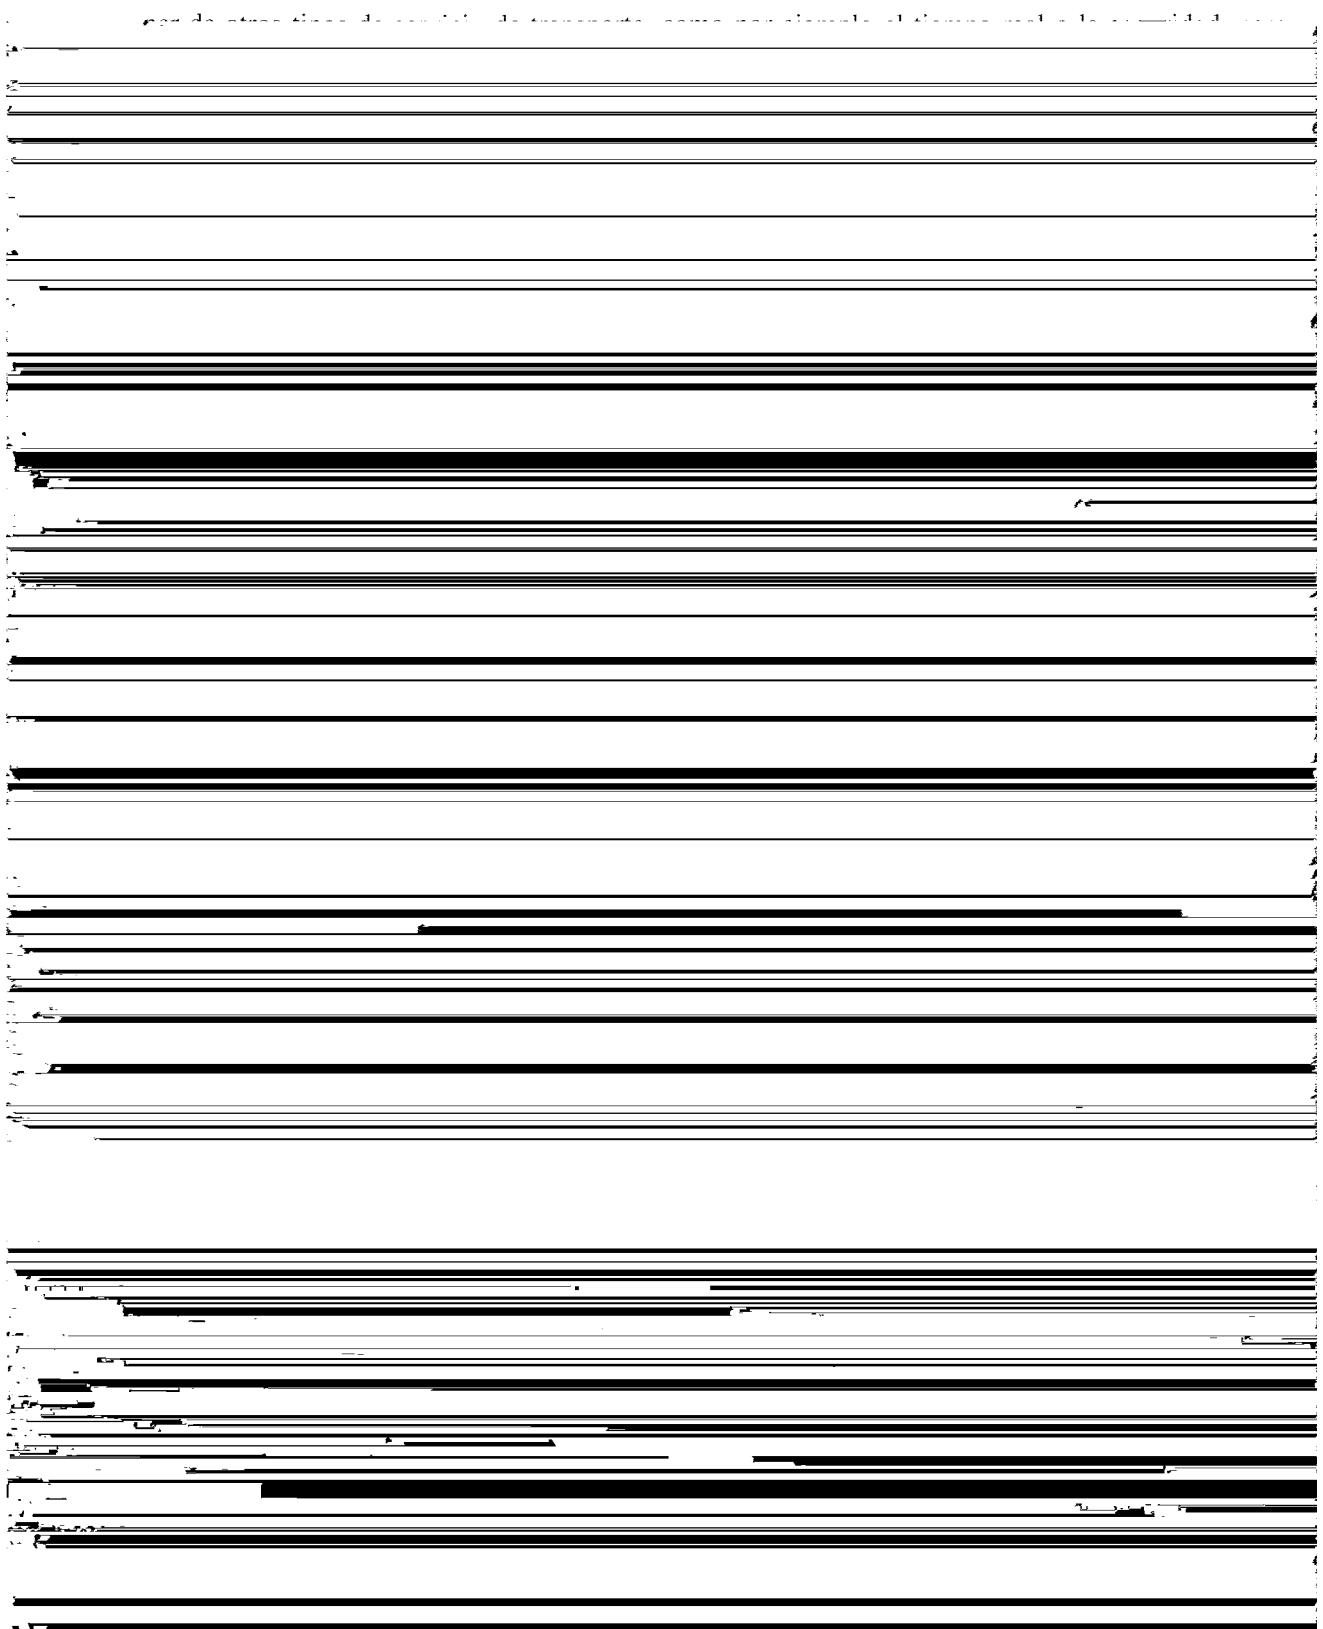
La Figura 3.19 muestra el mecanismo de encaminamiento de IP móvil. Cuando un paquete IP dirigido a la dirección base del host móvil es recibido en la red local base, es encaminado al HA. El HA encapsula el paquete IP en un paquete IP móvil y lo envía al FA. El FA desempaca el paquete IP original y se lo entrega al host móvil a través de la red local a la que está conectado. El método por el que tanto el HA como el FA reencaminan el paquete original hacia el destino apropiado es un ejemplo de la técnica del túnel descrita en la Sección 3.3.7.

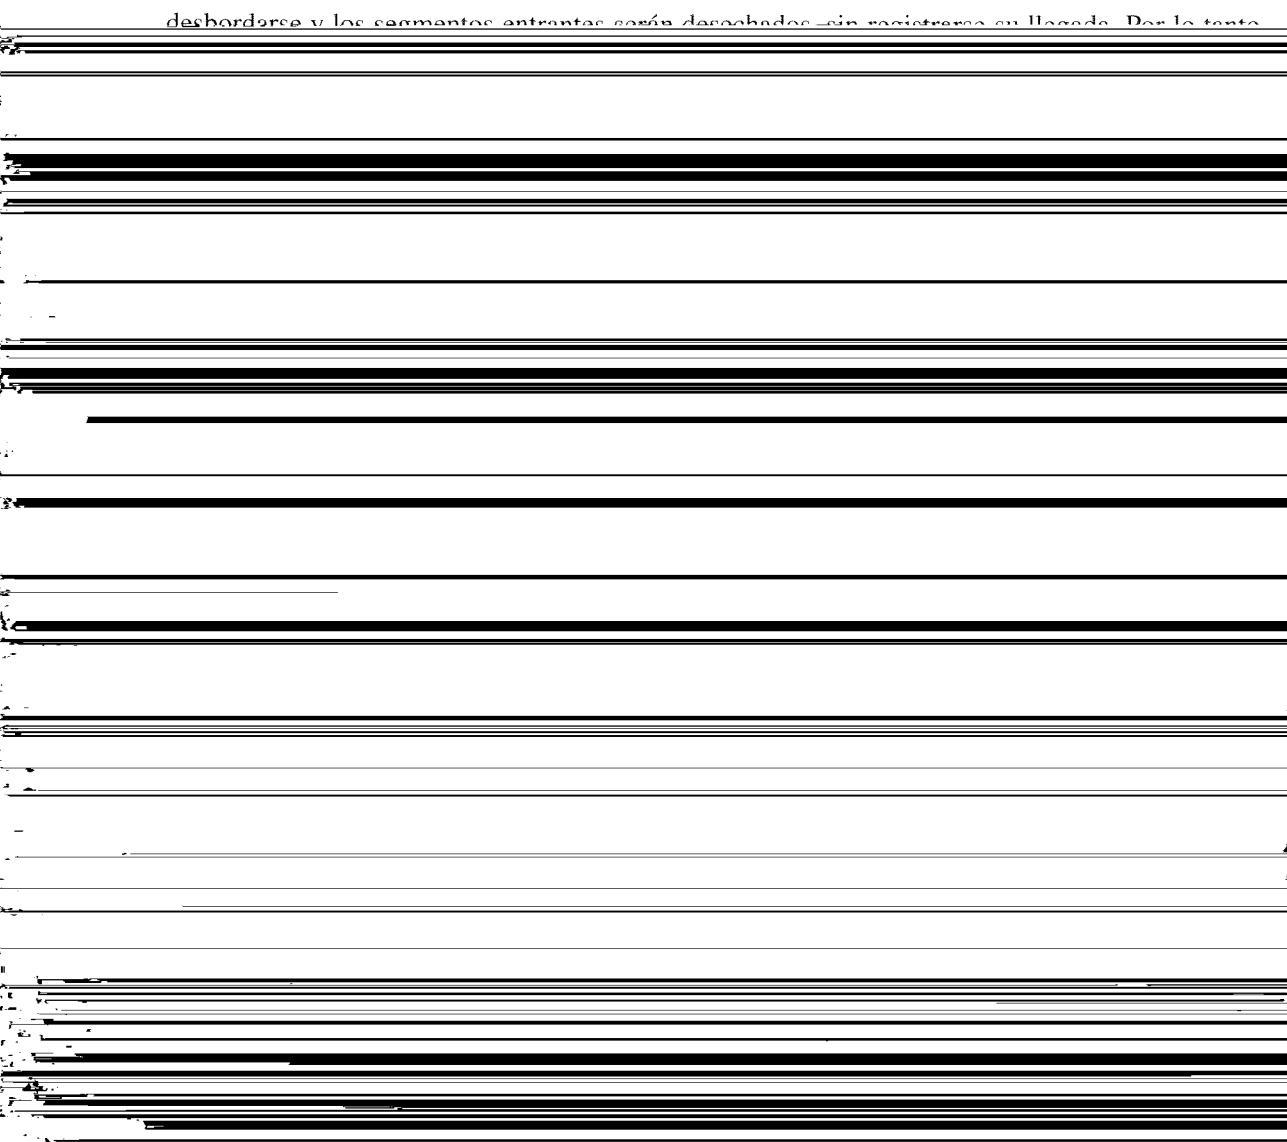
El HA también envía la dirección provisional del host móvil al emisor original. Si el emisor es capaz de gestionar IP móvil, tomará en cuenta esa dirección y la utilizará para las subsecuentes comunicaciones con el host móvil, evitando las sobrecargas de reencaminar vía el HA. Si no es así, entonces ignorará el cambio de dirección y las siguientes comunicaciones continuarán siendo reencaminadas a través del HA.

La solución IP móvil es efectiva, pero escasamente eficiente. Sería preferible una solución que tratara a los hosts móviles como ciudadanos de primera clase, permitiéndoles vagar sin avisar antes y encaminándoles los paquetes sin utilizar túneles o reencaminamiento. Hay que darse cuenta que esta aparentemente difícil hazaña es exactamente lo que está resuelto en las redes de telefonía celular, donde los teléfonos móviles no cambian sus números según van moviéndose entre células o incluso entre países. En lugar de eso, simplemente notifican a la estación base de la célula local su presencia cada cierto tiempo.

3.4.6. TCP Y UDP

Tanto TCP como UDP aportan unas características de comunicación a Internet que la convierten en útil para los programas de aplicación. Los desarrolladores de aplicaciones quizás deseen dispo-





desbordarse y los segmentos entrantes serán desechados, sin registrarse su llegada. Por lo tanto, su llegada no será reconocida y el emisor se verá obligado a retransmitirlos de nuevo.

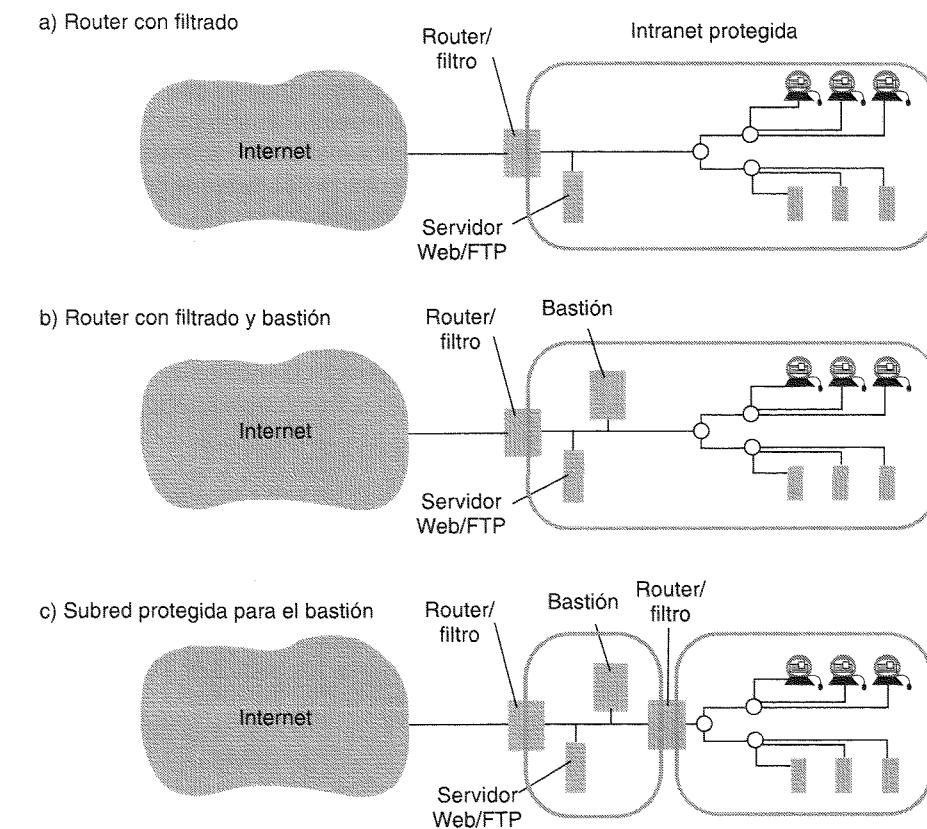


Figura 3.20. Configuraciones de cortafuegos.

El propósito de un cortafuegos es supervisar y controlar todas las comunicaciones entrantes y salientes de una intranet. Un cortafuegos consta de un conjunto de procesos que actúan como una pasarela hacia la intranet (Figura 3.20(a)), aplicando una política de seguridad determinada por la organización.

Los objetivos de la política de seguridad de un cortafuegos incluyen todos o algunos de los enumerados a continuación:

Control de servicios: para determinar qué servicios en los hosts internos son accesibles desde el exterior y para rechazar cualquier otra petición de servicio. También se controlan las peticiones de servicios al exterior y sus respuestas. Estas acciones de filtrado pueden basarse en el contenido de los paquetes IP y en las peticiones TCP y UDP que contienen. Por ejemplo, las peticiones HTTP pueden rechazarse a menos que sean dirigidas al host que alberga el servidor web oficial.

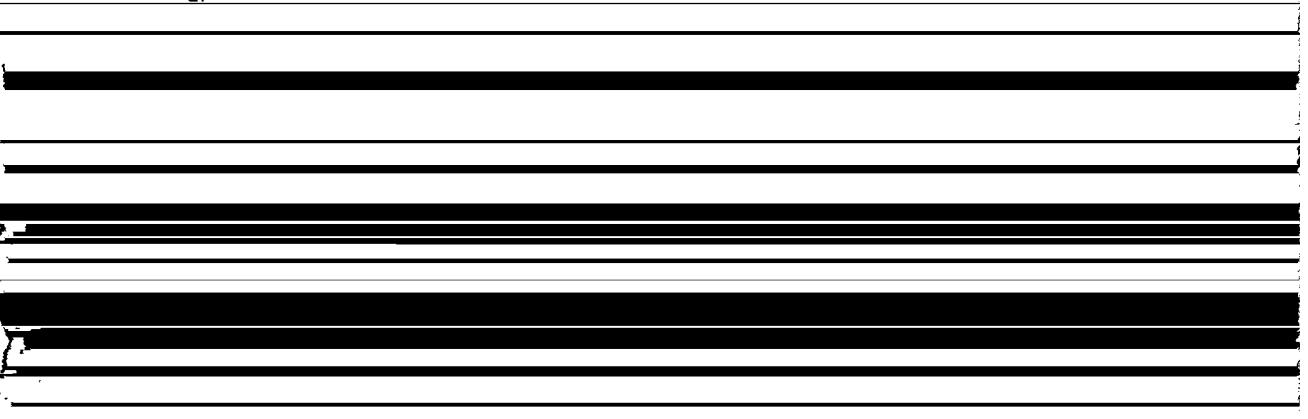
Control del comportamiento: para prevenir comportamientos que infrinjan las políticas de la organización, sean antisociales o no tengan un propósito legítimo y, por lo tanto, sean sospechosos de formar parte de un ataque. Algunas de estas acciones de filtrado pueden ser aplicadas a nivel IP o a nivel TCP, pero otras pueden requerir la interpretación de mensajes al más alto nivel. Por ejemplo, filtrar un ataque de *spam* en el correo electrónico puede necesitar examinar la dirección del remitente en la cabecera del mensaje o incluso el contenido del mismo.

Control de usuarios: la organización puede querer distinguir entre sus usuarios permitiéndoles



1 02 Sistemas distribuidos

Control de usuarios: la organización puede querer distinguir entre sus usuarios permitiéndoles



instalar software excepto a aquellos que son miembros del equipo de administradores de sistemas, para prevenir infecciones de virus o para mantener estándares de software. Este ejemplo

jores prestaciones y cierta tolerancia a fallos. En todas las configuraciones descritas a continuación e ilustradas en la Figura 3.20 tratamos el caso de un servidor Web/FTP sin protección. Éste solamente alberga información pública que no necesita protección frente al acceso público, y su software de servidor asegura que sólo los usuarios internos autorizados puedan actualizarla.

El filtrado de paquetes IP se realiza normalmente por un router (un computador con al menos dos direcciones de red en redes IP distintas). Éste ejecuta un proceso RIP, un proceso de filtrado de paquetes IP junto con el menor número de procesos más que sea posible. El router/filtro debe ejecutar solamente software fiable de modo que se garantice la aplicación de las políticas de filtrado. Esto implica asegurarse de que ningún proceso del tipo caballo troyano se ejecute en él y que el software de filtrado y encaminamiento no ha sido modificado o falsificado. La Figura 3.20(a) muestra una configuración de cortafuegos simple que confía exclusivamente en el filtrado IP y emplea un único router para ello. La configuración de la red de la Figura 3.20 incluye dos router/filtros que actúan como cortafuegos de este tipo. En esta configuración, existen dos router/filtros por razones de prestaciones y fiabilidad. Ambos obedecen a la misma política y el segundo no incrementa la seguridad del sistema.

Cuando se necesitan pasarelas TCP y del nivel de aplicación, normalmente se ejecutan en un computador separado, conocido como *bastión* (el término es originario de la construcción de castillos fortificados; corresponde a una torre de vigilancia sobresaliente desde la cual el castillo podía ser defendido o desde la cual los defensores podían negociar con aquellos que deseaban entrar). Un computador bastión es un host que está colocado dentro de la intranet protegida por un router/filtro IP y ejecuta las pasarelas TCP y del nivel de aplicación (Figura 3.20(b)). Como el router/filtro, el bastión debe ejecutar exclusivamente software fiable. En una intranet bien protegida se deben usar proxies para acceder a todos los servicios externos. Los lectores estarán familiarizados con la utilización de proxies en los accesos web. Éstos son un ejemplo del uso de proxies de cortafuegos; a menudo están construidos de modo que integran un servidor de caché web (descrito en el Capítulo 2). Éstos y otros proxies requieren bastantes recursos tanto de procesamiento como de almacenamiento.

La seguridad puede mejorarse empleando dos router/filtros en serie, con el bastión y los servidores públicos colocados en una subred separada que enlaza los dos router/filtros (Figura 3.20(c)). Esta configuración tiene varias ventajas respecto a la seguridad:

- Si la política del bastión es estricta, las direcciones IP de los hosts en la intranet no tienen por qué conocerse desde el mundo exterior, y las direcciones exteriores tampoco necesitan ser conocidas por los nodos interiores, ya que todas las comunicaciones externas pasan a través de los proxies del bastión, que tiene acceso a ambas.
- Si el primer router/filtro IP es atacado o comprometido, el segundo, que es invisible desde fuera de la intranet y, por lo tanto, menos vulnerable, sigue extrayendo y rechazando los paquetes IP indeseables.

◊ **Redes privadas virtuales.** La redes privadas virtuales (*virtual private network*, VPN) extienden el límite de protección del cortafuegos más allá de la intranet local utilizando canales seguros protegidos criptográficamente en el nivel IP. En la Sección 3.4.4, presentamos brevemente las extensiones de seguridad IP disponibles para IPv4 e IPv6 con el túnel IPsec [Thayer 1998]. Éstas son las bases de la implementación de VPN. Pueden utilizarse para usuarios externos individuales o para implementar conexiones seguras entre intranets localizadas en diferentes lugares utilizando enlaces Internet públicos.

Por ejemplo, un miembro de la plantilla de una organización puede necesitar conectarse a la intranet de la organización a través de un proveedor de acceso a Internet. Una vez conectado, debería disponer de las mismas posibilidades que cualquier usuario al otro lado del cortafuegos. Esto se puede conseguir si el host local implementa seguridad IP. El host local almacena una o más claves

criptográficas que comparte con el cortafuegos, y que son utilizadas para establecer un canal seguro en el momento de la conexión. Los mecanismos de canal seguro se describen con detalle en el Capítulo 7.

3.5. CASOS DE ESTUDIO: ETHERNET, LAN INALÁMBRICA Y ATM

Hasta aquí hemos discutido los principios involucrados en la construcción de las redes de computadores y hemos descrito IP, la *capa de red virtual* de Internet. Para completar este capítulo, en esta sección describiremos los fundamentos y las implementaciones de tres redes actuales.

En los primeros años ochenta, el instituto norteamericano de ingenieros eléctricos y electrónicos (*US Institute of Electrical and Electronics Engineers*, IEEE) creó un comité para especificar una serie de estándares de red local (el comité 802 [IEEE 1990]), y sus subcomités han producido una serie de especificaciones que se han convertido en la clave de los estándares de LAN. En la mayoría de los casos, los estándares se basan en estándares industriales previos que habían surgido de las investigaciones realizadas en los años setenta. En la Figura 3.21 se muestran los subcomités relevantes y los estándares que han publicado hasta la fecha.

Ellos difieren en prestaciones, eficiencia, fiabilidad y costo, pero todos proporcionan un ancho de banda relativamente grande sobre distancias cortas y medias. El estándar IEEE 802.3 Ethernet ha ganado de largo la batalla en el mercado de LAN cableadas, y lo describimos en la Sección 3.5.1 como representante de las tecnologías de redes LAN cableadas. Aunque existen implementaciones de Ethernet para varios anchos de banda, el principio de operación es idéntico en todas ellas.

El estándar IEEE 802.5 de Anillo con Paso de Testigo (*Token Ring*) resultó un competidor significativo en gran parte de los años noventa, ofreciendo ventajas sobre Ethernet en eficiencia y en garantías de ancho de banda, pero ahora ha desaparecido del mercado. Los lectores interesados en una breve descripción de esta interesante tecnología de red LAN pueden encontrar una en www.cdk3.net/networking.

El estándar IEEE 802.4 de Bus con Paso de Testigo (*Token Bus*) fue desarrollado para entornos industriales con requisitos de tiempo real y todavía se emplea en esos entornos. El estándar IEEE 802.6 de Área Metropolitana cubre distancias de hasta 50 kilómetros y está pensado para usarse en redes que abarquen ciudades pequeñas y grandes. Descripciones más detalladas y comparaciones de los cuatro estándares IEEE 802.3-802.6 se pueden encontrar en Tanenbaum [1996].

El estándar IEEE 802.11 de LAN Inalámbrica surgió algo tarde pero ahora ocupa una posición significativa en el mercado con productos de Lucent (WaveLAN) y otros vendedores, y se va a convertir en más importante de todos con el advenimiento de los dispositivos de cómputo ubicuos y móviles. El estándar IEEE 802.11 está diseñado para soportar comunicaciones a velocidades de hasta 11 Mbps sobre distancias de hasta 150 metros entre dispositivos equipados con transmisores/receptores inalámbricos simples. Describimos sus principios de funcionamiento en la Sección 3.5.2. Se pueden encontrar más detalles sobre las redes IEEE 802.11 en Crow y otros [1997] y Kurose y Ross [2000].

Núm. IEEE	Nombre	Referencia
802.3	Redes CSMA/CD (Ethernet)	[IEEE 1985a]
802.4	Redes de Bus con Testigo	[IEEE 1985b]
802.5	Redes de Anillo con Testigo	[IEEE 1985c]
802.6	Redes de Área Metropolitana	[IEEE 1994]
802.11	Redes de Área Local Inalámbricas	[IEEE 1999]

Figura 3.21. Estándares de red IEEE 802.

La tecnología ATM surgió de un gran esfuerzo de estandarización de industrias de telecomunicaciones e informática en el final de los años ochenta y principio de los años noventa [CCITT 1990]. Su propósito es proporcionar una tecnología digital de redes de área amplia con un gran ancho de banda adecuada para aplicaciones de telefonía, datos y multimedia (audio y vídeo de alta calidad). Aunque el despegue ha sido más lento de lo esperado, ATM es ahora la tecnología para las redes de área amplia de muy alta velocidad. También se piensa que puede ser un sustituto de Ethernet en aplicaciones de LAN, pero su éxito en ese mercado ha sido menor debido a la dura competencia con las Ethernet de 100 Mbps y 1.000 Mbps, disponibles a menor costo. Describimos los principios de funcionamiento de ATM en la Sección 3.5.3. En Tanenbaum [1996] y en Stallings [1998a] se pueden encontrar más detalles sobre ATM y sobre otras redes de alta velocidad.

3.5.1. ETHERNET

Ethernet fue desarrollada por el centro de investigación Palo Alto de Xerox en 1973 [Metcalfe y Boggs 1976; Shoch y otros 1982; 1985] como parte del programa de investigación llevado a cabo sobre estaciones de trabajo personales y sistemas distribuidos. La red Ethernet piloto fue la primera red de área local de alta velocidad, demostrando la factibilidad y utilidad de las redes locales de alta velocidad para enlazar computadoras en un mismo lugar, permitiéndoles comunicarse a altas velocidades de transmisión con bajas tasas de error y sin retardos de conmutación. El prototipo original Ethernet funcionaba a 3 Mbps. Los sistemas Ethernet están disponibles ahora con anchos de banda en el rango 10 Mbps a 1.000 Mbps. Muchas redes propietarias han sido implementadas utilizando el mismo método básico de operación con características de coste/prestaciones adecuadas para una variedad de aplicaciones. En su forma más barata, los mismos principios de funcionamiento se utilizan para conectar microcomputadores de bajo coste con velocidades de transmisión de 100 a 200 kbps.

Describiremos los principios de funcionamiento de Ethernet 10 Mbps especificados en el estándar IEEE 802.3 [IEEE 1985a]. Ésta fue la primera tecnología de red de área local ampliamente extendida, y probablemente hoy, todavía la tecnología predominante, aunque la variante de 100 Mbps sea ahora la elegida más habitualmente para las instalaciones nuevas. Daremos un repaso a las variaciones en la tecnología de transmisión y en el ancho de banda para redes Ethernet disponibles en la actualidad. Para una descripción comprensible de Ethernet en todas sus variantes, véase Spurgeon [2000].

Una red Ethernet es una línea de conexión en bus simple o ramificado que utiliza un medio de transmisión consistente en uno o más segmentos contiguos de cable enlazados por concentradores o repetidores. Los concentradores y los repetidores son dispositivos sencillos que enlazan trozos de cable, posibilitando que las señales pasen a través suyo. Se pueden enlazar varias Ethernet en el nivel de protocolo de red Ethernet por conmutadores o puentes Ethernet. Los conmutadores y los puentes funcionan al mismo nivel que los marcos Ethernet, encaminándolos a las redes Ethernet adyacentes cuando su destino está allí. Las redes Ethernet enlazadas aparecen como una única red para los protocolos de las capas superiores, tales como IP (véase la Figura 3.10, donde las subredes IP 138.37.88 y 138.37.94 se componen cada una de varias redes Ethernet enlazadas por elementos marcados como *Eswitch*). En concreto, el protocolo ARP (Sección 3.4.2) es capaz de hacer corresponder direcciones IP con direcciones Ethernet sobre un conjunto de redes Ethernet enlazadas; cada solicitud ARP se difunde a todas las redes enlazadas dentro de la subred.

Los modos de funcionamiento de las redes Ethernet son definidos por la frase *acceso múltiple sensible a la portadora, con detección de colisiones* (*carrier sensing, multiple access with collision detection, CSMA/CD*) y pertenecen a la clase de redes de contienda en bus. Los métodos de contienda utilizan un medio de transmisión único para enlazar todos los hosts. El protocolo que gestiona el acceso al medio se llama protocolo de control de acceso al medio (*medium access con-*

possible que toda interfaz hardware Ethernet reciba una dirección única de su fabricante, asegurándose que todas las estaciones en cualquier conjunto de Ethernet interconectadas tengan una dirección única. El IEEE actúa como autoridad de reserva para las direcciones Ethernet, reservando rangos de 48 bits a los fabricantes de interfaces hardware.

El campo de datos contiene el mensaje que está siendo transmitido o parte de él (si la longitud del mismo excede de los 1.500 bytes). El límite inferior de 46 bytes en el campo de datos asegura una longitud de paquete mínima de 64 bytes, la cual es necesaria para garantizar que las colisiones serán detectadas en todas las estaciones de la red, según se explica a continuación.

La secuencia de comprobación del marco es una suma de comprobación que genera e inserta el emisor y que sirve para validar los paquetes en el receptor. Los paquetes que producen sumas de comprobación incorrectas son simplemente desechados por la capa de enlace de datos en la estación receptora. Esto es otro ejemplo del argumento de extremo a extremo: para garantizar la transmisión de un mensaje, se debe utilizar un protocolo de la capa de transporte como TCP, con recepción de reconocimientos de cada paquete y retransmisión de cualquier paquete no reconocido. La incidencia de la corrupción de los datos en las redes locales es tan pequeña que el uso de este método de recuperación cuando se requiere garantía en la entrega es enteramente satisfactorio y hace posible que se pueda utilizar un protocolo de transporte menos costoso como UDP cuando no se necesite garantizar la entrega.

◊ **Colisiones de paquetes.** Incluso durante el relativamente corto período de tiempo que lleva la transmisión de un paquete, existe una probabilidad finita de que dos estaciones en la red estén intentando transmitir mensajes de forma simultánea. Si una estación intenta transmitir un paquete sin comprobar que el medio está siendo utilizado por otra estación, puede ocurrir una colisión.

Ethernet tiene tres mecanismos para tratar esta posibilidad. El primero es llamando detección de portadora; la interfaz hardware en cada estación escucha buscando la presencia de una señal en el medio (conocida como portadora por analogía con la difusión de señales de radio). Cuando una estación desea transmitir un paquete, espera hasta que no se detecte señal alguna en el medio y entonces comienza a transmitir.

Desgraciadamente, la detección de la portadora no previene todas las colisiones. Queda la posibilidad de que se produzca una colisión debido al tiempo finito τ que tarda una señal insertada en el medio de transmisión en un punto, en alcanzar todos los demás puntos (la velocidad de transmisión electrónica es aproximadamente 2×10^8 metros por segundo). Considere dos estaciones A y B que están listas para transmitir paquetes casi al mismo tiempo. Si A comienza a transmitir primero, B puede escuchar y no encontrar ninguna señal en el medio en cualquier instante de tiempo $t < \tau$ después de que A haya comenzado la transmisión. Por lo tanto, B comienza a transmitir, *interfiriendo* la transmisión de A. Ambos paquetes, el de A y el de B, se destruirán como consecuencia de la interferencia.

La técnica utilizada para reponerse de tales interferencias se llama *detección de colisiones*. Siempre que una estación está transmitiendo un paquete a través de su puerto de salida hardware, también escucha en su puerto de entrada y compara las dos señales. Si difieren, entonces es que se ha producido una colisión. Cuando esto sucede la estación deja de transmitir y produce una *señal de interferencia* para asegurarse de que todas las estaciones reconocen la colisión. Como ya hemos comentado, se necesita una longitud de paquete mínima para asegurarse de que se detectan todas las colisiones. Si dos estaciones transmiten aproximadamente de forma simultánea desde los extremos de la red, no se darán cuenta de que se ha producido una colisión durante 2τ segundos (ya que el primer emisor debe estar transmitiendo aun cuando reciba la segunda señal). Si los paquetes que transmiten tardan menos de τ en ser difundidos, la colisión no será detectada, ya que cada estación emisora no verá el otro paquete hasta que ha terminado de transmitir el propio, mientras que las estaciones en los puntos intermedios recibirán ambos paquetes simultáneamente, produciendo una corrupción de los datos.

Después de la señal de interferencia, todas las estaciones que están transmitiendo y escuchando cancelan la transmisión del paquete actual. Entonces, las estaciones transmisoras tendrán que intentar transmitir otra vez sus paquetes. Y es ahora cuando aparece una nueva dificultad. Si las estaciones involucradas en la colisión intentan retransmitir sus paquetes inmediatamente después de la señal de interferencia, con toda probabilidad se producirá otra colisión. Para evitar esto se utiliza una técnica llamada *marcha atrás (back-off)*. Cada una de las estaciones envueltas en una colisión esperará un tiempo $n\tau$ antes de intentar la retransmisión. El valor de n es un entero aleatorio elegido independientemente por cada estación y limitado por una constante L definida en el software de red. Si a pesar de esto se produce otra colisión, se duplica el valor de L y el proceso se repite si es necesario hasta 10 veces.

Finalmente, la interfaz hardware en la estación receptora calcula la secuencia de comprobación y la compara con la suma de comprobación transmitida en el paquete. Utilizando todas estas técnicas, las estaciones conectadas a Ethernet son capaces de gestionar el uso del medio de transmisión sin ningún control centralizado o sincronización.

◊ **Eficiencia de Ethernet.** La eficiencia de una red Ethernet es la relación entre el número de paquetes transmitidos satisfactoriamente y el número máximo teórico de paquetes que podrían haber sido transmitidos sin colisiones. Se ve afectada por el valor τ ya que el intervalo de 2τ segundos que comienza después del envío de un paquete es la *ventana de oportunidad* para las colisiones (no pueden ocurrir colisiones después de los 2τ segundos tras el comienzo de la transmisión de un paquete). También está afectada por el número de estaciones en la red y su nivel de actividad.

Para un cable de 1 kilómetro el valor de τ es menor que 5 microsegundos y la probabilidad de que se produzcan colisiones es suficientemente pequeña para asegurar una eficiencia alta. Ethernet puede conseguir una utilización del canal de entre el 80 y el 95 %, aunque los retardos debidos a la contienda se hacen notar cuando se supera una utilización del 50 %. Dado que la carga es variable, es imposible garantizar la entrega de un mensaje dado dentro de un tiempo fijo, ya que la red puede estar completamente cargada cuando el mensaje esté listo para ser transmitido. Pero la *probabilidad* de transferir el mensaje con un retardo dado es tan buena, o mejor que con otras tecnologías de red.

Ciertas medidas empíricas de prestaciones de una Ethernet en el PARC Xerox y registradas por Shoch y Hupp [1980] confirman este análisis. En la práctica, la carga en las redes Ethernet utilizadas en los sistemas distribuidos varían mucho. Muchas redes se utilizan principalmente para interacciones asíncronas cliente-servidor, y la mayoría del tiempo éstas trabajan sin estaciones esperando a transmitir y con una utilización del canal cercana a 1. Las redes que soportan un gran volumen de acceso a datos desde un gran número de usuarios muestran una mayor carga, y aquellas que transmiten caudales multimedia tienen tendencia a ser desbordadas en cuanto se transmiten unos pocos caudales concurrentemente.

◊ **Implementaciones físicas.** La descripción anterior define el protocolo de la capa de acceso al medio para todas las redes Ethernet. La amplia adopción de esta tecnología por parte de un gran mercado ha permitido que se pueda disponer de hardware a muy bajo costo que ejecuta los algoritmos necesarios para su implementación, y que se incluya como parte estándar de muchos computadores de sobremesa y de consumo.

Se pueden encontrar un amplio rango de implementaciones físicas sobre la base de Ethernet que ofrecen distintas prestaciones y relaciones calidad/precio explotando las crecientes prestaciones del hardware. Las variaciones se pueden dar en los diferentes medios de transmisión: cable coaxial, par trenzado (similar al utilizado en telefonía) y fibra óptica, con límites diferentes en el rango de transmisión; y en el uso de velocidades de señal cada vez mayores, obteniendo anchos de banda mayores y, generalmente, menores rangos de transmisión. El IEEE ha adoptado varios estándares para las implementaciones de la capa física, y utiliza un esquema de denominación para

distinguir entre ellos. Se utilizan nombres como 10Base5 y 100BaseT. Éstos tienen la siguiente forma:

$<R><L>$ donde:
 R = tasa de datos en Mbps
 B = tipo de medio de transmisión de la señal
(banda base o banda ancha)
 L = longitud máxima del segmento en metros/100 o T
(jerarquía de par trenzado)

Hemos construido una tabla con el ancho de banda y el rango máximo de varias configuraciones estándares y tipos de cable actualmente disponibles.

	10Base5	10BaseT	100BaseT	1.000BaseT
Velocidad de datos	10 Mbps	10 Mbps	100 Mbps	1.000 Mbps
<i>Longitud máx. de los segmentos</i>				
Par trenzado (UTP)	100 m	100 m	100 m	25 m
Cable coaxial (STP)	500 m	500 m	500 m	25 m
Fibra multimodo	2.000 m	2.000 m	500 m	500 m
Fibra monomodo	25.000 m	25.000 m	20.000 m	2.000 m

Las configuraciones que terminan con la designación T están implementadas con cable UTP (par trenzado no apantallado, *Unshielded Twisted Pair*), y están organizadas como una jerarquía de concentradores con computadores en las hojas del árbol. En ese caso, las longitudes de segmento dadas en nuestra tabla son dos veces la distancia máxima permitida desde un computador a un concentrador.

3.5.2. LAN INALÁMBRICA IEEE 802.11

En esta sección resumiremos las características especiales del trabajo con redes sin hilos que se pueden conseguir con la tecnología de red LAN inalámbrica y explicamos cómo las trata el estándar IEEE 802.11. El estándar IEEE 802.11 extiende el principio del acceso múltiple sensible a la portadora (CSMA) utilizado por la tecnología Ethernet (IEEE 802.3) para adecuarse a las características de la comunicación sin hilos. El estándar 802.11 está dirigido a soportar comunicaciones entre computadores separados unos 150 metros entre sí a velocidades de hasta 11 Mbps.

La Figura 3.22 ilustra una porción de una intranet que incluye una LAN inalámbrica. Varios dispositivos móviles inalámbricos se comunican con el resto de la intranet a través de una estación base que es el *punto de acceso* a la red LAN cableada. Una red sin hilos que se conecta al mundo a través de un punto de acceso en una LAN convencional se conoce como una *red de infraestructura*.

Una configuración alternativa para la conexiones de red inalámbricas es conocida como una *red ad hoc (al caso)*. Las redes *ad hoc* no incluyen un punto de acceso o una estación base. Se construyen *al vuelo* como resultado de la detección mutua de dos o más dispositivos móviles con interfaces inalámbricas en las cercanías. Una red *ad hoc* puede darse, por ejemplo, cuando dos o más usuarios de computadores portátiles establecen una conexión con cualquier estación disponible. Ellos podrían compartir archivos lanzando un proceso de servidor de archivos en cualquiera de las máquinas.

Las estaciones en las redes IEEE 802.11 utilizan como medio de transmisión señales de radio (en la banda de los 2,4 GHz) o señales de infrarrojos. La versión radio del estándar ha centrado la

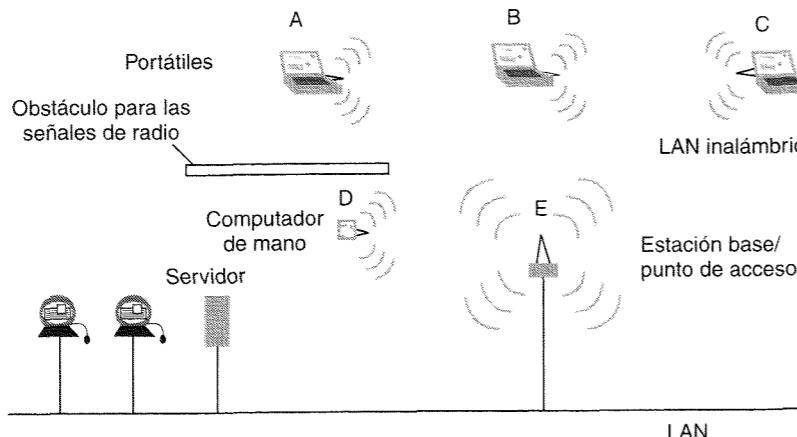


Figura 3.22. Configuración de una LAN inalámbrica.

mayor parte de la atención comercial y será la que describiremos. Utilizan técnicas de selección de frecuencia y de saltos de frecuencia para evitar las interferencias externas y mutuas entre redes LAN inalámbricas independientes, que no detallaremos aquí. Nos centraremos, en cambio, en los cambios que son necesarios realizar al mecanismo CSMA/CD para posibilitar las transmisiones de difusión que serán utilizadas en las transmisiones de radio.

Como Ethernet, el protocolo MAC del 802.11 ofrece iguales oportunidades a todas las estaciones para utilizar el canal de transmisión, y cualquier estación puede transmitir directamente a cualquier otra. Un protocolo MAC controla la utilización del canal por varias estaciones. Como en el caso de Ethernet, la capa MAC también realiza funciones tanto de la capa de enlace de datos como de la capa de red, entregando los paquetes de datos a los hosts en la red.

Cuando utilizamos ondas de radio en lugar de cables como medio de transmisión surgen varios problemas. Estos problemas se derivan del hecho de que los mecanismos de detección de portadora y de colisiones empleados en Ethernet son efectivos sólo cuando la potencia de la señal es aproximadamente la misma a lo largo de toda de la red.

Volvemos a recordar que el propósito de la detección de la portadora es determinar cuándo el medio está libre en todos los puntos entre las estaciones emisoras y receptoras, mientras que la detección de colisiones determina cuándo el medio en los alrededores del receptor está libre de interferencias mientras dura la transmisión. Dado que la potencia de la señal no es uniforme a lo largo del espacio en el que las redes LANs inalámbricas trabajan, la detección de la portadora y de las colisiones pueden fallar de los siguientes modos:

Estaciones ocultas: la detección de la portadora puede fallar en la detección de la transmisión de otra estación. Esto se muestra en la Figura 3.22. Si el computador de mano D está transmitiendo a la estación base E, el portátil A puede que no sea capaz de detectar la señal de D debido a la obstrucción de las señales de radio mostrada. Entonces, A puede comenzar a transmitir, produciendo una colisión en E, a menos que se tomen medidas para prevenirlo.

Atenuación: debido a la ley del inverso del cuadrado de la propagación de las ondas electromagnéticas, la potencia de las señales de radio disminuye rápidamente con la distancia al transmisor. Las estaciones dentro de una LAN inalámbrica pueden encontrarse fuera del alcance de otras estaciones en la misma LAN. Así, en la Figura 3.22, el portátil A puede ser incapaz de detectar una transmisión de C, aunque cada uno de ellos pueda transmitir perfectamente a B o a E. La atenuación imposibilita tanto la detección de la portadora como de las colisiones.

Enmascaramiento de colisiones: desgraciadamente, la técnica de *escuchar* utilizada en Ethernet para detectar las colisiones no es muy efectiva en las redes vía radio. Dada la ley del inverso del cuadrado referida antes, una señal generada localmente será siempre mucho más potente que cualquier señal originada en cualquier otro lugar, y tapará a la transmisión remota. Por eso, si los portátiles A y C transmitieran simultáneamente a E, ninguno de ellos detectaría la colisión, pero E recibiría una transmisión inutilizable.

A pesar de su propensión al fallo, la detección de portadora no se excluye del documento IEEE 802.11; aunque es aumentada por la adición al protocolo MAC del mecanismo de *reserva de ventana*. El esquema resultante se denomina acceso múltiple sensible a la portadora con eliminación de las colisiones (*carrier sensing multiple access with collision avoidance*, CSMA/CA).

Cuando una estación está preparada para transmitir comprueba el medio. Si no detecta ninguna portadora puede suponer que se cumple una de las siguientes condiciones:

1. El medio está disponible.
2. Una estación fuera de alcance está en el proceso de solicitar una ventana.
3. Una estación fuera de alcance está utilizando una ventana que había reservado previamente.

El protocolo de reserva de ventana lleva asociado el intercambio de un par de mensajes cortos (marcos) entre el emisor y el receptor. El primero es un marco de solicitud para enviar (*request to send*, RTS) del emisor al receptor. El mensaje RTS especifica una duración para la ventana solicitada. El receptor responde con un marco libre para enviar (*clear to send*, CTS) repitiendo la duración de la ventana. El efecto de este intercambio es el siguiente:

- Las estaciones dentro del rango del emisor capturarán el marco RTS y tomarán nota de la duración.
- Las estaciones dentro del rango del receptor capturarán el marco CTS y tomarán nota de la duración.

Como resultado, todas las estaciones dentro del rango del emisor y del receptor se abstendrán de transmitir durante la duración de la ventana solicitada, dejando libre el canal para que el emisor transmita un marco de datos de la longitud apropiada. Finalmente, la recepción satisfactoria del marco de datos es reconocida por el receptor para ayudar a tratar el problema de las interferencias externas del canal. Las características aportadas por la reserva de ventana al protocolo MAC ayudan a evitar las colisiones de las siguientes formas:

- Los marcos CTS ayudan a evitar los problemas de atenuación y de ocultación de estaciones.
- Los mensajes RTS y CTS son cortos, por lo que el riesgo de colisión es pequeño. Si se detecta una colisión o un marco RTS no produce otro marco CTS, se utiliza un período aleatorio de marcha atrás, como en Ethernet.
- Cuando los marcos RTS y CTS han sido correctamente intercambiados, no deberían producirse colisiones con los siguientes marcos de datos y de reconocimiento, a menos que una atenuación intermitente hubiera impedido a una tercera parte recibir cualquiera de los primeros.

◇ **Seguridad.** La privacidad y la integridad de las comunicaciones son un tema de interés obvio para las redes sin hilos. Cualquier estación dentro del rango de alcance y equipado con un receptor/transmisor puede encontrar el modo de conectarse a una red, o si esto falla, puede espiar las transmisiones entre otras estaciones. El estándar IEEE 802.11 contempla estos problemas. Se requiere un intercambio de autenticación para cada estación que se conecte a la red mediante el cual se demuestre el conocimiento de una clave compartida. Está basado en un mecanismo de autenticación de clave compartida similar al que se describirá en el Capítulo 7. Resulta efectivo para prevenir que cualquier estación que no tenga acceso a la clave compartida pueda conectarse a la red.

La prevención del espionaje se consigue mediante un esquema de encriptación simple. Éste enmascara el contenido de los flujos de datos transmitidos al combinarlo con una secuencia de números aleatorios utilizando una operación XOR al nivel de bits. La secuencia comienza desde una clave compartida y puede ser reproducida y utilizada para revelar los datos originales por cualquier estación que conozca la clave. Éste es un ejemplo de la técnica de cifrado de flujos descrita en la Sección 7.3.

3.5.3. REDES DE MODO DE TRANSFERENCIA ASÍNCRONO

Las redes ATM se han desarrollado para transportar una gran variedad de datos incluyendo datos multimedia como voz o vídeo. Es una red rápida de conmutación de paquetes basada en un método de encaminamiento de paquetes conocido como retransmisión de celdas, o *cell relay*, que puede funcionar mucho más rápidamente que la conmutación de paquetes tradicional. Consigue más velocidad evitando el control de flujo y la comprobación de errores en los nodos intermedios de una transmisión. Los enlaces y nodos de una transmisión deben presentar, por lo tanto, una probabilidad pequeña de que se produzcan datos corruptos. Otro factor que afecta a las prestaciones es que el tamaño de las unidades de datos transmitidas es pequeño y de tamaño fijo, lo que reduce el tamaño del búfer y el retardo debido a las colas en los nodos intermedios además de su complejidad. ATM trabaja en modo conectado, pero una conexión sólo puede ser establecida si se dispone de los recursos suficientes. Una vez que se ha establecido una conexión, se puede garantizar su calidad (esto es, las características de ancho de banda y de latencia).

ATM es una tecnología de conmutación de datos que puede implementarse sobre las redes de telefonía existentes, siendo éstas síncronas. Cuando ATM se asienta sobre una red de enlaces digitales síncronos de alta velocidad como aquellos especificados para las redes ópticas síncronas, (*Synchronous Optical Network*, SONET) [Omidyar y Aldridge 1993], produce una red de paquetes digital de alta velocidad mucho más flexible con muchas conexiones virtuales. Cada conexión virtual ATM proporciona garantía sobre el ancho de banda y sobre la latencia. Los circuitos virtuales resultantes pueden utilizarse para soportar un gran rango de servicios con velocidades variables. Éstos incluyen voz (32 kbps), fax, servicios de sistemas distribuidos, vídeo y televisión de alta definición (100-150 Mbps). El estándar ATM [CCITT 1990] recomienda la provisión de circuitos virtuales con tasas de transferencia de datos de hasta 155 ó 622 Mbps.

Las redes ATM también se pueden implementar en el *modo nativo* directamente sobre fibra óptica, cobre u otro medio de transmisión, permitiendo anchos de banda de hasta varios gigabits por segundo con la tecnología de fibra óptica actual. Éste es el modo en el cual se emplea en las redes de área local y metropolitana.

Los servicios ATM están estructurados en tres capas, representados por los bloques más oscuros de la Figura 3.23. La *capa de adaptación ATM* es una capa extremo a extremo implementada sólo en los hosts emisor y receptor. Se dedica a dar servicio a los protocolos de las capas superiores como TCP/IP y X25 por encima de la capa ATM. Las diferentes versiones de la capa de adaptación pueden proporcionar funciones diferentes de adaptación para ajustarse a las necesidades de los diferentes protocolos de niveles superiores. Incluirán algunas funciones comunes como el ensamblado o desensamblado de paquetes que serán utilizadas por los protocolos de nivel superior.

La *capa ATM* proporciona un servicio orientado a la conexión que transmite paquetes de longitud fija llamados *celdas*. Una conexión consiste en una secuencia de canales virtuales dentro de caminos virtuales. Un canal virtual, *virtual channel* (VC), es una asociación lógica unidireccional entre dos extremos de un enlace en un camino físico desde el origen al destino. Un camino virtual, *virtual path* (VP) es un paquete de canales virtuales que están asociados con un camino físico entre dos nodos comutadores. Los caminos virtuales están pensados para ser utilizados como soporte de conexiones semipermanentes entre pares de extremos. Los canales virtuales se reservan dinámicamente cuando se establecen las conexiones.

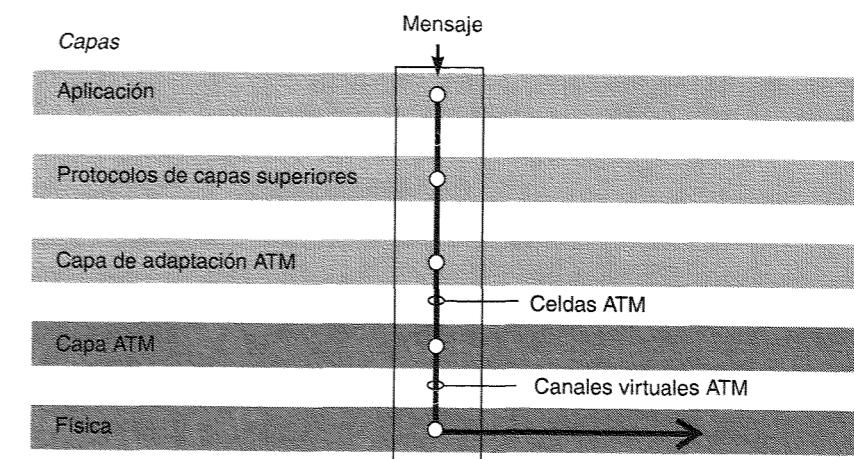


Figura 3.23. Capas del protocolo ATM.

Los nodos en una red ATM pueden jugar tres papeles distintos:

- *Hosts*, que envían y reciben mensajes.
- *Comutadores de VP*, que almacenan las tablas que muestran la correspondencia entre los caminos entrantes y salientes.
- *Comutadores VP/VC*, que almacenan tablas similares tanto para los caminos virtuales como para los canales virtuales.

Una celda ATM tiene una cabecera de 5 bytes y un campo de datos de 48 bytes (Figura 3.24). El campo de datos siempre se envía lleno, incluso cuando los datos no ocupan todo el espacio. La cabecera contiene un identificador de un canal virtual y de identificador de camino virtual, que juntos proporcionan la información necesaria para encaminar la celda a través de la red. El identificador de camino virtual se refiere a un camino virtual particular sobre el enlace físico en el que la celda es transmitida. El identificador de canal virtual se refiere a un canal virtual específico dentro del camino virtual. Además se utilizan otros campos en la cabecera para indicar el tipo de celda, la prioridad de pérdida y los límites de la celda.

Cuando una celda ATM llega a un comutador VP, se utiliza el identificador de camino virtual de la cabecera para buscar en la tabla de encaminamiento el correspondiente camino de salida físico (véase la Figura 3.25). Un comutador VP/VC puede efectuar un encaminamiento similar basándose tanto en los identificadores VP como VC.

Hay que hacer notar que los identificadores VP y VC se definen localmente. Este esquema tiene la ventaja de que no existe necesidad de identificadores globales dentro de toda la red, lo cual podría implicar el manejo de números muy grandes. Un esquema de direccionamiento global introduciría sobrecargas administrativas e implicaría la utilización de cabeceras y tablas en los comutadores capaces de almacenar más información.

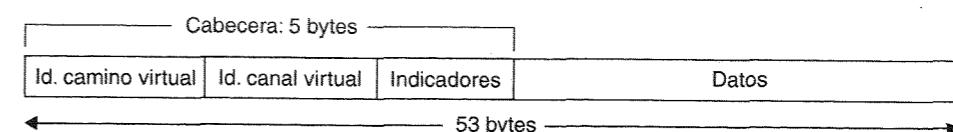


Figura 3.24. Esquema de una celda ATM.

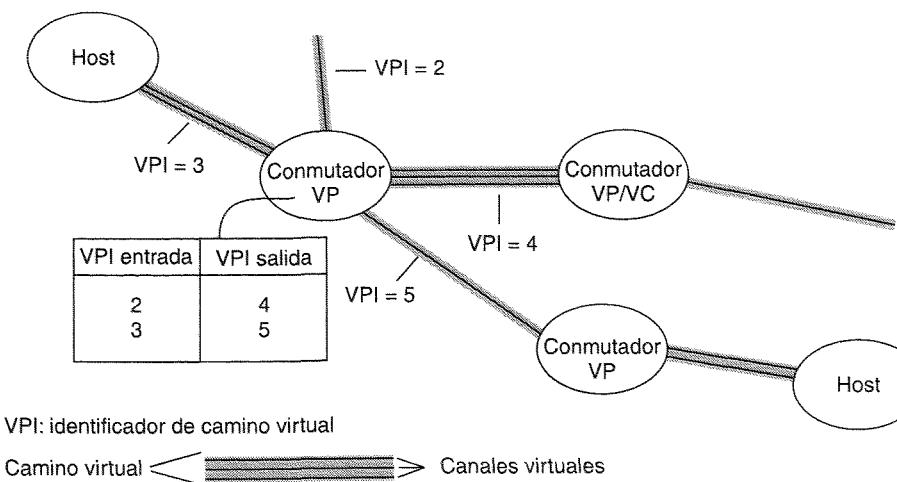


Figura 3.25. Conmutación de caminos virtuales en una red ATM.

ATM proporciona un servicio con latencias pequeñas: el retardo de conmutación es de unos 25 microsegundos por conmutador, dando, por ejemplo, una latencia de 250 microsegundos cuando un mensaje pasa a través de diez conmutadores. Esto se ajusta bien a nuestros requisitos estimados de prestaciones para los sistemas distribuidos (véase la Sección 3.2), sugiriendo que una red ATM podría soportar comunicación entre procesos e interacciones cliente-servidor con unas prestaciones similares a, o mejores que, las que están disponibles ahora en las redes de área local. También se dispone de canales con un ancho de banda muy alto, y con calidad de servicio garantizada que son perfectos para transmitir flujos de datos multimedia a velocidades de hasta 600 Mbps. En las redes ATM puras se pueden alcanzar gigabits por segundo.

3.6. RESUMEN

Nos hemos centrado en los conceptos y en las técnicas de las redes que se necesitan como base para los sistemas distribuidos y nos hemos aproximado a ellos desde el punto de vista de un diseñador de sistemas distribuidos. Las redes de paquetes y los protocolos a capas son la base de las comunicaciones en los sistemas distribuidos. Las redes de área local se basan en la difusión de paquetes en un medio común; y Ethernet es la tecnología dominante. Las redes de área amplia se basan en la conmutación de paquetes para encaminar los paquetes hacia sus destinos a través de la red conectada. El encaminamiento es el mecanismo clave y son varios los algoritmos de encaminamiento utilizados, de los cuales el de vectores de distancia es el más básico pero efectivo. Es necesario un control de la congestión para prevenir el desbordamiento de los búferes en el receptor y en los nodos intermedios.

Las interredes se construyen colocando una capa *virtual* de protocolo interred sobre la colección de redes unidas por los routers. Los protocolos de Internet TCP/IP hacen posible que los computadores en Internet se comuniquen con cualquier otro de una forma uniforme, independientemente de que se encuentren en la misma red de área local o en países diferentes. Los estándares de Internet incluyen varios protocolos del nivel de aplicación que resultan adecuados para su uso en aplicaciones distribuidas a gran escala. IPv6 tiene el espacio de direccionamiento necesario para la

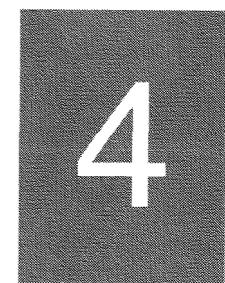
evolución futura de Internet y aporta los medios para satisfacer los requisitos de las nuevas aplicaciones tales como calidad de servicio y seguridad.

Los usuarios móviles tienen soporte de IP móvil en su deambular por áreas amplias, y por las LAN inalámbricas basadas en el IEEE 802.11 para una conectividad local. ATM ofrece un ancho de banda muy alto en comunicaciones asíncronas basadas en circuitos virtuales con calidad de servicio garantizada.

EJERCICIOS

- 3.1. Un cliente envía un mensaje de solicitud de 200 bytes a un servicio, que produce una respuesta conteniendo 5.000 bytes. Estime el tiempo total necesario para completar la operación en cada uno de los siguientes casos, según las suposiciones de prestaciones enumeradas a continuación:
 - i) Utilizando una comunicación de datagramas no orientada a conexión (por ejemplo, UDP).
 - ii) Utilizando una comunicación orientada a conexión (por ejemplo, TCP).
 - iii) El proceso servidor está en la misma máquina que el cliente.
 [Latencia por paquete (local o remoto, tanto en el enviar como en el recibir): 5 ms
 Tiempo de establecimiento de conexión (sólo TCP): 5 ms
 Tasa de transferencia de datos: 10 Mbps
 MTU: 1.000 bytes
 Tiempo de procesado de solicitud en el servidor: 2 ms
 Supóngase que la red está poco cargada.]
- 3.2. Internet es demasiado grande para que cualquier router pueda almacenar la información de encaminamiento para todos los nodos. ¿Cómo resuelve el esquema de encaminamiento de Internet este problema?
- 3.3. ¿Cuál es el cometido de un conmutador Ethernet? ¿Qué tablas mantiene?
- 3.4. Construya una tabla similar a la de la Figura 3.5 describiendo las tareas realizadas por el software del protocolo en cada capa cuando las aplicaciones Internet y el conjunto de protocolos TCP/IP están implementados sobre una red Ethernet.
- 3.5. ¿Cómo se ha aplicado el argumento de extremo a extremo [Saltzer y otros 1984] en el diseño de Internet? Considere el modo en que afectará a la viabilidad del *World Wide Web* la utilización de un protocolo de circuitos virtuales en lugar de IP.
- 3.6. ¿Cómo se puede estar seguro de que no hay dos computadores en Internet con la misma dirección IP?
- 3.7. Compare las comunicaciones no orientadas a conexión (UDP) y orientadas a conexión (TCP) para implementar cada uno de los siguientes protocolos del nivel de aplicación o del nivel de presentación:
 - i) Acceso virtual a terminales (por ejemplo, Telnet).
 - ii) Transferencia de archivos (por ejemplo, FTP).
 - iii) Localización de usuarios (por ejemplo, rwho, finger).
 - iv) Mostrar información (por ejemplo HTTP).
 - v) Invocación de procedimientos remotos.

- 3.8. Explique cómo es posible que una secuencia de paquetes transmitidos a través de una red de área amplia llegue a su destino en un orden diferente al utilizado en su envío. ¿Por qué esto no puede suceder en una red local? ¿Puede suceder en una red ATM?
- 3.9. Un problema específico que debe ser resuelto en los protocolos de acceso remoto a terminales como Telnet es la transmisión de eventos excepcionales como señales de finalización (*kill signals*) desde el *terminal* al host adelantándose a datos transmitidos previamente. Las señales de finalización deberían alcanzar su destino antes que cualquier transmisión en marcha. Discuta la solución de este problema con protocolos orientados y no orientados a conexión.
- 3.10. ¿Cuáles son las desventajas de utilizar la difusión (*broadcast*) a nivel de red para localizar recursos
- En una única Ethernet?
 - En una intranet?
- ¿En qué sentido mejora la multidifusión Ethernet a la difusión?
- 3.11. Sugiera un esquema que mejore el IP móvil cuando se accede a un servidor web desde un dispositivo móvil que algunas veces está conectado a Internet desde un teléfono móvil y otras veces está conectado por cable en varias localizaciones físicas.
- 3.12. Muestre la secuencia de cambios que sufrirían las tablas de encaminamiento de la Figura 3.8 (de acuerdo con el algoritmo RIP de la Figura 3.9) después de que se hubiera roto el enlace 3 de la Figura 3.7.
- 3.13. Utilice el diagrama de la Figura 3.13 como base para ilustrar la segmentación y encapsulación de una solicitud a un servidor HTTP y de la consiguiente respuesta. Suponga que la petición es un mensaje HTTP corto, pero que la respuesta incluye al menos 2.000 bytes de HTML.
- 3.14. Considere el uso de TCP en un cliente de terminal remoto Telnet. ¿Cómo debería ser almacenada en el cliente la entrada por teclado? Investigue los algoritmos de Nagle y de Clark [Nagle 1984, Clark 1982] para el control de flujo y compárelos con el algoritmo simple descrito en la página 97 cuando TCP es utilizado por (a) un servidor web, (b) una aplicación Telnet, (c) una aplicación gráfica remota con continuas entradas desde el ratón.
- 3.15. Construya un esquema de red similar al de la Figura 3.10 para la red local de su institución o empresa.
- 3.16. Describa el modo en que debería configurar un cortafuegos para proteger la red local de su institución o empresa. ¿Qué solicitudes entrantes y salientes debería interceptar?
- 3.17. ¿Cómo descubre un computador recién instalado y conectado a una red Ethernet la dirección IP de los servidores locales? ¿Cómo traduce esas direcciones a direcciones Ethernet?
- 3.18. ¿Pueden los cortafuegos prevenir los ataques de denegación de servicio como los descritos en el Epígrafe 3.4.2? ¿Qué otros métodos están disponibles para tratar este tipo de ataques?



COMUNICACIÓN ENTRE PROCESOS

- Introducción
- La interfaz de programación de aplicaciones para los protocolos de Internet
- Representación externa de datos y empaquetado
- Comunicación cliente-servidor
- Comunicación en grupo
- Caso de Estudio: comunicación entre procesos en UNIX
- Resumen

Este capítulo está dedicado a estudiar las características de los protocolos para la comunicación entre procesos en un sistema distribuido, ya sea por sí mismos, o como soporte para la comunicación entre objetos.

La interfaz de programación de aplicaciones (API) de Java para la comunicación entre procesos en Internet proporciona comunicación tanto por datagramas como por *streams*. Se tratarán ambas, junto a una discusión sobre sus modelos de fallo. Éstas proveen bloques constructivos alternativos para los protocolos de comunicación.

Se presentarán protocolos para la representación de colecciones de objetos mediante mensajes y referencias a objetos remotos.

También se discutirá la construcción de protocolos que soporten los dos patrones de comunicación más comúnmente utilizados en los programas distribuidos:

- Comunicación cliente-servidor: en la que los mensajes de petición y respuesta proporcionan la base para la invocación remota de métodos o de procedimientos.
- Comunicación de grupo: en la que el mismo mensaje se envía a varios procesos. Se presentará la comunicación entre procesos UNIX como un caso de estudio.

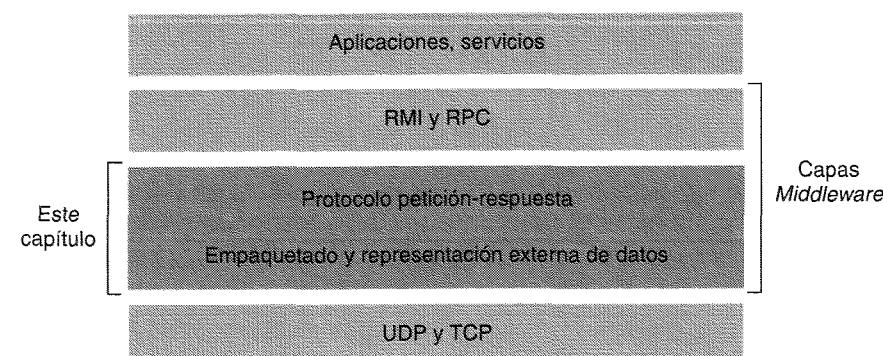


Figura 4.1. Capas de Middleware.

4.1. INTRODUCCIÓN

Tanto este capítulo como el siguiente están relacionados con el *middleware*. Este primer capítulo se centra en el nivel central que se encuentra resaltado en la Figura 4.1. La capa situada sobre ésta, que se estudia en el Capítulo 5, se encargará de integrar la comunicación en un paradigma de lenguaje de programación, proporcionando por ejemplo, la invocación de métodos remotos (*remote method invocation*, RMI) o la llamada de procedimientos remotos (*remote procedure call*, RPC). La *invocación de métodos remotos*, permite que un objeto invoque un método en otro objeto situado en un procedimiento remoto. Ejemplos de sistemas para la invocación remota son CORBA y Java RMI. De un modo similar, una *llamada a un procedimiento remoto*, permite que un cliente ejecute un procedimiento de un servidor remoto.

El Capítulo 3 hablaba de los protocolos de la capa de transporte de Internet, TCP y UDP, sin decir nada sobre cómo el middleware y los programas de aplicación pueden utilizar esos protocolos. La siguiente sección de este capítulo presenta las características de la comunicación entre procesos y discute UDP y TCP desde el punto de vista del programador, presentando la interfaz Java para estos dos protocolos, junto con una discusión de su modelo de fallo. La última sección de este capítulo presenta, como caso de estudio, la interfaz para *sockets* UNIX del tipo UDP y TCP.

La interfaz del programa de aplicación para UDP proporciona un abstracción del tipo *paso de mensajes*, la forma más simple de comunicación entre procesos. Esto hace que el proceso emisor pueda transmitir un mensaje simple al proceso receptor. Los paquetes independientes que contienen estos mensajes se llaman *datagramas*. Tanto en Java como en cada API UNIX, el emisor especifica el destino utilizando un zócalo, conector o *socket* (una referencia indirecta a un puerto particular utilizada por el proceso destino en el computador destino).

La interfaz del programa de aplicación de TCP proporciona la abstracción de un *flujo* (*stream*) de dos direcciones entre pares de procesos. La información intercambiada consiste en un stream de ítems de datos sin límites entre mensajes. Los streams son un bloque básico para la construcción de la comunicación productor-consumidor [Bacon 1998]. Un productor y un consumidor forman un par de procesos en los cuales el papel del primero es producir ítems de datos y el papel del segundo es consumirlos. Los ítems de datos enviados por el productor al consumidor se colocan en una cola a su llegada hasta que el consumidor esté en disposición de recibirlas. El consumidor debe esperar cuando no haya datos disponibles. El productor debe esperar si se llena el almacenamiento utilizado para guardar la cola con los ítems de datos.

La tercera sección de este capítulo trata sobre el modo en que los objetos y las estructuras de datos utilizadas en los programas de aplicación se traducen a una forma adecuada para ser enviada

en mensajes a través de la red, teniendo en cuenta el hecho de que computadores diferentes pueden usar diferentes representaciones para los datos simples. También aborda una representación adecuada para las referencias de objetos en un sistema distribuido.

Las secciones cuarta y quinta de este capítulo tratan sobre el diseño de protocolos capaces de soportar la comunicación cliente-servidor y en grupos. Los protocolos petición-respuesta están diseñados para soportar una comunicación cliente-servidor tanto bajo la forma RMI como RPC. Los protocolos de multidifusión en grupos están diseñados para soportar la comunicación entre grupos. La multidifusión en grupos es una forma de comunicación entre procesos en la cual un proceso de un grupo de procesos transmite el mismo mensaje a todos los miembros del mismo grupo.

Las operaciones de paso de mensajes se pueden utilizar para construir protocolos que soporten estructuras particulares de procesos y patrones de comunicación, por ejemplo la invocación de métodos remotos. Examinando los patrones de roles y de comunicación es posible diseñar protocolos de comunicación adecuados basados en intercambios eficientes evitando redundancias. En particular, estos protocolos especializados no deberían incluir acuses de recibo redundantes. Por ejemplo, en las comunicaciones petición-respuesta, en general se considera redundante el reconocimiento de un mensaje de petición, ya que el mensaje de respuesta sirve como acuse de recibo de la petición. Si un protocolo más especializado necesita acusar el recibo al emisor, o cualquier otra característica particular, será dotado de esas operaciones especializadas. La idea es añadir funciones especializadas sólo donde sean necesarias, con el propósito de conseguir protocolos que utilicen un mínimo de intercambios de mensajes.

4.2. API PARA LOS PROTOCOLOS DE INTERNET

En esta sección, estudiaremos las características generales de la comunicación entre procesos para después considerar los protocolos de Internet como un ejemplo de la misma, explicando el modo en que los programadores pueden utilizarlos, ya sea por medio de mensajes UDP o streams TCP.

La Sección 4.2.1 repasa las operaciones *envía* y *recibe* presentadas en la Sección 2.3.2 y discute el modo de sincronización y de direccionamiento en un sistema distribuido. La Sección 4.2.2 presenta los *sockets*, que se utilizan en la interfaz de programación de aplicaciones TCP y UDP. La Sección 4.2.3 trata sobre UDP y su API Java. La Sección 4.2.4 hace lo mismo con TCP y su API Java. Las API Java son orientadas al objeto pero se parecen a aquellas diseñadas originalmente en el sistema operativo UNIX BSD 4.x de Berkeley, que se tratan en la Sección 4.6. Los lectores que estudien los ejemplos de programación de esta sección deberían consultar la documentación Java en línea o a Flanagan [1997] para una especificación completa de las clases involucradas, que están en el paquete *java.net*.

4.2.1. LAS CARACTERÍSTICAS DE LA COMUNICACIÓN ENTRE PROCESOS

El paso de mensajes entre un par de procesos se puede basar en dos operaciones: *envía* y *recibe*, definidas en función del destino y del mensaje. Para que un proceso se pueda comunicar con otro, el proceso envía un mensaje (una secuencia de bytes) a un destino y otro proceso en el destino recibe el mensaje. Esta actividad implica la comunicación de datos desde el proceso emisor al proceso receptor y puede implicar además la sincronización de los dos procesos. La Sección 4.2.3 aporta las definiciones para las operaciones *envía* y *recibe* de la API Java de los protocolos de Internet.

◊ **Comunicación síncrona y asíncrona.** A cada destino de mensajes se asocia una cola. Los procesos emisores producen mensajes que serán añadidos a las colas remotas mientras que los pro-

cesos receptores eliminarán mensajes de las colas locales. La comunicación entre los procesos emisor y receptor puede ser síncrona o asíncrona. En la forma *síncrona*, los procesos receptor y emisor se sincronizan con cada mensaje. En este caso, tanto *envía* como *recibe* son operaciones *bloqueantes*. A cada *envía* producido, el proceso emisor se bloquea hasta que se produce el correspondiente *recibe*. Cuando se invoca un *recibe*, el proceso se bloquea hasta que llega un mensaje.

En la forma de comunicación *asíncrona*, la utilización de la operación *envía* es *no bloqueante*, de modo que el proceso emisor puede continuar tan pronto como el mensaje haya sido copiado en el búfer local, y la transmisión del mensaje se lleva a cabo en paralelo con el proceso emisor. La operación *recibe* puede tener variantes bloqueantes y no bloqueantes. En la variante no bloqueante, el proceso receptor sigue con su programa después de invocar la operación *recibe*, la cual proporciona un búfer que será llenado en un segundo plano, pero el proceso debe ser informado por separado de que su búfer ha sido llenado, ya sea por el método de encuesta o mediante una interrupción.

En un entorno como Java, que soporta múltiples hilos en un único proceso, el *recibe* bloqueante tiene pocas desventajas, puesto que puede ser invocado por un hilo mientras que el resto de hilos del proceso permanecen activos, y la simplicidad de sincronizar los hilos receptores con el mensaje entrante es una ventaja substancial. La comunicación no bloqueante parece ser más eficiente, pero implica una complejidad extra en el proceso receptor asociada con la necesidad de capturar el mensaje entrante fuera de su flujo de control. Por estas razones, los sistemas actuales no proporcionan la forma no bloqueante de *recibe*.

◇ **Destinos de los mensajes.** El Capítulo 3 explicaba que en los protocolos Internet, los mensajes son enviados a direcciones construidas por pares (*dirección Internet, puerto local*). Un puerto local es el destino de un mensaje dentro de un computador, especificado como un número entero. Un puerto tiene exactamente un receptor pero puede tener muchos emisores. Los procesos pueden utilizar múltiples puertos desde los que recibir mensajes. Cualquier proceso que conozca el número de puerto apropiado puede enviarle un mensaje. Generalmente, los servidores hacen públicos sus números de puerto para que sean utilizados por los clientes.

Si el cliente utiliza una dirección Internet fija para referirse a un servicio, entonces ese servicio debe ejecutarse siempre en el mismo computador para que la dirección se considere válida. Esto se puede evitar utilizando alguna de las siguientes aproximaciones que proporcionan transparencia de ubicación:

- Los programas cliente se refieren a los servicios por su nombre y utilizan un servidor de nombres o enlazador (véase la Sección 5.2.5) para trasladar esos nombres a ubicaciones del servidor en tiempo de ejecución. Esto permite reubicar los servicios en otro lugar, pero no migrarlos (cambiarlos de sitio mientras el sistema está en ejecución).
- El sistema operativo, por ejemplo Mach (véase el Capítulo 18), proporciona identificadores para los destinos de los mensajes independientes de la localización, haciéndoles corresponder con direcciones de más bajo nivel utilizadas para entregar los mensajes en los puertos, permitiendo tanto la migración como la reubicación de los servicios en otro lugar.

Una alternativa al uso de los puertos sería la entrega de los mensajes directamente a los procesos, tal y como sucedía en el sistema V [Cheriton 1984]. Sin embargo, los puertos tienen la ventaja de que proporcionan varios puntos de entrada alternativos para un proceso receptor. En algunas aplicaciones, es muy útil ser capaz de entregar el mismo mensaje a los miembros de un conjunto de procesos. Por lo tanto, algunos sistemas IPC proporcionan la capacidad de enviar mensajes a grupos de destinos, ya sean procesos o puertos. Por ejemplo, Chorus [Rozier y otros 1990] proporciona grupos de puertos.

◇ **Fiabilidad.** El Capítulo 2 definía una comunicación fiable en términos de validez e integridad. En lo que concierne a la propiedad de validez, se dice que un servicio de mensajes punto a

punto es fiable si se garantiza que los mensajes se entregan a pesar de poder dejar caer o perder un número *razonable* de ellos. Por el contrario, puede decirse que un servicio de mensajes punto a punto es no fiable si no se garantiza la entrega de los mensajes ante la pérdida o eliminación incluso de un solo paquete. Respecto a la integridad, los mensajes deben llegar sin corromperse ni duplicarse.

◇ **Ordenación.** Algunas aplicaciones necesitan que los mensajes sean entregados en el orden de su emisión, esto es, en el orden en el que fueron transmitidos por el emisor. La entrega de mensajes desordenados, por esas aplicaciones, es considerada como un fallo.

4.2.2. SOCKETS

Ambas formas de comunicación (UDP y TCP) utilizan la abstracción de *sockets*, que proporciona los puntos extremos de la comunicación entre procesos. Los sockets (conectores) se originan en UNIX BSD aunque están presentes en la mayoría de las versiones de UNIX, incluido Linux y también Windows NT y Macintosh OS. La comunicación entre procesos consiste en la transmisión de un mensaje entre un conector de un proceso y un conector de otro proceso, según se muestra en la Figura 4.2. Para los procesos receptores de mensajes, su conector debe estar asociado a un puerto local y a una de las direcciones Internet del computador donde se ejecuta. Los mensajes enviados a una dirección de Internet y a un número de puerto concretos, sólo pueden ser recibidos por el proceso cuyo conector esté asociado con esa dirección y con ese puerto. Los procesos pueden utilizar un mismo conector tanto para enviar como para recibir mensajes. Cada computador permite un gran número (2^{16}) de puertos posibles, que pueden ser usados por los procesos locales para recibir mensajes. Cada proceso puede utilizar varios puertos para recibir mensajes, pero un proceso no puede compartir puertos con otros procesos del mismo computador. Los procesos que utilizan multidifusión IP son una excepción ya que si comparten puertos (véase la Sección 4.5.1). No obstante, cualquier cantidad de procesos puede enviar mensajes a un mismo puerto. Cada conector se asocia con un protocolo concreto, que puede ser UDP o TCP.

◇ **API de Java para las direcciones Internet.** Como los paquetes IP que subyacen a TCP y UDP se envían a direcciones Internet, Java proporciona una clase, *InetAddress*, que representa las direcciones Internet. Los usuarios de esta clase se refieren a los computadores por sus nombres de host en el Servicio de Nombres de Dominio (*Domain Name Service, DNS*) (véase la Sección 3.4.7). Por ejemplo, se pueden crear instancias de *InetAddress* que contienen direcciones de Internet invocando a un método estático de *InetAddress* con un nombre DNS de host como argumento. El método utiliza DNS para conseguir la correspondiente dirección Internet. Por ejemplo, para conseguir un objeto que represente la dirección Internet de un host cuyo nombre DNS es *bruno.dcs.qmw.ac.uk*, utilice:

```
InetAddress unComputador = InetAddress.getByName("bruno.dcs.qmw.ac.uk");
```

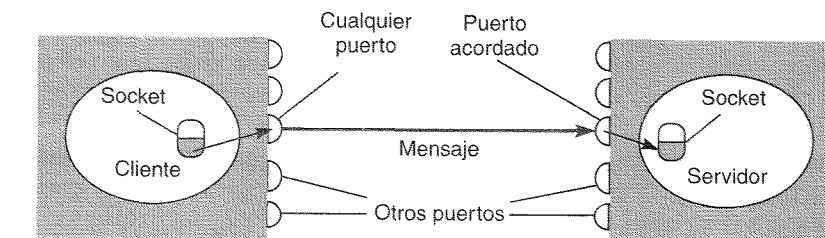
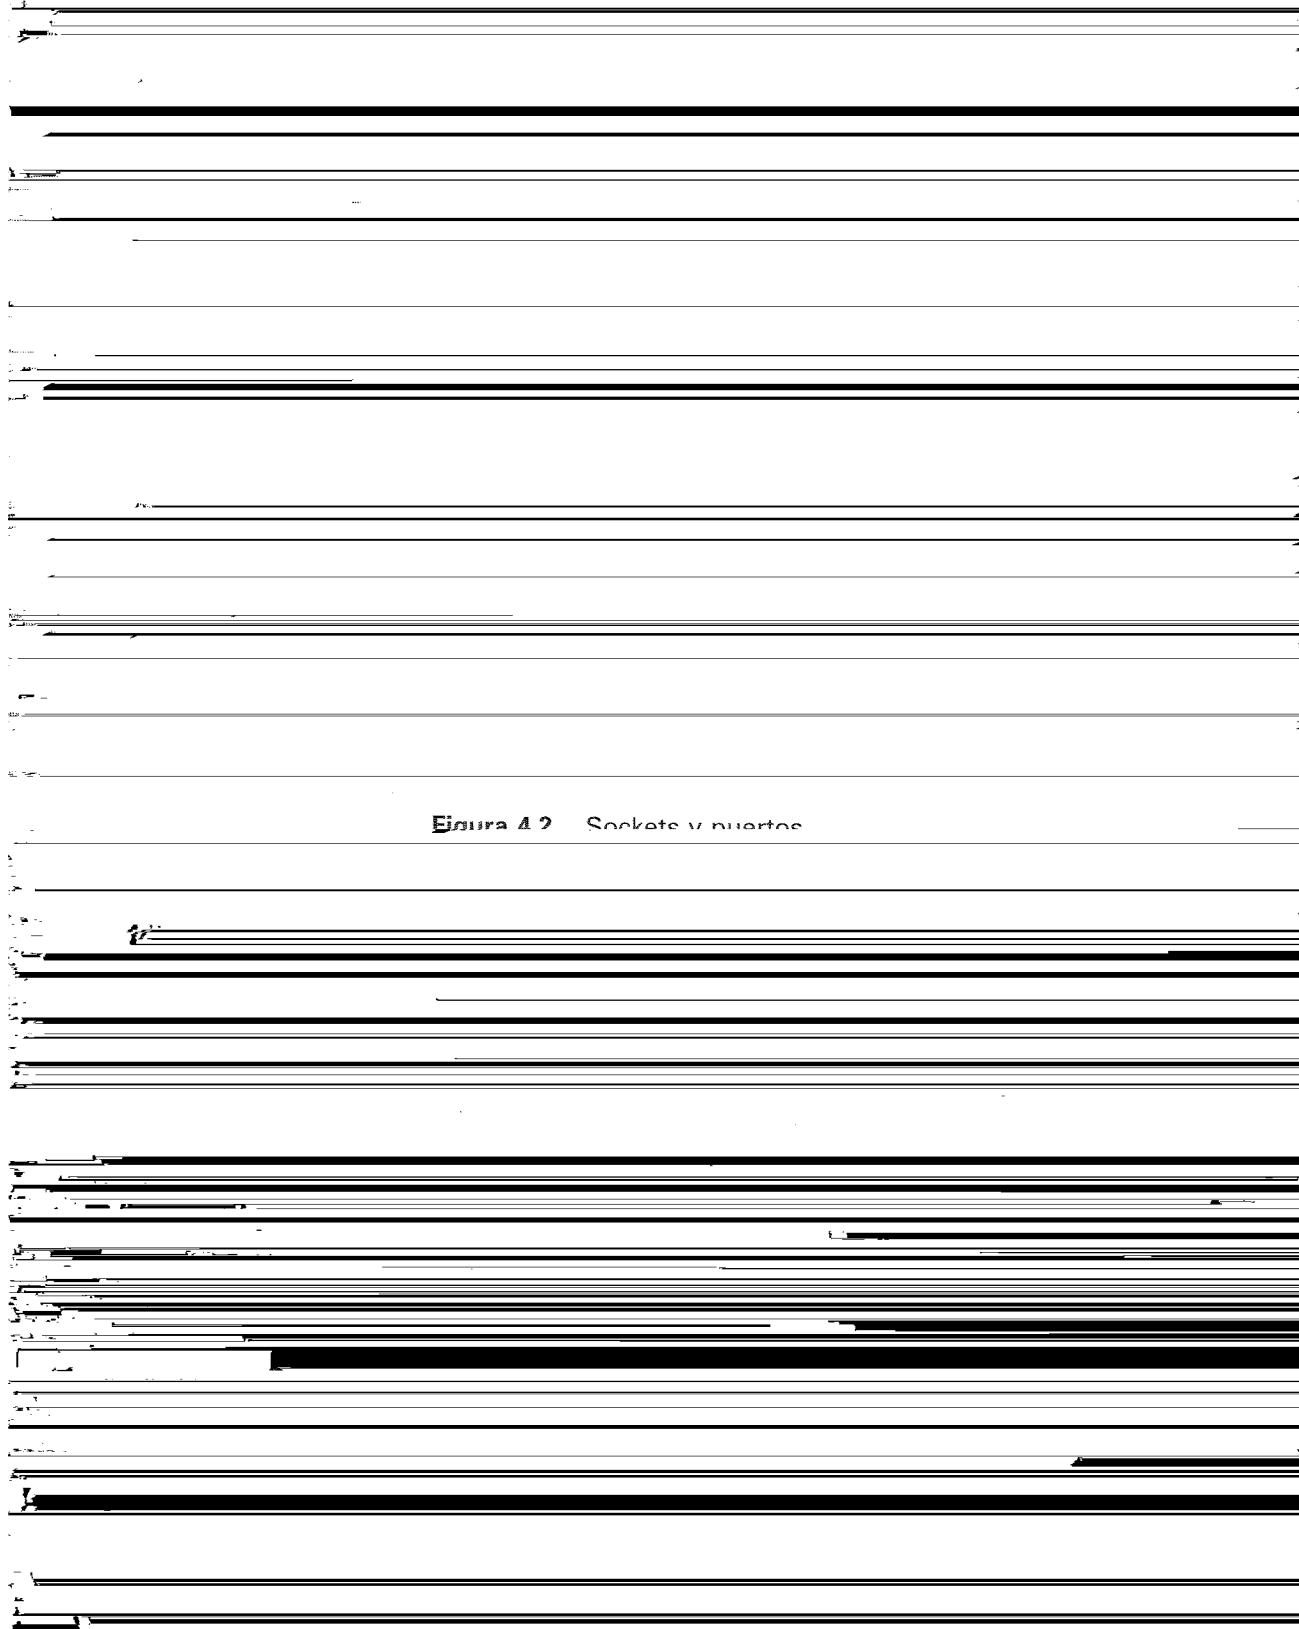


Figura 4.2. Sockets y puertos.

**Figura 4.2** Sockets y puertos

Recibe de cualquiera: el método *receive* no especifica el origen de los mensajes. En su lugar, al invocar *receive* aceptamos mensajes dirigidos a su conector desde cualquier origen. El método *receive* devuelve la dirección Internet y el puerto del emisor, permitiendo al receptor comprobar de dónde viene el mensaje. Es posible vincular un socket con un puerto y una dirección Internet remotas particulares, en cuyo caso el conector sólo podrá recibir y enviar mensajes con esa dirección.

◊ **Modelo de fallo.** El Capítulo 2 presentaba un modelo de fallo para los canales de comunicación y definía una comunicación fiable en términos de dos propiedades: integridad y validez. La propiedad de integridad requiere que los mensajes no se corrompan ni se dupliquen. La utilización de una suma de comprobación asegura que la probabilidad de que un mensaje esté corrompido sea despreciable. El modelo de fallo puede utilizarse para proponer un modelo de fallo para los datagramas UDP, que padece de las siguientes debilidades:

Fallos de omisión: los mensajes pueden desecharse ocasionalmente, ya sea porque se ha producido un error detectado por la suma de comprobación o porque no queda espacio en el búfer ya sea en el origen o en el destino. Para simplificar muestra discusión, incluiremos los fallos por omisión en el emisor y los fallos por omisión (véase la Figura 2.11) en el receptor como fallos de omisión en el canal de comunicaciones.

Ordenación: algunas veces, los mensajes se entregan en desorden con respecto a su orden de emisión.

Las aplicaciones que utilizan datagramas UDP dependen de sus propias comprobaciones para conseguir la calidad que necesitan respecto a la fiabilidad de la comunicación. Puede construirse un servicio de entrega fiable a partir de uno que adolece de fallos de omisión mediante la utilización de acuses de recibo. La Sección 4.4 discute el modo en que se pueden construir protocolos de petición-respuesta fiables para comunicaciones cliente-servidor sobre UDP.

◊ **Utilización de UDP.** Para algunas aplicaciones, resulta aceptable utilizar un servicio que sea susceptible de sufrir fallos de omisión ocasionales. Por ejemplo, el Servicio de Nombres de Dominio en Internet (*Domain Name Service*, DNS) está implementado sobre UDP. Los datagramas UDP son, en algunas ocasiones, una elección atractiva porque no padecen las sobrecargas asociadas a la entrega de mensajes garantizada. Existen tres fuentes principales para esa sobrecarga:

1. La necesidad de almacenar información de estado en el origen y en el destino.
2. La transmisión de mensajes extra.
3. La latencia para el emisor.

Las razones de estas sobrecargas se explicarán en la Sección 4.2.4.

◊ **API Java para datagramas UDP.** La API Java proporciona una comunicación de datagramas por medio de dos clases: *DatagramPacket* y *DatagramSocket*.

DatagramPacket: esta clase proporciona un constructor que crea una instancia compuesta por una cadena de bytes que almacena el mensaje, la longitud del mensaje y la dirección Internet y el número de puerto local del conector destino, tal y como sigue:

Paquete del datagrama

cadena de bytes contenido el mensaje	longitud del mensaje	dirección Internet	número de puerto
--------------------------------------	----------------------	--------------------	------------------

Las instancias de *DatagramPacket* podrán ser transmitidas entre procesos cuando uno las *envía*, y el otro las *recibe*.

Esta clase proporciona otro constructor para cuando se recibe un mensaje. Sus argumentos especifican la cadena de bytes en la que alojar el mensaje y la longitud de la misma. Un mensaje recibido se coloca en un *DatagramPacket* junto a su longitud y la dirección Internet y el número del puerto del conector emisor. El mensaje puede recuperarse del *DatagramPacket* mediante el método *getData*. Los métodos *getPort* y *getAddress* acceden, respectivamente, al puerto y a la dirección Internet.

DatagramSocket: esta clase maneja conectores para enviar y recibir datagramas UDP. Proporciona un constructor que toma un número de puerto como argumento, apropiado para los procesos que necesitan utilizar un puerto concreto. También proporciona un constructor sin argumentos que permite que el sistema elija un puerto de entre los que estén libres. Estos constructores pueden lanzar una excepción *SocketException* si el puerto ya está siendo usado o si se especifica un puerto reservado (por debajo del 1.024) cuando se ejecuta sobre UNIX.

La clase *DatagramSocket* proporciona varios métodos que incluyen los siguientes:

send y *receive*: estos métodos sirven para transmitir datagramas entre un par de conectores.

El argumento de *send* es una instancia de *DatagramPacket* conteniendo el mensaje y su destino. El argumento de *receive* es un *DatagramPacket* vacío en el que colocar el mensaje, su longitud y su origen. Tanto el método *send* como *receive* pueden lanzar una excepción *IOException*.

setSoTimeout: este método permite establecer un tiempo de espera límite. Cuando se fija un límite, el método *receive* se bloquea durante el tiempo fijado y después lanza una excepción *InterruptedException*.

connect: este método se utiliza para conectarse a un puerto remoto y a una dirección Internet concretos, en cuyo caso el conector sólo podrá enviar y recibir mensajes de esa dirección.

La Figura 4.3 muestra el programa de un cliente que crea un conector, envía un mensaje a un servidor en el puerto 6.789 y después espera una respuesta. Los argumentos para el método *main* proporcionan un mensaje y el nombre DNS de host del servidor. El mensaje se convierte a una cadena

```
import java.net.*;
import java.io.*;
public class ClienteUDP{
    public static void main(String args[ ]){
        // args proporciona el mensaje y el nombre del servidor
        try {
            DatagramSocket unSocket = new DatagramSocket();
            byte [ ] m = args[0].getBytes();
            InetAddress unHost = InetAddress.getByName(args[1]);
            int puertoServidor = 6789;
            DatagramPacket peticion =
                new DatagramPacket(m, args[0].length( ), unHost, puertoServidor);
            unSocket.send(peticion);
            byte [ ] bufer = new byte[1000];
            DatagramPacket respuesta = new DatagramPacket(bufer, bufer.length);
            unSocket.receive(respuesta);
            System.out.println("Respuesta: " + new String(respuesta.getData( )));
            unSocket.close();
        }catch (SocketException e){System.out.println("Socket: " + e.getMessage());
        }catch (IOException e){System.out.println("IO: " + e.getMessage());}
    }
}
```

Figura 4.3. Un cliente UDP enviando un mensaje a un servidor y recogiendo su respuesta.

```
import java.net.*;
import java.io.*;
public class ServidorUDP{
    public static void main(String args[ ]){
        try {
            DatagramSocket unSocket = new DatagramSocket(6789);
            byte [ ] bufer = new byte[1000];
            while (true){
                DatagramPacket peticion = new DatagramPacket(bufer, bufer.length);
                unSocket.receive(peticion);
                DatagramPacket respuesta = new DatagramPacket(peticion.getData( ),
                    peticion.getLength( ), peticion.getAddress( ), peticion.getPort( ));
                unSocket.send(respuesta);
            }
        }catch (SocketException e){System.out.println("Socket: " + e.getMessage());
        }catch (IOException e) {System.out.println("IO: " + e.getMessage());}
    }
}
```

Figura 4.4. Un servidor UDP recibe peticiones y las devuelve al cliente de forma repetitiva.

de bytes, y el nombre DNS del host a la correspondiente dirección Internet. La Figura 4.4 muestra el programa para el correspondiente servidor, el cual crea un conector ligado a su puerto de servidor (6.789) y entonces espera repetidamente a los mensajes de petición de los clientes, a los cuales responde mandando de vuelta el mismo mensaje.

4.2.4. COMUNICACIÓN DE STREAMS TCP

La API para el protocolo TCP, que es originaria de UNIX BSD 4.x, proporciona la abstracción de un flujo de bytes (*stream*) en el que pueden escribirse y desde el que pueden leerse datos. La abstracción de *stream* oculta las siguientes características de la red:

Tamaño de los mensajes: la aplicación puede elegir la cantidad de datos que quiere escribir o leer del *stream*. El conjunto de datos puede ser muy pequeño o muy grande. La implementación del flujo TCP subyacente decide cuántos datos recoge antes de transmitirlos como uno o más paquetes IP. En el destino, los datos son proporcionados a la aplicación según los va solicitando. Las aplicaciones pueden forzar, si fuera necesario, que los datos sean enviados de forma inmediata.

Mensajes perdidos: el protocolo TCP utiliza un esquema de acuse de recibo de los mensajes. Como un ejemplo de un esquema simple (no utilizado por TCP), el extremo emisor almacena un registro de cada paquete IP enviado y el extremo receptor acusa el recibo de todos los paquetes IP que le llegan. Si el emisor no recibe dicho acuse de recibo dentro de un plazo de tiempo fijo, volverá a transmitir el mensaje. El esquema de desplazamiento de ventana [Comer 1991], más sofisticado, reduce drásticamente el número de mensajes de reconocimiento necesarios.

Control del flujo: el protocolo TCP intenta ajustar las velocidades de los procesos que leen y escriben en un *stream*. Si el escritor es demasiado rápido para el lector, entonces será bloqueado hasta que el lector haya consumido una cantidad suficiente de datos.

Duplicación y ordenación de los mensajes: a cada paquete IP se le asocia un identificador, que hace posible que el receptor pueda detectar y rechazar mensajes duplicados, o que pueda reordenar los mensajes que lleguen desordenados.

◊ **Modelo de fallo.** Para satisfacer la propiedad de integridad de una comunicación fiable, los streams TCP utilizan una suma de comprobación para detectar y rechazar los paquetes corruptos, y utilizan un número de secuencia para detectar y eliminar los paquetes duplicados. Con respecto a la propiedad de validez, los streams TCP utilizan *timeouts* y retransmisión de los paquetes perdidos. Por lo tanto, los mensajes tienen garantizada su entrega incluso cuando alguno de los paquetes subyacentes se haya perdido.

Pero si la pérdida de paquetes sobrepasa un cierto límite, o la red que conecta un par de procesos en comunicación está severamente congestionada, el software TCP responsable de enviar los mensajes no recibirá acuses de recibo de los paquetes enviados y después de un tiempo declarará rota la conexión. Por esto TCP no proporciona comunicación fiable, ya que no garantiza la entrega de mensajes en presencia de algún tipo de problema.

Cuando una conexión está rota, se notificará al proceso que la utiliza siempre que intente leer o escribir. Esto tiene los siguientes efectos:

- Los procesos que utilizan la conexión no distinguen entre un fallo en la red y un fallo en el proceso que está en el otro extremo de la conexión.
- Los procesos comunicantes no pueden saber si sus mensajes recientes han sido recibidos o no.

◊ **Utilización de TCP.** Muchos de los servicios utilizados se ejecutan sobre conexiones TCP, con números de puerto reservados. Entre ellos se encuentran los siguientes:

HTTP: El protocolo de transferencia de hipertexto se utiliza en comunicación entre un navegador y un servidor web; se tratará de él más tarde en este capítulo.

FTP: El protocolo de transferencia de archivos permite leer los directorios de un computador remoto y transferir archivos entre los computadores de una conexión.

Telnet: La herramienta Telnet proporciona acceso a un terminal en un computador remoto.

SMTP: El protocolo simple de transferencia de correo se utiliza para mandar correos electrónicos entre computadores.

◊ **El API Java para los streams TCP.** La interfaz Java para los streams TCP está constituida por las clases *ServerSocket* y *Socket*.

ServerSocket: esta clase está diseñada para ser utilizada por un servidor para crear un conector en el puerto de servidor que escucha las peticiones de conexión de los clientes. Su método *accept* toma una petición *connect* de la cola, o si la cola está vacía, se bloquea hasta que llega una petición. El resultado de ejecutar *accept* es una instancia de *Socket*, un conector que da acceso a streams para comunicarse con el cliente.

Socket: esta clase es utilizada por el par de procesos de una conexión. El cliente utiliza un constructor para crear un conector, especificando el nombre DNS de host y el puerto del servidor. Este constructor no sólo crea el conector asociado con el puerto local, sino que también se conecta con el computador remoto especificado en el puerto indicado. Puede lanzar una excepción *UnknownHostException* si el nombre de host no es correcto, o una excepción *IOException* si se da un error de entrada y salida.

La clase *Socket* proporciona los métodos *getInputStream* y *getOutputStream* para acceder a los dos streams asociados con un conector. El tipo de datos devueltos por esos métodos son *InputStream* y *OutputStream*, respectivamente (clases abstractas que definen métodos para leer y escribir bytes). Los valores de retorno se pueden utilizar como argumentos de constructores para gestionar adecuadamente los streams de entrada y de salida del programa. Nuestro ejemplo utiliza *DataInputStream* y *DataOutputStream*, los cuales permiten utilizar representaciones binarias de los tipos primitivos de datos para ser leídos y escritos de una forma independiente de la máquina.

```

import java.net.*;
import java.io.*;
public class ClienteTCP{
    public static void main(String args[]){
        // los argumentos proporcionan el mensaje y el nombre del host destino
        try{
            int puertoServicio= 7896;
            Socket s = new Socket(args[1], puertoServicio);
            DataInputStream entrada = new DataInputStream(s.getInputStream());
            DataOutputStream salida =
                new DataOutputStream(s.getOutputStream());
            salida.writeUTF(args[0]); //UTF es una codificación de Strings, ir a Sec. 4.3
            String datos = entrada.readUTF();
            System.out.println("Recibido: " + datos);
            s.close();
        }catch (UnknownHostException e)
            System.out.println("Socket: "+ e.getMessage());
        }catch (EOFException e){System.out.println("EOF: "+e.getMessage());
        }catch (IOException e){System.out.println("IO: "+e.getMessage());
    }
}

```

Figura 4.5. Un cliente TCP realiza una conexión a un servidor, envía una petición y recibe una respuesta.

La Figura 4.5 muestra un programa cliente donde se le da como argumento al método *main* un mensaje y el nombre DNS del host del servidor. El cliente crea un conector ligado al nombre del host y al puerto 7896. Obtiene *DataInputStream* y *DataOutputStream* de los streams de los conectores de entrada y de salida respectivamente, y entonces escribe el mensaje en su stream de salida y espera a leer la respuesta en el stream de entrada. El programa del servidor de la Figura 4.6 abre un conector de servidor en su puerto de servicio (7896) y escucha las peticiones de conexión, *connect*. Cuando llega una, crea un nuevo hilo para comunicarse con el cliente. El nuevo hilo crea un *DataInputStream* y un *DataOutputStream* para los flujos de entrada y salida de su conector, y entonces espera a leer el mensaje del cliente y lo escribe de vuelta.

Como nuestro mensaje está compuesto por una cadena de caracteres, el cliente y el servidor utilizan el método *writeUTF* de *DataOutputStream* para escribirlo en el stream de salida, y el método *readUTF* de *DataInputStream* para leerlo del stream de entrada. UTF es un código que representa cadenas en un formato particular, descrito en la Sección 4.3.

Cuando un proceso ha cerrado su conector, no le será posible utilizar sus streams de entrada y de salida. El proceso al que le ha enviado datos puede leerlos de su cola, pero cualquier lectura después de que la cola esté vacía resultará en una excepción *EOFException*. Los intentos de utilizar un conector cerrado o de escribir en un stream roto tienen como resultado una excepción *IOException*.

4.3. REPRESENTACIÓN EXTERNA DE DATOS Y EMPAQUETADO

La información almacenada dentro de los programas en ejecución se representa mediante estructuras de datos (por ejemplo, por conjuntos de objetos interrelacionados) mientras que la información transportada en los mensajes consiste en secuencias de bytes. Independientemente de la forma de comunicación utilizada, las estructuras de datos deben ser *aplanadas* (convertidas a una secuencia

```

import java.net.*;
import java.io.*;
public class ServidorTCP{

```

de la máquina.

```

import java.net.*;
import java.io.*;
public class ServidorTCP{
    public static void main(String args[]){
        try{
            int puertoServicio= 7896;
            ServerSocket escuchandoSocket = new ServerSocket(puertoServicio);
            while (true) {
                Socket conectarCliente = escuchandoSocket.accept();

```

DataInputStream entrada;
DataOutputStream salida;

- Los valores se transmiten según el formato del emisor, junto con una indicación del formato utilizado, y el receptor los convierte si es necesario.

Los bytes no son alterados durante la transmisión. Para so-

portar datos sin embargo, que los bytes no son alterados durante la transmisión. Para so-

Tipo	Representación
sequence	longitud (unsigned long —entero largo sin signo—) seguida de los elementos en orden
string	longitud (unsigned long) seguida de los caracteres en orden (también puede tener caracteres anchos —2 bytes—)
array	elementos de la cadena en orden (no se especifica la longitud porque es fija)
struct	en el orden de declaración de los componentes
enumerated	unsigned long (los valores son especificados por el orden declarado)
union	etiqueta de tipo seguida por el miembro seleccionado

Figura 4.7. Tipos compuestos CDR de CORBA.

saje. El receptor lo traduce si es necesario a un orden diferente. Por ejemplo, un *short* de 16-bit ocupa dos bytes en el mensaje, y en el orden big-endian los bits más significativos ocupan el primer byte y los menos significativos el segundo. Cada valor primitivo se coloca en una posición en la secuencia de bytes de acuerdo con su tamaño. Supóngase que se indexa la secuencia de bytes desde cero. Entonces un valor primitivo cuyo tamaño son n bytes (donde $n = 1, 2, 4$ u 8) será añadido a la secuencia en una posición que sea un múltiplo de n en el flujo de bytes. Los valores de coma flotante siguen el estándar IEEE, en el cual el signo, el exponente y la parte fraccionaria están en los bytes 0- n para el orden big-endian y en el orden inverso para el little-endian. Los caracteres se representan por un conjunto de caracteres acordado entre el cliente y el servidor.

Tipos compuestos: los valores primitivos que componen cada tipo compuesto se añaden a la secuencia en un orden particular, según se muestra en la Figura 4.7.

La Figura 4.8 muestra un mensaje en CDR CORBA que contiene los tres campos de una estructura, *struct*, cuyos respectivos tipos son *string*, *string* y *unsigned long*. La figura muestra la secuencia de bytes con cuatro bytes en cada fila. La representación de cada cadena está compuesta por un *unsigned long* representando la longitud, seguido por los caracteres en la cadena. Para simplificar, supongamos que cada carácter ocupa justo un byte. Los datos de longitud variable se llenan con ceros de modo que tengan una forma estándar, haciendo que sean comparables los datos empacados o su suma de comprobación. Hay que hacer notar que cada *unsigned long*, que ocupa cuatro bytes, comienza en una posición que es múltiplo de cuatro. La figura no distingue entre los órdenes

Posición en la secuencia de bytes		Notas sobre la representación
0-3	5	Longitud del string
4-7	"Pérez"	«Pérez»
8-11	"z__"	
12-15	6	Longitud del string
16-19	"Madrid"	«Madrid»
20-23	"id__"	
24-27	1934	Unsigned long

La forma aplanaada representa una estructura *Persona* con el valor: {«Pérez», «Madrid», 1934}

Figura 4.8. Mensaje CDR CORBA.

big-endian y little-endian. Aunque el ejemplo de la Figura 4.8 es simple, el CDR de CORBA puede representar cualquier estructura de datos que se pueda componer a partir de datos primitivos y compuestos, siempre que no se utilicen punteros.

Otro ejemplo de una representación externa de datos es el estándar XDR de Sun, el cual está especificado en el RFC 1832 [Srinivasan 1995b] y descrito en www.cdk3.net/ipc. Fue desarrollado por Sun para utilizarlo en el intercambio de mensajes entre clientes y servidores en Sun NFS (véase el Capítulo 8).

El tipo de un elemento de datos no acompaña a la representación de los datos en el mensaje, ni en el CDR de CORBA ni el XDR de Sun. Esto es porque se supone que tanto el emisor como el receptor tienen un conocimiento común del orden y de los tipos de datos de los ítems en el mensaje. En particular para RMI o RPC, cada invocación de método pasa argumentos de unos tipos concretos, y el resultado es un valor de un tipo dado.

◊ **Empaquetado en CORBA.** Las operaciones de empaquetado se pueden generar automáticamente a partir de las especificaciones de los tipos de datos de los ítems que tienen que ser transmitidos en un mensaje. Los tipos de las estructuras de datos y los tipos de los ítems de datos básicos están descritos en CORBA IDL (véase la Sección 17.2.3), que proporciona una notación para describir los tipos de los argumentos y los resultados de los métodos RMI. Por ejemplo, podríamos utilizar CORBA IDL para describir la estructura de datos en el mensaje de la Figura 4.8 como sigue:

```
struct Persona
{
    string nombre;
    string lugar;
    long año;
};
```

La interfaz del compilador CORBA (véase el Capítulo 5) genera las operaciones de empaquetado y desempaquetado apropiadas para los argumentos y el resultado de los métodos remotos a partir las definiciones de los tipos de sus parámetros y resultados.

4.3.2. SERIALIZACIÓN DE OBJETOS EN JAVA

En Java RMI, tanto los objetos como los datos primitivos pueden ser pasados como argumentos y resultados de la invocación de métodos. Un objeto es una instancia de una clase Java. Por ejemplo, la clase Java equivalente a *struct Persona* definida en IDL de CORBA podría ser:

```
public class Persona implements Serializable {
    private String nombre;
    private String lugar;
    private int año;
    public Persona(String unNombre, String unLugar, int unAño) {
        nombre = unNombre;
        lugar = unLugar;
        año = unAño;
    }
    //seguido por los métodos para acceder a los campos
}
```

La clase de arriba declara implementar la interfaz *Serializable*, la cual no tiene métodos. Declarar que una clase implementa la interfaz *Serializable* (que viene dada en el paquete *java.io*) tiene el efecto de permitir que sus instancias sean serializables.

En Java, el término serialización se refiere a la actividad de aplanar un objeto o un conjunto relacionado de objetos para obtener una forma lineal adecuada para ser almacenada en disco o para ser transmitida en un mensaje, por ejemplo, como argumento o como resultado de un RMI. La deserialización consiste en restablecer el estado de un objeto o un conjunto de objetos desde su estado lineal. Se asume que el proceso que realiza la deserialización no tiene conocimiento previo de los tipos de los objetos en la forma lineal. Por lo tanto, debe incluirse en la forma lineal alguna información sobre la clase de cada objeto. Esta información posibilita al receptor la carga de la clase apropiada cuando un objeto es deserializado.

La información sobre la clase se compone del nombre de la clase y un número de versión. El número de versión está pensado para cambiar y reflejar con este cambio modificaciones importantes en la clase. Puede ser establecido por el programa o calculado de forma automática como un valor dependiente del nombre de la clase, sus campos, métodos e interfaces. El proceso que deserializa un objeto puede comprobar que tiene la versión correcta de la clase.

Los objetos Java pueden contener referencias a otros objetos. Cuando un objeto es serializado, todos los objetos a los que referencia son serializados con él para asegurarse de que cuando el objeto sea reconstruido, todas sus referencias pueden ser rellenadas en el destino. Las referencias se serializan como apuntadores (*handlers*) (en este caso, el apuntador es una referencia a un objeto dentro de la forma serializada, por ejemplo, el siguiente número en una secuencia de enteros positivos). El procedimiento de serialización debe asegurarse de que existe una correspondencia 1-1 entre las referencias y los apuntadores. También debe asegurarse de que cada objeto sea escrito sólo una vez (en la segunda o subsecuentes ocurrencias de un objeto, se escribirá el apuntador en lugar del objeto).

Para serializar un objeto, se escribe la información de su clase, seguida de los tipos y los nombres de los campos. Si los campos pertenecen a una clase nueva, entonces también se escribe la información de la clase, seguida de los nombres y los tipos de sus campos. Este procedimiento recursivo continúa hasta que se haya escrito la información de todas las clases necesarias y de los nombres y tipos de sus campos. Cada clase recibe un apuntador, y ninguna clase se escribe más de una vez en el flujo de bytes (en su lugar se escribe su apuntador cuando sea necesario).

Los contenidos de los campos que sean tipos de datos primitivos, como enteros, caracteres, booleanos, bytes y enteros largos, se escriben en un formato binario transportable utilizando métodos de la clase *ObjectOutputStream*. Las cadenas de caracteres y los caracteres se escriben con los métodos llamados *writeUTF* utilizando el Formato de Transferencia Universal (*Universal Transfer Format*, UTF), que hace que los caracteres ASCII sean representados sin cambios (en un byte) mientras que los caracteres Unicode se representan por varios bytes. Las cadenas de caracteres se preceden por el número de bytes que ocupan en el flujo.

Como ejemplo, considérese la serialización del siguiente objeto:

```
Persona p = new Persona("Pérez", "Madrid", 1934);
```

La forma serializada correspondiente se muestra en la Figura 4.9, la cual omite los valores de los apuntadores y de los marcadores de tipo que indican los objetos, clases, cadenas y otros objetos en la forma serializada completa. El primer campo (1934) es un entero que tiene una longitud fija, el segundo y el tercero son cadenas de caracteres que están precedidas por sus longitudes.

Para utilizar la serialización Java, por ejemplo para serializar el objeto *Persona*, hay crear una instancia de la clase *ObjectOutputStream* e invocar a su método *writeObject*, pasándole el objeto *Persona* como argumento. Para deserializar un objeto desde un flujo de datos, hay que abrir un *ObjectInputStream* sobre el flujo y utilizar su método *readObject* para reconstruir el objeto origi-

Valores serializados			Explicación
Persona	Número de versión de 8-bytes	a0	nombre de la clase, número de versión
3	int año	java.lang.String nombre:	número, tipo y nombre de las variables de instancia
1934	5 Pérez	6 Madrid	a1 valores de las variables de instancia

La auténtica forma serializada contiene marcadores de tipo adicionales; a0 y a1 son apuntadores

Figura 4.9. Muestra de una serialización Java.

nal. La utilización de este par de clases es similar al uso de las clases *DataOutputStream* y *DataInputStream* mostrado en las Figuras 4.5 y 4.6.

La serialización y la deserialización de los argumentos y los resultados de una invocación remota son llevadas a cabo generalmente de forma automática por el middleware, sin ninguna participación del programador. Si fuera necesario, los programadores con requisitos especiales pueden escribir sus propias versiones de los métodos que leen y escriben objetos. Para encontrar el modo de hacerlo y conseguir más información sobre la serialización en Java, lea el curso sobre serialización de objetos [java.sun.com II]. Otro modo en el que el programador puede modificar los efectos de la serialización es declarando aquellas variables que no deberían ser serializadas como *transient*. Ejemplos de cosas que no deberían ser serializadas son las referencias a recursos locales como archivos o sockets.

◊ **El uso de la reflexión.** El lenguaje Java soporta la *reflexión*, que es la habilidad de preguntar sobre las propiedades de una clase, tales como los nombres y los tipos de sus campos y métodos. Esto también hace posible que se creen las clases a partir de su nombre, y crear un constructor para una clase dada con unos argumentos dados. La reflexión hace posible hacer la serialización y la deserialización de una manera totalmente genérica. Esto significa que no hay necesidad de generar funciones de empaquetado especiales para cada tipo de objeto, como se describió anteriormente para CORBA. Para encontrar más información sobre la reflexión, véase Flanagan [1997].

La serialización de objetos Java utiliza la reflexión para encontrar el nombre de la clase del objeto a serializar y los nombres, tipos y valores de sus variables de instancia. Esto es todo lo que se necesita en la forma serializada.

Para la deserialización, se utiliza el nombre de la clase en la forma serializada para crear un nuevo constructor con los tipos de argumentos correspondientes a aquellos especificados en la forma serializada. Finalmente, se utiliza el nuevo constructor para crear una nueva instancia del objeto con aquellos valores leídos de la forma serializada.

4.3.3. REFERENCIAS A OBJETOS REMOTOS

Cuando un cliente invoca un método en un objeto remoto, se envía un mensaje de invocación al proceso servidor que alberga el objeto remoto. Este mensaje necesita especificar el objeto particular cuyo método se va a invocar. Una *referencia a un objeto remoto* es un identificador para un objeto remoto que es válida a lo largo y ancho de un sistema distribuido. En el mensaje de invocación se incluye una referencia a objeto remoto que especifica cuál es el objeto invocado. El Capítulo 5 explica que las referencias a objetos remotos también se pasan como argumentos y se devuelven como resultados de la invocación de métodos remotos, que cada objeto remoto tiene una única referencia a objeto remoto y que las referencias a objetos remotos pueden compararse para saber si se refieren al mismo objeto remoto. Ahora trataremos sobre la representación externa de las referencias a objetos remotos.

32 bits	32 bits	32 bits	32 bits
dirección Internet	número de puerto	tiempo	número de objeto

Figura 4.10. Representación de una referencia de objeto remoto.

Las referencias a objetos remotos deben generarse de modo que se asegure su unicidad sobre el espacio y el tiempo. En general, existirán varios procesos alojando objetos remotos, de modo que las referencias a objetos remotos deben ser únicas entre todos los procesos en los computadores de un sistema distribuido. Es importante que la referencia al objeto remoto no sea reutilizada incluso después de que el objeto remoto asociado a una referencia a objeto remoto haya sido borrado, ya que los potenciales invocadores podrían tener referencias remotas obsoletas. Cualquier intento de invocar objetos borrados debería producir un error en lugar de permitir el acceso a un objeto diferente.

Existen varios modos de asegurarse que una referencia a un objeto remoto es única. Un modo es construir una referencia a objeto remoto concatenando la dirección Internet de su computador y el número de puerto del proceso que lo creó junto con el instante de tiempo de su creación y un número de objeto local. El número de objeto local se incrementa cada vez que el proceso crea un objeto.

El número de puerto junto al tiempo constituyen un identificador único en ese computador. Con esta aproximación, las referencias a objetos remotos podrían representarse según un formato como el mostrado en la Figura 4.10. En las implementaciones más simples de RMI, los objetos remotos viven en el proceso que los crea y sobreviven sólo mientras que el proceso continúa en ejecución. En estos casos, la referencia a objeto remoto puede utilizarse como una dirección del objeto remoto. En otras palabras, los mensajes de invocación se envían a la dirección Internet de la referencia remota, y dentro del computador al proceso identificado por el número de puerto.

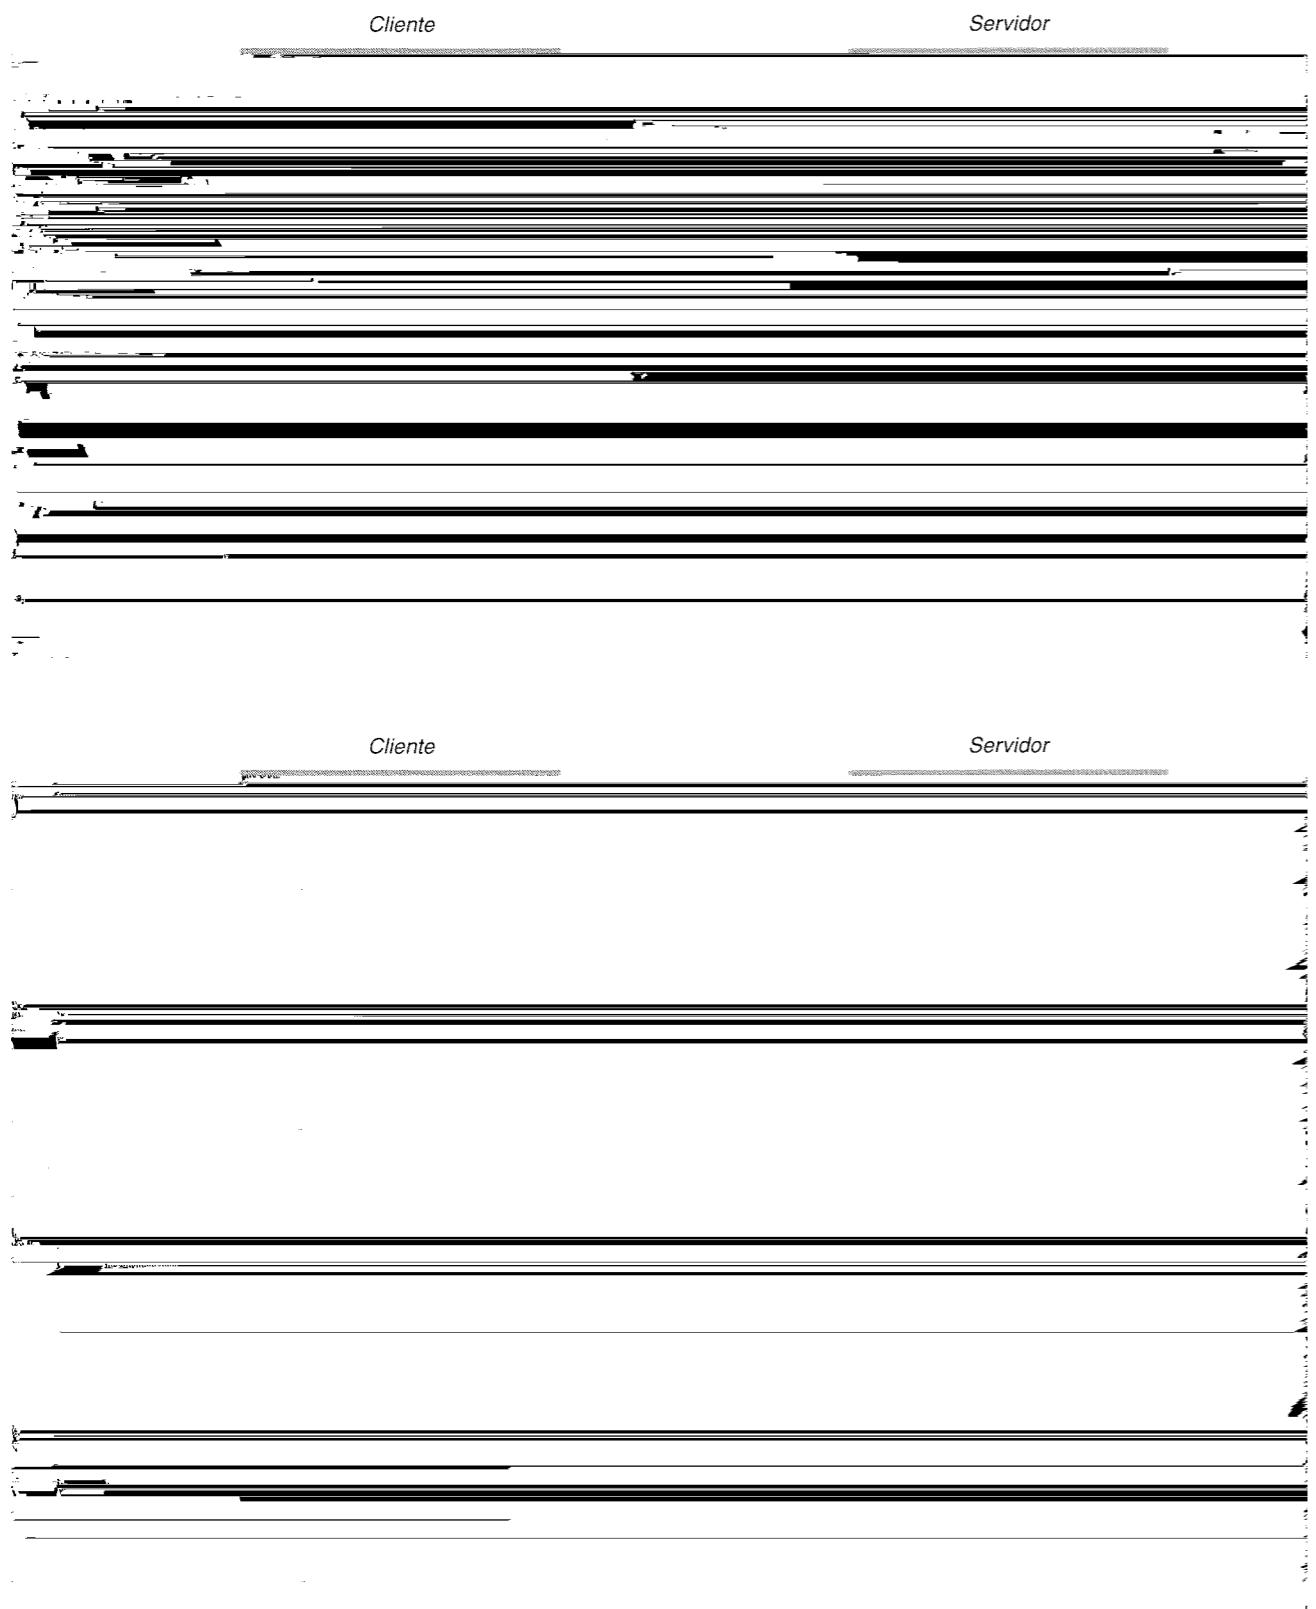
Para permitir que los objetos remotos sean recolocados en distintos procesos en computadores diferentes, las referencias de objetos remotos no debieran utilizarse como dirección del objeto remoto. La Sección 17.2.4 tratará sobre un formato de referencia de objetos remotos que permite que los objetos puedan ser activados en diferentes servidores a lo largo de su tiempo de vida.

El último campo de la referencia de objeto remoto mostrada en la Figura 4.10 contiene cierta información sobre la interfaz del objeto remoto, por ejemplo el nombre de la interfaz. Esta información es relevante para cualquier proceso que reciba una referencia de objeto remoto como argumento o resultado de una invocación remota, ya que necesitará conocer los métodos que ofrece el objeto remoto. Este punto se tratará de nuevo en la Sección 5.2.5.

4.4. COMUNICACIÓN CLIENTE-SERVIDOR

Esta forma de comunicación está orientada a soportar los roles y el intercambio de mensajes de las interacciones típicas cliente-servidor. En el caso normal, la comunicación petición-respuesta es síncrona, ya que el proceso cliente se bloquea hasta que llega la respuesta del servidor. Esta comunicación también puede ser fiable ya que la respuesta del servidor es, en efecto, un acuse de recibo para el cliente. La comunicación cliente-servidor asíncrona es una alternativa que puede ser útil en situaciones donde los clientes pueden recuperar las respuestas más tarde (véase la Sección 6.5.2).

En los siguientes párrafos se describen los intercambios cliente-servidor en términos de las operaciones *envía* y *recibe* del API Java para datagramas UDP, aunque muchas implementaciones actuales utilicen streams TCP. Un protocolo construido sobre datagramas evita las sobrecargas asociadas con el protocolo de streams TCP. En concreto:



ción Internet y el puerto del servidor del objeto remoto. La primitiva *hazOperacion* envía un mensaje de petición al servidor cuya dirección Internet y puerto se especifican en la referencia de objeto remoto dada como argumento. Después de enviar el mensaje de petición, *hazOperacion* invoca el método *recibe* para conseguir el mensaje respuesta, del que extrae el resultado y lo devuelve a su invocador. El invocador de *hazOperacion* se bloquea hasta que el objeto remoto en el servidor ejecuta la operación solicitada y transmite el mensaje respuesta al proceso cliente.

La primitiva *damePeticion* se usa en el servidor para hacerse con las peticiones de servicio, según se muestra en la Figura 4.11. Cuando el servidor ha invocado el método sobre el objeto especificado, utiliza el método *enviaRespuesta* para mandar el mensaje de respuesta al cliente. Cuando el cliente recibe el mensaje de respuesta, desbloquea la operación *hazOperacion* y continúa la ejecución el programa cliente.

La información transmitida en un mensaje de petición y de respuesta se muestra en la Figura 4.13. El primer campo indica cuándo el mensaje es una petición o una respuesta. El segundo campo, *idPeticion*, contiene un identificador de mensajes. Una primitiva *hazOperacion* en el cliente genera un *idPeticion* para cada mensaje de petición, y el servidor lo copia en el correspondiente mensaje de respuesta. Esto hace posible que *hazOperacion* pueda comprobar que un mensaje de respuesta es el resultado de la petición actual, no de una invocación anterior que se ha retrasado. El tercer campo es una referencia de objeto remoto empaquetada según la forma mostrada en la Figura 4.10. El cuarto campo es un identificador del método a invocar, por ejemplo, los métodos en una interfaz pueden numerarse 1, 2, 3, ...; si el cliente y el servidor utilizan un lenguaje común que soporte la reflexión, entonces se puede colocar en este campo una representación del método mismo (en Java, se puede colocar en este campo una instancia de *Method*).

Identificadores de mensaje: Cualquier esquema que involucre la gestión de mensajes para proporcionar propiedades adicionales como la entrega fiable de mensajes o una comunicación petición-respuesta necesita que cada mensaje tenga un identificador único por el que pueda ser referenciado. Un identificador de mensaje tiene dos partes:

1. Un identificador de petición, *idPeticion*, que proporciona el proceso emisor de una sucesión de enteros creciente.
2. Un identificador para el proceso emisor, por ejemplo, su puerto y su dirección Internet.

La primera parte hace que el identificador sea único para el emisor, y la segunda lo hace único para el sistema distribuido. (La segunda parte se puede obtener independientemente, por ejemplo, si se usa UDP, desde el mensaje recibido.)

Cuando el valor del campo *idPeticion* alcanza el valor máximo para un entero sin signo (por ejemplo $2^{32} - 1$) vuelve a cero. La única restricción impuesta es que el tiempo de vida de un identificador de mensaje deberá ser mucho menor que el tiempo que se necesita para dar la vuelta a esa secuencia de enteros.

tipoMensaje	<i>int (0 = Petición, 1 = Respuesta)</i>
idPeticion	<i>int</i>
referenciaObjeto	<i>RemoteObjectRef</i>
idMetodo	<i>int o Method</i>
argumentos	<i>// cadena de bytes</i>

Figura 4.13. Estructura de un mensaje petición-respuesta.



◊ **Modelo de fallos del protocolo petición-respuesta.** Si las tres primitivas *hazOperacion*, *devuelvePeticion*, *enviaRespuesta* se implementan con datagramas UDP, adolecerán de los mis-

- No se garantiza que los mensajes lleguen en el orden de emisión.

Además, el protocolo puede padecer el fallo de los procesos (véase la Sección 2.3.2). Presuponemos que los procesos pueden caer. Es decir, cuando se detienen, permanecen detenidos (no provocan un comportamiento bizantino).

En aquellas ocasiones en las que un servidor falle o se elimine un mensaje de petición o de respuesta, *hazOperacion* utilizará un *timeout* para esperar el mensaje de respuesta del servidor. La

Nombre		Mensajes enviados por	
	Cliente	Servidor	Cliente
R	Petición		
RR	Petición	Respuesta	
RRA	Petición	Respuesta	Confirmación de la respuesta

Figura 4.14. Protocolos de intercambio RPC.

Como los clientes pueden hacer una sola petición al tiempo, el servidor puede interpretar que cada petición es un reconocimiento de la respuesta previa. Por lo tanto, el historial sólo necesita contener el último mensaje de respuesta enviado a cada cliente. Sin embargo, el volumen de mensajes de respuesta en el historial de un servidor puede ser un problema cuando tiene un gran número de clientes. En particular, cuando un cliente termina, no reconoce la última respuesta recibida, por lo que los mensajes en el historial serán normalmente descartados después de que pase un período de tiempo.

Protocolo de intercambio de RPC: En la implementación de los distintos tipos de RPC se utilizan tres protocolos, con diferentes semánticas en presencia de fallos de comunicación. Inicialmente fueron identificados por Spector [1982]:

- El protocolo *petición* (R).
- El protocolo *petición-respuesta* (RR).
- El protocolo *petición-respuesta-confirmación de la respuesta* (RRA).

Los mensajes basados en estos protocolos se resumen en la Figura 4.14. El protocolo R (*request*) puede utilizarse cuando el procedimiento no tiene que devolver ningún valor y el cliente no necesita confirmación de que el procedimiento ha sido ejecutado. El cliente puede seguir inmediatamente después de haber enviado el mensaje de petición ya que no tiene que esperar un mensaje de respuesta. El protocolo RR (*request-reply*) es útil en la mayoría de los intercambios cliente-servidor, pues se basa en el protocolo petición-respuesta. No se necesitan mensajes especiales de acuse de recibo, ya que los mensajes de respuesta del servidor sirven como confirmación de las peticiones del cliente. Similarmente, una subsiguiente llamada desde un cliente podría ser considerada como un reconocimiento del mensaje de respuesta del servidor.

El protocolo RRA (*request-reply-acknowledge reply*) está basado en el intercambio de tres mensajes: petición-respuesta-confirmación de la respuesta. El mensaje de reconocimiento de la respuesta contiene el *idPeticion* del mensaje de respuesta que reconoce. Esto hace posible que el servidor pueda descartar las entradas de su historial. La llegada de un *idPeticion* en un mensaje de reconocimiento será interpretada como el acuse de recibo de la recepción de todos los mensajes de respuesta con identificadores de petición menores, por lo que la pérdida de un mensaje de reconocimiento de respuesta no resulta dañina. Aunque el intercambio implica un mensaje adicional, no necesita bloquear al cliente, ya que el reconocimiento puede transmitirse después de que la respuesta haya sido entregada al cliente, aunque esto requiere procesamiento y recursos de red. El Ejercicio 4.22 sugiere una optimización al protocolo RRA.

◊ **Utilización de streams TCP para implementar el protocolo petición-respuesta.** En la sección dedicada a los datagramas mencionamos que a menudo resulta difícil decidir un tamaño apropiado para el búfer en el cual se van a almacenar los datagramas recibidos. En el protocolo petición-respuesta, esto se aplica a los búferes utilizados por el servidor para recibir los mensajes de petición de los clientes y por el cliente para recibir las respuestas. La limitada longitud de los datagramas (normalmente 8 kilobytes) no se puede considerar como adecuada para su uso en sistemas

mas RMI transparentes, ya que los argumentos o resultados de los procedimientos pueden ser cualquier tamaño.

Una de las razones para elegir la implementación de los protocolos petición-respuesta sobre streams TCP es el deseo de evitar la implementación de protocolos multipaquete, permitiendo la transmisión de argumentos y resultados de cualquier tamaño. En particular la serialización de objetos Java es un protocolo de streams que permite enviar los argumentos y los resultados entre el cliente y el servidor sobre streams, haciendo posible la transmisión fiable de colecciones de objetos de cualquier tamaño. Si se utiliza el protocolo TCP, se está asegurando que los mensajes de petición y de respuesta serán entregados de manera fiable, de modo que no es necesario un protocolo petición-respuesta para tratar los mensajes de retransmisión y filtrar los duplicados, y los históricos. Además el mecanismo de control de flujo permite transmitir argumentos y resultados grandes sin tomar medidas especiales para evitar el desbordamiento en el destino. Por todo esto, se elige el protocolo TCP para implementar los protocolos petición-respuesta dado que puede simplificar su implementación. Si se envían sucesivas peticiones y respuestas entre el mismo par de cliente y servidor sobre el mismo flujo, no es necesaria la sobrecarga del establecimiento de la conexión en cada invocación remota. También se puede reducir la sobrecarga debida a los mensajes de reconocimiento si un mensaje de respuesta sigue inmediatamente a otro de petición.

Algunas veces, la aplicación no necesita de todas las posibilidades ofrecidas por TCP, y se puede implementar sobre UDP un protocolo más eficiente, especialmente construido. Por ejemplo, como hemos mencionado anteriormente, Sun NFS no necesita mensajes de tamaño ilimitado, ya que transmite mensajes constituidos por bloques de tamaño fijo entre el cliente y el servidor. Además, sus operaciones son idempotentes, de modo que no importa si las operaciones se ejecutan más de una vez a la hora de retransmitir los mensajes de respuesta perdidos, haciendo innecesario mantener un historial.

◊ **HTTP: un ejemplo de protocolo petición-respuesta.** El Capítulo 1 presentó el Protocolo de Transferencia de Hipertexto (*HyperText Transfer Protocol*, HTTP) utilizado por los navegadores web para realizar peticiones a los servidores web y para recibir las respuestas de ellos. Valga recordar, como recapitulación, que los servidores web gestionan recursos implementados de diferentes modos:

- Como datos, por ejemplo el texto de una página HTML, una imagen o la clase de un applet.
- Como programa, por ejemplo los programas *cgi* y los servlets (véase [[java.sun.com III](#)]) que puede ser ejecutado en el servidor web.

Las peticiones de los clientes especifican un URL que incluye el nombre DNS del host del servidor web y un número de puerto opcional, además del identificador de un recurso en el servidor.

HTTP es un protocolo que especifica los mensajes involucrados en un intercambio petición-respuesta, los métodos, argumentos y resultados y las reglas para representar (empaquetar) todo ello en los mensajes. Soporta un conjunto fijo de métodos (GET, PUT, POST, etc.) que son aplicables a todos los recursos. Al contrario de los protocolos anteriores, cada objeto tiene sus propios métodos. Además de invocar métodos sobre recursos web, el protocolo permite la negociación de contenidos y una autenticación del tipo *clave de acceso*.

Negociación del contenido: las peticiones de los clientes pueden incluir información sobre qué tipo de representación de datos pueden aceptar (por ejemplo lenguaje o tipo de medio), haciendo posible que el servidor pueda elegir la representación más apropiada para el usuario.

Autenticación: se utilizan credenciales y desafíos para conseguir una autenticación del estilo *clave de acceso*. En el primer intento de acceso al área protegida por palabra clave, el servidor responde con un desafío aplicable al recurso. El Capítulo 7 explica los desafíos. Cuando el cliente recibe el desafío pide al usuario un nombre y una palabra de paso, y se los envía al

servidor en las siguientes solicitudes. HTTP se implementa sobre TCP. En la versión original del protocolo, cada interacción cliente-servidor se componía de los siguientes pasos:

- El cliente solicita una conexión al puerto del servidor por defecto o a otro especificado en la petición aceptada por el servidor.
- El cliente envía un mensaje de petición al servidor.
- El servidor envía un mensaje de respuesta al cliente.
- Se cierra la conexión.

Sin embargo, la necesidad de establecer y cerrar una conexión para cada intercambio petición-respuesta resulta cara, sobrecargando al servidor y enviando demasiados mensajes por la red. Teniendo en cuenta que los navegadores generalmente hacen múltiples peticiones al mismo servidor, la siguiente versión del protocolo (HTTP 1.1: véase el RFC 2616 [Fielding y otros 1999]) utiliza *conexiones persistentes*; conexiones que permanecen abiertas durante una serie de intercambios petición-respuesta entre el cliente y el servidor. Una conexión persistente puede ser cerrada por el cliente o por el servidor en cualquier instante enviando una indicación al otro participante. Los servidores cerrarán una conexión persistente cuando ha estado inactiva durante un cierto intervalo de tiempo. Es posible que un cliente pueda recibir un mensaje del servidor indicándole que la conexión se cierra mientras se está en el transcurso del envío de otra petición o respuestas. En estos casos, el navegador volverá a enviar las peticiones sin que el usuario tenga que verse implicado en ello, ya que las operaciones involucradas son idempotentes. Por ejemplo, el método GET descrito a continuación es idempotente. Cuando estén implicadas operaciones no idempotentes, el navegador deberá consultar al usuario sobre los pasos a dar.

Las peticiones y las respuestas se empaquetan en los mensajes como cadenas de caracteres ASCII, aunque los recursos que pueden representarse como secuencias de bytes quizás tengan que ser comprimidos. El uso del texto como representación de datos externa simplifica el uso del HTTP por parte de los programadores de aplicaciones que trabajan directamente con el protocolo. En este contexto, una representación textual no añade mucha longitud a los mensajes.

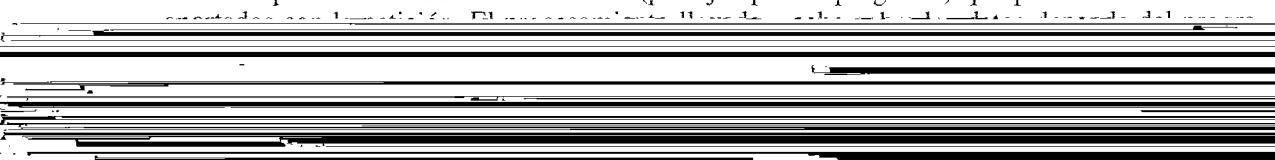
Los recursos considerados como datos se proporcionan en forma de estructuras de tipo MIME tanto en los argumentos como en los resultados. *Multipurpose Internet Mail Extensions* (Extensión de Correo Electrónico Multipropósito, MIME) es un estándar para enviar mensajes de correo electrónico compuestos por varias partes conteniendo a la vez, por ejemplo, texto, imágenes y sonido. Los datos van precedidos por su *tipo Mime*, de modo que el receptor podrá saber cómo gestionarlos. Un *tipo Mime* especifica un tipo y un subtipo, por ejemplo, *text/plain*, *text/html*, *image/gif*, *image/jpeg*. Los clientes también pueden especificar los tipos Mime que están dispuestos a aceptar.

Métodos HTTP: Cada petición de un cliente especifica el nombre de un método que habrá de ser aplicado al recurso en el servidor y el URL de dicho recurso. El mensaje de respuesta indica el estado de la petición. Las peticiones y las respuestas pueden contener también datos, el contenido de un formulario o la salida de un programa ejecutado en el servidor web. Los métodos considerados son los siguientes:

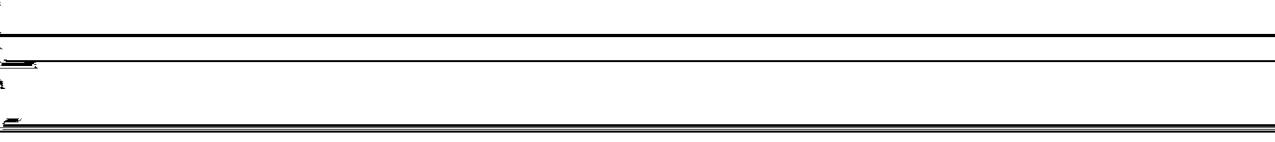
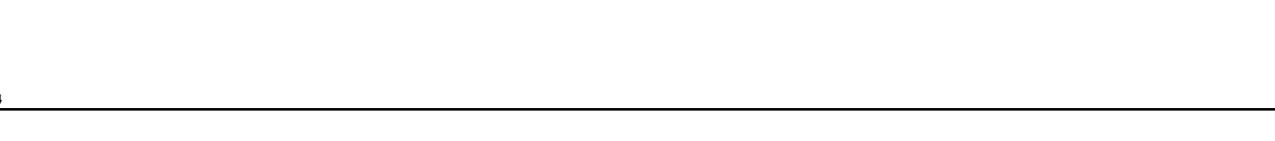
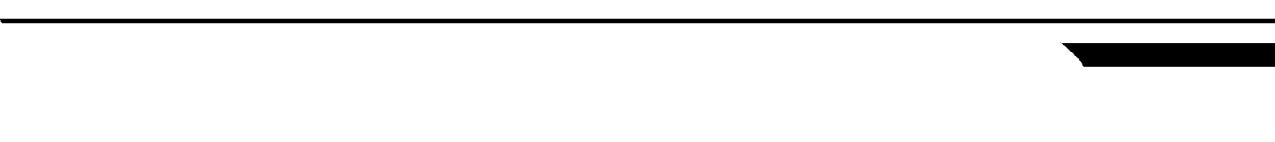
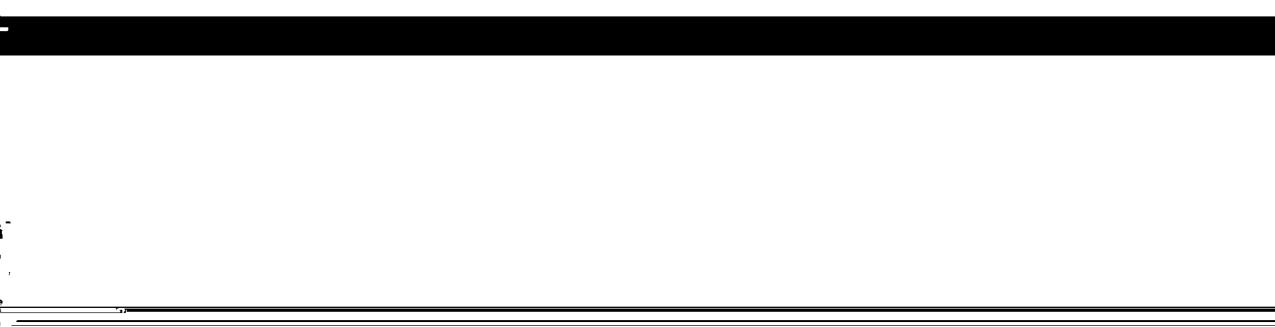
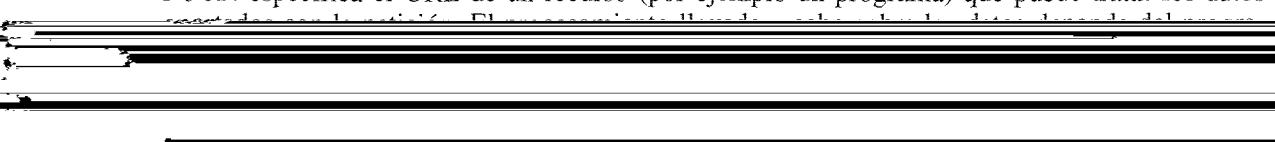
GET: pide el recurso cuyo URL se da como argumento. Si el URL se refiere a datos, entonces el servidor responderá enviando de vuelta los datos indicados por el URL. Si el URL se refiere a un programa, entonces el servidor web ejecutará el programa y devolverá su salida al cliente. Se pueden añadir argumentos al URL; por ejemplo, un GET se puede utilizar para enviar el contenido de un formulario a un programa *cgi* que los tomará como entrada. La operación GET puede condicionarse a la fecha de modificación del recurso indicado. El método GET también puede configurarse para obtener parte de los datos.

HEAD: esta petición es idéntica a GET, sólo que no devuelve datos. Sin embargo, devuelve toda la información sobre los datos, como el tiempo de la última modificación, su tipo o tamaño.

POST: especifica el URL de un recurso (por ejemplo un programa) que puede tratar los datos



POST: especifica el URL de un recurso (por ejemplo un programa) que puede tratar los datos



versión HTTP	código de estado	razón	cabeceras	cuadro del mensaje
HTTP/1.1	200	OK		datos del recurso

Figura 4.16. Mensaje HTTP Reply.

El cuadro del mensaje en los mensajes de petición o en los de respuesta contiene los datos asociados con la URL especificada en la petición. El cuadro del mensaje tiene sus propias cabeceras especificando información sobre los datos, como la longitud, el tipo Mime, el conjunto de caracteres, la codificación del contenido y la última fecha de modificación. El campo del tipo Mime concreta el tipo de los datos, por ejemplo *image/jpeg* o *text/plain*. El campo de codificación especifica el algoritmo de compresión utilizado.

4.5. COMUNICACIÓN EN GRUPO

El intercambio de mensajes entre iguales no es mejor modelo para la comunicación entre un proceso y un grupo de procesos, como por ejemplo se da en el caso de un servicio implementado por varios procesos en diferentes computadores, quizás para proporcionar tolerancia a fallos o mejorar la disponibilidad. Resulta más apropiada una *operación de multidifusión*; ésta es una operación que envía un único mensaje desde un proceso a cada uno de los miembros de un grupo de procesos, normalmente de modo que la pertenencia al grupo resulte transparente para el emisor. Existe un abanico de posibilidades respecto al comportamiento deseado de la multidifusión. La más simple no proporciona garantía alguna sobre la entrega del mensaje y el mantenimiento del orden de la emisión de los mismos.

Los mensajes de multidifusión proporcionan una infraestructura para construir sistemas distribuidos con las siguientes características:

1. *Tolerancia a fallos basada en servicios replicados:* un servicio replicado consta de un grupo de servidores. Las solicitudes de los clientes se dirigen a todos los miembros del grupo y cada uno de ellos realiza la misma operación. Incluso cuando varios de los miembros fallen, los clientes todavía serán servidos.
2. *Búsqueda de los servidores de descubrimiento en redes espontáneas:* la Sección 2.2.3 introdujo los servicios de descubrimiento en las redes espontáneas. Los servidores y los clientes pueden utilizar la multidifusión mensajes para localizar los servicios disponibles, y registrar sus interfaces, o para buscar las interfaces de otros servicios en el sistema distribuido.
3. *Mejores prestaciones basada en datos replicados:* los datos se replican para incrementar las prestaciones de un servicio; en algunos casos se colocan réplicas de los datos en los computadores de los usuarios. Cada vez que se producen cambios en los datos, el nuevo valor se comunica a los procesos que gestionan las réplicas de los datos mediante multidifusión.
4. *Propagación de las notificaciones de eventos:* la multidifusión a un grupo puede utilizarse para notificar a los procesos que algo ha sucedido. Por ejemplo, un sistema de noticias podría advertir a los usuarios interesados cada vez que se dirige un nuevo mensaje a un grupo de noticias particular. El sistema Jini utiliza multidifusión para informar a los usuarios interesados que se ha descubierto un nuevo servicio.

A continuación presentamos la multidifusión IP y después revisaremos si las necesidades de multidifusión mostradas arriba se pueden satisfacer por la multidifusión IP. Para aquellos casos en que no sea así, propondremos algunas propiedades añadidas a las de los protocolos de comunicación de grupos proporcionados por la multidifusión IP.

4.5.1. MULTIDIFUSIÓN IP. UNA IMPLEMENTACIÓN DE LA COMUNICACIÓN EN GRUPO

Esta sección discute la multidifusión IP y presenta el API de Java correspondiente a través de la clase *MulticastSocket*.

◊ **Multidifusión IP.** La multidifusión IP se construye sobre el protocolo Internet, IP. Tenga en cuenta que los paquetes IP se dirigen a los computadores; mientras que los puertos pertenecen a los niveles TCP y UDP. La multidifusión IP permite que el emisor transmita un único paquete IP a un conjunto de computadores que forman un grupo de multidifusión. El emisor no tiene que estar al tanto de las identidades de los receptores individuales y del tamaño del grupo. Los grupos de multidifusión se especifican utilizando las direcciones Internet de la clase D (véase la Figura 3.16); esto es, una dirección cuyos primeros cuatro bits son 1110 en IPv4.

El convertirse en miembro de un grupo de multidifusión permite al computador recibir los paquetes IP enviados al grupo. La pertenencia a los grupos de multidifusión es dinámica, permitiéndose que los computadores se apunten o se borren a un número arbitrario de grupos en cualquier instante. Es posible enviar datagramas a un grupo de multidifusión sin pertenecer a él.

En el nivel de programación de aplicación, la multidifusión sólo es accesible vía UDP. Un programa de aplicación ejecuta multidifusión enviando datagramas UDP con la dirección de multidifusión y el número de puerto de la forma usual. Es posible apuntarse a un grupo de multidifusión haciendo que su conector pertenezca al grupo, habilitándolo para recibir los mensajes dirigidos al grupo. En el nivel IP, un computador pertenece a un grupo de multidifusión cuando uno o más de sus procesos tienen conectores que pertenezcan a ese grupo. Cuando llega un mensaje de multidifusión a un computador, envía copias del mismo a los conectores locales que pertenecen a la dirección de multidifusión destino del mensaje y están limitadas por el número de puerto especificado. Los siguientes detalles son específicos de IPv4:

Routers multidifusión: los paquetes IP pueden multidifundirse tanto en la red local como en toda Internet. La multidifusión local utiliza la capacidad de multidifusión de la red local, como por ejemplo una Ethernet. La multidifusión dirigida a Internet hace uso de las posibilidades de multidifusión de los routers (encaminadores), los cuales reenvían los datagramas únicamente a otros routers de redes con miembros de ese grupo, donde serán multidifundidos a los miembros locales. Para limitar la distancia de propagación de un datagrama de multidifusión, el emisor puede especificar el número de routers que puede cruzar; llamado tiempo de vida (*time to live*, TTL). Para entender cómo conocen los routers qué otros routers tienen miembros de un grupo de multidifusión véase Comer [1995].

Reserva de direcciones de multidifusión: las direcciones de multidifusión se pueden reservar de forma temporal o permanentemente. Existen grupos permanentes incluso cuando no tengan ningún miembro; y sus direcciones son asignadas arbitrariamente por la autoridad de Internet en el rango 224.0.0.1 a 224.0.0.255. Por ejemplo, la primera dirección corresponde a todos los hosts multidifusión.

El resto de las direcciones de multidifusión están disponibles para su uso por parte de grupos temporales, los cuales deben ser creados antes de su uso y dejar de existir cuando todos los miembros los hayan dejado. Cuando se crea un grupo temporal, se necesita una dirección de multidifusión libre para evitar los conflictos con otros grupos existentes. El protocolo de multidifusión IP no resuelve este problema. Cuando los usuarios sólo necesitan comunicarse de forma local, ponen el TTL a un valor pequeño, haciendo difícil que entre en conflicto con la dirección de otros grupos. Sin embargo, los programas que tienen que utilizar multidifusión IP a través de Internet necesitan una solución a este problema. El programa de directorio de sesiones (sd) sirve para arrancar o unirse a una sesión de multidifusión [mice.ed.ac.uk, [session directory](#)]. Proporciona una herramienta con una interfaz interactiva que permite que los usuarios

```
import java.net.*;
import java.io.*;
public class participanteMultidifusion{
    public static void main(String args[ ]){
        // los argumentos dan el mensaje y la dirección del grupo (por ejemplo "228.5.6.7")
        try {
            InetAddress grupo = InetAddress.getByName(args[1]);
            MulticastSocket s = new MulticastSocket(6789);
            s.joinGroup(grupo);
            byte [ ] m = args[0].getBytes( );
            DatagramPacket mensajeSalida =
                new DatagramPacket(m, m.length, grupo, 6789);
            s.send(mensajeSalida);
            // conseguir mensajes de otros miembros del grupo
            byte [ ] bufer = new byte[1000];
            for (int i = 0; i < 3; i++) {
                DatagramPacket mensajeEntrada =
                    new DatagramPacket(bufer, bufer.length);
                s.receive(mensajeEntrada);
                System.out.println("Recibido:" + new String(mensajeEntrada.getData( )));
            }
            s.leaveGroup(grupo);
        }catch (SocketException e){System.out.println("Socket:" + e.getMessage( ));}
        catch (IOException e){System.out.println("IO:" + e.getMessage( ));}
    }
}
```

Figura 4.17. Un participante en multidifusión se apunta a un grupo y envía y recibe datagramas.

puedan detectar las sesiones de multidifusión existentes y anunciar su propia sesión, especificando el tiempo y la duración de la reserva (elige una dirección de multidifusión para nuevas sesiones).

◊ **Modelo de fallo para la multidifusión de datagramas.** La multidifusión de datagramas sobre la multidifusión IP tiene las mismas características de fallo que los datagramas UDP; esto es, sufren de fallos de omisión. El efecto en una multidifusión es que no se garantiza que los mensajes sean entregados a cualquier miembro particular del grupo en presencia de incluso un único fallo de omisión. Esto es, alguno, pero no todos los miembros del grupo pueden recibir el mensaje. Esto puede denominarse multidifusión *no fiable*, ya que no existe garantía de que un mensaje sea entregado a cualquier miembro del grupo. La multidifusión fiable se discutirá en el Capítulo 11.

◊ **API Java para la multidifusión IP.** El API Java para la multidifusión IP proporciona una interfaz de datagramas para la multidifusión IP a través de la clase *MulticastSocket*, que es una subclase de *DatagramSocket* con la capacidad adicional de ser capaz de pertenecer a grupos de multidifusión. La clase *MulticastSocket* proporciona dos constructores alternativos, permitiendo crear los conectores utilizando un número de puerto local concreto (por ejemplo el 6789, como en la Figura 4.17), o cualquier puerto local libre. Un proceso puede pertenecer a un grupo de multidifusión con una dirección de multidifusión dada invocando el método *joinGroup* de su conector de multidifusión. Como consecuencia, el conector pertenecerá a un grupo de multidifusión en un puerto dado y recibirá los datagramas enviados por los procesos en otros computadores a ese grupo en ese puerto. Un proceso puede dejar un grupo dado invocando el método *leaveGroup* de su conector multidifusión.

En el ejemplo de la Figura 4.17, los argumentos del método *main* especifican un mensaje a ser multidifundido y la dirección del grupo de multidifusión (por ejemplo, «228.5.6.7»). Después de

apuntarse a ese grupo. el proceso hace una instancia de *DatagramPacket* conteniendo el mensaje y

3. *Mejores prestaciones mediante datos replicados*: considere el caso en el que los datos replicados son distribuidos a través de mensajes multidifusión, en lugar de distribuir las operaciones sobre los datos. El efecto de los mensajes perdidos y la inconsistencia en la ordenación dependerá del método de replicación y de la importancia de que todas las réplicas estén actualizadas. Por ejemplo, las réplicas de los grupos de noticias no tienen que ser necesariamente consistentes con las demás en cualquier instante de tiempo (los mensajes pueden incluso aparecer en orden diferente, pero los usuarios pueden asumirlo).
4. *Propagación de las notificaciones de eventos*: esta particular aplicación determina la calidad necesaria de la multidifusión. Por ejemplo, el servicio de anuncios de Jini informa a las partes interesadas sobre los nuevos servicios disponibles utilizando multidifusión IP haciendo anuncios a intervalos frecuentes.

Estos ejemplos sugieren que algunas aplicaciones requieren un protocolo de multidifusión más fiable que la multidifusión IP. En concreto, existe la necesidad de la *multidifusión fiable*; en la cual cualquier mensaje transmitido o bien es recibido por todos los miembros de un grupo, o no lo recibe ninguno de ellos. Los ejemplos también sugieren que algunas aplicaciones tienen requerimientos fuertes de ordenación, que en el caso más estricto se denomina *multidifusión totalmente ordenada*, en la cual todos los mensajes transmitidos a un grupo llegan a todos los miembros en el mismo orden.

El Capítulo 11 definirá y mostrará cómo implementar la multidifusión *fiable* y varias garantías de orden útiles, incluyendo la multidifusión totalmente ordenada.

apuntarse a ese grupo. el proceso hace una instancia de *DatagramPacket* conteniendo el mensaje y

4.6 CASO DE ESTUDIO: COMUNICACIÓN ENTRE PROCESOS EN UNIX

Las primitivas IPC en las versiones UNIX BSD 4.x son proporcionadas como llamadas al sistema que son implementadas como una capa sobre los protocolos Internet TCP y UDP. Los destinos de los mensajes se especifican como direcciones de conectores; una dirección de conector consta de una dirección Internet y un número de puerto local.

Las operaciones de comunicación entre procesos se basan en la abstracción de conectores descrita en la Sección 4.2.2. Como se describía allí, los mensajes se colocan en una cola en el conector emisor hasta que el protocolo de red los transmite, y allí permanecen hasta que llega el correspondiente reconocimiento, si es que el protocolo así lo requiere. Cuando llega un mensaje, se coloca en una cola en el conector receptor hasta que el proceso destinatario realiza la correspondiente llamada al sistema para recogerlo.

Cualquier proceso puede crear un conector para utilizarlo en la comunicación con otro proceso. Esto se realiza invocando a la llamada al sistema *socket*, cuyos argumentos especifican el dominio de comunicación (normalmente Internet), el tipo (datagrama o flujo) y en algunas ocasiones un protocolo particular. El protocolo (por ejemplo, TCP o UDP) es seleccionado normalmente por el sistema dependiendo de si el tipo de comunicación es de datagramas o de streams.

La llamada *socket* devolverá un descriptor mediante el cual referirse al conector en las subsiguientes llamadas al sistema. El conector pervive hasta que se cierra (*close*) o mientras exista algún proceso con su descriptor. Se puede utilizar un par de conectores para la comunicación en ambas direcciones o en cualquier dirección entre procesos en el mismo o en computadores diferentes.

Antes de poder comunicar un par de procesos, el receptor debe *enlazar* su descriptor de conector con una dirección de conector. El emisor también debe enlazar su descriptor de conector con una dirección de conector si necesita responder. Para este propósito se utiliza la llamada al sistema *bind*; cuyos argumentos son el descriptor del conector y una referencia a una estructura que contiene la dirección del conector con la que se va a ligar el conector. Una vez que un conector está ligado a una dirección, ésta no puede cambiar.

Podría parecer más razonable tener una única llamada al sistema tanto para crear un conector como para ligarlo a una dirección, tal y como sucede en el API Java. La supuesta ventaja de tener dos llamadas separadas es que pueden ser útiles los conectores sin dirección.

Algunas direcciones son públicas en el sentido de que pueden ser utilizadas como destinos por cualquier proceso. Después de que un proceso ha ligado su conector a una dirección de conector, el conector puede ser apuntado indirectamente por otro proceso refiriéndose a la dirección de conector apropiada. Cualquier proceso, por ejemplo un servidor que planea recibir mensajes a través de su conector, debe primero enlazar ese conector a una dirección de conector y hacer que la dirección sea conocida por los potenciales clientes.

4.6.1. COMUNICACIÓN DE DATAGRAMAS

Para poder enviar datagramas, se identifica el par de conectores cada vez que se realiza una comunicación. Esto se logra en el proceso emisor utilizando su descriptor de conector local y la dirección del conector receptor cada vez que envía un mensaje.

Esto se muestra en la Figura 4.18, en la que se han simplificado los detalles de los argumentos.

- Ambos procesos utilizan la llamada *socket* para crear un conector y conseguir un descriptor para él. El primer argumento de *socket* especifica el dominio de comunicación como el dominio Internet, y el segundo argumento indica que se va a necesitar una comunicación de datagramas. El último argumento de la llamada *socket* puede utilizarse para especificar un protocolo particular, pero si se pone a cero produce que el sistema seleccione el protocolo adecuado (UDP en este caso).
- Ambos procesos, entonces, utilizan la llamada *bind* para enlazar sus conectores a las direcciones de conector. El proceso emisor enlaza su conector a una dirección de conector dada por cualquier puerto local libre. El proceso receptor enlaza su conector a una dirección de conector que contiene un puerto de servidor que debe ser conocido por el emisor.
- El proceso emisor utiliza la llamada *sendto*, con argumentos que especifican el socket a través del cual va a ser enviado el mensaje, el mensaje mismo y (una referencia a la estructura que contiene) la dirección del conector destino. La llamada *sendto* pasa el mensaje a las capas subyacentes UDP e IP y devuelve el número de bytes enviados. Como hemos solicitado un servicio de datagramas, el mensaje es transmitido a su destino sin acuse de recibo. Si el mensaje es demasiado grande para ser enviado, se produce un error que provoca la devolución del control (y el mensaje no será transmitido).
- El proceso receptor utiliza la llamada *recvfrom* con argumentos que especifican el conector local en el que se recibirá el mensaje, las direcciones de memoria en las que se almacenará el

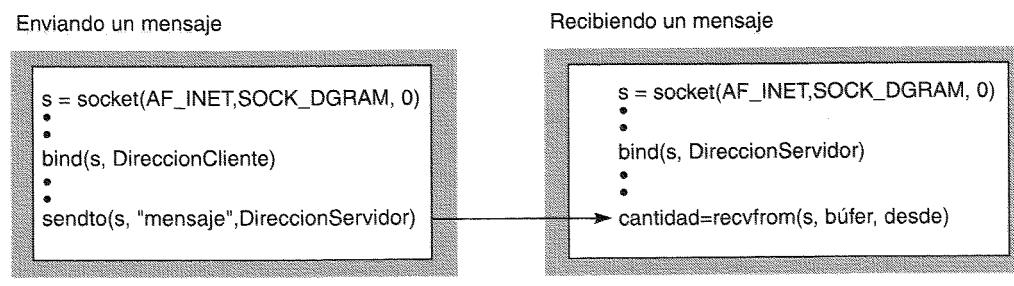


Figura 4.18. Conectores utilizados para datagramas.

mensaje y (una referencia a la estructura que contiene) la dirección de conector del conector emisor. La llamada *recvfrom* tomará el primer mensaje en la cola del conector, o si la cola está vacía esperará a que llegue uno.

La comunicación se produce exclusivamente cuando un *sendto* en un proceso dirige su mensaje al conector utilizado por *recvfrom* en otro proceso. En una comunicación cliente-servidor, no existe necesidad de que los servidores tengan conocimiento previo de las direcciones de los conectores de los clientes, ya que la operación *recvfrom* proporciona la dirección del emisor con cada mensaje que entrega. Las propiedades de la comunicación de datagramas en UNIX es la misma que la descrita en la Sección 4.2.3.

4.6.2. COMUNICACIÓN CON STREAMS

Antes de utilizar el protocolo de streams, dos procesos deben establecer una conexión entre sus pares de conectores. El acuerdo es asimétrico porque uno de los conectores estará escuchando peticiones de conexión y el otro estará preguntando por una conexión, según se describe en la Sección 4.2.4. Una vez que un par de conectores han sido conectados, pueden utilizarse para transmitir datos en ambas o en cualquier dirección. Esto es, se comportan como streams en los que cualquier dato disponible se lee inmediatamente en el mismo orden en que fue escrito y no existen indicaciones de fronteras entre los mensajes. Sin embargo, existe una cola limitada en el conector receptor y el receptor se bloqueará si la cola está vacía; y el emisor se bloqueará si la cola está llena.

Para la comunicación entre clientes y servidores, los clientes solicitan conexiones y los servidores que escuchan esas peticiones las aceptan. Cuando una conexión es aceptada, automáticamente UNIX crea un nuevo conector y lo empareja con el conector del cliente de modo que el servidor puede continuar escuchando las peticiones de conexión de los demás clientes a través del conector original. Un par de conector de stream conectados se pueden utilizar en una comunicación de stream hasta que se cierre la conexión.

La comunicación de streams se muestra en la Figura 4.19, en la que se han simplificado los detalles relativos a los argumentos. La figura no muestra al servidor cerrando el conector en el que escucha. Normalmente, un servidor primero escucha y acepta una conexión y entonces crea un nuevo proceso para comunicarse con el cliente. Mientras tanto, continúa escuchando en el proceso original.

- El servidor, o proceso en escucha, utiliza primero la operación *socket* para crear un conector de flujo y después la operación *bind* para enlazar su conector a la dirección del conector de servidor. El segundo argumento de la llamada al sistema *socket* es *SOCK_STREAM*, para indicar que se requiere una comunicación de streams. El tercer argumento se deja a cero, de

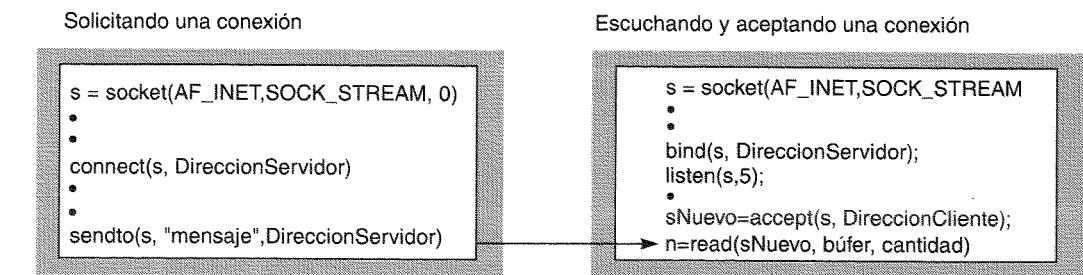


Figura 4.19. Conectores utilizados para streams.

modo que se seleccione el protocolo TCP/IP de forma automática. Utiliza la operación *listen* para escuchar en su conector las peticiones de conexión de los clientes. El segundo argumento de *listen* especifica el número máximo de peticiones de conexión que admite la cola de espera de ese conector.

- El servidor utiliza la llamada al sistema *accept* para aceptar una conexión solicitada por un cliente y obtener un nuevo conector para la comunicación con el cliente. El conector original continúa en uso para aceptar futuras peticiones de conexión de otros clientes.
- El proceso cliente utiliza la operación *socket* para crear un conector de stream y entonces utiliza la llamada al sistema *connect* para solicitar una conexión a través de la dirección de conector del proceso en escucha. Como la llamada al sistema *connect* enlaza automáticamente el conector con una dirección de conector, no es necesario un enlace previo.
- Después de que se ha establecido una conexión, ambos procesos pueden utilizar las operaciones *write* y *read* en sus respectivos conectores para enviar y recibir secuencias de bytes a través de la conexión. La operación *write* es similar a la operación de escritura en archivos. Especifica el mensaje a enviar al conector. Confía el mensaje a los protocolos TCP/IP subyacentes y devuelve el número de bytes enviados. La operación *read* recibe caracteres en su búfer y devuelve el número de bytes recibidos.

Las propiedades de la comunicación de streams en UNIX son las mismas que las descritas en la Sección 4.2.4.

4.7. RESUMEN

La primera sección de este capítulo muestra que existen dos alternativas a la hora de construir los bloques con los que elaborar los protocolos de Internet. Existe una interesante relación de compromiso entre estos dos protocolos: UDP proporciona la posibilidad de un simple paso de mensajes que adolece de fallos de omisión pero no lleva asociada penalización en las prestaciones. En el otro lado, en buenas condiciones, TCP garantiza la entrega de mensajes pero a cambio de tener mensajes adicionales y una mayor latencia y costos de almacenamiento.

La segunda sección aborda dos estilos alternativos de empaquetamiento de datos. CORBA y sus predecesores eligen empaquetar los datos que serán utilizados por receptores con un conocimiento previo de sus componentes. Por el contrario, cuando Java serializa datos, incluye la descripción completa del contenido, permitiendo que los receptores puedan reconstruirlo exclusivamente a partir del contenido. Otra gran diferencia es que CORBA necesita una especificación de los tipos de datos a ser empaquetados (en IDL) para generar una especificación de los tipos de datos de los elementos de información a empaquetar; mientras que Java utiliza la reflexión tanto para serializar datos como para deserializarlos a partir de la forma serializada.

La sección dedicada a los protocolos petición-respuesta muestra que se puede construir un protocolo específico para sistemas distribuidos efectivo basándose sobre datagramas UDP. El mensaje de respuesta se considera como un reconocimiento del mensaje de petición, evitando de este modo las sobrecargas de los mensajes de reconocimiento adicionales. El protocolo se puede hacer más fiable si fuera necesario. Tal como es, no existe garantía de que el envío de un mensaje de petición desencadene la ejecución de un método (para algunas aplicaciones esto puede resultar suficiente). Pero se puede conseguir una fiabilidad adicional haciendo uso de la identificación de los mensajes y de la retransmisión de los mensajes, de modo que nos aseguremos de que los métodos serán ejecutados. Para servicios con operaciones idempotentes, esto es suficiente. Sin embargo, otras aplicaciones necesitan que los mensajes de respuesta sean transmitidos sin tener que volver a ejecutar el método solicitado. Esto se puede conseguir utilizando un historial. Esto demuestra que resulta una buena idea construir distintos protocolos que se ajusten a las necesidades de diferentes

clases de aplicaciones en lugar de construir un único protocolo superfiel para su uso general, ya que esto último puede conducir a peores prestaciones en el caso de uso general, en el que raramente se dan fallos.

Los mensajes de multidifusión se utilizan en la comunicación entre los miembros de un grupo de procesos. El protocolo multidifusión IP proporciona un servicio de multidifusión tanto para redes de área local como para Internet. Esta forma de multidifusión tiene el mismo esquema de fallos que los datagramas UDP, pero aunque sufre de fallos de omisión es una herramienta útil para muchas aplicaciones de multidifusión. Otras aplicaciones tienen unos requisitos más exigentes; en particular aquellas en la que la multidifusión tiene que ser atómica, esto es, debe producirse una entrega a todos o a ninguno. Los requisitos más restrictivos relacionados con la multidifusión están asociados a la entrega ordenada de los mensajes, el más exigente de todos exige que todos los miembros del grupo reciban los mensajes en el mismo orden.

EJERCICIOS

- 4.1. ¿Resulta razonablemente útil que un puerto tenga varios receptores?
- 4.2. Un servidor crea un puerto que utiliza para recibir peticiones de sus clientes. Discuta los problemas de diseño concernientes a las relaciones entre el nombre de este puerto y los nombres utilizados por los clientes.
- 4.3. Los programas de la Figuras 4.3 y 4.4 están disponibles en cdk3.net/ipc. Utilícelos para hacer un prototipo que pruebe las condiciones en las que los datagramas son, en ocasiones, desecharados. Consejo: el programa cliente debería ser capaz de variar el número y el tamaño de los mensajes que envía; el servidor debería detectar cuándo se ha perdido un mensaje de un cliente particular.
- 4.4. Utilice el programa de la Figura 4.3 para construir un programa cliente que lea repetidamente un línea de entrada del usuario, la envíe a un servidor en un datagrama UDP, y entonces reciba un mensaje del servidor. El cliente asociará un tiempo de espera límite con su conector, de modo que pueda informar al usuario cuando el servidor no responda. Pruebe este cliente con el servidor de la Figura 4.4.
- 4.5. Los programas de las Figuras 4.5 y 4.6 están disponibles en cdk3.net/ipc. Modifíquelos de modo que el cliente obtenga de forma repetida una línea del usuario y la escriba en el flujo que el servidor leerá repetidamente, imprimiendo el resultado de la lectura. Compare los datos enviados utilizando un datagrama UDP y un stream.
- 4.6. Utilice los programas desarrollados en el Ejercicio 4.5 para probar el efecto causado sobre el emisor cuando el receptor se cae y viceversa.
- 4.7. El protocolo Sun XDR empaqueta los datos convirtiéndolos al estándar big-endian antes de la transmisión. Discuta las ventajas e inconvenientes de este método comparándolo con el CDR de CORBA.
- 4.8. El protocolo Sun XDR alinea cada valor primitivo en posiciones múltiples de cuatro bytes, mientras que el CORBA CDR alinea un valor primitivo de tamaño *n* en posiciones múltiplos de *n*. Discuta ambos métodos con respecto a la elección de los tamaños ocupados por los valores primitivos.

• Para cada una de las siguientes preguntas, indica la información explícita sobre los tipos de datos en CORBA-CDR?

- 4.19. Discuta si las siguientes operaciones son idempotentes o no:

 - Apretar el botón de solicitud de un ascensor.
 - Escribir datos en un archivo.
 - Añadir datos a un archivo.

¿Puede ser una condición necesaria para la idempotencia el que la operación no deba estar asociada con ningún estado?

4.20. Explique las opciones de diseño que son relevantes para minimizar la cantidad de datos de respuesta almacenados en un servidor. Compare las necesidades de almacenamiento cuando se utilizan protocolos RR y RRA.

4.21. Suponga que se está utilizando el protocolo RRA. ¿Cuánto tiempo deberían retener los servidores los mensajes de datos respuesta no reconocidos? ¿Deberían los servidores enviar las respuestas repetidamente en un intento de recibir un reconocimiento?

4.22. ¿Por qué el número de mensajes intercambiados en un protocolo puede tener más influencia en las prestaciones que la cantidad de datos enviados? Diseñe una variante del protocolo RRA en el que los acuses de recibo vayan adheridos, esto es, transmitidos en el mismo mensaje que la siguiente petición que resulte apropiada, y de otro modo enviados como un mensaje separado. (Consejo: utilice un cronómetro extra en el cliente.)

4.23. La multidifusión IP proporciona un servicio que adolece de fallos de omisión. Construya un prototipo (puede estar basado en el programa de la Figura 4.17) con el que descubrir las condiciones bajo las cuales un mensaje de multidifusión es desecharido a veces por uno de los miembros del grupo. El prototipo debería estar diseñado para permitir procesos emisores múltiples.

4.24. Esboce el diseño de un esquema que utiliza la retransmisión de mensajes con multidifusión IP para solucionar el problema de los mensajes perdidos. Su esquema deberá tener en cuenta los siguientes puntos:

 - i) Existen múltiples emisores.
 - ii) Generalmente sólo una pequeña porción de mensajes son desecharados.
 - iii) En contra de lo que sucede en el protocolo petición-respuesta, los receptores no tienen necesariamente que enviar un mensaje dentro de un rango de tiempo.

Suponga que los mensajes no desecharados llegan en el orden de emisión.

4.25. Su solución al Ejercicio 4.24 debería haber solucionado el problema de los mensajes desecharados en la multidifusión IP. ¿En qué sentido su solución difiere de la definición de multidifusión fiable?

4.26. Contemple un escenario en el cual las multidifusiones enviadas por clientes diferentes son entregadas en órdenes diferentes a los miembros de dos grupos. Suponga que se está utilizando alguna forma de retransmisión de mensajes, pero que esos mensajes que no son desecharados llegan en el orden de emisión. Sugiera el modo en que los receptores pueden remediar esta situación.

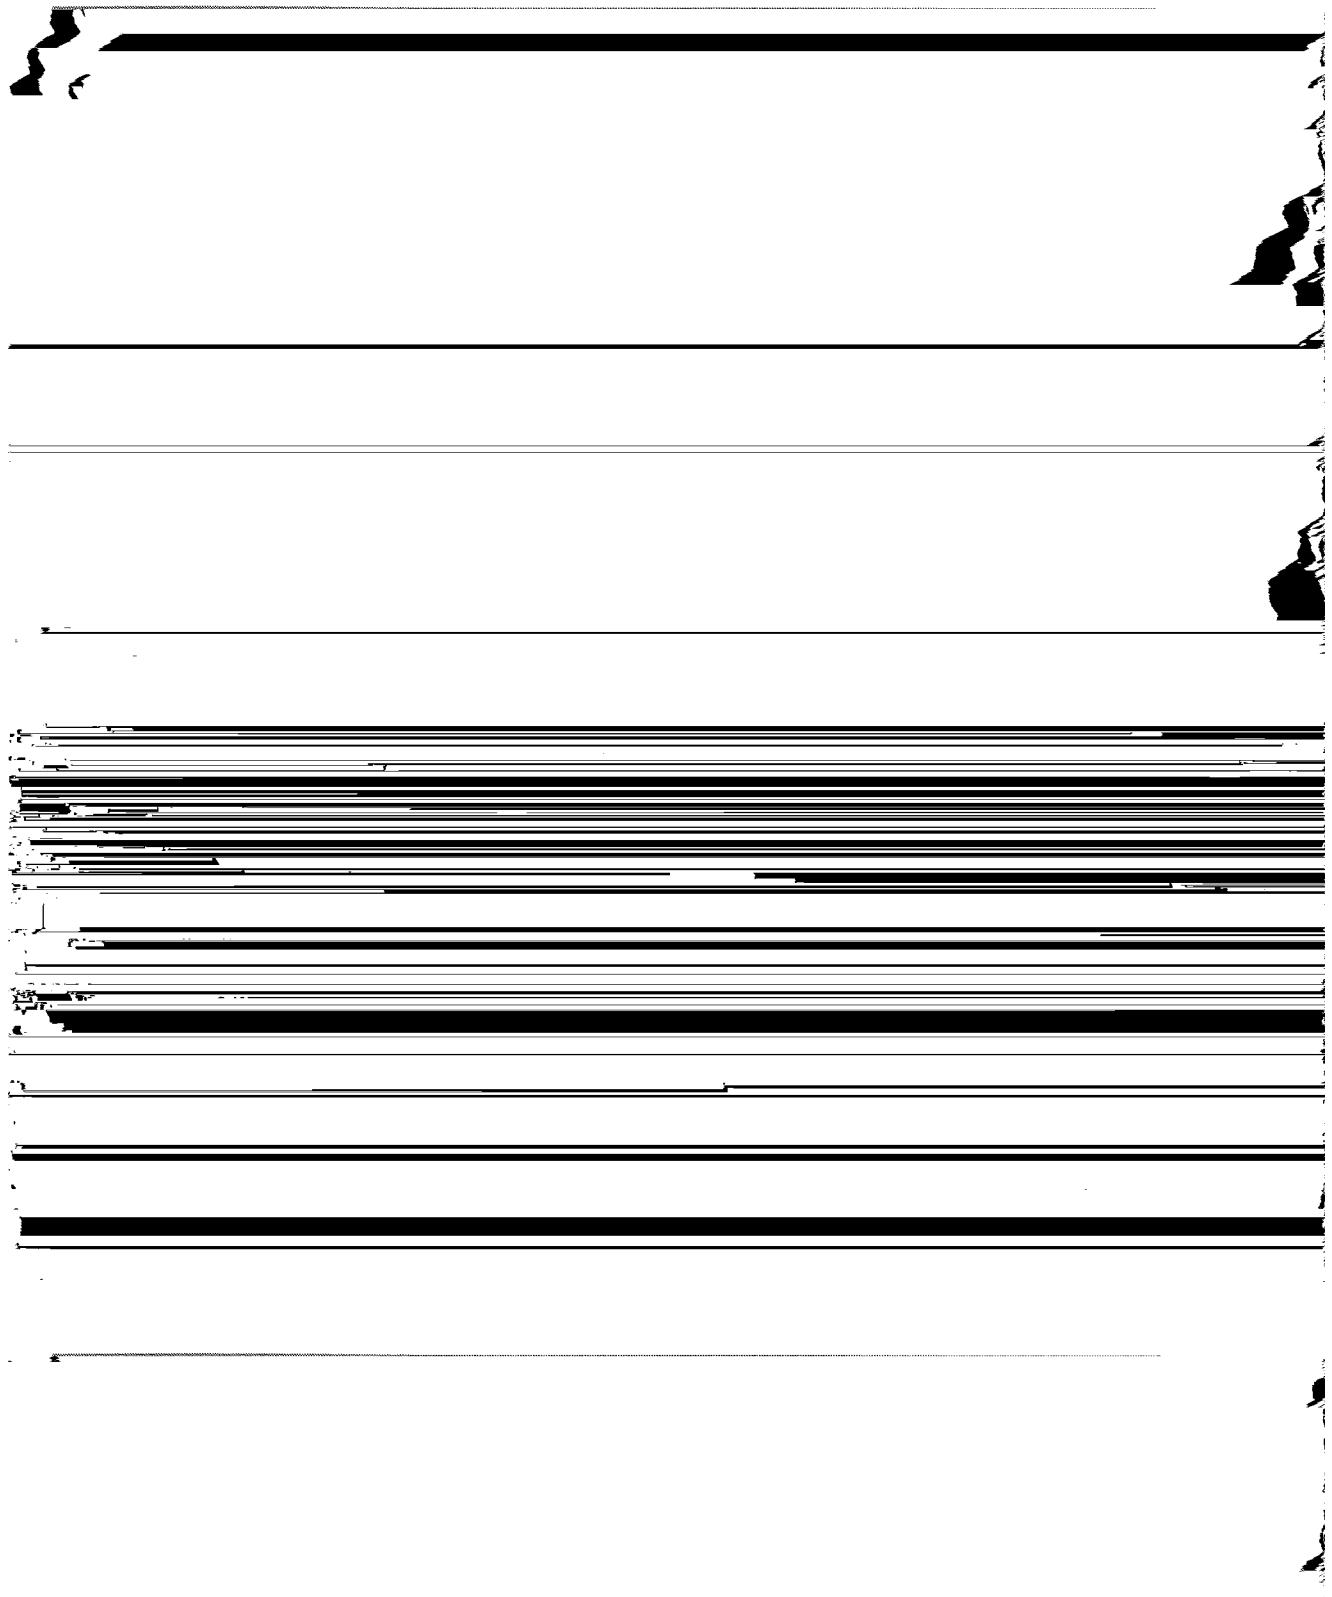
4.27. Defina la semántica y diseñe un protocolo para una forma de interacción petición-respuesta para un grupo, utilizando por ejemplo multidifusión IP.

152 Sistemas distribuidos

40 _____ Dado que la tabla **información** contiene sobre los tipos de datos en **COPRA CDR**?

crito en la Sección 4.3.2. El algoritmo debería mostrar cuándo son definidos o sustituidos los apuntadores para las clases y las instancias. Describa la forma serializada que su algoritmo producirá al serializar una instancia de la siguiente clase *Pareja*.

ORIENTACAO DIRETORIAL DA SOCIEDADE



ware de los computadores. Algunas formas de middleware permiten que los componentes separados estén escritos en diferentes lenguajes de programación.

Transparencia frente a ubicación: En RPC, el cliente que llama a un procedimiento no puede discernir si el procedimiento se ejecuta en el mismo proceso o en un proceso diferente, posiblemente en otro computador. El cliente tampoco necesita conocer la ubicación del servidor. Análogamente, en RMI el objeto que realiza la invocación no podrá decírnos si el objeto que invoca es local o no, y tampoco requiere conocer su ubicación. Asimismo, en los programas distribuidos basados en eventos, los objetos que generan eventos y los objetos que reciben notificaciones de esos eventos tampoco necesitan estar al corriente de sus ubicaciones respectivas.

Protocolos de comunicación: Los protocolos que dan soporte a las abstracciones del middleware son independientes de los protocolos de transporte subyacentes. Por ejemplo el protocolo petición-respuesta puede estar implementado tanto sobre UDP como sobre TCP.

Hardware de los computadores: En la Sección 4.3 se describen dos estándares comunes para la representación externa de datos. Se emplean en el empaquetado y desempaquetado de mensajes. Éstos ocultan las diferencias de arquitectura en el hardware, como el ordenamiento de los bytes.

Sistemas operativos: Las abstracciones de mayor nivel que provee la capa de middleware son independientes de los sistemas operativos subyacentes.

Utilización de diversos lenguajes de programación: Diversos middleware se diseñan para permitir que las aplicaciones distribuidas sean escritas en más de un lenguaje de programación. En particular CORBA (véase el Capítulo 17) permite a los clientes escritos en un lenguaje invocar métodos en objetos que viven en programas servidores escritos en otro lenguaje. Esto se obtiene empleando un *lenguaje de definición de interfaz* o IDL (*interface definition language*) para definir interfaces. IDL se discute en la siguiente sección.

5.1.1. INTERFACES

La mayoría de los lenguajes de programación modernos proporcionan medios para organizar un programa en conjuntos de módulos que puedan comunicarse unos con otros. La comunicación entre los módulos se puede realizar mediante llamadas a procedimientos entre los módulos o accediendo directamente a las variables de otro módulo. Para controlar las interacciones posibles entre los módulos, se define explícitamente una *interfaz* para cada módulo. Los módulos se implementan de forma que se oculte toda la información excepto aquella que se haga disponible a través de su interfaz. De este modo, mientras la interfaz permanezca inalterada, la implementación podrá cambiar sin afectar a los usuarios del módulo.

◊ **Las interfaces en los sistemas distribuidos.** En un programa distribuido, los módulos pueden lanzarse en procesos separados. No es posible para un módulo que se ejecuta en un proceso acceder a las variables de un módulo que está en otro proceso. Asimismo, la interfaz de un módulo escrita para RPC o RMI no puede especificar el acceso directo a variables. Advierta que las interfaces en IDL de CORBA pueden especificar atributos, lo que parece violar esta regla. Sin embargo, los atributos no son accedidos directamente sino mediante ciertos procedimientos de escritura y lectura que se añaden automáticamente a la interfaz.

Los mecanismos de paso de parámetros, por ejemplo la llamada por valor y la llamada por referencia, utilizados en las llamadas a procedimientos locales, no son adecuados cuando el que llama y el procedimiento llamado están en procesos diferentes. La especificación de un método o procedimiento en la interfaz de un módulo en un programa distribuido describe los parámetros como *entrada* o *salida* o, a veces, ambos. Los parámetros de *entrada* se pasan al módulo remoto mediante el envío de los valores de los argumentos en el mensaje de petición y posteriormente se

proporcionan como argumentos a la operación que se ejecutará en el servidor. Los parámetros de

```
// En el archivo Persona.idl
struct Persona {
    string nombre;
    string lugar;
    long año;
};

interface ListaPersonas {
    readonly attribute string nombrelista;
    void añadePersona(in Persona p);
    void damePersona(in string nombre, out Persona p);
    long número();
};
```

Figura 5.2. Ejemplo en CORBA IDL.

que emplea la sintaxis del lenguaje C y se denomina IDL; y DCOM IDL que se basa en DCE IDL [Box 1998] y que se emplea en el Modelo de Objetos Componentes Distribuido (*Distributed Component Object Model*) de Microsoft.

5.2. COMUNICACIÓN ENTRE OBJETOS DISTRIBUIDOS

El modelo basado en objetos para un sistema distribuido presentado en el Capítulo 1 extiende el modelo soportado por los lenguajes de programación con orientación al objeto para hacerlo aplicable a los objetos distribuidos. Esta sección aborda el tema de la comunicación entre objetos distribuidos mediante RMI. El material se presenta bajo los siguientes encabezados:

El modelo de objeto: una breve revisión de los aspectos relevantes del modelo de objetos, adecuado para el lector con un conocimiento básico de un lenguaje de programación con orientación al objeto, por ejemplo Java o C++.

Objetos distribuidos: una presentación de los sistemas distribuidos basados en objetos, donde se argumenta la conveniencia del modelo de objetos para los sistemas distribuidos.

El modelo de objetos distribuido: una discusión de las extensiones necesarias del modelo de objetos para dar soporte a los objetos distribuidos.

Cuestiones de diseño: un conjunto de razonamientos sobre las alternativas de diseño:

1. Las invocaciones locales se ejecutan exactamente una vez, pero, ¿qué semánticas de invocación adecuadas son posibles para las invocaciones remotas?
2. ¿Cómo puede hacerse que la semántica de un RMI sea similar a la invocación de métodos locales, y qué diferencias no podemos eliminar?

Implementación: una explicación de cómo podría diseñarse una capa de middleware sobre el protocolo petición-respuesta para dar soporte a RMI entre aplicaciones con objetos distribuidos al nivel de aplicación.

Compactación automática de la memoria distribuida: una presentación de un algoritmo para la compactación automática de la memoria (*garbage collection*) que sea adecuada para su uso con la implementación de RMI.

5.2.1. EL MODELO DE OBJETOS

Un programa orientado al objeto, por ejemplo en Java o C++, consta de un conjunto de objetos que interaccionan entre ellos, cada uno de los cuales consiste en un conjunto de datos y un conjun-

denomina *compactación automática de la memoria*. Cuando un lenguaje (por ejemplo C++) no da soporte para la compactación automática de la memoria, el programador debe encargarse de la liberación del espacio asignado a los objetos. Ésta puede ser una gran fuente de errores.

5.2.2. OBJETOS DISTRIBUIDOS

El estado de un objeto consta de los valores de sus variables de instancia. En el paradigma de la programación basada en objetos, el estado de un programa se encuentra fraccionado en partes separadas, cada una de las cuales está asociada con un objeto. Dado que los programas basados en objetos están fraccionados lógicamente, la distribución física de los objetos en diferentes procesos o computadores de un sistema distribuido es una extensión natural.

Los sistemas de objetos distribuidos pueden adoptar la arquitectura cliente-servidor. Es este caso los objetos están gestionados por servidores, y sus clientes invocan sus métodos utilizando una invocación de métodos remota. En RMI, la petición del cliente de invocación de un método de un objeto se envía en un mensaje al servidor que gestiona el objeto. La invocación se lleva a cabo ejecutando un método del objeto en el servidor y el resultado se devuelve al cliente en otro mensaje. Para permitir las cadenas de invocaciones relacionadas, se permite que los objetos en los servidores se conviertan en clientes de objetos de otros servidores.

Los objetos distribuidos pueden asumir los otros modelos arquitectónicos que se han descrito en el Capítulo 2. Por ejemplo, los objetos pueden estar replicados para obtener los beneficios usuales de tolerancia a fallos y mejora de prestaciones, y los objetos pueden migrar con vista a mejorar sus prestaciones y disponibilidad.

El disponer de objetos clientes y servidores en diferentes procesos promueve la encapsulación. Esto es, el estado de un objeto está accesible sólo para los métodos del objeto, lo que quiere decir que no es posible que los métodos no autorizados actúen sobre el estado. Por ejemplo, la posibilidad de RMI concurrente desde objetos en diferentes computadores implica que se pueda acceder concurrentemente a un objeto. De este modo, aparece la posibilidad de accesos conflictivos.

Sin embargo, el hecho de que los datos sobre un objeto sólo sean accesibles por sus propios métodos permite a los objetos proporcionar métodos para protegerse contra accesos incorrectos. Por ejemplo, se puede emplear primitivas de sincronización tales como variables de condición para proteger el acceso a sus variables de instancia.

Otra ventaja de tratar el estado compartido de un programa distribuido como un conjunto de objetos es que se pueda acceder a un conjunto de objetos vía RMI o también copiarse en una caché local y ser accedidos directamente, dado que la implementación de la clase está disponible localmente.

El hecho de que los objetos sean accedidos únicamente mediante sus métodos nos da otra ventaja para los sistemas heterogéneos en los que se pueden usar diferentes formatos de datos en diferentes lugares; estos formatos pasarán inadvertidos para aquellos clientes que usan RMI para acceder a los métodos de los objetos.

5.2.3. EL MODELO DE OBJETOS DISTRIBUIDO

Esta sección discute extensiones al modelo de objetos para hacerlo aplicable a los objetos distribuidos. Cada proceso contiene un conjunto de objetos, algunos de los cuales pueden recibir tanto invocaciones locales como remotas, mientras que los otros objetos sólo pueden recibir invocaciones locales, como se muestra en la Figura 5.3. Las invocaciones de métodos entre objetos en diferentes procesos, tanto si es en el mismo computador o no, se conocen como *invocaciones de métodos remotas*. Las invocaciones de métodos entre objetos del mismo proceso son invocaciones de métodos locales.

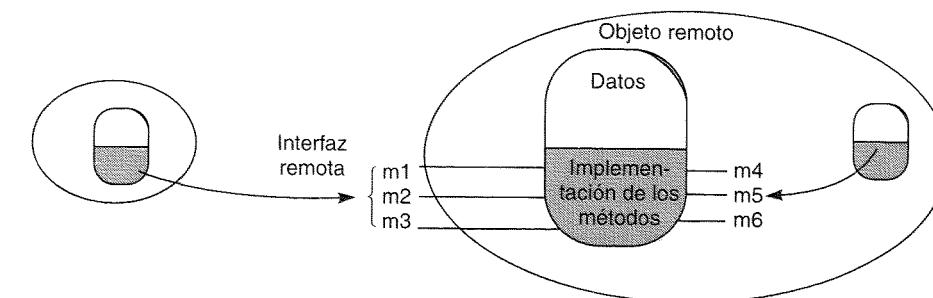
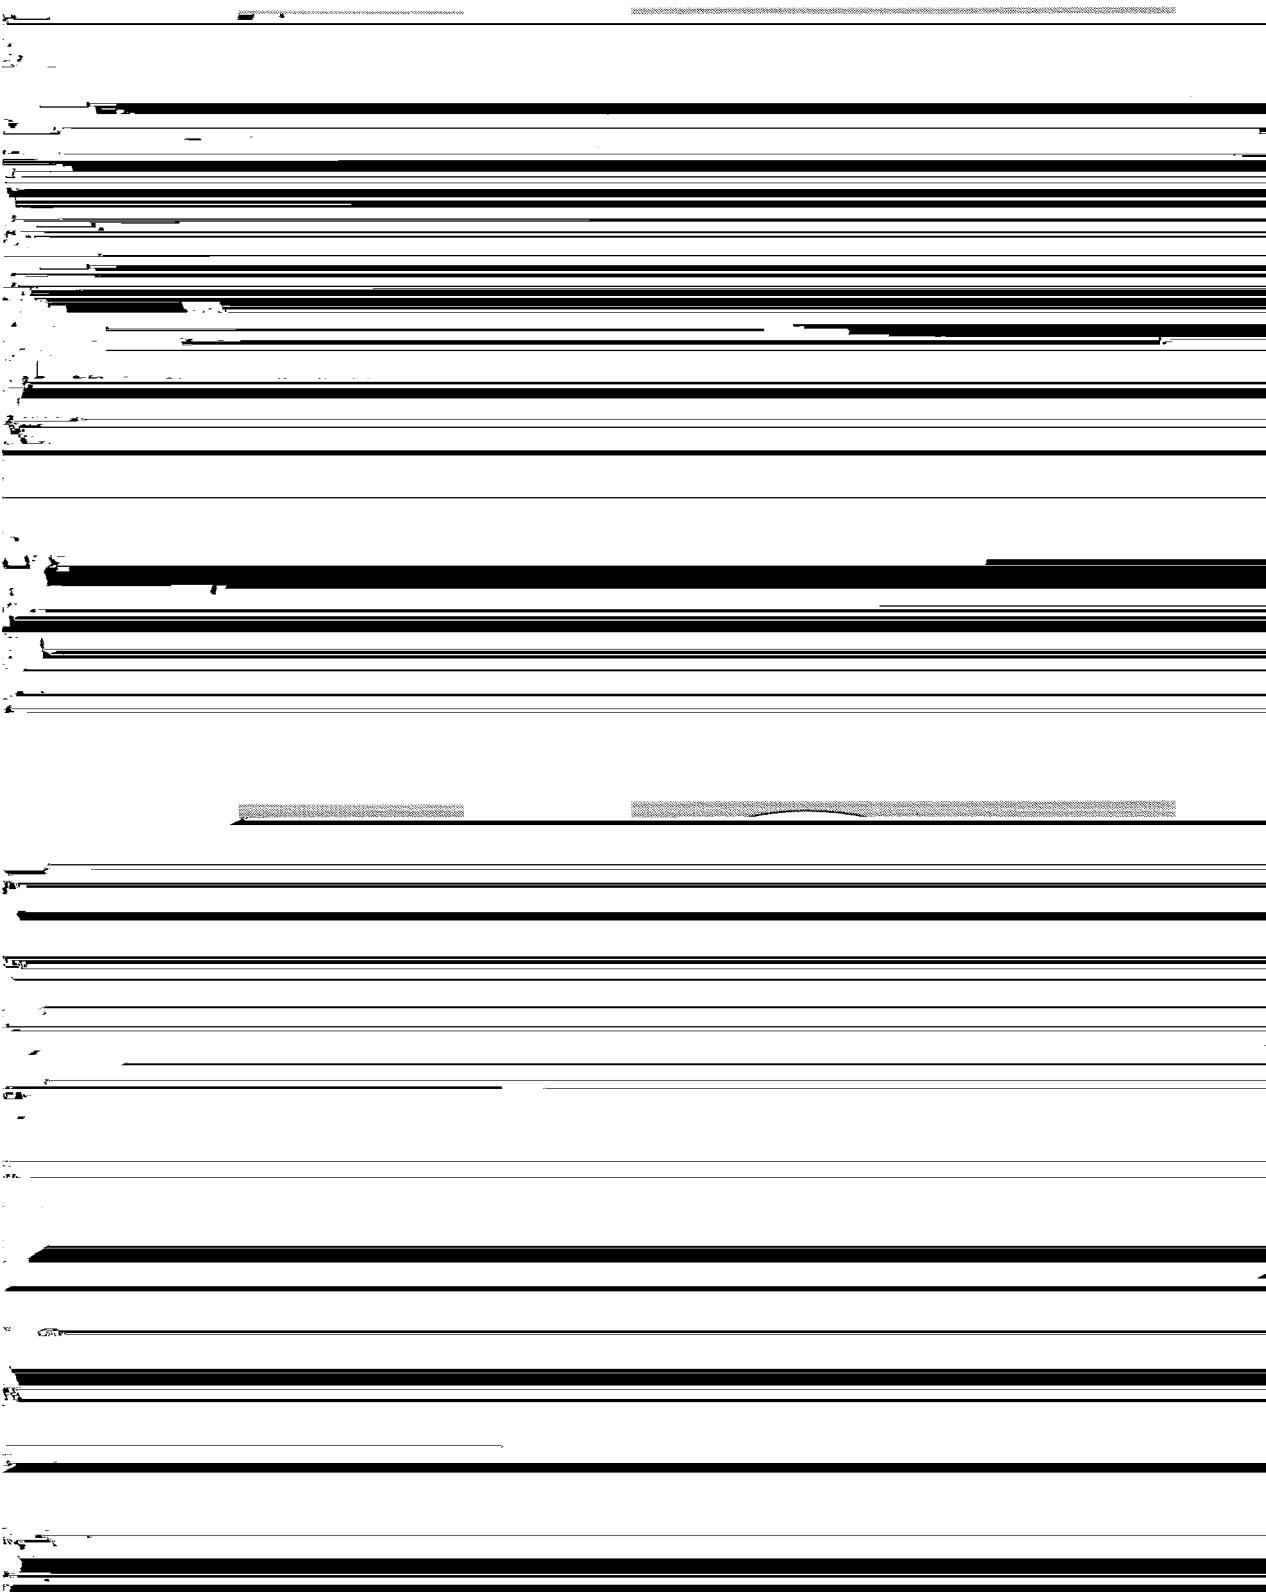


Figura 5.4. Un objeto remoto y su interfaz remota.

Ambos CORBA IDL (véase la Sección 17.2.3) y Java soportan herencia múltiple para sus interfaces. Esto es, se permite que una interfaz extienda una o más interfaces.

◊ **Acciones en un sistema de objetos distribuido.** Como en el caso no distribuido, una acción se inicia mediante la invocación de un método, que pudiera resultar en consiguientes invocaciones sobre métodos de otros objetos. Pero en el caso distribuido, los objetos involucrados en una cadena de invocaciones relacionadas pueden estar ubicados en procesos o en computadores diferentes. Cuando una invocación cruza los límites de un proceso o un computador, se emplea una RMI, y la referencia remota al objeto se hace disponible para hacer posible la RMI. En la Figura 5.3, el objeto A necesita poseer una referencia a objeto remoto para el objeto B. Las referencias a un objeto remoto pueden obtenerse como resultado de una invocación a un objeto remoto. Por ejemplo, el objeto A en la Figura 5.3 podría obtener una referencia remota al objeto F desde el objeto B.

◊ **Compactación automática de memoria en un sistema de objetos distribuido.** Si un lenguaje, por ejemplo Java, soporta compactación automática de memoria, entonces cualquier sistema RMI asociado debiera permitir la compactación automática de memoria para objetos remotos. La compactación automática de memoria, distribuida, se logra usualmente mediante la cooperación entre el compactador automático de memoria local y un módulo adicional que realiza una forma de compactación automática de memoria, distribuida, basada generalmente en una cuenta de referencias. La Sección 5.2.6 describirá tal esquema en detalle.

◊ **Excepciones.** Cualquier invocación remota puede fallar por razones relativas a que el objeto invocado está en un proceso o computador diferente de la del objeto que lo invoca. Por ejemplo, el proceso que contiene el objeto remoto pudiera malograrse o estar demasiado ocupado para responder, o pudiera perderse el mensaje resultante de la invocación. Es así, que una invocación a un método remoto debiera ser capaz de lanzar excepciones tales como *timeouts* debidos a la distribución así como aquellos lanzados durante la ejecución del método invocado. Ejemplos de esto último son: un intento de lectura pasado el fin de un archivo, o un acceso a un archivo sin los permisos adecuados.

CORBA IDL proporciona una notación para las excepciones específicas del nivel de aplicación, y el sistema subyacente genera excepciones estándar cuando ocurren errores debidos a la distribución. Los programas clientes CORBA deben ser capaces de gestionar las excepciones. Por ejemplo, un programa cliente C++ empleará los mecanismos de excepciones de C++.

5.2.4. CUESTIONES DE DISEÑO PARA RMI

La sección anterior sugería que RMI es una extensión natural a la invocación de métodos locales. En esta sección, discutiremos dos cuestiones de diseño que aparecen al realizar esta extensión:

- A pesar de que las invocaciones locales se ejecutan exactamente una sola vez, pudiera no ser siempre éste el caso para las invocaciones de métodos remotos. Se discutirán las alternativas.

El nivel de transparencia deseable para RMI

Semántica de invocación *al menos una vez*: Con la semántica de invocación *al menos una vez*, el invocante recibe un resultado, en cuyo caso el invocante sabe que el método se evaluó al menos una vez, a menos que se reciba una excepción informando que no se recibe ningún resultado. La semántica de invocación *al menos una vez* puede alcanzarse mediante la retransmisión de los mensajes de petición, que enmascara los fallos por omisión de los mensajes de invocación del resultado. La semántica *al menos una vez* puede padecer los siguientes tipos de fallo:

- Fallos por caída cuando el servidor que contiene el objeto remoto falla.
- Fallos arbitrarios. En casos donde el mensaje de invocación se retransmite, el objeto remoto puede recibirla y ejecutar el método más de una vez, provocando que se almacenen o devuelvan valores posiblemente erróneos.

El Capítulo 4 definía *operación idempotente* como aquella que se puede realizar repetidamente con el mismo efecto que si hubiera sido realizada exactamente una sola vez. Las operaciones no idempotentes pueden tener el efecto equivocado si se realizan más de una sola vez. Por ejemplo, una operación para incrementar un balance bancario en 10 unidades debería realizarse de una vez; ¡si tuviera que repetirse, el balance crecería y crecería! Si los objetos de un servidor se pudieran diseñar para que todos los métodos de sus interfaces remotas fueran operaciones idempotentes, entonces la semántica *al menos una vez* sería aceptable.

Semántica *como máximo una vez*: Con la semántica de invocación *como máximo una vez*, el invocante recibe bien un resultado, en cuyo caso el invocante sabe que el método se ejecutó exactamente una vez, o una excepción que le informa de que no se recibió el resultado, de modo que el método se habrá ejecutado o una vez o ninguna en absoluto. La semántica de invocación *como máximo una vez* puede obtenerse utilizando todas las medidas de tolerancia frente a fallos. Como en el caso anterior, al usar reintentos se enmascara cualquier fallo por omisión de los mensajes de invocación y del resultado. Las medidas adicionales de tolerancia frente a fallos previenen los fallos arbitrarios al asegurar que para cada RMI no se ejecuta el método más que una sola vez. Tanto Java RMI como CORBA observan la semántica de invocación *como máximo una vez*, pero CORBA permite emplear la semántica *pudiera ser* para los métodos que no devuelven resultados. Sun RPC proporciona la semántica de llamadas *al menos una vez*.

◊ **Transparencia.** Los creadores de RPC, Birrell y Nelson [1984], intentaban que las llamadas a procedimientos remotos fueran lo más parecido posible a las llamadas locales, sin distinción alguna entre la llamada a procedimiento remoto o local. Todas las llamadas necesarias a procedimientos de empaquetado y paso de mensajes se ocultaban del programador que empleaba la llamada. A pesar de que los mensajes de petición se retransmitían tras un timeout, se hace de modo transparente al que llama; para hacer que la semántica de llamada a procedimiento remoto fuera como la de llamada a procedimiento local. Esta noción de transparencia se extendió para aplicarla a los objetos distribuidos, pero implica la ocultación no sólo del empaquetado y el paso de mensajes sino también de la tarea de ubicación y contacto con un objeto remoto. Como un ejemplo, Java RMI hace que las invocaciones a métodos remotos sean como las llamadas a los locales permitiendo que se emplee la misma sintaxis.

Sin embargo, las invocaciones remotas son más vulnerables a fallos que las locales, puesto que involucran una red, otro computador y otro proceso. Cualquiera que sea la semántica de invocación empleada, siempre es posible que no se reciba resultado alguno, y en caso de fallo es imposible distinguir entre el fallo de la red y el fallo del proceso remoto. Esto requiere que los objetos que hacen invocaciones remotas sean capaces de recuperarse de tales situaciones.

La latencia de una invocación remota está en varios órdenes de magnitud mayor que la de una local. Esto sugiere que los programas que emplean invocaciones remotas deban ser capaces de tener en cuenta este factor, quizás minimizando sus interacciones remotas. Los diseñadores de Argus [Liskov y Scheifler 1982] sugirieron que el invocante debiera ser capaz de malograr una llamada a

un procedimiento remoto que tomara demasiado tiempo de forma que no tuviera efecto sobre el servidor. Para permitir esto, el servidor necesitaría poder restaurar las cosas al estado en que estaban cuando se llamó al procedimiento. Estas cuestiones se discutirán en el Capítulo 12.

Waldo y otros [1994] mencionan que la diferencia entre los objetos locales y remotos debería expresarse en la interfaz remota, para permitir que los objetos reaccionaran de forma consistente frente a fallos parciales. Otros sistemas avanzan más lejos que éste, argumentando que la sintaxis de una llamada remota debería ser diferente de la llamada local: en el caso de Argus, el lenguaje se extendió para que las operaciones remotas fueran explicitadas por el programador.

La elección de si las invocaciones remotas deben ser transparentes también está accesible para los diseñadores de un IDL. Por ejemplo, en CORBA, una invocación remota lanza una excepción cuando el cliente es incapaz de comunicarse con un objeto remoto. Esto requiere que el programa cliente maneje tales excepciones, permitiéndole tratar con tales fallos. Un IDL también proporciona una infraestructura para especificar la semántica de llamada de un método. Esto puede ayudar al diseñador del objeto remoto; por ejemplo, si se elige la semántica de llamada *al menos una vez* para evitar las sobrecargas de la semántica *como máximo una vez*, las operaciones del objeto se diseñan para que sean idempotentes.

El consenso actual parece ser que las invocaciones remotas deben ser transparentes en el sentido que la sintaxis de la invocación remota sea la misma que en la invocación local, pero la diferencia entre objetos remotos y locales debe indicarse en sus interfaces. En el caso de Java RMI, los objetos remotos pueden distinguirse porque por el hecho de que implementan la interfaz *Remote* y lanzan *RemoteExceptions*. Los programadores de un objeto remoto cuya interfaz esté especificada en un IDL también deben estar al tanto de la diferencia. El conocimiento de que un objeto está pensado para un acceso remoto tiene otra implicación para su diseñador: debiera ser capaz de mantener consistente su estado en presencia de accesos concurrentes desde múltiples clientes.

5.2.5. IMPLEMENTACIÓN DE RMI

En una invocación de método remoto están involucrados varios objetos y módulos separados. Esto se muestra en la Figura 5.6, en la que un objeto A del nivel de aplicación invoca un método en un objeto remoto B del nivel de aplicación para el cual dispone de una referencia de objeto remoto. Esta sección discute los papeles de cada uno de los componentes mostrados en esa figura, tratando primero con los módulos de comunicación y referencias remotas y después con el software RMI que se ejecuta sobre ellas.

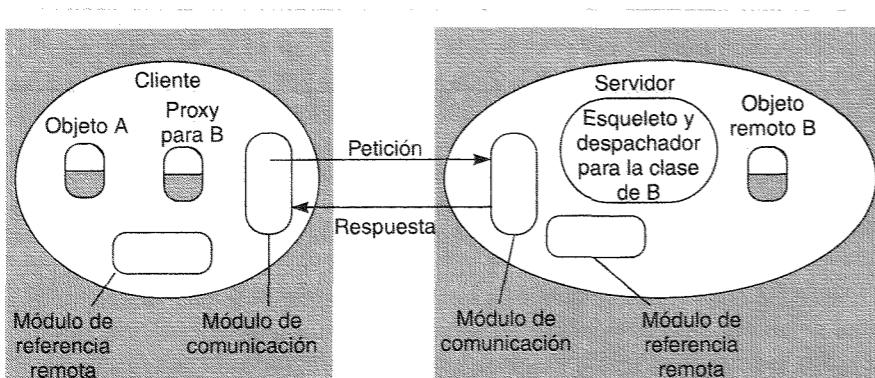


Figura 5.6. El papel de un proxy y un esqueleto en la invocación de métodos remotos.

El resto de esta sección trata de los siguientes temas relacionados: la generación de un proxy, enlace de nombres con referencias a objetos remotos, la activación y desactivación de objetos y la ubicación de objetos desde sus referencias a objetos remotos.

◊ **Módulo de comunicación.** Los dos módulos cooperantes realizan el protocolo de petición-respuesta, que retransmite los mensajes de *peticIÓN* y *respuESTA* entre el cliente y el servidor. Los contenidos de los mensajes *peticIÓN* y *respuESTA* se muestran en la Figura 4.13. El módulo de comunicación emplea sólo los tres primeros elementos, que especifican el tipo de mensaje, su *idPeticION* y la referencia remota del objeto que se invoca. La *idMetodo* y todo el empaquetado y desempaquetado es cuestión del software RMI que se discutirá más adelante. Los módulos de comunicación son responsables conjuntamente de proporcionar una semántica de invocación, por ejemplo *como máximo una vez*.

El módulo de comunicación en el servidor selecciona el distribuidor para la clase del objeto que se invoca, pasando su referencia local, que se obtiene del módulo de referencia remota en respuesta al identificador de objeto remoto en el mensaje *peticIÓN*. El papel del distribuidor se discute bajo el software RMI más adelante.

◊ **Módulo de referencia remota.** Un módulo de referencia remota es responsable de traducir las referencias entre objetos locales y remotos, y de crear referencias a objetos remotos. Para soportar sus responsabilidades, el módulo de referencia remota de cada proceso tiene una *tabla de objetos remotos* que almacena la correspondencia entre referencias a objetos locales en ese proceso y las referencias a objetos remotos (cuyo ámbito es todo el sistema). La tabla incluye:

- Una entrada para todo objeto remoto implementado por el proceso. Por ejemplo, en la Figura 5.6, el objeto remoto B estará registrado en la tabla del servidor.
- Una entrada para cada proxy local. Por ejemplo, en la Figura 5.6 el proxy para B estará registrado en la tabla de ese cliente.

El papel del proxy se discute bajo el siguiente párrafo sobre software de RMI. Las acciones del módulo de referencia remota ocurren como sigue:

- Cuando se pasa un objeto remoto por primera vez, como argumento o resultado, se le pide al módulo de referencia remota que cree una referencia a un objeto remoto, que se añade a su tabla.
- Cuando llega una referencia a un objeto remoto, en un mensaje de petición o respuesta, se le pide al módulo de referencia remota la referencia al objeto local correspondiente, que se referirá bien a un proxy o a un objeto remoto. En el caso de que el objeto remoto no esté en la tabla, el software RMI crea un nuevo proxy y pide al módulo de referencia remota que lo añada a la tabla.

Los componentes del módulo software de RMI llaman a este módulo cuando realizan el empaquetado y desempaquetado de las referencias a objetos remotos. Por ejemplo, cuando llega un mensaje de petición, se emplea su tabla para encontrar qué objeto local se va a invocar.

◊ **El software de RMI.** Éste consiste en una capa de software entre los objetos del nivel de aplicación y los módulos de comunicación y de referencia remota. Los papeles de los objetos de middleware mostrados en la Figura 5.6 son como sigue:

Proxy: el papel del proxy es hacer que la invocación al método remoto sea transparente para los clientes, y para ello se comporta como un objeto local para el que invoca; pero en lugar de ejecutar la invocación, dirige el mensaje al objeto remoto. Oculta los detalles de la referencia al objeto remoto, el empaquetado de los argumentos, el desempaquetado de los resultados y el envío y recepción de los mensajes desde el cliente. Hay un proxy para cada objeto remoto del que el cliente disponga de una referencia de objeto remoto. La clase de un proxy implementa los métodos de la interfaz remota del objeto remoto al que representa. Esto asegura que las

invocaciones al método remoto son adecuadas según el tipo del objeto remoto. Sin embargo, el proxy las implementa de modo bastante diferente. Cada método del proxy empaqueta una referencia hacia el objeto remoto, su propio *idMetodo* y sus argumentos en un mensaje de *peticIÓN* y lo envía al objetivo, espera el mensaje de *respuesta*, lo desempaquetá y devuelve los resultados a quién lo invocó.

Distribuidor: cada servidor tiene un distribuidor y un esqueleto para cada clase que represente a un objeto remoto. En nuestro ejemplo, el servidor tiene un distribuidor y un esqueleto para la clase del objeto remoto B. El distribuidor recibe el mensaje de *peticIÓN* desde el módulo de comunicación. Emplea el *idMetodo* para seleccionar el método apropiado del esqueleto, pasándole el mensaje de *peticIÓN*. El distribuidor y el proxy emplean los mismos métodos de asignación de cada *idMetodo* para los métodos de la interfaz remota.

Esqueleto: la clase de un objeto remoto tiene un *esqueleto*, que implementa los métodos de la interfaz remota. Se encuentran implementados de forma muy diferente de los métodos del objeto remoto. Un método del esqueleto desempaquetá los argumentos del mensaje de *peticIÓN* e invoca el método correspondiente en el objeto remoto. Espera la consumación de la invocación y después empaquetá el resultado, junto con las excepciones producidas, en un mensaje de *respuesta* para el método de envío del proxy.

Las referencias a objetos remotos se empaquetan de la forma indicada en la Figura 4.10, que incluye información sobre la interfaz remota del objeto remoto, por ejemplo el nombre de la interfaz remota o la clase del objeto remoto. Esta información permite determinar la clase proxy de modo que pueda crearse un nuevo proxy cuando se necesite. Por ejemplo, puede generarse el nombre de la clase proxy añadiendo «*_proxy*» al nombre de la interfaz remota.

◊ **Generación de las clases para cada proxy, distribuidor y esqueleto.** Las clases para cada proxy, distribuidor y esqueleto empleado en RMI se generan automáticamente mediante un compilador de interfaces. Por ejemplo, en Orbix, una implementación de CORBA, se generan las interfaces para las clases en CORBA IDL, y se emplea el compilador de interfaces para generar las clases para cada proxy, distribuidor y esqueleto en C++. Para Java RMI, el conjunto de métodos que se ofrecen en un objeto remoto se define como una interfaz Java que se implementa conjuntamente con la clase del objeto remoto. El compilador de Java RMI genera las clases proxy, distribuidor y esqueleto desde la clase del objeto remoto.

◊ **Programas cliente y servidor.** El programa servidor contiene las clases para los distribuidores y esqueletos, junto con las implementaciones de las clases de todos los objetos remotos a que da soporte. Las últimas se denominan a menudo clases servidoras. Además, el programa servidor contiene una sección de *inicialización* (por ejemplo en un método *main* en Java o C++). La sección de *inicialización* es responsable de crear e iniciar al menos uno de los objetos remotos que se alojarán en el servidor. Los objetos remotos adicionales se pueden crear en respuesta a las peticiones de los clientes. La sección de *inicialización* puede, también, registrar algunos de sus objetos remotos en un enlazador (*binder*) (véase el siguiente párrafo). Generalmente, sólo se registrará un objeto remoto, que será utilizado para acceder al resto.

El programa cliente contendrá las clases de cada proxy para todos los objetos remotos que invoque. Puede utilizar un enlazador para buscar las referencias a los objetos remotos.

Métodos factoría: Ya dimos cuenta de que las interfaces de objetos remotos no pueden incluir constructores. Esto viene a decir que los objetos remotos no pueden crearse mediante una invocación remota sobre los constructores. Los objetos remotos se crean bien en la sección de *inicialización* o en los métodos diseñados a tal efecto en la interfaz remota. El término *método factoría* se emplea a menudo para hacer referencia a un método que crea objetos remotos, y un *objeto factoría* es un objeto con métodos factoría. Cualquier objeto remoto que necesite ser capaz de crear un objeto remoto nuevo bajo demanda del cliente debe proporcionar métodos remotos en su interfaz re-

mota con este fin. A tales métodos se los llama métodos factoría, aunque en realidad son métodos como los demás.

◊ **El enlazador.** Los programas cliente requieren generalmente algún modo de obtener una referencia a un objeto remoto para al menos uno de los objetos remotos alojados en el servidor. Por ejemplo, en el objeto de la Figura 5.3, el objeto A requeriría una referencia a un objeto remoto B. Un *enlazador* (*binder*) en un sistema distribuido es un servicio separado que da soporte a una tabla que contiene relaciones con nombres textuales y referencias a objetos remotos. Se emplea, por parte de los servidores, para registrar sus objetos remotos mediante su nombre y, por parte de los clientes, para buscarlos por nombre. El Capítulo 17 contiene una discusión del Servicio de Nombres de CORBA. El enlazador Java, RMIregistry, se discute brevemente en el caso de estudio sobre Java RMI en la Sección 5.5.

◊ **Hilos del servidor.** Cuando un objeto ejecuta una invocación remota, su ejecución puede conducir a otras invocaciones de métodos de otros objetos remotos, que pueden tomarse su tiempo en volver. Para evitar que la ejecución de una invocación remota retrase la ejecución de otra, los servidores suelen asignar un hilo de ejecución separado para cada invocación remota. Cuando esto ocurre, el diseñador de la implementación de un objeto remoto debe tener en cuenta los efectos de las ejecuciones concurrentes sobre su estado.

◊ **Activación de objetos remotos.** Algunas aplicaciones requieren que su información sobreviva durante largos períodos de tiempo. Sin embargo, no resulta práctico que los objetos que representan esta información se mantengan en ejecución durante períodos de tiempo ilimitados, particularmente cuando no se usan durante todo ese tiempo. Para evitar el potencial gasto superfluo de recursos debido a la ejecución de todos los servidores que gestionan los objetos remotos, los servidores podrán arrancarse cuando sean necesitados por los clientes, así como se hace para los servicios estándar de tipo TCP como FTP, que se lanzan bajo demanda de un servicio denominado *Inetd*. Los procesos que lanzan los procesos servidores que alojan objetos remotos se denominan *activadores* por las siguientes razones.

Un objeto remoto se dice que está *activo* cuando está disponible para su invocación en el interior de un proceso en ejecución, mientras que se denomina *pasivo* (o *inactivo*) si no está activo actualmente pero puede activarse. Un objeto pasivo consta de dos partes:

1. La implementación de sus métodos.
2. Su estado en forma empaquetada.

La *activación* consiste en la creación de un objeto activo desde el objeto pasivo correspondiente mediante la creación de una nueva instancia de su clase y la iniciación de sus variables de instancia desde el estado almacenado. Los objetos pasivos pueden activarse bajo demanda, por ejemplo, cuando son invocados por otros objetos.

Un *activador* es responsable de:

- Registrar los objetos pasivos que estén disponibles para su activación, lo que implica el almacenamiento de los nombres de los servidores conjuntamente con el URL o nombre de archivo de un objeto pasivo correspondiente.
- Arrancar procesos de servicio con nombre y activar los objetos remotos de su interior.
- Mantener la pista de las ubicaciones de los servidores de los objetos remotos que ya han sido activados.

El caso de estudio CORBA describe su activador, que se denomina el repositorio de implementación. Java RMI emplea un activador en cada computador servidor, que es responsable de activar los objetos sobre ese computador.

◊ **Almacenes de objetos persistentes.** Un objeto cuya vida se encuentra garantizada entre procesos de activación se denomina *objeto persistente*. Los objetos persistentes suelen estar ges-

tionados por los almacenes de objetos persistentes, que almacenan su estado en forma empaquetada.

tionados por los almacenes de objetos persistentes, que almacenan su estado en forma empaquetada en el disco. Los ejemplos incluyen el servicio de objetos persistentes de CORBA (véase la Sección 17.2) y Domains Java Beans 1.0.6 (Java Sun.com 1997).

intenta la invocación con esa dirección, que fallará si el objeto ha sido movido. Para localizar un objeto que se ha movido o cuya ubicación no aparece en la caché, el sistema difunde una petición. Este esquema puede mejorarse mediante el empleo de apuntadores de localización hacia delante, que contienen pistas de la nueva ubicación de un objeto.

5.2.6. COMPACTACIÓN AUTOMÁTICA DE MEMORIA

El objetivo de un compactador automático de memoria es asegurar que mientras alguien posea una referencia a un objeto remoto o local, el objeto en sí mismo seguirá existiendo, pero tan pronto como no haya ningún objeto que haga referencia a él, se cobra dicho objeto y se recupera la memoria que empleaba.

Describiremos el algoritmo distribuido de compactación automática de memoria de Java, que es similar al descrito por Birrell y otros [1995]. Se basa en el recuento de las referencias. Cuando un proceso obtiene una referencia a un objeto remoto, se crea un proxy que permanecerá allí tanto tiempo como sea necesario. El proceso donde vive este objeto (su servidor) deberá estar informado del nuevo proxy en el cliente. Más tarde, cuando no hubiera tal proxy en el cliente, se informará al servidor. El compactador automático de memoria distribuido trabaja en cooperación con el compactador automático de memoria local como sigue:

- Cada proceso servidor mantiene un conjunto de procesos que guardan referencias a objetos remotos para cada uno de sus objetos remotos; por ejemplo, *B.titulares* es el conjunto de procesos clientes (máquinas virtuales) que tienen algún proxy del objeto *B*. (En la Figura 5.6, este conjunto incluirá los procesos cliente que se muestran.) Este conjunto puede almacenarse en una columna adicional de la tabla de objetos remotos.
- Cuando un cliente *C* recibe una referencia a un objeto remoto particular por primera vez, *B*, realiza una invocación *añadeRef(B)* al servidor de ese objeto remoto y entonces crea un proxy; el servidor añade *C* a *B.titulares*.
- Cuando el compactador automático de memoria de un cliente *C* advierte que ya no es posible acceder al proxy de un objeto remoto *B*, se hace una invocación a *eliminaRef(B)* en el servidor correspondiente y destruye el proxy; el servidor elimina *C* de *B.titulares*.
- Cuando *B.titulares* está vacío, el compactador automático de memoria local del servidor reclamará el espacio ocupado por *B* a menos que haya algún objeto local que sea titular de alguna referencia.

Este algoritmo está pensado para ser llevado a cabo mediante una comunicación emparejada petición-respuesta con una semántica del tipo *al menos una vez* entre los módulos de referencias remotas en los procesos; no requiere ninguna sincronización global. Observe también que las invocaciones extras realizadas en beneficio del algoritmo de compactación automática de memoria no afectan a las invocaciones RMI normales; sólo aparecen cuando se crea o elimina algún proxy.

Existe la posibilidad de que algún cliente realice una invocación *eliminaRef(B)* a la vez que otro cliente realice una invocación a *añadeRef(B)*. Si la operación *eliminaRef* llega primero y *B.titulares* se encuentra vacío, el objeto remoto *B* podría ser borrado antes de que llegara *añadeRef*. Para evitar esta situación, si el conjunto *B.titulares* está vacío en el momento en que se transmite una referencia al objeto remoto, se añade una entrada temporal hasta que llega *añadeRef*.

El algoritmo de compactación automática de memoria distribuido tolera los fallos de comunicación usando la siguiente aproximación. Las operaciones *añadeRef* y *eliminaRef* son idempotentes. En el caso de que una llamada a *añadeRef(B)* devuelva una excepción (que indicaría que el método se ejecutó una vez o ninguna), el cliente no creará un proxy pero hará una llamada a *removeRef(B)*. El efecto de *eliminaRef* es correcto tanto si tiene éxito como si no *añadeRef*. El caso de que falle *eliminaRef* se trata mediante concesiones (*leases*), según se describe en el párrafo próximo.

El algoritmo de compactación automática de memoria distribuida tolera el fallo de los procesos clientes. Para obtener esto, los servidores *ceden* sus objetos a los clientes durante un período de tiempo limitado. El período de concesión comienza cuando el cliente realiza una invocación *añadeRef* al servidor. Acaba bien cuando expira el plazo o cuando el cliente realiza una invocación *eliminaRef* al servidor. La información almacenada por el servidor, concerniente a cada concesión, contiene el identificador de la máquina virtual del cliente y el período de concesión. Los clientes son los responsables de pedir la renovación de sus concesiones antes de que éstas expiren.

◊ **Concesiones en Jini.** El sistema distribuido Jini incluye una especificación para las concesiones [Arnold y otros 1999] que puede utilizarse en variedad de situaciones cuando un objeto ofrezca un recurso a otro objeto, como por ejemplo cuando los objetos remotos ofrecen referencias a otros objetos. Los objetos que ofrecen tales recursos padecen el riesgo de tener que mantener los recursos aun cuando los usuarios ya no estén interesados o sus programas pudieran haber finalizado. Para evitar protocolos complicados para descubrir si los usuarios de los recursos están aún interesados, los recursos se ofrecen por un período de tiempo limitado. La cesión del uso de un recurso durante un período de tiempo se denomina *concesión*. El objeto que ofrece el recurso lo mantendrá hasta que expire el tiempo de la concesión. Los usuarios de los recursos son responsables de pedir su renovación cuando ésta expira.

El período de una concesión puede negociarse entre el que cede y el que toma la cesión, a pesar de que esto no ocurre con las concesiones utilizadas en Java RMI. Un objeto que represente una concesión implementa la interfaz *Lease*. Ésta contiene información sobre el período de la concesión y los métodos que permiten la renovación o la cancelación de la concesión. El que cede devuelve una instancia de la clase *Lease* cuando proporciona un recurso a otro objeto.

5.3. LLAMADA A UN PROCEDIMIENTO REMOTO

Una llamada a un procedimiento remoto es muy similar a una invocación a un método remoto, en la que un programa cliente llama a un procedimiento de otro programa en ejecución en un proceso servidor. Los servidores pueden ser clientes de otros servidores para permitir cadenas de RPC. Según se mencionó en la introducción a este capítulo, un proceso servidor define en su *interfaz de servicio* los procedimientos disponibles para ser llamados remotamente. RPC, como RMI, puede implementarse para ofrecer alguna de las semánticas de invocación discutidas en la Sección 5.2.4; generalmente se elige *al menos una vez* o *como máximo una vez*. RPC se implementa usualmente sobre un protocolo petición-respuesta como el que se discutió en la Sección 4.4, que se encuentra simplificado por la omisión de referencias a objetos remotos en la parte de los mensajes de petición. Los contenidos de los mensajes de petición y respuesta son los mismos que los que se mostraron para RMI en la Figura 4.13, excepto que se omite el campo *ReferenciaObjeto*.

El software que soporta RPC se muestra en la Figura 5.7. Es similar al mostrado en la Figura 5.6 excepto que no se requieren módulos de referencias remotas, dado que las llamadas a procedimientos no tienen que ver con objetos y referencias a objetos. El cliente que accede a un servicio incluye un *procedimiento de resguardo* para cada procedimiento en la interfaz de servicio. El papel de un procedimiento de resguardo es similar al de un proxy. Se comporta como un procedimiento local del cliente, pero en lugar de ejecutar la llamada, empaqueta el identificador del procedimiento y los argumentos en un mensaje de petición, que se envía vía su módulo de comunicación al servidor. Cuando llega el mensaje de respuesta, desempaquetá la respuesta. El proceso servidor contiene un distribuidor junto a un procedimiento de resguardo de servidor y un procedimiento de servicio para cada procedimiento de la interfaz de servicio. El distribuidor selecciona uno de los procedimientos de resguardo según el identificador de procedimiento del mensaje de petición. Un *procedimiento de resguardo de servidor* es como un método de esqueleto en el que se desem-

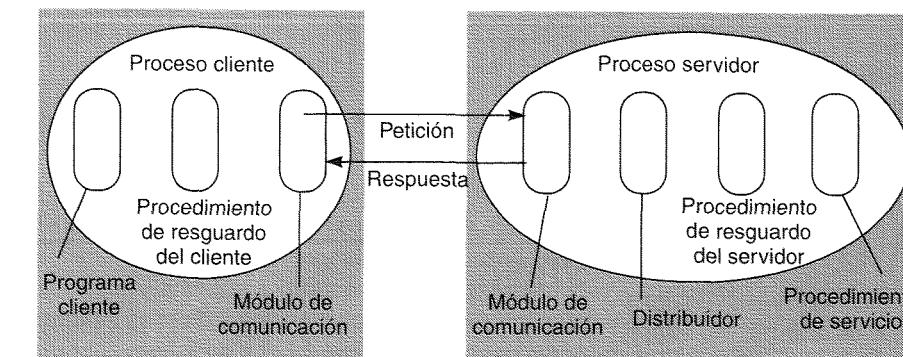


Figura 5.7. Papel de los procedimientos de resguardo de cliente y servidor en RPC.

paquetan los argumentos en el mensaje de petición, se llama al procedimiento de servicio correspondiente y se empaquetan los datos con el resultado para el mensaje de respuesta. Los procedimientos de servicio implementan los procedimientos en la interfaz de servicio.

Los procedimientos de resguardo del cliente y del servidor y el distribuidor pueden generarse desde la definición de la interfaz del servicio por medio de un compilador de interfaces.

5.3.1. CASO DE ESTUDIO SUN RPC

RFC 1831 [Srinivasan 1995] describe Sun RPC, que se diseñó para la comunicación cliente-servidor en el sistema de archivos en red Sun NFS. Sun RPC se denomina a menudo ONC (Computación de Red A —*Open Network Computing*) RPC. Se proporciona como parte de los varios sistemas operativos de Sun y otros del tipo UNIX, y también está disponible con otras instalaciones de NFS. Los diseñadores tienen la opción de utilizar llamadas a procedimientos remotos sobre UDP o TCP. Cuando se utiliza Sun RPC sobre UDP, la longitud de los mensajes de petición y respuesta se encuentra limitada, teóricamente a 64 kilobytes, aunque más a menudo se encuentran en la práctica limitaciones a 8 ó 9 kilobytes. Utiliza la semántica de llamada *al menos una vez*. Como opción existe la posibilidad de difusión de RPC.

El sistema Sun RPC proporciona un lenguaje de interfaz denominado XDR y un compilador de interfaces llamado *rpcgen* cuyo uso está orientado al lenguaje de programación C.

◊ **Lenguaje de definición de interfaz.** El lenguaje Sun XDR, diseñado originalmente para especificar representaciones externas de datos, se extendió para convertirse en un lenguaje de definición de interfaces. Puede utilizarse para definir una interfaz de servicio para Sun RPC especificando un conjunto de definiciones de procedimiento junto a las definiciones de tipos que las soporan. La notación es bastante primitiva en comparación con la usada por CORBA IDL o Java. En particular:

- La mayoría de los lenguajes permiten especificar nombres de interfaces, pero Sun RPC no; en su lugar, hay que proporcionar un número de programa y un número de versión. Los números de programa pueden obtenerse de una autoridad central para permitir que cualquier programa tenga un número propio único. Los números de versión cambian cuando cambia la firma de algún procedimiento. Tanto el número de programa como el de versión se envían en el mensaje de petición, de modo que el cliente y el servidor puedan concretar la versión que están usando.

```

const MAX = 1000;
typedef int IdentificadorArchivo;
typedef int ApuntadorArchivo;
typedef int Longitud;
struct Datos {
    int longitud;
    char bufer[MAX];
};

struct argumentosEscribe {
    IdentificadorArchivo f;
    ApuntadorArchivo posicion;
    Datos datos;
};

struct argumentosLee {
    IdentificadorArchivo f;
    ApuntadorArchivo posicion;
    Longitud longitud;
};

program LEEESCRIBEARCHIVO {
    version VERSION {
        void ESCRIBE(argumentosEscribe)=1
        Data LEE(argumentosLee)=2;
    }=2;
}=9999;

```

Figura 5.8. Interfaz de archivos en Sun XDR.

- Una definición de procedimiento especifica una firma o firma de un procedimiento y un número de procedimiento. El número de procedimiento se emplea como un identificador en los mensajes de petición. Hubiera sido posible que el compilador de interfaces generara los identificadores de procedimiento.
- Sólo se permite un parámetro de entrada. De este modo, los procedimientos que requieran varios parámetros deberán incluirlos como componentes de una sola estructura.
- Los parámetros de salida de un procedimiento se devuelven como un solo resultado.
- La firma del procedimiento consta de un tipo de resultado, el nombre del procedimiento y el tipo del parámetro de entrada. Tanto el tipo del resultado como el de entrada pueden ser bien un solo valor o una estructura conteniendo varios valores.

Por ejemplo, véase la definición XDR de la Figura 5.8 de una interfaz con un par de procedimientos para leer y escribir archivos. El número del programa es 9999 y el número de la versión es 2. El procedimiento *LEE* (ver la línea 2) toma como parámetro de entrada una estructura con tres componentes que especifican un identificador de archivo, una posición en el archivo y el número de bytes pedidos. Su resultado es una estructura que contiene el número de bytes devueltos y los datos del archivo. El procedimiento *ESCRIBE* (ver la línea 1) no tiene resultado. Los procedimientos *ESCRIBE* y *LEE* reciben los números 1 y 2. El número 0 se reserva para un procedimiento nulo, que se genera automáticamente y está pensado para comprobar si un servidor está disponible.

El lenguaje de definición de la interfaz proporciona una notación para definir constantes, definiciones de tipo, estructuras, tipos enumerados, uniones y programas. Las definiciones de tipo (*typedef*), estructuras (*struct*), tipos enumerados (*enum*) emplean la sintaxis del lenguaje C. El compilador de interfaces *rpcgen* puede emplearse para generar, desde la definición de interfaz, lo siguiente:

- El procedimiento de resguardo del cliente.

- El procedimiento *main* del servidor, el distribuidor y el procedimiento de resguardo del servidor.
- Los procedimientos de empaquetado y desempaquetado XDR para su empleo por el distribuidor y los procedimientos de resguardo del cliente y el servidor.

◊ **Enlazado.** Sun RPC lanza un servicio de enlazado denominado *enlazador de puertos (port mapper)* en un número de puerto bien conocido de cada computador. Cada ejemplar del enlazador de puertos almacena el número de programa, el número de versión y el número de puerto en uso por cada servicio que se ejecuta localmente. Cuando arranca un servidor, registra su número de programa, número de versión y número de puerto frente al enlazador de puertos. Cuando arranca el cliente, encuentra el puerto del servidor mediante una petición remota al enlazador de puertos del servidor huésped, especificando el número del programa y el número de la versión.

Cuando un servicio tiene múltiples ejemplares en ejecución sobre diferentes computadores, las instancias pueden usar diferentes números de puerto para recibir las peticiones de los clientes. Si un cliente necesita multidifundir una petición a todas las instancias de un servicio que están utilizando diferentes números de puerto, no podrá utilizar un mensaje de difusión directo con este fin. La solución es que los clientes efectúen una multidifusión de llamadas a procedimiento remoto mediante una difusión a todos los enlazadores de puertos, especificando los números de programa y versión. Cada enlazador de puertos dirigirá las llamadas a los programas de servicio apropiados, si hubiera alguno.

◊ **Autenticación.** Los mensajes de petición y respuesta de Sun RPC proporcionan campos adicionales que permiten pasar información de autenticación entre el cliente y el servidor. Por ejemplo, en el estilo de autenticación UNIX, las credenciales incluyen el *uid* y el *gid* del usuario. Se pueden construir mecanismos de control de acceso sobre la información de autenticación que se ofrece a los procedimientos de servicio a través de un segundo argumento. El programa servidor se hace responsable de poner en práctica el control de acceso decidendo si ejecutar o no cada llamada a procedimiento según la información de autenticación. Por ejemplo, si el servidor es un servidor de archivos NFS, puede comprobar si el usuario tiene suficientes derechos de acceso para llevar a cabo la operación requerida sobre un archivo.

Es posible dar soporte a diferentes protocolos de autenticación. Éstos incluyen:

- Ninguno.
- Al estilo UNIX, como se ha comentado.
- De forma en que se establece una clave compartida para firmar los mensajes RPC.
- Al estilo de autenticación de Kerberos (véase el Capítulo 7).

Un campo en la cabecera RPC indica cuál de ellos se está empleando.

En el RPC 2203 [Eisler y otros 1997] se describe una aproximación más genérica a la seguridad. Proporciona privacidad e integridad a los mensajes RPC, al mismo tiempo que autenticación. Permite que el cliente y el servidor negocien un contexto de seguridad en el que o bien no se aplica seguridad o bien se requiere seguridad, en cuyo caso se podrá aplicar tanto integridad de los mensajes como privacidad, conjuntamente o por separado.

◊ **Programas cliente y servidor.** En www.cdk3.net/RMI se dispone de material adicional sobre Sun RPC. Incluye programas cliente y servidor correspondientes a la interfaz definida en la Figura 5.8.

5.4. EVENTOS Y NOTIFICACIONES

La idea bajo el uso de eventos es que un objeto pueda reaccionar a un cambio que ocurre en otro objeto. Las notificaciones y los eventos son esencialmente asíncronos y son determinados por sus

Una situación en la que pueden ser útiles los eventos es la que se muestra en el siguiente ejemplo sobre una sala de contratación:

◊ **Sistema simple de una sala de contratación.** Considere un sistema simple de una sala de contratación cuya tarea es permitir que los tratantes hagan uso de los computadores para consultar la información más reciente sobre los precios del mercado de las mercancías con que comercian. El precio del mercado para una sola mercancía conocida se representa mediante un objeto con varias variables de instancia. La información llega a la sala de contratación desde diferentes fuentes externas en forma de actualizaciones de algunas o todas las variables de instancia de los objetos que representan las mercancías y es recolectada por procesos que llamamos proveedores de información. Los tratantes están interesados solamente en aquellas mercancías en que están especializados. Un sistema de sala de contratación podría modelarse mediante procesos con dos tareas diferentes:

- Un proceso proveedor de información recibe continuamente nueva información comercial desde una sola fuente externa y le aplica los objetos de la mercancía apropiada. Cada una de las actualizaciones a un objeto de mercancía se contempla como un evento. El objeto de mercancía que experimenta tales eventos notifica a todos los tratantes que se hayan suscrito a la mercancía correspondiente. Habrá un proceso proveedor de información separado para cada fuente externa.
- Un proceso tratante crea un objeto para representar cada mercancía que el usuario pida visualizar. Este objeto local se suscribe al objeto que representa esa mercancía en el proveedor de información relevante. Entonces recibe toda la información enviada al anterior mediante las notificaciones y la muestra al usuario.

La comunicación de las notificaciones se muestra en la Figura 5.9.

◊ **Tipos de eventos.** Una fuente de eventos puede generar eventos de uno o más *tipos* diferentes. Cada evento tiene *atributos* que especifican información sobre ese evento, tal como el nombre

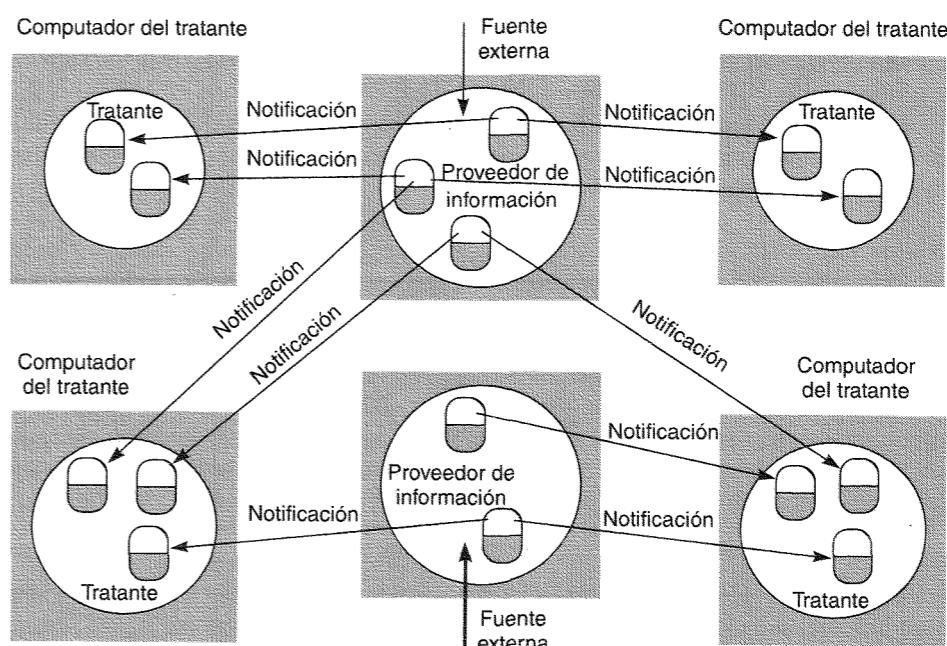


Figura 5.9. Sistema de sala de contratación.

o el identificador del evento que lo generó, la operación, sus parámetros y el tiempo (o un número de secuencia). Los tipos y los atributos se usan tanto para en la suscripción como en la notificación. Cuando nos suscribimos a un evento, se especifica el tipo del evento, a veces modificado con ciertos criterios sobre los valores de los atributos. Cuando quiera que aparezca un evento que concuerde con los atributos, se notificará a las partes interesadas. En el ejemplo de la sala de contratación, hay un tipo de evento (la llegada de una actualización de una mercancía), y los atributos podrían especificar el nombre de la mercancía, su precio actual, y la última elevación o caída de precio. Los tratantes podrán, por ejemplo, especificar si están interesados en todos los eventos relacionados con una mercancía con un nombre concreto.

5.4.1. LOS PARTICIPANTES EN UNA NOTIFICACIÓN DE EVENTOS DISTRIBUIDA

La Figura 5.10 muestra una arquitectura que especifica los papeles que juegan los objetos que participan en un sistema distribuido basado en eventos. Nuestra descripción proviene del papel sobre eventos y notificaciones en Internet de Rosenblum y Wolf [1997]. La arquitectura está diseñada para desacoplar los anunciantes de los suscriptores, permitiendo que los anunciantes sean desarrollados independientemente de sus suscriptores, y limitando hasta donde sea posible el trabajo que imponen los suscriptores sobre los anunciantes. El principal componente es un servicio de eventos que mantiene una base de datos de eventos publicados en el servicio de eventos. Los suscriptores informan al servicio de eventos de los tipos de eventos en los que están interesados. Cuando ocurre un evento en un objeto de interés se envía una notificación a los suscriptores de ese tipo de evento.

Los papeles de los objetos que participan son los siguientes:

El objeto de interés: éste es un objeto que experimenta cambios de estado, como resultado de las operaciones que se invocan sobre él. Sus cambios de estado podrían ser de interés para los otros objetos. Esta descripción permite eventos como el que una persona que lleva un distintivo identificador entre en una habitación, en cuyo caso la habitación es el objeto de interés y la operación consiste en añadir información sobre la nueva persona a su registro o quién está en la habitación. Se considera que el objeto de interés es parte del servicio de eventos si transmite notificaciones.

Evento: un evento aparece en un objeto de interés como resultado de la finalización de la ejecución de la ejecución de un método.

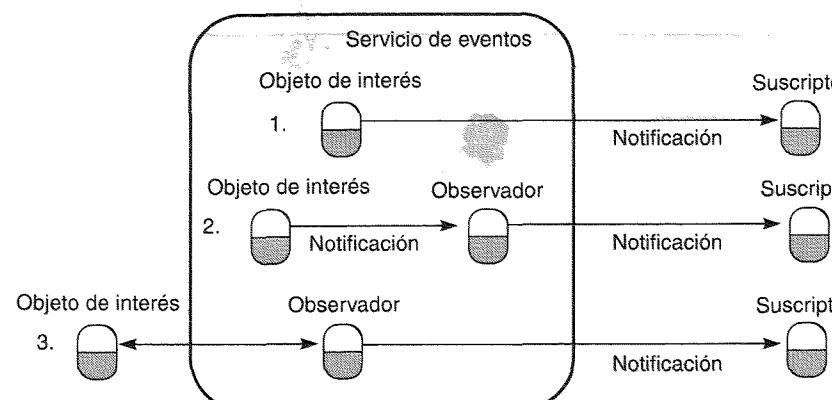


Figura 5.10. Arquitectura para la notificación distribuida de eventos.

Notificación: una notificación es un objeto que contiene información sobre un evento. Generalmente, contiene el tipo de evento y sus atributos, que generalmente incluyen la identidad del objeto de interés, el método que se invoca, y el momento en que ocurre, o un número de secuencia.

Suscriptor: un suscriptor es un objeto que se ha suscrito a algún tipo de evento en otro objeto. Recibirá notificaciones sobre tales eventos.

Objetos observadores: el principal objetivo de un observador es desacoplar un objeto de interés de sus suscriptores. Un objeto de interés puede tener muchos suscriptores diferentes con diferentes intereses. Por ejemplo, los suscriptores podrían diferir en el tipo de eventos en que están interesados, o aquellos que comparten los mismos requisitos sobre el tipo podrían divergir en los atributos sobre los que están interesados. Si hubiera que realizar, en el objeto de interés, todas las operaciones lógicas para distinguir las necesidades de sus suscriptores dicho objeto estaría complicado en exceso. Se pueden interponer uno o más observadores entre el objeto de interés y sus suscriptores. Los papeles de los observadores se discuten con más detalle en un párrafo posterior.

Anunciante: éste es un objeto que declara que generará notificaciones de tipos concretos de eventos. Un anunciante pudiera ser un objeto de interés o un observador.

La Figura 5.10 muestra tres casos:

1. Un objeto de interés en el interior de un servicio de eventos sin un observador. Envía notificaciones directamente a los suscriptores.
2. Un objeto de interés en el interior de un servicio de eventos con un observador. El objeto de interés envía notificaciones a los suscriptores vía el observador.
3. Un objeto de interés fuera del servicio de eventos. En este caso, un observador consulta al objeto de interés para descubrir cuando ocurre un evento. El observador envía notificaciones a los suscriptores.

◇ **Semántica de reparto.** Se puede proporcionar una variedad de garantías diferentes para las notificaciones; aquella que se elija dependerá de los requisitos de las aplicaciones. Por ejemplo, si se emplea multidifusión IP para enviar las notificaciones a un grupo de receptores, el modo de fallo estará relacionado con el que se describe para la multidifusión IP en la Sección 4.5.1 y no habrá garantías de que cualquier receptor particular reciba un mensaje de notificación concreto. Esto es apropiado en algunas aplicaciones, por ejemplo, para repartir el último estado de un jugador de un juego en Internet, porque es muy posible que se haga comprender en la próxima actualización.

Sin embargo, otras aplicaciones tienen requisitos más estrictos. Considere la aplicación de la sala de contratación: para ser justo con los tratantes interesados en una mercancía particular, requerimos que todos los tratantes para la misma mercancía reciban la misma información. Esto implica que habrá que usar un protocolo de multidifusión fiable.

En el sistema Mushroom mencionado anteriormente, las notificaciones sobre el cambio de estado de un objeto se envían de modo fiable a un servidor, cuya responsabilidad es mantener copias actualizadas de los objetos. Sin embargo, las notificaciones pueden enviarse a las réplicas de los objetos en los computadores de los usuarios mediante una multidifusión no fiable; el caso de que hubiera notificaciones perdidas, éstas pudieran recuperarse del estado del objeto desde el servidor. Cuando la aplicación lo requiera, se podrán ordenar las notificaciones y ser enviadas de modo fiable a las réplicas del objeto.

Algunas aplicaciones tienen restricciones de tiempo real. Éstas incluyen eventos de una planta de energía nuclear o un monitor de un paciente en un hospital. Es posible diseñar protocolos de multidifusión que proporcionen garantías de tiempo real así como fiabilidad y ordenamiento en un sistema que satisfaga las propiedades de un sistema distribuido síncrono.

◊ **Reglas para los observadores.** A pesar de que se pueden enviar las notificaciones directamente desde el objeto de interés al receptor, la tarea de procesar las notificaciones puede dividirse entre los procesos observadores que juegan una variedad de papeles diferentes. Describimos algunos ejemplos:

Encaminamiento: un observador encaminador puede llevar a cabo todo el trabajo de enviar las notificaciones a los suscriptores en representación de uno o más objetos de interés. Todo lo que necesita hacer un objeto de interés es enviar una notificación al observador de encaminamiento, y seguir realizando su tarea habitual. Para utilizar un observador de encaminamiento, un objeto de interés envía la información sobre los intereses de sus suscriptores al observador de encaminamiento.

Filtrado de notificaciones: un observador puede aplicar filtros para reducir el número de notificaciones recibidas según algún predicado sobre los contenidos de cada notificación. Por ejemplo, en el caso de que un evento trate de extracciones sobre la cuenta bancaria, pero el receptor sólo esté interesado en aquéllas de un monto mayor que 100 unidades.

Patrones de eventos: cuando un objeto se suscribe a eventos de un objeto de interés, puede especificar patrones de eventos sobre los que está interesado. Un patrón especifica una relación entre varios eventos. Por ejemplo, un suscriptor pudiera estar interesado en el caso en que haya tres extracciones de una cuenta bancaria sin un depósito entre medias. Tenemos un requisito similar cuando se correlacionan eventos en una variedad de objetos de interés; por ejemplo, notificar al suscriptor sólo cuando cierto número de ellos han generado eventos.

Buzones de notificaciones: en algunos casos, hay que retrasar las notificaciones hasta que cierto suscriptor particular está listo para recibirlas. Por ejemplo, si el suscriptor tiene conexiones defectuosas o un objeto puede haberse desactivado o activado de nuevo. Un observador podría tomar el papel de buzón de notificaciones, que recibirá las notificaciones en lugar del suscriptor, pasándolas al titular (en un solo envío) sólo cuando el suscriptor esté listo para recibirlas. El suscriptor podrá activar o desactivar el reparto según lo necesite. El suscriptor establece un buzón de notificación cuando se registra frente a un objeto de interés al especificar este buzón como el lugar donde se enviarán las notificaciones.

5.4.2. ESPECIFICACIÓN DE EVENTOS DISTRIBUIDOS DE JINI

La especificación de eventos distribuidos de Jini fue descrita por Arnold y otros [1999] y permite que un suscriptor potencial en una Máquina Virtual Java (JVM, *Java Virtual Machine*) se suscriba y reciba notificaciones de eventos de un objeto de interés en otra JVM, habitualmente en otro computador. Se podría insertar una cadena de observadores entre el objeto de interés y el suscriptor. Los principales objetos involucrados en la especificación de eventos distribuidos son:

Generadores de eventos: un generador de eventos es un objeto que permite que otros objetos se suscriban a sus eventos y generen notificaciones.

Oyentes de eventos remotos: un oyente de eventos remotos es un objeto que puede recibir notificaciones.

Eventos remotos: un evento remoto es un objeto que es pasado por valor a un oyente de eventos remotos. Un evento remoto es el equivalente de lo que hemos llamado una notificación.

Agentes terceros: se pueden interponer agentes tercero entre un objeto de interés y un suscriptor. Son los equivalentes a nuestros observadores.

Un objeto se suscribe a eventos del tipo de éstos al generador de eventos y al especificar un oyente de eventos remotos como destino de las notificaciones.

Para enviar notificaciones desde el generador de eventos al suscriptor se utiliza Java RMI, posiblemente mediante uno o más agentes tercero. Los diseñadores sostienen que los oyentes de eventos debieran replicar a las llamadas de notificación tan pronto como sea posible para evitar retrasos en los generadores de eventos. Éstos pueden procesar cada notificación tras la réplica. También se emplea Java RMI para suscribirse a los eventos. Los eventos Jini se proporcionan mediante las siguientes interfaces y clases:

RemoteEventListener: esta interfaz proporciona un método llamado *notify*. Los suscriptores y los agentes tercero implementan la interfaz *RemoteEventListener* de modo que puedan recibir las notificaciones cuando se invoca el método *notify*. Una instancia de la clase *RemoteEvent* representa una notificación y se pasa como argumento de cada método *notify*.

RemoteEvent: esta clase tiene variables de instancia que contienen:

- Una referencia a un generador de eventos en el que apareció el evento.
- Un identificador de eventos, que especifica el tipo de evento en ese generador de eventos.
- Un número de secuencia, que se aplica a los eventos de ese tipo. El número de secuencia debería incrementarse según ocurren los eventos en el tiempo. Puede usarse para permitir que los receptores ordenen los eventos de cada tipo provenientes de una fuente dada o para evitar aplicar el mismo evento dos veces.
- Un objeto empaquetado. Se aporta cuando el receptor se suscribe a ese tipo de evento y puede ser utilizada por un receptor, con cualquier finalidad. Generalmente, mantiene cualquier información que necesite el receptor para identificar el evento y reaccionar a su aparición. Por ejemplo, podría contener un procedimiento de finalización que haya que ejecutar cuando se notifica.

EventGenerator: esta interfaz proporciona un método llamado *register*. Los generadores de eventos implementan la interfaz *EventGenerator*, cuyo método *register* se emplea para suscribirse a eventos frente al generador de eventos. Los argumentos de *register* especifican:

- Un identificador de eventos, que especifica el tipo de evento.
- Un objeto empaquetado que se devolverá con cada notificación.
- Una referencia remota a un objeto oyente de eventos; el lugar donde enviar las notificaciones.
- El período de cesión que se solicita. El período de cesión especifica la duración de la concesión que requerida por el suscriptor, aunque la concesión real se devuelve con los resultados de *register*. Los tiempos límites sobre las suscripciones evitan el problema de que los generadores de eventos alojen suscripciones de eventos ya inútiles. Se pueden renovar las suscripciones en el caso de que expire el tiempo límite de las suscripciones.

La especificación de Jini indica que la interfaz *EventGenerator* es sólo un ejemplo del tipo de interfaz que podría ser usada por los suscriptores para registrar su interés en los eventos de un objeto de interés. Algunas aplicaciones podrían necesitar un tipo de interfaz diferente.

◊ **Agentes tercero.** Los agentes tercero que se intercalan entre un generador de eventos y un suscriptor pueden jugar una gran variedad de papeles útiles, incluyendo todos los descritos anteriormente.

En el caso más simple, un suscriptor registra su interés sobre un tipo particular de evento frente a un generador de eventos y se especifica a sí mismo como el oyente del evento remoto. Esto se corresponde con el caso 1 mostrado en la Figura 5.10.

Los agentes tercero pueden ser establecidos por un generador de eventos o por un suscriptor.

Un generador de eventos puede interponer uno o más agentes tercero entre el mismo y un suscriptor. Por ejemplo, los generadores de eventos de cada computador podrían utilizar un agente tercero compartido que fuera responsable del reparto fiable de las notificaciones.

Un suscriptor puede construir una cadena de agentes tercero para producir cualquier política de reparto que necesite. Entonces registra su interés frente a un generador de eventos, especificando el primero de la cadena de agentes tercero como el lugar destino de las notificaciones. Por ejemplo un suscriptor podría indicar que sus notificaciones se almacenaran en un agente tercero hasta el momento en que esté listo para recibirlas. El agente tercero puede tomar la responsabilidad de renovar las concesiones.

En la Sección 17.3.2 se discutirá el Servicio de Eventos de CORBA.

5.5. EL CASO DE ESTUDIO JAVA RMI

Java RMI extiende el modelo de objetos de Java para proporcionar soporte de objetos distribuidos en el lenguaje Java. En particular, permite que los objetos invoquen métodos sobre objetos remotos empleando la misma sintaxis que en las invocaciones locales. Además, la comprobación de tipos se aplica de modo igual en las invocaciones remotas como en las locales. Sin embargo, un objeto que realice una invocación remota conoce que su destino es remoto porque debe manejar *RemoteExceptions*; y el implementador de un objeto remoto conoce que es remoto porque debe implementar la interfaz *Remote*. A pesar de que el modelo de objetos distribuidos está integrado en Java de forma natural, la semántica de paso de parámetros difiere en que el objeto que invoca y el destino son remotos entre sí.

La programación de aplicaciones distribuidas en Java RMI debiera ser relativamente simple dado que es un sistema de un solo lenguaje; las interfaces remotas se definen en el lenguaje Java. Al emplear un lenguaje multi-sistema como CORBA, el programador debe conocer un IDL y comprender cómo se relaciona con el lenguaje de implementación. Sin embargo, incluso en un sistema de un solo lenguaje, el programador de un objeto remoto debe considerar su comportamiento en un entorno concurrente.

En el resto de esta introducción, damos un ejemplo de una interfaz remota, para después discutir la semántica de paso de parámetros con referencia al ejemplo. Finalmente discutiremos la descarga de clases y el enlazador. La segunda sección de este caso de estudio discute cómo construir programas cliente y servidor para la interfaz de ejemplo. La tercera sección trata del diseño e implementación de Java RMI. Para todos los detalles de Java RMI, véase el manual sobre invocación remota [[java.sun.com I](#)].

En este caso de estudio y en el caso de estudio CORBA del Capítulo 17, emplearemos el ejemplo de un *tablero* (*whiteboard*). Esta aplicación distribuida permite a un grupo de usuarios compartir la vista común de una superficie de dibujo que contiene objetos gráficos, tales como rectángulos, líneas y círculos, cada uno de los cuales ha sido dibujado por uno de los usuarios. El servidor mantiene el estado actual del dibujo proporcionando a los clientes una operación para informarles sobre la última figura dibujada por sus usuarios y guardando un registro de todas las figuras que hayan sido recibidas. El servidor también proporciona operaciones que permiten a los clientes recuperar las últimas formas dibujadas por otros usuarios mediante un servidor de escrutinio. El servidor tiene un número de versión (un entero) que se incrementa cada vez que llega una nueva forma y se añade a esta nueva forma. El servidor proporciona operaciones que permiten a los clientes preguntar por su número de versión y el número de versión de cada forma, de modo que puedan evitar el recuperar formas que ya poseen.

◊ **Interfaces remotas en Java RMI.** Las interfaces remotas se definen mediante la extensión de una interfaz denominada *Remote* que proporciona el paquete *java.rmi*. Los métodos deberán lanzar *RemoteException*, además de lanzar las excepciones específicas de la aplicación. La Figura 5.11 muestra un ejemplo de dos interfaces remotas denominadas *Forma* y *ListaForma*. En este ejemplo, *ObjetoGrafico* es una clase que aloja el estado del objeto gráfico, por ejemplo su tipo,

```

import java.rmi.*;
import java.util.Vector;
public interface Forma extends Remote {
    int dameVersion() throws RemoteException;
    ObjetoGrafico dameTodoEstado() throws RemoteException;
}
public interface ListaForma extends Remote {
    Forma nuevaForma(ObjetoGrafico g) throws RemoteException;
    Vector todasFormas() throws RemoteException;
    int dameVersion() throws RemoteException;
}

```

Figura 5.11. Interfaces *Remote* en Java para *Forma* y *ListaForma*.

posición, el rectángulo que la encierra, el color de línea y el color de relleno, y proporciona operaciones para acceder y actualizar su estado. *ObjetoGrafico* debe implementar la interfaz *Serializable*. Considere primero la interfaz *Forma*: el método *dameVersion* devuelve un entero, mientras que *dameTodoEstado* devuelve una instancia de la clase *ObjetoGrafico*. Ahora considere la interfaz *ListaForma*: su método *nuevaForma* pasa una instancia de *ObjetoGrafico* como argumento pero devuelve un objeto con una interfaz remota (es decir, un objeto remoto) como resultado. Un detalle importante es advertir que tanto los objetos ordinarios como los objetos remotos pueden aparecer como argumentos y resultados de una interfaz remota. Estos últimos se denotan por el nombre de su interfaz remota. En el próximo párrafo, discutimos cómo se pasan como argumento y como resultado los objetos ordinarios y los objetos remotos.

◊ **Paso de parámetros y resultados.** En Java RMI, se supone que los parámetros de un método son parámetros de *entrada* y el resultado de un método es un único parámetro de *salida*. La Sección 4.3.2 describía la serialización en Java, que es empleada para empaquetar los argumentos y los resultados en Java RMI. Cualquier objeto que sea serializable, es decir, que implemente la interfaz *Serializable*, puede pasarse como argumento o resultado en Java RMI. Todos los tipos primitivos y los objetos remotos son serializables. El receptor puede descargar las clases para los argumentos y los valores resultantes cuando sea necesario mediante el sistema RMI.

Paso de objetos remotos: cuando el tipo del valor de parámetro o de resultado implementa una interfaz remota, el correspondiente argumento o resultado siempre se pasa como una referencia a un objeto remoto. Por ejemplo, en la Figura 5.2 (en la línea 2) el valor de retorno del método *nuevaForma* se define como *Forma*, una interfaz remota. Cuando se recibe una referencia a un objeto remoto, puede ser utilizado para hacer llamadas RMI sobre el objeto remoto al que se refiere.

Paso de objetos no remotos: todos los objetos no remotos serializables se copian y se pasan por valor. Por ejemplo, en la Figura 5.11 (en las líneas 2 y 1) el argumento de *nuevaForma* y el valor devuelto por *dameTodoEstado* son del tipo *ObjetoGrafico*, que es serializable y es pasado por valor. Cuando se pasa un objeto por valor, se crea un nuevo objeto en el proceso del receptor. Los métodos de este nuevo objeto pueden invocarse localmente, causando, posiblemente, que su estado difiera del estado del objeto original del proceso que lo envió.

Consiguióntemente, en nuestro ejemplo, el cliente usa el método *nuevaForma* para pasar una instancia de *ObjetoGrafico* al servidor; el servidor crea un objeto remoto del tipo *Forma* que contiene el estado del *ObjetoGrafico* y devuelve una referencia remota a él. Los argumentos y valores devueltos de una invocación remota se serializan para encauzarlos empleando el método descrito en la Sección 4.3.2, con las siguientes modificaciones:

1. Cuando quiera que un objeto que implemente la interfaz *Remote* sea serializado, se reemplaza por su referencia a objeto remoto, que contiene el nombre de su clase (la del objeto remoto).
2. Cuando quiera que sea serializado un objeto, se anota su información de clase con la ubicación de la clase (como un URL), permitiendo la descarga de la clase por el receptor.

◇ **Descarga de las clases.** Java está diseñado para permitir la descarga de las clases desde una máquina virtual a otra. Esto es particularmente relevante para que los objetos remotos se comuniquen mediante la invocación remota. Hemos visto que los objetos no remotos se pasan por valor y los objetos remotos se pasan por referencia como argumentos y resultados de cada RMI. Si el receptor no posee ya la clase de un objeto que es pasado por valor, su código se descargará automáticamente. De igual modo, si el receptor de una referencia a un objeto remoto no posee ya la clase de un proxy, se descargará automáticamente su código. Esto permite dos ventajas:

1. No hay necesidad alguna de que cada usuario presente el mismo conjunto de clases en su entorno de trabajo.
2. Tanto los programas cliente como servidor pueden hacer un uso transparente de las instancias de las clases nuevas cuando quiera que éstas se añadan.

Como ejemplo, considere el programa de tablero y suponga que su implementación inicial de *ObjetoGrafico* no contempla el texto. Entonces un cliente con un objeto textual podrá implementar una subclase de *ObjetoGrafico* que trate con texto y pase una instancia al servidor como argumento del método *nuevaForma*. Tras ello, otros clientes podrán recuperar la instancia utilizando el método *dameTodaForma*. El código de la nueva clase se descargará automáticamente desde el primer cliente hacia el servidor y desde ahí a los otros clientes según lo vayan necesitando.

◇ **RMIregistry.** RMIregistry es el enlazador para Java RMI. En cada computador de servicio que aloje objetos remotos deberá haber un ejemplar de RMIregistry. Éste da soporte a una relación en forma de tabla textual, que contiene nombres al estilo URL y referencias a objetos remotos presentes en ese computador. Se accede a ella mediante métodos de la clase *Naming*, cuyos métodos toman como argumento una cadena formateada al estilo URL de la siguiente forma:

```
//nombreComputador:puerto/nombreObjeto
```

donde *nombreComputador* y *puerto* se refieren a la ubicación de RMIregistry. Si se omite, se presupone que es el computador local y el puerto por defecto. Su interfaz ofrece los métodos que se muestran en la Figura 5.12, en la que no se listan las excepciones (todos los métodos pueden lanzar *RemoteException*). Este servicio no es un sistema de enlace con amplitud de sistema. Los clientes deben dirigir sus consultas (*lookup*) a computadores concretos.

5.5.1. CONSTRUCCIÓN DE PROGRAMAS CLIENTES Y SERVIDORES

Esta sección bosqueja los pasos necesarios para producir programas clientes y servidores que empleen las interfaces *Remote*: *Forma* y *ListaForma* que se muestran en la Figura 5.11. El programa servidor es una versión simplificada de un servidor de tipo tablero que implementa las dos interfaces *Forma* y *ListaForma*. Describiremos un programa cliente simple de escrutinio y presentaremos la técnica de devolución de llamada que se emplea para evitar la necesidad de sondear al servidor. Las versiones completas de las clases que se ilustran en esta sección están disponibles en cdk3.net/rmi.

◇ **Programa servidor.** El servidor es un servidor de tablero: representa cada forma como un objeto remoto que implementa la interfaz *Forma* y mantiene el estado de un objeto gráfico así

```
void rebind(String nombre, Remote obj)
```

Este método es empleado por un servidor para registrar el identificador de un objeto remoto mediante su nombre, como se indica en la Figura 5.13, en la línea 3.

```
void bind(String nombre, Remote obj)
```

Este método puede ser empleado, alternativamente al anterior, por un servidor para registrar un objeto remoto mediante su nombre, pero si el nombre ya está ligado a una referencia a un objeto remoto se lanza una excepción.

```
void unbind(String nombre, Remote obj)
```

Este método destruye un enlace.

```
Remote lookup(String nombre)
```

Este método es usado por los clientes para buscar un objeto remoto mediante su nombre, según se indica en la Figura 5.15, en la línea 1. Devuelve una referencia a un objeto remoto.

```
String [ ] list()
```

Este método devuelve una tira de *Strings* que contienen los nombres enlazados del registro.

Figura 5.12. La clase *Naming* de Java RMIregistry.

como su número de versión; representa su conjunto de formas mediante un objeto remoto que implementa la interfaz *ListaForma* y mantiene un conjunto de formas en un *Vector*.

El servidor consta de un método *main* y una clase sirviente para implementar cada una de sus interfaces remotas. El método *main* del servidor crea una instancia de *SirvienteListaForma* y la enlaza a un nombre en RMIregistry, como se muestra en la Figura 5.13 (en las líneas 1 y 2). Adviértase que el valor ligado al nombre es una referencia a un objeto remoto, y su tipo es el tipo de su interfaz remota (*ListaForma*). Las dos clases sirvientes son *SirvienteListaForma*, que implementa la interfaz *ListaForma*, y *SirvienteForma*, que implementa la interfaz *Forma*. La Figura 5.14 proporciona un bosquejo de la clase *SirvienteListaForma*. Observe que *SirvienteListaForma* (en la línea 1), como muchas clases sirvientes, extiende una clase denominada *UnicastRemoteObject*, que proporciona objetos remotos que duran tanto tiempo como el proceso en que son creadas.

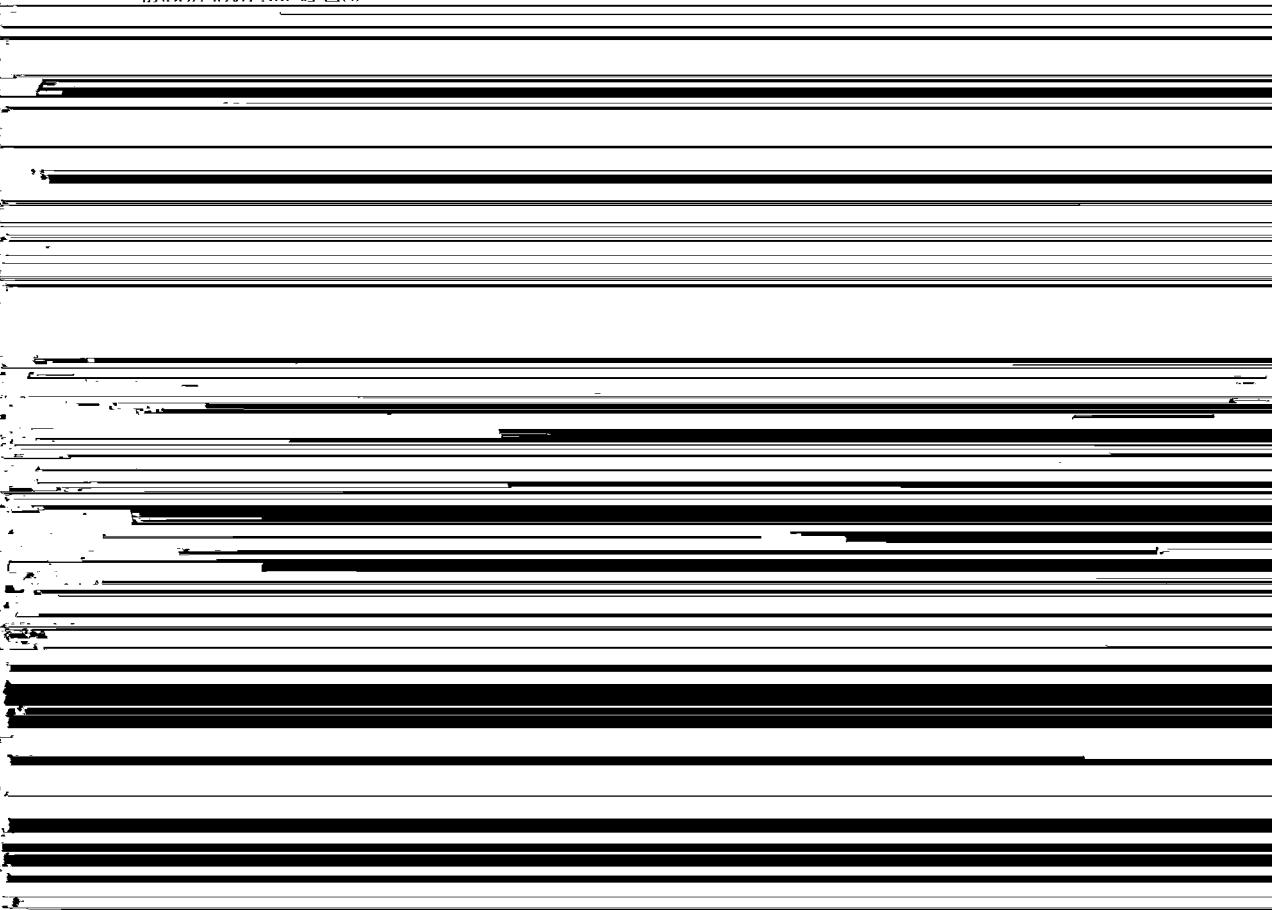
Las implementaciones de los métodos de la interfaz remota en una clase sirviente son directas dado que pueden escribirse sin que importen los detalles de la comunicación. Observe que el método de *nuevaForma* de la Figura 5.14 (en la línea 2), puede considerarse un método factoría dado que permite al cliente la creación de un objeto remoto. Emplea el constructor *SirvienteForma*, que crea un nuevo objeto remoto que contiene el *ObjetoGrafico* y el número de versión, que se pasan como argumentos. El tipo del valor devuelto por *nuevaForma* es *Forma*; la interfaz que implementa el nuevo objeto remoto. Antes de devolver el control, el método *nuevaForma* añade la forma nueva a su vector, que ya contiene la lista de formas (véase la línea 3).

```
import java.rmi.*;
public class ServidorListaForma{
    public static void main(String args[]){
        System.setSecurityManager(new RMISecurityManager());
        try{
            ListaForma unaListaForma = new SirvienteListaForma();
            Naming.rebind("Lista Forma", unaListaForma);
            System.out.println("Servidor de ListaForma listo");
        }catch (Exception e){
            System.out.println("main del servidor ListaForma:" + e.getMessage());
        }
    }
}
```

1
2

Figura 5.13. Clase Java *ServidorListaForma* con el método *main*.

```
import java.rmi.*;
import java.rmi.server.UnicastRemoteObject;
import java.util.Vector;
```



```
import java.rmi.*;
import java.rmi.server.UnicastRemoteObject;
import java.util.Vector;

public SirvienteListaForma( ) throws RemoteException{...}
public Forma nuevaForma(ObjetoGrafico g) throws RemoteException {
    version++;
    Forma s = new SirvienteForma(g, version);
    laLista.addElement(s);
    return s;
}
public Vector todasFormas( ) throws RemoteException{...}
public int dameVersion( ) throws RemoteException { ... }
}
```

Figura 5.14. Clase Java *SirvienteListaForma* implementando la interfaz *ListaForma*.

durante su ejecución, de acuerdo con las necesidades de la aplicación. En nuestro ejemplo, el cliente invoca el método *todasFormas* en el objeto remoto (véase la línea 2) y recibe un vector de referencias a objetos remotos para todas las formas almacenadas en ese momento en el servidor. Si el cliente implementara un visualizador para el tablero, utilizaría el método del servidor *dameTodoEstado* de la interfaz *Forma* para recuperar cada uno de los objetos gráficos en el vector y mostrarlos en una ventana. Cada vez que el usuario complete un objeto gráfico, invocará el método *nuevaForma* en el servidor, pasando como argumento el nuevo objeto gráfico. El cliente conservará un registro del último número de versión en el servidor, y de vez en cuando invocará el método *dameVersion* del servidor para conocer si otros usuarios han añadido nuevas formas. Si es así, las recuperará y visualizará.

◊ **Devolución de llamada.** La idea básica de la devolución de llamada es que en lugar de que los clientes sondeen al servidor para buscar si ha ocurrido algún evento, el servidor debería informarles si ha ocurrido algún evento. El término *devolución de llamada* se emplea para referirse a la acción del servidor en que notifica a los clientes acerca de un evento. Las devoluciones de llamada pueden implementarse en RMI como sigue:

- El cliente crea un objeto remoto que implementa una interfaz que contiene un método para que lo invoque el servidor. A este objeto lo denominamos objeto de devolución de llamada o de retrollamada.
- El servidor proporciona una operación que permite a los clientes interesados informarle de sus referencias a objetos remotos de sus objetos de retrollamada. El servidor las almacena en una lista.
- Cuando quiera que aparezca un evento de interés, el servidor llamará a los clientes interesados. Por ejemplo, el servidor de tablero llamará a sus clientes cuando quiera que se añada un objeto gráfico.

El empleo de devoluciones de llamada evita la necesidad de que un cliente sondee los objetos de interés en el servidor y las desventajas de atenderlas:

- Las prestaciones del servidor pueden degradarse si se somete a una encuesta constante.
- Los clientes podrían no notificar de las actualizaciones a los usuarios, si se basa en un método de tiempo.

Sin embargo, las devoluciones de llamada tienen otros problemas: primero, el servidor necesita tener una lista actualizada de los objetos de devolución de llamada de sus clientes. Pero puede que los clientes no siempre informen al servidor antes de terminarse, con lo que dejarán al servidor con listas incorrectas. Podría utilizarse la técnica de *concesiones*, que se discutió en la Sección 5.2.6, para soslayar este problema. El segundo problema asociado con las devoluciones de llamada, es que el servidor necesita realizar una serie de RMI síncronas a los objetos de retrollamada de la lista. Véase la Sección 5.4.1 y el Ejercicio 5.18 con algunas ideas sobre cómo resolver el segundo problema.

Ilustraremos el empleo de devoluciones de llamada en el contexto de la aplicación de tablero. La interfaz *RetrollamadaTablero* podría definirse como sigue:

```
public interface RetrollamadaTablero implements Remote {
    void retrollamada(int version) throws RemoteException;
};
```

Esta interfaz viene implementada en forma de objeto remoto por parte del cliente, permitiendo que el servidor le envíe un número de versión cuando vea que se añade un objeto nuevo. Aunque previamente a que el servidor pueda hacerlo, el cliente necesita informar al servidor sobre su objeto

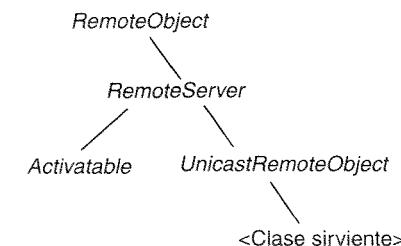
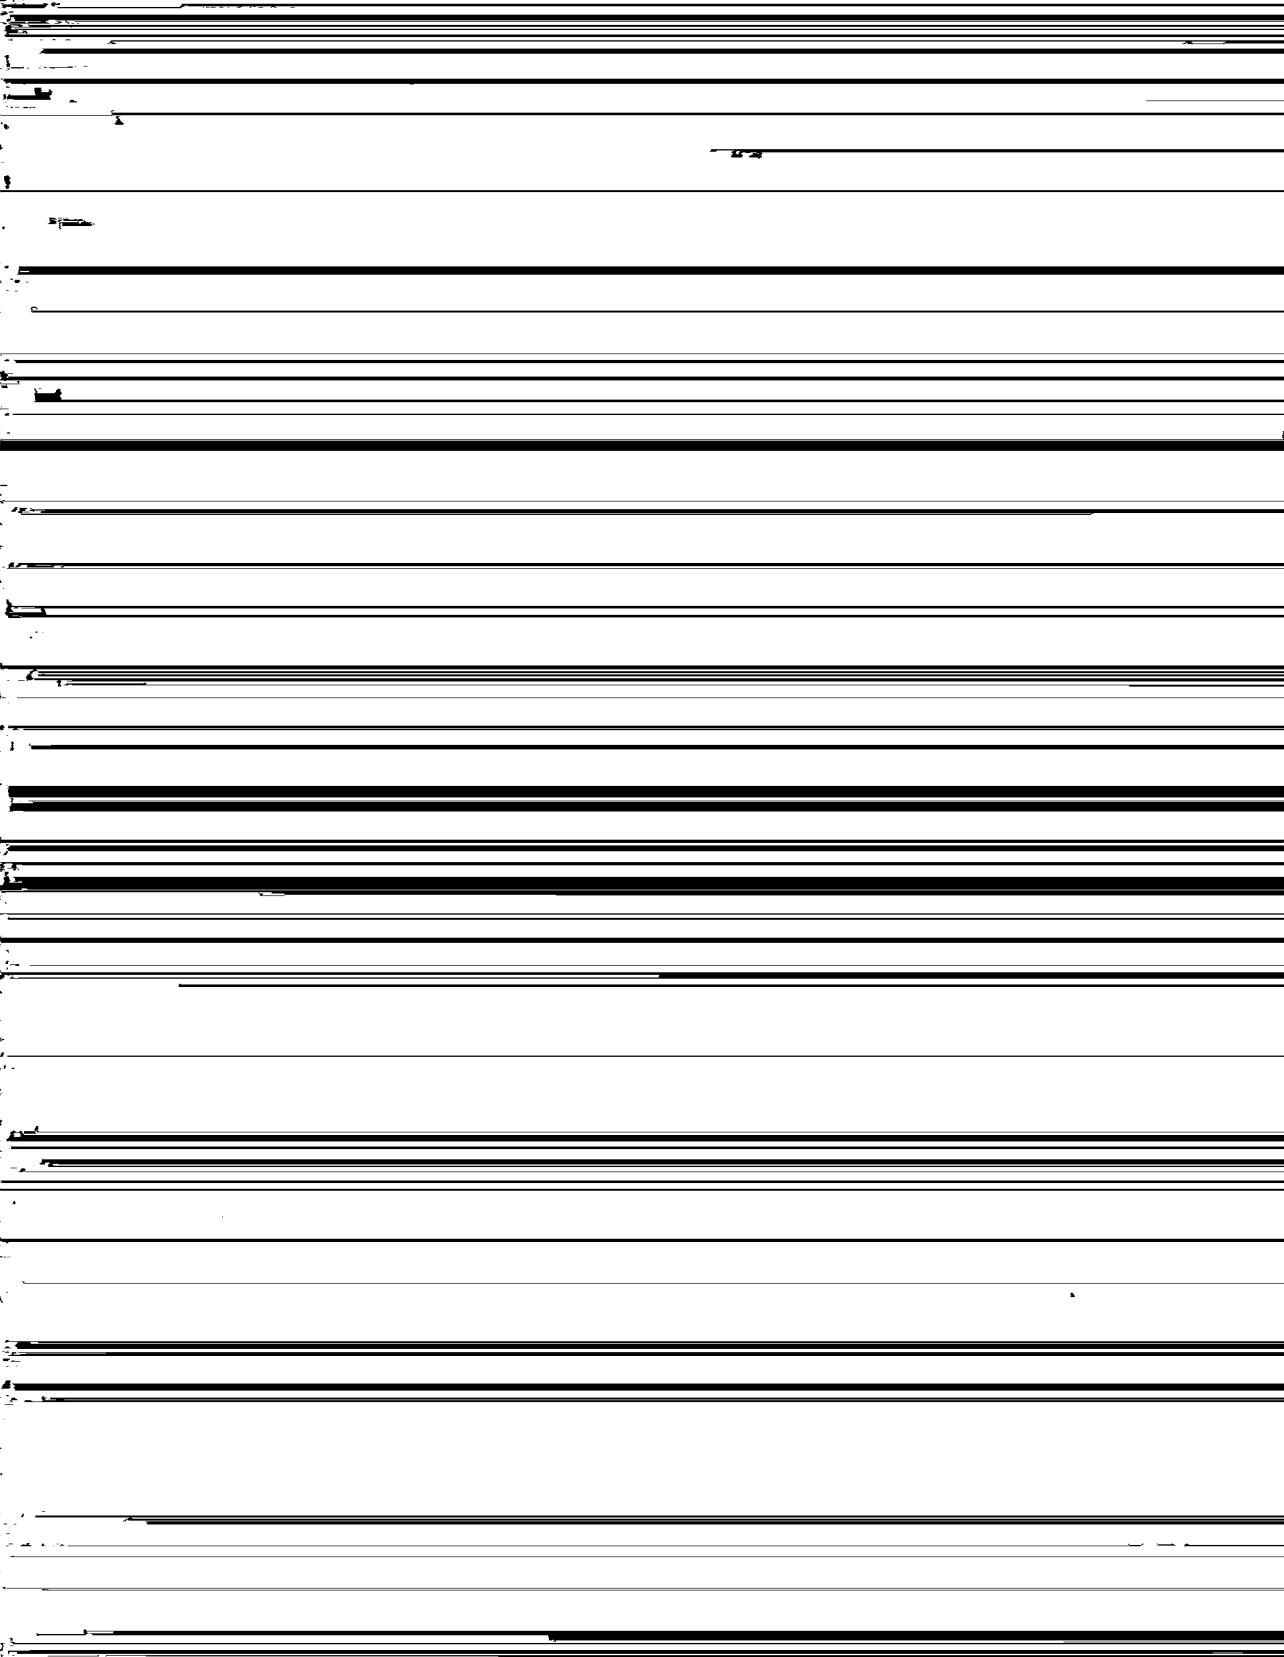


Figura 5.16. Clases de soporte de Java RMI.

varias alternativas más para objetos replicados. La clase *RemoteServer* es una subclase de *RemoteObject* que tiene una variable de instancia que aloja la referencia al objeto remoto y proporciona los siguientes métodos:

- equals*: este método compara referencias a objetos remotos;
- toString*: este método proporciona los contenidos de una referencia a un objeto remoto en forma de *String*;
- readObject*, *writeObject*: estos métodos deserializan/serializan objetos remotos.

Además, se puede utilizar el operador *instanceOf* para comprobar objetos remotos.

5.6. RESUMEN

Este capítulo ha discutido dos paradigmas de la programación distribuida: la invocación de métodos remotos y los sistemas basados en eventos. Ambos paradigmas contemplan los objetos como entidades independientes que pueden recibir invocaciones desde objetos remotos. En el primer caso, un método en la interfaz remota de un objeto particular es invocado síncronamente (el que invoca espera por la respuesta). En el segundo caso, se envían notificaciones asíncronamente a varios múltiples suscriptores cuando quiera que ocurra un evento publicado hacia un objeto interesado.

El modelo de objetos distribuidos es una extensión del modelo de objetos locales que se emplea en los lenguajes de programación basados en objetos. Los objetos encapsulados constituyen componentes útiles en un sistema distribuido, puesto que la encapsulación los hace enteramente responsables de gestionar su propio estado, y la invocación de métodos locales puede extenderse hacia la invocación remota. Cada objeto de un sistema distribuido tiene una referencia a un objeto remoto (un identificador global único) y una interfaz remota que especifica cuáles de sus operaciones pueden ser invocadas remotamente.

Una invocación a un método local da una semántica del tipo *exactamente una vez*, mientras que una invocación remota no puede dar las mismas garantías dado que los objetos participantes están en computadores diferentes, que pueden fallar independientemente y están ligados por una red, que también podría fallar. Lo mejor que podemos obtener es una semántica del tipo *como máximo una vez*. Debido a sus diferentes características de fallo y prestaciones, y a la posibilidad de acceso concurrente a estos objetos remotos, no parece una buena idea hacer que una invocación remota parezca idéntica a una invocación local.

Las implementaciones de middleware para RMI proporcionan componentes (que comprenden: proxy, esqueleto y distribuidor) que ocultan los detalles del empaquetado, el paso de mensajes y la localización de los objetos remotos desde los programas cliente y servidor. Estos componentes pueden generarse mediante un compilador de interfaces. Java RMI extiende la invocación local en invocación remota empleando la misma sintaxis, pero habrá que especificar las interfaces remotas

como una extensión de una interfaz denominada *Remote* y también cada método deberá lanzar la

como una extensión de una interfaz denominada *Remote* y también cada método deberá lanzar la

- 5.7. El servicio *Eleccion* debe garantizar que todos los votos se almacenan de modo seguro incluso cuando el proceso de servicio se malogra. Explique cómo puede conseguirse tomando como referencia el bosquejo de implementación de su respuesta al Ejercicio 5.6.

- 5.8. Muestre cómo utilizar la reflexión de Java para construir la clase proxy del cliente para la interfaz del servicio *Eleccion*. De los detalles de la implementación de uno de los métodos de esta clase, el cual debería llamar al método *hazOperacion* que posee la siguiente firma:

```
byte [ ] hazOperacion (RemoteObjectRef o, Method m, byte [ ] argumentos);
```

Sugerencia: cualquier variable de instancia de la clase proxy debería alojar una referencia a un objeto remoto (véase el Ejercicio 4.12).

- 5.9. Muestre cómo generar una clase proxy del cliente empleando un lenguaje como C++ (sin soporte de reflexión), por ejemplo para la definición de interfaz en CORBA dada en su respuesta al Ejercicio 5.3. De los detalles de la implementación de uno de los métodos de esta clase, que debería llamar al método *hazOperacion* definido en la Figura 4.12.

- 5.10. Explique cómo emplear la reflexión de Java para construir un distribuidor genérico. Dé el código en Java para un distribuidor cuya firma sea:

```
public void despacha(Object destino, Method unMetodo, byte [ ] argumentos);
```

Los argumentos proporcionan el objeto destino, el método que se ha de invocar y los argumentos para ese método en una cadena de bytes.

- 5.11. El Ejercicio 5.8 requería que el cliente convirtiera argumentos de tipo *Object* en una cadena de bytes antes de invocar *hazOperacion* y el Ejercicio 5.10 requería que el distribuidor convirtiera una cadena de bytes en una cadena de elementos de tipo *Object* antes de invocar el método. Discuta la implementación de una nueva versión de *hazOperacion* con la siguiente firma:

```
Object [ ] hazOperacion(RemoteObjectRef o, Method m, Object [ ] argumentos);
```

Que emplea las clases *FlujoSalidaObjeto* y *FlujoEntradaObjeto* para encauzar los mensajes de petición y respuesta entre el cliente y el servidor sobre una conexión TCP. ¿Cómo afectarán estos cambios al diseño del distribuidor?

- 5.12. Un cliente realiza llamadas a procedimientos remotos de un servidor. El cliente invierte 5 milisegundos en calcular los argumentos para cada petición, y el servidor se toma 10 milisegundos para procesar cada respuesta. El tiempo de procesamiento del sistema operativo local, para cada envío y recepción, es de 0,5 milisegundos, y el tiempo de la red para transmitir cada petición o cada respuesta es de 3 milisegundos. Tanto el empaquetado como el desempaquetado llevan 0,5 milisegundos por cada mensaje.

Calcúlese el tiempo que se invierte en el cliente para generar y volver de dos peticiones:

- (i) Si es de un solo hilo.
- (ii) Si tiene dos hilos que pueden hacer peticiones concurrentes sobre un único procesador.

Pueden ignorarse los tiempos de cambio de contexto. ¿Es necesario que RPC sea asíncrona si los procesos cliente y servidor son multihilo?

- 5.13. Diseñe una tabla de objetos remotos que pueda soportar compactación automática de memoria distribuida así como la traducción entre las referencias a objetos locales y remotos. Dé un ejemplo que implique varios objetos remotos y varios proxy en varios lugares para

Dé un ejemplo que implique varios objetos remotos y varios proxy en varios lugares para

6

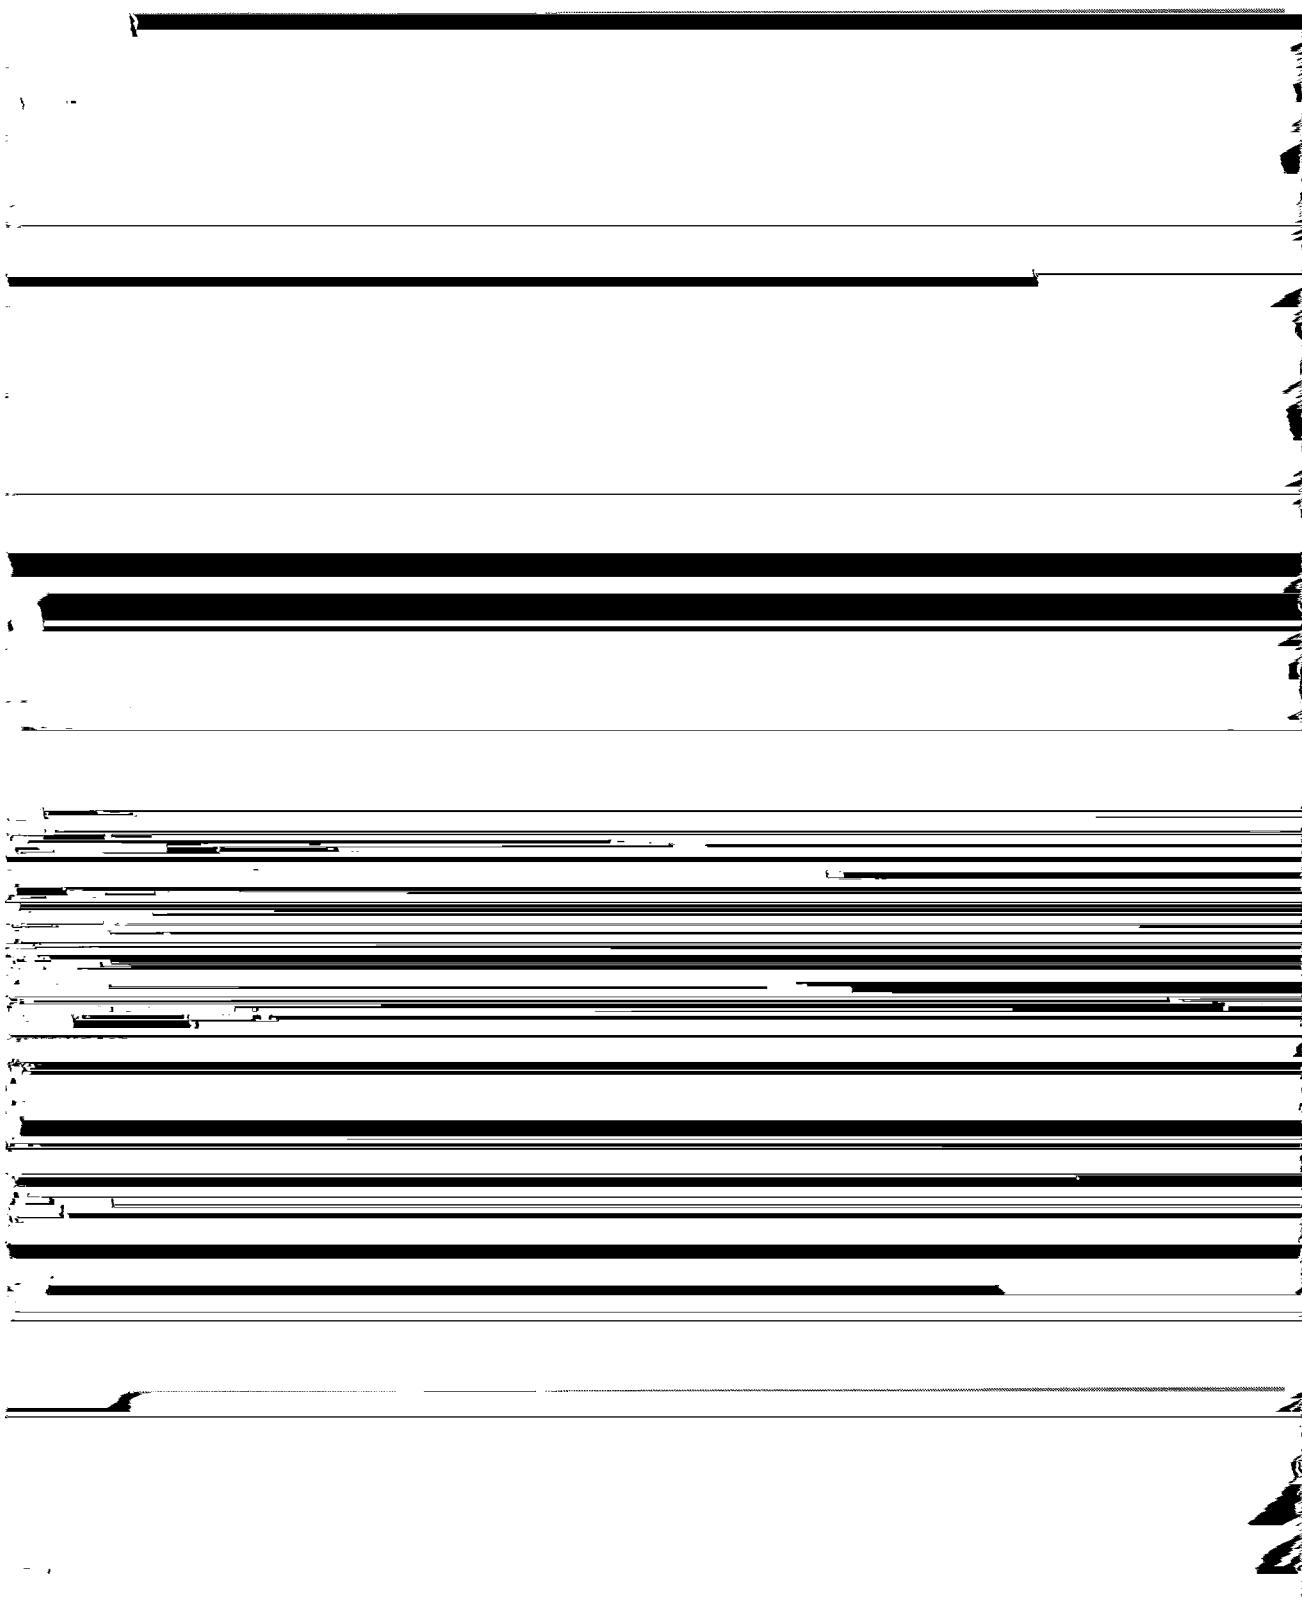
SOPORTE DEL SISTEMA OPERATIVO

- 6.1. Introducción
- 6.2. El nivel de sistema operativo
- 6.3. Protección
- 6.4. Procesos e hilos
- 6.5. Comunicación e invocación
- 6.6. Arquitectura del sistema operativo
- 6.7. Resumen

Este capítulo describe cómo los servicios del sistema operativo en los nodos de un sistema distribuido dan soporte al middleware. El sistema operativo facilita la encapsulación y protección de los recursos dentro de los servidores; además soporta los mecanismos de invocación requeridos para el acceso a dichos recursos, incluyendo comunicación y planificación.

Una cuestión importante en este capítulo es el papel del núcleo del sistema. Este capítulo aspira a proporcionar al lector la comprensión de las ventajas e inconvenientes de la división de la funcionalidad entre dominios de protección; en particular, la división de la funcionalidad entre el núcleo y el código de nivel de usuario. Se discute la relación entre los recursos del nivel de núcleo y los del nivel de usuario, incluyendo el enfrentamiento entre la eficiencia y la robustez.

El capítulo analiza el diseño e implementación del procesamiento multi-hilo y de los servicios de comunicación. Además, se exploran las principales arquitecturas de núcleo que han sido desarrolladas.



ción. Por ejemplo, se puede crear un nuevo proceso en el nodo con menor carga de trabajo del sistema, para evitar que pueda haber nodos sobrecargados arbitrariamente.

Un sistema operativo que genera, según la forma descrita, una única imagen del sistema para todos los recursos en un sistema distribuido se llama *sistema operativo distribuido* [Tanenbaum y van Renesse 1985].

◊ **Middleware y sistemas operativos en red.** En realidad, no se emplea ampliamente ningún sistema operativo distribuido, sino sólo sistemas operativos en red del tipo de UNIX, MacOS y diferentes variantes de Windows. Esta situación tiende a mantenerse, principalmente por dos razones. La primera es que los usuarios ya han realizado grandes inversiones en su software de aplicación, que normalmente resuelve sus problemas; por lo tanto no cambiarán a un nuevo sistema operativo que es incapaz de ejecutar sus aplicaciones, por muchas ventajas que ofrezca. Se han realizado distintos esfuerzos para emular los núcleos de UNIX y otros sistemas operativos sobre otros núcleos, pero las prestaciones de estas emulaciones no han sido nunca satisfactorias. En cualquier caso, el mantener actualizadas las emulaciones de los principales sistemas operativos al tiempo que evolucionan sería una tarea incalculable.

La segunda razón en contra de la utilización de un sistema operativo distribuido es que los usuarios prefieren tener autonomía en la gestión de sus propias máquinas, incluso en organizaciones fuertemente cohesionadas. Esto es así, concretamente, para conseguir buenas prestaciones [Douglis y Ousterhout 1991]. Por ejemplo, Pérez necesita buena respuesta interactiva mientras escribe sus documentos y podría molestarse si los programas de González retrasaran su trabajo. La combinación de middleware y sistemas operativos en red proporciona un equilibrio aceptable entre los requisitos de autonomía, por un lado, y la transparencia de red en el acceso a recursos, por el otro. Los sistemas operativos en red permiten a los usuarios ejecutar su procesador de textos preferido junto con otro tipo de aplicaciones de tipo independiente. El middleware les permite acceder a los servicios que aparecen como disponibles en el sistema distribuido.

En la siguiente sección se explica el funcionamiento del nivel de sistema operativo. En la Sección 6.2 se examinan los mecanismos de bajo nivel dedicados a la protección de recursos; éstos son necesarios para comprender la relación entre procesos e hilos y el papel del núcleo. La Sección 6.4 examina las abstracciones de proceso, espacio de direcciones e hilos. En este apartado los principales conceptos son la concurrencia, la gestión y protección de recursos locales y la planificación. La Sección 6.5 estudia las comunicaciones como parte de los mecanismos de invocación. La Sección 6.6 abarca las diferentes arquitecturas existentes de sistemas operativos, incluyendo los diseños monolíticos y de micronúcleo. En el Capítulo 18 se realizará un estudio del núcleo de Mach. El lector podrá encontrar estudios del caso para los sistemas operativos Amoeba, Chorus y Clouds en www.cdk3.net/oss.

6.2. EL NIVEL DE SISTEMA OPERATIVO

Los usuarios únicamente estarán satisfechos si la combinación entre el middleware y el sistema operativo proporciona buenas prestaciones. El middleware se ejecuta en múltiples combinaciones hardware/sistema operativo, es decir, en múltiples plataformas en los nodos de un sistema distribuido. El sistema operativo que se ejecuta en un cierto nodo (un núcleo junto con los servicios asociados de nivel de usuario, por ejemplo bibliotecas) proporciona dentro de ese nodo su propia imagen sobre las abstracciones de los recursos hardware locales de procesamiento, de almacenamiento y de comunicación. El middleware utiliza una combinación de esos recursos locales para implementar los mecanismos de invocación remota entre objetos o procesos en los nodos.

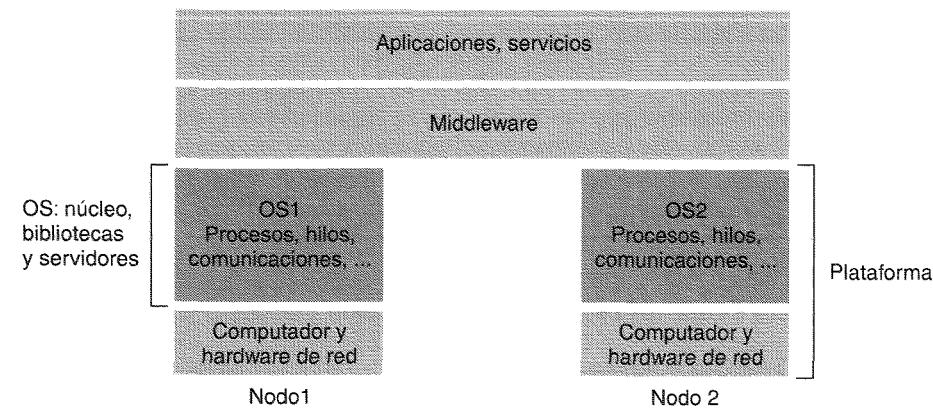


Figura 6.1. Niveles del sistema.

La Figura 6.1 muestra cómo el nivel de sistema operativo en cada uno de los dos nodos soporta un nivel de middleware común para proporcionar una infraestructura distribuida para aplicaciones y servicios.

Nuestro objetivo en este capítulo es examinar el impacto que los mecanismos concretos de los sistemas operativos tienen en la habilidad del middleware para proporcionar compartición de recursos distribuida a los usuarios. Los núcleos y los procesos cliente y servidor que se ejecutan entre ellos son los principales componentes de la arquitectura sobre los que trataremos. Los núcleos y el proceso servidor son los componentes que gestionan los recursos y los presentan a los clientes a través de una interfaz de recursos. Esta interfaz debe tener al menos las siguientes características:

Encapsulamiento: debe proporcionar un servicio de interfaz útil sobre los recursos, es decir, un conjunto de operaciones que cubra las necesidades de sus clientes. Los detalles del tipo gestión de la memoria o dispositivos utilizados para implementar los recursos deben ocultarse a los clientes.

Protección: los recursos deben protegerse de los accesos no permitidos; por ejemplo, los archivos se protegen contra la lectura por parte de usuarios que no tengan dicho permiso, así como los registros de los dispositivos se protegen de los procesos de usuario.

Procesamiento concurrente: los clientes pueden compartir múltiples recursos y acceder a ellos concurrentemente. Los gestores de dichos recursos son los responsables de conseguir transparencia en la concurrencia.

Los clientes acceden a los recursos mediante, por ejemplo, invocaciones a un método remoto de un objeto que reside en un cierto servidor o bien mediante llamadas al sistema en el núcleo. El mecanismo de acceso a un recurso encapsulado se denomina *mecanismo de invocación*, independientemente de cómo esté implementado. Una combinación de bibliotecas, núcleos y servidores puede utilizarse para realizar las siguientes tareas de invocación:

Comunicación: los parámetros de operación y los resultados deben pasarse hacia y desde los gestores de recursos, respectivamente, utilizando una red o bien dentro del computador.

Planificación: cuando se invoca una cierta operación, su procesamiento debe planificarse dentro del núcleo o del servidor.

La Figura 6.2 muestra la funcionalidad básica del sistema operativo la cual está relacionada con: la gestión de procesos e hilos, la gestión de la memoria, y la comunicación entre procesos en el mismo computador (las divisiones horizontales en la figura indican dependencias). El núcleo propor-

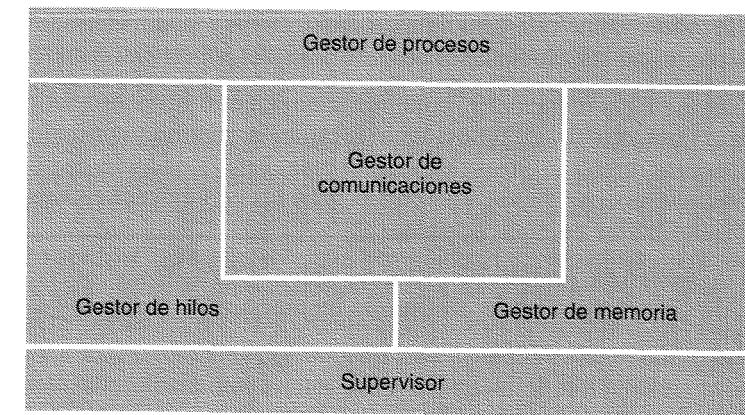


Figura 6.2. Funcionalidad básica del sistema operativo.

ciona la mayor parte de esta funcionalidad; o bien la proporciona de forma completa en el caso de algunos sistemas operativos.

El software del sistema operativo se diseña para ser portable, en la mayor medida en que sea posible, entre las diferentes arquitecturas de computadores. Esto supone que en su mayor parte se codifica en un lenguaje de alto nivel, ya sea C, C++ o Modula-3, y que sus servicios se organizan por niveles de forma que los componentes dependientes de la máquina se reducen a un único nivel inferior. Algunos núcleos pueden ejecutarse en multiprocesadores de memoria compartida, cuestión que se discute en el siguiente recuadro.

◊ **Multiprocesadores de memoria compartida.** Los computadores multiprocesador de memoria compartida se componen de varios procesadores que comparten uno o más módulos de memoria (RAM). De forma añadida, los procesadores pueden tener también su propia memoria privada. Los computadores multiprocesador se pueden construir de diferentes formas [Stone 1993]. Los multiprocesadores más simples y menos caros están construidos incorporando una tarjeta que contiene unos pocos procesadores (2-8) en un computador personal.

En la *arquitectura de procesamiento simétrico* cada procesador ejecuta el mismo núcleo y los núcleos realizan, en su mayor parte, las mismas tareas en la gestión de los recursos hardware. Los nucleos comparten las estructuras de datos clave como la cola de hilos en estado de ejecución, siendo sin embargo privados parte de sus datos de trabajo. Cada procesador puede ejecutar un hilo de forma simultánea, el cual accede a datos de la memoria compartida, que pueden ser privados (protegidos mediante hardware) o compartidos con otros hilos.

Los multiprocesadores se pueden utilizar para múltiples tareas de computación de altas prestaciones. En los sistemas distribuidos son particularmente muy utilizados para la implementación de servidores de altas prestaciones ya que el servidor puede ejecutar un único programa con varios hilos los cuales gestionan varias solicitudes llegadas de diferentes clientes de forma simultánea, proporcionando, por ejemplo, el acceso a una base de datos compartida (véase la Sección 6.4).

Los principales componentes de un sistema operativo son los siguientes:

Gestor de procesos: gestiona la creación y las diferentes operaciones sobre procesos. Un proceso es una unidad de gestión de recursos que incluye un espacio de direcciones y uno o más hilos.

Gestor de hilos: incluye la creación, sincronización y planificación de hilos. Los hilos son actividades planificables asociadas a procesos. Se describen de forma completa en la Sección 6.4.

Gestor de las comunicaciones: comunicaciones entre hilos asociados a diferentes procesos en un mismo computador. Algunos núcleos también soportan comunicaciones entre hilos asociados a procesos remotos. Otros núcleos no manejan el concepto de computador remoto de forma que deben añadirse servicios adicionales para las comunicaciones externas. La Sección 6.5 trata del diseño de las comunicaciones.

Gestor de memoria: gestión de memoria física y virtual. Las Secciones 6.4 y 6.5 describen la utilización de las técnicas de gestión de memoria para la copia y la compartición de datos de forma eficiente.

Supervisor: resolución de interrupciones, interrupciones internas de llamada al sistema y otras excepciones; control de la unidad de gestión de memoria y de las antememorias (caché) hardware; manipulación de registros del procesador y de la unidad en punto flotante. A todo esto se le llama Nivel de Abstracción del Hardware en Windows NT. El lector puede acudir a Bacon [1998] y Tanenbaum [1992] para una descripción más completa de los aspectos del núcleo que son más dependientes del computador.

6.3. PROTECCIÓN

Como se dijo previamente, los recursos necesitan protección contra los accesos no permitidos. Hay que tener en cuenta que las amenazas a la integridad de un sistema no provienen únicamente de código ideado de forma maliciosa. También un código bien intencionado puede contener un error o puede tener un comportamiento no esperado, provocando que parte del sistema se comporte a su vez de forma incorrecta.

Para comprender lo que se quiere decir con «acceso ilegítimo» a un recurso, consideremos un archivo. Supongamos, a efectos de explicación, que sobre los archivos abiertos, únicamente se pueden realizar dos operaciones, *lectura* y *escritura*. La protección del archivo se puede descomponer en dos subproblemas. El primero consiste en asegurar que cada una de las dos operaciones sobre el archivo puede ser realizada únicamente por clientes con los derechos suficientes. Por ejemplo, González, que es el propietario del archivo, tiene los derechos de *lectura* y *escritura* sobre él. Pérez sólo necesita acceder a la operación de *lectura*. En este caso se produciría un acceso ilegítimo si Pérez intentara realizar una operación de *escritura* sobre el archivo. Una solución completa a este subproblema de protección de recursos en un sistema distribuido requeriría técnicas criptográficas que se estudiarán en el Capítulo 7.

El otro tipo de acceso ilegítimo, que es preciso tratar, ocurre cuando un proceso se comporta de forma errónea, esquivando las operaciones que se exportan sobre un recurso. En nuestro ejemplo esto ocurriría si González o Pérez, de alguna forma, ejecutaran una operación que no fuera *lectura* ni *escritura*. Supongamos, por ejemplo, que Gonzalez tratara de acceder directamente a la variable de puntero al archivo. Para ello construiría la operación *setFilePointerRandomly*, la cual asignaría un valor arbitrario al puntero al archivo. Ésta es, desde luego, una operación sin sentido que podría perturbar la normal utilización del archivo y que nunca debiera exportarse como tal.

Podemos proteger, los recursos, de invocaciones ilegítimas del tipo de *setFilePointerRandomly*. Una posibilidad consiste en utilizar un lenguaje de programación con sistema de tipos seguro (*type-safe*), como Java o Modula-3. Estos lenguajes no permiten que un módulo acceda a otro módulo objeto a no ser que previamente obtenga una referencia a este último; él mismo no puede crear directamente un puntero que lo referencie, como se haría en C o C++. Además sólo podrá utilizar la referencia al módulo destino para realizar aquellas invocaciones (llamadas a método o a procedi-

miento) que el programador del módulo destino haya publicado. En otras palabras, no se pueden cambiar las variables del destino de forma arbitraria. Por el contrario, en C++ un programador puede realizar asignaciones a un puntero a voluntad, realizando de esta forma invocaciones de tipo inseguro.

También podemos utilizar soporte hardware para proteger los módulos entre sí en el nivel de invocaciones individuales, independientemente del lenguaje en que hayan sido escritas. Para operar con este esquema en un computador de propósito general se necesita un núcleo.

◊ **Núcleos y protección.** El núcleo es un programa cuya principal propiedad es que su código siempre se ejecuta con privilegios completos de acceso a los recursos físicos en el computador huésped. En concreto puede controlar la unidad de gestión de memoria y escribir en los registros del procesador de forma que se consiga impedir que cualquier otro código acceda a los recursos físicos de la máquina excepto en las formas aceptables.

La mayor parte de los procesadores tienen un registro de modo cuyo valor determina si pueden realizarse o no instrucciones privilegiadas; ejemplos de estas instrucciones son aquellas que determinan qué tablas de protección debe emplear la unidad de gestión de memoria. Un proceso del núcleo se ejecuta siempre con el procesador en modo *supervisor* (privilegiado); el núcleo hace que el resto de procesos se ejecuten en modo *usuario* (no privilegiado).

El núcleo también gestiona los *espacios de direcciones* para protegerse a sí mismo, y a otros procesos, de accesos desde un proceso anómalo, y para proporcionar a los procesos su espacio de memoria virtual. Un espacio de direcciones es un conjunto de rangos de posiciones de memoria virtual, existiendo en cada uno de ellos una combinación de derechos de acceso del tipo: acceso en sólo lectura o bien acceso en lectura-escritura. Un proceso no puede acceder a la memoria fuera de su espacio de direcciones. Los términos *proceso de usuario* o bien *proceso de nivel de usuario* se utilizan normalmente para describir aquellos procesos que se ejecutan en modo usuario y tienen un espacio de direcciones de nivel de usuario; es decir, un espacio de direcciones con derechos de acceso a memoria restringidos en comparación con el espacio de direcciones del núcleo.

Cuando un proceso ejecuta su código de aplicación lo hace en un espacio de direcciones de nivel de usuario único para esa aplicación; por el contrario cuando el mismo proceso ejecuta código del núcleo lo hace dentro del espacio de direcciones del núcleo. El proceso puede conmutar de forma segura entre el espacio de direcciones de nivel de usuario y el espacio de direcciones del núcleo por medio de una excepción, como una interrupción o bien una *interrupción interna de llamada al sistema*; este último mecanismo es el utilizado para acceder a los recursos gestionados por el núcleo. Una interrupción interna de llamada al sistema se implementa a través de una instrucción de lenguaje máquina llamada TRAP, la cual pone el procesador en modo supervisor y conmuta al espacio de direcciones del núcleo. Cuando se ejecuta la instrucción TRAP, de igual forma que ocurre en cualquier otro tipo de excepción, el hardware provoca que el procesador ejecute la rutina de manejo proporcionada por el núcleo para impedir que ningún proceso pueda acceder de forma ilegal al hardware.

Los programas deben pagar un precio por la protección. La conmutación entre espacios de direcciones consume varios ciclos de procesador y una interrupción interna de llamada al sistema es una operación más cara que una invocación a un procedimiento o a un método. Veremos a continuación cómo estas penalizaciones afectan a los costes de invocación.

6.4. PROCESOS E HILOS

El concepto tradicional en los sistemas operativos de que un proceso ejecuta una única actividad, ya se comprobó, en la década de los ochenta, que era poco adecuado para las especificaciones de los sistemas distribuidos; y también para ciertas aplicaciones sobre un solo computador que nece-

sitan concurrencia interna. El problema, como estudiaremos a continuación, es que los procesos tradicionales realizan la compartición entre actividades relacionadas de una forma difícil y cara.

La solución propuesta consistió en ampliar el concepto de proceso de forma que pudiera asociarse a múltiples actividades. Actualmente un proceso consiste en un entorno de ejecución formado por uno o más hilos. Un *hilo* es una abstracción del sistema operativo asociada a una actividad (este término deriva de la frase «hilo de ejecución»). Un *entorno de ejecución* equivale a una unidad de gestión de recursos: una colección de recursos locales gestionados por el núcleo sobre los que tienen acceso los hilos. Un entorno de ejecución consiste básicamente de los siguientes elementos:

- Un espacio de direcciones.
- Recursos de comunicación y sincronización de hilos, como semáforos e interfaces de comunicación (por ejemplo, sockets).
- Recursos de alto nivel, como archivos abiertos y ventanas.

Los entornos de ejecución son ciertamente caros en cuanto a su creación y gestión, aunque sin embargo pueden ser compartidos por más de un hilo, es decir, éstos pueden compartir todos los recursos accesibles dentro de cada entorno. En otras palabras, un entorno de ejecución representa el dominio de protección en el que se ejecutan los hilos.

Los hilos pueden crearse y destruirse de forma dinámica, según se necesite. El principal propósito para la existencia de múltiples hilos de ejecución es maximizar el grado de ejecución concurrente entre las diferentes operaciones, permitiendo así habilitar el solapamiento de la computación con la entrada-salida y el procesamiento concurrente en los multiprocesadores. Esto es particularmente útil en los servidores en los que el procesamiento concurrente de las solicitudes de los clientes pueden reducir la tendencia de los servidores a convertirse en cuellos de botella. Por ejemplo, un hilo puede procesar una solicitud de un cliente mientras que un segundo hilo que está sirviendo otra solicitud está esperando por la finalización de un acceso a disco para poder terminar.

Un entorno de ejecución proporciona protección contra los hilos externos de forma que los datos y otros recursos contenidos en él sean inaccesibles para los hilos residentes en otros entornos de ejecución. Sin embargo ciertos núcleos permiten la compartición controlada de recursos como la memoria física, entre entornos de ejecución diferentes residentes en el mismo computador.

Debido a que algunos sistemas operativos permiten un único hilo por proceso algunas veces usaremos el término *proceso multi-hilo* para resaltar la idea. Desconcertantemente, algunos modelos de programación y de sistemas operativos asocian el término proceso a lo que hemos llamado hilo. El lector encontrará en la literatura específica sobre el tema los términos *proceso de peso pesado* para indicar un entorno de ejecución y *proceso de peso ligero* en el caso contrario. En el recuadro siguiente se describe mediante una analogía la discusión entre hilos y entornos de ejecución.

6.4.1. ESPACIOS DE DIRECCIONES

Un espacio de direcciones, concepto introducido en la sección anterior, es una unidad de gestión de la memoria virtual de un proceso. Es grande (normalmente hasta 2^{32} bytes y a veces hasta 2^{64} bytes) y está formado por una o más *regiones*, separadas por áreas de memoria virtual inaccesibles. Una región (véase la Figura 6.3) es una zona de memoria virtual contigua accesible por los hilos del proceso propietario. Las regiones no se solapan. Hay que resaltar la distinción entre regiones y sus contenidos. Cada región se caracteriza por las siguientes propiedades:

- Su tamaño (su dirección virtual más baja y su tamaño).

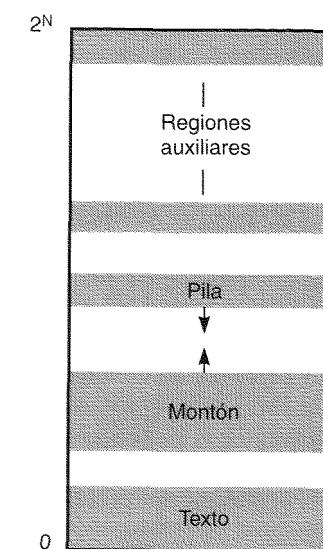


Figura 6.3. Espaciado de direcciones.

Semejanzas entre hilos y procesos. La siguiente descripción de hilos y procesos, particularmente descollante aunque un poco desagradable, fue encontrada en el grupo de USENET *comp.os.mach* y se debe a Chris Lloyd. Un entorno de ejecución es como un tarro taponado junto con el aire y la comida dentro de él. Inicialmente hay una mosca (un hilo) en el tarro. Esta mosca puede producir otras moscas y matarlas. Cualquier mosca puede consumir cualquier recurso (aire o comida) del tarro. Estos insectos podrían programarse para hacer cola de forma ordenada en el acceso a los recursos. Si las moscas resultan ser indisciplinadas, chocarán entre ellas dentro del tarro y producirán resultados impredecibles cuando intenten consumir los mismos recursos de una forma descontrolada. Podrán comunicarse entre ellas (enviar mensajes), y con otras moscas de otros recipientes, pero ninguna podrá escapar de su vasija al igual que ninguna mosca de fuera podrá entrar. Desde este punto de vista, un proceso UNIX estándar es un único tarro con una sola mosca estéril dentro de él.

- Los permisos de lectura/escritura/ejecución para los hilos del proceso.
- Una indicación de crecimiento hacia arriba o hacia abajo.

Hay que destacar que este modelo está orientado a páginas, no a segmentos. Las regiones, al contrario que los segmentos, podrían eventualmente solaparse si su tamaño se extendiera. Entre las regiones se dejan huecos para permitir su crecimiento. Esta representación de un espacio de direcciones como un conjunto disperso de regiones disjuntas es una generalización del espacio de direcciones de UNIX, el cual está formado por tres regiones: una región de texto de tamaño fijo, y no modificable, que contiene el código del programa; un montón (*heap*), parte del cual se inicializa con los valores almacenados en el archivo binario con el programa, y que es ampliable hacia direcciones virtuales crecientes; y una pila, que crecerá hacia direcciones virtuales decrecientes.

La existencia de un número indeterminado de regiones tiene su razón de ser en varios factores. Uno de ellos es la necesidad de que haya pilas separadas para cada hilo. La existencia de regiones de pila distintas para cada hilo permite detectar los intentos de exceder el límite de la pila y controlar el crecimiento de cada una de ellas. La memoria virtual no utilizada se halla debajo de cada

región de pila y los intentos de acceder a esa región generarán excepciones (faltas de página). Una alternativa consiste en asignar la pila de cada hilo en el montón, sin embargo en este caso se hace difícil detectar cuándo un hilo excede el límite de su pila.

Otra motivación es la de permitir que un archivo (cualquiera de ellos no sólo las secciones de texto y datos de los archivos binarios) puedan ponerse en correspondencia con espacios de direcciones. Los *archivos indexados por posición (memory mapped)* permiten un acceso similar a un vector de bytes en memoria. El sistema de memoria virtual permite que los accesos realizados en memoria se transmitan al sistema de almacenamiento de archivos. La Sección 18.6 describe cómo el núcleo de Mach extiende la abstracción de memoria virtual de forma que las regiones puedan corresponderse de forma arbitraria con objetos en la memoria y no únicamente con archivos.

La necesidad de compartir memoria entre procesos, o entre procesos y el núcleo, es otro factor que deriva en la necesidad de regiones adicionales en el espacio de direcciones. Una *región de memoria compartida* (de forma abreviada *región compartida*) es aquella en la que se asocia la misma memoria física a una o más regiones pertenecientes a otros espacios de direcciones. Por lo tanto los procesos acceden a los mismos contenidos de memoria en las regiones compartidas mientras que sus regiones no compartidas permanecen protegidas. Algunos usos de las regiones compartidas son los siguientes:

Bibliotecas: el código de las bibliotecas puede llegar a ser muy grande y se desperdiciaría una cantidad considerable de memoria si se cargaran de forma separada en cada proceso que las utilizase. Por contra, varios procesos pueden compartir una sola copia del código de las bibliotecas empleando una región compartida del espacio de direcciones.

Núcleo: frecuentemente el código y los datos del núcleo se corresponden dentro del espacio de direcciones en las mismas posiciones. Cuando un proceso realice una llamada al sistema, o bien cuando se genere una excepción, no habrá necesidad de conmutar a un nuevo conjunto de direcciones.

Compartición de datos y comunicación: entre dos procesos, o bien entre un proceso y el núcleo, se puede necesitar compartir datos para cooperar en la realización de una cierta tarea. Es más eficiente utilizar regiones de direcciones compartidas en lugar de intercambiar los datos mediante mensajes. La utilización de regiones compartidas para la comunicación se describirá en la Sección 6.5.

6.4.2. CREACIÓN DE UN PROCESO NUEVO

Tradicionalmente la creación de un proceso nuevo es una operación indivisible realizada por el sistema operativo. Por ejemplo, la llamada al sistema *fork* de UNIX crea un proceso con un entorno de ejecución que es copia del entorno del proceso que la invoca (y sólo difiere en el valor de retorno de *fork*). La llamada al sistema *exec* de UNIX transforma el proceso que la invoca en otro, producto de ejecutar el código del programa que se le indica.

Para un sistema distribuido el diseño del mecanismo de creación de un proceso debe tener en cuenta la utilización de múltiples computadores; de esta forma la infraestructura de gestión de procesos se divide en servicios de sistema separados.

La creación de un proceso nuevo puede separarse en dos aspectos independientes:

- La elección del computador destino. Por ejemplo, el nodo puede elegirse entre varios de un grupo (*clúster*) de computadores que actúan como servidores de computación (véase el recuadro siguiente).
- La creación de un entorno de ejecución (y la de un hilo inicial en él).

◊ **Elección del nodo de proceso.** La elección del nodo en el que residirá el nuevo proceso (la decisión de la ubicación de procesos) es una cuestión de política. En general, las políticas de localización de procesos varían desde aquellas que siempre lanzan los procesos nuevos en la estación de trabajo originaria hasta aquellos que comparten la carga de procesamiento entre un conjunto de computadores. Eager y otros [1986] distinguen las siguientes categorías de políticas de participación de la carga.

La *política de transferencia* decide si un proceso nuevo debe ubicarse en el nodo local o en un nodo remoto. Esta decisión dependerá, por ejemplo, de que el nodo local esté poco o muy cargado.

La *política de ubicación* determina qué nodo alojará un proceso nuevo seleccionado para transferirse. Esta decisión puede depender de las cargas relativas de los nodos, de su arquitectura y de algún recurso específico que posea. El sistema V [Cheriton 1984] y Sprite [Douglis y Ousterhout 1991] proporcionan mandatos de usuario para lanzar programas en estaciones de trabajo ociosas (a menudo hay varias al mismo tiempo) elegidas por el sistema operativo. En el sistema Amoeba [Tannenbaum 1990] el *servidor de ejecución* elige para cada proceso un nodo de entre un conjunto de procesadores compartidos. En todos los casos la elección del nodo destino es transparente tanto para el programador como para el usuario. Sin embargo, aquellos que programen para conseguir paralelismo explícito o tolerancia a fallos necesitan un medio para especificar la localización de cada proceso.

◊ **Clústeres.** Un grupo (*clúster*) no es más que un conjunto de computadores corrientes (desde decenas a varias centenas) conectados mediante una red de comunicaciones de alta velocidad, por ejemplo, Ethernet 100 megabit/segundo. Cada computador individualmente puede ser un PC usual, una estación de trabajo o varias tarjetas de procesador tipo PC montadas en grupo; cada nodo puede ser de tipo monoprocesador o multiprocesador. Una aplicación de los grupos es la de proporcionar capacidad de cómputo a los usuarios de computación basada en clientes ligeros (*thin-client*). Otra aplicación consiste en proporcionar servicios con alta disponibilidad y escalabilidad (como los motores de búsqueda en Internet) mediante la replicación o la partición del estado del servidor en el grupo de procesadores [Fox y otros 1997]. Los grupos también se utilizan para ejecutar programas paralelos [Anderson y otros 1995, now.cs.berkeley.edu, TFCC].

Las políticas de localización de procesos pueden ser *estáticas* o *adaptativas*. Las primeras operan sin tener en consideración el estado actual del sistema, aunque su diseño tiene en cuenta las características esperadas para el sistema a largo plazo. Se basan en análisis matemáticos orientados a la optimización de ciertos parámetros como la productividad global de procesos. Pueden ser deterministas (el nodo A debe siempre transferir procesos al nodo B) o probabilísticos (el nodo A debe transferir procesos a cualquiera de los nodos B-E de forma aleatoria). Por otra parte las políticas adaptativas aplican reglas heurísticas para tomar las decisiones de ubicación basándose en factores de tiempo de ejecución no predecibles, como la medida de la carga en cada nodo.

Los sistemas de compartición de carga pueden ser centralizados, jerárquicos o descentralizados. En el primer caso existe un *gestor de carga*, mientras que en el segundo hay varios, organizados en una estructura arborescente. Los gestores de carga consiguen información sobre los nodos y la usan para asignar nuevos procesos a esos nodos. En los sistemas jerárquicos, estos gestores toman las decisiones de localización de procesos sobre aquellos nodos con mayor profundidad posible en el árbol; sin embargo los gestores pueden intercambiarse procesos a través de un ancestro común, aunque siempre bajo determinadas condiciones de carga. En un sistema de compartición de carga descentralizado los nodos intercambian información entre ellos directamente para tomar las decisiones de localización. Por ejemplo, el sistema Spawn [Waldspurger y otros 1992] diferencia los nodos entre *compradores* y *vendedores* de recursos de computación y los organiza como una *economía de mercado* (descentralizada).

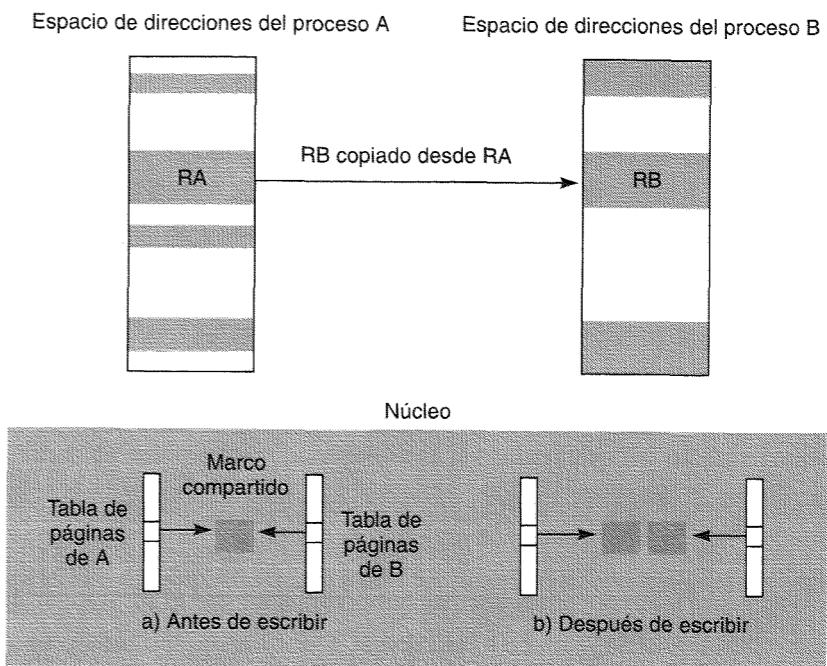
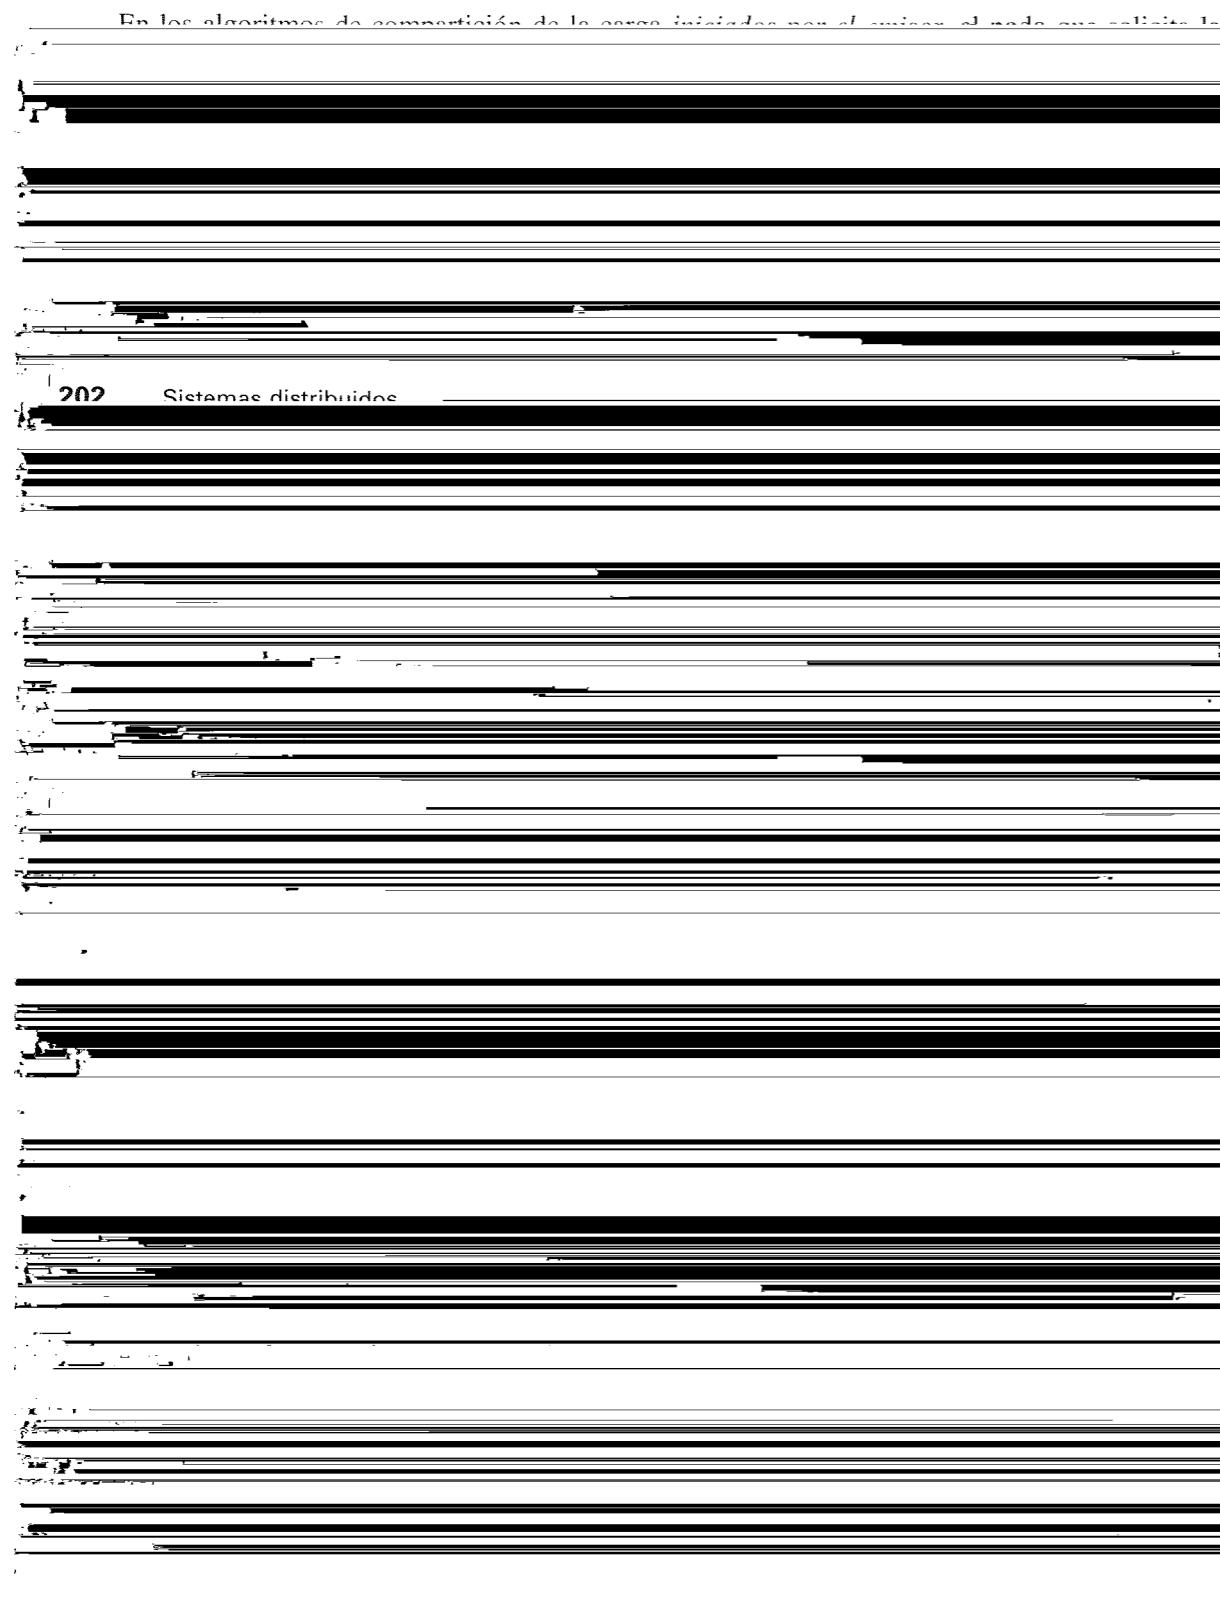


Figura 6.4. Copia en escritura.

Suponemos, con el ánimo de simplificar la explicación, que las páginas que pertenecen a la región *A* residen en memoria. Inicialmente todos los marcos de página asociados con las regiones se comparten mediante las tablas de páginas de los dos procesos. Las páginas están inicialmente protegidas contra escritura a nivel del hardware incluso si pertenecen a regiones que tienen privilegios lógicos de escritura. Si un hilo en cualquier proceso intenta modificar los datos se genera una excepción hardware llamada *fallo* o *falta de página*. Supongamos que el proceso *B* intentó la escritura. El gestor de faltas de páginas localiza un nuevo marco para el proceso *B* y copia los datos del marco original en él byte a byte. El número del marco antiguo es reemplazado por el número del nuevo marco en la tabla de páginas de un proceso (no importa de cual) y el número del marco antiguo se deja en la tabla de páginas del otro proceso. Las dos páginas equivalentes en los procesos *A* y *B* tienen ahora permisos de escritura al nivel de hardware. Tras las operaciones descritas, la instrucción de modificación del proceso *B* puede continuar.

6.4.3. HILOS

El siguiente aspecto importante de un proceso que debe considerarse en mayor detalle son sus hilos. En esta subsección se examinan las ventajas que supone la posibilidad de poseer más de un hilo para los procesos clientes y servidores. Se discute a continuación la programación con hilos, utilizando los hilos de Java a modo de ejemplo y se finaliza con diseños alternativos para implementar hilos.

Sea el servidor mostrado en la Figura 6.5 (en breve se analizará el cliente). El servidor tiene un conjunto formado por uno o más hilos cada uno de los cuales, y de forma repetitiva, toma una solicitud de la cola de solicitudes recibidas y la procesa. En este punto no interesa el instante en el que se reciben las solicitudes y se almacenan para ser procesadas por los hilos. Además se supone,

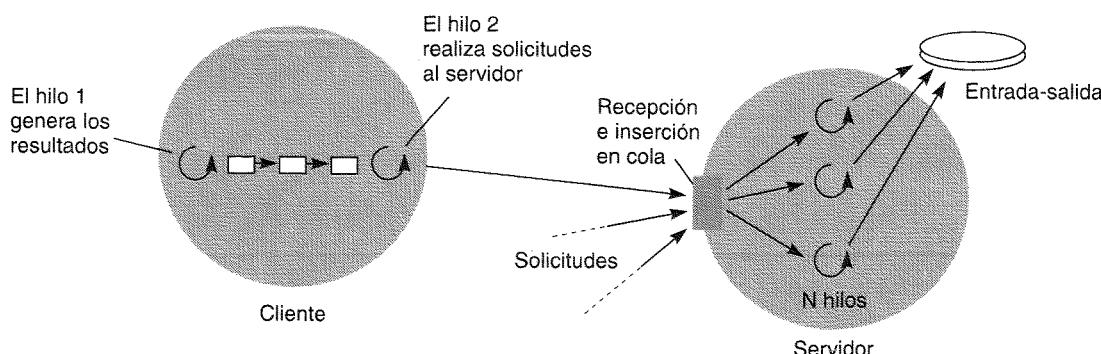


Figura 6.5. Clientes y servidores con hilos.

a efectos de simplificar el ejemplo, que cada hilo aplica el mismo procedimiento para procesar las solicitudes. Supongamos que cada solicitud necesita, por término medio, 2 milisegundos de procesamiento y 8 milisegundos de entrada-salida para que el servidor realice las lecturas desde el disco (no existe caché). Supongamos además temporalmente que el servidor se ejecuta en un computador con un único procesador.

Estudiemos la productividad *máxima* del servidor medida en solicitudes de cliente manejadas por segundo, en función del número de hilos. Si un único hilo debe realizar todo el procesamiento, el tiempo de retorno para manejar cualquier solicitud es de $2 + 8 = 10$ milisegundos, por término medio, de forma que este servidor podrá atender a 100 clientes por segundo. Cualquier mensaje de solicitud que llegue al servidor mientras está manejando una solicitud es insertado en la cola del puerto del servidor.

Ahora considérese qué ocurre cuando el servidor dispone de dos hilos. Se asume que los hilos se pueden planificar de forma independiente, es decir, un hilo puede planificarse cuando otro pasa a estado bloqueado por una operación de entrada-salida. El hilo número dos puede procesar una segunda solicitud mientras el hilo número uno está bloqueado, y viceversa. Esto incrementa la productividad del servidor. Desgraciadamente, en nuestro ejemplo los hilos se bloquean sobre una única unidad de disco. Si todas las solicitudes al disco se envían en serie y necesitan 8 milisegundos cada una, la productividad máxima resulta ser de $1.000/8 = 125$ solicitudes por segundo.

Supóngase ahora que existe una caché de bloques de disco. El servidor mantiene los datos leídos en búferes dentro de su espacio de direcciones; el hilo del servidor encargado de la obtención de los datos examina previamente la caché compartida evitándose el acceso al disco si los datos se encuentran allí. Si se consigue una tasa de aciertos del 75 %, el tiempo medio de entrada-salida por cada solicitud se reduce a $(0,75 \times 0 + 0,25 \times 8) = 2$ milisegundos, y la productividad máxima teórica se incrementa hasta 500 solicitudes por segundo. Sin embargo si el tiempo medio de *procesador* por cada solicitud se incrementa hasta 2,5 milisegundos por solicitud debido a la gestión de la caché (en cada operación es preciso gastar un cierto tiempo en la búsqueda de los datos en la caché) no se llega a la cantidad anterior. El servidor, limitado por el procesador, podrá ahora gestionar un máximo de $1.000/2,5 = 400$ solicitudes por segundo.

La productividad puede incrementarse mediante el uso de multiprocesadores de memoria compartida para resolver los cuellos de botella del procesador. Un proceso multi-hilo se adapta de forma natural a un multiprocesador de memoria compartida. El entorno de ejecución compartida puede implementarse en memoria compartida y los múltiples hilos pueden planificarse para su ejecución en múltiples procesadores. Considérese ahora el caso en el que el servidor de nuestro ejemplo se ejecuta en un multiprocesador con dos procesadores. Suponiendo que los hilos pueden planificarse independientemente sobre los diferentes procesadores entonces podrán procesar solici-

tudes en paralelo hasta un máximo de dos hilos. El lector deberá comprobar que dos hilos pueden procesar 444 solicitudes por segundo y tres o más hilos, limitados por el tiempo de entrada-salida, pueden procesar 500 solicitudes por segundo.

◊ **Arquitecturas para servidores multi-hilo.** Hemos descrito cómo el multi-hilo permite a los servidores maximizar su productividad, medida como el número de solicitudes procesadas por segundo. Para describir las diferentes formas que existen para vincular solicitudes a hilos dentro de un servidor resumimos el informe escrito por Schmidt [1998], en el que se describen las arquitecturas basadas en hilos de diferentes implementaciones del Agente de Solicitud de Objetos de CORBA (ORB, *Object Request Broker*). Cada ORB procesa solicitudes que llegan a través de un conjunto de sockets activos. Sus arquitecturas basadas en hilos son relevantes para múltiples tipos de servidores, independientemente del hecho que usen CORBA.

La Figura 6.5 muestra una de las posibles arquitecturas basadas en hilos, la *arquitectura de asociación de trabajadores*. En su forma más simple, el servidor, durante la inicialización, crea un conjunto fijo de hilos de *trabajadores* para procesar las solicitudes. El módulo marcado como *receptor* y *gestor de cola* en la Figura 6.5 se implementa normalmente como un hilo de *E/S*, el cual recibe solicitudes desde una colección de sockets o puertos y las sitúa en una cola de solicitudes compartidas para ser recuperadas por los trabajadores.

En ocasiones existe un requisito para tratar las solicitudes con prioridades cambiantes. Por ejemplo, un servidor web corporativo debiera procesar las solicitudes con diferentes prioridades en función del tipo de cliente del que se derive la solicitud [Bhatti y Friedrich 1999]. Se pueden gestionar prioridades de solicitud variables mediante múltiples colas en la arquitectura de asociación de trabajadores, de forma que los hilos del trabajador puedan examinar las colas en orden decreciente de prioridad. Una desventaja de esta arquitectura es su escasa flexibilidad: como se vio en el ejemplo previo, el número de hilos de trabajo en la asociación puede ser demasiado pequeño para manejar adecuadamente la tasa actual de llegada de solicitudes. Otra desventaja es el alto nivel de conmutación entre la *E/S* y los hilos de trabajo al manejar la cola compartida.

En la *arquitectura de hilo-por-solicitud* (véase la Figura 6.6a) el hilo de *E/S* genera un nuevo hilo de trabajo para cada solicitud, y ese trabajador se elimina a sí mismo cuando ha procesado la solicitud asociada a un objeto remoto. Esta arquitectura tiene la ventaja de que los hilos no compiten por el acceso a una cola compartida y la productividad se puede maximizar potencialmente dado que el hilo de *E/S* puede crear tantos trabajadores como solicitudes pendientes existan. Su desventaja es la sobrecarga debida a las operaciones de creación y destrucción de hilos.

La *arquitectura de hilo-por-conexión* (véase la Figura 6.6b) asocia un hilo a cada conexión. El servidor crea un nuevo hilo trabajador cuando un cliente realiza una conexión y lo destruye cuando el cliente cierra dicha conexión. En el intervalo, el cliente puede realizar múltiples solicitudes sobre la conexión, cuyo destino puede ser uno o más objetos remotos. La *arquitectura de hilo-por-objeto* (véase la Figura 6.6c) asocia un hilo a cada objeto remoto. Un hilo de *E/S* recibe las solici-

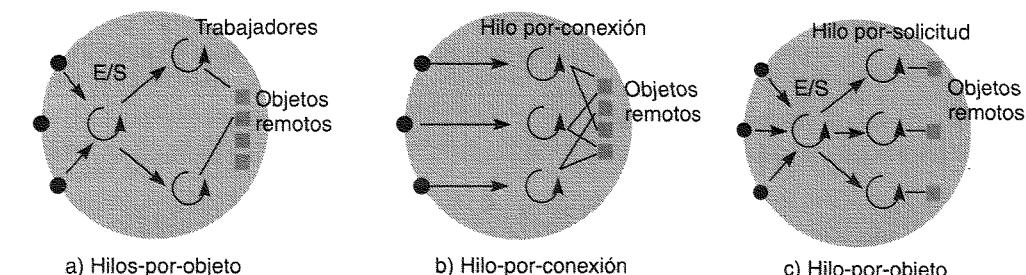


Figura 6.6. Arquitecturas alternativas de servidor basadas en hilos (véase también la Figura 6.5).

tudes y las inserta en colas para los trabajadores con la diferencia de que en este caso existe una cola por cada objeto.

En cada una de las dos últimas arquitecturas el servidor se beneficia de sobrecargas pequeñas en la gestión de los hilos en comparación con la arquitectura de hilo-por-solicitud. Su desventaja es que los clientes pueden sufrir retrasos si un hilo trabajador tiene varias solicitudes pendientes mientras que otro hilo puede estar parado sin trabajo que realizar.

Schmidt [1998] describe variantes de estas arquitecturas, así como algunas mezclas, y discute sus ventajas e inconvenientes en mayor detalle. En la Sección 6.5 se describe un modelo diferente basado en hilos para solicitudes en una única máquina, en el que los hilos cliente comparten el espacio de direcciones del servidor.

◇ **Hilos dentro de los clientes.** Los hilos pueden ser tan útiles para los clientes como para los servidores. En la Figura 6.5 se muestra un proceso cliente con dos hilos. El primer hilo genera resultados que se van a enviar al servidor mediante una invocación a método remoto, no necesitando, sin embargo, una respuesta. Las invocaciones a métodos remotos normalmente bloquean al que invoca, incluso aunque no sea estrictamente preciso esperar. Este proceso cliente puede añadir un segundo hilo, el cual realiza las invocaciones a los métodos remotos y se bloquea mientras el primer hilo puede continuar computando nuevos resultados. El primer hilo deposita sus resultados en búferes que son vaciados por el segundo hilo. Únicamente se bloquea cuando todos los búferes estén llenos.

La cuestión de clientes multihilo es evidente también en el ejemplo de los navegadores web. El usuario sufre retardos significativos mientras se cargan las páginas; es por lo tanto esencial para los navegadores la gestión de múltiples solicitudes concurrentes a páginas web.

◇ **Hilos frente a múltiples procesos.** De los ejemplos anteriores se puede deducir la utilidad de los hilos, que permiten que la computación se solape con la entrada-salida y, para el caso de un multiprocesador, con otros cómputos. El lector puede haber notado, sin embargo, que se puede obtener el mismo solapamiento mediante la utilización de múltiples procesos mono-hilo. Entonces, ¿por qué razón se prefiere el modelo de proceso multi-hilo? La respuesta es doble: la creación y gestión de los hilos es más barata que la de procesos y la compartición de recursos se puede conseguir de forma más eficiente entre hilos que entre procesos ya que los hilos comparten los entornos de ejecución.

En la Figura 6.7 se muestran algunos de los principales componentes del estado que deben gestionarse para entornos de ejecución e hilos, respectivamente. Un entorno de ejecución tiene un espacio de direcciones, interfaces de comunicación, como sockets, recursos de alto nivel del tipo de archivos abiertos y objetos para la sincronización de hilos como los semáforos; además debe mantener una relación de los hilos que se asocian a dicho entorno. Un hilo tiene una prioridad de planificación, un estado de ejecución (como *BLOQUEADO* o *PREPARADO*), los valores almacenados correspondientes a los registros del procesador cuando el hilo está *BLOQUEADO* y el estado rela-

Entorno de ejecución	Hilo
Tablas de espacio de direcciones	Registros del procesador salvados
Interfaces de comunicación, archivos abiertos	Prioridad y estado de ejecución (del tipo de <i>BLOQUEADO</i>)
Semáforos, otros objetos de sincronización	Información de gestión de interrupciones software
Lista de identificadores de hilos	Identificador de entorno de ejecución
Páginas del espacio de direcciones residentes en memoria; entradas de la caché hardware	

Figura 6.7. Estado asociado con los entornos de ejecución y los hilos.

cionado con la gestión de *interrupciones software* del hilo. Una *interrupción software* es un evento que provoca la interrupción de un hilo (de forma análoga al caso de interrupción hardware). Si el hilo tiene asignado un procedimiento de gestión se le transfiere el control. Las señales en UNIX son ejemplos de interrupciones software.

La figura muestra que un entorno de ejecución y los hilos que pertenecen a él se asocian con páginas que pertenecen al espacio de direcciones mantenido en memoria principal, mientras que los datos e instrucciones se almacenan en las cachés hardware.

Podemos resumir la comparación realizada entre procesos e hilos de la siguiente forma:

- La creación de un nuevo hilo dentro de un proceso existente es más barata que la creación de un proceso.
- Más importante aún, la comutación a un hilo diferente dentro del mismo proceso es más barata que la comutación entre hilos que pertenecen a diferentes procesos.
- Los hilos dentro de un proceso pueden compartir datos y otros recursos de forma más adecuada y eficiente que con procesos separados.
- Sin embargo, del mismo modo, los hilos dentro de un proceso no están protegidos entre ellos.

Considérese el coste de creación de un nuevo hilo dentro de un entorno de ejecución existente. La principal tarea consiste en asignar una región para la pila y proporcionar los valores iniciales de los registros del procesador y de la prioridad y estado de ejecución del hilo (initialmente puede estar *SUSPENDIDO* o *PREPARADO*). Debido a la existencia del entorno de ejecución, únicamente se debe colocar un identificador para él en el registro que describe al hilo (el cual contiene los datos necesarios para gestionar la ejecución del hilo). La sobrecarga asociada con la creación de un proceso es, por regla general, considerablemente mayor que la asociada a la creación de un hilo nuevo. Es preciso crear en primer lugar un nuevo entorno de ejecución, incluyendo las tablas del espacio de direcciones. Anderson y otros [1991] citan valores de alrededor de 11 milisegundos para la creación de un proceso UNIX nuevo y sobre 1 milisegundo para la creación de un hilo sobre la misma arquitectura de procesador CVAX ejecutando un núcleo Topaz; en cada caso el tiempo medido supone que la entidad creada realiza exclusivamente una invocación a un procedimiento vacío antes de terminar. Los valores anteriores se muestran exclusivamente a efectos de orientación.

Cuando la nueva entidad realiza alguna tarea significativa en lugar de la invocación a un procedimiento nulo, se producen costes a largo plazo que tienden a ser mayores para un nuevo proceso que para un nuevo hilo dentro de un proceso existente. En un núcleo que soporte memoria virtual, el nuevo proceso generará faltas de página según vaya accediendo por primera vez a datos e instrucciones; las cachés hardware no contendrán inicialmente valores de los datos del nuevo proceso y deberán adquirir las diferentes entradas de la caché según se vaya ejecutando. Por otro lado para el caso de la ejecución de un hilo las sobrecargas a largo plazo también pueden ocurrir, pero tienden a ser menores. Cuando el hilo accede al código y a los datos que han sido utilizados recientemente por otros hilos del mismo proceso, automáticamente se aprovecha del hecho de que dichos datos ya residen en cada caché hardware o bien en la memoria principal.

La segunda ventaja de prestaciones de los hilos se refiere a la *comutación* entre los hilos, es decir, la sustitución de un hilo por otro en un cierto procesador. Éste es el coste más relevante porque puede generarse en muchas ocasiones durante la vida del hilo. La comutación entre hilos que comparten el mismo entorno de ejecución es considerablemente más barata que la de hilos que pertenecen a diferentes procesos. Las sobrecargas asociadas con la comutación de hilos corresponden a la planificación (la elección del siguiente hilo a ejecutar) y al cambio de contexto.

Un contexto de procesador está formado por los valores de los registros del procesador como el contador de programa y el dominio de protección actual del hardware: el espacio de direcciones y el modo de protección del procesador (supervisor o usuario). El *cambio de contexto* es la transición

entre contextos que ocurre cuando se conmuta entre hilos o cuando un único hilo realiza una ll-

entre contextos que ocurre cuando se conmuta entre hilos o cuando un único hilo realiza una ll-

- En algunas situaciones se realiza una transferencia a un nuevo dominio de protección; a esto se le llama *transición de dominio*.

La conmutación entre hilos que comparten un mismo entorno de ejecución de nivel de usuario no supone la realización de transición de dominio y es relativamente barata. La conmutación al núcleo o a otro hilo que pertenece al mismo entorno de ejecución a través del núcleo, supone la realización de una transición de dominio. El coste es así mayor aunque, si el núcleo está vinculado al espacio de direcciones del cliente, es aún relativamente bajo. Sin embargo, cuando se conmuta entre hilos que pertenecen a diferentes entornos de ejecución se generan mayores sobrecargas. El recuadro siguiente explica las implicaciones de coste que supone la caché hardware en las transiciones de dominio. Los costes a largo plazo debidos a la ocupación de las entradas de la caché hardware y de las páginas de memoria principal tienden a aplicarse cuando ocurre la mencionada transición de dominio. Los valores presentados por Anderson y otros [1991] son de 1,8 milisegundos para realizar una conmutación entre procesos UNIX y de 0,4 milisegundos para la conmutación entre hilos pertenecientes al mismo entorno de ejecución realizada en el núcleo Topaz. Se han conseguido costes incluso menores (0,04 milisegundos) para hilos que conmutan a nivel de usu-

<i>Thread(ThreadGroup grupo, Runnable destino, String nombre)</i>	Crea un nuevo hilo en estado <i>SUSPENDIDO</i> , perteneciente a <i>grupo</i> e identificado con <i>nombre</i> ; el hilo ejecutará el método <i>run()</i> de <i>destino</i> .
<i>setPriority(int nuevaPrioridad), getPriority()</i>	Cambia y devuelve la prioridad del hilo.
<i>run()</i>	Un hilo ejecuta el método <i>run()</i> de su objeto destino, en el caso de que lo tenga, o bien su propio método <i>run()</i> en caso de que no lo tenga (los hilos de C implementan la función <i>Runnable</i>).
<i>start()</i>	Cambia el estado de un hilo desde <i>SUSPENDIDO</i> a <i>PREPARADO</i> .
<i>sleep(int milisegundos)</i>	Provoca que el hilo pase al estado <i>SUSPENDIDO</i> durante el tiempo que se especifica.
<i>yield()</i>	Pasa a estado <i>READY</i> e invoca a continuación al planificador.
<i>destroy()</i>	Elimina el hilo.

Figura 6.8. Métodos constructor y de gestión de hilos Java.

◊ **El problema de la suplantación.** Las unidades de gestión de memoria normalmente incluyen una caché hardware para mejorar la velocidad de traducción entre direcciones virtuales y físicas, llamado *búfer de apoyo de traducción* (*translation lookaside buffer*, TLB). Tanto un TLB como una caché de datos e instrucciones accedidas mediante direcciones virtuales sufren del *problema de suplantación* (*aliasing*). La misma dirección virtual puede ser válida sobre dos espacios de direcciones diferentes, refiriéndose, sin embargo, a datos físicos diferentes en dos espacios. A no ser que sus entradas estén etiquetadas con un identificador de contexto, tanto un TLB como una caché direccionada virtualmente no tienen en cuenta lo anterior y por lo tanto pueden contener datos incorrectos. Es por ello por lo que deben vaciarse tanto un TLB como los contenidos de una caché cuando se conmuta a un espacio de direcciones diferente. Una caché direccionada físicamente no tiene el problema de la suplantación; sin embargo la utilización de direcciones virtuales para acceder a una caché es algo común, en gran medida porque permite que las búsquedas se solapen con la traducción de direcciones.

◊ **Tiempos de vida de los hilos.** Cada nuevo hilo se crea en la misma máquina virtual Java (JVM, *Java virtual machine*) que su creador y en estado *SUSPENDIDO*. Una vez que ha pasado a estado *PREPARADO* con el método *start()*, ejecuta el método *run()* de un objeto designado en su constructor. JVM y los hilos que hay sobre él se ejecutan en un proceso sobre el sistema operativo

<i>thread.join(int milisegundos)</i>	Bloquea el hilo invocador durante el tiempo especificado hasta que el <i>hilo</i> haya terminado.
<i>thread.interrupt()</i>	Interrumpe el <i>hilo</i> : le obliga a volver desde una llamada a método bloqueante como <i>sleep()</i> .
<i>object.wait(long milisegundos, int nanosegundos)</i>	Bloquea el hilo invocador hasta que una llamada realizada a <i>notify()</i> o <i>notifyAll()</i> en el objeto despierte el hilo, o bien el hilo sea interrumpido, o bien el tiempo especificado se haya cumplido.
<i>object.notify(), object.notifyAll()</i>	Despierta, respectivamente, uno o todos los hilos que han invocado a <i>wait()</i> en el objeto.

Figura 6.9. Llamadas de sincronización de hilos en Java.

subyacente. Los hilos pueden tener asignada una prioridad de forma que las implementaciones de Java que soportan prioridades ejecutarán cada hilo de forma preferente al resto de hilos con menor prioridad. Un hilo finaliza su vida cuando vuelve del método *run()*, o bien cuando se invoca el método *destroy()*.

Los programas pueden gestionar los hilos en grupos. Cada hilo pertenece a un grupo, al que se le asigna en el momento de su creación. Los grupos de hilos son útiles cuando varias aplicaciones coexisten en la misma JVM. Un ejemplo de su uso es la seguridad: por defecto un hilo en un cierto grupo no puede gestionar operaciones sobre un hilo en otro grupo. De esta forma un hilo de una cierta aplicación no puede, de forma maliciosa, interrumpir un hilo del entorno de ventanas del sistema (AWT).

Los grupos de hilos también facilitan el control de las prioridades relativas de los hilos (en las implementaciones de Java que soportan prioridades). Esto es útil para visualizadores que ejecuten applets y para los servidores web que ejecuten los programas llamados *servlets* [Hunter y Crawford 1998], los cuales crean páginas web de forma dinámica. Un hilo no privilegiado dentro de un applet o servlet únicamente puede crear un nuevo hilo que pertenezca a su propio grupo, o a un grupo de menor prioridad creado dentro del suyo; las restricciones exactas dependen del administrador de seguridad (*SecurityManager*) que esté activo. Los visualizadores y los servidores pueden asignar hilos pertenecientes a diferentes applets o servlets a diferentes grupos y establecer la prioridad máxima de cada grupo en su conjunto (incluyendo los grupos descendientes). Para un hilo de applet o de servlet no existe forma de ignorar las prioridades de grupo impuestas por el gestor de hilos, ya que no pueden ser modificadas mediante llamadas a *setPriority()*.

◊ **Sincronización de hilos.** La programación de un proceso multi-hilo debe realizarse de forma cuidadosa. La principal dificultad estriba en la compartición de objetos y en las técnicas utilizadas para la coordinación y cooperación de los hilos. Las variables locales de cada hilo en sus métodos son privadas del hilo, es decir, los hilos tienen pilas privadas. Sin embargo, los hilos no disponen de copias privadas de las variables (clases) estáticas o de las variables instancia de objetos.

Suponga, por ejemplo, las colas compartidas descritas previamente en esta sección, las cuales tienen hilos de E/S y hilos de trabajo utilizados para transferir las solicitudes en arquitecturas de servidores basadas en hilos. Pueden aparecer condiciones de competencia (*race conditions*) cuando los hilos manipulan concurrentemente estructuras de datos del tipo de colas. Las solicitudes que residen en las colas pueden perderse o duplicarse, a no ser que los punteros de manipulación de los hilos hayan sido cuidadosamente coordinados.

Java proporciona a los programadores la palabra clave *synchronized* para designar un monitor, que es un recurso de sincronización de hilos muy conocido. Los programadores designan métodos completos o bien bloques de código de tamaño arbitrario como pertenecientes a un monitor asociado a un objeto individual. La garantía de un monitor viene del hecho de que como máximo un hilo puede ejecutarse dentro del monitor en cualquier instante. Podríamos seriar las acciones de los hilos de E/S y trabajadores en nuestro ejemplo designando los métodos *añadirA()* y *eliminarDe()* en la clase *Cola* como métodos *synchronized*. Todos los accesos a variables dentro de dichos métodos se realizan con exclusión mutua respecto a las invocaciones de esos métodos.

Java permite bloquear y despertar hilos a través de objetos arbitrarios que actúan como variables de condición. Un hilo que necesita bloquearse en espera de una cierta condición invoca un método *wait()*. Todos los objetos implementan este método, ya que pertenece a la clase raíz de Java llamada *Object*. Otro hilo invocará *notify()* para desbloquear como máximo un hilo, o bien invocará a *notifyAll()* para desbloquear todos los hilos en espera sobre el mismo objeto. Ambos métodos de notificación pertenecen también a la clase *Object*.

Como ejemplo, cuando un hilo trabajador descubre que ya no hay más solicitudes para procesar, invoca a *wait()* en la instancia de *Cola*. Cuando posteriormente el hilo de E/S añada una solicitud a la cola, invocará al método *notify()* de gestión de colas, para despertar al trabajador.

Los métodos de sincronización de Java se muestran en la Figura 6.9. Además de las primitivas de sincronización mencionadas, el método *join()* bloquea al que invoca hasta la terminación del hilo destino. El método *interrupt()* es útil para despertar prematuramente un hilo en espera. Todas las primitivas estándar de sincronización, como los semáforos, pueden implementarse en Java. Sin embargo es preciso hacerlo cuidadosamente ya que la garantía del monitor de Java se aplica únicamente a código de objetos declarado como *synchronized*; una clase tendrá una mezcla de métodos *synchronized* y no-*synchronized*. Además el monitor implementado en un objeto Java tiene una única variable de condición implícita mientras que en general un monitor puede tener varias variables de condición.

◊ **Planificación de hilos.** Una distinción importante entre modelos de planificación de hilos es si es apropiativa o no apropiativa. En la *planificación apropiativa* un hilo puede suspenderse en cualquier punto para dejar paso a otro hilo, incluso aunque el hilo pudiera seguir en ejecución. En la *planificación no apropiativa* (a veces llamada *planificación de corutinas*), un hilo se ejecuta hasta que él mismo realiza una invocación al sistema de gestión de hilos (por ejemplo, una llamada al sistema), siendo en ese momento cuando el sistema puede desalojarle para planificar otro hilo.

La ventaja de la planificación no apropiativa es que cualquier sección de código que no contenga una llamada al sistema de gestión de hilos es automáticamente una sección crítica. Así se pueden evitar cómodamente las condiciones de competencia. Por otro lado, los hilos planificados de forma no apropiativa no pueden aprovechar los sistemas multiprocesador, ya que se ejecutan de forma exclusiva. Es preciso tener cuidado con las secciones de código grandes que no contengan llamadas al sistema de gestión de hilos. El programador puede necesitar insertar invocaciones a *yield()* cuya función es la de permitir que otros hilos puedan planificarse y progresar en su trabajo. Los hilos planificados de forma no apropiativa no son aptos para su uso en aplicaciones en tiempo real, ya que en éstas los eventos llevan asociados tiempos absolutos en los que deben procesarse.

Java no soporta, por defecto, el procesamiento en tiempo real [www.rtj.org]. Por ejemplo, las aplicaciones multimedia que procesan datos del tipo de voz y vídeo tienen requisitos en tiempo real tanto para la comunicación como para el procesamiento (un ejemplo es el filtrado y la compresión) [Govindan y Anderson 1991]. El Capítulo 15 examinará los requisitos de planificación de hilos en tiempo real. El control de procesos es otro ejemplo del dominio del tiempo real. En general cada dominio de tiempo real tiene sus propios requisitos de planificación de hilos. Es por lo tanto deseable que a veces las aplicaciones implementen sus propias políticas de planificación. Para examinar esto estudiaremos ahora la implementación de los hilos.

◊ **Implementación de los hilos.** Muchos núcleos dan soporte para procesos multi-hilo de forma nativa, incluyendo Windows NT, Solaris, Mach y Chorus. Estos núcleos proporcionan las llamadas al sistema de creación y gestión de hilos, y planifican de forma individual los hilos. Otros núcleos disponen únicamente de la abstracción de procesos mono-hilo. Los procesos multi-hilo deben entonces implementarse en una biblioteca de procedimientos enlazada a los programas de aplicación. En estos casos el núcleo no conoce estos hilos de nivel de usuario y por lo tanto no puede planificarlos independientemente. Una biblioteca en tiempo de ejecución de hilos organiza su planificación. Un hilo podría bloquear el proceso, y por lo tanto todos los hilos dentro de él, si realiza una llamada bloqueante al sistema, de forma que debe usarse la entrada-salida asíncrona (no bloqueante) del núcleo subyacente. Análogamente la implementación puede utilizar los temporizadores proporcionados por el núcleo y las posibilidades de interrupciones software para realizar una compartición del tiempo entre hilos.

Cuando el núcleo no tiene soporte para procesos multi-hilo, las implementaciones al nivel de usuario de los hilos adolecen de estos problemas:

- Los hilos de un cierto proceso no pueden aprovecharse de la existencia de un multiprocesador.

- Un hilo que genera una falta de página bloquea el proceso completo y todos los hilos dentro de él.
- Los hilos de diferentes procesos no pueden planificarse de acuerdo a un único criterio de prioridad relativa.

Sin embargo las implementaciones de hilos del nivel de usuario tienen ventajas significativas sobre las implementaciones al nivel de núcleo:

- Algunas operaciones sobre hilos son bastante más baratas. Por ejemplo la conmutación entre hilos pertenecientes al mismo proceso no supone necesariamente una llamada al sistema, es decir, una interrupción interna que es relativamente cara.
- Debido a que el módulo de planificación de hilos se implementa fuera del núcleo, puede personalizarse de forma que se adapte a los requisitos particulares de una cierta aplicación. Las variaciones en los requisitos de planificación se dan en gran medida por las consideraciones específicas de la aplicación, por ejemplo la naturaleza en tiempo real del procesamiento multimedia.
- Pueden soportarse muchos más hilos de nivel de usuario de los que el núcleo puede proporcionar por defecto.

Es posible combinar las ventajas de las implementaciones de hilos de nivel de usuario y de nivel de núcleo. Una posible aproximación, aplicada en el núcleo de Mach [Black 1990], es la de permitir al código de nivel de usuario proporcionar indicaciones de planificación al planificador de hilos del núcleo. Otra posibilidad, utilizada en el sistema operativo Solaris 2, es un tipo de planificación jerárquica. Cada proceso crea uno o más hilos de nivel de núcleo, conocidos en Solaris como *procesos de peso ligero*. También soporta hilos de nivel de usuario. Un planificador de nivel de usuario asigna cada hilo de nivel de usuario a un hilo de nivel de núcleo. Este esquema puede explotar los multiprocesadores y se beneficia del hecho de que algunas operaciones de creación y conmutación de hilos se realizan al nivel de usuario. La desventaja de este esquema es su falta de flexibilidad: si un hilo se bloquea en el núcleo entonces a todos los hilos de nivel de usuario asignados a él se les impide la ejecución, independientemente de si tienen o no la posibilidad de ejecutarse.

Varios proyectos de investigación han desarrollado esquemas de planificación jerárquica más avanzados para obtener mayor eficiencia y flexibilidad. Entre ellos está el trabajo llamado de activación del planificador [Anderson y otros 1991] en el trabajo multimedia de Govindan y Anderson [1991], el sistema operativo multiprocesador Psyche [Marsh y otros 1991], el núcleo Nemesis [Leslie y otros 1996] y el núcleo SPIN [Bershad y otros 1995]. La idea conductora de estos diseños es que un planificador de nivel de usuario no sólo necesita del núcleo simplemente un conjunto de hilos soportados por el núcleo sobre los que se puedan vincular los hilos de nivel de usuario. El planificador de nivel de usuario también necesita que el núcleo le notifique los *eventos* relevantes en sus decisiones de planificación. Describimos el diseño de activaciones del planificador para aclarar este concepto.

El paquete FastThreads de Anderson y otros [1991] es una implementación de un sistema de planificación jerárquico basado en eventos. Considera que los principales componentes del sistema son un núcleo ejecutándose en un computador con uno o más procesadores y un conjunto de programas de aplicación ejecutándose sobre él. Cada proceso de aplicación contiene un planificador de nivel de usuario que se encarga de gestionar los hilos dentro del proceso. El núcleo es responsable de la asignación de *procesadores virtuales* a procesos. El número de procesadores virtuales asignados a un proceso depende de diferentes factores como los requisitos de la aplicación, sus prioridades relativas y la demanda total en los procesadores. En la Figura 6.10a se muestra un ejemplo de una máquina con tres procesadores en la que el núcleo asigna un procesador virtual al proceso A, ejecutando un trabajo de prioridad relativamente baja, y dos procesadores virtuales al proceso B. Se llaman procesadores *virtuales* porque el núcleo puede asignar procesadores físicos

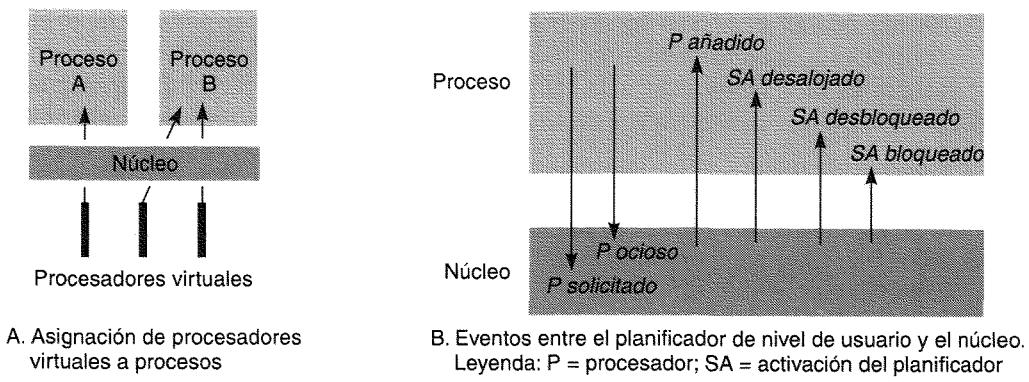


Figura 6.10. Activaciones del Planificador.

diferentes a cada proceso a lo largo del tiempo, mientras se garantice el número de procesadores asignados.

El número de procesadores virtuales asignados a un proceso puede variar. Los procesos pueden devolver un procesador virtual que han dejado de necesitar; además pueden solicitar procesadores virtuales extra. Por ejemplo, si el proceso A ha solicitado un procesador virtual extra y B termina, entonces el núcleo asigna uno a A.

En la Figura 6.10b se muestra que un proceso notifica al núcleo la ocurrencia de uno de estos dos tipos de eventos: cuando un procesador virtual está ocioso y no será necesario en el futuro o cuando se necesita un procesador virtual extra.

Además la Figura 6.10b muestra que el núcleo notifica al proceso cuándo ocurre un evento de entre cuatro posibles. Una *activación del planificador* (SA, *scheduler activation*) es una llamada desde el núcleo a un proceso que sirve para notificar al planificador del proceso la ocurrencia de un evento. La ejecución de esta manera de código desde un nivel inferior (el núcleo) es también conocida como *retrollamada* (*upcall*). El núcleo crea un SA cargando los registros físicos del procesador con un contexto que provoca la ejecución de código en el proceso, en una dirección de procedimiento designada por el planificador de nivel de usuario. Una SA puede de esta forma considerarse como una unidad de asignación de tiempo en un procesador virtual. El planificador de nivel de usuario tiene la tarea de asignar sus hilos *PREPARADOS* al conjunto de SA que en ese momento se están ejecutando en él. El número de SA es como máximo el número de procesadores virtuales que el núcleo ha asignado al proceso.

Los cuatro tipos de eventos que el núcleo notifica al planificador de nivel de usuario (al que nos referiremos en el futuro simplemente como *el planificador*) son los siguientes:

Procesador virtual asignado: el núcleo ha asignado un nuevo procesador virtual al proceso y éste es el primer intervalo temporal sobre él; el planificador puede cargar el SA con el contexto de un hilo *PREPARADO* el cual puede recomenzar su ejecución.

SA bloqueado: un SA se ha bloqueado en el núcleo y éste está utilizando un nuevo SA para notificarlo al planificador; el planificador pone el estado del hilo correspondiente a *BLOQUEADO* y puede asignar un hilo *PREPARADO* al SA de notificación.

SA desbloqueado: un SA que ha estado bloqueado en el núcleo se ha desbloqueado y está preparado para ejecutarse de nuevo al nivel de usuario; el planificador puede ahora devolver el hilo a la lista de *PREPARADOS*. Para la creación del SA de notificación, el núcleo puede asignar un procesador virtual nuevo al proceso o bien apropiarse de otro SA en el mismo proceso. En el segundo caso también debe comunicar el evento de apropiación al planificador, el cual recalculará la asignación de hilos a SA.

SA apropiado: el núcleo ha arrebatado el SA especificado al proceso (a pesar de que deberá

SA apropiado: el núcleo ha arrebatado el SA especificado al proceso (a pesar de que deberá realizar esta tarea asignando un procesador al nuevo SA en el mismo proceso); el planificador asigna el hilo desalojado a la lista de PREPARADOS y recalcula la asignación de hilos a

A pesar del amplio uso de los sockets TCP y UDP proporcionados por los núcleos más comunes, se continúa investigando para conseguir primitivas de comunicación con menores costes sobre núcleos experimentales. Examinaremos las cuestiones de prestaciones en la Sección 6.5.1.

◊ **Protocolos y apertura.** Uno de los principales requisitos de los sistemas operativos es el de proporcionar protocolos estándar que permitan la intercomunicación entre implementaciones middleware sobre diferentes plataformas. Algunos núcleos de investigación en la década de los ochenta incorporaban sus propios protocolos de red ajustados para las interacciones con RPC, siendo ejemplos notables Amoeba RPC [van Renesse y otros 1989], VMTCP [Cheriton 1986] y Sprite RPC [Ousterhout y otros 1988]. Sin embargo, estos protocolos no fueron ampliamente usados fuera de sus entornos de investigación nativos. Por el contrario, los diseñadores de los núcleos Mach 3.0 y Chorus (al igual que algunos núcleos de la década de los noventa, como L4 [Härtig y otros 1997]) decidieron dejar la elección de los protocolos de red como una cuestión abierta. Estos núcleos proporcionan un sistema de paso de mensajes únicamente entre procesos locales y dejan el procesamiento del protocolo de red a un servidor que se ejecuta sobre el núcleo.

Dados los requisitos diarios de acceso a Internet, es necesario que los sistemas operativos sean compatibles al nivel de TCP y UDP para todo, excepto para los dispositivos de red más pequeños. Además el sistema operativo debe habilitar al middleware para que pueda sacar partido de los nuevos protocolos de bajo nivel. Por ejemplo, los usuarios quieren beneficiarse de las tecnologías inalámbricas como las transmisiones por infrarrojos y por radiofrecuencia (RF), preferiblemente sin tener que actualizar sus aplicaciones. Esto supone que puedan integrarse los protocolos correspondientes, como IrDA para redes de infrarrojos y BlueTooth o HomeRF para las redes RF.

Los protocolos se organizan normalmente en una *pila* de niveles (véase el Capítulo 3). Muchos sistemas operativos permiten la integración estática de nuevos niveles, mediante la inclusión de un nivel del tipo de IrDa como *manejador (driver)* de protocolo instalado permanentemente. Por el contrario la *composición dinámica de protocolos* es una técnica en la que puede componerse dinámicamente una pila de protocolo para ajustarse a los requisitos de una aplicación particular y puede de utilizar cualquier nivel físico disponible dada la conectividad actual de la plataforma. Por ejemplo un navegador web ejecutándose en un computador portátil debe ser capaz de sacar partido de un enlace de área global inalámbrico mientras el usuario está en carretera, mientras que usará una conexión Ethernet de mayor velocidad cuando el usuario esté de vuelta en la oficina.

Otro ejemplo de composición dinámica de protocolos es el uso de un protocolo de solicitudes-respuestas a medida sobre un nivel de red inalámbrica para reducir las latencias de ida y vuelta. Las implementaciones estándar TCP tienen prestaciones mediocres sobre redes inalámbricas [Balakrishnan y otros 1996] donde tienen mayores tasas de paquetes perdidos que en las redes cableadas. Inicialmente, un protocolo de solicitud-respuesta del tipo de HTTP podría modificarse para trabajar de forma más eficiente sobre nodos conectados de modo inalámbrico mediante la utilización directa del nivel de transporte inalámbrico, en lugar de utilizar un nivel intermedio TCP.

El soporte para la composición de protocolos apareció en el diseño de los Streams de UNIX [Ritchie 1984]. De forma más reciente, Horus [van Renesse y otros 1995] y x-kernel [Hutchinson y Peterson 1991] tienen la capacidad de composición dinámica de protocolos.

6.5.1. PRESTACIONES DE LA INVOCACIÓN

Las prestaciones de la invocación son un factor crítico en el diseño de sistemas distribuidos. Cuanto más separan los diseñadores de la funcionalidad entre espacios de direcciones, más invocaciones remotas se necesitan. Los clientes y servidores pueden realizar muchos millones de operaciones asociadas a invocaciones a lo largo de su vida, de forma que pequeñas fracciones de milisegundos son relevantes en los costes de invocación. Las tecnologías de red continúan mejorando pero los tiempos de invocación no han decrecido en proporción con el incremento del ancho de banda de

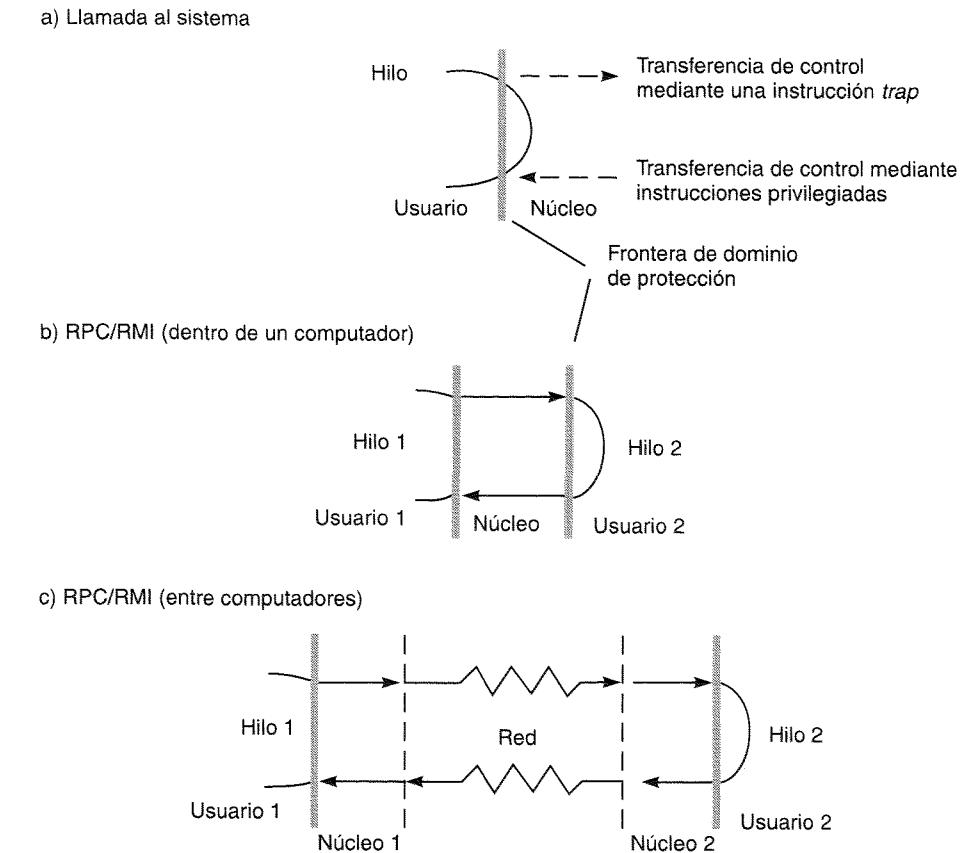
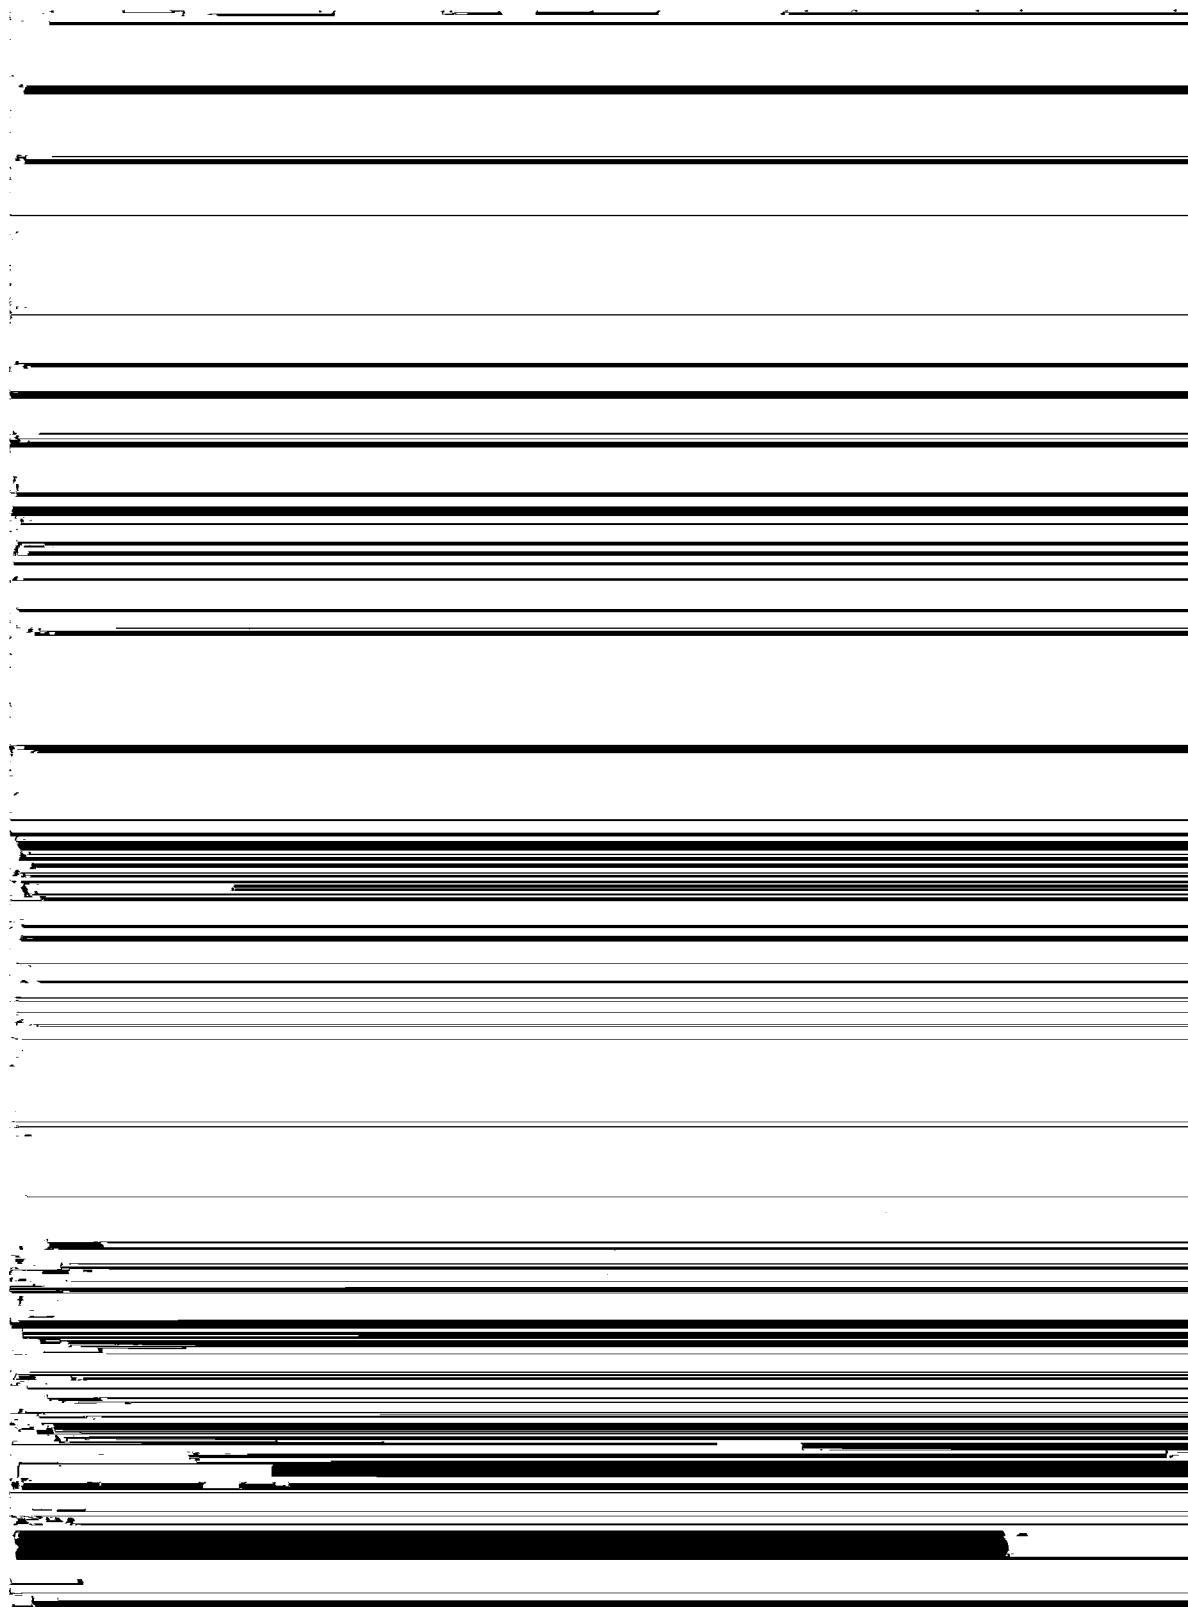


Figura 6.11. Invocaciones entre espacios de direcciones.

que este tamaño alcanza un umbral del tamaño del paquete de red. Por encima de este umbral debe enviarse al menos un paquete adicional para llevar los datos extra. En función del protocolo, puede usarse otro paquete más para reconocer la llegada de este paquete extra. Los saltos en el gráfico ocurren cada vez que se incrementa el número de paquetes.

El retardo no es el único valor de interés en una implementación de RPC: también está implicado el ancho de banda de RPC (o *productividad*) cuando hay que transferir datos en masa. Se trata de la tasa de transferencia de datos entre computadores en un único RPC. Si examinamos la Figura 6.12 se puede observar que el ancho de banda es relativamente bajo para pequeñas cantidades de datos, cuando las sobrecargas fijas de procesamiento predominan. Según se incrementa la cantidad de datos, el ancho de banda también se incrementa ya que las sobrecargas pasan a ser menos significativas. Gokhale y Schmidt [1996] calcularon una productividad de alrededor de 80 megabits/segundo en la transferencia de 64 kilobytes en un único RPC entre estaciones de trabajo sobre una red ATM con un ancho de banda nominal de 155 megabits/segundo. Para transferir 64 kilobytes se necesita alrededor de 0,8 milisegundos lo cual está en el mismo orden de magnitud que el tiempo calculado anteriormente para un RPC nulo sobre una red Ethernet a 100 megabits/segundo.

Recordemos que los pasos en un RPC son los siguientes (RMI realiza pasos similares):

- El resguardo del procedimiento del cliente empaqueta los argumentos de llamada dentro de un mensaje, envía el mensaje de solicitud y recibe y desempaquetá la respuesta.

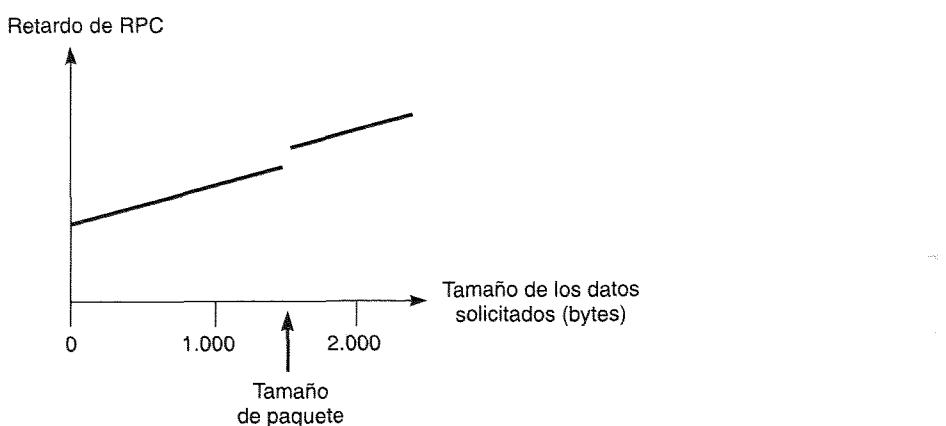


Figura 6.12. Retardo del RPC en función del tamaño del parámetro.

- En el servidor, un hilo de trabajo recibe la solicitud entrante, o bien un hilo de E/S recibe la solicitud y se la envía a un hilo de trabajo; en cualquier caso, el trabajador invoca el resguardo apropiado del procedimiento del servidor.
- El resguardo del servidor desempaqueteta el mensaje de solicitud, invoca el procedimiento designado y empaqueta y envía la respuesta.

Los siguientes son los principales componentes significativos en el retardo de invocación remota, aparte del tiempo de transmisión sobre la red:

Empaquetamiento: el empaquetamiento y desempaquetamiento, que llevan asociados la copia y conversión de datos, suponen una sobrecarga significativa al incrementarse la cantidad de datos.

Copia de datos: potencialmente, incluso después del empaquetamiento, los datos del mensaje son copiados varias veces durante un RPC:

1. En la frontera entre el usuario y el núcleo, es decir, entre el espacio de direcciones del cliente o del servidor y los búffers del núcleo.
2. Sobre cada nivel de protocolo (por ejemplo, RPC/UDP/IP/Ethernet).
3. Entre el interfaz de red y los búffers del núcleo.

Las transferencias entre la interfaz de red y la memoria principal son gestionadas normalmente por el acceso directo a memoria (DMA). El procesador gestiona el resto de copias.

Inicialización de paquetes: supone la inicialización de las cabeceras y terminaciones del protocolo, incluyendo los *checksums*. El coste es por lo tanto proporcional, en parte, a la cantidad de datos enviados.

Planificación de hilos y conmutación de contexto: puede ocurrir de la siguiente forma:

1. En un RPC se realizan varias llamadas al sistema (es decir, cambios de contexto) al invocar los resguardos las operaciones de comunicación del núcleo.
2. Se planifican uno o más hilos en el servidor.
3. Si el sistema operativo utiliza un proceso independiente de gestión de red, entonces cada *Envía* supone un cambio de contexto a uno de sus hilos.

Espera por reconocimientos: la elección del protocolo RPC puede influir en los retardos y en particular cuando se envían grandes cantidades de datos.

Un diseño cuidadoso del sistema operativo puede ayudar a reducir algunos de estos costes. El caso de estudio del diseño de Firefly RPC, disponible en www.cdk3.net/oss, muestra alguna de esas posibilidades en detalle, al mismo tiempo que muestra técnicas aplicables en la implementación del middleware. Ya hemos mostrado cómo un soporte correcto de hilos por parte del sistema operativo puede ayudar a reducir las sobrecargas debidas al multi-hilo. El sistema operativo también puede influir significativamente en la reducción de las sobrecargas de copia en memoria mediante recursos de compartición de memoria.

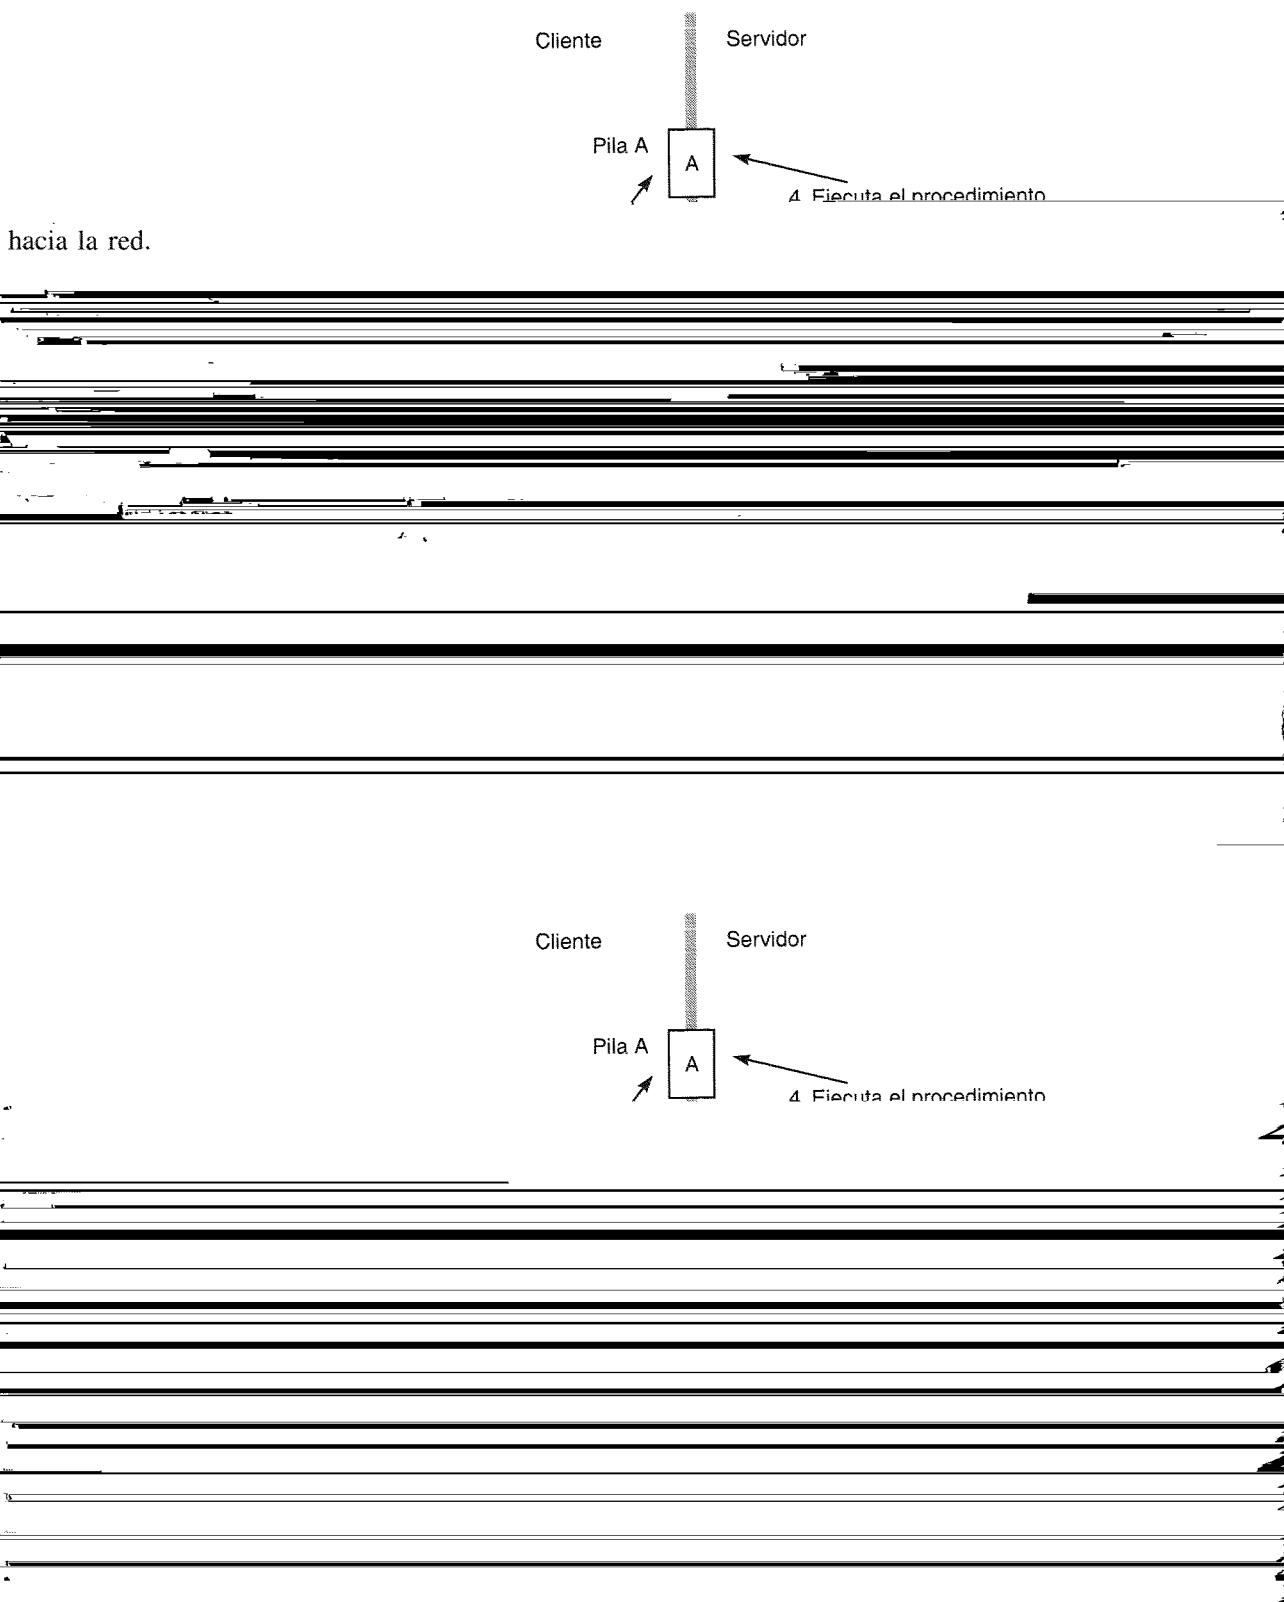
◊ **Compartición de memoria.** Las regiones compartidas (presentadas en la Sección 6.4) pueden utilizarse para una comunicación rápida entre un proceso de usuario y el núcleo, o bien entre procesos de usuario. Los datos se comunican mediante la escritura y la lectura en la región compartida. De esta forma los datos son enviados eficientemente, sin necesidad de copiarlos hacia o desde el espacio de direcciones del núcleo. Sin embargo, se pueden necesitar llamadas al sistema e interrupciones software para la sincronización, por ejemplo cuando el proceso de usuario ha escrito datos que deben ser transmitidos o cuando el núcleo ha escrito datos que deben ser consumidos por el proceso de usuario. Por supuesto una región compartida sólo se justifica cuando se utiliza suficientemente, de forma que se amortiza el coste de inicialización.

Incluso si se utilizan regiones compartidas, el núcleo debe copiar los datos desde cada búfer a las interfaces de red. La arquitectura U-Net [von Eicken y otros 1995] permite al código de nivel de usuario acceder directamente a la interfaz de red propia de forma que el código de nivel de usuario puede transferir datos a la red sin necesidad de copiarlos.

◊ **Elección del protocolo.** El retardo que sufre un cliente durante las interacciones solicitud-respuesta sobre TCP no es necesariamente peor que sobre UDP y en ocasiones es menor, por ejemplo en los mensajes largos. Sin embargo, cuando se implementan interacciones de tipo solicitud-respuesta sobre TCP es preciso hacerlo de forma cuidadosa, ya que no fue diseñado específicamente para este propósito. En particular el comportamiento del almacenamiento en TCP puede impedir la obtención de buenas prestaciones, y sus sobrecargas de conexión son una desventaja en comparación con UDP, a no ser que se envíe un número suficiente de mensajes sobre una única conexión para hacer despreciable la sobrecarga por cada solicitud.

Las sobrecargas de conexión de TCP son particularmente evidentes en las invocaciones web, debido a que HTTP 1.0 realiza una conexión TCP diferente en cada invocación. Los navegadores cliente se retrasan hasta que se realice la conexión. Además en muchos casos el algoritmo de arranque lento de TCP afecta retrasando la transferencia de datos HTTP de forma innecesaria. El algoritmo de arranque lento opera de forma pesimista en prevención de una posible congestión en la red enviando en primer lugar únicamente una pequeña ventana de datos, de forma previa a la recepción de un reconocimiento. Nielson y otros [1997] discuten cómo HTTP 1.1 utiliza las llamadas *conexiones persistentes*, que permanecen a lo largo de varias invocaciones. Por lo tanto los costes iniciales de conexión son amortizados siempre que se realicen varias invocaciones al mismo servidor web. Esto es razonable, ya que los usuarios a menudo solicitan varias páginas del mismo sitio, cada una de ellas conteniendo varias imágenes.

Nielson y otros también encontraron que la desactivación del almacenamiento por defecto proporcionado por el sistema operativo podría tener un impacto significativo en el retardo de invocación. A menudo es beneficioso almacenar varios mensajes pequeños para enviarlos a continuación todos juntos, en lugar de enviarlos en paquetes separados, debido a la latencia por paquete que se describió previamente. Por esta razón el sistema operativo no envía necesariamente los datos sobre la red inmediatamente después de la llamada de sockets *write()*. El comportamiento por defecto del sistema operativo es el de esperar hasta que el búfer esté lleno o bien, con la esperanza de que puedan llegar más datos, utilizar un temporizador que indique cuándo se deben despachar los datos hacia la red.



en una región compartida, debido a que varios hilos en el mismo cliente pueden invocar al servidor al mismo tiempo.

Bershad y otros también consideraron el coste de la planificación de hilos. Compárese el modelo de llamada al sistema y llamadas a procedimientos remotos de la Figura 6.11. Cuando se genera una llamada al sistema la mayor parte de los núcleos no planifican un nuevo hilo para manejar la llamada realizando en su lugar un cambio de contexto en el hilo que invoca de forma que él mismo maneja la llamada al sistema. En un RPC debe existir un procedimiento remoto en un computador diferente del computador donde se ejecuta el hilo del cliente, de forma que debe planificarse un hilo diferente para ejecutarlo. Sin embargo, para el caso local, será más eficiente para el hilo del cliente (el cual en otro caso estará *BLOQUEADO*) llamar al procedimiento invocado en el espacio de direcciones del servidor.

En este caso, debe programarse un servidor propio de modo diferente en la forma en la que hemos descrito los servidores previamente. En lugar de inicializar uno o más hilos que escuchan en los puertos esperando solicitudes de invocación, el servidor exporta un conjunto de procedimientos que están preparados para ser llamados. Los hilos en los procesos locales pueden entrar en el entorno de ejecución del servidor mientras se inicializan mediante la llamada a uno de los procedimientos exportados por el servidor. Un cliente que necesita invocar una operación del servidor debe en primer lugar enlazar con la interfaz del servidor (no mostrado en la figura). Esto lo realiza a través del núcleo, que a su vez notifica al servidor; cuando el servidor ha respondido al núcleo con una lista de direcciones de procedimiento permitidas, el núcleo responde al cliente con una capacidad para invocar las operaciones del servidor.

En la Figura 6.13 se muestra una invocación. Un hilo cliente entra en el entorno de ejecución del servidor realizando inicialmente una interrupción software hacia el núcleo y a continuación presentando al núcleo una capacidad. El núcleo lo comprueba y únicamente permite un cambio de contexto hacia un procedimiento válido del servidor; si es válido, el núcleo conmuta el contexto del hilo para llamar al procedimiento en el entorno de ejecución del servidor. Cuando el procedimiento en el servidor termina, el hilo vuelve al núcleo, el cual conmuta el hilo hacia atrás, es decir, hacia el entorno de ejecución del cliente. Hay que resaltar que tanto los clientes como el servidor emplean procedimientos resguardo para ocultar a los programadores de aplicaciones los detalles descritos.

◊ **Discusión de LRPC.** Hay pocas dudas acerca de que LRPC es más eficiente que RPC en el caso local, mientras se realicen suficientes invocaciones para amortizar los costes de gestión de la memoria. Bershad y otros obtuvieron valores de retardo para LRPC menores en un factor de tres que los valores de los RPC ejecutados de forma local.

La transparencia de ubicación no se sacrifica en la implementación de Bershad. Un resguardo del cliente examina un bit actualizado durante el enlace que indica si el servidor es local o remoto, y utiliza LRPC o RPC respectivamente. La aplicación ignora cuál se usa. Sin embargo, la transparencia frente a migración puede ser difícil de conseguir cuando se transfiere un recurso desde un servidor local a un servidor remoto, o viceversa, debido a la necesidad de cambiar los mecanismos de invocación.

En trabajos posteriores, Bershad y otros [1991] describieron varias mejoras de prestaciones, que se dirigen especialmente a la operación en multiprocesadores. Las mejoras se refieren en su mayor parte a la eliminación de interrupciones software hacia el núcleo y a la planificación de procesadores de forma que se eliminen transiciones de dominio innecesarias. Por ejemplo si un procesador está ocioso en el contexto de gestión de memoria del servidor en el momento en que un hilo cliente intenta invocar a un procedimiento del servidor, entonces el hilo debe transferirse a ese procesador. Esto elimina una transición de dominio; al mismo tiempo el procesador del cliente puede ser usado por otro hilo en el cliente. Estas mejoras implican una implementación a dos niveles (usuario y núcleo) de la planificación de hilos, como fue descrito en la Sección 6.4.



6.5.2. OPERACIÓN ASÍNCRONA

Hemos discutido cómo el sistema operativo puede ayudar al nivel de middleware a proporcionar

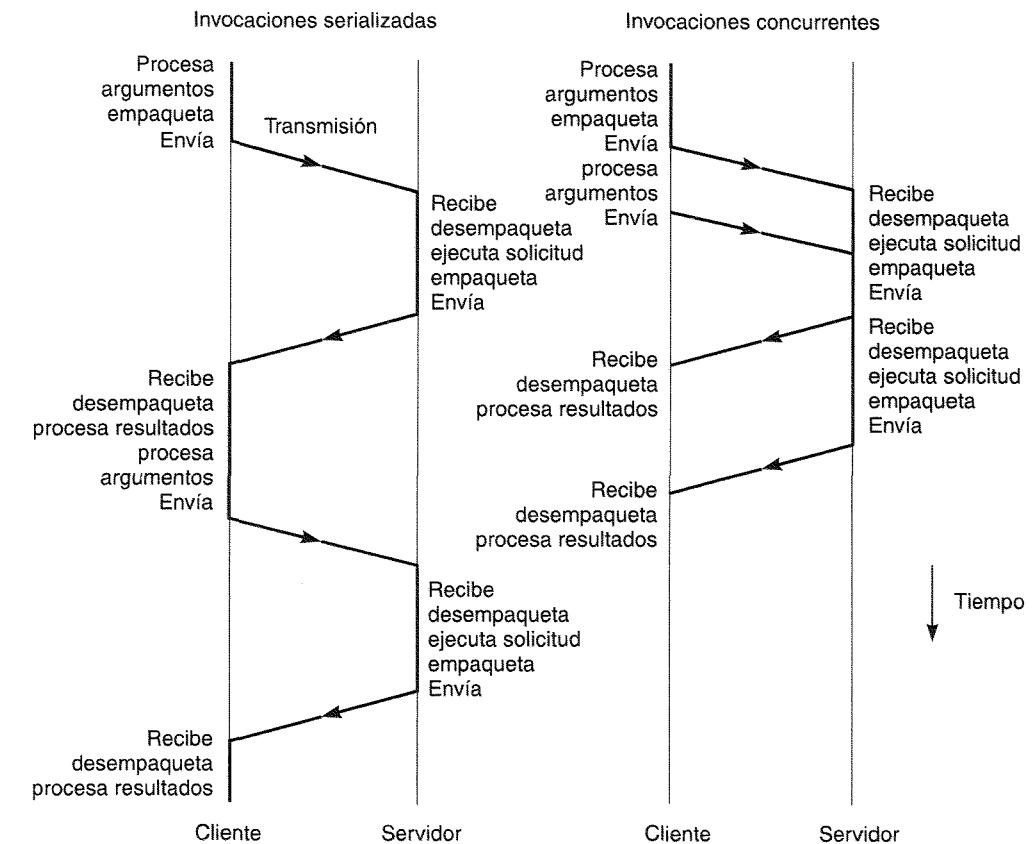


Figura 6.14. Temporización para invocaciones serializadas y concurrentes.

tan pronto como el mensaje de solicitud de invocación ha sido creado y está preparado para ser enviado.

Algunas veces el cliente no necesita respuesta (excepto posiblemente una indicación de fallo si el nodo destino no puede ser alcanzado). Por ejemplo, las invocaciones *de una dirección* de CORBA tienen semántica *pudiera*. En caso contrario el cliente utiliza una llamada separada para obtener los resultados de la invocación. Por ejemplo, el sistema de comunicación Mercury [Liskov y Shira 1988] soporta invocaciones asíncronas. Una operación asíncrona devuelve un objeto llamado *promesa*. Finalmente, cuando la invocación tiene éxito o bien se considera que ha fallado, el sistema Mercury pone el estado y cualquier valor de retorno en la promesa. El que invoca utiliza la operación *reclamación* para obtener los resultados desde la promesa. La operación reclamación se bloquea hasta que la promesa está preparada, con lo que devuelve los resultados o las excepciones desde la llamada. La operación *preparado* está disponible para comprobar una promesa sin necesidad de bloquearse; devuelve *cierto* o *falso* en función de si la promesa está preparada o bloqueada.

◊ **Invocaciones asíncronas persistentes.** Los mecanismos de invocación asíncrona tradicionales como las invocaciones Mercury y las invocaciones *de una dirección* de CORBA son implementadas mediante streams TCP y fallan si un stream se rompe, es decir, si el enlace de red está fuera de servicio o el nodo destino deja de funcionar.

Sin embargo, un modelo de invocación asíncrona más desarrollado, al que llamaremos *invocación asíncrona persistente*, está resultando cada vez más relevante debido a la operación desconec-

tada. Este modelo es similar a Mercury respecto a las operaciones de programación que proporciona, pero la diferencia estriba en la semántica de fallos. Un mecanismo de invocación convencional (síncrono o asíncrono) está diseñado para fallar después de que han ocurrido un cierto número de timeouts. Sin embargo, a menudo estos timeouts a corto plazo no son apropiados cuando se generan desconexiones o latencias muy elevadas.

Un sistema de invocación asíncrona persistente intenta realizar la invocación indefinidamente, hasta que puede determinar que ha tenido éxito o ha fracasado, o hasta que la aplicación cancela la invocación. Un ejemplo es QRPC (RPC en colas) en el conjunto de herramientas Rover para acceso a información móvil [Joseph y otros 1997].

Tal y como el nombre sugiere, QRPC inserta en colas, realizando un registro estable, las solicitudes de invocaciones salientes mientras no exista conexión de red y planifica las operaciones que son enviadas a los servidores a través de la red cuando existe conexión. De forma similar inserta en colas en el servidor los resultados de las invocaciones en lo que se puede considerar como el buzón de invocaciones del cliente, hasta que el cliente vuelva a conectarse y los obtenga. Las solicitudes y los resultados pueden comprimirse al insertarse en las colas, antes de ser transmitidos sobre una red de pequeño ancho de banda.

QRPC se puede aprovechar de los diferentes enlaces de comunicación para el envío de solicitudes de invocación y para la recepción de las respuestas. Por ejemplo, puede enviarse una solicitud sobre un enlace GSM mientras que el usuario esté en la carretera y la respuesta recibirse posteriormente sobre un enlace Ethernet cuando el usuario conecte su dispositivo a la intranet corporativa. En principio, el sistema de invocación puede incluso almacenar los resultados de la invocación cerca del siguiente punto de conexión esperado para el usuario.

El planificador de red del cliente opera según diferentes criterios y no envía necesariamente las invocaciones en orden FIFO. Las aplicaciones pueden asignar prioridades a las invocaciones individuales. Cuando una conexión pasa a estar disponible, QRPC evalúa su ancho de banda y los gastos de su utilización. En primer lugar envía solicitudes de invocación de alta prioridad, no enviándolas todas si el enlace es lento y caro (como las conexiones sin hilos de área global) asumiendo que un enlace más rápido y barato como Ethernet estará finalmente disponible. De forma similar, QRPC utiliza prioridades cuando solicita los resultados de las invocaciones desde el buzón sobre un enlace de bajo ancho de banda.

La programación con un sistema de invocación asíncrona (persistente o de otro tipo) suscita la cuestión de cómo los usuarios pueden continuar usando las aplicaciones en sus dispositivos cliente si los resultados de las invocaciones no son todavía conocidos. Por ejemplo, el usuario se puede preguntar si ha tenido éxito actualizando un párrafo sobre un documento compartido, o bien algún otro usuario puede haber realizado una actualización conflictiva como el borrado de un párrafo. En el Capítulo 14 se examina esta cuestión.

6.6. ARQUITECTURA DEL SISTEMA OPERATIVO

En esta sección se examina la arquitectura de un núcleo válido para un sistema distribuido. Adoptamos una aproximación de principios básicos comenzando con el requisito de apertura y examinando las principales arquitecturas de núcleo propuestas con este requisito en mente.

Un sistema distribuido abierto debería posibilitar lo siguiente:

- Ejecutar en cada computador únicamente el software de sistema que sea necesario para jugar su papel particular en la arquitectura del sistema; los requisitos del software de sistema pueden variar entre, por ejemplo, asistentes digitales personales y servidores de cálculo dedicados. La carga de módulos redundantes desperdicia los recursos de memoria.
- Permitir al software (y al computador) implementar la posibilidad de que cualquier servicio particular sea cambiado independientemente de otros recursos.

- Permitir que se puedan proporcionar diferentes alternativas para el mismo servicio, cuando ello sea requerido por los diferentes usuarios o aplicaciones.
- Introducir nuevos servicios sin dañar la integridad de los ya existentes.

La separación entre los *mecanismos* de gestión de recursos fijos y las *políticas* de gestión de recursos, las cuales varían entre diferentes aplicaciones y entre diferentes servicios, ha sido durante mucho tiempo un principio guía en el diseño de los sistemas operativos [Wulf y otros 1974]. Por ejemplo, decimos que un sistema de planificación ideal debería proporcionar mecanismos para permitir a una aplicación multimedia, como una aplicación de videoconferencia, conseguir sus necesidades de tiempo real mientras coexiste con aplicaciones que no son en tiempo real, como un navegador web.

De forma ideal, el núcleo debería proporcionar únicamente los mecanismos básicos sobre los que se implementan en un cierto nodo las tareas de gestión de recursos generales. Los módulos del servidor deberían cargarse de forma dinámica bajo solicitud, para implementar las políticas de gestión de recursos que solicitan las aplicaciones actualmente en ejecución.

◇ **Núcleos monolíticos y micronúcleos.** Existen dos ejemplos clave en el diseño de los núcleos: la aproximación *monolítica* y la aproximación *micronúcleo*. Estos diseños difieren básicamente en la decisión sobre qué funcionalidad pertenece al núcleo y qué se deja al proceso servidor que puede ser cargado dinámicamente para ejecutarse sobre él. A pesar de que los micronúcleos no están ampliamente extendidos, es instructivo entender sus ventajas e inconvenientes comparándolos con los núcleos típicos existentes actualmente.

Se dice que el núcleo del sistema operativo UNIX es *monolítico* (véase la definición en la caja). Este término intenta sugerir el hecho de que es *masivo*: realiza todas las funciones básicas del sistema operativo necesitando para ello del orden de megabytes de código y datos, y en su composición es *indistinguible*: está codificado de una forma no modular. El resultado es que en gran medida resulta *intratable*: es difícil alterar cualquier componente software individual para adaptarlo a los requisitos cambiantes. Otro ejemplo de un núcleo monolítico es el del sistema operativo en red Sprite [Ousterhout y otros 1988]. Un núcleo monolítico puede contener algunos procesos servidores que se ejecutan dentro de su espacio de direcciones, incluyendo servidores de archivos y de red. El código que ejecutan estos procesos es parte de la configuración estándar del núcleo (véase la Figura 6.15).

◇ **Monolítico.** El Diccionario Chambers del Siglo XX proporciona la siguiente definición de *monolito* y *monolítico*. «**monolito**, *n.* un pilar o una columna o una simple piedra: cualquier cosa que recuerde la uniformidad de un monolito, carácter masivo e inflexibilidad. -*adj.* relacionado con monolítico o parecido a un monolito: de un estado, una organización, etc., masivo y en todo sin diferencias; por esta razón intratable».

Por el contrario, para el caso de un diseño micronúcleo, el núcleo proporciona únicamente las abstracciones más básicas, principalmente espacios de direcciones, hilos y comunicación *local* entre procesos; el resto de servicios del sistema vienen dados por servidores que se cargan dinámicamente, precisamente en aquellos computadores del sistema distribuido que los requieran (véase la Figura 6.15). Los clientes acceden a esos servicios del sistema utilizando los mecanismos de invocación basados en mensajes proporcionados por el núcleo.

Hemos dicho previamente que los usuarios tienden a rechazar sistemas operativos que no ejecutan sus aplicaciones. Además de la extensibilidad, los diseñadores de micronúcleos tienen otro objetivo: la emulación binaria de sistemas operativos estándar como el UNIX [Armand y otros 1989, Golub y otros 1990, Hartig y otros 1997].

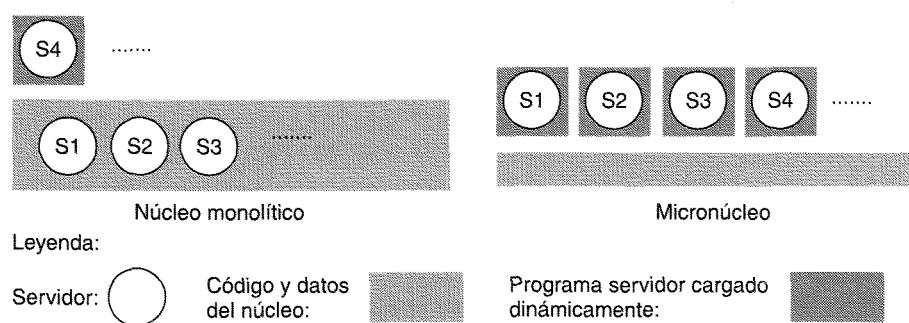


Figura 6.15. Núcleo monolítico y micronúcleo.

La situación del micronúcleo (en su forma más general) dentro del diseño del sistema distribuido en su conjunto se muestra en la Figura 6.16. El micronúcleo aparece como un nivel entre el de hardware y el que forman los principales componentes del sistema, llamados *subsistemas*. Si las prestaciones son el principal objetivo, en lugar de la portabilidad, entonces el middleware puede utilizar directamente los servicios del micronúcleo. En otro caso, utiliza un lenguaje con un subsistema de soporte en tiempo de ejecución, o bien una interfaz de sistema operativo de alto nivel proporcionado por un subsistema de emulación de sistema operativo. Cada uno de ellos se implementa mediante una combinación de procedimientos de biblioteca enlazados dentro de las aplicaciones y un conjunto de servidores ejecutándose sobre el micronúcleo.

Puede existir más de una interfaz de llamadas al sistema (más de un *sistema operativo*) a disposición del programador en la misma plataforma. Esta situación es una reminiscencia de la arquitectura del IBM 370, cuyo sistema operativo VM puede presentar varias máquinas virtuales completas a diferentes programas que se ejecutan en el mismo computador (monoprocesador). Un ejemplo para el caso de sistemas distribuidos es la implementación de UNIX y OS/2 sobre el núcleo del sistema operativo distribuido MACH.

◇ **Comparación.** Las principales ventajas de un sistema operativo basado en micronúcleo son su extensibilidad y su capacidad para hacer cumplir la modularidad por encima de las fronteras de la protección de memoria. Además es más probable que un núcleo relativamente pequeño esté libre de errores que uno mayor y más complejo.

La ventaja de un diseño monolítico es la eficiencia relativa con la que pueden invocarse las operaciones. Las llamadas al sistema pueden ser más caras que los procedimientos convencionales,

pero incluso utilizando las técnicas que hemos estudiado en la sección anterior, una invocación a un espacio de direcciones de nivel de usuario separado en el mismo nodo es todavía más costosa.

La falta de estructura en los diseños monolíticos puede evitarse utilizando técnicas de ingeniería de software como el diseño por niveles (utilizado en MULTICS [Organick 1972]) o el diseño orientado a objetos, utilizado por ejemplo en Choices [Campbell y otros 1993]. Windows NT utiliza una combinación de ambos [Custer 1998]. Sin embargo, Windows NT sigue siendo *masivo*, y la mayor parte de su funcionalidad no está diseñada para ser reemplazada de forma rutinaria. Incluso un núcleo grande modularizado puede ser difícil de mantener y proporciona un soporte muy limitado para un sistema distribuido abierto. Mientras los módulos se ejecuten dentro del mismo espacio de direcciones utilizando un lenguaje del tipo C o C++, que genera código con el objetivo de la eficiencia pero permite accesos a datos de forma arbitraria, es posible que la modularidad sea abandonada por parte de programadores que buscan implementaciones eficientes, y que un error en un módulo corrompa los datos de otro.

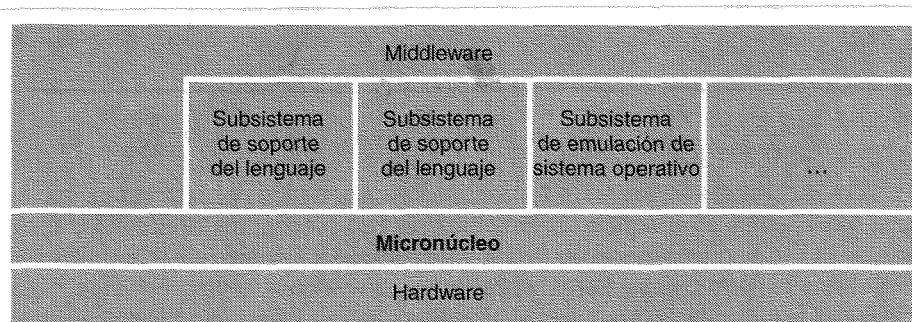
◇ **Algunas aproximaciones híbridas.** Dos de los micronúcleos originales, Mach [Acetta y otros 1986] y Chorus [Rozier y otros 1990], comenzaron su evolución ejecutando los servidores únicamente como procesos de usuario. Por lo tanto la modularidad está asegurada por el hardware mediante los espacios de direcciones. Donde los servidores necesiten acceso directo al hardware, pueden proporcionarse llamadas especiales al sistema para esos procesos privilegiados, las cuales vincularán registros de dispositivo y búferes sobre sus espacios de direcciones. El núcleo convierte interrupciones en mensajes que permitirán a los servidores de nivel de usuario el manejo de interrupciones.

Debido a problemas en las prestaciones, los diseños del micronúcleo de Chorus y Mach finalmente cambiaron para permitir que los servidores pudieran cargarse dinámicamente sobre el espacio de direcciones del núcleo o bien sobre el espacio de direcciones de nivel de usuario. En cualquier caso los clientes interactúan con los servidores utilizando las mismas llamadas de comunicación entre procesos. Un programador puede por lo tanto depurar un servidor al nivel de usuario y, cuando el desarrollo esté aparentemente completo, permitir al servidor ejecutarse dentro del espacio de direcciones del núcleo para optimizar las prestaciones del sistema. Sin embargo, un servidor de este tipo amenaza la integridad del sistema ya que puede llegar a contener errores.

El diseño del sistema operativo SPIN [Bershad y otros 1995] afronta de forma astuta el problema de ceder eficiencia por protección mediante el empleo de servicios de protección en el lenguaje. El núcleo y todos los módulos cargados de forma dinámica e insertados en el núcleo se ejecutan en un único espacio de direcciones. Sin embargo, todos ellos son escritos en un lenguaje de tipos seguro (Modula-3), de forma que pueden estar mutuamente protegidos. Los dominios de protección dentro del espacio de direcciones del núcleo se establecen utilizando espacios de nombres protegidos. Ningún módulo insertado en el núcleo puede acceder a un recurso a no ser que haya gestionado una referencia a él; y Modula-3 fuerza el cumplimiento de la regla que dice que una referencia puede utilizarse únicamente para realizar operaciones permitidas por el programador.

En un intento de minimizar las dependencias entre los módulos del sistema, los diseñadores de SPIN eligen un modelo basado en eventos como mecanismo para la interacción entre módulos insertados en el espacio de direcciones del núcleo (véase la Sección 5.4 para una descripción de la programación basada en eventos). El sistema define un conjunto de eventos centrales, como la llegada de un paquete de red, interrupciones del temporizador, faltas de página y cambios de estado de los hilos. Los componentes del sistema operan registrándose a ellos mismos como manejadores de los eventos que los afectan. Por ejemplo, un planificador se registrará a sí mismo como gestor de eventos similares a aquellos estudiados en el sistema de activaciones del planificador; véase la Sección 6.4.

Los sistemas operativos del tipo de Nemesis [Leslie y otros 1996] explotan el hecho de que, incluso a nivel del hardware, un espacio de direcciones no es necesariamente un único dominio de



El micronúcleo soporta el middleware mediante subsistemas

Figura 6.16. El papel del micronúcleo.

protección. El núcleo coexiste en un único espacio de direcciones con todos los módulos del sistema cargados dinámicamente y con todas las aplicaciones. Cuando el núcleo carga una aplicación, sitúa el código de la aplicación y los datos en regiones seleccionadas entre aquéllas disponibles en tiempo de ejecución. La llegada de procesadores con direcciones de 64-bits ha provocado que los sistemas operativos de espacio de direcciones único pasen a ser especialmente atractivos, ya que soportan espacios de direcciones muy grandes que pueden albergar muchas aplicaciones.

El núcleo de un sistema operativo de espacio de direcciones único configura los atributos de protección sobre regiones individuales dentro del espacio de direcciones para restringir el acceso al código de nivel de usuario. El código de nivel de usuario se ejecuta todavía con el procesador en un contexto de protección particular (determinado por la configuración en el procesador y en la unidad de gestión de memoria), lo que proporciona acceso completo a sus propias regiones y únicamente acceso compartido de forma selectiva a otras regiones. El ahorro conseguido por el espacio de direcciones único, comparado con la utilización de múltiples espacios de direcciones, es que el núcleo nunca vacía cualquier caché cuando implementa una transición de dominio.

Algunos diseños de núcleos más recientes, del tipo de L4 [Hartig y otros 1997] y Exokernel [Kaashoek y otros 1997], se basan en la idea de lo que hemos llamado *micronúcleos* todavía contienen excesiva política en relación con mecanismos. L4 es un diseño de micronúcleo de *segunda generación* que obliga a los módulos del sistema cargados dinámicamente a ejecutarse en espacios de direcciones de nivel de usuario, pero optimiza la comunicación entre procesos para compensar los costes de ese tipo de operación. Descarga la mayor parte de la complejidad del núcleo cediendo la gestión de los espacios de direcciones a los servidores de nivel de usuario. Exokernel utiliza una aproximación completamente diferente, basada en el empleo de bibliotecas de nivel de usuario en lugar de servidores de nivel de usuario para proporcionar las extensiones funcionales. Proporciona asignación protegida de recursos de muy bajo nivel, como bloques de disco, y espera que el resto de la funcionalidad de gestión de recursos (incluso un sistema de archivos) sea realizada mediante el enlace de bibliotecas en las aplicaciones.

En palabras de un diseñador de micronúcleos [Liedtke 1996], *la historia de los micronúcleos está llena de buenas ideas y de callejones sin salida*. La cuestión todavía pendiente estriba en cómo diseñar una arquitectura de sistema operativo que sea lo suficientemente extensible y que proporcione buenas prestaciones en comparación con los diseños monolíticos.

6.7. RESUMEN

Este capítulo ha descrito cómo el sistema operativo soporta el nivel de middleware proporcionando invocaciones sobre recursos compartidos. El sistema operativo proporciona una colección de mecanismos sobre los que se pueden implementar múltiples políticas de gestión de recursos, con el objeto de satisfacer los requisitos locales y para aprovechar las mejoras tecnológicas. Permite a los servidores encapsular y proteger los recursos, mientras que permite a los clientes compartirlos concurrentemente. Proporciona los mecanismos necesarios para que los clientes invoquen operaciones sobre los recursos.

Un proceso está formado por un entorno de ejecución e hilos: un entorno de ejecución consiste en un espacio de direcciones, interfaces de comunicación y otros recursos locales como semáforos; un hilo es una abstracción de la actividad que se ejecuta dentro de un entorno de ejecución. Los espacios de direcciones deben ser grandes y dispersos para soportar la compartición y el acceso mediante correspondencias de objetos como los archivos. Se pueden crear espacios de direcciones nuevos cuyas regiones sean heredadas de los procesos padre. Una técnica importante para copiar regiones es la llamada copia en escritura. Los procesos pueden tener múltiples hilos, los cuales comparten el entorno de ejecución. Los procesos multi-hilo permiten conseguir concurrencia relati-

vamente barata y aprovechar el paralelismo de los multiprocesadores. Son útiles tanto para los clientes como para los servidores. Implementaciones recientes de hilos permiten una planificación a dos niveles: el núcleo proporciona acceso a múltiples procesadores, mientras que el código de nivel de usuario maneja los detalles de la política de planificación.

El sistema operativo proporciona primitivas básicas de paso de mensajes y mecanismos de comunicación a través de memoria compartida. La mayor parte de los núcleos incluyen la comunicación sobre red como un servicio básico; otros proporcionan únicamente comunicación local y dejan la comunicación sobre la red a los servidores, que pueden implementar múltiples protocolos de comunicación. Se trata de una pugna de las prestaciones contra la flexibilidad.

Discutimos las invocaciones remotas y contabilizamos las diferencias entre las sobrecargas debidas directamente al hardware de red y las debidas a la ejecución de código de sistema operativo. Encontramos que la proporción del tiempo total debida al software es relativamente grande para una invocación nula pero disminuye proporcionalmente al tamaño de los argumentos de la invocación. Las principales sobrecargas relacionadas con una invocación que son susceptibles de ser optimizadas son el empaquetamiento, la copia de datos, la inicialización de los paquetes, la planificación de los hilos y el cambio de contexto y el flujo de control del protocolo usado. La invocación entre diferentes espacios de direcciones dentro del mismo computador es un caso especialmente importante, por lo que hemos descrito las técnicas de gestión de hilos y de paso de parámetros utilizadas en los RPC de peso ligero.

Existen principalmente dos aproximaciones a la arquitectura del núcleo: núcleos monolíticos y micronúcleos. La principal diferencia entre ellos reside en dónde se coloca la línea separadora entre la gestión de recursos del núcleo y la gestión de recursos realizada por servidores cargados dinámicamente (y normalmente de nivel de usuario). Un micronúcleo debe soportar al menos la noción de proceso y la comunicación entre procesos. Soporta subsistemas de emulación de sistemas operativos así como soporte de lenguaje y otros subsistemas, como los de procesamiento en tiempo real.

EJERCICIOS

- 6.1. Discuta cada una de las tareas de encapsulamiento, procesamiento concurrente, protección, resolución de nombres, comunicación de parámetros y resultados y planificación para el caso del servicio de archivos de UNIX (o de cualquier otro núcleo con el que esté familiarizado)
- 6.2. ¿Por qué algunas interfaces de sistema están implementadas con llamadas al sistema dedicadas (o al núcleo), mientras que otras lo están sobre llamadas al sistema basadas en mensajes?
- 6.3. González decide que cada hilo de sus procesos debe tener su propia pila *protegida* mientras que el resto de regiones de cada proceso podrá estar completamente compartida. ¿Tiene esto sentido?
- 6.4. ¿Deben los gestores de señales (interrupciones software) pertenecer a un proceso o a un hilo?
- 6.5. Discuta la cuestión de los nombres aplicada a las regiones de memoria compartidas.
- 6.6. Sugiera un esquema para equilibrar la carga en un conjunto de computadores. Debe discutir:
 - i) Qué requisitos de usuario o sistema debe cumplir el esquema.
 - ii) A qué categoría de aplicaciones está dirigido.

- iii) Cómo se mide la carga y con qué precisión.
 iv) Cómo se monitoriza la carga y se selecciona la localización de un nuevo proceso. Suponga que los procesos no pueden migrar.
- ¿Cómo puede su diseño verse afectado si los procesos pueden migrar entre computadores?
 ¿Espera que la migración de procesos tenga un coste significativo?
- 6.7.** Explique las ventajas de la copia en escritura de regiones en UNIX, en la que una invocación a *fork* está normalmente seguida de una invocación a *exec*. ¿Qué ocurrirá si una región que ha sido copiada utilizando copia en escritura se copia a sí misma?
- 6.8.** Un servidor de archivos utiliza caché y consigue una tasa de acierto del 80 %. Las operaciones sobre archivos en el servidor suponen 5 milisegundos de tiempo de CPU cuando el servidor encuentra en la caché el bloque solicitado, y suponen otros 15 milisegundos adicionales de E/S en disco si no lo encuentra. Explicando cualquier suposición que realice, estime la productividad del servidor (valor medio de solicitudes/segundo) si éste es:
- Mono-hilo.
 - Dos hilos ejecutándose en un único procesador.
 - Dos hilos ejecutándose en un computador con dos procesadores.
- 6.9.** Compare la arquitectura multi-hilo de asociación de trabajadores con la arquitectura de hilo por solicitud.
- 6.10.** ¿Qué operaciones sobre hilos son más costosas?
- 6.11.** Un *spin lock* (véase Bacon [1998]) es una variable booleana accedida a través de una instrucción atómica *test-and-set*, que se utiliza para conseguir exclusión mutua. ¿Se podría utilizar un *spin lock* para obtener exclusión mutua entre hilos en un computador con un único procesador?
- 6.12.** Explique qué debe proporcionar el núcleo para una implementación de hilos a nivel de usuario, como en Java o en UNIX.
- 6.13.** ¿Las faltas de página son un problema para la implementación de hilos de nivel de usuario?
- 6.14.** Explique los factores que motivan la planificación híbrida del diseño de *activaciones de planificación* (en lugar de la planificación pura de nivel de usuario o de nivel de núcleo).
- 6.15.** ¿Por qué debería estar interesado un paquete de hilos en los eventos que provocan que un hilo pase a bloqueado o a desbloqueado? ¿Por qué debería estar interesado en el evento de desalojo inminente de un procesador virtual? (Nota: otros procesadores virtuales pueden ser asignados.)
- 6.16.** El tiempo de transmisión de red supone un 20 % en un RPC nulo y un 80 % en un RPC que transmite 1.024 bytes de usuario (menor que el tamaño de un paquete de red). ¿En qué porcentaje de tiempo mejorarán esas dos operaciones si la red es actualizada desde 10 megabits/segundo a 100 megabits/segundo?
- 6.17.** Un RMI nulo sin parámetros que invoca un procedimiento vacío y que no devuelve ningún valor retarda al invocador 2,0 milisegundos. Explique qué contribuye a conseguir ese valor. En el mismo sistema RMI, cada 1 K de datos de usuario añade 1,5 milisegundos extra. Un cliente necesita solicitar 32 K de datos desde un servidor de archivos. ¿Debe usar un RMI de 32 K o bien 32 RMIs de 1 K?
- 6.18.** ¿Qué factores identificados en el coste de una invocación remota también afectan a un sistema de paso de mensajes?

- 6.19.** Explique cómo puede utilizarse una región compartida para que un proceso lea datos escritos por el núcleo. Incluya en su explicación lo necesario para la sincronización.
- 6.20.**
 - ¿Puede un servidor que es invocado por una llamada a procedimiento de peso ligero controlar el grado de concurrencia dentro de él?
 - Explique por qué y cómo un cliente que utiliza RPC's de peso ligero no puede realizar invocaciones a código arbitrario dentro de un servidor.
 - ¿Expone LRPC a los clientes y servidores a mayores riesgos de interferencia mutua que los RPC convencionales (dada la compartición de memoria)?
- 6.21.** Un cliente realiza RMI sobre un servidor. El cliente necesita 5 milisegundos para computar los argumentos de cada solicitud y el servidor necesita 10 milisegundos para procesar cada solicitud. El tiempo de procesamiento local del sistema operativo para cada operación *envío* o *recepción* es de 0,5 milisegundos y el tiempo necesario de red para transmitir cada solicitud o respuesta es de 3 milisegundos. El empaquetamiento y el desempaquetamiento necesitan 0,5 milisegundos por cada mensaje.
 Estime el tiempo que necesita un cliente para generar y obtener resultados de 2 solicitudes (i) si es mono-hilo, y (ii) si tiene dos hilos que pueden realizar solicitudes de forma concurrente sobre un único procesador. ¿Hay necesidad de que RMI sea asíncrono si los procesos son multi-hilo?
- 6.22.** Explique qué se entiende por política de seguridad y cuáles son los mecanismos correspondientes para el caso de un sistema operativo multiusuario del tipo de UNIX.
- 6.23.** Explique los requisitos de enlazado de programas que deben cumplirse si un servidor es cargado dinámicamente dentro del espacio de direcciones del núcleo, y cómo estos requisitos difieren para el caso de ejecutar el servidor al nivel de usuario.
- 6.24.** ¿Cómo puede comunicarse una interrupción a un servidor de nivel de usuario?
- 6.25.** Ciertos computadores se estiman que, independientemente de que lo ejecute o no el sistema operativo, la planificación de hilos cuesta alrededor de 50 microsegundos, una invocación a un procedimiento nulo 1 milisegundo, un cambio de contexto hacia el núcleo cuesta 20 microsegundos y una transición de dominio 40 microsegundos. Para Mach y SPIN, estime el coste de un cliente que invoca a un procedimiento nulo cargado dinámicamente.

7

SEGURIDAD

- 7.1. Introducción
- 7.2. Visión general de las técnicas de seguridad
- 7.3. Algoritmos criptográficos
- 7.4. Firmas digitales
- 7.5. Prálmática de la criptografía
- 7.6. Casos de estudio: Needham-Schroeder, Kerberos, SSL y Millicent
- 7.7. Resumen

Hay una necesidad apremiante de medidas para garantizar la privacidad, integridad y disponibilidad de recursos en los sistemas distribuidos. Los ataques contra la seguridad toman las formas de escuchas, suplantación, modificación y denegación de servicio. Los diseñadores de sistemas distribuidos seguros deben tratar con interfaces de servicio desprotegidos y redes inseguras en un entorno donde se supone que los atacantes tienen conocimiento sobre los algoritmos empleados para desplegar los recursos computacionales.

La criptografía proporciona la base de la autenticación de mensajes así como del secreto y la integridad; y para explotarla es preciso utilizar protocolos de seguridad diseñados cuidadosamente. La selección de algoritmos criptográficos y la administración de claves son puntos críticos para la efectividad, prestaciones y usabilidad de los mecanismos de seguridad. La criptografía de clave pública facilita la distribución de claves criptográficas pero sus prestaciones son inadecuadas para la encriptación de datos masivos. La criptografía de clave secreta es más adecuada para tareas de encriptación masiva. Los protocolos híbridos como SSL (*Secure Sockets Layer*) establecen canales seguros empleando criptografía de clave pública para intercambiar claves secretas que se usarán en subsiguientes intercambios de datos.

La información digital puede venir firmada, ofreciéndonos certificados digitales. Estos certificados permitirán establecer relaciones de confianza entre los usuarios y las organizaciones.

7.1. INTRODUCCIÓN

En todos aquellos sistemas de computadores, donde haya objetivos potenciales para ataques maliciosos o con fines de diversión habrá que incluir medidas de seguridad. Esto es especialmente cierto para sistemas que traten con transacciones financieras, confidenciales, clasificadas u otra información cuyo secreto e integridad sea crítica. En la Figura 7.1, se resume la evolución de las necesidades de seguridad en los sistemas de computadores desde su aparición con el advenimiento de la compartición de datos en los sistemas de tiempo compartido multiusuario de las décadas de los años sesenta y setenta. Hoy en día, con el advenimiento de los sistemas distribuidos abiertos de carácter global se nos presenta una amplia lista de cuestiones sobre seguridad.

La necesidad de proteger la integridad y la privacidad de la información, y otros recursos que pertenecen a individuos y organizaciones, conjuga ambos mundos: el físico y el digital. Nace, como es lógico, de la necesidad de compartir recursos. En el mundo físico, las organizaciones adoptan *políticas de seguridad* para poder compartir recursos dentro de unos límites especificados. Por ejemplo, una compañía podrá permitir la entrada a sus dependencias a ciertos empleados y visitantes autorizados. Una política de seguridad para documentos especificará grupos de empleados que podrán acceder a clases de documentos, o incluso se especificarán usuarios concretos para ciertos documentos importantes.

Las políticas de seguridad se hacen cumplir con la ayuda de los *mecanismos de seguridad*. Por ejemplo, un recepcionista controlará el acceso a un edificio, extenderá identificaciones a los visitantes acreditados, y esto se hará cumplir por un guardia de seguridad o mediante cerraduras electrónicas. El acceso a los documentos impresos se puede controlar mediante una custodia y una distribución rigurosa.

En el mundo electrónico, la distinción entre políticas de seguridad y los mecanismos también es importante; sin ella, sería difícil determinar si un sistema particular es seguro. Las políticas de seguridad son independientes de la tecnología empleada, así como el instalar una cerradura en una puerta no garantiza la seguridad del edificio a menos que haya una política de uso (por ejemplo, que la puerta esté cerrada cuando no esté vigilada). Los mecanismos de seguridad que describiremos no garantizan, por sí mismos, la seguridad de un sistema. En la Sección 7.1.2, se bosquejarán los requisitos de seguridad en distintos escenarios simplificados de comercio electrónico, ilustrando la necesidad de las políticas de seguridad en ese contexto. Como ejemplo de partida, considere la seguridad de un servidor de archivos en red cuya interfaz sea accesible a los clientes. Para garantizar que se mantiene el control de acceso a los archivos, deberá existir una política que asegure que todas las peticiones deban incluir una identidad de usuario autenticada.

	1965-75	1975-89	1990-99	Actualmente
Plataformas	Computadores multiusuario de tiempo compartido	Sistemas distribuidos basados en redes locales	Internet, servicios de área extensa	Internet + dispositivos móviles
Recursos compartidos	Memoria, archivos	Servicios locales (p. ej.: NFS), redes locales	e-mail, lugares web, comercio Internet	Objetos distribuidos, código móvil
Requisitos de seguridad	Identificación y autenticación de usuario	Protección de servicios	Seguridad robusta para transacciones comerciales	Control de acceso para objetos individuales, código móvil seguro
Entorno de gestión de la seguridad	Autoridad única, base de datos de autorización única (p. ej.: /etc/passwd)	Autoridad única, delegación, bases de datos de autorización replicadas (p. ej.: NIS)	Muchas autoridades, sin autoridad en la red, en general	Autoridades por actividad, grupos con responsabilidades compartidas

Figura 7.1. Contexto histórico: evolución de las necesidades de seguridad.

Cómo proporcionar mecanismos de seguridad para proteger datos (y otros recursos computacionales) y para asegurar las transacciones en la red es el tema de este capítulo. Describiremos los mecanismos que permiten hacer cumplir las políticas de seguridad en los sistemas distribuidos. Los mecanismos que veremos son suficientemente fuertes para resistir los ataques más determinados.

La distinción entre políticas de seguridad y mecanismos de seguridad es de utilidad cuando se diseñan sistemas seguros, pero no es fácil estar seguro de que cierto conjunto de mecanismos de seguridad implementan completamente las políticas de seguridad deseadas. En la Sección 2.3.3, presentamos un modelo de seguridad diseñado para ayudar en el análisis de las amenazas de seguridad potenciales en un sistema distribuido. Podemos resumir el modelo de seguridad del Capítulo 2 como sigue:

- Los procesos encapsulan recursos (tales como objetos de un lenguaje de programación de alto nivel y otros recursos definidos en el sistema) y acceden a comunicarse con los clientes a través de sus interfaces. Los principales (usuarios u otros procesos) pueden estar autorizados explícitamente para operar sobre los recursos. Los recursos deben estar protegidos contra accesos no autorizados.
- Los procesos interactúan en la red, que está siendo compartida por muchos usuarios. Los enemigos (atacantes) pueden acceder a la red. Así, podrán copiar o intentar leer cualquier mensaje que se transmita por este medio así como introducir mensajes arbitrarios, dirigidos hacia cualquier destino y simular que provienen de cualquier otro lugar de la red.

Este modelo de seguridad identifica las características de los sistemas de seguridad expuestos a ataques. En este capítulo detallaremos estos ataques y las técnicas de seguridad disponibles para derrotarlos.

◊ **La emergencia de la criptografía en el dominio público.** La criptografía proporciona la base para la mayoría de los sistemas de seguridad de los computadores. La criptografía tiene una larga y fascinante historia. La necesidad de comunicaciones militares seguras y la correspondiente necesidad del enemigo de interceptarlas y desencriptarlas ha fomentado la inversión de mucho esfuerzo intelectual, por parte de los mejores cerebros matemáticos de cada época. Los lectores interesados en explorar su historia encontrarán sobre el tema libros de absorbente lectura por David Kahn [1967, 1983, 1991] y Simon Singh [1999]. Whitfield Diffie, uno de los inventores de la criptografía de clave pública, ha relatado experiencias de primera mano sobre la historia y la política reciente [Diffie 1998, Diffie y Landau 1998] y también en el prefacio al libro de Schneier [1996].

Pero sólo en tiempos recientes la criptografía emerge de la trastienda en la que fue puesta por la clase dirigente de políticos y militares que solían controlar su desarrollo y su aplicación. Hoy en día es un tema de investigación abierto y con una comunidad de investigadores amplia y muy activa, donde los resultados se publican en muchos libros, revistas y conferencias. La publicación del libro de Schneier, *Applied Cryptography* [1996], fue la piedra de toque de la apertura de este campo del conocimiento. Fue el primer libro en que se publicaron muchos algoritmos importantes, incluyendo código fuente; una valiente aportación, dado que cuando apareció su primera edición en 1994 la situación legal de tal publicación no estaba nada clara. Schneier sigue siendo la referencia definitiva en la mayoría de los aspectos de la criptografía moderna. Menezes y otros [1997] también proporcionan un buen manual práctico con una interesante base teórica.

La reciente apertura es, en su mayor medida, resultado del importante crecimiento del interés en las aplicaciones no militares de la criptografía y los requisitos de seguridad de los sistemas de computadores distribuidos. Esto desembocó en la existencia, por primera vez, de una comunidad autosuficiente de criptógrafos aparte del entorno militar.

Irónicamente, esta apertura al público de la criptografía ha traído consigo un mayor avance de las técnicas criptográficas, su resistencia a los ataques criptoanalíticos y la comodidad con la que se despliegan las medidas criptográficas. La criptografía de clave pública es fruto de esta apertura. Un ejemplo más, el algoritmo de encriptación estándar DES fue inicialmente un secreto militar. Su

Alice	Primer participante
Bob	Segundo participante
Carol	Otro participante en los protocolos a tres o cuatro bandas
Dave	Participante en protocolos a cuatro bandas
Eve	Fisgón
Mallory	Atacante malevolente
Sara	Un servidor

Figura 7.2. Nombres familiares (del mundo anglosajón) para los protagonistas de los protocolos de seguridad.

eventual publicación y los esfuerzos exitosos para romperlo han traído consigo el desarrollo de algoritmos de encriptación de clave secreta mucho más resistentes.

Otro producto secundario útil ha sido el desarrollo de una terminología y aproximación común. Un ejemplo de esto último es la adopción de un conjunto de nombres familiares para los protagonistas (principales) involucrados en las transacciones que hay que asegurar. El uso de nombres familiares para los principales y los atacantes ayuda a aclarar y acercar al mundo las descripciones de los protocolos de seguridad y los potenciales ataques sobre ellos, lo que supone un paso importante hacia la identificación de sus debilidades. Los nombres mostrados en la Figura 7.2 se emplean ampliamente en literatura internacional sobre seguridad y aquí los emplearemos libremente. No hemos sido capaces de descubrir sus orígenes; la aparición más temprana de la que tenemos noticia está en el artículo original de criptografía de clave pública RSA [Rivest y otros 1978]. En Gordon [1984] podemos encontrar un divertido comentario sobre su utilización.

7.1.1. AMENAZAS Y ATAQUES

Algunos ataques son obvios; por ejemplo, en la mayoría de los tipos de redes locales es fácil construir y lanzar un programa sobre un computador conectado para que obtenga copias de los mensajes transmitidos entre otros computadores. Otras amenazas son más sutiles; si los clientes fallan en autenticar los servidores, un programa podría situarse a sí mismo en lugar del auténtico servidor de archivos y así obtener copias de información confidencial que los clientes, inconscientemente, envián para su almacenamiento.

Además del peligro de pérdida o daño de información o de recursos por violaciones directas, también pueden aparecer reclamaciones fraudulentas contra el propietario de un sistema que no sea demostrablemente seguro. Para evitar tales reclamaciones, el propietario debe estar en situación de desacreditar la reclamación mostrando que el sistema es seguro contra tales violaciones, o también produciendo un registro histórico de todas las transacciones durante el período en cuestión. Un ejemplo habitual es el problema de *débito fantasma* en los dispensadores automáticos de dinero en efectivo (cajeros automáticos). La mejor respuesta que un banco puede aportar a tal reclamación es proporcionar un registro de la transacción firmado digitalmente por el titular de la cuenta, de manera que no pueda ser falsificado por un tercero.

La principal meta de la seguridad es restringir el acceso a la información y los recursos de modo que sólo tengan acceso aquellos principales autorizados. Las amenazas de seguridad caen en tres amplias clases:

Fuga — la adquisición de información por receptores no autorizados.

Alteración — la modificación no autorizada de información.

Vandalismo — interferencia con el modo de operación adecuado de un sistema, sin ganancia alguna para el perpetrador.

Los ataques en los sistemas distribuidos dependen de la obtención de acceso a los canales de comunicación existentes o del establecimiento de canales nuevos que se suplantan a las conexiones. (Empleamos el término *canal* para hacer alusión a cualquier mecanismo de comunicación entre procesos.) Los métodos de ataque pueden clasificarse más aún en función del modo en que se abusa del canal:

Fisgar — obtener copias de mensajes sin autoridad.

Suplantar — enviar o recibir mensajes utilizando la identidad de otro principal sin su autorización.

Alterar mensajes — interceptar mensajes y alterar sus contenidos antes de pasarlos al receptor pretendido. El *ataque del ‘hombre entre medias’* es una forma de *alteración de mensaje* en la cual un atacante intercepta el primer mensaje en un intercambio de claves de encriptación (al establecer un canal seguro). El atacante sustituye claves comprometidas que le permitirán desencriptar los subsiguientes mensajes antes de encriptarlos de nuevo, con las claves correctas, y dejarlos pasar hasta su destino.

Reenviar — almacenar mensajes interceptados y enviarlos más tarde. Este ataque pudiera ser efectivo incluso con mensajes encriptados autenticados.

Denegación de servicio — desbordar un canal u otro recurso con mensajes con el fin de impedir que otros accedan a él.

En teoría, éstos son los peligros, pero, ¿cómo se llevan a la práctica estos ataques? Los ataques victoriosos dependen del descubrimiento de agujeros en la seguridad de los sistemas. Desgraciadamente, estos problemas son demasiado comunes en los sistemas de hoy en día, y no son necesariamente complicados. Cheswick y Bellovin [1994] identificaron cuarenta y dos debilidades que pudieran poner en serios riesgos para sistemas y componentes de Internet ampliamente usados. Empezando desde la adivinación de claves de acceso hasta ataques en los programas que implementan el protocolo de tiempo de red, o manejan la transmisión de correo. Algunos de ellos han desembocado en famosos ataques [Stoll 1988, Spafford 1989], y muchos de ellos han sido explotados con fines lúdicos o criminales.

Cuando se diseñó Internet y los sistemas conectados a ella, la seguridad no era una prioridad. Los diseñadores, probablemente, no tenían un concepto adecuado de la escala en que crecería Internet, aparte de que el diseño básico de sistemas como UNIX es previo al advenimiento de las redes de computadores. Como ya veremos, la incorporación de medidas de seguridad requiere ser cuidadosos con la etapa de diseño, y se pretende que el contenido de este capítulo proporcione las bases de tal idea.

Nos hemos concentrado en los ataques a los sistemas distribuidos que nacen de la exposición de sus canales de comunicación y sus interfaces. Para muchos sistemas, éstos son los únicos ataques que debemos considerar y que no se derivan de los errores humanos; los mecanismos de seguridad no pueden protegernos contra una clave de acceso mal elegida o mal custodiada. Pero para sistemas que incluyan programas móviles y sistemas cuya seguridad sea particularmente sensible a la fuga de información, hay aún más ataques.

◇ **Ataques desde código móvil.** Varios lenguajes de programación, recientemente desarrollados, han sido diseñados para permitir que la descarga de programas desde servidores remotos y así lanzar procesos que se ejecutan localmente. En este caso, las interfaces internas y los objetos del interior de un proceso en ejecución pueden quedar expuestos a un ataque por código móvil.

Java es el lenguaje de este tipo más conocido, y los diseñadores pusieron considerable atención en el diseño y la construcción del lenguaje y los mecanismos para la descarga remota, en un esfuerzo para restringir el riesgo (el modelo de *caja de arena* —sandbox— de protección contra código móvil).

La Máquina Virtual Java (JVM, *Java Virtual Machine*) se diseñó con el código móvil en mente. A cada aplicación se le da su propio entorno de ejecución. Cada entorno tiene un gestor de

seguridad que determina qué recursos están disponibles para la aplicación. Por ejemplo, el gestor

240 Sistemas distribuidos

seguridad que determina qué recursos están disponibles para la aplicación. Por ejemplo, el gestor

Email: aunque los sistemas originales de correo electrónico no incluyeran soporte de seguridad, hay muchos usos del correo en que los contenidos de los mensajes deben mantenerse confidenciales (por ejemplo, al enviar un número de tarjeta de crédito) o los contenidos y el emisor del mensaje deben estar autenticados (por ejemplo cuando se remite una puja a una subasta por email). La seguridad criptográfica basada en las técnicas que se describen en este capítulo se incluye actualmente en muchos clientes de correo.

Compra de bienes y servicios: tales transacciones son, hoy en día, algo usual. Los compradores seleccionan bienes y pagan por ellos empleando el Web, más tarde le son enviados por el mecanismo de reparto más apropiado. El software y otros productos digitales (como grabaciones y vídeo) se pueden enviar mediante el procedimiento de descarga desde Internet. Los bienes tangibles como libros, discos compactos y casi cualquier otro tipo de producto puede venderse desde comercios en Internet; éstos se envían mediante un servicio de reparto.

Transacciones bancarias: los bancos electrónicos de hoy en día ofrecen virtualmente a los usuarios todos los servicios que proporcionan los bancos convencionales. Éstos proporcionan la comprobación de los cargos y balance de cuentas, transferencias de efectivo entre cuentas, el establecimiento de cargos regulares automáticos y demás desde la cuenta.

Micro-transacciones: Internet se presta a proporcionar pequeñas cantidades de información y otros servicios hacia sus clientes. Por ejemplo, el acceso a la mayoría de las páginas web no exige ningún pago, pero el desarrollo del Web como un medio de publicación de alta calidad seguramente depende de hasta qué punto los proveedores de información puedan obtener beneficio de los clientes de esta información. El uso de Internet para voz y videoconferencia nos da otro ejemplo de servicio que se proporciona sólo cuando se anticipa el pago por los usuarios finales. El precio de tales servicios puede suponer sólo una fracción de un céntimo, y el pago de los gastos generales deberá ser correspondientemente bajo. En general los esquemas de pago basados en transferencia bancaria y servicio de tarjeta de crédito para cada transacción no son los más adecuados.

Las transacciones como éstas sólo se pueden realizar de modo seguro cuando se encuentran protegidas contra la revelación de los códigos de crédito (números de tarjeta) durante la transmisión, y contra un vendedor fraudulento que obtenga un pago sin intención de proveer bien alguno. Los vendedores deben recibir el pago antes de enviar los bienes, y para los productos que pueden descargarse deberá asegurarse de que sólo el comprador recibe los datos de forma utilizable. La protección necesaria debe obtenerse a un coste razonable comparado con el valor de la transacción.

Una política de seguridad sensata para vendedores y compradores de Internet exige los siguientes requisitos para asegurar las compras web:

1. Autenticación del vendedor al comprador, de modo que el comprador pueda confiar en que está en contacto con un servidor operado por el vendedor con el que se supone que tiene que tratar.
2. Mantenimiento del número de tarjeta de crédito y otros detalles del comprador bajo secreto, para evitar que caigan en manos de terceras partes y asegurar que se transmiten de forma inalterada del comprador al vendedor.
3. Si los bienes se encuentran en una forma útil para su descarga, asegurar que su contenido llega al comprador sin alteración y sin ser desvelados a terceras partes.

La identidad del comprador no suele ser un requisito del vendedor (excepto por necesidades de envío de los bienes en el caso en que no puedan descargarse electrónicamente). El vendedor deseará comprobar que el comprador tiene los fondos necesarios para pagar la compra, aunque esto se realiza usualmente requiriendo el pago al banco del comprador antes de enviar los bienes.

Las necesidades de seguridad de las transacciones bancarias que emplean una red abierta son similares a las de las transacciones de compra, con el titular de la cuenta y el banco como vendedor, aunque aquí ciertamente *hay* necesidad de:

4. Autenticar la identidad del titular de la cuenta hacia el banco antes de darle acceso a su cuenta.

Observe que en esta situación es importante para el banco estar seguro de que el titular de la cuenta no pueda negar haber participado en una transacción. A este requisito se le da el nombre de *no repudio*.

Además de los requisitos anteriores, dictados por políticas de seguridad, hay otros requisitos de sistema. Éstos surgen de la gran escala de Internet, que hace impracticable el requerir que los compradores inicien algún tipo de relación especial con los vendedores (por ejemplo, registrando claves de encriptación para un posterior uso, etc.). Debiera ser posible para un comprador completar una transacción segura con un vendedor incluso si no ha habido contacto previo entre el comprador y el vendedor, y sin la participación de una tercera parte. Técnicas tales como el uso de «cookies» (registros de transacciones previas almacenadas en el host del cliente del usuario) tienen ciertas debilidades obvias; los dispositivos de sobremesa y los host móviles suelen estar situados en entornos físicos inseguros.

A causa de la importancia de la seguridad para el comercio en Internet y el rápido crecimiento de éste, hemos elegido, para ilustrar el uso de las técnicas de seguridad criptográfica que se describirán en la Sección 7.6, el protocolo de seguridad estándar *de facto* empleado en la mayoría del comercio electrónico (*Secure Sockets Layer*, SSL), y Millicent, un protocolo diseñado específicamente para micro-transacciones.

El comercio en Internet es una aplicación importante de las técnicas de seguridad, pero no es ciertamente la única. Es una necesidad cuando quiera que dos computadores sean utilizados por individuos u organizaciones para almacenar y comunicar información importante. La utilización de correo electrónico encriptado para la comunicación privada entre individuos es un caso concreto que ha sido objeto de considerable discusión política. Nos referiremos a este debate en la Sección 7.5.2.

7.1.3. DISEÑO DE SISTEMAS SEGUROS

En los últimos años se han dado pasos inmensos en el desarrollo y la aplicación de las técnicas criptográficas, aunque el diseño de sistemas seguros siga siendo una tarea inherentemente difícil. En el corazón de este dilema está el hecho de que el objetivo del diseñador es excluir *todos* los posibles ataques y agujeros. La situación es análoga a la del programador cuyo principal objetivo es excluir todos los errores de su programa. En ningún caso existe un método concreto para asegurar las metas durante el diseño. Cada uno diseña con los mejores estándares disponibles y aplica un análisis informal y comprobaciones. Una vez que un diseño está completo, una opción es la validación formal. El trabajo en la validación formal de protocolos de seguridad ha producido algunos resultados importantes [Lampson y otros 1992, Schneider 1996, Abadi y Gordon 1999]. Una descripción de uno de los primeros pasos en esta dirección, la lógica de autenticación BAN [Burrows y otros 1990] y su aplicación puede encontrarse en www.cdk3.net/security.

La seguridad trata de evitar los desastres y minimizar los contratiempos. Cuando se diseña para seguridad es necesario pensar siempre en lo peor. El recuadro de las páginas 243 y 244 muestra un conjunto de premisas y guías de diseño útiles. Estas premisas penetran las ideas subyacentes a cada técnica que se describe en este capítulo.

Para demostrar la validez de los mecanismos de seguridad empleados en un sistema, los diseñadores deben construir, en primer lugar, una lista de amenazas (métodos por los cuales se puede

violar una política de seguridad) y probar que cada una de ellas se puede prevenir mediante los mecanismos empleados. Esta demostración puede tomar la forma de un argumento informal, o mejor aún, de una demostración lógica.

Es lógico pensar que ninguna lista de amenazas sea completamente exhaustiva, de modo que en el caso de aplicaciones sensibles a la seguridad deberán emplearse métodos de auditoría. Su aplicación es directamente implementable bajo la forma de un histórico de aquellas acciones del sistema sensibles a la seguridad, guardando siempre los detalles relativos a los usuarios, y la autoridad de que disponen, que realizan tales acciones.

Un histórico de seguridad contendrá una secuencia de registros fechados de las acciones de los usuarios. Como mínimo, los registros incluirán la identidad del principal, la operación realizada (por ejemplo, borrar un archivo, actualizar un registro de contabilidad), la identidad del objeto sobre el que se opera y la fecha y hora. Donde se sospeche que pudiera haber violaciones concretas, los registros pueden contener información más detallada para incluir la utilización de los recursos físicos (ancho de banda de red, periféricos), o disparar un procedimiento histórico especial de operaciones sobre objetos concretos. Posteriormente se puede efectuar un análisis de carácter estadístico o bien basado en búsquedas. Incluso aunque no se sospeche de alguna violación, las técnicas estadísticas permitirán comparar registros a lo largo del tiempo para descubrir tendencias o cualquier suceso inusual.

El diseño de sistemas seguros es un ejercicio de balance entre los costes y las amenazas. El abanico de técnicas útiles para desplegar procesos de protección y asegurar la comunicación entre procesos es suficientemente potente como para resistir cualquier ataque, aunque su utilización trae consigo ciertos costes e inconvenientes:

- Su uso acarrea un coste (en esfuerzo computacional y uso de la red). Los costes deben compensar la amenaza.
- Unas especificaciones de medidas de seguridad inapropiadas podrían impedir a los usuarios legítimos el realizar ciertas acciones necesarias.

Tales inconvenientes son difíciles de identificar sin comprometer la seguridad y puede parecer que entran en conflicto con el consejo del primer párrafo de esta subsección, pero podemos cuantificar la fuerza de las técnicas de seguridad y seleccionarlas basándonos en una estimación del coste de un ataque. El coste relativamente bajo de las técnicas empleadas en el protocolo Millicent para pequeñas transacciones comerciales, descrito en la Sección 7.6.4, proporciona un ejemplo de ello.

Premisas del peor caso posible y guías de diseño

Las interfaces están desprotegidas: Los sistemas distribuidos se componen de procesos que ofrecen servicios que comparten información. Sus interfaces de comunicación son necesariamente abiertas (para permitir el acceso a nuevos clientes); un atacante puede enviar un mensaje a cualquier interfaz.

Las redes son inseguras: Por ejemplo, puede falsificarse la fuente de cualquier mensaje; pudiera parecer que ciertos mensajes provienen de Alice cuando en realidad fueron generados por Mallory. Se puede suplantar la dirección de cualquier host; Mallory puede conectarse a la red con la misma dirección de Alice y recibir copias de mensajes pretendidamente enviados para ésta.

Límitese el tiempo de vida y el alcance de cada secreto: Cuando se genera por primera vez una clave secreta podemos confiar en que no se encuentra comprometida. Cuando más la usemos y más ampliamente se conozca, mayor será el riesgo. La utilización de secretos como las contraseñas y las claves secretas compartidas debería tener una caducidad, y un alcance de uso restringido.

Los algoritmos y el código de los programas están disponibles para los atacantes: Cuanto mayor y más ampliamente se difunde un secreto, mayor es el riesgo de que se descubra. Los algoritmos de encriptación secreta son totalmente inadecuados para los entornos de red de gran escala de hoy en día. La mejor práctica es publicar los algoritmos empleados para la encriptación y la autenticación, confiándose solamente en el secreto de las claves criptográficas. Abriendo los algoritmos al público el escrutinio de terceras partes nos ayuda a garantizar el que éstos sean suficientemente fuertes.

Los atacantes tienen acceso a suficientes recursos: El coste de la potencia de cálculo decrece con rapidez. Deberíamos presuponer que los atacantes tendrán acceso a los computadores más grandes y más potentes que se puedan proyectar durante la vida útil de un sistema, y aun así añadir unos cuantos órdenes de magnitud más para contemplar desarrollos inesperados.

Minimícese la base de confianza: Las porciones de un sistema responsable de la implementación de su seguridad, y *todos los componentes hardware y software sobre los que descansen*, deben ser confiables; a esto se le denomina *base de computación confiable*. Cualquier defecto o error de programación en esta base de confianza puede producir debilidad en el sistema, de modo que debiéramos tender a minimizar su tamaño. Por ejemplo, los programas de aplicación de usuario no debieran ser dignos de confianza para proteger los datos de sus usuarios.

7.2. VISION GENERAL DE LAS TÉCNICAS DE SEGURIDAD

El objetivo de esta sección es presentar al lector algunas de las técnicas y mecanismos más importantes para asegurar sistemas y aplicaciones distribuidas. Aquí se las describe informalmente, reservando otra descripción más rigurosa para las Secciones 7.3 y 7.4. Emplearemos los nombres ya familiares para los principales que se presentaron en la Figura 7.2 y la notación para los elementos encriptados y firmados que se muestra en la Figura 7.3.

7.2.1. CRIPTOGRAFÍA

La encriptación es el proceso de codificación de un mensaje de forma que queden ocultos sus contenidos. La criptografía moderna incluye algunos algoritmos seguros de encriptación y desencriptación de mensajes. Todos ellos se basan en el uso de ciertos secretos llamados *claves*. Una clave criptográfica es un parámetro empleado en un algoritmo de encriptación de forma que la encriptación no sea reversible sin el conocimiento de una clave.

Hay dos clases principales de algoritmos de encriptación de uso general. La primera emplea *claves secretas compartidas*; el emisor y el receptor deben compartir el conocimiento de una clave y ésta no debe ser revelada a ningún otro. La segunda clase de algoritmos de encriptación emplea

K_A	Clave secreta de Alice
K_B	Clave secreta de Bob
K_{AB}	Clave secreta compartida por Alice y Bob
$K_{A\text{priv}}$	Clave privada de Alice (sólo conocida por Alice)
$K_{A\text{pub}}$	Clave pública de Alice (publicada por Alice para lectura de cualquiera)
$\{M\}_K$	Mensaje M encriptado con la clave K
$[M]_K$	Mensaje M firmado con la clave K

Figura 7.3. Notación criptográfica.

pares de claves pública/privada; el emisor de un mensaje emplea una *clave pública*, difundida previamente por el receptor, para encriptar el mensaje. El receptor emplea la *clave privada* correspondiente para desencriptar el mensaje. A pesar de que una multitud de principales pudiera examinar la clave pública, solamente el receptor puede desencriptar el mensaje, gracias a su clave privada.

Ambas clases de algoritmo de encriptación son extremadamente útiles y ampliamente utilizadas para la construcción de sistemas distribuidos seguros. Los algoritmos de encriptación de clave pública requieren usualmente de 100 a 1.000 veces más potencia de procesamiento que los algoritmos de clave secreta, aunque hay situaciones en las que su conveniencia compensa esta desventaja.

7.2.2. USOS DE LA CRIPTOGRAFÍA

La criptografía juega tres papeles principales en la implementación de los sistemas seguros. Aquí hacemos un bosquejo de ellas a través de escenarios simplificados. En las secciones posteriores de este capítulo, las describimos con mayor detalle junto a otros protocolos, desglosando también algunos problemas aún no resueltos que aquí solamente se reseñan.

En todos nuestros escenarios que veremos más adelante, podemos presuponer que Alice, Bob y cualquier otro participante se han puesto previamente de acuerdo sobre los algoritmos de encriptación que desean utilizar y además tienen implementaciones de ellos. También partimos de que cualquier clave de que dispongan, ya sea secreta o privada, puede almacenarse de forma segura para prevenir que los atacantes las obtengan.

◊ **Secreto e integridad.** La criptografía se emplea para mantener el secreto y la integridad de la información dondequiera que pueda estar expuesta a ataques potenciales, por ejemplo durante la transmisión a través de redes vulnerables a la indiscreción y a la manipulación de mensajes. Este uso de la criptografía se corresponde con su papel tradicional en las actividades militares y de inteligencia. Se explota el hecho de que un mensaje encriptado con una clave de encriptación particular sólo puede ser desencriptado por un receptor que conozca la correspondiente clave de desencriptación. Así se conseguirá el secreto del mensaje encriptado en la medida de que la clave de desencriptado no esté *comprometida* (desvelada a los que no intervienen en la comunicación) y a condición de que el algoritmo de encriptación sea suficientemente fuerte como para derrotar cualquier posible intento de romperlo. La encriptación también preserva la integridad de la información encriptada, supuesto que se incluya algo de información redundante, de la misma forma en que se incluyen y comprueban las sumas de chequeo (*checksums*).

Escenario 1. Comunicación secreta con clave secreta compartida: Alice desea enviar cierta información a Bob de modo secreto. Alice y Bob comparten una clave secreta K_{AB} .

1. Alice emplea K_{AB} y acuerda una función de encriptación $E(K_{AB}, M)$ para encriptar y enviar cualquier cantidad de mensajes $\{M_i\}_{K_{AB}}$ para Bob. Alice puede continuar utilizando K_{AB} tanto como sea seguro suponer que K_{AB} no ha sido comprometida.
2. Bob lee los mensajes encriptados con la correspondiente función de desencriptado $D(K_{AB}, M)$.

Bob podrá ahora leer el mensaje original M . Si el mensaje tiene sentido cuando es desencriptado por Bob, o mejor, si incluye algún valor acordado entre Alice y Bob, tal como una suma de comprobación del mensaje, entonces Bob conoce con certeza que el mensaje proviene de Alice y no ha sido sabotead. Pero aún hay otros problemas:

Problema 1: ¿Cómo puede enviar Alice a Bob una clave compartida K_{AB} de modo seguro?

Problema 2: ¿Cómo sabe Bob que cualquier $\{M_i\}$ no es nunca copia de un anterior mensaje encriptado de Alice, y que fue capturado por Mallory para ser reenviado más tarde? Mallory no necesita tener la clave K_{AB} para llevar a cabo este ataque; no hay más que hacer una simple

copia del patrón de bits que representa el mensaje y enviarlo a Bob más tarde. Por ejemplo, si el mensaje es una solicitud para hacer cierto pago a alguien, Mallory podría engañar a Bob para que pagara dos veces.

Más adelante, en este capítulo, veremos cómo se pueden resolver estos problemas.

◊ **Autenticación.** La criptografía se emplea como base para los mecanismos para autenticar la comunicación entre pares de principales. Un principal que desencripta un mensaje con éxito empleando una clave particular puede presuponer que el mensaje es auténtico si contiene una suma de chequeo correcta o, si se emplea el modo de encriptación de encadenamiento de bloques, que se describe en la Sección 7.3, cualquier otro valor esperado. Éstos podrán inferir que el emisor del mensaje estaba en posesión de la clave de encriptación correspondiente y entonces deducir la identidad del emisor, siempre que la clave sólo sea conocida por las dos partes. En resumen, si las claves se mantienen en secreto, una desencriptación con éxito da fe de que el mensaje desencriptado proviene de un emisor concreto.

Escenario 2. Comunicación autenticada con un servidor: Alice desea acceder a los archivos guardados por Bob, en un servidor de archivos de la red local de la organización donde ella trabaja. Sara es un servidor de autenticación administrado de modo seguro. Sara administra usuarios con su clave de acceso y almacena las claves secretas actuales de todos los principales en el sistema que sirve (generadas aplicando alguna transformación a la clave de acceso del usuario). Por ejemplo, conoce la clave K_A de Alice y la clave K_B de Bob. En nuestro escenario hacemos uso de *tickets*. Un ticket es un elemento encriptado emitido por un servidor de autenticación, que contiene la identidad del principal a quien se dirige y una clave compartida que ha sido generada por la actual sesión de comunicación.

1. Alice envía un mensaje (no encriptado) a Sara indicando su identidad y reclamando un ticket para acceder a Bob.
2. Sara responde a Alice con un mensaje encriptado con K_A que consta de un ticket (para enviar a Bob con cada petición de acceso a archivos) encriptado con K_B y una nueva clave secreta K_{AB} para su uso en la comunicación con Bob. Así la respuesta que recibe Alice se parece a ésta: $\{\{Ticket\}_{K_B}, K_{AB}\}_{K_A}$.
3. Alice desencripta la respuesta utilizando K_A (que genera con su palabra de acceso empleando la misma transformación; la palabra clave no se transmite en la red y una vez que se ha empleado, se borra del almacenamiento local para evitar ponerla en peligro). Si Alice tiene la clave correcta derivada de la palabra de acceso, K_A , obtiene un ticket válido para utilizar el servicio de Bob, más una nueva clave de encriptación para comunicarse con Bob. Alice no puede desencriptar o manipular el ticket, porque está encriptado con K_B . Si el receptor no es Alice entonces no conocerá la clave de Alice, de modo que no será capaz de desencriptar el mensaje.
4. Alice envía el ticket a Bob junto con su identidad y una solicitud R para acceder a un archivo: $\{Ticket\}_{K_B}, Alice, R$.
5. El ticket, originalmente creado por Sara, es en realidad $\{K_{AB}, Alice\}_{K_B}$. Bob desencripta el ticket empleando su clave K_B . Así Bob obtiene la identidad auténtica de Alice (basada en el conocimiento compartido entre Alice y Sara acerca de la clave de Alice) y una nueva clave secreta compartida K_{AB} que le permite interaccionar con Alice. (A ésta se le denomina *clave de sesión* porque puede utilizarse de modo seguro entre Alice y Bob para una serie de interacciones.)

Este escenario es una versión simplificada del protocolo de autenticación desarrollado originalmente por Roger Needham y Michael Schroeder [1978] y utilizado posteriormente en el sistema Kerberos desarrollado y utilizado en el MIT [Steiner y otros, 1988], y que se describirá en la Sección 7.6.2. En nuestra descripción simplificada de este protocolo no existe protección contra la

repetición de mensajes de autenticación antiguos. Ésta y alguna otra debilidad se tratan en nuestra descripción del protocolo Needham-Schroeder completo, que se describirá en la Sección 7.6.1.

El protocolo de autenticación que hemos descrito depende del conocimiento previo por el servidor de autenticación Sara de las claves de Alice y Bob, K_A y K_B . Esto es realizable en una organización única donde Sara emplea un computador físicamente seguro y está administrado por un principal fiable que genera valores iniciales para las claves y las transmite a los usuarios mediante un canal seguro independiente. Pero este esquema no es apropiado para el comercio electrónico u otras aplicaciones de área extensa, donde el emplear un canal independiente es extremadamente inconveniente y los requisitos para una tercera parte digna de crédito es poco realista. La criptografía de clave pública nos rescata de este dilema.

Utilidad de los desafíos: Un aspecto importante del avance de 1978 de Needham y Schroeder fue el darse cuenta de que no hay por qué enviar una contraseña de usuario a un servicio de autenticación (y ser expuesta a la red) cada vez que se auténtica. En su lugar, presentaron el concepto de *desafío* criptográfico. Como se puede ver en el paso 2, donde el servidor Sara emite un ticket a Alice *encriptado en la clave secreta de Alice*, K_A . Esto conforma un desafío porque Alice no podrá utilizar el ticket a menos que pueda desencriptarlo, y sólo puede hacerlo si puede conseguir K_A , que se deriva de la clave de acceso de Alice. Un impostor que afirmara ser Alice sería vencido en este momento.

Escenario 3. Comunicación autenticada con claves públicas: Supongamos que Bob ha generado un par de claves pública/privada, así el siguiente diálogo les permite a Bob y Alice establecer una clave secreta compartida K_{AB} :

1. Alice accede a un servicio de distribución de claves para obtener un *certificado de clave pública*, dada la clave pública de Bob. Se denomina certificado porque viene firmado por una autoridad en quien se puede confiar; una persona u organización de la que se sabe bien que es de fiar. Tras comprobar la firma, ella lee la clave pública de Bob K_{Bpub} a partir del certificado. (Discutiremos la construcción y utilización de los certificados de clave pública en la Sección 7.2.3.)
2. Alice crea una nueva clave compartida K_{AB} y la encripta usando K_{Bpub} con un algoritmo de clave pública. Entonces envía el resultado a Bob, junto con un nombre clave que identifica de modo único un par de claves pública/privada (dado que Bob puede tener varias). Así Alice envía a Bob: *nombreClave*, $\{K_{AB}\}_{K_{Bpub}}$.
3. Bob selecciona la clave privada correspondiente K_{Bpriv} de su almacén de claves privadas y la emplea para desencriptar K_{AB} . Observe que el mensaje de Alice a Bob pudiera haber sido corrompido o saboteados mientras estaba en tránsito. La consecuencia seguramente sería que Bob y Alice no compartirían la misma clave K_{AB} . Si esto fuera un problema, podría soslayarse añadiendo un valor acordado o un texto al mensaje, tales como los nombres o direcciones de correo de Bob y Alice, con lo cual Bob podría comprobarlo tras desencriptarlo.

El escenario anterior muestra el uso de la criptografía de clave privada para distribuir una clave compartida. Esta técnica se conoce como *protocolo criptográfico híbrido* y se utiliza ampliamente, dado que explota características útiles de ambos algoritmos de encriptación, de clave pública y de clave privada.

Problema: este intercambio de claves es vulnerable a ataque del *hombre entre medias*. Mallory podría interceptar la petición inicial de Alice al servicio de distribución de claves buscando el certificado de clave pública de Bob y enviar una respuesta que contenga su propia clave pública. Él puede, en ese momento, interceptar todos los mensajes subsiguientes. En nuestra descripción de arriba, se impide este ataque obligando que el certificado de Bob esté firmado por una autoridad bien conocida. Para protegerse de este ataque, Alice debe asegurarse de que el certifi-



1. <i>Tipo de certificado:</i>	Clave pública
2. <i>Nombre:</i>	Banco de Bob
3. <i>Cuenta:</i>	$K_{B\text{pub}}$
4. <i>Autoridad certificadora:</i>	Fred, la Federación de Banqueros
5. <i>Firma:</i>	$\{\text{Resumen}(\text{campo } 2 + \text{campo } 3)\}_{K_{F\text{priv}}}$

Figura 7.5. Certificado de clave pública para el Banco de Bob.

para certificar que tiene una cuenta con el Banco de Bob. El certificado se firma con la clave privada de Bob $K_{B\text{priv}}$. Un vendedor Carol puede aceptar tal certificado para cargar compras a la cuenta de Alice siempre que ella pueda validar la firma del campo 5. Para ello, Carol necesita la clave pública de Bob y también estar segura de su autenticidad para estar a cubierto de la posibilidad de que Alice pueda firmar un certificado falso asociando su nombre con la cuenta de algún otro. Para cometer este ataque, Alice simplemente generaría un nuevo par de claves $K_{B\text{pub}}, K_{B\text{priv}}$ y los utilizaría para generar un certificado falso pretendiendo que proviene del Banco de Bob.

Lo que Carol necesita es un certificado donde figure la clave pública de Bob, firmado por una autoridad bien conocida y de fiar. Supongamos que Fred representa a la Federación de Banqueros, uno de cuyos papeles es certificar las claves públicas de los bancos. Entonces Fred emitiría un *certificado de clave pública* para Bob (véase la Figura 7.5).

Como es lógico, este certificado depende de la autenticidad de la clave pública de Fred $K_{F\text{pub}}$, de modo que tenemos un problema recursivo de autenticidad; Carol sólo puede fiarse de este certificado si está segura de que conoce la auténtica clave pública de Fred $K_{F\text{pub}}$. Podemos romper esta recursión asegurándonos que Carol obtiene $K_{F\text{pub}}$ mediante alguna forma en que ella confíe; esta clave podría haberse entregado en mano por un representante de Fred o haber recibido una copia firmada por éste de alguien en quien ella confíe y que le asegure que lo recibió directamente de Fred. Nuestro ejemplo muestra una cadena de certificados; en este caso, una con dos enlaces.

Ya hemos hecho alusión a uno de los problemas que aparecen con los certificados: la dificultad al elegir una autoridad fiable de donde pueda arrancar una cadena de autenticaciones. La confianza raramente es absoluta, de modo que la elección de una autoridad dependerá del objetivo para el que se necesite el certificado. Otros problemas nacen del riesgo de comprometer (desvelar) las claves privadas y de la longitud permisible de una cadena de certificación; cuanto más larga, mayor es el riesgo de un eslabón débil.

Supuesto que se haya tenido cuidado con estas cuestiones, ocurre que las cadenas de certificados son una piedra angular importante para el comercio electrónico y de otro tipo de transacciones del mundo real. Ayudan a abordar el problema de la escala: hay seis mil millones de personas en el mundo, de modo que cómo podemos construir un entorno electrónico en el que podamos establecer las credenciales de cualquiera de ellas.

Los certificados pueden emplearse para establecer la autenticidad de muchos tipos de enunciados. Por ejemplo, los miembros de un grupo o asociación desean mantener una lista de correo abierta tan sólo para los miembros del grupo. Una buena forma que el administrador de socios (Bob) pueda llevarlo a cabo es emitir un certificado de miembro ($S, Bob, \{\text{Resumen}(S)\}_{K_{B\text{priv}}}$) para cada miembro, donde S es un enunciado de la forma Alice es un miembro de la Sociedad de Amigos y $K_{B\text{priv}}$ es la clave privada de Bob. Un miembro (Alice) que quiera pertenecer a la lista de correo de la Sociedad de Amigos tendrá que aportar una copia de su certificado al sistema de administración de la lista, que comprobará el certificado antes de permitir que Alice se una a la lista.

Para que los certificados sean útiles se requieren dos cosas:

- Un formato estándar y una representación para ellos de modo que los emisores de certificados y los usuarios de certificados puedan construirlos e interpretarlos.

- Un acuerdo sobre la forma en que se construyen las cadenas de certificados, y en particular

- Un acuerdo sobre la forma en que se construyen las cadenas de certificados, y en particular la noción de autoridad fiable.

Volveremos a estos requisitos en la Sección 7.4.4.

▲ veces se requiere revocar un certificado por ejemplo. Alice podría interrumpir su asociación

Habilitaciones (capabilities): Cada proceso, según el dominio en que esté ubicado, aloja un conjunto de habilitaciones. Una habilitación es un valor binario que actúa como una clave de acceso permitiendo al que lo posee acceder a ciertas operaciones sobre un recurso especificado. Para su uso en los sistemas distribuidos, donde las habilitaciones deben ser infalsificables, toman la forma de:

<i>Identificador del recurso</i>	Un identificador único para el recurso objeto
<i>Operaciones</i>	Una lista de operaciones permitidas sobre el recurso
<i>Código de autenticación</i>	Una firma digital que hace la habilitación infalsificable

Los servicios sólo proporcionan habilitaciones a los clientes cuando se les ha autenticado como pertenecientes al dominio de protección pretendido. La lista de operaciones en cada habilitación es un subconjunto de operaciones definidas para el recurso objetivo y siempre se codifica como un mapa de bits. Para las diferentes combinaciones de derechos de acceso al mismo recurso se emplean habilitaciones diferentes.

Cuando se emplean habilitaciones, las peticiones de los clientes tienen la forma $<op, idUsuario, habilitación>$. Esto es, se incluye en ellas una habilitación para acceder al recurso en lugar de un simple identificador, lo que da al servidor una prueba inmediata de que el cliente está autorizado a acceder al recurso identificado por la habilitación con las operaciones especificadas por ésta. Una comprobación de control de acceso sobre una petición acompañada por una habilitación involucra solo la validación de la habilitación y una comprobación de que la operación solicitada está en el conjunto permitido por la habilitación. Esta característica es la mayor ventaja de las habilitaciones, que constituyen una clave de acceso autocontenido, tal y como una llave física para una cerradura es una clave para acceder al edificio protegido por la cerradura.

Las habilitaciones comparten dos inconvenientes de las llaves de una cerradura física:

Robo de llaves: cualquiera que posea la llave de un edificio puede utilizarla para tener acceso a él, sea o no un poseedor autorizado de la llave; ésta pudiera haber sido robada u obtenida de alguna forma fraudulenta.

El problema de la revocación: la cualificación para poseer una llave cambia con el tiempo. Por ejemplo, el poseedor pudiera dejar de ser un empleado o el propietario del edificio, pero podría seguir reteniendo la llave, o una copia de ella, y utilizarla de manera no autorizada.

Las únicas soluciones para estos problemas para las llaves físicas son (1) encerrar en la cárcel al poseedor ilícito de la llave (no siempre posible en el intervalo de tiempo que pudiera prevenir que efectuara algún daño), o (2) cambiar la cerradura y reexpedir llaves a todos los portadores de la llave (una operación torpe y onerosa).

Quedan claros los problemas análogos para las habilitaciones:

- Las habilitaciones podrían, debido a un descuido o como resultado de un ataque a la confidencialidad, caer en manos de otros principales que no son para quienes fueron emitidas. Si ocurre esto, los servidores quedan a merced de ser utilizados ilícitamente.
- Resulta difícil cancelar las habilitaciones. El estado del portador pudiera cambiar y sus derechos de acceso debieran cambiar conforme a ello, pero aún pueden utilizar la habilitación antigua.

Se han propuesto y desarrollado soluciones a ambos problemas, basadas tanto en la inclusión de información que identificaría al portador, como en tiempos de caducidad más listas de habilitaciones revocadas [Gong 1989, Hayton y otros 1998]. A pesar de que añaden complejidad, a un concepto bastante simple de otro modo, las habilitaciones siguen siendo una técnica importante, por ejemplo, pueden usarse en conjunción con las listas de control de acceso para optimizar el control

de acceso en accesos repetidos al mismo recurso, y además proporcionan el mecanismo más limpio para la implementación de la delegación (véase la Sección 7.2.5).

Es interesante observar la similitud entre las habilitaciones y los certificados. Considere el certificado de propiedad de Alice de su cuenta bancaria, presentado en la Sección 7.2.3. Difiere de las habilitaciones, tal y como aquí se describen, sólo en que no hay una lista de operaciones permitidas y en que se identifica al emisor. Los certificados y las habilitaciones pueden ser conceptos intercambiables bajo ciertas circunstancias. El certificado de Alice puede contemplarse como una clave de acceso para realizar todas las operaciones sobre la cuenta bancaria de Alice que se permiten a los titulares de las cuentas, dando por sentado que pueda probarse que el solicitante sea Alice.

Listas de control de acceso: Se almacena una lista con cada recurso, con una entrada de la forma $\langle\text{dominio}, \text{operaciones}\rangle$ para cada dominio que tenga acceso al recurso y especificando las operaciones permitidas al dominio. Un dominio puede especificarse mediante un identificador de un principal o puede ser una expresión susceptible de ser utilizada para determinar la pertenencia del principal al dominio. Por ejemplo, *el propietario de este archivo* es una expresión que puede evaluarse comparando la identidad del principal solicitante con la identidad del propietario almacenada con el archivo.

Éste es el esquema adoptado en la mayoría de los sistemas de archivos, incluyendo UNIX y Windows NT, donde se asocia a cada archivo un conjunto de bits de permisos de acceso, y los dominios a los cuales se ceden los permisos se definen por medio de una referencia a la información de pertenencia almacenada con cada archivo.

Las peticiones a los servidores son de la forma $\langle\text{op}, \text{principal}, \text{recurso}\rangle$. Para cada petición, el servidor identifica el principal y comprueba si la operación solicitada está incluida en la entrada del principal en la lista de control de acceso del recurso relevante.

◊ **Implementación.** Las firmas digitales, las credenciales y los certificados de clave pública proporcionan las bases criptográficas para el control de acceso seguro. Los canales seguros ofrecen beneficios de prestaciones, posibilitando el manejo de múltiples peticiones sin necesidad de comprobar los principales y las credenciales reiteradamente [Wobber y otros 1994].

Ambos CORBA y Java ofrecen un API de seguridad. Uno de sus principales objetivos es dar soporte para el control de acceso. Java proporciona soporte para que los objetos distribuidos administren su propio control de acceso mediante las clases Principal, Signer y ACL, así como métodos de autenticación por defecto y soporte para certificados, validación de firmas y comprobaciones de control de acceso. También están soportadas la criptografía de clave secreta y pública. Farley [1998] presenta una buena introducción a estas características de Java. La protección de los programas Java que incluyen código móvil se basa en el concepto de dominio de protección; el código local y el código descargado tienen diferentes dominios de protección en que ejecutarse. Puede haber un dominio de protección para cada código fuente descargado, con derechos de acceso para diferentes conjuntos de recursos locales dependiendo del nivel de confianza, el cual se indica en el código descargado.

CORBA ofrece una especificación de Servicio de Seguridad [Blakley 1999, OMG 1998b] con un modelo de ORB para proporcionar comunicación, autenticación, control de acceso con credenciales, ACL y auditoría; éstas se describirán con más detalle en la Sección 17.3.4.

7.2.5. CREDENCIALES

Las credenciales son un conjunto de evidencias presentadas por un principal cuando pide acceso a un recurso. En el caso más simple, un certificado de una autoridad relevante afirmando la identidad del principal es suficiente, y ésta podrá emplearse para comprobar los permisos del principal en una lista de control de acceso (véase la Sección 7.2.4). A menudo esto es todo lo que se

necesita o se proporciona, pero el concepto puede generalizarse para tratar con muchos requisitos más sutiles.

No es conveniente pedir que los usuarios contacten con el sistema y se autentiquen ellos mismos cada vez que se requiere su autoridad para realizar una operación sobre un recurso protegido. En su lugar, se introduce la noción de credencial que *habla por* un principal. Así un certificado de clave pública de un usuario habla por ese usuario; cualquier proceso que reciba una petición autenticada con la clave privada del usuario puede asumir que la petición fue enviada por ese usuario.

La idea de *hablar por* puede llevarse mucho más adelante. Por ejemplo, en una tarea cooperativa, se puede pedir que ciertas acciones sensibles sólo se realicen con la autoridad de dos miembros del equipo; en tal caso, el principal que solicita la acción remitiría su credencial de identificación y una credencial de respaldo de otro miembro del equipo, junto con una indicación de que se empleen simultáneamente cuando se comprueben las credenciales.

De modo similar, para votar en una elección, cada emisión de voto vendría acompañada por un certificado de elector así como un certificado de identificación. Un certificado de delegación permite al principal actuar en lugar de otro, etcétera. En general, una comprobación de control de acceso involucra la evaluación de una fórmula lógica que combina los certificados aportados. Lampson y otros [1992] han desarrollado una completa lógica de autenticación para su empleo en la evaluación de la autoridad de tipo *hablar por* asociada a un conjunto de credenciales. Wobber y otros [1994] describen un sistema que soporta esta aproximación tan general. En [Rowley 1998] se puede encontrar más material sobre formas útiles de credenciales para su aplicación en tareas cooperativas en el mundo real.

Las credenciales basadas en funciones parecen especialmente útiles en el diseño de esquemas de control de acceso prácticos [Sandhu y otros 1996]. Los conjuntos de credenciales basadas en funciones se definen para las organizaciones o para tareas cooperativas, y los derechos de acceso de nivel de aplicación se construyen con referencia a ellas. Se pueden asignar funciones o roles a principales específicos mediante la generación de un certificado de rol que asocia un principal con un rol determinado en una tarea u organización específica [Coulouris y otros 1998].

◊ **Delegación.** Una forma particularmente útil de credencial es aquella que permite a un principal, o proceso actuando para un principal, realizar una acción con la autoridad de otro principal. Una necesidad de delegación puede aparecer en cualquier situación donde un servicio necesite acceder a un recurso protegido para completar una acción en representación de su cliente. Considere el ejemplo de un servidor de impresora que acepta solicitudes de impresión de archivos. Sería un gasto inútil de recursos copiar el archivo, de modo que únicamente se pasa el nombre del archivo al servidor de impresión y éste es accedido por el servidor en representación del usuario que realiza la petición. Si el archivo está protegido contra lectura, no funcionará a menos que el servidor de impresión pueda tomar temporalmente los derechos de lectura del archivo. La delegación es un mecanismo diseñado para resolver problemas como éste.

Se puede conseguir la delegación utilizando un certificado de delegación o una habilitación. El certificado está firmado por el principal solicitante y autoriza a otro principal (el servidor de impresión en nuestro ejemplo) para acceder a un recurso con nombre (el archivo que hay que imprimir). En los sistemas que lo soportan, las habilitaciones pueden lograr el mismo resultado sin necesidad de identificar a los principales; se puede pasar una habilitación para acceder a un recurso en la petición al servidor. La habilitación es un conjunto codificado e infalsificable de derechos de acceso al recurso.

Cuando se delegan derechos, es común restringirse a un subconjunto de los derechos que posee el principal que lo emite, de este modo el principal delegado no podrá abusar de ellos. En nuestro ejemplo, el certificado podría estar limitado en el tiempo para reducir el riesgo de que el código del servidor de impresión esté comprometido posteriormente y se desvele el archivo a terceras par-

tes. El Servicio de Seguridad de CORBA incluye un mecanismo para la delegación de derechos basado en certificados con soporte para la restricción de los derechos que conlleva.

7.2.6. CORTAFUEGOS

Se presentaron los cortafuegos en la Sección 3.4.8. Con ellos se protege una intranet, se realizan acciones de filtrado en las comunicaciones entrantes y salientes. Aquí se discuten sus ventajas y desventajas como mecanismos de seguridad.

En un mundo ideal, la comunicación debiera ocurrir siempre entre procesos que confíen mutuamente y transcurrir siempre entre canales seguros. Hay muchas razones por las que este ideal es irrealizable, algunas se pueden resolver, pero otras no como consecuencia de la naturaleza abierta de ciertos sistemas distribuidos o debido a los errores presentes en la mayoría del software. La facilidad con la que se pueden enviar mensajes hacia cualquier servidor, en cualquier lugar, y el hecho de que muchos servidores no están diseñados para resistir ataques maliciosos de los hackers o por errores accidentales, convierten en algo sencillo la fuga de información confidencial de los servidores de una organización. Ciertos elementos indeseables pueden, también, penetrar en la red de una organización, permitiendo que entren programas de gusano y virus en los computadores. Véase [web.mit.edu II] para una crítica más profunda de los cortafuegos.

Los cortafuegos producen un entorno de comunicación local en el que se intercepta toda comunicación externa. Los mensajes se reenvían al recipiente local final sólo para las comunicaciones que estén autorizadas explícitamente.

Se puede controlar el acceso a las redes internas mediante cortafuegos, pero el acceso a los servicios públicos a Internet no puede restringirse porque su objetivo es ofrecer éstos a un amplio conjunto de usuarios. El empleo de cortafuegos no ofrece protección contra los ataques desde el interior de una organización, y es ciertamente tosco en el control del acceso externo. En consecuencia existe una necesidad de mecanismos de seguridad de un grano más fino, que permitan a los usuarios individuales compartir información con otros usuarios seleccionados sin comprometer la privacidad y la integridad. Abadi y otros [1998] describen una aproximación a la provisión de acceso a datos web privados para usuarios externos basada en un mecanismo de *tunel web* que pueda ser integrado con un cortafuegos. Éste ofrece acceso a los usuarios fiables y autenticados hacia los servidores web mediante un proxy seguro basado en el protocolo HTTPS (HTTP sobre SSL).

Los cortafuegos no son particularmente útiles contra ataques de denegación de servicios tales como el que se describe en la Sección 3.4.2, basado en la suplantación de direcciones IP. El problema es que el flujo de mensajes generado por tales ataques sobrepasa las capacidades de cualquier elemento de defensa singular como un cortafuegos. Cualquier remedio contra las riadas de mensajes debiera aplicarse corriente arriba del objetivo. Los remedios basados en el empleo de mecanismos de calidad de servicio para restringir el flujo de mensajes desde la red hasta un nivel que el objetivo pueda manejar parece ser que prometen.

7.3. ALGORITMOS CRIPTOGRÁFICOS

Un mensaje puede encriptarse mediante la aplicación por el emisor de alguna regla que transforme el *texto en claro* del mensaje (cualquier secuencia de bits) a un *texto cifrado* o *criptograma* (una secuencia diferente de bits). El receptor debe conocer la regla inversa para transformar el texto cifrado en el texto original. El resto de los principales deben ser incapaces de descifrar el mensaje

a menos que conozcan esta regla inversa. La transformación de encriptación se define mediante dos elementos, una *función E* y una *clave K*. El mensaje resultante encriptado se escribe $\{M\}_K$.

$$E(K, M) = \{M\}_K$$

La función de encriptación *E* define un algoritmo que transforma los datos de texto en datos encriptados al combinarlos con la clave y transformándolos de un modo que depende fuertemente del valor de la clave. Podemos pensar en un algoritmo de encriptación como en una especificación de una familia grande de funciones, de la que seleccionamos un miembro particular mediante una clave dada. La desencriptación se lleva a cabo empleando una función inversa *D*, que también toma como parámetro una clave. Para la encriptación de clave secreta, la clave de desencriptado es la misma que la de encriptado:

$$D(K, E(K, M)) = M$$

Debido este uso simétrico de las claves, a menudo se habla de la criptografía de clave secreta como *criptografía simétrica*, mientras que la criptografía de clave pública se denomina *asimétrica* debido a que las claves empleadas para el encriptado y el desencriptado son diferentes, como veremos más adelante. En la próxima sección, describiremos varias funciones de encriptación de ambos tipos, ampliamente utilizadas.

◊ **Algoritmos simétricos.** Si eliminamos de la consideración el parámetro de la clave y definimos $F_K([M]) = E(K, M)$, una propiedad de las funciones de encriptación robustas es que $F_K([M])$ sea relativamente fácil de calcular, mientras que la inversa, $F_K^{-1}([M])$ sea tan difícil de calcular que no sea factible. Tales funciones se las conoce como funciones de un solo sentido. La efectividad de cualquier método para encriptar información depende del uso de una función de encriptación *F_K* que posea esta propiedad de irreversibilidad. Es esta propiedad la que protege a *M* de ser descubierto dado $\{M\}_K$.

Para los algoritmos simétricos bien diseñados como los que se describen en la próxima sección, su fortaleza contra los intentos de descubrir *K* dado un texto en claro *M* y el correspondiente texto cifrado $\{M\}_K$ depende del tamaño de *K*. La causa de esto se encuentra en que la forma más general de ataque efectivo es la más rudimentaria, conocida como *ataque por fuerza bruta*. La aproximación de fuerza bruta consiste en recorrer todos los valores posibles de *K*, calculando *E(K, M)* hasta que el resultado concuerda con el valor de $\{M\}_K$ conocido. Si *K* tiene *N* bits entonces tal ataque requiere 2^{N-1} iteraciones de media, y un máximo de 2^N iteraciones, para encontrar *K*. Entonces el tiempo para romper *K* es exponencial con el número de bits en *K*.

◊ **Algoritmos asimétricos.** Cuando se emplea un par de claves pública/privada, las funciones de un solo sentido se explotan de otra forma. La factibilidad de un esquema de clave pública fue propuesta por primera vez por Diffie y Hellman [1976] como un método criptográfico que eliminaba la necesidad de confianza entre dos partes que se comunican. La base de todos los esquemas es la existencia de *funciones de puerta falsa*. Una función de puerta falsa es una función de un solo sentido con una salida secreta: es fácil calcularla en una dirección pero impracticable calcular su inversa a menos que se conozca un secreto. Fue la posibilidad de encontrar tales funciones y utilizarlas en la práctica criptográfica lo que Diffie y Hellman propusieron por primera vez. Desde entonces, se han propuesto y desarrollado varios esquemas prácticos de clave pública. Todos ellos dependen del empleo de funciones de números grandes como funciones de puerta falsa.

El par de claves necesario para los algoritmos asimétricos se deriva de una raíz común. Para el algoritmo RSA, que se describirá en la Sección 7.3.2, la raíz es un par de números primos muy grandes que se eligen arbitrariamente. La derivación del par de claves desde la raíz es una función de un solo sentido. En el caso del algoritmo RSA, los números primos grandes se multiplican uno con otro; un cálculo que precisa unos pocos segundos, incluso para números primos verdadera-

mente grandes. El producto resultante, N , es por supuesto mucho más grande que los multiplicandos. Este uso de la multiplicación es una función de un solo sentido en cuanto a que es impráctico obtener los multiplicandos originales a partir del producto (esto es, factorizar el producto).

Un miembro del par de claves se emplea para encriptar. Para RSA, la función de encriptación oscurece el texto en claro tratando cada bloque de bits como un número binario y elevándolo a la potencia de la clave, módulo N . El número resultante es el bloque criptografiado correspondiente.

El tamaño de N y al menos un miembro del par de claves es mucho mayor que el tamaño de clave seguro para claves simétricas con el fin de asegurar que N no sea factorizable. Por esta razón el potencial de los ataques por fuerza bruta sobre RSA es pequeño; su resistencia a los ataques depende de la imposibilidad de factorizar N . Discutiremos los tamaños seguros para N en la Sección 7.3.2.

◊ **Cifradores de bloque.** La mayoría de los algoritmos de encriptación operan sobre bloques de datos de tamaño fijo; 64 bits es un tamaño de bloque popular. Cada mensaje se subdivide en bloques, el último bloque se rellena hasta la longitud estándar si fuera necesario y cada bloque se encripta independientemente. El primer bloque está listo para ser transmitido tan pronto como haya sido encriptado.

Para un simple cifrador de bloque, el valor de cada bloque del criptograma no depende de los bloques precedentes. Esto constituye una debilidad, dado que un atacante puede reconocer patrones repetidos e inferir su relación con el texto en claro. Tampoco se garantiza la integridad de los mensajes a menos que se añada una suma de chequeo o se emplee un mecanismo de resumen seguro. La mayoría de los algoritmos de cifrado de bloque emplean un encadenamiento de bloques de cifrado (*cipher block chaining*, CBC) para soslayar estas debilidades.

Encadenamiento de bloques de cifrado: En el modo de encadenamiento de bloques de cifrado, cada bloque de texto en claro se combina con el bloque de criptograma precedente empleando la operación O-exclusivo (XOR) antes de encriptarlo (véase la Figura 7.6). En el desencriptado, el bloque se desencripta y se efectúa una operación XOR con el bloque encriptado precedente (que habrá sido almacenado con este fin) obteniendo el nuevo bloque de texto en claro. Esto es posible porque la operación XOR es *idempotente* (dos aplicaciones sucesivas producen el mismo valor).

Con el CBC se pretende impedir que dos porciones idénticas de texto en claro deriven en dos porciones de código encriptado idénticas. Aunque persista una debilidad al comienzo de cada secuencia de bloques: si abrimos dos conexiones encriptadas hacia dos destinatarios y enviamos el mismo mensaje, las secuencias de bloques encriptadas serán la misma, y un fisiólogo podría obtener algo de información útil de ello. Para prevenir esto, necesitamos insertar un trozo de texto en claro diferente a la cabeza de cada mensaje. Tal texto se denomina *vector de iniciación*. Un número contenido en la fecha y la hora del mensaje sirve bien como vector de iniciación, y fuerza a que cada mensaje comience con un bloque de texto en claro diferente. Esto, combinado con la operación CBC, deviene en criptogramas diferentes, incluso con dos textos en claro idénticos.

El uso del modo CBC se restringe a la encriptación de datos que se transmiten a lo largo de una conexión fiable. El desencriptado fallará si se pierde cualquiera de los bloques del criptograma, dado que el proceso de desencriptado será incapaz de desencriptar bloques a partir de ese momento. En consecuencia, es inadecuado para ser empleado en aplicaciones como las que se describen

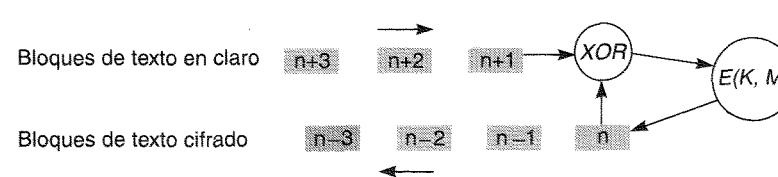


Figura 7.6. Encadenamiento de bloques de cifrado.

en el Capítulo 15, en las que se puede tolerar alguna pérdida de datos. En tales circunstancias habrá que utilizar un cifrador de flujos de datos.

◊ **Cifradores de flujo.** Para algunas aplicaciones, tales como el encriptado de conversaciones telefónicas, la encriptación en bloques es inapropiada porque los flujos de datos se producen en tiempo real en pequeños fragmentos. Las muestras de datos pueden ser tan pequeñas como 8 bits o incluso de 1 bit, y sería un desperdicio llenar el resto de los 64 bits antes de encriptar y transmitirlos. Los cifradores de caudal son algoritmos de encriptado que pueden realizar la encriptación incrementalmente, convirtiendo el texto en claro en texto criptografiado bit a bit.

Esto parece difícil de lograr, pero de hecho resulta muy simple convertir un algoritmo de cifrado de bloque en un cifrador de caudal. El truco está en construir un *generador del flujo de clave*. Un caudal de clave es una secuencia de bits de tamaño arbitrario que puede emplearse para oscurecer los contenidos de un caudal de datos combinando el caudal de clave con el caudal de datos mediante la función XOR (véase la Figura 7.7). Si el caudal de clave es seguro, el caudal de datos encriptados también lo será.

La idea es análoga a la técnica empleada en la comunidad de espionaje e inteligencia para frustrar las posibles escuchas en la que se emite ruido blanco para ocultar la conversación en una habitación aunque se esté grabando la conversación. Si el ruido ambiente y el ruido blanco se graban por separado, la conversación puede limpiarse sustrayendo el ruido blanco de la grabación del ruido ambiente.

Se puede construir un generador del caudal de clave iterando una función matemática sobre un rango de valores de entrada para producir un caudal continuo de valores de salida. Los valores de salida se concatenan entonces para construir bloques de texto en claro, y los bloques se encriptan empleando una clave compartida por el emisor y el receptor. El caudal de clave puede además disfrazarse aplicando CBC. Los bloques encriptados resultantes se emplean como el caudal de clave. Una iteración de casi cualquier función que devuelva uno de un rango de valores no enteros diferentes funcionará como material fuente, aunque se suele emplear un generador de números aleatorios con un valor de comienzo acordado entre el emisor y receptor. Para conservar la calidad de servicio del caudal de datos, los bloques del flujo de clave deberían producirse con un poco de antelación sobre el momento en que vayan a ser empleados, además el proceso que los produce no debiera exigir demasiado esfuerzo de procesamiento como para retrasar el caudal de datos.

Así en principio, los flujos de datos en tiempo real pueden encriptarse de modo tan seguro como los datos por lotes, siempre que haya disponible suficiente potencia de cálculo para encriptar el caudal de clave en tiempo real. Obviamente, algunos dispositivos que podrían beneficiarse de la encriptación en tiempo real, como los teléfonos móviles, no están equipados con procesadores muy potentes y en este caso sería necesario reducir la seguridad del algoritmo de caudal de clave.

◊ **Diseño de algoritmos criptográficos.** Existen muchos algoritmos criptográficos bien diseñados tales que $E(K, M) = \{M\}_K$ oculta el valor de M y resulta prácticamente imposible recuperar K con mejor éxito que el que proporciona la fuerza bruta. Todos los algoritmos de encriptación se apoyan en manipulaciones que preservan la información de M y emplean principios basados en

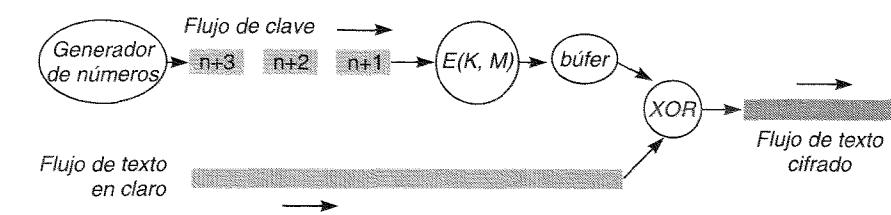


Figura 7.7. Cifrador de caudal.

la teoría de la información [Shannon 1949]. Schneier [1996] describe los principios de *confusión* y

la teoría de la información [Shannon 1949]. Schneier [1996] describe los principios de *confusión* y *difusión* de Shannon para el ocultamiento del contenido del bloque de criptograma M , combinándolo con una clave K de tamaño suficiente para ponerlo a prueba de ataques por fuerza bruta

```

1 void encripta(unsigned long k[], unsigned long texto[]) {
2     unsigned long y = texto[0], z = texto[1];
3     unsigned long delta = 0x9e3779b9, suma = 0; int n;
4     for (n = 0; n < 32; n++) {
5         suma += delta;
6         y += ((z << 4) + k[0]) ^ (z + suma) ^ ((z >> 5) + (k[1]));
7         z += ((y << 4) + k[2]) ^ (y + suma) ^ ((y >> 5) + (k[3]));
}
texto[0] = y; texto[1] = z;
}

```

Figura 7.8. Función de encriptación de TEA.

El algoritmo TEA emplea vueltas de sumas enteras, XOR (el operador \wedge) y desplazamientos lógicos de bits ($<<$ y $>>$) para obtener la difusión y la confusión de los patrones de bits en el texto en claro. El texto en claro es un bloque de 64 bits representado como dos enteros de 32 bits en el vector $texto[]$. La clave tiene 128 bits, representada como cuatro enteros de 32 bits.

En cada una de las 32 etapas, se combinan repetidamente las dos mitades del texto con porciones desplazadas de la clave y entre sí en las líneas 5 y 6. El empleo de XOR sobre porciones del texto desplazadas introduce confusión, y el desplazamiento e intercambio de las dos porciones del texto introduce difusión. La constante *delta* que se combina con cada porción del texto en cada ciclo para oscurecer la clave en caso de que fuera revelada por una sección de texto que no variara. La función de desencriptado es la inversa de la función de encriptación y se muestra en la Figura 7.9.

Este pequeño programa proporciona una encriptación de clave secreta rápida y razonablemente segura. Se han medido sus prestaciones y ronda el triple de velocidad que el algoritmo DES, a la vez que lo conciso del programa se presta a la optimización e implementación por hardware. La clave de 128 bits es segura contra los ataques de fuerza bruta. Los estudios realizados por sus autores y otros han revelado sólo dos pequeñas debilidades que han sido tenidas en cuenta en una nota subsiguiente [Wheeler y Needham 1997].

Para ilustrar su utilización, la Figura 7.10 muestra un simple procedimiento que emplea la encriptación y desencriptación entre un par de archivos abiertos previamente (empleando la librería estándar C *stdio*).

◊ **DES.** El Estándar de Encriptación de Datos (*Data Encryption Standard*, DES) [National Bureau of Standards 1997] fue desarrollado por IBM y adoptado subsiguientemente como un estándar nacional de los EE.UU. para aplicaciones gubernamentales y de negocios. En este estándar, la función de encriptación proyecta un texto en claro de 64 bits en una salida encriptada de 64 bits usando una clave de 56 bits. El algoritmo tiene 16 etapas dependientes de clave conocidas como *vueltas*,

```

void desencripta(unsigned long k[], unsigned long texto[]) {
    unsigned long y = texto[0], z = texto[1];
    unsigned long delta = 0x9e3779b9, suma = delta << 5; int n;
    for (n = 0; n < 32; n++) {
        z -= ((y << 4) + k[2]) ^ (y + suma) ^ ((y >> 5) + (k[3]));
        y -= ((z << 4) + k[0]) ^ (z + suma) ^ ((z >> 5) + (k[1]));
        suma -= delta;
    }
    texto[0] = y; texto[1] = z;
}

```

Figura 7.9. Función de desencriptación de TEA.

◊ **IDEA.** El Algoritmo de Encriptación de Datos Internacional (*International Data Encryption Algorithm*, IDEA) se desarrolló a comienzos de los años noventa [Lai y Massey 1990, Lai 1992] como sucesor de DES. Como TEA, emplea una clave de 128 bits para encriptar bloques de 64 bits. El algoritmo se basa en el álgebra de grupos y tiene ocho vueltas XOR, suma módulo 2^{16} y multiplicación. Tanto DES como IDEA, emplean una misma función para la encriptación y desencriptación: una propiedad útil para los algoritmos que han de implementarse en hardware.

La resistencia de IDEA ha sido analizada extensamente, y no se han encontrado debilidades significativas. Realiza la encriptación y desencriptación a una velocidad tres veces superior que la de DES.

◊ **AES.** En 1997, el Instituto Nacional para los Estándares y la Tecnología (NIST) publicó una invitación para remitir propuestas de un algoritmo seguro y eficiente que sería adoptado como nuevo Estándar de Encriptación Avanzada (Advanced Encryption Standard, AES) [NIST 1999]. La evaluación concluyó en mayo del año 2000, cuando se seleccionó un estándar preliminar; el estándar final se publicará en el año 2001¹.

La comunidad de investigación sobre criptografía remitió quince algoritmos, como respuesta a la invitación inicial para el AES. Tras una intensa inspección técnica se seleccionaron cinco de ellos para la siguiente fase de evaluación. Todos los candidatos soportaban claves de 128, 192 y 256 bits, siendo todos ellos de altas prestaciones. Es de esperar que, una vez anunciado, el AES se convierta en el algoritmo de encriptación simétrica más ampliamente utilizado.

7.3.2. ALGORITMOS DE CLAVE PÚBLICA (ASIMÉTRICOS)

Hasta la fecha sólo se han desarrollado unos pocos esquemas prácticos de clave pública. Dependen del uso de funciones de puerta falsa de números grandes para producir las claves. Las claves K_e y K_d son un par de números muy grandes, y la función de encriptación realiza una operación, con una exponenciación de M , usando una de ellas. La desencriptación es una función similar usando la otra clave. Si la exponenciación usa una aritmética modular, puede demostrarse que el resultado es el mismo que el valor original de M ; es decir:

$$D(K_d, E(K_e, M)) = M$$

Un principal que deseé participar en una comunicación segura con otros confecciona un par de claves K_e y K_d y guarda en secreto la clave de desencriptación K_d . La clave de encriptación K_e puede publicarse para cualquiera que quiera comunicar. La clave de encriptación K_e puede verse como parte de una función de encriptación de un sentido E , y la clave de desencriptación K_d es el trozo de conocimiento secreto que permite al principal p invertir la encriptación. Cualquiera que posea K_e (disponible públicamente) puede encriptar mensajes $\{M\}_{K_e}$, pero solamente el principal que posea el secreto K_d puede operar la puerta falsa.

El empleo de números grandes conlleva costes de procesamiento importantes en el cálculo de las funciones E y D . Veremos más tarde que éste es un problema que hay que abordar de forma que el uso de las claves públicas se restrinja a las etapas iniciales de las sesiones de comunicación segura. El algoritmo RSA es ciertamente el algoritmo de clave pública más conocido y lo describiremos con cierto detalle. Otro tipo de algoritmos se basa en funciones derivadas del comporta-

¹ En octubre de 2000, el NIST seleccionó a uno de los candidatos, Rijndael, como propuesta firme de AES. Tras un período de tres meses de revisión pública, en febrero de 2001 la Secretaría de Comercio anunció la disponibilidad al público del borrador de Estándar Federal para el Procesamiento de Información (FIPS, *Federal Information Processing Standard*), para su revisión. Según los planes, las pruebas de validación para el estándar estarán disponibles hacia el verano de 2001. (N. del T.)

La función para desencriptar un bloque de texto encriptado c para producir el bloque de texto en claro original es:

$$D'(d, N, c) = c^d \bmod N$$

Rivest, Shamir y Adelman probaron que E' y D' son inversas mutuas (esto es, que $E'(D'(x)) = D'(E'(x)) = x$) para cualquier valor P en el rango $0 \leq P \leq N$.

Los dos parámetros e , N pueden considerarse como clave para la función de encriptación, e igualmente d , N representan una clave para función de desencriptación. Así podemos escribir $K_e = \langle e, N \rangle$ y $K_d = \langle d, N \rangle$, y obtener las funciones de encriptación $E(K_e, M) = \{M\}_K$ (esta notación indica que el mensaje encriptado puede ser encriptado sólo por el portador de la clave privada K_d) y $D(K_d, \{M\}_K) = M$.

Merece la pena fijarse en una potencial debilidad de todos los algoritmos de clave pública: dado que la clave pública está disponible para los atacantes, éstos pueden generar fácilmente mensajes encriptados. Así, se podría intentar desencriptar un mensaje desconocido encriptando exhaustivamente secuencias arbitrarias de bits hasta que concuerden con el mensaje objetivo. Este ataque se conoce como *ataque de texto en claro escogido*, y se vence asegurando que todos los mensajes son más largos que la longitud de la clave, de forma que el ataque por fuerza bruta sea menos factible que un ataque directo sobre la clave.

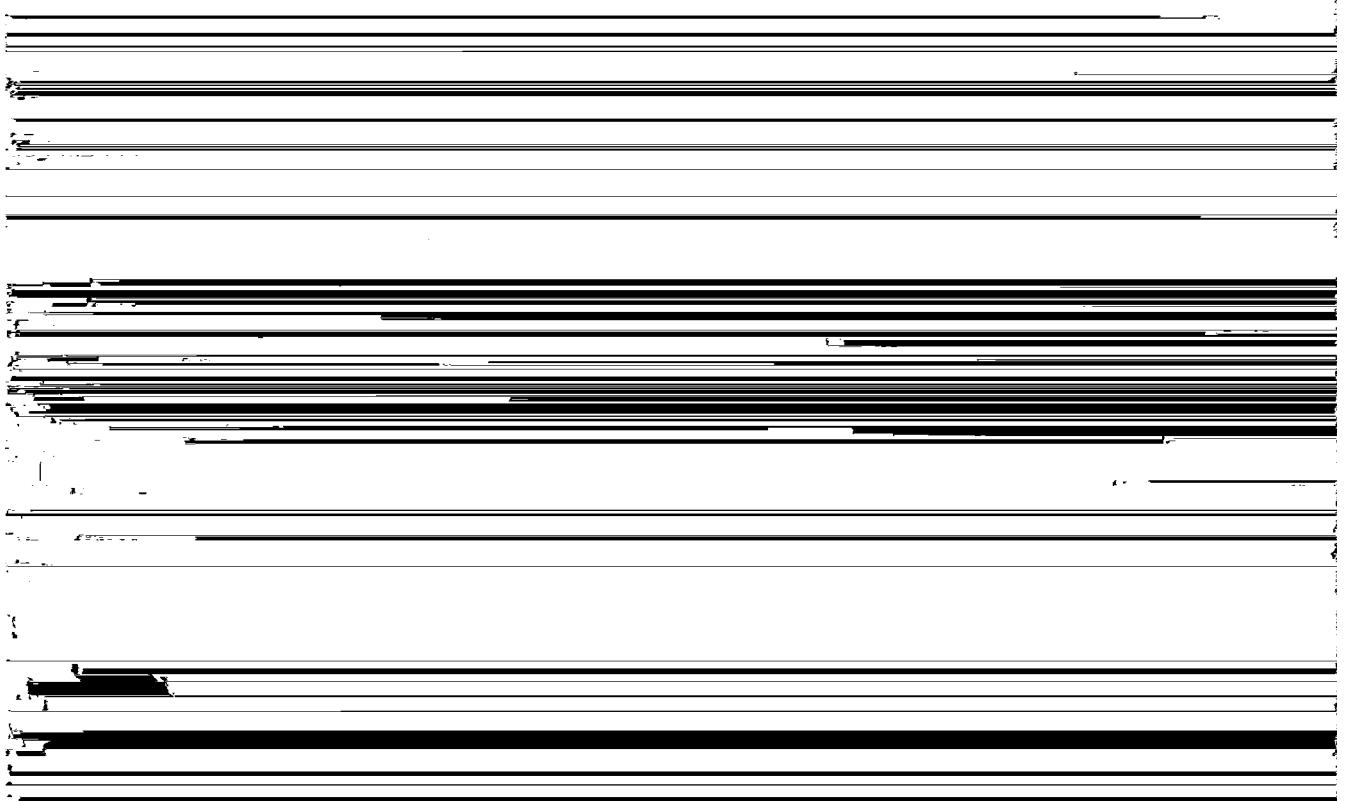
Un aspirante a receptor de información secreta debe publicar o distribuir de cualquier forma el par $\langle e, N \rangle$ manteniendo d secreto. La publicación de $\langle e, N \rangle$ no compromete el secreto de d , porque cualquier intento de determinar d requiere el conocimiento de los números primos P y Q originales, y esto sólo se puede obtener mediante la factorización de N . La factorización de números primos grandes (recordamos que P y Q se eligen $> 10^{100}$, y entonces $N > 10^{200}$) es extremadamente costoso en tiempo, incluso con computadores de altas prestaciones. En 1978, Rivest y otros calcularon que factorizar un número del tamaño de 10^{200} tomaría más de cuatro mil millones de años con el mejor algoritmo conocido sobre un computador que efectuara un millón de instrucciones por segundo.

Desde la afirmación de Rivest en 1978 se han desarrollado computadores mucho más rápidos y métodos de factorización mejores. RSA Corporation publicó una serie de retos para realizar factorizaciones de números de más de 100 dígitos decimales [www.rsasecurity.com II]. Se han logrado factorizar números de hasta 155 dígitos decimales de longitud mediante un consorcio distribuido de usuarios de Internet trabajando de un modo similar al esfuerzo de romper DES que se describe en la sección anterior. En el momento de escribir esto, el hecho es que se han factorizado con éxito números de 155 dígitos (o aproximadamente 500 dígitos binarios), lo que recorta la confianza en la seguridad de claves de 512 bits. El esfuerzo necesario para factorizar no ha sido publicado, pero un número de 140 dígitos requirió del orden de 2.000 MIPS al año en febrero de 1999. Un MIPS al año es el esfuerzo de procesamiento generado por un procesador con una velocidad de un millón de instrucciones por segundo calculando durante un año. Los procesadores de un solo chip actuales tienen velocidades del orden de 200 MIPS, lo que les permite completar esta tarea en cerca de diez años, pero las aplicaciones distribuidas de factorización y los procesadores paralelos podrían reducir esta magnitud a días. RSA Corporation (propietarios de las patentes del algoritmo RSA) recomiendan una clave de al menos 768 bits, es decir 230 dígitos decimales, para la seguridad a largo plazo (cerca de 20 años). En algunas aplicaciones se emplean claves de 2.048 bits.

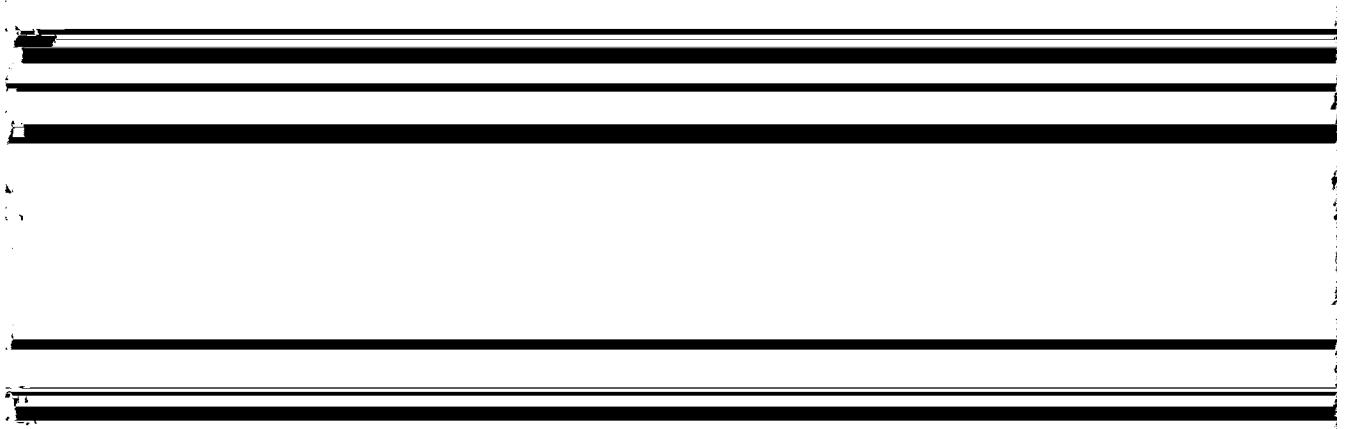
Todos los cálculos de resistencia anteriores, presuponen de que los algoritmos conocidos actualmente son los mejores disponibles. RSA, y otras formas de criptografía asimétrica que emplean multiplicación de números primos como función de un sentido, serían vulnerables en el caso de que se descubriera un algoritmo de factorización más rápido.

◇ **Algoritmos de curvas elípticas.** Se ha desarrollado y probado un algoritmo para generar pares de claves pública/privada basándose en las propiedades de las curvas elípticas. Los detalles

completos pueden encontrarse en el libro de Menezes dedicado al tema [Menezes 1993]. Las cla-



completos pueden encontrarse en el libro de Menezes dedicado al tema [Menezes 1993]. Las cla-



fáciles de generar, copiar y alterar. La simple adición de la identidad del emisor en forma de cadena de texto, una fotografía o una imagen manuscrita, no tiene valor alguno como medio de verificación.

Lo que se requiere es un medio de enlazar una identidad de un firmante a la secuencia completa de bits que representa un documento. Con esto cumplimos el primer requisito anterior, de autenticidad. Como con las firmas manuscritas, la fecha del documento no está garantizada por la sola firma. El destinatario de un documento firmado sólo sabe que el documento fue firmado con anterioridad a la recepción.

Con respecto al no repudio, existe un problema que no aparece con las firmas manuscritas. ¿Qué pasa si el firmante revela deliberadamente su clave privada y posteriormente niega haber firmado, argumentando que otros podrían haberlo hecho también, puesto que la clave no era privada? Se han desarrollado algunos protocolos para resolver este problema con el nombre de *firmas digitales innegables* [Schneier 1996], pero añaden una complejidad considerable al procedimiento.

Se puede considerar que un documento con firma digital es más robusto frente a la falsificación que uno escrito a mano. Pero la palabra «original» carece de significado con respecto a los documentos digitales. Como veremos en nuestro discurso sobre las necesidades del comercio electrónico, las firmas digitales aisladamente no pueden prevenir, por ejemplo, el gasto doble de dinero electrónico, y se requieren otras medidas para prevenirlo. Aquí describiremos dos técnicas para firmar documentos digitalmente, vinculando la identidad de un principal al documento. Ambas dependen del uso de la criptografía.

◊ **Firmado digital.** Un documento o mensaje electrónico M puede ser firmado por un principal A encriptando una copia de M con una clave K_A y añadiéndola a una copia del texto en claro M y un identificador de A . El documento firmado consta de: $M, A, [M]_{K_A}$. La firma puede ser verificada por un principal que reciba después el documento para comprobar si fue originada por A y que sus contenidos, M , no han sido alterados posteriormente.

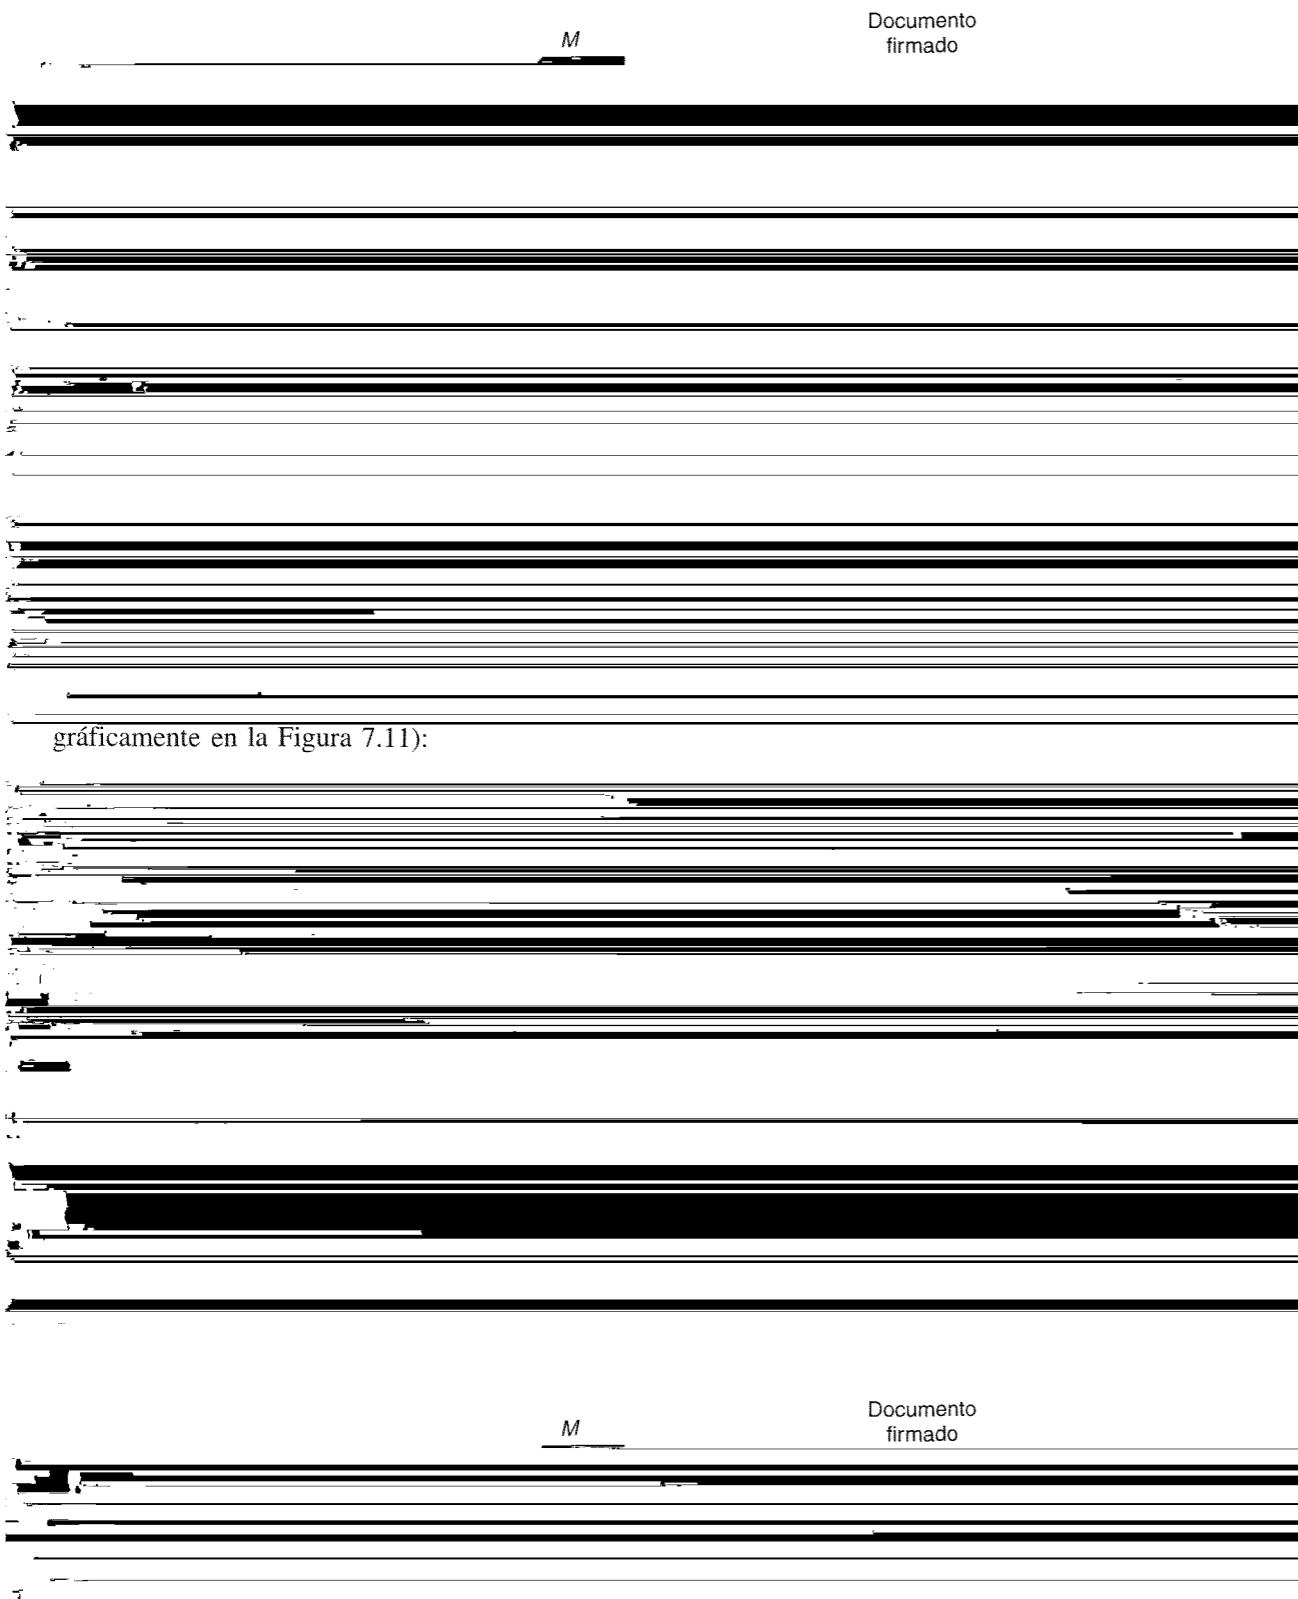
Si se emplea una clave secreta para encriptar el documento, sólo los principales que comparten el secreto pueden verificar la firma. Pero si se emplea criptografía de clave pública, el firmante utiliza su clave privada y cualquiera que disponga de la clave pública correspondiente puede verificar la firma. Ésta proporciona una mejor analogía de una firma convencional y posee un rango de aplicación mayor para el usuario. La verificación de firmas digitales sigue caminos diferentes dependiendo de si se emplea criptografía de clave pública o privada para producir la firma. Describimos ambos casos en las Secciones 7.4.1 y 7.4.2.

◊ **Funciones resumen.** Las funciones resumen se denominan también *funciones de dispersión seguras* y se denotan con $H(M)$. Éstas deben diseñarse cuidadosamente para asegurar que $H(M)$ sea diferente de $H(M')$ para todos los probables pares de mensajes M y M' . Si hubiera cualquier par de mensajes similares M y M' de modo que $H(M) = H(M')$, un principal mentiroso podría enviar una copia firmada de M , pero al someterse a una validación argumentaría que envió M' , y que el original fue alterado en el tránsito. Discutiremos algunas funciones de dispersión seguras en la Sección 7.4.3.

7.4.1. FIRMAS DIGITALES CON CLAVES PÚBLICAS

La criptografía de clave pública se adapta particularmente bien a la generación de firmas digitales dado que es relativamente simple y no requiere ninguna comunicación entre el destinatario de un documento firmado y el firmante o cualquier otro.

El método para que A firme un mensaje M y B lo verifique es como sigue (según se ilustra gráficamente en la Figura 7.11):



- El descubrimiento de una clave secreta empleada para una firma es poco deseable puesto que debilita la seguridad de las firmas realizadas con ella; podría falsificarse una firma por alguien que posea la clave y que no sea su propietario.

Por todas estas razones, el método de clave pública para generar y verificar firmas ofrece la solución más conveniente en la mayoría de las situaciones.

Existe una excepción cuando se utiliza un canal seguro para transmitir los mensajes desencriptados pero subsiste la necesidad de verificar la autenticidad de los mensajes. Dado que un canal seguro proporciona comunicaciones seguras entre pares de procesos, se puede establecer una clave secreta empleando el método híbrido indicado en la Sección 7.3.3 y así producir firmas de coste bajo. Estas firmas se denominan *códigos de autenticación de mensajes* (*message authentication codes*, MAC) para reflejar su objetivo más limitado: autentican la comunicación entre pares de principales basándose en un secreto compartido.

En la Figura 7.12 se ilustra una técnica de firmado de bajo coste basada en claves secretas que da una seguridad suficiente para muchos propósitos, y que se bosqueja a continuación. El método depende de la existencia de un canal seguro por el que se puede distribuir la clave compartida:

1. A genera una clave aleatoria K para firmar, y la distribuye utilizando canales seguros a uno o más principales que necesiten autenticar los mensajes recibidos de A. Se *confía* en que los principales no descubran la clave compartida.
2. Para cualquier documento M que A desee firmar, A concatena M con K , calcula el resumen del resultado: $h = H(M + K)$ y envía el documento firmado $[M]_K = M, h$ a cualquiera que desee verificar la firma (el resumen h es un MAC). K no queda comprometida por la publicación de h , dado que la función de dispersión oscurece totalmente su valor.
3. El receptor, B, concatena la clave secreta K con el documento recibido M y calcula el resumen $h' = H(M + K)$. La firma es válida si $h = h'$.

Aun cuando este método sufre de las desventajas indicadas anteriormente, tiene la ventaja de sus buenas prestaciones porque no involucra encriptación alguna. (La dispersión segura es aproximadamente de 3 a 10 veces más rápida que la encriptación simétrica, véase la Sección 7.6.3.) El protocolo de canal seguro SSL descrito en la Sección 7.6.3 soporta el uso de una amplia variedad

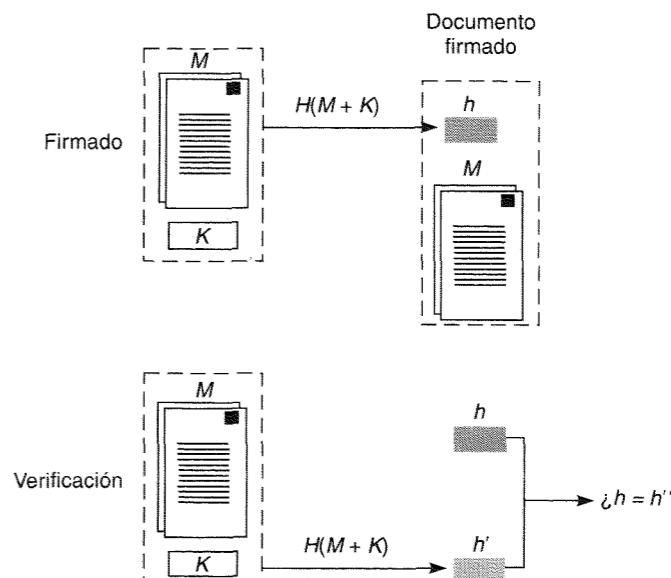


Figura 7.12. Firmas de pequeño coste con una clave secreta compartida.

de MAC incluyendo el esquema que aquí se describe. Este método también se emplea en el protocolo de dinero electrónico Millicent que se describe en la Sección 7.6.4, donde es muy importante mantener bajo el coste de procesamiento para transacciones de bajo valor.

7.4.3. FUNCIONES DE RESUMEN SEGURO

Hay muchas formas de producir un patrón de bits de longitud fija que caracterice un mensaje o documento de longitud arbitraria. Quizás la más simple es utilizar repetidamente la operación XOR para combinar trozos de tamaño fijo del documento fuente. Tal función se emplea a menudo en protocolos de comunicación para producir un patrón de dispersión de longitud fija para caracterizar un mensaje con fines de detección de errores; pero este sistema es inadecuado como base de un esquema de firma digital. Una función de resumen segura $h = H(M)$ debería poseer las siguientes propiedades:

1. Dado M , debe ser fácil calcular h .
2. Dado h , debe ser extremadamente difícil calcular M .
3. Dado M , debe ser extremadamente difícil encontrar otro mensaje M' , tal que $H(M) = H(M')$.

Tales funciones se denominan también *funciones de dispersión de un solo sentido*. La razón de este nombre es evidente por sí misma si vemos las dos primeras propiedades. La propiedad 3 requiere una característica adicional: incluso aunque conozcamos que la aplicación de la función de dispersión no dé un valor único (porque el resumen es una transformación de reducción de información), necesitamos asegurarnos que un atacante, dado un mensaje M que produce un valor h , no pueda descubrir otro mensaje M' que también produzca h . Si un atacante pudiera hacer esto, podría falsificar un documento firmado M' sin tener que conocer la clave de la firma, simplemente copiando la firma del documento firmado M y añadiéndosela a M' .

Desde luego, el conjunto de mensajes que se aplican sobre el mismo valor está restringido y el atacante lo tendría difícil para producir una falsificación con sentido, pero con paciencia podría hacerse, de modo que hay que prevenirlo. La posibilidad de conseguirlo aumenta considerablemente si se emplea el denominado *ataque del cumpleaños* (*birthday attack*):

1. Alice prepara dos versiones M y M' de un contrato para Bob. M es favorable a Bob y M' no.
2. Alice consigue varias versiones sutilmente diferentes de M y M' que aparenten ser visualmente la misma, añadiendo espacios al final de las líneas, etc. Ella compara los valores de dispersión de todos los M con la de todos los M' . Si encuentra dos que sean las mismas, ella puede seguir adelante; si no, sigue produciendo versiones visualmente indistinguibles hasta que encuentra dos adecuadas.
3. Cuando ya tiene un par de documentos M y M' que proyectan el mismo valor, le da el documento favorable M a Bob para que lo firme con una firma digital utilizando la clave privada de él. Cuando lo devuelve, ella intercambia el contenido por la versión M' , manteniendo la firma de M .

Si nuestros valores de dispersión tienen un tamaño de 64 bits, sólo necesitamos 2^{32} versiones de M y M' por término medio. Es demasiado poco para quedar conforme. Al menos necesitamos que nuestros valores de dispersión tengan 128 bits para alejar el peligro de este ataque.

El ataque descansa sobre la paradoja estadística conocida como la paradoja del cumpleaños: la probabilidad de encontrar un par idéntico en un conjunto dado es mucho mayor que la de encontrar la pareja para un individuo dado. Stallings [1999] da una derivación estadística para la probabilidad de que haya dos personas con la misma fecha de nacimiento al considerar un conjunto de n personas. El resultado es que para un conjunto de sólo 23 personas la probabilidad es del 50 por

ciento, mientras que para que la probabilidad de que una persona haya nacido cierto día sea también del 50 por ciento se requieren 253 personas.

Para satisfacer las propiedades indicadas arriba, hay que diseñar la función de resumen segura cuidadosamente. Las operaciones al nivel de bit empleadas y su secuenciación son similares a las que se encuentran en la criptografía simétrica, pero en este caso las operaciones no tienen por qué preservar la información, dado que la función no tiene por qué ser reversible en absoluto. De modo que una función de resumen segura puede emplear cualquier operación aritmética y lógica al nivel de bit. La longitud del texto fuente se incluye habitualmente entre los datos resumidos.

Dos funciones de resumen ampliamente utilizadas son el algoritmo MD5 (llamado así porque es el quinto de una serie de algoritmos de resumen desarrollados por Ron Rivest) y el SHA (*Secure Hash Algorithm*) adoptado para su estandarización por el NIST. Ambos han sido probados y analizados cuidadosamente, y puede considerarse que son apropiadamente seguros durante el futuro previsible, al mismo tiempo que sus implementaciones son razonablemente eficientes. Las describimos brevemente aquí. Schneier [1996] y Mitchell y otros [1992] informan en profundidad de las técnicas de firma digital y las funciones de resumen de mensajes.

◊ **MD5.** El algoritmo MD5 [Rivest 1992] emplea cuatro vueltas, cada una aplicando una de cuatro funciones no lineales a cada uno de los diecisésis segmentos de 32 bits de un bloque de texto fuente de 512 bits. El resultado es un resumen de 128 bits. MD5 es uno de los algoritmos más eficientes de que se dispone hoy en día.

◊ **SHA.** SHA [NIST 1995] es un algoritmo que produce un resumen de 160 bits. Se basa en el algoritmo de Rivest MD4 (similar a MD5) con algunas operaciones adicionales. Es sustancialmente más lento que MD5, pero el resumen de 160 bits ofrece una mayor seguridad contra los ataques por fuerza bruta y del cumpleaños.

◊ **Empleo de un algoritmo de encriptación para obtener un resumen.** Es posible utilizar un algoritmo de encriptación simétrico tales como los detallados en la Sección 7.3.1 para producir un resumen seguro. En este caso, la clave debería ser pública de modo que el algoritmo pudiera ser aplicado por cualquiera que deseara verificar una firma digital. El algoritmo de encriptado se emplea en modo CBC, y el resumen es el resultado de combinar el penúltimo valor CBC con el bloque final encriptado.

7.4.4. ESTÁNDARES DE CERTIFICACIÓN Y AUTORIDADES DE CERTIFICACIÓN

X.509 es el formato estándar de certificación más ampliamente usado [CCITT 1988b]. A pesar de que el formato de certificación X.509 es parte del estándar X.500 para la construcción de directorios globales de nombres y atributos [CCITT 1988a], se emplea habitualmente en el mundo criptográfico como una definición de formato para certificados aislados. Describiremos el estándar de nombres X.500 en el Capítulo 9.

La estructura y contenido de un certificado X.509 se muestra en la Figura 7.13. Como puede verse, se enlaza una clave pública a una entidad con nombre denominada *sujeto*. El enlace está en la firma, que es emitida por otra entidad denominada *emisora*. El certificado tiene un *periodo de validez*, que es definido mediante dos fechas. Los contenidos etiquetados como <Nombre Diferenciado> se refieren al nombre de una persona, organización o cualquier otra entidad junto con suficiente información contextual para darlo por único. En una implementación completa X.500 esta información contextual podría obtenerse de una jerarquía de directorio en la que aparezca la entidad nombrada, pero en ausencia de una implementación X.500 completa sólo puede usarse como una cadena descriptiva.

Este formato se incluye en el protocolo SSL para comercio electrónico y de amplia implantación en la autenticación de claves públicas de servicios y sus clientes. De hecho ciertas compañías

Sujeto	Nombre Diferenciado, Clave pública
Emisor	Nombre Diferenciado, Firma
Período de validez	Fecha inicio, Fecha expiración
Información administrativa	Versión, Número de Serie
Información añadida	

Figura 7.13. Formato de Certificado X.509.

y organizaciones de relieve en Internet se han establecido ellas mismas como *autoridades de certificación* (por ejemplo Verisign [www.verisign.com], CREN [www.cren.net]), y otras compañías e individuos pueden obtener certificados de clave pública X.509 de los anteriores remitiéndoles alguna evidencia satisfactoria de su identidad. Esto nos conduce a un procedimiento de verificación de dos pasos para cualquier certificado X.509:

1. Obtener el certificado de clave pública del emisor (una autoridad de certificación) desde una fuente fiable.
2. Validar la firma.

◊ **Aproximación SPKI.** La aproximación X.509 se basa en la unicidad global de los nombres diferenciados. Ya se ha indicado que esta meta es inalcanzable dado que no refleja la realidad actual legal y de la práctica comercial [Ellison 1996] en la que no se presupone la unicidad de la identidad de los individuos si no se hace referencia a otras personas y organizaciones. Esto se pone en evidencia, por ejemplo, en el uso de un permiso de conducción o una carta de un banco para autenticar el nombre y dirección de un individuo (un nombre a secas puede estar repetido si consideramos la población mundial). Esto nos lleva a cadenas de verificación más largas, puesto que hay muchos emisores posibles de certificados de clave pública, y sus firmas deben validarse a través de una cadena de verificación que nos lleve a alguien conocido en quien confíe el principal que realiza la verificación. A pesar de ello la verificación resultante suena más convincente, y muchos de los pasos de esta cadena pueden guardarse para acortar el proceso en otras ocasiones.

Los argumentos de arriba son la base de las propuestas recientemente desarrolladas para la Infraestructura de Clave Pública Simple (*Simple Public-key Infrastructure*, SPKI) (véase RFC 2693 [Ellison y otros 1999]). Éste es un esquema para la creación y administración de conjuntos de certificados públicos. Posibilita el procesamiento de cadenas de certificaciones empleando inferencia lógica para producir certificados derivados. Por ejemplo, «Bob cree que la clave pública de Alice es $K_{A\text{pub}}$ » y «Carol confía en la clave de Alice que tiene Bob» implica que «Carol cree que la clave pública de Alice es $K_{A\text{pub}}$ ».

7.5. PRAGMÁTICA DE LA CRIPTOGRAFÍA

En la Sección 7.5.1, compararemos las prestaciones de la encriptación y los algoritmos de dispersión seguros descritos o mencionados anteriormente. Consideramos los algoritmos de encriptación al mismo tiempo que las funciones de dispersión seguras porque la encriptación puede usarse también como un método de firma digital.

En la Sección 7.5.2, discutiremos algunas cuestiones no técnicas que rodean al uso de la criptografía. No hay espacio suficiente que haga justicia a la enorme cantidad de discusión política que ha tenido lugar sobre este tema desde que aparecieron en el dominio público los primeros algoritmos criptográficos robustos, aunque los debates no hayan alcanzado muchas conclusiones definitivas. Nuestro objetivo es, meramente, hacer tomar conciencia al lector de este debate en curso.

	Tamaño de clave/tamaño de dispersión (bits)	Velocidad extrapolada (kbytes/sec)	PRB optimizado (kbytes/s)
TEA	128	700	—
DES	56	350	7.746
Triple-DES	112	120	2.842
IDEA	128	700	4.469
RSA	512	7	—
RSA	2.048	1	—
MD5	128	1.740	62.425
SHA	160	750	25.162

Figura 7.14. Prestaciones de los algoritmos de encriptación y resúmenes seguros.

7.5.1. PRESTACIONES DE LOS ALGORITMOS CRIPOTOGRAFICOS

La Figura 7.14 muestra el tamaño de la clave (o el tamaño del resultado en el caso de funciones de resumen seguras) y la velocidad de los algoritmos de encriptación y las funciones de resumen seguras que hemos discutido en este capítulo. Donde sea posible, damos dos medidas de velocidad; las que aparecen bajo el título «velocidad extrapolada» están basadas en cifras de Schneier (excepto para TEA, que se basan en [Wheeler y Needham 1994]). Bajo el título «PRB optimizado» se basan en las publicadas en [Preneel y otros 1998]. En ambos casos hemos ajustado las cifras para tener en cuenta los avances en las prestaciones de los procesadores entre esa fecha y últimos del año 1999; los números pueden tomarse como estimaciones aproximadas de las prestaciones de los algoritmos sobre un procesador Pentium II a 330 MHz. Las longitudes de las claves dan una indicación aproximada de la fortaleza de los algoritmos; en realidad sólo proporciona una indicación del coste computacional de un ataque por fuerza bruta sobre la clave; la auténtica resistencia de los algoritmos criptográficos es mucho más difícil de evaluar y descansa sobre razonamientos acerca del éxito de cada algoritmo para oscurecer el texto en claro. La gran diferencia entre las dos columnas de prestaciones proviene del hecho de que las cifras dadas por Schneier están basadas en el código C publicado en [Schneier 1996], sin ningún intento de optimizar el código, mientras que las cifras del PRB son el resultado de un sustancial esfuerzo para producir implementaciones propietarias, optimizadas, de los algoritmos en lenguaje ensamblador. Preneel y otros [1998] presentan una discusión útil sobre la resistencia y prestaciones de los principales algoritmos simétricos.

Sólo hemos presentado cifras de prestaciones para el software. En la práctica se realizan esfuerzos considerables para producir implementaciones de altas prestaciones y bajo coste (un solo chip) y de ellas cabe esperar prestaciones mucho mayores.

7.5.2. APPLICACIONES DE LA CRIPTOGRAFÍA Y OBSTÁCULOS POLÍTICOS

Todos los algoritmos anteriormente descritos emergen durante los años ochenta y noventa, cuando comienzan a utilizarse las redes de computadores con objetivos comerciales y se hizo evidente que las necesidades de seguridad eran una cuestión importante. Tal y como mencionamos en la introducción de este capítulo, la emergencia del software criptográfico tuvo una fuerte resistencia del gobierno de los EE.UU. La oposición tuvo dos orígenes, la Agencia de Seguridad Nacional (*National Security Agency*, NSA) que urgía una política para restringir la robustez de la criptografía disponible a otras naciones a un nivel en el que el NSA pudiera desencriptar cualquier comunicación

ción de que los canales de comunicación secretos pueden ser de mucha utilidad a criminales de todo tipo. Históricamente, los gobiernos han tenido los medios de interceptar y analizar las comunicaciones públicas. La criptografía fuerte altera radicalmente esa situación. Pero estas propuestas para legislar con el fin de prevenir el uso de criptografía fuerte no comprometida han tenido una fuerte oposición desde los grupos de ciudadanos para las libertades civiles, preocupados por su impacto en los derechos a la privacidad de los ciudadanos. Hasta el momento, no se ha adoptado ninguna de estas propuestas legislativas, pero los esfuerzos políticos continúan y la eventual introducción de un marco legal para el uso de la criptografía parece algo inevitable.

7.6. CASOS DE ESTUDIO: NEEDHAM-SCHROEDER, KERBEROS, SSL Y MILLICENT

Los protocolos de autenticación publicados originalmente por Needham y Schroeder [1978] son el núcleo de muchas técnicas de seguridad. Se presentan con detalle en la Sección 7.6.1. Una de las aplicaciones más importantes de su protocolo de autenticación de clave secreta es el sistema Kerberos [Steiner y otros 1988], que es sujeto de nuestro segundo caso de estudio (Sección 7.6.2). Kerberos se diseñó para proporcionar autenticación entre clientes y servidores en redes que constituyan un único dominio de administración (intranets).

También presentamos dos casos de estudio que describen protocolos de seguridad en el nivel de aplicación y que son importantes para el comercio electrónico. El primer caso de estudio del nivel de aplicación trata con el protocolo de Capa de Sockets Segura (*Secure Sockets Layer, SSL*). Se diseñó específicamente para cumplimentar la necesidad de transacciones seguras. Hoy en día está soportada por la mayoría de los visualizadores y servidores web, y se emplea en la mayoría de las transacciones comerciales que tienen lugar vía Web. Nuestro segundo caso de estudio describe el protocolo Millicent, diseñado específicamente para las necesidades de un método de pago para micro-transacciones.

7.6.1. EL PROTOCOLO DE AUTENTICACIÓN DE NEEDHAM Y SCHROEDER

Los protocolos aquí descritos se desarrollaron en respuesta a la necesidad de medios seguros para tratar con claves (y passwords) en una red. En el momento de su publicación [Needham y Schroeder 1978], los servicios de archivos en red estaban justo empezando y había una necesidad urgente de mejores formas de administrar la seguridad de las redes locales.

En redes integradas con fines de administración, esta necesidad se cumplimenta mediante el uso de un servicio de claves seguras que envía claves de sesión bajo la forma de desafíos (véase la Sección 7.2.2). Éste es el objetivo del protocolo de clave secreta desarrollado por Needham y Schroeder. En la misma publicación, Needham y Schroeder también confeccionan un protocolo basado en el uso de claves públicas para autenticación y distribución de claves y que no depende de la existencia de servidores de claves seguros, y de este modo es más adecuado para su empleo en redes con muchos dominios de administración independientes, como Internet. No describimos aquí la versión de clave pública, pero el protocolo SSL que se describe en la Sección 7.6.3 es una variación de éste.

Needham y Schroeder propusieron una solución a la autenticación y la distribución de claves basada en un *servidor de autenticación* que proporciona claves secretas a sus clientes. El trabajo del servidor de autenticación es proporcionar una forma segura por la que pares de procesos obtengan claves compartidas. Para hacer esto, debe comunicarse con sus clientes usando mensajes encriptados.

◇ **Needham y Schroeder con claves secretas.** En su modelo, un proceso que represente a un principal A que desee iniciar una comunicación segura con otro proceso que represente al principal B puede obtener una clave con este fin. El protocolo se describe para dos procesos arbitrarios A y B, pero en sistemas cliente-servidor, A es cualquier cliente que inicie una secuencia de solicitudes hacia algún servidor B. La clave le viene dada a A de dos formas, una que A puede usar para encriptar los mensajes que envíe a B y otra que pueda transmitir de modo seguro a B. (La última se encuentra encriptada en una clave que es conocida por B pero no por A, de modo que B puede desencriptarla y no se compromete durante la transmisión.)

El servidor de autenticación S mantiene una tabla que contiene un nombre y una clave secreta para cada principal conocido por el sistema. La clave secreta se emplea sólo para autenticar los procesos del cliente frente al servidor de autenticación y para transmitir mensajes de modo seguro entre procesos cliente y el servidor de autenticación. Nunca se muestra a terceras partes y se transmite por la red como máximo una sola vez, cuando se genera. (Idealmente, sólo se debería transmitir por otros mecanismos, como en papel o de forma verbal, evitando cualquier exposición a la red.) Una clave secreta sería el equivalente de la contraseña (*password*) que se emplea para autenticar usuarios en los sistemas centralizados. Para los principales humanos, el nombre conocido por el servicio de autenticación es su «nombre de usuario» y la clave secreta es su password. El proceso cliente que actuará como representante del usuario le pedirá ambos.

El protocolo se basa en la generación y transmisión de tickets por el servidor de autenticación. Un ticket es un mensaje encriptado que contiene una clave secreta para su uso en la comunicación entre A y B. En la Figura 7.15 tabulamos los mensajes del protocolo de clave secreta de Needham y Schroeder. El servidor de autenticación es S.

N_A y N_B son *ocasiones*. Una ocasión es un valor entero que se añade a un mensaje para demostrar su frescura. Las ocasiones se utilizan una sola vez y se generan bajo demanda. Por ejemplo, se pueden generar ocasiones mediante una secuencia de valores enteros o leyendo el reloj de la máquina emisora.

Si el protocolo se completa con éxito, tanto A como B pueden estar seguros de que cualquier mensaje encriptado con K_{AB} que se recibe proviene del otro, y que cualquier mensaje encriptado con K_{AB} que se envía puede ser entendido por el otro y sólo por éste (además de S, que se supone que es de fiar). Esto es así porque los únicos mensajes que han sido enviados conteniendo K_{AB} fueron encriptados en la clave secreta de A o en la de B.

Encabezado	Mensaje	Anotaciones
1. A → S:	A, B, N_A	A solicita a S una clave para comunicarse con B.
2. S → A:	$\{N_A, B, K_{AB}, \{K_{AB}, A\}_{K_B}\}_{K_A}$	S retorna un mensaje encriptado en la clave secreta de A, que contiene una clave nueva K_{AB}' , y un «ticket» encriptado en la clave secreta de B. La ocasión N_A demuestra que el mensaje fue enviado en respuesta a la anterior. A cree que S envió el mensaje porque sólo S conoce la clave secreta de A.
3. A → B:	$\{K_{AB}', A\}_{K_B}$	A envía el «ticket» a B.
4. B → A:	$\{N_B\}_{K_{AB}}$	B desencripta el ticket y usa la nueva clave K_{AB} para encriptar otra ocasión N_B .
5. A → B:	$\{N_B - 1\}_{K_{AB}}$	A demuestra a B que fue el emisor del mensaje anterior devolviendo una transformación acordada sobre N_B .

Figura 7.15. Protocolo de autenticación de clave secreta de Needham-Schroeder.

Existe una debilidad en este protocolo en la que B no encuentre razones para creer que el mensaje 3 sea reciente. Un intruso que se las apañe para obtener la clave K_{AB} y que haga una copia del ticket y del autenticador $\{K_{AB}, A\}_{K_B}$ (cualquiera de los cuales podría haberse dejado en un área de almacenamiento desprotegida debido a un descuido o a un programa de cliente fallido que se ejecutara bajo la autoridad de A), podría utilizarlos para iniciar un intercambio posterior con B, suplantando a A. Para que ocurra este ataque debe comprometerse un antiguo valor de K_{AB} ; en terminología de hoy en día, Needham y Schroeder no incluyeron esta posibilidad en su lista de amenazas, y la opinión consensuada es que uno debería hacerlo. La debilidad puede remediarla añadiendo una ocasión o una marca temporal mensaje 3, de modo que se convierte en: $\{K_{AB}, A, t\}_{K_B pub}$. B desencripta este mensaje y comprueba que t es reciente. Ésta es la solución adoptada en Kerberos.

7.6.2. KERBEROS

Kerberos se desarrolló en el MIT en los años ochenta [Steiner y otros 1988] para proporcionar un catálogo de medios de autenticación y seguridad para su uso en la red de computación del campus en el MIT y otras intranets. Ha soportado varias revisiones y mejoras a la luz de la experiencia y la realimentación de las organizaciones de usuarios. La versión 5 de Kerberos [Neumann y T'so 1994], que describimos aquí, está en vías de ser un estándar Internet (véase el RFC 1510 [Kohl y Neuman 1993]) y es usada hoy en día por muchas compañías y universidades. El código fuente de la implementación de Kerberos está disponible desde el MIT [web.mit.edu I]; se incluye en el Entorno de Computación Distribuida de OSF (*Distributed Computing Environment*, DCE) [OSF 1997] y en el sistema operativo Windows 2000 como servicio de autenticación por defecto [www.microsoft.com II]. Se ha propuesto su extensión para incorporar el uso de certificados de clave pública para la autenticación inicial de principales (paso A de la Figura 7.16) [Neuman y otros 1999].

La Figura 7.16 muestra la arquitectura del proceso. Kerberos trata con tres clases de objetos de seguridad:

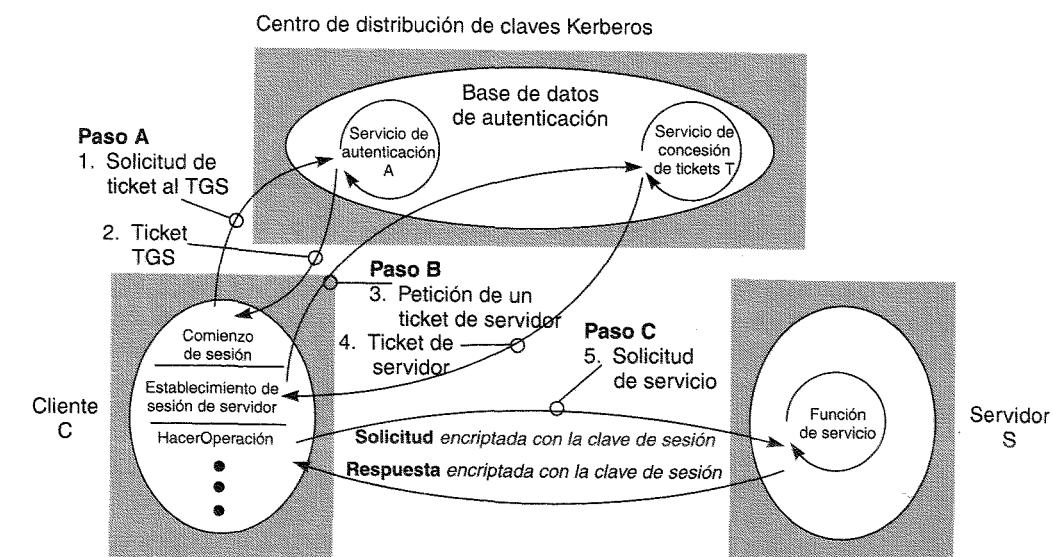


Figura 7.16. Arquitectura del sistema Kerberos.

A. Obtención de una clave de sesión Kerberos y un ticket TGS, una vez por inicio de sesión

Encabezado	Mensaje	Anotaciones
1. C → A: Solicitud de un ticket TGS	C, T, n	El cliente C pide al servidor de autenticación Kerberos A que proporcione un ticket para comunicarse con el servicio de concesión de tickets T.
2. A → C: Clave de sesión TGS y ticket	$\{K_{CT}, n\}_{KC}, \{\text{ticket}(C, T)\}_{KT}$ conteniendo C, T, t_1, t_2, K_{CT}	A retorna un mensaje que contiene un ticket encriptado en su clave secreta y una clave de sesión para que C la use con T. La inclusión de la ocasión n encriptada en K_{CS} muestra que el mensaje proviene del receptor del mensaje 1, que debe conocer K_C .

Notación:

A Nombre del servicio de autenticación Kerberos.
 T Nombre del servicio de concesión de tickets Kerberos.
 C Nombre del cliente.

n Una ocasión.
 t Una marca temporal.
 t_1 Instante de comienzo de la validez de un ticket.
 t_2 Instante de finalización de la validez de un ticket.

Al mensaje 2 se le denomina también «desafío» porque se le presenta al peticionario información que sólo tiene utilidad si conoce la clave secreta de C, K_C . Un impostor que intentara suplantar a C enviando el mensaje 1 no iría muy lejos, porque no puede desencriptar el mensaje 2. Para los principales que sean usuarios, K_C es una versión confusa de la clave de acceso del usuario. El proceso cliente pedirá que el usuario introduzca su clave de acceso e intentará desencriptar el mensaje 2 con ella. Si el usuario da la contraseña correcta, el proceso cliente obtendrá la clave de sesión K_{CT} y un ticket válido para el servicio de concesión de tickets; si no, obtendrá un texto incoherente. Los servidores tienen claves secretas de su propiedad, solamente conocidas por el proceso servidor relevante y el servidor de autenticación.

Cuando se ha obtenido un ticket válido del servicio de autenticación, el cliente C podrá usarlo para comunicarse con el servicio de concesión de tickets para obtener tickets para otros servidores cuantas veces quiera mientras no expire el ticket. Así para obtener un ticket para cualquier servidor S, C construye un autenticador encriptado en K_{CT} de la forma:

$\{C, t\}_{K_{CT}}$, que denotaremos como $\{\text{aut}(C)\}_{K_{CT}}$ y envía la solicitud a T:

B. Obtener un ticket para un servidor S, una vez por sesión cliente-servidor

3. C → T: Pedir ticket para el servicio S	$\{\text{auth}(C)\}_{K_{CT}},$ $\{\text{ticket}(C, T)\}_{KT}, S, n$	C solicita al servidor de concesión de tickets T un ticket para comunicarse con otro servidor S.
4. T → C: Servicio del ticket	$\{K_{CS}, n\}_{K_{CT}}, \{\text{ticket}(C, S)\}_{KS}$	T comprueba el ticket. Si es válido, T genera una nueva clave aleatoria de sesión K_{CS} y la devuelve junto a un ticket para S (encriptado en la clave secreta del servidor K_S).

C está listo entonces para enviar mensajes de solicitud al servidor, S:

C. Enviar una petición al servidor con un ticket

5. C → S: Solicitud de servicio	$\{auth(C)\}_{K_{CS}},$ $\{ticket(C, S)\}_{K_S}$ request, n	C envía el ticket a S con un nuevo autenticador generado para C y una petición. La petición podría estar encriptada con K_{CS} si se requiere confidencialidad.
---------------------------------------	---	---

Para que el cliente esté seguro de la autenticidad del servidor, S debiera devolver la ocasión n a C. (Para reducir el número de mensajes requerido, se podría incluir en los mensajes que contienen la respuesta del servidor a la solicitud):

D. Autenticar el servidor (opcionalmente)

6. S → C: Autenticación del servidor	$\{n\}_{K_{CS}}$	(Opcional): S envía la ocasión a C, encriptada con K_{CS} .
--	------------------	---

◊ **Aplicación de Kerberos.** Kerberos se desarrolló para su uso en el Proyecto Athena en el MIT; una infraestructura de computación en red por todo el campus, para las titulaciones de licenciatura e ingeniería, con muchas estaciones de trabajo y servidores que dan servicio a más de 5.000 usuarios. El entorno es tal que no es posible presuponer ni la confianza en los clientes ni la seguridad de la red y las máquinas que ofrecen servicios de red; por ejemplo, las estaciones de trabajo no están protegidas contra la instalación de software de sistema desarrollado por los usuarios, y las máquinas servidoras (diferentes al servidor Kerberos) no están aseguradas necesariamente contra una interferencia física con su configuración software.

Kerberos proporciona virtualmente toda la seguridad del sistema Athena. Se emplea para autenticar usuarios y otros principales. La mayoría de los servidores que operan en la red han sido extendidos para solicitar un ticket de cada cliente al comienzo de cada interacción cliente-servidor. En éstos se incluyen el almacenamiento de archivos (NFS y el sistema de archivos Andrew), correo electrónico, entrada remota en el sistema e impresión. Las claves de acceso de los usuarios son conocidas sólo por cada uno de ellos y por el servicio de autenticación Kerberos. Los servicios tienen claves secretas conocidas sólo para Kerberos y los servidores que proporcionan el servicio.

Ahora, describiremos la forma en que se aplica Kerberos a la autenticación de los usuarios al entrar en el sistema. Su empleo para asegurar el servicio de archivos NFS se describirá en el Capítulo 8.

◊ **Entrada en el sistema con Kerberos.** Cuando un usuario entra en una estación de trabajo, el programa de bienvenida envía el nombre del usuario al servicio de autenticación de Kerberos. Si el usuario es conocido al servicio de autenticación éste responde con una clave de sesión y una ocasión encriptada en su clave de acceso y un ticket para el TGS. El programa de bienvenida, ahora, intenta desencriptar la clave de sesión y la ocasión empleando la clave de acceso que deberá introducir el usuario en respuesta a una petición. Si la clave de acceso es correcta, el programa de bienvenida obtiene la clave de sesión y la ocasión. Entonces comprueba la ocasión y almacena la clave de sesión junto al ticket para ser usado posteriormente cuando se comunique con el TGS. En este momento, el programa de bienvenida puede borrar la clave de acceso del usuario de su memoria, dado que el ticket ya sirve para autenticar al usuario. En este momento se inicia la sesión del usuario en la estación del sistema. Observe que la clave del usuario nunca se expone al escrutinio en la red; se retiene en la estación de trabajo y se borra de la memoria tan pronto como se ha empleado.

◊ **Acceso a los servidores en Kerberos.** Cuando un programa en ejecución en una estación de trabajo solicita el acceso a un nuevo servicio, pide un ticket para este servicio al servicio de concesión de tickets. Por ejemplo, cuando un usuario UNIX desea acceder a un computador remoto, el mandato *rlogin* de la estación del usuario obtendrá un ticket del servicio de concesión de tickets de Kerberos para acceder al servicio de red *rlogind*. El programa del mandato *rlogin* envía el ticket, junto con un nuevo autenticador, en la petición al proceso *rlogind* del computador donde el usuario desea acceder. El programa *rlogind* desencripta el ticket con la clave secreta del servicio *rlogin* y comprueba la validez del ticket (esto es, que no haya expirado la validez del ticket). Las máquinas servidoras deben tener cuidado de almacenar sus claves secretas en un almacén que no sea accesible a los intrusos.

El programa *rlogind* usa entonces la clave de sesión incluida en el ticket para desencriptar el autenticador y comprueba que el autenticador es reciente (los autenticadores sólo pueden usarse una vez). Una vez que el programa *rlogind* se da por satisfecho, ticket y autenticador válidos, no hay necesidad de comprobar el nombre y la clave de acceso del usuario, dado que la identidad del usuario es conocida por el programa *rlogind* y consecuentemente se inicia la sesión del usuario remoto.

◊ **Implementación de Kerberos.** Kerberos se implementa como un servidor que se ejecuta sobre una máquina remota. Se proporciona un conjunto de bibliotecas para uso de las aplicaciones clientes y servicios. Se emplea el algoritmo de encriptación DES, pero se implementa en un módulo separado que puede reemplazarse fácilmente.

El servicio Kerberos es escalable; el mundo se divide en dominios de autoridades de autenticación separados, denominados *esferas* (*realms*), cada una con su propio servidor Kerberos. La mayoría de los principales están registrados en una sola esfera, pero los servidores de concesión de tickets de Kerberos están registrados en todas las esferas. Los principales pueden autenticarse a sí mismos frente a los servidores en otros dominios a través del servidor de concesión de tickets local.

Dentro de un dominio, puede haber varios servidores de autenticación, cada uno de los cuales tiene copias de la misma base de datos de autenticación. La base de datos de autenticación se replica mediante una simple técnica maestro-esclavo. Las actualizaciones se aplican a la copia maestra por un único servicio de Administración de Base de Datos Kerberos (*Kerberos Database Management*, KDBM) que se ejecuta sólo en la máquina maestra. El KDBM maneja las solicitudes de cambio de claves de acceso de los usuarios y las peticiones de los administradores para añadir o borrar principales y para cambiar sus claves de acceso.

Para hacer transparente este esquema a los usuarios, el tiempo de vida de los tickets TGS debería ser tan largo como la sesión de usuario más larga posible, dado que el uso de un ticket expirado trae consigo el rechazo de las solicitudes de servicio, y el único remedio es que el usuario re-autentifique su entrada y pida nuevos tickets de servidor para todos los servicios en uso. En la práctica, el período de vida de un ticket suele ser de 12 horas.

◊ **Críticas a Kerberos.** El protocolo de la versión 5 de Kerberos que se ha descrito contiene varias mejoras diseñadas para resolver las críticas de versiones anteriores [Bellovin y Merritt 1990, Burrows y otros 1990]. La crítica más importante de la versión 4 consiste en que las ocasiones usadas en los autenticadores se implementan como marcas temporales, y la protección contra el re-envío de autenticadores depende de una cierta, aunque relajada, sincronización del reloj de los clientes y los servidores. En consecuencia si se empleara un protocolo de sincronización para acoplar ligeramente la sincronía de los relojes de clientes y servidores; este mismo protocolo debería asegurarse contra ataques de seguridad. Véase el Capítulo 10 para información sobre protocolos de sincronización.

La definición de protocolo de la versión 5 permite que las ocasiones de los autenticadores se implementen como marcas temporales o como una secuencia de números. En ambos casos, se re-

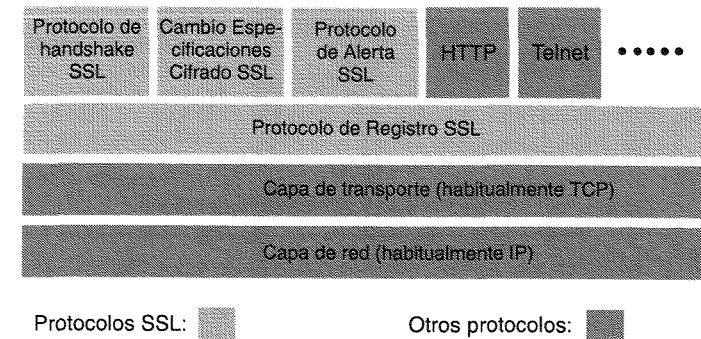


Figura 7.17. Pila de protocolos de SSL.

(Las figuras en esta sección están basadas sobre los diagramas en Hirsch [1997] y han sido publicadas con el permiso de Frederick Hirsch.)

handshake y otros dos protocolos relacionados que establecen y mantienen una sesión SSL (esto es, un canal seguro) entre un cliente y un servidor. Ambos están implementados habitualmente mediante bibliotecas software en el nivel de aplicación en el cliente y en el servidor. El protocolo de registro de SSL es una capa de nivel de sesión; puede emplearse para transportar datos del nivel de aplicación de modo transparente entre un par de procesos mientras garantiza su privacidad, integridad y autenticidad. Éstas son exactamente las propiedades que especificábamos para los canales seguros en nuestro modelo de seguridad (véase la Sección 2.3.3), pero en SSL hay opciones para que los participantes de la comunicación escogen si desplegar o no la desencriptación y autenticación de los mensajes en cada dirección. A cada sesión segura se le da un identificador y cada participante puede almacenar los identificadores de sesión en una caché para su uso subsiguiente, evitando la sobrecarga de establecer una nueva sesión cuando se requiere otra sesión segura con el mismo compañero.

SSL se usa ampliamente para añadir una capa de comunicación segura a los protocolos del nivel de aplicación existentes. El protocolo se publicó por primera vez en 1994, al que se añadieron revisiones hasta producir dos versiones posteriores. SSL 3.0 es el tema de una propuesta de estandarización [Netscape 1996]. Su uso más extendido es, probablemente, la seguridad de las interacciones HTTP en el comercio en Internet, aunque también se usa en otras aplicaciones sensibles a la seguridad. Se encuentra implementado en virtualmente todos los visualizadores y servidores web: el uso del prefijo de protocolo *https*: en un URL inicia el establecimiento de un canal seguro SSL entre un navegador y un servidor web. También se ha empleado para proporcionar implementaciones seguras de Telnet, FTP y muchos otros protocolos de aplicación. SSL es el estándar *de facto* para su uso en aplicaciones que requieran canales seguros, y existe un amplio catálogo de implementaciones disponibles, tanto comerciales como de dominio público, con interfaces de programación para CORBA y Java.

El protocolo de handshake para SSL se muestra en la Figura 7.18. El handshake se realiza sobre una conexión existente. Comienza con texto en claro y establece una sesión SSL intercambiando las opciones y parámetros acordados que se necesitan para realizar la encriptación y la autenticación. La secuencia de handshake varía dependiendo de si se requiere, o no, autenticación de cliente y servidor. El protocolo de handshake puede invocarse también más tarde para cambiar la especificación de un canal seguro, por ejemplo, la comunicación podría comenzar con un mensaje de autenticación empleando sólo códigos de autenticación de mensajes. En un punto posterior se puede añadir encriptación. Esto se obtiene efectuando el protocolo de handshake de nuevo para negociar una nueva especificación de encriptado usando el canal existente.

El handshake inicial de SSL es potencialmente vulnerable a los ataques del *hombre entre medias*, como se describe en el escenario 3 de la Sección 7.2.2. Para protegerse de él, la clave pública

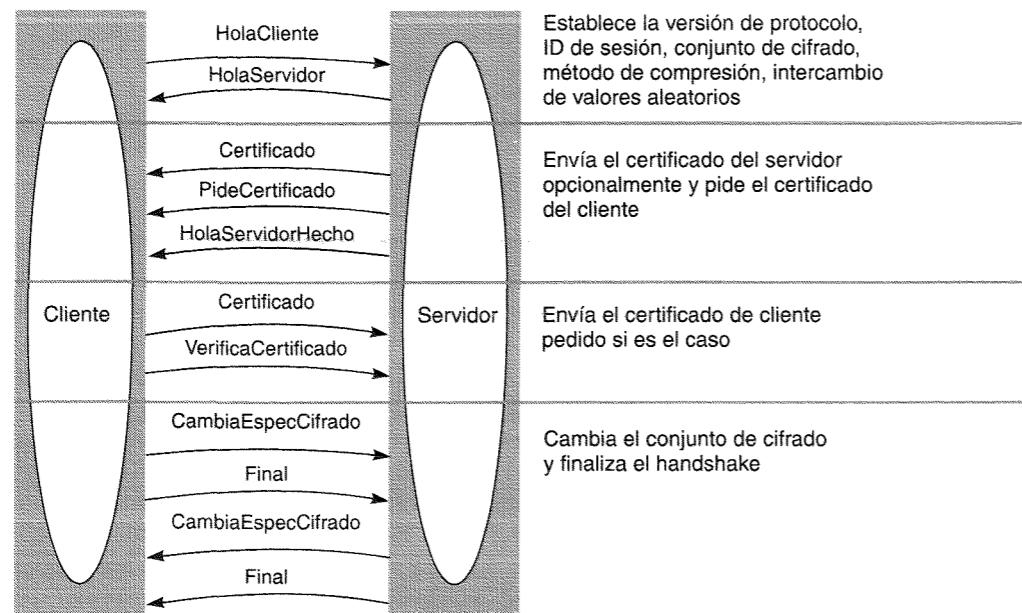


Figura 7.18. Protocolo de handshake de SSL.

usada para verificar el primer certificado recibido podría recibirse por un canal separado; por ejemplo, los navegadores y otros programas de Internet instalados desde CD-ROM pueden incluir un conjunto de claves públicas para algunas autoridades de certificado bien conocidas. Otra defensa para los clientes de servicios bien conocidos se basa en la inclusión del nombre de dominio del servicio en sus certificados de clave pública; los clientes sólo debieran tratar con servicios en los que su dirección IP se corresponda con su nombre de dominio.

SSL soporta una variedad de opciones de funciones criptográficas. El nombre colectivo que recibe es *catálogo de cifrado*. Un catálogo de cifrado incluye una elección única para cada una de las características que se muestran en la Figura 7.19.

Se suelen encontrar ya cargadas cierta variedad usual de catálogos de cifrado, con identificadores estándar tanto en el cliente como en el servidor. Durante el handshake, el servidor ofrece al cliente una lista de los identificadores de catálogos de cifrado disponibles, y el cliente responde seleccionando uno de ellos (o dando una indicación de error si no coincide con ninguno). En esta etapa también deben acordar (opcionalmente) un método de compresión y un valor de arranque aleatorio para las funciones de encriptación de bloque CBC (véase la Sección 7.3).

A continuación, los participantes deben autenticarse opcionalmente uno a otro intercambiando certificados de clave pública en el formato X.509. Estos certificados pueden obtenerse de una auto-

Componente	Descripción	Ejemplo
Método de intercambio de clave	El método que se usará para intercambiar una clave de sesión	RSA con certificados de clave pública
Cifrado para la transferencia de datos	El cifrador de bloque o de caudal que se usará para los datos	IDEA
Función de resumen de mensajes	Para crear los códigos de autenticación de mensajes (MAC)	SHA

Figura 7.19. Opciones de configuración del handshake de SSL.

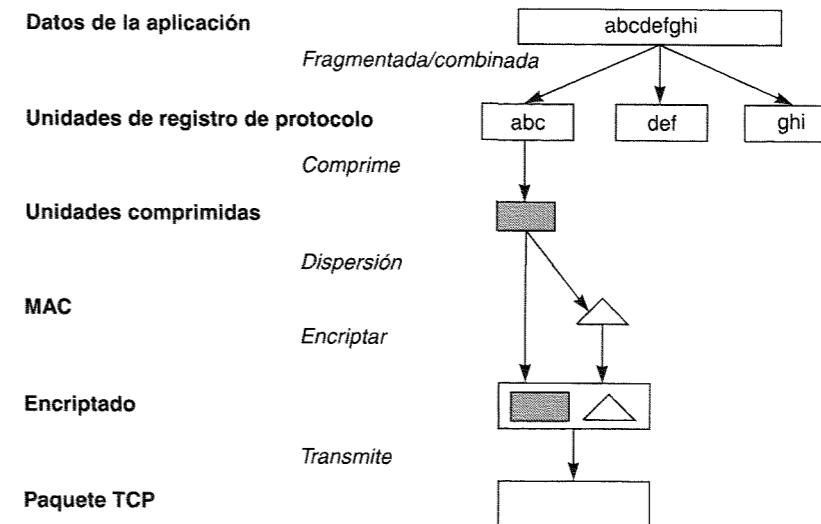


Figura 7.20. Protocolo de registro de seguridad de SSL.

ridad de clave pública o pueden generarse simplemente de modo temporal con este fin. De cualquier manera, debe haber al menos una clave pública para ser usada en la siguiente etapa del handshake.

Un participante genera entonces un *secreto pre-maestro* y lo envía encriptado con la clave pública al otro participante. Un secreto pre-maestro es un valor aleatorio grande con el que ambos participantes generan las dos claves de sesión (llamadas claves de *escritura*) para encriptar los datos en cada dirección y los secretos de autenticación de mensajes que habrá que usar para la autenticación de los mensajes. Cuando se ha hecho esto comienza una sesión segura. Ésta se inicia mediante los mensajes *CambiaEspecCifrado* que se intercambian entre los participantes. A los cuales siguen los mensajes *Final*. Una vez que se han intercambiado los mensajes *Final*, toda comunicación posterior se encripta y se firma con las claves acordadas y según el catálogo de cifrado elegido.

La Figura 7.20 muestra la operación del protocolo de registro. Un mensaje a transmitir se fragmenta inicialmente en bloques de un tamaño manejable, y opcionalmente después se comprimen. La compresión no es estrictamente una característica de la comunicación segura, pero se incorpora aquí para sacar provecho del procesamiento masivo de datos que se genera en los algoritmos de encriptación y firma digital. En otras palabras, dentro de la capa SSL de registro se puede establecer conjuntamente un flujo de transformaciones sobre los datos mucho más eficiente que si se realizaran individualmente.

Las transformaciones de encriptado y autenticación de mensajes (MAC) lanzan los algoritmos especificados en el catálogo de cifrado acordado, tal y como se describe en las Secciones 7.3.1 y 7.4.2. Finalmente, el bloque firmado y encriptado se transmite al destinatario mediante la conexión TCP asociada, donde se invierten las transformaciones para producir el bloque de datos originales.

◊ **Resumen.** SSL proporciona una implementación práctica de un esquema de encriptación híbrido con autenticación e intercambio de claves basado en claves públicas. Dado que los cifradores se negocian en la etapa de handshake, no depende de la disponibilidad de ningún algoritmo en particular. Tampoco depende de servicios de seguridad en el momento de establecer la sesión. El único requisito es que los certificados de clave pública enviados por una autoridad sean reconocidos por ambas partes.

Ya que se hicieron públicos tanto el protocolo como una implementación de referencia [Netscape 1996], fue tema de revisión y debate. Se hicieron algunas enmiendas a los primeros diseños, y fue apoyado ampliamente como un valioso estándar. SSL se integra, hoy en día, en la mayoría de los visualizadores y servidores web, así como en otras aplicaciones como Telnet y FTP seguros. Hay disponibles implementaciones comerciales y de dominio público [www.rsasecurity.com, Hirsch 1997, www.openssl.org] en forma de bibliotecas y conectores para navegadores web.

7.6.4. TRANSACCIONES ELECTRÓNICAS DE PEQUEÑO IMPORTE: EL PROTOCOLO MILLICENT

Un requisito de los sistemas de pago seguro en Internet es que sea económico y conveniente para la compra de servicios de importe pequeño y el acceso a recursos electrónicos con precios en el rango de 0,1 a 100 céntimos, por ejemplo para cobrar el acceso a páginas web, transmisiones de correo electrónico o llamadas de teléfono por Internet. La mayoría de los esquemas de pago tales como transacciones de tarjeta de crédito son demasiado caros para estos propósitos.

Aquí describimos la solución que ofrece el esquema Millicent [Glassman y otros 1995]. El esquema emplea la forma simple de una firma digital basada en clave secreta para reducir su coste computacional. Sólo se empleará la encriptación cuando se requiera privacidad.

◊ **Sistemas de pago actual y sus desventajas.** Los autores del protocolo Millicent han resumido las desventajas de los métodos de pago disponibles actualmente como sigue. Todos ellos necesitan seguridad criptográfica, sus costes de comunicación y de cálculo varían pero en cualquier caso son no despreciables.

Tarjetas de crédito: El problema del empleo de tarjetas de crédito para pequeñas transacciones es el alto coste de la transacción que resulta de la necesidad de interaccionar con el sistema central de la compañía, lo cual se agrava por los costes adicionales de las transacciones electrónicas seguras y otras características como la preparación de informes para los clientes.

Los clientes mantienen cuentas con los vendedores: Los clientes necesitan establecer una cuenta con un vendedor antes de la primera transacción. Los costes de la transacción son entonces bajos, pero la sobrecarga inicial tiende a desanimar las transacciones casuales. Un vendedor debe mantener una entrada de cliente en una base de datos de cuentas durante un período bastante largo.

Acumulación de transacciones: Cuando un cliente realiza varias cuentas, el vendedor puede guardar los registros de ellas y facturarle al final del período. Esto es parecido al mantenimiento de cuentas aunque puede evitar ciertos costes iniciales. El vendedor debe mantener registros incluso de los clientes que han realizado una sola compra, y el coste de ésta podría exceder el beneficio.

Dinero digital: Al igual que el dinero convencional, el dinero digital (es decir testigos digitales de un valor, emitidos por un banco o un agente de bolsa) ofrecería un medio eficiente de pago para transacciones pequeñas, pero los desarrolladores del dinero digital deben resolver el problema del *doble gasto*. El doble gasto es una consecuencia del hecho de que el portador de un testigo digital puede realizar cualquier número de copias indetectables. En consecuencia, los testigos deben ser identificables únicamente y deben ser validados como no gastados en el momento del uso. El reto está en disponer un esquema de validación que sea escalable, fiable y económico bajo cualquier circunstancia.

◊ **El esquema Millicent.** El proyecto Millicent ha desarrollado un esquema para la distribución segura y el uso de *vales* (*scrip*): una forma especializada de dinero digital diseñada para su uso en pequeñas transacciones. El interés de Millicent para nuestro caso viene de que emplea varias técnicas de seguridad que se describen en este capítulo con un resultado que, sorprendentemente, difiere de los que hemos visto sobre SSL y otros sistemas de seguridad.

El vale es una forma de dinero digital con valor sólo para un vendedor concreto. Se diseña para ofrecer las siguientes características:

- Tiene un valor sólo para un vendedor específico.
- Sólo se puede gastar una vez.
- Es resistente a las modificaciones y difícil de falsificar.
- Sólo puede gastarlo su auténtico propietario.
- Puede producirse y validarse eficientemente.

El diseño del esquema Millicent es escalable porque cada servidor del vendedor es responsable solamente de validar el vale que ha emitido. Los clientes pueden adquirir vales directamente del vendedor, o de un intermediario que posea vales de muchos vendedores, mediante una transacción comercial.

El vale (*scrip*), la moneda específica de un vendedor presentada por Millicent, se representa mediante fichas digitales con el siguiente formato:

Vendedor	Valor	ID vale	ID cliente	Fecha de expiración	Propiedades	Certificado
----------	-------	---------	------------	---------------------	-------------	-------------

El campo de *propiedades* está disponible para los usos que determine el vendedor; por ejemplo, podría incluir el país o el estado donde reside el cliente, de forma que pueda aplicarse la tasa de impuestos apropiada. El *certificado* es una firma digital que protege todos los campos del vale contra su modificación. La firma se produce mediante un método MAC como el que se describe en la Sección 7.4.2. El objetivo del resto de los campos lo describiremos más adelante.

El vale lo generan y distribuyen *brokers*; los brokers, o intermediarios, son servidores que tratan con los vales de modo masivo, relevando a los clientes y a los servidores de algunas de las sobrecargas que implica el uso de vales. Los intermediarios intercambian vales por dinero real, comprando vales (o el derecho de generarlos) a los vendedores, con cierto descuento, y vendiéndolos a los clientes con cargo a una tarjeta de crédito u otro medio de pago. Los clientes pueden comprar vales de varios vendedores desde un solo intermediario, acumulando los cargos y el pago al final de un período.

◊ **Escenario.** Un proceso de transacción de compra electrónica con vales es como sigue: una cliente, Alice, está interesada en comprar un pequeño producto o servicio (por ejemplo una llamada telefónica o una página web) del vendedor Venetia. Alice podría poseer vales adecuados para las transacciones con Venetia que le pudieran haber sobrado de transacciones anteriores; si no, Venetia le daría un URL de un intermediario, que comercia con vales de Venetia (llamémoslos *vales-V*). Alice compra algunos vales-V de Bob.

Alice envía a Venetia una solicitud de compra, agregando un vale-V con un valor suficiente para cubrir la compra que ella desea hacer. Venetia valida el vale; comprobando que su ID-vale no está en su lista de vales gastados y que el ID-cliente del vale es el de Alice. Si el valor es mayor que el pago requerido, Venetia hace un nuevo vale para cubrir la diferencia y se lo envía de vuelta a Alice.

Los intermediarios pueden obtener vales del vendedor de muchas formas. En el caso más simple, Venetia crea vales y los vende a Bob con cierto descuento por ser una transacción masiva. Alternativamente, Venetia otorga una licencia a Bob para manufacturar vales en su lugar. Según este modelo, Venetia no es consciente del vale hasta que lo recibe como pago desde un cliente. De vez en cuando ella contacta con Bob y le envía los identificadores de los vales que ha recibido de los clientes, Bob le paga por ellos con una cierta rebaja.

◊ **Metas.** Millicent se diseñó como un sistema de dinero electrónico que evita las sobrecargas de comunicación y los retrasos asociados a los sistemas centralizados, mientras que proporciona

una seguridad adecuada para prevenir el uso fraudulento. La seguridad de los vales se basa en las firmas digitales; se emplea encriptación para mantener la privacidad sólo cuando sea necesario. Se emplea criptografía de bajo coste en comparación con el coste de las transacciones que se realizan con los vales, de modo que no merezca la pena el beneficio de criptoanalizarlo.

El esquema Millicent funciona aisladamente. Puede implementarse sin apoyo de otros servicios, como un servicio de nombres seguro, dado que no depende de la autenticación externa de la identidad de los clientes y vendedores. En su lugar, Millicent genera y distribuye claves secretas únicas para su uso por las partes de las transacciones con vales.

◊ **Implementación.** La Figura 7.21 muestra una visión general de la arquitectura. Hemos mencionado que los vales vienen firmados para protegerlos de cualquier alteración o falsificación. La firma contenida en el certificado, anexa a cada elemento del vale, se produce cuando se genera el vale, usando un *secreto de vale maestro* como clave de firmado. El método de firmado es exactamente el mismo que el método de firma MAC descrito en la Sección 7.4.2. La clave se añade a los otros campos del vale, y se usa una función de resumen segura tal como MD5 o SHA para producir un resumen de 128 bits, que se convierte en el certificado.

Antes de generar cualquier vale, un vendedor (o un intermediario con licencia de un vendedor) generará un vector de secretos maestros de vale de 64 bits. Cada secreto de esta clase sería suficiente, pero la disponibilidad de varios permite seleccionar uno nuevo cada vez para evitar su descubrimiento por accidente o en caso de un ataque con éxito.

Cada elemento del vale tiene un identificador único. Su valor incluye un *índice de secretos maestros* de 8 bits, que se emplea para seleccionar un secreto maestro del vector de secretos maestros.

Los secretos maestros son retenidos por el vendedor y se emplea uno de ellos para producir un certificado por cada elemento del vale que se genera.

Se han sugerido diversas variaciones para el protocolo Millicent, para ofrecer niveles de seguridad diferentes. En todos ellos el vendedor debe validar cada vale remitido por los clientes, que se describe a continuación.

Para validar elemento de un vale:

1. El vendedor comprueba que no ha sido falsificado o modificado por medio de una comprobación de firma para lo que emplea el secreto maestro relevante (usando el índice de secretos maestros a partir del ID-vale para seleccionarlo del vector de secretos maestros) y lo compara con la firma del certificado.

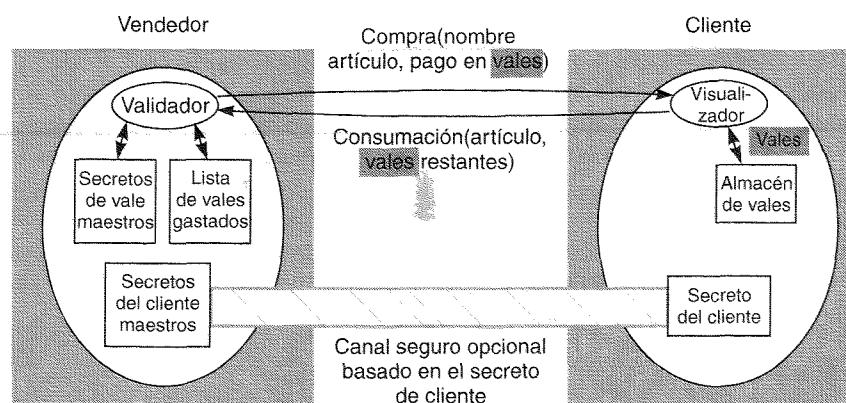


Figura 7.21. Arquitectura de Millicent.

2. El vendedor comprueba que el vale no ha sido ya gastado. Para hacer esto, ella mantiene una lista de los ID y fechas de expiración de todos los vales que ha emitido, con una indicación de si ha sido ya gastado. El campo de la fecha de expiración permite al vendedor borrar el vale caducado de la lista, previniendo así que crezca continuamente. Los clientes deben intercambiar vales viejos por los nuevos antes de que caduquen.

Las transacciones como las que se describen en el escenario anterior se pueden realizar de modo seguro basándose sólo en la validación. Esto protege al vendedor de la falsificación y del doble gasto, pero no protege al cliente del robo de vales, ni proporciona confidencialidad entre el vendedor y el cliente.

La protección contra el robo requiere que el vendedor o el intermediario que vende vales mantengan un vector de *secretos maestros del cliente* (seleccionados utilizando una parte del ID-cliente) y enviar a cada cliente un *secreto de cliente*. El secreto del cliente se construye añadiendo el secreto maestro del cliente al ID-cliente y aplicando una función de dispersión segura como MD5 al resultado. El secreto del cliente debe transmitirse desde el vendedor al cliente mediante un canal seguro. Se recomienda emplear SSL en cada compra inicial de vales.

Una vez transmitido al cliente, el secreto del cliente puede usarse como una clave secreta compartida entre el cliente y el vendedor. El cliente puede usarla para firmar transacciones y tanto el cliente como el vendedor pueden usarla como clave de encriptación cuando se requiere confidencialidad.

Para prevenir el robo, las transacciones están firmadas por el cliente, usando su secreto del cliente, y el vendedor comprueba que el ID-cliente del vale concuerda con el ID-cliente asociado con el secreto del cliente. Si no, entonces el vale sería gastado por alguien distinto al cliente a quien se vendió; en otras palabras, sería robado.

Para proporcionar confidencialidad, un cliente envía su ID-cliente al vendedor y establece un canal seguro usando un algoritmo de encriptación de clave secreta con la clave del cliente como clave de encriptación. El canal seguro es un medio útil para realizar una transacción en secreto.

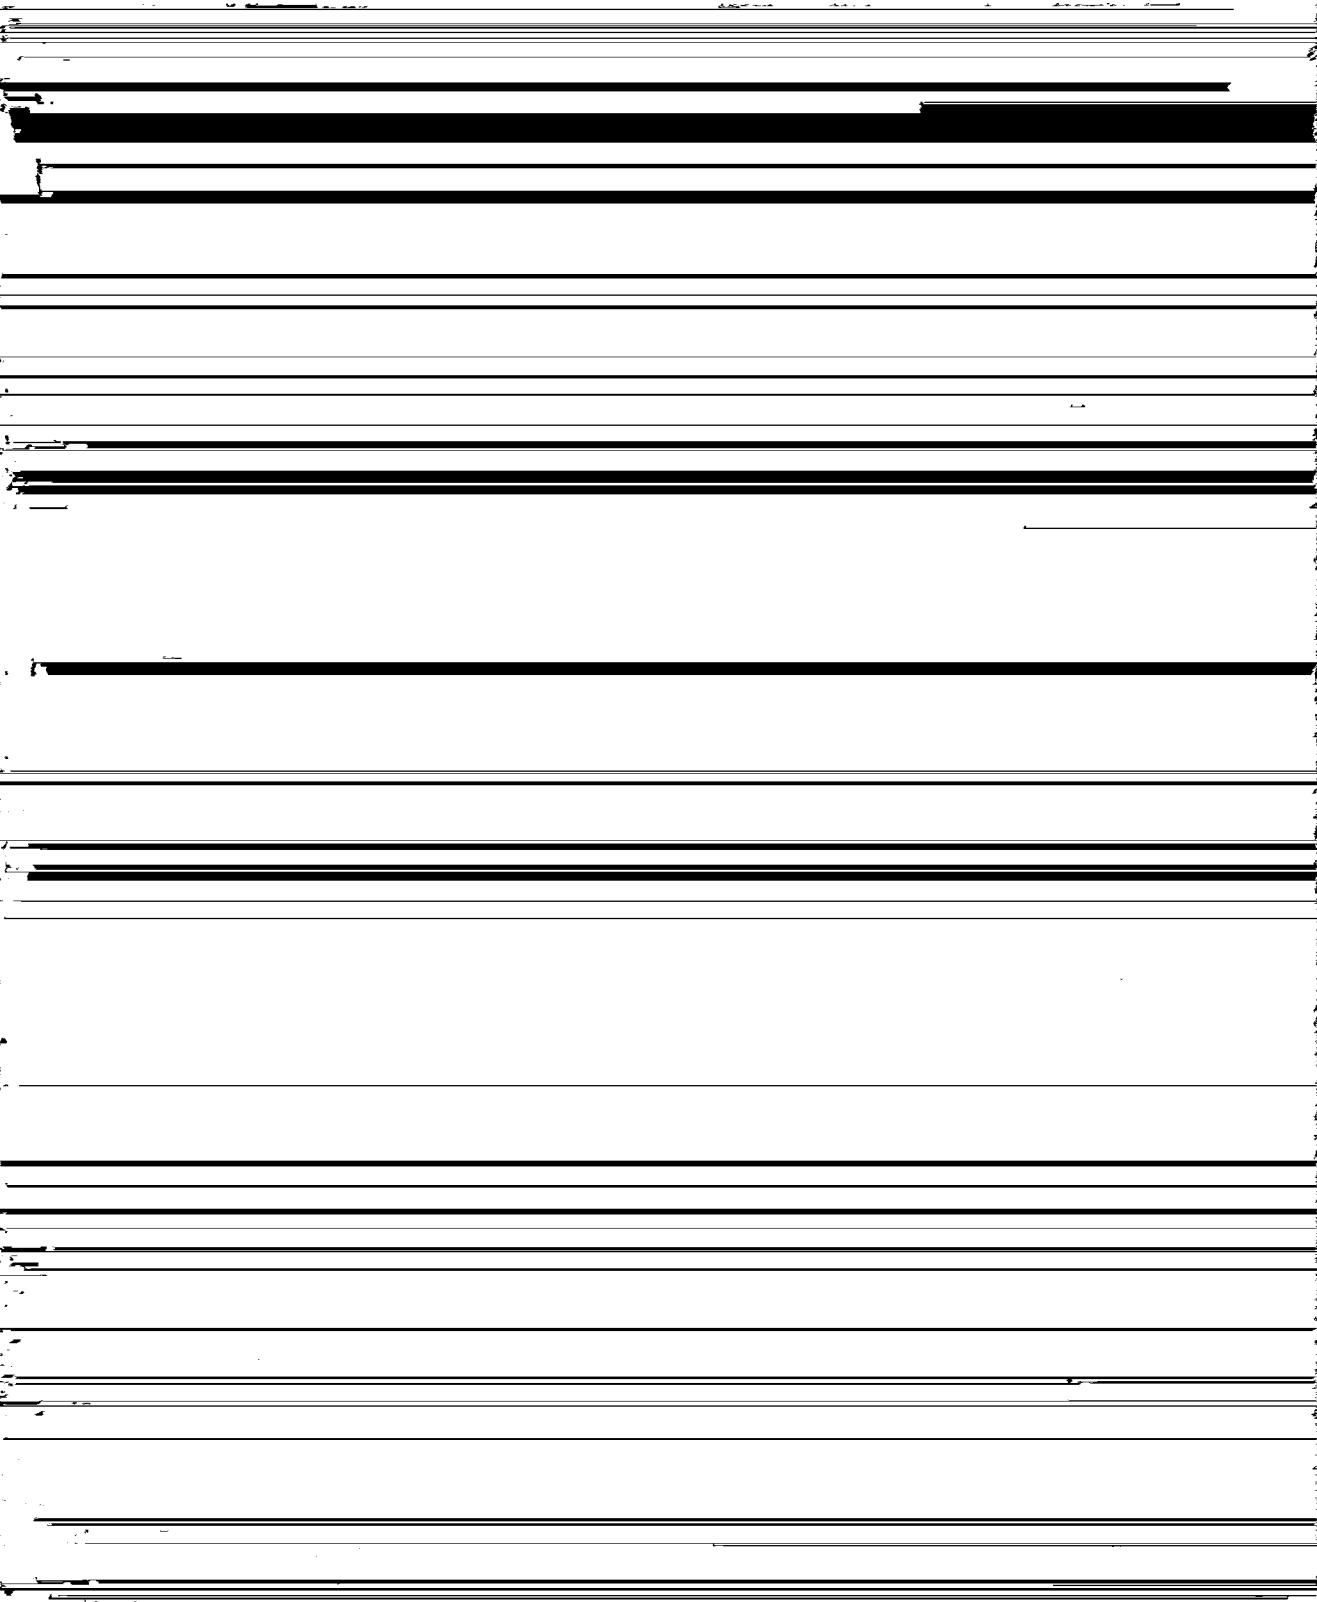
Hemos descrito Millicent con cierto detalle porque proporciona un ejemplo del mundo real que ilustra la aplicación de muchas de las técnicas de seguridad que se describen en este capítulo. El sistema Millicent es uno de los diversos esquemas de dinero electrónico que se han desarrollado para su uso en comercio electrónico. Fue desarrollado originalmente en Digital Systems Research Center, en Palo Alto, California y lo vende Compaq Corporation [www.millicent.com].

7.7 RESUMEN

Los ataques a la seguridad son parte de la realidad de los sistemas distribuidos. Es esencial proteger los canales e interfaces de comunicación de cualquier sistema que trate con información que sea susceptible de ser atacada. El correo personal, el comercio electrónico y otras transacciones financieras son ejemplos de tal tipo de información. Los protocolos de seguridad se diseñan cuidadosamente para evitar trampas. El diseño de los sistemas seguros parte de un listado de premisas de ataque y un conjunto de «peores casos posibles».

Los mecanismos de seguridad se basan en la criptografía de clave pública y de clave secreta. Los algoritmos criptográficos disfrazan los mensajes de forma que no puede revertirse el proceso sin el conocimiento de la clave de desencriptación. La criptografía de clave secreta es simétrica: la misma clave sirve tanto para la encriptación como para la desencriptación. Si dos partes comparten una clave secreta, podrán intercambiar información encriptada sin riesgo de que sea desvelada o modificada y con garantías de autenticidad.

La criptografía de clave pública es asimétrica: se utilizan claves separadas para la encriptación y la desencriptación, y el conocimiento de una de ellas no implica el de la otra. Una de ellas se

- 
- 7.5. ¿Cómo podría enviarse un correo electrónico a una lista de receptores utilizando PGP o un esquema similar? Sugiera un esquema más simple y rápido cuando la lista se usa frecuentemente.
 - 7.6. La implementación del algoritmo de encriptación simétrico TEA que se muestra en las Figuras 7.8 a 7.10 no es portable entre máquinas de diferentes arquitecturas. Explique por qué. ¿Cómo podría transmitirse un mensaje encriptado usando una implementación de TEA de modo que fuera desencriptado en cualquier otra arquitectura?
 - 7.7. Modifique el programa de aplicación de TEA de la Figura 7.10 para utilizar cifrado por encadenamiento de bloques (CBC).
 - 7.8. Construya una aplicación de cifrado de caudal basada en el programa de la Figura 7.10.
 - 7.9. Estime el tiempo requerido para romper una clave DES de 56 bits por fuerza bruta empleando una estación de trabajo de 500 MIPS (millones de instrucciones por segundo), suponiendo que el bucle interno de un programa de ataque por fuerza bruta contiene una 10 instrucciones por valor de la clave, más el tiempo de encriptación de un texto en claro de 8 bytes (véase la Figura 7.14). Realice el mismo cálculo para una clave IDEA de 128 bits. Extrapole sus cálculos para obtener el tiempo de ataque para un procesador paralelo de 50.000 MIPS (o un consorcio Internet con un poder de procesamiento similar).
 - 7.10. En el protocolo de autenticación de Needham y Schroeder con claves secretas, explique por qué la siguiente versión del mensaje 5 no es segura:

$$A \rightarrow B: \{N_B\}_{K_{AB}}$$

SISTEMAS DE ARCHIVOS

- 8.1. Introducción
- 8.2. Arquitectura del servicio de archivos
- 8.3. Sistema de archivos en red de Sun (NFS)
- 8.4. Sistema de archivos Andrew
- 8.5. Avances recientes
- 8.6. Resumen

Los sistemas de archivos distribuidos soportan la compartición de información en forma de archivos a través de Internet. Un servicio de archivos bien diseñado proporciona acceso a los archivos almacenados en un servidor con prestaciones y fiabilidad semejantes (y en algunos casos mejor) que la de archivos almacenados en discos locales. Un sistema de archivos distribuidos permite a los programas almacenar y acceder a archivos remotos del mismo modo que si fueran locales, permitiendo a los usuarios que accedan a archivos desde cualquier computador en una intranet.

Describimos los diseños de dos sistemas de archivos distribuidos que han sido de uso extendido durante una década o más:

- Sistema de archivos en red de Sun, NFS.
- Sistema de archivos Andrew, AFS.

Estos casos de estudio ilustran un rango de soluciones de diseño para la emulación de una interfaz de un sistema de archivos UNIX con distintos grados de escalabilidad y tolerancia a fallos. Cada una exige alguna desviación de la emulación de la semántica de actualización de archivo de *una copia* de UNIX.

Recientes avances en el diseño de sistemas distribuidos han explotado la conectividad de mayor ancho de banda de las redes de área local comutadas y los nuevos modos de organización de datos en disco para obtener prestaciones muy altas, tolerancia a fallos y sistemas de archivos altamente escalables.

8.1. INTRODUCCIÓN

En los Capítulos 1 y 2, identificamos el hecho de compartir recursos como un objetivo clave de los sistemas distribuidos. El compartir información almacenada es quizás el aspecto más importante de la compartición de recursos distribuidos. Se obtiene a gran escala en Internet principalmente por el uso de los servidores web, pero los requisitos para compartir en redes de área local e intranet conduce a una necesidad de un tipo de servicio diferente, uno que soporte el almacenamiento persistente de datos y programas de todos los tipos, en nombre de los clientes, y la consiguiente distribución de datos actualizados. El propósito de este capítulo es describir la arquitectura e implementación de sistemas de archivos distribuidos *básicos*. Utilizamos aquí la palabra «básico» para señalar sistemas de archivos distribuidos cuyo propósito principal es emular la funcionalidad de sistemas de archivos no distribuidos para programas cliente ejecutándose en múltiples computadores remotos. Éstos no mantienen múltiples réplicas persistentes de archivos, ni soportan el ancho de banda y las garantías de temporización requeridas para flujos de datos multimedia, cuyos requisitos se revisarán en capítulos posteriores. Los sistemas de archivos distribuidos básicos proporcionan un sustento esencial para la organización de la computación basada en intranets.

Comenzamos con un breve repaso del espectro de los sistemas de almacenamiento distribuidos y no distribuidos. Los sistemas de archivos fueron desarrollados originalmente para sistemas centralizados de computadores y computadores portátiles como una disponibilidad del sistema operativo que proporciona una interfaz de programación adecuada para el almacenamiento en disco. Así, adquirieron posteriormente características tales como control de acceso y mecanismos de bloqueo a archivos que les hicieron útiles para la compartición de datos y programas. Los sistemas de archivos distribuidos soportan la compartición de la información en forma de archivos y recursos hardware que dan soporte al almacenamiento persistente a través de una intranet. Un servicio de archivos bien diseñado proporciona acceso a los sistemas almacenados en un servidor con prestaciones y fiabilidad semejantes a, y en algunos casos mejor que, los archivos almacenados en discos locales. Su diseño se adapta para las características de prestaciones y fiabilidad de redes locales y por ello son más efectivos proporcionando almacenamiento persistente compartido para uso en intranets. Los primeros servidores de archivos fueron desarrollados por investigadores en la década de los setenta [Birrell y Needham 1980, Mitchell y Dion 1982, Leach y otros 1983] y el Sistema de Archivos en Red de Sun estuvo disponible en los primeros años ochenta [Sandberg y otros 1985, Callaghan 1999].

Un servicio de archivos permite a los programas almacenar y acceder a los archivos remotos del mismo modo que se hace con los locales, permitiendo a los usuarios acceder a sus archivos desde cualquier computador de una intranet. La concentración de almacenamiento persistente en unos pocos servidores reduce la necesidad de almacenamiento en disco local y (más importante) permite economizar la gestión y el archivo de datos persistentes pertenecientes a una organización. Otros servicios, como el servicio de nombres, el servicio de autenticación de usuarios y el servicio de impresión, pueden ser implementados más fácilmente si hacen llamadas al servicio de archivos, que satisface sus necesidades de almacenamiento permanente. Los servidores web dependen de los sistemas de archivos para el almacenamiento de las páginas web que sirven. En organizaciones que operan con servidores web para acceso externo e interno vía una intranet, los servidores web suelen almacenar y acceder al material desde un sistema de archivos local distribuido.

Con la llegada de la programación orientada a objetos distribuida, aparece la necesidad del almacenamiento persistente y la distribución para los objetos compartidos. Una forma de lograr esto es serializar los objetos (de la forma descrita en la Sección 4.3.2) y almacenar y recuperar estos objetos serializados sobre archivos. Pero este método para obtener persistencia y distribución llega a ser impracticable para objetos que cambian rápidamente, y se han desarrollado otras aproximaciones más directas. La invocación remota de objetos de Java y de los ORB de CORBA proporcio-

	Compartición	Persistencia	Caché/réplicas distribuidas	Mantenimiento de consistencia	Ejemplo
Memoria principal	✗	✗	✗	1	RAM
Sistema de archivos	✗	✓	✗	1	Sistema de archivos UNIX
Sistema de archivos distribuido	✓	✓	✓	✓	Sun NFS
Web	✓	✓	✓	✗	Servidor Web
Memoria compartida distribuida	✓	✗	✓	✓	Ivy (Cap. 16)
Objetos remotos (RMI/ORB)	✓	✗	✗	1	CORBA
Almacén de objetos persistentes	✓	✓	✗	1	Servicio de objetos persistentes de CORBA
Almacén de objetos persistentes distribuido	✓	✓	✓	✓	PerDis, Khazana

Figura 8.1. Sistemas de almacenamiento y sus propiedades.

nan acceso a objetos remotos, compartidos, pero ninguno de ellos asegura la persistencia de los objetos ni la replicación de los objetos distribuidos.

Los desarrollos recientes, sobre la distribución de la información almacenada, se orientan hacia los sistemas de memoria compartida distribuida (DSM) y los almacenes de objetos persistentes. DSM se describe con detalle en el Capítulo 16. Proporciona una emulación de una memoria compartida mediante la replicación de páginas o segmentos de memoria, en cada máquina. Los almacenes de objetos persistentes se presentaron en el Capítulo 5. Su finalidad es proporcionar persistencia para objetos compartidos distribuidos. Ejemplos de ello son el Servicio de Objetos Persistentes de CORBA (véase el Capítulo 17) y extensiones de persistencia para Java [Jordan 1996, [java.sun.com IV](http://java.sun.com/IV)]. Algunas investigaciones recientes han resultado en plataformas que soportan la replicación automática y el almacenamiento persistente de objetos (por ejemplo, PerDiS [Ferreira y otros 2000] y Khazana [Carter y otros 1998]).

La Figura 8.1 proporciona un resumen de las propiedades de los distintos tipos de sistemas de almacenamiento que hemos mencionado. La columna *consistencia* indica qué mecanismos existen para el mantenimiento de la consistencia entre múltiples copias de datos cuando ocurren actualizaciones. Virtualmente todos los sistemas de almacenamiento confían en el uso de caché para optimizar las prestaciones de los programas. Las técnicas de caché se aplicaron en primer lugar a la memoria principal y a los sistemas de archivos no distribuidos, para los que la consistencia es estricta (señalado por un «1», para consistencia de una copia en la Figura 8.1), los programas no contemplan discrepancias entre las copias en la caché y los datos almacenados después de una actualización. Cuando se utilizan réplicas distribuidas, la consistencia estricta es más difícil de obtener. Los sistemas de archivos distribuidos como Sun NFS y el sistema de archivos Andrew replican copias de porciones de archivos en los computadores de los clientes y adoptan mecanismos de consistencia específicos para mantener una aproximación a la consistencia estricta. Esto se indica mediante una marca (✓) en la columna de consistencia de la Figura 8.1. Discutiremos estos mecanismos y el grado en el que se desvían de la consistencia estricta en las Secciones 8.3 y 8.4.

La Web utiliza cachés extensivamente tanto en los computadores cliente como en los servidores proxy mantenidos por la organización de cada usuario. La consistencia entre las copias almacenadas en la caché de un proxy web y los clientes y en el servidor original sólo se consigue mediante acciones específicas del usuario. Cuando se actualiza una página almacenada en el servidor

original no se advierte a los clientes, y son ellos quienes deben realizar comprobaciones periódicas para mantener sus copias actualizadas. Esto sirve adecuadamente para el propósito de navegación web, pero no soporta el desarrollo de aplicaciones cooperativas como el de un tablero compartido distribuido. Los mecanismos de consistencia utilizados en los sistemas DSM se discutirán con detalle en el Capítulo 16. Los sistemas de objetos persistentes varían considerablemente en su aproximación al uso de caché y consistencia. Los esquemas CORBA y Persistent Java mantienen una única copia de cada objeto persistente y para acceder a ellos es preciso realizar una invocación remota, por lo que el único tema de consistencia está entre la copia persistente de un objeto en disco y la copia activa en memoria, que no es visible para los clientes remotos. Los proyectos PerDiS y Khazana que hemos mencionado anteriormente mantienen réplicas en la caché de los objetos y emplean mecanismos de consistencia bastante elaborados para producir formas de consistencia semejantes a las que se encuentran en los sistemas DSM.

Habiendo presentado algunos temas más profundos relacionados con el almacenamiento y distribución de datos persistentes y no persistentes, volvemos al tema principal de este capítulo, el diseño de sistemas básicos de archivos distribuidos. Describimos algunas características relevantes de los sistemas de archivos (no distribuidos) en la Sección 8.1.1, y los requisitos para sistemas de archivos distribuidos en la Sección 8.1.2. La Sección 8.1.3 presenta los casos de estudio que se utilizarán a lo largo del capítulo. En la Sección 8.2 definimos un modelo abstracto para un servicio básico de archivos distribuidos, incluyendo un conjunto de interfaces de programación. El sistema Sun NFS se describe en la Sección 8.3, comparte muchas de las características del modelo abstracto. En la Sección 8.4 describimos el Sistema de Archivos Andrew, un sistema ampliamente usado que emplea mecanismos de caché y consistencia sustancialmente diferentes. La Sección 8.5 revisa algunos de los desarrollos recientes en el diseño de servicios de archivos.

Los sistemas descritos en este capítulo no cubren el espectro total de los sistemas de archivos distribuidos y gestión de datos. Varios sistemas con características más avanzadas serán descritos posteriormente en el libro. El Capítulo 14 incluirá una descripción de Coda, un sistema de archivos distribuidos que mantiene réplicas persistentes de los archivos para la fiabilidad, disponibilidad y el trabajo desconectado. Bayou, un sistema de gestión de datos distribuidos que proporciona una forma de replicación débilmente consistente para alta disponibilidad se tratará también en el Capítulo 14. El Capítulo 15 discutirá el servidor de archivos de vídeo Tiger, que está diseñado para proporcionar la entrega oportuna de caudales de datos a gran número de clientes.

8.1.1. CARACTERÍSTICAS DE LOS SISTEMAS DE ARCHIVOS

Los sistemas de archivos son responsables de la organización, almacenamiento, recuperación, nomenclación, compartición y protección de los archivos. Proporcionan una interfaz de programación característica de la abstracción de archivo, liberando a los programadores de la preocupación por los detalles de la asignación y la disposición del almacenamiento. Los archivos se almacenan en discos y otros medios de almacenamiento no volátiles.

Los archivos contienen *datos* y *atributos*. Los datos consisten en una secuencia de elementos de datos (normalmente bytes de 8 bits), donde cualquier porción de ésta es accesible mediante operaciones de lectura y escritura. Los atributos se alojan como un único registro que contiene información como la longitud del archivo, marcas de tiempo, tipo del archivo, identidad del propietario y listas de control de acceso.

En la Figura 8.3 se muestra una estructura típica del registro de atributos. Los atributos resaltados son administrados por el sistema de archivos y no son modificables habitualmente desde los programas del usuario.

Los sistemas de archivos están diseñados para almacenar y gestionar gran número de archivos, con posibilidades de crear, nombrar y borrar archivos. La nomenclatura de los archivos está respal-

Módulo de directorio:	relaciona nombres de archivos con ID de archivos
Módulo de archivos:	relaciona ID de archivos con archivos concretos
Módulo de control de acceso:	comprueba los permisos para una operación solicitada
Módulo de acceso a archivos:	lee o escribe datos o atributos de un archivo
Módulo de bloques:	accede y asigna bloques de disco
Módulo de dispositivo:	E/S de disco y búferes

Figura 8.2. Módulos del sistema de archivos.

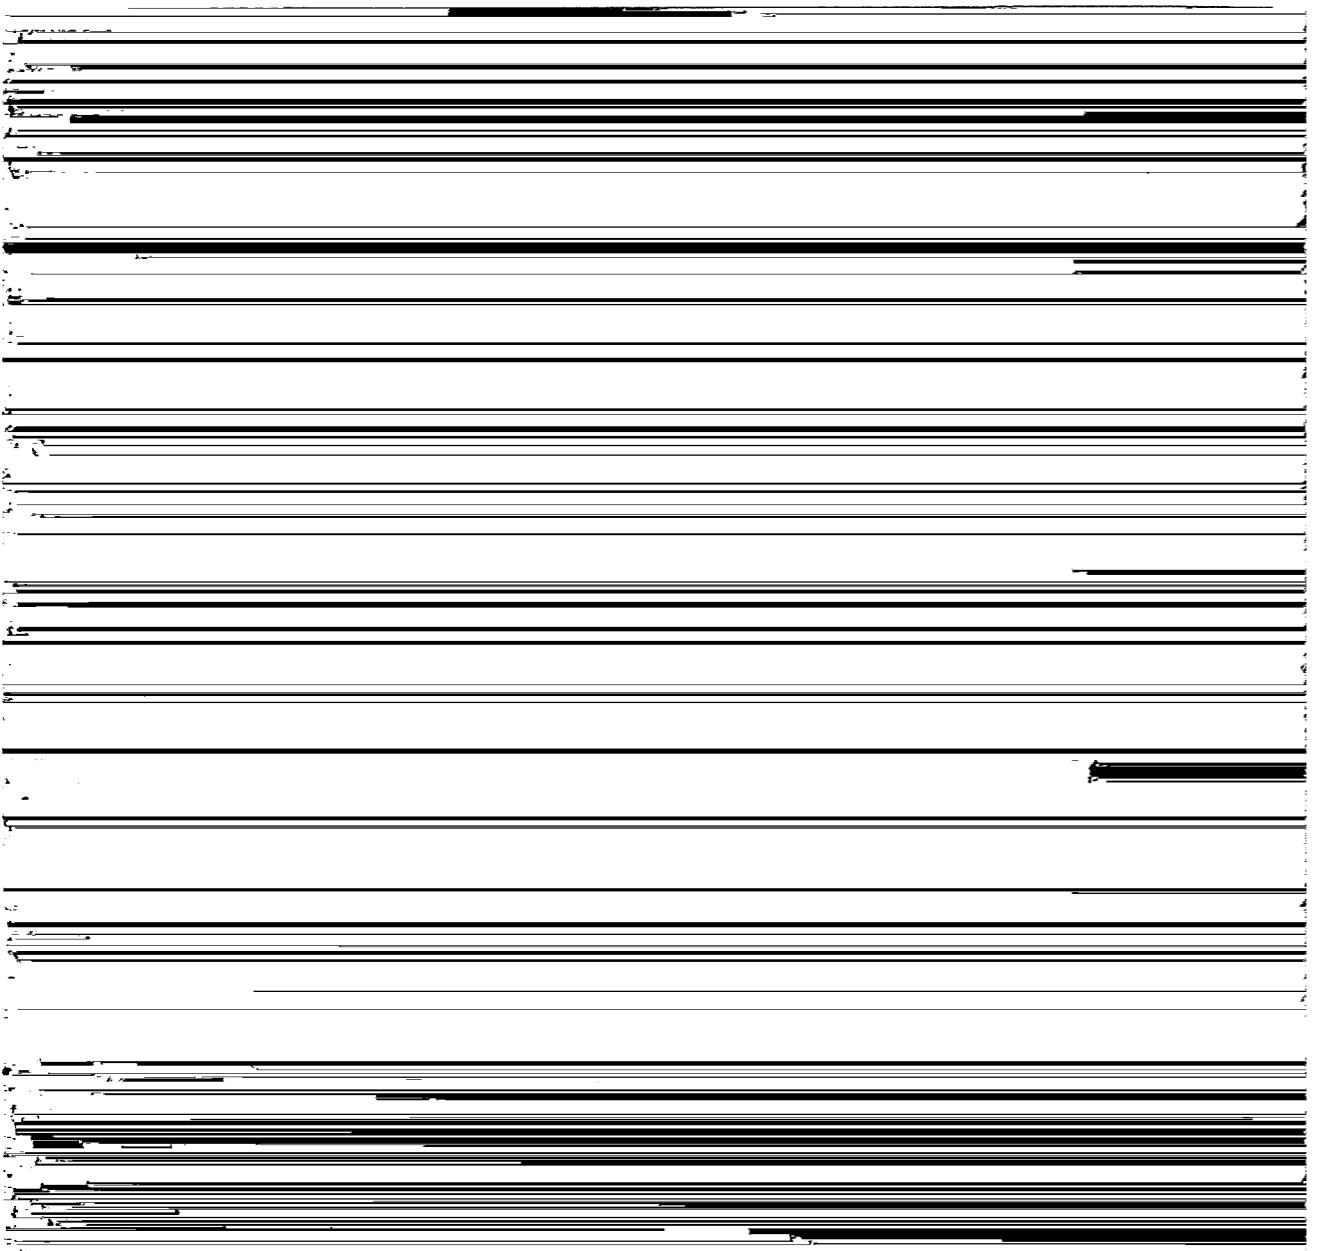
dada por la utilización de directorios. Un *directorio* es un archivo, a menudo de un tipo especial, que relaciona los nombres en texto con los identificadores internos de los archivos. Los directorios pueden incluir los nombres de otros directorios derivando en el esquema familiar de nomenclatura jerárquica de archivos y los *nombres de ruta*, tanto para los archivos en UNIX como para otros sistemas operativos. Los sistemas de archivo tienen también la responsabilidad del control de acceso a los archivos, restringiendo el acceso a los mismos de acuerdo con las autorizaciones de los usuarios y el tipo de acceso solicitado (lectura, actualización, ejecución y demás).

El término *metadato* se utiliza a menudo para referirse a toda la información extra almacenada por un sistema de archivos que es necesaria para la gestión de los mismos. Incluye los atributos de los archivos, los directorios y todas las demás informaciones persistentes empleadas por el sistema de archivos.

La Figura 8.2 muestra una estructura típica de niveles para la implementación de un sistema de archivos no distribuido en un sistema operativo convencional. Cada nivel depende sólo de los niveles que se encuentran debajo de él. La implementación de un servicio de archivos distribuidos requiere todos los componentes indicados, junto a componentes adicionales para ocuparse de la comunicación cliente-servidor y de la nomenclatura y ubicación de los archivos distribuidos.

Tamaño del archivo
Marca temporal de creación
Marca temporal de lectura
Marca temporal de escritura
Marca temporal de atributos
Contador de referencias
Propietario
Tipo de archivo
Lista de control de acceso

Figura 8.3. Estructuras del registro de atributos de un archivo.



`desarchivo = open(nombre, modo)`
`desarchivo = creat(nombre, modo)`

Abre un archivo existente con un *nombre* determinado.
 Crea un archivo nuevo con un *nombre* determinado.

la Sección 1.4.7. El diseño debe balancear la flexibilidad y escalabilidad que se derivan de la transparencia frente a la complejidad del software y las prestaciones. Las siguientes formas de transparencia son parcial o totalmente tratadas por los actuales servicios de archivos:

Transparencia de acceso: los programas del cliente no deben preocuparse de la distribución de los archivos. Se proporciona un conjunto sencillo de operaciones para el acceso a archivos locales y remotos. Los programas escritos para trabajar sobre archivos locales serán capaces de acceder a los archivos remotos sin modificación.

Transparencia de ubicación: los programas del cliente deben ver un espacio de nombres de archivos uniforme. Los archivos o grupos de archivos pueden ser reubicados sin cambiar sus nombres de ruta, y los programas de usuario verán el mismo espacio de nombres en cualquier parte que sean ejecutados.

Transparencia de movilidad: ni los programas del cliente ni las tablas de administración de sistema en los nodos cliente necesitan ser cambiados cuando se mueven los archivos. Esta movilidad de archivos permite que archivos o, más comúnmente, conjuntos o volúmenes de archivos puedan ser movidos, ya sea por los administradores del sistema o automáticamente.

Transparencia de prestaciones: los programas cliente deben continuar funcionando satisfactoriamente mientras la carga en el servicio varíe dentro de un rango especificado.

Transparencia de escala: el servicio puede ser aumentado por un crecimiento incremental para tratar con un amplio rango de cargas y tamaños de redes.

◊ **Actualizaciones concurrentes de archivos.** Los cambios en un archivo por un cliente no deben interferir con la operación de otros clientes que acceden o cambian simultáneamente el mismo archivo. Esto es el tema bien conocido del control de concurrencia, discutido con detalle en el Capítulo 12. La necesidad de control de concurrencia para el acceso a datos compartidos en muchas aplicaciones está ampliamente aceptada y las técnicas para su implementación son conocidas, aunque muy costosas. La mayoría de los servicios de archivos actuales siguen los estándares de UNIX moderno proporcionando bloqueo consultivo u obligatorio a nivel de archivo o registro.

◊ **Replicación de archivos.** En un servicio de archivos que soporta replicación, un archivo puede estar representado por varias copias de su contenido en diferentes ubicaciones. Esto tiene dos beneficios, permite que múltiples servidores compartan la carga de proporcionar un servicio a los clientes que acceden al mismo conjunto de archivos, mejorando la escalabilidad del servicio y mejorando la tolerancia a fallos, permitiendo a los clientes localizar otro servidor que mantiene una copia del archivo cuando uno ha fallado. Muy pocos servicios de archivos soportan totalmente la replicación, pero la mayoría soportan la caché local de archivos o porciones de archivos, una forma limitada de replicación. La replicación de datos se discutirá en el Capítulo 14, que incluye una descripción del servicio de archivos replicado Coda.

◊ **Heterogeneidad del hardware y del sistema operativo.** Las interfaces del servicio deben estar definidas de modo que el software del cliente y el servidor pueden estar implementados por diferentes sistemas operativos y computadores. Este requisito es un aspecto importante de la extensibilidad.

◊ **Tolerancia a fallos.** El papel central de un servicio de archivos en los sistemas distribuidos hace que sea esencial que el servicio continúe funcionando aun en el caso de fallos del cliente y del servidor. Afortunadamente un diseño moderadamente tolerante a fallos es inmediato para servidores sencillos. Para manejar los fallos de comunicación transitorios, el diseño puede estar basado en la semántica de invocación de como *máximo una vez* (véase la Sección 5.2.4). O puede utilizarse la semántica más sencilla *al menos una vez* con un protocolo de servidor diseñado en términos de operaciones *idempotentes*, asegurando que solicitudes duplicadas no producen actualizaciones inválidas en los archivos. Los servidores pueden ser *sin estado*, por lo que pueden ser rearrancados

y el servicio restablecido después de un fallo sin necesidad de recuperar el estado previo. La tolerancia a la desconexión o fallos del servidor precisa replicación de los archivos, que es más difícil de alcanzar y será discutida en el Capítulo 14.

◊ **Consistencia.** Los sistemas de archivos convencionales, como los que se proporcionan en UNIX, ofrecen una *semántica de actualización de una copia*. Esto se refiere a un modelo para acceso concurrente a archivos en el que el contenido del archivo visto por todos los procesos que acceden o actualizan a un archivo dado es aquel que ellos verían si existiera un única copia del contenido del archivo. Cuando los archivos están replicados, o en la caché, en diferentes lugares, hay un retardo inevitable en la propagación de las modificaciones hechas en un lugar hacia los otros lugares que mantienen copias, y esto puede producir alguna desviación de la semántica de una copia.

◊ **Seguridad.** Virtualmente todos los sistemas de archivos proporcionan mecanismos de control de acceso basados en el uso de listas de control de acceso. En sistemas de archivos distribuidos, hay una necesidad de autenticar las solicitudes del cliente por lo que el control de acceso en el servidor está basado en identificar al usuario correcto y proteger el contenido de los mensajes de solicitud y respuesta con firmas digitales y (opcionalmente) encriptación de datos secretos. Discutiremos el impacto de estos requisitos en nuestras descripciones de casos de estudio.

◊ **Eficiencia.** Un servicio de archivos distribuidos debe ofrecer posibilidades con la misma potencia y generalidad que las que se encuentran en los sistemas de archivos convencionales y deben proporcionar un nivel de prestaciones comparable. Birrell y Needham [1980] expresaron sus objetivos de diseño para el Servidor de Archivos Cambridge (CFS) en estos términos:

Nosotros deseáramos tener un servidor de archivos sencillo, de bajo nivel, para compartir un recurso caro, por ejemplo un disco, mientras dejamos libertad para diseñar el sistema de archivos más apropiado para un cliente particular, pero deseáramos también tener disponible un sistema de alto nivel compartido entre clientes.

El cambio del coste de almacenamiento de disco ha reducido la importancia de su primer objetivo, pero su percepción de la necesidad de un rango de servicios que respondan a los requisitos de los clientes con diferentes objetivos, permanece y puede ser conseguido mejor por una arquitectura modular del tipo esbozado anteriormente.

Las técnicas utilizadas para la implementación de los servicios de archivo son una parte importante del diseño de sistemas distribuidos. Un sistema de archivos distribuidos debe proporcionar un servicio que sea comparable con, o mejor que, los sistemas de archivos locales en prestaciones y fiabilidad. Debe ser adecuado para administrar, proporcionando operaciones y herramientas que permitan a los administradores del sistema instalar y operar el sistema convenientemente.

8.1.3. CASOS DE ESTUDIO

Hemos construido un modelo abstracto para un servicio de archivos para actuar como un ejemplo introductorio separando las cuestiones de implementación y proporcionando un modelo simplificado. Describimos el Sistema de Archivos en Red (*Network File System*) de Sun (NFS) con algún detalle, basándonos en nuestro modelo abstracto más sencillo para aclarar su arquitectura. Posteriormente se describe el Sistema de Archivos Andrew (AFS), proporcionando una visión de un sistema de archivos distribuido que considera una aproximación diferente para la escalabilidad y el mantenimiento de la consistencia.

◊ **Arquitectura del servicio de archivos.** Éste es un modelo arquitectónico abstracto sobre el que se sustentan tanto NFS como AFS. Está basado en una división de las responsabilidades entre tres módulos, un módulo cliente que emula la interfaz de un sistema de archivos convencio-

nal para los programas de aplicación y módulos servidores, que realizan operaciones para los clientes en directorios y archivos. La arquitectura está diseñada para permitir una implementación *sin estado* del módulo del servidor.

◊ **NFS de SUN.** El sistema de archivos en red de SUN (NFS) ha sido adoptado ampliamente en la industria y en entornos académicos desde su introducción en 1985. El diseño y desarrollo de NFS fueron emprendidos por el personal de Sun Microsystems en 1984 [Sandberg y otros 1985; Sandberg 1987, Callaghan 1999]. Aunque ya habían sido desarrollados varios servicios de archivos distribuidos, y utilizados con éxito, en universidades y laboratorios de investigación, NFS fue el primer servicio de archivos que fue diseñado como un producto. El diseño e implementación de NFS ha obtenido un éxito considerable tanto técnica como comercialmente.

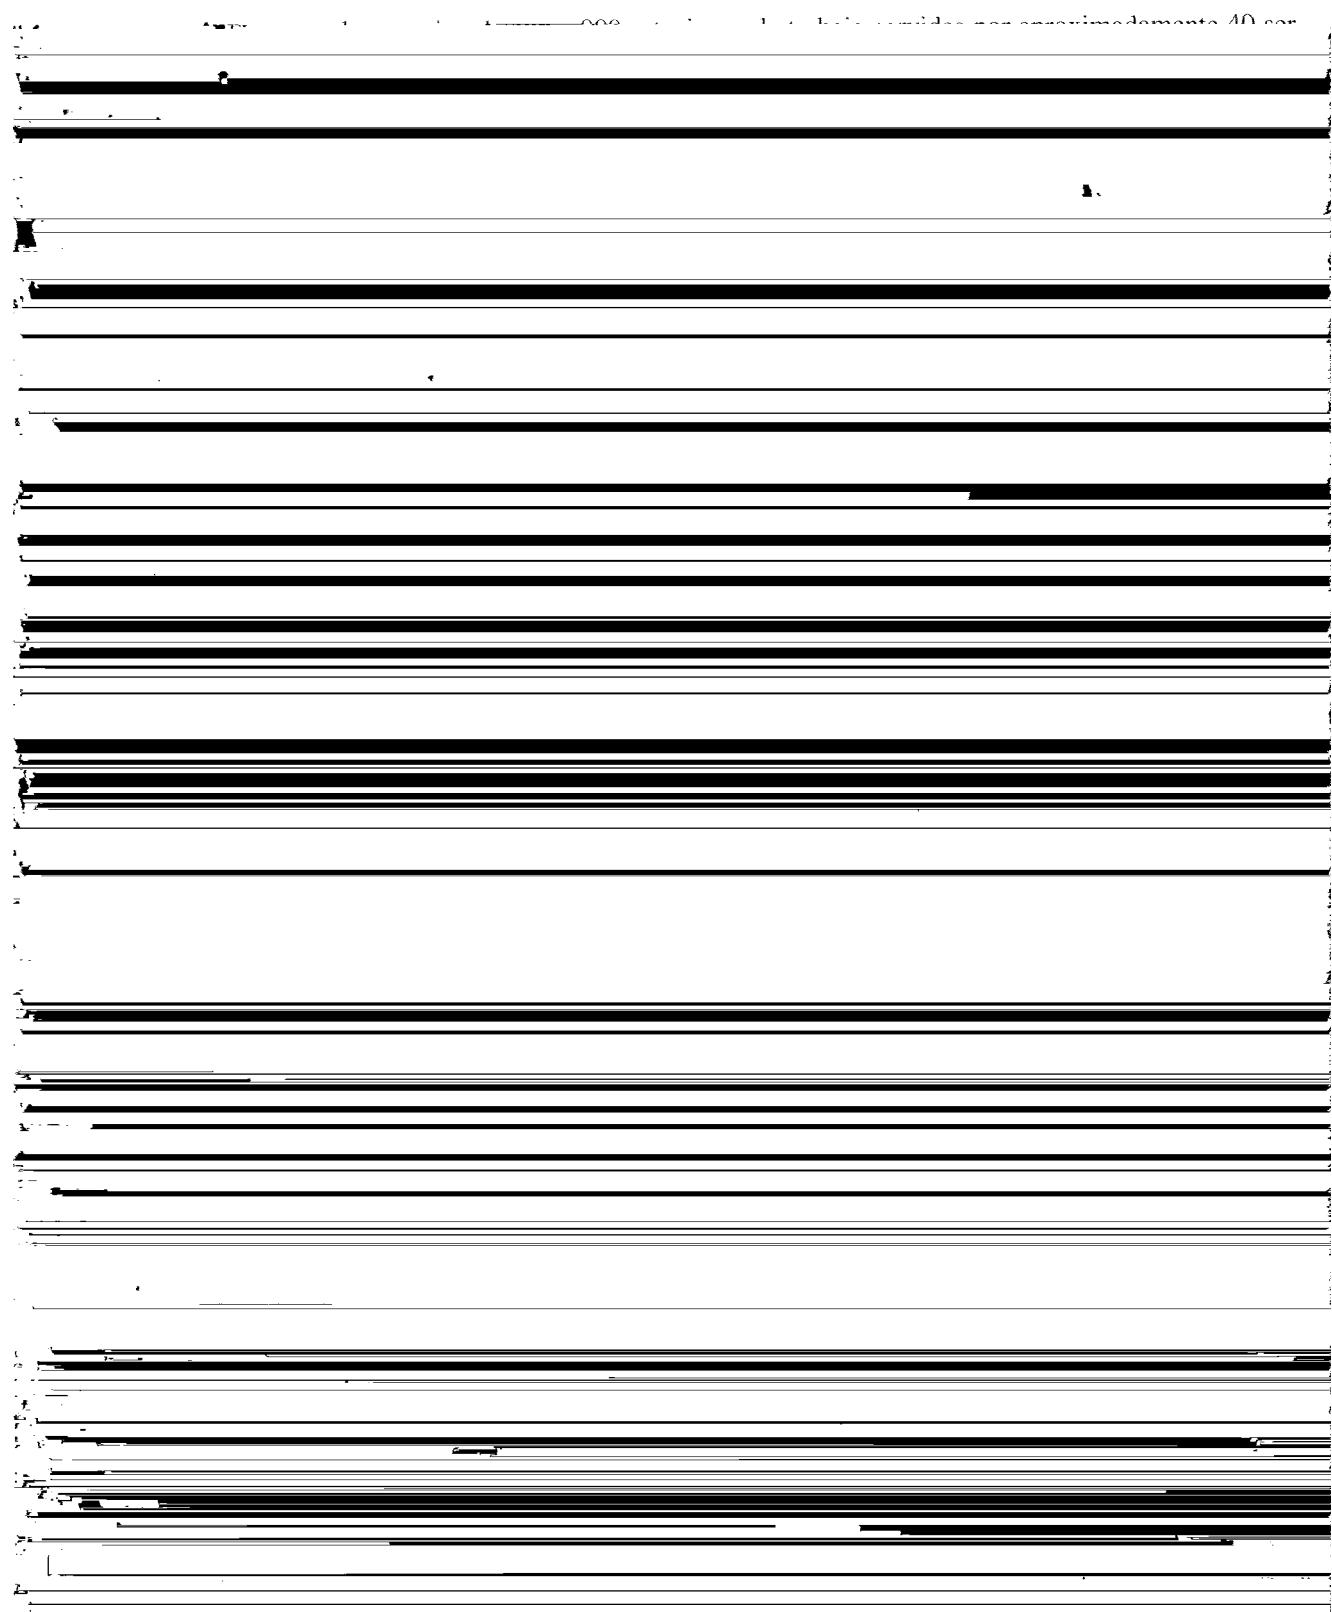
Para animar a su adopción como un estándar, las definiciones de las interfaces fundamentales fueron situadas en el dominio público [Sun 1989], permitiendo a otros vendedores producir implementaciones, y el código fuente fue puesto disponible para una implementación de referencia a otros vendedores de computadores bajo licencia. Actualmente está soportado por muchos vendedores y el protocolo NFS (versión 3) es un estándar de Internet, definido en RFC 1813 [Callaghan y otros 1995]. El libro del mismo Callaghan sobre NFS [Callaghan 1999] es una fuente excelente sobre el diseño y desarrollo de NFS y temas relacionados.

NFS proporciona acceso transparente a archivos remotos desde programas cliente ejecutándose sobre UNIX y otros sistemas. Normalmente, cada computador tiene un cliente NFS y módulos servidor instalados en el núcleo del sistema, al menos en el caso de los sistemas UNIX. La relación cliente-servidor es simétrica: Cada computador en una red NFS puede actuar tanto como cliente como servidor, y los archivos en cada máquina pueden hacerse disponibles para acceso remoto desde otras máquinas. Cualquier computador puede ser un servidor, exportando algunos de sus archivos, y un cliente, accediendo a archivos de otras máquinas. Pero es una práctica habitual configurar instalaciones grandes con algunas máquinas como servidores dedicados y otras como estaciones de trabajo.

Un objetivo importante de NFS es conseguir un elevado nivel de soporte para la heterogeneidad de hardware y el sistema operativo. El diseño es independiente del sistema operativo: Existen implementaciones de servidor y cliente para casi todos los sistemas operativos y plataformas actuales, incluyendo Windows 95, Windows NT, MacOS y VMS así como Linux y casi cualquier otra versión de UNIX. Se han desarrollado implementaciones de NFS en máquinas multiprocesador de altas prestaciones por varios vendedores y éstas se utilizan ampliamente para satisfacer los requisitos de almacenamiento en intranets con muchos usuarios concurrentes.

◊ **Andrew File System.** Andrew es un entorno de computación distribuida desarrollado en la Universidad Carnegie Mellon (CMU) para su utilización como un sistema de información y computación de campus [Morris y otros 1986]. El diseño de Andrew File System (a partir de ahora abreviado como AFS) refleja una intención de soportar la compartición de información en gran escala minimizando la comunicación cliente servidor. Esto fue conseguido transfiriendo archivos completos (o para archivos grandes, trozos de 64-kbytes) entre los computadores del servidor y del cliente y haciendo caché de ellos en los clientes hasta que el servidor reciba una versión más actualizada. La red de computación de campus que servía Andrew se esperaba que creciera hasta incluir entre 5.000 y 10.000 estaciones de trabajo durante el tiempo de vida del sistema. Describiremos AFS-2, la primera implementación de producción, siguiendo las descripciones de Satyanarayanan [1989a, 1989b]. Se pueden encontrar descripciones más recientes en Campbell [1997] y [Linux AFS].

AFS fue implementado inicialmente sobre una red de estaciones de trabajo y servidores trabajando en BSD UNIX y el sistema operativo Mach en CMU y posteriormente estuvo disponible en versiones comerciales y de dominio público. Más recientemente, se ha hecho disponible una implementación de dominio público de AFS para el sistema operativo Linux [Linux AFS]. En 1991, AFS



funciones necesarias para generar directorios, para añadir nuevos nombres de archivo a los directorios y para obtener UFID desde los directorios. Es un cliente del servicio de archivos plano, sus archivos de directorio están almacenados en archivos del servicio de archivos plano. Cuando se adopta un esquema jerárquico de nominación de archivos, como en UNIX, los directorios mantienen referencias a otros directorios.

◊ **Módulo cliente.** En cada computador cliente se ejecuta un módulo de cliente, que integra y extiende las operaciones del servicio de archivos plano y el servicio de directorio bajo una interfaz de programación de aplicaciones sencilla, que estará disponible para los programas a nivel de usuario en los computadores cliente. Por ejemplo, en máquinas UNIX, se debe proporcionar un módulo cliente que emula el conjunto total de operaciones UNIX sobre archivos, interpretando los nombres *compuestos* de archivos UNIX mediante reiteradas solicitudes al servicio de directorio. El módulo cliente mantiene también información sobre las ubicaciones en la red del proceso servidor de archivos planos y del proceso servidor de directorio. Finalmente el módulo cliente puede jugar un papel importante consiguiendo unas prestaciones satisfactorias mediante la implementación de una caché de los bloques de archivos utilizados recientemente en el cliente.

◊ **Interfaz del servicio de archivos plano.** La Figura 8.6 contiene una definición de la interfaz para un servicio de archivos planos. Es la interfaz RPC utilizada por los módulos cliente. No es utilizada directamente por los programas a nivel de usuario, normalmente. Un *IdArchivo* es inválido si el archivo a que se refiere no está presente en el servidor que procesa la solicitud o si sus permisos de acceso son inapropiados para la operación solicitada. Todos los procedimientos de la interfaz excepto *Crea* lanzan excepciones si el argumento *IdArchivo* contiene un UFID inválido o el usuario no tiene los derechos de acceso suficientes. Estas excepciones se han omitido por la claridad de la definición.

Las operaciones más importantes son las de lectura y escritura. Tanto la operación de lectura como la de escritura necesitan un parámetro *i* especificando una posición en el archivo. La operación de lectura copia la secuencia de *n* elementos de datos comenzando en el elemento *i* del archivo especificado en *Datos* que se devuelve entonces al cliente. La operación *Escribe* copia la secuencia de elementos de datos de *Datos* en el archivo especificado comenzando en el elemento *i*, reemplazando el contenido anterior del archivo en la posición correspondiente y extendiendo el archivo si es necesario.

Crea crea un archivo nuevo, vacío y devuelve el UFID que se ha generado. *Elimina* borra el archivo especificado.

DameAtributos y *PonAtributos* permiten a los usuarios acceder al registro de los atributos. *DameAtributos* está disponible generalmente para cualquier usuario que acceda al archivo. El acceso a la operación *PonAtributos* suele estar restringida normalmente al servicio de directorio que accede

<i>Lee(IdArchivo, i, n) → Datos</i>	Si $1 \leq i \leq \text{Tamaño}(\text{Archivo})$: Lee una secuencia de hasta <i>n</i> elementos del archivo, partiendo del elemento <i>i</i> y la devuelve en <i>Datos</i> .
<i>Escribe(IdArchivo, i, Datos)</i>	Si $1 \leq i \leq \text{Tamaño}(\text{Archivo}) + 1$: Escribe una secuencia de <i>Datos</i> sobre el archivo, partiendo del elemento <i>i</i> , y extendiendo el archivo si es preciso.
<i>Crea() → IdArchivo</i>	Crea un nuevo archivo de tamaño 0 y obtiene un UFID para él.
<i>Elimina(IdArchivo)</i>	Elimina el archivo del almacén de archivos.
<i>DameAtributos(IdArchivo) → Atrib</i>	Obtiene los atributos del archivo.
<i>PonAtributos(IdArchivo, Atrib)</i>	Pone los atributos del archivo (sólo aquellos que le están permitidos en la Figura 8.3.)

Figura 8.6. Operaciones del servicio de archivos plano.

al archivo. Los valores de la longitud y de las partes de marcas de tiempo del registro de atributos

~~no son afectados por los cambios que suceden en el archivo.~~

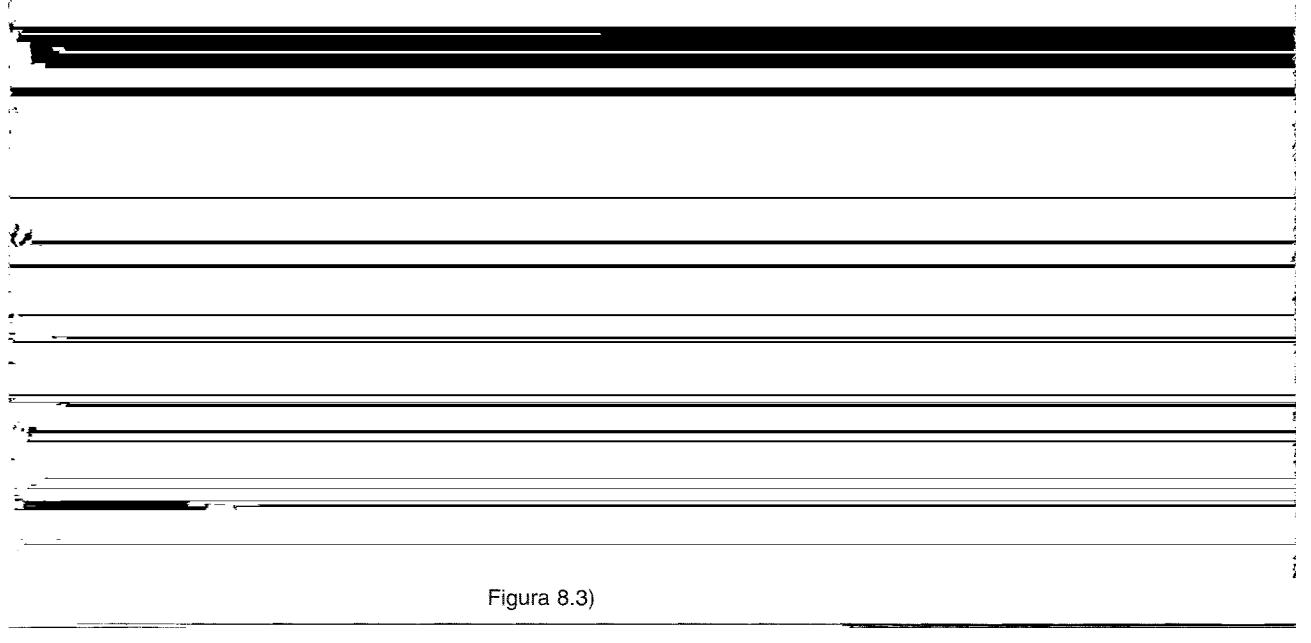


Figura 8.3)

ción de derechos de acceso, y se usarán para otros acceso, el servidor ya no sería sin estado. Se pueden adoptar dos aproximaciones alternativas a este último problema:

- Se realiza una comprobación de acceso cuando se convierte un nombre de archivo en un UFID, y los resultados se codifican en forma de una habilitación (ver Sección 7.2.4), que se devuelve al cliente para su envío con las solicitudes posteriores.
- Se envía la identidad del usuario con cada solicitud del cliente, y las comprobaciones de acceso se realizan en el servidor para cada operación sobre el archivo.

Ambos métodos permiten una implementación de servidor sin estado, y ambas se han utilizado en los sistemas de archivos distribuidos. El segundo es más común, y se utiliza tanto en NFS como en AFS. Ninguna de estas aproximaciones resuelve el problema de seguridad relacionado con las identidades olvidadas del usuario. Hemos visto en el Capítulo 7 que este problema puede abordarse mediante el uso de firmas digitales. Kerberos es un esquema de autenticación efectivo que ha sido aplicado tanto en NFS como en AFS.

En nuestro modelo abstracto, no hacemos suposiciones sobre el método con el que debe estar implementado el control de acceso. La identidad del usuario se pasa como un parámetro implícito y puede utilizarse cuando sea preciso.

◊ **Interfaz del servicio de directorio.** La Figura 8.7 contiene una definición de la interfaz RPC para un servicio de directorio. El propósito principal del servicio de directorio es proporcionar un servicio para trasladar nombres a UFID. Con este fin, se mantienen archivos de directorios que contienen las equivalencias entre los nombres de los archivos y cada UFID. Cada directorio se almacena en un archivo convencional con una UFID, de forma que el servicio de directorio es un cliente del servicio de archivos.

Definimos únicamente las operaciones sobre directorios individuales. Para cada operación, se precisa una UFID para el archivo que contiene el directorio (en el parámetro *Dir*). La operación *Busca* en el servicio básico de directorios realiza una traducción sencilla *Nombre* → *UFID*. Es un bloque básico para su uso en otros servicios o para realizar traducciones más complejas en el módulo del cliente, como la interpretación jerárquica de nombres encontrada en UNIX. Como antes, las excepciones producidas por derechos de acceso no adecuados se omiten de las definiciones.

Hay dos operaciones para modificar directorios: *AñadeNombre* y *DesNombre*. *AñadeNombre* añade una entrada al directorio e incrementa el campo de contador de referencias en el registro de atributos del archivo.

DesNombre elimina una entrada de un directorio y decremente el contador de referencias. Si esto produce que el contador de referencias llegue a cero, se elimina el archivo. *DameNombres* se proporciona para permitir a los clientes examinar el contenido de los directorios y para implementar operaciones de concordancia de patrones de nombres de archivos como las que se encuentran en el intérprete de órdenes de UNIX. Devuelven todos o un subconjunto de los nombres almacenados.

Busca(*Dir*, *Nombre*) → *IdArchivo*
— lanza *NoEncontrado*

AñadeNombre(*Dir*, *Nombre*, *Archivo*)
— lanza *NombreDuplicado*

DesNombre(*Dir*, *Nombre*)
— lanza *NoEncontrado*

DameNombres(*Dir*, *Patrón*) → *SecNombres*

Busca el texto *Nombre* en el directorio y devuelve el UFID relevante.
Si *Nombre* no está en el directorio, lanza una excepción.

Si *Nombre* no está en el directorio, añade (*Nombre*, *Archivo*) al directorio y actualiza el registro de atributos de archivo.

Si *Nombre* está en el directorio: la entrada que contiene *Nombre* se elimina del directorio.
Si *Nombre* no está en el directorio: lanza una excepción.

Devuelve todos los nombres del directorio que concuerdan con la expresión regular *Patrón*.

Figura 8.7. Operaciones del servicio de directorio.

dos en un directorio dado. Los nombres son seleccionados mediante comparación de patrones frente a una expresión regular proporcionada por el cliente.

La disponibilidad de reconocimiento de patrones en las operación *DameNombres* permite a los usuarios determinar los nombres de uno o más archivos al proporcionar una especificación incompleta de los caracteres de los nombres. Una expresión regular es una especificación de una clase de cadenas de caracteres en forma de una expresión que contiene una combinación de subcadenas literales y símbolos que representan caracteres variables u ocurrencias repetidas de caracteres o subcadenas.

◇ **Sistema de archivos jerárquico.** Un servicio de archivos jerárquico, como uno de los que proporciona UNIX, consiste en un número de directorios organizados en una estructura de árbol. Cada directorio contiene los nombres de los archivos y otros directorios que son accesibles desde él. Cualquier archivo o directorio puede ser referenciado con un nombre de ruta (*path*), un nombre compuesto de varias partes que representa una ruta a través del árbol. La raíz tiene un nombre que le distingue y cada archivo o directorio tiene un nombre en un directorio. El esquema de nominación de archivos de UNIX no es una jerarquía estricta, los archivos pueden tener varios nombres y pueden estar en varios directorios. Esto se implementa mediante una operación de enlace (*link*), que añade un nuevo nombre para un archivo en un directorio especificado.

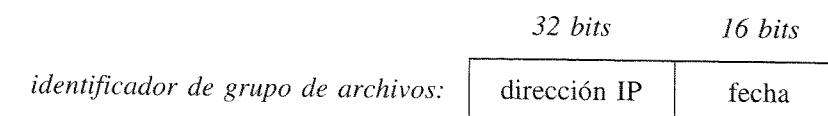
Un sistema de nominación de archivos como el de UNIX puede ser implementado desde el módulo cliente utilizando los servicios de directorio y archivos planos que hemos definido. Se construye una red de directorios estructurados en forma de árbol con los archivos en las hojas y los directorios en los otros nodos del árbol. La raíz del árbol es un directorio con una UFID *bien conocida*. Se da soporte a varios nombres un archivo utilizando la operación *AñadeNombre* y el campo de contador de referencias del registro de atributos.

Se puede proporcionar una función en el módulo del cliente que consiga la UFID de un archivo dado un nombre de ruta. La función interpreta el nombre de ruta comenzando desde la raíz, utilizando *Busca* para obtener la UFID de cada directorio en la ruta.

En un servicio jerárquico de archivos, los atributos asociados con los archivos deben incluir un tipo que distingue a los archivos ordinarios de los directorios. Esto se utiliza cuando se sigue una ruta para garantizar que cada parte del nombre, excepto la última, se refiere a un directorio.

◇ **Agrupación de archivos.** Un *grupo de archivos* es una colección de archivos ubicada en un servidor dado. Un servidor puede mantener varios grupos de archivos y los grupos pueden ser reubicados entre servidores, pero un archivo no puede cambiar el grupo al que pertenece. Una construcción similar (llamada *filesystem-volumen*) se utiliza en UNIX y en la mayoría de los sistemas operativos. Los grupos de archivos se introdujeron inicialmente para trasladar colecciones de archivos almacenados en cartuchos de disco extraíbles entre computadores. En un servicio de archivos distribuidos, los grupos de archivos permiten la asignación de archivos a servidores de archivos almacenados en varios servidores. En un sistema de archivos distribuidos que soporta grupos de archivos, la representación de UFID incluye un componente identificador de grupo de archivos, permitiendo al módulo cliente en cada computador cliente tomar la responsabilidad de enviar las solicitudes al servidor que mantiene el grupo de archivos relevante.

Los identificadores de grupo de archivos deben ser únicos a lo largo de un sistema distribuido. Puesto que se pueden trasladar grupos de archivos, y los sistemas distribuidos que están separados inicialmente se pueden mezclar para formar un sistema único, la única forma de asegurar que los identificadores de grupo serán siempre distintos en un sistema dado es generarlos con un algoritmo que garantice la unicidad global. Por ejemplo, cuando se crea un nuevo grupo de archivos, se puede generar un identificador único de archivos concatenando la dirección IP de 32 bits de la máquina que crea el nuevo grupo con un entero de 16 bits derivado de la fecha, produciendo un entero único de 48 bits:



Observe que la dirección IP no debe utilizarse para el propósito de localizar el grupo de archivos, puesto que puede ser trasladado a otro servidor. En lugar de eso, hay que mantener en el servicio de archivos una traducción entre identificadores de grupo y servidores.

8.3. SISTEMA DE ARCHIVOS EN RED DE SUN (NFS)

La Figura 8.8 representa la arquitectura de NFS de Sun. Sigue el modelo abstracto definido en la sección precedente. Todas las implementaciones de NFS soportan el protocolo de NFS: un conjunto de llamadas a procedimientos remotos que proporcionan el medio para que los clientes realicen operaciones en un almacén de archivos remotos. El protocolo NFS es independiente del sistema operativo pero fue desarrollado originalmente para su utilización en redes de sistemas UNIX, y nosotros describiremos la implementación del protocolo NFS en UNIX (versión 3).

El módulo *servidor NFS* reside en el núcleo de cada computador que actúa como un servidor NFS. Las solicitudes que se refieren a archivos en un sistema de archivos remoto se traducen en el módulo cliente a operaciones del protocolo NFS y después se trasladan al módulo servidor NFS en el computador que mantiene el sistema de archivos relevante.

Los módulos cliente y servidor NFS se comunican utilizando llamadas a procedimientos remotos. El sistema RPC de SUN, descrito en la Sección 5.3.1, se desarrolló para su uso en NFS. Puede configurarse para utilizar UDP o TCP, y el protocolo NFS es compatible con ambos. Se incluye un servicio de enlace que permite a los clientes encontrar los servicios de una máquina a partir del nombre. La interfaz RPC para el servidor NFS es abierta: cualquier proceso puede enviar solicitudes a un servidor NFS. Si las solicitudes son válidas e incluyen credenciales válidas del usuario, serán ejecutadas. El envío de credenciales firmadas del usuario puede requerirse como una característica adicional de seguridad, como lo puede ser la encriptación de los datos para privacidad e integridad.

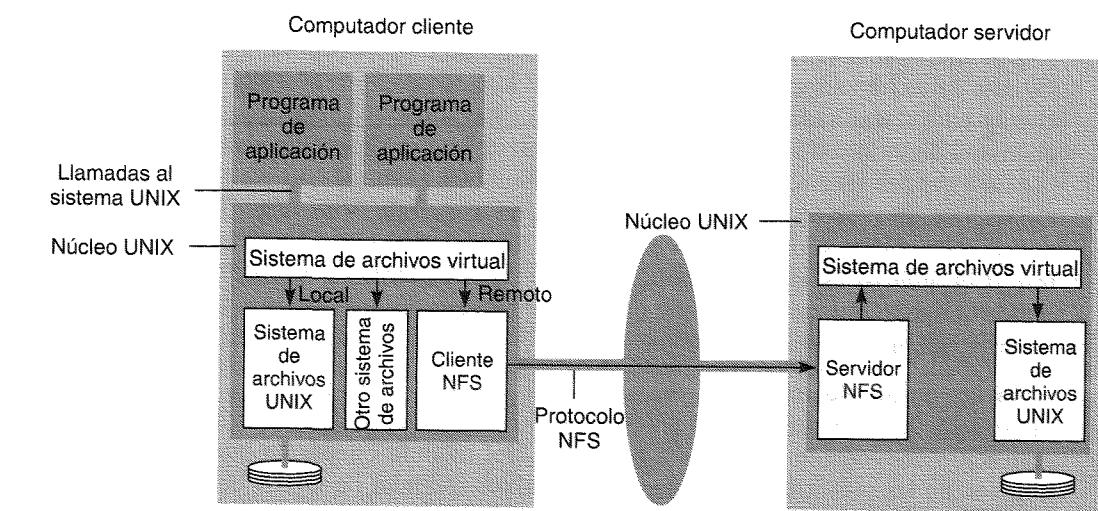


Figura 8.8. Arquitectura NFS.

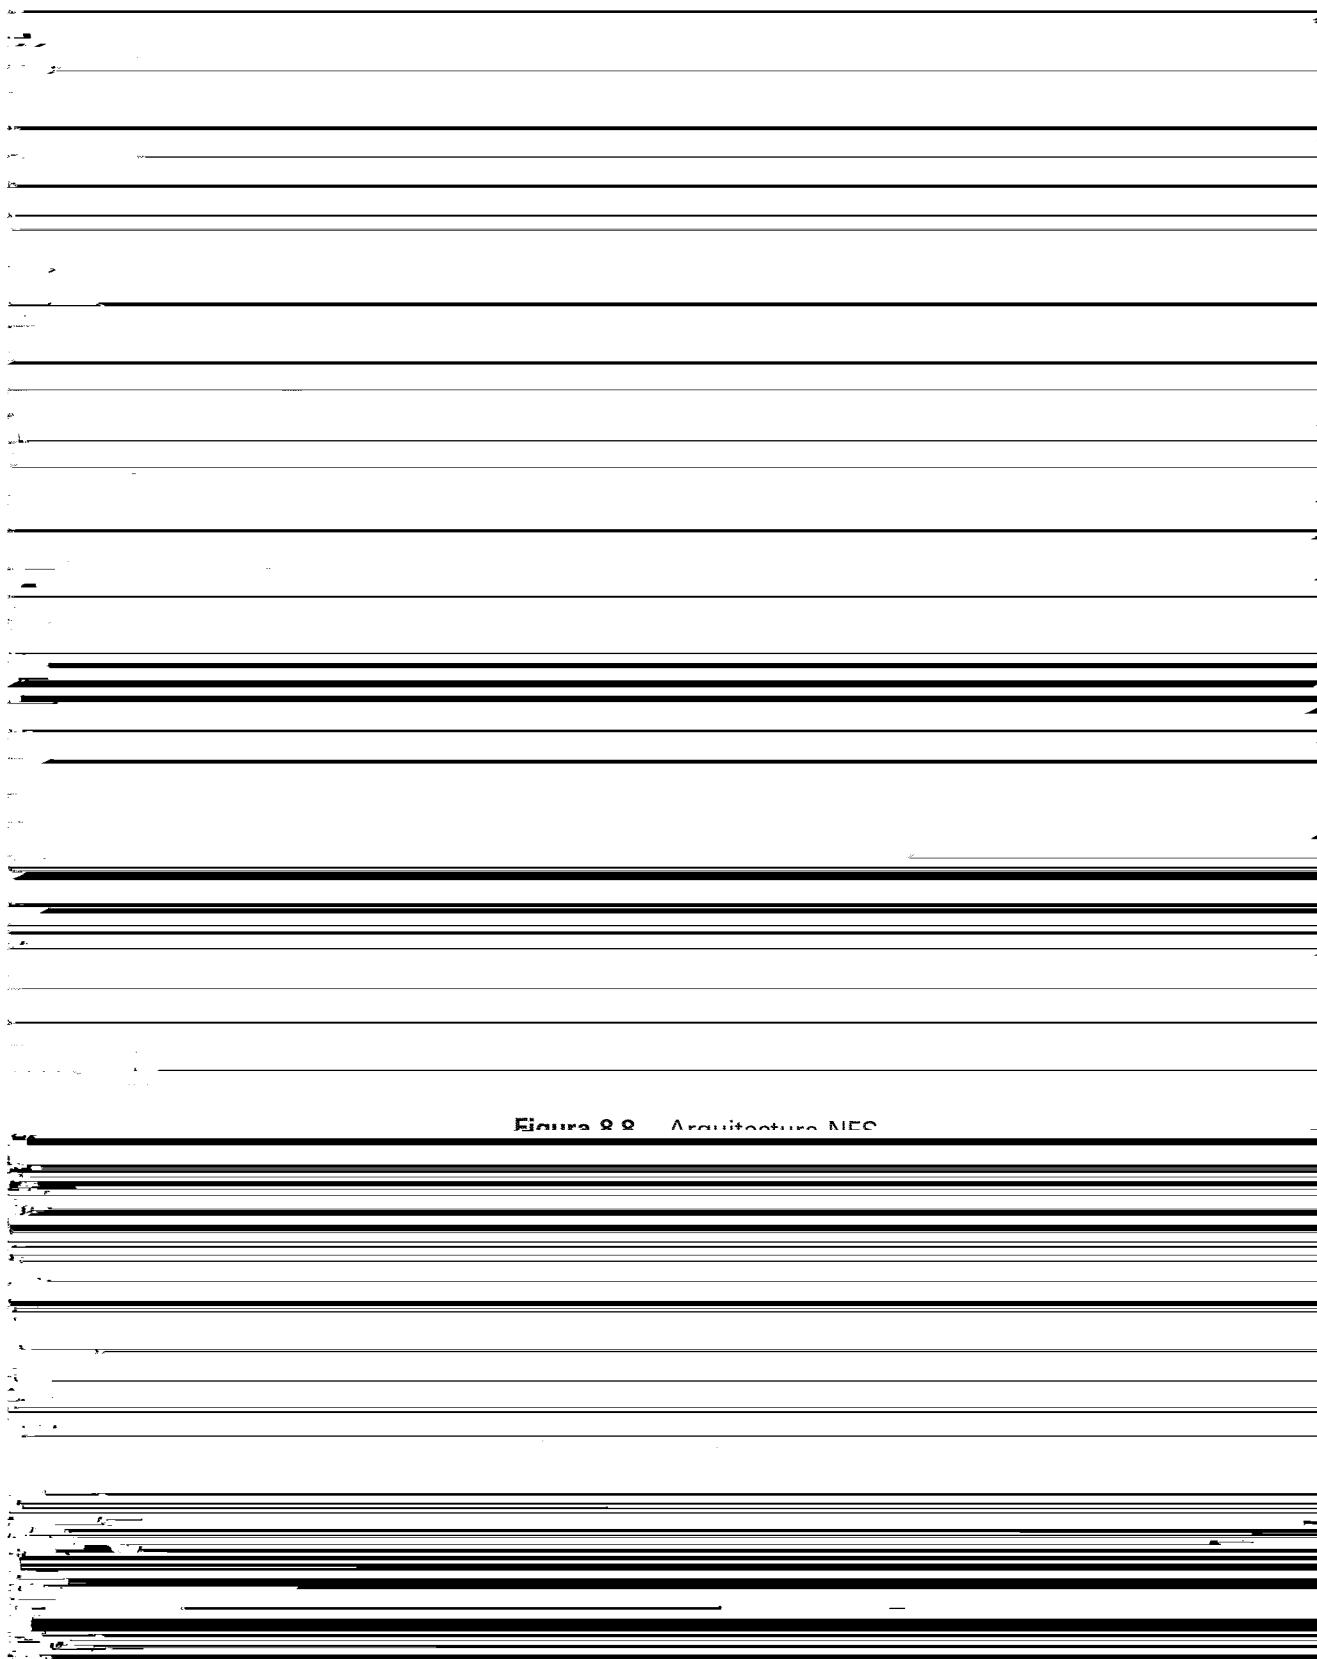


Figura 8.8 Arquitectura NFS

- Los programas de usuario pueden acceder a los archivos mediante llamadas del sistema de UNIX sin recompilación o recarga.
- Un único módulo cliente sirve a todos los procesos del nivel del usuario, con una caché compartida de los bloques utilizados recientemente (se describirán posteriormente).
- La clave de encriptación utilizada para autenticar las ID del usuario pasadas al servidor (ver más adelante) puede retenerse en el núcleo, previniendo la impersonación por clientes a nivel de usuario.

El módulo cliente de NFS coopera con el sistema de archivos virtual en cada máquina cliente. Funciona de una manera semejante al sistema de archivos convencional de UNIX, transfiriendo bloques de archivos hacia y desde el servidor y haciendo *caching* de los bloques en la memoria local cuando es posible. Comparte el mismo búfer de caché que el utilizado por el sistema de entrada-salida local. Pero puesto que varios clientes en diferentes máquinas pueden acceder simultáneamente al mismo archivo remoto, se plantea un nuevo y significativo problema de consistencia de caché.

◊ **Control de acceso y autenticación.** A diferencia del sistema de archivos convencional UNIX, el servidor NFS es sin estado y no mantiene archivos abiertos en nombre de sus clientes. Por lo tanto el servidor debe comprobar la identidad del usuario frente a los atributos de acceso del archivo en cada solicitud, para ver si el usuario tiene permiso de acceso al archivo de la forma solicitada. El protocolo Sun RPC requiere que los clientes envíen la información de autenticación del usuario (por ejemplo, los convencionales 16 bits de la ID del usuario y del grupo de UNIX) con cada solicitud y ésta se comprueba frente a los permisos de acceso en los atributos del archivo. Estos parámetros adicionales no se muestran en nuestra revisión del protocolo NFS de la Figura 8.9, vienen dados automáticamente por el sistema RPC.

En la forma más simple, hay una laguna de seguridad en este mecanismo de control de acceso. Un servidor NFS proporciona una interfaz RPC convencional en un puerto bien conocido en cada máquina y cualquier proceso puede comportarse como un cliente, enviando solicitudes al servidor para acceder o actualizar un archivo. El cliente puede modificar las llamadas RPC para incluir la ID de cualquier usuario, haciéndose pasar por el usuario sin su conocimiento o permiso. Esta laguna de seguridad ha sido cerrada con el uso de una opción en el protocolo RPC para la encriptación de la información de autenticación del usuario. Más recientemente, se ha integrado Kerberos en Sun NFS para proporcionar una solución más fuerte y completa a los problemas de autenticación y seguridad del usuario, que nosotras describimos más adelante.

◊ **Interfaz del servidor NFS.** En la Figura 8.9 se ve una representación simplificada de la interfaz RPC proporcionada por el servidor NFS (definida en RFC 1813 [Callaghan y otros 1995]). Las operaciones NFS de acceso al archivo *read*, *write*, *getattr* y *setattr* son casi idénticas a las operaciones *Lee*, *Escribe*, *DameAtributos* y *PonAtributos* definidas en nuestro modelo de servicio de archivos planos (Figura 8.6). La operación *lookup* y la mayoría de las demás operaciones de directorio definidas en la Figura 8.9 son semejantes a las de nuestro modelo de servicios de directorio (Figura 8.7).

Las operaciones de archivo y directorio están integradas en un único servicio, la creación e inserción de nombres de archivo en directorios se realiza en una única operación *create* que toma el nombre del nuevo archivo y el apuntador de archivo del directorio destino (*aadir*) como argumentos. Las otras operaciones NFS sobre directorios son *create*, *remove*, *rename*, *link*, *symlink*, *readlink*, *mkdir*, *rmdir*, *readdir* y *statfs*. Se parecen a sus equivalentes UNIX con la excepción de *readdir*, que proporciona un método independiente de la representación para leer el contenido de directorios, y *statfs*, que proporciona la información del estado en los sistemas de archivos remotos.

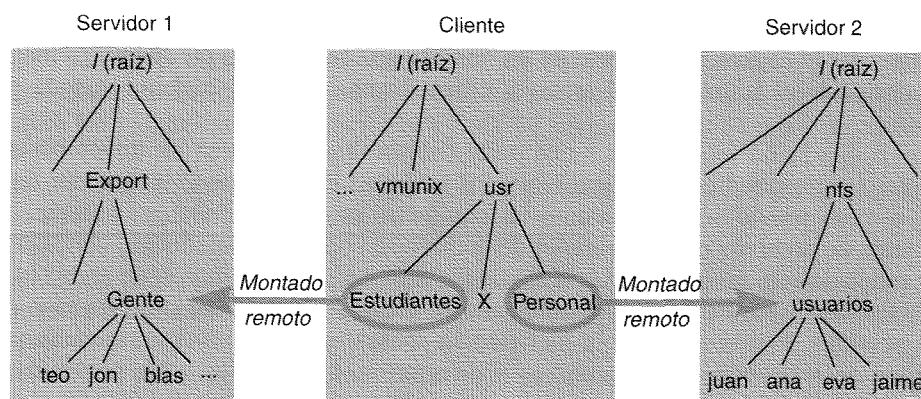
◊ **Servicio de montado.** El montado de los sub-árboles de los sistemas de archivos remotos por los clientes está soportado por un proceso de *servicio de montado* separado que se ejecuta a

<i>lookup(aadir, nombre) → aa, atrib</i>	Devuelve el apuntador del archivo y los atributos para el archivo <i>nombre</i> en el directorio <i>aadir</i> .
<i>create(aadir, nombre, atrib) → aanuevo, atrib</i>	Crea un nuevo archivo <i>nombre</i> en el directorio <i>aadir</i> con los atributos <i>atrib</i> y devuelve el nuevo apuntador de archivo y sus atributos.
<i>remove(aadir, nombre) → estado</i>	Elimina el archivo <i>nombre</i> del directorio <i>aadir</i> .
<i>getattr(aa) → atrib</i>	Devuelve los atributos del archivo <i>aa</i> . (Igual que la llamada UNIX <i>stat()</i> .)
<i>setattr(aa) → atrib</i>	Establece los atributos (modo, ID usuario, ID grupo, tamaño, tiempo de acceso y tiempo de modificación de un archivo). Si se pone el tamaño a 0 se trunca el archivo.
<i>read(aa, despl, conteo) → atrib, datos</i>	Devuelve hasta <i>conteo</i> bytes de datos desde el archivo, comenzando en <i>despl</i> . También devuelve los atributos más recientes del archivo.
<i>write(aa, despl, conteo, datos) → atrib</i>	Escribe <i>conteo</i> bytes de datos sobre el archivo, comenzando en <i>despl</i> . También devuelve los atributos del archivo tras la operación de escritura.
<i>rename(aadir, nombre, destadir, destnombre) → estado</i>	Cambia el nombre del archivo <i>nombre</i> del directorio <i>aadir</i> en <i>destnombre</i> del directorio <i>destadir</i> .
<i>link(nuevoaddir, nuevonombre, aadir, nombre) → estado</i>	Crea una entrada <i>nuevonombre</i> en el directorio <i>nuevoaddir</i> que se refiere al archivo <i>nombre</i> en el directorio <i>aadir</i> .
<i>symlink(nuevoaddir, nuevonombre, texto) → estado</i>	Crea una entrada <i>nuevonombre</i> en el directorio <i>nuevoaddir</i> , con un <i>enlace simbólico</i> con el valor <i>texto</i> . El servidor no interpreta <i>texto</i> pero crea un archivo de enlace simbólico para alojarlo.
<i>readlink(aa) → texto</i>	Devuelve el <i>texto</i> asociado con el archivo de enlace simbólico identificado por <i>aa</i> .
<i>mkdir(aadir, nombre, atrib) → nuevoaa, atrib</i>	Crea un nuevo directorio <i>nombre</i> con los atributos <i>atrib</i> y devuelve el nuevo apuntador de archivo (<i>nuevoaa</i>) y sus atributos.
<i>rmdir(aadir, nombre) → estado</i>	Elimina el directorio vacío <i>nombre</i> del directorio padre <i>aadir</i> . Falla si el directorio no está vacío.
<i>readdir(aadir, cookie, conteo) → entradas</i>	Devuelve <i>conteo</i> bytes de entradas de directorio desde el directorio <i>aadir</i> . Cada entrada contiene un nombre de archivo, un apuntador a archivo, y un puntero opaco a la siguiente entrada del directorio, denominado <i>cookie</i> (galletita). <i>cookie</i> se emplea en las siguientes llamadas a <i>readdir</i> para comenzar la lectura desde la siguiente entrada. Si se pone el valor de <i>cookie</i> a 0, lee desde la primera entrada.
<i>statfs(aa) → estadosf</i>	Devuelve información sobre el sistema de archivos (tal como tamaño de bloque, número de bloques libres y demás) para el sistema de archivos que contiene el archivo <i>aa</i> .

Figura 8.9. Operaciones del servidor NFS (simplificado).

nivel de usuario en cada computador servidor NFS. En cada servidor, hay un archivo con un nombre bien conocido (*/etc/exports*) conteniendo los nombres de los sistemas de archivos locales que están disponibles para montado remoto. Se asocia una lista de acceso con cada nombre del sistema de archivos indicando qué máquinas están autorizadas para montar el sistema de archivos.

Los clientes utilizan una versión modificada del mandato *mount* de UNIX para solicitar el montado de un sistema de archivos remoto, especificando el nombre de la máquina remota, el nombre de la ruta de un directorio en el sistema de archivos remoto y el nombre local con el que va a ser montado. El directorio remoto puede ser cualquier sub-árbol del sistema de archivos remoto solicitado, permitiendo a los clientes montar cualquier parte del sistema de archivos remoto. El



Nota: El sistema montado en */usr/estudiantes* en el cliente, en realidad es un sub-árbol ubicado en */export/gente* en el Servidor 1; el sistema de archivos montado en */usr/personal* en el cliente es realmente el sub-árbol */nfs/users* ubicado en el Servidor 2.

Figura 8.10. Sistemas de archivos locales y remotos accesibles desde un cliente NFS.

mandato *mount* modificado comunica con el proceso del servicio de montado en la máquina remota, utilizando un *protocolo de montado*. Éste es un protocolo RPC e incluye una operación que toma un nombre de ruta de directorio y devuelve el asidero de archivo del directorio especificado si el cliente tiene permiso de acceso para el sistema de archivos relevante. La ubicación (dirección IP y número de puerto) del servidor y el asidero de archivo para el directorio remoto se pasan a la capa VFS y al cliente NFS.

La Figura 8.10 muestra un *Cliente* con dos almacenes de archivos montados remotamente. Los nodos *gente* y *usuarios* en los sistemas de archivos en el *Servidor 1* y *Servidor 2* están montados sobre los nodos *estudiantes* y *personal* en el almacén de archivos local del *Cliente*. El significado de esto es que programas que se ejecuten en *Cliente* pueden acceder a archivos en *Servidor 1* y *Servidor 2* utilizando nombres de ruta como */usr/estudiantes/jon* y */usr/personal/ana*.

Los volúmenes remotos pueden tener un *montado rígido* (*hard-mounted*) o *flexible* (*soft-mounted*) en el computador del cliente. Cuando un proceso a nivel de usuario accede a un archivo en un volumen montado rígidamente, el proceso se suspende hasta que se completa la solicitud y si la máquina remota no está disponible por alguna razón el módulo cliente NFS continúa reintentando la solicitud hasta que se satisface. Por tanto en el caso de un fallo del servidor, los procesos a nivel de usuario se suspenden hasta que el servidor rearrastra y entonces continúan justo como si no hubiera habido fallo. Pero si el volumen relevante tiene un montado flexible, el módulo cliente NFS devuelve una indicación de fallo a los procesos a nivel de usuario después de un pequeño número de intentos. Los programas construidos adecuadamente detectarán el fallo y tomarán las acciones de recuperación e información adecuadas. Pero muchas utilidades y aplicaciones UNIX no comprueban el fallo de las operaciones de acceso a archivos y éstas se comportan de forma impredecible en el caso de fallo de un volumen con un montado flexible. Por esta razón, muchas instalaciones utilizan exclusivamente montado rígido, con la consecuencia que los programas son incapaces de recuperarse adecuadamente cuando un servidor NFS está indisponible durante un período de tiempo significativo.

◊ **Traducción de un nombre de ruta.** Los sistemas de archivos UNIX traducen nombres de ruta de archivo compuestos a referencias de i-nodo, en un proceso paso a paso cuando se utilicen las llamadas del sistema *open*, *creat* o *stat*. En NFS, los nombres de ruta no pueden traducirse en el servidor, porque el nombre puede cruzar un «punto de montado» en el cliente, los directorios que mantienen diferentes partes de un nombre compuesto pueden residir en volúmenes en diferentes

servidores. Por lo tanto los nombres de ruta se analizan y su traducción se realiza de manera interactiva por el cliente. Cada parte de un nombre que se refiere a un directorio montado remotamente se traducido al apuntador del archivo utilizando una solicitud *lookup* separada para el servidor remoto.

La operación *lookup* busca una parte del nombre de ruta en un directorio dado y devuelve el asidero correspondiente del archivo y los atributos del mismo. El apuntador devuelto del archivo en el paso previo se utiliza como un parámetro en el paso *lookup* siguiente, el identificado del sistema de archivos en el apuntador de archivo se compara inicialmente con las entradas en la tabla de montado remoto mantenida en el cliente para ver si otro almacén de archivos montados remotamente debiera ser accedido. Manteniendo en caché los resultados de cada paso en las traducciones de nombres de ruta se alivia la inefficiencia aparente de este proceso, sacando partido de la proximidad de referencia de los archivos y directorios, los usuarios y los programas acceden normalmente a los archivos de solo uno o un pequeño número de directorios.

◊ **Automontador.** El automontador se añadió a la implementación UNIX de NFS para poder montar un directorio remoto dinámicamente cuando un punto de montado «vacío» es referenciado por un cliente. La implementación original del automontador se ejecutaba como un proceso UNIX a nivel de usuario en cada computador cliente. Las versiones posteriores (llamadas *autofs*, se implementaron en el núcleo de Solaris y Linux. Aquí describimos la versión original.

El automontador mantiene una tabla de puntos de montado (nombres de ruta) con una referencia a uno o más servidores NFS por cada punto. Se comporta igual que un servidor local NFS en la máquina del cliente. Cuando el módulo cliente NFS intenta resolver un nombre de ruta que incluye uno de estos puntos de montado, pasa una solicitud *lookup()* al automontador local que localiza el volumen solicitado en su tabla y envía una solicitud de «prueba» a cada servidor de la lista. Se monta el volumen del primer servidor que responda, utilizando el servicio normal de montado. El volumen montado se enlaza con un punto de montado utilizando un enlace simbólico, por lo que el acceso a él no precisará de otras solicitudes al automontador. El acceso al archivo se realiza de la forma normal sin más referencias al automontador a menos que no haya referencias al enlace simbólico durante varios minutos. En este caso, el automontador desmonta el volumen remoto.

Las últimas implementaciones del núcleo reemplazan los enlaces simbólicos con montados reales, impidiendo algunos problemas que se presentan con las aplicaciones que hacen *caching* de los nombres de ruta temporales utilizados en los automontadores a nivel de usuario [Callaghan 1999].

Puede conseguirse una forma sencilla de replicación de sólo lectura listando los distintos servidores que contienen copias idénticas de un volumen o un sub-árbol de archivos frente a un nombre en la tabla de automontador. Esto se utiliza en sistemas de archivos utilizados frecuentemente que cambian con poca frecuencia, como los programas binarios de UNIX. Por ejemplo, se pueden mantener copias del directorio */usr/lib* y su subárbol en más de un servidor. En la primera ocasión que se abre un archivo de */usr/lib* en un cliente, se enviarán mensajes de prueba a todos los servidores, y el primero que responda será montado en el cliente. Esto proporciona un grado limitado de tolerancia a fallos y balance de carga, puesto que el primer servidor que responda será uno que no ha fallado y es probable que sea uno que no está fuertemente ocupado sirviendo otras solicitudes.

◊ **Caché en el servidor.** El mantenimiento de caché tanto en el computador del cliente como en el servidor son características indispensables de las implementaciones NFS con el fin de obtener las prestaciones adecuadas.

En los sistemas UNIX convencionales, las páginas de archivo, los directorios y los atributos de archivo que han sido leídas del disco son retenidas en un *cache búfer* en la memoria principal hasta que se precisa el espacio del búfer para otras páginas. Si un proceso efectúa entonces una solicitud de lectura o escritura de una página que ya está en la caché, podrá satisfacerse sin hacer otro acceso a disco. El modo de *lectura anticipada* (*read-ahead*) se adelanta a los accesos de lectura y busca las páginas que siguen a las que han sido leídas más recientemente, y el modo de *escritura retardada* (*delayed-write*) optimiza las escrituras: cuando una página ha sido alterada (por una solicitud de escritura), su nuevo contenido se escribe en disco sólo cuando se necesita el búfer para otra página. Para salvaguardar los datos frente a pérdidas por una caída del sistema, la operación *sync* de UNIX pasa las páginas actualizadas a disco cada 30 segundos. Las técnicas de caché funcionan en un entorno UNIX tradicional porque todas las solicitudes de lectura y escritura realizadas por los procesos a nivel de usuario pasan a través de una única caché que está implementada en el espacio del núcleo de UNIX. La caché se mantiene actualizada y los accesos a los archivos no pueden evitar la caché.

Los servidores NFS utilizan la caché en la máquina de servidor como se utiliza para otros accesos a archivos. La utilización de la caché del servidor para mantener los bloques de disco leídos recientemente no plantea ningún problema de consistencia, pero cuando un servidor realiza operaciones de escritura, se necesitan medidas extra para garantizar que los clientes pueden estar seguros que los resultados de las operaciones de escritura son persistentes, incluso cuando ocurren caídas del servidor. En la versión 3 del protocolo NFS, la operación *write* ofrece para esto dos opciones (no representadas en la Figura 8.9):

1. Los datos recibidos de los clientes en las operaciones de *escritura* se almacenan en la memoria caché en el servidor y se escriben en disco antes de que se envíe una respuesta al cliente. Esto se llama *escritura a través* (*write-through*) de la caché. El cliente puede estar seguro de que los datos son almacenados persistentemente en el momento en el que se ha recibido la respuesta.
2. Los datos en las operaciones de *escritura* sólo se almacenan en la memoria caché. Éstos serán escritos en disco cuando se reciba una operación de *consumación* (*commit*) para el archivo relevante. El cliente puede estar seguro que los datos están almacenados persistentemente sólo cuando se ha recibido una respuesta a una operación de *consumación* para el archivo relevante. Los clientes de NFS estándar utilizan este modo de operación, emitiendo una *consumación* cuando se cierra un archivo que fue abierto para escritura.

La *consumación* es una operación adicional proporcionada en la versión 3 del protocolo NFS, se añadió para superar un cuello de botella en las prestaciones producido por el modo de operación de *escritura a través* en los servidores que reciben un gran número de operaciones *write*.

El requisito de *escritura a través* en los sistemas de archivos distribuidos es una instancia de los modos independientes de fallos discutidos en el Capítulo 1, los clientes continúan trabajando cuando un servidor falla, y los programas de aplicación pueden realizar acciones en la suposición de que los resultados de las escrituras previas han sido consumados en el almacenamiento del disco. Esto es improbable que ocurra en el caso de actualizaciones de archivos locales, dado que el fallo de un sistema de archivos locales es casi seguro produzca el fallo de todos los procesos de aplicación ejecutándose en el mismo computador.

◊ **Caché en el cliente.** El módulo cliente NFS emplea caché para los resultados de las operaciones *read*, *write*, *getattr*, *lookup* y *readdir*, con el fin de reducir el número de solicitudes transmitidas a los servidores. La caché del cliente introduce el potencial para que existan diferentes versiones de archivos o porciones de archivos en diferentes nodos cliente, porque las escrituras por un cliente no producen la actualización inmediata de las copias en la caché del mismo archivo en otros clientes. En su lugar, los clientes son responsables de sondear al servidor para comprobar la actualidad de los datos en la caché que ellos mantienen.

Para validar los bloques en la caché antes de que sean utilizados se emplea un método basado en marcas de tiempo. Cada elemento de datos o metadatos de la caché se etiqueta con dos marcas de tiempo:

Tc es el tiempo en el que la entrada en la caché fue validada últimamente.

Tm es el tiempo en el que el bloque fue modificado por última vez en el servidor.

T_m es el tiempo en el que el bloque fue modificado por última vez en el servidor.

a procesos a nivel de usuario que realizan tareas del sistema). El papel de los bio-demonios es realizar operaciones de lectura adelantada y escritura retrasada. Después de cada solicitud se avisa al bio-demonio, y éste solicita la transferencia de el siguiente bloque del archivo desde el servidor a la caché del cliente. En el caso de escritura el bio-demonio enviará un bloque al servidor cuando se haya llenado un bloque una operación del cliente. Los bloques de directorio se envían cuando se ha producido una modificación.

Los procesos bio-demonio mejoran las prestaciones, asegurando que el módulo cliente no se bloquea esperando la vuelta de las lecturas o la consumación de escrituras en el servidor. No hay un requisito lógico, puesto que en ausencia de lectura adelantada, una operación *read* en un proceso de usuario disparará una solicitud síncrona para el servidor relevante, y los resultados de *write* en los procesos de usuario serán transferidos al servidor cuando el archivo relevante se cierra o cuando el sistema de archivos virtual en el cliente lanza una operación *sync*.

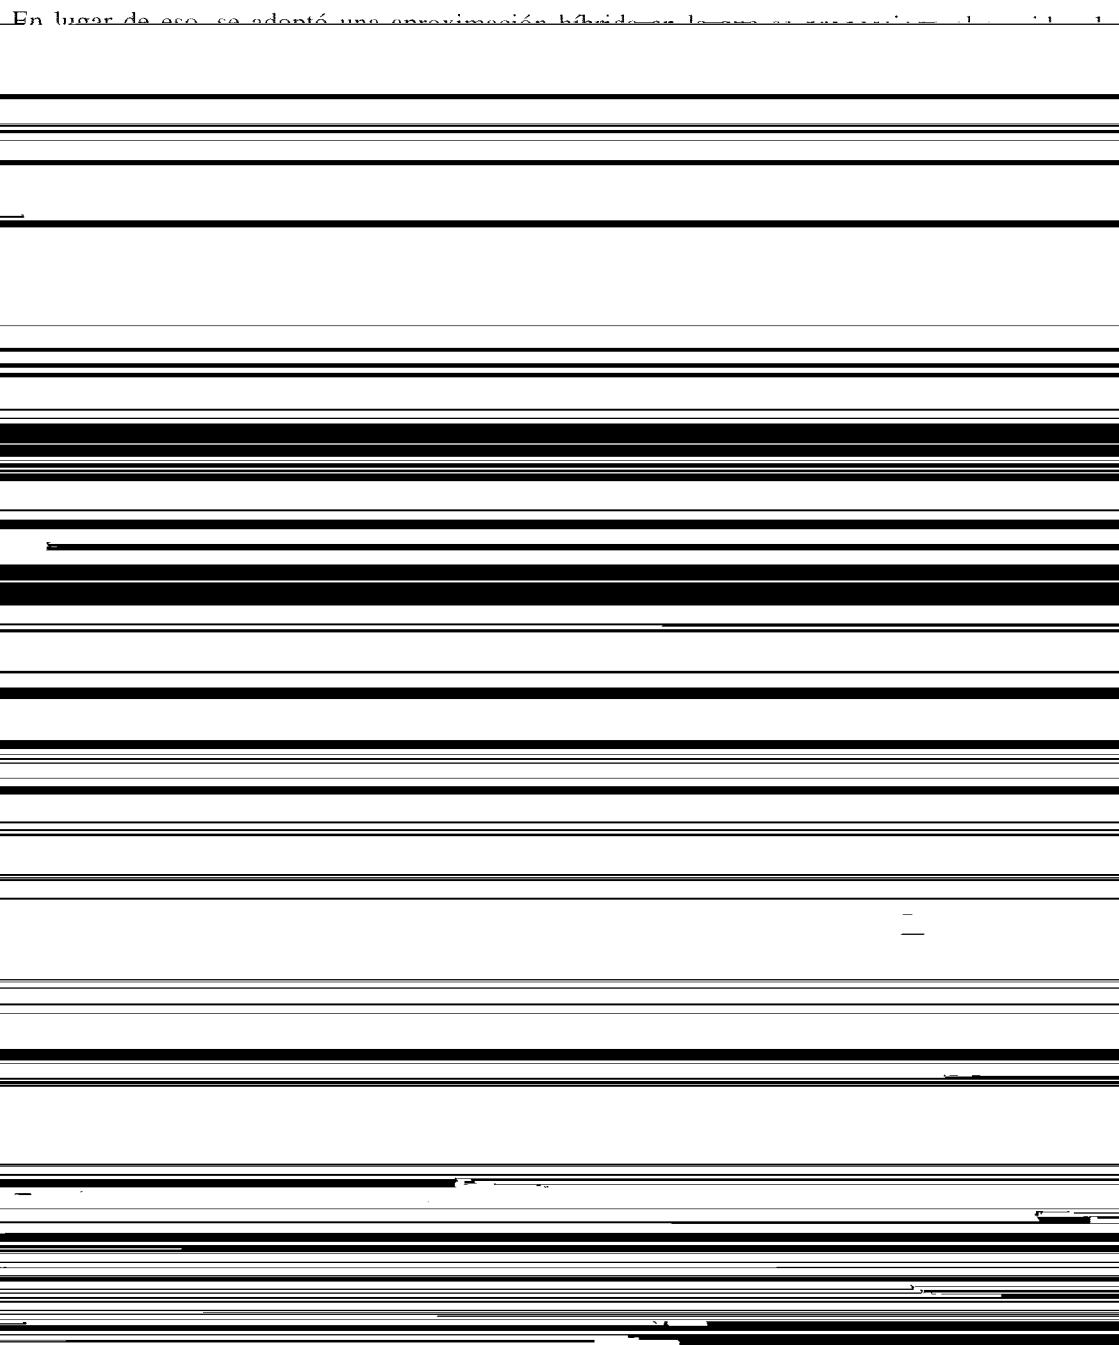
◊ **Otras optimizaciones.** El sistema de archivos de Sun está basado en el Sistema Rápido de Archivos (*Fast File System*, FFS) de UNIX BSD que utiliza bloques de disco de ocho kbytes, lo que resulta en menos llamadas al sistema de archivos para acceso a archivos secuenciales que en los sistemas UNIX anteriores. Los paquetes UDP utilizados para la implementación de Sun RPC se extienden a nueve kilobytes, permitiendo que una llamada RPC conteniendo un bloque entero como argumento sea transferida en un único paquete y minimice el efecto de la latencia de red cuando se lean archivos secuencialmente. En NFS versión 3 no hay límite en el tamaño máximo de los bloques de archivo que pueden ser mantenidos en las operaciones *read* y *write*, los clientes y los servidores pueden negociar tamaños más grandes que ocho kbytes si son capaces de mantenerlos.

Como se ha mencionado anteriormente la información del estado del archivo en la caché en los clientes debe actualizarse al menos cada tres segundos para los archivos activos. Para reducir la consecuente carga del servidor resultante de solicitudes *getattr*, todas las operaciones que se refieran a archivos o directorios son tomadas como solicitudes *getattr* implícitas, y los valores de los atributos actuales son acarreados con el resto de los resultados de la operación.

◊ **Haciendo seguro NFS con Kerberos.** En la Sección 7.6.2 se ha descrito el sistema de autenticación desarrollado en el MIT Kerberos, que ha llegado a ser un estándar industrial para servidores de intranet seguros contra accesos no autorizados y ataques de impostores. La seguridad de las implementaciones de NFS ha sido incrementada con el uso del esquema Kerberos para autenticar clientes. En esta subsección, describimos la «Kerberización» de NFS tal y como fue reailizada por los diseñadores de Kerberos.

En la implementación estándar original de NFS, la identidad del usuario se incluye en cada solicitud en forma de un identificador numérico no encriptado (el identificador fue encriptado en versiones posteriores de NFS). NFS no realiza ningún otro paso para comprobar la autenticidad del identificador proporcionado. Esto implica un alto grado de confianza en la integridad del computador cliente y en su software por NFS, mientras que el propósito de Kerberos y otros sistemas de seguridad basados en autenticación es reducir a un mínimo el rango de componentes sobre los que se supone dicha confianza. Esencialmente, al utilizar NFS en un entorno «Kerberizado» sólo se aceptarán solicitudes de clientes cuya identidad pueda ser comprobada que ha sido autenticada por Kerberos.

Una solución obvia, considerada por los desarrolladores de Kerberos, fue cambiar la naturaleza de las credenciales solicitadas por NFS para ser un sistema Kerberos basado en tickets y un autenticador de pleno derecho. Pero como NFS está implementado como un servidor sin estado, cada solicitud de acceso a un archivo individual se despacha por su validez intrínseca y entonces los datos de autenticación deberían incluirse en cada solicitud. Esto fue considerado inaceptablemente costoso dado el tiempo requerido para realizar la encriptaciones necesarias y que debieran llevarse a cabo añadiendo la biblioteca cliente Kerberos al núcleo de todas las estaciones de trabajo.



En lugar de eso, se adoptó una aproximación híbrida en la que se proporciona el servidor de montado NFS con todos los datos de autenticación de Kerberos para el usuario cuando se montan

adecuadamente, para producir espacios de nombre semejantes en todos los clientes. NFS soporta hardware y sistemas operativos heterogéneos. La implementación del servidor NFS es sin estado, permitiendo a los clientes y servidores recuperar la ejecución después de un fallo sin necesidad de ningún procedimiento de recuperación. La migración de archivos o sistemas de archivos no está soportada, excepto en el nivel de intervención manual para reconfigurar las directivas de montado después de un movimiento de un sistema de archivos a una nueva ubicación.

Las prestaciones de NFS mejoran mucho gracias a la caché de bloques de archivo en cada computador cliente. Esto es importante para la obtención de prestaciones satisfactorias pero produce alguna desviación de la semántica de actualización de una copia de archivo estricta UNIX.

Los otros objetivos de diseño de NFS y las extensiones a ellos que han sido conseguidas, se discuten a continuación.

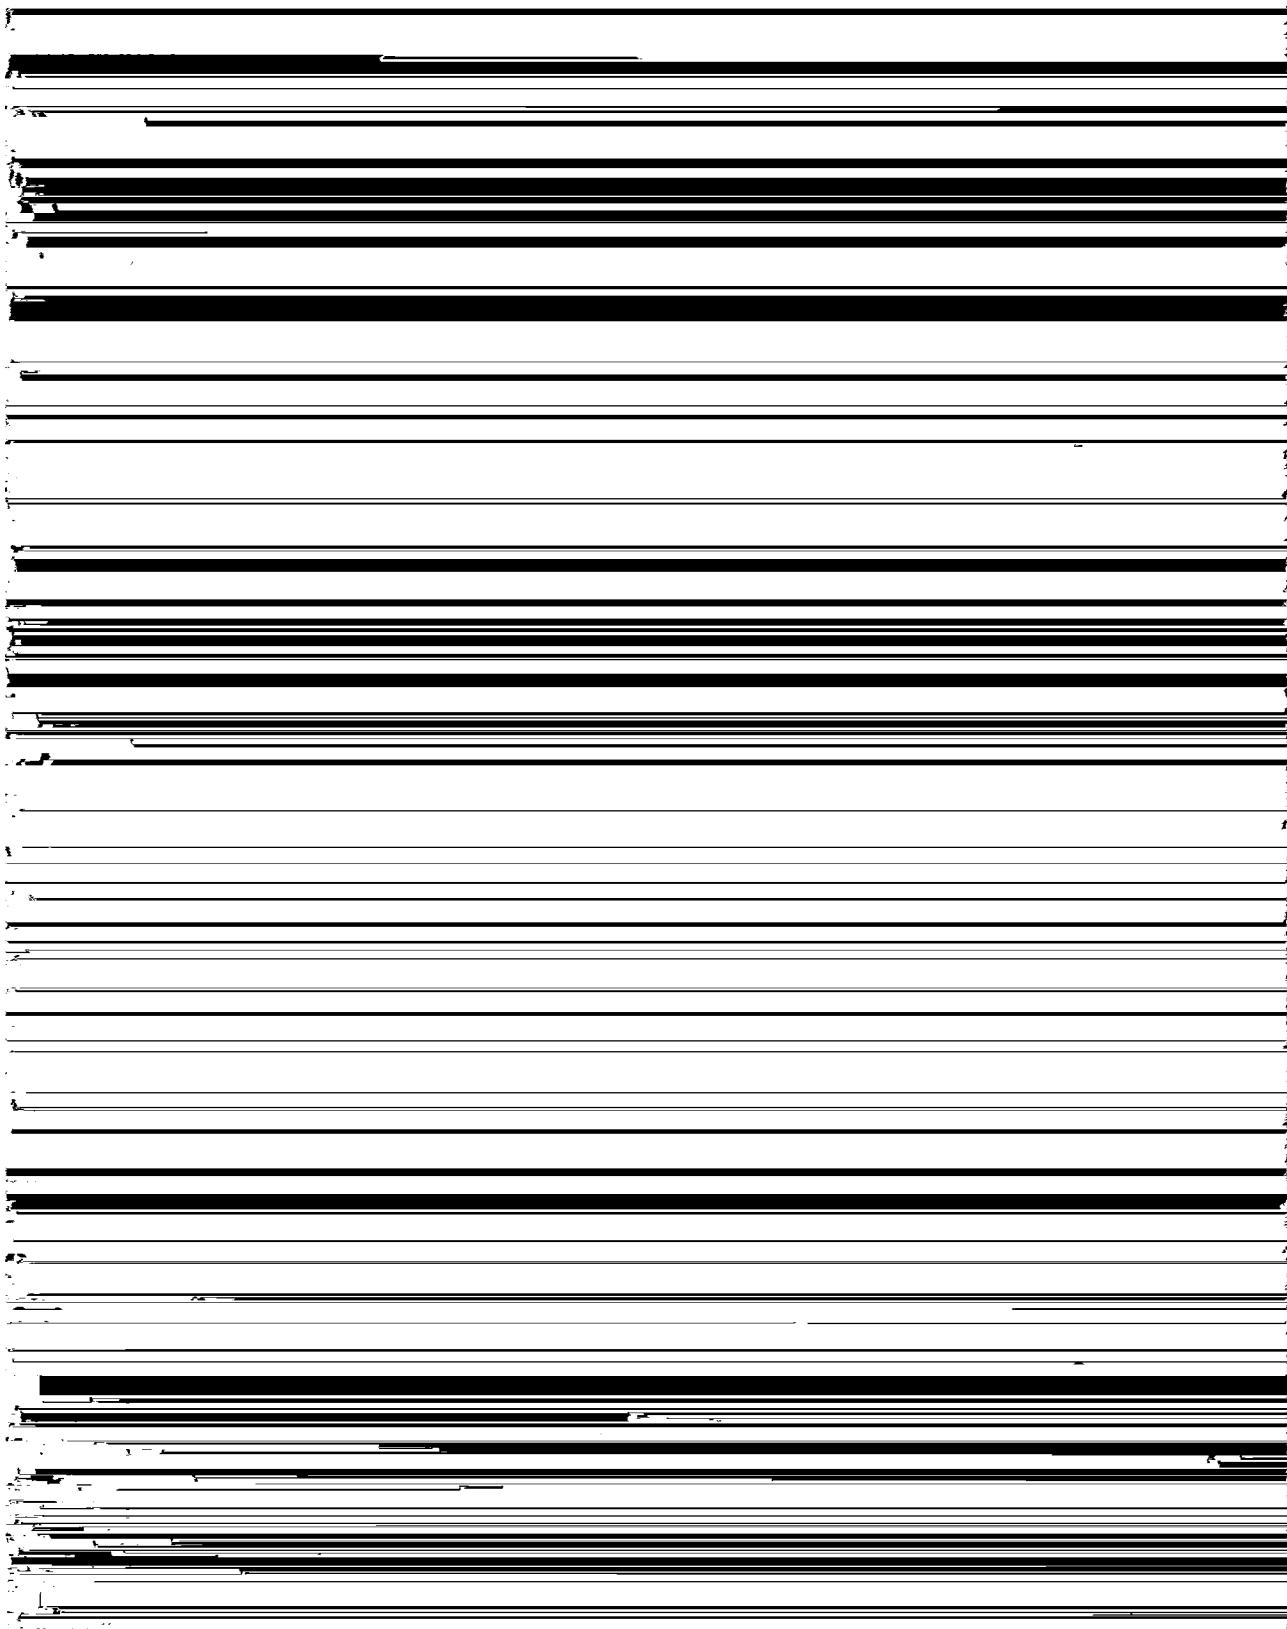
Transparencia de acceso: el módulo cliente NFS proporciona una interfaz de programación de aplicación para los procesos locales que es idéntica a la interfaz del sistema operativo local. Por tanto en un cliente UNIX, los accesos a archivos remotos se realizan utilizando llamadas al sistema normales de UNIX. No se precisa modificar los programas existentes para poder trabajar correctamente con archivos remotos.

Transparencia de ubicación: cada cliente establece un espacio de nombres de archivo añadiendo directorios montados en volúmenes remotos sobre su espacio local de nombres. Los sistemas de archivos han de ser *exportados* por el nodo que los mantiene y *montados remotamente* por un cliente antes que ellos puedan ser accedidos por procesos ejecutándose en el cliente (véase la Figura 8.10). El punto de la jerarquía de nombres del cliente donde aparece montado remotamente un sistema de archivos lo determina el cliente, por tanto NFS no fuerza un espacio de nombres de archivo único a través de la red; cada cliente ve un conjunto de sistemas de archivos remotos que es determinado localmente, y los archivos remotos pueden tener diferentes nombres de ruta en diferentes clientes, pero se puede establecer un espacio de nombres uniforme en cada cliente mediante las tablas de configuración apropiadas, logrando el objetivo de transparencia de ubicación.

Transparencia de movilidad: los volúmenes (en el sentido UNIX, esto es, subárboles de archivos) pueden ser reubicados entre servidores, pero las tablas de montado remoto en cada cliente deben ser actualizadas separadamente para permitir a los clientes el acceso al sistema de archivos en su nueva ubicación, por lo que la transparencia de migración no está totalmente conseguida en NFS.

Escalabilidad: las cifras de prestaciones publicadas muestran que se pueden construir servidores NFS que mantengan cargas reales muy grandes, de una manera eficiente y beneficiosa. Se pueden incrementar las prestaciones de un único servidor mediante la adición de procesadores, discos y controladores. Cuando los límites de esos procesos son alcanzados, hay que instalar servidores adicionales y los sistemas de archivos deben ser reubicados entre ellos. La efectividad de esa estrategia está limitada por la existencia de archivos de uso muy frecuente, son archivos sencillos que son accedidos tan frecuentemente que el servidor llega al límite de prestaciones. Cuando las cargas exceden el máximo de prestaciones disponible con esa estrategia, una solución mejor es emplear un sistema de archivos distribuidos que soporte la replicación de los archivos actualizables (como Coda, descrito en el Capítulo 14), o uno como AFS que reduce el tráfico del protocolo haciendo caché de los archivos completos. En la Sección 8.5 discutiremos otras aproximaciones a la escalabilidad.

Replicación de archivos: los almacenes de archivos de *sólo lectura* pueden ser replicados en varios servidores NFS, pero NFS no soporta la replicación de archivos actualizables. El Servicio de Información de Red de Sun (*Network Information Service*, NIS) es un servicio separado disponible para su uso con NFS que soporta la replicación de bases de datos sencillas organiza-



AFS difiere notoriamente de NFS en su diseño e implementación. Las diferencias son atribuibles principalmente a la identificación de la escalabilidad como el objetivo de diseño más importante. AFS está diseñado para trabajar bien con gran número de usuarios activos más que otros sistemas de archivos distribuidos. La estrategia clave para alcanzar la escalabilidad es la caché de los archivos completos en los nodos cliente. AFS tiene dos características de diseño inusuales:

Servicio de archivo completo: el contenido entero de los directorios y los archivos es transmitido a los computadores cliente por los servidores AFS (en AFS-3, los archivos más grandes de 64 kbytes son transferidos en trozos de 64 kbytes).

Caché de archivo completo: una vez que una copia de un archivo, o un trozo, ha sido transferido a un computador cliente es almacenado en una caché en el disco local. La caché contiene varios cientos de archivos, los utilizados más recientemente en ese computador. La caché es permanente sobreviviendo a los rearranques del computador cliente. Las copias locales de los archivos son utilizadas para satisfacer las solicitudes *open* de los clientes con preferencias sobre las copias remotas cuando es posible.

◊ **Escenario.** Aquí presentamos un escenario simple que ilustra el funcionamiento de AFS:

- Cuando un proceso de usuario en un computador cliente emite una llamada del sistema *open* para un archivo en un espacio de archivos compartido y no hay una copia actual del archivo en la caché local, el servidor que mantiene el archivo se localiza y se envía una solicitud para una copia del archivo.
- La copia es almacenada en el sistema de archivos UNIX local en el computador del cliente; se *abre* la copia y el descriptor UNIX resultante del archivo es devuelto al cliente.
- Las operaciones posteriores: *read*, *write* y demás, sobre el archivo por los procesos en el computador cliente, se aplican a la copia local.
- Cuando el proceso en el cliente emite una llamada del sistema *close*, si la copia local ha sido actualizada su contenido es enviado de vuelta al servidor. El servidor actualiza el contenido del archivo y las marcas de tiempo del mismo. La copia en el disco local del cliente es retenida en el caso de que se necesite de nuevo por un proceso a nivel de usuario en la misma estación de trabajo.

Discutiremos las prestaciones de AFS observadas más adelante, pero podemos hacer aquí algunas observaciones y predicciones generales basadas en las características de diseño descritas anteriormente:

- Para archivos compartidos que son actualizados infrecuentemente (aquejlos que contienen el código de los comandos y librerías de UNIX) y para archivos que son accedidos normalmente por un único usuario (como la mayoría de los archivos en un directorio *home* del usuario y su sub-árbol), las copias en la caché localmente probablemente permanezcan válidas durante períodos largos, en el primer caso porque no se actualizan y en el segundo porque si se actualizan, la copia actualizada estará en la caché de la estación de trabajo del propietario. Esta clase de archivo es la abrumadora mayoría de los accesos.
- La caché local puede reservar una proporción sustancial del espacio de disco en cada estación de trabajo, pongamos 100 megabytes. Esto es normalmente suficiente para el establecimiento de un conjunto de trabajo de los archivos utilizados por un usuario. La provisión de almacenamiento caché suficiente para el establecimiento de un conjunto de trabajo asegura que los archivos de uso regular en una estación de trabajo dada son normalmente retenidos en la caché hasta que son necesarios de nuevo.
- La estrategia de diseño está basada en algunas suposiciones sobre los tamaños promedio y máximo de los archivos y la proximidad de referencia de los mismos en sistemas UNIX. Estas suposiciones se derivan de las observaciones de las cargas de trabajo UNIX típicas en entornos académicos y otros [Satyanarayanan 1981; Ousterhout y otros 1985; Floyd 1986].

Las observaciones más importantes son:

- Los archivos son pequeños; la mayoría son menores de 10 kilobytes de tamaño.
- Las operaciones de lectura en los archivos son mucho más comunes que la escritura (unas seis veces más habituales).
- El acceso secuencial es lo habitual, y el acceso aleatorio es inusual.
- La mayoría de los archivos son leídos y escritos por sólo un usuario. Cuando se comparte un archivo normalmente sólo lo modifica un usuario.
- Los archivos son referenciados a ráfagas. Si un archivo ha sido referenciado recientemente hay una alta probabilidad que sea referenciado en el futuro próximo.

Estas observaciones fueron utilizadas para guiar el diseño y optimización de AFS, *no* para restringir la funcionalidad vista por los usuarios.

- AFS trabaja mejor con las clases de archivo identificadas en el primer punto anterior. Hay un tipo importante de archivo que no concuerda con ninguna de estas clases, las bases de datos son compartidas normalmente por muchos usuarios y generalmente son actualizadas muy a menudo. Los diseñadores de AFS han excluido explícitamente la provisión de facilidades de almacenamiento para bases de datos de sus objetivos de diseño, afirmando que las restricciones impuestas por las diferentes estructuras de nombrado (esto es, acceso basado en contenido) y la necesidad para acceso a datos con gran detalle, control de concurrencia y atomicidad de las actualizaciones hace difícil el diseño de un sistema de base de datos distribuida que es también un sistema de archivos distribuido. Ellos arguyen que la provisión de funcionalidades de bases de datos distribuidas debiera ser considerada separadamente [Satyanarayanan 1989a].

8.4.1. IMPLEMENTACIÓN

El escenario anterior ilustra la operación de AFS pero deja muchas preguntas no contestadas sobre su implementación. Entre las más importantes están:

- ¿Cómo consigue el control AFS cuando una llamada del sistema *open* o *close* refiriéndose a un archivo en el espacio de archivos compartidos es emitida por un cliente?
- ¿Cómo está manteniendo el servidor el archivo localizado requerido?
- ¿Qué espacio está reservado para los archivos en la caché en las estaciones de trabajo?
- ¿Cómo asegura AFS que las copias en la caché de los archivos están actualizadas cuando los archivos pueden ser actualizados por varios clientes?

A continuación respondemos a estas preguntas.

AFS está implementado como dos componentes software que existen como procesos UNIX llamados *Vice* y *Venus*. La Figura 8.11 muestra la distribución de los procesos Vice y Venus. Vice es el nombre dado al servidor software que se ejecuta como un proceso UNIX a nivel de usuario en cada computador servidor, y Venus es un proceso a nivel de usuario que se ejecuta en cada computador cliente y corresponde al módulo cliente en nuestro modelo abstracto.

Los archivos disponibles para los procesos de usuario que se ejecutan en estaciones de trabajo son o *locales* o *compartidos*. Los archivos locales se manejan como archivos normales UNIX. Están almacenados en el disco de la estación de trabajo y están disponibles sólo para los procesos de usuario locales. Los archivos compartidos están almacenados en los servidores y las copias de ellos son introducidas en la caché en los discos locales de las estaciones de trabajo. El espacio de nombres visto por los procesos del usuario es el ilustrado en la Figura 8.12. Es una jerarquía convencional de directorios UNIX, con un subárbol específico (llamado *cmu*) conteniendo todos los archivos compartidos. Este desdoblamiento del espacio de nombres de archivos en archivos loca-

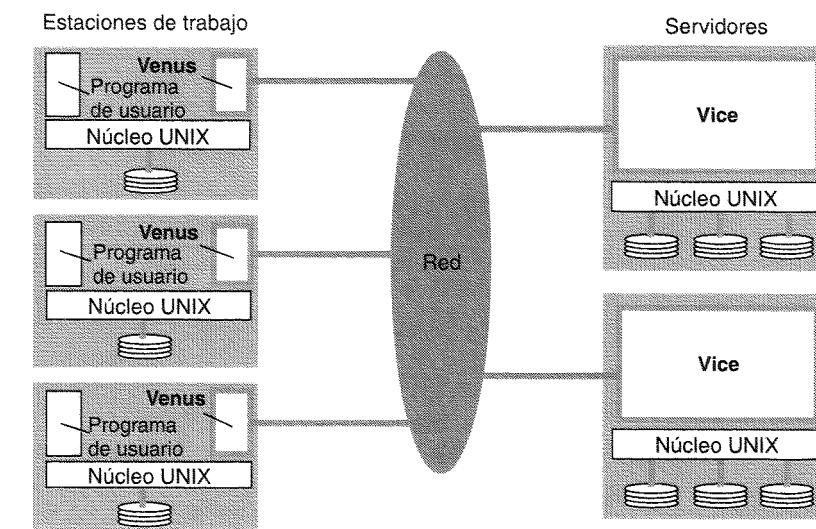


Figura 8.11. Distribución de procesos en el Sistema de Archivos Andrew.

les y compartidos conduce a alguna pérdida de la transparencia de ubicación, pero esto apenas evidente para usuarios distintos de los administradores del sistema. Los archivos locales son utilizados sólo para archivos temporales (*/tmp*) y procesos que son esenciales para el arranque de la estación de trabajo. Otros archivos estándar UNIX (como aquellos encontrados normalmente en */bin*, */lib*, etc.) están implementados como enlaces simbólicos desde los directorios locales a los archivos mantenidos en el espacio compartido. Los directorios de los usuarios están en el espacio compartido permitiendo a los usuarios acceder a sus archivos desde cualquier estación de trabajo.

El núcleo UNIX de cada estación de trabajo y servidor es una versión modificada de UNIX BSD. Las modificaciones están diseñadas para interceptar *open*, *close* y algunas otras llamadas del sistema para archivos cuando ellas se refieren a archivos en el espacio de nombres compartido y pasan entonces al proceso Venus en el computador cliente (como se ve en la Figura 8.13). Se incluye otra modificación del núcleo por razones de prestaciones y se describe más adelante.

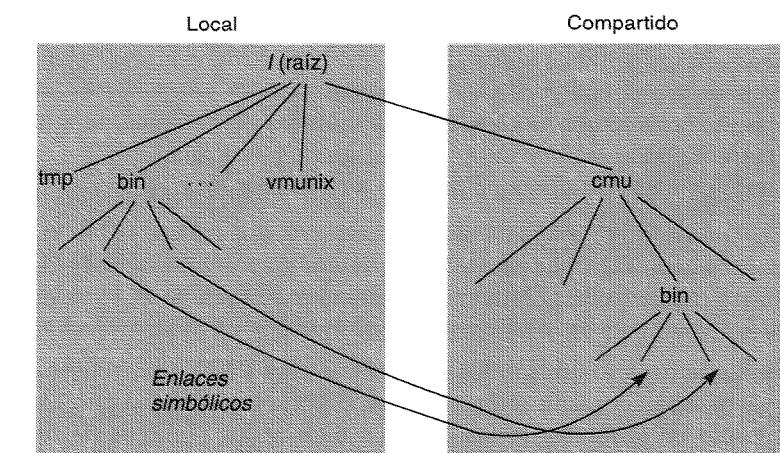
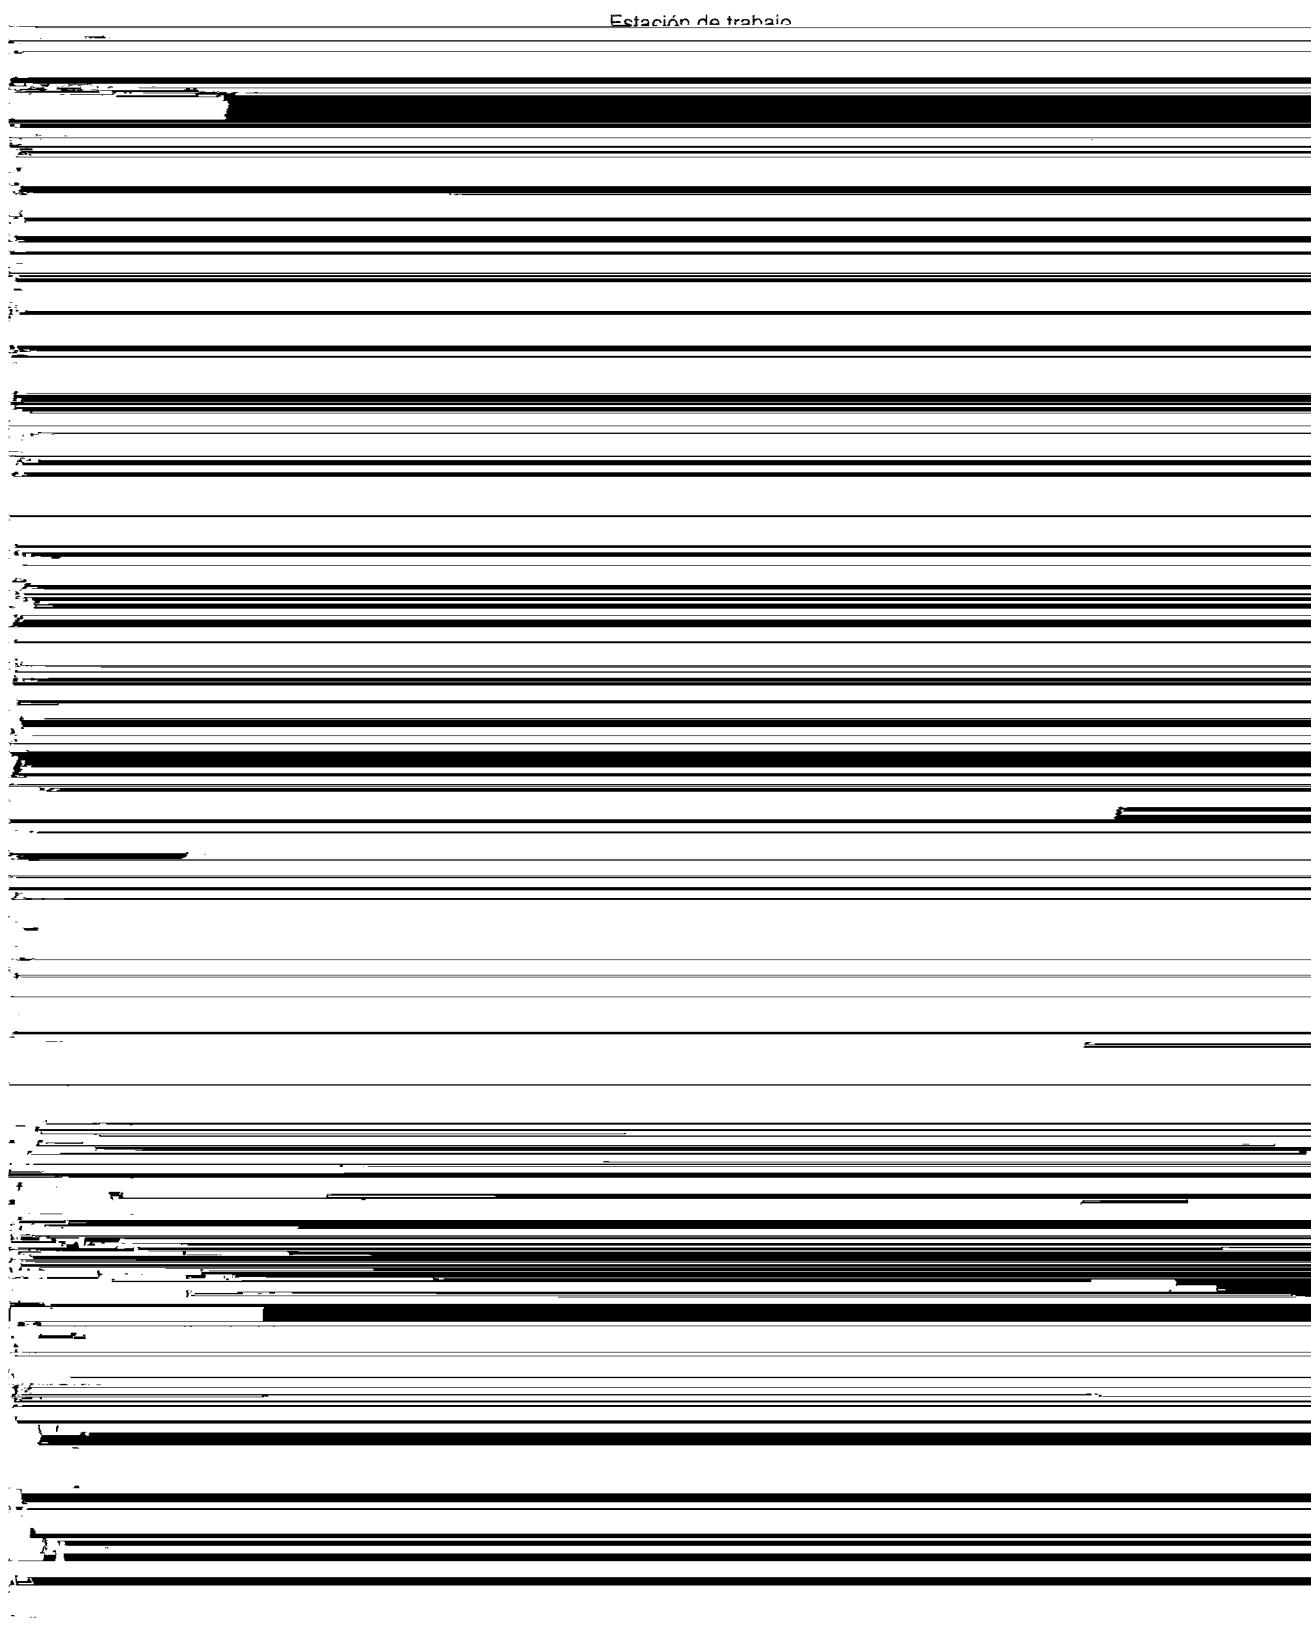


Figura 8.12. Espacio de nombres visto por los clientes de AFS.



Proceso de usuario	Núcleo UNIX	Venus	Red	Vice
<i>open(NombreArchivo, modo)</i>	Si <i>NombreArchivo</i> se refiere a un archivo del espacio de archivos compartido, pasa la petición a Venus.	Comprueba la lista de archivos en la caché local. Si no está presente o no hay una <i>promesa de devolución de llamada</i> , envía una petición de archivo al servidor Vice que es el custodio del volumen que contiene el archivo.		
	Abre el archivo local y devuelve el descriptor de archivo a la aplicación.	Sitúa la copia del archivo en el sistema de archivos local, inserta su nombre local en la caché de lista local y devuelve el nombre local a UNIX.		Transfiere una copia del archivo y una promesa de <i>devolución de llamada</i> a la estación de trabajo. Registra la promesa de devolución de llamada.
<i>read(DescriptorArchivo, Búfer, tamaño)</i>	Realiza una operación de lectura UNIX normal sobre la copia local.			
<i>write(DescriptorArchivo, Búfer, tamaño)</i>	Realiza una operación de escritura UNIX normal sobre la copia local.			
<i>close(DescriptorArchivo)</i>	Cierra la copia local y notifica a Venus que el archivo ha sido cerrado.	Si la copia local ha sido cambiada, envía una copia al servidor Vice que es el custodio del archivo.		Reemplaza los contenidos del archivo y envía una <i>devolución de llamada</i> a todos los otros clientes que posean <i>promesas de devolución de llamada</i> sobre el archivo.

Figura 8.14. Implementación de las llamadas al sistema en AFS.

La Figura 8.14 describe las acciones tomadas por Vice, Venus y el núcleo UNIX cuando un proceso de usuario emite cada llamada del sistema mencionada en nuestro bosquejo de escenario anterior. La promesa de *devolución de llamada* (*callback*) mencionada aquí es un mecanismo para asegurar que las copias en la caché de los archivos son actualizadas cuando otro cliente cierra el mismo archivo después de actualizarlo. Este mecanismo se discute en la sección siguiente.

8.4.2. CONSISTENCIA DE LA CACHÉ

Cuando Vice proporciona una copia de un archivo al proceso Venus también le proporciona una *promesa de devolución de llamada*, un testigo emitido por el servidor Vice que es el custodio del

archivo, que garantiza que notificará al proceso Venus cuando otro cliente modifica el archivo. Las promesas de devolución de llamada se almacenan con los archivos en la caché sobre los discos de las estaciones de trabajo y tienen dos estados: *válida* o *cancelada*. Cuando un servidor realiza una solicitud para actualizar un archivo notifica a todos los procesos Venus a los que ha emitido promesas de devolución de llamada enviando *una devolución de llamada* a cada uno, una promesa de devolución de llamada es una llamada a un procedimiento remoto desde el servidor al proceso Venus. Cuando el proceso Venus recibe una devolución de llamada, coloca el testigo de la *promesa de devolución de llamada* para el archivo relevante a *cancelada*.

Cuando Venus usa *open* en nombre de un cliente, comprueba la caché. Si el archivo requerido se encuentra en la caché, se comprueba el testigo. Si su valor es *cancelada*, entonces debe buscarse una copia reciente del archivo en el servidor Vice, pero si el testigo es *válida*, entonces puede ser abierta y utilizada la copia de la caché sin referenciar a Vice.

Cuando una estación de trabajo se rearranca después de un fallo o una parada, Venus intenta retener tanto archivos de la caché en el disco local como sea posible, pero no puede presuponer que los testigos de promesa de devolución de llamada sean correctos, puesto que algunas devoluciones de llamada pueden haberse perdido. Por cada archivo con un testigo válido, Venus debe enviar una solicitud de validación de la caché conteniendo la marca de tiempo de modificación del archivo al servidor que es el custodio del archivo. Si la marca de tiempo es actual, el servidor responde con *válida* y el testigo es rehabilitado. Si la marca de tiempo muestra que el archivo está caducado, el servidor responde con *cancelada* y el testigo es colocado a *cancelada*. Las promesas de devolución de llamada deben ser renovadas antes de un *open* si ha transcurrido un tiempo T (normalmente del orden de unos pocos minutos) desde que el archivo fue introducido en la caché sin comunicación con el servidor. Esto se hace para tratar los posibles fallos de comunicación, que producen la pérdida de mensajes de devolución de llamada.

Este mecanismo basado en devoluciones de llamada para mantener la consistencia de la caché se adoptó porque ofrecía la aproximación más escalable, siguiendo la evaluación en el prototipo (AFS-1) de un mecanismo basado en marca de tiempo semejante al utilizado en NFS. En AFS-1, un proceso Venus que mantiene una copia en la caché de un archivo interroga al proceso Vice en cada *open* para determinar si la marca de tiempo en la copia local concuerda con la del servidor. La aproximación basada en devoluciones de llamada es más escalable porque produce comunicación entre el cliente y el servidor y actividad en el servidor sólo cuando el archivo ha sido actualizado, mientras que la aproximación por marca de tiempo produce una interacción cliente-servidor en cada *open*, incluso cuando hay una copia válida en la caché. Puesto que la mayoría de los archivos no son accedidos concurrentemente, y las operaciones *read* predominan sobre las *write*, el mecanismo de *devolución de llamada* redundante en una reducción dramática del número de interacciones cliente-servidor.

El mecanismo de devolución de llamada utilizado en AFS-2 y versiones posteriores de AFS requiere que los servidores Vice mantengan algo del estado en nombre de sus clientes Venus a diferencia de AFS-1, NFS y nuestro modelo de servicio de archivos. El estado precisado dependiente del cliente precisado consiste en una lista de los procesos Venus para los que se han planteado promesas de devolución de llamada para cada archivo. Estas listas de devoluciones de llamada deben retenerse aun en el caso de fallos en el servidor, mantenerse en los discos del servidor y ser actualizadas utilizando operaciones atómicas.

La Figura 8.15 muestra las llamadas RPC proporcionadas por los servidores AFS para operaciones sobre archivos (esto es, la interfaz proporcionada por los servidores AFS para los procesos Venus).

◇ **Semántica de actualización.** El objetivo de este mecanismo de coherencia de caché es conseguir la mejor aproximación a la semántica de *una copia* de archivo que sea practicable sin una degradación considerable de las prestaciones. Una implementación estricta de la semántica de

<i>Fetch(ida) → atrib, datos</i>	Devuelve los atributos (estado) y, opcionalmente, los contenidos del archivo identificado por el <i>ida</i> y registra una promesa de devolución de llamada sobre él.
<i>Store(ida, atrib, datos)</i>	Actualiza los atributos y (opcionalmente) los contenidos de un archivo especificado.
<i>Create() → ida</i>	Crea un nuevo archivo y registra una promesa de devolución de llamada sobre él.
<i>Remove(ida)</i>	Elimina el archivo especificado.
<i>SetLock(ida, modo)</i>	Establece un bloqueo sobre el archivo o directorio especificado. El modo del bloqueo puede ser compartido o exclusivo. Los bloqueos no eliminados expiran a los 30 minutos.
<i>ReleaseLock(ida)</i>	Desbloquea el archivo o directorio especificado.
<i>RemoveCallback(ida)</i>	Informa al servidor de que un proceso Venus ha volcado un archivo desde su caché.
<i>BreakCallback(ida)</i>	Esta llamada se realiza desde un servidor Vice a un proceso Venus. Cancela la promesa de devolución de llamada del archivo en cuestión.

Nota: No se muestran las operaciones de directorio ni las administrativas (*Rename*, *Link*, *Removedir*, *GetTime*, *CheckToken*, y demás).

Figura 8.15. Componentes principales de la interfaz de servicio Vice.

una copia para las primitivas de acceso a archivos UNIX requeriría que los resultados de cada *write* a un archivo fueran distribuidos a todos los sitios en los que se mantenga el archivo en la caché antes de que puedan ocurrir otros accesos. Esto no es practicable en los sistemas de gran escala, en su lugar, el mecanismo de promesa de devolución de llamada mantiene una aproximación bien definida a la semántica de una copia.

Para AFS-1 la semántica de actualización puede ser establecida formalmente en muy pocos términos. Para un cliente *C* operando sobre un archivo *F* cuyo custodio es un servidor *S*, se mantienen las siguientes garantías de actualidad de las copias de *F*:

después de un <i>open</i> con éxito:	<i>latest(F, S)</i> -el último
después de un <i>open</i> fallido:	<i>failure(S)</i> -fallo
después de un <i>close</i> con éxito:	<i>updated(F, S)</i> -actualizado
después de un <i>close</i> fallido:	<i>failure(S)</i> -fallo

Donde *latest(F, S)* indica una garantía de que el valor actual de *F* en *C* es el mismo que el valor en *S*, *failure(S)* indica que la operación *open* o *close* no ha sido realizada en *S* (y el fallo puede ser detectado por *C*), y *updated(F, S)* indica que el valor de *F* en *C* ha sido propagado con éxito hacia *S*.

Para AFS-2, la garantía actual es ligeramente más débil, y la declaración formal correspondiente de la garantía es más compleja. Esto es porque un cliente puede abrir una copia antigua de un archivo después de que haya sido actualizado por otro cliente. Esto ocurre si se pierde un mensaje de *devolución de llamada*, por ejemplo como resultado de un fallo de la red. Pero hay un máximo de tiempo T para el que un cliente puede permanecer sin darse cuenta de una versión más nueva de un archivo. Aquí tenemos la garantía siguiente:

después de un <i>open</i> con éxito:	<i>latest(F, S, 0)</i> o (<i>lostCallback(S, T)</i> e <i>inCache(F)</i>) y <i>latest(F, S, T)</i>)
--------------------------------------	---

Donde *latest(F, S, T)* indica que la copia de *F* vista por el cliente está caducada no más allá de T segundos, *lostCallback(S, T)* indica que se ha perdido un mensaje de devolución de llamada desde *S* hasta *C* en algún instante durante los últimos T segundos, y *inCache(F)* que el archivo *F* estaba en la caché en *C* antes que fuera intentada la operación *open* intentada. La declaración formal anterior expresa el hecho que la copia en la caché de *F* en *C* después de una operación *open* es la

versión más reciente en el sistema o que un mensaje de devolución de llamada se ha perdido (debi-

lectura, se realiza después de la actualización por un procedimiento operativo explícito. Las entradas en la base de datos de ubicaciones para volúmenes que están replicados de esta forma son *una a muchas*, y el servidor para cada solicitud del cliente se selecciona en base a las cargas y accesibilidad de los servidores.

◊ **Transferencias al por mayor.** AFS transfiere archivos entre los clientes y los servidores en trozos de 64-kilobytes. El uso de paquetes de tan gran tamaño es una ayuda importante para las prestaciones, minimizando el efecto de latencia de la red. Por tanto el diseño de AFS permite optimizar el uso de la red.

◊ **Cacheado parcial de archivos.** La necesidad de transferir el contenido completo de los archivos a los clientes incluso cuando el requisito de la aplicación es para leer tan sólo una pequeña porción del archivo, es una fuente de ineficiencia obvia. La versión 3 de AFS elimina este requisito permitiendo que los datos del archivo sean transferidos e introducidos en la caché en bloques de 64- kbytes mientras se mantiene todavía la semántica de consistencia y otras características del protocolo AFS.

◊ **Prestaciones.** El objetivo principal de AFS es la escalabilidad, por lo que sus prestaciones con un gran número de usuarios son de particular interés. Howard y otros [1988] dan detalles de una extensa comparativa de medidas de prestaciones, que fueron acometidas utilizando *AFS benchmark* desarrollado con este fin, y que ha sido utilizado posteriormente ampliamente para la evaluación de sistemas de archivos distribuidos. Como era de esperar, el cacheado de los archivos completos y el protocolo de devolución de llamadas derivaron una drástica reducción de las cargas en los servidores. Satyanarayanan [1989a] sostiene que se midió una carga del servidor del 40 % con 18 nodos cliente ejecutando una prueba estándar, frente a una carga del 100 % para NFS evaluando la misma prueba. Satyanarayanan atribuye muchas de las ventajas de prestaciones de AFS a la reducción en la carga del servidor derivada del uso de devoluciones de llamada para notificar a los clientes de las actualizaciones en los archivos, comparado con el mecanismo de timeout utilizado en NFS para la comprobación de la validez de las páginas en las cachés de los clientes.

◊ **Soporte de área amplia.** La versión 3 de AFS soporta múltiples celdas administrativas, cada una con sus propios servidores, clientes, administradores de sistema y usuarios. Cada celda es un entorno completamente autónomo, pero una federación de celdas puede cooperar presentando a los usuarios un espacio de nombres de archivo uniforme de una pieza. El sistema resultante fue ampliamente utilizado por Transarc Corporation y fue publicado un resumen detallado de los patrones de uso de las prestaciones resultantes [Spasojevic y Satyanarayanan 1996]. El sistema se instaló en unos 1.000 servidores en 150 sitios. El resumen mostró proporciones de éxito de la caché en el rango de 96-98 % para accesos a una muestra de 32.000 volúmenes de archivos manteniendo 200 Gbytes de datos.

8.5. AVANCES RECENTES

Desde la aparición de NFS y AFS se han realizado varios avances en el diseño de sistemas de archivos distribuidos. En esta sección, describimos los avances que mejoran las prestaciones, disponibilidad y escalabilidad de los sistemas de archivos distribuidos convencionales. Avances más radicales se describen en otras partes del libro, incluyendo el mantenimiento de la consistencia en sistemas de archivos de *lectura escritura* replicados, para soportar la operación de modo desconectado y alta disponibilidad en los sistemas Bayou y Coda (véase las Secciones 14.4.2 y 14.4.3), y una arquitectura altamente escalable para la entrega de secuencias de datos en tiempo real con calidad garantizada en el servidor de archivos de vídeo Tiger (véase la Sección 15.6).

versión más reciente en el sistema o que un mensaje de devolución de llamada se ha perdido (debi-

◊ **Mejoras NFS.** Varios proyectos de investigación han tratado la cuestión de la semántica de actualización de una copia extendiendo el protocolo NFS para incluir las operaciones *open* y *close* y añadir un mecanismo de devolución de llamada para permitir al servidor notificar a los clientes la necesidad de invalidar entradas en la caché. Aquí describimos dos de tales esfuerzos, sus resultados parecen indicar que estas mejoras pueden ser acomodadas sin complejidad excesiva o costes de comunicación extras.

Agunos esfuerzos recientes de Sun y otros desarrolladores NFS se han dirigido a hacer más accesibles y útiles los servidores NFS en redes de área ancha. Mientras que el protocolo HTTP soportado por los servidores web ofrece un método efectivo y altamente escalable para hacer disponibles los archivos completos a los clientes a través de Internet, es menos útil para los programas de aplicación que requieren el acceso a porciones de grandes archivos o aquellos que actualizan porciones de archivos. El desarrollo WebNFS (descrito posteriormente) hace posible que los programas de aplicación lleguen a ser clientes de los servidores NFS en cualquier sitio de Internet (utilizando el protocolo NFS directamente en lugar de hacerlo indirectamente a través de un módulo del núcleo). Esto, junto con las bibliotecas apropiadas para Java y otros lenguajes de programación de red, deben ofrecer la posibilidad de implementar aplicaciones de Internet para compartir datos directamente, como juegos multiusuario o clientes de grandes bases de datos dinámicas.

Obtención de la semántica de actualización de una copia: La arquitectura de servidor sin estado de NFS proporciona grandes ventajas en robustez y facilidad de implementación para NFS, pero evita la consecución de una semántica de actualización de *una copia* requerida (los efectos de las escrituras concurrentes por diferentes clientes en el mismo archivo no están garantizados que sean las mismas que serían en un sistema único UNIX cuando múltiples procesos escriben en un archivo local). También impide la utilización de devoluciones de llamada para notificar a los clientes los cambios en los archivos, y esto deviene en solicitudes frecuentes de *getattr* de los clientes para comprobar la modificación de archivos.

Se han desarrollado dos sistemas de investigación que tratan con estas desventajas. Spritely NFS [Srinivasan y Mogul 1989, Mogul 1994] es un desarrollo de un sistema de archivos desarrollado para el sistema operativo distribuido Sprite en Berkeley [Nelson y otros 1988]. Spritely NFS es una implementación del protocolo NFS con la adición de llamadas *open* y *close*. Los módulos de los clientes deben enviar una operación *open* cuando un proceso local a nivel de usuario abre un archivo que está en el servidor. Los parámetros de una operación *open* en Sprite especifican un modo (lectura, escritura o ambas) e incluyen contadores del número de procesos locales que tienen el archivo abierto para lectura y para escritura. De modo semejante, cuando un proceso local cierra un archivo remoto se envía una operación *close* al servidor con los contadores actualizados de los lectores y los escritores. El servidor registra esos números en una *tabla de archivos abiertos* con la dirección IP y el número de puerto del cliente.

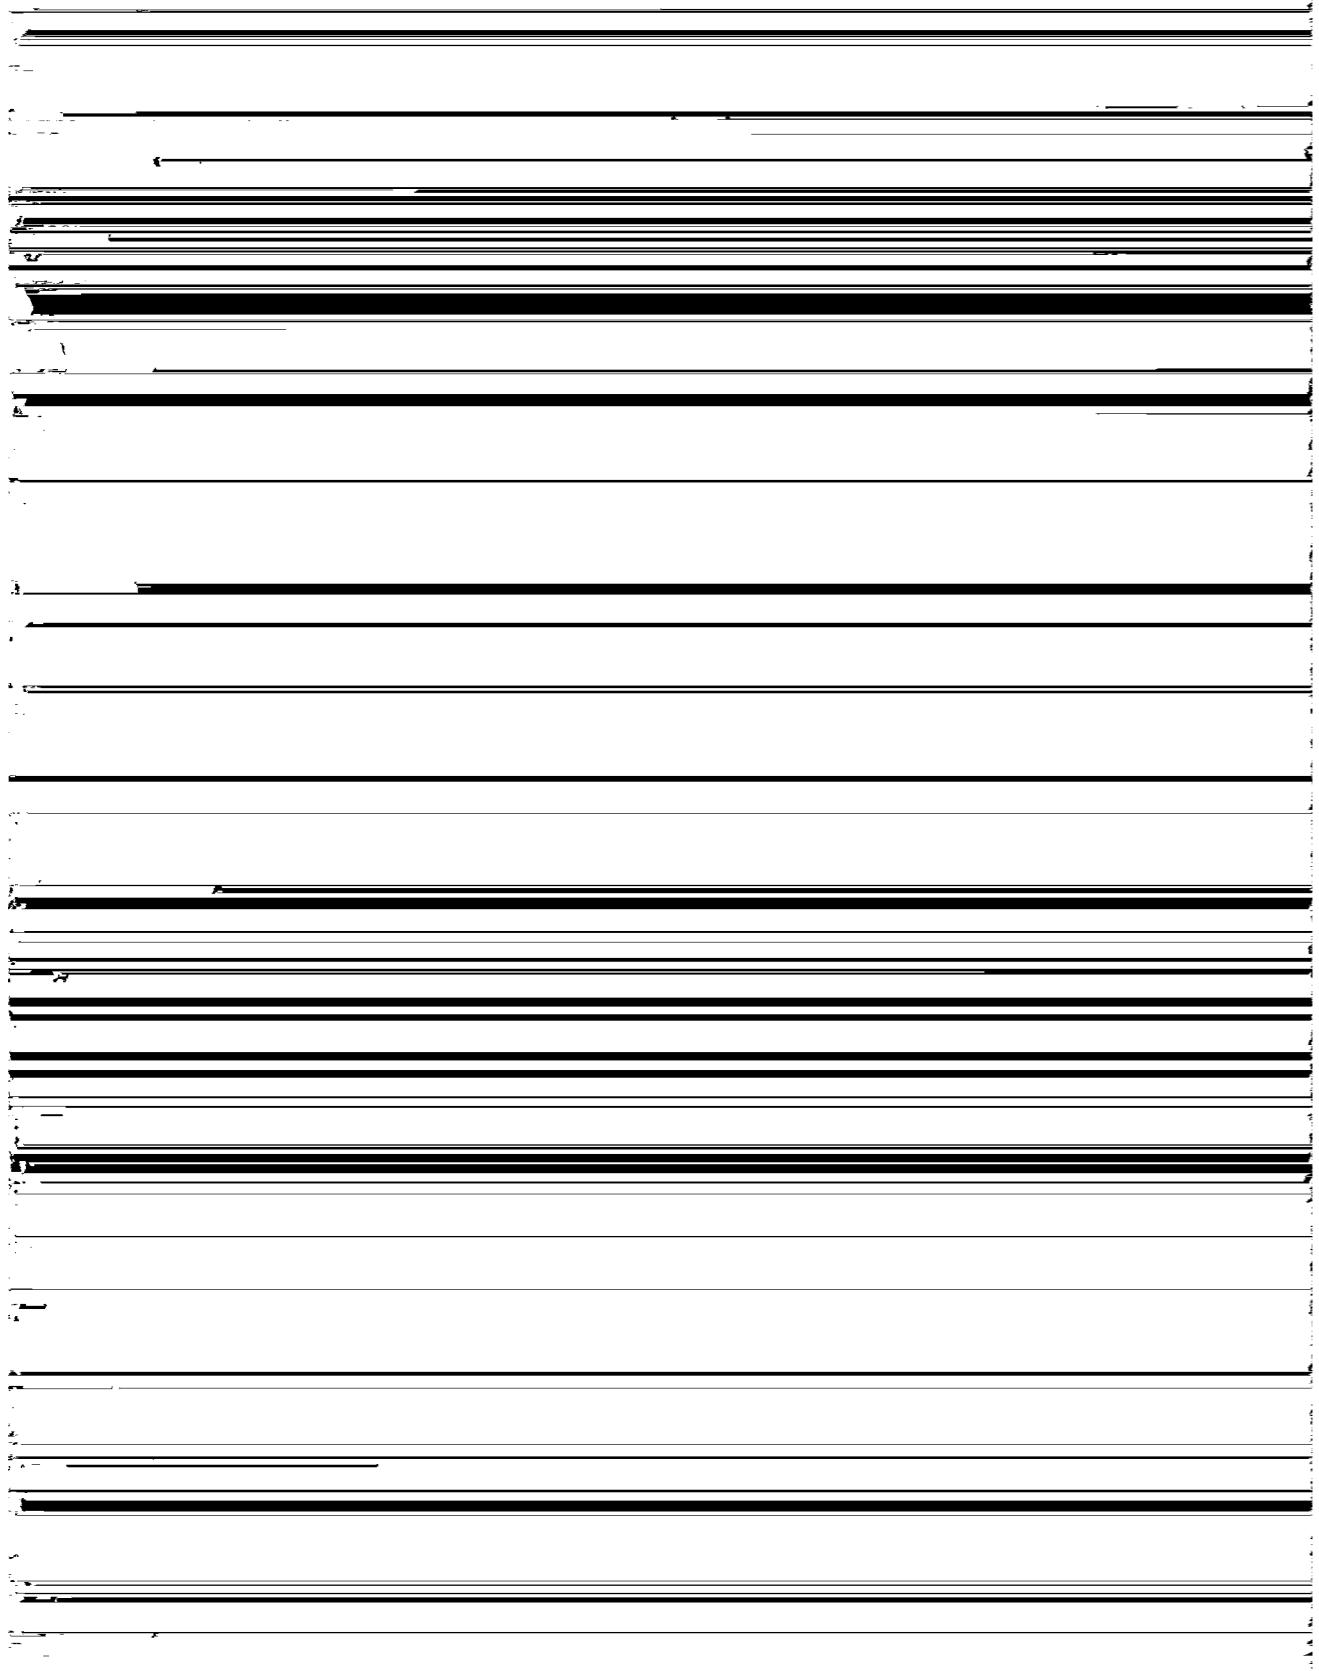
Cuando un servidor recibe un *open*, comprueba la *tabla de archivos abiertos* para otros clientes que tengan el mismo archivo abierto y envía mensajes de devolución de llamada a dichos clientes instruyéndoles para modificar su estrategia de caché. Si *open* especifica el modo de escritura, entonces fallará si cualquier otro cliente tiene el archivo abierto para escritura. Los otros clientes que tengan el archivo abierto para lectura serán instruidos para invalidar cualquier porción del archivo en la caché local.

Para operaciones *open* que especifican modo de lectura, el servidor envía un mensaje de devolución de llamada a cualquier cliente que esté escribiendo, indicándole que detenga la introducción en la caché (*caching*) (es decir, que utilice estrictamente el modo de escritura a través), e instruye a todo los clientes que están leyendo dejen de introducir en la caché el archivo (por lo que todas las llamadas de lectura locales producen una solicitud al servidor).

Estas medidas conducen a un servicio de archivos que mantienen la semántica de actualización de una copia UNIX con el coste de llevar algo del estado relacionado con el cliente al servidor.

También permiten ganar alguna eficiencia en el mantenimiento de las escrituras en la caché. Si el

También permiten ganar alguna eficiencia en el mantenimiento de las escrituras en la caché. Si el



reconstruidos completamente y la operación continúe normalmente en el caso de fallos de disco. RAID produce también mejores prestaciones que un único disco, porque las listas que representan un bloque son leídas y escritas concurrentemente.

Log-structured file storage (Almacen de archivo estructurado en histórico, LFS): como Sprite-NFS, esta técnica originada en el proyecto de sistema operativo Sprite en Berkeley [Rosenblum y Ousterhout 1992]. Los autores observaron que a medida que cantidades más grandes de memoria principal llegaban a estar disponibles para caché en los servidores de archivos, un incremento en el nivel de éxitos en la caché producía excelentes prestaciones en la lectura, pero las prestaciones en la escritura seguían siendo mediocres. Esto se debía a las altas latencias asociadas con las escrituras de bloques de datos individuales a disco y las actualizaciones asociadas con los datos de los metabloques (esto es, los bloques conocidos como *i-nodos* que mantienen los atributos de los archivos y un vector de apuntadores a los bloques en un archivo).

La solución LFS es acumular un conjunto de escrituras en memoria y entonces realizarlas a disco en segmentos de tamaño fijo, grandes, contiguos. Éstos se llaman *segmentos log* porque los bloques de datos y metadatos son almacenados estrictamente en el orden en el que fueron actualizados. Las copias frescas de los bloques de datos y los metadatos actualizados se escriben siempre, precisando el mantenimiento de un mapa dinámico (en memoria con una copia de respaldo persistente) apuntando a los bloques de *i-nodos*. Se precisa también la recolección de basura de los bloques rancios, con la compactación de los bloques *vivos* para dejar áreas continuas de almacenamiento libres para el almacenamiento de los *segmentos log*. El último es un proceso bastante complejo, es realizado como una actividad en segundo plano de un componente llamado el *limpiador*. Se han desarrollado algunos algoritmos sofisticados para el limpiador basados en los resultados de simulaciones.

A pesar de estos costes extra, la ganancia en prestaciones globales es excelente. Rosenblum y Ousterhout midieron un rendimiento de escritura tan alto como el 70 % de ancho de banda disponible del disco, comparado con menos del 10 % para un sistema de archivos UNIX convencional. La estructura log simplifica también la recuperación después de caídas del servidor. El sistema de archivos Zebra [Hartman y Ousterhout 1995], desarrollado como una continuación del trabajo original LFS, combina escrituras estructuradas en históricos con una aproximación RAID distribuida, los *segmentos log* se subdividen en secciones con corrección de error en los datos y escrituras en los discos en nodos de red separados. Se indican prestaciones de cuatro a cinco veces las de NFS, para las escrituras de archivos grandes, con ganancias más pequeñas para archivos pequeños.

◊ **Nuevas aproximaciones de diseño.** La disponibilidad de redes comutadas de altas prestaciones (como ATM o Ethernet de alta velocidad comutado) han provocado varios esfuerzos para proporcionar sistemas de almacenamiento persistente que distribuyan los archivos de datos de una manera altamente escalable y tolerante a fallos entre muchos nodos en una intranet, separando las responsabilidades de lectura y escritura de los datos de las de gestión de los metadatos y solicitudes de servicio de los clientes. A continuación, esbozamos dos de tales desarrollos.

Estas aproximaciones escalan mejor que las de los servidores más centralizados que han sido descritas en secciones precedentes. Demandan generalmente un alto nivel de confianza entre los computadores que cooperan para proporcionar el servicio, porque incluyen un protocolo de bastante bajo nivel para la comunicación con los nodos que mantienen los datos (algo análogo a una API de *disco virtual*). Su alcance aquí está probablemente limitado a una única red local.

xFS: Un grupo de la Universidad de Berkeley en California, propuso una arquitectura de sistema de archivos en red sin servidor y desarrolló un prototipo de implementación, xFS [Anderson y otros 1996]. Su aproximación estuvo motivada por tres factores:

1. La oportunidad proporcionada por las redes de área local (LAN) conmutadas rápidamente

Petal proporciona una abstracción de discos virtuales distribuidos entre muchos discos ubicados en múltiples servidores en una red local conmutada. La abstracción de disco virtual tolera la mayoría de los fallos de hardware y software con la ayuda de réplicas de los datos almacenados y balanza automáticamente la carga en los servidores para reubicar datos. Los discos virtuales de Petal son accedidos mediante un manejador de disco UNIX utilizando operaciones estándar de entrada-salida de bloques, por lo que pueden ser utilizados para soportar la mayoría de los sistemas de archivos. Petal añade entre el 10 y 100 % a la latencia de los accesos a disco, pero la estrategia de caché produce rendimientos en las lecturas y escrituras al menos tan buenos como los manejadores de disco subyacentes.

Los módulos de servidor Frangipani se ejecutan en el núcleo del sistema operativo. Como en xFS, la responsabilidad de gestionar archivos y las tareas asociadas (incluyendo la provisión de un servicio de bloqueo de archivos para los clientes) se ha asignado dinámicamente a las máquinas, y todas las máquinas ven un nombre unificado de archivo con accesos coherentes (con la semántica similar a *una copia*) para los archivos compartidos actualizables. Los datos se almacenan en un formato *estructurado en históricos* y en *ristras* en el depósito de discos virtuales Petal. El uso de Petal libera a Frangipani de la necesidad de administrar el espacio físico de disco, implementando un sistema de archivos distribuidos mucho más sencillo, Frangipani puede emular las interfaces de servicio de varios servicios de archivos existentes, incluyendo NFS y DCE/DFS. Las prestaciones de Frangipani son al menos tan buenas como las de la implementación de Digital del sistema de archivos UNIX.

3.6. RESUMEN

Las características fundamentales de diseño para sistemas de archivos distribuidos son:

- La utilización efectiva de la memoria caché en el cliente para conseguir iguales prestaciones o mejores que las de los sistemas de archivos locales.
- El mantenimiento de la consistencia entre múltiples copias de archivos en las cachés de los clientes cuando son actualizadas.
- La recuperación después de un fallo en el servidor o en el cliente.
- El alto rendimiento en la lectura y escritura de archivos de todos los tamaños.
- La escalabilidad.

Los sistemas de archivos distribuidos son empleados intensamente en la computación de las organizaciones, y sus prestaciones han estado sujetas a muchos ajustes. NFS tiene un protocolo sin estado sencillo, que ha mantenido su posición inicial como la tecnología dominante de los sistemas de archivos distribuidos con la ayuda de mejoras relativamente menores al protocolo, implementaciones muy ajustadas y soporte de hardware de altas prestaciones.

AFS demostró la viabilidad de una arquitectura relativamente sencilla utilizando el estado del servidor para reducir el coste del mantenimiento de la coherencia de las cachés en los clientes. AFS sobrepasa a NFS en muchas situaciones. Los avances recientes han empleado reparto de los datos entre múltiples discos y escritura *estructurada en históricos* para mejorar más las prestaciones y la escalabilidad.

En el estado actual del arte, los sistemas de archivos distribuidos son altamente escalables, proporcionan buenas prestaciones tanto entre las redes de área local como las de áreas grandes, mantienen la semántica de actualización de *una copia* y toleran y se recuperan de los fallos. Los requisitos futuros incluyen soporte para usuarios móviles con operación desconectada y garantías de reintegración automática y calidad del servicio para satisfacer la necesidad de un almacenamiento persistente y la entrega de secuencias de multimedia y otros datos dependientes del tiempo. Los soluciones a estos requisitos se discutirán en los Capítulos 14 y 15.

soluciones a estos requisitos se discutirán en los Capítulos 14 y 15.

- 8.15. Compare la semántica de actualización de UNIX cuando se accede a archivos locales con las de NFS y AFS. ¿Bajo qué circunstancias pueden los clientes llegar a despreocuparse de la diferencias?
- 8.16. ¿Cómo se ocupa AFS del riesgo de que los mensajes de devolución de llamada (*callback*) sean perdidos?
- 8.17. ¿Qué características del diseño de AFS lo hacen más escalable que NFS? ¿Cuáles son los límites de su escalabilidad, suponiendo que se pueden añadir servidores cuando sea preciso? ¿Qué desarrollos recientes ofrecen una gran escalabilidad?

so? ¿Qué desarrollos recientes ofrecen una gran escalabilidad?

9.1. INTRODUCCIÓN

En un sistema distribuido los nombres se utilizan para hacer referencia a una amplia variedad de recursos como computadores, servicios, objetos remotos y archivos, así como a usuarios. El dar nombres es una cuestión que puede ser fácilmente olvidada pero que es fundamental en el diseño de sistemas distribuidos. Los nombres facilitan la comunicación y la compartición de recursos. Se necesita un nombre para solicitar que un sistema computacional actúe sobre un recurso específico elegido entre muchos posibles; por ejemplo, se necesita un nombre en forma de URL para acceder a una página web particular. Los procesos no pueden compartir recursos particulares gestionados por un sistema computacional a no ser que puedan nombrarlos de forma consistente. Los usuarios no pueden comunicarse entre ellos a través de un sistema distribuido a no ser que puedan nombrarse, por ejemplo mediante la dirección de correo electrónico.

Los nombres no constituyen el único medio útil de identificación: otro procedimiento son los atributos descriptivos. A veces los clientes no conocen el nombre de una entidad particular que están buscando, pero tienen información que la describe. O puede que el cliente necesite un servicio (en lugar de la entidad particular que lo implementa) y conozca algunas de las características que debe tener el servicio que solicita.

Se presentan los servicios de nombres, los cuales proporcionan a los clientes datos sobre los objetos nombrados en sistemas distribuidos; también se presentan los conceptos relacionados sobre servicios de directorio y de descubrimiento, los cuales proporcionan datos sobre objetos que cumplen una cierta descripción. Describimos diferentes posibles aproximaciones en el diseño e implementación de esos servicios, utilizando el Servicio de Nombres de Dominio (DNS), GNS y X500 como casos de estudio. Comenzaremos examinando los conceptos fundamentales de nombres y atributos.

9.1.1. NOMBRES, DIRECCIONES Y OTROS ATRIBUTOS

Cualquier proceso que necesite acceder a un recurso específico debe poseer su nombre o un identificador. Ejemplos de nombres fácilmente legibles son nombres de archivos como `/etc/passwd`, URL's como `http://www.cdk3.net/` y nombres de dominio de Internet, como `dcs.qmw.ac.uk`. El término *identificador* se utiliza a veces para referirse a nombres que sólo se interpretan en los programas. Las referencias a objetos remotos y administradores de archivos NFS son ejemplos de identificadores. Los identificadores se eligen por la eficiencia con la que pueden ser buscados y almacenados por el software.

Needham [1993] distingue entre nombre *puro* y otros. Los nombres puros son simplemente patrones de bits sin interpretar. Los nombres *no puros* contienen información acerca del objeto al que nombran; en particular pueden contener información sobre la ubicación del objeto. Los nombres puros siempre deben buscarse antes de poder ser utilizados. En el otro extremo de un nombre puro se sitúa la *dirección* de un objeto: un valor que identifica la ubicación del objeto en lugar del objeto en sí mismo. Las direcciones son eficaces para acceder a los objetos, pero los objetos a veces cambian de localización, por lo que las direcciones no siempre resultan adecuadas como medio de identificación. Por ejemplo, las direcciones de correo electrónico de los usuarios normalmente cambian cuando los usuarios se mueven entre organizaciones o entre proveedores de servicio a Internet; no son suficientes por ellas mismas para referirse a un individuo específico a lo largo del tiempo.

Decimos que un nombre está *resuelto* cuando está traducido a datos relacionados con el recurso u objeto nombrado, a menudo con el objetivo de realizar una acción de invocación sobre él. La asociación entre un nombre y un objeto se llama *enlace*. En general los nombres se enlazan a los

atributos de los objetos nombrados en lugar de enlazarlos a la implementación de los propios objetos.

Un atributo es el valor de una propiedad asociada con un objeto. Un atributo clave de una entidad, que es normalmente relevante en un sistema distribuido, es su dirección. Por ejemplo:

- DNS relaciona los nombres de dominio con los atributos de un cierto computador: su dirección IP, el tipo de entrada (por ejemplo una referencia a un servidor de correo o a otro tipo de nodo) y, por ejemplo, el período de tiempo durante el que la entrada del nodo será válida.
- Se puede utilizar el servicio de directorio X.500 para relacionar un nombre de persona sobre atributos que incluyen la dirección de correo electrónico y el número de teléfono.
- El Servicio de Nombres y el Servicio de Comercio de CORBA se presentará en el Capítulo 17. El servicio de nombres relaciona el nombre de un objeto remoto con su referencia de objeto remoto, mientras que el servicio comercial relaciona el nombre de un objeto remoto con su referencia de objeto remoto, junto con un número arbitrario de atributos que describen el objeto en términos comprensibles para el usuario humano.

Obsérvese que una *dirección* puede ser considerada a menudo simplemente como otro nombre que debe ser buscado o bien que puede contener dicho nombre. Cada dirección IP debe ser buscada para obtener una dirección de red, como una dirección Ethernet. De forma similar los navegadores web y clientes de correo electrónico utilizan DNS para interpretar los nombres de dominio de los URL y las direcciones de correo electrónico. La Figura 9.1 muestra la porción de nombres de dominio de un URL resuelto vía DNS para conseguir una dirección IP en primer lugar, y a continuación la dirección Ethernet del servidor web conseguida a través de ARP. La última parte del URL se resuelve en el sistema de archivos del servidor web para encontrar el archivo relevante.

◊ **Nombres y servicios.** Muchos de los nombres utilizados en un sistema distribuido son específicos de algún servicio particular. Un cliente utiliza dicho nombre al solicitar un servicio con objeto de realizar una operación sobre el objeto nombrado o sobre un recurso que éste maneja. Por ejemplo, al servicio de archivos se le proporciona un nombre de archivo cuando se solicita la eliminación de dicho archivo; al servicio de gestión de procesos se le proporciona un identificador de proceso cuando se solicita el envío de una señal a dicho proceso. Esos nombres sólo se utilizan en el contexto del servicio que gestiona los objetos nombrados, exceptuando cuando los clientes se comunican mediante objetos compartidos.

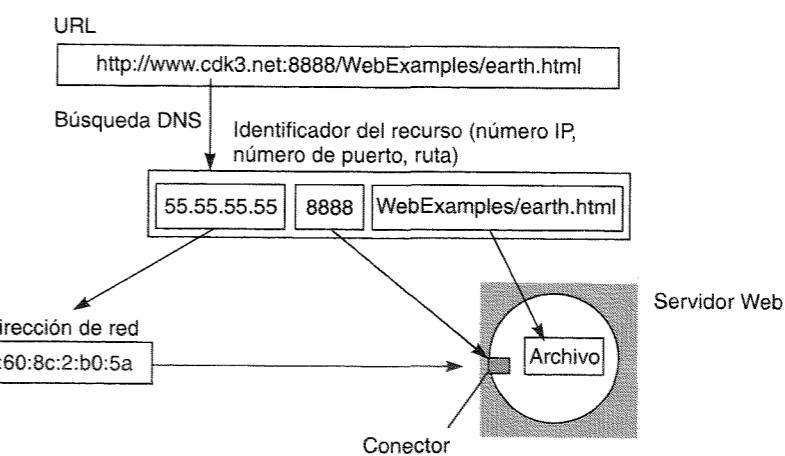


Figura 9.1. Dominios de nominación compuestos utilizados para acceder a un recurso desde un URL.

Los nombres también son necesarios para referirse a entidades del sistema distribuido que están fuera del ámbito de un único servicio. Los principales ejemplos de estas entidades son los usuarios (con nombres propios, nombres de login, identificadores de usuario y direcciones de correo electrónico), los computadores (con *nombres de host* como *bruno* o *bronwyn*) y los propios servicios (como el *servicio de archivos* o el *servicio de impresión*). En el middleware orientado a objetos, los nombres hacen referencia a objetos remotos que ofrecen servicios o proporcionan aplicaciones. Nótese que todos estos nombres deben ser legibles y tener significado para los humanos, ya que los usuarios y los administradores de sistema necesitan referirse a los principales componentes y elementos de configuración de los sistemas distribuidos; los programadores necesitan referirse a los servicios en los programas; y los usuarios necesitan comunicarse entre ellos en el sistema distribuido y determinar qué servicios están disponibles en sus diferentes partes. Partiendo de la conectividad proporcionada por Internet, estos requisitos de nominación tienen potencialmente un ámbito a escala mundial.

◊ **Identificadores de Recurso Unificados.** En la Sección 1.3 se presentó el URL como el principal medio de identificación de recursos web. De hecho los *Localizadores Uniformes de Recursos* (*Uniform Resource Locator*) son un tipo particular de *Identificadores Uniformes de Recursos* (*Uniform Resource Identifier*, URI) [URI].

Los URL presentan la importante propiedad de la escalabilidad, de modo que pueden hacer referencia a un conjunto de recursos web sin límite, a la vez que apuntan de forma eficiente a los recursos. El acceder a un recurso es fácil, partiendo de la información en su URL (un nombre DNS de computador y un camino en esa máquina). Aunque debido a que los URL son esencialmente direcciones de recursos web, sufren el inconveniente de que si el recurso se borra o se reubica, por ejemplo de un sitio web a otro, entonces habrá generalmente enlaces desconectados del recurso asociado al antiguo URL. Si un usuario trata de acceder a un enlace desconectado, el servidor web responderá que el recurso no ha sido encontrado o, posiblemente peor, proporcionará un recurso diferente que actualmente ocupa la misma situación.

El otro tipo principal de URI es el *Nombre Uniforme de Recurso* (*Uniform Resource Name*, URN). Los URN tratan de resolver el problema de los enlaces desconectados y proporcionan modos más completos de encontrar recursos en el Web. La idea consiste en tener un URN permanente para un recurso en el Web, incluso si el recurso se recoloca. El propietario de un recurso registrará su nombre, junto con el URL actual, frente a un servicio de búsqueda URN que proporcionará el URL a partir del URN. El propietario debe anotar el nuevo URL si se traslada el recurso. Un URN tiene la forma *urn:espacioNombres: nombreEspecífico-espacioNombres*. Por ejemplo, *urn:ISBN:0-201-62433-8* podría referirse al libro que lleva el nombre 0-201-62433-8 en el esquema de nombres estándar ISBN. El nombre (inventado) *urn:doi:10.555/music-pop1234* se refiere a la publicación llamada *music-pop-1234* conocida en el esquema de nombres del editor como 10.555 en el esquema Identificador de Objetos Digital (*Digital Object Identifier*) [www.doi.org]. De forma similar, un URN como *urn:dcs.gormenghast.ac.uk:TR2000-56* podría, en principio, utilizarse para obtener el último URL para el informe técnico conocido como TR2000-56, registrado con servicio de búsqueda de URN en *dcs.gormenghast.ac.uk*, en el Departamento de Ciencias de la Computación de la Universidad de Gormenghast.

Las *Características de Recurso Uniformes* (*Uniform Resource Characteristics*, URC, también conocidas como Citas de Recursos Uniformes) son un subconjunto de los URN's. Un URC es una descripción de un recurso web que consta de atributos del recurso, del tipo de *author=Leslie Lamport, keywords=tiempo,...* Los URC's sirven para describir recursos web y para realizar búsquedas de recursos web que cumplan con su especificación de atributos. Discutiremos en las dos secciones siguientes los servicios que se necesitan para buscar recursos partiendo de sus nombres y descripciones.

9.2. SERVICIOS DE NOMBRES Y EL SISTEMA DE NOMBRES DE DOMINIO

Un *servicio de nombres* almacena una colección de uno o más *contextos* de nominación, es decir, conjuntos de enlaces entre nombres textuales y atributos de objetos como usuarios, computadores, servicios y objetos remotos. La principal tarea que facilita un servicio de nombres es la resolución de un nombre, es decir, la búsqueda de atributos dado un cierto nombre. En la Sección 9.2.2 describimos la implementación de la resolución de nombres. También son necesarias otras operaciones, por ejemplo, crear nuevos enlaces, eliminar enlaces, listar los nombres enlazados y añadir y eliminar contextos.

La gestión de nombres estará muy separada de los otros servicios en virtud del carácter abierto de los sistemas distribuidos, el motivo de esto se encuentra en:

Unificación: a menudo es conveniente que los recursos que se gestionan desde diferentes servicios utilicen el mismo esquema de nomenclatura. Los URL son un buen ejemplo.

Integración: no es siempre posible predecir el ámbito de la compartición en un sistema distribuido. Puede ser necesario compartir y por lo tanto nombrar recursos que fueron creados en diferentes dominios administrativos. Sin un servicio de nombres común podría ocurrir que los dominios administrativos utilizasen nomenclaturas completamente diferentes.

◊ **Requisitos de un servicio de nombres general.** En sus inicios, los servicios de nombres eran muy simples ya que se diseñaron para cubrir únicamente las necesidades de vincular nombres con direcciones en un único dominio de gestión, correspondiente a una única LAN o WAN. La interconexión de redes y el incremento de escala de los sistemas distribuidos han hecho que el problema de la correspondencia de nombres sea mucho más complejo.

Grapevine [Birrell y otros 1982] fue uno de los primeros servicios de nombres extensibles y multidominio. se diseñó explícitamente para ser escalable por encima de, al menos, dos órdenes de magnitud el número de nombres y en la carga de solicitudes que podía manejar.

El Servicio de Nombres Global (*Global Name Service*), desarrollado en el Centro de Investigación de Sistemas de Digital Equipment Corporation [Lampson 1986], desciende de Grapevine aunque con objetivos más ambiciosos:

Gestionar un número arbitrario de nombres y servir un número arbitrario de organizaciones administrativas: por ejemplo, el sistema debería ser capaz, entre otras cosas, de gestionar direcciones de correo electrónico para todos los usuarios de computadores del mundo.

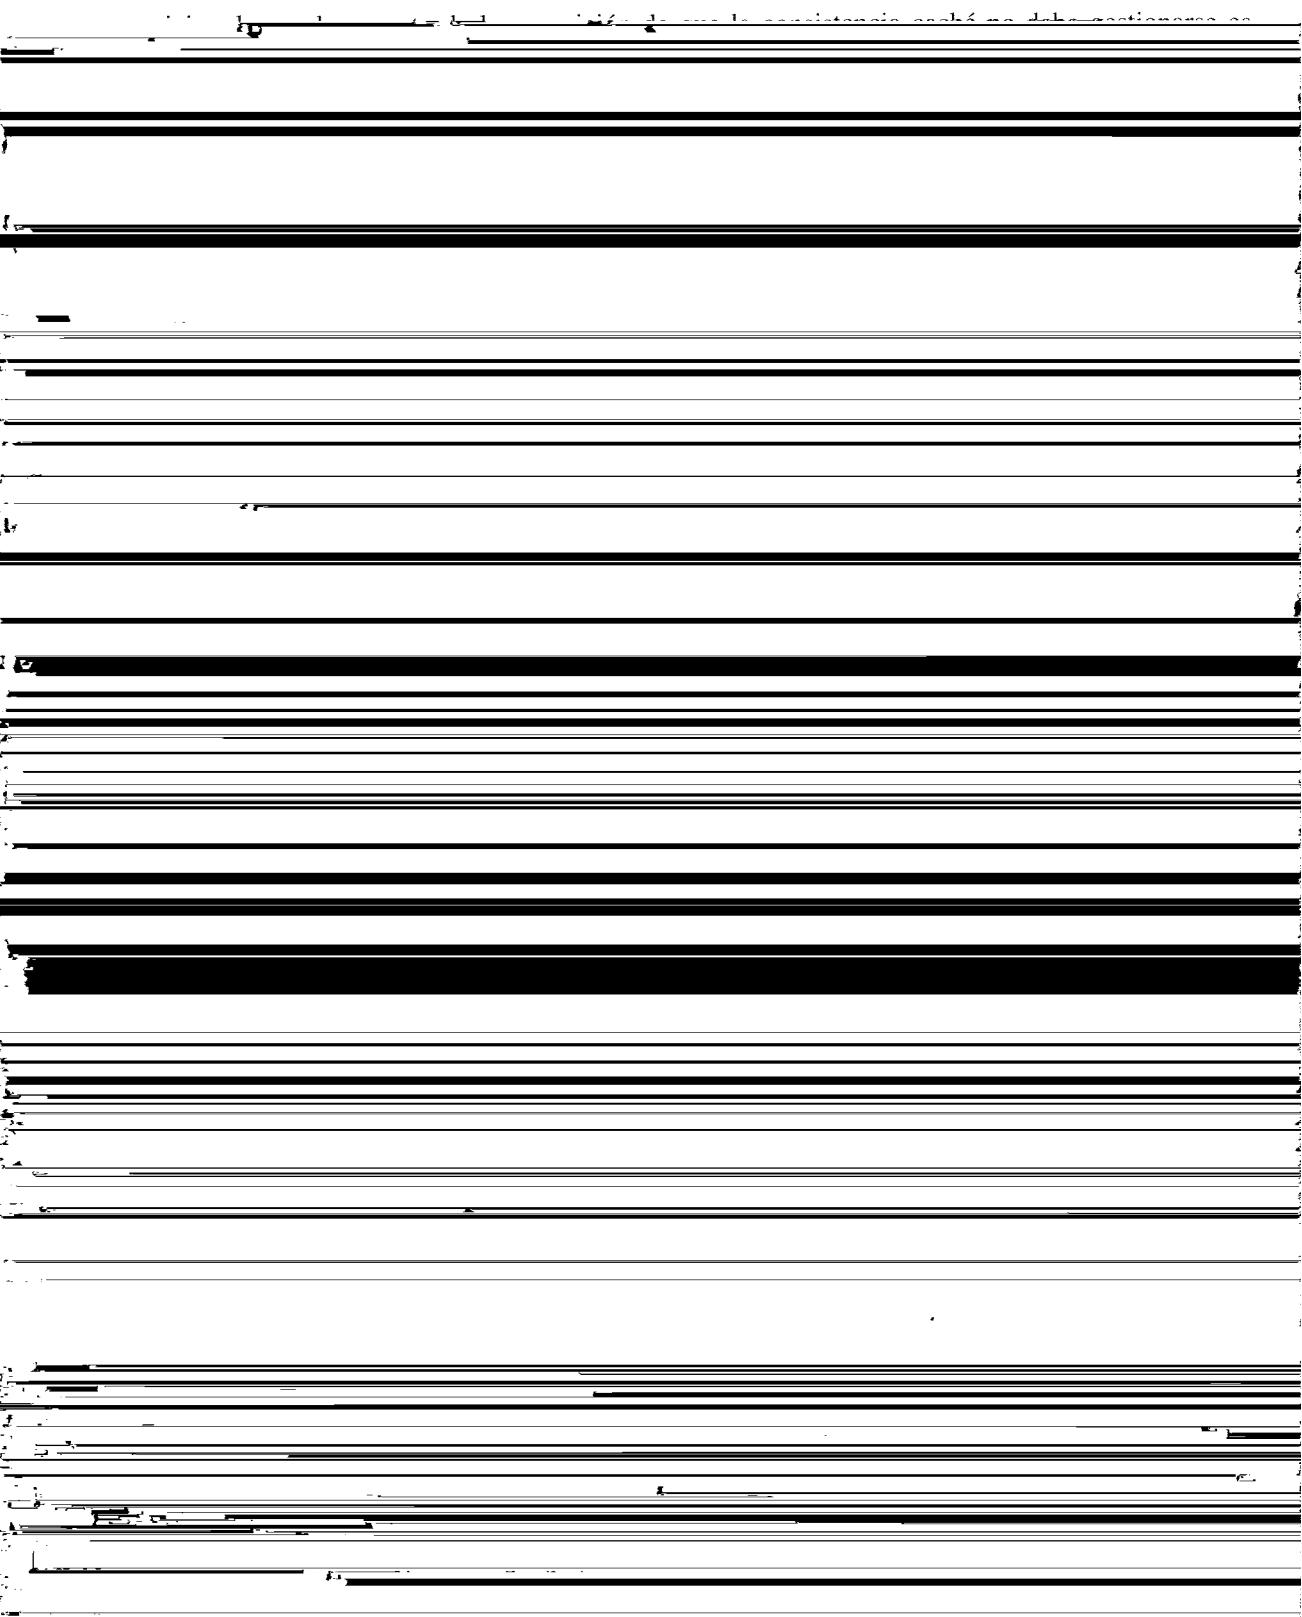
Tiempo de vida elevado: durante el tiempo de vida del servicio ocurrirán muchos cambios en la organización del conjunto de nombres y en los componentes que lo implementan.

Alta disponibilidad: la mayor parte del resto del sistema dependerá del servicio de nombres; y no podrán funcionar si este servicio no está disponible.

Aislamiento de fallos: de forma que los fallos locales no provoquen el fallo del sistema completo.

Tolerancia a la ausencia de autenticación: en un sistema abierto a gran escala no hay ningún componente que esté autenticado por *todos* los clientes del sistema.

Dos ejemplos de servicios de nombres que se han concentrado en el objetivo de la escalabilidad para un gran número de objetos son el servicio de nombres Globe [van Steen y otros 1998] y el sistema Handle [www.handle-net]. El Sistema de Nombres de Dominio de Internet (DNS), presentado en el Capítulo 3, es menos ambicioso en el número de objetos que es capaz de manejar, pero continúa usándose de forma muy amplia. Este sistema nombra objetos (en la práctica computadores) en Internet. Para proporcionar un servicio satisfactorio, se basa en gran medida en la replicación y el almacenamiento en caché de los datos de nominación. El diseño de DNS y de otros



Los servidores DNS no reconocen los nombres relativos: todos los nombres se refieren a la raíz global. Sin embargo, en la implementación práctica, el software de cliente mantiene una lista de nombres de dominio que se añaden automáticamente a cualquier nombre de componente único antes de la resolución. Por ejemplo, el nombre *bruno* sobre el dominio *dcs.qmw.ac.uk* se refiere probablemente a *bruno.dcs.qmw.ac.uk*; el software de cliente añadirá el dominio por defecto *dcs.qmw.ac.uk* e intentará resolver el nombre resultante. Si esto falla, entonces se añadirán otros nombres de dominio por defecto; finalmente, el nombre (absoluto) *bruno* se presentará a la raíz para su resolución. Sin embargo, los nombres con más de un componente se presentan normalmente de forma intacta al DNS como nombres absolutos.

◊ **Alias.** Desgraciadamente, los nombres con más de uno o dos componentes son desagradables de teclear y recordar. En general, un *alias* es similar a los enlaces simbólicos de tipo UNIX, permitiendo que un nombre práctico sea sustituto de otro más complicado. DNS permite alias, en los que se define un nombre de dominio para representar a otro. La razón para disponer de alias es la de proporcionar transparencia. Por ejemplo, los alias se usan habitualmente para especificar los nombres de máquinas que ejecutan un servicio web o un servicio FTP. El nombre *www.dcs.qmw.ac.uk* es un alias de *copper.dcs.qmw.ac.uk*. Esto tiene la ventaja de que los clientes pueden hacer referencia al servidor web mediante un nombre genérico que no se refiere a una máquina particular, y si el servidor web se mueve a otro computador, todo lo que hay que hacer es actualizar el alias en la base de datos DNS.

◊ **Dominios de nombres.** Un *dominio de nombres* es un espacio de nombres para el que existe una única autoridad administrativa global para asignar nombres. Esta autoridad ejerce, en conjunto, un control de los nombres que se pueden enlazar al dominio, aunque pueda delegar libremente esta tarea.

Los dominios en DNS son colecciones de nombres de dominio; sintácticamente el nombre de un dominio es el sufijo común de los nombres de dominio que hay dentro de él, aunque por otra parte no se pueda distinguir, por ejemplo, del nombre de un computador. Por ejemplo, *qmw.ac.uk* es un dominio que contiene *dcs.qmw.ac.uk*. Observe que el término *nombre de dominio* es potencialmente confuso ya que sólo algunos nombres de dominio identifican dominios. Un computador puede llegar a tener el mismo nombre que un dominio: por ejemplo, *yahoo.com* es el nombre de un servidor web en el dominio llamado *yahoo.com*.

El administrador de dominios puede estar involucrado en sub-dominios. El dominio *dcs.qmw.ac.uk* (Department of Computer Science, en Queen Mary and Westfield College, UK) puede contener cualquier nombre que deseé el departamento. Sin embargo, el propio nombre de dominio *dcs.qmw.ac.uk* debe estar de acuerdo con las autoridades del colegio, quienes gestionan el dominio *qmw.ac.uk*. De forma análoga, *qmw.ac.uk* debe acordar con la autoridad registrada para *ac.uk* y así consecutivamente.

La responsabilidad de un dominio de nombres va normalmente en paralelo con la responsabilidad de gestionar y mantener actualizada la porción correspondiente de la base de datos almacenada en un servidor de nombres autorizado y utilizado por el servicio de nombres. Los datos de nominación pertenecientes a diferentes dominios de nombres se almacenan generalmente en distintos servidores de nombres, gestionados por sus autoridades correspondientes.

◊ **Combinación y personalización de los espacios de nombres.** DNS proporciona un espacio de nombres global y homogéneo en el que un cierto nombre se refiere a la misma entidad, independientemente de qué proceso, en qué computador busque dicho nombre. Por el contrario, algunos servicios de nombres permiten distintos espacios de nombres (algunas veces espacios de nombres heterogéneos) incluidos en ellos; también algunos servicios de nombres permiten personalizar el espacio de nombres para acomodarse a las necesidades de grupos individuales, usuarios e incluso procesos.

Fusionado: El montado de sistemas de archivos UNIX y NFS (véase la Sección 8.3) es un ejemplo en el que una parte de un espacio de nombres se inserta cómodamente en otro. Pero, considére-

incluso procesos.

Fusionado: El montado de sistemas de archivos UNIX y NFS (véase la Sección 8.3) es un ejemplo en el que una parte de un espacio de nombres se inserta cómodamente en otro. Pero, considére-

ejemplo */etc/passwd* se refiere a un archivo en *rojo* y a otro diferente en *azul*. La forma más obvia de mezclar los sistemas de archivos es reemplazar la raíz de cada computador por una *súper raíz* y montar cada sistema de archivos de cada computador en esta *súper raíz*, sea por ejemplo */rojo* y */azul*. Los usuarios y los programas se referirán entonces a */rojo/etc/passwd* y a */azul/etc/passwd*. Sin embargo, la nueva asignación de nombres podría provocar que fallaran aquellos programas que todavía manejan el nombre antiguo */etc/passwd*. Una solución es dejar los contenidos de la raíz antigua en cada computador e insertar los sistemas de archivos */rojo* y */azul* en ambos computadores (asumiendo que esto no genera conflictos de nombres con los contenidos de la antigua raíz).

vos del tipo */etc/passwd*, pero esos nombres deben resolverse en el sistema de archivos de *rojo*, no en el de *azul*. Esto se logra en Spring pasando a *azul* una referencia al contexto de nominación local de *rojo* y utilizándola como el contexto de nominación del programa. Plan 9 [Pike y otros 1993] también permite a los procesos tener su propio espacio de nombres de sistema de archivos. Una característica novedosa de Plan 9 (que también puede implementarse en Spring) es que pueden ordenarse y fusionarse los directorios físicos dentro de un único directorio lógico. El efecto es que la búsqueda de un nombre en el directorio lógico único se realizará en la sucesión de los directorios físicos hasta que se encuentre, momento en el que se devolverán los atributos. Esto elimina la necesidad de proveer listas de rutas cuando se buscan programas o archivos de biblioteca.

9.2.2. RESOLUCIÓN DE NOMBRES

En general, la resolución es un proceso iterativo en el que se presenta de forma repetitiva un nombre sobre los contextos de nominación. Un contexto de nominación puede asociar un cierto nombre sobre un conjunto de atributos básicos (como los del usuario) bien de forma directa o bien asociando el nombre sobre otro contexto de nominación y sobre otro nombre derivado para presentarse en ese contexto. Para resolver un nombre, en primer lugar se presenta sobre un contexto de nominación inicial; el proceso de resolución se reitera mientras se generen otros contextos y otros nombres derivados. Esto se ilustró al principio de la Sección 9.2.1, con el ejemplo de */etc/passwd*, en el que *etc* se presenta al contexto */*, y a continuación *passwd* se presenta sobre el contexto */etc*.

Otro ejemplo de la naturaleza iterativa de la resolución es la utilización de alias. Por ejemplo, siempre que se pregunte a un servidor DNS para resolver un alias como *www.dcs.qmw.ac.uk*, el servidor primeramente resuelve el alias en otro nombre de dominio (en este caso *copper.dcs.qmw.ac.uk*), el cual deberá ser resuelto a continuación para producir la dirección IP.

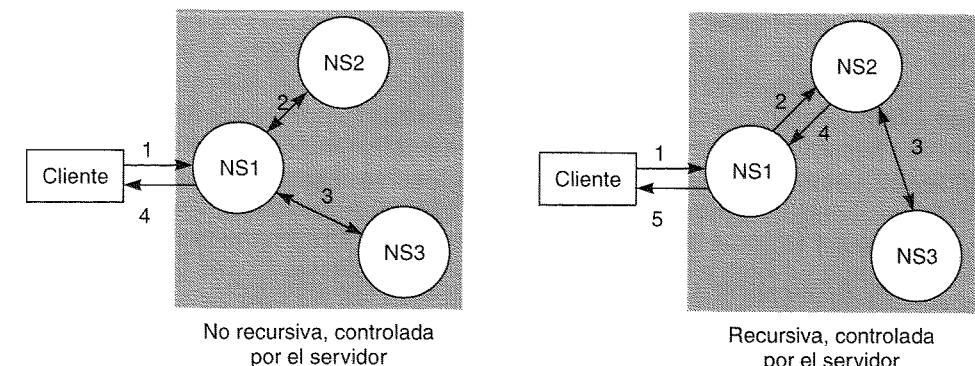
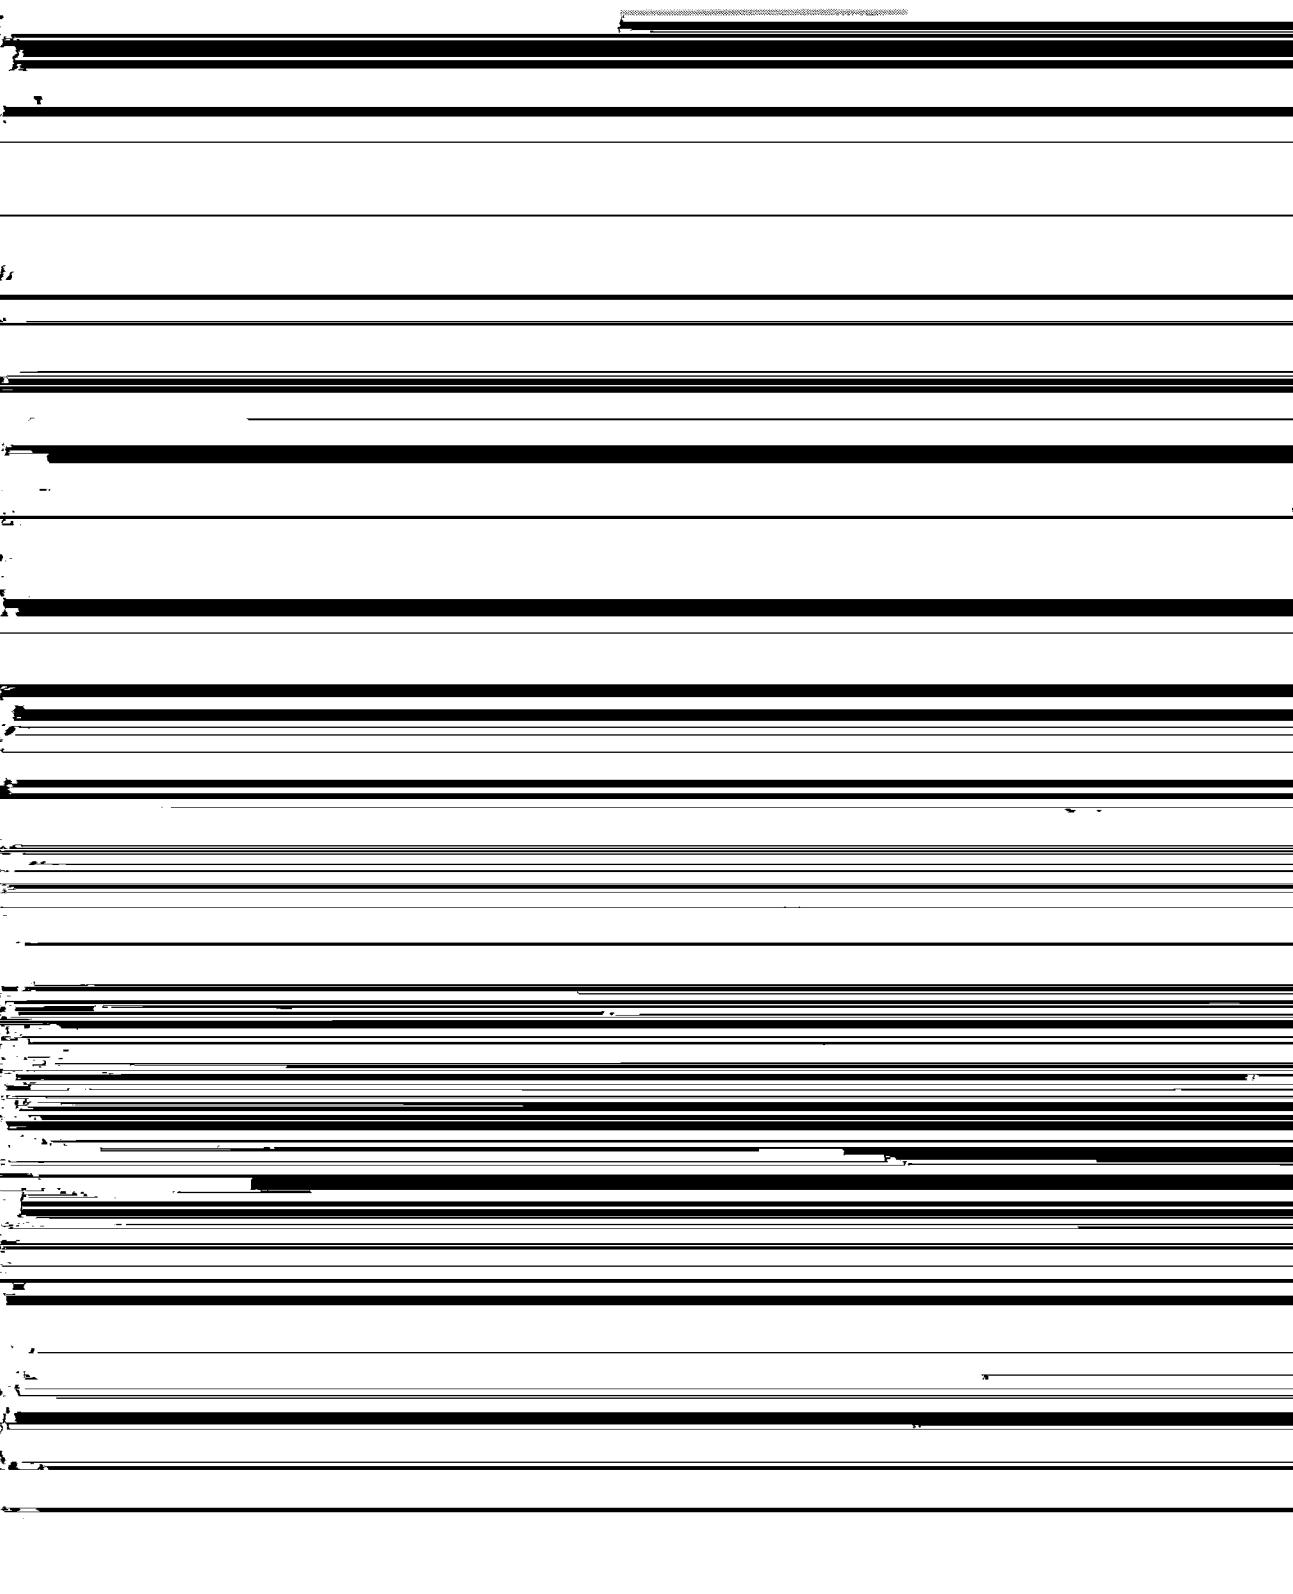
En general, la utilización de alias permite la presencia de ciclos en el espacio de nombres, en cuyo caso puede que la resolución no termine nunca. Existen dos soluciones, la primera consiste en abandonar el proceso de resolución si el número de resoluciones supera un cierto umbral; y, la segunda, permitir a los administradores vetar cualquier alias que pueda inducir ciclos.

◊ **Servidores de nombres y navegación.** Cualquier servicio de nombres, como DNS, que almacena una gran base de datos y es utilizado por una población grande no almacenará toda su información de nominación en un único computador servidor. Ese servidor sería un cuello de botella y un punto de fallo crítico. Cualquier servicio de nominación fuertemente utilizado deberá usar replicación para conseguir la suficiente disponibilidad. Veremos que DNS especifica que cada subconjunto de sus bases de datos sea replicada en, al menos, dos servidores independientes.

Hemos mencionado previamente que los datos que pertenecen a un dominio de nombres se almacenan normalmente en un servidor de nombres local gestionado por la autoridad responsable de ese dominio. A pesar de que, en algunos casos, un servidor de nombres puede almacenar datos relativos a más de un dominio, normalmente es correcto decir que los datos se reparten sobre los servidores de acuerdo a sus dominios. Veremos que en DNS, la mayor parte de las entradas se utilizan en los computadores locales. Aun así, también hay servidores de nombres para dominios superiores, como *yahoo.com* y *ac.uk*, y para el dominio raíz.

La partición de los datos implica que el servidor de nombres local no podrá responder a todas las solicitudes sin la ayuda de otros servidores de nombres. Por ejemplo, el servidor de nombres en el dominio *dcs.qmw.ac.uk* no es capaz de proporcionar la dirección IP de un computador en el dominio *cs.purdue.edu* a no ser que esa información esté en la caché (por supuesto eso no ocurre la primera vez que se realiza la consulta).

El proceso de localización de los datos con nombre entre más de un servidor de nombres, para resolver un nombre, se llama *navegación*. El software cliente de resolución de nombres realiza



Un cliente de nombres NS1 se comunica con otros servidores de nombres representando a un cliente

Figura 9.3. Navegación no recursiva y recursiva controlada por el servidor.

iterativa con sus parejas en la forma descrita previamente. En la navegación recursiva controlada por el servidor, una vez más el cliente contacta con un solo servidor. Si el nombre no está en este servidor, el servidor contacta con un igual que almacene un prefijo (más largo) del nombre, el cual a su vez intenta su resolución. Este procedimiento continúa de forma recursiva hasta que se resuelve el nombre.

Si un servicio de nombres abarca diferentes dominios administrativos, entonces se puede prohibir que los clientes que se estén ejecutando en un cierto dominio administrativo accedan a los servidores de nombres pertenecientes a otro dominio. Además, incluso puede prohibirse que los servidores de nombres descubran de la disposición de datos de nominación sobre servidores de nombres en otros dominios administrativos. En ese caso, tanto la navegación controlada por cliente como la no recursiva controlada por servidor son inapropiadas, y deberá utilizarse la navegación recursiva controlada por servidor. Los servidores de nombres autorizados solicitan datos de servicio de nombres a los servidores designados por los diferentes administradores, los cuales devuelven los atributos sin revelar las zonas de la base de datos de nominación en las que estaban almacenados.

◊ **Caché.** En DNS y otros servicios de nombres, el software de resolución de nombres del cliente y los servidores mantienen una caché de resultados de resoluciones previas. Cuando un cliente solicita la búsqueda de un nombre, el software de resolución de nombres consulta su caché. Si encuentra un resultado reciente de una búsqueda previa de dicho nombre, la devuelve al cliente; en otro caso se la envía al servidor. A su vez, dicho servidor puede devolver datos provenientes de otros servidores pero almacenados en su caché.

El almacenamiento de datos en caché es clave en las prestaciones de un servicio de nombres y ayuda en el mantenimiento de la disponibilidad tanto del servicio como de otros servicios que seguirán funcionando incluso después de que el servidor de nombres falle. La mejora en los tiempos de respuesta que generan gracias al ahorro en las comunicaciones con los servidores de nombres es obvia. Las cachés pueden utilizarse para eliminar a los servidores de nombres (por ejemplo, el servidor raíz) del camino de navegación, permitiendo que se realice la resolución a pesar del posible fallo de algún servidor.

El uso de caché por parte de los sistemas de resolución de nombres en los clientes está ampliamente difundido en los servicios de nombres, y con mucho éxito ya que los datos de nominación raramente cambian. Por ejemplo, la información del tipo de dirección de computador o de servicio tiende a permanecer inalterada durante meses o años. Sin embargo, existe la posibilidad de que un servicio de nombres devuelva atributos caducados, por ejemplo una dirección obsoleta, durante el proceso de resolución.

9.2.3. EL SISTEMA DE NOMBRES DE DOMINIO

El Sistema de Nombres de Dominio es un diseño de servicio de nombres, y su base de datos principal se utiliza a lo largo de Internet. Fue ideado principalmente por Mockapetris [1987] con el objetivo de reemplazar el esquema de nombres original de Internet, en el que todos los nombres de host y las direcciones se mantenían en un único archivo maestro central y se descargaban vía FTP a todos los computadores que los necesitaban [Harrenstien y otros 1985]. Pronto se vio que este esquema inicial sufría de fuertes limitaciones:

- No era escalable hasta un número grande de computadores.
- Las organizaciones locales deseaban administrar sus propios sistemas de nombres.
- Se necesitaba un servicio de nombres general, no uno que sólo sirviera para buscar direcciones de computadores.

Los objetos nombrados por DNS son, en primer lugar, computadores (para las cuales en su mayor parte lo que se almacena como atributos son sus direcciones IP) y lo que en este capítulo hemos denominado como dominios de nombres son llamados simplemente *dominios* en DNS. Sin embargo, en principio se puede nombrar cualquier tipo de objeto, y su arquitectura tienen la capacidad suficiente para múltiples implementaciones. Las organizaciones y departamentos pueden manejar sus propios datos de nominación. En Internet hay millones de nombres enlazados mediante DNS, y se realizan búsquedas contra dicho sistema a lo largo de todo el mundo. Cualquier nombre puede ser resuelto por cualquier cliente. Esto se consigue mediante una partición jerárquica de la base de datos de nombres, mediante la replicación de los datos de nombres y mediante el uso de cachés.

◊ **Nombres de dominio.** DNS está diseñado para utilizarse de variadas formas, cada una de las cuales puede tener su propio espacio de nombres. Sin embargo, en la práctica sólo uno se utiliza ampliamente, el usado para los nombres de Internet. El espacio de nombres DNS de Internet se divide de acuerdo a criterios de organización y geográficos. Los nombres se escriben con el dominio de mayor importancia en la derecha. Los dominios de organización de primer nivel (también llamados *dominios genéricos*) utilizados actualmente en Internet son:

<i>com</i>	– Organizaciones comerciales
<i>edu</i>	– Universidades y otras instituciones de educación
<i>gov</i>	– Agencias de gobierno de los EE.UU.
<i>mil</i>	– Organizaciones militares de los EE.UU.
<i>net</i>	– Principales centros de soporte de la red
<i>org</i>	– Otras organizaciones no mencionadas anteriormente
<i>int</i>	– Organizaciones internacionales

Además, cada país tiene sus propios dominios:

<i>us</i>	– Estados Unidos
<i>uk</i>	– Reino Unido
<i>fr</i>	– Francia
...	...

Los diferentes países, excepto los EE.UU., utilizan su propio dominio para distinguir sus organizaciones. El Reino Unido, por ejemplo, tiene los dominios *co.uk* y *ac.uk*, que corresponden a *com* y *edu* respectivamente (*ac* significa *comunidad académica*). Nótese que, a pesar de que el sufijo *uk* es claramente geográfico, un dominio como *doit.co.uk* podría ubicarse en la oficina española de Doit Ltd, una compañía británica. En otras palabras, incluso los nombres de dominio con connotaciones claramente geográficas son completamente independientes de sus ubicaciones físicas.

◊ **Solicitudes DNS.** DNS en Internet se utiliza, inicialmente, como sistema de resolución de nombres de host y para la búsqueda de hosts de correo electrónico, como se explica a continuación:

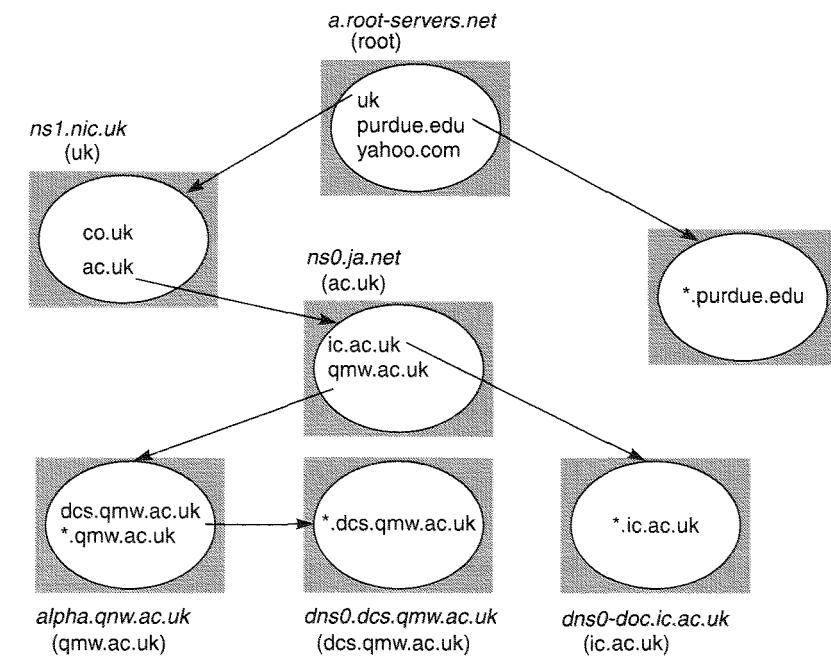
aquellas partes de la base de datos cercanas a los puntos donde se necesitan. La base de datos DNS

aquellas partes de la base de datos cercanas a los puntos donde se necesitan. La base de datos DNS

se refieren a computadores en el dominio local y son satisfechas mediante servidores dentro de dicho dominio. Sin embargo, cada servidor almacena los nombres de dominio y direcciones de otros servidores de nombres, de forma que puedan satisfacerse las solicitudes referentes a objetos de fuera del dominio.

Los datos de nominación de DNS se dividen en *zonas*. Una zona contiene los siguientes datos:

- Datos de atributos para nombres en el dominio, excepto los sub-dominios administrados por autoridades de menor nivel. Por ejemplo, una zona podría contener datos para el Colegio Queen Mary y Westfield (*qmw.ac.uk*) excepto los datos gestionados por los departamentos, por ejemplo el Department of Computer Science (*dcs.qmw.ac.uk*).
- Los nombres y direcciones de al menos dos servidores de nombres que proporcionan datos *autorizados* para la zona. Se trata de versiones de datos de zona para los que se puede confiar que estén razonablemente actualizados.
- Los nombres de servidores de nombres que mantienen datos autorizados para sub-dominios



Nota: los nombres de los servidores de nombres están en cursiva, y los dominios correspondientes están entre paréntesis. Las flechas indican entradas en el servidor de nombres

Figura 9.4. Servidores de nombres DNS.

ciados a países. Por ejemplo, el dominio *uk* actualmente tiene siete servidores de nombres, uno de los cuales se llama *ns1.nic.net*. Estos servidores de nombres conocen los servidores de nombres para los dominios de segundo nivel del Reino Unido como *ac.uk* y *co.uk*. Los servidores de nombres (actualmente cinco) del dominio *ac.uk* conocen los servidores de nombres de todos los dominios universitarios en el país, como *qmw.ac.uk* o *ic.ac.uk*. En algunos casos, un dominio universitario delega algunas de sus responsabilidades en un sub-dominio como *dcs.qmw.ac.uk*.

La información del dominio raíz se replica desde un servidor primario sobre una docena de servidores secundarios, como se ha descrito previamente. A pesar de esto, algunos servidores raíz sirven alrededor de 1.000 solicitudes por segundo, según Liu y Albitz [1998]. Todos los servidores DNS almacenan las direcciones de uno o más servidores de nombres raíz, los cuales no cambian a menudo. También almacenan a menudo la dirección de un servidor autorizado para el dominio padre. Una solicitud formada por un nombre de dominio de tres componentes del tipo de *www.berkeley.edu* puede ser satisfecha utilizando dos pasos de navegación en el peor caso: uno hacia un servidor raíz que almacena la correspondiente entrada de servidor de nombres y un segundo paso al servidor cuyo nombre es devuelto.

Remitiéndonos a la Figura 9.4, el nombre de dominio *jeans-pc.dcs.qmw.ac.uk* puede ser buscado desde *dcs.qmw.ac.uk* utilizando el servidor local *dns0.dcs.qmw.ac.uk*. Este servidor no almacena una entrada para el servidor web *www.ic.ac.uk* pero mantiene una entrada en caché para *ic.ac.uk* (que ha sido obtenida desde el servidor autorizado *ns0.ja.net*). El servidor *dns0-doc.ic.ac.uk* puede ser accedido para resolver el nombre completo.

◊ **Navegación y procesamiento de solicitudes.** Los clientes DNS son conocidos como *resolvedores* [RESOLVER]. Normalmente se implementan en forma de biblioteca software. Aceptan solicitudes, las formatean y las insertan en mensajes válidos del protocolo DNS y después se

Los registros adicionales de tipo A en la base de datos proporcionan las direcciones IP de los dos servidores de nombres *dns0* y *dns1*. Las direcciones IP de los hosts de correo y del tercer servidor de nombres se proporcionan en las bases de datos correspondientes a sus dominios.

La mayor parte del resto de registros de una zona inferior como *dcs.qmw.ac.uk* serán de tipo A y enlazarán el nombre de dominio de un computador sobre su dirección IP. Pueden contener algunos alias para servicios conocidos, por ejemplo:

<i>Nombre de dominio</i>	<i>Tiempo de vida</i>	<i>Clase</i>	<i>Tipo</i>	<i>valor</i>
www	1D	IN	CNAME	copper
copper	1D	IN	A	138.37.88.248

Si el dominio tiene sub-dominios, habrá registros adicionales de tipo *NS* especificando sus servidores de nombres, los cuales tendrán también entradas A individuales. Por ejemplo, la base de datos de *qmw.ac.uk* contiene los siguientes registros para los servidores de nombres en su sub-dominio *dcs.qmw.ac.uk*:

<i>Nombre de dominio</i>	<i>Tiempo de vida</i>	<i>Clase</i>	<i>Tipo</i>	<i>valor</i>
dcs	1D	IN	NS	dns0.dcs
dns0.dcs	1D	IN	A	138.37.88.249
dcs	1D	IN	NS	dns1.dcs
dns1.dcs	1D	IN	A	138.37.94.248
dcs	1D	IN	NS	cancer.ucs.ed.ac.uk

Compartición de carga en los servidores de nombres: En algunos puntos, servicios fuertemente utilizados como Web y FTP pueden estar soportados por un grupo de computadores sobre la misma red. En este caso se utiliza el mismo nombre de dominio para cada miembro del grupo. Cuando un nombre de dominio se comparte por varios computadores, hay un registro para cada computador en el grupo, el cual proporciona sus direcciones IP. El servidor de nombres responde a las solicitudes que se refieren a múltiples registros con el mismo nombre devolviendo la dirección IP mediante una planificación *round robin*. Los clientes sucesivos tienen acceso a servidores diferentes de forma que los servidores puedan compartir la carga de trabajo. La caché puede, potencialmente, malograr este esquema, ya que un servidor de nombres no autorizado o un cliente pueden tener la dirección del servidor en su caché y continuar usándola. Para contrarrestar este efecto, se proporciona a los registros un tiempo de vida muy corto.

◊ **La implementación BIND de DNS.** El Dominio de Nombres Internet de Berkeley (*Berkeley Internet Name Domain*, BIND) es una implementación de DNS para computadores que ejecutan UNIX. Los programas cliente enlazan el resolvedor en las bibliotecas software. Los servidores de nombres DNS ejecutan el demonio *named*.

BIND soporta tres categorías de servicio de nombres: servidores primarios, servidores secundarios y servidores sólo caché; el programa *named* implementa sólo uno de esos tipos en función de los contenidos de un archivo de configuración. Las dos primeras categorías son como las descritas previamente. Los servidores sólo caché leen desde un archivo de configuración suficientes nombres y direcciones de servidores autorizados para resolver cualquier nombre. Por lo tanto únicamente almacenan esos datos y los aprenden al resolver nombres de clientes.



un servicio, pero no conocen qué entidad del sistema lo proporciona, a pesar de que el servicio es accesible de forma cómoda. Por ejemplo, un usuario puede preguntar *¿qué computadores en este edificio son Macintosh ejecutando el sistema operativo MacOS 8.6?* o bien *¿dónde puedo imprimir una imagen en color de alta resolución?*

Un servicio que almacene colecciones de enlaces entre nombres y atributos y que realice búsquedas de entradas que emparejan especificaciones basadas en atributos se llama *servicio de directorio*. Por ejemplo el Servicio de Directorio Activo de Microsoft, X.500 y su primo LDAP (descripto en la Sección 9.5), Univers [Bowman y otros 1990] y Profile [Peterson 1988]. Los servicios de directorio a veces son llamados *servicios de páginas amarillas*, y los servicios de nombres convencionales a veces son llamados *servicios de páginas blancas*, utilizando una analogía obvia con los diferentes tipos de directorios telefónicos. A veces los servicios de directorio son conocidos como *servicios de nombres basados en atributos*.

Un servicio de directorio devuelve los atributos de cualquier objeto encontrado que coincida con los atributos especificados. De forma que, por ejemplo, la solicitud *NumeroTelefono = 020-555 9980* debe devolver *Nombre = Juan Herrero, NumeroTelefono = 020-555 9980, DireccionCorreo = juan@dcs.gormenghast.ac.uk, ...* El cliente puede especificar que únicamente un subconjunto de los atributos es de su interés; por ejemplo, simplemente las direcciones de correo electrónico de los objetos encontrados. X.500 y algunos otros servicios de directorio también permiten buscar objetos mediante nombres de texto de una jerarquía convencional.

Los atributos son claramente más potentes que los nombres como designadores de objetos: es posible escribir programas que seleccionen objetos de acuerdo con especificaciones precisas de los atributos mientras que los nombres puede que no sean conocidos. Otra ventaja de los atributos es que no desvelan la estructura de las organizaciones al resto del mundo como lo harían los nombres divididos usando criterios asociados a una cierta organización. Sin embargo, la relativa simplicidad asociada a la utilización de nombres de texto hace que, para muchas aplicaciones, no puedan ser reemplazados por la nominación basada en atributos.

◊ **Servicios de descubrimiento.** Un servicio de descubrimiento es un servicio de directorio que registra los servicios proporcionados en un entorno de red espontáneo. Como se explicó en la Sección 2.2.3, en las redes espontáneas los dispositivos tienen tendencia a conectarse sin previo aviso y sin preparación administrativa. El requisito consiste en integrar, sin intervención de usuarios, un conjunto de clientes y servicios que cambian dinámicamente. Para cumplir esas necesidades, un servicio de descubrimiento proporciona una interfaz que automáticamente registra y desregistra servicios, así como una interfaz para que los clientes busquen los servicios que necesitan de entre los que están actualmente disponibles.

Por ejemplo, considérese un visitante ocasional a una organización o un hotel (véanse las Secciones 1.2.3 y 2.2.3), que necesita imprimir un documento. No se puede esperar que el usuario disponga en la configuración de su computador portátil de los nombres de las impresoras, o que adivine dichos nombres (\myrtle\titus y \lione\frederick). En lugar de forzar a que el usuario configure su máquina, es preferible que el portátil pueda hacer uso de una interfaz de *búsqueda* de un servicio de descubrimiento para encontrar el conjunto de impresoras de red disponible que cumplen las necesidades del usuario. Puede seleccionarse una impresora concreta mediante la interacción con el usuario o consultando un registro de preferencias del usuario. Esta posibilidad resultará familiar a los usuarios del sistema operativo Macintosh.

Los atributos requeridos para el servicio de impresión pueden, por ejemplo, especificar si debe ser *láser* o de *chorro de tinta*; si se debe proporcionar o no impresión en color; y la situación física respecto al usuario (por ejemplo, su número de habitación).

De forma similar, los servicios notifican su existencia al servicio de descubrimiento a través de una interfaz de *registro*. Por ejemplo, una impresora (o el servicio que la gestiona) puede registrar sus atributos con el servicio de descubrimiento de la siguiente forma:

sus atributos con el servicio de descubrimiento de la siguiente forma:

`clasederecurso = impresora, tipo = laser, color = si, resolucion = 600dpi,
localizacion = habitacion101, url = http://www.hotelDuLac.com/services/printer57.`

sariamente la intervención de un usuario. Por ejemplo, un frigorífico podría descubrir un servicio de gestión de errores si se produce un fallo en el test de auto-diagnóstico, con el fin de notificar a su propietario el fallo utilizando el PC del hogar.

En los servicios de descubrimiento, el contexto para el descubrimiento se denomina frecuentemente *ámbito*. Algunos servicios, como el protocolo simplificado de descubrimiento de servicios, están pensados para utilizarse en ciertos ámbitos en función de la accesibilidad de una red local, como el ámbito de todos los recursos conectados a una red sin cables en el hogar. Esto es conveniente en diversidad ocasiones. Por ejemplo, cuando un usuario solicita una impresora normalmente quiere una que esté físicamente cercana, lo cual suele implicar que esté situada en una red local. Por el contrario, los servicios de directorio como X.500 se estructuran jerárquicamente para reflejar ámbitos geográficos y de organización. Es así que, X.500 puede utilizarse tanto para buscar un persona en la organización local como en un país.

Recientes desarrollos en servicios de descubrimiento incluyen el servicio de descubrimiento Jini (véase a continuación), el protocolo de localización de servicios [Guttmann 1999], el sistema de nominación intencional [Adjie-Winoto y otros 1999], el protocolo simplificado de descubrimiento de servicios, el cual está en el corazón de la iniciativa *plug and play universal* [www.upnp.com] y el servicio de descubrimiento de servicios seguros [Czerwinski y otros 1999].

◊ **Jini.** Jini [Waldo 1999, Arnold y otros 1999] es un sistema diseñado para ser utilizado en entornos de red espontáneos. Está completamente basado en Java, asumiendo que se ejecuta una JVM (*Java Virtual Machine*) en todos los computadores, permitiendo la comunicación mediante RMI (véase el Capítulo 5) y la descarga de código según se necesite. Jini proporciona recursos para descubrimiento de servicios, para transacciones, para espacios de datos compartidos llamados *javaSpaces* (similares a los espacios de tuplas [Carriero y Gelernter 1989]) y para eventos. Describiremos únicamente el sistema de descubrimiento.

Los componentes relacionados con el descubrimiento en un sistema Jini son servicios de *búsqueda*, servicios Jini y clientes Jini (véase la Figura 9.6). El servicio de *búsqueda* implementa lo

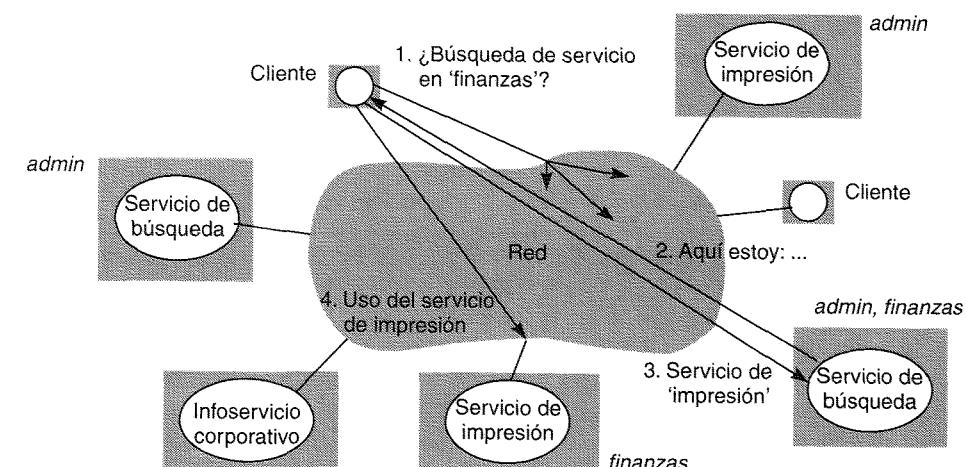


Figura 9.6. Servicio de descubrimiento en Jini.

cualquier otro servicio de descubrimiento: mediante la multidifusión a una dirección de multidifusión IP bien conocida. Esta dirección es conocida por todas las instancias del software Jini.

Cuando un cliente o servicio Jini comienza, envía una petición a esta dirección de multidifusión. Para ello se utiliza un valor de *tiempo de vida* que restringe el alcance del datagrama que lleva la solicitud a su vecindario en la red. Los servicios de búsqueda escuchan en un conector (*socket*) enlazado en la misma dirección para recibir dichas solicitudes. Cualquier servicio de búsqueda que reciba la solicitud y pueda responderla (véase a continuación) responderá con la dirección de contacto en la que recibe solicitudes de servicio. El solicitante puede realizar una invocación remota para buscar o registrar un servicio (el registro se denomina *joining* en Jini).

Los servicios de búsqueda también anuncian su existencia mediante datagramas enviados a la misma dirección de multidifusión. Los clientes y servicios Jini también pueden escuchar en la dirección de multidifusión para apercibirse de nuevos servicios de búsqueda.

Puede haber varias instancias del servicio de búsqueda accesible mediante multidifusión desde un cierto cliente o servicio Jini. Cada una de esas instancias se configura con uno o más nombres de *grupo* como *admin*, *finanzas* y *ventas*, los cuales actúan como etiquetas de ámbito. Cuando clientes y servicios solicitan un servicio de búsqueda, pueden especificar cualquier grupo en el que estén especialmente interesados, y únicamente responderán los servicios de búsqueda enlazados a los mismos nombres de grupo. Por ejemplo, en una organización dividida en departamentos, un dispositivo que necesite una impresora *admin* puede encontrar una que pertenezca al grupo *admin*, y un dispositivo que necesite una impresora *finanzas* encontrará una enlazada al grupo *finanzas*.

En la Figura 9.6 se muestra un cliente Jini descubriendo y utilizando un servicio de impresión. El cliente necesita un servicio de búsqueda en el grupo *finanzas* de forma que multidifunde una solicitud enfocada al nombre del grupo. Sólo un servicio de búsqueda está enlazado al grupo *finanzas* (el mismo servicio que también está enlazado al grupo *admin*), y dicho servicio responde. La respuesta del servicio de búsqueda incluye su dirección por lo que el cliente se comunica directamente con él mediante RMI para localizar todos los servicios de tipo *impresión*. Sólo un servicio de impresión se ha registrado con dicho servicio de búsqueda bajo el grupo *finanzas*, devolviéndose un objeto para acceder a dicho servicio. A continuación el cliente utiliza el servicio de impresión directamente, utilizando el objeto devuelto. La figura también muestra otro servicio de impresión, el situado en el grupo *admin*. También hay un servicio de información corporativa que no está enlazado a ningún grupo particular (y que puede ser registrado con todos los servicios de búsqueda).

Jini utiliza *concesiones*, discutidas en el Capítulo 5. Cuando los servicios de Jini se registran con el servicio de búsqueda, se les proporciona una concesión que garantiza su entrada de registro por un período de tiempo limitado. Si un servicio no se comunica con el servicio de búsqueda para renovar su concesión antes de que éste expire, entonces se asume que ha fallado y el servicio de búsqueda puede eliminar la entrada.

9.4. ESTUDIO DEL CASO DEL SERVICIO DE NOMBRES GLOBAL

Un Servicio de Nombres Global (*Global Name Service*, GNS) fue diseñado e implementado por Lampson y algunos colegas en el Centro de Investigación de Sistemas de DEC [Lampson 1986] para proporcionar servicios de localización de recursos, direccionamiento de correo y autenticación. Los objetivos de diseño de GNS ya se mostraron al final de la Sección 9.1; reflejan el hecho de que un servicio de nombres, para su uso entre diferentes tipos de redes, debe soportar una base de datos de nombres que pueda extenderse para incluir los nombres de millones de computadores y (finalmente) direcciones de correo electrónico para billones de usuarios. Los diseñadores de GNS también admitieron que la base de datos de nombres tiende a tener un tiempo de vida largo, que debe continuar operando efectivamente mientras crece y mientras la red en la que está basada evoluciona. Durante ese tiempo, la estructura del espacio de nombres puede cambiar para reflejar los cambios en las estructuras de organización. El servicio debe proporcionar cabida a los cambios en los nombres de los individuos, organizaciones y grupos que gestiona; y cambios en la estructura de nominación, del tipo de los que ocurren cuando una empresa es absorbida por otra. En esta descripción, realizaremos especial hincapié en aquellas características de diseño que permiten acomodarse a dichos cambios.

La potencialmente enorme base de datos de nombres y la escala del entorno distribuido en el que GNS ha sido ideado para operar hacen que el uso de las cachés sea esencial, y provocan que sea extremadamente difícil mantener la consistencia completa entre todas las copias de una entrada de la base de datos. La estrategia adoptada para la consistencia caché se basa en la suposición de que las actualizaciones a las bases de datos serán poco frecuentes y que una diseminación lenta de las actualizaciones es aceptable, ya que los clientes pueden detectar y recuperarse de la utilización de datos de nominación caducados.

GNS gestiona una base de datos de nombres compuesta de un árbol de directorios que contienen nombres y valores. Los directorios se identifican mediante nombres de caminos compuestos referidos a una raíz, o relativos a un directorio de trabajo, muy parecidos a los nombres de archivos del sistema de archivos de UNIX. Cada directorio tiene también asignado un entero el cual sirve como *identificador de directorio* (DI) único. En esta sección utilizamos nombres en cursiva cuando nos referimos a un DI o a un directorio, de forma que *EC* es el identificador del directorio EC. Un directorio contiene una lista de nombres y referencias. Los valores almacenados en las hojas del árbol de directorio se organizan en *árboles de valores*, de forma que los atributos asociados con los nombres pueden ser valores estructurados.

Los nombres en GNS tienen dos partes: *<nombre de directorio, nombre de valor>*. La primera parte identifica un directorio; la segunda se refiere a un árbol de valor, o a alguna porción de un árbol de valor. Por ejemplo, véase la Figura 9.7 en la que cada DI se muestra como un entero corto a pesar de que en realidad se eligen de entre un rango de enteros que aseguran su singularidad. Los atributos de un usuario Pedro.Herrero en el directorio QMW deberían estar almacenados en el árbol de valor llamado *<EC/UK/AC/QMW, Pedro.Herrero>*. El árbol de valor incluye una contraseña, que puede referenciarse como *<EC/UK/AC/QMW, Pedro.Herrero/clave>*, además de varias direcciones de correo, cada una de las cuales se debe mostrar en el árbol de valor bajo un único nodo llamado *<EC/UK/AC/QMW, Pedro.Herrero/buzones>*.

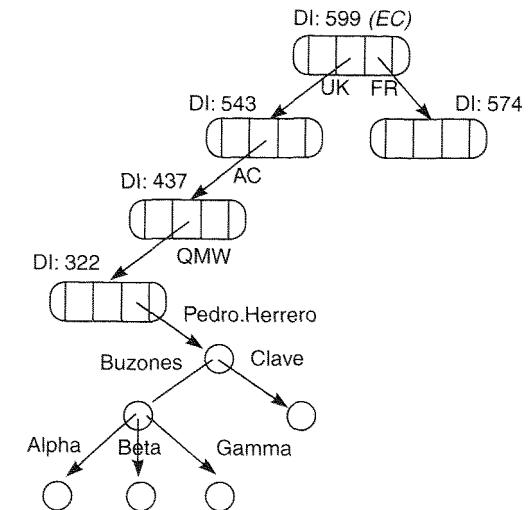


Figura 9.7. Árbol de directorio de GNS y valor del árbol para el usuario Pedro.Herrero.

El árbol de directorio está dividido y almacenado en muchos servidores, con cada partición replicada en varios servidores. La consistencia del árbol se mantiene frente a dos o más actualizaciones concurrentes; por ejemplo, dos usuarios pueden intentar crear entradas con el mismo nombre de forma simultánea, y sólo uno de ellos lo conseguirá. Los directorios replicados presentan un segundo problema de consistencia; se trata mediante un algoritmo de actualización distribuida asíncrona que asegura la consistencia final, pero sin garantías de que todas las copias estén siempre actualizadas. Este nivel de consistencia se considera satisfactorio.

◊ **Adecuación de los cambios.** Trataremos ahora los aspectos de diseño involucrados en la implementación del crecimiento y cambio en la estructura de la base de datos de nominación. En el nivel de clientes y administradores, el crecimiento se sirve de la forma habitual, es decir, mediante la extensión del árbol de directorio. Sin embargo, podemos querer integrar los árboles de nombres de dos servicios GNS que previamente estaban separados. Por ejemplo, ¿cómo podemos integrar la base de datos mostrada en la Figura 9.7 cuya raíz es el directorio EC con otra base de datos para NORTEAMÉRICA? En la Figura 9.8 se muestra la nueva raíz MUNDO insertada por encima de las raíces existentes de los dos árboles que se quieren mezclar. Esta técnica es sencilla, pero, ¿cómo afecta a los clientes que continúan utilizando nombres referidos a lo que era la *raíz* antes de que se realizará la integración? Por ejemplo *</UK/AC/QMW, Pedro.Herrero>* es un nombre uti-

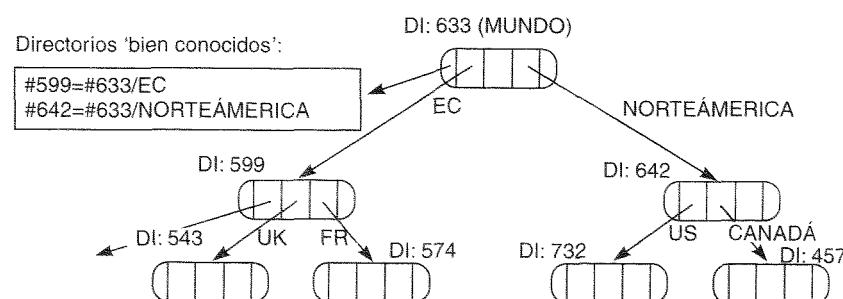


Figura 9.8. Firmas digitales con claves públicas.

lizado por los clientes antes de la integración. Se trata de un nombre absoluto (al comenzar con el

lizado por los clientes antes de la integración. Se trata de un nombre absoluto (al comenzar con el símbolo raíz «/»), pero se refiere a la raíz *EC*, no a *MUNDO*. *EC* y *NORTEAMÉRICA* son *raíces de trabajo*, es decir, contextos iniciales sobre los que se buscan los nombres que comienzan con la

queda de directorio de GNS interpreta el enlace como una redirección al directorio *US* en su nueva localización.

◊ **Discusión de GNS.** GNS desciende de Grapevine [Birrell y otros 1982] y Clearinghouse [Oppen y Dalal 1983], dos sistemas de nominación de mucho éxito desarrollados fundamentalmente para la gestión del correo en la Corporación Xerox. GNS resuelve perfectamente las necesidades de escalabilidad y reconfigurabilidad, pero la solución adoptada para mezclar y mover los árboles de directorio implica el requisito de que la base de datos (la tabla de directorios bien conocidos) deba estar replicada sobre cada nodo. En una red a gran escala, las reconfiguraciones pueden suceder en cualquier nivel, y esta tabla podría crecer hasta un tamaño muy elevado, entrando en conflicto con el objetivo de la escalabilidad.

9.5 ESTUDIO DEL CASO DEL SERVICIO DE DIRECTORIO X.500

X.500 es un servicio de directorio en el sentido definido en la Sección 9.3. Puede ser utilizado de la misma forma que un servicio de nombres convencional, pero se usa principalmente para satisfacer solicitudes descriptivas, diseñadas para descubrir los nombres y atributos de otros usuarios o recursos de sistema. Los usuarios pueden tener múltiples requisitos para la búsqueda en un directorio de usuarios en red, organizaciones y recursos de sistema para obtener información acerca de las entidades contenidas en el directorio. Los posibles usos de ese tipo de servicio pueden ser variados. Éstos van desde la realización de consultas análogas a la utilización de directorios telefónicos, como accesos corrientes a las *páginas blancas* para obtener la dirección de correo electrónico de un usuario o una solicitud a las *páginas amarillas* con el objetivo, por ejemplo, de obtener los nombres y números telefónicos de garajes especializados en la reparación de un cierto tipo particular de coche, al uso del directorio para acceder a detalles personales, como puesto de trabajo, hábitos dietéticos o incluso imágenes fotográficas de los individuos.

Este tipo de solicitudes pueden provenir de los usuarios, como el ejemplo de la consulta sobre garajes realizada en las *páginas amarillas* explicada previamente, o desde procesos, cuando pueden ser utilizados para la identificación de servicios que cumplen un cierto requisito funcional.

Los individuos y las organizaciones pueden utilizar un servicio de directorio para proporcionar una amplia cantidad de información sobre ellos mismos y sobre los recursos que ofrecen para ser utilizados desde la red. Los usuarios pueden realizar búsquedas sobre el directorio para encontrar información específica basándose únicamente en un conocimiento parcial de su nombre, estructura o contenido.

Las organizaciones de estandarización ITU e ISO han definido el *Servicio de Directorio X.500* [ITU/ISO 1997] como un servicio de red orientado al cumplimiento de dichos requisitos. El estándar lo describe como un servicio para el acceso a información de *entidades del mundo real*, pero puede utilizarse igualmente para el acceso a información sobre servicios y dispositivos hardware y software. X.500 se especifica como un servicio de nivel de aplicación en el conjunto de estándares de Interconexión de Sistemas Abiertos (OSI), pero su diseño no depende de forma significativa de otros estándares OSI por lo que puede verse como el diseño de un servicio de directorio de propósito general. Esbozaremos a continuación el diseño del servicio de directorio X.500 y su implementación. Los lectores interesados en una descripción más detallada de X.500 y de los métodos para su implementación pueden referirse al libro de Rose sobre este tema [Rose 1992]. X.500 es también la base para LDAP (se explicará posteriormente); y se utiliza en el servicio de directorio DCE [OSF 1997].

Los datos almacenados en los servidores X.500 se organizan en una estructura de árbol en la que los nodos tienen nombres, como en otros servidores de nombres descritos en este capítulo, pero en X.500 es posible almacenar una gran cantidad de atributos en cada nodo del árbol y el

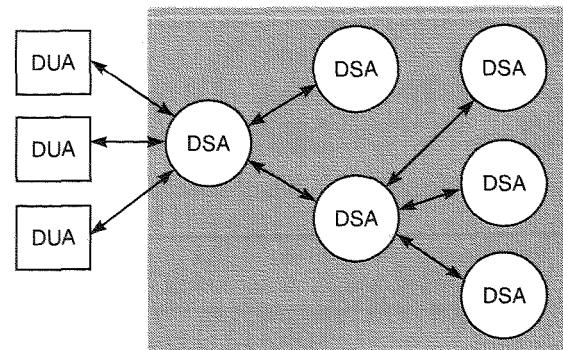


Figura 9.10. Arquitectura del servicio X.500.

acceso no se realiza simplemente por nombre sino que también se pueden realizar búsquedas basadas en cualquier combinación de atributos.

El árbol de nombres de X.500 se llama *Árbol de Información de Directorio* (*Directory Information Tree*, DIT), y la estructura de directorio completa incluyendo los datos asociados a los nodos se llama *Base de Información de Directorio* (*Directory Information Base*, DIB). Está pensado para tener un único DIB integrado que contiene la información proporcionada por las organizaciones de todo el mundo, con porciones de DIB situadas en servidores X.500 individuales. Normalmente, una organización de tamaño medio o grande debería proporcionar al menos un servidor.

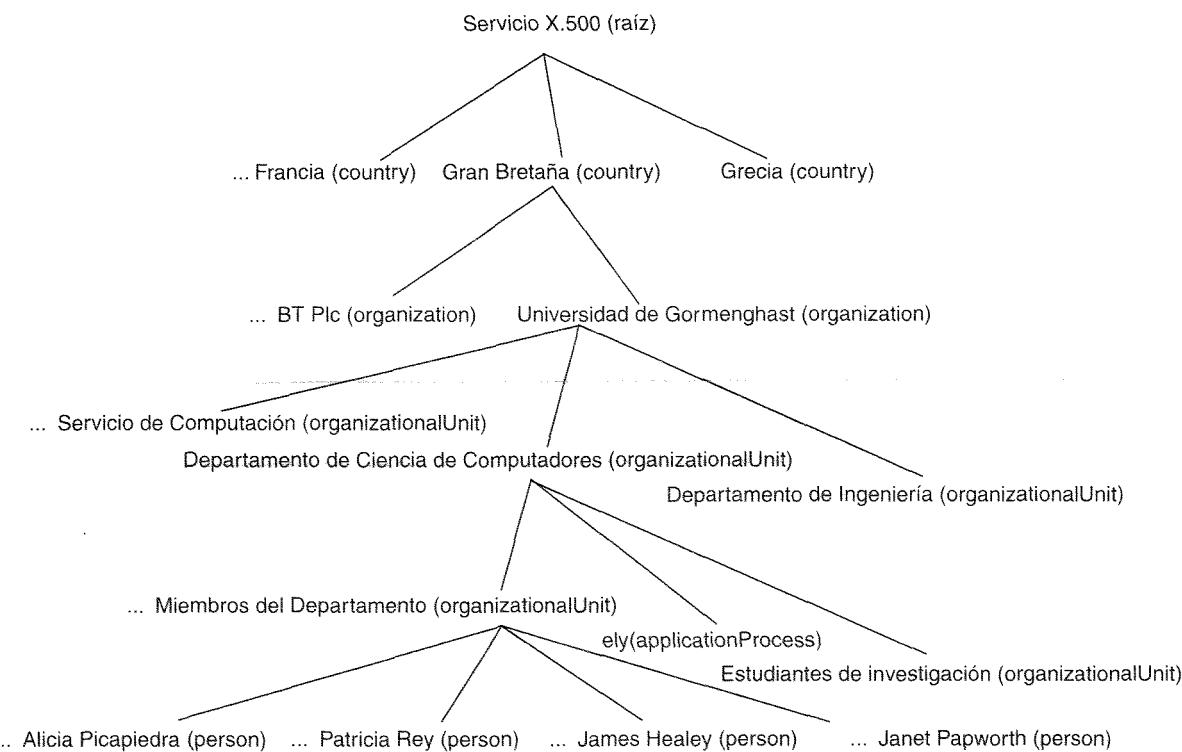


Figura 9.11. Parte del Árbol de Información de Directorio X.500.

<i>info</i>	Alicia Picapiedra, Miembro del Departamento, Departamento de Ciencia de los Computadores, Universidad de Gormenghast, GB
<i>commonName</i>	
	Alicia.L.Picapiedra
	Alice.Picapiedra
	Alice Picapiedra
	A. Picapiedra
<i>surname</i>	Picapiedra
<i>telephoneNumber</i>	+ 44 986 33 4604
<i>uid</i>	alf
<i>mail</i>	alp@dcs.gormenghast.ac.uk
	Alicia. Picapiedra @dcs.gormenghast.ac.uk
<i>roomNumber</i>	Z42
<i>userClass</i>	Investigador

Figura 9.12. Una Entrada DIB en X.500.

Los clientes acceden al directorio estableciendo una conexión al servidor y enviándole solicitudes de acceso. Los clientes pueden enviar una solicitud de información a cualquier servidor. Si los datos solicitados no están en el segmento de la DIB gestionado por el servidor sobre el que se ha contactado, éste realizará una invocación a otros servidores para resolver la solicitud o bien redirigirá al cliente sobre otro servidor.

Utilizando la terminología del estándar X.500, los servidores se llaman *Agentes de Servicio de Directorio* (*Directory Service Agent*, DSA) y los clientes son *Agentes de Usuario de Directorio* (*Directory User Agents*, DUA). En la Figura 9.10 se muestra la arquitectura del software y uno de los posibles modelos de navegación, en el que cada proceso cliente DUA interactúa con un único DSA, el cual accede a otros DSAs según se necesite para resolver la solicitud.

Cada entrada en la DIB está formada por un nombre y un conjunto de atributos. Al igual que en otros servidores de nombres, el nombre completo de una entrada se corresponde con un camino a través del DIT, desde la raíz del árbol hasta la entrada. Además de nombres completos o *absolutos*, un DUA puede establecer un contexto formado por un nodo base, y usar nombres relativos más cortos que proporcionan el camino desde el nodo base a la entrada nombrada.

En la Figura 9.11 se muestra la porción del Árbol de Información de Directorio que incluye la Universidad de Gormenghast, en Gran Bretaña, y en la Figura 9.12 aparece una de las entradas DIB asociadas. La estructura de datos para las entradas en la DIB y en la DIT es muy flexible. Una entrada en la DIB está formada por un conjunto de atributos, en el que cada atributo tiene un *tipo* y uno o más *valores*. El tipo de cada atributo distingue por un nombre de tipo (por ejemplo, *countryName*, *organizationName*, *commonName*, *telephoneNumber*, *mailbox*, *objectClass*). Si es necesario se pueden definir nuevos tipos para los atributos. Para cada tipo distinto existe una definición de tipo, la cual incluye una descripción de tipo y una definición sintáctica en Notación ASN.1 (un estándar de notación para definiciones sintácticas) definiendo representaciones para todos los valores permitidos del tipo.

Las entradas DIB se clasifican de forma similar a las estructuras de clases de objetos que aparecen en lenguajes de programación orientados a objetos. Cada entrada incluye un atributo *objectClass*, el cual determina la clase (o clases) del objeto al que se refiere dicha entrada. Algunos ejemplos de valores de *objectClass* son *Organization*, *organizationalPerson* y *document*. Si es necesario se pueden definir nuevas clases. La definición de una clase debe indicar qué atributos son obligatorios y cuáles son opcionales para las entradas en dicha clase. Las definiciones de clases se organizan en una jerarquía de herencias en la que todas las clases excepto una (llamada *topClass*) deben contener un atributo *objectClass* y el valor de dicho atributo debe ser el nombre de una

o más clases. Si existen varios valores *objectClass*, el objeto hereda los atributos obligatorios y opcionales de cada una de las clases.

El nombre de una entrada DIB (el nombre que determina su posición en el DIT) se determina seleccionando como *atributos distinguidos* a uno o más de sus atributos. Los atributos seleccionados para este propósito son llamados *Nombres Distinguidos* (DN) de una entrada.

Ahora podemos considerar los métodos utilizados para acceder a un directorio. Existen dos tipos principales de solicitudes de acceso:

read: debe proporcionarse un nombre absoluto o relativo (un *nombre de dominio* en la terminología X.500) de una entrada, junto con una lista de atributos para ser leídos (o una indicación de que se solicitan todos los atributos). El DSA localiza la entrada nombrada mediante la navegación en el DIT y enviando solicitudes a otros servidores DSA para aquellas partes del árbol que no mantenga. Obtiene los atributos requeridos y se los envía al cliente.

search: se trata de una solicitud de acceso basada en atributos. Se proporcionan en forma de argumentos un nombre base y una expresión de filtro. El nombre base especifica el nodo en el DIT desde el cual debe comenzar la búsqueda; la expresión de filtro es una expresión booleana que debe ser evaluada para cada nodo que se encuentre por debajo del nodo base. El filtro especifica un criterio de búsqueda: una combinación lógica de tests sobre los valores de cualquier atributo en una entrada. El mandato *search* devuelve una lista de nombres (Nombres de Dominio) para todas aquellas entradas por debajo del nodo base para las que la evaluación del filtro haya resultado *TRUE*.

Por ejemplo, se puede construir y aplicar un filtro para encontrar los *commonNames* de las personas que ocupan la habitación Z42 en el Departamento de Ciencias de la Computación de la Universidad de Gormenghast (véase la Figura 9.12). A continuación, se utiliza una solicitud de lectura para obtener uno o todos los atributos de las entradas DIB encontradas.

La búsqueda puede ser costosa cuando se aplica a grandes porciones del árbol de directorio (los cuales pueden residir en varios servidores). Se pueden proporcionar argumentos adicionales a *search* para restringir el ámbito de esta búsqueda, el tiempo durante el que se permite que una búsqueda continúe y el tamaño de la lista de entradas que se devuelve.

◇ **Administración y actualización de la DIB.** La interfaz DSA incluye operaciones para añadir, eliminar y modificar entradas. Se proporciona control de acceso tanto para solicitudes como para operaciones de actualización, de forma que el acceso a partes del DIT pueda restringirse a ciertos usuarios o clases de usuarios.

La DIB se divide bajo la suposición de que cada organización proporcionará como mínimo un servidor que gestione los detalles de las entidades en dicha organización. Se pueden replicar porciones de la DIB sobre diferentes servidores.

Al ser X.500 un estándar (*recomendación* si se utiliza la terminología CCITT) no cuestiona la implementación. Sin embargo, resulta evidente que cualquier implementación sobre múltiples servidores en una red de área amplia se debe basar en una utilización extensiva de las técnicas de replicación y caché para reducir las redirecciones generadas en las solicitudes.

Existe una implementación, descrita en Rose [1992], en un sistema desarrollado en el University College, en Londres, conocido como QUIPU [Kille 1991]. En esta implementación, tanto la caché como la replicación se realizan al nivel de entradas DIB individuales, y al nivel de colecciones de entradas que descienden del mismo nodo. Se asume que los valores pueden volverse inconsistentes después de una actualización y que el intervalo de tiempo que tarda en resolverse la inconsistencia puede ser de varios minutos. Esta forma de diseminación de las actualizaciones se considera normalmente aceptable para aplicaciones de servicio de directorios.

◇ **Protocolo de peso ligero para el acceso a directorios.** La interfaz estándar de X.500 utiliza un protocolo que implica a los niveles superiores de la pila de protocolos ISO. En la Univer-

sidad de Michigan un grupo propuso una aproximación de peso ligero llamada *Protocolo de Peso Ligero para el Acceso a Directorios* (LDAP), en la que un DUA accede a un servicio de directorio X.500 directamente utilizando TCP/IP. Véase RFC 2251 [Wahl y otros 1997]. LDAP simplifica la interfaz de X.500 de otras formas. Proporciona un API relativamente simple; reemplaza la codificación ASN.1 mediante la codificación textual.

A pesar de que la especificación LDAP se basa en X.500, LDAP no lo necesita. Cualquier otro servidor de directorio que cumpla la especificación LDAP más simple (al contrario que la especificación X.500) puede ser utilizado por una implementación LDAP. Por ejemplo, el Servicio de Directorio Activo de Microsoft proporciona una interfaz LDAP. LDAP ha sido ampliamente adoptado, sobre todo en servicios de directorio de intranet. Proporciona acceso seguro a datos de directorio mediante autenticación.

◇ **Discusión de X.500.** X.500 especifica un modelo detallado para servicios de directorio que van desde el ámbito de organizaciones individuales hasta directorios globales, siendo por ello muy importante. Su mayor impacto se ha producido a nivel de intranet, donde su influencia se ha conseguido a través de software LDAP de amplia difusión. El futuro de X.500 como estándar de directorio global (Internet) no está claro. En primer lugar, el requisito de un sistema de directorio global de existir en absoluto (basado o no en X.500) no está claro, sobre todo a la vista de los problemas de privacidad que pueden llegar a existir sobre dicho directorio. Segundo, dicho sistema de directorio global necesitará integrarse con los estándares de nombres existentes en Internet, incluyendo nombres DNS y direcciones de correo. Finalmente, las decisiones sobre el ámbito de la información que deberá ser proporcionada en los directorios deberá ser tomada a nivel nacional e internacional para asegurar la uniformidad de las clases de objetos almacenados en la DIB.

9.6. RESUMEN

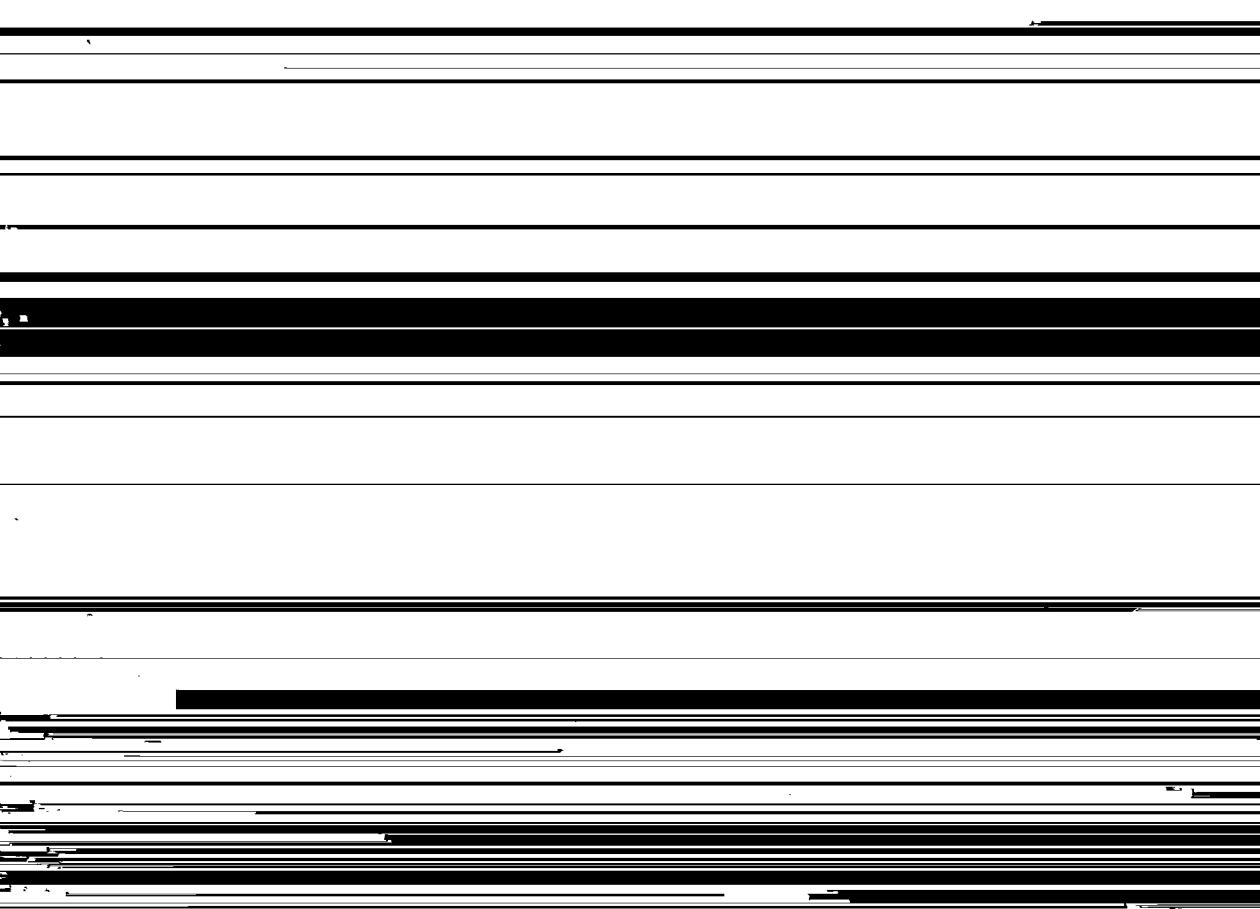
En este capítulo se ha descrito el diseño e implementación de los servicios de nombres en sistemas distribuidos. Los servicios de nombres almacenan los atributos de objetos en un sistema distribuido (en especial sus direcciones) y devuelven esos atributos cuando se realiza una búsqueda sobre un cierto nombre de texto.

Los principales requisitos que debe poseer un servicio de nombres son la habilidad para manejar un número arbitrario de nombres; tiempo de vida grande; alta disponibilidad; aislamiento de los fallos; y tolerancia frente a la falta autenticación.

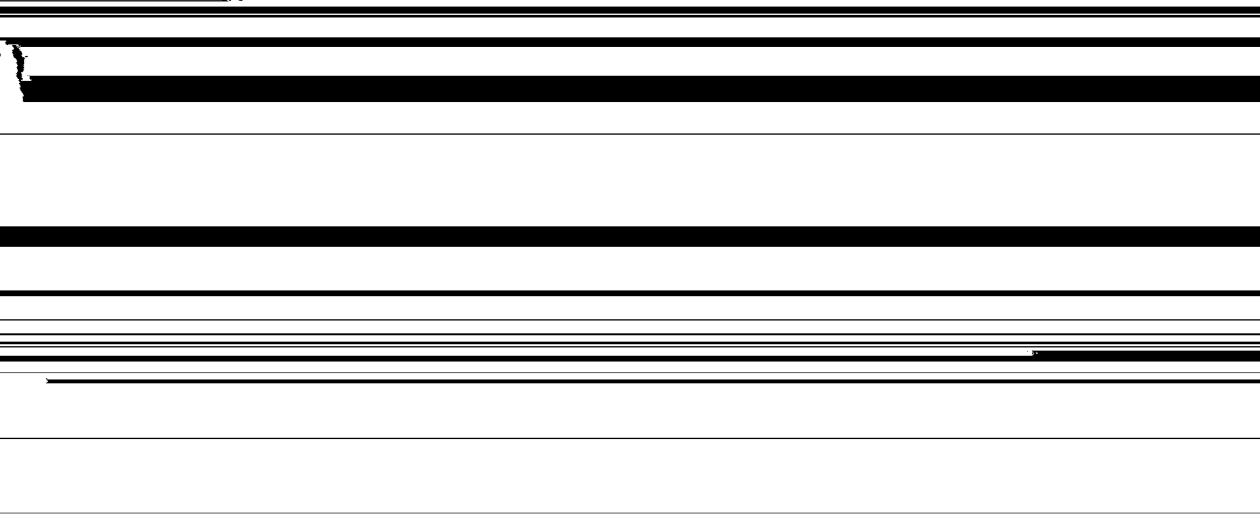
Las principales cuestiones de diseño son, en primer lugar, la estructura del espacio de nombres, es decir, las reglas sintácticas que gobiernan la formación de nombres. Una cuestión relacionada es el modelo de resolución: las reglas mediante las que un nombre multi-componente se resuelve en un conjunto de atributos. El conjunto de nombres enlazados debe ser gestionado. La mayor parte de los diseños dividen el espacio de nombres en dominios (secciones discretas del espacio de nombres), asociando a cada uno de ellos una única autoridad que controla el enlazado de nombres dentro del dominio.

La implementación del servicio de nombres puede abarcar diferentes organizaciones y comunidades de usuarios. En otras palabras, la colección de enlaces entre nombres y atributos, se almacena en varios servidores de nombres, cada uno de los cuales almacena al menos parte del conjunto de nombres del dominio de nombres. Se plantea así la cuestión de la navegación, es decir, el procedimiento utilizado para resolver un nombre cuando la información necesaria es almacenada en más de un punto. Los tipos de navegación soportados son la iterativa, la multidifusión, la recursiva controlada por el servidor y la no recursiva controlada por el servidor.

Otro aspecto importante sobre la implementación de un servicio de nombres es la utilización de



Otro aspecto importante sobre la implementación de un servicio de nombres es la utilización de



- 9.11. ¿Cuándo podrá un servidor DNS proporcionar múltiples respuestas a la búsqueda de un solo nombre, y por qué?
- 9.12. El servicio de búsqueda de Jini busca coincidencias entre las ofertas de servicio con las solicitudes de clientes basándose en atributos o en tipos Java. Explique con ejemplos la diferencia entre esas dos formas de buscar coincidencias. ¿Cuál es la ventaja de proporcionar ambos tipos?
- 9.13. Explique cómo el servicio de búsqueda de Jini utiliza concesiones para asegurar que la lista de servicios registrados en un servidor de búsquedas permanece actualizada a pesar de que los servicios puedan fallar o volverse inaccesibles.
- 9.14. Describa la utilización de multidifusión IP y grupos de nombres en el servicio de *descubrimiento* de Jini, el cual permite que clientes y servidores localicen servidores de búsquedas.
- 9.15. GNS no garantiza que todas las copias de las entradas en la base de datos de nombres estén actualizadas. ¿Cómo pueden los clientes GNS detectar que se les ha respondido con una entrada caducada? ¿Bajo qué circunstancias puede esto ser perjudicial?
- 9.16. Discuta las ventajas e inconvenientes potenciales de utilizar un servicio de directorio X.500 en lugar de DNS y los programas de manejo de correo de Internet. Esboce el diseño de un sistema de manejo de correo en un entorno de red en el que todos los usuarios y hosts de correo estén registrados en una base de datos X.500.
- 9.17. ¿Qué cuestiones de seguridad tienden a ser relevantes en un servicio de directorio como X.500 operando dentro de una organización de tipo universitario?

TIEMPO Y ESTADOS GLOBALES

- 10.1. Introducción
- 10.2. Reloj, eventos y estados de proceso
- 10.3. Sincronización de relojes físicos
- 10.4. Tiempo lógico y relojes lógicos
- 10.5. Estados globales
- 10.6. Depuración distribuida
- 10.7. Resumen

En este capítulo, presentamos algunos temas relacionados con la cuestión del tiempo en los sistemas distribuidos. El tiempo es una tema práctico importante. Por ejemplo, necesitamos computadores en todo el mundo para marcar en el tiempo las transacciones de comercio electrónico consistentemente. El tiempo es también una construcción teórica importante para comprender cómo se desarrollan las transacciones distribuidas. Pero el tiempo es problemático en los sistemas distribuidos. Cada computador puede tener su propio reloj físico, pero los relojes se desvían normalmente, y no podemos sincronizarlos perfectamente. Examinaremos algoritmos para sincronizar relojes físicos aproximadamente, y después pasaremos a explicar los relojes lógicos, incluyendo relojes vectoriales que son una herramienta para ordenar los eventos sin conocer de forma precisa cuándo ocurren.

La ausencia de tiempo físico global hace difícil descubrir el estado de nuestros programas distribuidos cuando se ejecutan. A menudo necesitamos conocer cuál es el estado de proceso A cuando el proceso B está en un cierto estado, pero no podemos confiar en los relojes físicos para conocer lo que es verdad al mismo tiempo. La segunda mitad del capítulo examina algoritmos para determinar estados globales de computaciones distribuidas a pesar de la falta de tiempo global.

10.1. INTRODUCCIÓN

Este capítulo presenta conceptos y algoritmos fundamentales relacionados con la monitorización de cómo se desarrolla la ejecución en los sistemas distribuidos, y para temporizar los eventos que ocurren en sus ejecuciones.

El tiempo es una característica importante e interesante en los sistemas distribuidos, por varias razones. Primero, porque el tiempo es una cantidad que a menudo queremos medir de forma precisa. Para saber en qué hora del día ocurrió un evento particular en un computador concreto es necesario sincronizar su reloj, con una fuente de tiempo externa, fidedigna. Por ejemplo, una transacción de *comercio electrónico* implica eventos en el computador del comerciante y en un computador del banco. Es importante, para propósitos de auditoría, que esos eventos sean marcados en el tiempo de forma precisa.

Segundo, se han desarrollado algoritmos que dependen de la sincronización de reloj para varios problemas en distribución [Liskov 1993]. Éstos incluyen el mantenimiento de la consistencia de los datos distribuidos (el uso de marcas de tiempo para serializar transacciones se discutirá en la Sección 12.6), la comprobación de la autenticidad de una solicitud enviada a un servidor (una versión del protocolo de autenticación de Kerberos, discutido en el Capítulo 7, depende de relojes sincronizados no fuertemente); y eliminando el procesamiento de actualizaciones duplicadas (ver, por ejemplo, Ladin y otros [1992]).

Einstein demostró, en su Teoría Especial de la Relatividad, las intrigantes consecuencias que se siguen de la observación que la velocidad de la luz es constante para todos los observadores, a pesar de su velocidad relativa. Él probó, a partir de esta suposición entre otras cosas, que dos sucesos que se considera que son simultáneos en un marco de referencia no son necesariamente simultáneos de acuerdo con los observadores en otros marcos de referencia que se mueven con relación a ellos. Por ejemplo, un observador en la Tierra y un observador alejándose de la Tierra en una nave espacial no coincidirán en el intervalo de tiempo entre dos sucesos, que será mayor a medida que aumente su velocidad relativa.

Sin embargo, el orden relativo de dos sucesos puede ser incluso invertido por dos observadores diferentes. Pero esto no puede suceder si un suceso pudiera haber sido la causa de que ocurra el otro. En este caso, el efecto físico sigue a la causa física para todos los observadores, aunque el tiempo transcurrido entre causa y efecto puede variar. Se probó, entonces la relatividad con respecto al observador de la temporización de los sucesos físicos, así como se desacreditó la noción de tiempo físico absoluto de Newton. No existe un reloj físico especial en el universo al que podamos invocar cuando queramos medir intervalos de tiempo.

La noción de tiempo físico también es problemática en un sistema distribuido. Esto no es debido a los efectos de la relatividad especial, que son despreciables o no existentes para computadores normales (ja menos que uno considere los computadores viajando en las naves espaciales!). El problema se basa en una limitación similar de nuestra capacidad para marcar sucesos en diferentes nodos de una manera suficientemente precisa para conocer el orden en el que ocurrieron cualquier par de sucesos, o si ellos ocurrieron simultáneamente. No hay un tiempo absoluto, global al que podamos invocar. Y aún más, a veces necesitamos observar sistemas distribuidos y establecer si ciertos estados de asuntos ocurrieron al mismo tiempo. Por ejemplo, en los sistemas orientados a objetos necesitamos ser capaces de establecer las referencias a un objeto particular ya apenas existe, ya si el objeto ha llegado a ser desecharable (en cuyo caso podemos liberar su memoria). Establecer esto requiere observaciones de los estados de los procesos (para encontrar si ellos contienen referencias) y de los canales de comunicación entre los procesos (en el caso de los mensajes que contienen referencias están en tránsito).

En la primera mitad de este capítulo, examinamos métodos en los que los relojes de los computadores pueden ser sincronizados aproximadamente, utilizando paso de mensajes. A continuación

presentaremos los relojes lógicos, incluyendo los relojes vectoriales, que son utilizados para definir un orden de sucesos sin medir el tiempo físico en el que ellos han ocurrido.

En la segunda mitad, describimos algoritmos cuyo propósito es capturar los estados globales de los sistemas distribuidos cuando se ejecutan.

10.2. RELOJES, EVENTOS Y ESTADOS DE PROCESO

En el Capítulo 2 se presentó un modelo introductorio de interacción entre procesos en un sistema distribuido. Nosotros refinaremos ese modelo con el fin de ayudarnos a comprender cómo caracterizar la evolución del sistema a medida que se ejecuta, y cómo marcar los eventos de la ejecución del sistema que interesan a los usuarios. Comenzamos considerando cómo ordenar y colocar marcas de tiempo a los eventos que ocurren en un único proceso.

Consideramos que un sistema distribuido consta de una colección φ de N procesos p_i , $i = 1, 2, \dots, N$. Cada proceso se ejecuta en un único procesador, y los procesadores no comparten memoria (el Capítulo 17 considera el caso de procesos que comparten memoria). Cada proceso p_i en φ tiene un estado s_i que, en general, se transforma a medida que se ejecuta. El estado del proceso incluye los valores de todas sus variables. El estado puede incluir también los valores de cualquiera de los objetos en el entorno de su sistema operativo local que lo afecte, como los archivos. Suponemos que los procesos no se pueden comunicar entre ellos de ninguna forma, excepto mediante el envío de mensajes a través de la red. Por lo tanto, por ejemplo, si el proceso opera sobre los brazos de un robot conectados a sus respectivos nodos en el sistema, no les está permitido comunicarse jajitando los brazos de otro robot!

A medida que cada proceso p_i se ejecuta toma una serie de acciones, cada una de las cuales es un mensaje Envía o Recibe, o una operación que transforma el estado p_i , que cambia uno o más valores de s_i . En la práctica, podemos elegir si utilizar una descripción de alto nivel de las acciones, de acuerdo con la aplicación. Por ejemplo, si los procesos en φ están incluidos en una aplicación de comercio electrónico, entonces las acciones pueden ser del estilo de *el cliente envió un mensaje de pedido o el servidor del comerciante anotó la transacción en el registro*.

Decimos que un evento es la ocurrencia de una única acción que un proceso realiza a medida que se ejecuta, una acción de comunicación o una acción de transformación del estado. La secuencia de sucesos en un único proceso p_i puede ser colocada en orden único, total, que indicaremos con la relación \rightarrow_i entre eventos. Es decir, $e \rightarrow_i e'$ si y sólo si el evento e ocurre antes del e' en p_i . Esta ordenación está bien definida, sea o no el proceso multihilo, puesto que hemos supuesto que el proceso se ejecuta en un procesador único.

Ahora podemos definir la *historia* del proceso p_i como la serie de eventos que tienen lugar en él, ordenados de la forma que hemos descrito con la relación \rightarrow_i :

$$\text{historia}(p_i) = h_i = \langle e_i^0, e_i^1, e_i^2, \dots \rangle$$

◇ **Relojes.** Hemos visto cómo ordenar los eventos en un proceso pero no cómo proporcionarles marcas de tiempo, para asignarles una fecha y una hora del día. Los computadores pueden disponer de su propio reloj físico. Estos relojes son dispositivos electrónicos que cuentan las oscilaciones que ocurren en un cristal a una frecuencia definida, y que normalmente dividen esta cuenta y almacenan el resultado en un registro contador. Los dispositivos de reloj pueden estar programados para generar impulsos a intervalos regulares con el fin de que, por ejemplo, pueda ser implementada la división de tiempo, sin embargo nosotros no trataremos con este aspecto del funcionamiento de los relojes.

El sistema operativo lee el valor del reloj hardware $H_i(t)$ del nodo, lo escala y añade una compensación para producir un reloj software $C_i(t) = \alpha H_i(t) + \beta$ que mide aproximadamente el tiempo

El *Tiempo Universal Coordinado* —abreviado como UTC (del equivalente francés)— es un estándar internacional de cronometraje. Está basado en el tiempo atómico, aunque ocasionalmente se inserta un salto de un segundo —o, más raramente, borrado— para mantenerse en sintonía con el tiempo astronómico. Las señales UTC se sincronizan y difunden regularmente desde las estaciones de radio terrestres y los satélites, que cubren muchas partes del mundo. Por ejemplo, en USA la estación de radio WWV difunde señales de tiempo en frecuencias de onda corta. Las fuentes de los satélites incluyen el *Sistema de Posicionamiento Global* (*Global Positioning System*, GPS).

Hay disponibles receptores comerciales. Comparados con UTC *perfecto*, las señales recibidas desde las estaciones terrestres tienen una precisión del orden de 0,1-10 milisegundos, dependiendo de la estación utilizada. Las señales recibidas desde GPS tienen una precisión de alrededor de 1 microsegundo. Los computadores con receptores adjuntos pueden sincronizar sus relojes con estas señales de tiempo. Los computadores pueden también recibir el tiempo con una precisión de unos pocos milisegundos sobre una línea telefónica con organizaciones tales como el Instituto Nacional para los Estándares y Tecnología (*National Institute for Standards and Technology*, NIST) en USA.

10.3. SINCRONIZACIÓN DE RELOJES FÍSICOS

Para conocer en qué hora del día ocurren los sucesos en los procesos de nuestro sistema distribuido ϕ —por ejemplo, para propósitos de contabilidad— es necesario sincronizar los relojes de los procesos C_i con una fuente de tiempo externa autorizada. Esto es la *sincronización externa*. Y si los relojes C_i están sincronizados con otro con un grado de precisión conocido, entonces podemos medir el intervalo entre dos eventos que ocurren en diferentes computadores llamando a sus relojes locales, incluso aunque ellos no estén necesariamente sincronizados con una fuente externa de tiempo. Esto es *sincronización interna*. Definimos estos dos modos de sincronización más detalladamente como sigue, sobre un intervalo de tiempo real I :

Sincronización externa: para una sincronización dada $D > 0$, y para una fuente S de tiempo UTC, $|S_i(t) - C_i(t)| < D$, para $i = 1, 2, \dots, N$ y para todos los tiempos reales t en I . Otra forma de decir esto es que los relojes C_i son *precisos* con el límite D .

Sincronización interna: para una sincronización dada $D > 0$, $|C_i(t) - C_j(t)| < D$, para $i = 1, 2, \dots, N$ y para todos los tiempos reales t en I . Otra forma de decir esto es que los relojes C_i *concuerdan* con el límite D .

Los relojes que están sincronizados internamente no están necesariamente sincronizados externamente, puesto que pueden desplazarse colectivamente desde una fuente de tiempo externa incluso aunque estén de acuerdo entre sí. Sin embargo, se deduce de las definiciones que si el sistema ϕ está sincronizado externamente con un límite D entonces el mismo sistema está sincronizado internamente con un límite de $2D$.

Se han sugerido varias nociones de *corrección* para relojes. Es común definir que un reloj hardware H es correcto si su ritmo de deriva cae dentro de un límite conocido $\rho > 0$ (un valor derivado de uno proporcionado por el fabricante, como 10^{-6} segundos/segundo). Esto significa que el error midiendo el intervalo entre tiempos reales t y t' ($t' > t$) está limitado por:

$$(1 - \rho)(t' - t) \leq H(t') - H(t) \leq (1 + \rho)(t' - t)$$

Esta condición prohíbe saltos en el valor de los relojes hardware (durante su operación normal). A veces nosotros requerimos que nuestros relojes software obedezcan la condición. Pero una condición más débil de *monotonicidad* puede bastar. Monotonicidad es la condición que un reloj C sólo avanza siempre que:

$$t' > t \Rightarrow C(t') > C(t)$$

Por ejemplo, la utilidad *make* de UNIX es una herramienta que se utiliza para compilar sólo aquellos archivos fuente que han sido modificados desde la última vez que fueron compilados. Las fechas de modificación de cada par correspondiente de archivos fuente y objeto son comparadas para determinar esta condición. Si un computador cuyo reloj estaba corriendo rápido retrasa su reloj después de compilar un archivo fuente pero antes de que el archivo sea cambiado, puede parecer que el archivo fuente ha sido modificado antes de la compilación. Erróneamente, *make* no recomendará la compilación del archivo fuente.

Podemos conseguir monotonicidad a pesar del hecho de que un reloj se encuentre corriendo rápido. Sólo necesitamos cambiar el ritmo al que se hacen las actualizaciones al tiempo dado a las aplicaciones. Esto puede ser conseguido por software sin cambiar el ritmo al que los ticks del reloj hardware subyacente; recuerde que $C_i(t) = \alpha H_i(t) + \beta$, donde somos libres de elegir los valores de α y β .

Una condición híbrida de corrección que es aplicada a veces es requerir que un reloj obedezca la condición de monotonicidad, y que su ritmo de deriva esté limitado entre los puntos de sincronización, pero permitir que el valor del reloj salte por delante de los puntos de sincronización.

Un reloj que no se atiene a ninguna de las condiciones de corrección aplicadas se dice que es *defectuoso*. Un *fallo de ruptura* de reloj se dice que ocurre cuando el reloj deja de pulsar por completo; cualquier otro fallo de reloj es un *fallo arbitrario*. Un ejemplo de un fallo arbitrario es el de un reloj con el *error del año 2000*, que rompe la condición de monotonicidad registrando la fecha de después del 31 de diciembre de 1999 como 1 de enero de 1900 en lugar de 2000; otro ejemplo es un reloj cuyas baterías están muy bajas y cuyo ritmo de deriva llega a ser de repente muy grande.

Tenga en cuenta que los relojes no tienen por qué ser precisos para ser correctos, de acuerdo con las definiciones. Puesto que el objetivo puede ser la sincronización interna más que la externa, los criterios para corrección están relacionados únicamente con el funcionamiento adecuado del *mecanismo* del reloj, no con su ajuste absoluto.

Describimos ahora algoritmos para sincronización externa e interna.

10.3.1. SINCRONIZACIÓN EN UN SISTEMA SÍNCRONO

Comenzamos considerando el caso más simple posible: El de sincronización interna entre dos procesos en un sistema distribuido síncrono. En un sistema síncrono se conocen los límites para el ritmo de deriva de los relojes, el máximo retardo de transmisión de mensajes y el tiempo para ejecutar cada paso de un proceso (véase la Sección 2.3.1).

Un proceso envía el tiempo t de su reloj local a otro en un mensaje m . En principio, el proceso receptor podría tener su reloj en el tiempo $t + T_{trans}$, donde T_{trans} es el tiempo preciso para transmitir m entre ellos. Los dos relojes podrían coincidir (puesto que la meta es la sincronización interna, no importa si el reloj del proceso emisor es preciso).

Desafortunadamente, T_{trans} está sujeto a variaciones y es desconocido. En general, otros procesos están compitiendo por recursos con los procesos a sincronizar en sus respectivos nodos y otros mensajes compiten con m por la red. A pesar de todo, hay siempre un tiempo mínimo de transmisión min que podría obtenerse si no se ejecutara ningún otro proceso y no existiera más tráfico en la red; min puede ser medido o estimado de forma conservadora.

En un sistema síncrono, por definición hay también un límite superior max del tiempo tomado para transmitir cualquier mensaje. Sea la incertidumbre en el tiempo de transmisión del mensaje u , donde $u = (max - min)$. Si el receptor coloca su reloj a $t + min$, entonces el sesgo del reloj puede ser como mucho u , puesto que el mensaje puede de hecho haber necesitado un tiempo max para llegar. Similarmente, si coloca su reloj a $t + max$, el sesgo podría ser otra vez como mucho u . Sin embargo, si coloca su reloj al punto mitad, $t + (max + min)/2$, entonces el sesgo es como

mucho $u/2$. En general, para un sistema síncrono, el límite óptimo que puede ser conseguido en el sesgo de reloj cuando sincronizamos N relojes es $u(1 - 1/N)$ [Lindelius y Linch 1984].

La mayoría de los sistemas distribuidos encontrados en la práctica son asíncronos: Los factores que conducen a retardos de los mensajes no están limitados en su efecto, y no hay límite superior max en los retardos de transmisión de mensajes. Esto es particularmente así para Internet. Para un sistema asíncrono, nosotros sólo podremos decir que $T_{trans} = min + x$, donde $x \geq 0$. El valor de x no es conocido en un caso particular, aunque para una instalación particular podría medirse una distribución de valores.

10.3.2. MÉTODO DE CRISTIAN PARA SINCRONIZAR RELOJES

Cristian [1989] sugirió la utilización de un servidor de tiempo, conectado a un dispositivo que recibe señales de una fuente de UTC, para sincronizar computadores externamente. Bajo solicitud, el proceso servidor S proporciona el tiempo de acuerdo con su reloj tal como se muestra en la Figura 10.2.

Cristian observó que aunque no hay límite superior en los retardos de transmisión de mensajes en un sistema asíncrono, los tiempos de ida y vuelta de los mensajes intercambiados entre cada par de procesos son a menudo razonablemente cortos, una pequeña fracción de un segundo. El describe el algoritmo como *probabilístico*: el método consigue sincronización sólo si los tiempos de ida y vuelta entre el cliente y el servidor son suficientemente cortos comparados con la precisión requerida.

Un proceso p solicita el tiempo en un mensaje m_r , y recibe el valor del tiempo t en un mensaje m_t (t se inserta en m_t en el último instante posible antes de la transmisión desde un computador de S). El proceso p registra el tiempo total de ida y vuelta T_{round} tomado para enviar la solicitud m_r y recibir la respuesta m_t . Se puede medir este tiempo con precisión razonable si su ritmo de deriva de reloj es pequeño. Por ejemplo, el tiempo de ida y vuelta debiera ser del orden de 1 a 10 milisegundos en una LAN, sobre dicho tiempo un reloj con un ritmo de deriva de 10^{-6} milisegundos/segundo varía como mucho 10^{-5} milisegundos.

Una estimación sencilla del tiempo al que p debe fijar su reloj es $t + T_{round}/2$, que supone que el tiempo transcurrido se desdoble igualmente antes y después de que S coloque t en m_t . Esto es normalmente una suposición razonable de precisión, a menos que los dos mensajes sean transmitidos sobre redes diferentes. Si el valor del tiempo mínimo de transmisión min es conocido o puede ser estimado conservativamente, entonces podemos determinar la precisión de este resultado como sigue.

El instante más temprano en el que S podría haber colocado el tiempo en m_t fue min después de que p enviara m_r . El punto más tarde al que podría haber hecho esto sería min antes de que m_t llegue a p . El tiempo del reloj de S cuando el mensaje de respuesta llega estará en el rango $[t + min, t + T_{round} - min]$. La anchura de este rango es $T_{round} - 2min$, por lo que la precisión es $\pm(T_{round}/2 - min)$.

Se puede tratar con la variabilidad en alguna medida haciendo varias solicitudes a S (espaciando las solicitudes de modo que se pueda eliminar la congestión transitoria) y tomando el valor

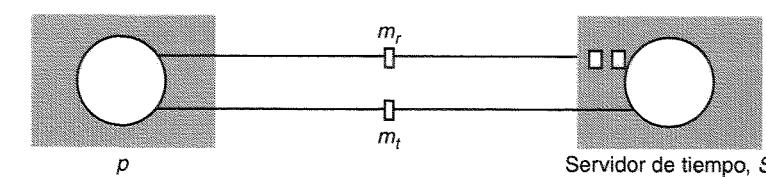


Figura 10.2. Sincronización de relojes utilizando un servidor de tiempo.

mínimo de T para conseguir una estimación más precisa. Cuanto más grande es la precisión

mínimo de T para conseguir una estimación más precisa. Cuanto más grande es la precisión

Si el maestro fallara, entonces puede ser elegido otro para asumir y funcionar exactamente como su predecesor. La Sección 11.3 discute algunos algoritmos de elección de propósito general. Hay que tener en cuenta que éstos no garantizan la elección de un nuevo maestro en un tiempo limitado y por tanto la diferencia entre dos relojes sería ilimitada si fueran utilizados.

10.3.4. EL PROTOCOLO DEL TIEMPO DE RED

El método de Cristian y el algoritmo de Berkeley están pensados principalmente para utilizar en intranets. El Protocolo de Tiempo de Red (*Network Time Protocol*, NTP) [Mills 1995] define una arquitectura para un servicio de tiempo y un protocolo para distribuir la información del tiempo sobre Internet.

Los objetivos y las metas principales de diseño de NTP son los siguientes.

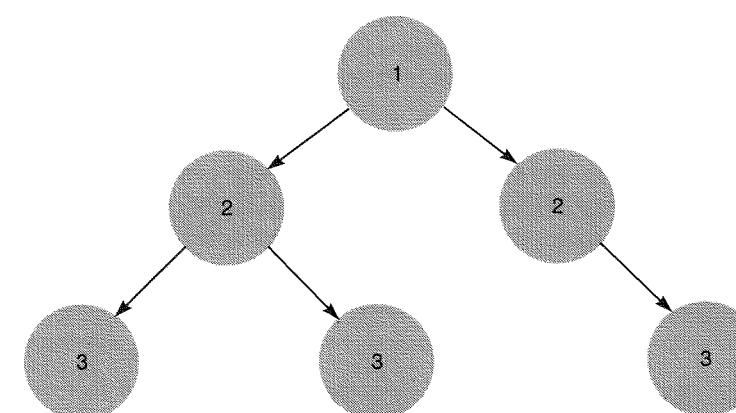
Proporcionar un servicio que permita a los clientes a lo largo de Internet estar sincronizados de forma precisa a UTC: a pesar de los retardos largos y variables de los mensajes encontrados en la comunicación Internet, NTP emplea técnicas estadísticas para el filtrado de los datos de tiempo y discrimina entre la calidad de los datos de tiempo de los diferentes servidores.

Proporcionar un servicio fiable que pueda sobrevivir a pérdidas largas de conectividad: hay servidores redundantes y recorridos redundantes entre los servidores. Los servidores pueden reconfigurarse para continuar proporcionando el servicio si uno de ellos llega a ser inalcanzable.

Permitir a los clientes resincronizar con suficiente frecuencia para compensar las tasas de deriva encontradas en la mayoría de los computadores: el servicio está diseñado para escalar a gran número de clientes y servidores.

Proporcionar protección contra la interferencia con el servicio de tiempo, ya sea maliciosa o accidental: el servicio de tiempo utiliza técnicas de autenticación para comprobar que los datos de tiempo se originan de las fuentes verdaderas reclamadas. También valida las direcciones de devolución de los mensajes enviados hacia él.

El servicio NTP está proporcionado por una red de servidores localizados a través de Internet. Los servidores primarios están conectados directamente a una fuente de tiempo como un radioreloj recibiendo UTC; los servidores secundarios están sincronizados, en el fondo, con servidores primarios. Los servidores están conectados en una jerarquía lógica llamada una *subred de sincronización* (véase la Figura 10.3), cuyos niveles se llaman *estratos*. Los servidores primarios ocupan el estrato



Nota: Las flechas indican control de la sincronización, los números indican estratos.

Figura 10.3. Un ejemplo de una subred de sincronización en una implementación NTP.

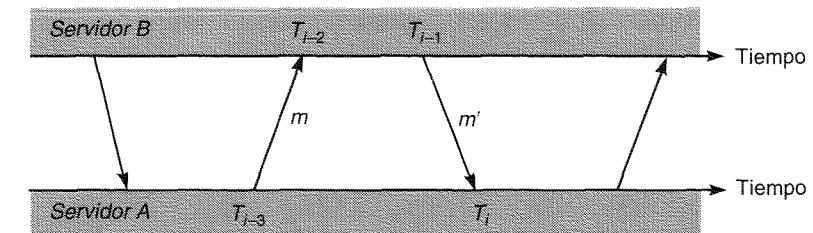
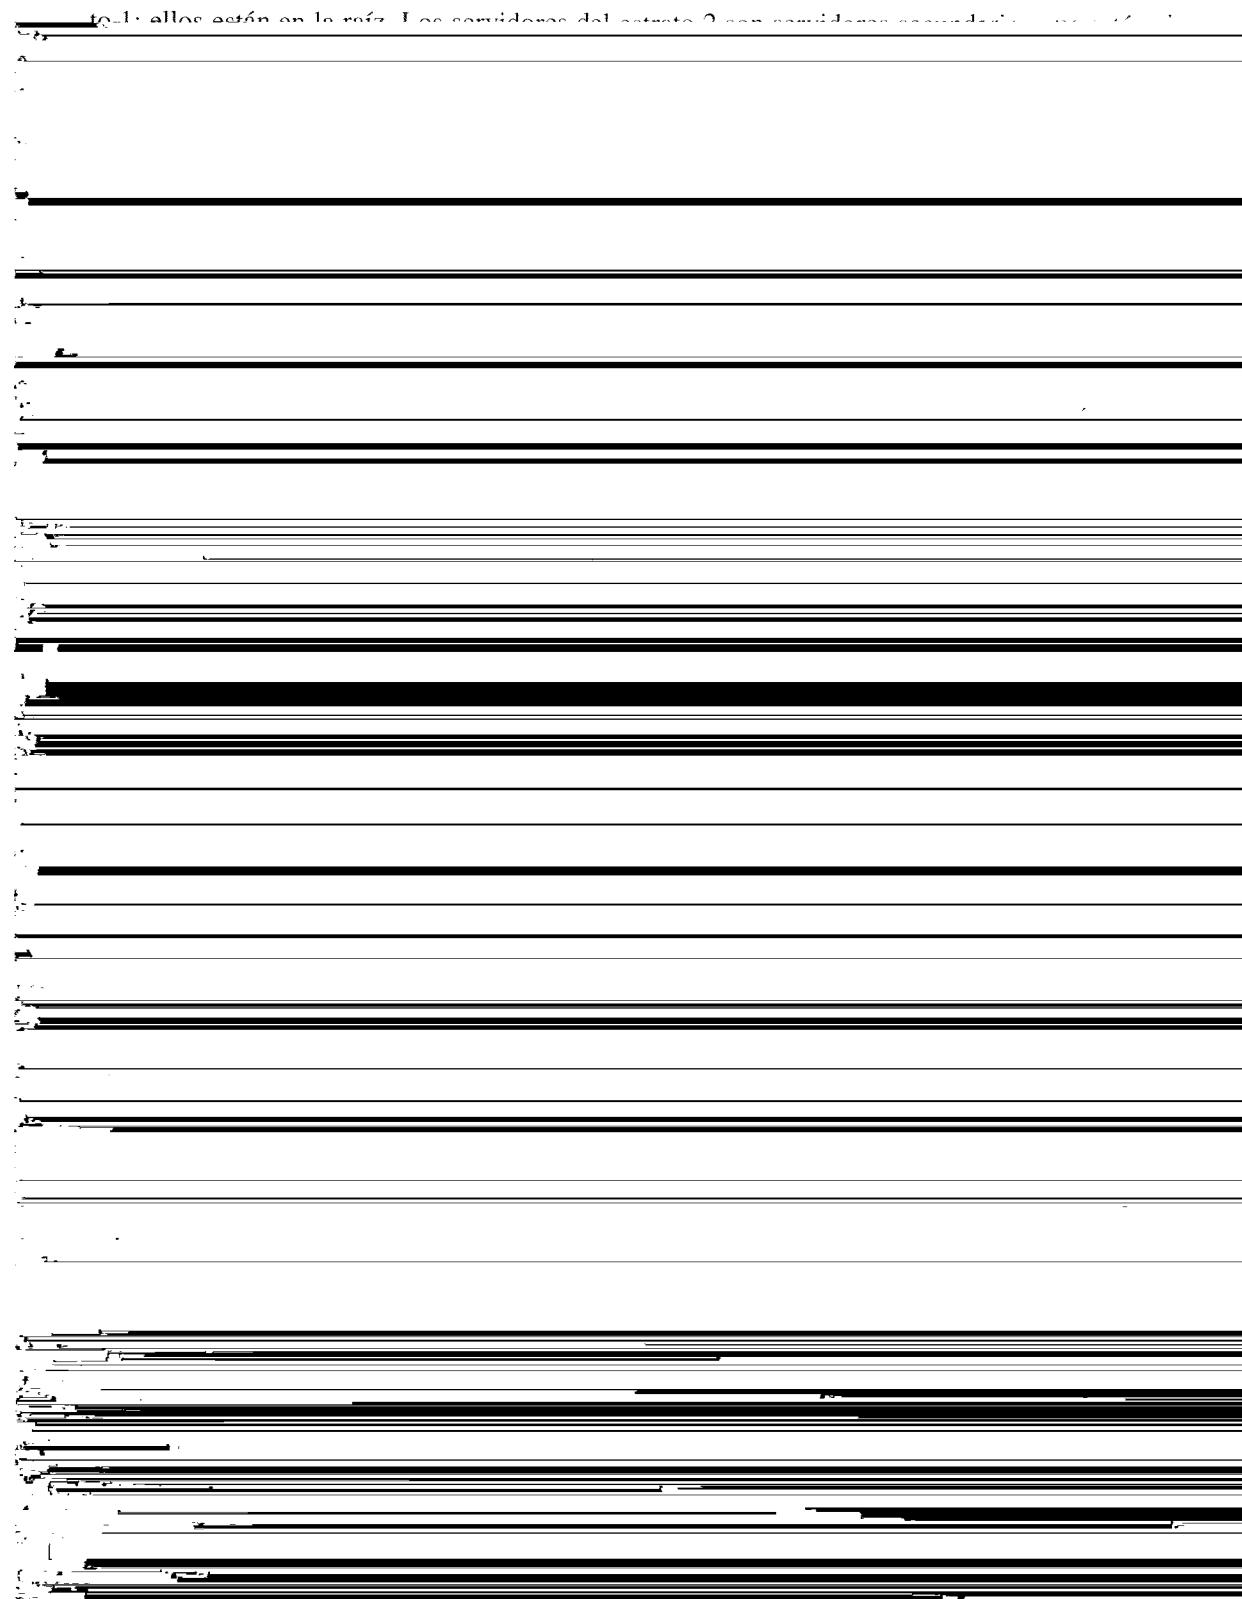


Figura 10.4. Mensajes intercambiados entre un par de iguales NTP.

También se verifica que:

$$o = o_i + (t' - t)/2, \text{ donde } o_i = (T_{i-2} - T_{i-3} + T_{i-1} - T_i)/2$$

Usando el hecho de que $t, t' \geq 0$ se puede ver que $o_i - d_i/2 \leq o \leq o_i + d_i/2$. Por tanto o_i es una estimación de la deriva, y d_i es una medida de la precisión de esta estimación.

Los servidores NTP aplican un algoritmo de filtrado de datos a pares sucesivos de $\langle o_i, d_i \rangle$, que estima la deriva o y calculan la calidad de esta estimación como una cantidad estadística llamada el *filtro de dispersión*. Un filtro de dispersión relativamente alto implica datos relativamente poco fiables. Los ocho pares $\langle o_i, d_i \rangle$ más recientes son retenidos. Como con el algoritmo de Cristian, se elige como estimación de o el valor de o_j que corresponde con el mínimo valor d_j .

Sin embargo, el valor del desplazamiento derivado de la comunicación con una única fuente no se utiliza necesariamente en sí mismo para controlar el reloj local. En general un servidor NTP conecta en los intercambios de mensajes con varios de sus iguales, o colegas. Además del filtrado de datos aplicados a los intercambios con cada igual, NTP aplica un algoritmo de selección de colega. Éste examina los valores obtenidos de los intercambios con cada uno de los distintos colegas, buscando los valores relativamente menos fiables. La salida de este algoritmo puede provocar que un servidor cambie el colega que utilizaba inicialmente para la sincronización.

Los colegas con número de estrato más bajo son menos favorecidos que aquéllos en el estrato más alto porque están más *próximos* a las fuentes de tiempo primarias. También, aquéllos con la *dispersión de sincronización* más baja son favorecidos relativamente. Ésta es la suma de las dispersiones del filtro medidas entre el servidor y la raíz de la subred de sincronización. (Los colegas intercambian la dispersión de sincronización en mensajes, permitiendo que se calcule este total.)

NTP emplea un modelo de bucle de bloqueo de fase (*phase lock*) [Mills 1995], que modifica la frecuencia de actualización del reloj de acuerdo con las observaciones de su tasa de deriva. Para considerar un ejemplo sencillo, si se descubre que un reloj siempre se adelanta a una tasa de, digamos, cuatro segundos por hora, entonces puede reducirse su frecuencia ligeramente (en software o hardware) para compensarlo. La deriva del reloj es reducida por tanto en los intervalos entre sincronización.

Mills acota precisiones de sincronización del orden de decenas de milisegundos sobre recorridos en Internet, y un milisegundo en LAN.

10.4. TIEMPO LÓGICO Y RELOJES LÓGICOS

Desde el punto de vista de un único proceso, los sucesos están ordenados de forma única por los tiempos mostrados en el reloj lógico. Sin embargo, como apuntó Lamport [1978], puesto que no podemos sincronizar perfectamente los relojes a lo largo de un sistema distribuido, no podemos usar, en general, el tiempo físico para obtener el orden de cualquier par arbitrario de sucesos que ocurran en él.

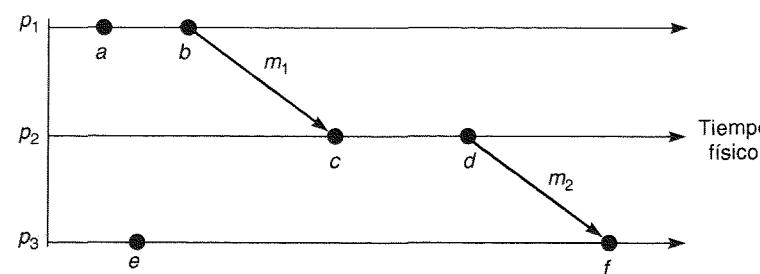


Figura 10.5. Sucesos ocurridos en tres procesos.

En general, podemos utilizar un esquema que es similar a la causalidad física, pero que se aplica en los sistemas distribuidos, para ordenar algunos de los sucesos que ocurren en diferentes procesos. Esta ordenación está basada en dos puntos sencillos e intuitivamente obvios:

Si dos sucesos han ocurrido en el mismo proceso p_i ($i = 1, 2, \dots, N$), entonces ocurrieron en el orden en el que les observa p_i , éste es el orden \rightarrow_i que hemos definido anteriormente.

Cuando se envía un mensaje entre procesos, el suceso de enviar el mensaje ocurrió antes del de recepción del mismo.

Lamport llamó a la ordenación parcial obtenida al generalizar estas dos relaciones la realización *suceder antes*. Esto también se conoce a veces como la relación de *orden causal* o *ordenación causal potencial*.

Definimos la relación *suceder antes*, indicada por \rightarrow , como sigue:

SA1: Si \exists un proceso p_i : $e \rightarrow_i e'$, entonces $e \rightarrow e'$.

SA2: Para cualquier mensaje m , $\text{envía}(m) \rightarrow \text{recibe}(m)$; donde $\text{envía}(m)$ es el suceso de enviar el mensaje, y $\text{recibe}(m)$ el de recibirlo.

SA3: Si e, e' y e'' son sucesos tal que $e \rightarrow e'$ y $e' \rightarrow e''$, entonces $e \rightarrow e''$.

Por tanto si e y e' son sucesos, y si $e \rightarrow e'$, entonces podemos encontrar una serie de sucesos e_1, e_2, \dots, e_n ocurriendo en uno o más sucesos tal que $e = e_1$, y $e' = e_n$, y para $i = 1, 2, \dots, N - 1$ o bien se aplica SA1 o SA2 entre e_i y e_{i+1} . Esto es, o bien ocurren en sucesión en el mismo proceso, o hay mensaje m tal que $e_1 = \text{envía}(m)$ y $e_{i+1} = \text{recibe}(m)$. La secuencia de sucesos e_1, e_2, \dots, e_n no necesita ser única.

En la Figura 10.5 se ilustra la relación \rightarrow para el caso de tres procesos p_1, p_2 y p_3 . Se puede ver que $a \rightarrow b$, puesto que los sucesos ocurren en este orden en el proceso p_1 ($a \rightarrow_1 b$) y de modo similar $c \rightarrow d$. Además $b \rightarrow c$, puesto que estos sucesos son el envío y recepción del mensaje m_1 , y de modo semejante $d \rightarrow f$. Combinando estas relaciones, podemos decir también, por ejemplo, que $a \rightarrow f$.

De la Figura 10.5 se puede ver también que no todos los sucesos están relacionados con la relación \rightarrow . Por ejemplo, $a \not\rightarrow e$ y $e \not\rightarrow a$, puesto que ocurren en diferentes procesos, y no hay una cadena de mensajes que intervengan entre ellos. Decimos que sucesos como a y e que no están ordenados por \rightarrow son concurrentes y se escribe $a \parallel e$.

La relación \rightarrow captura un flujo de información entre dos eventos. Nótese, sin embargo, que en principio la información pueden fluir de formas distintas de la de paso de mensajes. Por ejemplo, si Pérez presenta un mandato a su proceso para que envíe un mensaje, acto seguido telefona a Gómez, quien ordena a su proceso que envíe otro mensaje, luego el envío del primer mensaje claramente *sucedió antes* que el segundo. Desafortunadamente, como no se han enviado mensajes de red entre los procesos que los emitieron, no podemos modelar este tipo de relaciones en nuestro sistema.

Otro punto a señalar es que aun produciéndose la relación *sucedió antes* entre dos sucesos, el primero podría o no haber causado realmente el segundo. Por ejemplo, si un servidor recibe un mensaje de petición y consecuentemente envía una respuesta, entonces la transmisión de respuesta está causada por la transmisión de petición. Sin embargo, la relación \rightarrow captura sólo la causalidad potencial, y dos sucesos pueden estar relacionados por \rightarrow incluso aunque no haya una conexión real entre ellos. Un proceso podría, por ejemplo, recibir un mensaje y consecuentemente enviar otro mensaje, pero uno que él emite cada cinco minutos en cualquier caso y no tiene ninguna relación específica con el primer mensaje. No se ha supuesto ninguna causalidad real, pero la relación \rightarrow debe ordenar estos sucesos.

◇ **Reloj lógico.** Lamport inventó un mecanismo simple por el que la relación *sucedió antes* puede capturarse numéricamente, denominado *reloj lógico*. Un reloj lógico de Lamport es un contador software que se incrementa monótonamente, cuyos valores no necesitan tener ninguna relación particular con ningún reloj físico. Cada proceso p_i mantiene su propio reloj lógico, L_i , que él utiliza para aplicar las llamadas *marcas de tiempo de Lamport* a los sucesos. Representamos la marca de tiempo e del suceso en p_i por $L_i(e)$, y representamos por $L(e)$ la marca de tiempo del suceso e en el proceso en el que ocurrió.

Para capturar la relación *sucedió antes* \rightarrow , los procesos actualizan sus relojes lógicos y transmiten los valores de sus relojes lógicos en mensajes como sigue:

RL1: L_i se incrementa antes de emitir cada suceso en el proceso p_i :

$$L_i = L_i + 1$$

RL2: (a) Cuando un proceso p_i envía un mensaje m , acarrea en m el valor de $t = L_i$.
(b) Al recibir (m, t) , cada proceso p_j calcula $L_j := \max(L_j, t)$ y entonces aplica RL1 antes de realizar la marca de tiempo del suceso $\text{recibe}(m)$.

Aunque nosotros incrementamos los relojes en 1, podríamos haber elegido cualquier valor positivo. Se puede ver fácilmente, por inducción en la longitud de cualquier secuencia de sucesos relacionando dos sucesos e y e' , que $e \rightarrow e' \Rightarrow L(e) < L(e')$.

Hay que señalar que el inverso no es verdadero. Si $L(e) < L(e')$, no podemos inferir que $e \rightarrow e'$. En la Figura 10.6 ilustramos el uso de los relojes lógicos para el ejemplo dado en la Figura 10.5. Cada uno de los procesos p_1, p_2 y p_3 tienen su reloj lógico inicializado a 0. Los valores del reloj dados son aquéllos inmediatamente después del suceso para el que son adyacentes. Tenga en cuenta, también, $L(b) > L(e)$ pero $b \parallel e$.

◇ **Reloj lógico totalmente ordenado.** Algunos pares de sucesos distintos, generados por diferentes procesos, tienen marcas de tiempo de Lamport numéricamente idénticas. Sin embargo, podemos crear un orden total sobre los sucesos, esto es, uno para el que todos los pares de sucesos distintos están ordenados, teniendo en cuenta los identificadores de los procesos en los que

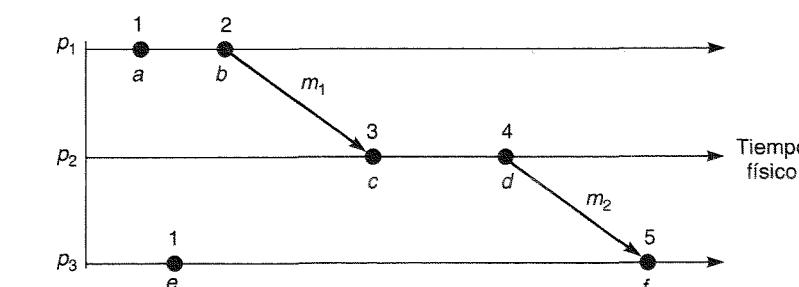


Figura 10.6. Marcas temporales de Lamport para los eventos mostrados en la Figura 10.5.

ocurren los sucesos. Si e es un suceso que ocurre en p_i con marca de tiempo local T_i , y e' es un suceso que ocurre en p_j con marca de tiempo local T_j , definimos las marcas de tiempo globales para esos sucesos como (T_i, i) y (T_j, j) respectivamente. Y definimos $(T_i, i) \leq (T_j, j)$ si y sólo si $T_i < T_j$, o $T_i = T_j$ y $i < j$. Esta ordenación no tiene significado físico general (porque los identificadores de los procesos son arbitrarios), pero a veces es útil. Lamport la utilizó, por ejemplo, para ordenar la entrada de procesos en una sección crítica.

◊ **Relojes vectoriales.** Mattern [1989] y Fidge [1991] desarrollaron relojes vectoriales para vencer la deficiencia de los relojes de Lamport: del hecho que $L(e) < L(e')$ no podemos deducir que $e \rightarrow e'$. Un reloj vectorial para un sistema de N procesos es un vector de N enteros. Cada proceso mantiene su propio reloj vectorial V_i , que utiliza para colocar marcas de tiempo en los sucesos locales. Como las marcas de tiempo de Lamport, cada proceso adhiere el vector de marcas de tiempo en los mensajes que envía al resto, y hay unas reglas sencillas para actualizar los relojes, como las siguientes:

- RV1: Inicialmente, $V_i[j] = 0$, para $i, j = 1, 2, \dots, N$.
- RV2: Justo antes que p_i coloque una marca de tiempo en un suceso, coloca $V_i[i] := V_i[i] + 1$.
- RV3: p_i incluye el valor $t = V_i$ en cada mensaje que envía.
- RV4: Cuando p_i recibe una marca de tiempo y en un mensaje, establece $V_i[j] := \max(V_i[j], t[j])$, para $j = 1, 2, \dots, N$. Esta operación de *mezcla* toma el vector máximo entre dos componentes a componente.

Para un vector V_i , $V_i[i]$ es el número de sucesos a los que p_i ha puesto una marca de tiempo, y $V_i[j] (j \neq i)$ es el número de sucesos que han ocurrido en p_j que han sido potencialmente afectados por p_i . (El proceso p_j puede haber puesto marcas de tiempo en más sucesos por este método, pero la información no ha fluido hacia p_i en mensajes todavía.)

Podemos comparar vectores de marcas de tiempo de la forma siguiente:

$$\begin{aligned} V = V' &\text{ si y sólo si } V[j] = V'[j] \text{ para } j = 1, 2, \dots, N \\ V \leq V' &\text{ si y sólo si } V[j] \leq V'[j] \text{ para } j = 1, 2, \dots, N \\ V < V' &\text{ si y sólo si } V \leq V' \wedge V \neq V' \end{aligned}$$

Sea $V(e)$ el vector de marcas de tiempo aplicadas por el proceso en el que ocurre e . Es sencillo mostrar, por inducción sobre la longitud de cualquier secuencia de sucesos que relacione los sucesos e y e' , que $e \rightarrow e' \Rightarrow V(e) < V(e')$. El Ejercicio 10.13 solicita que el lector muestre el recíproco: Si $V(e) < V(e')$, entonces $e \rightarrow e'$.

La Figura 10.7 muestra los vectores de marcas de tiempo de los eventos de la Figura 10.5. Se puede ver, por ejemplo, que $V(a) < V(f)$, que refleja el hecho que $a \rightarrow f$. De forma semejante, podemos decir si dos sucesos son concurrentes comparando sus marcas de tiempo. Por ejemplo, que $c \parallel e$ pueda ser deducido del hecho que ni $V(c) \leq V(e)$ ni $V(e) \leq V(c)$.

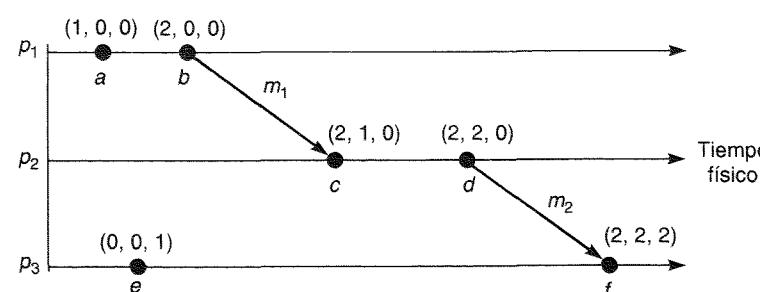


Figura 10.7. Vector de marcas temporales para los eventos mostrados en la Figura 10.5.

Los vectores de marcas de tiempo tienen la desventaja, comparados con las marcas de tiempo de Lamport, de precisar una cantidad de almacenamiento y de carga real de mensajes que es proporcional a N , el número de procesos. Charron-Bost [1991] mostró que, si somos capaces de decir si dos sucesos son o no concurrentes inspeccionando sus marcas de tiempo, entonces la dimensión N es inevitable. Sin embargo, existen técnicas para almacenar y transmitir cantidades más pequeñas de datos, a costa del procesamiento precisado para reconstruir los vectores completos. Raynal y Singhal [1996] dan cuenta de alguna de estas técnicas. También describen la noción de *relojes matriciales*, en la que los procesos mantienen estimaciones de los vectores de tiempo de otros procesos así como las suyas propias.

10.5. ESTADOS GLOBALES

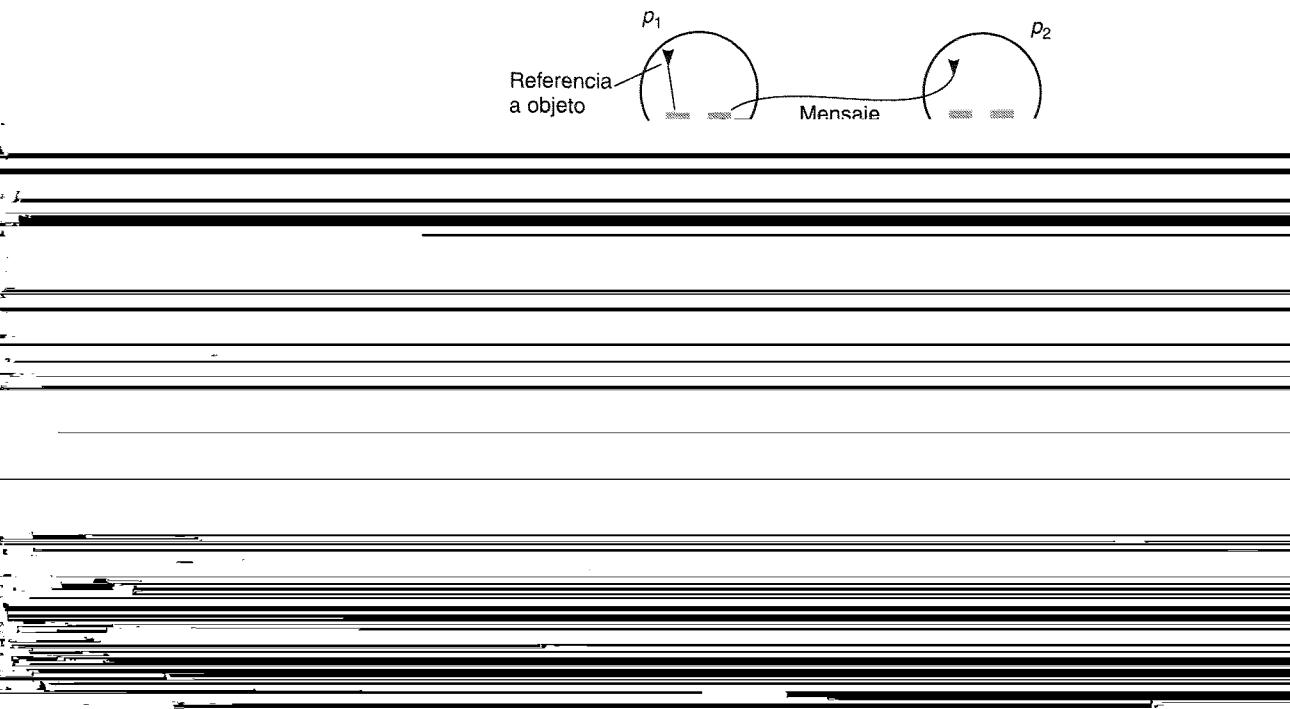
En esta sección y en la siguiente examinaremos el problema de descubrir si una propiedad particular de un sistema distribuido es cierta cuando éste se ejecuta. Comenzamos dando ejemplos de compactación de memoria distribuida, detección de bloqueos indefinidos, detección de terminación y depuración.

Compactación automática de memoria: un objeto se considera desecharable si no hay posteriormente ninguna referencia a él desde cualquier parte del sistema distribuido. La memoria ocupada por el objeto puede ser reclamada, una vez que se sabe que éste es desecharable. Para comprobar que un objeto es desecharable, debemos verificar que no hay referencias a él en cualquier parte del sistema. En la Figura 10.8a, el proceso p_1 tiene dos objetos, ambos con referencias, uno tiene una referencia al propio p_1 , y el otro tiene una referencia a p_2 . El proceso p_2 tiene un objeto desecharable, al que no existe ninguna referencia en el sistema. Hay también otro objeto al que ni p_1 ni p_2 tienen acceso, pero hay una referencia a él en un mensaje que transita entre ambos. Esto nos muestra que cuando consideramos las propiedades de un sistema, debemos incluir el estado de los canales de comunicación así como el de los procesos.

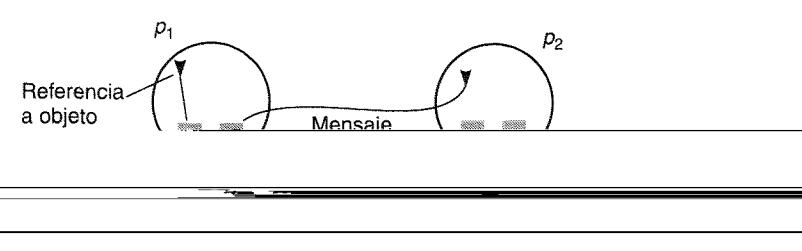
Detección distribuida de bloqueos indefinidos: un bloqueo indefinido distribuido ocurre cuando cada uno de los procesos de una colección espera por otro proceso para enviarle un mensaje, y donde hay un ciclo en el grafo de esta relación *espera por*. La Figura 10.8b muestra que cada uno de los procesos p_1 y p_2 espera un mensaje del otro, por lo que el sistema nunca progresará.

Detección de la terminación distribuida: el problema aquí es detectar que un algoritmo distribuido ha terminado. La detección de la terminación es un problema que parece muy fácil de resolver: al principio parece sólo necesario comprobar si cada proceso se ha detenido. Para ver que esto no es así, consideremos un algoritmo distribuido ejecutado por dos procesos p_1 y p_2 , cada uno de los cuales puede necesitar valores del otro. Instantáneamente, podemos encontrar que un proceso es activo o pasivo, un proceso pasivo no está ligado a ninguna actividad por sí mismo pero está preparado para responder con un valor solicitado por el otro. Supongamos que descubrimos que p_1 es pasivo y que p_2 también lo es (véase la Figura 10.8c). Para ver que no podemos determinar que el algoritmo ha terminado, consideremos el siguiente escenario: cuando hemos comprobado p_1 para ver si es pasivo, un mensaje estaba en su camino desde p_2 , que se convirtió en pasivo inmediatamente después de enviarlo. Cuando recibió el mensaje, p_1 se convertirá de nuevo en activo, después de encontrar que era pasivo. El algoritmo no habrá terminado.

Los fenómenos de terminación y bloqueo indefinido son de alguna forma semejantes, pero son problemas diferentes. En primer lugar, un bloqueo indefinido puede afectar sólo a un subconjunto de procesos en el sistema, mientras que todos los procesos tienen que haber terminado. En segundo lugar, la pasividad de un proceso no es lo mismo que la espera en un ciclo de bloqueo indefinido: un proceso bloqueado está intentando realizar otra acción, por lo que espera a otro proceso; un proceso pasivo no está ligado con ninguna actividad.



382 Sistemas distribuidos



c. Terminación

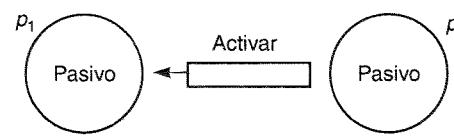


Figura 10.8. Detección de propiedades globales.

Retornemos a nuestro sistema general φ de N procesos $p_i (i = 1, 2, \dots, N)$, cuya ejecución deseamos estudiar. Hemos dicho anteriormente que ocurre una serie de eventos en cada proceso, y que podemos caracterizar la ejecución de un proceso por su historia:

$$\text{historia}(p_i) = h_i = \langle e_i^0, e_i^1, e_i^2, \dots \rangle$$

De forma semejante, podemos considerar cualquier prefijo finito de la historia del proceso:

$$h_i^k = \langle e_i^0, e_i^1, \dots, e_i^k \rangle$$

Cada evento es una acción interna del proceso (por ejemplo, la actualización de una de sus variables) o el envío o la recepción de un mensaje sobre los canales de comunicación que conectan los procesos.

En principio, podemos registrar qué ocurrió en la ejecución de φ . Cada proceso puede registrar los sucesos que se producen allí, y la sucesión de estados por la que pasa. Denotamos con s_i^k el estado del proceso p_i inmediatamente antes que ocurra el suceso k , por lo que e_i^0 es el estado inicial de p_i . Hemos tenido en cuenta en los ejemplos anteriores que el estado de los canales de comunicación es relevante a veces. Más que introducir un nuevo tipo de estado, hacemos que el proceso registre el envío o la recepción de todos los mensajes como una parte de su estado. Si encontramos que el proceso p_i ha registrado que envió un mensaje m al proceso $p_j (i \neq j)$, entonces examinando si p_j ha recibido el mensaje podemos inferir o no que m es parte del estado del canal entre p_i y p_j .

Podemos formar la historia global de φ como la unión de las historias individuales de los procesos:

$$H = h_0 \cup h_1 \cup \dots \cup h_{N-1}$$

Matemáticamente, podemos tomar cualquier conjunto de estados de los procesos individuales para formar un estado global (s_1, s_2, \dots, s_N) . Pero qué estados son significativos; esto es, ¿cuál de los estados de los procesos podrían haber ocurrido al mismo tiempo? Un estado global corresponde a los prefijos iniciales de las historias individuales de los procesos. Un *corte* de la ejecución del sistema es un subconjunto de su historia global que es la unión de los prefijos de las historias de los procesos:

$$C = h_1^{c_1} \cup h_2^{c_2} \cup \dots \cup h_N^{c_N}$$

El estado s_i en el estado global S correspondiente al corte C es el de p_i inmediatamente después del último suceso procesado por p_i en el corte, $e_i^{c_i} (i = 1, 2, \dots, N)$. El conjunto de sucesos $\{e_i^{c_i} : i = 1, 2, \dots, N\}$ se llama la *frontera* del corte.

Consideremos los sucesos que ocurren en los procesos p_1 y p_2 mostrados en la Figura 10.9. La figura representa dos cortes, uno con frontera $\langle e_1^0, e_2^0 \rangle$ y otro con frontera $\langle e_1^2, e_2^2 \rangle$. El corte de más a la izquierda es *inconsistente*. Esto es porque p_2 incluye la recepción del mensaje m_1 , pero en p_1 no incluye el envío del mensaje. Esto se considera como un *efecto* sin una *causa*. La ejecución actual no estuvo nunca en un estado global correspondiente a los estados del proceso en la frontera, y podemos decir esto, en principio, examinando la relación \rightarrow entre los sucesos. Por el contrario, el corte de la derecha es *consistente*. Incluye tanto el envío como la recepción del mensaje m_1 . Incluye el envío pero no la recepción del mensaje m_2 . Esto es consistente con la ejecución actual; después de todo, el mensaje se tomó algún tiempo para llegar.

Un corte C es consistente si, para cada suceso que contiene, también contiene todos los sucesos que *sucedieron antes* del suceso:

$$\text{Para todos los sucesos } e \in C, f \rightarrow e \Rightarrow f \in C$$

También anotamos aquí otras dos nociones relevantes para los predicados de estado global: seguridad y vitalidad. Supongamos que hay una propiedad indeseable α que es un predicado del estado global del sistema: por ejemplo, α podría ser la propiedad de estar bloqueado indefinidamente. Sea S_0 el estado original del sistema. *Seguridad* con respecto a α es la aserción que α evalúa a *Falso* para todos los estados S alcanzables desde S_0 . A la inversa, sea β una propiedad deseable de un estado global del sistema: por ejemplo, la propiedad de alcanzar la terminación. *Vitalidad* con respecto a β es la propiedad que, para cualquier linealización L comenzando en el estado S_0 , β se evaluará a *Verdadero* para algún estado S_l alcanzable desde S_0 .

10.5.3. EL ALGORITMO DE INSTANTÁNEA DE CHANDY Y LAMPORT

Chandy y Lamport [1985] describen un algoritmo de *instantánea* para determinar estados globales de sistemas distribuidos, que presentamos ahora. El objetivo del algoritmo es registrar un conjunto de estados de procesos y canales (una *instantánea*) para un conjunto de procesos $p_i (i = 1, 2, \dots, N)$ tal que, incluso a través de una combinación de estados registrados que nunca podrían haber ocurrido al mismo tiempo, el estado global registrado sea consistente.

Veremos que el estado que registra el algoritmo de *instantánea* tiene propiedades convenientes para evaluar predicados del estado global.

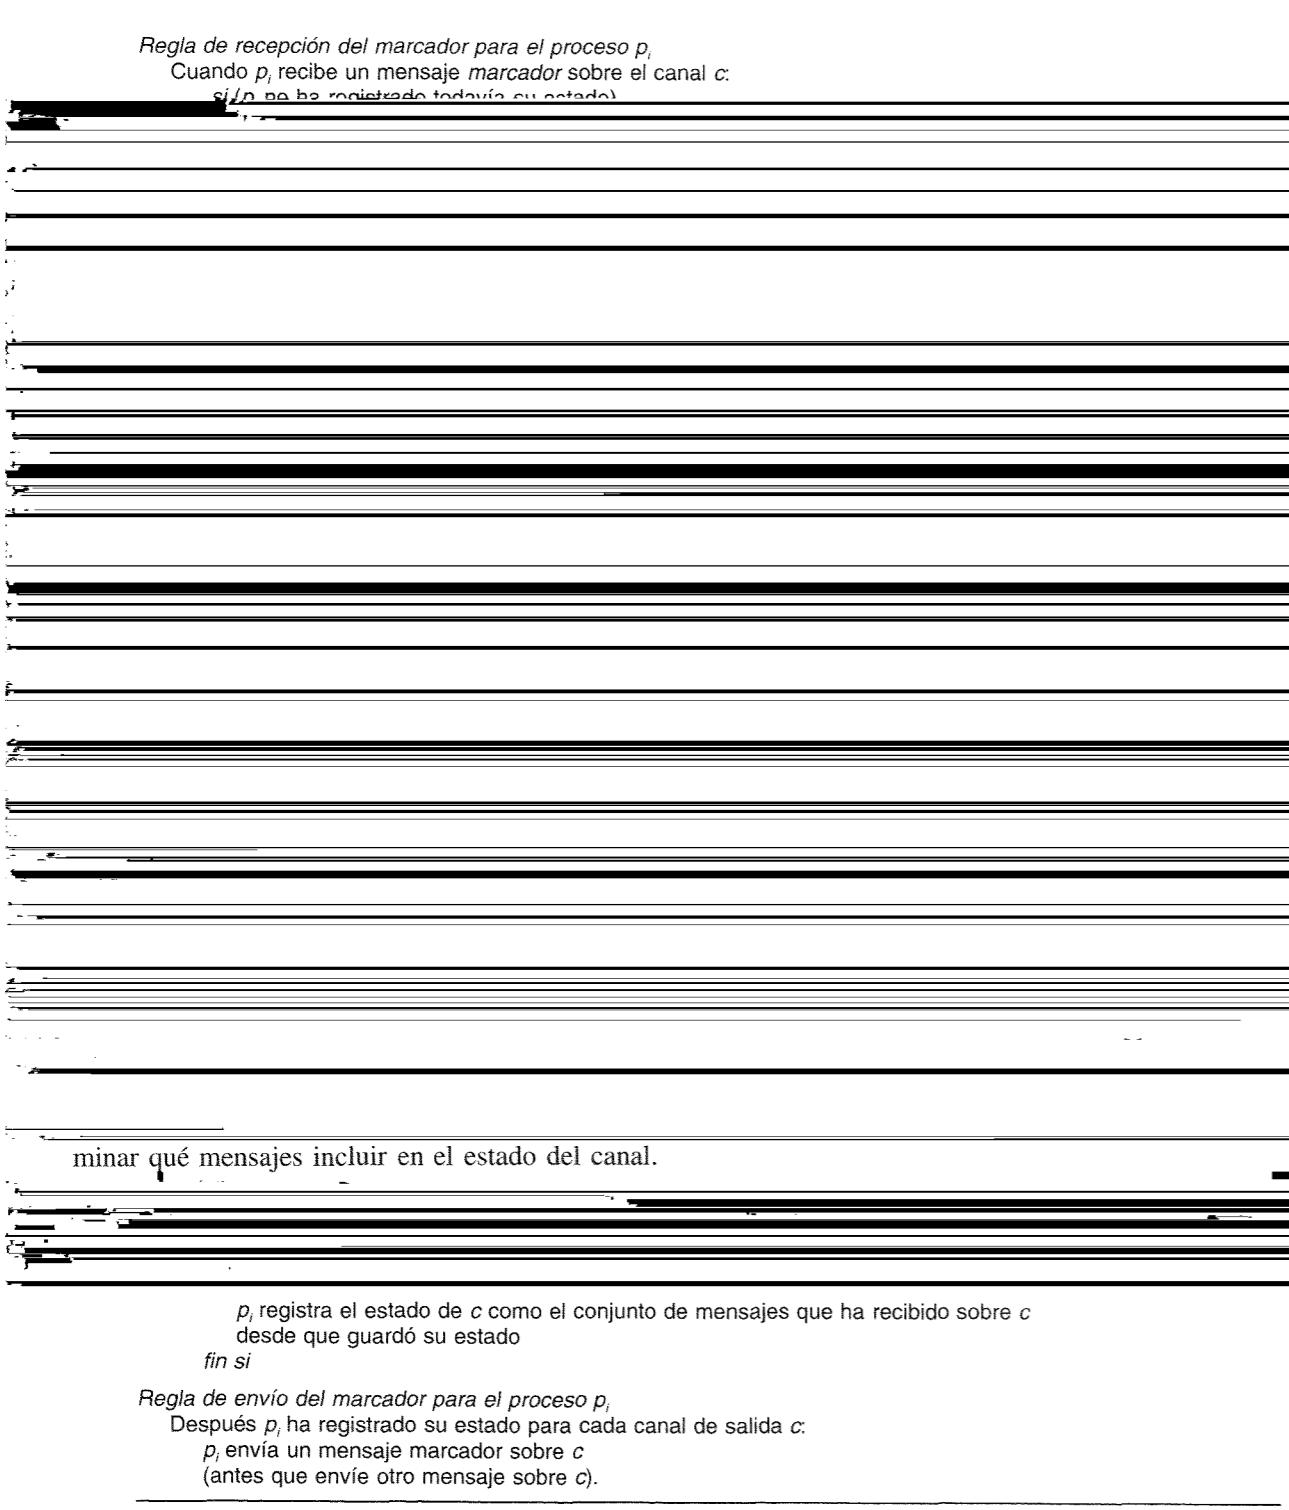
El algoritmo registra el estado localmente en los procesos; no proporciona un método para recoger el estado global en un sitio. Un método obvio para recoger el estado es que todos los procesos envíen el estado que ellos han registrado a un proceso recolector designado, pero no tratamos aquí más ese tema.

El algoritmo supone que:

- No fallan ni los canales ni los procesos; la comunicación es fiable por lo que cada mensaje enviado es recibido intacto, exactamente una vez.
- Los canales son unidireccionales y proporcionan la entrega de los mensajes con ordenación FIFO.
- El grafo de los procesos y canales está fuertemente conectado (hay un recorrido entre dos procesos cualquiera).
- Cualquier proceso puede iniciar una instantánea global en cualquier instante.
- Los procesos pueden continuar su ejecución y enviar y recibir mensajes normales mientras tiene lugar la instantánea.

Para cada proceso p_i , se considera que los canales entrantes son aquéllos por medio de los cuales otros procesos envían mensajes a p_i ; del mismo modo los canales salientes de p_i son aquellos sobre los que él envía mensajes a otros procesos. La idea esencial del algoritmo es como sigue. Cada proceso registra su estado y para cada canal entrante también un conjunto de mensajes enviados a él. El proceso registra, para cada canal, todos los mensajes que entraron después de que él registrara el estado y antes que el emisor registrara su propio estado. Este planteamiento nos permite registrar los estados de los procesos en momentos diferentes menos para dar cuenta de las diferencias entre los estados del proceso en términos de mensajes transmitidos pero todavía no recibidos. Si el proceso p_i ha enviado un mensaje m al proceso p_j , pero p_j no lo ha recibido todavía, entonces consideramos a m como perteneciente al estado del canal entre ellos.

El algoritmo procede mediante el uso de mensajes *marcador* especiales, que son distintos de cualquiera de los otros mensajes que envían los procesos, y que los procesos podrán enviar y recibir mientras continúan con su ejecución normal. El marcador tiene un papel dual: como un aviso para que el receptor guarde su propio estado, si no lo ha hecho aún; y como un medio para determinar qué mensajes incluir en el estado del canal.



El algoritmo se define mediante de dos reglas, la *regla de recepción del marcador* y la *regla de*

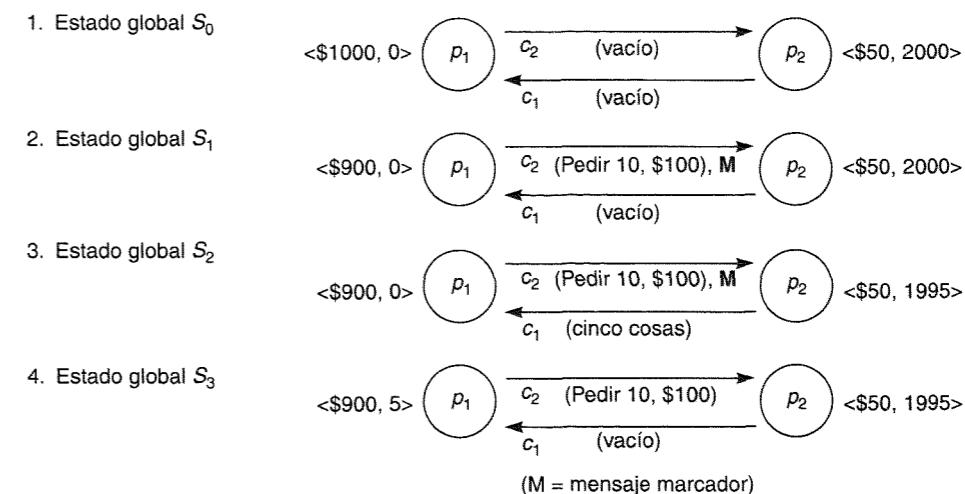


Figura 10.12. La ejecución de los procesos de la Figura 10.11.

Antes de que p_2 reciba el marcador, emite un mensaje de aplicación (cinco cosas) sobre c_1 como respuesta a la orden previa de p_1 , produciendo un nuevo estado actual S_2 .

Ahora el proceso p_1 recibe el mensaje de p_2 (cinco cosas), y p_2 recibe el marcador. Siguiendo la regla de recepción del marcador, p_2 registra su estado como $<50\$, 1995>$ y el del canal c_2 como la secuencia vacía. Siguiendo la regla de envío del marcador, envía un mensaje marcador sobre c_1 .

Cuando el proceso p_1 recibe el mensaje marcador de p_2 , registra el estado del canal c_1 como un único mensaje (cinco cosas) que recibe después que ha registrado su estado. El estado global final actual es S_3 .

El estado final registrado es $p_1: <1000\$, 0>; p_2: <50\$, 1995>; c_1: <(cinco cosas)>; c_2: <>$. Hay que considerar que el estado difiere de todos los estados globales a través de los que ha pasado realmente el sistema.

◊ **Terminación del algoritmo de instantánea.** Suponemos que un proceso que ha recibido un mensaje marcador registra su estado en un tiempo finito y envía mensajes marcador sobre cada canal saliente en un tiempo finito (incluso cuando no se necesite enviar más mensajes sobre esos canales). Si hay un recorrido de canales de comunicación y procesos desde un proceso p_i hasta un proceso $p_j (j \neq i)$, entonces está claro de estas suposiciones que p_j registrará su estado un tiempo finito después que p_i haya registrado el suyo. Puesto que estamos suponiendo que el grafo de procesos y canales está conectado fuertemente, se deduce que todos los procesos habrán registrado sus estados y los de los canales entrantes un tiempo finito después que algunos procesos hayan registrado inicialmente su estado.

◊ **Características del estado observado.** El algoritmo de instantánea selecciona un corte de la historia de la ejecución. El corte, y por tanto el estado registrado por este algoritmo, es consistente. Para ver esto, sean e_i y e_j sucesos que ocurren en p_i y p_j , respectivamente, tal que $e_i \rightarrow e_j$. Afirmamos que si e_j está en el corte entonces e_i también lo está. Esto es, si e_j sucedió antes que p_j registrara su estado, entonces e_i debe haber sucedido antes que p_i registrara el suyo. Esto es obvio si los dos procesos son el mismo, por lo que deberíamos haber supuesto que $j \neq i$. Supongamos, por el momento, lo opuesto de lo que deseamos probar: que p_i registró su estado antes que ocurriera e_i . Consideremos la secuencia H de mensajes $m_1, m_2, \dots, m_H (H \geq 1)$, produciendo la relación

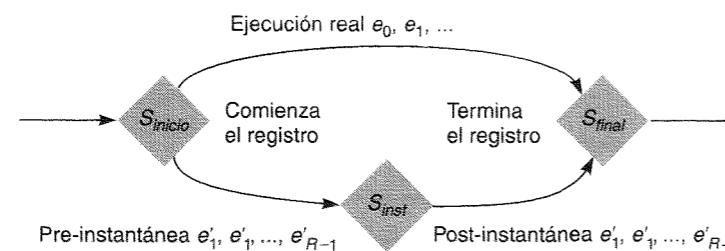


Figura 10.13. Alcanzabilidad entre estado en el algoritmo de «instantánea»

$e_i \rightarrow e_j$. Mediante una ordenación FIFO sobre los canales que atraviesan estos mensajes, y por las reglas de envío y recepción del marcador, un mensaje marcador debiera haber alcanzado p_j por delante de m_1, m_2, \dots, m_H . Por la regla de recepción del marcador, p_j debería haber registrado su estado antes que el suceso e_j . Esto contradice nuestra suposición que e_j está en el corte, y hemos acabado.

Podríamos establecer además una relación de alcanzabilidad entre el estado global observado y los estados inicial y final cuando se ejecuta el algoritmo. Sea $S_{\text{Sis}} = e_0, e_1, \dots$ una linealización del sistema tal y como se ejecuta (donde a dos sucesos ocurridos exactamente al mismo tiempo, los ordenamos de acuerdo con sus identificadores de proceso). Sea S_{inicio} el estado global inmediatamente antes que el primer proceso registrara su estado; sea S_{final} el estado global cuando termina el algoritmo de *instantánea*, inmediatamente después de la última acción de registro de estado; y sea S_{reg} el estado global registrado.

Encontraremos una permutación de Sis , $Sys' = e'_0, e'_1, e'_2, \dots$ tal que los tres estados S_{inicio} , S_{inst} y S_{final} ocurren en Sis' . S_{inst} es alcanzable desde S_{inicio} en Sis' , y es alcanzable desde S_{ins} en Sis' . La Figura 10.13 muestra esta situación, en la que la linealización superior es Sis , y la inferior Sis' .

Deducimos Sis' de Sis categorizando inicialmente todos los sucesos en Sis como sucesos *pre-instantánea* o *post-instantánea*. Un suceso pre-instantánea en el proceso p_i es uno que *sucedió en* p_i *antes* de que registrara su estado; todos los demás sucesos son post-instantánea. Es importante comprender que un suceso post-instantánea puede suceder antes que uno pre-instantánea en Sis , si los sucesos ocurren en diferentes procesos. (Naturalmente ningún suceso post-instantánea puede *suceder antes* que otro pre-instantánea en el mismo proceso.)

Mostraremos cómo podemos ordenar todos los sucesos pre-instantánea antes que los post-instantánea para obtener Sis' . Supongamos que e_j es un suceso post-instantánea de otro proceso, y e_{j+1} es un suceso pre-instantánea de un proceso diferente. No puede ser que $e_j \rightarrow e_{j+1}$. Para ello estos dos sucesos deberían ser el envío y recepción de un mensaje, respectivamente. Un mensaje marcador debería tener que haber precedido al mensaje, haciendo de la recepción del mensaje un suceso post-instantánea, pero por suposición e_{j+1} es un suceso pre-instantánea. Podríamos, por tanto, conmutar ambos sucesos sin violar la relación *sucedió antes* (esto es, la secuencia resultante de los sucesos mantiene una linealización). La conmutación no introduce nuevos estados de procesos, puesto que no hemos alterado el orden en el que ocurren los sucesos en cualquier proceso individual.

Continuamos comutando tantos pares de sucesos adyacentes de esta forma como sea necesario hasta que hemos ordenado todos los sucesos pre-instantánea $e'_0, e'_1, e'_2, \dots, e'_{R-1}$ anteriores a todos los sucesos post-instantánea $e'_R, e'_{R+1}, e'_{R+2}, \dots$ de la ejecución resultante Sis' . Para cada proceso el conjunto de sucesos en $e'_0, e'_1, e'_2, \dots, e'_{R-1}$ que ocurrieron en él es exactamente el conjunto de sucesos que experimentó antes de que registrara su estado. Por tanto el estado de cada proceso en ese punto, y el estado de los canales de comunicación, es el del estado global S_{inst} registrado por el algoritmo. No hemos desordenado ninguno de los estados S_{inicio} o S_{final} con los que la linealización comienza y termina. Por lo tanto hemos establecido una relación de alcanzabilidad.

◊ **Estabilidad y alcanzabilidad del estado observado.** La propiedad de alcanzabilidad del algoritmo de instantánea se utiliza para detectar predicados estables. En general, cualquier predicado no estable que nosotros establezcamos como *Verdadero* en el estado S_{inst} puede o no haber sido *Verdadero* en la ejecución actual cuyo estado global hemos registrado. Sin embargo, si un predicado estable es *Verdadero* en el estado S_{inst} entonces podemos concluir que el predicado es *Verdadero* en el estado S_{final} , puesto que por definición un predicado estable que es *Verdadero* en un estado S lo es también en cualquier otro estado alcanzable de S . De forma similar, si el predicado se evalúa a *Falso* para S_{inst} , entonces debe ser también *Falso* para $S_{inicial}$.

10.6. DEPURACIÓN DISTRIBUIDA

Examinamos ahora el problema del registro de un estado global de un sistema de forma que podemos hacer afirmaciones útiles sobre si un estado transitorio, como opuesto a uno estable, ocurrió en la actual ejecución. Esto es lo que precisamos, en general, cuando depuramos un sistema distribuido. Ya dimos un ejemplo en el que cada conjunto de procesos p_i tiene una variable x_i . La condición de seguridad requerida en este ejemplo es $|x_i - x_j| \leq \delta$ ($i, j = 1, 2, \dots, N$); esta restricción será satisfecha incluso aunque un proceso pueda cambiar el valor de su variable en cualquier instante. Otro ejemplo es un sistema distribuido controlando un sistema de tuberías en una fábrica donde estamos interesados en si todos las válvulas (controladas por diferentes procesos) fueron abiertas al mismo tiempo. En estos ejemplos, no podemos observar, en general, los valores de las variables o los estados de las válvulas simultáneamente. El reto es monitorizar la ejecución del sistema a lo largo del tiempo, para capturar información de la *traza* mas que una simple instantánea, por lo que podemos establecer *a posteriori* si la condición de seguridad requerida fue violada o pudo haberlo sido.

El algoritmo de instantánea de Chandy y Lamport recoge el estado de una forma distribuida y hemos indicado ya cómo los procesos del sistema podrían enviar el estado que ellos conforman a un proceso monitor para su recogida. El algoritmo que describiremos (debido a Marzullo y Neiger [1991]) es centralizado. Los procesos observados envían sus estados a un proceso llamado monitor, que ensambla estados globalmente consistentes de los que recibe. Consideraremos que el monitor se encuentra fuera del sistema observando su ejecución.

Nuestro objetivo es determinar casos en los que dado un predicado de estado global ϕ era sin duda alguna *Verdadero* en algún punto de la ejecución que observamos, y los casos en los que posiblemente era *Verdadero*. La noción *posiblemente* surge como un concepto natural porque podemos extraer un estado global consistente S de un sistema en ejecución y encontrar que $\phi(S)$ es *Verdadero*. Una observación única de un estado global consistente no nos permite concluir si un predicado no estable será evaluado siempre a *Verdadero* en la ejecución actual.

La noción *sin duda alguna* se aplica a la ejecución actual y no a una ejecución que hayamos extrapolado de ella. Nos puede parecer paradójico considerar qué sucedió en la ejecución actual. Sin embargo, es posible evaluar si ϕ fue *sin duda alguna Verdadero* considerando todas las linealizaciones de los sucesos observados.

Definimos ahora las nociones de *posiblemente* ϕ y *sin duda alguna* ϕ para un predicado ϕ en función de las linealizaciones de H , la historia de la ejecución del sistema.

posiblemente ϕ

La afirmación *posiblemente* ϕ significa que hay un estado consistente S a través del cual pasa una linealización H tal que $\phi(S)$ es *Verdadero*.

sin duda alguna q

φ La afirmación *sin duda alguna* ϕ significa que para todas las linealizaciones L de H , hay un estado consistente S a través del cual pasa L tal que $\phi(S)$ es Verdadero.

Cuando utilizamos el algoritmo de instantánea de Chandy y Lamport y obtenemos el estado global S_{inst} podemos afirmar *posiblemente* ϕ si $\phi(S_{inst})$ si ocurre que es *Verdadero*. Pero, en general, evaluar *posiblemente* ϕ implica una búsqueda a través de todos los estados globales consistentes derivados de la ejecución observada. Únicamente si $\phi(S)$ se evalúa a *Falso* para todos los estados globales consistentes S no es el caso de *posiblemente* ϕ . Hay que tener en cuenta que mientras que podemos concluir *sin duda alguna* ($\neg\phi$) de *posiblemente* ϕ , no podemos concluir *negación posiblemente* ϕ de *sin duda alguna* ($\neg\phi$). La última es la afirmación que $\neg\phi$ se mantiene en algún estado en cada linealización: puede mantenerse en otros estados.

Ahora describimos:

- Cómo se recogen los estados del proceso.
- Cómo los monitores extraen estados consistentes globales.
- Cómo el monitor evalúa *posiblemente* ϕ y *sin duda alguna* $\neg\phi$ tanto en sistemas síncronos como asíncronos.

◊ **Recolección del estado.** Los procesos observados p_i ($i = 1, 2, \dots, N$) envían su estado inicial al proceso monitor inicialmente, y después de tiempo en tiempo, en *mensajes de estado*. El proceso monitor registra los mensajes de estado de los procesos p_i en una cola separada Q_i , para cada $i = 1, 2, \dots, N$.

La actividad de preparar y enviar mensajes de estado puede retrasar la ejecución normal de los procesos observados, pero aparte de eso no interfiere con ellos. No hay necesidad de enviar el estado inicialmente o cuando cambia. Hay dos optimizaciones para reducir el tráfico de mensajes de estado hacia el monitor. Primero, el predicado de estado global puede depender solo de ciertas partes de los estados de los procesos. Por ejemplo, puede depender solo de los estados de variables particulares. Por lo que los procesos observados solo necesitan enviar el estado relevante al proceso monitor. Segundo, solo necesitan enviar el estado en los instantes en que el predicado ϕ puede llegar a ser *Verdadero* o dejar de serlo. No tiene sentido enviar los cambios de estado que no afectan al valor del predicado.

Así, en el ejemplo del sistema de procesos p_i que se supone deben obedecer la restricción $|x_i - x_j| \leq \delta$, ($i = 1, 2, \dots, N$), los procesos necesitan notificar al monitor sólo cuando los valores de sus propias variables x_i cambian. Cuando éstos envían su estado, también proporcionan el valor de x_i pero no necesitan enviar ninguna otra variable.

10.6.1. OBSERVACIÓN DE ESTADOS GLOBALES CONSISTENTES

El monitor debe recoger los estados globales consistentes frente a los que evaluar ϕ . Recuerde que un corte C es consistente si y sólo si para todos los sucesos en el corte C , $f \rightarrow e \Rightarrow f \in C$.

Por ejemplo, la Figura 10.14 muestra dos procesos p_1 y p_2 con variables x_1 y x_2 respectivamente. Los sucesos mostrados en las líneas de tiempo (con los vectores de marcas de tiempo) están ajustados a los valores de las dos variables. Inicialmente $x_1 = x_2 = 0$. El requisito es que $|x_i - x_j| \leq 50$. El proceso hace ajustes en sus variables, pero grandes ajustes producen que se envíe a los otros procesos un mensaje conteniendo el nuevo valor. Cuando cualquiera de los procesos recibe un mensaje de ajuste de otro, coloca su variable homóloga al valor contenido en el mensaje.

Cuando uno de los procesos p_1 o p_2 ajusta el valor de sus variables (tanto si es un ajuste *pequeño* como *uno grande*), envía el valor en un mensaje de estado al proceso monitor. El último mantiene los mensajes de estado en las colas *por proceso* para el análisis. Si los procesos monitor usaron valores del corte inconsistente C_1 de la Figura 10.14, entonces se debería encontrar que $x_1 = 1$, $x_2 = 100$, incumpliendo la restricción $|x_i - x_j| \leq 50$. Pero ese estado de cosas nunca llegó a ocurrir. Por otro lado, los valores del corte consistente C_2 muestra $x_1 = 105$, $x_2 = 90$.

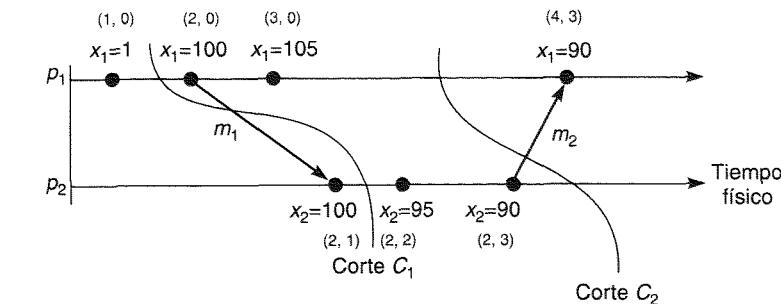


Figura 10.14. Vectores de marcas de tiempo y valores variables para la ejecución de la Figura 10.9.

Con el fin que el monitor pueda distinguir estados globales consistentes de estados globales inconsistentes, los procesos observados engloban sus valores de reloj vectorial con sus mensajes de estado. Cada cola Q_i se mantiene ordenada por el orden de envío, que puede ser establecido inmediatamente examinando el i -ésimo componente del vector de marcas de tiempo. Naturalmente el proceso monitor no puede deducir nada sobre la ordenación de los estados enviados por procesos diferentes a partir de su orden de llegada, a causa de las latencias de los mensajes. En su lugar debe examinar los vectores de marcas de tiempo de los mensajes de estado.

Sea $S = (s_1, s_2, \dots, s_N)$ un estado global obtenido de los mensajes de estado que ha recibido el proceso monitor. Sea $V(s_i)$ el vector de marcas de tiempo del estado s_i recibido desde p_i . Se puede mostrar que S es un estado global consistente si y sólo si:

$$V(s_i)[i] \geq V(s_j)[i] \quad \text{para } i, j = 1, 2, \dots, N \quad (\text{Condición EGS})$$

Esto viene a decir que el número de sucesos de p_i conocidos en p_j cuando éste envía s_j no es más que el número de sucesos que han ocurrido en p_i cuando envió s_i . En otras palabras, si el estado de un proceso depende del estado del otro (de acuerdo con la ordenación *sucedió antes*), entonces el estado global también abarca el estado del que depende.

En resumen, ahora poseemos un método por el que el proceso monitor puede establecer si un estado global dado es consistente, usando el vector de marcas de tiempo mantenido por los procesos observados e incluido en los mensajes de estado que ellos le enviaron.

La Figura 10.15 muestra la red de estados globales consistentes correspondiente a la ejecución de los dos procesos de la Figura 10.14. Esta estructura captura la relación de alcanzabilidad entre estados globales consistentes. Los nodos representan estados globales, y los arcos representan posibles transiciones entre los estados. El estado global S_{00} tiene a ambos procesos en su estado inicial; S_{10} tiene a p_2 aún en su estado inicial y a p_1 en el siguiente estado en su historia local. El estado S_{01} no es consistente, porque el mensaje m_1 se envió desde p_1 a p_2 , por lo que no aparece en la red.

La red está organizada en niveles con, por ejemplo, S_{00} en el nivel 0, S_{10} en el nivel 1. En general, S_{ij} está en el nivel $(i + j)$. Una linealización atraviesa la red desde cualquier estado global a cualquier otro estado global alcanzable desde él en el siguiente nivel, es decir, en cada paso algún proceso experimenta un suceso. Por ejemplo, S_{22} es alcanzable desde S_{20} , pero no lo es desde S_{30} .

La red nos muestra todas las linealizaciones correspondientes a una historia. Ahora está claro, en principio, como un proceso monitor debiera evaluar *posiblemente* ϕ y *sin duda alguna* ϕ . Para evaluar *posiblemente* ϕ , el proceso monitor comienza en el estado inicial y salta a través de todos los estados consistentes alcanzables desde ese punto, evaluando ϕ en cada etapa. Éste se detendrá

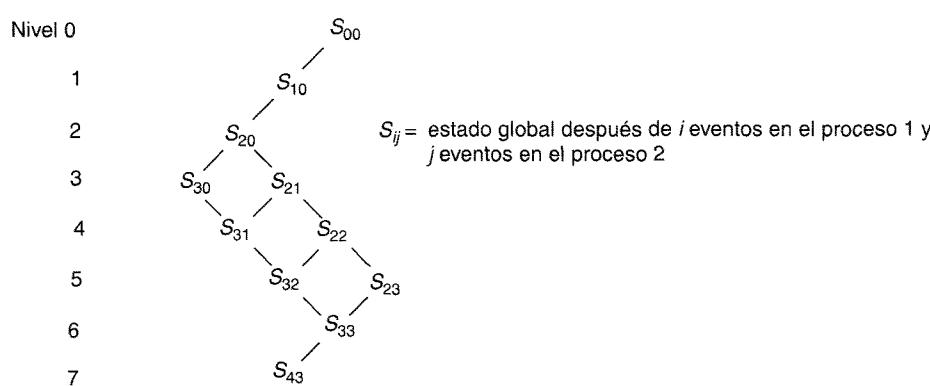


Figura 10.15. La red de estados globales para la ejecución de la Figura 10.14.

cuando ϕ se evalúa a *Verdadero*. Para evaluar *sin duda alguna* ϕ , el proceso monitor deberá intentar encontrar el conjunto de estados a través de los cuales deben pasar todas las linealizaciones, y en cuál de ellos ϕ se evalúa a *Verdadero*. Por ejemplo, si $\phi(S_{30})$ y $\phi(S_{21})$ en la Figura 10.15 son ambos *Verdaderos* entonces, puesto que todas las linealizaciones pasan a través de estos estados, se mantiene *sin duda alguna* ϕ .

10.6.2. EVALUANDO POSIBLEMENTE ϕ

Para evaluar *posiblemente* ϕ , el proceso monitor debe atravesar la red de estados alcanzables, comenzando desde el estado inicial $(s_1^0, s_2^0, \dots, s_N^0)$. El algoritmo se muestra en la Figura 10.16. Dicho algoritmo supone que la ejecución es infinita. Puede ser adaptado fácilmente para una ejecución finita.

El proceso monitor puede descubrir el conjunto de estados consistentes en el nivel $L + 1$ alcanzable desde un estado consistente en el nivel L por el método siguiente. Sea $S = (s_1, s_2, \dots, s_N)$ un

1. Evaluando posiblemente ϕ para la historia global H de N procesos

```

 $L := 0$ 
Estados := {  $(s_1^0, s_2^0, \dots, s_N^0)$  } ;
mientras ( $\phi(S) = \text{Falso}$  para todos los  $S \in \text{Estados}$ )
   $L := L + 1$ ;
  Alcanzable := {  $S$ :  $S$  alcanzable en  $H$  desde algún  $S \in \text{Estados} \wedge \text{nivel}(S) = L$  };
  Estados := Alcanzable
fin mientras
salida "posiblemente  $\phi$ ";
```

2. Evaluando sin duda alguna ϕ para la historia global H de N procesos

```

 $L := 0$ ;
si ( $\phi(s_1^0, s_2^0, \dots, s_N^0)$ ) entonces Estados := {} sino Estados := {  $(s_1^0, s_2^0, \dots, s_N^0)$  } ;
mientras (Estados  $\neq \{ \}$ )
   $L := L + 1$ ;
  Alcanzable := {  $S$ :  $S$  alcanzable en  $H$  desde algún  $S \in \text{Estados} \wedge \text{nivel}(S) = L$  };
  Estados := {  $S \in \text{Alcanzable}: \phi(S) = \text{Falso}$  }
fin mientras
salida "sin duda alguna  $\phi$ ";
```

Figura 10.16. Algoritmos para evaluar posiblemente ϕ y sin duda alguna ϕ .

estado consistente. Entonces un estado consistente en el siguiente nivel alcanzable desde S es de la forma $S' = (s_1, s_2, \dots, s'_i, \dots, s_N)$, que difiere de S sólo porque contiene el siguiente evento de algún proceso p_i . El monitor puede encontrar todos esos estados atravesando las colas de estados Q_i ($i = 1, 2, \dots, N$). El estado S' es alcanzable desde S si y sólo si:

$$\text{para } j = 1, 2, \dots, N, j \neq i: V(s_j)[j] \geq V(s'_i)[j]$$

Esta condición se deduce de la anterior condición EGC y del hecho que S ya estaba en un estado consistente. Un estado dado, en general, puede ser alcanzado desde varios estados del nivel anterior, por lo que el proceso monitor debería tener cuidado de evaluar la consistencia de cada estado sólo una vez.

10.6.3. EVALUANDO SIN DUDA ALGUNA ϕ

Para evaluar *sin duda alguna* ϕ , el proceso monitor atraviesa de nuevo la red de estados alcanzables en un tiempo, comenzando desde el estado inicial $(s_1^0, s_2^0, \dots, s_N^0)$. El algoritmo (presentado en la Figura 10.16) supone de nuevo que la ejecución es infinita pero puede ser adaptado fácilmente para una ejecución finita. Mantiene el conjunto *Estados*, que contiene aquellos estados en el nivel actual que pueden ser alcanzados en una linealización desde el estado inicial atravesando sólo estados en los que ϕ se evalúa a *Falso*. Por el hecho que existe una linealización, no podemos afirmar *sin duda alguna* ϕ : la ejecución podría haber tomado esta linealización, y ϕ sería *Falso* en cada etapa a lo largo de ella. Si alcanzamos un nivel en el que no existe dicha linealización, podemos concluir que *sin duda alguna* ϕ .

En la Figura 10.17, en el nivel 3 el conjunto *Estados* consta de un solo estado, que es alcanzable por una linealización en la que todos los estados están a *Falso* (marcado en líneas oscuras). El único estado considerado en el nivel 4 es uno marcado con «F». (El estado a su derecha no se considera, puesto que sólo puede ser alcanzado vía un estado para el que ϕ se evalúa a *Verdadero*.) Si ϕ se evalúa a *Verdadero* en el estado del nivel 5, entonces podemos concluir que *sin duda alguna* ϕ . En otro caso el algoritmo debe continuar más allá de este nivel.

◇ **Coste.** Los algoritmos que acabamos de describir explotan combinatoriamente. Supongamos que k es el máximo número de sucesos de un único proceso. Entonces los algoritmos que hemos descrito implican $O(k^N)$ comparaciones (el proceso monitor compara los estados de cada uno de los N procesos observados con todos los demás).

Hay también un coste de espacio para estos algoritmos de $O(k^N)$. Sin embargo, observamos que el monitor puede borrar un mensaje contenido en el estado s_i de la cola Q_i cuando ningún otro ítem

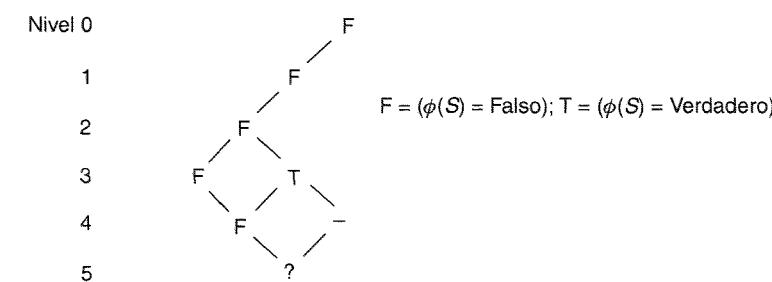


Figura 10.17. Evaluando sin duda alguna ϕ .

de estado llegando desde otro proceso pudiera estar posiblemente implicado en un estado global consistente que contenga s_i . Esto es, cuando:

$$V(s_j^{\text{ultimo}})[i] > V(s_i)[i] \quad \text{para } j = 1, 2, \dots, N, j \neq i$$

donde s_j^{ultimo} es el último estado que el proceso monitor ha recibido desde el proceso p_j .

10.6.4. EVALUANDO DEFINITIVAMENTE ϕ Y SIN DUDA ALGUNA ϕ EN SISTEMAS SÍNCRONOS

Los algoritmos que hemos dado anteriormente trabajan en un sistema asíncrono: no hemos hecho suposiciones temporales. Pero el precio pagado por esto es que el monitor debe examinar un estado global consistente $S = (s_1, s_2, \dots, s_N)$ para el que dos estados locales cualquiera s_i y s_j ocurrieron en un tiempo arbitrariamente distante en la ejecución actual del sistema. Nuestro requisito, por contraste, es considerar sólo aquellos estados por los que la ejecución actual podría haber pasado.

En un sistema síncrono, suponemos que los procesos mantienen sus relojes físicos sincronizados internamente con un límite conocido, y que los procesos observados proporcionan marcas de tiempo físicas así como un vector de marcas de tiempo en sus mensajes de estado. Entonces el proceso monitor necesita considerar sólo aquellos estados globales consistentes cuyos estados locales podrían posiblemente haber existido simultáneamente, dada la sincronización aproximada de los relojes. Con suficientemente buena sincronización de los relojes, éstos serían un número mucho menor que todos los estados consistentes globalmente.

Damos ahora un algoritmo para explotar los relojes sincronizados de esta forma. Suponemos que cada proceso observado $p_i (i = 1, 2, \dots, N)$ y el proceso monitor, que podríamos llamar p_m , mantiene un reloj físico $C_i (i = 1, 2, \dots, N)$. Éstos están sincronizados con un límite conocido $D > 0$; es decir, en el mismo tiempo real:

$$|C_i(t) - C_j(t)| < D \quad \text{para } i, j = 1, 2, \dots, N$$

Los procesos observados envían al proceso monitor tanto su tiempo vectorial como el tiempo físico con sus mensajes de estado. El proceso monitor aplica ahora una condición que no sólo comprueba la consistencia de un estado global $S = (s_1, s_2, \dots, s_N)$, sino también comprueba cualquier par de estados que pudieran haber ocurrido en algún instante real, dado los valores del reloj físico. En otras palabras, para $i, j = 1, 2, \dots, N$:

$$V(s_i)[i] \geq V(s_j)[i] \quad \text{y} \quad s_i \text{ y } s_j \text{ podrían haber ocurrido en el mismo tiempo real.}$$

La primera cláusula es la condición que hemos utilizado anteriormente. Para la segunda cláusula, hay que señalar que p_i está en el estado s_i desde el momento en que notifica su estado al proceso monitor, $C_i(s_i)$, hasta algún tiempo local posterior $L_i(s_j)$, por ejemplo, cuando ocurre la transición al siguiente estado en p_i . Para que s_i y s_j se hayan obtenido en el mismo instante real tenemos, por tanto, que permitir para el límite en la sincronización del reloj:

$$C_i(s_i) - D \leq C_j(s_j) \leq L_i(s_i) + D, \text{ o viceversa (cambiando } i \text{ por } j).$$

El proceso debe calcular un valor para $L_i(s_i)$, que se mide contra el reloj de p_i . Si el proceso monitor ha recibido un mensaje de estado para el siguiente estado de p_i , entonces $L_i(s_i)$ es $C_i(s'_i)$. En caso contrario el proceso monitor estima $L_i(s_i)$ como $C_0 - \max + D$, donde C_0 es el valor actual del reloj del monitor, y \max el tiempo máximo de transmisión para un mensaje de estado.

10.7. RESUMEN

Este capítulo comenzó describiendo la importancia del mantenimiento de la precisión del tiempo en los sistemas distribuidos. Después ha descrito algoritmos para sincronización de relojes a pesar de sus derivas entre ellos y la variabilidad de los retardos en los mensajes entre computadores.

El grado de precisión que es obtenible en la sincronización satisface, en la práctica, muchos requisitos pero no es suficiente, sin embargo, para determinar la ordenación de un par arbitrario de sucesos que ocurrían en diferentes computadores. La relación *sucedió antes* es un orden parcial entre sucesos que refleja un flujo de información entre ellos, dentro de un proceso o vía mensajes entre procesos. Algunos algoritmos requieren que los sucesos estén ordenados en un orden *sucedió antes*, por ejemplo las actualizaciones sucesivas hechas sobre copias separadas de datos. Los relojes de Lamport son contadores que se actualizan de acuerdo con la relación *sucedió antes* entre eventos. Los relojes vectoriales son una mejora de los relojes de Lamport, porque es posible determinar, examinando sus vectores de marcas de tiempo, si dos sucesos están ordenados en la relación *sucedió antes* o son concurrentes.

Hemos presentado los conceptos de eventos (sucesos), historias locales y globales, recortes, estados globales y locales, ejecuciones, estados consistentes, linealizaciones (ejecuciones consistentes) y alcanzabilidad. Un estado o ejecución consistente es uno que está de acuerdo con la relación *sucedió antes*.

Hemos continuado considerando el problema de registrar un estado global consistente observando la ejecución de un sistema. Nuestro objetivo ha sido evaluar un predicado sobre este estado. Una clase importante de predicados son los predicados estables. Hemos descrito el algoritmo de instantánea de Chandy y Lamport, que captura un estado consistente global y permite hacer aserciones sobre si un predicado estable se mantiene en la ejecución actual. Continuamos, dando el algoritmo de Marzullo y Neiger para derivar afirmaciones sobre si se mantiene un predicado o podría haberse mantenido en la ejecución actual. El algoritmo emplea un proceso de monitor para recoger estados. El monitor examina el vector de marcas de tiempo para extraer estados consistentes globales, y construye y examina la red de todos los estados existentes globales. Este algoritmo presenta gran complejidad computacional pero es valioso de comprender y puede ser de algún beneficio práctico en sistemas reales donde relativamente pocos sucesos cambian el valor del predicado global. El algoritmo tiene una variante más eficiente para sistemas síncronos, donde los relojes pueden estar sincronizados.

EJERCICIOS

- 10.1. ¿Por qué es necesaria la sincronización del reloj de los computadores? Describa los requisitos de diseño para un sistema para sincronizar los relojes en un sistema distribuido.
- 10.2. Un reloj proporciona la lectura 10:27:54.0 (hr:min:seg) cuando se descubre que adelanta 4 segundos. Explicar por qué es deseable ajustarlo al tiempo correcto en ese punto y mostrar (numéricamente) cómo debiera ser ajustada de modo que sea correcto después de transcurridos 8 segundos.
- 10.3. Un esquema para implementar la entrega como mucho una vez de mensajes fiable utiliza relojes sincronizados para rechazar mensajes duplicados. Los procesos colocan su valor local del reloj (una *marca de tiempo*) en los mensajes que envían. Cada receptor mantiene una tabla, dando para cada proceso emisor, el mensaje con la marca de tiempo más grande que ha visto. Suponer que los relojes están sincronizados en 100 ms, y que los mensajes pueden llegar como mucho 50 ms después de la transmisión.

- (i) ¿Cuándo ignora un proceso un mensaje llevando una marca de tiempo T , si ha registrado el último mensaje recibido desde el proceso que tiene una marca de tiempo T' ?
(ii) ¿Cuándo puede un receptor eliminar una marca de tiempo 175.000 (ms) de su tabla? (Sugerencia: utilizar el valor del reloj local del receptor).
(iii) ¿Los relojes deben estar sincronizados interna o externamente?
- 10.4.** Un cliente intenta sincronizarse con un servidor de tiempo. Registra los tiempos de ida y vuelta y las marcas de tiempo devuelto por el servidor en la tabla posterior.
¿Cuál de estos tiempos debiera utilizarse para sintonizar el reloj? ¿A qué tiempo debiera colocarse? Estimar la precisión de la sintonización con respecto al reloj del servidor. Si se sabe que el tiempo entre enviar y recibir un mensaje en el sistema implicado es de al menos 8 ms, ¿cambiarían tus respuestas?
- | Ida y vuelta (ms) | Tiempo (hr:min:seg) |
|-------------------|---------------------|
| 22 | 10:54:23.674 |
| 25 | 10:54:25.450 |
| 20 | 10:54:28.342 |
- 10.5.** En el sistema del Ejercicio 10.4 se requiere sincronizar un reloj de un servidor de archivos con ± 1 milisegundo. Discutir esto en relación con el algoritmo de Cristian.
- 10.6.** ¿Qué reconfiguraciones crees que ocurrán en la subred de sincronización NTP?
- 10.7.** Un servidor B de NTP recibe un mensaje del servidor A a las 16:34:23.480 llevando una marca de tiempo 16:34:13.430 y lo responde. A recibe el mensaje a las 16:34:15.725, llevando una marca de tiempo 16:34:25.7 de B. Estimar la deriva entre B y A y la precisión de la estimación.
- 10.8.** Discutir los factores que se toman en cuenta cuando se decide con qué servidor NTP debe sincronizar un cliente su reloj.
- 10.9.** Discutir cómo es posible compensar la deriva de reloj entre puntos de sincronización observando el ritmo de deriva sobre el tiempo. Discutir cualquier limitación a su tiempo.
- 10.10.** Considerando una cadena de cero o más mensajes conectando sucesos e y e' y utilizando la inducción, mostrar que $e \rightarrow e' \Rightarrow L(e) \rightarrow L(e')$.
- 10.11.** Mostrar que $V_i[j] \leq V_i[i]$.
- 10.12.** De una forma similar al Ejercicio 10.10, mostrar que $e \rightarrow e' \Rightarrow V(e) < V(e')$.
- 10.13.** Utilizando el resultado del Ejercicio 10.11, mostrar que si los sucesos e y e' son concurrentes entonces no se cumple ni $V(e) \leq V(e')$ ni $V(e') \leq V(e)$. De esta manera, si $V(e) < V(e')$ entonces $e \rightarrow e'$.
- 10.14.** Dos procesos P y Q están conectados en un anillo utilizando dos canales, y permanentemente rotan un mensaje m . En un instante cualquiera, sólo hay una copia de m en el sistema. El estado de cada proceso consiste en el número de veces que ha recibido el mensaje m , y P es el que envía el primer mensaje m . En un cierto punto, P tiene el mensaje y sus

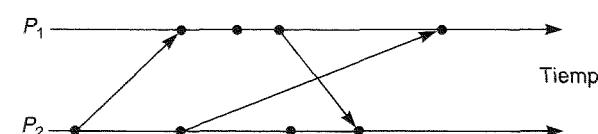
estado es 101. Inmediatamente después de enviar m , P inicia el algoritmo de instantánea. Explicar la operación del algoritmo en este caso, proporcionando el posible estado global devuelto por él.

- 10.15.** La figura anterior muestra sucesos que ocurren en dos procesos, p_1 y p_2 . Las flechas entre procesos indican transmisión de mensaje.

Dibuje y etiquete la red de estados consistentes (estado p_1 , estado p_2), comenzando con el estado inicial $(0, 0)$.

- 10.16.** Pérez está ejecutando una colección de procesos p_1, p_2, \dots, p_N . Cada proceso p_i contiene una variable v_i . Ella desea determinar si todas las variables v_1, v_2, \dots, v_N han sido siempre iguales en el curso de la ejecución.

- (i) Los procesos de Pérez se ejecutan en un sistema síncrono. Ella utiliza un proceso monitor para determinar si las variables fueron siempre iguales. ¿Cuándo deberían los procesos de la aplicación comunicarse con el proceso monitor, y qué deberían contener sus mensajes?
(ii) Explicar la declaración posiblemente $(v_1 = v_2 \dots = v_N)$. ¿Cómo puede Pérez determinar si esta declaración es verdadera durante su ejecución?



COORDINACIÓN Y ACUERDO

- 11.1. Introducción
- 11.2. Exclusión mutua distribuida
- 11.3. Elecciones
- 11.4. Comunicación por multidifusión
- 11.5. Consenso y sus problemas relacionados
- 11.6. Resumen

En este capítulo, se presentan algunos temas y algoritmos relacionados con la forma en la que los procesos coordinan sus acciones y realizan acuerdos sobre valores compartidos en sistemas distribuidos aun en presencia de fallos. El capítulo empieza presentando algoritmos para conseguir exclusión mutua entre una colección de procesos y para coordinar sus accesos a los recursos compartidos. Continúa examinando cómo puede implementarse una elección en un sistema distribuido. Esto es, describe cómo un grupo de procesos pueden ponerse de acuerdo acerca de un nuevo coordinador de sus actividades tras fallar el coordinador anterior.

La segunda mitad del capítulo examinará los problemas relacionados con la comunicación por multidifusión, el consenso, los acuerdos bizantinos y la consistencia interactiva. En el caso de la comunicación por multidifusión se centra en la consecución de acuerdos en temas tales como el orden en el cual se entregan los mensajes. El consenso y el resto de los problemas se generalizan a partir de la siguiente idea: ¿cómo puede cualquier colección de procesos ponerse de acuerdo en algún valor, con independencia del dominio de los valores en cuestión? Encontramos un resultado fundamental en la teoría de sistemas distribuidos: bajo ciertas condiciones, entre las que se incluyen condiciones de fallo sorprendentemente benignas, es imposible garantizar que los procesos alcanzarán un consenso.

11.1. INTRODUCCIÓN

Este capítulo presenta una colección de algoritmos con objetivos variados, pero que comparten un fin que es fundamental en los sistemas distribuidos: dado un conjunto de procesos, coordinar sus acciones o ponerse de acuerdo en uno o más valores. Por ejemplo, en el caso de un mecanismo complejo como el de una nave espacial, es esencial que los computadores que realizan el control acuerden condiciones tales como si la misión de la nave prosigue o si ésta ha sido abortada. Además, los computadores deben coordinar sus acciones correctamente con respecto a los recursos compartidos (los sensores y actuadores de la nave espacial). Los computadores han de ser capaces de hacerlo incluso cuando no hay una relación establecida maestro-esclavo entre los componentes (que haría la coordinación particularmente simple). La razón para evitar relaciones fijas maestro-esclavo es que, frecuentemente, requerimos de nuestros sistemas que se mantengan trabajando correctamente incluso si ocurre un fallo, por lo que es necesario evitar puntos de fallo individuales tales como maestros prefijados.

Una distinción importante, como se hizo en el Capítulo 10, será si el sistema distribuido en estudio es síncrono o asíncrono. En un sistema asíncrono, no podemos hacer suposiciones con relación a la coordinación temporal. En un sistema síncrono, supondremos que hay límites para el retraso máximo en la transmisión de mensajes, en el tiempo para ejecutar cada proceso y en el promedio de derivas de los relojes. Las suposiciones de sincronía permiten que se usen timeouts para detectar caídas en los procesos.

Otra meta importante del capítulo, cuando se discuta sobre algoritmos, será la de considerar la presencia de fallos y cómo tenerlos en cuenta cuando se diseñan dichos algoritmos. En la Sección 2.3.2 se presentó un modelo de fallo que se usará en este capítulo. El abordar el tema de los fallos es una tarea sutil; por lo tanto, se empezará considerando algoritmos que no toleran fallos, se avanzará introduciendo fallos benignos y se llegará a considerar cómo tolerar fallos arbitrarios. Además, se encuentra un resultado fundamental en la teoría de sistemas distribuidos. Incluso bajo condiciones de fallo sorprendentemente benignas, es imposible garantizar en un sistema asíncrono que una colección de procesos puedan ponerse de acuerdo en un valor compartido; por ejemplo, que todos los procesos involucrados en el control de la nave espacial se pongan de acuerdo en si «la misión sigue» o «la misión aborta».

La Sección 11.2 examina el problema de la exclusión mutua distribuida. Ésta es la extensión a los sistemas distribuidos del conocido problema de evitar condiciones de competición continua en los núcleos y aplicaciones multi-hilo. La exclusión mutua es un problema importante a resolver, dado que lo que ocurre fundamentalmente en un sistema distribuido es que los procesos comparten recursos. A continuación, la Sección 11.3 presenta un asunto relacionado, aunque más general, que es cómo «elegir» dentro de una colección de procesos a uno para que desarrolle un papel especial. Por ejemplo, en el Capítulo 10 se vio cómo los procesos sincronizaban sus relojes con un servidor de tiempos previamente designado. Si el servidor falla y han sobrevivido otros servidores que pueden desempeñar ese papel, entonces es necesario elegir un servidor que lo releve con el fin de mantener la consistencia.

La comunicación por multidifusión es el tema de la Sección 11.4. Tal y como se explicó en la Sección 4.5.1, la técnica de multidifusión es un paradigma de comunicación muy útil, pudiendo aplicarse en temas tan dispares como la localización de recursos o la coordinación de actualizaciones de datos replicados. La Sección 11.4 examina la fiabilidad y la semántica de la ordenación en la técnica de multidifusión y proporciona algoritmos para lograr las distintas variantes. La entrega en la multidifusión es esencialmente un problema de llegar a un acuerdo entre procesos: los receptores acuerdan qué mensajes recibirán y en qué orden. La Sección 11.5 describe el problema de acuerdos de forma más general, principalmente en las formas conocidas como consenso y acuerdos bizantinos.

El tratamiento que se sigue en este libro implica el establecimiento de las hipótesis y los objetivos que deben cumplirse, y dar una explicación informal de por qué los algoritmos que se presentan son correctos. No puede proporcionarse una aproximación más rigurosa dados los problemas de espacio. Debido a esto, remitiremos al lector a los textos que proporcionan informes minuciosos de algoritmos distribuidos, tales como Attiya y Welch [1998] y Lynch [1996].

Antes de introducir los problemas y los algoritmos, discutiremos las hipótesis sobre fallos y la forma práctica de detectar fallos en un sistema distribuido.

11.1.1. SUPOSICIONES SOBRE FALLOS Y DETECTORES DE FALLOS

Para simplificar, este capítulo supone que cada par de procesos están conectados por canales fiables. Esto es, aunque los componentes de la red subyacente puedan sufrir fallos, los procesos utilizan un protocolo de comunicación fiable que enmascara estos fallos, por ejemplo mediante la retransmisión de mensajes perdidos o corruptos. También por simplificar, se supone que ningún fallo en un proceso implica una amenaza para la capacidad de otros procesos de comunicarse. Esto significa que ningún proceso depende de otro para enviar mensajes.

Nótese que un canal fiable *al final* entrega un mensaje en el búfer de entrada del receptor. En un sistema síncrono, suponemos que existe una redundancia en el hardware allí donde sea necesario de tal forma que un canal fiable no sólo entrega finalmente un mensaje a pesar de los fallos, sino que lo hace dentro de un tiempo límite especificado.

En un intervalo de tiempo cualquiera, la comunicación entre ciertos procesos puede tener éxito mientras que la comunicación entre otros procesos puede verse retrasada. Por ejemplo, el fallo de un encaminador entre dos redes puede significar que un conjunto de cuatro procesos se divide en dos parejas, de tal forma que la comunicación dentro de las parejas es posible sobre sus respectivas redes; pero la comunicación entre las parejas no es posible mientras el encaminador siga fallando. Esto se conoce como una *partición de la red* (véase la Figura 11.1). Sobre una red punto a punto como es Internet, la presencia de topologías complicadas y elecciones de encaminamiento independientes conllevan que la conectividad pueda ser *asimétrica*: la comunicación es posible entre el proceso *p* y el proceso *q*, pero no viceversa. La conectividad puede ser también *intransitiva*: la comunicación es posible desde *p* hasta *q* y desde *q* hasta *r*; pero *p* no puede comunicarse directamente con *r*. Así, nuestra suposición de fiabilidad implica que al final cualquier enlace o encaminador caído será reparado o rodeado. Sin embargo, no todos los procesos son capaces de comunicarse al mismo tiempo.

El capítulo supone, salvo que se diga lo contrario, que los procesos sólo fallan por caídas, una hipótesis que es suficientemente buena para muchos sistemas. En la Sección 11.5 consideraremos cómo tratar los casos en los que los procesos tengan fallos arbitrarios (extraños). Cualquiera que

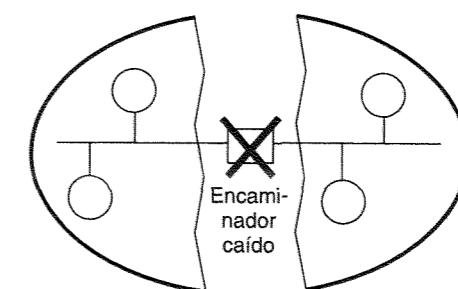


Figura 11.1. Una partición de la red.

sea el fallo, un proceso *correcto* es uno que no muestra fallos en ningún momento de la ejecución que se esté considerando. Nótese que el término corrección se aplica a la ejecución completa, no sólo a una parte de ella. Por lo tanto, un proceso que sufre un fallo por caída se dice que está «sin fallo» antes de ese momento, pero no que sea «correcto» antes de ese momento.

Uno de los problemas en el diseño de algoritmos que puedan superar las caídas de procesos es el de decidir cuándo un proceso ha caído. Un *detector de fallo* [Chandra y Toueg 1996, Stelling y otros 1998] es un servicio al que recurren los procesos para saber si un proceso determinado ha fallado. Frecuentemente, se implementa usando un objeto local en cada proceso (en el mismo computador) que ejecuta un algoritmo de detección de fallos en colaboración con sus equivalentes en los otros procesos. El objeto local a cada proceso se llama un *detector de fallo local*. Se esbozará brevemente cómo implementar detectores de fallo, pero antes hemos de concentrarnos en algunas de las propiedades de los detectores de fallos.

Un «detector» de fallos no es necesariamente exacto. La mayor parte de ellos pueden catalogarse como *detectores de fallo no fiables*. Uno de estos detectores puede generar uno de dos valores cuando se le proporcione la identidad de un proceso: *Sospechoso* o *No sospechoso*. Ambos resultados deben considerarse como indicios que pueden reflejar de forma precisa o no si el proceso ha fallado en realidad. Un resultado de *No sospechoso* significa que el detector ha recibido recientemente evidencias que le sugieren que el proceso no ha fallado; por ejemplo, se recibió recientemente un mensaje enviado por él. Pero, por supuesto, el proceso puede haber fallado desde entonces. Un resultado de *Sospechoso* debe entenderse como que el detector de fallo tiene alguna indicación de que el proceso puede haber fallado. Por ejemplo, puede ser que no haya recibido ningún mensaje por parte del proceso en un período de silencio mayor al permitido (incluso en un sistema asíncrono pueden usarse como indicios algunos límites superiores prácticos). La sospecha puede estar equivocada; por ejemplo, el proceso puede estar funcionando correctamente, pero al otro lado de una partición en la red; o puede estar funcionando más lentamente de lo esperado.

Un *detector de fallo fiable* es aquel que siempre detecta fallos en un proceso de forma exacta. Responde a las preguntas de los procesos bien con el término *No sospechoso*, que, como antes, puede ser sólo un indicio, o con el término *Fallido*. Un resultado de *Fallido* significa que el detector ha determinado que el proceso se ha caído. Recuérdese que un proceso que se ha caído permanece en ese estado, dado que por definición un proceso nunca continúa una vez se ha malogrado.

Es importante darse cuenta de que, aunque se habla de un detector de fallos actuando dentro de una colección de procesos, la respuesta que el detector proporciona al proceso es tan buena como la información de la que dispone el proceso. Además, un detector puede dar algunas veces diferentes respuestas a diferentes procesos, dado que las condiciones de comunicación varían de un proceso a otro.

Podemos implementar un detector de fallos no fiable utilizando el siguiente algoritmo. Cada proceso p manda un mensaje « p está aquí» al resto de procesos, y lo hace cada T segundos. El detector de fallos utiliza una estimación del máximo tiempo de transmisión de un mensaje de D segundos. Si el detector de fallos local en un proceso q no recibe un mensaje « p está aquí» dentro de los $T + D$ segundos desde el último, entonces informa a q que p es *Sospechoso*. Sin embargo, si posteriormente recibe un mensaje « p está aquí», entonces informa a q de que p está correctamente.

En un sistema distribuido real hay límites prácticos en los tiempos de transmisión de mensajes. Incluso los sistemas de correo abandonan tras unos pocos días, dado que es probable que los enlaces de comunicación y los encaminadores hayan sido reparados en ese tiempo. Si elegimos valores pequeños para T y D (que sumen en total 0,1 segundos, por ejemplo) entonces el detector de fallos probablemente sospechará bastantes veces de procesos que no se han caído, y una buena parte del ancho de banda se dedicará a los mensajes « p está aquí». Si elegimos un valor de timeout total grande de (por ejemplo, una semana) entonces los procesos que se han caído serán considerados frecuentemente como *No sospechosos*.

Una solución práctica para este problema es usar valores de timeout que reflejen las condiciones de retraso observadas en la red. Si un detector de fallos local recibe un mensaje « p está aquí» en 20 segundos en lugar del máximo esperado de 10 segundos, entonces tendría que cambiar el valor del tiempo para p de acuerdo con la nueva información. El detector de fallos sigue siendo no fiable y sus respuestas a las preguntas deben seguir considerándose como indicios, pero la probabilidad de que sea exacto aumenta.

En un sistema sincrónico, el sistema detector antes descrito puede convertirse en fiable. Se puede elegir D de tal forma que no sea una estimación sino un límite absoluto en los tiempos de transmisión de mensajes; la ausencia de un mensaje « p está aquí» dentro de los $T + D$ segundos lleva al detector de fallos local a concluir que el proceso p se ha caído.

Los lectores pueden preguntarse si los detectores de fallo tienen alguna utilidad práctica. Por un lado, los detectores de fallos no fiables pueden sospechar de un proceso que no haya fallado (pueden ser *inexactos*); y pueden no sospechar de un proceso que de hecho haya fallado (pueden ser *incompletos*). Por otro lado, los detectores de fallos fiables requieren que el sistema sea sincrónico (y muy pocos sistemas lo son en la práctica).

Se han presentado los detectores de fallos porque ayudan a pensar en la naturaleza de los fallos en un sistema distribuido. Y cualquier sistema práctico que se diseñe para soportar fallos debe detectarlos, aunque no lo haga de una forma perfecta. No obstante, parece que incluso los detectores de fallos no fiables con algunas propiedades bien definidas pueden ayudar a proporcionar soluciones prácticas al problema de la coordinación de procesos en presencia de fallos. Se volverá a este tema en la Sección 11.5.

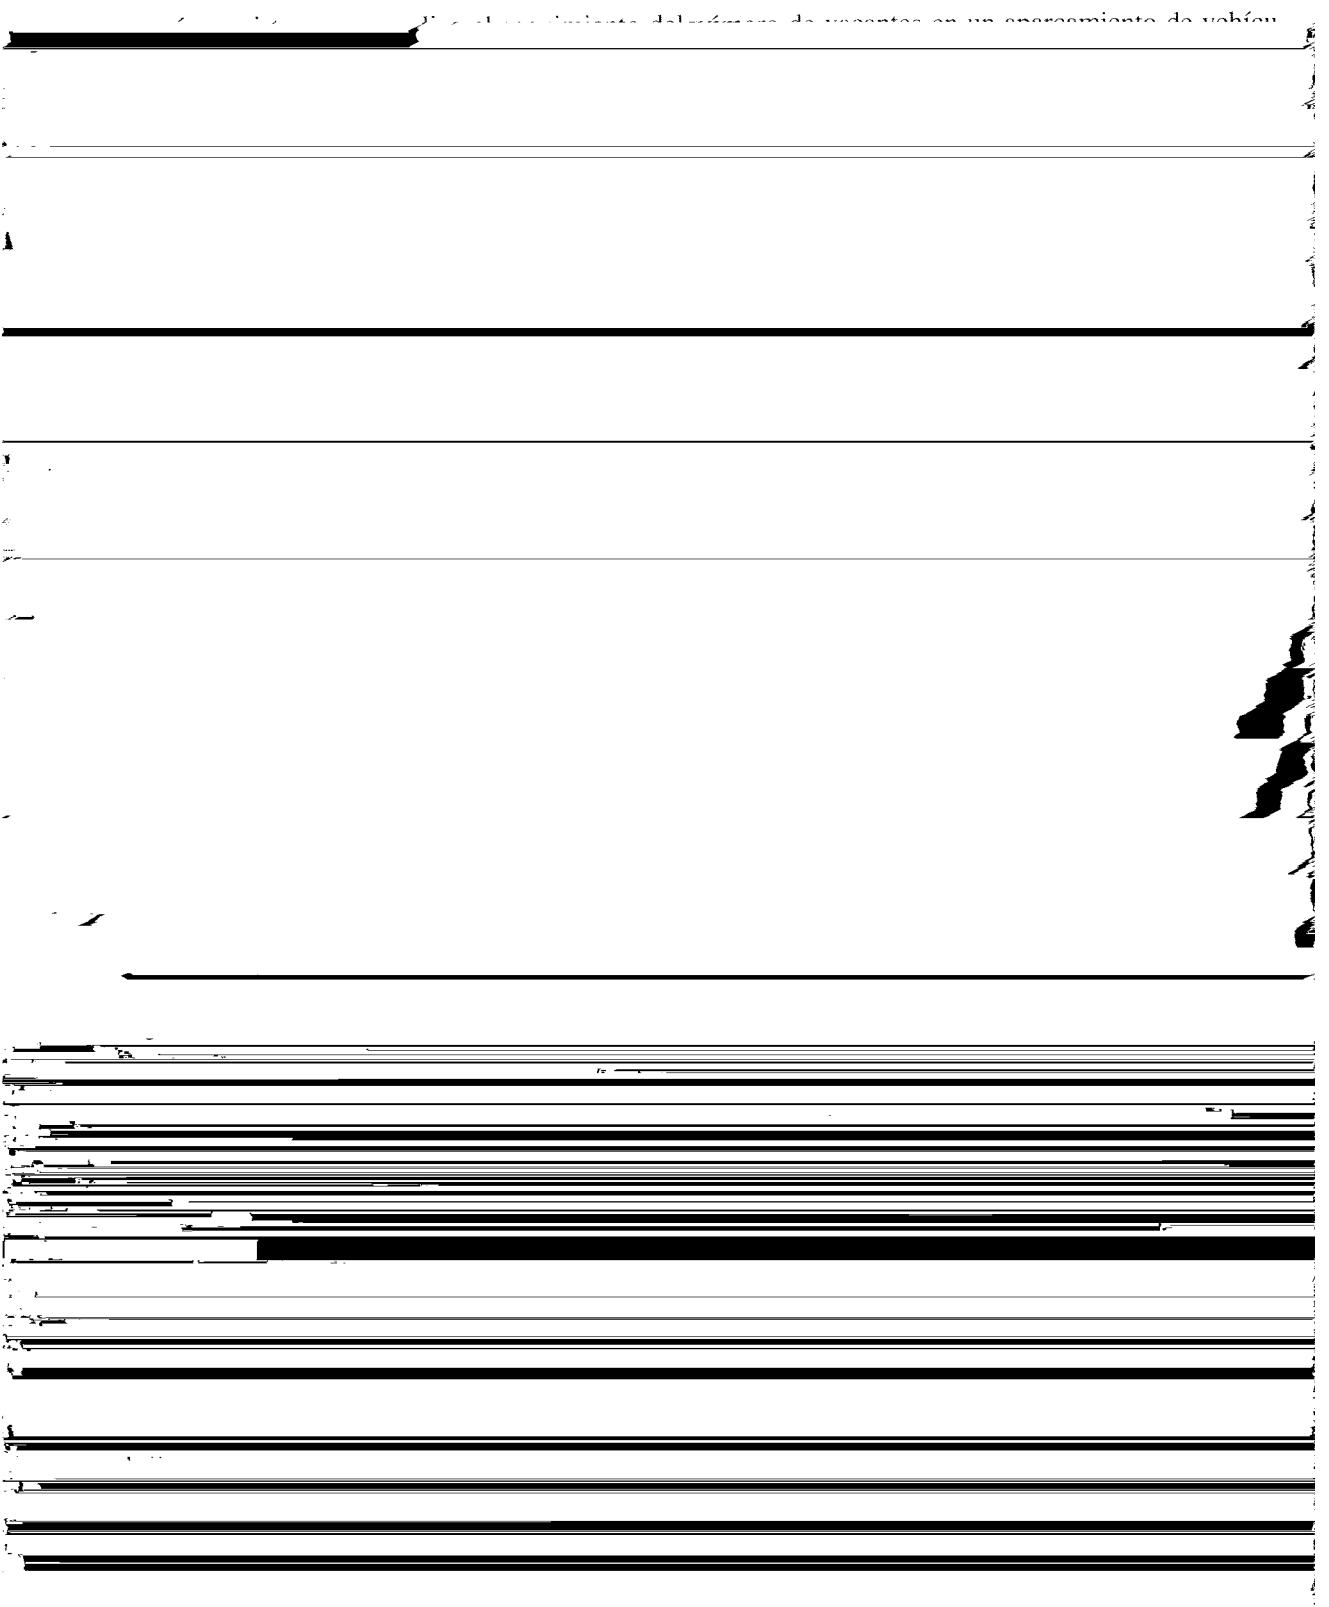
11.2. EXCLUSIÓN MUTUA DISTRIBUIDA

Los procesos distribuidos necesitan frecuentemente coordinar sus actividades. Si una colección de procesos comparte un recurso o una colección de recursos, entonces se requiere con frecuencia la exclusión mutua para prevenir interferencias y asegurar la consistencia cuando se accede a los recursos. Éste es el problema de la *sección crítica*, conocido en el dominio de los sistemas operativos. Sin embargo, en un sistema distribuido ni las variables compartidas ni las utilidades proporcionadas por un núcleo local pueden usarse para solucionarlo de forma general. Se requiere una solución para la *exclusión mutua distribuida*: una que esté basada exclusivamente en el paso de mensajes.

En algunos casos, los recursos compartidos son gestionados por servidores que, además, proporcionan mecanismos para la exclusión mutua. El Capítulo 12 describe cómo algunos servidores sincronizan los accesos de los clientes a los recursos. Pero en algunos casos prácticos se requiere un mecanismo separado de exclusión mutua.

Considérese el caso de los usuarios que actualizan un archivo de texto. Un método sencillo de asegurar que sus actualizaciones sean consistentes es permitirles que cada vez sólo uno tenga acceso, exigiendo al editor que bloquee el archivo antes de que se hagan las actualizaciones. Los servidores de archivos NFS, descritos en el Capítulo 8, se diseñan para que no tengan estado y, por lo tanto, no admiten el bloqueo de archivos. Por esta razón, los sistemas UNIX proporcionan un servicio de bloqueo de archivos separado, implementado mediante el proceso demonio *lockd*, para gestionar las peticiones de bloqueo por parte de los clientes.

Un ejemplo, particularmente interesante, se da donde no existen servidores de forma que una colección de procesos de igual importancia debe coordinar sus accesos a recursos compartidos por ellos mismos. Esto ocurre de forma habitual en redes tales como las de tipo Ethernet y las redes inalámbricas IEEE 802.11 en modo *ad hoc*, donde las interfaces de red cooperan como procesos iguales, de tal forma que sólo un nodo transmite cada vez en el medio compartido. Otro ejemplo



da a una sección crítica. Durante este tiempo, podría enviar un mensaje a otro proceso, el cual, a continuación, también intentaría entrar en la sección crítica. EM3 especifica que debe garantizarse el acceso al primer proceso antes que al segundo.

A continuación se evalúa el rendimiento de los algoritmos para la exclusión mutua de acuerdo a los siguientes criterios:

- El *ancho de banda* consumido, que es proporcional al número de mensajes enviados en cada operación *entrar y salir*.
- El *retraso del cliente* en el que incurre un proceso en cada operación *entrar y salir*.
- El efecto del algoritmo sobre la capacidad de procesamiento del sistema. Ésta es la tasa promedio a la que la colección de procesos, en su totalidad, puede acceder a la sección crítica, teniendo en cuenta que es necesaria alguna comunicación entre procesos sucesivos. Se mide el efecto por medio del *retraso en la sincronización* entre un proceso que sale de la sección crítica y el siguiente proceso que entra en ella; la capacidad de procesamiento es mayor cuando el retraso en la sincronización es menor.

No se tendrá en cuenta en nuestra descripción la implementación de accesos a recursos. Sin embargo, se asumirá que los procesos cliente se comportan bien y emplean un tiempo finito accediendo a los recursos dentro de sus secciones críticas.

◊ **El algoritmo del servidor central.** La forma más simple de conseguir exclusión mutua es emplear un servidor que dé los permisos para entrar en la sección crítica. La Figura 11.2 muestra el uso de este servidor. Para entrar en una sección crítica, un proceso envía un mensaje de petición al servidor y espera una respuesta por su parte. Conceptualmente, la respuesta constituye un testigo que significa permiso para entrar en la sección crítica. Si ningún otro proceso tiene el testigo en el instante de la petición, entonces el servidor responde inmediatamente, dándoselo. Si en ese momento lo tiene otro proceso, entonces el servidor no responde sino que lo pone en una cola la petición. Cuando un proceso sale de la sección crítica envía un mensaje al servidor, devolviéndole el testigo.

Si la cola de procesos en espera no está vacía, entonces el servidor escoge la entrada más antigua en la cola, la elimina y responde al proceso correspondiente. El proceso seleccionado mantiene entonces el testigo. En la figura, se muestra una situación en la cual la petición de p_2 ha sido añadida a la cola, que ya contenía la petición de p_4 . A continuación, p_3 sale de la sección crítica, y el servidor elimina la entrada de p_4 y le responde, concediéndole permiso para entrar. El proceso p_1 no requiere en ese momento entrada en la sección crítica.

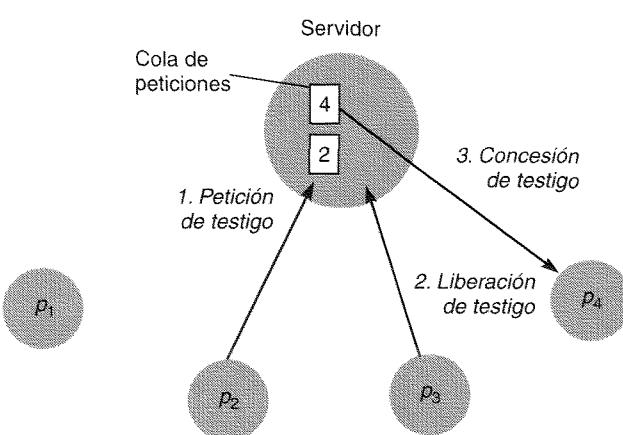
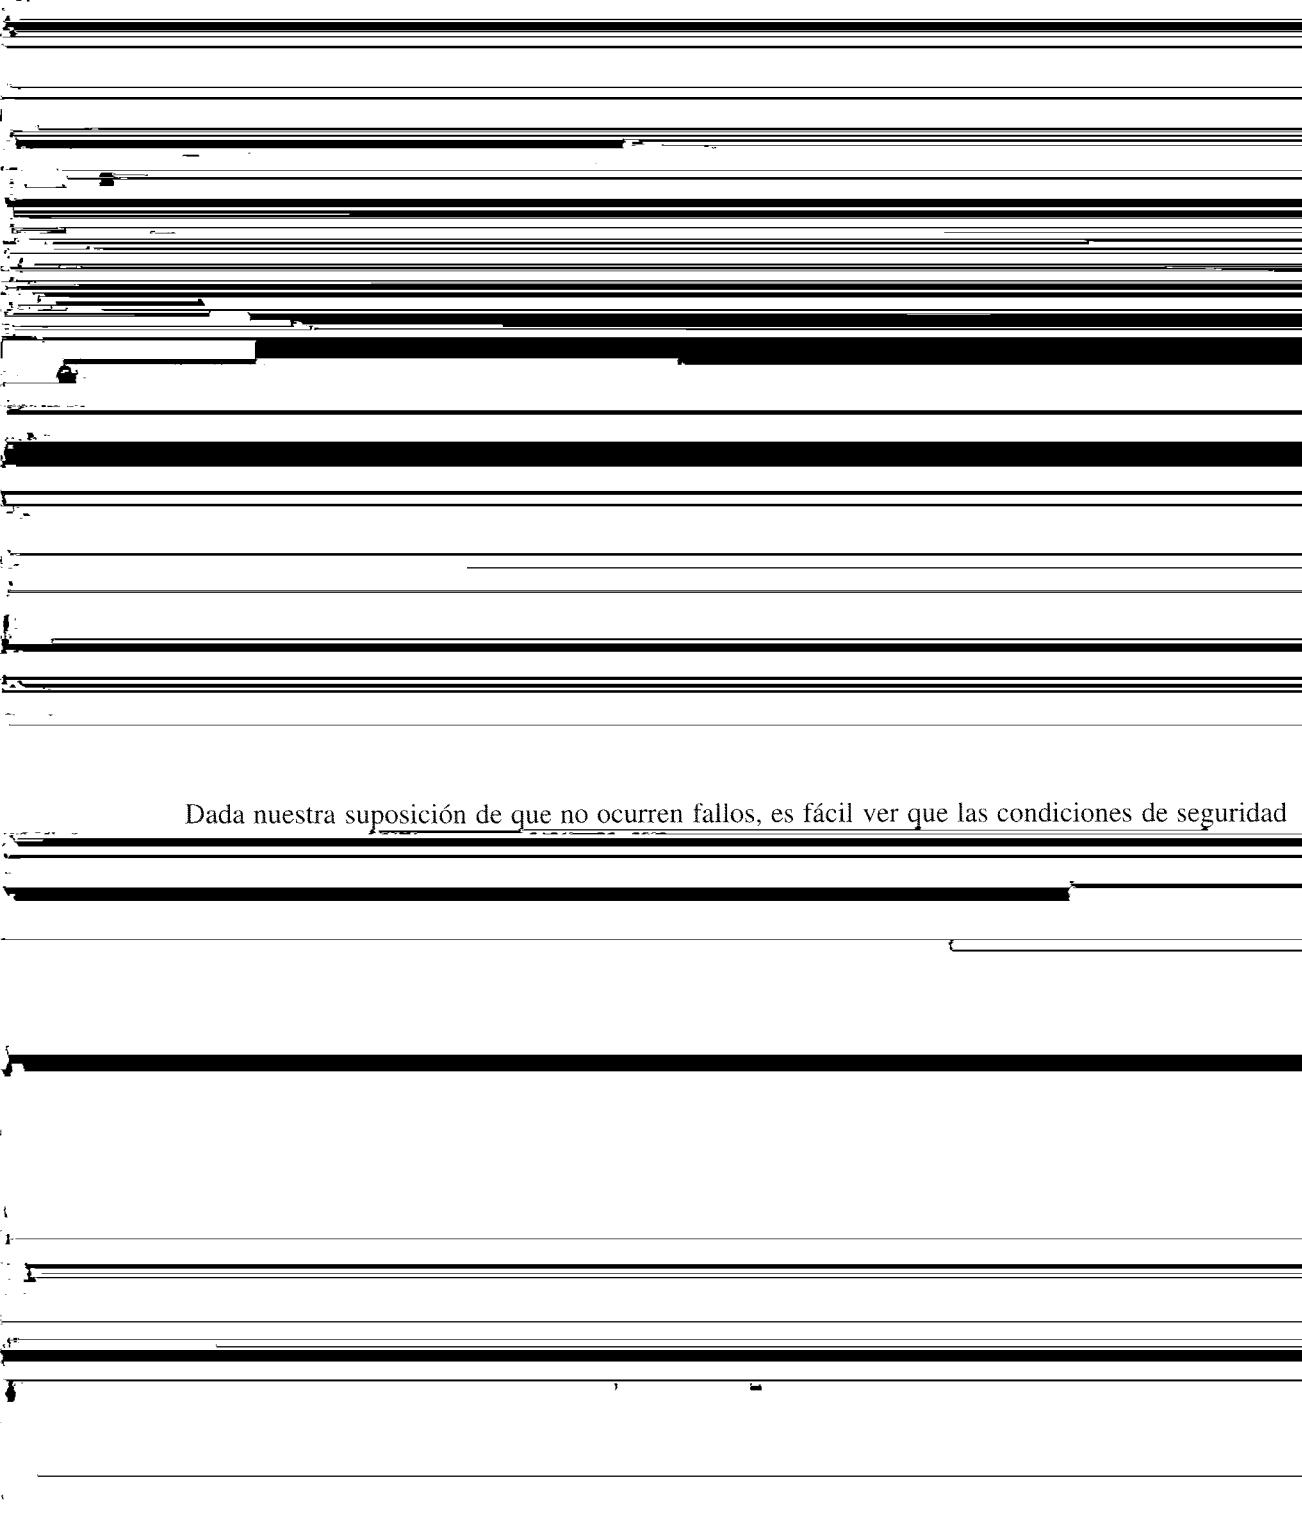


Figura 11.2. Servidor que gestiona un testigo de exclusión mutua para un conjunto de procesos.

Dada nuestra suposición de que no ocurren fallos, es fácil ver que las condiciones de seguridad



En la inicialización
 estado := LIBERADA;

Para entrar en la sección crítica

```

  estado := BUSCADA;
  Multitransmite petición a todos los procesos; } Se aplaza aquí el procesamiento de peticiones
  T := marca temporal de la petición;
  Espera hasta que (número de respuestas recibidas = (N - 1));
  estado := TOMADA;
```

Al recibir una petición <T_i, p_i> en el proceso p_i (i ≠ j)
si (estado = TOMADA o (estado = BUSCADA y (T, p) < (T_i, p_i)))
entonces

```

  pon en la cola la petición por parte de pi sin responder;
  sino
    responde inmediatamente a pi;
finsi
```

Para salir de la sección crítica
 estado := LIBERADA;
 responde a cualquiera de las peticiones en la cola;

Figura 11.4. Algoritmo de Ricart y Agrawala.

mente un mensaje. El retraso en la sincronización entre la salida de un proceso de la sección crítica y la entrada del siguiente proceso está en algún punto entre 1 y N transmisiones de mensajes.

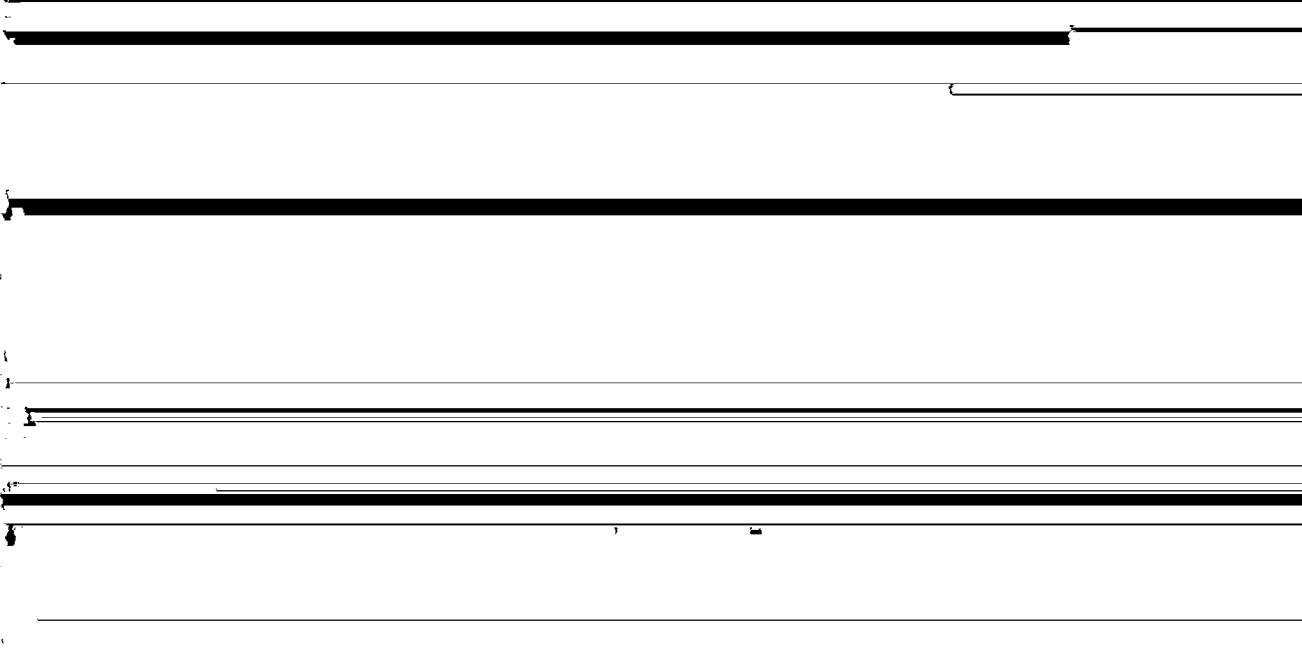
◊ **Un algoritmo que usa multidifusión y relojes lógicos.** Ricart y Agrawala [1981] desarrollaron un algoritmo para implementar la exclusión mutua entre N procesos de importancia pareja basado en la técnica de multidifusión. La idea básica es que los procesos que necesitan entrar en una sección crítica envían un mensaje de petición mediante multidifusión y pueden entrar en ella solamente cuando el resto de los procesos haya respondido al mensaje. Las condiciones bajo las cuales un proceso responde a una petición se diseñan para asegurar que se cumplan las condiciones EM1 a EM3.

Los procesos p_1, p_2, \dots, p_N llevan distintos identificadores numéricos. Se supone que disponen de canales de comunicación con el resto y cada proceso p_i mantiene un reloj tipo Lamport, actualizado de acuerdo con las reglas RL1 y RL2 de la Sección 10.4. Aquellos mensajes que soliciten entrar tienen la forma $\langle T, p_i \rangle$ donde T es el marca de tiempo del emisor y p_i es su identificador.

Cada proceso registra en una variable *estado* el estar fuera de la sección crítica (LIBERADA), de querer entrar (BUSCADA) o de estar en la sección crítica (TOMADA). El protocolo se muestra en la Figura 11.4.

Si un proceso solicita entrar y el estado de todos los procesos es LIBERADA, entonces todos los procesos contestarán inmediatamente al que hizo la solicitud y éste obtendrá la entrada. Si algún proceso estuviese en el estado TOMADA no responderá a las peticiones hasta que haya finalizado con la sección crítica; por lo tanto, durante ese tiempo no se concederá la entrada al proceso que realizó la solicitud. Si dos o más procesos solicitan la entrada al mismo tiempo entonces la petición que exhiba una marca temporal más baja será la que recoja las $N - 1$ respuestas, garantizando que será el siguiente en entrar. Si las dos peticiones llevan marcas temporales tipo Lamport iguales, las solicitudes se ordenan de acuerdo a los identificadores correspondientes a cada proceso. Nótese que cuando un proceso solicita la entrada, aplaza el procesamiento de peticiones por parte de otros procesos hasta que su propia solicitud haya sido enviada y se haya grabado la marca temporal T de la misma. Ésta es la razón por la que los procesos realizan decisiones consistentes cuando procesan peticiones.

Dada nuestra suposición de que no ocurren fallos, es fácil ver que las condiciones de seguridad



conjuntos de sus pares, siempre que los subconjuntos utilizados por cualquier par de procesos se solapen. Podemos pensar en los procesos votando para que otro pueda entrar en la sección crítica. Un proceso «candidato» debe recoger suficientes votos para entrar. Los procesos en la intersección de dos conjuntos de votantes aseguran la propiedad de seguridad EM1 (que a lo sumo un proceso pueda entrar en la sección crítica) dando su voto a un único candidato.

Maekawa asoció un *conjunto de votantes* V_i con cada proceso p_i ($i = 1, 2, \dots, N$), donde $V_i \subseteq \{p_1, p_2, \dots, p_N\}$. Los conjuntos V_i se eligen de tal forma que, para todo $i, j = 1, 2, \dots, N$:

- $p_i \in V_i$.
- $V_i \cap V_j \neq \emptyset$ – hay al menos un miembro común a cada par de conjuntos de votantes.
- $|V_i| = K$ – para ser equitativos, cada proceso ha de tener conjuntos de votantes del mismo tamaño.
- Cada proceso p_j está contenido en M de los conjuntos de votantes V_i .

Maekawa demostró que la solución óptima, que minimiza K y permite a los procesos conseguir la exclusión mutua, tiene $K \sim \sqrt{N}$ y $M = K$ (de tal forma que cada proceso está en tantos conjuntos de votantes como elementos hay en cada uno de esos conjuntos). El cálculo de los conjuntos óptimos R_i no es trivial. De forma aproximada, una manera simple de encontrar estos conjuntos R_i tales que $|R_i| = 2\sqrt{N}$ es colocar los procesos en una matriz de \sqrt{N} por \sqrt{N} y hacer que V_i sea la unión de la fila y la columna que contiene a p_i .

El algoritmo de Maekawa se muestra en la Figura 11.6. Para poder entrar a la sección crítica, un proceso p_i envía mensajes de *petición* a todos los $K - 1$ miembros de V_i . p_i no puede entrar a la sección crítica hasta que no haya recibido $K - 1$ mensajes de *respuesta*. Cuando un proceso p_j en V_i recibe un mensaje de *petición* de p_i , envía un mensaje de *respuesta* inmediatamente, a no ser que su estado sea TOMADA o ya haya contestado («votado») desde que recibió el último mensaje de *liberada*. Si no es éste el caso, guarda en una cola el mensaje de petición (en el orden de llegada), pero no responde todavía. Cuando un proceso recibe un mensaje de *liberada*, elimina la cabeza de su cola de peticiones pendientes (si la cola no está vacía) y envía un mensaje de *respuesta* (un «voto»). Para dejar la sección crítica, p_i envía mensajes de *liberada* a los $K - 1$ miembros de V_i .

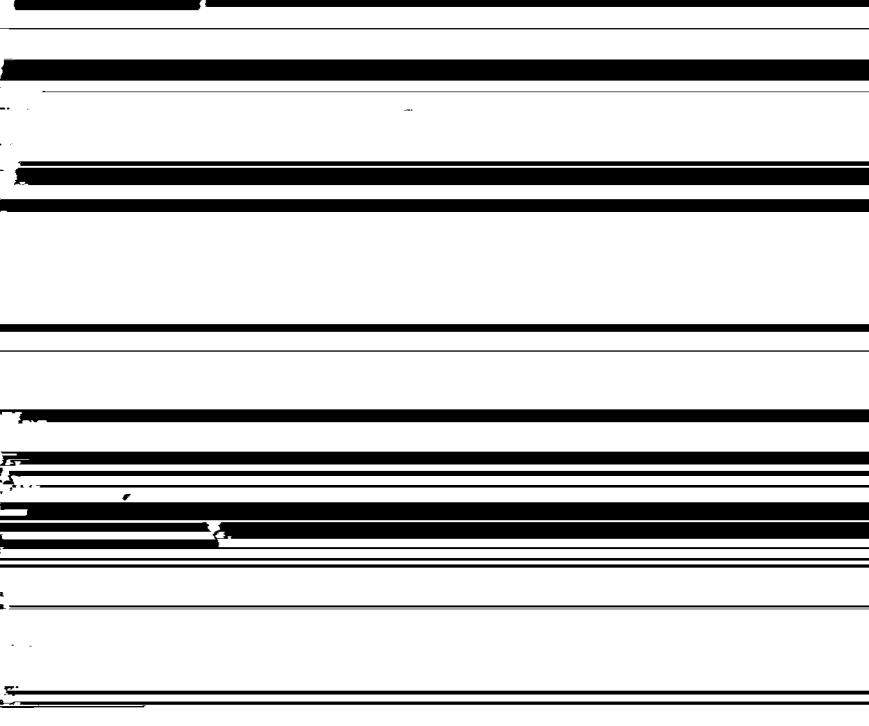
Este algoritmo cumple la propiedad de seguridad EM1. Si fuese posible que dos procesos p_i y p_j entrasen en la sección crítica al mismo tiempo, implicaría que los procesos en $V_i \cap V_j \neq \emptyset$ deberían haber votado por ambos a la vez. Sin embargo, el algoritmo permite a los procesos realizar, a lo sumo, un voto entre recepciones sucesivas de un mensaje *liberada*; por lo tanto, la situación es imposible.

Desgraciadamente, el algoritmo es propenso a las situaciones de estancamiento. Considérense tres procesos p_1 , p_2 y p_3 , con $V_1 = \{p_1, p_2\}$, $V_2 = \{p_2, p_3\}$ y $V_3 = \{p_3, p_1\}$. Si los tres procesos solicitan entrada a la sección crítica de forma concurrente, entonces es posible que p_1 responda a p_2 pero que haga esperar a p_3 ; que p_2 responda a p_3 pero haga esperar a p_1 ; y que p_3 responda a p_1 pero haga esperar a p_2 . Cada proceso ha recibido una de las dos respuestas por las que espera y ninguno puede seguir adelante.

El algoritmo puede modificarse de tal forma que no se produzcan estancamientos [Saunders 1987]. En la versión modificada del protocolo, los procesos almacenan las peticiones pendientes en orden sucedió-antes, con lo cual, también se satisface el requisito EM3.

La utilización del ancho de banda por parte del algoritmo es de $2\sqrt{N}$ mensajes por entrada en la sección crítica y de \sqrt{N} mensajes por salida (asumiendo que no existan utilidades hardware para realizar la multidifusión). El número total de $3\sqrt{N}$ es superior al de $2(N - 1)$ mensajes que requiere el algoritmo de Ricart y Agrawala, siempre que $N > 4$. La espera para el cliente es la misma que la del algoritmo de Ricart y Agrawala, pero la espera en la sincronización es peor: un viaje de ida y vuelta en lugar de un tiempo de transmisión de un mensaje individual.

En la inicialización
estado := LIBERADA



awa.

es con respecto a su tolerancia a

- ¿Qué ocurre cuando un proceso se cae?

Ninguno de los algoritmos descritos anteriormente toleraría la pérdida de mensajes, en el caso de que los canales no fuesen fiables. El algoritmo basado en anillo no puede tolerar un fallo por caída de ningún proceso individual. Como ya se vio, el algoritmo de Maekawa puede tolerar que algunos procesos se caigan: si un proceso que se ha caído no está en un conjunto de votantes que están siendo requeridos, entonces ese fallo no afectará al resto de procesos. El algoritmo del servidor central puede soportar la caída de un proceso cliente que ni tenga ni haya pedido el testigo. El algoritmo de Ricart y Agrawala, tal y como ha quedado descrito, puede adaptarse para tolerar la rotura de un proceso haciendo que, de forma implícita, conceda todas las peticiones.

Se invita al lector a considerar cómo adaptar los algoritmos para tolerar fallos suponiendo que esté disponible un detector de fallos fiable. Incluso con un detector de fallos fiable se ha de tener cuidado para tomar en consideración un fallo en cualquier instante de tiempo (incluso durante el proceso de recuperación) y para reconstruir el estado de los procesos tras haberse detectado un fallo. Por ejemplo, en el algoritmo del servidor central, si el servidor falla entonces se debe establecer si él tiene el testigo o si lo tiene uno de los procesos cliente.

Se examinará en la Sección 11.5 el problema general de cómo los procesos deben coordinar sus acciones en presencia de fallos.

11.3. ELECCIONES

Un algoritmo para escoger un proceso único que juegue un papel específico se llama *algoritmo de elección*. Por ejemplo, en una variante de nuestro algoritmo de «servidor central» para exclusión mutua, el «servidor» se escoge entre los procesos p_i , $i = 1, 2 \dots, N$ que necesitan usar la sección crítica. Se necesita un algoritmo de selección para escoger cuál de los procesos jugará el papel de servidor. Es esencial que todos los procesos estén de acuerdo en la elección. Tras ésta, si el proceso que juega el papel de servidor desea retirarse, entonces se requiere otro proceso de selección para escoger un sustituto.

Se dirá que un proceso *pide una elección* si lleva a cabo una acción que inicie una ejecución específica del algoritmo de elección. Un proceso individual no pide más de una elección cada vez, pero, en principio, los N procesos podrían pedir N elecciones concurrentes. Un proceso p_i , en cualquier instante de tiempo, es o bien un *participante* (lo que significa que está comprometido en alguna ejecución del algoritmo de elección) o bien, un *no participante* (lo que significa que no está comprometido actualmente en ninguna elección).

Un requisito importante es que la selección del proceso elegido sea única, incluso si distintos procesos piden elecciones de forma concurrente. Por ejemplo, dos procesos podrían decidir de forma independiente que un proceso coordinador ha fallado y pedir ambos elecciones.

Sin pérdida de generalidad, se requiere que el proceso elegido sea escogido como aquél con el mayor identificador. El »identificador» puede ser cualquier valor útil siempre que los identificadores sean únicos y estén totalmente ordenados. Por ejemplo, podríamos elegir el proceso con la menor carga computacional, teniendo que usar cada proceso $<1/carga, i>$ como su identificador, donde la $carga > 0$ y el índice del proceso i se usa para ordenar los identificadores con la misma carga.

Cada proceso p_i , ($i = 1, 2 \dots, N$) posee una variable $elegido_i$, que contendrá el identificador del proceso elegido. Cuando el proceso se convierta en participante en una elección por primera vez, fijará la variable al valor especial \perp para señalar que no ha sido definido todavía.

Nuestros requisitos serán que durante una ejecución en particular del algoritmo:

E1: (seguridad)

Un proceso participante p_i tiene $elegido_i = \perp$ o $elegido_i = P$, donde P se elige como el proceso con el identificador mayor que no se ha caído al final de la ejecución.

E2: (pervivencia)

Todos los procesos p_i participan y, al final, fijan $elegido_i \neq \perp$; o bien se han caído.

Observe que puede haber procesos p_j que no son aún participantes y que almacenan en $elegido_j$ el identificador del proceso elegido anteriormente.

Se mide el rendimiento de un algoritmo de elección por su utilización del ancho de banda total de la red (que es proporcional al número total de mensajes enviados) y por el *tiempo de vuelta (turnaround)* para el algoritmo, número de veces de transmisión de mensajes serializados entre el comienzo y la finalización de una ejecución individual.

◊ **Un algoritmo de elección basado en anillo.** A continuación se presenta el algoritmo de Chang y Roberts [1979], que es apropiado para una colección de procesos dispuestos en un anillo lógico. En éste cada proceso p_i tiene un canal de comunicación con el siguiente proceso del anillo, $p_{(i+1)modN}$, y todos los mensajes se mandan en el sentido de las agujas del reloj alrededor del anillo. Se supone que no ocurren fallos y que el sistema es asíncrono. El objetivo del algoritmo es elegir un proceso individual llamado el *coordinador*, que es el proceso con el identificador más grande.

Inicialmente, cada proceso se etiqueta como *no participante* en una elección. Cualquier proceso puede comenzar una elección. Para ello se marca a sí mismo como un *participante*, colocando

su identificador en un mensaje de *elección* y enviándolo hacia el próximo vecino en el sentido de las agujas del reloj.

Cuando un proceso recibe un mensaje de *elección*, compara el identificador que viene en el mensaje con el suyo. Si el identificador que le llega es mayor, entonces hace avanzar el mensaje hacia su vecino. Si el identificador que llega es más pequeño y el receptor es un *no participante*, entonces cambia el identificador del mensaje por el suyo y lo vuelve a enviar; si en este mismo caso, el receptor ya fuera un *participante*, no lo enviaría nuevamente. En cualquier caso, en el momento en el que se envía un mensaje de *elección*, el proceso se etiqueta a sí mismo como *participante*.

Sin embargo, si el identificador que se recibe es el del propio receptor, entonces ese identificador ha de ser el mayor y se convierte en el coordinador. El coordinador se señala a sí mismo como *no participante* una vez más y envía un mensaje de *elegido* a su vecino, anunciando su elección e incluyendo en el mensaje su identidad.

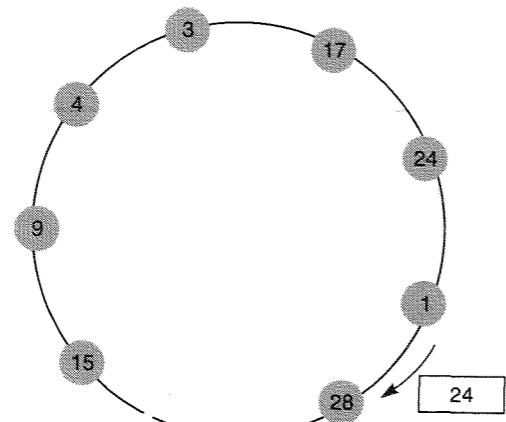
Cuando un proceso p_i recibe un mensaje de *elegido*, se marca a sí mismo como *no participante*, fija su variable $elegido_i$ al valor del identificador que hay en el mensaje y, a no ser que sea el nuevo coordinador, envía el mensaje a su vecino.

Se observa fácilmente que se cumple la condición E1. Se comparan todos los identificadores, ya que un proceso ha de recibir su propio identificador antes de enviar un mensaje de *elegido*. Para cualquier par de procesos, aquél con el identificador más grande no pasará el identificador del más pequeño. Por lo tanto, es imposible que ambos reciban sus propios identificadores de vuelta.

La condición E2 se obtiene de forma inmediata ya que se garantiza que se atraviesa el anillo (no hay fallos). Nótese cómo los estados *no participante* y *participante* se utilizan de tal manera que, si surgen mensajes cuando otro proceso comienza una elección al mismo tiempo, desaparecen tan pronto como sea posible y siempre antes de que el resultado de «ganador» de la elección haya sido anunciado.

Si un único proceso comienza una elección, entonces el caso de peor rendimiento ocurre cuando su vecino de al lado, en sentido anti-horario, tiene el identificador mayor. En ese caso, se necesitan $N - 1$ mensajes para llegar a ese vecino, que no anunciará su elección hasta que haya completado otra vuelta al anillo, dando lugar a N nuevos mensajes. Después, el mensaje *elegido* se envía N veces, totalizando $3N - 1$ mensajes. El tiempo necesario para completar la tarea es también $3N - 1$, ya que todos los mensajes se envían secuencialmente.

En la Figura 11.7 se muestra el funcionamiento de una elección basada en anillo. El mensaje de *elección* contiene 24 en ese momento, pero cuando llegue al proceso 28, éste lo reemplazará con su identificador.



Nota: La elección fue iniciada por el proceso 17. El identificador de proceso más elevado encontrado a continuación es el 24. Los procesos participantes están indicados con un tono más oscuro.

Figura 11.7. Progreso de una elección basada en anillo.

Aunque el algoritmo basado en anillo es útil para comprender las características de los algoritmos de elección en general, el hecho de que no tolere fallos hace que tenga escaso valor práctico. No obstante, si se dispone de un detector de fallos fiable es posible, en principio, rehacer el anillo cuando un proceso se cae.

◊ **El algoritmo abusón (bully).** El algoritmo del abusón [García-Molina 1982] permite la caída de procesos durante una elección, aunque supone que la entrega de mensajes entre procesos es fiable. A diferencia del algoritmo basado en anillo, este algoritmo supone que el sistema es síncrono, esto es, que utiliza timeouts para detectar un fallo en un proceso. Otra diferencia es que el algoritmo basado en anillo supone que los procesos tienen un conocimiento mínimo *a priori* de cada uno de los otros procesos: cada uno sabe cómo comunicarse únicamente con su vecino y ninguno conoce los identificadores de los otros procesos. Por otro lado, el algoritmo del abusón supone que cada proceso conoce qué procesos tienen identificadores mayores y que puede comunicarse con todos esos procesos.

Hay tres tipos de mensajes en este algoritmo. Un mensaje de *elección* se envía para anunciar un proceso de elección; un mensaje de *respuesta* se envía para responder a un mensaje de elección; y un mensaje *coordinador* se envía para anunciar la identidad del proceso elegido, el nuevo «coordinador». Un proceso comienza una elección cuando se da cuenta, a través de los timeouts, que el coordinador ha fallado. Además, varios procesos pueden descubrirlo de forma concurrente.

Dado que el sistema es síncrono, se puede construir un detector de fallos fiable. Existe un retraso máximo en la transmisión de un mensaje T_{trans} y un retraso máximo para el procesado de un mensaje $T_{procesado}$. Por lo tanto, podemos calcular un tiempo $T = 2T_{trans} + T_{procesado}$ que es el límite superior sobre el tiempo total transcurrido desde que se envió un mensaje a otro proceso hasta que se recibió la respuesta. Si no llega una respuesta dentro de ese tiempo T , entonces el detector de fallos local puede informar que el supuesto receptor de la petición ha fallado.

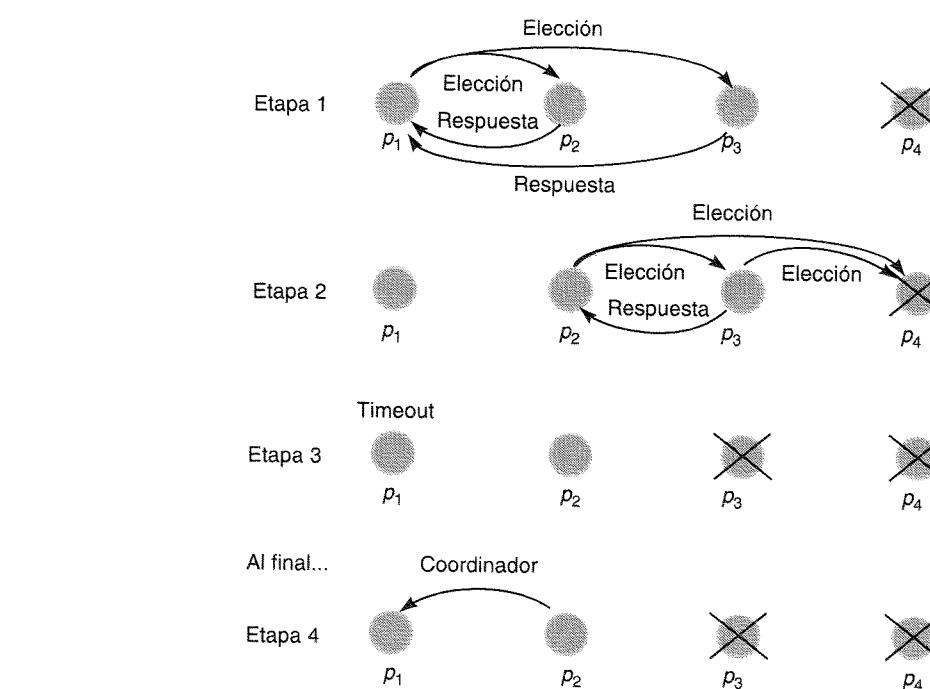
El proceso que sabe que posee el identificador más alto puede elegirse a sí mismo como el coordinador, simplemente enviando un mensaje *coordinador* a todos los procesos con identificadores más bajos. Por otro lado, un proceso con identificador más bajo comienza una elección con un mensaje de *elección* hacia aquellos procesos que tienen un identificador más alto y espera un mensaje de *respuesta*. Si no le llega ninguno dentro de un tiempo T , el proceso se considera a sí mismo el coordinador y envía un mensaje *coordinador* anunciándolo a todos los procesos con un identificador menor. Si ha recibido un mensaje de *respuesta*, el proceso espera otro período T' por que le llegue un mensaje *coordinador* procedente del nuevo coordinador. Si no llega ninguno, comienza otra elección.

Si un proceso p_i recibe un mensaje *coordinador*, fija su variable $elegido_i$ al identificador del coordinador que está contenido en el propio mensaje y trata a ese proceso como el coordinador.

Si un proceso recibe un mensaje de *elección*, devuelve un mensaje de *respuesta* y comienza otra elección a no ser que él ya haya comenzado una.

Si para sustituir a un proceso caído se lanza uno nuevo, éste comienza una elección. Si tiene el identificador de proceso más alto, entonces decidirá que es el coordinador y lo anunciará a otros procesos. Así se convertirá en el coordinador, aunque el coordinador actual siga funcionando. Esta es la razón por la que a este algoritmo se le llama algoritmo «del abusón».

El funcionamiento del algoritmo se muestra en la Figura 11.8. Hay cuatro procesos $p_1 - p_4$. El proceso p_1 detecta el fallo del coordinador p_4 y anuncia una elección (etapa 1 en la figura). Cuando reciben el mensaje de elección proveniente de p_1 , los procesos p_2 y p_3 mandan mensajes de *respuesta* a p_1 y comienzan sus propias elecciones; si bien p_3 envía un mensaje de *respuesta* a p_2 , p_3 no recibe mensaje de *respuesta* del proceso fallido p_4 (etapa 2). Por lo tanto, p_3 decide que es el nuevo coordinador. Pero antes de que pueda enviar el mensaje *coordinador*, él también falla (etapa 3). Cuando el timeout T' de p_1 expira (suponemos que ocurre antes de que expire el tiempo



La elección del coordinador p_2 después del fallo de p_4 y p_3

Figura 11.8. El algoritmo del abusón.

límite de p_2) deduce la ausencia de un mensaje *coordinador* y comienza otra elección. Al final, p_2 es elegido coordinador (etapa 4).

Este algoritmo cumple claramente la condición de pervivencia E2, ya que supone que la entrega de mensajes es fiable. Y en el caso en que no se reemplace proceso alguno, entonces también cumple la condición E1. Es imposible que dos procesos decidan que ambos son el coordinador, dado que el proceso con el identificador menor descubrirá que el otro existe y cederá ante él.

Sin embargo, *no* se puede garantizar que el algoritmo cumpla la condición de seguridad E1 si los procesos que se han caído son reemplazados por procesos con el mismo identificador. Un proceso que reemplaza a otro proceso p caído puede decidir que posee el identificador más alto justo cuando otro proceso, que ha detectado la caída de p , ha decidido que posee el identificador más alto. Los dos procesos se anunciarán de forma concurrente como los coordinadores. Desgraciadamente, no existen garantías en el orden de entrega de los mensajes, y los receptores de los mensajes pueden alcanzar conclusiones diferentes sobre qué proceso es el coordinador.

Además, la condición E1 puede romperse si los valores de los tiempos límites que se han supuesto resultan ser imprecisos, o lo que es lo mismo, si el detector de fallos en los procesos no es fiable.

Volviendo al ejemplo anterior, supongamos que p_3 no había fallado pero estaba funcionando de una forma inusualmente lenta (dicho de otra forma, la suposición de que el sistema es síncrono es incorrecta) o bien que p_3 ha fallado y ha sido reemplazado. Justo cuando p_2 manda su mensaje *coordinador*, p_3 (o su sustituto) hace lo mismo. p_2 recibe el mensaje *coordinador* de p_3 cuando ya ha enviado el suyo y, por lo tanto, determina que $elegido_2 = p_3$. A continuación, debido a los retrasos variables en la transmisión de mensajes, p_1 recibe el mensaje *coordinador* de p_2 tras el mensaje de p_3 y al final decide fijar $elegido_1 = p_2$. Por lo tanto, la condición E1 no se ha cumplido.

En lo que respecta al rendimiento del algoritmo, en el mejor caso, el proceso con el segundo identificador más alto se da cuenta del fallo en el coordinador. En ese caso se puede elegir inme-

diatamente a sí mismo como coordinador y manda $N - 2$ mensajes de *coordinador*. El tiempo necesario para completar la tarea es de un mensaje. Sin embargo, el algoritmo del abusón requiere un número de mensajes de $O(N^2)$ en el peor caso (esto es, cuando el proceso con el identificador menor detecta en primer lugar el fallo en el coordinador). En ese caso serán $N - 1$ procesos quienes comiencen a la vez el proceso de elecciones, cada uno mandando mensajes a los procesos con los identificadores mayores.

11.4. COMUNICACIÓN POR MULTIDIFUSIÓN

La Sección 4.5.1 describía la multidifusión IP, que es una implementación de la comunicación en grupo. La comunicación en grupo, o multidifusión, requiere la presencia de coordinación y acuerdo. Su objetivo es que cada uno de los procesos de un grupo reciba los mensajes enviados al grupo, frecuentemente, con garantías de que han sido entregados. Estas garantías incluyen el acuerdo sobre el grupo de mensajes que todo proceso del grupo debería recibir y sobre el orden de entrega dentro de los miembros del grupo.

Los sistemas de comunicación en grupo son extremadamente sofisticados. Incluso la multidifusión IP, que proporciona unas garantías de entrega mínimas, requiere grandes esfuerzos de realización. Como preocupaciones principales están la eficiencia en el tiempo consumido y en el uso de ancho de banda, que suponen un reto incluso para grupos estáticos de procesos. Estos problemas se multiplican cuando los procesos pueden unirse o dejar los grupos de forma arbitraria.

Aquí se estudiará la multidifusión para grupos de procesos cuyos miembros son conocidos. El Capítulo 14 ampliará este estudio para la comunicación en grupo con todas sus variantes, incluyendo la gestión de grupos que varían de forma dinámica.

La comunicación por multidifusión ha sido el objeto de estudio de varios proyectos entre los que se incluyen el sistema V [Cheriton y Zwaenepoel 1985], Chorus [Rozier y otros 1988], Amoeba [Kaashoek y otros 1989, Kaashoek y Tanenbaum 1991], Trans/Total [Melliar-Smith y otros 1990], Delta-4 [Powell 1991], Isis [Birman 1993], Horus [van Renesse y otros 1996], Totem [Moser y otros 1996] y Transis [Dolev y Malki 1996], junto con otros trabajos reseñables que se irán citando a lo largo de esta sección.

La característica esencial de la comunicación por multidifusión es que un proceso realiza solamente una operación *multicast* para enviar un mensaje a cada uno de los miembros de un grupo (en Java esta operación es `unSocket.send(unMensaje)`) en lugar de realizar múltiples operaciones *enviar* sobre los procesos individuales. La comunicación a *todos* los procesos de un sistema, en contraposición a un subgrupo de los mismos, se conoce como difusión (*broadcast*).

El uso de una única operación *multicast* en lugar de múltiples operaciones *enviar* implica mucho más que una ventaja para el programador. Permite una implementación eficiente y que ésta proporcione garantías de entrega más fuertes que las que serían posible obtener de otra forma.

Eficiencia: la certeza de que el mismo mensaje va a ser entregado a todos los procesos de un grupo permite a la implementación ser eficiente en el uso del ancho de banda. La implementación puede proceder de tal forma que sólo envíe el mensaje una vez sobre cada enlace de comunicación, mediante el envío de un mensaje sobre un árbol de distribución. Incluso puede valerse del hardware de la red que proporcione multidifusión allí donde esté disponible. Además dicha implementación puede también minimizar el tiempo total empleado en entregar el mensaje a todos los destinos, en lugar de transmitirlo de forma separada y en serie.

Para ver estas ventajas basta comparar la utilización del ancho de banda y el tiempo total de transmisión empleado cuando se envía el mismo mensaje desde un computador en Londres a dos computadores en la misma Ethernet en Palo Alto, en el caso (a) utilizando dos órdenes UDP *enviar*, y en el caso (b) mediante una única operación de multidifusión IP. En el primer

caso, se mandan dos copias del mensaje de forma independiente y la segunda se retrasa en función de la primera. En el segundo caso, un conjunto de encaminadores atentos a la multidifusión envía una única copia del mensaje desde Londres al encaminador en la LAN de destino. El encaminador final utiliza entonces hardware de multidifusión (proporcionado por la Ethernet) para entregar el mensaje a los dos destinos, en lugar de tener que enviarlo dos veces.

Garantías de entrega: si un proceso realiza múltiples operaciones *envía* independientes a procesos individuales, entonces la implementación no tiene medios para proporcionar garantías de entrega que afecten al grupo de procesos en su conjunto. Si el remitente falla en la mitad del proceso de envío, entonces algunos miembros del grupo recibirán el mensaje mientras que otros no lo recibirán. Además, no está definido el orden relativo entre dos mensajes entregados a dos miembros de un grupo. En el caso particular de la multidifusión IP, no se ofrecen garantías de ordenación ni de fiabilidad. Sin embargo, pueden proporcionarse mayores garantías de multidifusión y en breve definiremos algunas.

◊ **Modelo del sistema.** El sistema contiene una colección de procesos que pueden comunicarse entre ellos de forma fiable a través de canales uno-a-uno. Como se había supuesto antes, los procesos sólo pueden fallar por caída.

Dichos procesos son miembros de grupos, que son los destinos de los mensajes enviados en una operación *multicast*. Por lo general, es útil permitir que los procesos sean miembros de distintos grupos de forma simultánea; por ejemplo permitir a los procesos que reciban información de distintas fuentes mediante la inclusión en distintos grupos. Pero, para simplificar la discusión de las propiedades de ordenación, algunas veces se restringirá en cada instante la pertenencia de un proceso como máximo a un grupo.

La operación *multicast*(g, m) envía el mensaje m a todos los miembros del grupo de procesos g . A esta operación le corresponde una operación *entrega*(m) que entrega el mensaje mandado por multidifusión al proceso que ha realizado la petición. Utilizamos el término *entrega* en lugar de *recibe* para dejar claro que un mensaje multidifundido no siempre se entrega a la capa de aplicación dentro del proceso tan pronto como es recibido en el nodo del proceso. Esto será explicado brevemente cuando se discuta la semántica de la entrega por multidifusión.

Todo mensaje m porta el identificador único del proceso *emisor*(m) que lo envía y el identificador único del grupo al que se envía *grupo*(m). Se supone que los procesos no mienten sobre el origen o destino de sus mensajes.

Se dice que un grupo está *cerrado* si sólo los miembros del grupo pueden multidifundir dentro de él (véase la Figura 11.9). Un proceso dentro de un grupo cerrado se entrega a sí mismo cual-

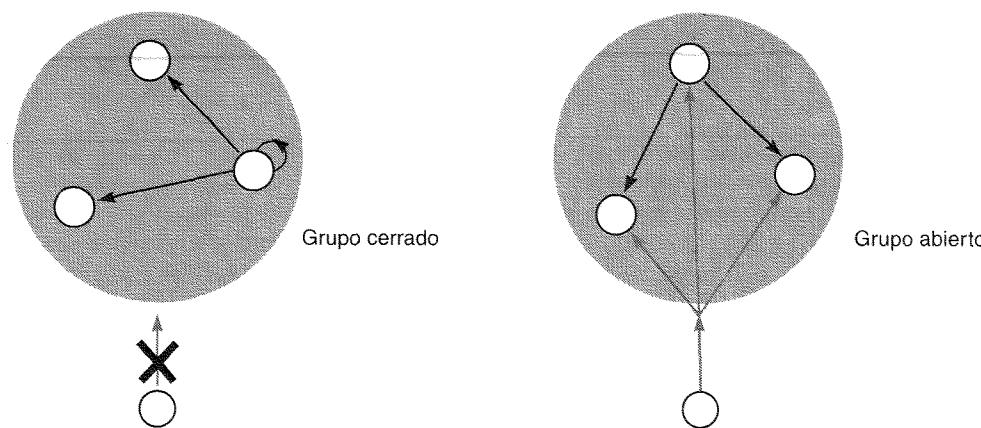


Figura 11.9. Grupos abiertos y cerrados.

quier mensaje que multidifunde al grupo. Un grupo se dice *abierto* si los procesos que no están en el grupo le pueden mandar mensajes (las categorías de «abierto» y «cerrado» también se aplican con significados análogos a las listas de correo). Los grupos cerrados de procesos son útiles, por ejemplo, entre servidores cooperantes para enviar mensajes entre ellos y que sólo ellos deberían recibir. Los grupos abiertos son útiles, por ejemplo, para informar de eventos a grupos de procesos interesados.

Algunos algoritmos suponen que los grupos son cerrados. El mismo efecto que proporciona la apertura se puede conseguir con un grupo cerrado escogiendo a un miembro del grupo y enviándole un mensaje (uno-a-uno) para que multidifunda al resto de su grupo. Rodrigues y otros [1998] discuten la multidifusión para grupos abiertos.

11.4.1. MULTIDIFUSIÓN BÁSICA

Es útil tener a nuestra disposición una primitiva de multidifusión básica que garanticé, a diferencia de la multidifusión IP, que un proceso correcto al final entregará el mensaje siempre que el sistema que realiza la multidifusión no se caiga. La primitiva se llamará *B-multicast* y su correspondiente primitiva de entrega básica se llamará *B-entrega*. Se permitirá a los procesos que pertenezcan a varios grupos y que cada mensaje se destine a un grupo en particular.

Una forma directa de implementar el *B-multicast* es utilizar una operación *envía* fiable uno-a-uno de la siguiente forma:

Para realizar *B-multicast*(g, m): para cada proceso $p \in g$, $g, \text{envía}(p, m)$;

Al *recibir*(m) en $p : B\text{-entrega}(m)$ en p .

La implementación puede usar hilos para realizar las operaciones *envía* de forma concurrente, con el fin de reducir el tiempo total empleado para entregar el mensaje. Desgraciadamente, tal implementación es susceptible de sufrir la denominada *ack-implosion* (colapso por exceso de acuses de recibo) si el número de procesos es grande. Es factible que los acuses de recibo, enviados como parte de una operación *envía* fiable, lleguen aproximadamente al mismo tiempo desde muchos procesos. Los búferes del proceso que están realizando la multidifusión se llenarán rápidamente y es probable que pierdan algún acuse de recibo. En ese caso retransmitiría el mensaje, dando lugar todavía a más acuses de recibo y un mayor desperdicio del ancho de banda. Puede construirse un servicio básico de multidifusión más práctico usando la multidifusión IP y se deja como ejercicio para el lector.

11.4.2. MULTIDIFUSIÓN FIABLE

La Sección 2.3.2 definió los canales de comunicación fiables uno-a-uno entre pares de procesos. La propiedad de seguridad requerida se denominaba *integridad*, esto es, que todo mensaje entregado es idéntico al enviado y que ningún mensaje se entrega dos veces. La propiedad de pervivencia requerida se denominaba *validez*, esto es, que todo mensaje al final sea entregado en su destino, si éste es correcto.

De forma similar a Hadzilacos y Toueg [1996], se define a continuación una *multidifusión fiable* con sus operaciones correspondientes *F-multicast* y *F-entrega*. Queda claro que sería muy conveniente disponer de propiedades análogas a la integridad y a la validez para la entrega en la operación de multidifusión. No obstante, se añade otro requisito: *todos* los procesos correctos en un grupo deben recibir un mensaje si *alguno* de ellos lo recibe. Es importante darse cuenta de que esta propiedad no existe en el algoritmo de *B-multicast* que se basa en una operación fiable de envío uno-a-uno. El emisor puede fallar en cualquier instante del *B-multicast*, por lo tanto algunos procesos pueden recibir un mensaje mientras que otros no.

Un proceso de multidifusión fiable será aquel que satisfaga las siguientes propiedades:

Integridad: un proceso correcto p entrega un mensaje m a lo sumo una vez. Además, $p \in grupo(m)$ y m fue proporcionado a la operación *multicast* por un *emisor(m)* (de la misma forma que con la comunicación uno-a-uno, los mensajes pueden distinguirse por un número de secuencia propio al emisor).

Validez: si un proceso correcto multidifunde un mensaje m , entonces al final m será entregado.

Acuerdo: si un proceso correcto entrega un mensaje m , entonces el resto de procesos correctos en el *grupo(m)* deben al final entregar el mensaje m .

Una vez definidas estas propiedades se procede a explicarlas con más detalle.

La propiedad de integridad es análoga a la de comunicación fiable uno-a-uno. La propiedad de validez garantiza la pervivencia para el emisor. Ésta podría parecer una propiedad poco habitual, ya que es asimétrica (sólo se menciona un proceso en concreto). Pero hay que darse cuenta de que las propiedades de validez y acuerdo conjuntamente permiten obtener el requisito de pervivencia global; si un proceso, el *emisor*, finalmente entrega un mensaje m entonces, puesto que los procesos correctos están de acuerdo en el conjunto de mensajes que entregan, de lo que se deduce que m será entregado, finalmente, a todos los miembros correctos del grupo.

La ventaja de expresar la condición de validez en términos de auto-entrega es la sencillez. Lo que se requiere es que el mensaje sea entregado en último caso por *algún* miembro correcto del grupo.

La condición de acuerdo está relacionada con la atomicidad, que es la propiedad de «todo o nada» aplicada a la entrega de mensajes a un grupo. Si un proceso que está enviando un mensaje mediante multidifusión se cae antes de haberlo entregado, entonces es posible que el mensaje no se entregue a ningún proceso del grupo; pero si lo ha entregado a algún proceso correcto, entonces el resto de procesos correctos lo entregarán. Muchos trabajos en la literatura existente usan el término «atómico» para incluir una condición de ordenación total, que se define a continuación.

◇ **Implementación de la multidifusión fiable sobre *B-multicast*.** La Figura 11.10 proporciona un algoritmo de multidifusión fiable con las primitivas *F-multicast* y *F-entrega*, que permiten a los procesos pertenecer a distintos grupos cerrados de forma simultánea. Para enviar un mensaje mediante *F-multicast*, un proceso envía el mensaje mediante *B-multicast* a los procesos miembros del grupo (incluido él mismo). Cuando el proceso ha sido *B-entregado*, el receptor, a cambio, realiza *B-multicast* del mensaje al grupo (si no es el emisor original) y, a continuación, *F-entrega* el mensaje. Ya que un mensaje puede llegar más de una vez a cualquier nodo, los duplicados del mensaje se detectan y no se reenvían.

En la inicialización

 Recibido := {};

Para que el proceso p realice *R-multicast* de un mensaje m a un grupo g

B-multicast(g, m); // $p \in g$ se incluye como destino

En *B-entrega*(m) a un proceso q con $g = grupo(m)$

 si ($m \notin Recibido$)

 entonces

 Recibido := Recibido ∪ { m };

 si ($q \neq p$) entonces *B-multicast*(g, m); fin si;

F-entrega m ;

 fin si

Figura 11.10. Algoritmo de multidifusión fiable.

Este algoritmo claramente satisface el requisito de validez, ya que un proceso correcto realizará en último caso una *B-entrega* a sí mismo. Además, por la propiedad de integridad de los canales de comunicación subyacentes que se usan en los envíos *B-multicast*, el algoritmo también satisface la propiedad de integridad.

El acuerdo se consigue a partir del hecho de que todo proceso correcto envía mediante *B-multicast* el mensaje a otros procesos una vez que lo ha *B-entregado*. Si un proceso correcto no realiza la *F-entrega* del mensaje, entonces esto se debe a que nunca ha realizado la *B-entrega*. Esto, a su vez, puede deberse solamente a que ningún otro proceso correcto lo ha *B-entregado* antes; por lo tanto, ninguno lo *B-entregará*.

El algoritmo de multidifusión fiable que se ha descrito es correcto en un sistema asíncrono, ya que no se han realizado suposiciones sobre las temporizaciones. Sin embargo, el algoritmo es ineficiente en la práctica, ya que cada mensaje se envía $|g|$ veces a cada proceso.

◇ **Multidifusión fiable sobre multidifusión IP.** Una alternativa para realizar *F-multicast* es combinar la multidifusión IP, acuses de recibo adheridos (*piggy backed*) (esto es, acuses de recibo adjuntos a otros mensajes), y acuses de recibo negativos. Este protocolo para *F-multicast* se basa en la observación de que la comunicación por multidifusión IP casi siempre tiene éxito. En el protocolo, los procesos no envían mensajes separados de acuse de recibo; en su lugar adhieren los reconocimientos en los mensajes que envían al grupo. Los procesos envían un mensaje de respuesta por separado sólo cuando detectan que han perdido un mensaje. La respuesta indicando la ausencia de un mensaje esperado se conoce como *acuse de recibo negativo*.

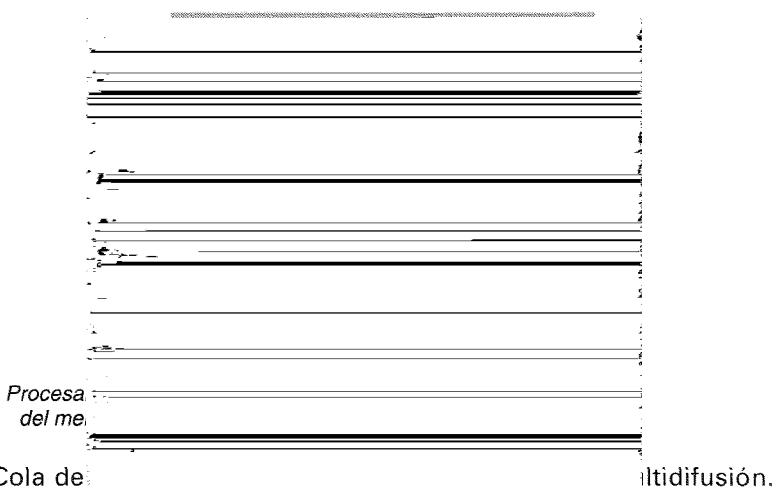
La descripción supone que los grupos son cerrados. Cada proceso p mantiene un número de secuencia S_q^p para cada grupo g al que pertenece. El número de secuencia es inicialmente cero.

Cada proceso almacena además R_g^p , el número de secuencia del último mensaje que ha sido entregado por el proceso p y que fue enviado desde el grupo g .

Cuando el proceso p emplea *F-multicast* para un mensaje al grupo g , adhiere a dicho mensaje el valor S_g^p . Además adhiere acuses de recibo sobre el mensaje que envía, de la forma $\langle q, R_g^p \rangle$. Dicho acuse de recibo establece el número de secuencia del último mensaje destinado para ese grupo, que le ha sido entregado desde el proceso q desde la última vez que se multidifundió un mensaje. El proceso p que empleó la multidifusión envía a continuación el mensaje mediante multidifusión IP con su número de secuencia y con acuse de recibo adheridos para g , e incrementa S_g^p en uno.

Un proceso *F-entrega* un mensaje destinado para g con el número de secuencia S y proveniente de p si y sólo si $S = R_g^p + 1$, e incrementa R_g^p en uno inmediatamente tras la entrega. Además, retiene cualquier mensaje que no haya podido entregar en una *cola de retención* (véase la Figura 11.11); tales colas se necesitan con frecuencia para que se cumplan las garantías en la entrega de mensajes. Si, por otro lado, un mensaje que llega tiene $S \leq R_g^p$, entonces r ha entregado el mensaje antes y lo descarta. Si $S > R_g^p + 1$ o $R > R_g^p$, para cualquier acuse de recibo $\langle q, R \rangle$ incluido en otro mensaje, entonces r ha perdido uno o más mensajes. En ese momento los solicita mediante el envío de acuses de recibo negativos. Puede enviar la petición al proceso del cual percibió la omisión o al emisor original, si es distinto. En algunas variaciones del protocolo, aquél realiza la petición mediante multidifusión a los procesos de su red vecina, por si acaso lo hubieran recibido.

La propiedad de integridad se consigue con la detección de duplicados y las propiedades subyacentes de la multidifusión IP (que utiliza sumas de comprobación para eliminar mensajes corruptos). La propiedad de validez se cumple porque la multidifusión IP tiene dicha propiedad. Por acuerdo necesitamos, primero, que un proceso siempre pueda detectar mensajes perdidos. Esto a cambio significa que siempre recibirá un mensaje posterior que le permite detectar la omisión. Como establece este protocolo simplificado, garantizamos la detección de los mensajes perdidos sólo en el caso en que se suponga que cada proceso multidifunda de forma indefinida. Segundo, la



propiedad de acuerdo requiere que un proceso correcto entregue m' para un proceso que no lo haya recibido. Por lo tanto, el acuerdo uniforme es una entrega ordenada, de los mensajes que han enviado.

Ninguna de las suposiciones hechas para asegurar el acuerdo es práctica. Sin embargo, el acuerdo se consigue en la práctica en los protocolos de los cuales se deriva éste: el protocolo Psync [Peterson y otros 1989], el protocolo Trans [Melliar-Smith y otros 1990] y el protocolo de multidifusión fiable y ampliable [Floyd y cols. 1997]. Psync y Trans garantizan, además, una entrega ordenada.

◊ **Propiedades uniformes.** La definición de acuerdo antes mencionada sólo se refiere al comportamiento de los procesos *correctos*, que nunca fallan. Considérese qué ocurriría en el algoritmo de la Figura 11.10 si un proceso no es correcto y se cae tras haber *F-entregado* un mensaje. Teniendo en cuenta que cualquier proceso que *F-entrega* el mensaje ha de haber realizado previamente un *B-multicast* del mismo, se concluye que todos los procesos correctos acabarían entregando el mensaje.

Cualquier propiedad que se cumpla tanto si los procesos son correctos como si no se denomina propiedad *uniforme*. Se define acuerdo uniforme de la siguiente forma:

Acuerdo uniforme: si un proceso, correcto o con fallo, entrega un mensaje m , entonces todos los procesos correctos en el *grupo(m)* entregarán finalmente m .

El acuerdo uniforme permite que un proceso tras entregar un mensaje, y al mismo tiempo asegura que todos los procesos correctos entregarán el mensaje. Ya se discutió que el algoritmo de la Figura 11.10 satisface esta propiedad, que es más fuerte que la propiedad de acuerdo no uniforme definida con anterioridad.

El acuerdo uniforme es útil en aquellas aplicaciones donde un proceso puede realizar una acción que produzca una inconsistencia observable justo antes de caerse. Por ejemplo, considérese el caso en el que los procesos son servidores que gestionan las copias de una cuenta bancaria y que las actualizaciones en la cuenta se mandan al grupo de servidores utilizando multidifusión fiable. Si la multidifusión no satisface la propiedad de acuerdo uniforme, un cliente que acceda a un servidor justo antes de que se caiga puede observar una actualización que ningún otro servidor procesará.

Es importante resaltar que si se invierte el orden de las líneas *F-entrega m* y *si (q ≠ p) entonces B-multicast(g, m); fin si* en la Figura 11.10, entonces el algoritmo resultante no cumple la propiedad de acuerdo uniforme.

De la misma forma que hay una versión uniforme de acuerdo, hay versiones uniformes del resto de propiedades de la multidifusión, incluyendo validez e integridad además de las propiedades de ordenación que se definen a continuación.

11.4.3. MULTIDIFUSIÓN ORDENADA

El algoritmo de multidifusión básico de la Sección 11.4.1 entrega los mensajes a los procesos en un orden arbitrario, debido a los retrasos arbitrarios asociados a las operaciones subyacentes de envío uno-a-uno. Esta falta de la propiedad de ordenación no es admisible en muchas aplicaciones. Por ejemplo, en una planta nuclear es importante que los eventos asociados a amenazas en las condiciones de seguridad y los eventos que implican acciones por parte de las unidades de control sean observados en el mismo orden por todos los procesos del sistema.

Los requisitos de ordenación más frecuentes son la ordenación total, la ordenación causal, la ordenación FIFO y las ordenaciones híbridas total-causal y total-FIFO. Para simplificar la exposición se definen a continuación estas ordenaciones bajo la suposición de que cualquier proceso pertenece a lo sumo a un grupo. Más adelante se discutirán las implicaciones de permitir que los grupos se solapen.

Ordenación FIFO: si un proceso correcto realiza un $\text{multicast}(g, m)$ y a continuación un $\text{multicast}(g, m')$, entonces todo proceso correcto que entregue m' ha de haber entregado previamente m .

Ordenación causal: si $\text{multicast}(g, m) \rightarrow \text{multicast}(g, m')$, donde \rightarrow indica la relación sucedió-antes inducida por los mensajes enviados solamente entre los miembros de g , entonces cualquier proceso correcto que entregue m' habrá entregado antes m .

Ordenación total: si un proceso correcto entrega el mensaje m antes de que entregue m' , entonces cualquier otro proceso que entregue m' ha de haber entregado m antes.

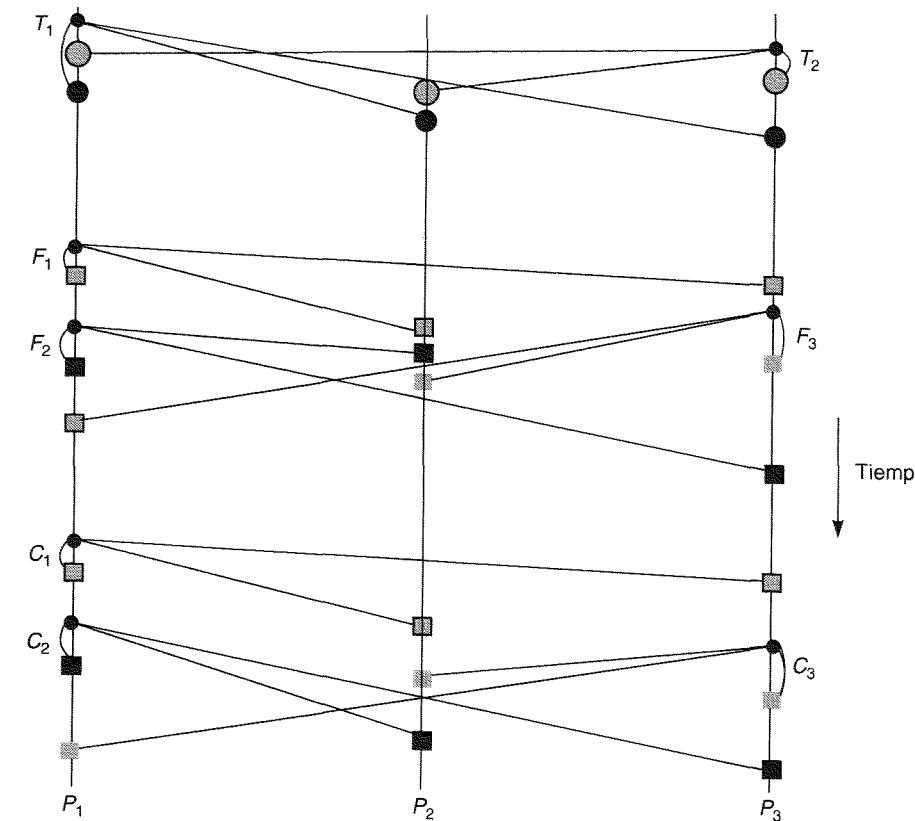
La ordenación causal implica una ordenación FIFO, ya que dos envíos *multicast* cualesquiera dentro del mismo proceso están relacionados en la forma sucedió-antes. Hay que resaltar que tanto la ordenación FIFO como la ordenación causal son ordenaciones parciales: de forma general, no todos los mensajes son enviados por el mismo proceso; de forma similar, algunas multidifusiones son concurrentes (y, por lo tanto, no ordenadas mediante sucedió-antes).

La Figura 11.12 ilustra las ordenaciones en el caso en que existan tres procesos. Un análisis en profundidad de la figura muestra que los mensajes totalmente ordenados se entregan en el orden contrario al tiempo físico en el que fueron enviados. De hecho, la definición de ordenación total permite que la entrega de mensajes se ordene de manera arbitraria, ya que el orden es el mismo en procesos diferentes. Además, dado que la ordenación total no es necesariamente ni una ordenación FIFO ni una ordenación causal, se define la ordenación híbrida *FIFO-total* como aquella en la que la entrega de mensajes obedece a ambos tipos de ordenación; de forma parecida, cuando existe una entrega de mensajes con ordenación *causal-total* se obedecen ambos tipos de ordenaciones.

Las definiciones de multidifusión ordenada ni suponen ni implican fiabilidad. Por ejemplo, el lector podría comprobar que bajo la hipótesis de ordenación total, si un proceso p entrega un mensaje m y a continuación entrega un mensaje m' , un proceso correcto q puede entregar m sin necesidad de entregar m' o cualquier otro mensaje ordenado tras m .

También se pueden formar protocolos híbridos ordenados y fiables. Una multidifusión totalmente ordenada fiable suele denominarse en la literatura como un *multidifusión atómica*. De forma similar se pueden conseguir multidifusión FIFO fiable, multidifusión causal fiable y versiones fiables de los multidifusión con ordenación híbrida.

La ordenación en la entrega de mensajes por multidifusión, tal y como se verá, puede ser costosa en términos de latencia en la entrega y consumo de ancho de banda. La semántica asociada a las



Obsérvese la ordenación consistente de los mensajes con ordenación total T_1 y T_2 , los mensajes relacionados por criterio FIFO, $F_1 > F_2$, y los mensajes relacionados causalmente C_1 y C_2 ; y en el resto de casos, entrega de mensajes con ordenación.

Figura 11.12. Ordenaciones total, FIFO y causal de mensajes de multidifusión.

ordenaciones que se han descrito puede retrasar la entrega de mensajes de forma innecesaria. Esto es, desde el punto de vista de la aplicación, un mensaje puede verse retrasado por otro del cual no depende. Por esta razón, algunos autores han propuesto sistemas de multidifusión que utilizan semánticas de los mensajes específicos de la aplicación para determinar el orden en la entrega de mensajes [Cheriton y Skeen 1993, Pedone y Schiper 1999].

◇ **El ejemplo del tablón de anuncios.** Para concretar más la semántica de la entrega de mensajes considérese una aplicación en la cual los usuarios ponen mensajes en tablones de anuncios. Cada usuario ejecuta un proceso que es una aplicación tablón de anuncios. Cada tema de discusión tiene su propio grupo de procesos. Cuando un usuario manda un mensaje al tablón, la aplicación multidifunde dicho mensaje al resto del grupo del tema en el que él o ella están interesados, de tal forma que el usuario sólo recibirá los anuncios concernientes a ese tema.

Se necesita multidifusión fiable si todo usuario ha de recibir al final cada anuncio. Los usuarios también imponen requisitos de ordenación. La Figura 11.13 muestra los anuncios tal y como le aparecen a un usuario en particular. Como mínimo, se desea tener una ordenación FIFO, de tal forma que cualquier anuncio para un usuario (por ejemplo, A. Pérez) se recibirá en el mismo orden y los usuarios pueden hablar de forma consistente acerca del segundo mensaje de A. Pérez.

El lector debe fijarse en que los mensajes cuyos asuntos son *Re: Microkernels* (25) y *Re: Mach* (27) aparecen tras los mensajes a los que se refieren. Por lo tanto, se necesita una multidifusión

Tablón de anuncios: os.interesante		
Ítem	De	Asunto
23	A. Pérez	Mach
24	G. Mayor	Microkernels
25	A. Pérez	Re: Microkernels
26	T. L. Heureux	RPC performance
27	M. Walker	Re: Mach
Fin		

Figura 11.13. Pantalla de un programa tablón de anuncios.

ordenada causalmente para garantizar estas relaciones. De otra forma, retrasos arbitrarios en los mensajes pueden ocasionar que un mensaje *Re: Mach* aparezca antes que el mensaje original concerniente a Mach.

Si la multidifusión estuviese totalmente ordenada, entonces la numeración en la columna de la izquierda sería consistente entre los usuarios. En ese caso, los usuarios podrían referirse sin ambigüedad al mensaje 24.

En la práctica, el sistema del tablón de anuncios de USENET no implementa ni ordenación causal ni total. Los costes asociados a la comunicación para conseguir estas ordenaciones a gran escala exceden ampliamente las ventajas que aportan.

◇ **Implementación de una ordenación FIFO.** Para conseguir una multidifusión con ordenación FIFO (que tendrá las operaciones *OF-multicast* y *OF-entrega*) se utilizan secuencias de números, de forma similar a como se conseguiría en una comunicación uno-a-uno. Se considerarán sólo grupos que no se solapen. Se deja como ejercicio para el lector que verifique que el protocolo de multidifusión fiable que se definió sobre la base de la multidifusión IP en la Sección 11.4.2, además garantiza la ordenación FIFO. Ahora se mostrará cómo construir multidifusión con ordenación FIFO sobre la base de cualquier multidifusión. Se usarán las variables S_g^p y R_g^q asociadas al proceso p como se hacía en el protocolo de multidifusión fiable de la Sección 11.4.2: S_g^p es un contador del número de mensajes que p ha enviado al grupo g , y para cada q , R_g^q es el número de secuencia del último mensaje que p ha entregado, partiendo del proceso q y que fue enviado al grupo g .

Cuando p quiere enviar un mensaje mediante *OF-multicast* al grupo g , adhiere en el mensaje el valor S_g^p , realiza el *B-multicast* del mensaje al grupo g e incrementa S_g^p en 1. Cuando p recibe un mensaje de q que lleva el número de secuencia S , comprueba si $S = R_g^q + 1$. Si es así, ése era el mensaje esperado por parte de q y p usa *OF-entrega*, fijando $R_g^q := S$. Si $S > R_g^q + 1$, retiene el mensaje en la cola hasta que los mensajes intermedios hayan sido entregados y $S = R_g^q + 1$.

Dado que todos los mensajes enviados por un emisor se entregan siguiendo la misma secuencia, y dado que se pospone la entrega de un mensaje hasta que se alcance su número de secuencia, se cumple claramente la condición de ordenación FIFO. Sin embargo, esto sólo ocurre si se cumple la condición de grupos que no se solapan.

En este protocolo podría usarse cualquier implementación de *B-multicast*. Además, si se usase una primitiva *F-multicast* en lugar de *B-multicast*, se obtendría una multidifusión FIFO fiable.

◇ **Implementación de la ordenación total.** La manera básica de implementar la ordenación total es asignar identificadores totalmente ordenados a los mensajes que se multidifunden de tal forma que todo proceso realice la misma ordenación basada en esos identificadores. El algoritmo de entrega sería muy similar al descrito para la ordenación FIFO, la diferencia sería que los procesos almacenarían números de secuencia específicos para cada grupo en lugar de números específicos de secuencia para cada proceso. Aquí se considerará sólo cómo ordenar totalmente mensajes

1. Algoritmo para el miembro p del grupo

En la inicialización: $r_g := 0$;

Para hacer OT-multicast de un mensaje m al grupo g
Hacer $B\text{-multicast}(g \cup \{\text{secuenciador}(g)\}, \langle m, i \rangle)$;

En $B\text{-entrega}(\langle m, i \rangle)$ con $g = \text{grupo}(m)$
Coloca $\langle m, i \rangle$ en la cola de retención;

En $B\text{-entrega}(m_{\text{orden}} < "orden", i, S_g)$ con $g = \text{grupo}(m)$
Espera hasta que $\langle m, i \rangle$ esté en la cola de retención y $S_g = r_g + 1$;
 $OT\text{-entrega } m$; // (tras eliminarlo de la cola de retención)
 $r_g := S_g$;

2. Algoritmo para el secuenciador de g

En la inicialización: $s_g := 0$;

En $B\text{-entrega}(\langle m, i \rangle)$ con $g = \text{grupo}(m)$
Haz $B\text{-multicast}(g, \langle "orden", i, s_g \rangle)$;
 $s_g := s_g + 1$;

Figura 11.14. Ordenación total que usa un secuenciador.

que se envían a grupos que no se solapan. Las operaciones de multidifusión se denominarán *OT-multicast* y *OT-entrega*.

Se discuten fundamentalmente dos métodos para asignar los identificadores a los mensajes. El primero consiste en que un proceso denominado *secuenciador* los asigne (véase la Figura 11.14). Cuando un proceso desea enviar un mensaje m con *OT-multicast* a un grupo g adjunta un identificador único $id(m)$ al mismo. Los mensajes destinados a g se envían al secuenciador para g , *secuenciador*(g), al igual que a los miembros de g . (El secuenciador puede ser, incluso, un miembro de g .) El proceso *secuenciador*(g) guarda un número de secuencia específico para el grupo S_g , que utiliza para asignar números de forma creciente y consecutiva a los mensajes que *B-entrega*. El secuenciador anuncia la secuencia de números mediante *B-multicast* al grupo g de mensajes con el *ordenamiento* (para obtener más detalles véase la Figura 11.14).

Un mensaje permanecerá retenido en la cola indefinidamente hasta que pueda efectuarse *OT-entrega* de acuerdo con el correspondiente número de secuencia. Partiendo de que la secuencia de números está bien definida (ya que viene dada por el secuenciador), se observa que se cumple el criterio de orden total. Además, si los procesos utilizasen una variante de ordenación FIFO del *B-multicast*, entonces además de estar totalmente ordenado está también causalmente ordenado. Esta demostración se deja para el lector.

El problema obvio asociado a un esquema basado en un secuenciador es que éste puede convertirse en un cuello de botella y además es un punto de fallo crítico. Existen algoritmos que en la práctica solucionan el problema del fallo. Chang y Maxemchuk [1984] fueron los primeros en sugerir un protocolo de multidifusión que utilizaba un secuenciador (lo que denominaron *lugar del testigo*). Kaashoek y otros [1989] desarrollaron un protocolo basado en un secuenciador para el sistema Amoeba. Estos protocolos aseguran que un mensaje está en la cola de retención en $f + 1$ nodos antes de ser entregado; de esta forma se pueden tolerar f fallos. Al igual que Chang y Maxemchuk, Birman y otros [1991] también utilizan un sitio que retiene el testigo y que actúa como secuenciador. El testigo se puede pasar de unos procesos a otros, de tal forma que sólo un proceso multidifunde todos los mensajes de forma totalmente ordenada dicho proceso puede actuar como un secuenciador, ahorrando el proceso de comunicación.

El protocolo propuesto por Kaashoek y otros usa multidifusión implementada vía hardware (que está disponible, por ejemplo, en Ethernet) en lugar de usar una comunicación fiable punto-a-

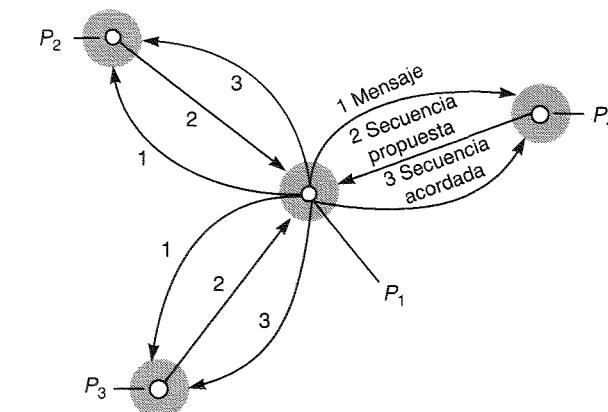


Figura 11.15. El algoritmo ISIS para ordenación total.

punto. En la versión más simple de su protocolo los procesos envían sus mensajes al secuenciador para que realice la multidifusión, y esta comunicación la realizan uno-a-uno. El secuenciador multidifunde junto con el identificador y el número de secuencia. Esto presenta la ventaja de que los otros miembros del grupo reciben sólo un mensaje mediante multidifusión; el inconveniente radica en el incremento en el uso del ancho de banda. El protocolo se encuentra descrito en su totalidad en www.cdk3.net/coordination.

El segundo método examinado para conseguir multidifusión totalmente ordenada es aquel en el que los procesos se ponen de acuerdo de una forma distribuida en la asignación de números de secuencia. En la Figura 11.15 se muestra un algoritmo simple, similar al que fue desarrollado originalmente para implementar la entrega en la multidifusión totalmente ordenada para la herramienta ISIS [Birman y Joseph 1987a]. Una vez más, un proceso envía un mensaje mediante *B-multicast* a los miembros del grupo. Éste puede ser abierto o cerrado. Los procesos que reciben los mensajes proponen números de secuencia según les van llegando y se los devuelven al emisor, que los usa para generar números de secuencia *acordados*.

Cada proceso q en el grupo g mantiene A_g^q , que es el mayor número de secuencia acordado que se ha observado hasta el momento para el grupo g y P_g^q , que es su mayor número de secuencia propuesto. El algoritmo que sigue cada proceso p para multidifundir un mensaje m al grupo g es el siguiente:

1. p usa *B-multicast* $\langle m, i \rangle$ a g , donde i es el identificador único para m .
2. Cada proceso q responde al emisor p con una propuesta del número de secuencia acordado como $P_g^q := \text{Máx}(A_g^q, P_g^q) + 1$. En realidad, habría que incluir los identificadores de procesos en los valores propuestos P_g^q para asegurar el orden total, ya que de otra forma, distintos procesos podrían proponer el mismo valor para mensajes distintos; sin embargo, para facilitar la notación, no se mencionará de forma explícita. Cada proceso asigna al mensaje de forma provisional el número de secuencia propuesto y lo almacena en la cola de retención, que se ordena con el número de secuencia *menor* al comienzo.
3. p recoge todos los números de secuencia propuestos y selecciona el mayor a como el siguiente número de secuencia acordado. A continuación emplea *B-multicast* $\langle i, a \rangle$ para g . Cada proceso q en g fija $A_g^q := \text{Máx}(A_g^q, a)$ y adjunta a al mensaje (que es identificado mediante i). Además reordena el mensaje en la cola de retención si el número de secuencia acordado difiere del propuesto. Cuando al mensaje al principio de la cola de retención se le haya asignado su número de secuencia acordado, se transfiere al final de la cola de entre-

Cada proceso p_i ($i = 1, 2, \dots, N$) mantiene su propio vector de marcas temporales (véase la Sección 10.4). Cada entrada asociada a la marca temporal cuenta el número de mensajes multidifundidos de cada proceso que sucedieron antes que el próximo mensaje que va a ser enviado mediante multidifusión.

Para enviar un mensaje mediante *OC-multicast* al grupo g , el proceso suma 1 a su entrada en el vector de marcas temporales y envía el mensaje mediante *B-multicast* a g junto con su marca de tiempo.

Cuando un proceso p_i *B-entrega* un mensaje p_j , tiene que colocarlo en la cola de retención antes de realizar la *OC-entrega*: primero tiene que asegurarse de que ha entregado todos los mensajes que le precedían causalmente. Para asegurarse de ello, p_i espera hasta que a) ha entregado todo mensaje enviado anteriormente por parte de p_j y b) ha entregado cualquier mensaje que p_j hubiese entregado hasta el instante de tiempo en el que multidifundió el mensaje. Ambas condiciones pueden detectarse examinando el vector de marcas temporales, como se muestra en la Figura 11.16. Hay que tener en cuenta de que un proceso puede *OC-entregarse* inmediatamente hacia sí mismo un mensaje que él envíe con *OC-multicast*, aunque esto no se describa en la Figura 11.16.

Cada proceso actualiza su vector de marcas temporales cada vez que entrega un mensaje, para llevar la cuenta de los mensajes que le preceden causalmente. Esto lo consigue incrementando en 1 la entrada j -ésima en su marca de tiempo. Esto supone una optimización de la operación de fusión que aparece en las reglas de actualización de la Sección 10.4. Esta optimización se consigue gracias a la condición de entrega en el algoritmo de la Figura 11.16, que garantiza que sólo se incrementa la entrada j -ésima.

Sin entrar en detalles, la prueba de corrección del algoritmo sería la siguiente. Supóngase que $\text{multicast}(g, m) \rightarrow \text{multicast}(g, m')$. Sean V y V' los vectores de marcastemporales de m y m' , respectivamente. Mediante inducción se prueba directamente que $V < V'$. En concreto, si un proceso p_k envía m mediante *multicast*, entonces $V[k] \leq V'[k]$.

Considérese qué ocurre cuando algún proceso correcto p_i realiza *B-entrega* de m' (en lugar de *OC-entregarlo*) sin haber *OC-entregado* m . Según el algoritmo, $V_i[k]$ puede incrementarse sólo cuando p_i entrega un mensaje que viene de p_k y lo incrementa en uno. Pero p_i no ha recibido m y por lo tanto $V_i[k]$ no puede aumentar más allá de $V_i[k] - 1$. En consecuencia, no es posible, para p_i realizar la *OC-entrega* de m' ya que requeriría que $V_i[k] \geq V'[k]$, y por consiguiente que $V_i[k] \geq V[k]$.

El lector debería comprobar que si se sustituye la primitiva fiable *F-multicast* en lugar de *B-multicast*, se obtendrá una multidifusión a la vez fiable y con ordenación causal.

Además, si se combina el protocolo para multidifusión causal con el protocolo basado en secuenciador para una entrega totalmente ordenada se obtiene una entrega de mensajes con ordenación total y causal. El secuenciador entrega los mensajes según el orden causal y multidifunde la secuencia de números para los mensajes según el orden en el que los recibió. Los procesos en el grupo de destino no entregan el mensaje hasta que reciben otro mensaje por parte del secuenciador con el *orden* y dicho mensaje sea el próximo en la secuencia de entrega.

Dado que el secuenciador entrega los mensajes según un orden causal y dado que el resto de procesos entregan los mensajes en el mismo orden que el secuenciador, el orden es, por lo tanto, total y causal.

◊ **Grupos que se solapan.** En las definiciones y en la semántica de los algoritmos de ordenación FIFO, causal y total, se han considerado sólo grupos que no se solapaban. Esto simplifica el problema, pero no es satisfactorio, ya que en general los procesos necesitan pertenecer a múltiples grupos que se solapan. Por ejemplo, un proceso puede estar interesado en eventos de múltiples fuentes y, consiguientemente, puede unirse al correspondiente conjunto de grupos de distribución de eventos.

Se pueden ampliar las definiciones de ordenación para cubrir ordenaciones globales [Hadzilacos y Toueg 1994], en las cuales ha de considerarse que si el mensaje m se multidifunde a g , y si el

En el caso de una elección, los procesos acuerdan cuál es el proceso elegido. En la multidifusión totalmente ordenada, los procesos acuerdan el orden de entrega de los mensajes.

Existen protocolos que solucionan de forma específica estos tipos de acuerdo. Algunos se han descrito previamente en este capítulo, y los Capítulos 12 y 13 examinarán las transacciones. No obstante, es útil considerar formas de acuerdo más genéricas buscando características y soluciones comunes.

Esta sección define el consenso de forma más precisa y lo relaciona con tres problemas asociados al acuerdo: los generales bizantinos, la consistencia interactiva y la multidifusión con ordenación total. Se procede examinando bajo qué circunstancias se pueden resolver los problemas, y se perfilan algunas soluciones. En particular, se discutirán los conocidos resultados sobre imposibilidad debidos a Fischer y otros [1985], que establecen que en un sistema asíncrono una colección de procesos que contenga un proceso que ha fallado no se puede garantizar que se alcance el consenso. Finalmente, se considerará la existencia de algoritmos que funcionan en la práctica a pesar del resultado de imposibilidad.

11.5.1. DEFINICIÓN DEL MODELO DEL SISTEMA Y DEL PROBLEMA

El modelo del sistema incluye una colección de procesos p_i ($i = 1, 2, \dots, N$) que se comunican mediante el paso de mensajes. En muchos casos prácticos un requisito importante a considerar es que ha de alcanzarse un consenso incluso cuando hay fallos. Como antes, se supone que la comunicación es fiable, pero los procesos pueden fallar. En esta sección se considerarán fallos por caída así como procesos que fallan de formas (arbitrariamente) extrañas. Algunas veces se especificará la suposición de que pueden fallar hasta f de los N procesos, esto es, éses exhiben algún tipo de fallo especificado, mientras que el resto permanece correcto.

Si pueden ocurrir fallos arbitrarios, ha de considerarse otro factor en la especificación del sistema y es si los procesos firman digitalmente los mensajes que envían (véase la Sección 7.4). Si los procesos lo hacen, entonces se puede limitar el daño que puede ocasionar un proceso que ha fallado. Concretamente, durante la ejecución de un algoritmo de acuerdo dicho proceso no puede hacer afirmaciones falsas sobre los valores que le ha enviado un proceso correcto. De todas formas, la importancia de la firma de mensajes quedará patente cuando se discutan soluciones al problema de los generales bizantinos. Por defecto, se asumirá que no existe dicha firma.

◊ **Definición del problema del consenso.** Para alcanzar el consenso, cada proceso p_i comienza en el estado *no decidido* y *propone* un solo valor v_i de un conjunto de posibles valores D ($i = 1, 2, \dots, N$). Los procesos se comunican entre sí, intercambiando valores. Entonces, cada proceso fija el valor de una *variable de decisión* d_i . Al hacer esto pasa al estado *decidido*, en el cual ya no puede cambiar el valor de d_i ($i = 1, 2, \dots, N$). La Figura 11.17 muestra a tres procesos envueltos en un algoritmo de consenso. Dos procesos proponen «proseguir» y el tercero propone «abortar», pero se cae. Los dos procesos que permanecen correctos deciden «proseguir».

Los requisitos para un algoritmo de consenso son que han de cumplirse las siguientes condiciones cada vez que se ejecute:

Terminación: finalmente, cada proceso correcto ha de fijar su variable de decisión.

Acuerdo: el valor de decisión de todos los procesos correctos es el mismo: si p_i y p_j son correctos y están en el estado *decidido*, entonces $d_i = d_j$ ($i, j = 1, 2, \dots, N$).

Integridad: si todos los procesos correctos han propuesto el mismo valor, entonces cualquier proceso correcto en el estado *decidido* ha elegido dicho valor.

Pueden aceptarse distintas variaciones en la definición de integridad, en función de la aplicación. Por ejemplo, un tipo de integridad más débil requeriría que el valor de decisión sea igual al pro-

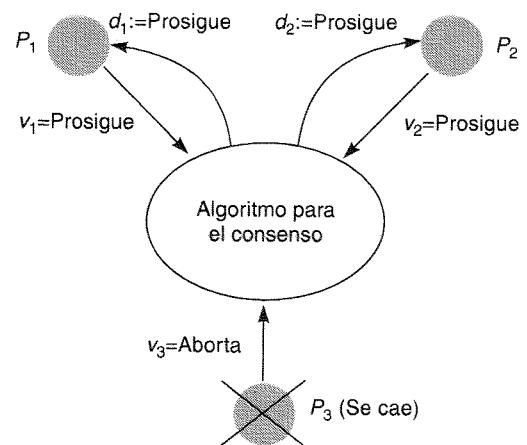


Figura 11.17. El problema del consenso para tres procesos.

puesto por algún proceso correcto, aunque no necesariamente igual para todos. De todas formas, se usará la definición dada anteriormente.

Para facilitar la comprensión de cómo obtener un algoritmo a partir de la formulación del problema, considérese un sistema en el que los procesos no pueden fallar. En ese caso es inmediato resolver el consenso. Por ejemplo, pueden reunirse todos los procesos en un grupo y que cada proceso del grupo multidifunda de modo fiable su valor propuesto al resto de los miembros del grupo. Todos los procesos esperan hasta recibir los N valores propuestos, incluido el suyo. Entonces evalúa la función *mayoría* (v_1, v_2, \dots, v_N), que devuelve el valor más frecuente entre sus argumentos, o el valor especial $\perp \notin D$ si no hay mayoría. Se garantiza la terminación gracias a la multidifusión fiable. Se garantizan el acuerdo y la integridad por la definición de *mayoría* y por la propiedad de integridad de la multidifusión fiable. Cada proceso recibe el mismo conjunto de valores propuestos, y cada proceso evalúa la misma función sobre esos valores. En consecuencia, han de ponerse de acuerdo y si cada proceso propone el mismo valor, entonces todos decidirán ese valor.

Hay que matizar que *mayoría* es sólo una de las posibles funciones a utilizar por los procesos para ponerse de acuerdo en los valores candidatos. Por ejemplo, si los valores están ordenados, las funciones *máximo* y *mínimo* también serían apropiadas.

Si los procesos pueden malograrse se introduce la complicación de tener que detectar los fallos y no queda claro que una ejecución del algoritmo de consenso termine. De hecho, si el sistema es asíncrono puede no hacerlo; se volverá a este punto en breve.

Si los procesos pueden fallar de formas (extrañamente) *arbitrarias*, aquellos que fallen pueden, en principio, comunicar valores aleatorios al resto. Esto puede parecer improbable en la práctica, pero no hay que descartar la posibilidad de que un proceso con un error falle de esa forma. Además, el fallo puede no ser accidental, sino el resultado de operaciones maliciosas o malévolas. Alguien podría deliberadamente forzar a un proceso a enviar diferentes valores a distintos procesos parejos con el fin de frustrar sus operaciones cuando están intentando alcanzar un consenso. En caso de que exista inconsistencia, los procesos correctos deben comparar lo que han recibido con lo que otros procesos dicen haber recibido.

◇ **El problema de los generales bizantinos.** En la definición informal del *problema de los generales bizantinos* [Lamport y otros 1982], tres o más generales han de ponerse de acuerdo en si atacar o retirarse. Uno de ellos, el comandante, cursa la orden. Los otros, los tenientes del comandante, deben decidir si atacar o retirarse. Pero uno o más de los generales puede ser un «traidor», o lo que es lo mismo, pueden fallar. Si el comandante es el traidor, manda atacar a un general y

retirarse a otro. Si el traidor es un teniente, informa a uno de sus iguales que el comandante le

retirarse a otro. Si el traidor es un teniente, informa a uno de sus iguales que el comandante le mandó atacar mientras que a otro le dice que le ordenó retirarse.

El problema de los generales bizantinos se distingue del de consenso en que un proceso destaca

CI a partir de GB. Se crea una solución para CI a partir de GB ejecutando GB N veces, una por cada proceso p_i ($i = 1, 2, \dots, N$) que actúe como comandante:

$$CI_i(v_1, v_2, \dots, v_N)[j] = GB_i(j, v_j) \quad (i, j = 1, 2, \dots, N)$$

C a partir de CI. Creamos una solución para C a partir de CI ejecutando CI para producir un vector de valores en cada proceso; a continuación se aplica una función apropiada sobre los valores del vector para determinar un único valor:

$$C(v_1, \dots, v_N) = \text{mayoría}(CI_i(v_1, \dots, v_N)[1], \dots, CI_i(v_1, \dots, v_N)[N])$$

($i = 1, 2, \dots, N$), donde *mayoría* se corresponde con su definición anterior.

GB a partir de C. Se crea una solución para GB a partir de C de la siguiente forma:

- El comandante p_j envía su valor propuesto v a sí mismo y a cada uno de los procesos restantes.
- Todos los procesos ejecutan C con los valores v_1, v_2, \dots, v_N que han recibido (teniendo en cuenta que p_j puede haber fallado).
- Obtienen $GB_i(j, v) = C_i(v_1, v_2, \dots, v_N)$ ($i = 1, 2, \dots, N$).

Queda como ejercicio para el lector comprobar que las condiciones de terminación, acuerdo e integridad se cumplen en cada caso. Fischer [1983] muestra los tres problemas con más detalle.

Solucionar el consenso equivale a resolver la multidifusión fiable y con ordenación total: dada una solución para uno, se puede resolver el otro. La implementación del consenso con una operación de multidifusión fiable y con ordenación total *FOT-multicast* es inmediata. Se reúnen todos los procesos en un grupo g . Para conseguir el consenso cada proceso p_i realiza *FOT-multicast*(g, v_i). Entonces, cada proceso p_i elige $d_i = m_i$, donde m_i es el *primer* valor que p_i ha *FOT-entregado*. La propiedad de terminación se deduce de la fiabilidad de la multidifusión. Las propiedades de acuerdo e integridad se deducen de la fiabilidad y ordenación total de la multidifusión. Chandra y Toueg [1996] han demostrado cómo se puede conseguir multidifusión fiable y con ordenación total a partir del consenso.

11.5.2. CONSENSO EN UN SISTEMA SÍNCRONO

Esta sección describe un algoritmo que utiliza un protocolo de multidifusión básico para resolver el problema del consenso en un sistema asíncrono. El algoritmo supone que un máximo de f de N procesos pueden sufrir fallos por caída.

Para alcanzar el consenso, cada proceso correcto recoge valores propuestos por los otros procesos. El algoritmo realiza $f + 1$ vueltas, en cada una de las cuales los procesos correctos hacen *B-multicast* de los valores entre ellos mismos. Se supone que pueden fallar un máximo de f procesos. En el peor de los casos, las f caídas ocurrieron durante las vueltas, pero el algoritmo garantiza que al final de las mismas todos los procesos correctos que han sobrevivido están en disposición de llegar a un acuerdo.

El algoritmo, que se muestra en la Figura 11.18, se basa en el propuesto por Dolev y Strong [1983] y en su presentación por parte de Attiya y Welch [1998]. La variable $Valores_i^r$ almacena el conjunto de valores conocidos para el proceso p_i al comienzo de la ronda r . Cada proceso multidifunde el conjunto de valores que no ha enviado en rondas anteriores. A continuación recoge las entregas de mensajes multidifusión similares por parte de otros procesos y guarda los nuevos valores. Aunque no se muestra en la Figura 11.18, la duración de cada ronda está delimitada por un timeout basado en el tiempo máximo que necesita un proceso correcto para realizar la multidifusión. Tras $f + 1$ rondas, cada proceso ha elegido el valor mínimo que haya recibido y su valor de decisión.

Algoritmo para los procesos $p_i \in g$; el algoritmo lo realiza en $f + 1$ rondas

En la inicialización

$$Valores_i^0 := \{v_i\}; Valores_i^0 = \{\}$$

En la ronda r ($1 \leq r \leq f + 1$)

Hacer *B-multicast*($g, Valores_i^r - Valores_i^{r-1}$); // Enviar sólo valores que no hayan sido enviados

$$Valores_i^{r+1} := Valores_i^r;$$

mientras (se está en la ronda r)

{

 En *B-entrega*(V_j) por parte de p_j hacer

$$Valores_i^{r+1} := Valores_i^{r+1} \cup V_j;$$

}

Tras ($f + 1$) rondas

Asignar $d_i = \text{mínimo}(Valores_i^{f+1})$

Figura 11.18. El problema del consenso en un sistema síncrono.

La terminación es obvia ya que el sistema es síncrono. Para comprobar la corrección del algoritmo hay que demostrar que cada proceso llega al mismo conjunto de valores al final de la última ronda. El acuerdo y la integridad vendrán dados porque los procesos aplican la función *mínimo* a su conjunto de valores.

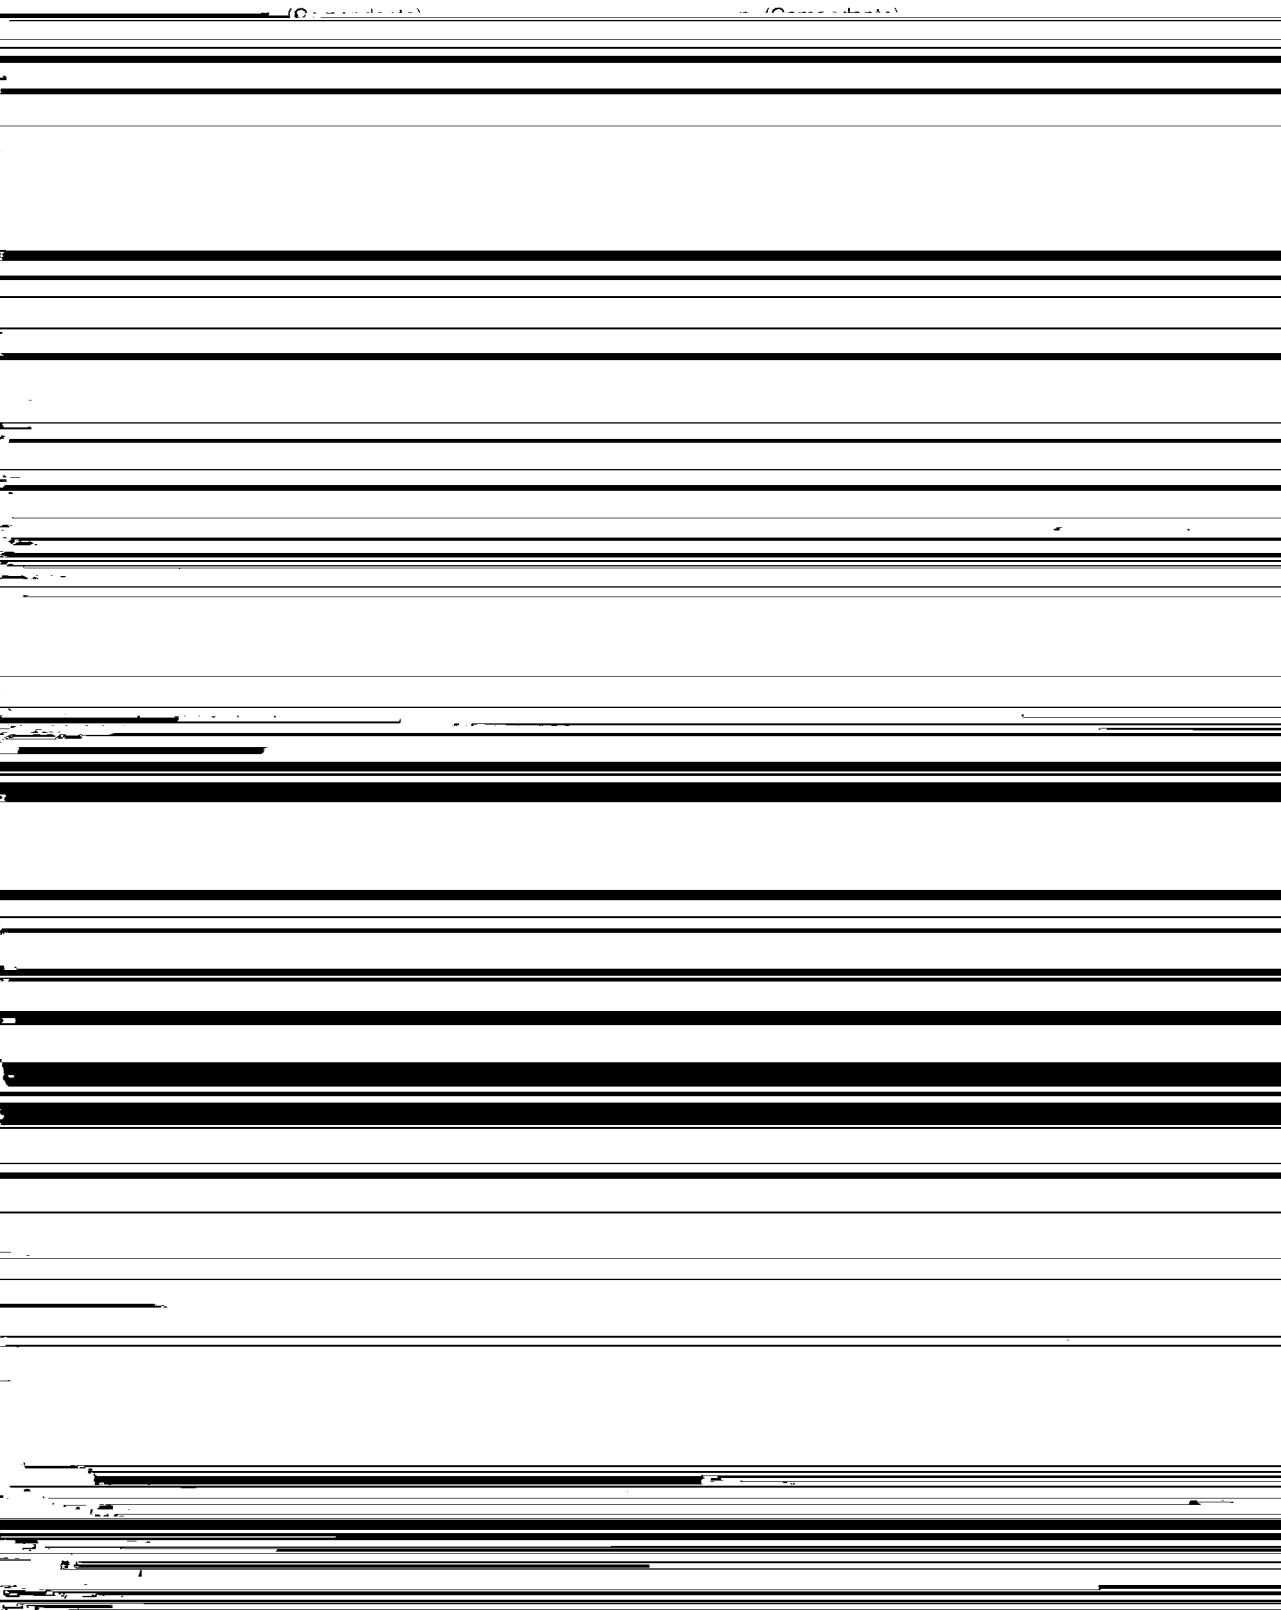
Supóngase, por el contrario, que dos procesos difieren en su conjunto final de valores. Sin pérdida de generalidad, algún proceso correcto p_i tiene un valor v que otro proceso correcto p_j ($i \neq j$) no tiene. La única explicación para que p_i tenga al final un valor propuesto v que p_j no tiene es que cualquier tercer proceso, por ejemplo p_k , que consiguió enviar v a p_i se cayó antes de que v pudiese ser entregada a p_j . A su vez, cualquier proceso que hubiese enviado v en la ronda anterior debería haber caído, para explicar por qué p_k tiene v en esa ronda pero p_j no lo tiene. Procediendo de esta forma hemos de suponer al menos una caída en cada una de las rondas precedentes. Sin embargo, se supuso que podían ocurrir a lo sumo f caídas y hubo $f + 1$ rondas. Hemos llegado a una contradicción.

Se concluye que *cualquier* algoritmo que quiera alcanzar el consenso a pesar de f fallos por caída requiere al menos $f + 1$ rondas de intercambio de mensajes con independencia de cómo está construido [Dolev y Strong 1983]. Este límite inferior también se cumple en el caso de fallos extraños [Fischer y Lynch 1980].

11.5.3. EL PROBLEMA DE LOS GENERALES BIZANTINOS EN UN SISTEMA SÍNCRONO

Se ha discutido previamente este problema en un sistema asíncrono. A diferencia del algoritmo para el consenso descrito en la sección anterior, se supone que los procesos pueden presentar fallos arbitrarios. Esto es, un proceso que ha fallado puede enviar un mensaje con cualquier valor en cualquier momento; y puede decidir no enviar ningún mensaje. Un máximo de f de N procesos pueden fallar. Los procesos correctos pueden determinar la ausencia de mensajes mediante un tiempo límite, pero no pueden concluir que el emisor se ha caído, ya que puede estar en silencio por un tiempo y después volver a enviar mensajes.

Se supone que los canales de comunicación entre pares de procesos son privados. Si un proceso pudiera examinar todos los mensajes enviados por otros procesos, podría detectar las inconsistencias enviadas a diferentes procesos por parte de un proceso con fallo. La suposición por defecto de fiabilidad en el canal implica que ningún proceso con fallo puede injectar mensajes en el canal de comunicación de dos procesos correctos.



puede resumirse de la siguiente forma. Supóngase que existe una solución para $N \leq 3f$. Utilícese la solución de tres procesos p_1 , p_2 y p_3 para simular el comportamiento de n_1 , n_2 y n_3 generales, respectivamente, donde $n_1 + n_2 + n_3 = N$ y $n_1, n_2, n_3 \leq N/3$. Se supone, además, que uno de los tres procesos falla. Aquéllos entre p_1 , p_2 y p_3 que están correctos simulan generales correctos: ellos simulan las interacciones de sus propios generales de forma interna y envían mensajes de parte de sus generales a aquellos simulados por otros procesos. Los generales simulados por procesos fallidos se suponen con fallo: los mensajes que envían como parte de la simulación pueden ser espurios. Dado que $N \leq 3f$ y $n_1, n_2, n_3 \leq N/3$, a lo sumo f generales simulados tienen fallos.

Dado que el algoritmo que ejecuta los procesos se supone correcto, la simulación termina. Los generales correctamente simulados (en los procesos correctos) están de acuerdo y satisfacen la propiedad de integridad. Pero ahora es necesario encontrar el consenso para dos de un conjunto de tres procesos: cada uno decide según el valor elegido por sus generales simulados. Esto contradice el resultado de imposibilidad para tres procesos con uno de ellos fallido.

◊ **Solución de un proceso que falla.** Por problemas de espacio no se describe completamente el algoritmo de Pease y otros que resuelve los problemas de los generales bizantinos en un sistema sincrónico con $N \geq 3f + 1$. En su lugar, se muestra el funcionamiento del algoritmo para el caso $N \leq 4$, $f = 1$ y se da el ejemplo con $N = 4$, $f = 1$.

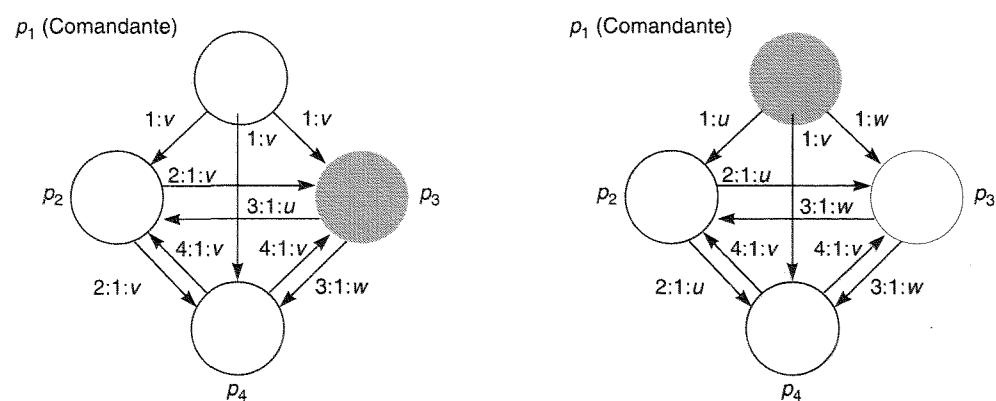
Los generales que están correctos alcanzan el acuerdo en dos rondas de mensajes:

- En la primera ronda, el comandante envía su valor a cada uno de sus tenientes.
- En la segunda ronda, cada uno de los tenientes envía el valor que ha recibido a sus iguales.

Un teniente recibe un valor de su comandante y $N - 2$ valores de sus iguales. Si el comandante ha fallado, entonces todos los tenientes están correctos y cada uno habrá recogido exactamente el conjunto de valores que les envió el comandante. En otro caso, uno de los tenientes ha fallado; cada uno de sus iguales que estaban correctos recibirá $N - 2$ copias del valor enviado por el comandante junto con un valor enviado por el teniente que ha fallado.

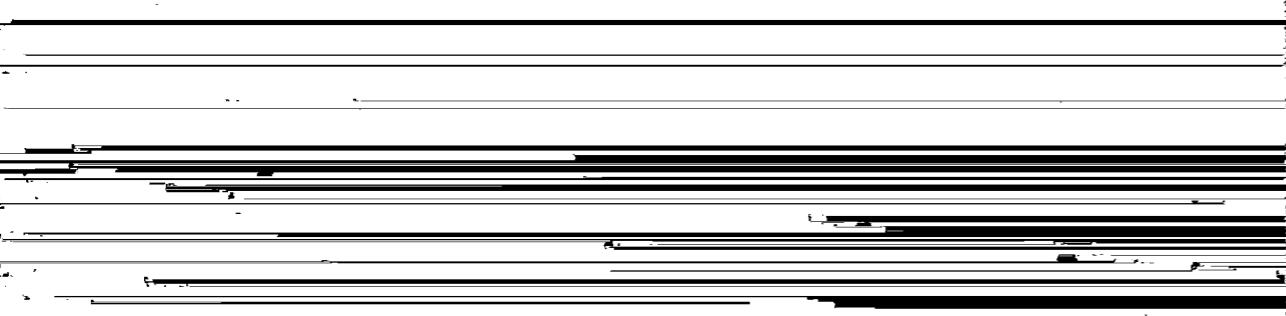
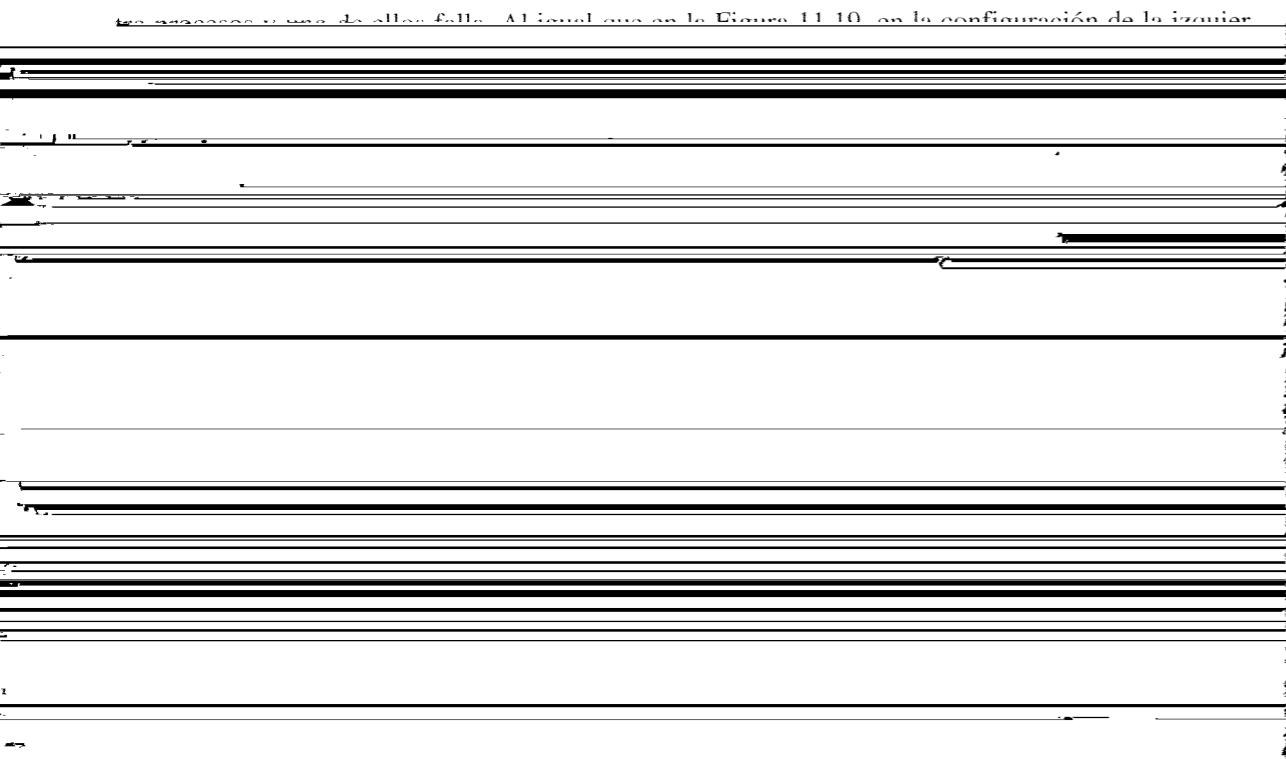
En ambos casos, el teniente que está correcto sólo necesita aplicar una función de mayoría simple al conjunto de valores que ha recibido. Ya que $N \geq 4$, $(N - 2) \geq 2$. Por lo tanto, la función *mayoría* ignorará cualquier valor enviado por el teniente que ha fallado y producirá el valor enviado por el comandante, si éste está correcto.

A continuación se ilustra el algoritmo que se ha esbozado para el caso de cuatro generales. La Figura 11.20 muestra dos escenarios similares a los de la Figura 11.19, pero en este caso hay cu-

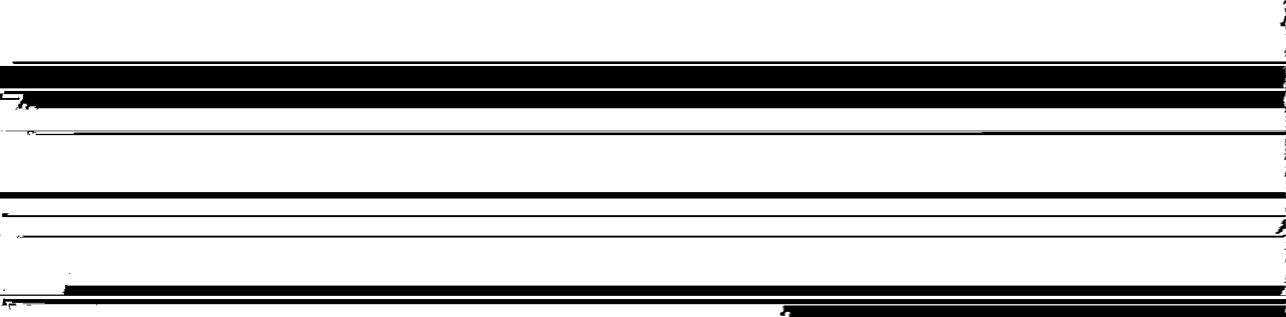


Los procesos fallidos se muestran resaltados

Figura 11.20. Cuatro generales bizantinos.



tro procesos y uno de ellos falla. Al igual que en la Figura 11.19, en la configuración de la izquierda ha fallado p_3 , uno de los tenientes; en la de la derecha, ha fallado el comandante p_1 .



Fischer y otros [1985] demostraron que ningún algoritmo puede garantizar que se encuentre un consenso en un sistema asíncrono, incluso cuando sólo falle uno de los procesos. En un sistema asíncrono, los procesos pueden responder a los mensajes en tiempos arbitrarios y, en consecuencia, no se puede distinguir un proceso lento de uno que se ha caído. Su demostración, que está fuera del alcance de este libro, implica la demostración de que siempre hay alguna continuación de la ejecución de los procesos que evita que se alcance el consenso.

A partir de este resultado de Fischer y otros se deduce que no se puede garantizar una solución en un sistema asíncrono para el problema de los generales bizantinos, ni para el de la consistencia interactiva ni para la multidifusión fiable y totalmente ordenada. Si hubiese una solución, a partir de los resultados de la Sección 11.5.1, se encontraría una solución para el consenso, contradiciendo el resultado de imposibilidad.

Obsérvese el término «garantizar» en la sentencia del resultado de imposibilidad. El resultado no significa que *nunca* se pueda alcanzar el consenso distribuido en un sistema asíncrono. Permite que el consenso se alcance con una probabilidad mayor que cero, confirmándose la observación en la práctica. Por ejemplo, a pesar del hecho de que nuestros sistemas frecuentemente son asíncronos en la práctica, los sistemas de transacciones han estado llegando a consensos durante varios años.

Una aproximación para trabajar a pesar del resultado de imposibilidad es considerar a los sistemas como *parcialmente sincrónicos* . Estos sistemas son lo suficientemente más débiles que los sistemas sincrónicos como para ser útiles como modelos de sistemas en la práctica, y lo suficientemente más fuertes que los sistemas asíncronos como para que pueda resolverse en ellos el consenso [Dwork y otros 1988]. Esta aproximación va más allá del alcance de este libro; no obstante, se van a esbozar otras técnicas que permiten trabajar bajo el resultado de imposibilidad. Estas técnicas son 1) el enmascaramiento de fallos, 2) alcanzar el consenso aprovechándose de los detectores de fallos y 3) alcanzar el consenso mediante la aleatoriedad en los aspectos del comportamiento de los procesos.

◊ **Enmascaramiento de fallos.** La primera técnica consiste en evitar el resultado de imposibilidad en su conjunto mediante el enmascaramiento de los fallos que puedan ocurrir en un proceso (véase la Sección 2.3.2 para una introducción al enmascaramiento de fallos). Por ejemplo, los sistemas de transacciones utilizan el almacenamiento persistente, que sobrevive a la caída de los procesos. Si un proceso se cae, a continuación se reinicia (automáticamente o por medio de un administrador). El proceso guarda en los puntos críticos de su programa suficiente información en el almacenamiento persistente, de tal forma que si se cae y es reiniciado, encontrará suficientes datos como para continuar de forma correcta con la tarea interrumpida. Dicho de otra forma, se comportará como un proceso que está correcto, pero que de vez en cuando toma un largo tiempo largo procesar un paso.

Por supuesto, el enmascaramiento de fallos generalmente se puede aplicar durante el diseño del sistema. El Capítulo 13 tratará cómo los sistemas de transacciones aprovechan el almacenamiento persistente. El Capítulo 14 describirá cómo los fallos en los procesos también pueden ser enmascarados mediante la replicación de componentes software.

◊ **Consenso que utiliza detectores de fallos.** Otro método para evitar el resultado de imposibilidad es emplear detectores de fallos. En la práctica, algunos sistemas utilizan detectores de fallo «perfectos por diseño» para alcanzar el consenso. No obstante, ningún detector de fallo en un sistema asíncrono que funcione exclusivamente en base a paso de mensajes puede realmente ser perfecto. Sin embargo, pueden ponerse de acuerdo en *juzgar* un proceso que ha fallado si no ha respondido en un tiempo delimitado. El hecho de que un proceso no responda no significa que haya fallado, pero el resto de los procesos se comportará como si lo hubiese hecho. En estos casos de «fallo-por-silencio», los procesos descartan, a partir de ese momento, cualesquiera de los mensajes que reciban de ese proceso «fallido». Dicho de otra forma, en la práctica se ha

11.6. RESUMEN

El capítulo comenzó discutiendo la necesidad de que los procesos accedan a recursos compartidos bajo condiciones de exclusión mutua. Los servidores que gestionan los recursos compartidos no siempre incorporan la posibilidad de realizar bloqueos, y se necesita un servicio separado de exclusión mutua distribuida. Se trataron tres algoritmos para conseguir la exclusión mutua: uno que emplea un servidor central, otro basado en un anillo y el tercero basado en la multidifusión que usa relojes lógicos. Ninguno de estos mecanismos puede soportar fallos en la forma en la que fueron descritos, aunque pueden modificarse para que toleren algunos fallos.

A continuación, el capítulo consideró un algoritmo basado en anillo y el algoritmo del abusón, cuyo objetivo común es elegir exclusivamente un proceso dentro de un conjunto, incluso si tienen lugar distintos procesos de elección de forma concurrente. El algoritmo del abusón podría usarse, por ejemplo, para elegir un nuevo maestro servidor de tiempos o un nuevo servidor de bloqueos cuando el existente falla.

El capítulo continuó describiendo la comunicación por multidifusión. Se discutió la multidifusión fiable, en el cual los procesos correctos se ponen de acuerdo en el conjunto de mensajes a entregar, y la multidifusión con ordenación FIFO, causal y total, en la entrega. Se dieron algoritmos para obtener multidifusión fiable y para los tres tipos de ordenación en la entrega.

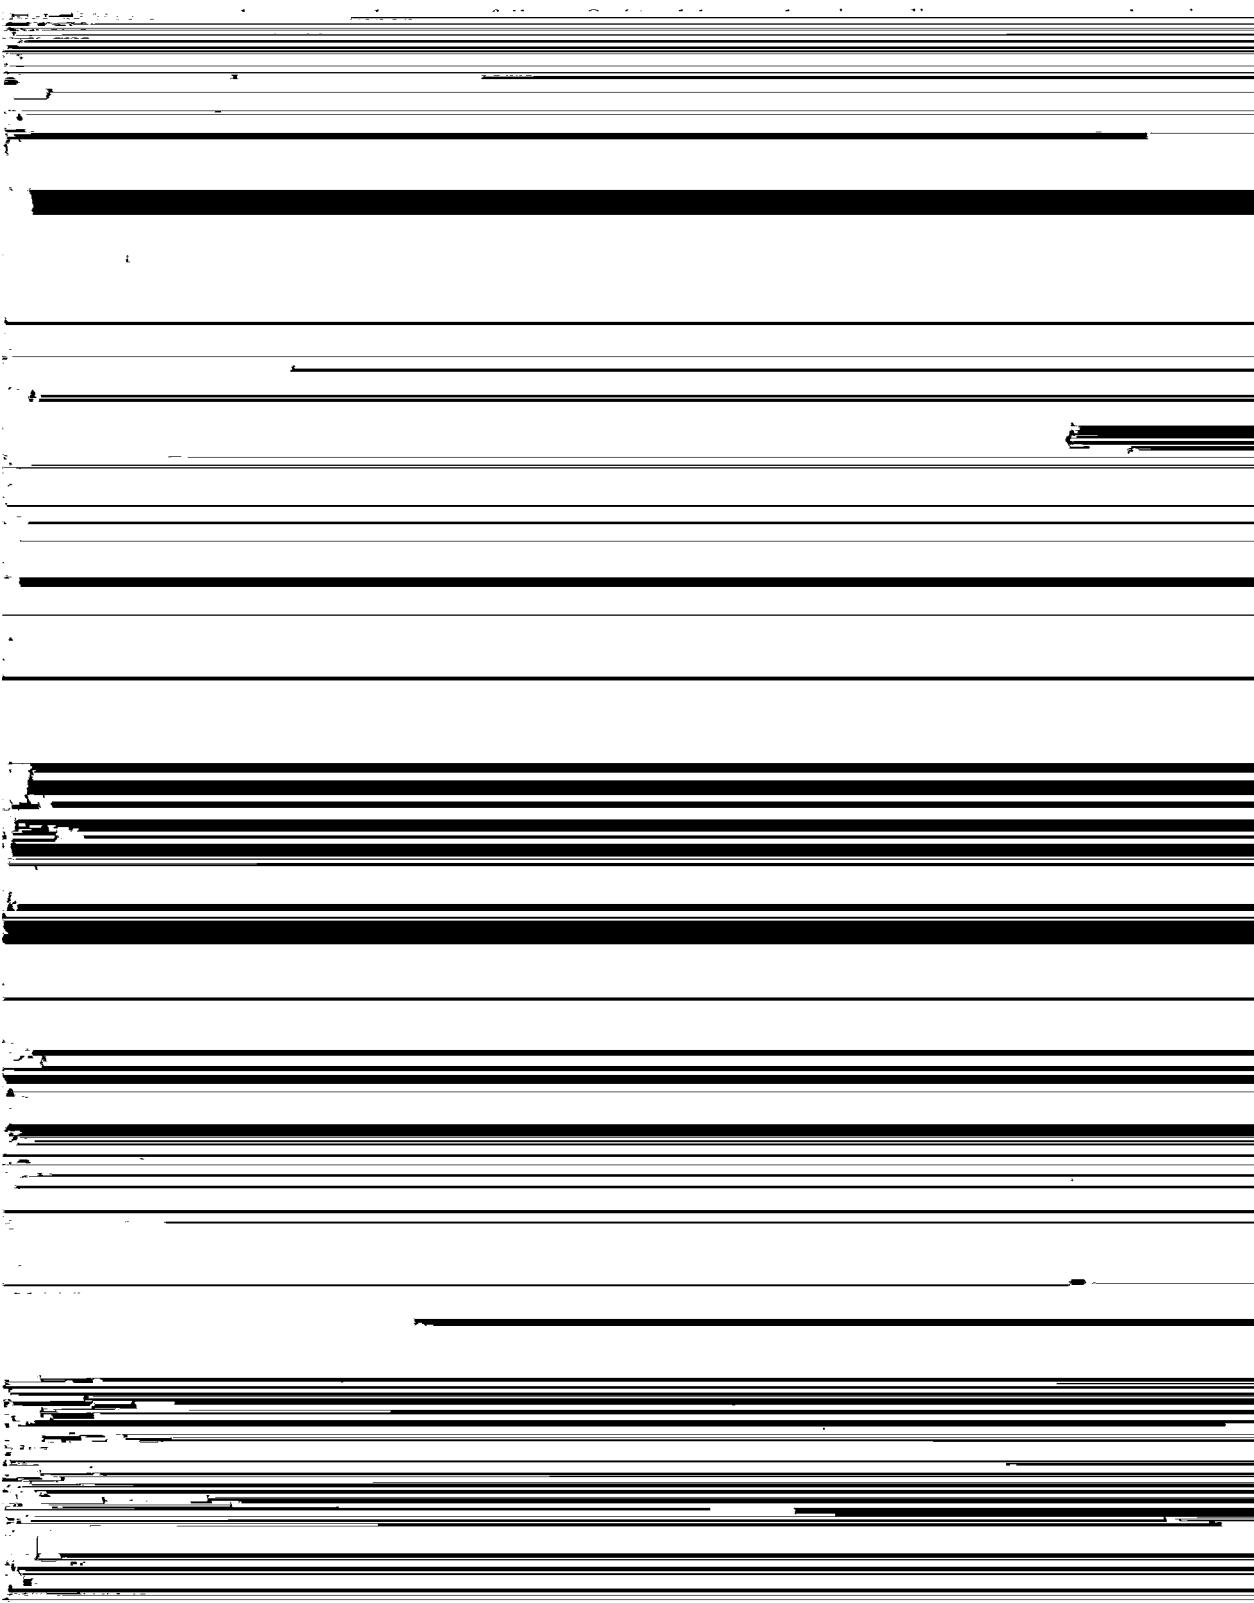
Finalmente, se describieron los problemas del consenso, los generales bizantinos y la consistencia interactiva. Se establecieron las condiciones para poder solucionarlos y se mostraron las relaciones existentes entre ellos, incluyendo la relación entre el consenso y la multidifusión fiable y con ordenación total.

Pueden encontrarse soluciones en un sistema síncrono, como se describió para algunos de los problemas. De hecho, existen soluciones incluso con fallos arbitrarios. Se esbozó parte de la solución propuesta por Lamport y otros para el problema de los generales bizantinos. Aunque algoritmos más recientes tienen una menor complejidad, en principio, ninguno puede evitar las $f + 1$ rondas de dicho algoritmo, a menos que los mensajes se firmen digitalmente.

El capítulo terminó describiendo el resultado fundamental de Fischer y otros que concierne a la imposibilidad de garantizar el consenso en un sistema asíncrono. Se discutió el hecho de que, a pesar de ello, los sistemas llegan regularmente al acuerdo en ese tipo de sistemas.

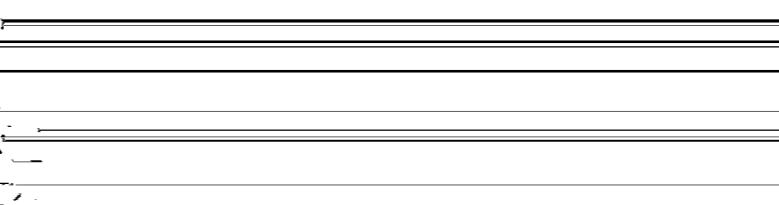
EJERCICIOS

- 11.1.** ¿Es posible implementar un detector de procesos con fallo, fiable o no, utilizando un canal de comunicación no fiable?
- 11.2.** Si todos los procesos cliente usan una comunicación de un único hilo, ¿es relevante la condición EM3 de exclusión mutua (que especifica la entrada según ordenación sucedió-antes)?
- 11.3.** Obténgase una fórmula para la máxima capacidad de procesamiento de un sistema de exclusión mutua en términos del retardo de sincronización.
- 11.4.** En el algoritmo con servidor central para conseguir exclusión mutua, descríbase una situación en la cual dos peticiones no son procesadas con ordenación sucedió-antes.
- 11.5.** Adáptese el algoritmo con servidor central para conseguir exclusión mutua para tratar el fallo por caída de cualquier cliente (en cualquier estado), suponiendo que el servidor está correctamente y que se dispone de un detector de fallos fiable. Comentar si el sistema re-



- Utilíicense estos subconjuntos como grupos de destino de multidifusión para mostrar cómo una ordenación total por parejas no es necesariamente acíclica.
- 11.19.** Constrúyase una solución a la multidifusión fiable con ordenación total en un sistema síncrono utilizando multidifusión fiable y una solución para el problema del consenso.
 - 11.20.** Se ofreció una solución para el problema del consenso a partir de una solución para la multidifusión fiable y totalmente ordenada, que involucraba la selección del primer valor a entregar. Explíquese, utilizando primeros principios, por qué en un sistema asíncrono no podemos obtener una solución utilizando un servicio de multidifusión fiable pero sin ordenación total y la función «mayoría» (ha de notarse que, si se pudiese, ¡esto estaría en contradicción el resultado de imposibilidad de Fischer y otros!) Pista: ténganse en cuenta los procesos lentos o que han fallado.
 - 11.21.** Muestre que se puede alcanzar el acuerdo bizantino por tres generales, con uno de ellos fallando, si los generales firman digitalmente sus mensajes.

TRANSACCIONES



- 12.1. Introducción
- 12.2. Transacciones
- 12.3. Transacciones anidadas
- 12.4. Bloqueos
- 12.5. Control optimista de la concurrencia
- 12.6. Ordenación por marcas de tiempo
- 12.7. Comparación de métodos para el control de concurrencia
- 12.8. Resumen

Este capítulo trata sobre la aplicación de las transacciones y el control de concurrencia a los objetos compartidos gestionados por los servidores.

Una transacción define una secuencia de operaciones que se realiza por el servidor y se garantiza por el mismo que es atómica, ya sea en presencia de múltiples usuarios e incluso de caídas del servidor. Las transacciones anidadas están estructuradas a partir de conjuntos de otras transacciones. Se utilizan particularmente en los sistemas distribuidos porque permiten concurrencia adicional.

Todos los protocolos de control de concurrencia están basados en el criterio de equivalencia en serie y se derivan de reglas para los conflictos entre operaciones. Se describen tres métodos:

- Se utilizan bloqueos para ordenar transacciones que acceden a los mismos objetos de acuerdo con el orden de llegada de sus operaciones sobre dichos objetos.
- El control optimista de concurrencia permite a las transacciones avanzar hasta que están dispuestas para consumarse, que es cuando se realiza una comprobación para ver si se han efectuado operaciones conflictivas con los objetos.
- La ordenación por marca de tiempo utiliza dichas marcas para ordenar las transacciones que acceden a los mismos objetos de acuerdo con los instantes de comienzo.

12.1. INTRODUCCIÓN

La meta de las transacciones es asegurar que todos los objetos gestionados por un servidor permanecen en un estado consistente cuando dichos objetos son accedidos por múltiples transacciones y en presencia de caídas del servidor. En el Capítulo 2 se presentó un modelo de fallo para los sistemas distribuidos. Las transacciones se ocupan de los fallos por caída de los procesos y los de omisión en la comunicación, aunque no cualquier tipo de comportamiento arbitrario (o bizantino). El modelo de fallo para transacciones se presenta en la Sección 12.1.2.

Los objetos que pueden recobrarse después de la caída de su servidor se llaman *recuperables*. En general, esto alude a los objetos gestionados por un servidor en una memoria volátil (por ejemplo, RAM) o en almacenamiento persistente (por ejemplo, disco). Incluso si los objetos se almacenan en memoria volátil, el servidor puede utilizar la memoria persistente para almacenar suficiente información para recobrar el estado de los objetos en caso que caiga el proceso servidor. Esto permite a los servidores hacer que los objetos sean recuperables. Una transacción viene especificada desde un cliente como un conjunto de operaciones sobre los objetos que se realizarán como una unidad indivisible por los servidores que gestionan dichos objetos. Los servidores deben garantizar que se realiza completamente la transacción y que los resultados se almacenan en una memoria permanente o, en el caso de una o más caídas, sus efectos se eliminan completamente. El siguiente capítulo discute temas relacionados con transacciones que implican varios servidores, en particular el cómo decidir el resultado de una transacción distribuida. Este capítulo se concentra en las cuestiones relacionadas con un único servidor. Cada transacción de un cliente es considerada también como indivisible desde el punto de vista de las transacciones de los otros clientes en el sentido de que las operaciones de una transacción no pueden observar los efectos parciales de las otras transacciones. La Sección 12.1.1 analiza la sincronización simple de acceso a objetos, y la 12.2 presenta las transacciones, que precisan de técnicas más avanzadas para prevenir la interferencia entre clientes. La Sección 12.3 discute las transacciones anidadas. Las Secciones de la 12.4 a la 12.6 discuten tres métodos de control de concurrencia para transacciones cuyas operaciones están dirigidas hacia un servidor único (bloqueos, control optimista de concurrencia, y ordenación por marca de tiempo). El Capítulo 13 discutirá cómo se extienden estos métodos para usarlos con transacciones cuyas operaciones están dirigidas hacia varios servidores.

Para explicar algunas de las consideraciones que se hacen en este capítulo, utilizamos un ejemplo bancario, como se ve en la Figura 12.1. Cada cuenta está representada por un objeto remoto cuya interfaz *Cuenta* proporciona las operaciones de hacer depósitos y realizar reintegros y para consultar y actualizar el balance. Cada sucursal del banco está representada por un objeto remoto cuya interfaz *Sucursal* proporciona operaciones para crear una nueva cuenta, para localizar una cuenta por nombre y para preguntar por el total de los fondos de la sucursal.

12.1.1. SINCRONIZACIÓN SENCILLA (SIN TRANSACCIONES)

Uno de los temas más importantes de este capítulo es que a menos que el servidor esté diseñado cuidadosamente, las operaciones realizadas en nombre de diferentes clientes pueden interferir a veces unas con otras. Dicha interferencia puede producir valores incorrectos en los objetos. En esta sección discutimos cómo pueden estar sincronizadas las operaciones de los clientes sin recurrir a las transacciones.

◊ **Operaciones atómicas en el servidor.** En los capítulos anteriores se ha visto que utilizar múltiples hilos es beneficioso para las prestaciones en muchos servidores. Hemos señalado también que el uso de hilos permite que se ejecuten concurrentemente las operaciones de varios clientes y aun accediendo, posiblemente, a los mismos objetos. Por tanto, los métodos de los objetos

<i>deposita(cantidad)</i>	deposita <i>cantidad</i> en la cuenta
<i>extrae(cantidad)</i>	saca <i>cantidad</i> de la cuenta
<i>obténBalance() → cantidad</i>	devuelve el balance de la cuenta
<i>ponBalance(cantidad)</i>	inicializa el balance de la cuenta con <i>cantidad</i>
Operaciones de la interfaz <i>Sucursal</i>	
<i>crea(nombre) → cuenta</i>	crea una nueva cuenta con el nombre especificado
<i>busca(nombre) → cuenta</i>	devuelve una referencia a la cuenta con el nombre especificado
<i>totalSucursal() → cantidad</i>	devuelve el total de todos los balances de la sucursal

Figura 12.1. Operaciones de la interfaz *Cuenta*.

debieran estar diseñados para funcionar en un contexto multi-hilo. Por ejemplo, si los métodos *deposita* (*deposit*) y *extrae* (*withdraw*) no están diseñados para su utilización en un programa multi-hilo, es posible que las acciones de dos o más ejecuciones concurrentes del método puedan entremezclarse arbitrariamente y tener efectos extraños en las variables de instancia de los objetos *cuenta*.

El Capítulo 6 explica el uso de la palabra *synchronized* (sincronizado), que puede ser aplicado a los métodos en Java para asegurar que sólo puede acceder a un objeto un hilo cada vez. En nuestro ejemplo, la clase que implementa la interfaz *Cuenta* será capaz de declarar métodos como sincronizados. Por ejemplo:

```
public synchronized void deposita(int cantidad) throws RemoteException{
    // añade cantidad al balance de la cuenta
}
```

Si un hilo invoca un método sincronizado de un objeto, entonces el objeto es bloqueado efectivamente, y otro hilo que invoque uno de sus métodos sincronizados será bloqueado hasta que el bloqueo anterior sea liberado. Esta forma de sincronización fuerza que la ejecución de los hilos sea separada en el tiempo y asegura que las variables instancia de un único objeto sean accedidas de forma consistente. Sin sincronización, dos invocaciones *deposita* separadas podrían leer el balance antes de que ninguna lo hubiera actualizado, lo que produciría un valor incorrecto. Cualquier método que acceda a una variable instancia que pueda variar debe ser *synchronized*.

Las operaciones que están libres de interferencia de operaciones concurrentes que se están realizando en otros hilos se llaman operaciones atómicas. El uso de métodos sincronizados en Java es una forma de conseguir operaciones atómicas. Pero en otros entornos de programación para servidores multi-hilo las operaciones en objetos necesitan disponer de operaciones atómicas con el fin de mantener sus objetos consistentes. Esto se puede conseguir mediante el uso de cualquier mecanismo de exclusión mutua, como un mutex.

◊ **Mejora de la colaboración del cliente mediante sincronización de las operaciones del servidor.** Los clientes pueden utilizar un servidor como un medio de compartir algunos re-

cursos. Esto se consigue por algunos clientes utilizando operaciones para actualizar los objetos del servidor y otros utilizando operaciones para acceder a ellos. El esquema anterior para acceso sincronizado a objetos proporciona todo lo que se precisa en muchas aplicaciones, previene que los hilos interfieran unos con otros. Sin embargo, algunas aplicaciones necesitan una forma para que los hilos se comuniquen unos con otros.

Por ejemplo, puede surgir una situación en la que la operación requerida por un cliente no puede completarse hasta que se haya realizado otra operación requerida por otro usuario.

Esto puede ocurrir cuando algunos clientes son productores y otros consumidores, los consumidores deben esperar hasta que un productor haya proporcionado algún elemento más del artículo en cuestión. Puede también ocurrir cuando los clientes comparten un recurso, pueden necesitar esperar hasta que otros clientes lo liberan. Se verá más tarde en este capítulo que se llega una situación similar cuando se utilizan los bloqueos o las marcas de tiempo para controlar la concurrencia en las transacciones.

Los métodos *wait* (espera) y *notify* (notifica) Java presentados en el Capítulo 6 permiten que los hilos se comuniquen con los otros de una manera que resuelva los problemas anteriores. Deben utilizarse dentro de los métodos sincronizados de un objeto. Un hilo llama a *wait* en un objeto para suspenderse él mismo y permitir a otro hilo ejecutar un método en ese objeto. Un hilo llama a *notify* para informar que cualquier hilo que esté esperando en el objeto que ha cambiado alguno de sus datos. El acceso a un objeto es todavía atómico cuando un hilo espera por otro: un hilo que llama a *wait* activa su bloqueo y se suspende como una acción atómica, cuando el hilo es activado después de ser notificado adquiere un nuevo bloqueo en el objeto y recupera la ejecución después del *wait*. Un hilo que llama a *notify* (desde un método sincronizado) completa la ejecución del método antes de liberar el bloqueo en el objeto.

Consideremos la implementación de un objeto *Cola* compartida con dos métodos: *primero* extrae y devuelve el primer objeto de la cola, *añade* añade un objeto determinado al final de la cola. El método *primero* comprueba primero si la cola está vacía, en cuyo caso llama a un *wait* en la cola. Si un cliente llama a *primero* cuando la cola está vacía, no conseguirá ninguna respuesta hasta que otro cliente haya añadido algo en la cola, la operación *añade* efectuará *notify* cuando haya añadido un objeto a la cola. Esto permite que uno de los hilos que están esperando continúe su ejecución y devuelva el primer objeto de la cola a su cliente. Cuando los hilos pueden sincronizar sus acciones en un objeto por medio de *wait* y *notify*, el servidor mantiene las solicitudes que no pueden ser satisfechas inmediatamente y el cliente espera por una contestación hasta que otro cliente ha producido lo que necesita.

En la última sección de bloqueos para transacciones, discutimos la implementación de un bloqueo como un objeto con operaciones sincronizadas. Cuando los clientes intentan obtener un bloqueo, se les puede hacer esperar hasta que el bloqueo es liberado por otros clientes.

Sin la capacidad para sincronizar hilos de esta forma, no se puede satisfacer a un cliente inmediatamente, por ejemplo, a un cliente que llame al primer método de una cola vacía se le dice que lo intente más tarde. Esto no es satisfactorio, porque supondrá que el cliente debe estar consultando al servidor y el servidor debe satisfacer estas consultas extras. Es también potencialmente injusto porque otros clientes pueden efectuar solicitudes antes de que el cliente que espera lo intente de nuevo.

12.1.2. MODELO DE FALLOS PARA TRANSACCIONES

Lampson [1981a] propuso un modelo de fallos para transacciones distribuidas que considera los fallos en discos, servidores y comunicación. En este modelo, se intenta que los algoritmos trabajen correctamente en presencia de fallos predecibles, pero no se hacen consideraciones sobre su comportamiento cuando ocurre un desastre. Aunque pueden existir errores, no pueden ser detectados y

considerados antes de que ocurra cualquier comportamiento incorrecto. El modelo establece lo siguiente:

- Las escrituras sobre almacenamiento permanente pueden fallar, o porque no se escribe nada o porque se escribe un valor incorrecto, por ejemplo, escribir en el bloque incorrecto es un desastre. El almacenamiento en disco puede deteriorarse. Las lecturas sobre almacenamiento permanente pueden detectar (mediante una suma de comprobación) cuando un bloque de datos es incorrecto.
- Los servidores pueden fallar ocasionalmente. Cuando un servidor averiado se reemplaza por un nuevo proceso, su memoria volátil se sitúa primeramente en un estado en el que no conoce ninguno de los valores (por ejemplo, de objetos) de antes de la ruptura. Después lleva a cabo un procedimiento de recuperación, utilizando la información del almacenamiento permanente y la obtenida de otros procesos para fijar los valores de los objetos incluyendo los relacionados con el protocolo de consumación (*commit*) en dos fases (se verá en la Sección 13.6). Cuando un procesador está fallando, se le considera caído para prevenir el envío de mensajes erróneos y la escritura de valores incorrectos en el almacenamiento permanente, esto es, para no producir fallos arbitrarios. Las rupturas se pueden producir en cualquier instante de tiempo, en particular, pueden ocurrir durante la recuperación.
- Puede existir un retardo arbitrario antes que llegue un mensaje. Un mensaje puede haberse perdido, duplicado o modificado. El receptor puede detectar mensajes modificados (mediante una suma de comprobación). Tanto a los mensajes falsificados como a los mensajes corruptos no detectados se les contempla como desastres.

El modelo de fallos para almacenamiento permanente, procesadores y comunicaciones se usó para diseñar un sistema estable cuyos componentes pueden sobrevivir a un único fallo y presentar un modelo de fallos sencillo. En particular, el *almacenamiento estable* proporcionaba una operación *write* atómica en presencia de un fallo de la operación *write* o una ruptura del proceso. Esto se consiguió replicando cada bloque en dos bloques de disco. Una operación *write* se aplicaba a los pares de bloques de disco, y en el caso de un fallo siempre estaba disponible un bloque correcto. Un *procesador estable* utilizaba almacenamiento estable para facilitar la recuperación de objetos después de una ruptura. Los errores de comunicación se enmascaraban utilizando un mecanismo de llamada a procedimientos remoto fiable.

12.2. TRANSACCIONES

En algunas situaciones, los clientes necesitan que una secuencia de solicitudes separadas al servidor sean atómicas en el sentido de:

1. Estén libres de interferencia por las operaciones que se están realizando en nombre de otros clientes concurrentes.
2. Todas las operaciones deben ser completadas con éxito o no tendrán ningún efecto si el servidor falla.

Volvemos a nuestro ejemplo bancario para ilustrar las transacciones. Un cliente, que realiza una secuencia de operaciones en una cuenta particular del banco por encargo de un usuario, realizará primero una búsqueda (*busca*) de la cuenta por nombre y después aplicará las operaciones de depositar (*deposita*), extraer (*extrae*) y obtener balance (*obténBalance*) directamente sobre la cuenta considerada. En nuestros ejemplos, utilizamos cuentas con nombres *A*, *B* y *C*. El cliente las localiza y almacena las referencias a ellas en las variables *a*, *b* y *c* de tipo cuenta (*Cuenta*). Los detalles de la búsqueda de cuentas por nombre y las declaraciones de variables se omiten de los ejemplos.

Transacción T:
 a.extrae(100);
 b.deposita(100);
 c.extrae(200);
 d.deposita(200);



Figura 12.2. Una transacción bancaria de un cliente.

Transacción T:
 a.extrae(100);
 b.deposita(100);
 c.extrae(200);
 d.deposita(200);

La Figura 12.2 muestra un ejemplo de la transacción de un cliente que especifica una serie de

abreTransacción() → trans;
 comienza una nueva transacción y proporciona una única TID *trans*. Este identificador será utilizado en el resto de las operaciones de la transacción.
cierraTransacción(trans) → (*consumado*, *abortado*);
 finaliza una transacción: la devolución de un valor *consumado* indica que la transacción se ha consumado; la devolución de un valor *abortado* indica que ella se ha abortado.
abortaTransacción(trans);
 aborta la transacción.

Figura 12.3. Operaciones en la Interfaz Coordinador.

reconoce la finalización de una transacción del cliente, todos los cambios de la transacción en los objetos deben haber sido registrados en almacenamiento permanente.

Un servidor que soporta transacciones debe sincronizar suficientemente las operaciones para asegurar que se satisface el requisito de aislamiento. Una forma de hacerlo es realizar las transacciones secuencialmente, una cada vez en un orden arbitrario. Desafortunadamente, esta solución sería generalmente inaceptable para servidores cuyos recursos son compartidos por múltiples usuarios interactivos. En nuestro ejemplo bancario, es deseable permitir a distintos cajeros realizar transacciones en línea al mismo tiempo.

El fin de cualquier servidor que soporta transacciones es maximizar la concurrencia. Se permite, por tanto, que se ejecuten concurrentemente transacciones si el efecto de ellas fuera el mismo que si se ejecutaran secuencialmente, es decir si fueran *secuencialmente equivalentes* o *secuenciales*.

Se pueden añadir recursos de transacciones a los servidores de objetos recuperables. Cada transacción es creada y gestionada por un administrador, que implementa la interfaz *Coordinador* mostrada en la Figura 12.3. El coordinador da a cada transacción un identificador, o TID. El cliente invoca el método *abreTransacción* del coordinador para introducir una nueva transacción, se asigna un identificador de transacción, o TID, y se devuelve. Al final de una transacción, el cliente invoca el método *cierraTransacción* para indicar su fin; todos los objetos recuperables accedidos durante la transacción debieran ser guardados. Si, por alguna razón, el cliente quiere abortar la transacción, invoca el método *abortaTransacción*, y todos los efectos debieran ser eliminados.

◊ **Propiedades ACID.** Härder y Reuter [1983] sugirieron el nemotécnico **ACID** (*Atomicity*, *Consistency*, *Isolation*, *Durability*) para recordar las propiedades de las transacciones de la forma siguiente:

Atomicidad: una transacción debe ser todo o nada.

Consistencia: una transacción hace pasar el sistema de un estado consistente a otro.

Aislamiento.

Durabilidad.

No hemos incluido *consistencia* en nuestra propia lista de propiedades de las transacciones porque generalmente es responsabilidad de los programadores de los servidores y los clientes el asegurar que las transacciones dejen la base de datos consistente.

Como un ejemplo de consistencia, supongamos que en el ejemplo del banco, un objeto mantiene la suma de todos los balances de las cuentas y su valor se utiliza como el resultado de *totalSucursal*. Los clientes pueden obtener la suma de los balances de todas las cuentas utilizando *totalSucursal* o llamando a *obténBlance* en cada cuenta. Para la consistencia, se debe obtener el mismo resultado de ambos métodos. Para mantener esta consistencia, las operaciones de *deposita* y *extrae* deben actualizar el objeto conservando la suma de todos los balances de las cuentas.

Con éxito	Abortado por el cliente	Abortado por el servidor
<i>AbreTransacción</i>	<i>AbreTransacción</i>	<i>AbreTransacción</i>
<i>Operación</i>	<i>Operación</i>	<i>Operación</i>
<i>Operación</i>	<i>Operación</i>	<i>Operación</i>
•	•	El servidor aborta la transacción →
•	•	•
<i>Operación</i>	<i>Operación</i>	<i>ERROR en la operación informado al cliente</i>
<i>CierraTransacción</i>	<i>AbortaTransacción</i>	

Figura 12.4. Historias de vida de una transacción.

Cada transacción se obtiene por cooperación entre un programa cliente, algunos objetos recuperables y un coordinador. El cliente especifica la secuencia de invocaciones sobre los objetos recuperables que forman la transacción. Para conseguir esto, el cliente envía con cada invocación el identificador de la transacción devuelto por *abreTransacción*. Una forma de hacer esto posible es incluir el TID como un argumento extra en cada operación de un objeto recuperable. Por ejemplo, en el servicio bancario la operación *deposita* podría definirse:

deposita(trans, cantidad)

deposita la *cantidad* en la cuenta para la transacción cuyo TID es *trans*

Cuando se proporcionan las transacciones como middleware, se puede pasar el TID implícitamente en cada invocación remota entre *abreTransacción* y *cierraTransacción* o *abortaTransacción*. Esto es lo que hace el servicio de transacciones de CORBA. En nuestros ejemplos no mostraremos los TID.

Así, una transacción finaliza cuando el cliente realiza una solicitud *cierraTransacción*. Si la transacción ha progresado normalmente la contestación indica que la transacción está consumada, esto constituye una garantía para el cliente de que todos los cambios solicitados en la transacción se registran permanentemente y que cualquiera de las transacciones futuras que accedan a los mismos datos verán los resultados de todos los cambios realizados durante la transacción.

Alternativamente, la transacción puede tener que abortar por alguna de distintas razones relacionadas con la naturaleza de la transacción misma, por conflictos con otra transacción o por fallo de un proceso o computador. Cuando una transacción es abortada, las partes implicadas (los objetos recuperables y el coordinador) deben asegurar que ninguno de los efectos es visible para futuras transacciones, en los objetos o en sus copias en almacenamiento permanente.

Una transacción o tiene éxito o se aborta de una de las dos maneras siguientes, el cliente la aborta (utilizando una llamada *abortaTransacción* para el servidor) o la aborta el servidor. La Figura 12.4 muestra estas tres historias de vida alternativas para las transacciones. Nos referimos a una transacción como *en fallo*, o *fallando*, en ambos casos.

◇ **Acciones de servicio relacionadas con la ruptura de un proceso.** Si un proceso servidor falla inesperadamente, se reemplazará en algún momento. El nuevo proceso servidor aborta todas las transacciones no finalizadas y usa un procedimiento de recuperación para restablecer los valores de los objetos a los valores producidos por la transacción finalizada de forma correcta más recientemente. Para tratar con un cliente que falla inesperadamente durante una transacción, los servidores pueden dar a cada transacción un tiempo de expiración y abortar cualquier transacción que no haya sido completada antes de su tiempo de expiración.

◇ **Acciones del cliente relativas a la ruptura del proceso servidor.** Si un servidor falla mientras una transacción está en progreso, el cliente será consciente de ello cuando una de las operaciones devuelve una excepción después de un *timeout* (tiempo límite de espera). Si un servidor falla y es reemplazado durante el progreso de una transacción, ésta ya no será válida y el cliente debe ser informado con una excepción para la siguiente operación. En cualquier caso, el cliente debe formular un plan, posiblemente consultando con la persona humana, para la finalización o el abandono de la tarea de la que la transacción era una parte.

12.2.1. CONTROL DE CONCURRENCIA

Esta sección ilustra dos problemas bien conocidos de transacciones concurrentes en el contexto del ejemplo bancario, el problema de las «actualizaciones perdidas» y el de las «recuperaciones inconsistentes». Esta sección muestra cómo ambos problemas pueden evitarse efectuando ejecuciones de transacciones secuencialmente equivalentes. Suponemos que cada operación *deposita*, *extrae*, *obténBalance* y *ponBalance* está sincronizada, es decir, sus efectos en la variable de instancia que registra el balance de la cuenta es atómica.

◇ **El problema de las actualizaciones perdidas.** Este problema se muestra mediante el siguiente par de transacciones sobre las cuentas bancarias A, B y C, cuyos balances iniciales son 100\$, 200\$ y 300\$ respectivamente. La transacción *T* transfiere cierta cantidad desde la cuenta A a la cuenta B. La transacción *U* transfiere otra cantidad desde la cuenta C a la B. En ambos casos, la cantidad transferida se calcula para incrementar el balance de B en un 10 %. Los efectos netos sobre la cuenta B al ejecutar las transacciones *T* y *U* debieran hacer incrementar el balance de la cuenta B en un 10 % dos veces, por lo que el valor final será 242\$.

Consideremos ahora los efectos de permitir que las transacciones *T* y *U* se ejecuten concurrentemente, como en la Figura 12.5. Ambas transacciones obtiene el balance de B como 200\$ y después depositan 20\$. El resultado es incorrecto, al incrementar el balance de la cuenta B en 20\$ en lugar de 42\$. Esto es un ejemplo del problema de las «actualizaciones perdidas». La actualización de *U* se pierde porque *T* escribe sin mirar. Ambas transacciones han leído el valor previo antes de escribir el nuevo valor.

En la Figura 12.5, se muestran sucesivamente las operaciones que afectan al balance de una cuenta, y el lector debe suponer que la operación de una cierta línea se ejecuta en un momento posterior al de otra que se encuentra en una línea superior.

Transacción <i>T</i> :	Transacción <i>U</i> :
<i>balance = b.obténBalance();</i>	<i>balance = b.obténBalance();</i>
<i>b.ponBalance(balance*1.1);</i>	<i>b.ponBalance(balance*1.1);</i>
<i>a.extrae(balance/10);</i>	<i>c.extrae(balance/10);</i>
<i>balance = b.obténBalance();</i> 200\$	<i>balance = b.obténBalance();</i> 200\$
<i>b.ponBalance(balance*1.1);</i> 220\$	<i>b.ponBalance(balance*1.1);</i> 220\$
<i>a.extrae(balance/10);</i> 80\$	<i>c.extrae(balance/10);</i> 280\$

Figura 12.5. El problema de las actualizaciones perdidas.

Transacción V:	Transacción W:
<i>a.extrae(100);</i>	<i>unasucursal.totalSucursal();</i>
<i>b.deposita(100)</i>	
<i>a.extrae(100)</i>	<i>total = a.obténBalance()</i>
<i>b.deposita(100)</i>	<i>100\$</i>
	<i>300\$</i>
	<i>total = total + b.obténBalance();</i>
	<i>400\$</i>
	<i>total = total + c.obténBalance();</i>
	<i>...</i>

Transacción V:	Transacción W:
<i>a.extrae(100);</i>	<i>unasucursal.totalSucursal();</i>
<i>b.deposita(100)</i>	
<i>a.extrae(100)</i>	<i>100\$</i>
<i>b.deposita(100)</i>	<i>300\$</i>
	<i>total = a.obténBalance()</i>
	<i>100\$</i>
	<i>total = total + b.obténBalance();</i>
	<i>400\$</i>
	<i>total = total + c.obténBalance();</i>
	<i>...</i>

Figura 12.8. Un solapamiento de V y W secuencialmente equivalente.

ción se realiza antes que la otra, porque la última transacción leerá el valor escrito por la anterior. Como un solapamiento secuencialmente independiente de dos transacciones produce el mismo efecto de una secuencial, podemos resolver el problema de las actualizaciones perdidas mediante la equivalencia secuencial. La Figura 12.7 muestra dicho solapamiento en el que las operaciones que afectan a la cuenta compartida B, son realmente secuenciales, puesto que la transacción T realiza todas las operaciones antes que las realice la transacción U. Otro solapamiento de T y U que tenga esta propiedad es uno en el que la transacción U finaliza sus operaciones en la cuenta B antes de que comience la transacción T.

Vamos a considerar ahora el efecto de la equivalencia secuencial con relación al problema de las recuperaciones equivalentes, en la que la transacción V está transfiriendo una suma de desde la cuenta A a la cuenta B y la transacción W está obteniendo la suma de todos los balances (véase la Figura 12.6). El problema de las recuperaciones inconsistentes puede ocurrir cuando una transacción de recuperación se ejecuta concurrentemente con una transacción de actualización. No puede ocurrir si la transacción de recuperación se realiza antes o después de una transacción de actualización. Un solapamiento secuencialmente equivalente de una transacción de recuperación y una de actualización, por ejemplo como en la Figura 12.8, impedirá que ocurran las recuperaciones inconsistentes.

◊ **Operaciones conflictivas.** Cuando decimos que un par de operaciones tienen conflictos queremos decir que su efecto combinado depende del orden en el que se ejecutan. Para simplificar las cosas consideremos un par de operaciones *lee* y *escribe*. *Lee* accede al valor de un objeto y *escribe* cambia su valor. El *efecto* de una operación se refiere al valor colocado en el objeto por una operación *escribe* y el resultado devuelto por una operación *lee*. En la Figura 12.9 se dan las reglas de conflicto para *lee* y *escribe*.

Operaciones de diferentes transacciones	Conflicto	Causa	
Lee	Lee	No	Porque el efecto de un par de operaciones de <i>lectura</i> no depende del orden en el que son ejecutadas
Lee	Escribe	Sí	Porque el efecto de una operación de <i>lectura</i> y una de <i>escritura</i> dependen del orden de su operación
Escribe	Escribe	Sí	Porque el efecto de un par de operaciones de <i>escritura</i> depende del orden de su ejecución

Figura 12.9. Reglas de conflicto en las operaciones *lee* y *escribe*.

Transacción T:	Transacción U:
$x = \text{lee}(i)$ $\text{escribe}(i, 10)$	$y = \text{lee}(j)$ $\text{escribe}(j, 30)$
$\text{escribe}(j, 20)$	$z = \text{lee}(i)$

Figura 12.10. Un solapamiento de las operaciones de las transacciones T y U no secuencialmente equivalente.

Para cualquier par de transacciones, es posible determinar el orden de pares de operaciones conflictivas sobre objetos accedidos por ambas. La equivalencia secuencial puede definirse en términos de las operaciones conflictivas como sigue:

Para que dos transacciones sean *secuencialmente equivalentes*, es necesario y suficiente que todos los pares de operaciones conflictivas de las dos transacciones se ejecuten en el mismo orden sobre los objetos a los que ambas acceden.

Consideremos como ejemplo las transacciones T y U , definidas como sigue:

T : $x = \text{lee}(i)$; $\text{escribe}(i, 10)$; $\text{escribe}(j, 20)$;

U : $y = \text{lee}(j)$; $\text{escribe}(j, 30)$; $z = \text{lee}(i)$;

Consideremos ahora el solapamiento de sus ejecuciones, mostrado en la Figura 12.10. Toma nota que el acceso de cada transacción a los objetos i y j es secuencial con respecto al otro, porque T realiza todos sus accesos a i antes de que lo haga U y U hace todos sus accesos a j antes de que lo haga T . Pero la ordenación no es secuencialmente equivalente, porque los pares de operaciones conflictivas no se hacen el mismo orden en ambos objetos. Las ordenaciones secuencialmente equivalentes requieren una de las dos condiciones siguientes:

1. T accede a i antes de U y T accede a j antes de U .
2. U accede a i antes de T y U accede a j antes de T .

La equivalencia secuencial se utiliza como un criterio para la obtención de protocolos de control de concurrencia. Estos protocolos intenta secuenciarizar las transacciones en sus accesos a los objetos. Para el control de concurrencia se utilizan normalmente tres aproximaciones alternativas: bloqueo, control de concurrencia optimista y ordenación por marca de tiempo. Sin embargo, los sistemas más pragmáticos utilizan el bloqueo, que se discutirá en la Sección 12.4. Cuando se utiliza el bloqueo, el servidor establece un bloqueo, etiquetado con el identificador de la transacción, en cada objeto justo en el momento antes de ser accedido y elimina estos bloqueos cuando la transacción ha finalizado. Mientras un objeto está bloqueado, sólo la transacción que ha realizado el bloqueo puede acceder al objeto; las otras transacciones deberán esperar hasta que el objeto sea desbloqueado o, en algunos casos, compartir el bloqueo. El uso de bloqueos puede conducir al bloqueo mutuo (*deadlock*), en el que cada transacción espera a que la otra libere los bloqueos, como, por ejemplo, cuando un par de transacciones ha bloqueado cada una un objeto bloqueado al que precisa acceder la otra. Discutiremos el problema del bloqueo mutuo y algunas soluciones para ello en la Sección 12.4.1.

El control optimista de la concurrencia se describe en la Sección 12.5. En los esquemas optimistas, una transacción avanza hasta que solicita la consumación, y antes de que se le autorice a realizar la consumación el servidor realiza una comprobación para descubrir si se han efectuado

operaciones —sobre objetos— que presentan algún conflicto con las operaciones de otras transacciones concurrentes, en cuyo caso el servidor la aborta y el cliente podrá iniciarla de nuevo. El objetivo de la comprobación es asegurar que todos los objetos son correctos.

La ordenación por marcas de tiempo se describe en la Sección 12.6. En esta ordenación, un servidor registra el tiempo más reciente de lectura y escritura en cada objeto y para cada operación, se compara la marca de tiempo de la transacción con la del objeto para determinar si puede realizarse inmediatamente, o bien retrasarse o rechazarse. Cuando se retrasa una operación, la transacción espera, cuando es rechazada; cuando es rechazada, la transacción es abortada.

Básicamente, el control de concurrencia puede ser obtenido o porque los clientes de las transacciones esperen uno por otro o reiniciando las transacciones después de que se hayan detectado conflictos entre operaciones, o bien mediante una combinación de las dos.

12.2.2. RECUPERABILIDAD DE TRANSACCIONES ABORTADAS

Los servidores deben registrar los efectos de todas las transacciones finalizadas y ninguno de los efectos de las transacciones abortadas. Deben considerar, por tanto, el hecho de que una transacción pueda ser abortada en previsión de que afecte a otras transacciones concurrentes si es el caso.

Esta sección muestra dos problemas asociados con las transacciones abortadas en el contexto del ejemplo del banco. Estos problemas se conocen como «lecturas sucias» y «escrituras prematuros», y ambas pueden aparecer en presencia de ejecuciones secuencialmente equivalentes. Estas cuestiones están relacionadas con el efecto de las operaciones sobre objetos, tales como el balance de una cuenta de banco. Para simplificar las cosas, se consideran dos categorías de operaciones, operaciones de lectura (*lectura*) y de escritura (*escritura*). En nuestras ilustraciones, *obténBalance* es una operación de lectura y *ponBalance* es una de escritura.

◊ **Lecturas sucias.** La propiedad de aislamiento de las transacciones requiere que éstas no vean el estado no finalizado de las demás. El problema de la «lectura sucia» está causado por la interacción entre una operación de lectura en una transacción y una operación temprana de escritura en otra transacción sobre el mismo objeto. Considérense las trazas mostradas en la Figura 12.11, donde T consigue el balance de la cuenta A y le añade 10\$ más, a continuación U consigue el balance de A y le añade 20\$ más, y las dos ejecuciones son secuencialmente equivalentes. Supongamos ahora que la transacción T aborta después de que U ha finalizado. Entonces la transacción U habrá visto un valor que nunca ha existido, puesto que se restaurará el valor original en A . En este caso se dice que la transacción U ha realizado una *lectura sucia*. Como ha finalizado no puede ser desechara.

Transacción T:	Transacción U:
$a.\text{obténBalance}()$	$a.\text{obténBalance}()$
$a.\text{ponBalance(balance + 10)}$	$a.\text{ponBalance(balance + 20)}$
$balance = a.\text{obténBalance}()$ $a.\text{ponBalance(balance + 10)}$	$balance = a.\text{obténBalance}()$ $a.\text{ponBalance(balance + 20)}$ consumar transacción
100\$	110\$
110\$	130\$
abortar transacción	

Figura 12.11. Una lectura sucia cuando se aborta T .

◊ **Recuperación de transacciones.** Si una transacción (como U) ha finalizado después de que ha visto los efectos de una transacción que posteriormente ha sido abortada, la situación no es recuperable. Para asegurar que tales situaciones no se planteen, cualquier transacción (como U) que esté en peligro de tener una lectura sucia rechaza la finalización de su operación. La estrategia para la recuperación es retrasar la finalización hasta después de que haya finalizado cualquier otra transacción cuyo estado no finalizado haya sido observado. En nuestro ejemplo, U retrasa su finalización hasta después que se produzca la finalización de T . En el caso en que T sea abortada, U debe abortar también.

◊ **Abortos en cascada.** En la Figura 12.11, suponemos que la transacción U retrasa su consumación hasta después que T aborte. Como hemos dicho, U debe abortar también. Desafortunadamente, si algunas otras transacciones han visto los efectos debidos a U , deberían también ser abortadas. El aborto de estas últimas transacciones puede causar que se aborten todavía más transacciones. Tales situaciones se conocen como *abortos en cascada*. Para evitar los abortos en cascada, solo se permite a las transacciones leer objetos que fueron escritos por transacciones consumadas. Para asegurar que esto es así, debe retrasarse cualquier operación de *lectura* hasta que haya sido consumada o abortada cualquier otra transacción que haya realizado una operación de *escritura* sobre el mismo objeto. La evitación de los abortos en cascada es una condición más fuerte que la recuperabilidad.

◊ **Escrituras prematuras.** Consideremos otra implicación de la posibilidad que una transacción pueda abortar. Ésta es una relacionada con las interacciones entre operaciones de *escritura* en el mismo objeto que se realizan en diferentes transacciones. Como ilustración, consideremos dos transacciones *InicializaBalance* T y U sobre la cuenta A , como se muestra en la Figura 12.12. Antes de las transacciones el balance de la cuenta A era de 100\$. Las dos ejecuciones son secuencialmente equivalentes, con T poniendo el balance a 105\$ y U a 110\$. Si la transacción U aborta y T se consuma, el balance debería ser 105\$.

Algunos sistemas de bases de datos implementan la acción *aborta* restableciendo las «imágenes anteriores» de todas las *escrituras* de una transacción. En nuestro ejemplo, A es 100\$ inicialmente, que es la «imagen anterior» de la *escritura* de T ; de forma similar 105\$ es la «imagen anterior» de la *escritura* de U . Por tanto si U aborta, conseguimos el balance correcto de 105\$.

Ahora consideremos el caso en que U se consume y después T aborta. El balance debería estar a 110\$, pero la imagen anterior de la *escritura* de T es 100\$, por lo que conseguimos el balance incorrecto de 100\$. De forma similar si T aborta y después U aborta, la «imagen anterior» de la *escritura* de U es 105\$ por lo que conseguimos el balance erróneo de 105\$, el balance debería proporcionar 100\$.

Para garantizar los resultados correctos en un esquema de recuperación que utiliza las imágenes anteriores, las operaciones de *escritura* deben ser retrasadas hasta que hayan sido consumadas o abortadas las transacciones anteriores que actualizaron los mismos objetos.

◊ **Ejecuciones estrictas de las transacciones.** Generalmente, se requiere que las transacciones retrasen sus operaciones de *lectura* y *escritura* lo suficiente como para impedir tanto las «lec-

Transacción T : <code>a.ponBalance(105)</code>	Transacción U : <code>a.ponBalance(110)</code>
100\$	
<code>a.ponBalance(105)</code>	110\$

Figura 12.12. Reescritura en valores no consumados.

turas sucias» como las «escrituras prematuras». Las ejecuciones de las transacciones se llaman *estrictas* si el servicio de las operaciones de *lectura* y de *escritura* sobre un objeto se retrasa hasta que todas las transacciones que previamente escribieron el objeto han sido consumadas o abortadas. La ejecución estricta de las transacciones hace cumplir la deseada propiedad de aislamiento.

◊ **Versiones provisionales.** Para que un servidor de objetos recuperables participe en las transacciones, debe estar diseñado de forma que las actualizaciones de los objetos puedan ser eliminadas si y cuando la transacción aborta. Para hacer esto posible, todas las operaciones de actualización realizadas durante una transacción se hacen sobre versiones provisionales de los objetos en memoria volátil. A cada transacción se le proporciona su propio conjunto privado de versiones provisionales de cualquiera de los objetos que ella ha alterado. Todas las operaciones de actualización de una transacción almacenan valores de los objetos en el propio conjunto privado de la transacción si es posible, o fallan.

Las versiones provisionales son transferidas a los objetos sólo cuando una transacción se consuma, en cuyo caso ellas serán también registradas en memoria permanente. Esto se realiza en un único paso, durante el cual las otras transacciones son excluidas de acceder a los objetos que están siendo alterados. Cuando una transacción aborta, sus versiones provisionales se borran.

12.3. TRANSACCIONES ANIDADAS

Las transacciones anidadas extienden el modelo anterior de transacción permitiendo que las transacciones estén compuestas de otras. Por tanto desde una transacción se pueden arrancar varias transacciones, permitiendo considerarlas como módulos que pueden componerse cuando se precise.

La transacción más exterior en un conjunto de transacciones anidadas se llama la transacción de *nivel superior*. Las transacciones diferentes de la del nivel superior se llaman *subtransacciones*. Por ejemplo en la Figura 12.13, T es una transacción de *nivel-superior*, que inicializa un par de transacciones T_1 y T_2 . La subtransacción T_1 inicializa su propio par de transacciones T_{11} y T_{12} . Del mismo modo, la transacción T_2 inicia su propia subtransacción T_{21} que inicia otra subtransacción T_{211} .

Una subtransacción se presenta como atómica a su padre con respecto a los fallos en la transacción y al acceso concurrente. Las subtransacciones del mismo nivel, como T_1 y T_2 pueden ejecutarse concurrentemente pero sus accesos a objetos comunes son secuenciados, por ejemplo mediante el esquema de bloqueo descrito en la Sección 12.4. Cada subtransacción puede fallar independientemente de su padre y otras subtransacciones. Cuando una subtransacción aborta, la

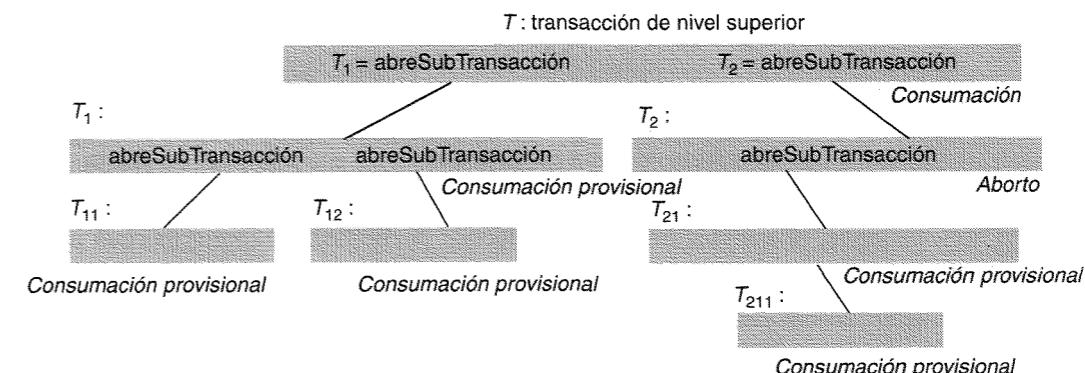


Figura 12.13. Transacciones anidadas.

transacción padre puede elegir una subtransacción alternativa para completar su tarea. Por ejemplo, una transacción para entregar un mensaje de correo a una lista de destinatarios podría estar estructurada así:

Figura 12.12 Transacciones anidadas



transacción padre puede elegir una subtransacción alternativa para completar su tarea. Por ejemplo, una transacción para entregar un mensaje de correo a una lista de destinatarios podría estar estructurada así:

Esto se puede estructurar como un par de transacciones, una para la operación de *extrae* y la otra para *deposita*. Cuando las dos subtransacciones se consuman, la transacción *Transferencia* puede consumirse también. Supongamos que una transacción *extrae* aborta cuando una cuenta tiene un descubierto. Ahora consideremos el caso en que la subtransacción *extrae* aborta y la subtransacción *deposita* se consume; y recuerde que la consumación de una transacción hijo está condicionada a la consumación de la transacción padre. Suponemos que la transacción de alto nivel (*Transferencia*) decidirá abortar. El aborto de la transacción padre produce que las subtransacciones aborten, por lo que la operación *deposita* se aborta y todos sus efectos se eliminan.

El Servicio de Transacciones de Objetos CORBA permite tanto transacciones planas como anidadas. Las transacciones anidadas se utilizan particularmente en los sistemas distribuidos porque las transacciones hijas pueden ejecutarse concurrentemente en distintos servidores. Volveremos a este tema en el Capítulo 14. Esta forma de transacciones anidadas se debe a Moss [1985]. Se han propuesto otras variantes de transacciones anidadas con diferentes propiedades de secuencialidad; por ejemplo, ver Weikum [1991].

12.4. BLOQUEOS

Las transacciones deben planificarse de forma que sus efectos sobre datos compartidos sean secuencialmente equivalentes. Un servidor puede conseguir la equivalencia secuencial de las transacciones secuenciando el acceso a los objetos. La Figura 12.7 representaba un ejemplo de cómo se puede conseguir la equivalencia secuencial con algún grado de concurrencia. Ambas transacciones *T* y *U* acceden a la cuenta *B*, pero *T* completa su acceso antes que *U* comience a acceder a ella.

Un ejemplo sencillo de un mecanismo de secuenciación es el uso de bloqueos exclusivos. En este esquema de bloqueo el servidor intenta bloquear cualquier objeto que vaya a ser utilizado por cualquier operación de la transacción de un cliente. Si un cliente solicita el acceso a un objeto que ya está bloqueado por una transacción de otro cliente, la solicitud es suspendida y el cliente debe esperar hasta que el objeto es desbloqueado.

La Figura 12.14 ilustra el uso de bloqueos exclusivos. Muestra las mismas transacciones de la Figura 12.7, pero con una columna extra para cada transacción que representa el bloqueo, la espera y el desbloqueo. En este ejemplo se supone que cuando las transacciones *T* y *U* comienzan los balances de las cuentas *A*, *B* y *C* no están todavía bloqueados. Cuando la transacción *T* va a utilizar la cuenta *B*, *B* se bloquea para *T*. Consecuentemente, cuando la transacción *U* va a utilizar *B* ésta está todavía bloqueada para *T*, y la transacción *U* espera. Cuando se consuma la transacción *T*, *B* es desbloqueado, después de lo cual se reanuda la transacción *U*. El uso del bloqueo en *B* serializa efectivamente el acceso a *B*. Hay que tener en cuenta que si, por ejemplo, *T* ha liberado el bloqueo en *B* entre sus operaciones *obténBalance* y *ponBalance*, la operación *obténBalance* de la transacción *U* puede solaparse entre ellas.

La equivalencia secuencial precisa que todos los accesos de una transacción a un objeto particular sean secuenciados con respecto a los accesos por otras transacciones. Todos los pares de operaciones conflictivas de dos transacciones debieran ser ejecutados en el mismo orden. Para asegurar esto, no está permitido a una transacción ningún nuevo bloqueo después que ha liberado uno. La primera fase de cada transacción se conoce como «fase de crecimiento», durante la cual se adquieren nuevos bloqueos. En la segunda fase, se liberan los bloqueos (una «fase de acortamiento»). Esto se llama *bloqueo en dos fases*.

Vimos en la Sección 12.2.2 que ya que las transacciones pueden abortar, se necesitan ejecuciones estrictas para prevenir lecturas sucias y escrituras prematuras. Bajo un régimen de ejecución estricta, una transacción que necesita leer o escribir un objeto debe ser retrasada hasta que otras transacciones que escribieron el mismo objeto sean consumidas o abortadas. Para hacer cumplir

Transacción T:		Transacción U:	
$bal = b.\text{obténBalance}()$ $b.\text{ponBalance}(bal * 1.1)$ $a.\text{extrae}(bal / 10)$		$bal = b.\text{obténBalance}()$ $b.\text{ponBalance}(bal * 1.1)$ $c.\text{extrae}(bal / 10)$	
Operaciones	Bloqueos	Operaciones	Bloqueos
<i>abreTransacción</i>		<i>abreTransacción</i>	
$bal = b.\text{obténBalance}()$	bloquea B	$bal = b.\text{obténBalance}()$	
$b.\text{ponBalance}(bal * 1.1)$		$b.\text{ponBalance}(bal * 1.1)$	espera por el bloqueo en B de T
$a.\text{extrae}(bal / 10)$	bloquea A	$c.\text{extrae}(bal / 10)$	
<i>cierraTransacción</i>	desbloquea A, B	$c.\text{extrae}(bal / 10)$	bloquea B
	• • •	<i>cierraTransacción</i>	bloquea C
			desbloquea B, C

Figura 12.14. Las transacciones T y U con bloqueos exclusivos.

esta regla, se mantienen todos los bloqueos aplicados durante el progreso de una transacción hasta que ésta se consuma o aborta. Esto se llama *bloqueo en dos fases estricto*. La presencia de bloqueos impide que otras transacciones lean o escriban los objetos. Cuando se consuma una transacción, para asegurar la recuperabilidad, los bloqueos se deben mantener hasta que todos los objetos que ella actualizó han sido escritos en memoria permanente.

Un servidor contiene generalmente un gran número de objetos, una transacción típica accede sólo a unos pocos de ellos y es poco probable colisionar con otras transacciones en curso. La *granularidad* con la que puede aplicarse el control de la concurrencia a los objetos es un tema importante, puesto que el ámbito para el acceso concurrente a objetos en un servidor estará limitado severamente si el control de concurrencia (por ejemplo, los bloqueos) sólo se puede aplicar a todos los objetos al instante. En nuestro ejemplo bancario, si se aplican los bloqueos a todas las cuentas de usuario en una sucursal, sólo un cajero del banco podría realizar una transacción bancaria en línea cada vez, ¡una restricción difícilmente aceptable!

La porción de objetos a los que se debe secuenciar el acceso debiera ser tan pequeño como sea posible; es decir, sólo la parte implicada en cada operación solicitada por las transacciones. En nuestro ejemplo bancario, una sucursal mantiene un conjunto de cuentas, cada una de las cuales tiene un balance. Cada operación bancaria afecta a uno o más balances de cuentas. *deposita* o *extrae* afectan al balance de una cuenta y *totalSucursal* afecta al de todas ellas.

La descripción de los esquemas de control de concurrencia dados a continuación no presuponen ninguna granularidad concreta. Discutimos los protocolos del control de concurrencia que son aplicables a objetos cuyas operaciones pueden modelarse en términos de operaciones de *lectura* y *escritura* sobre los objetos. Para que los protocolos funcionen correctamente, es esencial que cada operación de *lectura* y *escritura* seaatómica en sus efectos sobre los objetos.

Los protocolos de control de concurrencia están diseñados para tratar con *conflictos* entre operaciones sobre el mismo objeto en diferentes transacciones. En este capítulo, utilizamos la noción de conflicto entre operaciones para explicar los protocolos. Las reglas de conflicto para operaciones de lectura y escritura están dadas en la Figura 12.9, que muestra qué pares de operaciones de diferentes transacciones en el mismo objeto no entran en conflicto. Por tanto, el utilizar un simple

bloqueo exclusivo tanto para las operaciones de *lectura* y como de *escritura* reduce la concurrencia más de lo necesario.

Es preferible adoptar un esquema de bloqueo que controle el acceso a cada objeto de modo que pueda haber varias transacciones concurrentes leyendo un objeto, o una única transacción escribiendo un objeto, pero no ambas. Esto se denomina normalmente el esquema *muchos lectores/un escritor*. Se utilizan dos tipos de bloqueos: *bloqueos de lectura* y *bloqueos de escritura*. Antes de realizar una operación de *lectura* en una transacción, se debe activar un bloqueo de lectura en el objeto. Antes que se realice una operación de escritura, se debe activar un bloqueo de escritura en el objeto. Cuando es imposible activar un bloqueo inmediatamente, la transacción (y el cliente) debe esperar hasta que es posible hacerlo; tenga en cuenta que nunca se rechaza una solicitud de un cliente.

Como un par de operaciones de lectura, desde transacciones diferentes, no entra en conflicto, un intento de activar un bloqueo de lectura en un objeto que presente un bloqueo de lectura siempre tendrá éxito. Todas las transacciones que leen los mismos objetos comparten su bloqueo de lectura. Por esta razón, los bloqueos de lectura se llaman, a veces, *bloqueos compartidos*.

Las reglas de conflicto de la operación nos dicen que:

- Si una transacción T ha realizado ya una operación de lectura en un objeto particular, entonces una transacción concurrente U no debe escribir ese objeto hasta la consumación de T, o que aborte.
- Si una transacción T ha realizado ya una operación de escritura en un objeto particular, entonces una transacción concurrente U no debe leer o escribir ese objeto la consumación de T, o que aborte.

Para hacer cumplir (1), cada solicitud de bloqueo de escritura sobre un objeto se retrasará por la presencia de un bloqueo de lectura que pertenezca a otra transacción. Para hacer cumplir (2), cada solicitud de bloqueo de lectura o escritura sobre un objeto retrasará por la presencia de un bloqueo de escritura perteneciente a otra transacción.

La Figura 12.15 muestra la compatibilidad de los bloqueos de lectura y escritura sobre cualquier objeto concreto. Las entradas en la primera columna de la tabla representan el tipo de bloqueo ya activado, si lo hay. Las entradas en la primera fila representan el tipo de bloqueo solicitado. La entrada de cada celda representa el efecto que tiene en la transacción que solicita el tipo de bloqueo, dado anteriormente, cuando el objeto ha sido ya bloqueado en otra transacción con el tipo de bloqueo de la izquierda.

Las recuperaciones inconsistentes y las actualizaciones perdidas se producen por conflictos entre las operaciones de *lectura* en una transacción y de *escritura* en otra sin la protección de un esquema de control de concurrencia como el bloqueo. Las recuperaciones inconsistentes se previenen realizando la transacción de recuperación antes de la de actualización. Si llega primero la transacción de recuperación, su bloqueo de lectura retrasará la transacción de actualización. Si llega la segunda su solicitud de bloqueo de lectura produce su retraso hasta que se haya completado la transacción de actualización.

Para un objeto	Bloqueo solicitado	
	Lectura	Escritura
Bloqueo ya activado	Ninguno Lectura Escritura	Bien Bien Espera
		Espera Espera

Figura 12.15. Compatibilidad de bloqueos.

1. Cuando una operación accede a un objeto en una transacción:
 - (a) Si el objeto no estaba ya bloqueado, es bloqueado y comienza la operación.
 - (b) Si el objeto tiene activado un bloqueo conflictivo con otra transacción, la transacción debe esperar hasta que esté desbloqueado.
 - (c) Si el objeto tiene activado un bloqueo no conflictivo de otra transacción, se comparte el bloqueo y comienza la operación.
 - (d) Si el objeto ya ha sido bloqueado en la misma transacción, el bloqueo será promovido si es necesario y comienza la operación. (Donde la promoción está impedida por un bloqueo conflictivo, se utiliza la regla (b).)
2. Cuando una transacción se consuma o aborta, el servidor desbloquea todos los objetos bloqueados por la transacción.

Figura 12.16. Uso de los bloqueos en un sistema de bloqueo en dos fases estricto.

Las actualizaciones perdidas aparecen cuando dos transacciones leen un valor en un objeto y entonces usan ese valor para calcular uno nuevo. Las actualizaciones perdidas se previenen haciendo que las transacciones posteriores retrasen sus lecturas hasta que las anteriores se han completado. Esto se consigue, para cada transacción, activando un bloqueo de lectura cuando se lee un objeto y *promoviéndolo* a un bloqueo de escritura cuando se escribe sobre el mismo objeto —cuando una transacción posterior precisa un bloqueo de lectura se retrasará hasta que la transacción actual se haya completado.

Una transacción con un bloqueo de lectura compartido con otras transacciones no puede promover su bloqueo de lectura a uno de escritura, porque las posteriores entrarían en conflicto con los bloqueos de lectura mantenidos por otras transacciones. Por tanto, tal transacción debe solicitar un bloqueo de escritura y esperar a que los otros bloqueos de lectura sean liberados.

La promoción de bloqueos se refiere a la conversión de un bloqueo a otro más fuerte, es decir, a un bloqueo que es más exclusivo. La tabla de compatibilidad de bloqueos muestra qué bloqueos son más o menos exclusivos. El bloqueo de lectura permite otros bloqueos de lectura, mientras que el de escritura no. Ninguno permite otros bloqueos de escritura. Por tanto, un bloqueo de escritura es más exclusivo que uno de lectura. Los bloqueos pueden promoverse hacia bloqueos más exclusivos. No es seguro degradar un bloqueo mantenido por una transacción antes de que ésta se consume, porque el resultado será más permisivo que uno previo y puede permitir ejecuciones de otras transacciones que son inconsistentes con la equivalencia secuencial.

Las reglas para el uso de los bloqueos en una implementación de bloqueo en dos fases estricto se resumen en la Figura 12.16. Para asegurar que se siguen estas reglas, el cliente no tiene acceso a las operaciones de bloqueo o desbloqueo de partes de datos. El bloqueo se realiza cuando las solicitudes para operaciones de *lectura* y *escritura* van a ser aplicadas a los objetos recuperables, y el desbloqueo se realiza por las operaciones *consumo* o *aborta* del coordinador de transacciones.

Por ejemplo, puede utilizarse el Servicio de Control de Concurrencia de Corba [OMG 1997a] para aplicar control de concurrencia en nombre de las transacciones o para proteger objetos sin utilizar transacciones. Proporciona un medio de asociar una colección de bloqueos (llamado un *lockset*) con un recurso como un objeto recuperable. Un lockset permite adquirir o liberar bloques. Un método *lock* (bloqueo) del lockset adquirirá un bloqueo o se inmovilizará hasta que el bloqueo esté libre; otro método permitirá promover o liberar los bloqueos. Los locksets transaccionales permiten los mismos métodos que los locksets, pero sus métodos precisan los identificadores de transacción como argumentos. Hemos mencionado anteriormente que el servicio de transacción de CORBA etiqueta todas las solicitudes del cliente en una transacción con el identificador de transacción. Esto permite la adquisición de un bloqueo adecuado antes de que se acceda a cada uno de

```

public class Bloqueo {
    private Object objeto;           // El objeto que es protegido por el bloqueo
    private Vector propietarios;     // las TIDs de los propietarios
    private TipoBloqueo tipoBloqueo; // el tipo actual

    public synchronized void adquiere(IDTrans trans, TipoBloqueo unTipoBloqueo) {
        while /* otra transacción posea en bloqueo en modo conflictivo */ {
            try {
                wait();
            } catch (InterruptedException e) {/*...*/}
        }
        if (propietarios.estaVacio()) { // ningún TID posee un bloqueo
            propietarios.agregaElemento(trans);
            tipoBloqueo = unTipoBloqueo;
        } else if /* otra transacción posee el bloqueo, lo comparte */ {
            if /* esta transacción no es un poseedor*/ propietarios.agregaElemento(trans);
        } else if /* esta transacción es un poseedor pero necesita más de un bloqueo exclusivo */
            tipoBloqueo.promueve();
    }

    public synchronized void libera(IDTrans trans) {
        holders.removeElement(trans); // elimina este poseedor
        // establece el tipo de bloqueo a ninguno
        notifyAll();
    }
}

```

Figura 12.17. La clase *Bloqueo*.

los objetos recuperables durante una transacción. El coordinador de transacciones es el responsable de liberar los bloqueos cuando una transacción se consuma o se aborta.

Las reglas dadas en la Figura 12.16 aseguran la rigurosidad, porque los bloqueos se mantienen hasta que se ha consumido o abortado una transacción. Sin embargo, no es necesario mantener un conjunto de bloqueos para asegurar su rigor. Los bloqueos de lectura no necesitan ser mantenidos hasta que llega la petición de consumir o abortar.

◇ **Implementación de bloqueos.** La concesión de los bloqueos será implementada por un objeto separado del servidor que llamamos *gestor de bloqueos*. El gestor de bloqueos mantiene un conjunto de bloqueos, por ejemplo en una tabla de dispersión (*hash*). Cada bloqueo es una instancia de la clase *Bloqueo* y está asociada con un objeto particular. La clase *Bloqueo* se representa en la Figura 12.17. Cada instancia de *Bloqueo* mantiene la siguiente información en sus variables instancia:

- El identificador del objeto bloqueado.
- Los identificadores de las transacciones que mantienen actualmente el bloqueo (los bloqueos compartidos pueden tener varios poseedores).
- Un tipo de bloqueo.

Los métodos de *Bloqueo* están sincronizados de modo que los hilos que intentan adquirir o liberar un bloqueo no interferirán con el otro. Pero además, los intentos de adquirir el bloqueo utilizan el método *wait* cuando tengan que esperar que otro hilo lo libere.

El método *adquiere* cumple las reglas dadas en las Figuras 12.15 y 12.16. Sus argumentos especifican un identificador de transacción y el tipo de bloqueo precisado por ella. Se comprueba si

```

public class GestorBloqueo {
    private Hashtable losBloqueos;

    public void ponBloqueo(Object objeto, IDTrans trans, TipoBloqueo tipoBloqueo){
        Bloqueo bloqueoEncontrado;
        synchronized (this){
            //busca el bloqueo asociado con el objeto
            //si no hay ninguno, lo crea y lo agrega a la tabla de dispersión
        }
        bloqueoEncontrado.agrega(trans, tipoBloqueo);
    }

    //sincroniza este dato que queremos eliminar todas las entradas
    public synchronized void desBloqueo(TransID trans){
        Enumeration e = losBloqueos.elements();
        while (e.hasMoreElements()){
            Bloqueo unBloqueo = (Bloqueo)(e.nextElement());
            if (!(* trans is a holder of this lock*)) unBloqueo.libera(trans);
        }
    }
}

```

Figura 12.18. La clase *GestorBloqueo*.

se puede conceder la solicitud. Si otra transacción mantiene el bloqueo en un modo conflictivo, ésta invocará *wait*, que provoca que el hilo de la que lo llama sea suspendido hasta un *notify* correspondiente. Hay que tener en cuenta que el *wait* está encerrado en un *while*, porque se notifica a todos los que esperan y alguno de ellos puede no ser capaz de proseguir. Cuando, eventualmente se satisfaga la condición, el resto del método activa el bloqueo adecuadamente:

- Si ninguna otra transacción mantiene el bloqueo, agrega la transacción dada a los poseedores y establece el tipo.
- Sino, si otra transacción mantiene el bloqueo, lo comparte añadiéndola transacción dada a los poseedores (a menos que él ya sea un poseedor).
- Sino, si esta transacción es un poseedor pero está solicitando un bloqueo más exclusivo, se promueve el bloqueo.

Los argumentos del método *libera* especifican el identificador de la transacción que está liberando el bloqueo. Elimina el identificador de transacción de los poseedores, establece el tipo de bloqueo a *ninguno* y llama a *notifyAll*. El método notifica a todos los hilos esperando en el caso que haya múltiples transacciones esperando para adquirir bloqueos de lectura, en cuyo caso todos ellos serían capaces de proseguir.

En la Figura 12.18 se muestra la clase *GestorBloqueo*. Todas las solicitudes de activar bloqueos y liberarlos en beneficio de las transacciones se envían a una instancia de *GestorBloqueo*.

- Los argumentos del método *ponBloqueo* indican al objeto que una transacción dada quiere un bloqueo y el tipo de éste. Obtiene un bloqueo para ese objeto en su tabla de dispersión, o si es preciso crea una. Despues invoca el método *adquiere* de ese bloqueo.
- Los argumentos del método *desBloqueo* especifican la transacción que está liberando sus bloqueos. Obtienen todos los bloqueos en la tabla de dispersión que tiene como poseedor a la transacción dada. Por cada uno, llama al método *libera*.

Algunas cuestiones de política: Observe que, cuando varios hilos *esperan* en el mismo objeto bloqueado, la semántica de *espera* garantiza que cada transacción consigue su turno. En el programa anterior, las reglas de conflicto permiten que los que mantienen un bloqueo sean varios lectores

o un único escritor. La llegada de una petición de un bloqueo de lectura está siempre garantizada a menos que el poseedor tenga un bloqueo de escritura. Se invita al lector a considerar o siguiente:

- ¿Cuál es la consecuencia para las transacciones de *escritura* de la presencia de un goteo estacionario de solicitudes para bloqueos de lectura? Piense en una alternativa de implementación.

Cuando el poseedor tiene un bloqueo de escritura, puede haber varios lectores y escritores esperando. El lector debiera considerar el efecto de *notifyAll* y pensar en una alternativa de implementación. Si un poseedor de un bloqueo de lectura intenta promover el bloqueo cuando está compartido, se inmovilizará. ¿Hay alguna solución a esta dificultad?

◊ **Reglas de bloqueo para transacciones anidadas.** El propósito de un esquema de bloqueo es serializar el acceso a objetos de modo que:

1. Cada conjunto de transacciones anidadas sea una única entidad a la que se debe impedir observar los efectos de cualquier otro conjunto de transacciones anidadas.
2. Se debe impedir que cada transacción con un conjunto de transacciones anidadadas observe los efectos parciales de otras transacciones del conjunto.

La primera regla se hace cumplir disponiendo que cada bloqueo que se adquiere después de una subtransacción con éxito sea heredado por su padre cuando finaliza. Los bloqueos heredados son heredados también por los ascendientes. ¡Téngase en cuenta que esta forma de herencia pasa del hijo al padre! La transacción del nivel superior hereda eventualmente todos los bloqueos que fueron adquiridos por las subtransacciones con éxito en cualquier profundidad de una transacción anidada. Esto garantiza que puedan mantenerse los bloqueos hasta que se haya consumado o abortado la transacción de nivel superior, lo que impide que los miembros de diferentes conjuntos de transacciones anidadas observen los resultados parciales de los otros.

La segunda regla se hace cumplir como sigue:

- No se permite la ejecución concurrente de las transacciones padre con las de sus hijos. Si una transacción padre tiene un bloqueo sobre un objeto, *retiene* el bloqueo durante el tiempo que su transacción hijo se está ejecutando. Esto significa que la transacción hijo adquiere temporalmente el bloqueo del padre durante su duración.
- Se permite la ejecución concurrente de las subtransacciones del mismo nivel, por lo que cuando éstas acceden a los mismos objetos, el esquema de bloqueo deberá secuenciar su acceso.

Las siguientes reglas describen la adquisición y liberación del bloqueo:

- Para que una subtransacción adquiera un bloqueo de lectura sobre un objeto, ninguna transacción activa puede tener un bloqueo de escritura sobre ese objeto, y los únicos que retienen un bloqueo de escritura son sus ascendientes.
- Para que una subtransacción adquiera un bloqueo de escritura sobre un objeto, ninguna otra transacción activa puede tener un bloqueo de lectura o escritura sobre ese objeto, y los únicos que retienen los bloqueos de lectura y escritura en ese objeto son sus ascendientes.
- Cuando se consuma una transacción, sus bloqueos son heredados por su padre, permitiendo al padre retener los bloqueos del mismo modo que el hijo.
- Cuando una subtransacción aborta, sus bloqueos son eliminados. Si el padre todavía continúa manteniendo los bloqueos puede continuar haciéndolo.

Tenga en cuenta que las subtransacciones al mismo nivel al que accede el mismo objeto realizarán turnos para adquirir los bloqueos retenidos por su padre. Esto asegura que su acceso a un objeto común es secuencializado.

Transacción <i>T</i>		Transacción <i>U</i>	
Operaciones	Bloqueos	Operaciones	Bloqueos
<i>a.deposita(100);</i>	Escribe bloquea <i>A</i>	<i>b.deposita(200);</i>	Escribe bloquea <i>B</i>
<i>b.extrae(100);</i>		<i>a.extrae(200);</i>	Espera por <i>T</i>
• • •	Espera por <i>U</i> Bloqueo en <i>B</i>	• • •	Bloqueo en <i>A</i>
• • •		• • •	
• • •		• • •	

Figura 12.19. Bloqueo indefinido con bloqueos de escritura.

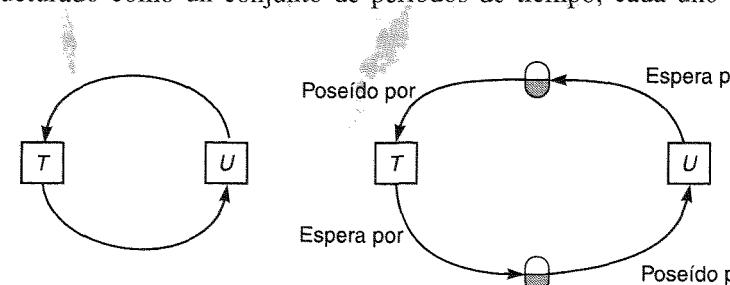
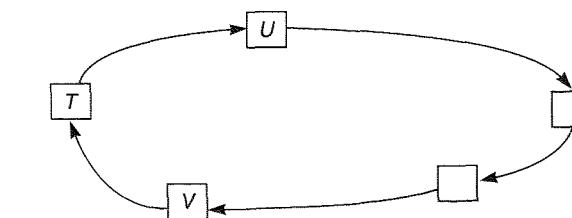
Como ejemplo, supongamos que las subtransacciones T_1 , T_2 y T_{11} en la Figura 12.13 acceden todas a un objeto común, que no es accedido por la transacción del nivel superior T . Supongamos que la subtransacción T_1 es la primera que accede al objeto y adquiere un bloqueo con éxito, que le pasa a T_{11} para la duración de su ejecución, devolviéndolo cuando T_{11} finalice. Cuando T_1 finaliza su ejecución, la transacción del nivel superior T hereda el bloqueo, que mantiene hasta que finaliza el conjunto de transacciones anidadas. La subtransacción T_2 puede adquirir el bloqueo de T para la duración de su ejecución.

12.4.1. BLOQUEOS INDEFINIDOS

El uso de bloqueos puede conducir a bloqueos indefinidos. Consideremos el uso de bloqueos representado en la Figura 12.19. Puesto que los métodos *deposita* y *extrae* son atómicos, los representamos adquiriendo bloqueos de escritura, aunque en la práctica ellos leen el balance y escriben en él. Cada uno de ellos adquiere un bloqueo y se inmoviliza cuando intenta acceder a la cuenta que ha bloqueado el otro. Ésta es una situación de bloqueo indefinido: dos transacciones están esperando y cada una depende de la otra para liberar un bloqueo y poder reanudarse.

El bloqueo indefinido es una situación particularmente común cuando los clientes están implicados en un programa interactivo, una transacción en un programa interactivo puede durar un período largo de tiempo, produciendo que muchos objetos queden inmovilizados y permanezcan así, impidiendo por tanto que otros clientes los utilicen.

Tenga en cuenta que el bloqueo de sub-elementos en objetos estructurados puede ser útil para impedir conflictos y posibles situaciones de bloqueo indefinido. Por ejemplo, un día en un diario puede estar estructurado como un conjunto de períodos de tiempo, cada uno de los cuales puede

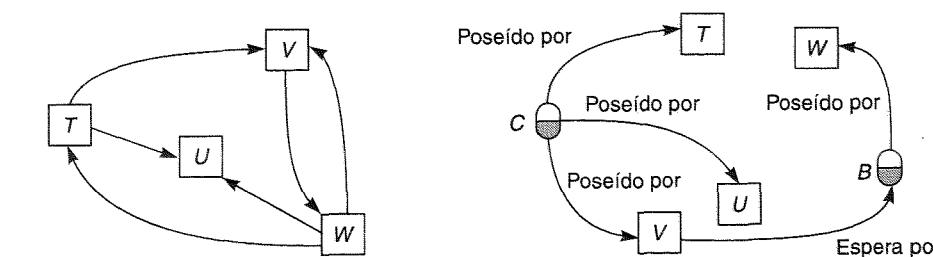
Figura 12.20. El grafo *espera por* para la Figura 12.19.Figura 12.21. Un ciclo en el grafo *espera por*.

ser bloqueado independientemente para actualización. Los esquemas de bloqueo jerárquico son útiles si la aplicación requiere una granularidad independiente del bloqueo para diferentes operaciones. Véase la Sección 12.4.2.

◇ **Definición de bloqueo indefinido.** Un bloqueo indefinido es un estado en el que cada miembro de un grupo de transacciones está esperando por algún otro miembro para liberar un bloqueo. Se puede utilizar un grafo *espera por* para representar las relaciones de espera entre las transacciones actuales. En un grafo *espera por* las nodos representan las transacciones y los arcos representan las relaciones *espera por* entre transacciones, hay un arco del nodo T al nodo U cuando la transacción T está esperando que la transacción U libere un bloqueo. Inspeccione la Figura 12.20, que muestra el grafo *espera por* correspondiente a la situación de bloqueo indefinido ilustrada en la Figura 12.19. Recuerde que un bloqueo indefinido surge porque las transacciones T y U intentaron cada una adquirir un objeto mantenido por la otra. Por tanto T espera por U y U espera por T . La dependencia entre las transacciones es indirecta, mediante una dependencia de los objetos. El diagrama de la derecha muestra los objetos mantenidos y esperados por las transacciones T y U . Como cada transacción puede esperar sólo por un objeto, los objetos pueden ser omitidos del grafo *espera por*, conduciendo al grafo simple de la izquierda.

Supongamos que como en la Figura 12.21, un grafo *espera por* contiene un ciclo $T \rightarrow U \rightarrow \dots \rightarrow V \rightarrow T$, luego cada transacción está esperando por la siguiente transacción en el ciclo. Todas esas transacciones están inmovilizadas esperando a causa de los bloqueos. Ninguno de los bloqueos podrá ser liberado nunca, y las transacciones permanecerán esperando indefinidamente. Si se aborta una de las transacciones en el ciclo, se liberan sus bloqueos y el ciclo se rompe. Por ejemplo, si una transacción T en la Figura 12.21 se aborta, liberará un bloqueo sobre un objeto por el que está esperando V , y V no tendrá que esperar más por T .

Consideremos ahora un escenario en el que tres transacciones T , U y V comparten un bloqueo de lectura sobre un objeto C , la transacción mantiene un bloqueo de escritura sobre el objeto B por el que está esperando la transacción V para obtener un bloqueo, como se muestra en la Figura 12.22. Las transacciones T y W solicitarán entonces bloqueos de escritura sobre el objeto C y se

Figura 12.22. Otro grafo *espera por*.

presenta una situación de bloqueo indefinido en la que T espera por U y V , V espera por W y W espera por T , U y V , como se muestra en la izquierda de la Figura 12.22. Esto muestra que aunque cada transacción puede esperar por sólo un objeto cada vez, puede estar implicado en varios ciclos. Por ejemplo la transacción V está implicada en los ciclos: $V \rightarrow W \rightarrow T \rightarrow V$ y $V \rightarrow W \rightarrow V$.

En este ejemplo, suponemos que se aborta la transacción V . Esto liberará el bloqueo de V en C y se romperán los dos ciclos en los que está implicado V .

◇ **Prevención de bloqueos indefinidos.** Una solución es prevenir el bloqueo indefinido. Una forma aparentemente simple pero no muy buena para vencer el bloqueo indefinido es bloquear todos los objetos utilizados por una transacción cuando comienza. Esto necesitaría realizarse en un único paso atómico para impedir el bloqueo indefinido en esta etapa. Dicha transacción no puede ejecutarse en bloqueo indefinido con otras transacciones, pero restringe innecesariamente el acceso a los recursos compartidos. En suma, a veces es imposible predecir al comienzo de una transacción qué objetos serán utilizados. Éste es generalmente el caso de aplicaciones interactivas, el usuario tendría que decir con anterioridad exactamente qué objetos estaba planeando utilizar, lo que es inconcebible en aplicaciones del estilo de hojeo (*browsing*), que ofrecen a los usuarios objetos de los que no conocen nada de antemano. El bloqueo indefinido puede también impedirse solicitando los bloqueos en los objetos en un orden predefinido, pero esto puede producir un bloqueo prematuro o una reducción de la concurrencia.

◇ **Detección de bloqueos indefinidos.** Los bloqueos indefinidos pueden detectarse a través de los ciclos en el grafo *espera por*. Una vez detectado un bloqueo indefinido, para romper el ciclo se debe seleccionar una transacción para abortar.

El software responsable de la detección de bloqueos indefinidos puede ser parte del gestor de bloqueos. Debe mantener una representación del grafo *espera por* para que pueda comprobar si existen ciclos en él de tiempo en tiempo. Los arcos son añadidos y eliminados del grafo por las operaciones *ponBloqueo* y *desBloqueo* del gestor de bloqueos. En el punto ilustrado por la Figura 12.22 en la izquierda tendremos la siguiente información:

Transacción	Esperas por la transacción
T	U, V
V	W
W	T, U, V

Un arco $T \rightarrow U$ se añade cuando el gestor de bloqueos bloquea una solicitud desde la transacción T causada por un bloqueo en un objeto que ya está bloqueado en el marco de la transacción U . Considere, que cuando un bloqueo es compartido, se pueden añadir varios arcos. Un arco $T \rightarrow U$ es borrado cuando U libera un bloqueo por el que está esperando T y permite a T continuar. Para una discusión más detallada de la implementación de detección de bloqueos indefinidos véase el Ejercicio 12.14. Si una transacción comparte un bloqueo, el bloqueo no es liberado, pero los arcos que conducen a una transacción particular se eliminan.

La presencia de ciclos se puede comprobar cada vez que se añade un arco, o con menos frecuencia para evitar una sobrecarga innecesaria. Cuando se detecta un bloqueo indefinido, se debe elegir una de las transacciones en el ciclo y abortarla. El nodo correspondiente y los arcos involucrados se eliminan del grafo *espera por*. Esto sucederá cuando la transacción abortada tenga su bloqueos eliminados.

La elección de la transacción a abortar no es sencilla. Algunos factores que pueden ser considerados son la edad de la transacción y el número de ciclos implicados en ella.

Transacción T		Transacción U	
Operaciones	Bloqueos	Operaciones	Bloqueos
$a.\text{deposita}(100);$	Escriftura bloquea A	$b.\text{deposita}(200);$	Escriftura bloquea B
$b.\text{extrae}(100);$		$a.\text{extrae}(200);$	Espera por T
• • •	Espera por U Bloqueo en B (Transcurre el intervalo)	• • •	Bloqueo en A
	El bloqueo de T en A llega a ser vulnerable, desbloqueo de A , T se aborta	• • •	
		$a.\text{extrae}(200);$	Escriftura bloquea en A Desbloquea A, B

Figura 12.23. Resolución del bloqueo indefinido en la Figura 12.19.

◇ **Timeouts.** Los timeouts de bloqueo son un método para la resolución de bloqueos indefinidos que se utiliza normalmente. A cada bloqueo se le proporciona un período limitado en el que es invulnerable. Después de este tiempo es vulnerable. Supuesto que ninguna otra transacción está compitiendo por el objeto que está bloqueado, un objeto con un bloqueo vulnerable continúa bloqueado. Sin embargo, si cualquier otra transacción está esperando para acceder al objeto protegido por un bloqueo vulnerable, el bloqueo se rompe (es decir, el objeto es desbloqueado) y se reanuda la transacción que estaba esperando. La transacción cuyo bloqueo se ha roto normalmente aborta.

Hay muchos problemas con el uso de timeouts como un remedio para bloqueos indefinidos: el peor problema es que a veces se abortan transacciones debido a que sus bloqueos llegan a ser vulnerables cuando otras transacciones están esperando por ellas, aunque en realidad no hay bloqueo indefinido. En un sistema sobrecargado, el número de transacciones que superan la temporización aumentará y las transacciones que precisan un tiempo largo serán penalizadas. En resumen, es duro decidir una magnitud apropiada para un timeout. En contraste, si se utiliza la detección de bloqueo indefinido, las transacciones son abortadas porque han ocurrido bloqueos indefinidos y se ha hecho una elección para determinar qué transacción abortar.

Usando timeouts de bloqueos, podemos resolver el bloqueo indefinido en la Figura 12.19, como se muestra en la Figura 12.23, en la que el bloqueo de escritura para T en A llega a ser vulnerable después de su período de timeout. La transacción U está esperando para adquirir un bloqueo de escritura en A . Por tanto, T se aborta y libera su bloqueo en A , permitiendo a U reanudar y completar la transacción.

Cuando las transacciones acceden a objetos ubicados en varios servidores diferentes, surge la posibilidad de bloqueos indefinidos distribuidos. En un bloqueo indefinido distribuido, el grafo *espera por* puede implicar a objetos en múltiples ubicaciones. Volveremos a este tema en la Sección 13.5.

12.4.2. INCREMENTANDO LA CONCURRENCIA EN ESQUEMAS DE BLOQUEO

Incluso cuando las reglas de bloqueo están basadas en conflictos entre las operaciones de *lectura* y *escritura* y la granularidad con que se aplican será tan pequeña como sea posible, con lo que habrá posibilidades de incrementar la concurrencia. Discutiremos dos aproximaciones que se han utilizado. En la primera aproximación (bloqueo en dos versiones), la activación de bloqueos exclusivos

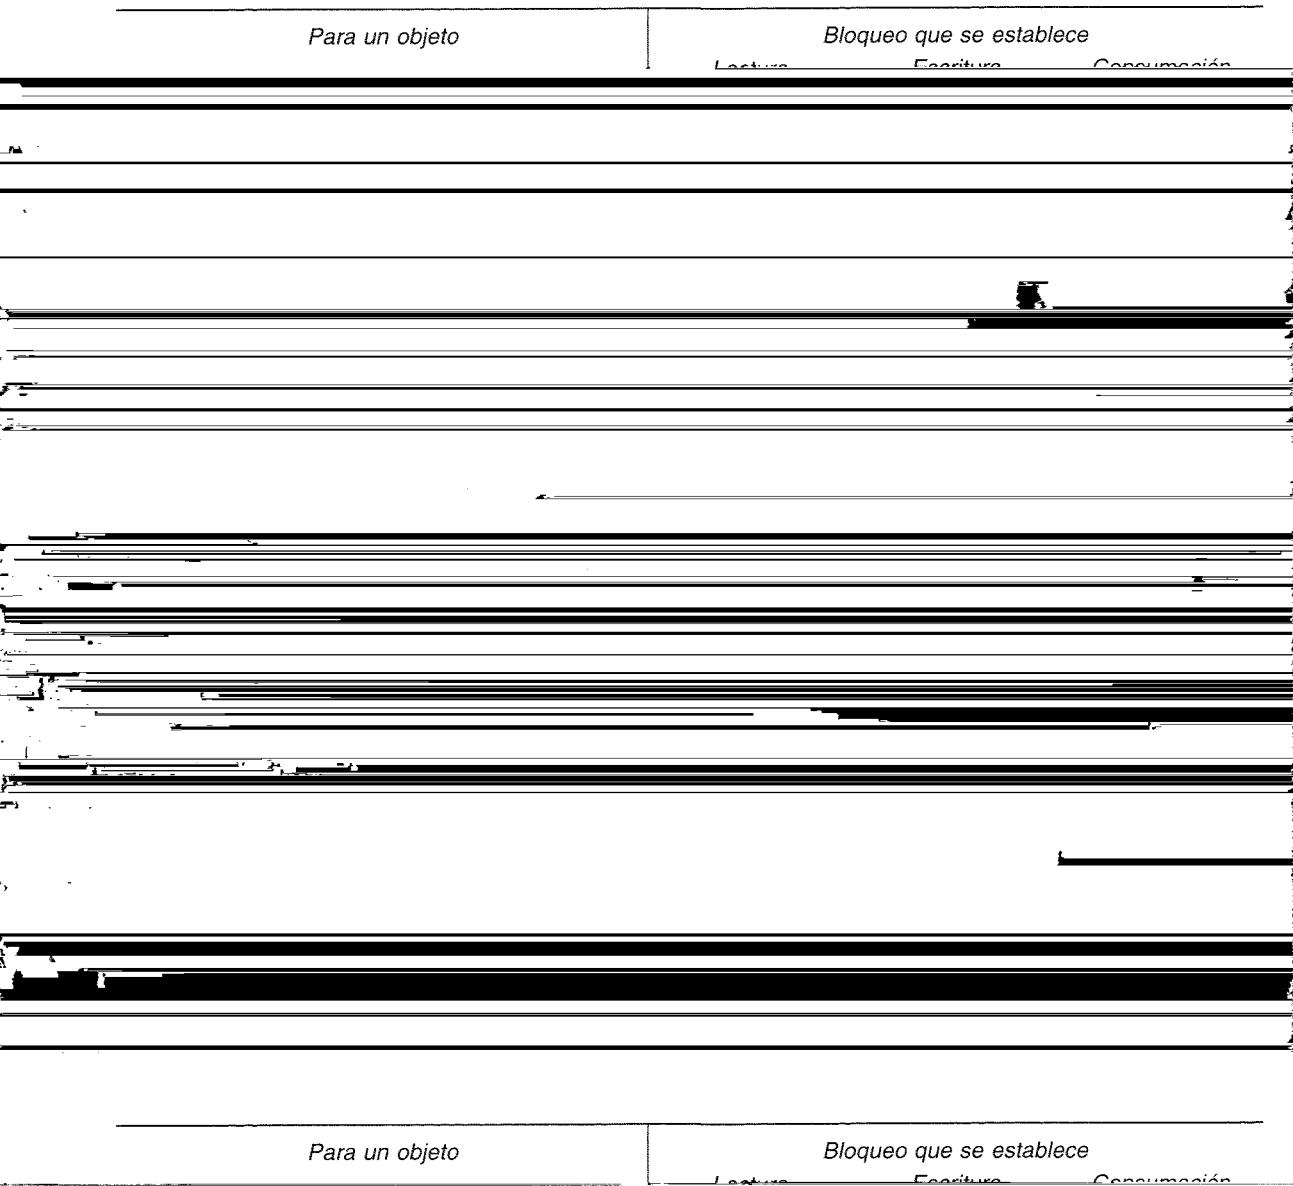


Figura 12.24. Compatibilidad de bloques (letra, escritura y consumación).

se retrasa hasta que un transacción se consuma. En la segunda aproximación (bloques jerárquicos), se utilizan bloques de granularidad mixta.

◊ **Bloqueo de dos versiones.** Éste es un esquema optimista que permite que una transacción escriba versiones tentativas de objetos mientras otras transacciones leen de la versión consumada de los mismos objetos. Las operaciones de *lectura* sólo esperan si otra transacción se está consumiendo actualmente en el mismo objeto. Este esquema permite más concurrencia que la de los bloques de lectura-escritura, pero existe el riesgo que las transacciones de escritura esperen o incluso sean rechazadas cuando intentan consumirse. Las transacciones no pueden consumir sus operacio-

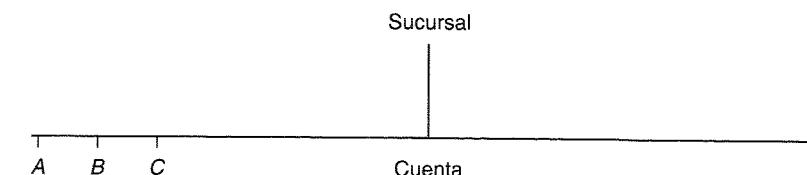


Figura 12.25. Jerarquía de bloques para el ejemplo bancario.

todos los balances de las cuentas y parecería requerir un bloqueo de lectura de todos ellos. Para reducir la sobrecarga de bloqueo, sería útil permitir que coexistan bloques de granularidad mezclada.

Gray [1978] propuso la utilización de una jerarquía de bloques con diferentes granularidades. En cada nivel, la activación de un bloqueo padre tiene el mismo efecto que la activación de todos los bloques hijo equivalentes. Esto economiza el número de los bloques que se deben activar. En nuestro ejemplo bancario, la sucursal es el padre y las cuentas son los hijos (ver Figura 12.25).

Se podrían utilizar bloques de granularidad mezclada en un sistema de dietario, en el que los datos podrían estar estructurados de modo que el dietario para una semana viene formado con una página para cada día y éstos subdivididos además en un espacio para cada hora del día, como se muestra en la Figura 12.26. La operación para ver una semana produciría la activación de un bloqueo de lectura en la parte superior de esta jerarquía, mientras que la operación de introducir un apunte produciría la activación de un bloqueo de escritura en un espacio de tiempo. El efecto de un bloqueo de lectura en una semana sería el prevenir operaciones de escritura en cualquiera de sus subestructuras, por ejemplo en los espacios de tiempo de cada día de la semana.

En el esquema de Gray, cada nodo en la jerarquía puede ser bloqueado, dando al propietario del bloqueo acceso explícito al nodo y acceso implícito a sus hijos. En nuestro ejemplo, en la Figura 12.25 un bloqueo de lectura-escritura en la sucursal bloquea implícitamente todas las cuentas para lectura-escritura. Antes de que se conceda un bloqueo de lectura-escritura a un nodo hijo, se activa una intención de bloqueo de lectura-escritura en el nodo padre y en sus antepasados (si los hubiere). La intención de bloqueo es compatible con otras intenciones de bloqueo pero entra en conflicto con los bloques de lectura y escritura, según las reglas habituales. La Figura 12.27 proporciona la tabla de compatibilidad para bloques jerárquicos. Gray propone también un tercer tipo de intención de bloqueo, uno que combina la propiedad de un bloqueo de lectura con una intención de bloqueo de escritura.

En nuestro sistema bancario, la operación *totalSucursal* solicita un bloqueo de lectura en la sucursal, que implícitamente activa bloques de lectura en todas las cuentas. Una operación *deposita* necesita activar un bloqueo de escritura en un balance, pero intenta primero activar una intención para un bloqueo de escritura en la sucursal. Estas reglas impiden que estas operaciones se ejecuten concurrentemente.

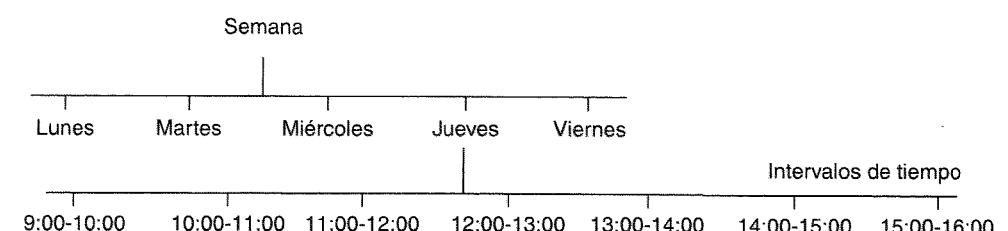


Figura 12.26. Jerarquía de bloques para un diario.

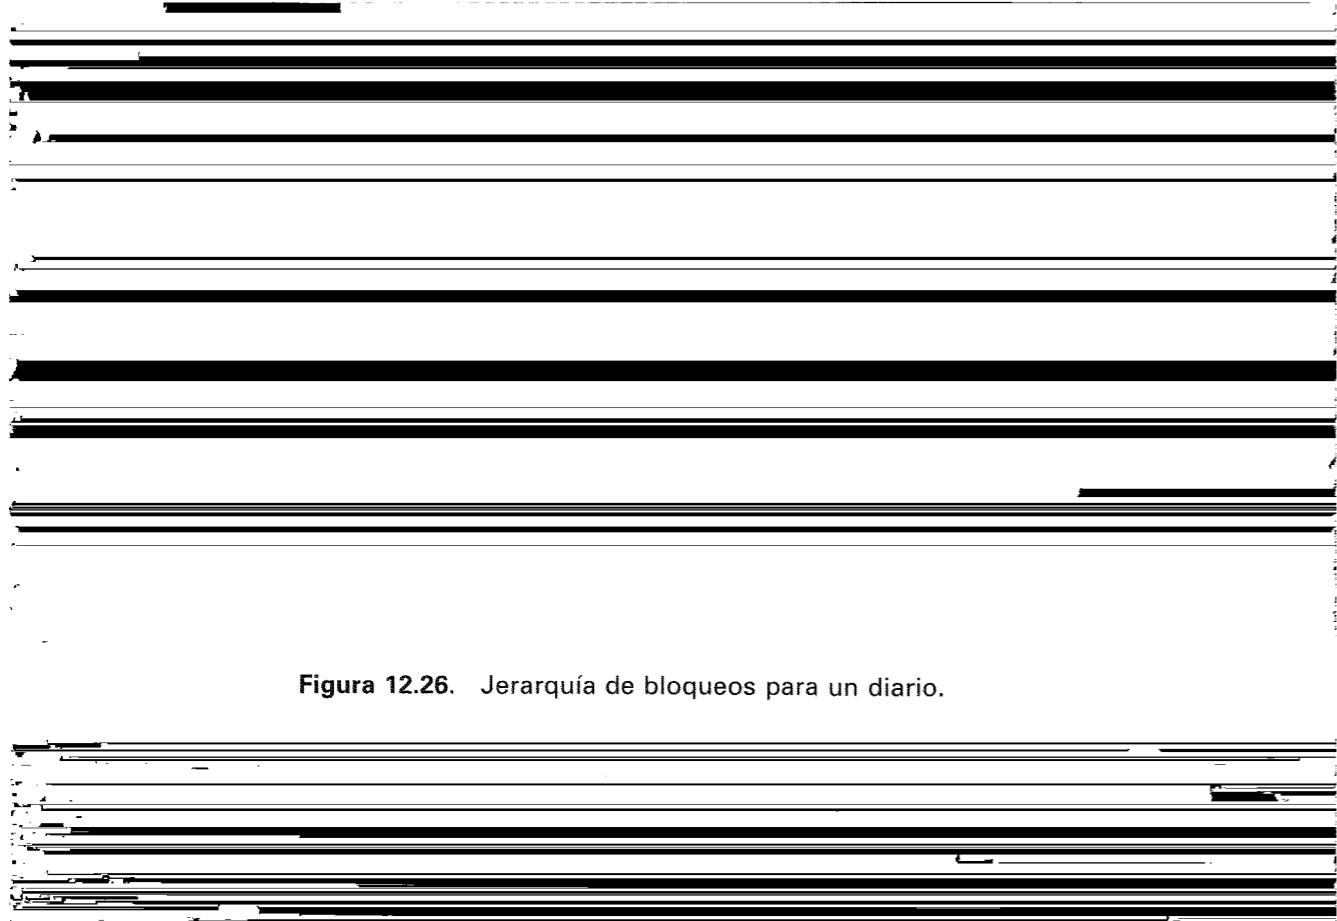


Figura 12.26. Jerarquía de bloqueos para un diario.

Para un bloqueo	Bloqueo que se va a activar			
	Lectura	Escritura	I-Lectura	I-Escritura
Bloqueo ya activado	Ninguno	Rion	Rion	Rion

Figura 12.27. Tabla de compatibilidad para bloqueos jerárquicos.

Los bloqueos jerárquicos tienen la ventaja de reducir el número de bloqueos cuando se precisa un bloqueo de granularidad mezclada. Las tablas de compatibilidad y las reglas para promoción de bloqueos son más complejas.

La granularidad mezclada de bloqueos podría permitir a cada transacción bloquear una porción cuyo tamaño se elige de acuerdo con las necesidades. Una transacción larga que accede a muchos

algunas transacciones y se necesitará reinicializar el cliente. Cada transacción presenta las siguientes fases:

Fase de trabajo: durante la fase de trabajo, cada transacción tiene una versión tentativa de cada uno de los objetos que actualiza. Ésta es una copia de la versión del objeto más recientemente consumida. El empleo de las versiones tentativas permite a la transacción abortar (sin efecto alguno sobre los objetos), tanto durante la fase de trabajo como si falla su validación debido a otras transacciones en conflicto. las operaciones de *lectura* se realizan inmediatamente: si existe una versión tentativa para la transacción, la operación de *lectura* accederá a ella, de otro modo accederá al valor más recientemente consumido del objeto. La operación de *escritura* almacena los nuevos valores de los objetos bajo versiones tentativas (las cuales son invisibles al resto de transacciones). Cuando hay varias transacciones concurrentes, podrán coexistir valores tentativos diferentes sobre el mismo objeto. Además, se almacenan dos registros para cada objeto al que se accede en la transacción: un *conjunto de lectura* que contiene los objetos leídos por la transacción; y un *conjunto de escritura* que contiene los objetos modificados por la transacción. Observe que dado que todas las operaciones de lectura se realizan sobre versiones consumadas de los objetos (o copias de ellos), no habrá lecturas sucias.

Fase de validación: cuando se recibe la solicitud *cierraTransacción*, se valida la transacción para establecer si sus operaciones en los objetos entran en conflicto o no con las operaciones en otras transacciones sobre los mismos objetos. Si la validación tiene éxito, entonces se puede consumar la transacción. Si la validación falla, se debe utilizar alguna forma de resolución de conflictos y o bien habrá que abortar la transacción actual o, en algunos casos, aquellas con las que entra en conflicto.

Fase de actualización: si una transacción está validada, todos los cambios registrados en su versiones provisionales se hacen permanentes. Las transacciones de *sólo lectura* pueden consumarse inmediatamente después de pasar la validación. Las transacciones de escritura están dispuestas a consumarse una vez que las versiones provisionales de los objetos se hayan grabado en memoria permanente.

◇ **Validación de transacciones.** La validación utiliza las reglas de conflictos de lectura-escritura para garantizar que la planificación de una transacción particular es secuencialmente equivalente con respecto a todas las demás que se *solapan* con ella, es decir, cualquier otra transacción que no se haya consumado en el instante de comienzo de la transacción considerada. Para asistir en la realización de la validación, se le asigna un número a cada transacción cuando comienza su fase de validación (esto es, cuando un cliente emite un *cierraTransacción*). Si se valida la transacción y finaliza con éxito, retiene ese número; si fallan las comprobaciones de validación y se aborta, o si las transacciones son sólo de lectura, se libera el número para su reasignación. Los números de transacciones son enteros asignados en orden de secuencia ascendente; el número de una transacción define por tanto su posición en el tiempo: una transacción siempre termina su fase de trabajo después de todas las transacciones con números más pequeños. Es decir, una transacción con el número T_i siempre precede a una transacción con número T_j si $i < j$. (Si el número de transacción se asignó al comienzo de la fase de trabajo, entonces una transacción que alcanzó el final de la fase de trabajo antes que otra con un número más pequeño tendría que esperar hasta que la anterior haya completado antes de que ella pueda ser validada.)

La comprobación de validación en la transacción T_v está basada en conflictos entre pares de operaciones de la transacción T_v y T_i . Para que una transacción T_v sea secuencializable con respecto a una transacción T_i solapada con ella, sus operaciones deben ajustarse a las siguientes reglas:

T_v	T_i	Regla
escribe	lee	1. T_i no debe leer los objetos escritos por T_v .
lee	escribe	2. T_v no debe leer los objetos escritos por T_i .
escribe	escribe	3. T_i no debe escribir en los objetos escritos por T_v y T_v no debe escribir en los objetos escritos por T_i .

Como las fases de validación y actualización de una transacción son generalmente cortas en duración, comparadas con la fase de trabajo, se puede conseguir una simplificación considerando la regla de que sólo puede haber una transacción en la fase de validación y actualización cada vez. Cuando no se pueden solapar dos transacciones en la fase de actualización, se satisface la regla 3. Hay que considerar que esta restricción en las operaciones de *escritura*, junto con el hecho que no pueden ocurrir lecturas sucias, produce ejecuciones estrictas. Para impedir el solapamiento, las fases completas de validación y actualización se pueden implementar como una sección crítica por lo que sólo puede ejecutarla un cliente cada vez. Con el fin de incrementar la concurrencia, la parte de validación y actualización puede implementarse fuera de la sección crítica, pero es esencial que la asignación de números a las transacciones se realice secuencialmente. Consideramos que en cualquier instante, los números actuales de transacción son como un pseudo-reloj que marca cuándo una transacción se completa con éxito.

La validación de una transacción debe asegurar que se obedecen las reglas 1 y 2 comprobando que el solapamiento entre los objetos de pares de transacciones T_v y T_i . Existen dos formas de validación, hacia delante y hacia atrás [Härder 1984]. La validación hacia atrás realiza la validación de la transacción considerada con otras transacciones precedentes que se solapan con ella, aquellas que entraron en la fase de validación antes que ella. La validación hacia delante realiza la validación de la transacción considerada con otras transacciones posteriores, que están todavía activas.

◊ **Validación hacia atrás.** Ya que todas las operaciones de *lectura* de las transacciones anteriores que se solapan fueron realizadas antes que comenzara la validación de T_v , no pueden ser afectadas por las *escrituras* de la transacción en curso (y se satisface la regla 1). La validación de la transacción T_v comprueba si su conjunto de lectura (los objetos afectados por las operaciones de *lectura* de T_v) se solapan con cualquiera de los conjuntos de escritura de las transacciones anteriores T_i que se solapan con ella (regla 2). Si no hay ningún solapamiento, la validación falla.

Sea $nT_{initial}$ el número de transacción más grande asignado (para alguna otra transacción consumada) en el instante en que la transacción T_v comenzó su fase de trabajo y nT_{final} el número de transacción más grande asignado en el instante en que T_v entró en su fase de validación. El programa siguiente describe el algoritmo para la validación de T_v :

```
boolean válida = cierto;
for (int  $T_i = nT_{initial} + 1$ ;  $T_i <= nT_{final}$ ;  $T_i + +$ ){
    if (el conjunto de lectura de  $T_v$  interseca el conjunto de escritura de  $T_i$ ) válida = falso;
}
```

La Figura 12.28 muestra transacciones que se solapan que pueden ser tenidas en cuenta en la validación de una transacción T_v . El tiempo aumenta de izquierda a derecha. Las transacciones consumadas anteriormente son T_1 , T_2 y T_3 . T_1 se consumó antes de que comenzara T_v . T_2 y T_3 se consumieron antes de que T_v finalizara su fase de trabajo. $nT_{initial} + 1 = T_2$ y $nT_{final} + 1 = T_3$. En la validación hacia atrás el conjunto de lectura de T_v debe ser comparado con los conjuntos de escritura de T_2 y T_3 .

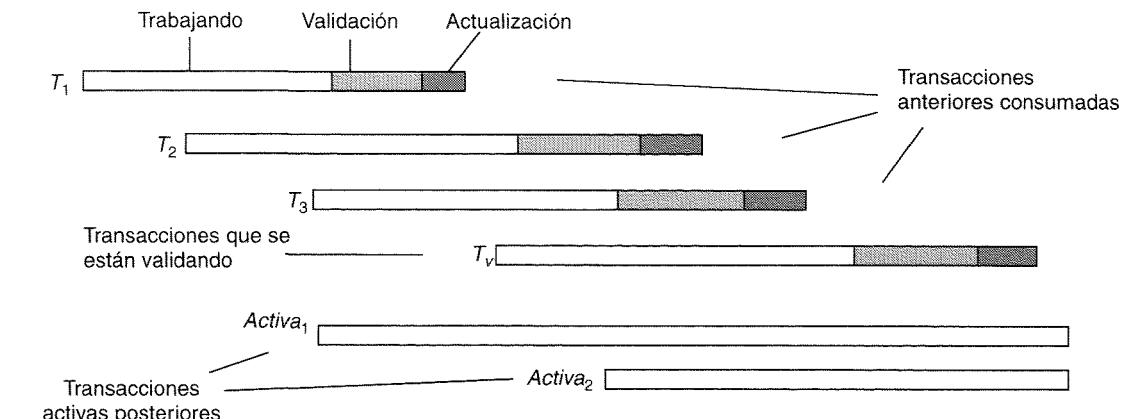


Figura 12.28. Validación de transacciones.

En la validación hacia atrás, el conjunto de lectura de la transacción que se está validando se compara con los conjuntos de escritura de otras transacciones que ya han sido consumadas. Por tanto, la única forma de resolver conflictos es abortar la transacción que está experimentando la validación.

En la validación hacia atrás, las transacciones que no tienen operaciones de *lectura* (sólo de *escritura*) no necesitan ser comprobadas.

El control optimista de concurrencia con validación hacia atrás precisa que los conjuntos de escritura de las versiones antiguas de objetos ya consumidas correspondientes a transacciones recientemente consumidas sean retenidas hasta que no haya transacciones solapadas invalidadas con las que pudieran entrar en conflicto. Cuando una transacción se valida con éxito, su número de transacción, $nT_{initial}$ y el conjunto de escritura se registran en una lista de transacciones precedentes que es mantenida por el servicio de transacciones. Téngase en cuenta que esta lista está ordenada por número de transacción. En un entorno con transacciones largas, la retención de los conjuntos de escritura de objetos anteriores puede ser un problema. Por ejemplo, en la Figura 12.28 los conjuntos de escritura de T_1 , T_2 , T_3 y T_v deben ser retenidos hasta que la transacción activa $activa_1$ se complete. Hay que tener en cuenta que aunque las transacciones activas tienen identificadores de transacción, no tienen aún números de transacción.

◊ **Validación hacia delante.** En la validación hacia delante de la transacción T_v , el conjunto de escritura de T_v se compara con los conjuntos de lectura de todas las transacciones activas que se solapan, aquellas que están aún en su fase de trabajo (regla 1). La regla 2 se satisface automáticamente porque las transacciones activas no escriben hasta que no se ha completado T_v . Consideremos que las transacciones activas (consecutivas) tienen identificadores $activa_1$ a $activa_N$, el siguiente programa describe el algoritmo para la validación hacia delante de T_v :

```
boolean válida = cierto;
for (int  $T_{id} = activa_1$ ;  $T_{id} <= activa_N$ ;  $T_{id} + +$ ){
    if (el conjunto de escritura de  $T_v$  interseca el conjunto de lectura de  $T_{id}$ ) válida = falso;
```

En la Figura 12.28, el conjunto de escritura de la transacción T_v debe compararse con los conjuntos de lectura de las transacciones con identificadores $activa_1$ y $activa_2$. (La validación hacia delante debiera permitir el hecho que los conjuntos de lectura de las transacciones activas pueden cambiar durante la validación y la escritura.) Como los conjuntos de lectura de la transacción que se está validando no están incluidos en la comprobación, las transacciones de *sólo lectura* siempre pasan

la comprobación de validación. Como las transacciones que están siendo comparadas con la de validación están todavía activas, tomamos una elección de si abortar la transacción de validación o tomar alguna vía alternativa de resolver el conflicto. Arder [1984] sugiere varias estrategias alternativas:

- Aplazar la validación hasta un instante posterior cuando hayan finalizado las transacciones conflictivas. Sin embargo, no hay garantía que a la transacción que está siendo validada le vaya mejor en el futuro. Existe siempre la posibilidad de que otras transacciones conflictivas activas puedan comenzar antes que se obtenga la validación.
- Abortar todas las transacciones conflictivas activas y consumir las transacciones que se están validando.
- Abortar la transacción que se está validando. Ésta es la estrategia más sencilla pero tiene la desventaja que las futuras transacciones conflictivas pueden ser abortadas, en cuyo caso la transacción bajo validación ha abortado innecesariamente.

◊ **Comparación de la validación hacia delante y hacia atrás.** Hemos visto que la validación hacia delante permite flexibilidad en la resolución de conflictos, mientras que la validación hacia atrás sólo permite una elección: abortar la transacción que está siendo validada. En general, los conjuntos de lectura de las transacciones son mucho más grandes que los de escritura. Por tanto, la validación hacia atrás compara un conjunto posiblemente grande de lectura frente a los antiguos conjuntos de escritura, mientras que la validación hacia delante tiene la sobrecarga de almacenar los conjuntos antiguos de escritura hasta que no se necesiten más. Vemos que la validación hacia atrás tiene la sobrecarga de almacenar conjuntos de escritura antiguos hasta que ya no se necesiten. Por otra parte, la validación hacia delante tiene que considerar únicamente las nuevas transacciones que comienzan durante el proceso de validación.

◊ **Inanición (Starvation).** Cuando se aborta una transacción, normalmente será reiniciada por el programa del cliente. Pero en esquemas que confían en abortar y reiniciar transacciones, no hay garantía que una transacción particular pase siempre las comprobaciones de validación, por ello puede entrar en conflicto con otras transacciones en el uso de los objetos cada vez que es reiniciada. La prevención de que una transacción siempre será capaz de consumirse se llama inanición.

Las apariciones de la inanición son probablemente raras, pero un servidor que utiliza control de concurrencia optimista debe asegurar que un cliente no sufre un aborto constante de una de sus transacciones. Kung y Robinson sugieren que esto se puede conseguir si el servidor detecta una transacción que ha sido abortada varias veces. Ellos sugieren que cuando el servidor detecta tal transacción debiera dársele acceso exclusivo para usar la sección crítica, protegida por un semáforo.

12.6. ORDENACIÓN POR MARCAS DE TIEMPO

En los esquemas de control de concurrencia basados en ordenación por marcas de tiempo, cada operación en una transacción se valida cuando se lleva a cabo. Si la operación no puede ser validada, la transacción es abortada inmediatamente y puede ser reiniciada por el cliente. A cada transacción se le asigna una valor de marca de tiempo único cuando comienza. La marca de tiempo define su posición en la secuencia de tiempo de las transacciones. Las solicitudes de las transacciones pueden ser ordenadas totalmente de acuerdo con sus marcas de tiempo. La regla de ordenación básica por marca de tiempo está basada en los conflictos de operación y es muy sencilla:

- Una solicitud de una transacción para escribir un objeto es válida sólo si ese objeto fue leído y escrito por última vez por transacciones anteriores. Una petición de lectura de un objeto por una transacción es válida sólo si ese objeto fue escrito por última vez por una transacción anterior.

Esta regla supone que sólo existe una versión de cada objeto y restringe el acceso a una transacción en cada instante. Si cada transacción tiene su propia versión tentativa de cada objeto al que accede, entonces varias transacciones concurrentes pueden acceder al mismo objeto. La regla de ordenación por marca de tiempo está diseñada para asegurar que cada transacción accede a un conjunto consistente de versiones de los objetos. Debe asegurar también que las versiones tentativas de cada objeto son consumidas en el orden determinado por las marcas de tiempo de las transacciones que las realizaron. Esto se consigue haciendo que las transacciones esperen, cuando es preciso, a que las transacciones anteriores completen sus escrituras. Las operaciones de *escritura* pueden realizarse después que ha retornado la operación *cierraTransacción*, sin hacer que espere el cliente. Pero el cliente debe esperar cuando las operaciones de *lectura* deben esperar a que finalicen las transacciones anteriores. Esto no conduce a un bloqueo indefinido, puesto que las transacciones sólo esperan por las anteriores (y no puede ocurrir un ciclo en el grafo *espera por*).

Las marcas de tiempo pueden venir asignadas desde el reloj del servidor o, como en la sección anterior, puede usarse un *pseudo-tiempo* basado en un contador que se incrementa cuando se emite un valor de marca de tiempo. En el Capítulo 13 se considerará el problema de generar marcas de tiempo cuando el servicio de transacciones está distribuido y varios servidores están implicados en una transacción.

Describiremos ahora una forma de control de concurrencia basado en marca de tiempo siguiendo los métodos adoptados en el sistema SDD-1 [Bernstein y otros 1980] y descritos por Ceri y Pelagatti [1985].

Como es normal, las operaciones de *escritura* son registradas en versiones tentativas de los objetos y son invisibles para las demás transacciones hasta que se realiza una solicitud *cierraTransacción* y la transacción se consuma. Cada objeto tiene una marca de tiempo de escritura y un conjunto de versiones tentativas, cada una de las cuales tiene una marca de tiempo de escritura asociada con ella; y un conjunto de marcas de tiempo de lectura. La marca de tiempo de escritura del objeto (consumido) es anterior que la de cualquiera de sus versiones tentativas, y el conjunto de marcas de tiempo de lectura puede representarse por su elemento con valor máximo. Cuando se acepta una operación de *escritura* de la transacción en un objeto, el servidor crea una nueva versión tentativa del mismo con la marca de tiempo de escritura colocada al valor de marca de tiempo de la transacción. Una operación de *lectura* de la transacción es dirigida a la versión con el valor máximo de la marca de tiempo de escritura menor que la de la marca de tiempo de la transacción. Cuando se acepta una operación de *lectura* sobre un objeto, la marca de tiempo de la transacción se añade a su conjunto de marcas de tiempo de lectura. Cuando se consuma una transacción, los valores de las versiones tentativas se convierten en los valores de los objetos, y las marcas de tiempo de las versiones tentativas se convierten en las de los objetos correspondientes.

En la ordenación por marcas de tiempo, cualquier solicitud por parte de un transacción para una operación de *lectura* o *escritura* en un objeto se comprueba para ver si está conforme con las reglas de conflicto de la operación. Una solicitud de la transacción actual T_c puede tener conflicto con las operaciones anteriores hechas por otras transacciones, T_i , cuyas marcas de tiempo indican que deberían ser posteriores a T_c . Estas reglas se muestran en la Figura 12.29, en la que $T_i > T_c$ significa que es posterior que T_c y $T_i < T_c$ significa que T_i es anterior a T_c .

Regla de escritura por ordenación de marca de tiempo: Combinando las reglas 1 y 2 tenemos la siguiente regla para decidir si se acepta una operación de lectura solicitada por la transacción T_c en el objeto D :

```
if ( $T_c \geqslant$  la máxima marca de tiempo de lectura en  $D$  &&
     $T_c >$  la marca de tiempo de escritura en la versión consumada de  $D$ )
    realiza la operación de escritura en la versión tentativa de  $D$  con marca de tiempo  $T_c$ 
else /* escribir es demasiado tarde */
    aborta la transacción  $T_c$ 
```

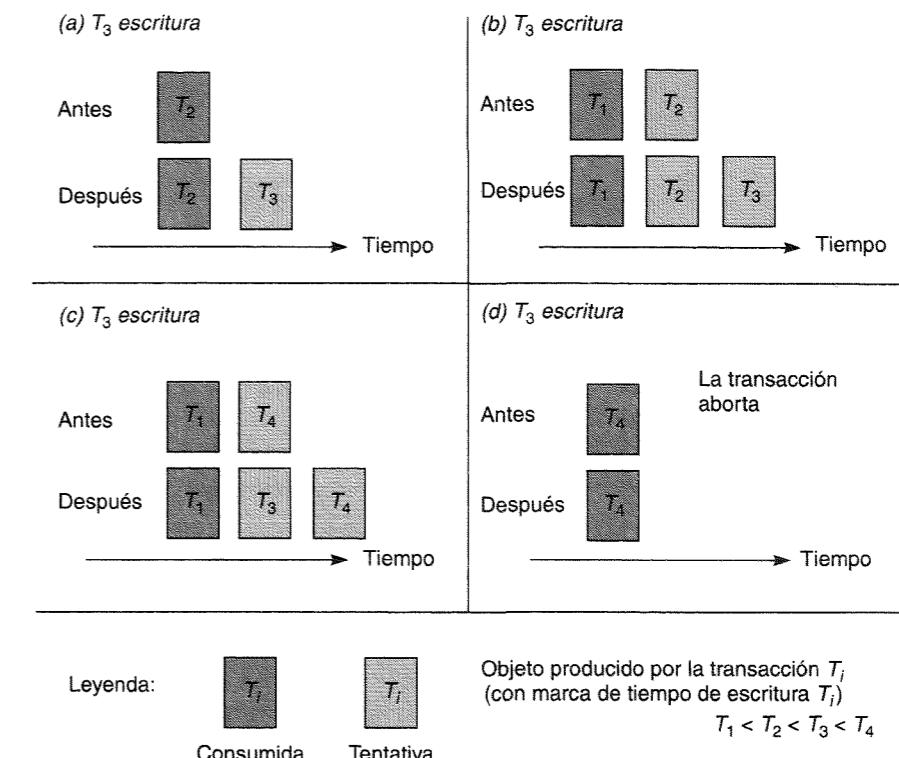
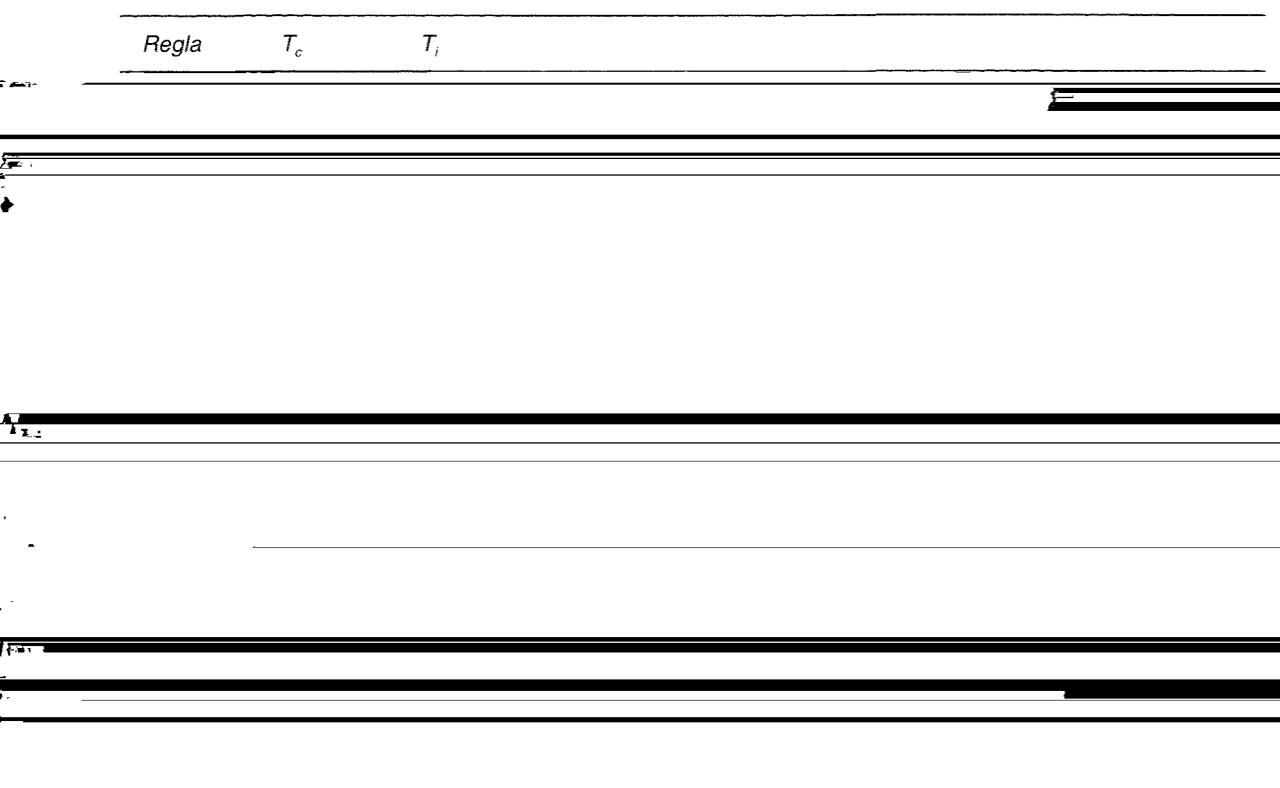
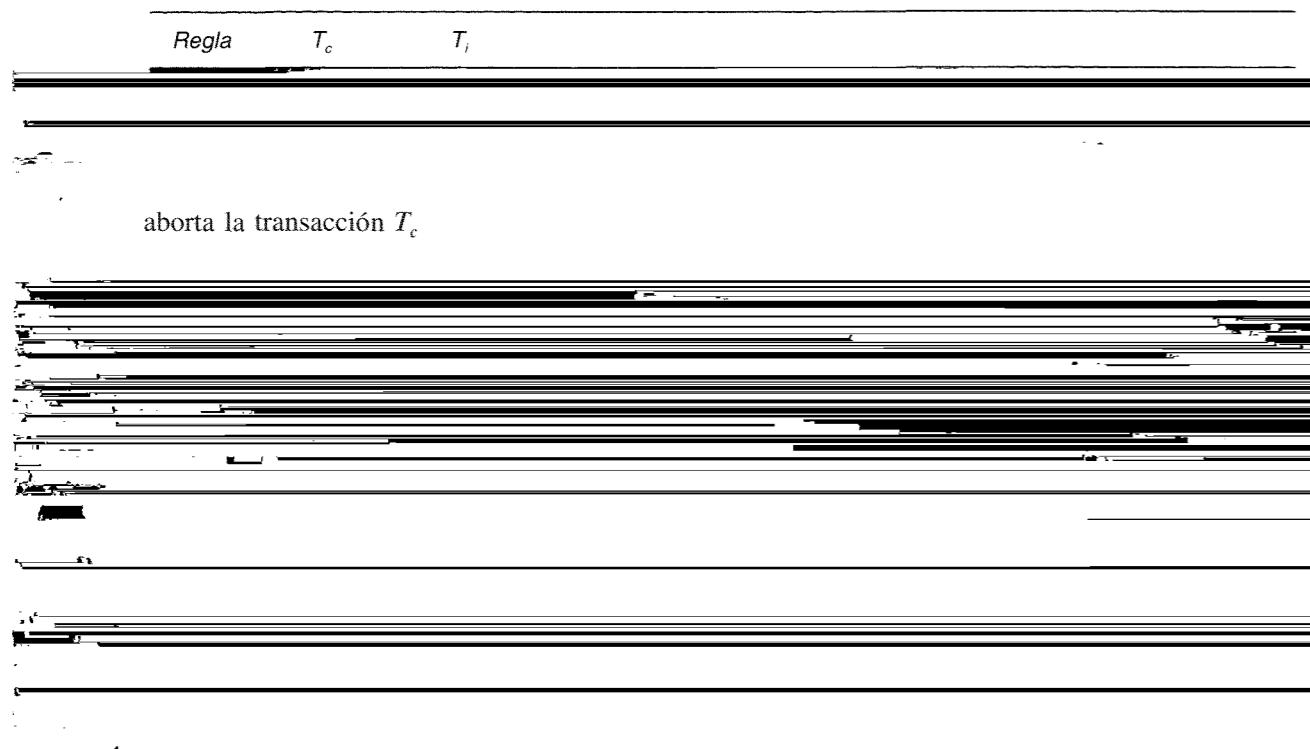


Figura 12.30. Operaciones de escritura y marcas de tiempo.

La Figura 12.31 ilustra la regla de lectura de la ordenación por marca de tiempo. Incluye cuatro casos etiquetados (a) a (d), cada uno de los cuales ilustra la acción de una operación de *lectura* por la transacción T_3 . En cada caso, se selecciona una versión cuya marca de tiempo de escritura es menor o igual que T_3 . Si existe tal versión, se indica con una línea. En los casos (a) y (b) la operación de *lectura* se dirige a una versión consumada, en (a) es la única versión, mientras que en (b) hay una versión tentativa que pertenece a una transacción posterior. En el caso (c) la operación de *lectura* está dirigida a una versión tentativa y debe esperar hasta que la transacción realiza la consumación o aborta. En el caso (d) no existe una versión adecuada para leer y la transacción T_3 se aborta.

Cuando un coordinador recibe una petición para consumir una transacción, siempre será capaz de hacerlo porque se comprueban todas las operaciones de las transacciones para consistencia con las transacciones anteriores antes de realizarlo. Las versiones consumadas de cada objeto deben ser creadas en el orden de la marca de tiempo. Por tanto, un coordinador necesita esperar, a veces, que se completen las transacciones anteriores antes de escribir todas las versiones consumadas de los objetos accedidos por una transacción particular, pero no necesita esperar por el cliente. Con el fin de hacer una transacción recuperable después de una ruptura, las versiones tentativas de los objetos y el hecho que la transacción se ha consumido deben ser escritos en almacenamiento permanente antes de reconocer a la solicitud del cliente para consumir la transacción.

Observe que este algoritmo de ordenación por marca de tiempo es estricto, asegura la ejecuciones estrictas de las transacciones (véase Sección 12.2). La regla de lectura por ordenación de marca de tiempo retarda una operación de lectura de una transacción en cualquier objeto hasta que todas las transacciones que han escrito previamente ese objeto han sido consumadas o abortadas. El plan

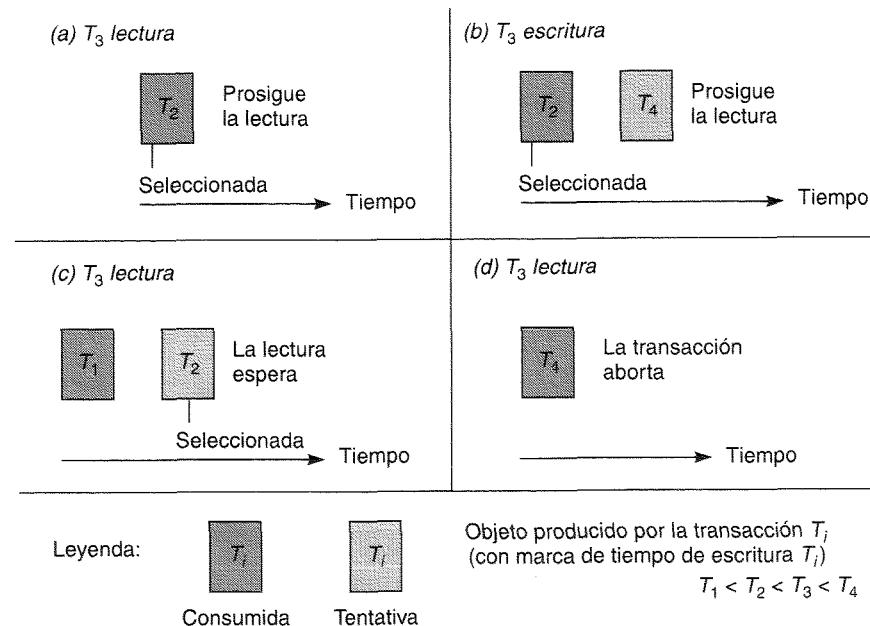


Figura 12.31. Operaciones de lectura y marcas de tiempo.

para consumar versiones en el orden asegura que la ejecución de una operación de *escritura* de la transacción en cualquier objeto se retrasa hasta que todas las transacciones que han escrito previamente ese objeto se han consumado o abortado.

En la Figura 12.32, volvemos a nuestra ilustración considerando las dos transacciones bancarias concurrentes T y U presentadas en la Figura 12.7. Las columnas encabezadas por A , B y C se refieren a información sobre cuentas con esos nombres. Cada cuenta tiene una entrada MTL que registra la marca de tiempo máxima de lectura y otra MTE que registra la marca de tiempo de escritura de cada versión, con las marcas de tiempo de versiones ya consumidas en negrita. Inicialmente, todas las cuentas tienen versiones consumadas escritas por la transacción S , y el conjunto de marcas de tiempo de lectura está vacío. Suponemos que $S < T < U$. El ejemplo muestra que cuando una transacción U está dispuesta a conseguir el balance de B esperará hasta que T finalice por lo que se puede leer el valor escrito por T si ésta se consuma.

El método de marca de tiempo escrito anteriormente no impide el bloqueo indefinido, tiende totalmente al rearranque. Existe una mejora conocida como regla de *ignorar escrituras obsoletas*. Es una modificación a la regla de escritura por ordenación de marca de tiempo:

Si una escritura es demasiado tardía puede ser ignorada en lugar de abortar la transacción, porque si hubiera llegado a tiempo sus efectos deberían haber sido sobreescritos en cualquier caso. Sin embargo, si otra transacción ha leído el objeto, la transacción con la última escritura falla debido a la marca de lectura en el ítem.

◇ **Ordenación por marca de tiempo multiversión.** En esta sección, hemos visto cómo la concurrencia proporcionada por la ordenación de marca de tiempo básica se mejora permitiendo a cada transacción escribir su propia versión tentativa de los objetos. En la ordenación de marca de tiempo multiversión, que fue presentada por Reed [1983], se mantiene una lista de versiones antiguas consumadas así como de versiones tentativas para cada objeto. Esta lista representa la historia de los valores del objeto. El beneficio de utilizar múltiples versiones está en que las operaciones de lectura que llegan demasiado tarde no necesitan ser rechazadas.

T	U	Marcas de tiempo y versiones de objetos					
		A		B		C	
		MTL {} <i>abreTransacción</i>	MTE S <i>bal = b.obténBalance()</i>		MTL {} <i>abreTransacción</i>	MTE S <i>b.ponBalance(bal*1.1)</i>	MTL {} <i>bal = b.obténBalance()</i> <i>espera por T</i> • • • • • • <i>a.extrae(bal/10)</i> <i>consumo</i>
							<i>bal = b.obténBalance()</i> <i>b.ponBalance(bal*1.1)</i> <i>c.extrae(bal/10)</i>
							S, T <i>T</i> T <i>T</i> U <i>T, U</i> S, U

Figura 12.32. Marcas de tiempo en las transacciones T y U .

Cada versión tiene una marca de tiempo de lectura que registra la marca de tiempo más grande de cualquier transacción que ha leído el objeto además de la marca de tiempo de escritura. Como antes, cuando se acepta una operación de *escritura*, se dirige a una versión tentativa con la marca de tiempo de escritura de la transacción. Cuando se realiza una operación de *lectura* se dirige a la versión con marca de tiempo de escritura más grande menor que la marca de tiempo de la transacción. Si la marca de tiempo de la transacción es más grande que la marca de tiempo de la transacción de lectura que está siendo utilizada, la marca de tiempo de lectura se establecerá a la de la marca de tiempo de la transacción.

Cuando una lectura llega tarde, se le puede permitir leer de una versión antigua ya consumida, por lo que no hay necesidad de abortar las operaciones de *lectura* tardías. En ordenación por marcas de tiempo multiversión, las operaciones de *lectura* se permiten siempre, aunque puedan tener que *esperar* que transacciones anteriores se completen (ya consumándose o abortando), lo que asegura que las ejecuciones sean recuperables. Véase el Ejercicio 12.22 para una discusión de la posibilidad de abortos en cascada. Esto se trata con la regla 3 en las reglas de conflicto para ordenación por marcas de tiempo.

No hay conflicto entre operaciones de escritura de diferentes transacciones, porque cada transacción escribe su propia versión consumida de los objetos a los que accede. Esto elimina la regla 2 en las reglas de conflicto para ordenación por marcas de tiempo, dejándonos con:

Regla 1: T_c no debe escribir objetos que han sido leídos por cualquier T_i donde $T_i > T_c$.

Esta regla no se considerará si hay alguna versión del objeto con marca de tiempo de lectura $> T_c$, pero sólo esta versión tiene una marca de tiempo de escritura menor que o igual a T_c . (Esta escritura no puede tener ningún efecto en versiones posteriores.)

Regla de escritura en la ordenación de marca de tiempo multiversión: Como cualquier operación de *lectura* potencialmente conflictiva tendrá que ser dirigida hacia la versión más reciente de un objeto, el servidor inspecciona la versión $D_{\text{másTemprana}}$ con la marca de tiempo de escritura máxima menor o igual que T_c . Tenemos la regla siguiente para realizar una operación de *escritura* solicitada por la transacción T_c en el objeto D :

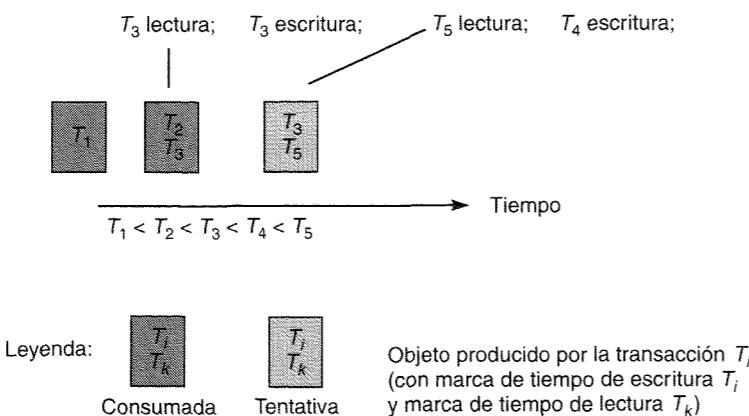


Figura 12.33. La última operación de *escritura* invalidaría una *lectura*.

```

if (marca de tiempo de lectura de  $D_{\text{másTemprana}} \leq T_c$ )
    realiza la operación de escritura en una versión tentativa de  $D$  con la marca de tiempo de
    escritura  $T_c$ 
else aborta la transacción  $T_c$ 

```

La Figura 12.33 muestra un ejemplo donde se rechaza una *escritura*. El objeto ya tiene versiones consumadas con marcas de tiempo de escritura T_1 y T_2 . El objeto recibe la siguiente secuencia de solicitudes para operaciones sobre el objeto:

T_2 *lectura*; T_3 *escritura*; T_5 *lectura*; T_4 *escritura*

1. T_3 solicita una operación de *lectura*, que pone una marca de tiempo T_3 en la versión de T_2 .
2. T_3 solicita una operación de *escritura*, que hace una nueva versión tentativa con la marca de tiempo T_3 .
3. T_5 solicita una operación de *lectura*, que utiliza la versión con la marca de tiempo de escritura T_3 (la marca de tiempo más alta que es menor que T_5).
4. T_4 solicita una operación de *escritura*, que es rechazada porque la marca de tiempo de lectura T_5 de la versión con marca de tiempo de escritura T_3 es más alta que T_4 . (Si se permitiera la marca de tiempo de escritura de la nueva versión debería ser T_4 . Si se permitiera tal versión, se debería invalidar la operación de lectura T_5 , que debiera haber usado la versión con marca de tiempo T_4 .)

Cuando una transacción se aborta, todas las versiones que ella creó se eliminan. Cuando una transacción se consume, todas las versiones que ella creó se retienen, pero para controlar la utilización del espacio de almacenamiento, las versiones antiguas deberían ser borradas de cuando en cuando. Aunque supone una sobrecarga de espacio de almacenamiento, la ordenación de marca de tiempo multiversión permite una concurrencia considerable, no sufre de bloqueos indefinidos y permite siempre operaciones de *lectura*. Para más información sobre la ordenación por marca de tiempo multiversión consultar Bernstein y otros [1987].

12.7. COMPARACIÓN DE MÉTODOS PARA EL CONTROL DE CONCURRENCIA

Hemos descrito tres métodos distintos para controlar el acceso concurrente a datos compartidos: bloqueo en dos fases estricto, métodos optimistas y ordenación por marca de tiempo. Todos los métodos implican algunas sobrecargas en el tiempo y el espacio que precisan, y todos limitan de alguna forma el potencial de la operación concurrente.

El método de ordenación por marca de tiempo es similar al bloqueo en dos fases en el sentido que ambos utilizan una aproximación pesimista en la que los conflictos entre transacciones son detectados a medida en que cada objeto es accedido. Por un lado, la ordenación por marca de tiempo decide el orden de secuenciación estáticamente, cuando comienza una transacción. Por otro lado, el bloqueo en dos fases decide el orden de secuenciación dinámicamente, de acuerdo con el orden en el que son accedidos los objetos. La ordenación por marca de tiempo y, en particular, la ordenación por marca de tiempo multiversión es mejor que el bloqueo en dos fases estricto para transacciones de sólo lectura. El bloqueo en dos fases es mejor cuando las operaciones en las transacciones son actualizaciones predominantemente.

Algunos trabajos plantean que la ordenación por marca de tiempo es beneficiosa para transacciones con operaciones predominantemente de *lectura* y que el bloqueo es beneficioso para transacciones con más *escrituras* que *lecturas* como un argumento para permitir esquemas híbridos en los que algunas transacciones utilizan ordenación por marca de tiempo y otras bloqueo para el control de concurrencia. Los lectores que estén interesados en la utilización de este tipo de métodos mezclados deben leer Bernstein y otros [1987].

Los métodos pesimistas difieren en la estrategia utilizada cuando se detecta un conflicto de acceso sobre un objeto. La ordenación por marca de tiempo aborta la transacción inmediatamente, mientras el bloqueo hace esperar a la transacción, pero con una posible penalización de aborto más tarde para impedir el bloqueo indefinido.

Cuando se utiliza el control de concurrencia optimista, se permite proceder a todas las transacciones, pero algunas son abortadas cuando ellas intentan la consumación, o en validación hacia delante las transacciones son abortadas antes. Esto consigue una operación relativamente eficiente cuando hay pocos conflictos, pero se puede repetir una cantidad sustancial de trabajo cuando se aborta una transacción.

El bloqueo se ha utilizado durante muchos años en los sistemas de bases de datos, mientras la ordenación por marca de tiempo ha sido utilizada en el sistema de bases de datos SDD-1. Ambos métodos se han utilizado en servidores de archivos.

Varios sistemas distribuidos, por ejemplo Argus [Liskov 1988] y Arjuna [Shrivastava y otros 1991], han explorado el uso de los bloqueos semánticos, ordenación por marcas de tiempo y nuevas aproximaciones para transacciones largas.

El trabajo sobre dos áreas de aplicación ha mostrado que los mecanismos anteriores de control de concurrencia no son siempre adecuados. Una de esas áreas trata con aplicaciones multiusuario en las que todos los usuarios esperan disponer de vistas comunes de los objetos que están siendo actualizados por cualquiera de ellos. Dichas aplicaciones precisan que sus datos sean atómicos en presencia de actualizaciones concurrentes y caídas del servidor, y las técnicas de transacciones parecen ofrecer una aproximación a su diseño. Sin embargo, estas aplicaciones tienen dos nuevos requisitos relacionados con el control de concurrencia: (1) el usuario precisa la notificación inmediata de los cambios realizados por otros usuarios, lo que es contrario a la idea de aislamiento, y (2) los usuarios necesitan ser capaces de acceder a los objetos antes de que otros usuarios hayan completado sus transacciones, lo que conduce al desarrollo de nuevos tipos de bloqueo que disparan acciones cuando se accede a los objetos. El trabajo en esta área ha sugerido muchos esquemas que relacionan el aislamiento y proporcionan notificación de los cambios. Para una revisión de este trabajo,

jan el aislamiento y proporcionan notificación de los cambios. Para una revisión de este trabajo,

EJERCICIOS

- 12.1.** La BolsadeTareas es un servicio cuya funcionalidad es proporcionar un almacén para las *descripciones de tareas*. Permite a los clientes de diferentes computadores realizar partes de una computación en paralelo. Un proceso *maestro* coloca las descripciones de las sub-tareas de una computación en la BolsadeTareas, y un proceso *trabajador* selecciona tareas de la BolsadeTareas y las efectúa, devolviendo los resultados a la BolsadeTareas. El *maestro* recoge los resultados y los combina para producir el resultado final.

El servicio BolsadeTareas proporciona las siguientes operaciones:

- | | |
|------------------|---|
| <i>ponTarea</i> | permite a los clientes añadir descripciones de tareas a la bolsa; |
| <i>tomaTarea</i> | permite a los clientes tomar descripciones de tareas de la bolsa. |

Un cliente realiza una petición *tomaTarea*, cuando una tarea no está disponible pero puede estar disponible en breve. Discutir las ventajas y desventajas de las siguientes alternativas:

- El servidor puede responder inmediatamente, diciendo al cliente que lo intente más tarde.
- Se hace que el servidor espere (y por lo tanto también el cliente) hasta que una tarea esté disponible.
- Se utilizan devoluciones de llamada.

- 12.2.** Un servidor gestiona los objetos a_1, a_2, \dots, a_n . El servidor proporciona dos operaciones a sus clientes:

- lee(i)* devuelve el valor de a_i ;
escribe(i, Valor) asigna *Valor* a a_i .

Las transacciones *T* y *U* se definen de la siguiente forma:

- T*: $x = \text{lee}(j); y = \text{lee}(i); \text{escribe}(j, 44); \text{escribe}(i, 33);$
U: $x = \text{lee}(k); \text{escribe}(i, 55); y = \text{lee}(j); \text{escribe}(k, 66);$

Proporcione tres solapamientos serialmente equivalentes de las transacciones *T* y *U*.

- 12.3.** Obtenga solapamientos secuencialmente equivalentes de *T* y *U* del Ejercicio 12.2 con las siguientes propiedades: (1) que sean estrictos; (2) que no sean estrictos pero no puedan producir abortos en cascada; (3) que puedan producir abortos en cascada.
- 12.4.** La operación *crea* inserta una nueva cuenta en una sucursal. Las transacciones *T* y *U* están definidas como siguen:

- T*: *unaSucursal.crea(«Z»)*;
U: *z.deposita(10); z.deposita(20)*;

Supóngase que *Z* no existe todavía. Supóngase también que la operación *deposita* no hace nada si la cuenta proporcionada en el argumento no existe. Considérese el siguiente solapamiento de las transacciones *T* y *U*:

<i>T</i>	<i>U</i>
<i>unaSucursal.crea(Z)</i>	<i>z.deposita(10);</i> <i>z.deposita(20);</i>

Establecer el balance de Z después de la ejecución en este orden. ¿Son consistentes todas las ejecuciones de T y U secuencialmente equivalentes?

- 12.5.** Un objeto recién creado como Z en el Ejercicio 12.4 se llama a veces un *fantasma*. Desde el punto de vista de la transacción U , Z no existe al principio y entonces aparece (como un fantasma). Explicar, con un ejemplo, cómo se podría producir un fantasma cuando se borra una cuenta.
- 12.6.** Las transacciones *transferencia* T y U se definen como:

T : a.extrae(4); b.deposita(4);
 U : c.extrae(3); b.deposita(3);

Supóngase que están estructuradas como pares de transacciones anidadas:

T_1 : a.extrae(4); T_2 : b.deposita(4);
 U_1 : c.extrae(3); U_2 : b.deposita(3);

Compare el número de solapamientos secuencialmente equivalentes de T_1 , T_2 , U_1 y U_2 con el número de solapamientos secuencialmente equivalentes de T y U . Explique por qué el uso de transacciones anidadas permite un número más grande de solapamientos secuencialmente equivalentes que las no anidadas.

- 12.7.** Considere los aspectos de recuperación de las transacciones anidadas definidas en el Ejercicio 12.6. Suponga que una transacción *reintegro* abortará si la cuenta queda en descubierto y que en este caso la transacción padre también abortará. Describa solapamientos de T_1 , T_2 , U_1 y U_2 secuencialmente equivalentes con las siguientes propiedades: (i) que sean estrictos; (ii) que no sean estrictos. ¿Con qué opción el criterio de ser estricto reduce la ganancia potencial de concurrencia de las transacciones anidadas?
- 12.8.** Explique por qué la equivalencia secuencial precisa que una vez que una transacción ha liberado un bloqueo sobre un objeto, no le está permitido obtener más bloqueos. Un servidor gestiona los objetos a_1 , a_2 , ... a_n . El servidor proporciona a sus clientes dos operaciones:

$lee(i)$ devuelve el valor de a_i
 $escribe(i, Valor)$ asigna $Valor$ a a_i

Las transacciones T y U están definidas de la forma siguiente:

T : $x = lee(i); escribe(j, 44);$
 U : $escribe(i, 55); escribe(j, 66);$

Describa un solapamiento de las transacciones T y U en el que los bloqueos se liberan prontamente con el efecto de que el solapamiento no es secuencialmente equivalente.

- 12.9.** Las transacciones T y U en el servidor del Ejercicio 12.8 se definen:

T : $x = lee(i); escribe(j, 44);$
 U : $escribe(i, 55); escribe(j, 66);$

Los valores iniciales de a_i y a_j son 10 y 20 respectivamente. ¿Cuál de los siguientes solapamientos son secuencialmente equivalentes, y qué ocurriría con un bloqueo en dos fases?

(a)	T	U	(b)	T	U
	$x = lee(i);$ $escribe(j, 44);$	$escribe(i, 55);$ $escribe(j, 66);$		$x = lee(i);$ $escribe(j, 44);$	$escribe(i, 55);$ $escribe(j, 66);$

(c)	T	U	(d)	T	U
	$x = lee(i);$ $escribe(j, 44);$	$escribe(i, 55)$ $escribe(j, 66);$		$x = lee(i);$ $escribe(j, 44);$	$escribe(i, 55);$ $escribe(j, 66);$

- 12.10.** Considere una relajación de los bloqueos en dos fases en los que las transacciones de *sólo lectura* pueden leer los bloqueos con anterioridad. ¿Debería tener recuperaciones consistentes una transacción de sólo lectura? ¿Llegarían los objetos a ser inconsistentes? Ilustre su respuesta con las siguientes transacciones T y U en el servidor del Ejercicio 12.8:

T : $x = lee(i); y = lee(j);$
 U : $escribe(i, 55); escribe(j, 66);$

en las que los valores iniciales de a_i y a_j son 10 y 20.

- 12.11.** Las ejecuciones de transacciones son estrictas si las operaciones *lee* y *escribe* sobre un objeto son retrasadas hasta que todas las transacciones que escribieron sobre ese objeto previamente se han consumido o abortado. Explique cómo las reglas de bloqueo de la Figura 12.16 aseguran ejecuciones estrictas.
- 12.12.** Describa cómo se podrá alcanzar una situación no recuperable si los bloqueos de escritura son liberados después de la última operación de una transacción pero antes de su consumación.

- 12.13.** Explique por qué las ejecuciones son siempre estrictas, incluso si los bloqueos de lectura son liberados después de la última operación de una transacción pero antes de su consumación. Proporcione una exposición mejorada de la regla 2 de la Figura 12.16.

- 12.14.** Considere un esquema de detección de bloqueo indefinido para un servidor único. Describa de forma precisa cuándo se añaden y se eliminan arcos de un grafo *espera por*. Ilustre su respuesta con respecto a las siguientes transacciones T , U y V en el servidor del Ejercicio 12.8.

T	U	V
$escribe(i, 55)$	$escribe(i, 66)$ $consuma$	$escribe(i, 77)$

- 12.19.** Considere el uso de ordenación por marcas de tiempo con cada uno de los solapamientos ejemplo de las transacciones T y U en el Ejercicio 12.9. Los valores iniciales de a_i y a_j son 10 y 20, respectivamente, y las marcas de tiempo de lectura y escritura iniciales son t_0 . Suponga que cada transacción se abre y obtiene una marca de tiempo justo antes de su primera operación; por ejemplo, en (a) T y U obtienen las marcas de tiempo t_1 y t_2 respectivamente, donde $t_0 < t_1 < t_2$. Describa los efectos de cada operación de T y U en orden ascendente de tiempo. Para cada operación establece lo siguiente:

- Si la operación puede realizarse de acuerdo con la regla de lectura o escritura.
- Las marcas de tiempo asignadas a las transacciones o a los objetos.
- Creación de objetos tentativos y sus valores.

¿Cuáles son los valores finales de los objetos y sus marcas de tiempo?

- 12.20.** Repita el Ejercicio 12.19 para los siguientes solapamientos de las transacciones T y U :

T	U	T	U
abreTransacción $x = \text{lee}(i);$ $\text{escribe}(j, 44);$	abreTransacción $\text{escribe}(i, 55);$ $\text{escribe}(j, 66);$ consuma	abreTransacción $x = \text{lee}(i);$ $\text{escribe}(j, 44);$	abreTransacción $\text{escribe}(i, 55);$ $\text{escribe}(j, 66);$ consuma

- 12.21.** Repita el Ejercicio 12.20 empleando la ordenación de marcas de tiempo multiversión.
- 12.22.** En la ordenación por marcas de tiempo multiversión, las operaciones de *lectura* pueden acceder a versiones tentativas de los objetos. Dé un ejemplo para mostrar cómo pueden suceder los abortos en cascada si se permite que todas las operaciones de *lectura* se realicen inmediatamente.
- 12.23.** ¿Cuáles son las ventajas y las desventajas de la ordenación por marcas de tiempo multiversión en comparación con la ordenación por marcas de tiempo ordinaria?
- 12.24.** Haga una comparación de las secuencias de operaciones de las transacciones T y U del Ejercicio 12.8 que sean posibles bajo el bloqueo en dos fases (Ejercicio 12.9) y bajo control de concurrencia optimista (Ejercicio 12.16).

TRANSACCIONES DISTRIBUIDAS

- 13.1. Introducción
- 13.2. Transacciones distribuidas planas y anidadas
- 13.3. Protocolos de consumación atómica
- 13.4. Control de concurrencia en transacciones distribuidas
- 13.5. Interbloqueos distribuidos
- 13.6. Recuperación de transacciones
- 13.7. Resumen

Este capítulo presenta las transacciones distribuidas, que son aquellas que involucran a más de un servidor. Las transacciones distribuidas pueden ser planas o anidadas.

Un protocolo de consumación atómica es un procedimiento cooperativo utilizado por un conjunto de servidores involucrados en una transacción distribuida. Permite que los servidores lleguen a una decisión conjunta sobre si una transacción debe ser consumada o debe ser abortada. Este capítulo describe el protocolo de consumación en dos fases, que es el protocolo de consumación atómica más habitualmente utilizado.

La sección dedicada al control de concurrencia entre transacciones distribuidas discute cómo pueden extenderse las técnicas de control de concurrencia (mediante bloqueo, ordenación mediante marcas temporales y optimista) para su utilización en las transacciones distribuidas.

La utilización de esquemas de bloqueo puede llevar a interbloqueos distribuidos. Se discutirán los algoritmos de detección de interbloqueo distribuido.

Los servidores que proporcionan transacciones incluyen un gestor de recuperación, cuyo cometido es asegurarse de que los efectos de las transacciones sobre los objetos gestionados por un servidor puedan recuperarse cuando se le reemplaza tras un fallo. El gestor de recuperación guarda los objetos en dispositivos de almacenamiento permanente, junto con las listas de intenciones y la información acerca del estado de cada transacción.

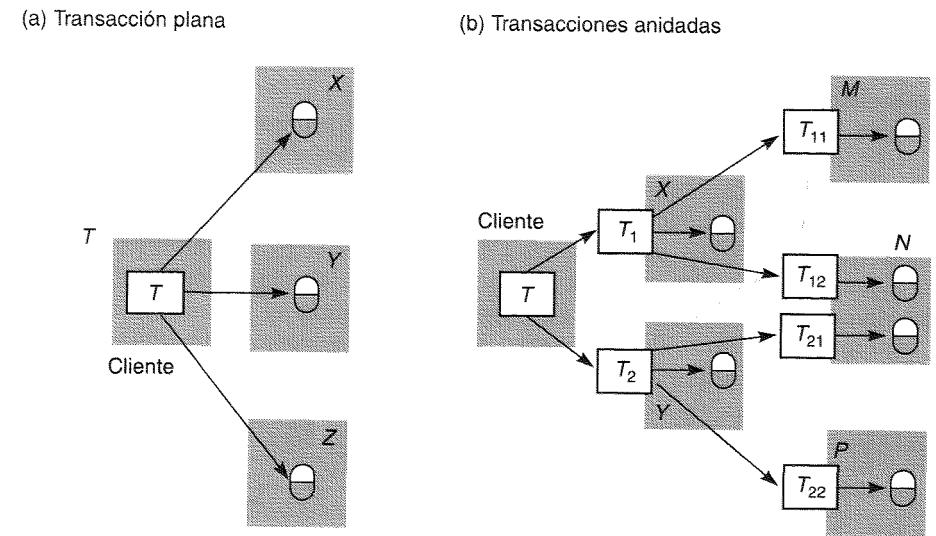


Figura 13.1. Transacciones distribuidas.

servidores separados X e Y , y las cuentas C y D están en el servidor Z . Si la transacción se estructura como un conjunto de cuatro transacciones anidadas, como se muestra en la Figura 13.2, las cuatro peticiones (dos *depósitos* y dos *extracciones*) pueden ejecutarse en paralelo, y el efecto global puede conseguirse con mejor rendimiento que el de una transacción simple en la que las cuatro operaciones se invocan secuencialmente.

13.2.1. EL COORDINADOR DE UNA TRANSACCIÓN DISTRIBUIDA

Los servidores que ejecutan peticiones como parte de una transacción distribuida necesitan poder comunicarse entre ellos para coordinar sus acciones cuando se consuma la transacción. Un cliente comienza una transacción enviando una petición de *abreTransacción* al coordinador en cualquier servidor, como se describe en la Sección 12.2. El coordinador con el que se contacta lleva a cabo

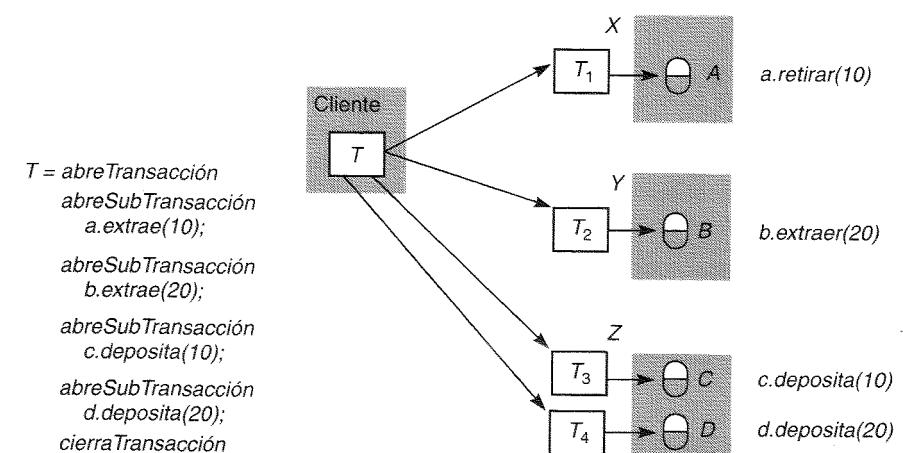


Figura 13.2. Transacción bancaria anidada.

abrirTransacción y devuelve al cliente el identificador resultante de la transacción. Los identificadores de transacción son únicos dentro del sistema distribuido.

ubicado en uno de los servidores involucrados en la transacción. Cada servidor se muestra por medio de un *participante*, que se une a la transacción invocando al método *unirse* del coordinador. Cuando el cliente invoca uno de los métodos dentro de la transacción, por ejemplo *b.extrae(T, 3)*, el objeto que recibe la invocación (en este caso *B* en la *SucursalY*) informa a su objeto participante que el objeto pertenece a la transacción *T*. Si no ha informado ya al coordinador, el objeto participante utilizará la operación *unirse* para hacerlo. En este ejemplo, se muestra el identificador de la transacción siendo pasado como un argumento adicional de tal forma que el receptor puede pasárselo al coordinador. En el momento en el que el cliente llame a *cierraTransacción*, el coordinador tiene referencias de todos los participantes.

Nótese que es posible que un participante llame a *abortaTransacción* en el coordinador si, por alguna razón, es incapaz de continuar con la transacción.

13.3. PROTOCOLOS DE CONSUMACIÓN ATÓMICA

Los protocolos de consumación de transacciones fueron desarrollados a comienzos de la década de los años setenta, y el protocolo de consumación en dos fases apareció en Gray [1978]. La atomicidad de las transacciones requiere que al finalizar una transacción distribuida, bien se han llevado a cabo todas las operaciones o bien no se ha llevado a cabo ninguna. En el caso de una transacción distribuida, el cliente ha solicitado operaciones en más de un servidor. Una transacción finaliza cuando el cliente solicita que la transacción sea consumada o abortada. Una forma sencilla de completar la transacción de una forma atómica es que el coordinador comunique, a todos los participantes en la transacción, la petición de consumar o abortar, y continúe repitiendo la petición hasta que todos ellos hayan enviado un acuse de recibo indicando que la han llevado a cabo. Éste es un ejemplo de *protocolo de consumación atómica en una fase*.

Este sencillo protocolo de consumación atómica en una fase es inadecuado porque, en el caso en el que el cliente solicita una consumación, no permite a un servidor tomar una decisión unilateral de abortar la transacción. Las razones que impiden que un servidor sea capaz de consumir su parte de una transacción están relacionadas, generalmente, con temas de control de concurrencia. Por ejemplo, si se está usando un bloqueo, la resolución de un interbloqueo puede llevar a abortar una transacción sin que el cliente sea consciente de ello, a no ser que haga otra petición al servidor. Si se utiliza un control de concurrencia optimista, el fallo de la validación en un servidor podría causar que éste decida abortar la transacción. El coordinador podría no saber cuándo se ha caído un servidor y ha sido reemplazado durante el progreso de una transacción distribuida (dicho servidor necesitará abortar la transacción).

El *protocolo de consumación en dos fases* está diseñado para permitir que cualquier participante aborde su parte de la transacción. Debido al requisito de atomicidad, si una parte de la transacción es abortada, en consecuencia debe abortarse también la transacción en su totalidad. En la primera fase del protocolo, cada participante vota para que la transacción sea consumada o abortada. Una vez que un participante ha votado por la consumación de la transacción, no se le permite que la aborde. Por tanto, antes de que un participante vote para que se consume la transacción, debe asegurarse que será capaz de llevar a cabo su parte del protocolo de consumación, incluso si falla y es reemplazado en su transcurso. Se dice que un participante en una transacción está en estado *preparado* para una transacción si será finalmente capaz de consumarla. Para estar seguro de esto, cada participante guarda en un dispositivo de almacenamiento permanente todos los objetos que haya alterado durante la transacción, junto con su estado (*preparado*).

En la segunda fase del protocolo, todo participante en la transacción lleva a cabo la decisión conjunta. Si alguno de los participantes vota por abortar, entonces la decisión ha de ser de abortar la transacción. Si todos los participantes votan consumar, entonces la decisión es de consumar la transacción.

El problema está en estar seguro de que todos los participantes votan y que todos llegan a la misma decisión. Esto es relativamente sencillo si no ocurre ningún fallo; no obstante el protocolo debe trabajar correctamente incluso cuando algunos de los servidores fallan, se pierden mensajes o los servidores son temporalmente incapaces de comunicarse entre ellos.

◊ **Modelo de fallos para los protocolos de consumación.** La Sección 12.12 presentaba un modelo de fallo para transacciones que se aplica también a los protocolos de consumación en dos fases (o a cualquier otro protocolo de consumación). Los protocolos de consumación se diseñan para trabajar en un sistema asíncrono, en el cual pueden caer los servidores o pueden producirse pérdidas de mensajes. Se supone que un protocolo subyacente de petición-respuesta elimina los mensajes duplicados y los corruptos. No existen fallos extraños, es decir, los servidores se caen o bien obedecen los mensajes que se les envían.

El protocolo de consumación en dos fases es un ejemplo de un protocolo para alcanzar el consenso. El Capítulo 11 estableció que no puede alcanzarse el consenso en un sistema asíncrono si los procesos, de vez en cuando, fallan. Sin embargo, el protocolo de consumación en dos fases es capaz de alcanzar el consenso en estas condiciones. Esto se debe a que los fallos por caída de los procesos se enmascaran reemplazando el proceso caído por un nuevo proceso cuyo estado se establece partiendo de la información guardada en un dispositivo de almacenamiento permanente y de la información que han retenido otros procesos.

13.3.1. EL PROTOCOLO DE CONSUMACIÓN EN DOS FASES

Durante el progreso de una transacción, no existe comunicación entre el coordinador y los participantes, excepto cuando los participantes informan al coordinador de que se unen a la transacción. La petición de un cliente de consumir (o abortar) una transacción se dirige al coordinador. Si el cliente solicita *abortaTransacción*, o si la transacción es abortada por los participantes, el coordinador informará a los participantes inmediatamente. Es cuando el cliente pide al coordinador que se complete la transacción cuando el protocolo de consumación en dos fases entra en acción.

En la primera fase del protocolo de consumación en dos fases el coordinador pregunta a todos los participantes si están preparados para consumir; y en el segundo, les dice que consumen (o aborten) la transacción. Si un participante puede consumir su parte de la transacción, dirá que está de acuerdo tan pronto como haya grabado los cambios y su estado en un dispositivo de almacenamiento permanente, y esté preparado para consumir. El coordinador en una transacción distribuida

puedeConsumar?(trans) → Sí / No

Llamada desde el coordinador al participante para preguntar si puede consumar una transacción.
El participante responde con su voto.

Consuma(trans)

Llamada desde el coordinador al participante para decirle que consume su parte de una transacción.

Aborta(trans)

Llamada desde el coordinador al participante para decirle que aborte su parte de una transacción.

heConsumado(trans, participante)

Llamada desde el participante al coordinador para confirmar que ha consumido la transacción.

dameDecisión(trans) → Sí / No

Llamada desde el participante al coordinador para preguntar por la decisión sobre una transacción tras haber votado Sí aunque no ha obtenido respuesta tras cierto tiempo. Se utiliza para recuperarse de la caída de un servidor o de mensajes con retraso.

Figura 13.4. Operaciones para el protocolo de consumación en dos fases.

Fase 1 (fase de votación):

1. El coordinador envía una petición *puedeConsumar?* a cada participante en la transacción.
2. Cuando un participante recibe una petición *puedeConsumar?*, responde al coordinador con su voto (Sí o No). Antes de votar Sí, se prepara para consumir, guardando los objetos en un dispositivo de almacenamiento permanente. Si el voto es No, el participante aborta inmediatamente.

Fase 2 (finalización en función del resultado de la votación)

3. El coordinador recoge los votos (incluyendo el propio).
 - (a) Si no hay fallos y todos los votos son Sí, el coordinador decide consumir la transacción y envía peticiones *Consuma* a cada uno de los participantes.
 - (b) En otro caso, el coordinador decide abortar la transacción y envía peticiones *Aborta* a todos los participantes que votaron Sí.
4. Los participantes que han votado Sí están esperando por una petición *Consuma* o *Aborta* por parte del coordinador. Cuando un participante recibe uno de estos mensajes, actúa en función de ellos, y en el caso de *Consuma*, realiza una llamada de *heConsumado* como confirmación hacia el coordinador.

Figura 13.5. El protocolo de consumación en dos fases.

se comunica con los participantes para llevar a cabo el protocolo de consumación en dos fases mediante las operaciones que se resumen en la Figura 13.4. Los métodos *puedeConsumar?*, *Consuma* y *Aborta* son métodos de la interfaz del participante. Los métodos *heConsumado* y *dameDecisión* están en la interfaz del coordinador.

El protocolo de consumación en dos fases, como se muestra en la Figura 13.5, consta de una fase de votación y una fase de finalización. Al final de la etapa (2), el coordinador y todos los participantes que votaron Sí están preparados para consumir. Al final del paso (3), la transacción ha finalizado a todos los efectos. En el paso (3a) el coordinador y los participantes se han comprometido y, por lo tanto, el coordinador puede informar al cliente de una decisión de consumir. En el paso (3b) el coordinador informa al cliente de la decisión de abortar.

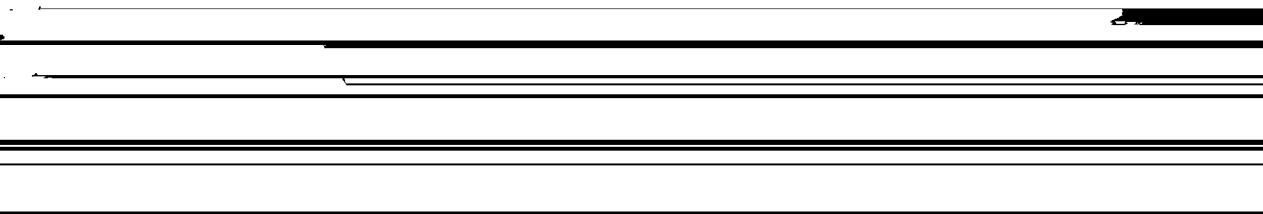
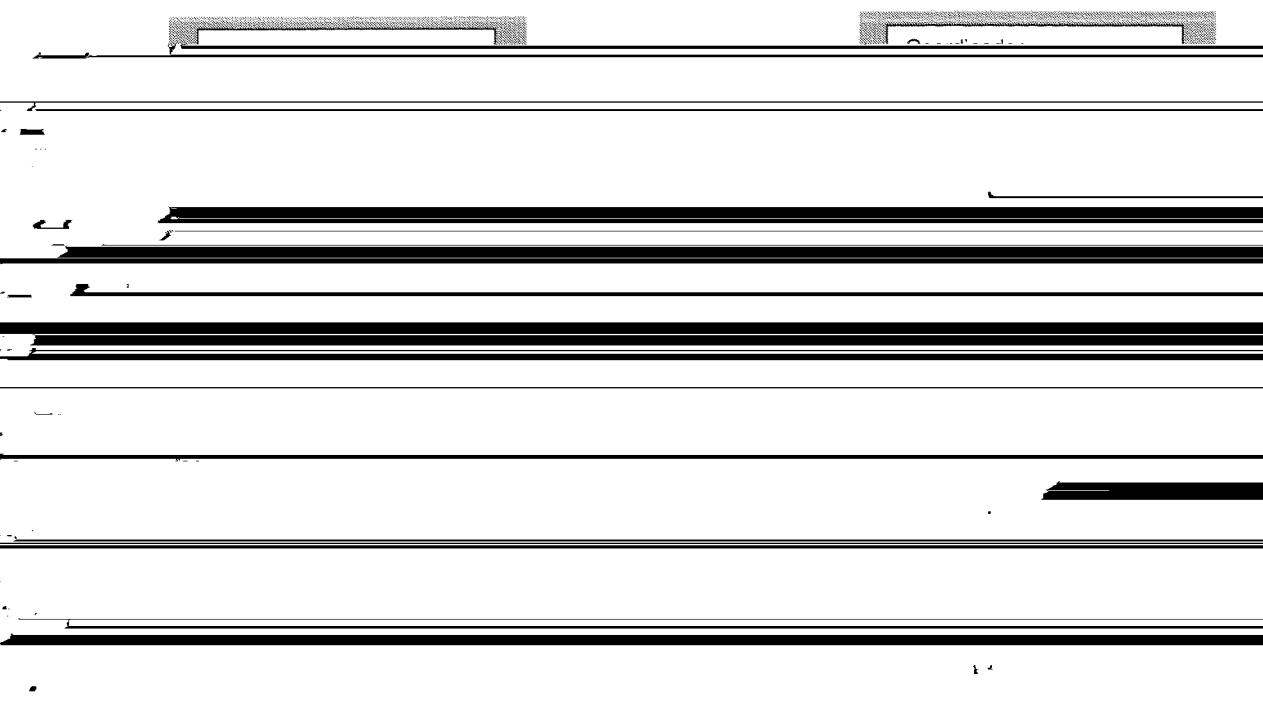
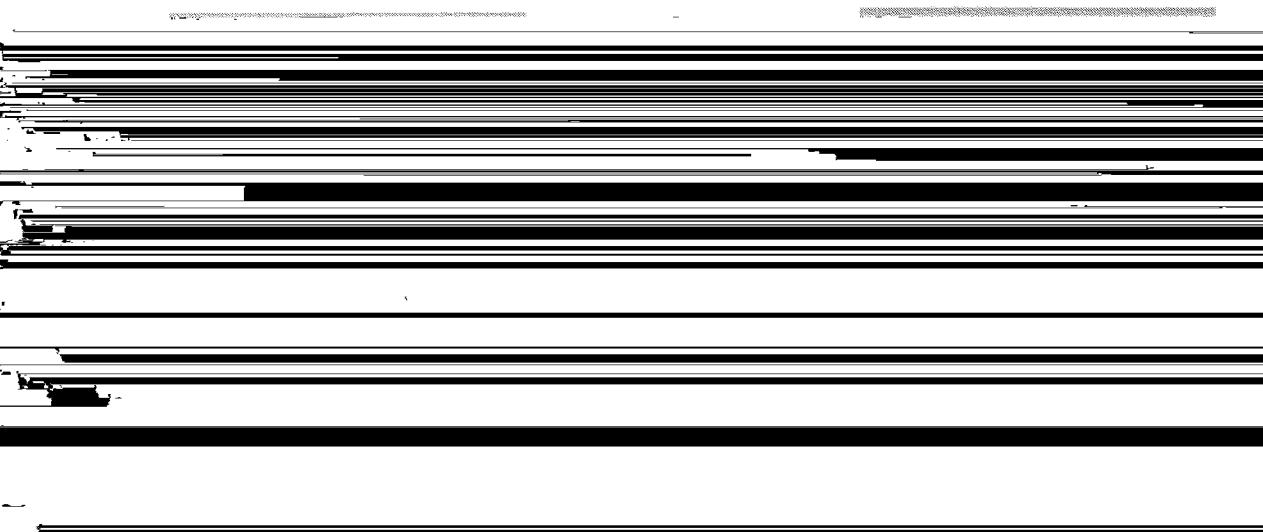
En el paso (4) los participantes confirman que ellos han consumido su parte, de tal forma que el coordinador sabe en qué momento deja de ser necesaria la información que almacenaba con respecto a la transacción.

Este protocolo, aparentemente directo, podría fallar debido a la caída de uno o más de los servidores o debido a un corte de la comunicación entre los servidores. Para cubrir la posibilidad de caídas, cada servidor guarda la información relativa al protocolo de consumación en dos fases en un dispositivo de almacenamiento permanente. Esta información puede ser recuperada por un nuevo proceso que se inicie para reemplazar al servidor caído. Los aspectos de la recuperación en las transacciones distribuidas se discuten en la Sección 13.6.

El intercambio de información entre el coordinador y los participantes puede fallar cuando uno de los servidores se cae o cuando se pierden mensajes. Para evitar que los procesos se queden bloqueados de forma indefinida se utilizan tiempos límite de espera (*timeout*). Cuando ocurre un timeout dentro de un proceso, éste debe emprender una acción apropiada. Para permitir este aspecto, el protocolo incluye una acción asociada a un tiempo límite para cada paso en el cual pueda bloquearse el proceso. Estas acciones se diseñan teniendo en cuenta el hecho de que en un sistema asíncrono exceder un tiempo límite no implica, necesariamente, que el proceso haya fallado.

◊ **Acciones frente a un timeout en el protocolo de consumación en dos fases.** Existen varias fases en el protocolo en las cuales el coordinador o un participante no pueden avanzar en su parte del protocolo hasta que reciban una petición o una respuesta por parte de los otros.

En primer lugar, considérese la situación en la que un participante ha votado Sí y está esperando para que el coordinador le informe del resultado de la votación, indicándole que consume o



En el peor de los casos, podría haber un número arbitrario de fallos en el servidor y las comunicaciones durante el protocolo de consumación en dos fases. Sin embargo, el protocolo está diseñado para tolerar una sucesión de fallos (caídas de servidores o pérdida de mensajes) y se garantiza que finaliza, de alguna forma, aunque no es posible especificar un límite de tiempo en el que se completa.

Como se apuntó en la sección de los tiempos límite, el protocolo de consumación en dos fases puede ocasionar retrasos considerables a los participantes en un estado *incierto*. Estos retrasos se dan cuando el coordinador ha fallado y no puede responder a las peticiones de *dameDecisión* por parte de los participantes. Incluso si un protocolo cooperativo permite a los participantes hacer peticiones de *dameDecisión* a otros participantes, ocurrirán retrasos si todos los participantes activos están en estado *incierto*.

Para rebajar estos retrasos se han diseñado protocolos de consumación en tres fases. Éstos son más costosos en cuanto al número de mensajes y al número de rondas necesarias para el caso normal (sin fallos). Para una descripción de los protocolos de consumación en tres fases, vea el Ejercicio 13.2 y Bernstein y otros [1987].

13.3.2. PROTOCOLO DE CONSUMACIÓN EN DOS FASES PARA TRANSACCIONES ANIDADAS

La transacción más externa en un conjunto de transacciones anidadas se denomina *transacción de nivel superior*. El resto de transacciones distintas a la de nivel superior se denominan *subtransacciones*. En la Figura 13.1(b), T es la transacción de nivel superior, T_1 , T_2 , T_{11} , T_{12} , T_{21} y T_{22} son subtransacciones. T_1 y T_2 son las transacciones hijas de T , a la que se refieren como madre. De forma similar, T_{11} y T_{12} son transacciones hijas de T_1 , y T_{21} y T_{22} son transacciones hijas de T_2 . Cada subtransacción comienza tras su madre y termina antes que ella. Así, por ejemplo, T_{11} y T_{12} comienzan antes que T_1 y terminan antes que ella.

Cuando finaliza una subtransacción, toma una decisión independiente sobre si consumarse de forma provisional o si abortar. Una consumación provisional no es lo mismo que estar preparado; simplemente, es una decisión local y no se guarda una copia en un dispositivo de almacenamiento permanente. Si, a continuación, el servidor se cae, su sustituto no será capaz de llevar a cabo la consumación provisional. Por esta razón, se requiere un protocolo de consumación en dos fases para transacciones anidadas, que permita a los servidores que han fallado, que aborten las transacciones que se hayan consumido provisionalmente.

Un coordinador para una subtransacción proporcionará una operación para abrir una subtransacción, junto con una operación que permita al coordinador de una subtransacción preguntar si su madre ya se ha consumado o ha abortado tal como se muestra en la Figura 13.7.

Un cliente comienza un conjunto de transacciones anidadas abriendo una transacción de nivel superior, mediante una operación *abreTransacción*. Dicha operación devuelve un identificador de transacción para la transacción de nivel superior. El cliente comienza una subtransacción invocando la operación *abreSubTransacción*, cuyo argumento especifica su transacción madre. La nueva

abreSubTransacción(trans) → subTrans

Abre una nueva subtransacción cuya madre es *trans*, y devuelve un identificador de subtransacción único.

dameEstado(trans) → consumada, abortada, provisional

Pide al coordinador que informe del estado de la transacción *trans*. Devuelve valores que representan uno de los siguientes: *consumada, abortada, provisional*.

Figura 13.7. Operaciones en el coordinador para las transacciones anidadas.

subtransacción automáticamente se une (unirse) a la transacción madre y se obtiene un identifica-

Coordinador de la transacción	Transacciones hijas	Participante	Lista de consumaciones provisionales	Lista de abortadas
T	T_1, T_2	Sí	T_1, T_{12}	T_{11}, T_2
T_1	T_{11}, T_{12}	Sí	T_1, T_{12}	T_{11}
T_2	T_{21}, T_{22}	No (abortada)		T_2
T_{11}		No (abortada)		T_{11}
T_{12}, T_{21}		T_{12} pero no T_{21}	T_{21}, T_{12}	
T_{22}		No (madre ha abortado)		T_{22}

Figura 13.9. Información retenida por los coordinadores de transacciones anidadas.

abortado a su madre sin dar ninguna información acerca de sus descendientes. Al final, la transacción de nivel superior recibe una lista de todas las subtransacciones en el árbol, junto con el estado de cada una de ellas. Lo que realmente ocurre es que se eliminan de la lista los descendientes de las subtransacciones que han abortado.

En la Figura 13.9 se muestra la información que mantiene cada coordinador en el ejemplo de la Figura 13.8. Nótese que T_{12} y T_{21} comparten el mismo coordinador, ya que ambas se ejecutan en el servidor N . Cuando la subtransacción T_2 abortó, informó del hecho a su madre, T , pero no pasó información alguna acerca de sus subtransacciones T_{21} y T_{22} . Una subtransacción es *huérfana* si una de sus ascendientes ha abortado, bien de forma explícita, bien porque su coordinador se ha caído.

En nuestro ejemplo, las subtransacciones T_{21} y T_{22} son huérfanas porque sus madres abortaron sin pasar información acerca de ellos a la transacción de nivel superior. Su coordinador puede, sin embargo, realizar indagaciones acerca del estado de sus madres utilizando la operación *dameEstado*. Una subtransacción consumada provisionalmente dentro de una transacción abortada debería ser abortada, sin tener en cuenta si al final la transacción del nivel superior se consuma.

La transacción de nivel superior juega el papel de coordinador en el protocolo de consumación en dos fases, y la lista de participantes consta de los coordinadores de todas las subtransacciones en el árbol que se han consumido provisionalmente pero no tienen ascendientes que hayan abortado. Al llegar a esta fase, la lógica del programa ha determinado que la transacción de nivel superior debe intentar consumir lo que quede, a pesar de algunas subtransacciones abortadas. En la Figura 13.8, los coordinadores de T , T_1 y T_{12} son participantes y se les pedirá que voten para obtener el resultado. Si votan consumar, entonces deben *preparar* sus transacciones guardando el estado de los objetos en el dispositivo de almacenamiento permanente. Este estado se registra como perteneciente a la transacción de nivel superior de la cual formará parte. El protocolo de consumación en dos fases puede ejecutarse tanto de una forma jerárquica como de una forma plana.

La segunda fase del protocolo de consumación en dos fases es la misma que para el caso no anidado. El coordinador recoge los votos y después informa a los participantes en función del resultado. Cuando finalice, el coordinador y los participantes habrán consumado o abortado sus transacciones.

◊ **Protocolo de consumación en dos fases jerárquico.** En esta aproximación, el protocolo de consumación en dos fases se convierte en un protocolo anidado multi-nivel. El coordinador de la transacción de nivel superior se comunica con los coordinadores de las subtransacciones para las que es su madre inmediata. Envía mensajes *puedeConsumar?* a cada uno de estas últimas, las cuales, a su vez, los pasan a los coordinadores de sus transacciones hijas (y así sucesivamente en

puedeConsumar?(trans, subTrans) → Sí / No

Llama a un coordinador para que pregunte al coordinador de una subtransacción hija si puede consumar una subtransacción *subTrans*. El primer argumento *trans* es el identificador de la transacción del nivel superior. El participante responde con su voto *Sí / No*.

Figura 13.10. *puedeConsumar?* para el protocolo de consumación en dos fases jerárquico.

el árbol). Cada participante recoge las respuestas de sus descendientes antes de responder a sus madres. En nuestro ejemplo, T envía mensajes *puedeConsumar?* al coordinador de T_1 y luego T_1 envía mensajes *puedeConsumar?* a T_{12} preguntando acerca de los descendientes de T_1 . El protocolo no incluye a los coordinadores de las transacciones tales como T_2 , que ha abortado. La Figura 13.10 muestra los argumentos que son necesarios para *puedeConsumar?*. El primer argumento es el TID de la transacción de nivel superior, que será usado cuando se preparen los datos. El segundo argumento es el TID del participante que hace la llamada *puedeConsumar?*. El participante que recibe la llamada busca en su lista de transacciones cualquier transacción o subtransacción consumada provisionalmente que concuerde con el TID del segundo argumento. Por ejemplo, el coordinador de T_{12} es también el coordinador de T_{21} , ya que se ejecutan en el mismo servidor, pero cuando reciba la llamada de *puedeConsumar?* el segundo argumento será T_1 y tratará sólo con T_{12} .

Si un participante encuentra cualquier subtransacción que se ajuste al segundo argumento, prepara los objetos y responde con un voto *Sí*. Si no consigue encontrar alguna, entonces debe haberse caído desde que realizó la subtransacción y le responde con un voto *No*.

◊ **Protocolo de consumación en dos fases plano.** En esta aproximación, el coordinador de la transacción de nivel superior envía mensajes *puedeConsumar?* a los coordinadores de todas las subtransacciones en la lista de consumaciones provisionales. En nuestro ejemplo, a los coordinadores de T_1 y T_{12} . Durante el protocolo de consumación, los participantes se refieren a la transacción por su TID del nivel superior. Cada participante busca en su lista de transacciones cualquier transacción o subtransacción que se ajuste a ese TID. Por ejemplo, el coordinador de T_{12} es además el coordinador de T_{21} , ya que se ejecutan en el mismo servidor (N).

Desafortunadamente, esto no proporciona suficiente información para permitir a los participantes realizar acciones correctas, como en el caso del coordinador en el servidor N , que tiene una mezcla de subtransacciones consumadas provisionalmente o abortadas. Si al coordinador de N simplemente se le pide que consume T acabará consumiendo tanto T_{12} como T_{21} , porque, de acuerdo con su información local, ambos se han consumado provisionalmente. Esto es erróneo en el caso de T_{21} , ya que su madre, T_2 , ha abortado. Para tener en cuenta tales casos, la operación *puedeConsumar?* en el protocolo de consumación plano tiene un segundo argumento que proporciona una lista de subtransacciones abortadas, como se muestra en la Figura 13.11. Un participante podrá consumar descendientes de la transacción del nivel superior a no ser que éstas tengan ascendientes abortados. Cuando un participante recibe una petición de *puedeConsumar?*, hace lo siguiente:

- Si el participante tiene algunas transacciones consumadas provisionalmente que sean descendientes de la transacción de nivel superior, *trans*:
 - Comprueba que no tienen ascendentes abortados en la *listaAbortadas*. En ese caso puede prepararse para consumir (guardando la transacción y sus objetos en un dispositivo de almacenamiento permanente).
 - Aquellas transacciones con ascendentes abortados, serán abortadas.
 - Envía un voto *Sí* al coordinador.
- Si el participante no tiene transacciones consumadas provisionalmente que sean descendientes de la transacción de nivel superior, debe haber fallado desde que realizó la subtransacción, y envía un voto *No* al coordinador.

puedeConsumar?(trans, listaAbortadas) → Sí / No

Llamada desde el coordinador a un participante para preguntar si puede consumar una transacción. El participante responde con su voto *Sí / No*.

Figura 13.11. *puedeConsumar?* para el protocolo de consumación en dos fases plano.

◊ **Comparación de las dos aproximaciones.** El protocolo jerárquico tiene la ventaja de que, en cada etapa, el participante sólo necesita buscar subtransacciones de su madre inmediata, mientras que en el protocolo plano necesita disponer de la lista de transacciones abortadas para eliminar aquellas transacciones cuyos madres hubiesen abortado. Moss [1985] prefería el algoritmo plano porque permitía al coordinador de la transacción de nivel superior comunicarse directamente con todos los participantes, mientras que la variante jerárquica involucra el paso de una serie de mensajes hacia arriba y hacia abajo en el árbol en las distintas etapas.

◊ **Acciones asociadas a tiempos límite.** El protocolo de consumación en dos fases para el caso de transacciones anidadas puede ocasionar que se retrasen el coordinador o un participante en los mismos tres pasos que en la versión no anidada. Aparece un cuarto paso en el cual la subtransacción puede retrasarse. Considere las subtransacciones consumadas provisionalmente y que son hijas de subtransacciones abortadas: éstas puede que no sean informadas del resultado de la votación de la transacción. En nuestro ejemplo, T_{22} es una de estas transacciones, ésta se ha consumado provisionalmente, pero como su madre T_2 ha abortado, no se convierte en una participante. Para abordar estas situaciones, cualquier subtransacción que no haya recibido un mensaje *puedeConsumar?* indagará pasado un período de tiempo límite. La operación *dameEstado* de la Figura 13.7 permite que una subtransacción pregunte si su madre se ha completado o ha abortado. Para hacer posibles tales preguntas, los coordinadores de las subtransacciones abortadas han de sobrevivir un cierto período de tiempo. Si una subtransacción huérfana no puede contactar con su madre, al final, abortará.

13.4. CONTROL DE CONCURRENCIA EN TRANSACCIONES DISTRIBUIDAS

Cada servidor gestiona un conjunto de objetos y es responsable de asegurar que éstos mantienen su consistencia cuando se accede a ellos desde transacciones concurrentes. Por lo tanto, cada servidor es responsable de aplicar un control de concurrencia sobre sus propios objetos. Los miembros de una colección de servidores de transacciones distribuidas son responsables conjuntamente de asegurar que dichas transacciones se realizan de una forma secuencialmente equivalente.

Esto implica que si la transacción T se da antes que la transacción U en un acceso conflictivo a objetos en uno de los servidores, entonces han de estar en ese orden en todos los servidores a cuyos objetos se accede, de forma conflictiva, por T y U .

13.4.1. BLOQUEO

En una transacción distribuida, los bloqueos sobre un objeto se mantienen localmente (en el mismo servidor). El gestor de bloqueos locales, puede decidir la concesión de un bloqueo o hacer que la transacción espere. Sin embargo, no puede liberar ningún bloqueo hasta que sepa que la transacción se ha consumado o ha abortado en todos los servidores involucrados en la transacción. Cuando se utilizan bloqueos para el control de concurrencia, los objetos permanecen bloqueados y no están disponibles para otras transacciones durante el protocolo de consumación atómica, aunque una transacción abortada libere sus bloqueos tras la primera fase del protocolo.

Dado que los gestores de bloqueos en distintos servidores fijan sus bloqueos con independencia de los otros, es posible que distintos servidores impongan ordenamientos distintos sobre las transacciones. Considérese el siguiente solapamiento de las transacciones T y U en los servidores X e Y :

T	U
<i>Escribe(A)</i> en X bloquea A	<i>Escribe(B)</i> en Y bloquea B
<i>Lee(B)</i> en Y espera por U	<i>Lee(A)</i> en X espera por T

La transacción T bloquea al objeto A en el servidor X y, a continuación, la transacción U bloquea al objeto B en el servidor Y . Tras esto, T intenta acceder a B en el servidor Y , y espera dado el bloqueo de U . De forma similar, la transacción U intenta acceder a A en el servidor X , y tiene que esperar dado el bloqueo de T . Por lo tanto, tenemos T antes que U en un servidor y U antes que T en el otro. Estas ordenaciones distintas pueden llevar a ciclos de dependencias entre transacciones y surge una situación de interbloqueo distribuido. La detección y solución de interbloqueos distribuidos se discute en la siguiente sección de este capítulo. Cuando se detecta un interbloqueo, se aborta una transacción para resolverlo. En este caso, se informará al coordinador y se abortará la transacción en los participantes involucrados en dicha transacción.

13.4.2. CONTROL DE CONCURRENCIA CON ORDENACIÓN DE MARCAS TEMPORALES

En una transacción en un único servidor, el coordinador asigna una marca temporal única a cada transacción cuando ésta comienza. Se consigue la equivalencia secuencial consumiendo las versiones de los objetos en el orden de las marcas temporales de las transacciones que acceden a ellos. En las transacciones distribuidas, se requiere que cada coordinador genere marcas temporales que sean globalmente únicas. El primer coordinador al que accede la transacción le proporcionará al cliente una marca temporal para la transacción globalmente única. La marca temporal de la transacción se pasa al coordinador de cada servidor sobre cuyos objetos se realice una operación en la transacción.

Los servidores de transacciones distribuidas son responsables conjuntamente de asegurar que las transacciones se realicen de forma secuencialmente equivalente. Por ejemplo, si la versión de un objeto al que accede la transacción U se consume después que la versión a la que accede T en otro servidor, entonces si T y U acceden al mismo objeto de la misma forma en otros servidores, deben consumirse tam bien en el mismo orden. Para conseguir la misma ordenación en todos los servidores, los coordinadores deben ponerse de acuerdo en lo referente a la ordenación de sus marcas temporales. Una marca temporal consta de una pareja *<marca temporal local, identificador del servidor>*. La ordenación acordada entre parejas de marcas temporales se basa en una comparación en la cual la parte del *identificador del servidor* es la parte menos significativa.

Se puede conseguir la misma ordenación de las transacciones en todos los servidores incluso si sus relojes locales no están sincronizados. Sin embargo, por razones de eficiencia, se requiere que las marcas temporales proporcionadas por un coordinador estén aproximadamente sincronizadas con aquellas que emiten otros coordinadores. Cuando ocurre esto, la ordenación de transacciones se corresponde, generalmente, con el orden en el que comienzan en el tiempo real. Las marcas temporales pueden mantenerse sincronizadas de una forma aproximada mediante la utilización de relojes físicos sincronizados localmente (véase el Capítulo 10).

Cuando se utiliza la ordenación de marcas temporales para el control de concurrencia, los conflictos se resuelven según se realiza cada operación. Si la resolución de un conflicto requiere que se aborde una transacción, se informará al coordinador y éste abortará la transacción en todos los participantes. Por lo tanto, toda transacción que le llegue al cliente con la petición de consumirse debería ser siempre capaz de consumirse. En consecuencia, normalmente en el protocolo de consumación en dos fases un participante llegará a un acuerdo para consumirse. La única situación en la cual un participante no llegará a un acuerdo para consumirse es que éste se haya caído durante la transacción.

13.4.3. CONTROL DE CONCURRENCIA OPTIMISTA

Recuérdese que con el control de concurrencia optimista, cada transacción se valida antes de que se le permita consumirse. Se asignan los números de transacción al comienzo de la validación y se establece la secuencia de las transacciones de acuerdo al orden de los números de transacciones. Una transacción distribuida es validada por una colección de servidores independientes, cada uno de los cuales valida las transacciones que acceden a sus propios objetos. La validación en todos los servidores tiene lugar durante la primera fase del protocolo de consumación en dos fases.

Considérense las siguientes transacciones entrelazadas T y U , que acceden a los objetos A y B en los servidores X e Y , respectivamente.

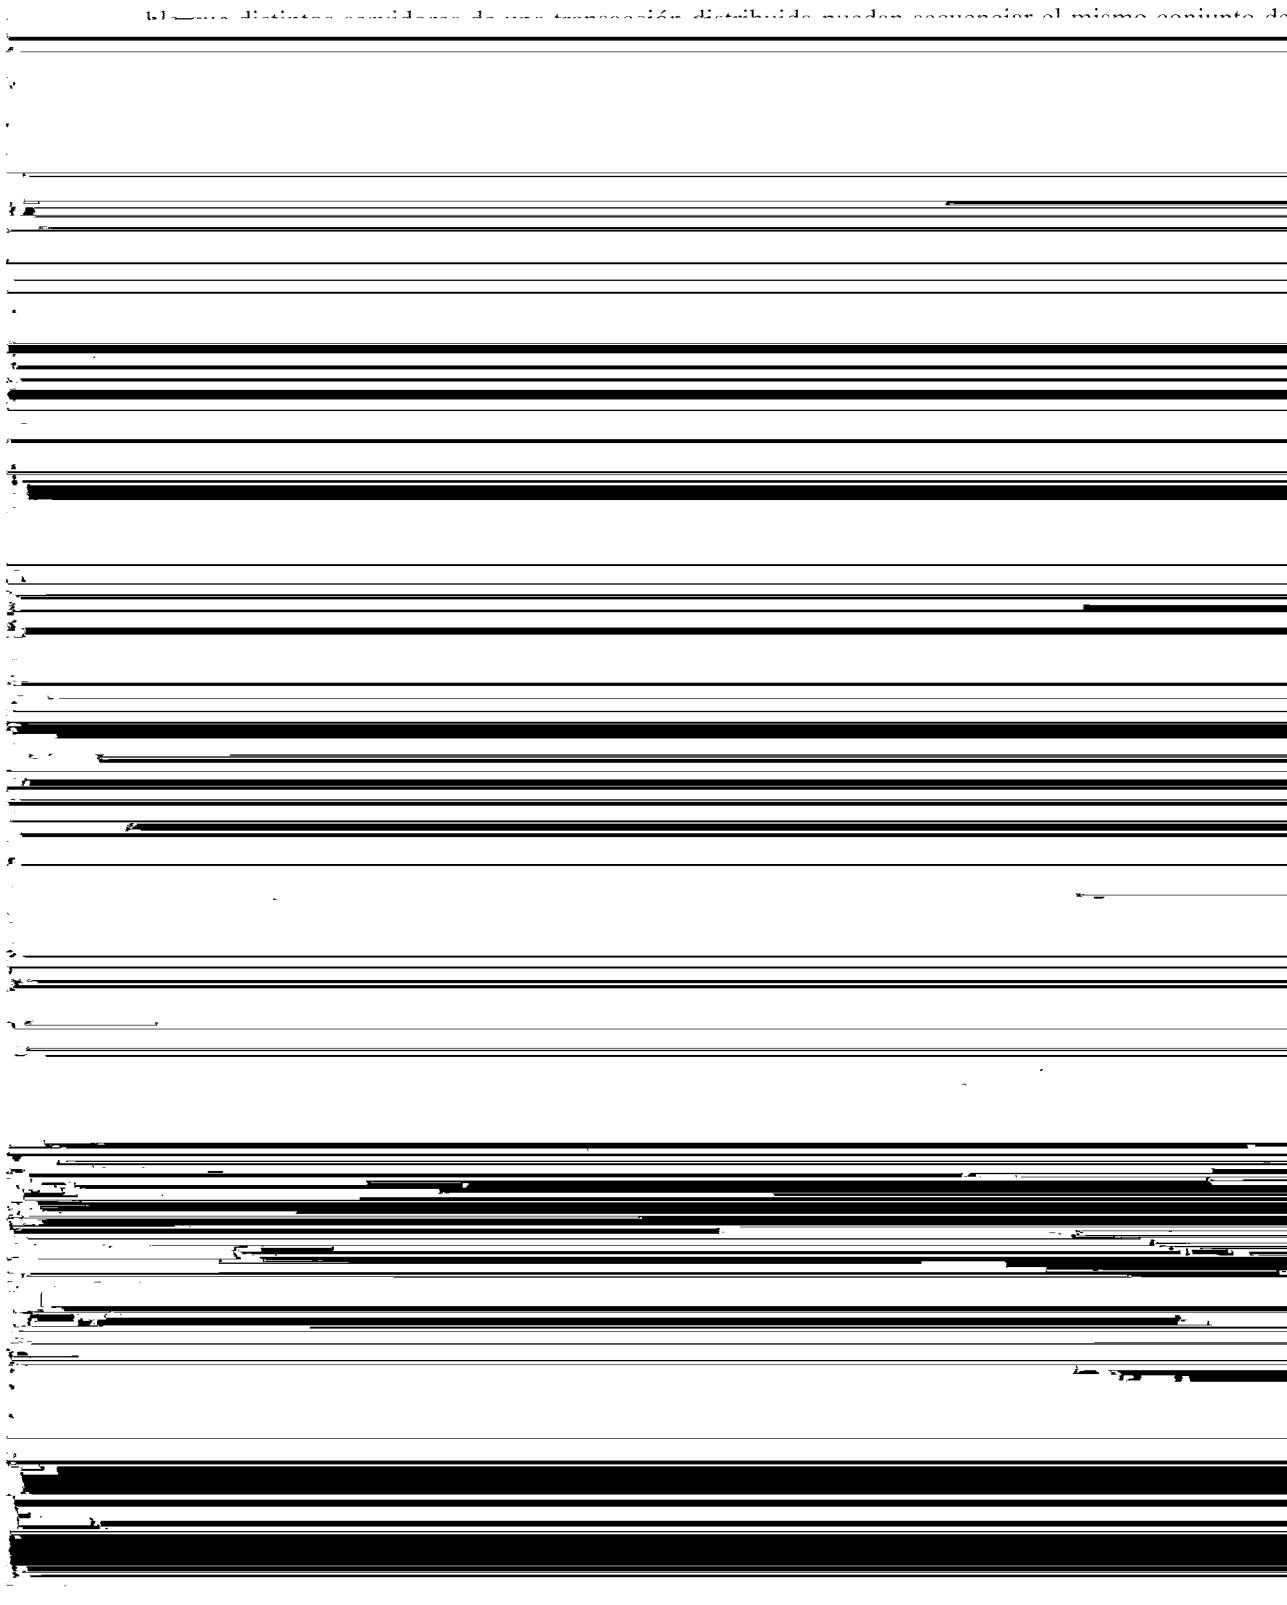
T	U
<i>Lee(A)</i> en X	<i>Lee(B)</i> en Y
<i>Escribe(A)</i>	<i>Escribe(B)</i>

T	U
<i>Lee(B)</i> en Y	<i>Lee(A)</i> en X
<i>Escribe(B)</i>	<i>Escribe(A)</i>

Las transacciones acceden a los objetos en el orden « T antes que U » en el servidor X y en el orden « U antes que T » en el servidor Y . Ahora supóngase que T y U comienzan la validación aproximadamente al mismo tiempo, pero el servidor X valida a T primero y el servidor Y valida a U primero. Recuérdese que la Sección 12.5 recomendaba una simplificación del protocolo de validación que establece una regla por la que sólo una transacción puede realizar, cada vez, las fases de validación y actualización. Por lo tanto, cada servidor será incapaz de validar la otra transacción hasta que la primera se haya completado. Éste es un ejemplo de interbloqueo por consumación.

Las reglas de validación de la Sección 12.5 asumía que la validación es rápida, lo cual es cierto para transacciones sobre un único servidor. Sin embargo, en una transacción distribuida, el protocolo de compromiso en dos fases puede necesitar algún tiempo y retrasar que otras transacciones entren a la validación hasta que se haya obtenido una decisión sobre la transacción actual. En el caso de transacciones distribuidas optimistas, cada servidor aplica en paralelo un protocolo de validación. Ésta es una extensión de la validación hacia delante o hacia atrás, para permitir que varias transacciones estén al mismo tiempo en la fase de validación. En esta extensión, deben comprobarse tanto la regla 3 como la regla 2 para la validación hacia atrás. Esto es, debe comprobarse el conjunto de escritura de una transacción que está siendo validada para detectar alguna superposición con el conjunto de escritura de transacciones anteriores con las que se solapan. En el trabajo de Kung y Robinson [1991] se describe la validación en paralelo.

Si se utiliza la validación en paralelo, las transacciones no sufrirán de interbloqueo por consumación. Sin embargo, si los servidores sencillamente realizan validaciones independientes, es posi-



<i>U</i>	<i>V</i>	<i>W</i>
<i>d.deposita(10)</i> bloquea <i>D</i>	<i>b.deposita(10)</i> bloquea <i>B</i> en <i>Y</i>	
<i>a.deposita(20)</i> bloquea <i>A</i> en <i>X</i>		<i>c.deposita(30)</i> bloquea <i>C</i> en <i>Z</i>
<i>b.extrae(30)</i> espera en <i>Y</i>	<i>c.extrae(20)</i> espera en <i>Z</i>	<i>a.extrae(20)</i> espera en <i>X</i>

Figura 13.12. Entrelazamientos de las transacciones *U*, *V* y *W*.

una transacción o una transacción esperando por un objeto. Existe un interbloqueo si y sólo si hay un ciclo en el grafo *espera por*.

La Figura 13.12 muestra el entrelazamiento de las transacciones *U*, *V* y *W* que involucran a los objetos *A* y *B* gestionados por los servidores *X* e *Y*, y los objetos *C* y *D* gestionados por el servidor *Z*.

En la Figura 13.13(a) el grafo *espera por* completo muestra que un ciclo asociado a un interbloqueo está formado por arcos alternados, que representan a una transacción esperando por un objeto y un objeto retenido por una transacción. Ya que cualquier transacción puede estar esperando sólo por un objeto cada vez, los objetos pueden dejarse fuera de los grafos *espera por*, como se muestra en la Figura 13.13(b).

La detección de un interbloqueo distribuido requiere encontrar un ciclo en el grafo *espera por* global de la transacción, que está distribuido entre los servidores que estaban involucrados en las transacciones. Los gestores de bloqueos en cada servidor pueden construir los grafos *espera por* locales, como se comentó en el Capítulo 12. En el ejemplo anterior, los grafos *espera por* locales de los servidores son:

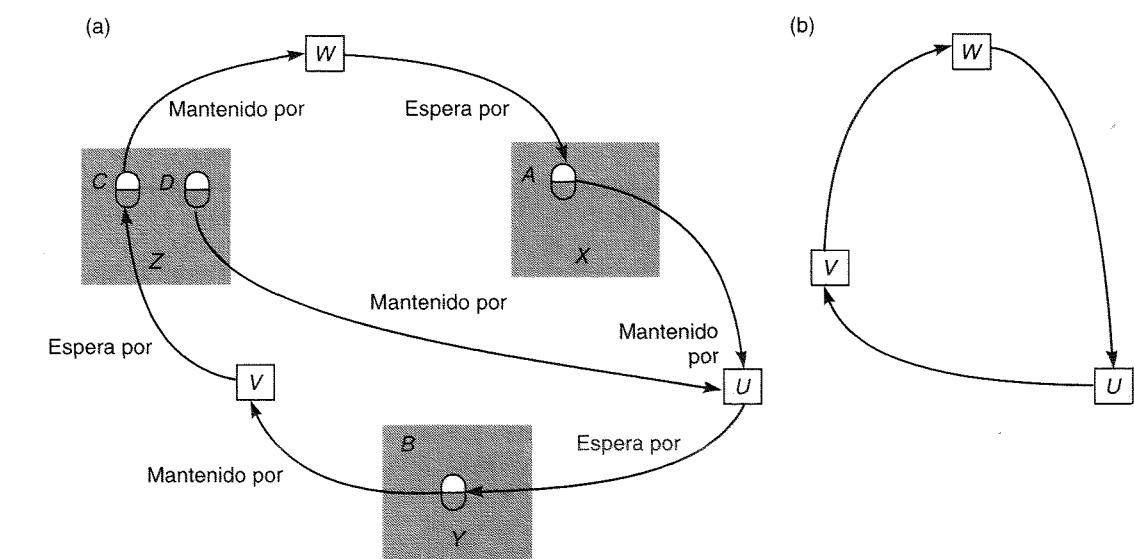
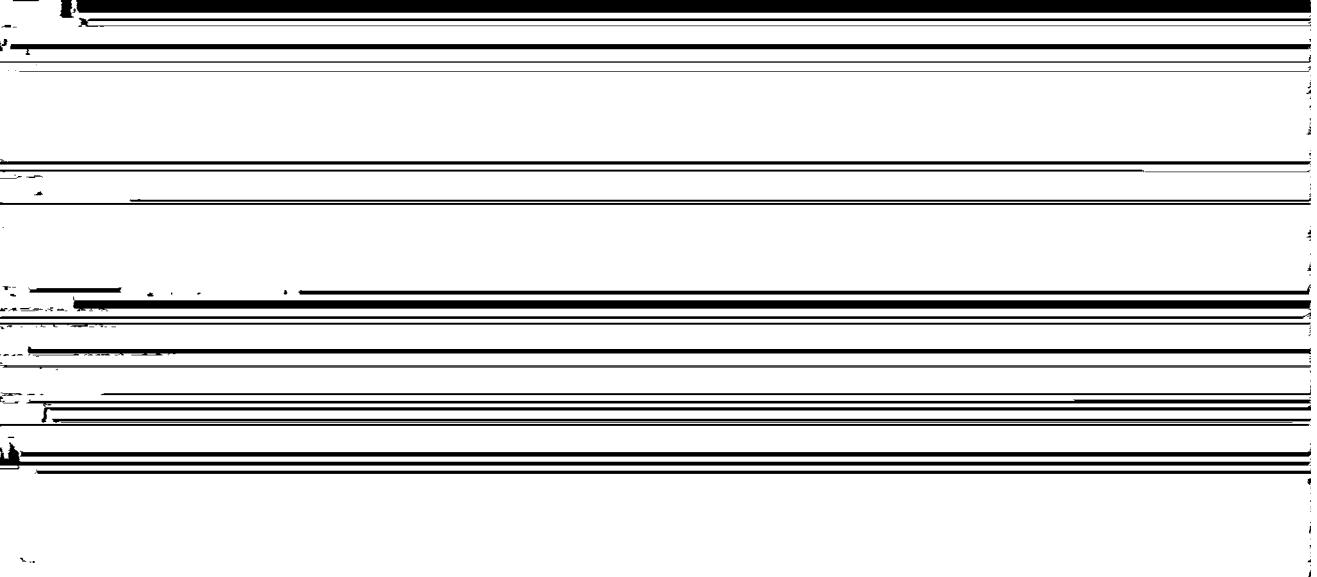


Figura 13.13. Interbloqueo distribuido.

servidor Y: $U \rightarrow V$ (se añade cuando U solicita $b.extrae(30)$)
 servidor Z: $V \rightarrow W$ (se añade cuando V solicita $c.extrae(20)$)



servidor Y: $U \rightarrow V$ (se añade cuando U solicita $b.extrae(30)$)
 servidor Z: $V \rightarrow W$ (se añade cuando V solicita $c.extrae(20)$)



ciclo $T \rightarrow U \rightarrow V \rightarrow T$ y U aborta una vez que ha sido recogida la información relativa a U, entonces roto ya el ciclo no hay interbloqueo.

◊ **Caza de arcos.** Una aproximación distribuida para la detección de interbloqueos utiliza una técnica denominada captura de los arcos (*edge chasing*) o empuje de caminos (*path pushing*). En esta aproximación, el grafo no se construye *espera por* global, sino que cada uno de los servidores implicados posee información sobre algunos de sus arcos. Los servidores intentan encontrar ciclos mediante el envío de mensajes denominados *sondas*, que siguen los arcos de un grafo a través del sistema distribuido. Un mensaje sonda está formado por las relaciones *espera por* de transacciones que representan un camino en el grafo *espera por* global.

La pregunta es: ¿cuándo debería un servidor enviar una sonda? Considérese la situación en el servidor X en la Figura 13.13. Este servidor sólo ha añadido el arco $W \rightarrow U$ a su grafo *espera por* local y en ese momento, la transacción U está esperando para acceder al objeto B, que la transacción V retiene en el servidor Y. Este arco podría ser, posiblemente, parte de un ciclo tal como $V \rightarrow T_1 \rightarrow T_2 \rightarrow \dots \rightarrow W \rightarrow U \rightarrow V$ involucrando transacciones que utilizan objetos en otros servidores. Esto indica que hay un potencial ciclo asociado a un interbloqueo distribuido, que podría encontrarse enviando una sonda al servidor Y.

Ahora considérese la situación un poco antes, cuando el servidor Z añadió el arco $V \rightarrow W$ a su grafo local: en ese momento, W no está esperando. Por lo tanto, no sería necesario mandar la sonda.

Cada transacción distribuida comienza en un servidor (denominado el coordinador de la transacción) y se mueve a otros servidores distintos (denominados participantes en la transacción), que pueden comunicarse con el coordinador. En cualquier instante de tiempo, una transacción puede estar, bien activa, bien esperando en sólo uno de estos servidores. El coordinador es responsable de registrar si la transacción está activa o está esperando por un objeto concreto, y los participantes pueden obtener esta información desde su coordinador. Los gestores de bloqueos informan a los coordinadores cuando las transacciones comienzan a esperar por objetos, y cuando las transacciones adquieren dichos objetos y vuelven a estar activas. Cuando se aborta una transacción para romper un interbloqueo, su coordinador informará a los participantes y se eliminarán todos sus bloqueos, con el efecto de que todos los arcos involucrados en la transacción se eliminarán de los grafos *espera por* locales.

Los algoritmos de captura de arcos tienen tres pasos: iniciación, detección y resolución.

Iniciación: cuando un servidor percibe que una transacción T comienza a buscar a otra transacción U, y ésta a su vez está esperando para acceder a un objeto en otro servidor, iniciará la detección enviando una sonda que contiene el arco $\langle T \rightarrow U \rangle$ al servidor del objeto por el cual está bloqueada la transacción U. Si U está compartiendo un bloqueo, se envían sondas a todos los que poseen dicho bloqueo. Algunas veces otras transacciones pueden comenzar a compartir el bloqueo más tarde, en cuyo caso también deben enviárselas sondas a ellas.

Detección: la detección consiste en recibir sondas y decidir si se ha producido un interbloqueo o si hay que enviar nuevas sondas.

Por ejemplo, cuando un servidor de un objeto recibe la sonda $\langle T \rightarrow U \rangle$ (indicando que T está esperando por la transacción U, que retiene un objeto local) comprueba si U está también esperando. Si es así, la transacción por la que espera (por ejemplo, V) se añade a la sonda (consiguiendo $\langle T \rightarrow U \rightarrow V \rangle$), y si la nueva transacción (V) está esperando por otro objeto en otro sitio, se vuelve a enviar la sonda.

De esta forma, se construye un camino a través del grafo *espera-por* global añadiendo un eje cada vez. Antes de volver a enviar una sonda, el servidor comprueba si la transacción que acaba de ser añadida (por ejemplo, T) ha ocasionado un ciclo en la sonda (por ejemplo $\langle T \rightarrow U \rightarrow V \rightarrow T \rangle$). Si es éste el caso, ha encontrado un ciclo en el grafo y se ha detectado un interbloqueo.

Resolución: cuando se detecta un ciclo, se aborta una transacción en el ciclo para romper el interbloqueo.

En nuestro ejemplo, los siguientes pasos describen cómo se inicia la detección de interbloqueos y cómo se envían las sondas durante la correspondiente fase de detección.

- El servidor X inicia la detección enviando la sonda $<W \rightarrow U>$ al servidor de B (Servidor Y).
- El servidor Y recibe la sonda $<W \rightarrow U>$, observa que B es retenida por V y concatena V a la sonda para producir $<W \rightarrow U \rightarrow V>$. Observa que V está esperando por C en el servidor Z. La sonda se envía al servidor Z.
- El servidor Z recibe la sonda $<W \rightarrow U \rightarrow V>$ y observa que C es retenida por W y concatena W a la sonda para producir $<W \rightarrow U \rightarrow V \rightarrow W>$.

Este camino contiene un ciclo. El servidor detecta un interbloqueo. Para romper el interbloqueo debe abortarse una de las transacciones en el ciclo. La transacción a abortar puede elegirse de acuerdo a las prioridades de las transacciones, tema que se tratará en breve.

La Figura 13.15 muestra el progreso de los mensajes sonda desde la iniciación por parte del servidor de A hasta la detección del interbloqueo por parte del servidor de C. Las sondas se muestran como flechas remarcadas, los objetos como círculos y los coordinadores de las transacciones como rectángulos. Cada sonda se muestra yendo directamente de un objeto hasta otro. En realidad, antes de que un servidor transmita una sonda a otro servidor, consulta al coordinador de la última transacción en el camino para averiguar si este último está esperando por otro objeto en otra parte. Por ejemplo, antes de que el servidor de B transmita la sonda $<W \rightarrow U \rightarrow V>$ consulta al coordinador de V para averiguar si V está esperando por C. En la mayoría de los algoritmos de captura de arcos, los servidores de los objetos envían las sondas a los coordinadores de las transacciones, que pueden, a su vez, enviarlos (si la transacción está esperando) al servidor del objeto por el cual está esperando la transacción. En nuestro ejemplo, el servidor de B transmite la sonda $<W \rightarrow U \rightarrow V>$ al coordinador de V, que a su vez la envía al servidor de C. Esto muestra que para reenviar una sonda, se necesitan dos mensajes.

El algoritmo que se acaba de describir debería encontrar cualquier interbloqueo que pueda darse, dado que las transacciones que están esperando no abortan y que no hay fallos tales como pérdida de mensajes o caída de servidores. Para entender esto, considere un ciclo asociado a un

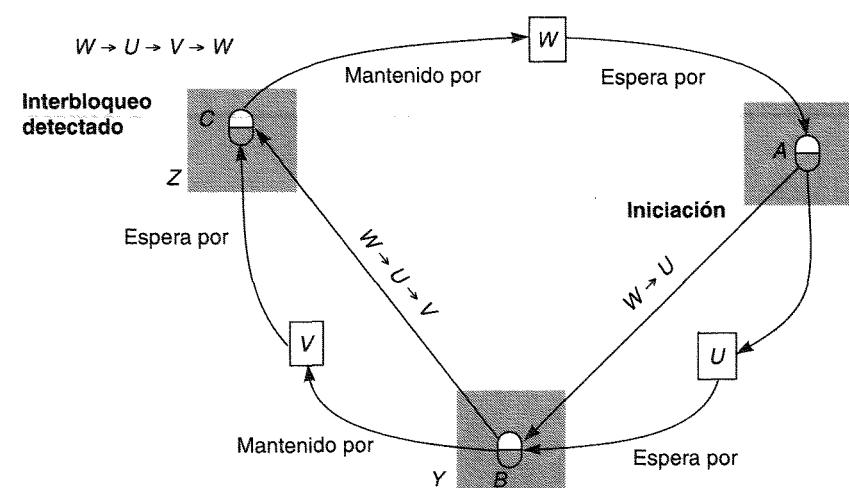


Figura 13.15. Sondas transmitidas para detectar interbloqueos.

interbloqueo en el cual la última transacción, W, comienza a esperar y se completa el ciclo. Cuando W comienza a esperar por un objeto el servidor lanza una sonda que va al servidor del objeto retenido por cada transacción por la que está esperando W. Los receptores amplían y reenvían las sondas a los servidores de los objetos solicitados por todas las transacciones en espera que pueden encontrar. De esta forma, cada transacción por la cual W está esperando, directa o indirectamente, se añadirá a la sonda, a no ser que se detecte un interbloqueo. Cuando hay un interbloqueo, W está esperando, de forma indirecta, por sí misma. Por lo tanto, la sonda volverá al objeto que retiene W.

Podría parecer que se manda un gran número de mensajes para detectar un interbloqueo. En el ejemplo de arriba, se observa que se usan dos mensajes sonda para detectar un ciclo que involucra a tres transacciones. Cada uno de los mensajes sonda consta, generalmente, de dos mensajes (del objeto al coordinador y del coordinador al objeto).

Una sonda que detecte un ciclo que involucra a N transacciones será enviado por parte de $(N - 1)$ coordinadores de transacciones a través de $(N - 1)$ servidores de los objetos, lo que requiere $2(N - 1)$ mensajes. Afortunadamente, la mayoría de los interbloqueos de deben a ciclos que contienen sólo dos transacciones, y no hay necesidad de preocuparse innecesariamente acerca del número de mensajes involucrados. Esta observación se ha obtenido partiendo de estudios en bases de datos. También se puede deducir de las probabilidades de accesos conflictivos a objetos. Véase Bernstein y otros [1987].

◊ **Prioridades de las transacciones.** En el algoritmo descrito anteriormente, cada transacción involucrada en un ciclo de un interbloqueo puede causar el inicio de una detección de un interbloqueo. El efecto asociado a que varias transacciones en un ciclo inicien la detección de interbloqueos es que pueden darse detecciones en distintos servidores del ciclo, con el resultado de que se aborte más de una transacción del ciclo.

En la Figura 13.16(a) se consideran las transacciones T, U, V y W, donde U está esperando por W y V está esperando por T. Aproximadamente al mismo tiempo, T solicita el objeto retenido por U y W solicita el objeto retenido por V. Se inician dos sondas por separado, $<T \rightarrow U>$ y $<W \rightarrow V>$, por parte de los servidores de esos objetos y están circulando hasta que dos servidores distintos detectan un interbloqueo. Véase la Figura 13.16(b), donde el ciclo es $<T \rightarrow U \rightarrow W \rightarrow V \rightarrow T>$, y el apartado (c), donde el ciclo detectado es $<W \rightarrow V \rightarrow T \rightarrow U \rightarrow W>$.

Para asegurarse de que sólo será abortada una de las transacciones en el ciclo, se asignan *prioridades* a las transacciones, de tal forma que estén totalmente ordenadas. Pueden utilizarse, por ejemplo, las marcas temporales como prioridades. Cuando se encuentra un ciclo asociado a un interbloqueo se aborta la transacción con la prioridad más baja. Incluso si varios servidores distintos detectan el mismo ciclo, todos tomarán la misma decisión sobre cuál debe ser la transacción a

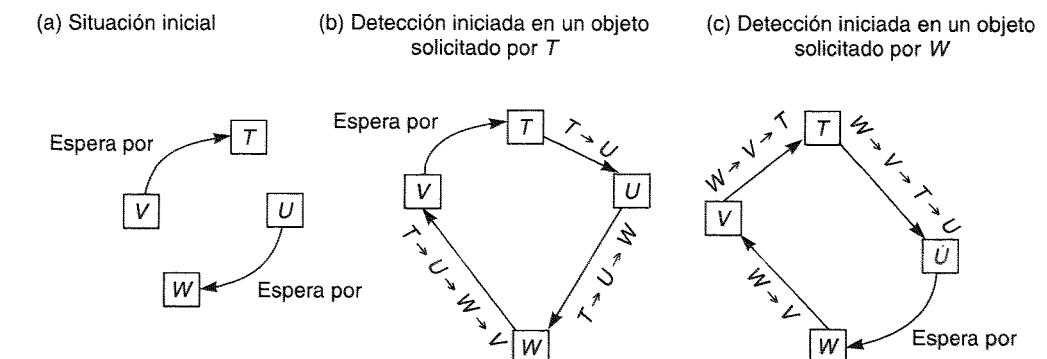


Figura 13.16. Dos sondas iniciadas.

abortar. Se escribirá $T > U$ para indicar que T tiene una prioridad mayor que U . En el ejemplo anterior, se asume que $T > U > V > W$. Por lo tanto, será abortada la transacción W cuando se detecten cualesquier de los dos ciclos: $\langle T \rightarrow U \rightarrow W \rightarrow V \rightarrow T \rangle$ o $\langle W \rightarrow V \rightarrow T \rightarrow U \rightarrow W \rangle$.

abortar. Se escribirá $T > U$ para indicar que T tiene una prioridad mayor que U . En el ejemplo anterior, se asume que $T > U > V > W$. Por lo tanto, será abortada la transacción W cuando se detecten cualesquier de los dos ciclos: $\langle T \rightarrow U \rightarrow W \rightarrow V \rightarrow T \rangle$ o $\langle W \rightarrow V \rightarrow T \rightarrow U \rightarrow W \rangle$.

Cuando un algoritmo requiere que se almacenen las sondas en colas de sondas, también requiere convenios para pasar las sondas a los nuevos retenedores y para descartar las sondas que se refieren a transacciones que ya se han consumado o que han abortado. Si se descartan sondas relevantes, podrían perderse detecciones de interbloqueos, y si se retienen sondas desfasadas, podrían detectarse interbloqueos falsos. Esto aumenta la complejidad de cualquier algoritmo de captura de arcos. Los lectores que estén interesados en los detalles de tales algoritmos deberían estudiar los trabajos de Sinha y Natarajan [1985] y de Choudhary y otros [1989], que presentan algoritmos para su uso con bloqueos exclusivos. Pero debe observarse que Choudhary y otros mostraron que el algoritmo de Sinha y Natarajan es incorrecto y no detecta todos los interbloqueos, y puede, incluso, informar de falsos interbloqueos. Kshemkalyani y Singhal [1991] corrigieron el algoritmo de Choudhary y otros (que no detecta todos los interbloqueos y puede informar de falsos interbloqueos) y proporcionaron una prueba de la corrección para el algoritmo corregido. En un trabajo posterior, Kshemkalyani y Singhal [1994] discuten que los interbloqueos distribuidos no están completamente comprendidos porque en un sistema distribuido no existen ni un estado ni un tiempo globales. De hecho, cualquier ciclo que se haya encontrado puede contener secciones que hayan sido grabadas en instantes de tiempo distintos. Además, los sitios pueden oír hablar de los interbloqueos, pero pueden no escuchar que han sido resueltos hasta que hayan transcurrido retrasos aleatorios. El trabajo describe los interbloqueos distribuidos en términos de los contenidos de la memoria distribuida, utilizando relaciones causales entre sucesos en sitios distintos.

13.6. RECUPERACIÓN DE TRANSACCIONES

La propiedad de atomicidad de las transacciones requiere que se reflejen en los objetos a los que han accedido los efectos de todas las transacciones que se han consumado y ninguno de los efectos de las transacciones incompletas o abortadas. Esta propiedad puede describirse en términos de dos aspectos: durabilidad o persistencia (*durability*) y atomicidad frente a fallos (*failure atomicity*). La durabilidad requiere que los objetos se guarden en dispositivos de almacenamiento permanentes y que, después, estén disponibles allí de forma indefinida. Por lo tanto, un acuse de recibo asociado a una petición de consumación por un cliente implica que todos los efectos de la transacción han sido registrados tanto en almacenamientos permanentes como en los objetos (volátiles) del servidor. La atomicidad ante fallos requiere que los efectos de las transacciones sean atómicas, incluso cuando el servidor se cae. La recuperación se ocupa de asegurar que los objetos de un servidor sean perdurables y que el servicio proporciona atomicidad ante fallos.

Aunque los servidores de archivos y los servidores de bases de datos mantienen los datos en dispositivos de almacenamiento permanente, otros tipos de servidores de objetos recuperables no necesitan hacerlo, excepto por motivos de recuperación. En este capítulo, se asume que cuando un servidor está en funcionamiento, mantiene todos sus objetos en la memoria volátil y registra sus objetos consumados en un *archivo* o *archivos de recuperación*. Por lo tanto, la recuperación consiste en restaurar el servidor a partir de los dispositivos de almacenamiento permanente y dejarlo con las últimas versiones consumadas de los objetos. Las bases de datos necesitan tratar con grandes volúmenes de datos. Éstas, generalmente, mantienen los objetos en dispositivos de almacenamiento estable en un disco, con una memoria caché en la memoria volátil.

Los dos requisitos de persistencia y de atomicidad ante fallos no son realmente independientes uno de otro, y pueden tratarse mediante un único mecanismo, el *gestor de recuperación*. Las tareas de un gestor de recuperación son:

- Guardar los objetos de todas las transacciones consumadas en dispositivos de almacenamiento permanente (en un archivo de recuperación).
- Restaurar los objetos del servidor tras una caída.

- Reorganizar el archivo de recuperación para mejorar el rendimiento de la recuperación.
- Reclamar espacio de almacenamiento (en el archivo de recuperación).

En algunos casos, se requerirá que el gestor de recuperación sea resistente a los fallos en los medios, como fallos en su archivo de recuperación tales que se perdieran algunos datos del disco, bien porque se hayan corrompido durante la caída, por degeneración aleatoria o por fallos permanentes. En tales casos, necesitamos otra copia del archivo de recuperación. Ésta puede estar en un dispositivo de almacenamiento estable, que se implementa para que sea muy improbable que falle, mediante discos en espejo (*mirror*) o copias en diferentes ubicaciones.

◊ **Lista de intenciones.** Cualquier servidor que proporcione transacciones necesita mantener el contacto con los objetos a los que acceden las transacciones de los clientes. Recuerde del Capítulo 12 que cuando un cliente inicia una transacción, el servidor con el que contacta en primer lugar genera un nuevo identificador de transacción y se lo devuelve al cliente. Cada solicitud posterior del cliente dentro de una transacción, incluyendo las peticiones *consuma* o *aborta*, incluirá como argumento el identificador de transacción. Durante el progreso de una transacción, las operaciones de actualización se aplican sobre un conjunto privado de versiones tentativas de los objetos que pertenecen a la transacción.

En cada servidor se guarda una *lista de intenciones* para cada una de sus transacciones actualmente activas (una lista de intenciones de una transacción en particular contiene una lista de las referencias y los valores de los objetos que son alterados durante la transacción). Cuando una transacción se consuma, se utiliza la lista de intenciones de esa transacción para identificar los objetos afectados. La versión consumada de cada objeto es reemplazada por la versión tentativa obtenida mediante la transacción, y se escribe el nuevo valor en el archivo de recuperación del servidor. Cuando aborta una transacción, el servidor utiliza la lista de intenciones para borrar todas las versiones tentativas de los objetos que fueron creadas por esa transacción.

Recuérdese además que una transacción distribuida ha de llevar a cabo un protocolo de consumoación atómico antes de que pueda consumarse o abortarse. Nuestra discusión sobre recuperación se centra en el protocolo de consumación en dos fases, en el cual todos los participantes involucrados en una transacción en primer lugar dicen si están preparados para consumarla y después, si todos los participantes están de acuerdo, llevan a cabo las acciones reales de consumación. Si los participantes no pueden ponerse de acuerdo sobre la consumación, deben abortar la transacción.

En el momento en el que un participante dice que está preparado para consumar una transacción, su gestor de recuperación debe haber guardado en su archivo de recuperación tanto su lista de intenciones para esa transacción como los objetos de la lista de intenciones, de tal forma que después podría llevar a cabo la consumación, incluso si, entretanto, se cae.

Cuando todos los participantes implicados en una transacción acuerdan en consumarla, el coordinador informa al cliente y, a continuación, envía mensajes a los participantes para que consuman su parte de la transacción. Una vez que se ha informado al cliente de que la transacción se ha consumado, los archivos de recuperación de los servidores participantes deben contener suficiente información para asegurarse de que la transacción es consumada por todos los servidores, incluso si algunos de ellos se caen entre la preparación de la consumación y la propia consumación.

◊ **Entradas en el archivo de recuperación.** Para tratar con la recuperación de un servidor enrolado en transacciones distribuidas, se almacena en el archivo de recuperación información adicional además de los valores de los objetos. Esta información concierne al *estado* de cada transacción (ya sea *consumada*, *abortada* o *preparada* para consumarse). Además, cada objeto en el archivo de recuperación se asocia con una transacción en concreto, mediante la grabación en dicho archivo de la lista de intenciones. La Figura 13.18 muestra un resumen de los tipos de entradas incluidos en un archivo de recuperación.

Los valores del estado de la transacción relacionados con el protocolo de consumación en dos fases se discutirán en la Sección 13.6.4, cuando se trate la recuperación del protocolo de consu-

<i>Tipo de entrada</i>	<i>Descripción de los contenidos de la entrada</i>
Objeto	Un valor de un objeto
Estado de la transacción	Identificador de la transacción, estado de la transacción (<i>preparada</i> , <i>consumada</i> , <i>abortada</i>), y otros valores de estado utilizados para el protocolo de consumación en dos fases.
Lista de intenciones	Identificador de la transacción y una secuencia de intenciones, cada una de las cuales consiste en <identificador de objeto>, <posición en el archivo de recuperación del valor del objeto>.

Figura 13.18. Tipos de entradas en un archivo de recuperación.

mación en dos fases. Ahora, describiremos dos aproximaciones al empleo de los archivos de recuperación: el registro histórico (*logging*) y las versiones sombra (*shadow*).

13.6.1. REGISTRO HISTÓRICO

En la técnica de registro histórico, el archivo de recuperación representa a un registro que contiene el historial de todas las transacciones realizadas por el servidor. El historial consta de los valores de los objetos, las entradas del estado de la transacción y las listas de intenciones de las transacciones. El orden de las entradas en el registro refleja el orden en el cual se prepararon, consumieron o abortaron las transacciones en el servidor. En la práctica, el archivo de recuperación contendrá una instantánea reciente de los valores de todos los objetos en el servidor, seguido de un historial de las transacciones ocurridas tras dicha instantánea.

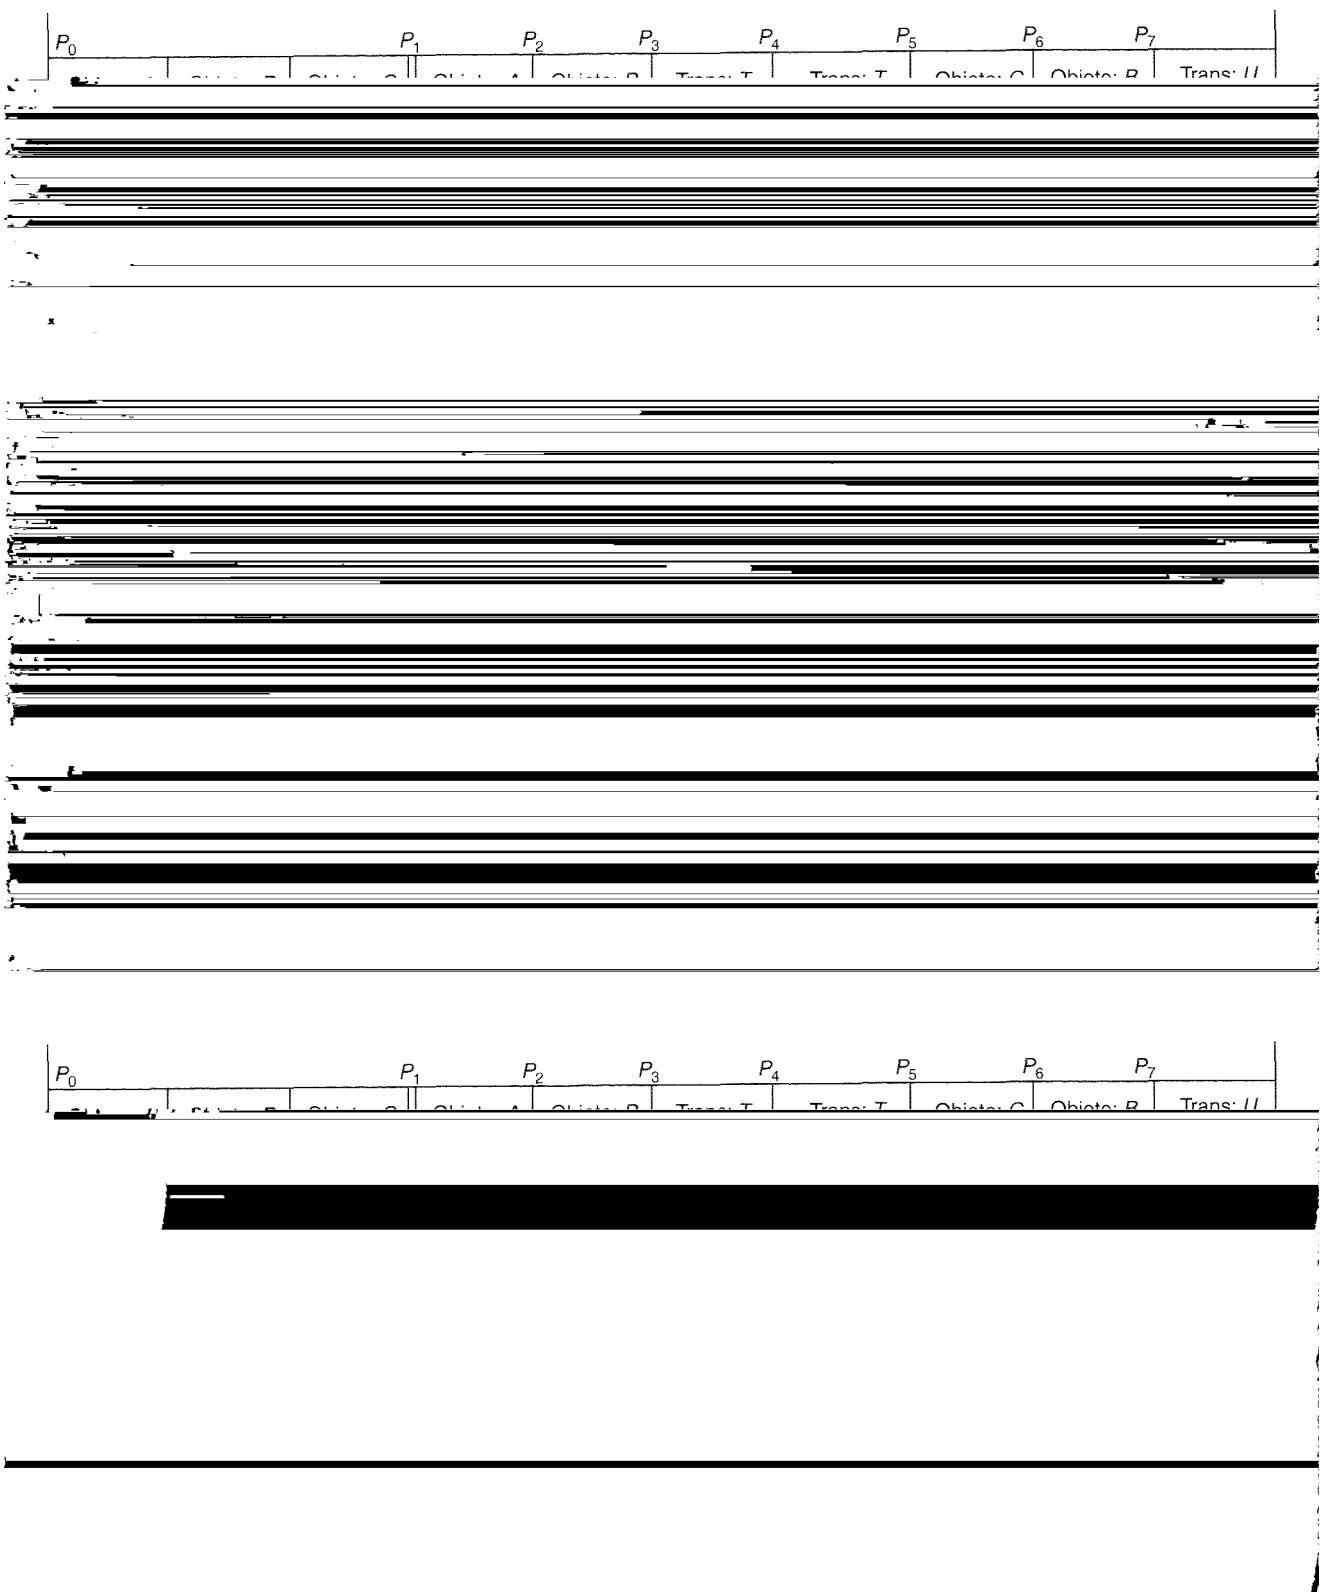
Durante la operación normal de un servidor, se llama a su gestor de recuperación en cualquier momento en el que una transacción se prepare para consumirse, ya se consume o se aborte. Cuando el servidor está preparado para consumar una transacción, el gestor de recuperación añade al archivo de recuperación todos los objetos en su lista de intenciones, seguidos por el estado actual de la transacción (*preparada*), junto con su lista de intenciones. Cuando una transacción finalmente se consuma o aborta, el gestor de recuperación añade el correspondiente estado de la transacción a su archivo de recuperación.

Se asume que la operación añadir es atómica, en el sentido de que escribe una o más entradas completas en el archivo de recuperación. Si el servidor falla, sólo puede haber sido incompleta la última escritura. Para utilizar eficientemente el disco, pueden guardarse en un búfer varias escrituras consecutivas, y a continuación pasarlo al disco con una sola operación de escritura. Una ventaja adicional de la técnica de registro histórico es que las escrituras secuenciales en el disco son más rápidas que las escrituras en ubicaciones aleatorias.

Tras una caída, se aborta cualquier transacción que no tenga el estado *consumada* en el registro. En consecuencia, cuando una transacción se consuma, debe *forzarse* la entrada en el registro de su estado, *consumada*; es decir, ha de escribirse en el registro junto con cualquier otra entrada almacenada en el búfer.

El gestor de recuperación asocia un identificador único a cada objeto, de tal forma que puedan asociarse las versiones sucesivas de un objeto en el archivo de recuperación con los objetos del servidor. Por ejemplo, una forma perdurable de una referencia a un objeto remoto, como puede ser la referencia persistente de CORBA, actuará como identificador de un objeto.

La Figura 13.19 ilustra el mecanismo de registro para las transacciones *T* y *U* del servicio bancario en la Figura 12.7. El registro histórico se reorganizó recientemente, y las entradas a la izquierda de la línea doble representan una instantánea de los valores de *A*, *B* y *C* antes de que



cadores y las posiciones en el archivo de recuperación de los valores de todos los objetos que se vieron afectados por la transacción.

Si el servidor falla en el punto al que se llegó en la Figura 13.19, su gestor de recuperación recuperará los objetos como sigue. Comienza en la última entrada del estado de transacción en el registro (en P₇) y concluye que la transacción *U* no se había consumado y sus efectos han de ser olvidados. A continuación, se mueve a la entrada anterior de estado de transacción en el registro (en P₄) y concluye que la transacción *T* se había consumado. Para recuperar los objetos afectados por la transacción *T*, se mueve a la entrada previa de estado de transacción en el registro (en P₃) y encuentra la lista de intenciones para *T*(*A*, P₁), (*B*, P₂). Entonces restaura los objetos *A* y *B* a partir de los valores en P₁ y P₂. Ya que no ha restaurado *C*, se mueve hacia atrás hasta P₀, que es un punto de control, y restaura *C*.

Para facilitar la reorganización subsiguiente del archivo de recuperación, el gestor de recuperación anota todas las transacciones preparadas que encuentra durante el proceso de restauración de los objetos del servidor. Para cada transacción preparada, añade al archivo de recuperación un estado de transacción abortada. Esto asegura que en el archivo de recuperación toda transacción, al final, se muestra bien como consumada o bien como abortada.

El servidor podría fallar de nuevo durante los procedimientos de recuperación. Es esencial que la recuperación sea idempotente en el sentido de que pueda realizarse cualquier número de veces con el mismo efecto. Esto es inmediato bajo nuestra suposición de que todos los objetos se restauran sobre la memoria volátil. En el caso de una base de datos, que guarda sus objetos en un dispositivo de almacenamiento permanente, con una memoria caché en la memoria volátil, algunos de los objetos en el dispositivo de almacenamiento permanente estarán anticuados cuando sea reemplazado el servidor tras una caída. Por lo tanto, su gestor de recuperación ha de restaurar los objetos en el dispositivo de almacenamiento permanente. Si falla durante la recuperación, los objetos parcialmente restaurados estarán ya allí. Esto hace que sea un poco más difícil conseguir la idempotencia.

◊ **Reorganización del archivo de recuperación.** Un gestor de recuperación es responsable de reorganizar su archivo de recuperación para conseguir que el proceso de recuperación sea más rápido y para reducir el espacio usado. Si no se reorganiza alguna vez el archivo de recuperación, entonces el proceso de recuperación debe buscar hacia atrás a través del archivo de recuperación hasta que haya encontrado un valor para cada uno de sus objetos. Conceptualmente, la única información que se requiere para la recuperación es una copia de las versiones consumadas de todos los objetos en el servidor. Ésta sería la forma más compacta para el archivo de recuperación. El término *establecimiento de un punto de control* (*checkpointing*) se utiliza para referirse al proceso de escribir los valores consumados actuales de los objetos de un servidor a un nuevo archivo de recuperación, junto con las entradas de los estados de las transacciones y las listas de intenciones de las transacciones que no habían sido completamente resueltas (incluyendo la información relacionada con el protocolo de consumación en dos fases). El término *punto de control* se utiliza para referirse a la información guardada por los procesos de establecimiento de puntos de control. El propósito de crear puntos de control es reducir el número de transacciones con las que tratar durante la recuperación y para aprovechar el espacio del archivo.

El establecimiento de puntos de control puede hacerse inmediatamente tras una recuperación, pero antes han de comenzar todas las nuevas transacciones. Sin embargo, puede que no se dé con mucha frecuencia la recuperación. En consecuencia, puede que sea necesario establecer de puntos de control, de vez en cuando, durante la actividad normal de un servidor. El punto de control se escribe sobre un futuro archivo de recuperación, y el archivo de recuperación actual permanece en uso hasta que el punto de control esté completo. El establecimiento de puntos de control consiste en *añadir una marca* al archivo de recuperación cuando comienza dicho proceso, escribiendo los objetos del servidor en el futuro archivo de recuperación y, a continuación, copiando (1) las entra-

das anteriores a la marca que se relacionan con transacciones no resueltas todavía, y (2) todas las entradas tras la marca en el archivo de recuperación hacia el futuro archivo de recuperación. Cuando un punto de control está completo, el futuro archivo de recuperación se convierte en el archivo de recuperación.

El sistema de recuperación puede reducir su utilización del espacio descartando el antiguo archivo de recuperación. Cuando el gestor de recuperación está llevando a cabo el proceso de recuperación, puede encontrarse un punto de control en el archivo de recuperación. Cuando ocurre esto, puede restaurar, de forma inmediata, todos los objetos destacados a partir de dicho punto de control.

13.6.2. VERSIONES SOMBRA

La técnica de *registro histórico* graba las entradas del estado de las transacciones, las listas de intenciones y todos los objetos en el mismo archivo: el registro histórico. La técnica de *versiones sombra* es una forma alternativa de organizar un archivo de recuperación. Utiliza un *mapa* para localizar versiones de los objetos del servidor en un archivo denominado *almacén de versiones*. El mapa asocia los identificadores de los objetos del servidor con las posiciones de sus versiones actuales en el almacén de versiones. Las versiones escritas por cada transacción son *sombra*s de las versiones previas consumadas. Las entradas del estado de las transacciones y las listas de intenciones se tratan de forma separada. Primero se van a describir las versiones sombra.

Cuando una transacción está preparada para consumarse, cualquiera de los objetos cambiados por la transacción se añade al almacén de versiones, dejando las correspondientes versiones consumadas sin cambios. Estas nuevas versiones, todavía tentativas, se denominan *versiones sombra*. Cuando una transacción se consuma, se hace un nuevo mapa mediante la copia del viejo mapa e introduciendo las posiciones de las versiones sombreadas. Para completar el proceso de consumo, el nuevo mapa reemplaza al viejo.

Para restaurar los objetos cuando se reemplaza un servidor tras una caída, su gestor de recuperación lee el mapa y utiliza la información en el mapa para localizar los objetos en el almacén de versiones.

Esta técnica se ilustra con el mismo ejemplo que involucra a las transacciones *T* y *U* en la Figura 13.20. La primera columna en la tabla muestra el mapa antes de las transacciones *T* y *U*, cuando los saldos de las cuentas *A*, *B* y *C* son 100\$, 200\$ y 300\$, respectivamente. La segunda columna muestra el mapa cuando se ha consumado la transacción *T*.

El almacén de versiones contiene un punto de control, seguido por las versiones, originadas por la transacción *T*, de *A* y de *B* en *P₁* y *P₂*. Además contiene las versiones sombreadas de *B* y de *C*, generadas por la transacción *U*, en *P₃* y *P₄*.

Mapa al inicio		Mapa cuando <i>T</i> se consuma	
<i>A</i> → <i>P₀</i>		<i>A</i> → <i>P₁</i>	
<i>B</i> → <i>P'₀</i>		<i>B</i> → <i>P₂</i>	
<i>C</i> → <i>P''₀</i>		<i>C</i> → <i>P''₀</i>	
<i>P₀</i>	<i>P'₀</i>	<i>P''₀</i>	<i>P₁</i>
100	200	300	80
<i>Punto de control</i>		<i>P₂</i>	220
Almacén de versiones		<i>P₃</i>	278
		<i>P₄</i>	242

Figura 13.20. Versiones sombra.

El mapa debe escribirse siempre en un lugar bien conocido (por ejemplo, al comienzo del almacén de versiones o en un archivo separado) de tal forma que pueda ser encontrado cuando el sistema necesita ser recuperado.

El cambio del viejo mapa al nuevo debe realizarse en un único paso atómico. Para conseguir esto, es esencial que se utilice para el mapa un dispositivo de almacenamiento estable, de tal forma que se garantice que sea un mapa válido incluso cuando falla una operación de escritura en archivo. El método de versiones sombra proporciona una recuperación más rápida que la del registro histórico porque las posiciones de los objetos consumados actuales se graban en el mapa, mientras que la recuperación desde un registro requiere la búsqueda a través de los objetos del registro. La técnica de registro debería ser más rápida que las versiones sombreadas durante la actividad normal del sistema. Esto se debe a que el registro requiere solamente una secuencia de operaciones añadir sobre el mismo archivo, mientras que las versiones sombra requieren una escritura sobre un dispositivo de almacenamiento estable adicional (involucrando dos bloques no relacionados del disco).

Las versiones sombra no son suficientes, por sí mismas, para un servidor que maneje transacciones distribuidas. Las entradas del estado de las transacciones y las listas de intenciones se graban en un archivo que se denomina archivo del estado de la transacción. Cada lista de intenciones representa la parte del mapa que será alterado por una transacción cuando se complete. El archivo del estado de la transacción puede, por ejemplo, organizarse como un registro histórico.

La siguiente figura muestra el mapa y el archivo del estado de la transacción para nuestro ejemplo actual, cuando *T* se ha consumado y *U* está preparada para consumirse.

Mapa	Almacenamiento estable	Archivo de estado de transacción
<i>A</i> → <i>P₁</i>	preparada	<i>T</i>
<i>B</i> → <i>P₂</i>	<i>A</i> → <i>P₁</i>	consumada
<i>C</i> → <i>P''₀</i>	<i>B</i> → <i>P₂</i>	<i>B</i> → <i>P₃</i>
		<i>C</i> → <i>P₄</i>

Existe una posibilidad de que un servidor pueda caerse entre el momento en el que se escriba el estado consumada hacia el archivo del estado de la transacción y el momento en el que se actualiza el mapa, en cuyo caso no se habrá enviado un acuse de recibo al cliente. El gestor de recuperación debe permitir esta posibilidad cuando el servidor es reemplazado tras una caída, por ejemplo comprobando si el mapa incluye los efectos de la última transacción consumada en el archivo del estado de las transacciones. Si no, entonces la última debería marcarse como abortada.

13.6.3. LA NECESIDAD DE ENTRADAS DEL ESTADO DE LA TRANSACCIÓN Y LISTA DE INTENCIÓNES EN UN ARCHIVO DE RECUPERACIÓN

Es posible diseñar un archivo de recuperación simple que no incluya entradas para elementos del estado de la transacción ni listas de intenciones. Esta clase de archivo de recuperación puede ser adecuada cuando todas las transacciones se dirigen a un único servidor. El uso de los elementos de estado de la transacción y de las listas de intenciones en el archivo de recuperación es esencial para un servidor pensado para participar en transacciones distribuidas. Esta aproximación también puede ser útil para servidores de transacciones no distribuidas por varias razones, incluyendo las siguientes:

- Algunos gestores de recuperación están diseñados para una pronta escritura de los objetos en el archivo de recuperación, bajo la suposición de que las transacciones normalmente se consuman.

Trans: T	Coord: T	•	Trans: T	Trans: U	•	Particip: U	Trans: U	Trans: U
Preparada	Lista de participantes: ...	•	Consumada	Preparada	•	Particip: U	Trans: U	Trans: U
Listas de intenciones				Listas de intenciones		Coord: ...	Incierta	Consumada

Figura 13.21. Registro con las entradas relacionadas con el protocolo de consumación en dos fases.

de recuperación (ésta no necesita ser forzada). La entrada del estado *hecha* no es parte del protocolo, pero se utiliza cuando se reorganiza el archivo de recuperación. La Figura 13.21 muestra las entradas en un registro histórico para la transacción *T* en la cual el servidor jugó el papel de coordinador, y para la transacción *U*, en la que el servidor jugó el papel de participante.

Para ambas transacciones, llega primero la entrada del estado *preparada* de la transacción. En el caso de un coordinador, es seguida por una entrada coordinador, y por una entrada del estado *consumada* de la transacción. La entrada del estado *hecha* de la transacción no se muestra en la Figura 13.21. En el caso de un participante, la entrada del estado *preparada* de la transacción es seguida por una entrada participante cuyo estado es *incierta* y, después, una entrada del estado de la transacción: *consumada* o *abortada*.

Cuando se reemplaza un servidor tras una caída, el gestor de recuperación tiene que tratar con el protocolo de consumación en dos fases además de restaurar los objetos. Para cualquier transacción donde el servidor haya jugado el papel de coordinador, debería encontrar una entrada coordinador y un conjunto de entradas del estado de la transacción. Para cualquier transacción donde el servidor haya jugado el papel de participante, debería encontrar una entrada participante y un conjunto de entradas del estado de la transacción. En ambos casos, la entrada del estado de la transacción más reciente, esto es, aquella más cercana al final del registro, determina el estado de la transacción en el momento del fallo. La acción del gestor de recuperación con respecto al protocolo de consumación en dos fases para cualquier transacción depende de si el servidor fue el coordinador o un participante y de su estado en el momento del fallo, como se muestra en la Figura 13.22.

◊ **Reorganización de un archivo de recuperación.** Hay que tener cuidado cuando se está creando un punto de control para asegurarse de que no se eliminan del archivo de recuperación las entradas del *coordinador* asociadas a transacciones sin el estado *hecha*. Estas entradas han de retenerse hasta que todos los participantes hayan confirmado que han completado sus transacciones. Las entradas con estado *hecha* pueden descartarse. También deben retenerse las entradas de participante con estado de la transacción *incierta*.

◊ **Recuperación de transacciones anidadas.** En el caso más simple, cada subtransacción de una transacción anidada accede a un conjunto de objetos distintos diferente. Según se prepara cada participante para consumar durante el protocolo de consumación en dos fases, escribe sus objetos y listas de intenciones en el archivo de recuperación local, asociándole el identificador de transacción de la transacción del nivel superior. Aunque las transacciones anidadas utilizan una variante especial del protocolo de consumación en dos fases, el gestor de recuperación utiliza los mismos valores de estado de la transacción que para las transacciones planas.

Sin embargo, la recuperación de transacciones abortadas es compleja debido a que distintas subtransacciones, al mismo y a diferentes niveles en la jerarquía de anidamiento, pueden acceder al mismo objeto. La Sección 12.4 describe un esquema de bloqueo en el que las transacciones madre heredan bloqueos y las subtransacciones adquieren los bloqueos de sus madres. El esquema de bloqueos fuerza a las transacciones madre y a las subtransacciones a acceder a los datos de objetos

Papel	Estado	Acción del gestor de recuperación
Coordinador	Preparada	No se había alcanzado una decisión cuando cayó el coordinador. Envía <i>abortaTransacción</i> a todos los servidores en la lista de participantes y reabre la transacción.
Participante	Consumada	La transacción.
Participante	Consumada	Se había alcanzado una decisión de consumar antes de que el servidor fallase. Envía un mensaje <i>Consumar</i> a todos los participantes en su lista de participantes (en caso de que no lo haya hecho antes) y continúa el protocolo en dos fases en el paso 4 (véase Figura 13.5).
Participante	Incierta	El participante envía un mensaje <i>heConsumado</i> al coordinador (en caso de que no lo hubiese hecho antes que fallase). Esto permitirá al coordinador descartar información acerca de esta transacción en el siguiente punto de control.
Participante	Preparada	El participante falló antes de saber el resultado de la transacción. No puede determinar el estado de la transacción hasta que el coordinador le informe de la decisión. Enviará un mensaje <i>dameDecisión</i> al coordinador para determinar el estado de la transacción. Cuando reciba la respuesta, y en función de ella, consumará o abortará.
Coordinador	Hecha	El participante no había votado y puede abortar la transacción.

Figura 13.22. Recuperación del protocolo de consumación en dos fases.

comunes en distintos instantes de tiempo y aseguran que los accesos por parte de subtransacciones concurrentes sobre los mismos objetos deben estar secuenciados.

Los objetos a los que se accede según las reglas de transacciones anidadas se hacen recuperables proporcionando versiones tentativas para cada subtransacción. La relación entre las versiones tentativas de un objeto utilizado por las subtransacciones de una transacción anidada es similar a la

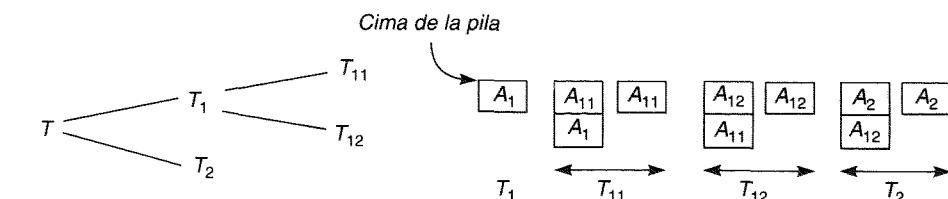


Figura 13.23. Transacciones anidadas.

consumada de A y se pone en la pila. Cuando T_{11} comienza a ejecutarse, basa su versión A_{11} en A_1 y la pone en la pila; cuando se complete, reemplaza la versión de su madre en la pila. Las transacciones T_{12} y T_2 actúan de una forma similar, dejando finalmente el resultado de T_2 en lo alto de la pila.

13.7. RESUMEN

En el caso más general, la transacción de un cliente solicitará operaciones sobre objetos en varios servidores distintos. Una transacción distribuida es aquella cuya actividad involucra a varios servidores distintos. Puede usarse una transacción con una estructura anidada para facilitar una concurrencia adicional y una consumación independiente por parte de los servidores dentro de una transacción distribuida.

La propiedad de atomicidad de las transacciones requiere que todos los servidores que participen en una transacción distribuida se consumen o abren. Para lograr este efecto, incluso cuando los servidores se caen durante la ejecución, se diseñan protocolos de consumaciónatómica. El protocolo de consumación en dos fases permite que un servidor aborde de forma unilateral. Incluye acciones asociadas a tiempos límite para tratar con los retrasos ocasionados por la caída de servidores. El protocolo de consumación en dos fases puede emplear una cantidad de tiempo no delimitado para su finalización, pero se garantiza que, al final, se completará.

El control de concurrencia en las transacciones distribuidas es modular, cada servidor es responsable de la secuenciaabilidad de las transacciones que acceden a sus propios objetos. Sin embargo, se necesitan protocolos adicionales para garantizar que las transacciones sean globalmente secuenciables. Las transacciones distribuidas que utilizan ordenación por marcas temporales necesitan alguna forma de generar una ordenación de marcas temporales acordada entre múltiples servidores. Aquellas que utilizan control de concurrencia optimista necesitan una validación global o algún medio de forzar un ordenamiento global sobre la consumación de las transacciones.

Las transacciones distribuidas que utilizan un bloqueo en dos fases pueden padecer interbloqueos distribuidos. El objetivo de la detección de interbloqueos distribuidos es buscar ciclos en un grafo *espera por* global. Si se encuentra un ciclo, han de abortarse una o más transacciones para solucionar el interbloqueo. Una aproximación descentralizada para la detección de interbloqueos distribuidos es la captura de arcos.

Las aplicaciones basadas en transacciones tienen requisitos fuertes en lo que respecta a la persistencia y a la integridad de la información almacenada, aunque no suelen tener requisitos de respuesta inmediata en todo momento. Los protocolos de consumaciónatómica son la clave para las transacciones distribuidas, pero no se puede garantizar que se completen dentro de un tiempo límite concreto. Mediante los puntos de control y al registro en históricos se consigue que las transacciones sean perdurables, lo cual se utiliza para recuperarse al sustituir un servidor tras una caída. Los usuarios de un servicio de transacciones experimentarán algunas demoras durante la recuperación.

ción. Aunque se asume que los servidores de transacciones distribuidas pueden fallar por caídas y

[REDACTED]

[REDACTED]

[REDACTED]

ción. Aunque se asume que los servidores de transacciones distribuidas pueden fallar por caídas y

[REDACTED]

[REDACTED]

quirir toda la información relevante a partir de dispositivos de almacenamiento permanente o bien de otros servidores.

EJERCICIOS

- 13.6. Extienda la definición del bloqueo en dos fases para aplicarla a las transacciones distribuidas. Explique cómo aseguran esto las transacciones distribuidas al emplear localmente el bloqueo en dos fases estricto.

- 13.7. Asumiendo que se usa un bloqueo en dos fases estricto, describa cómo se relacionan las acciones del protocolo de consumación en dos fases con las acciones del control de concurrencia de cada servidor individual. ¿Cómo encaja ahí la detección de interbloqueo distribuido?

- 13.8. Un servidor utiliza ordenación de marcas temporales para el control de concurrencia local. ¿Qué cambios deben hacerse para adaptarla y usarla en transacciones distribuidas? ¿Bajo qué condiciones podría argumentarse que el protocolo de consumación en dos fases es redundante con la ordenación de marcas temporales?

- 13.9. Considérese un control de concurrencia distribuida optimista en el cual cada servidor realiza validación local hacia atrás secuencialmente (esto es, sólo con una transacción en las fases de validar y actualizar de cada vez), en relación con la respuesta al Ejercicio 13.4. Describa los posibles resultados cuando las dos transacciones intentan consumirse. ¿Qué diferencia hay cuando los servidores utilizan validación en paralelo?

- 13.10. Un detector de interbloqueo global centralizado aloja la unión de los grafos *espera por* locales. Dé un ejemplo para explicar cómo podría detectarse un interbloqueo fantasma si una transacción que está esperando en un ciclo de interbloqueo aborta durante el procedimiento de detección del interbloqueo.

- 13.11. Considere el algoritmo de captura de arcos (sin prioridades). Dé ejemplos que muestren que podría detectar interbloqueos fantasma.

- 13.12. Un servidor gestiona los objetos a_1, a_2, \dots, a_n . Proporciona dos operaciones a sus clientes:

$Lee(i)$ devuelve el valor de a_i
 $Escribe(i, Valor)$ asigna $Valor$ a a_i

Las transacciones T , U y V se definen como sigue:

T : $x = Lee(i); Escribe(j, 44);$
 U : $Escribe(i, 55); Escribe(j, 66);$
 V : $Escribe(k, 77); Escribe(k, 88);$

Describa la información que se escribe en el archivo de registro histórico en función de estas tres transacciones si se está usando un bloqueo en dos fases estricto, y U adquiere a_i y a_j antes de comenzar T . Describa cómo utilizaría esta información el gestor de recuperación para recuperar los efectos de T , U y V cuando se reemplaza el servidor tras una caída. ¿Cuál es el significado del orden de las entradas de consumación en el archivo de registros histórico?

- 13.13. El añadir una entrada al archivo de registro es una operación atómica, pero pueden intercalarse operaciones de adición por parte de transacciones diferentes. ¿Cómo afecta esto a la respuesta del Ejercicio 13.12?

- 13.14. Las transacciones T , U y V del Ejercicio 13.12 utilizan bloqueo en dos fases estricto y sus peticiones se intercalan como sigue:

<i>T</i>	<i>U</i>	<i>V</i>
$x = Lee(i);$		<i>Escribe(k, 77);</i>
	<i>Escribe(i, 55);</i>	
<i>Escribe(j, 44)</i>		<i>Escribe(k, 88)</i>
	<i>Escribe(j, 66)</i>	

Asumiendo que el gestor de recuperación añade inmediatamente al archivo de registro la entrada de datos correspondientes a cada operación *Escribe* en lugar de esperar hasta el final de la transacción, describese la información escrita al archivo de registro histórico en función de las transacciones *T*, *U* y *V*. ¿Afecta una escritura temprana a la corrección del procedimiento de recuperación? ¿Cuáles son las ventajas y desventajas de la escritura temprana?

- 13.15. Las transacciones *T* y *U* se ejecutan con control de concurrencia por ordenamiento de marcas temporales. Describa la información que se escribe en el archivo de registro histórico en función de *T* y *U*, teniendo en cuenta el hecho de que *U* tiene una marca temporal posterior a la de *T* y debe esperar por *T* para consumarse. ¿Por qué es esencial que las entradas de consumación en el archivo de registro estén ordenadas por las marcas temporales? Describa el efecto de la recuperación si el servidor se cae (i) entre las dos *Consuma* y (ii) tras ambas.

<i>T</i>	<i>U</i>
$x = Lee(i);$	
	<i>Escribe(i, 55);</i>
<i>Escribe(j, 44);</i>	<i>Escribe(j, 66);</i>
	<i>Consuma</i>
<i>Consuma</i>	

Cuáles son las ventajas y desventajas de la escritura temprana con ordenación por marcas temporales.

- 13.16. Las transacciones *T* y *U* del Ejercicio 13.15 se ejecutan con control de concurrencia optimista utilizando validación hacia atrás y reiniciando las transacciones que fallan. Describa la información escrita en el archivo de registro histórico en su nombre. ¿Por qué es esencial que las entradas de consumación en el archivo de registro histórico estén ordenadas por los números de transacción? ¿Cómo son los conjuntos de escritura de las transacciones consumadas que se representan en el archivo de registro?
- 13.17. Suponga que el coordinador de una transacción cae tras haber registrado la entrada de la lista de intenciones, pero antes de que haya grabado la lista de participantes o haya enviado las peticiones de *puedeConsumar*? Describa cómo resuelven esta situación los participantes. ¿Qué hará el coordinador cuando se recupere? ¿Hubiese sido mejor registrar la entrada de la lista de participantes antes que la de la lista de intenciones?

- ## REPASO
-
- 14.1. Introducción
 - 14.2. Modelo de sistema y comunicación en grupo
 - 14.3. Servicios tolerantes a fallos
 - 14.4. Servicios con alta disponibilidad
 - 14.5. Transacciones con datos replicados
 - 14.6. Resumen

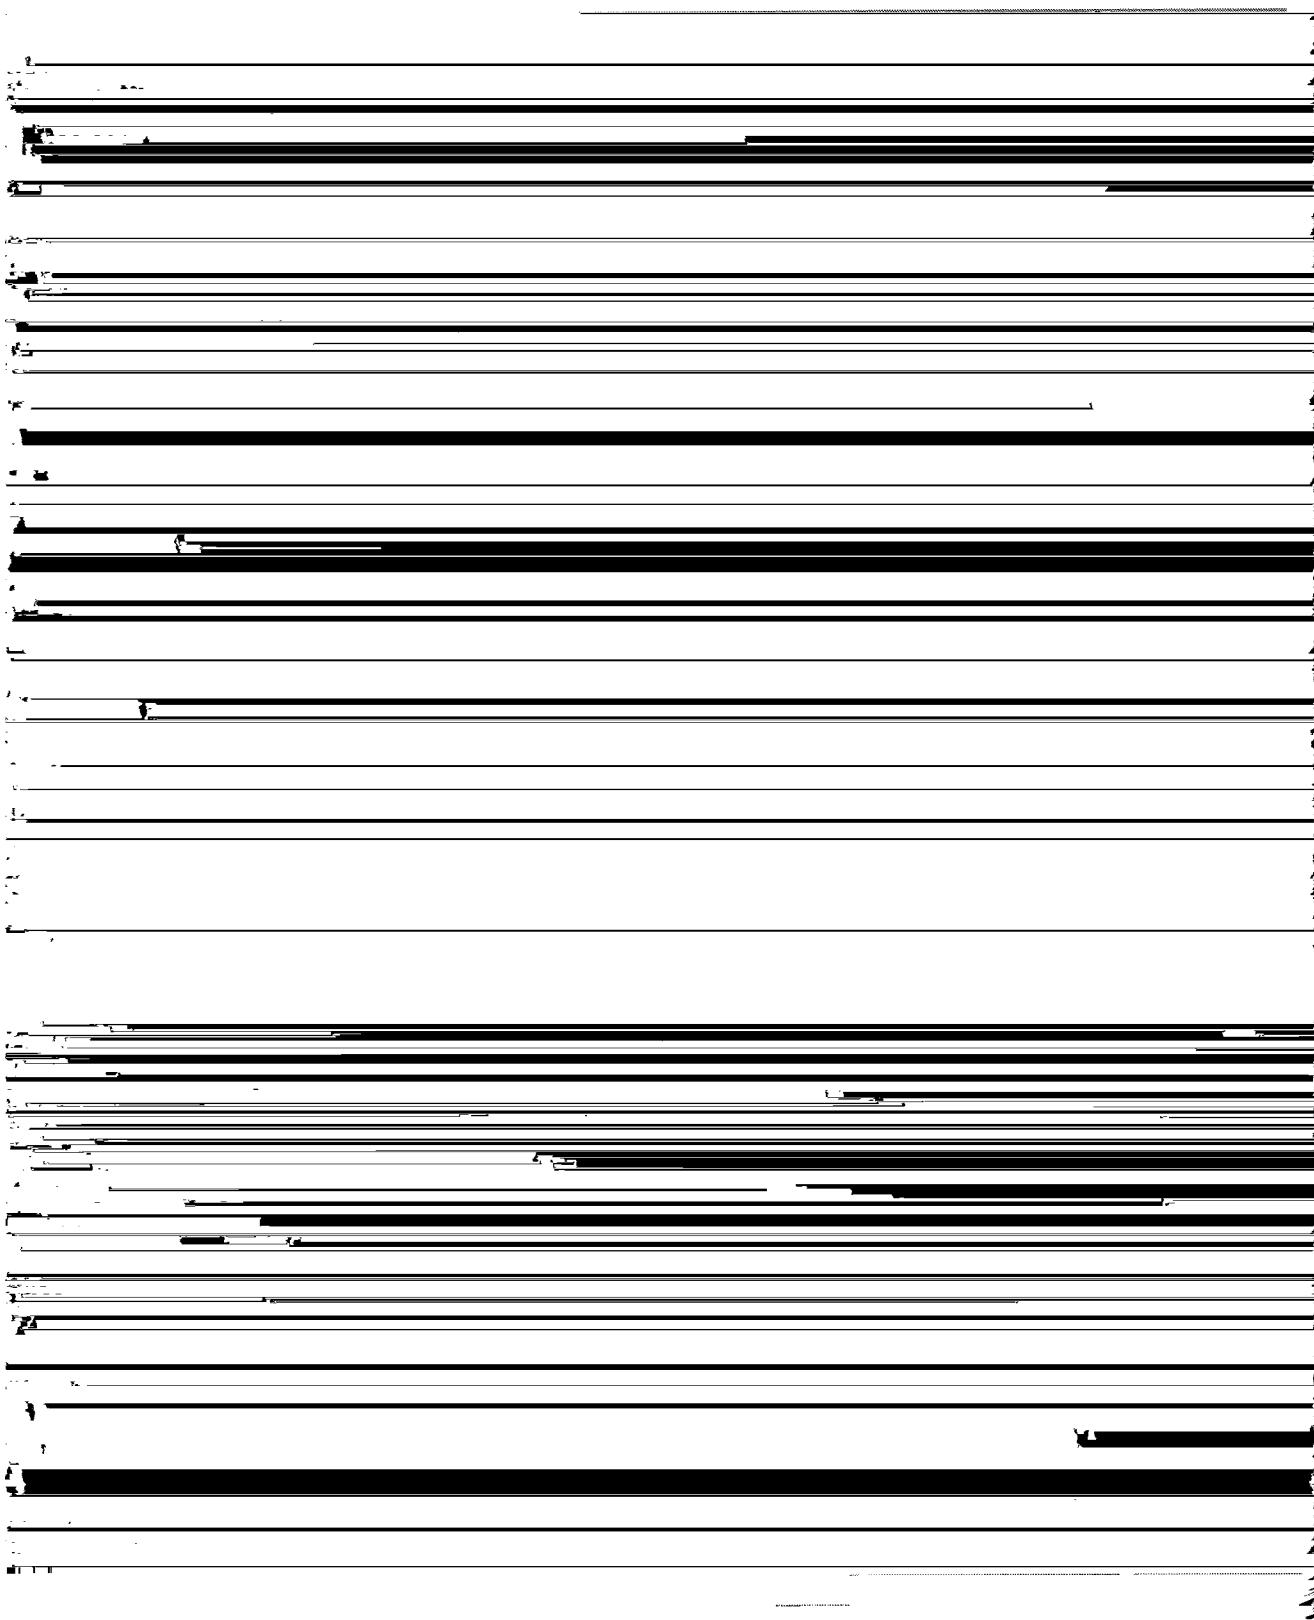
La replicación es la clave para proporcionar alta disponibilidad y tolerancia a fallos en sistemas distribuidos. Cada vez hay más interés en la alta disponibilidad dada la tendencia hacia la computación móvil y, por consiguiente, hacia las operaciones sin conexión. La tolerancia a fallos es una preocupación constante en los servicios que se prestan en sistemas donde la seguridad es crítica y en otros tipos de sistemas importantes.

La primera parte del capítulo trata aquellos sistemas que solicitan una operación individual cada vez sobre colecciones de objetos replicados. El capítulo comienza con una descripción de los componentes de la arquitectura y un modelo de sistema para aquellos servicios que empleen replicación. Describiremos la integración de la gestión de pertenencia a grupos como parte de la comunicación en grupo, que es especialmente importante para los servicios tolerantes a fallos.

A continuación, el capítulo describe las aproximaciones para conseguir la tolerancia a fallos. Se presentan los criterios de corrección: capacidad de secuenciación y la consistencia secuencial. Posteriormente se presentan y discuten dos aproximaciones: la replicación pasiva (primario-respaldo), en la cual los clientes se comunican con una réplica distinguida, y la replicación activa, en la cual los clientes se comunican mediante multidifusión con todas las réplicas.

Se considerarán tres sistemas para proporcionar servicios con alta disponibilidad. En las arquitecturas de cotilleo y Bayou, las actualizaciones se propagan de forma diferida entre las réplicas de los datos compartidos. En Bayou, se emplea la técnica de transformación operacional para hacer cumplir la consistencia. Coda es un ejemplo de un servicio de archivos con alta disponibilidad.

El capítulo finaliza considerando las transacciones (secuencias de operaciones) sobre objetos replicados. Trata las arquitecturas de sistemas transaccionales replicados y cómo estos sistemas gestionan los fallos en los servidores y las particiones en la red.



dad es $1 - 0,05^2 = 1 - 0,0025 = 99,75\%$. Una diferencia importante entre los sistemas de caché y la replicación de servidores es que las memorias caché no mantienen necesariamente en su totalidad colecciones de objetos, como pueden ser los archivos. Por lo tanto, las memorias caché no incrementan necesariamente la disponibilidad a nivel de aplicación (un usuario podría obtener un archivo que ya se ha usado pero no otro).

Las particiones de la red (véase la Sección 11.1) y las operaciones sin conexión son el segundo factor en contra de la alta disponibilidad. Los usuarios móviles desconectan sus computadores deliberadamente o pueden intencionadamente encontrarse sin conexión de una red inalámbrica mientras se mueven. Por ejemplo, un usuario en un tren con un portátil podría no tener acceso a la red (la conexión a la red inalámbrica podría estar interrumpida o podría no disponerse de tal posibilidad). Para poder trabajar en estas circunstancias (llamado *trabajo sin conexión u operación sin conexión*), el usuario se suele preparar copiando los datos frecuentemente usados, tales como los contenidos de una agenda compartida, desde su entorno habitual al portátil. Pero a menudo debe pagarse un precio por la disponibilidad durante el período de desconexión; cuando el usuario consulta o actualiza la agenda, se arriesga a leer datos que, entre tanto, otro puede haber alterado. Por ejemplo, pueden concertar una cita en un hueco que ya ha sido ocupado. El funcionamiento sin conexión sólo es factible si el usuario (o la aplicación, en su nombre) puede arreglárselas con datos anticuados y resolver más tarde cualquier conflicto que surja.

Tolerancia a fallos: datos con alta disponibilidad no equivale necesariamente a datos estrictamente correctos. Pueden no estar actualizados, por ejemplo; o dos usuarios en lados opuestos de una partición de la red podrían hacer actualizaciones que entraran en conflicto y que necesitasen ser resueltas. Por el contrario, un servicio tolerante a fallos siempre garantiza un comportamiento estrictamente correcto a pesar de un cierto número y un cierto tipo de fallos. La corrección alude a la frescura de los datos proporcionados al cliente y los efectos de las operaciones del cliente sobre los datos. Algunas veces, la corrección también se refiere a la oportunidad de las respuestas del servicio, como por ejemplo en el caso de un sistema de control de tráfico aéreo, donde se necesitan datos correctos cada poco tiempo.

La misma técnica básica usada para conseguir alta disponibilidad (de replicación de los datos y funcionalidad entre los computadores) se aplica también para conseguir tolerancia a fallos. Si un máximo de f de $f + 1$ servidores se caen, entonces, en principio, al menos uno de ellos se mantiene para proporcionar el servicio. Y si un máximo de f servidores pueden exhibir fallos complejos, entonces, en principio, un grupo de $2f + 1$ servidores pueden proporcionar un servicio correcto, ya que los servidores correctos ganarían en la votación a los servidores fallidos (quienes podrían proporcionar valores espurios). Sin embargo, la tolerancia a fallos es más sutil de lo que esta simple descripción hace pensar. El sistema debe gestionar la coordinación de sus componentes de un modo preciso para mantener las garantías de corrección en presencia de fallos, lo cual puede suceder en cualquier momento.

Un requisito común cuando los datos están replicados es la *transparencia frente la replicación*. Esto quiere decir que los clientes normalmente no deberían advertir que existen múltiples copias físicas de los datos. Por lo que respecta a los clientes, los datos se organizan como objetos lógicos individuales (u objetos) e identifican sólo un ítem en cada caso cuando requieren que se realice una operación. Además, los clientes esperan que las operaciones sólo devuelvan un conjunto de valores. Esto ha de ser así a pesar de que las operaciones puedan efectuarse de común acuerdo sobre más de una copia física.

El otro requisito general para los datos replicados, y que puede ser más o menos restrictivo según las aplicaciones, es el de la consistencia. Ésta se refiere a si las operaciones efectuadas sobre una colección de objetos replicados producen resultados que cumplan las especificaciones de corrección para esos objetos.

Vimos en el ejemplo del dietario que durante las operaciones sin conexión se podría permitir que los datos fuesen inconsistentes, al menos temporalmente. Pero cuando los clientes se encuentran conectados, no suele ser aceptable para los diferentes clientes (que usan copias físicas diferentes de los datos) el obtener resultados inconsistentes cuando realizan peticiones que afectan a los mismos objetos lógicos. Esto es, no es aceptable que los resultados incumplan los criterios de corrección de la aplicación.

A continuación examinaremos con más detalle los aspectos del diseño que surgen cuando se replican datos para conseguir alta disponibilidad y servicios tolerantes a fallo. También se examinarán algunas soluciones estándar y técnicas para tratar estos aspectos. En primer lugar, las Secciones 14.2 y 14.4 cubrirán el caso en el que los clientes hacen invocaciones individuales sobre datos compartidos. La Sección 14.2 presentará una arquitectura general para la gestión de datos replicados y presentará, como una herramienta importante, la comunicación en grupo. La comunicación en grupo es particularmente útil para conseguir tolerancia a fallos, lo que constituirá la materia de la Sección 14.3. La Sección 14.4 describirá las técnicas para conseguir alta disponibilidad, incluyendo operaciones sin conexión. Se incluyen como casos de estudio la arquitectura de cotilleo, Bayou y el sistema de archivos Coda. La Sección 14.5 examinará cómo dar soporte a las transacciones sobre datos replicados. Como se explicó en los Capítulos 12 y 13, las transacciones son secuencias de operaciones, más que operaciones individuales.

14.2. MODELO DE SISTEMA Y COMUNICACIÓN EN GRUPO

Los datos en nuestro sistema consisten en una colección de elementos a los que llamará objetos. Un *objeto* podría ser un archivo o un objeto en Java. Pero cada objeto *lógico* se implementa mediante una colección de copias *físicas* llamadas *réplicas*. Las réplicas son objetos físicos, almacenados cada uno de ellos en un computador individual, con datos y comportamientos que están vinculados con un cierto grado de consistencia dentro del funcionamiento del sistema. Las *réplicas* de un cierto objeto no son necesariamente idénticas, al menos no en cada instante de tiempo particular. Algunas réplicas pueden haber recibido actualizaciones que otras no hayan recibido.

En esta sección, se proporciona un modelo general de sistema para gestionar réplicas y a continuación, se describen sistemas de comunicación en grupo, los cuales son particularmente útiles para conseguir tolerancia a fallos mediante la replicación.

14.2.1. MODELO DEL SISTEMA

Suponemos un sistema asíncrono en el cual los procesos pueden fallar sólo por caída. Nuestra suposición por defecto será que no pueden darse particiones en la red, pero algunas veces consideraremos qué ocurriría si las hubiese. Las particiones de la red hacen más difícil la construcción de detectores de fallo, que se usan para conseguir una multidifusión fiable y totalmente ordenada.

Para generalizar, se describen los componentes de la arquitectura según los papeles que desempeñan, sin que ello implique que tengan que ser necesariamente implementados por procesos distintos (o máquinas distintas). El modelo implica réplicas mantenidas por distintos *gestores de réplicas* (véase la Figura 14.1), que son componentes que almacenan las réplicas en un cierto computador y realizan directamente operaciones sobre ellas. Este modelo general puede aplicarse en un entorno cliente-servidor, en cuyo caso el gestor de réplicas es el servidor. Algunas veces, se les llamará simplemente servidores. Igualmente, puede referirse a una aplicación y, en ese caso, los procesos de la aplicación pueden actuar tanto como clientes como gestores de réplicas. Por ejemplo, el portátil de un usuario en un tren puede contener una aplicación que actúa como un gestor de réplicas para su agenda.

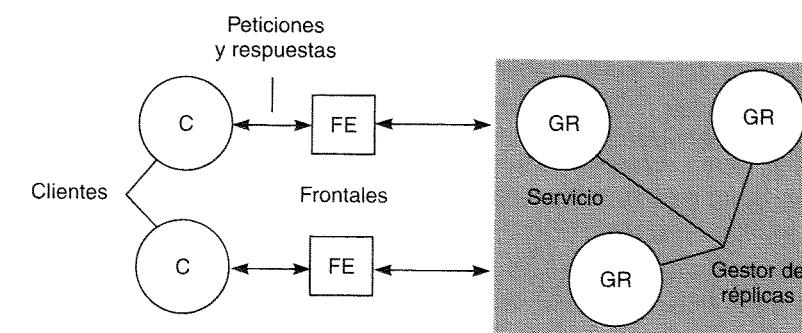


Figura 14.1. Un modelo básico de arquitectura para la gestión de datos replicados.

Siempre se exigirá que un gestor de réplicas solicite operaciones a sus réplicas con capacidad de recuperación. Esto permite suponer que una operación en un gestor de réplicas no deja resultados inconsistentes si falla durante el proceso. Algunas veces, también se exigirá a cada gestor de réplicas que sea una *máquina de estado* [Lamport 1978, Schneider 1990]. Dicho gestor de réplicas aplica operaciones atómicas (indivisibles) a sus réplicas, de tal forma que su ejecución es equivalente a realizar las operaciones siguiendo una secuencia estricta. Más aún, el estado de las réplicas es una función determinista de los estados iniciales y de la secuencia de operaciones que se les ha aplicado. Otros estímulos, como la lectura de un reloj o de un sensor adjunto, no tienen efecto sobre los valores del estado. Sin esta premisa no podrían darse las garantías de consistencia entre gestores de réplicas que acepten operaciones de actualización de forma independiente. El sistema únicamente puede determinar qué operaciones aplicar en todos los gestores de réplicas y en qué orden (no puede reproducir efectos no deterministas). La premisa implica que no sería posible, dependiendo de la arquitectura de hilos, que los servidores sean multi-hilo.

Con frecuencia un gestor de réplicas mantiene una réplica de todos los objetos y se supone que esto es así a no ser que se diga lo contrario. Aunque, en general, las réplicas de diferentes objetos pueden ser mantenidas por diferentes conjuntos de gestores de réplicas. Por ejemplo, un objeto podría ser requerido mayoritariamente por clientes de una red y otro objeto por clientes de otra red. Se gana bien poco replicándolos en los gestores en la otra red.

El conjunto de gestores de réplicas puede ser estático o dinámico. En un sistema dinámico pueden aparecer nuevos gestores de réplicas (por ejemplo, un/a segundo/a secretario/a copia una agenda en su portátil); esto no está permitido en un sistema estático. En un sistema dinámico los gestores de réplicas podrán caerse y entonces se considerará que han abandonado el sistema (aunque después sean reemplazados). En un sistema estático los gestores de réplicas no se caen (una caída implica no ejecutar *nunca* otra instrucción), sino que pueden cesar en su operación durante un período indefinido. Se volverá al tema de los fallos en la Sección 14.2.2.

El modelo general de gestión de réplicas se muestra en la Figura 14.1. Una colección de gestores de réplicas proporciona un servicio a los clientes. Los clientes perciben un servicio que les da acceso a los objetos (por ejemplo, agendas o cuentas bancarias) que, de hecho, están replicados en los gestores. Cada uno de los clientes solicita una serie de operaciones (invocaciones sobre uno o más de los objetos). Una operación implica una combinación de lecturas y actualizaciones de objetos. Las operaciones solicitadas que no incluyen actualizaciones se denominan *peticiones o solicitudes de «sólo lectura»*; las operaciones solicitadas que actualicen un objeto se denominan *peticiones de actualización* (éstas, a su vez, también pueden involucrar lecturas).

Las peticiones de cada cliente son atendidas, en primer lugar, por un componente llamado *frontal (front end)*. El papel del frontal es comunicar por paso de mensajes con uno o más de los gestores de réplicas en lugar de forzar al cliente a hacerlo de forma explícita por sí mismo. Es el

vehículo para hacer transparente la replicación. Un frontal podría estar implementado en el espacio de direcciones del cliente o pudiera ser un proceso separado.

En general, hay cinco fases implicadas en la realización de una petición individual sobre los objetos replicados [Wiesmann y otros 2000]. Las acciones en cada fase varían en función del tipo de sistema, como se aclarará en las dos siguientes secciones. Por ejemplo, un servicio que permita operaciones sin conexión se comportará de forma distinta de uno que proporcione un servicio tolerante a fallos. Las fases son las siguientes:

El frontal realiza la petición a uno o más de los gestores de réplicas. La primera posibilidad para un frontal es comunicarse con un gestor de réplicas individual que, a su vez, se comunica con otros gestores de réplicas. La segunda posibilidad es multidifundir la petición a los gestores de réplicas.

Coordinación: los gestores de réplicas se coordinan para ejecutar la petición de forma consistente. Se ponen de acuerdo, si es necesario en esa fase, en si la petición debe realizarse (podría no realizarse en absoluto si ocurriesen fallos en este punto). Además, deciden sobre la ordenación de esta petición en relación con otras. Todos los tipos de ordenación definidos para la multidifusión en la Sección 11.4.3 también se aplican al manejo de peticiones y definimos, de nuevo, aquellas ordenaciones en este contexto:

Ordenación FIFO: si un frontal solicita r y después solicita r' , entonces cualquier gestor de réplicas correcto que manipule r' debe haber manipulado antes r .

Ordenación causal: si la cuestión de la petición r ocurrió antes que la cuestión de la petición r' , entonces cualquier gestor de réplicas correcto que manipule r' debe haber manipulado antes r .

Ordenación total: si un gestor de réplicas correcto manipula la petición r antes que la petición r' , entonces cualquier gestor de réplicas correcto que manipule r' ha de haber manipulado antes r .

La mayor parte de las aplicaciones requieren ordenación FIFO. Los requisitos para la ordenación causal y la ordenación total se discuten en la siguiente sección (junto con las ordenaciones híbridas que son a la vez FIFO y total, o causal y total).

Ejecución: los gestores de réplicas ejecutan la petición, puede que de forma *tentativa*, esto es, de tal forma que pueden deshacer sus efectos posteriormente.

Acuerdo: los gestores de réplicas alcanzan un consenso, si lo hubiese, en cuanto al efecto de una petición antes de consumarla. Por ejemplo, en un sistema de transacciones los gestores de réplicas pueden acordar colectivamente abortar o consumir la transacción en este punto.

Respuesta: uno o más gestores de réplicas responden al frontal. En algunos sistemas, uno de los gestores de réplicas envía la respuesta. En otros, el frontal recibe respuestas de una colección de gestores de réplicas y selecciona o sintetiza una respuesta individual para devolvérsela al cliente. Por ejemplo, podría devolverle la primera respuesta que llegue, si el objetivo es tener una alta disponibilidad. Si el objetivo fuese la tolerancia a fallos complejos, entonces podría dar al cliente la respuesta que proporcione la mayoría de los gestores de réplicas.

Distintos sistemas pueden hacer diferentes selecciones respecto a la ordenación de las fases, así como de sus contenidos. Por ejemplo, en un sistema que soporte operaciones sin conexión, es importante dar al cliente (digamos, la aplicación del portátil del usuario) una respuesta tan pronto como sea posible. El usuario no quiere esperar hasta que el gestor de réplicas en su portátil se coordine más tarde con el gestor de réplicas en la oficina. Por el contrario, en un sistema tolerante a fallos, a un cliente no se le da respuesta hasta el final, cuando pueda garantizarse la corrección del resultado.

14.2.2. COMUNICACIÓN EN GRUPO

En la Sección 11.4 se discutió la comunicación por multidifusión, que también se conoce como comunicación en grupo porque son grupos de procesos los destinatarios de los mensajes de multidifusión. Los grupos son útiles tanto para gestionar datos replicados como para otros sistemas donde los procesos cooperen para lograr un objetivo común, recibiendo y procesando el mismo conjunto de mensajes de multidifusión. Son igualmente útiles donde los miembros del grupo consumen, de forma independiente, uno o más flujos de mensajes comunes, tales como mensajes con eventos frente a los que los procesos reaccionan de forma independiente.

La Sección 11.4 consideró que la pertenencia a los grupos estaba definida de manera estática, aunque los miembros del grupo pudieran malograrse. Sin embargo, en la práctica, los sistemas suelen requerir pertenencia dinámica: los procesos se unen y dejan el grupo según el sistema trabaja. Por ejemplo, en un servicio que maneja datos replicados, los usuarios pueden añadir o retirar un gestor de réplicas, o pudiera caerse un gestor de réplicas y, por lo tanto, necesitaría ser excluido de la operación del sistema. Una implementación completa de la comunicación en grupo incluye un *servicio de pertenencia al grupo* para gestionar la pertenencia dinámica de los grupos, además de la comunicación por multidifusión.

La gestión de la comunicación por multidifusión y la de pertenencia a grupos están fuertemente relacionadas. La Figura 14.2 muestra un sistema abierto, en el cual un proceso fuera del grupo manda al grupo un mensaje sin conocer los miembros del grupo. El servicio de comunicación en grupo ha de gestionar cambios en los miembros del grupo mientras tienen lugar multidifusiones de forma concurrente.

◊ **Papel del servicio de pertenencia a grupos.** Un servicio de pertenencia a grupos tiene cuatro tareas principales, que son las siguientes:

Proporcionar una interfaz para los cambios en la pertenencia a grupos: el servicio de pertenencia proporciona operaciones para crear y destruir grupos de procesos y para añadir o retirar un proceso de un grupo. En la mayoría de los sistemas, un proceso individual puede pertenecer a distintos grupos al mismo tiempo. Esto es así, por ejemplo, en la multidifusión IP.

Implementar un detector de fallos: el servicio incorpora un detector de fallos (véase la Sección 11.1). El servicio vigila a los miembros del grupo no sólo en el caso en el que puedan

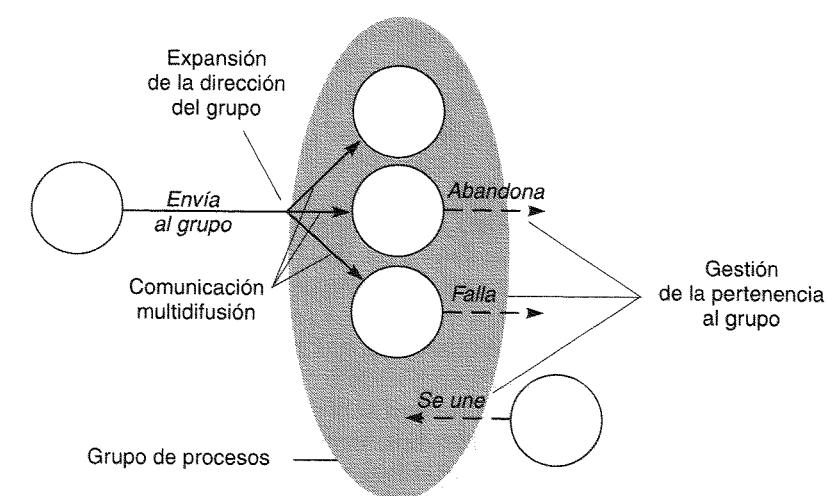


Figura 14.2. Servicios proporcionados por los grupos de procesos.

caerse sino también en el caso en el que puedan llegar a hacerse inaccesibles debido a un fallo en la comunicación. El detector marca a los procesos como *Sospechosos* o *No sospechosos*. El servicio utiliza al detector de fallos para tomar una decisión acerca de la pertenencia al grupo: excluye a un proceso si sospecha que ha fallado o se ha vuelto inaccesible.

Notificar a los miembros del grupo los cambios en la pertenencia: el servicio notifica a los miembros del grupo cuándo se añade o cuándo se excluye un proceso (debido a un fallo o cuando el proceso se retira deliberadamente del grupo).

Expandir las direcciones del grupo: cuando un proceso multidifunde un mensaje, proporciona el identificador del grupo en vez de una lista de los procesos del grupo. El servicio de gestión de pertenencia expande el identificador para obtener los miembros actuales del grupo y proceder al reparto. El servicio puede coordinar el reparto de multidifusión con cambios en los miembros mediante el control de la expansión de direcciones. Esto es, puede decidir de forma consistente dónde entregar cualquier mensaje dado, incluso aunque los miembros puedan cambiar durante la entrega. Más adelante se discutirá la comunicación *con vistas síncronas*.

Obsérvese que la multidifusión IP es un caso débil de servicio de pertenencia a un grupo, con algunas de sus propiedades pero no todas. Permite que los procesos se unan o dejen los grupos dinámicamente y realiza la expansión de direcciones, por lo que los remitentes sólo necesitan proporcionar una dirección de multidifusión IP individual como destino de un mensaje de multidifusión. Pero la multidifusión IP por sí misma no proporciona a los miembros del grupo información acerca de los miembros actuales y la entrega por multidifusión no está coordinada con los cambios de miembros.

Los sistemas que pueden adaptarse según se unan, se vayan y se rompan los procesos —en particular los sistemas tolerantes a fallos— requieren las funciones más avanzadas de detección de fallos y notificación de cambios en la pertenencia. Un servicio completo de pertenencia a grupo mantiene *vistas del grupo*, que son listas de los miembros actuales del grupo, identificados por su identificador único de proceso. La lista está ordenada, por ejemplo, de acuerdo a la secuencia en la cual los miembros se unieron al grupo. Cuando se añaden o excluyen procesos se genera una nueva vista del grupo.

Es importante comprender que un servicio de pertenencia al grupo puede excluir a un proceso de un grupo debido a que sea *Sospechoso*, incluso aunque no haya caído. Un fallo en la comunicación puede haber dejado al proceso inaccesible, aunque siguiera ejecutándose con normalidad. Un servicio de pertenencia es muy libre de excluir tales procesos. El efecto de la expulsión es que, de ahí en adelante, no se le entregarán más mensajes a este proceso. Aun más, en el caso de un grupo cerrado, si el proceso vuelve a conectarse, cualquier mensaje que intente enviar no será entregado al resto de miembros del grupo. Ese proceso ha de volver a reunirse al grupo (como una *reencarnación* de sí mismo, con un nuevo identificador) o abortar sus operaciones.

Una sospecha infundada sobre un proceso y la consecuente exclusión del mismo del grupo puede reducir la efectividad del grupo. El grupo tendrá que arreglárselas sin el rendimiento o la fiabilidad extra que potencialmente podría haber proporcionado el proceso abandonado. El reto de diseño, dejando a un lado el diseño de detectores de fallo que sean lo más precisos posible, es asegurar que un sistema basado en comunicación en grupos no se comporte *incorrectamente* si se sospecha erróneamente de un proceso.

Una consideración importante alude a cómo se ocupa el servicio de gestión de grupos de las particiones en la red. La desconexión o el fallo de componentes, tales como un encaminador en una red, puede dividir un grupo de procesos en dos o más subgrupos, de tal forma que la comunicación entre subgrupos sea imposible. Los servicios de gestión de grupos se diferencian en si son de *partición primaria* o *particionables*. En el primer caso, el servicio de gestión permite que sobreviva, a lo sumo, un subgrupo (una mayoría) de la partición; al resto de procesos se les informa que deben suspender las operaciones. Esta disposición es apropiada en casos donde los procesos gestio-

nan datos importantes y los costes de inconsistencias entre dos o más subgrupos exceden cualquier ventaja del trabajo sin conexión.

Por otro lado, en algunas circunstancias es aceptable para dos o más subgrupos continuar operando; esto se permite en un servicio de pertenencia a grupos particionable. Por ejemplo, en una aplicación en la cual los usuarios mantienen una audio o videoconferencia para discutir algunos asuntos, puede ser aceptable para dos o más subgrupos de usuarios continuar sus discusiones independientes a pesar de la partición. Los usuarios podrán combinar sus resultados cuando la partición se restablezca y los subgrupos se conecten de nuevo.

◊ **Entrega de vistas.** Considérese la tarea de un programador escribiendo una aplicación que funcione en cada proceso de un grupo que debe enfrentarse con miembros nuevos y perdidos. El programador necesita saber que el sistema trata a cada miembro de forma consistente cuando cambian los miembros. Sería inadecuado si el programador tuviese que pedir el estado de todos los otros miembros y tomar una decisión global cuando ocurriera un cambio en la pertenencia, en lugar de ser capaz de tomar una decisión local sobre cómo responder al cambio. La vida del programador será más o menos dura en función de las garantías que se apliquen cuando el sistema entregue vistas a los miembros del grupo.

Para cada grupo g el servicio de gestión de grupos entrega a cada proceso miembro $p \in g$ una sucesión de vistas $v_0(g)$, $v_1(g)$, $v_2(g)$, etc. Una sucesión de vistas podrían ser, por ejemplo, $v_0(g) = (p)$, $v_1(g) = (p, p')$ y $v_2(g) = (p)$, esto es, p se une a un grupo vacío, posteriormente se une p' al grupo y finalmente p' lo abandona. Aunque los cambios en la pertenencia pueden ocurrir de forma concurrente, como cuando un proceso se une a un grupo justo cuando otro se va, el sistema impone un orden en la sucesión de vistas que da a cada proceso.

Se hablará de un miembro *entregando una vista* cuando ocurra un cambio en la pertenencia y se notifique a la aplicación la nueva pertenencia, de la misma forma en que se habla de un proceso entregando un mensaje multidifundido. Y como ocurre en la entrega de multidifusión, la entrega de una vista es distinta a la recepción de una vista. Los protocolos de pertenencia a grupos mantienen las vistas propuestas en una cola de retención hasta que todos los miembros existentes se pongan de acuerdo en la entrega.

También, decimos que un evento ocurre *dentro de una vista* $v(g)$ en el proceso p si, en el momento en el que ocurra el evento, p ha entregado $v(g)$ pero todavía no ha entregado la próxima vista $v'(g)$.

Algunos requisitos básicos para la entrega de vistas son los siguientes:

Orden: si un proceso p entrega una vista $v(g)$ y posteriormente entrega la vista $v'(g)$, entonces ningún proceso $q \neq p$ entregará $v'(g)$ antes que $v(g)$.

Integridad: si un proceso p entrega la vista $v(g)$ entonces $p \in v(g)$.

No trivialidad: si un proceso q se une al grupo y está en contacto o puede ponerse en contacto, indefinidamente, con un proceso $p \neq q$, pasado un tiempo, q estará siempre en las vistas que entregue p . De forma similar, si el grupo se partitiona y permanece partitionado, entonces, al final, las vistas entregadas en cualquiera de las particiones excluirá cualquier proceso de otras particiones.

El primero de estos requisitos, de alguna forma, proporciona al programador una garantía de consistencia asegurando que los cambios en las vistas ocurren en el mismo orden en diferentes procesos. El segundo requisito es una *comprobación de consistencia*. El tercero le protege frente a soluciones triviales. Por ejemplo, un servicio de pertenencia que diga a un proceso, con independencia de su conectividad, que está en un grupo por sí mismo, no es de gran interés. La condición de no trivialidad establece que dos procesos que se hayan unido al mismo grupo podrán, al final, comunicarse indefinidamente; ambos serán considerados del mismo grupo. De forma similar, requiere que cuando se produzca una partición, el servicio de pertenencia debería reflejar finalmente la parti-

ción. La condición no establece cómo debería comportarse el servicio de pertenencia a grupos en el caso problemático de conectividad intermitente.

◊ **Comunicación en grupos con vistas síncronas.** Un sistema de comunicación en grupos con *vistas síncronas* genera garantías adicionales en lo que respecta al orden en las entregas de notificaciones de vistas con respecto al reparto de mensajes de multidifusión. La comunicación mediante vistas síncronas extiende la semántica de la multidifusión fiable, que fue descrita en el Capítulo 11, para considerar los cambios en las vistas del grupo. Con el fin de simplificar, nuestra discusión se restringirá al caso donde no puedan ocurrir particiones. Las garantías que proporciona la comunicación en grupo mediante vistas síncronas son las siguientes:

Acuerdo: los procesos correctos reparten el mismo conjunto de mensajes en cualquier vista. Dicho de otra forma, si un proceso entrega un mensaje m en una vista $v(g)$ y a continuación entrega la siguiente vista $v'(g)$, entonces todos los procesos que sobrevivan para entregar la siguiente vista $v'(g)$ (esto es, los miembros de $v(g) \cap v'(g)$) también entregan m en la vista $v(g)$.

Integridad: si un proceso p entrega un mensaje m , entonces no volverá a entregar m de nuevo. Además, $p \in \text{grupo}(m)$ y m fue proporcionado a una operación de multidifusión por el *emisor*(m) (ésta es la misma condición que en el caso de la multidifusión fiable).

Validez (grupos cerrados): los procesos correctos siempre entregan los mensajes que mandan. Si el sistema no es capaz de entregar un mensaje a cualquier proceso q , entonces se notifica a los procesos supervivientes mediante la entrega de una nueva vista en la que se excluye a q (inmediatamente después de la vista en la cual cualquiera de ellos entregó el mensaje). Esto es, sea p cualquier proceso correcto que entrega el mensaje m en una vista $v(g)$. Si algún proceso $q \in v(g)$ no entrega m en la vista $v(g)$, entonces la siguiente vista $v'(g)$ que entregue p tendrá que $q \notin v'(g)$.

Considérese un grupo con tres procesos p , q y r (véase la Figura 14.3). Supóngase que p envía un mensaje m mientras se está en la vista (p, q, r) pero p cae poco tiempo después de enviar m , mientras q y r siguen siendo correctos. Una posibilidad sería que p cayese antes de que m haya alcanzado cualquier otro proceso. En este caso, q y r entregan cada uno la nueva vista (q, r) , pero ninguno entregará nunca m (véase la Figura 14.3a). La otra posibilidad sería que m alcance al menos a uno de los dos procesos supervivientes al caer p . Entonces, tanto q como r entregan primero m y después la vista (q, r) (véase la Figura 14.3b). No se permite que q y r entreguen primero la vista (q, r) y después m (véase la Figura 14.3c), ya que en ese caso estarían entregando un mensaje de un proceso fallido del cual habían sido informados; tampoco pueden, ninguno de los dos, entregar el mensaje y la nueva vista en órdenes distintos (véase la Figura 14.3d).

En un sistema de vistas síncronas, la entrega de una nueva vista traza una línea conceptual a lo largo del sistema, y cualquier entrega ha de ser consistente a ambos lados de esa línea. Esto permite al programador obtener conclusiones útiles acerca del conjunto de mensajes que otros procesos hayan entregado cuando entregue una nueva vista, basadas solamente en el orden local de los eventos de entrega de mensajes y de entrega de vistas.

Un ejemplo ilustrativo de la utilidad de la comunicación mediante vistas síncronas lo constituye su uso para conseguir una *transferencia de estado*: la transferencia del estado de trabajo por parte de un miembro actual de un grupo de procesos a un nuevo miembro del grupo. Por ejemplo, si los procesos son gestores de réplicas que mantienen cada uno el estado de una agenda, entonces, cuando se une un nuevo gestor de réplicas al grupo para usar esa agenda necesitará adquirir el estado actual de la agenda. Pero la agenda podría estar siendo actualizada de concurrente mientras se está capturando el estado. Es importante que el gestor de réplicas no pierda ninguno de los mensajes de actualización que no están reflejados en el estado que está adquiriendo y que no vuelva a actualizar mensajes que ya estén reflejados en el estado (a no ser que las actualizaciones sean idempotentes).

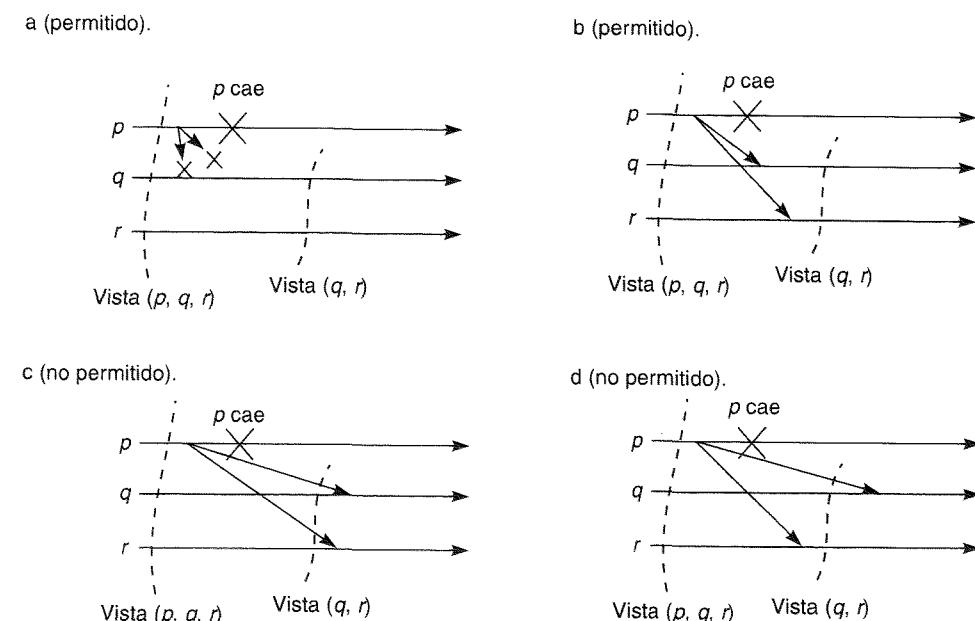


Figura 14.3. Comunicación en grupo con vista síncrona.

Para conseguir esta transferencia de estados se puede usar comunicación mediante vistas síncronas en un esquema simple como el siguiente. Al repartir la primera vista que contiene al nuevo proceso, algún proceso miembro de los ya existentes (por ejemplo el más antiguo) capta su estado, lo envía individualmente al nuevo miembro y suspende su ejecución. El resto de procesos que ya existían suspenden sus ejecuciones. Nótese que precisamente el conjunto de actualizaciones reflejadas en este estado, por definición, ha sido aplicado al resto de los miembros. Una vez recibido el estado, el nuevo proceso lo integra y multidifunde al grupo un mensaje «¡comenzad!» y, en ese momento, todos prosiguen nuevamente.

◊ **Discusión.** La noción de comunicación en grupo mediante vistas síncronas que se ha presentado es una formulación del paradigma de comunicación *virtualmente síncrona* desarrollado originalmente en el sistema ISIS [Birman 1993, Birman y otros 1991, Birman y Joseph 1987b]. En Schiper y Sandoz [1993] se describe un protocolo para conseguir la comunicación mediante vistas síncronas (o *vistas atómicas*, como ellos las denominan). Nótese que un servicio de pertenencia a grupos alcanza un consenso, pero lo hace sin despreciar el resultado de imposibilidad de Fisher y otros [1985]. Como se discutió en la Sección 11.5.4, un sistema puede burlar ese resultado usando un detector de fallos apropiado.

Schiper y Sandoz también proporcionan una versión uniforme de la comunicación mediante vistas síncronas en la cual la condición de acuerdo contempla el caso de procesos que caen. Éste es similar al acuerdo uniforme para la comunicación por multidifusión, que se describió en la Sección 11.4.2. En la versión uniforme de comunicación mediante vistas síncronas, incluso si un proceso se cae tras entregar un mensaje, todos los procesos correctos son obligados a entregar el mensaje en la misma vista. Esta garantía más fuerte se necesita, algunas veces, en aplicaciones tolerantes a fallo, ya que un proceso que ha entregado un mensaje puede haber tenido un efecto en el mundo exterior antes de caer. Por la misma razón, Hadzilacos y Toueg [1994] tratan las versiones uniformes de los protocolos de multidifusión fiables y ordenados que se describieron en el Capítulo 11.

El sistema V [Cheriton y Zwaenepoel 1985] fue el primer sistema en dar soporte a grupos de

El sistema V [Cheriton y Zwaenepoel 1985] fue el primer sistema en dar soporte a grupos de

y otros 1996] y Transis [Dolev y Malki 1996].

Se han propuesto variaciones en la sincronía de las vistas para servicios de pertenencia a grupos particionables, incluyendo apoyo para aplicaciones atentas a particiones [Babaoglu y otros 1998] y para sincronía virtual extendida [Moser y otros 1994].

cuentas en sus gestores de réplicas locales, pero, si éstos fallan, utilizan otros. Los gestores de réplicas propagan las actualizaciones entre ellos en segundo plano tras responder al cliente. Inicialmente, ambas cuentas tienen un balance de 0 dólares.

El cliente 1 actualiza a 1 dólar el balance de x en su gestor de réplicas local B y, a continuación, intenta actualizar el balance de y para que sea de 2 dólares, pero descubre que B ha fallado. A consecuencia de esto, el cliente 1 realiza la actualización en A en vez de en B . En ese momento, el cliente 2 lee sus balances en su gestor de réplicas local A y se encuentra que y tiene 2 dólares y que x tiene 0 dólares (la actualización de la cuenta bancaria x por parte de B no ha llegado dado que B falló). La situación se muestra a continuación, etiquetándose las operaciones por parte del computador en el cual tuvieron lugar por primera vez y donde las operaciones que están más abajo sucedieron más tarde:

Cliente 1:	Cliente 2:
$ponBalance_B(x, 1)$	
$ponBalance_A(y, 2)$	
	$obténBalance_A(y) \rightarrow 2$
	$obténBalance_A(x) \rightarrow 0$

Esta ejecución no se ajusta a una especificación dictada por el sentido común para el comportamiento de cuentas bancarias: el cliente 2 debería haber obtenido un balance de 1 dólar para x , puesto que obtiene el balance de 2 dólares para y , y el balance de y se actualizó después del de x . Este comportamiento anómalo en el caso que utiliza la replicación no se habría dado si se hubiera implementado utilizando un único servidor. Se pueden construir sistemas que gestionen objetos replicados sin los comportamientos anómalos asociados al protocolo ingenuo del ejemplo anterior. Primero, debemos entender qué se considera comportamiento correcto para un sistema replicado.

◊ **Linealizabilidad y consistencia secuencial.** Hay varios criterios de corrección para objetos replicados. Los sistemas más estrictamente correctos son *linealizables* y a esta propiedad se denomina *linealizabilidad*. De cara a comprender la linealizabilidad considere una implementación de servicio replicado con dos clientes. Sea $o_{i0}, o_{i1}, o_{i2}, \dots$ una secuencia de operaciones de lectura y actualización que el cliente i realiza en cierta ejecución. Cada operación o_{ij} de estas secuencias se especifica mediante el tipo de operación, sus argumentos y los valores que devuelve según se producen en tiempo de ejecución. Se supone que cada operación es síncrona. Esto es, los clientes aguardan a que se complete una operación antes de solicitar la siguiente.

Un único servidor que gestionase una única copia de los objetos podría secuenciar las operaciones de los clientes. En el caso de una ejecución sólo con los clientes 1 y 2, este entrelazado de las operaciones podría ser, por ejemplo, $o_{20}, o_{21}, o_{10}, o_{22}, o_{11}, o_{12}, \dots$. Definimos nuestro criterio de corrección para objetos replicados haciendo referencia a un entrelazamiento *virtual* de las operaciones de los clientes, que no tiene necesariamente que ocurrir físicamente en un gestor de réplicas concreto, pero que establece la corrección de la ejecución.

Un servicio de objetos compartidos replicados se dice linealizable si *para cualquier ejecución* existe algún entrelazamiento de las series de operaciones emprendidas por cada cliente que satisface los dos siguientes criterios:

- La secuencia entrelazada de operaciones cumple la especificación de una (única) copia correcta de los objetos.
- El orden de las operaciones del entrelazamiento es consistente con los tiempos reales en los cuales ocurrieron las operaciones en la ejecución real.

Esta definición plasma la idea de que para cualquier conjunto de operaciones de los clientes existe una ejecución canónica virtual (las operaciones intercaladas a las que se refiere la definición) sobre

una única imagen virtual de los objetos compartidos. Y que cada cliente observa una vista de los objetos compartidos que es consistente con esa única imagen: esto es, los resultados de las operaciones del cliente tienen sentido según ocurran dentro del entrelazamiento.

El servicio que dio lugar a la ejecución de los clientes de las cuentas bancarias en el ejemplo anterior no es linealizable. Incluso si se ignoran los tiempos reales en los que ocurrieron las operaciones, no existe un entrelazamiento de las operaciones de los dos clientes que pudiera satisfacer cualquier especificación correcta de cuentas bancarias: con vistas a un examen, si la actualización de una cuenta sucedió tras otra, entonces habrá de observarse la primera actualización si es que se observa la segunda.

Observe que la linealizabilidad tiene que ver solamente con el entrelazamiento de operaciones individuales y que no está pensado que sea transaccional. Una ejecución linealizable podría romper las nociones de consistencia específicas de una aplicación si no se aplica un control de concurrencia.

El requisito de capacidad de secuenciación en tiempo real es deseable en un mundo ideal, dado que capta nuestra noción de que los clientes deberían recibir información actualizada. Sin embargo, la presencia del tiempo real en la definición plantea la cuestión de la practicabilidad de la linealizabilidad, ya que no siempre se pueden sincronizar los relojes con el grado de precisión requerido. Una condición de corrección más débil es la *consistencia secuencial*, que capta un requisito esencial con respecto al orden en el cual se procesan las peticiones, sin aludir al tiempo real. Su definición mantiene el primer criterio de la definición de capacidad de secuenciación, pero modifica el segundo de la siguiente manera:

Un servicio de objetos replicados compartidos se dice que es secuencialmente consistente si para cualquier ejecución existe algún entrelazamiento de las series de operaciones emprendidas por los clientes que satisface los dos siguientes criterios:

- La secuencia de operaciones intercaladas cumple la especificación de una (única) copia correcta de los objetos.
- El orden de las operaciones en el entrelazamiento es consistente con el orden en el programa con el cual cada cliente individual ejecutó dichas operaciones.

Ha de notarse que en esta definición no hay mención de tiempos absolutos. Ni tampoco a cualquier orden *total* sobre todas las operaciones. La única noción relevante de ordenación es el orden de los eventos en cada cliente por separado, esto es, el orden en su programa. El entrelazamiento de las operaciones puede barajar en cualquier orden la secuencia de operaciones que provienen de un conjunto de clientes, siempre y cuando el orden de cada cliente no se viole y el resultado de cada operación sea consistente con las operaciones que la han precedido, en términos de las especificaciones de los objetos. Esto sería parecido a mezclar varios mazos de cartas de modo que las cartas se entremezclan de forma tal que se mantuviese el orden inicial de cada baraja.

Cada servicio linealizable es, asimismo, secuencialmente consistente, ya que la ordenación por tiempo real refleja el orden dentro del programa de cada cliente. Lo contrario no se cumple. A continuación se muestra un ejemplo de ejecución para un servicio que es secuencialmente consistente pero no linealizable:

Cliente 1:	Cliente 2:
$ponBalance_B(x, 1)$	
	$obténBalance_A(y) \rightarrow 0$
	$obténBalance_A(x) \rightarrow 0$
	$ponBalance_A(y, 2)$

Esta ejecución es posible bajo una estrategia ingenua de replicación, incluso si ninguno de los computadores *A* o *B* falla menos si la actualización de *x* que hace el cliente 1 en *B* no haya alcan-

zado *A* cuando el cliente 2 lo lee. El criterio de tiempo real para la secuenciación no se satisface, ya que $dameBalance_A(x) \rightarrow 0$ sucede más tarde que $ponBalance_B(x, 1)$; sin embargo, el entrelazamiento siguiente satisface los dos criterios para la consistencia secuencial: $dameBalance_A(y) \rightarrow 0$, $dameBalance_A(x) \rightarrow 0$, $ponBalance_B(x, 1)$, $ponBalance_A(y, 1)$.

Lamport concibió ambos términos: consistencia secuencial [1979] y de capacidad de secuenciación [1986], en relación con los registros de memoria compartida (aunque él utilizó el término *atomicidad* en lugar de *linealizabilidad*). Herlihy y Wing [1990] generalizaron la idea para cubrir cualquier tipo de objetos compartidos. El Capítulo 16, que examina la memoria compartida distribuida, definirá y discutirá algunas propiedades de consistencia más débiles.

14.3.1. REPLICACIÓN PASIVA (PRIMARIO-RESPALDO)

En el modelo de replicación *pasiva* o *primario-respaldo* para la tolerancia a fallos (véase la Figura 14.4), en cada instante existe un único gestor de réplicas primario y uno o más gestores de réplicas secundarios (*respaldos* o *esclavos*). En el modelo puramente formal, los frontales se comunican exclusivamente con el gestor de réplicas primario para obtener el servicio. El gestor de réplicas primario ejecuta las operaciones y envía copias de los datos actualizados a los gestores de respaldo. Si el primario falla, uno de los secundarios se promociona para que actúe como gestor primario.

Cuando un cliente solicita que se realice una operación, la secuencia de eventos es la siguiente:

1. *Petición*: el frontal lanza la petición, que contiene un identificador único, al gestor de réplicas primario.
2. *Coordinación*: el primario acepta cada petición de forma atómica, en el orden en que las recibe. Comprueba el identificador único y, en el caso en el que ya hubiera ejecutado la petición, simplemente reenvía la respuesta.
3. *Ejecución*: el primario ejecuta la petición y guarda la respuesta.
4. *Acuerdo*: si la petición es una actualización, entonces el primario envía a todas las copias de seguridad el estado actualizado, la respuesta y el identificador único. Los respaldos envían, a su vez, un acuse de recibo.
5. *Respuesta*: el primario responde al frontal, que proporciona la respuesta de vuelta al cliente.

Obviamente, este sistema implementa la linealizabilidad si el gestor primario es correcto, dado que éste secuencia todas las operaciones sobre los objetos compartidos. Si el primario falla, entonces el sistema conserva la capacidad de secuenciación si sólo un respaldo se convierte en el nuevo primario y si la nueva configuración del sistema toma el control exactamente donde lo dejó el anterior:

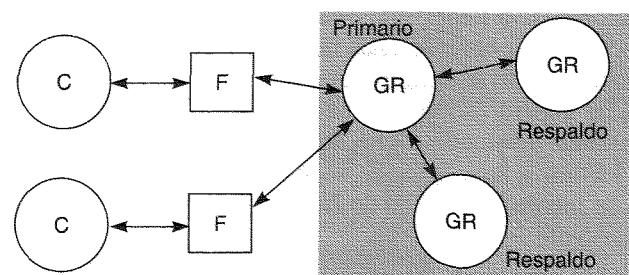
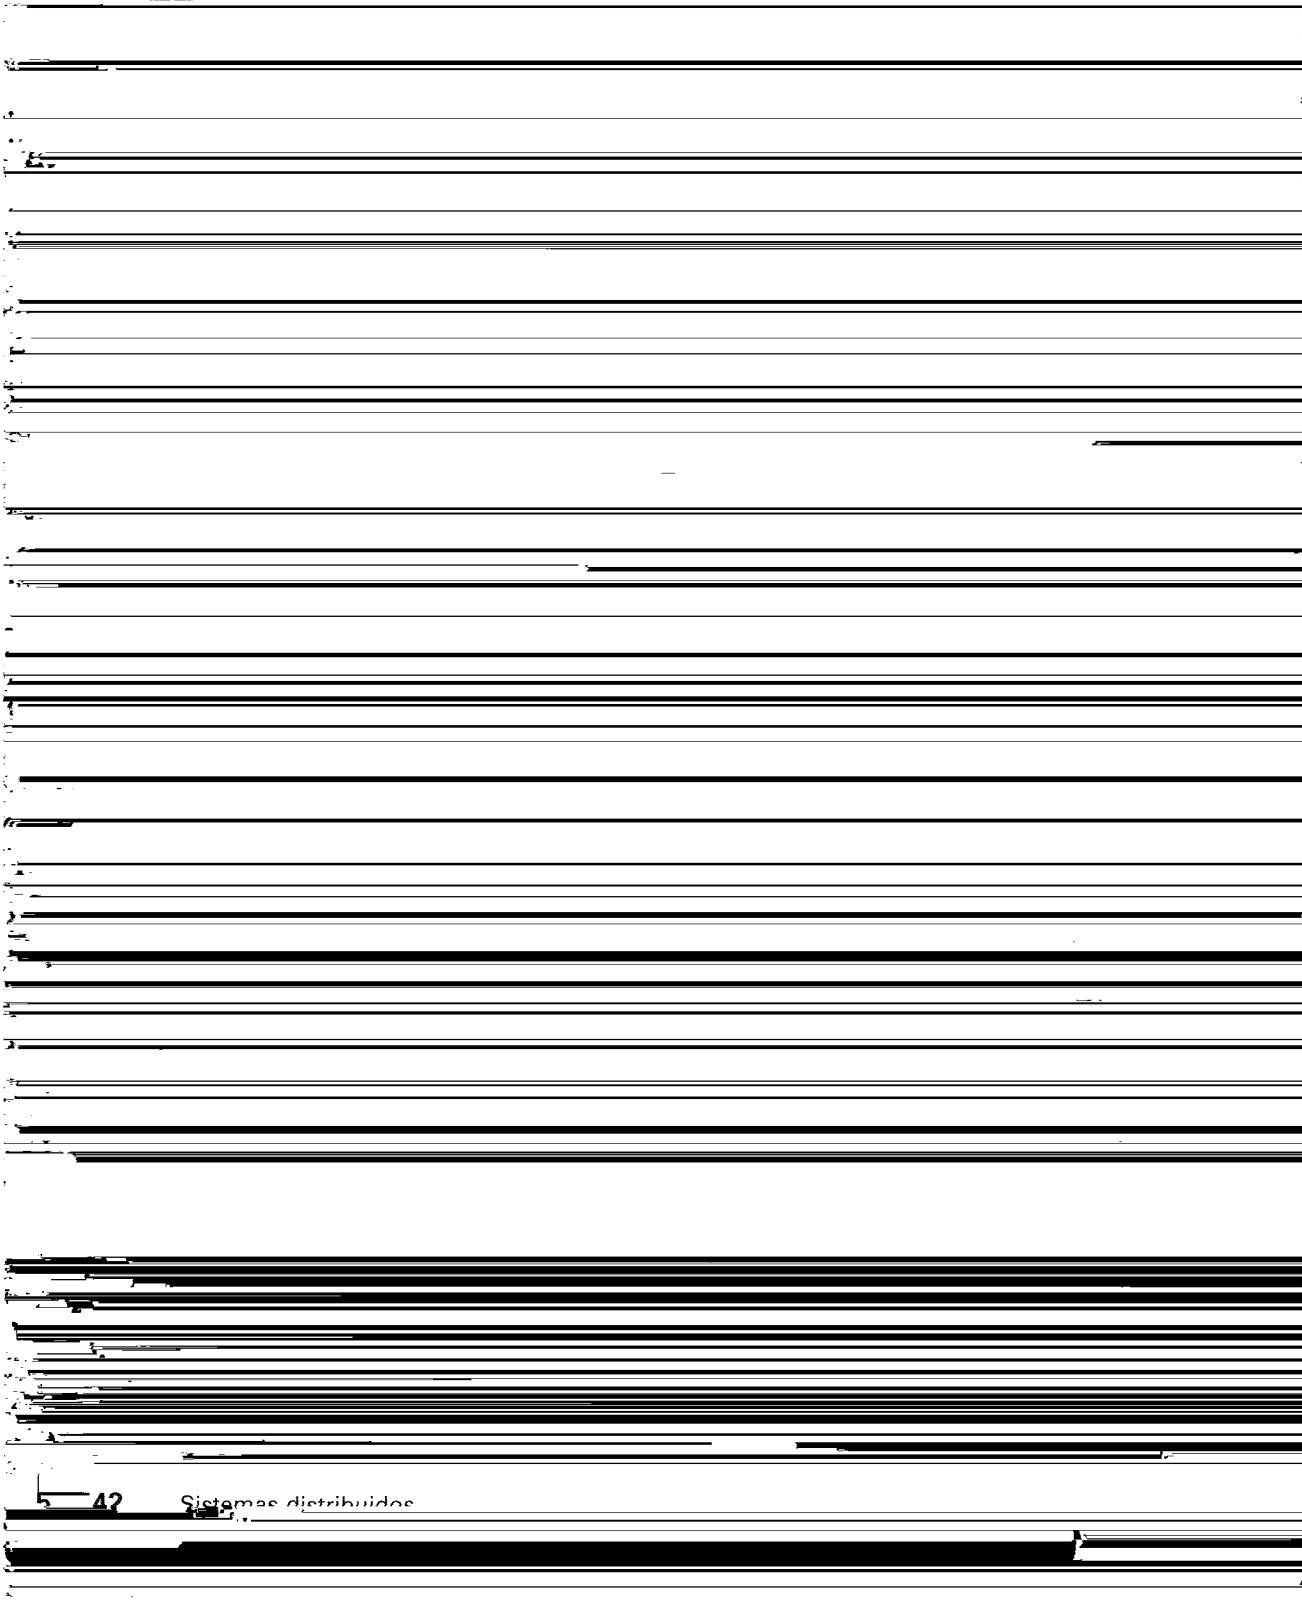


Figura 14.4. El modelo pasivo (primario-respaldo) para tolerancia a los fallos.

Figura 14.4. El modelo pasivo (primario responde) para tolerancia a los fallos.



dimiento, aunque con garantías más débiles que la consistencia secuencial. Las garantías de consistencia más débiles son todavía satisfactorias para muchos fines, tales como el almacenamiento de ciertos tipos de registros de administración del sistema. Los datos replicados se actualizan en un servidor maestro y se propaga desde ahí a los servidores esclavos utilizando una comunicación *uno a uno* (en lugar de la comunicación en grupo). Para recuperar información, los clientes pueden comunicarse bien con un servidor maestro, bien con uno esclavo. En NIS, sin embargo, los clientes no pueden solicitar actualizaciones: las actualizaciones se hacen vía archivos maestros.

14.3.2. REPLICACIÓN ACTIVA

En el modelo de replicación *activa* para tolerancia a fallos (véase la Figura 14.5), los gestores de réplicas son máquinas de estado que desempeñan papeles equivalentes y se organizan como un grupo. Los frontales multidifunden sus peticiones al grupo de gestores de réplicas y todos los gestores de réplicas procesan la petición de forma independiente, pero idéntica, y responden. Si cae cualquier gestor de réplicas, no tiene necesariamente impacto en las prestaciones del servicio, puesto que los restantes gestores de réplicas continúan respondiendo de la forma habitual. Veremos que la replicación activa puede tolerar fallos bizantinos (extraños), puesto que el frontal puede recopilar y comparar las respuestas que recibe.

Bajo replicación activa, la secuencia de eventos que se desarrolla cuando un cliente solicita que se efectúe una operación es como sigue:

1. *Petición*: el frontal adjunta un identificador único a la petición y la multidifunde al grupo de gestores de réplicas, usando una primitiva de multidifusión fiable y totalmente ordenado. Se asume que, en el peor de los casos, el frontal puede fallar por caída. Además, no emitirá la siguiente petición hasta que haya recibido una respuesta.
2. *Coordinación*: el sistema de comunicación en grupo reparte la petición a cada gestor de réplicas correcto en el mismo orden (total).
3. *Ejecución*: cada gestor de réplicas ejecuta la petición. Puesto que son máquinas de estado, y las peticiones se entregan en el mismo orden total, todos los gestores de réplicas correctos procesan idénticamente la petición. La respuesta contiene el identificador único de la petición del cliente.
4. *Acuerdo*: no se necesita fase de acuerdo, debido a la semántica de reparto de la multidifusión.
5. *Respuesta*: cada gestor de réplicas envía su respuesta al frontal. El número de respuestas que recoge el frontal depende de las suposiciones de fallo y del algoritmo de multidifusión.

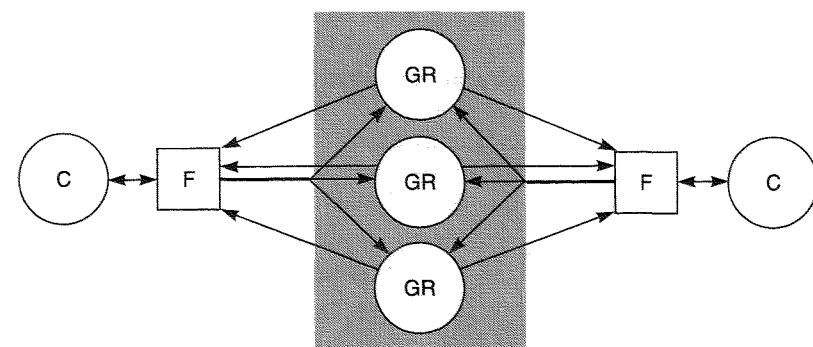
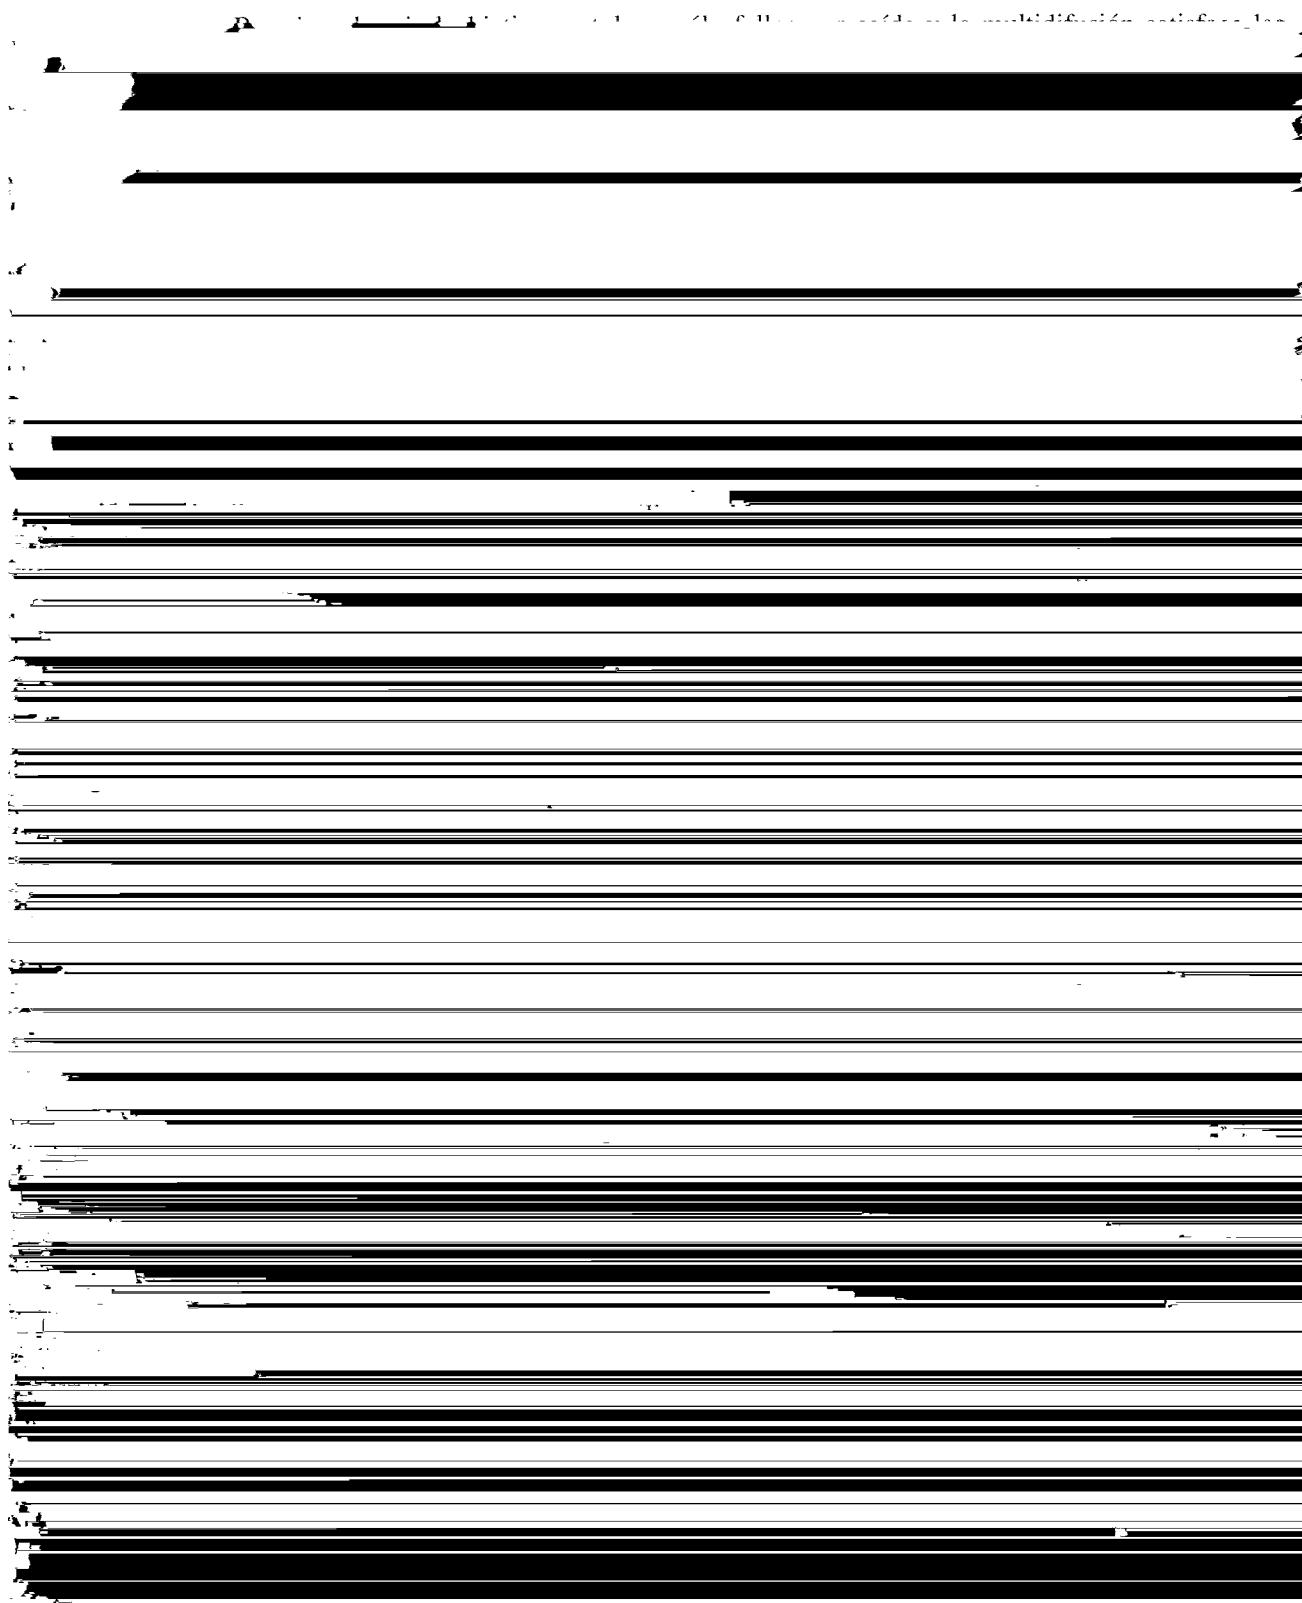


Figura 14.5. Replicación activa.



las peticiones, pero el servicio mantiene la consistencia secuencial. Además, el frontal puede fácilmente enmascarar el fallo de un gestor de réplicas en esta situación, simplemente enviando la petición de *sólo lectura* a otro gestor de réplicas.

14.4. SERVICIOS CON ALTA DISPONIBILIDAD

En lo que resta de capítulo, se considerará cómo aplicar las técnicas de replicación para conseguir una alta disponibilidad en los servicios. Nuestro énfasis está ahora en proporcionar a los clientes el acceso al servicio (con tiempos de respuesta razonables) durante el mayor tiempo posible, incluso si algunos resultados no cumplen la consistencia secuencial. Por ejemplo, el usuario en el tren al comienzo del capítulo podría admitir trabajar con inconsistencias temporales entre las copias de los datos, tales como agendas, si puede continuar trabajando mientras está desconectado y puede corregir los problemas después.

En la Sección 14.3, se vio que los sistemas tolerantes a fallos transmiten de modo *acuciante* (*eager*) las actualizaciones a los gestores de réplicas: todos los gestores de réplicas correctos reciben las actualizaciones lo antes posible y llegan a un acuerdo colectivo antes de devolver el control al cliente. Este comportamiento no es deseable para operaciones con alta disponibilidad. En su lugar, el sistema debería proporcionar un nivel de servicio aceptable utilizando un conjunto mínimo e gestores de réplicas conectados al cliente. Y debería minimizar el tiempo que el cliente está obligado a esperar mientras los gestores de réplicas coordinan sus actividades. Generalmente, los grados de consistencia más débiles requieren un menor grado de acuerdo y permiten que los datos compartidos estén disponibles durante más tiempo.

A continuación se examinan distintos sistemas que proporcionan servicios con alta disponibilidad: sistemas de cotilleo, Bayou y Coda.

14.4.1. LA ARQUITECTURA COTILLA

Ladin y otros [1992] desarrollaron lo que en adelante se llamará la *arquitectura cotilla*, o *de cotilleo*, como un marco de referencia para implementar servicios con alta disponibilidad mediante la replicación de datos en puntos cercanos a los lugares donde los grupos de clientes los necesitan. El nombre refleja el hecho de que los gestores de réplicas intercambian periódicamente mensajes de *cotilleo* para transmitir las actualizaciones que ha recibido cada uno por parte de sus clientes (véase la Figura 14.6). La arquitectura está basada en un trabajo anterior en bases de datos de Fischer y Michael [1982] y Wu y Bernstein [1984]. Puede usarse, por ejemplo, para un tablón de anuncios electrónico altamente disponible o un servicio de dietario.

Un servicio cotilla proporciona dos tipos básicos de operaciones: *preguntas* que son operaciones de *sólo lectura* y *actualizaciones* que modifican pero no leen el estado (ésta es una definición más restrictiva que la que se venía usando). Una característica importante es que los frontales envían preguntas y actualizaciones a cualquier gestor de réplicas que elijan (cuálquiera que esté disponible y proporcione tiempos de respuesta razonables). El sistema garantiza dos cosas, incluso aunque los gestores de réplicas no puedan comunicarse temporalmente unos con otros:

Cada cliente consigue un servicio consistente a lo largo del tiempo: en respuesta a una pregunta, los gestores de réplicas siempre proporcionan al cliente datos que reflejan al menos las actualizaciones que hubiese observado hasta ese momento. Esto es así incluso aunque los clientes puedan comunicarse con distintos gestores de réplicas en instantes de tiempo diferentes y, por lo tanto, en principio, podrían comunicarse con un gestor de réplicas que estuviese *menos avanzado* que con otro con el que se comunicaron antes.

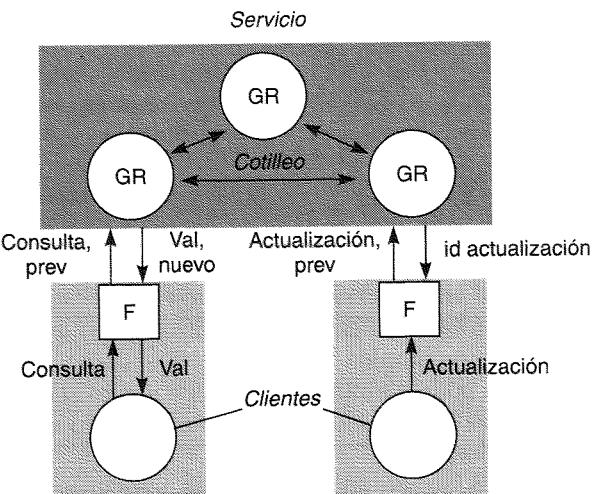


Figura 14.6. Operaciones de consulta y actualización en un servicio cotilla.

Consistencia relajada entre réplicas: todos los gestores de réplicas, en algún momento, recibirán todas las actualizaciones y las aplican con garantías de ordenación que hacen a las réplicas lo suficientemente parecidas como para cumplir las necesidades de la aplicación. Es importante darse cuenta de que aunque la arquitectura de cotilleo pueda usarse para obtener consistencia secuencial, está pensada inicialmente para proporcionar garantías de consistencia más débiles. Dos clientes pueden observar réplicas distintas aunque las réplicas incluyan el mismo conjunto de actualizaciones; y un cliente pueda observar datos anticuados.

Para proporcionar la consistencia relajada, la arquitectura cotilla proporciona actualización con orden *causal*, tal y como se definió en la Sección 14.2.1. Además, aporta garantías de ordenación más fuertes en la forma de orden *forzado* (total y causal) e *inmediato*. Las actualizaciones *inmediatamente ordenadas* se aplican en un orden consistente en relación con *cualquier* otra actualización en todos los gestores de réplicas, ya sean las otras ordenaciones de actualización causales, forzadas o inmediatas. Se proporciona el *orden inmediata* además del *orden forzado* porque una actualización con *orden forzado* y una actualización con *orden causal* que no estén relacionadas mediante la relación *sucedió antes* pueden ser aplicadas en distintos órdenes en diferentes gestores de réplicas.

Se deja al diseñador de la aplicación la elección de qué ordenación utilizar, y refleja un compromiso entre la consistencia y los costes de la operación. Las actualizaciones causales son considerablemente menos costosas que las otras y es de esperar que se utilicen siempre que sea posible. Obsérvese que las preguntas, que pueden ser satisfechas por cualquier gestor de réplicas individual se ejecutan siempre en orden causal con respecto a otras operaciones.

Considere una aplicación tablón de anuncios electrónico, en el cual un programa cliente (que incorpora al frontal) se ejecuta en el computador del usuario y se comunica con un gestor de réplicas local. El cliente envía los anuncios del usuario al gestor de réplicas local y éste envía los nuevos anuncios mediante cotilleos a otros gestores de réplicas. Los lectores de los tablones de anuncios perciben listas de anuncios ligeramente atrasadas, pero esto generalmente no es importante si el retraso es del orden de minutos u horas en lugar de días. Se puede utilizar un orden causal para depositar un anuncio. Esto, en general, significaría que los anuncios podrían aparecer con distintas ordenaciones en gestores de réplicas diferentes, pero que, por ejemplo, un anuncio cuyo asunto es *Re: naranjas* siempre se anunciará tras el mensaje sobre *naranjas* al cual se refiere. La ordenación forzada podría utilizarse para añadir un nuevo suscriptor al tablón de anuncios, de tal forma que

exista un registro no ambiguo del orden en el cual los usuarios se unieron al grupo. La ordenación inmediata podría utilizarse para retirar a un usuario de una lista de suscripción a un tablón de anuncios, de tal forma que los mensajes no puedan ser retirados por el usuario mediante algún gestor de réplicas lento una vez que la operación de eliminación haya terminado.

El frontal para un servicio cotilla manipula las operaciones que el cliente realiza utilizando una API específica de la aplicación y las convierte en operaciones de cotilleo. Por lo general, las operaciones de un cliente pueden bien leer el estado replicado, bien modificarlo o ambas cosas. Ya que en las actualizaciones cotillas únicamente se modifica el estado, el frontal convierte una operación que lee y modifica el estado en una pregunta y una actualización separadas.

En términos de nuestro modelo básico de replicación, se esboza, a continuación, cómo un servicio cotilla procesa las operaciones de pregunta y actualización:

1. *Petición:* El frontal normalmente envía peticiones sólo a un gestor de réplicas de cada vez. No obstante, un frontal se comunicará con un gestor de réplicas diferente cuando el que utiliza normalmente falla o se vuelve inaccesible, e incluso puede intentar uno o más si el gestor habitual se encuentra muy cargado. Los frontales y, por lo tanto, los clientes, pueden bloquearse en operaciones de pregunta. Por otro lado, la decisión por defecto para operaciones de actualización consiste en volver al cliente tan pronto como la operación haya sido pasada al frontal; a continuación, éste propaga la operación en segundo plano. Alternativamente, y para incrementar la fiabilidad, se podría impedir al cliente continuar hasta que la actualización haya sido entregada a $f + 1$ gestores de réplicas y, por lo tanto, puede entregarse en cualquier destino a pesar de un máximo de f fallos.
2. *Respuesta a una actualización:* Si la petición es una actualización, entonces el gestor de réplicas responde tan pronto como haya recibido la actualización.
3. *Coordinación:* El gestor de réplicas que recibe una petición no la procesa hasta que pueda aplicar la petición de acuerdo con las restricciones de ordenación que se requieran. Esto puede involucrar la recepción de actualizaciones por parte de otros gestores de réplicas mediante mensajes de cotilleo. No se realiza ninguna otra coordinación entre los gestores de réplicas.
4. *Ejecución:* El gestor de réplicas ejecuta la petición.
5. *Respuesta a la pregunta:* Si la petición es una pregunta, el gestor de réplicas se responde en este momento.
6. *Acuerdo:* Los gestores de réplicas se actualizan entre ellos intercambiando *mensajes de cotilleo*, que contienen las actualizaciones más recientes que hayan recibido. Se dice que se actualizan unos a otros de una forma *perezosa*, ya que pueden intercambiarse los mensajes cotillas sólo ocasionalmente tras recoger varias actualizaciones; o cuando un gestor de réplicas se da cuenta de que ha perdido una actualización enviada a uno de sus iguales y que la necesita para procesar una petición.

A continuación describiremos el sistema cotilla con más detalle. Comenzaremos considerando las estructuras de datos y marcas temporales que mantienen los frontales y los gestores de réplicas para preservar las garantías de ordenamiento en las actualizaciones. A continuación, a partir de estos, explicaremos cómo los gestores de réplicas procesan las preguntas y las actualizaciones. La mayor parte del procesamiento de los vectores de marcas temporales necesarias para mantener las actualizaciones causales es parecido al del algoritmo de multidifusión causal de la Sección 11.4.3.

◊ **Las marcas temporales de la versión del frontal.** Para controlar la ordenación en el procesamiento de operaciones, cada frontal guarda un vector de marcas temporales que refleja la versión de los últimos valores de los datos a los que accedió (y a los que, por lo tanto, accedió el cliente). Estas marcas temporales, denominadas *prev* en la Figura 14.6, contienen una entrada para cada gestor de réplicas. El frontal los envía en cada mensaje de petición a un gestor de réplicas junto con una descripción de la operación de pregunta o actualización. Cuando un gestor de

todavía aplicar la actualización porque no es *estable*. Una actualización estable es aquella que puede aplicarse consistentemente con sus garantías de ordenación (causal, forzada o inmedia- ta). Una actualización que no es aún estable debe ser retenida y no procesarse aún. La segunda razón para mantener una actualización en el registro histórico es que, aunque la actualización se haya vuelto estable y haya sido aplicada al valor, el gestor de réplicas no ha recibido confir- mación de que esta actualización haya sido recibida por el resto de los gestores de réplicas. Mientras tanto, el gestor propaga la actualización en mensajes de cotilleo.

Marcas temporales de la réplica: este vector de marcas temporales representa aquellas actuali- zaciones que han sido aceptadas por el gestor de réplicas, esto es, colocadas en el registro his- tórico del gestor. Generalmente, difiere de los valores de las marcas temporales, por supuesto, pues no todas las actualizaciones del registro histórico son estables.

Tabla de operaciones ejecutadas: la misma actualización podría llegar a cierto gestor de répi- licas desde un frontal y en mensajes de cotilleo desde otros gestores de réplicas. Para evitar que una actualización se aplique dos veces se mantiene la tabla de *operaciones ejecutadas*, que contiene los identificadores únicos de las actualizaciones que han sido aplicadas al componente valor y que fueron proporcionados por el frontal. Los gestores de réplicas comprueban esta ta- blla antes de añadir una actualización al registro histórico.

Tabla de marcas temporales: esta tabla contiene un vector de marcas temporales para cada uno de los otros gestores de réplicas, que contiene las marcas temporales que han llegado de ellos en los mensajes de cotilleo. Los gestores de réplicas utilizan la tabla para establecer cuándo se ha aplicado una actualización en todos los gestores de réplicas.

Los gestores de réplicas se numeran 0, 1, 2, ... y el i -ésimo elemento de un vector de marcas tem- porales mantenido por el gestor de réplicas i corresponde al número de actualizaciones hechas reci- bidas por i de otros frontales; y el j -ésimo componente ($j \neq i$) corresponde al número de actualiza- ciones recibidas por j y propagadas hasta i en mensajes cotillas. Por ejemplo, en un sistema cotilla con tres gestores un valor de marca temporal de (2, 4, 5) en el gestor 0 representaría el hecho de que el valor en la posición 0 refleja las dos primeras actualizaciones aceptadas desde los frontales en el gestor 0, las cuatro primeras en el gestor 1 y las cinco primeras en el gestor 2. A continuación se examina con más detalle cómo se usan las marcas temporales para asegurar la ordenación.

◊ **Operaciones pregunta.** La operación más simple que se considera es la pregunta. Recuér- dese que una petición de pregunta q contiene una descripción de la operación y una marca tempo- ral $q.prev$ enviadas por el frontal. El último dato refleja la última versión del valor que el frontal ha leído o enviado como una actualización. Por lo tanto, la tarea del gestor de réplicas consiste en devolver un valor que sea, por lo menos, tan reciente como éste. Si $valorMT$ es el valor de la mar- ca temporal de la réplica, entonces q puede aplicarse sobre el valor de la réplica si:

$$q.prev \leq valorMT$$

El gestor de réplicas guarda q en una lista de operaciones pregunta pendientes (esto es, una cola de retención) hasta que se cumpla esta condición. Bien puede esperar por las actualizaciones extravia- das que, en último término, deberían llegar en mensajes cotillas; o bien puede solicitar las actualiza- ciones a los gestores de réplicas aludidos. Por ejemplo, si $valorMT$ es (2,5,5) y $q.prev$ es (2,4,6) se puede observar que sólo se ha extraviado una actualización, por parte del gestor de réplicas 2 (para que el frontal que envió q haya visto esta actualización, que el gestor de réplicas no ha visto, debe haber contactado previamente con un gestor de réplicas diferente).

Cuando pueda hacerse la pregunta, el gestor de réplicas devolverá $valorMT$ al frontal como la marca temporal *nueva*, que aparece en la Figura 14.6. A continuación, el frontal fusiona ésta con su marca temporal: $frontalMT := fusiona(frontalMT, nueva)$. La actualización en el gestor de répi- licas 1, que el frontal no había visto antes de la pregunta en el ejemplo anterior ($q.prev$ tiene un 4

donde el gestor de réplicas tiene un 5), se reflejará en la actualización de *frontalMT* (y, dependiendo de la pregunta, posiblemente, en el valor que se devuelva).

◊ **Procesamiento de operaciones de actualización en orden causal.** Un frontal envía una petición de actualización a uno o más gestores de réplicas. Cada petición de actualización *a* contiene la especificación de dicha actualización (su tipo y parámetros) *a.op*, la marca temporal del frontal *a.prev* y un identificador único *a.id* generado por el frontal. Si éste envía, a distintos gestores de réplicas, la misma petición *a*, utilizará en todos los casos el mismo identificador para *a* para que no sea procesada como varias peticiones idénticas.

Cuando un gestor de réplicas *i* recibe una petición de actualización de un frontal, comprueba que no la haya procesado ya, buscando el identificador de la operación en la tabla de operaciones ejecutadas y en las fichas del registro histórico. El gestor de réplicas descarta la actualización si ya la había visto; en otro caso, incrementa en uno el *i*-ésimo elemento en la marca temporal de su réplica para llevar la cuenta del número de actualizaciones que ha recibido directamente de los frontales. A continuación, el gestor de réplicas asigna a la petición de actualización *a* un único vector de marcas temporales (en un proceso que será explicado en breve), y se coloca una nueva entrada en el registro del gestor de réplicas para esa actualización. Si *mt* es la marca temporal única que el gestor de réplicas asigna a la actualización, entonces el registro de la actualización, que se guarda en el registro histórico, se construye como una tupla que tiene la siguiente forma:

fichaRegistro := <*i*, *mt*, *a.op*, *a.prev*, *a.id*>

El gestor de réplicas *i* obtiene la marca temporal *mt* a partir de *a.prev* reemplazando el *i*-ésimo elemento de *a.prev* por el *i*-ésimo elemento de su marca temporal de réplica (que acaba de ser incrementada). Esta acción hace que *mt* sea única, asegurando de esta forma que todos los componentes del sistema registrarán correctamente si han observado o no la actualización. Los elementos restantes en *mt* se copian de *a.prev*, ya que son estos valores mandados por el frontal los que deben usarse para determinar cuándo la actualización es estable. En ese momento, inmediatamente el gestor de réplicas devuelve *mt* al frontal, que lo fusiona con la marca temporal que ya tenía. Obsérvese que un frontal puede enviar su actualización a varios gestores de réplicas y, consecuentemente, recibiendo de vuelta distintas marcas temporales, que deben fusionarse en su marca temporal.

La condición de estabilidad para una actualización *a* es similar a la de las preguntas:

a.prev ≤ *valorMT*

Esta condición establece que todas las actualizaciones de las cuales depende esta actualización (esto es, todas las actualizaciones que han sido observadas por el frontal que generó la actualización) han sido ya aplicadas al valor. Si esta condición no se cumple en el momento en el que se envía la actualización, será comprobada de nuevo cuando lleguen los mensajes de cotilleo. Cuando se ha cumplido la condición de estabilidad para un registro de actualización *r*, el gestor de réplicas aplica la actualización al valor y actualiza tanto el valor de la marca temporal como la tabla de operaciones ejecutadas:

```
valor := aplica(valor, r.a.op)
valorMT := fusiona(valorMT, r.mt)
ejecutadas := ejecutadas ∪ {r.a.id}
```

La primera de estas tres instrucciones representa la aplicación de la actualización al valor. En la segunda instrucción, la marca temporal de la actualización se fusiona con la del valor. En la tercera, el identificador de operación de la actualización se añade al conjunto de identificadores de operaciones que han sido ejecutadas, lo cual se utiliza para detectar peticiones de operaciones repetidas.

◊ Operaciones de actualización forzadas e inmediatas

Las actualizaciones forzadas e

◊ **Operaciones de actualización forzadas e inmediatas.** Las actualizaciones forzadas e inmediatas requieren un tratamiento especial. Recuérdese que las actualizaciones forzadas están or-

- Fusionar el registro histórico que le llega con el suyo (ya que puede contener actualizaciones que el receptor no había observado).
- Aplicar cualquier actualización que se haya convertido en estable y que no haya sido ejecutada antes (a su vez, algunas actualizaciones estables en el registro que llega puede que hagan estables algunas actualizaciones pendientes).
- Eliminar entradas en el registro histórico y entradas de la tabla de operaciones ejecutadas, cuando se sepa que dichas actualizaciones se han realizado en todas partes y que no existe peligro de repeticiones. Ésta es una tarea importante, ya que si no se borrasen entradas de ambas tablas, éstas podrían crecer de forma ilimitada.

El proceso de fusionar el registro histórico contenido en un mensaje recibido con el registro del receptor es inmediato. Sea $réplicaMT$ la marca temporal de la réplica del receptor. Se añade cada entrada r del registro en $m.log$ al registro histórico del receptor a no ser que $r.mt \leqslant réplicaMT$, en cuyo caso ya estará en el registro o ya fue aplicada la actualización y después descartada.

El gestor de réplicas fusiona la marca temporal del mensaje de cotilleo entrante con su propia marca temporal de réplica $réplicaMT$, de forma que se corresponda con las nuevas incorporaciones al registro:

$$réplicaMT := \text{fusiona}(réplicaMT, m.mt)$$

Cuando se hayan fusionado los nuevos registros de actualizaciones en el registro histórico, el gestor de réplicas colecciona el conjunto E de actualizaciones en el registro que en ese momento sean estables. Éstas se pueden aplicar al valor, pero se ha de tener cuidado en el orden en el que se aplicarán para que se cumpla la relación *sucedió antes*. El gestor de réplicas ordena las actualizaciones dentro de dicho conjunto según el orden parcial « \leqslant » entre vectores de marcas temporales. Éste aplica entonces las actualizaciones en este orden: primero las menores. Esto es, cada $r \in E$ se aplica sólo cuando no haya un $s \in E$ tal que $s.prev < r.prev$.

A continuación el gestor de réplicas busca en el registro las entradas que puedan descartarse. Si el mensaje cotilla fue enviado por el gestor de réplicas j y si la $tablaMT$ es la tabla de las marcas temporales de los gestores de réplicas, entonces el gestor de réplicas establece:

$$tablaMT[j] := m.mt$$

El gestor de réplicas puede ahora descartar cualquier entrada para actualización r en el registro histórico que haya sido recibido en todas partes. Esto es, si c es el gestor de réplicas que ha creado la entrada en el registro, entonces se requiere para todos los gestores de réplicas i que:

$$tablaMT[i][c] \geqslant r.mt[c]$$

La arquitectura cotilla también define cómo los gestores de réplicas pueden descartar entradas en la tabla de operaciones ejecutadas. Es importante no descartar estas entradas demasiado pronto ya que una operación muy retrasada podría aplicarse erróneamente dos veces. Ladin y otros [1992] proporcionan más detalles del esquema. En esencia, los frontales emiten acuses de recibo a las respuestas a sus actualizaciones, por lo que los gestores de réplicas saben cuándo un frontal terminará de enviar la actualización. A partir de ese momento, asumen un retraso máximo en la propagación de las actualizaciones.

◊ **Propagación de las actualizaciones.** La arquitectura cotilla no especifica cuándo intercambian mensajes cotillas los gestores de réplicas, ni cómo un gestor de réplicas escoge a otro para enviarle un mensaje cotilla. Se necesita una estrategia robusta de propagación de actualizaciones para que todos los gestores de réplicas reciban todas las actualizaciones en un período de tiempo aceptable.

El tiempo que tardan todos los gestores de réplicas en recibir una actualización determinada depende de tres factores:

- La frecuencia y la duración de las particiones de la red.
- La frecuencia con las que los gestores de réplicas envían mensajes cotillas.
- La política de selección de un socio con el cual intercambiar mensajes cotillas.

El primer factor está más allá del control del sistema, aunque los usuarios pueden determinar, hasta cierto punto, la frecuencia con la que trabajan sin conexión.

La frecuencia deseada de intercambio de mensajes cotillas puede sintonizarse en función de la aplicación. Considérese un sistema de tablón de anuncios compartido entre varios sitios. Parece innecesario que cada ítem se comunique inmediatamente a todos los sitios. Pero, ¿qué sucedería si sólo se intercambiasen los mensajes cotillas tras largos períodos, digamos una vez al día? Si sólo se usan actualizaciones causales, entonces es muy posible que los clientes en cada sitio tengan sus propios debates consistentes sobre el mismo tablón de anuncios, sin ser conscientes de las discusiones en los otros sitios. Entonces, todos los debates se fusionarían, por ejemplo a medianoche; pero es probable que los debates sobre el mismo tema se vuelvan incongruentes, cuando habría sido preferible para ellos tenerse en cuenta los unos a los otros. Un período de tiempo de minutos u horas, para el intercambio de mensajes de cotilleo, hubiera sido más apropiado para este caso.

Hay varios tipos de política de selección de socios. Golding y Long [1993] consideran las políticas *aleatorias*, *deterministas* y *topológicas* para su *protocolo anti-entrópico con marcas temporales*, que utiliza un esquema de propagación de actualizaciones de estilo cotilla.

Las políticas aleatorias escogen al azar un socio, pero con probabilidades ponderadas que favorecen a algunos socios frente a otros: por ejemplo, socios cercanos frente a socios lejanos. Golding y Long se dieron cuenta de que tal política funcionaba sorprendentemente bien en simulación. Las políticas deterministas utilizan una expresión que es función del estado del gestor de réplicas para escoger un socio. Por ejemplo, un gestor de réplicas puede examinar su tabla de marcas temporales y escoger al gestor de réplicas que parezca más divergente en cuanto a las actualizaciones que ha recibido.

Las políticas topológicas organizan a los gestores de réplicas en grafos fijos. Una posibilidad es una malla: los gestores de réplicas envían mensajes cotillas a los cuatro gestores de réplicas con los que están conectados. Otra posibilidad es organizar a los gestores de réplicas en un círculo, pasando cada uno de ellos un mensaje cotilla sólo a su vecino (por ejemplo, en el sentido de las agujas del reloj), de tal modo que las actualizaciones que llegan de cada gestor de réplicas finalmente atraviesan el círculo. Hay muchas otras topologías posibles, incluyendo los árboles.

Distintas políticas de selección de socios, entre las que se incluyen las anteriores, valoran la cantidad de comunicación frente a mayores latencias de transmisión y la posibilidad de que un único fallo afecte a otros gestores de réplicas. En la práctica, la elección depende de la importancia relativa de estos factores. Por ejemplo, la topología circular produce relativamente poca comunicación pero está sujeta a mayores latencias en las transmisiones ya que los mensajes cotillas han de pasar, generalmente, por distintos gestores de réplicas. Aún más, si un gestor de réplicas falla, el círculo no funciona y necesita ser reconfigurado. Por el contrario, la política de selección aleatoria no es susceptible a los fallos pero puede producir tiempos de propagación de las actualizaciones más variables.

◊ **Discusión sobre la arquitectura cotilla.** La arquitectura cotilla tiene como objetivo alcanzar una alta disponibilidad en los servicios. Se puede decir en su favor que los clientes pueden seguir obteniendo un servicio incluso cuando están en una partición aislados del resto de la red, siempre que, al menos, un gestor de réplicas continúe funcionando en esa partición. No obstante, esta disponibilidad se consigue a cambio de proporcionar garantías de consistencia relajadas. Para el caso de objetos como cuentas bancarias, donde se requiere consistencia secuencial, una arquitectura

tura cotilla no será mejor que el sistema tolerante a fallos de la Sección 14.3 y proporcionará el servicio sólo en la partición mayoritaria.

La forma perezosa en la que propaga las actualizaciones hace que este sistema no sea apropiado para la actualización de réplicas con requisitos próximos al tiempo real, como cuando los usuarios participan en una conferencia en *tiempo real* y actualizan un documento compartido. En ese caso sería más apropiado un sistema basado en multidifusión.

Otro tema es la capacidad de aumentar de tamaño de un sistema cotilla. En la medida que el número de gestores de réplicas crece también aumenta el número de mensajes que han de transmitirse y el tamaño de los vectores de marcas temporales. Si un cliente realiza una pregunta, normalmente se necesitarán dos mensajes (entre el frontal y el gestor). Si un cliente realiza una operación de actualización causal y si cada uno de los R gestores de réplicas normalmente recoge C actualizaciones dentro de un mensaje cotilla, entonces el número de mensajes que se intercambian es $2 + (R - 1)/C$. El primer término representa la comunicación entre el frontal y el gestor de réplicas y el segundo es la parte de la actualización de un mensaje cotilla enviado a los otros gestores de réplicas. Aumentando C se mejora el número de mensajes. Pero eso también empeora las latencias de entrega, porque el gestor de réplicas espera hasta que lleguen más actualizaciones antes de propagarlas.

Una aproximación para conseguir que los sistemas basados en cotilleo puedan aumentar de tamaño es hacer que la mayoría de las réplicas sean de *sólo lectura*. En otras palabras, estas réplicas se actualizan a través de mensajes cotillas, pero no reciben actualizaciones directamente de los frontales. Esta organización es útil, potencialmente, donde la proporción *actualización/pregunta* es pequeña. Las réplicas de *sólo lectura* pueden ser situadas próximas a los grupos de clientes y las actualizaciones pueden ser servidas por un número relativamente pequeño de gestores de réplicas. El tráfico cotilla se reduce, ya que las réplicas de *sólo lectura* no propagan mensajes de cotilleo. Y los vectores de marcas temporales sólo contienen entradas para réplicas actualizables.

14.4.2. EL SISTEMA BAYOU Y LA APROXIMACIÓN DE LA TRANSFORMACIÓN OPERACIONAL

El sistema Bayou [Terry y otros 1995, Petersen y otros 1997] proporciona replicación de datos con alta disponibilidad con garantías más débiles que la consistencia secuencial, como la arquitectura cotilla y el protocolo anti-entrópico con marcas temporales. Como en esos sistemas, los gestores de réplicas Bayou pueden hacer frente a una conectividad variable, mediante el intercambio de actualizaciones por parejas, en lo que los diseñadores también denominan un protocolo anti-entropía. Sin embargo, el sistema Bayou adopta una aproximación marcadamente diferente, en la que se posibilitan técnicas de detección y resolución de conflictos específicas del dominio.

Considérese a un usuario que necesita actualizar una agenda mientras trabaja sin conexión. Si se requiere consistencia estricta, entonces, en la arquitectura cotilla las actualizaciones tendrían que realizar una operación forzada (totalmente ordenada). Pero entonces, sólo los usuarios de una partición mayoritaria podrían actualizar la agenda. Así, el acceso de los usuarios a la agenda podría verse limitado independientemente de si ellos de hecho necesiten hacer actualizaciones que rompieran la integridad de la agenda. Los usuarios que quieran llenar un hueco con una cita que no dé lugar a un conflicto serán tratados de la misma forma que aquellos usuarios que involuntariamente puedan haber reservado por duplicado un hueco en su agenda.

Por el contrario, en el sistema Bayou los usuarios, en el tren y en el trabajo, podrían hacer cualquier actualización que quisieran. Todas las actualizaciones se aplican y se registran en cualquier gestor de réplicas que se encuentren. Cuando las actualizaciones recibidas en dos gestores de réplicas cualesquiera se fusionan durante un intercambio anti-entropía, los gestores de réplicas detectan y resuelven los conflictos. Se puede aplicar cualquier criterio de conflicto específico del do-

minio entre las operaciones. Por ejemplo, si una ejecutiva y su secretario han añadido citas en el mismo hueco, entonces un sistema Bayou lo detecta después de que la ejecutiva haya reconectado su portátil. Además, el sistema resuelve el conflicto según una política específica del dominio. En este caso, podría, por ejemplo, confirmar la cita de la ejecutiva y quitar la reserva del secretario en el hueco. Tal efecto, en el que una o más de un conjunto de operaciones conflictivas se deshacen o se alteran para resolver dichos conflictos, se denomina *transformación operacional*.

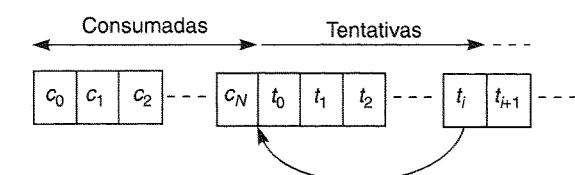
El estado que el sistema Bayou replica se guarda en forma de base de datos, permitiendo preguntas y actualizaciones (que podrían insertar, modificar o borrar ítems en la base de datos). Aunque aquí no se insistirá en este aspecto, una actualización Bayou es un caso especial de transacción. Consiste en una operación individual, una llamada a un *procedimiento prefijado*, que afecta a varios objetos dentro de cada gestor de réplicas, pero que es llevado a cabo con las garantías ACID. El sistema Bayou puede deshacer y rehacer actualizaciones de la base de datos según proceda la ejecución.

La garantía que proporciona el sistema Bayou es que, al final, cada gestor de réplicas recibe el mismo conjunto de actualizaciones y finalmente aplica esas actualizaciones de modo que las bases de datos de los gestores de réplicas sean idénticas. En la práctica podría haber un flujo continuo de actualizaciones y las bases de datos no lleguen a ser nunca idénticas; pero llegarían a serlo si cesaran las actualizaciones.

◊ **Actualizaciones tentativas y consumadas.** Las actualizaciones se marcan como *tentativas* al principio de aplicarse a la base de datos. Bayou se encarga de que las actualizaciones tentativas se dispongan finalmente en un orden canónico y se marquen como *consumadas*. Mientras las actualizaciones sean tentativas, el sistema puede deshacerlas y reaplicarlas según produzcan un estado consistente. Una vez consumadas, se mantiene su aplicación en el orden asignado. En la práctica, el orden de consumación puede obtenerse designando a algún gestor de réplicas como gestor de réplicas *primario*. Como es normal, éste decide el orden de consumación como aquel en el que recibe las actualizaciones, y propaga esta información de ordenación a los otros gestores de réplicas. Para el primario, los usuarios puede elegir, por ejemplo, una máquina rápida que esté usualmente disponible; igualmente, podría ser el gestor de réplicas en el portátil de la ejecutiva, si las actualizaciones de esa usuaria tienen prioridad.

En cada momento, el estado de la base de datos de la réplica se obtiene a partir de una secuencia (posiblemente vacía) de actualizaciones consumadas, seguidas por una secuencia (posiblemente vacía) de actualizaciones tentativas. Cuando llega la siguiente actualización consumada, o si una de las actualizaciones tentativas que se aplicó se convierte en la siguiente actualización consumada, entonces debe tener lugar una reordenación de las actualizaciones. En la Figura 14.9, t_i pasa a estar consumada. Todas las actualizaciones tentativas posteriores a c_N deben ser desechadas; después t_i se aplica tras c_N y desde t_0 hasta t_{i-1} y t_{i+1} , etc. se vuelven a aplicar tras t_i .

◊ **Procedimientos de chequeo de consistencia y de fusión.** Una actualización puede entrar en conflicto con alguna otra operación que ya se haya aplicado. Debido a esta posibilidad, toda



La actualización tentativa t_i se convierte en la siguiente actualización consumada y se inserta tras la última actualización consumada c_N .

Figura 14.9. Actualizaciones consumadas y tentativas en el sistema Bayou.

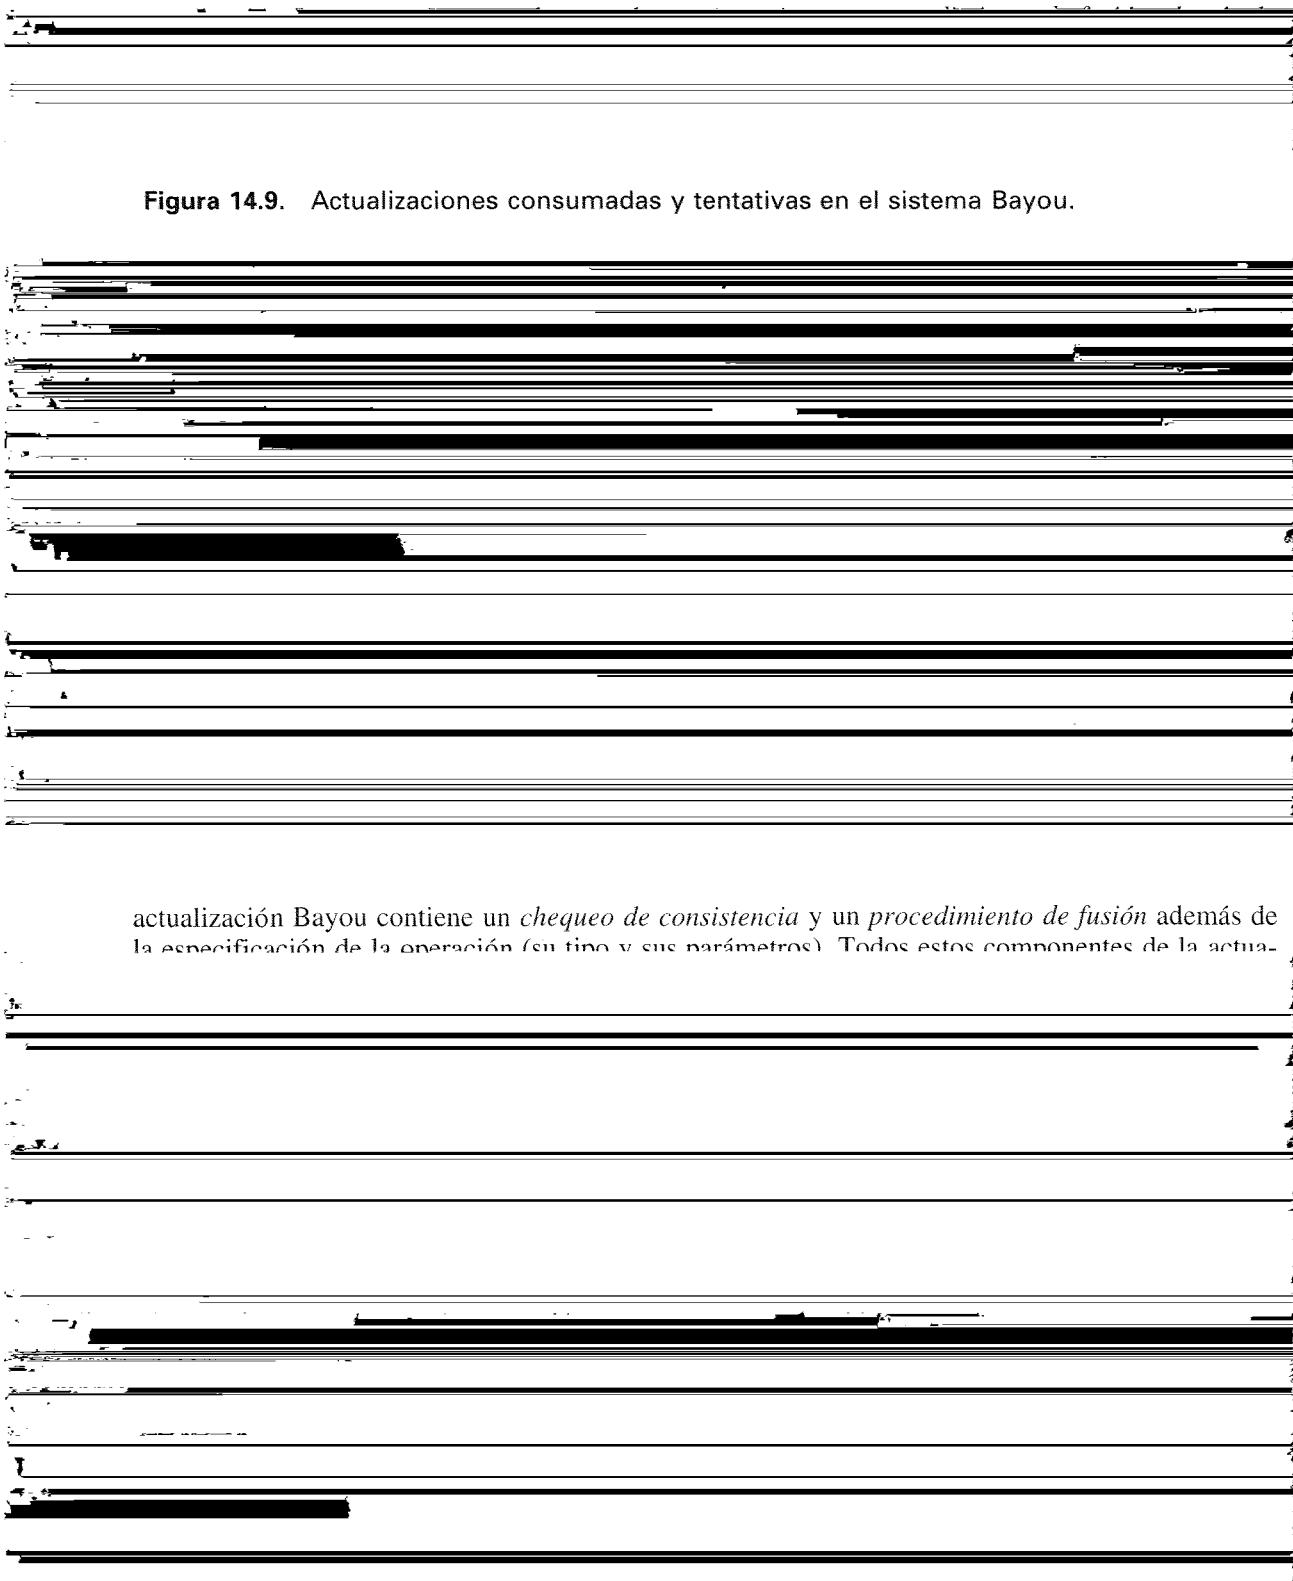


Figura 14.9. Actualizaciones consumadas y tentativas en el sistema Bayou.

actualización Bayou contiene un *chequeo de consistencia* y un *procedimiento de fusión* además de la especificación de la operación (su tipo y sus parámetros). Todos estos componentes de la actualiza-

llon (CMU) [Satyanarayanan y otros 1990; Kistler y Satyanarayanan 1992]. Los requisitos de diseño para Coda provenían de la experiencia con AFS en la CMU y otros lugares, donde se había empleado en sistemas distribuidos a gran escala en redes de comunicaciones de área tanto local como amplia.

Mientras que el funcionamiento y la facilidad de administración de AFS se consideró satisfactoria bajo las condiciones de uso en la UCM, se intuyó que la forma limitada de replicación ofrecida por AFS (restringida a volúmenes de sólo lectura) se convertiría en un factor limitante a una cierta escala, especialmente para acceder a archivos ampliamente compartidos tales como los tableros de anuncios electrónicos y otras bases de datos de grandes sistemas.

Además, había espacio para la mejora de la disponibilidad del servicio ofrecido por AFS. Las dificultades más comunes con las que se encontraban los usuarios de AFS surgían del fallo (o de la interrupción programada) de servidores y componentes de red. El tamaño del sistema en la CMU era tal que ocurrían fallos en el servicio algunas veces al día, que podían causar molestias a muchos usuarios durante períodos de tiempo que iban desde unos pocos minutos a varias horas.

Finalmente, aparecía en esos momentos un uso de los computadores que AFS no podía proporcionar: el uso móvil de los computadores portátiles. Esto hizo incluir el requisito de que debían estar disponibles todos los archivos necesarios para que un usuario continuase su trabajo mientras estaba desconectado de la red, sin que tuviese que recurrir a métodos manuales para gestionar la ubicación de los archivos.

El sistema Coda intenta cumplir estos tres requisitos bajo el encabezamiento general de *disponibilidad constante de los datos*. Su propósito era que los usuarios se beneficiasen de un repositorio de archivos compartidos a la vez que pudieran depender por completo de recursos locales cuando el repositorio estuviera parcial o totalmente inaccesible. Además de estos propósitos, el sistema Coda mantenía los objetivos originales de AFS en lo que respecta a la capacidad de crecimiento y la emulación de la semántica de los archivos en UNIX.

A diferencia de AFS, donde los volúmenes de lectura-escritura se almacenan sólo en un servidor, el diseño de Coda se basa en la replicación de volúmenes de archivos para conseguir una mayor capacidad de procesamiento de las operaciones de accesos a archivos y un mayor grado de tolerancia a fallos. Además, el sistema Coda se basa en la ampliación de un mecanismo utilizado en AFS para el mantenimiento en caché de copias de los archivos dentro de los computadores de los clientes, para permitir a esos computadores operar cuando no están conectados a la red.

Veremos que Coda es como Bayou (véase la Sección 14.4.2) en cuanto que mantiene una estrategia optimista. Esto es, permite que los usuarios actualicen datos mientras el sistema está participando, basándose en que los conflictos son relativamente improbables y que pueden solucionarse si llegaran a ocurrir. Detecta conflictos como Bayou, pero a diferencia de él, realiza el chequeo con independencia de la semántica de los datos almacenados en los archivos. Y también, a diferencia de Bayou, sólo proporciona un apoyo limitado a la resolución de los casos donde las réplicas entran en conflicto.

◊ **La arquitectura Coda.** El sistema Coda, adoptando la terminología AFS, ejecuta lo que denomina procesos *Venus* en los computadores de los clientes y procesos *Vice* en los computadores del servidor de archivos. Los procesos Vice son los que aquí se han denominado gestores de réplicas. Los procesos Venus son un híbrido entre los frontales y los gestores de réplicas. Realizan la tarea del frontal de ocultar la implementación del servicio a los procesos locales de los clientes, pero desde el momento en el que manejan una copia local caché de los archivos, también son gestores de réplicas, aunque de un tipo distinto al de los procesos Vice.

El conjunto de servidores que mantiene las réplicas de un volumen de archivos se conoce como el *grupo de almacenamiento del volumen* (*volume storage group*, VSG). En cualquier instante, un cliente que desee abrir un archivo en dicho volumen puede acceder a algún subconjunto del VSG, conocido como el grupo disponible de almacenamiento del volumen (*available VSG*, AVSG). Los

miembros del AVSG varían según los servidores estén accesibles o se vuelvan inaccesibles debido a fallos en la red o en los servidores.

miembros del AVSG varían según los servidores estén accesibles o se vuelvan inaccesibles debido a fallos en la red o en los servidores.

Normalmente, el acceso a archivos del sistema Coda se realiza de una forma similar a AFS, mediante el almacenamiento en caché de copias de los archivos que son proporcionadas a los com-

contenidos del archivo. El proceso Vice en cada sitio comprueba el CVV y, si es mayor que el que guarda en ese momento, almacena los nuevos contenidos para ese archivo y devuelve un acuse de recibo positivo. A continuación, el proceso Venus calcula el nuevo CVV incrementando los contadores de modificaciones para los servidores que respondieron de forma positiva al mensaje de actualización y distribuye el nuevo CVV entre los miembros del AVSG.

Dado que el mensaje se envía sólo a los miembros del AVSG y no al VSG, los servidores que no estén en el AVSG actual no reciben el nuevo CVV. Por lo tanto, todo CVV contendrá un contador de modificaciones exacto para el servidor local, pero los contadores para los servidores no locales serán, en general, más bajos, ya que serán actualizados sólo cuando el servidor reciba un mensaje de actualización.

El recuadro siguiente contiene un ejemplo que ilustra el uso de los CVV para gestionar la actualización de un archivo replicado en tres sitios. En Satyanarayanan y otros [1990] se pueden encontrar más detalles del uso de CVV para la gestión de actualizaciones. El concepto de CVV está basado en las técnicas de replicación utilizadas en el sistema Locus [Popek y Walker 1985].

En el modo de operación normal, el comportamiento del sistema Coda es similar al de AFS. La pérdida de una memoria caché es transparente al usuario y sólo impone un peor rendimiento. Las ventajas que se derivan de la replicación de varios o de todos los volúmenes de archivos en múltiples servidores son:

- Los archivos en un volumen replicado se mantienen accesibles para cualquier cliente que pueda acceder, al menos, a una de las réplicas.
- El rendimiento del sistema puede mejorarse compartiendo algo de la carga de las peticiones de servicio sobre un volumen replicado entre todos los servidores que mantengan réplicas.

En la operación sin conexión (cuando el cliente no puede acceder a ninguno de los servidores de un volumen), la pérdida de una memoria caché impide que se pueda continuar y se suspende la computación hasta que se recupere la conexión o el usuario aborte el proceso. Por lo tanto, es importante que se cargue la memoria caché antes de que comience la operación sin conexión de tal forma que se evite la pérdida de dicha memoria caché.

En resumen, comparado con AFS, Coda aumenta la disponibilidad gracias tanto a la replicación de archivos entre todos los servidores como a la posibilidad de que los clientes operen enteramente a partir de sus cachés. Ambos métodos dependen del uso de una estrategia optimista para la detección de conflictos en la actualización en presencia de particiones en la red. Ambos mecanismos son complementarios e independientes. Por ejemplo, un usuario puede aprovechar los beneficios de la operación sin conexión incluso aunque los volúmenes de archivos requeridos estén almacenados en un único servidor.

Ejemplo: Considérese una secuencia de modificaciones a un archivo F en un volumen que está replicado en tres servidores: S_1 , S_2 y S_3 . El VSG para F es $\{S_1, S_2, S_3\}$. F es modificado, aproximadamente al mismo tiempo, por dos clientes: C_1 y C_2 . Debido a un fallo en la red, C_1 puede acceder sólo a S_1 y S_2 (el AVSG de C_1 es $\{S_1, S_2\}$) y C_2 puede acceder sólo a S_3 (el AVSG de C_2 es $\{S_3\}$).

1. Inicialmente, los CVV para F en los tres servidores son iguales, por ejemplo [1, 1, 1].
2. C_1 ejecuta un proceso que abre F , lo modifica y después lo cierra. El proceso Venus en C_1 difunde un mensaje de actualización a su AVSG, $\{S_1, S_2\}$, obteniendo al final una nueva versión de F y un CVV [2,2,1] en S_1 y S_2 , pero no en S_3 .
3. Mientras tanto, C_2 ejecuta dos procesos, cada uno de los cuales abre F , lo modifican y posteriormente lo cierran. El proceso Venus en C_2 difunde tras cada modificación un mensaje de actualización a su AVSG, $\{S_3\}$; al final, se obtiene una nueva versión de F y un CVV de [1,1,3] en S_3 .

4. Algun tiempo después, se repara el fallo en la red, y C_2 realiza un chequeo rutinario para comprobar si los miembros no accesibles de su VSG se han vuelto accesibles (más tarde se describirá el proceso mediante el cual se realizan estas comprobaciones) y descubre que S_1 y S_2 lo están. Modifica su AVSG a $\{S_1, S_2, S_3\}$ para el volumen que contiene a F y solicita los CVV para F por parte de todos los miembros del nuevo AVSG. Cuando los recibe, C_2 descubre que S_1 y S_2 cada uno tiene $[2,2,1]$ mientras que S_3 tiene $[1,1,3]$. Esto representa un *conflicto* que requiere una intervención manual para actualizar F , de tal forma que se minimice la pérdida de información de actualización.

Por otro lado, considérese un escenario parecido, pero más simple, que siga la misma secuencia de eventos que se acaba de describir, pero omitiendo el ítem (3), de tal forma que F no es modificado por C_2 . Por lo tanto, el CVV en S_3 no ha cambiado y sigue siendo $[1,1,1]$; cuando se repara la red, C_2 descubre que los CVVs en S_1 y S_2 ($[2,2,1]$) *dominan* al de S_3 . La versión del archivo en S_1 o en S_2 debería reemplazar la de S_3 .

◊ **Semántica de actualización.** Las garantías de vigencia ofrecidas por el sistema Coda cuando un cliente abre un archivo son más débiles que las de AFS, dada la estrategia de actualización optimista. El servidor único S al que se refieren las garantías de vigencia en AFS se reemplazan por un conjunto de servidores \bar{S} (el VSG del archivo), y el cliente C puede acceder a un subconjunto de servidores \bar{s} (el AVSG del archivo que puede ver C).

Dicho de manera informal, la garantía que ofrece un *open* con éxito en el sistema Coda consiste en proporcionar la copia más reciente de F por parte del actual AVSG y, en el caso en el que no haya servidores disponibles, se utiliza una copia local de F , si está disponible, almacenada en la memoria caché. Un *close* con éxito garantiza que el archivo ha sido propagado al conjunto de servidores actualmente accesibles o, en el caso de que no los hubiera, el archivo es marcado para que se propague a la menor oportunidad.

Se puede hacer una definición más precisa de estas garantías, teniendo en cuenta el efecto de las devoluciones de llamada perdidas, utilizando una extensión de la notación usada para AFS. En cada definición, excepto la última, hay dos casos: el primero, comenzando por $\bar{s} \neq \emptyset$, que se refiere a todas las situaciones en las cuales el AVSG no está vacío; y el segundo, que trata la operación sin conexión:

tras un *open* con éxito: $\bar{s} \neq \emptyset$ y $(\text{latest}(F, \bar{s}, 0)$
 o $(\text{latest}(F, \bar{s}, T) \text{ y } \text{lostCallback}(\bar{s}, T) \text{ y }$
 $\text{inCache}(F))$)

o $(\bar{s} = \emptyset \text{ y } \text{inCaché}(F))$

tras un *open* fallido: $\bar{s} \neq \emptyset$ y $\text{conflict}(F, \bar{s})$
 o $(\bar{s} = \emptyset \text{ y } \neg \text{inCaché}(F))$

tras un *close* con éxito: $\bar{s} \neq \emptyset$ y $\text{updated}(F, \bar{s})$
 o $(\bar{s} = \emptyset)$

tras un *close* fallido: $\bar{s} \neq \emptyset$ y $\text{conflict}(F, \bar{s})$

Este modelo asume que el sistema es síncrono: T es el mayor tiempo durante el cual un cliente puede permanecer sin estar advertido de una actualización en otra parte de un archivo que esté en su caché; $\text{latest}(F, \bar{s}, T)$ denota el hecho de que el valor actual de F en C fue el último entre todos los servidores en \bar{s} en algún instante dentro de los últimos T segundos y que no hubo conflictos

entre las copias de F hasta aquel instante; $\text{lostCallback}(\bar{s}, T)$ significa que se envió una devolución de llamada desde algún miembro de \bar{s} en los últimos T segundos y no fue recibida por C ; por último, $\text{conflict}(F, \bar{s})$ indica que los valores de F en algunos servidores de \bar{s} están en ese momento en conflicto.

◊ **Acceso a las réplicas.** La estrategia usada en *open* y *close* para acceder a las réplicas de un archivo es una variante de la aproximación *uno lee/todos escriben*. En *open*, si no hay una copia del archivo en la caché local el cliente identifica, para ese archivo, un servidor preferido dentro del AVSG. Dicho servidor preferido puede elegirse de forma aleatoria o basándose en criterios de rendimiento tales como la proximidad física o la carga del servidor. El cliente solicita al servidor preferido una copia de los atributos y el contenido del archivo, y cuando los recibe, contacta con el resto de los miembros del AVSG para verificar que dicha copia es la última versión disponible. Si no es así, uno de los miembros del AVSG con la última versión pasa a ser el sitio preferido, se vuelven a traer los contenidos del archivo y se notifica a los miembros del AVSG que algunos miembros poseen réplicas anticuadas. Cuando se ha terminado de traer los contenidos, se establece en el servidor preferido una promesa de devolución de llamada.

Cuando se cierra un archivo en un cliente tras una modificación, sus atributos y contenidos se transmiten en paralelo a todos los miembros del AVSG utilizando un protocolo de llamada a procedimiento remoto multidifundido. Esto maximiza la probabilidad de que cada sitio de replicación para un archivo tenga una versión actualizada en todo momento. Pero no lo garantiza, porque el AVSG no incluye, necesariamente, a todos los miembros de un VSG. Al mismo tiempo minimiza la carga en el servidor cediendo a los clientes la responsabilidad de propagar los cambios a los sitios de replicación en el caso normal (los servidores sólo se ven implicados cuando se descubre una réplica atrasada en una operación *open*).

Ya que el mantenimiento en todos los miembros de un AVSG del estado de devolución de llamada sería caro, la promesa de devolución de llamada se mantiene solamente en el servidor. Pero esto presenta un nuevo problema: el servidor preferido para un cliente no tiene que estar en el AVSG de otro cliente. Si es éste el caso, una actualización por parte del segundo cliente no ocasionará una devolución de llamada sobre el primer cliente. En la siguiente subsección se tratará la solución adoptada para este problema.

◊ **Coherencia caché.** Las garantías de vigencia del sistema Coda, expuestas anteriormente, implican que el proceso Venus en cada cliente debe detectar los siguientes eventos dentro de los T segundos siguientes a que hayan ocurrido:

- Aumento del tamaño de un AVSG (debido a que un servidor que antes estaba inaccesible se ha vuelto accesible).
- Reducción del tamaño de un AVSG (debido a que un servidor se vuelve inaccesible).
- Pérdida de un evento de devolución de llamada.

Para conseguir esto, Venus envía un mensaje de sondeo cada T segundos a todos los servidores en los VSG de los archivos que tiene en su memoria caché. Sólo se recibirán respuestas por parte de los servidores accesibles. Si Venus recibe una respuesta de un servidor previamente inaccesible aumenta de tamaño su correspondiente AVSG y retira las promesas de volver a llamar de cualquier archivo que esté manteniendo del volumen en cuestión. Esto se hace debido a que la copia en la memoria caché puede que ya no sea la última versión disponible en el nuevo AVSG.

Si no recibe una respuesta por parte de un servidor previamente accesible, Venus reduce el tamaño del correspondiente AVSG. No se requieren cambios en las promesas de devolución de llamada a no ser que la reducción esté causada por la pérdida de un servidor preferido, en cuyo caso se retiran de ese servidor todas las promesas de devolución de llamada. Si una de las respuestas indica que un mensaje de devolución de llamada fue enviado pero no recibido, se retira la promesa de devolución de llamada asociada al archivo correspondiente.

Resta abordar el problema mencionado anteriormente, de actualizaciones perdidas por un servido

Resta abordar el problema mencionado anteriormente, de actualizaciones perdidas por un servidor porque no está en el AVSG de otro cliente que realiza una actualización. Para tratar este caso,

rencia equivalente a cinco usuarios típicos sobrepasa sólo en un 5 % la del AFS sin replicación. Sin embargo, con la triple replicación y una carga equivalente a 50 usuarios, el tiempo necesario para completar la carga de referencia se incrementa hasta un 70 %, mientras que el incremento para el AFS sin replicación es de sólo un 16 %. Esta diferencia se atribuye sólo en parte a los costes operacionales asociados con la replicación (se dice que las diferencias en la sintonización de la implementación explican parte de las diferencias en el rendimiento).

◊ **Discusión.** Anteriormente se apuntó que Coda es similar a Bayou en que también emplea una aproximación optimista para obtener una alta disponibilidad (aunque difieren en otras cosas, siendo una de las más importantes que uno gestiona archivos y el otro bases de datos). Hemos descrito también cómo Coda utiliza los CVV para comprobar la existencia de conflictos, sin tener en cuenta la semántica de los datos archivados en los archivos. La aproximación puede detectar conflictos potenciales *escritura-escritura* pero no conflictos *lectura-escritura*. Éstos son conflictos *potenciales escritura-escritura* porque al nivel de la semántica de la aplicación podría no haber conflictos reales: los clientes podrían haber actualizado diferentes objetos en el archivo de un modo compatible y sería posible realizar una fusión automática simple.

La aproximación global de Coda a la detección de conflictos independientes de la semántica y su resolución manual es sensata en muchos casos, especialmente en aplicaciones que requieran del juicio humano o en sistemas donde no hay conocimiento de la semántica de los datos.

Los directorios son un caso especial en Coda. Algunas veces es posible mantener automáticamente la integridad de esos objetos clave a través de la resolución de los conflictos, ya que sus semánticas son relativamente simples. Los únicos cambios que pueden hacerse en los directorios son la inserción o supresión de entradas en el directorio. Coda incorpora su propio método para solucionar el caso de los directorios. Tiene el mismo efecto que la aproximación de transformación operacional de Bayou, pero Coda fusiona el estado de los directorios en conflicto directamente, ya que no tiene un registro histórico de las operaciones que han efectuado los clientes.

14.5. TRANSACCIONES CON DATOS REPLICADOS

Hasta el momento, en este capítulo se han considerado sistemas en los cuales los clientes solicitan, de cada vez, operaciones individuales sobre conjuntos de objetos replicados. Los Capítulos 12 y 13 explicaban que las transacciones son *secuencias* de una o más operaciones, aplicadas de tal manera que se respetan las propiedades ACID. Al igual que con los sistemas de la Sección 14.4, los objetos en los sistemas transaccionales podrían replicarse para incrementar tanto su disponibilidad como su rendimiento.

Desde el punto de vista de un cliente, una transacción sobre objetos replicados debería parecer idéntica a una con objetos no replicados. En un sistema sin replicación las transacciones parecen que se realizan, una de cada vez, siguiendo algún orden. Esto se consigue asegurando un entrelazado secuencial equivalente de las transacciones de los clientes. El efecto de las transacciones realizadas por los clientes sobre objetos replicados debería ser el mismo que si se hubiesen realizado una por una sobre un único conjunto de objetos. A esta propiedad se la denomina *secuenciabilidad de una copia*. Es similar a la consistencia secuencial, pero no hay que confundirlas. La consistencia secuencial considera ejecuciones válidas sin ninguna noción de agregar las operaciones del cliente como transacciones.

Cada gestor de réplicas proporciona control de concurrencia y capacidad de recuperación de sus propios objetos. En esta sección, se asumirá que se utiliza bloqueo en dos etapas para el control de concurrencia.

La recuperación se complica por el hecho de que un gestor de réplicas fallido es un miembro de una colección y que los otros miembros continúan proporcionando el servicio durante el tiempo

que aquél no está disponible. Cuando un gestor de réplicas se recupera de un fallo, utiliza la información que obtiene de los otros gestores de réplicas para restaurar sus propios objetos a sus valores actuales, teniendo en cuenta todos los cambios que han ocurrido durante el tiempo que no estuvo disponible.

En esta sección se presenta primero la arquitectura para realizar transacciones con datos replicados. Las preguntas que atañen a la estructura son: si la petición de un cliente puede enviarse a cualquiera de los gestores de réplicas, cuántos gestores de réplicas se necesitan para que se complete una operación de forma satisfactoria, si un gestor de réplicas con el que contacte un cliente puede aplazar el paso de peticiones hasta que se consume una transacción y cómo llevar a cabo un protocolo de consumación en dos fases.

La implementación de la secuenciabilidad de *una copia* se ilustra mediante *uno lee/todos escriben* (que es un esquema simple de replicación en el cual las operaciones *lee* son realizadas por un único gestor de réplicas y las operaciones *escribe* son realizadas por todos los gestores).

A continuación, en la sección se discuten los problemas de implementar esquemas de replicación cuando hay servidores que se caen y se recuperan. Se introduce la replicación de copias disponibles, una variante del esquema de replicación *uno lee/todos escriben* en el que las operaciones *lee* son realizadas por un único gestor de réplicas y las operaciones *escribe* son realizadas por todos aquellos gestores que están disponibles.

Finalmente, la sección presenta tres esquemas de replicación que funcionan correctamente cuando la colección de gestores de réplicas se divide en subgrupos a causa de una partición en la red:

- *Copias disponibles con validación*: la replicación de copias disponibles se aplica en cada partición y cuando ésta se repara, se aplica un procedimiento de validación y se trata cualquier inconsistencia.
- *Consenso con quórum*: un subgrupo debe tener un quórum (lo que significa que tiene suficientes miembros) para que se le permita continuar proporcionando un servicio cuando se produce una partición. Cuando ésta es reparada, y cuando un gestor de réplicas se reinicia tras un fallo, los gestores de réplicas consiguen actualizar sus objetos por medio de procedimientos de recuperación.
- *Partición virtual*: una combinación de consenso con quórum y copias disponibles. Si una partición virtual tiene quórum puede usar replicación de las copias disponibles.

14.5.1. ARQUITECTURAS PARA TRANSACCIONES REPLICADAS

Al igual que con la serie de sistemas que ya se han considerado en secciones anteriores, un frontal podría tanto multidifundir las peticiones de un cliente a grupos de gestores de réplicas o bien podría enviar cada petición a un gestor de réplicas individual, el cual es entonces responsable del procesamiento de la petición y de la respuesta al cliente. Wiesmann y otros [2000] y Schiper y Raynal [1996] consideran el caso de peticiones por multidifusión que no se tratará aquí. A partir de aquí, se asumirá que un frontal envía las peticiones de un cliente a un gestor del grupo de gestores de réplicas de un objeto lógico. En la aproximación mediante *copia primaria*, todos los frontales se comunican con un gestor de réplicas distinguido como *primario* para realizar una operación; ese gestor de réplicas mantiene actualizadas las copias de respaldo. De forma alternativa, los frontales podrían comunicarse con cualquier gestor de réplicas para realizar una operación, pero en ese caso la coordinación entre los gestores de réplicas es, en consecuencia, más compleja.

El gestor de réplicas que recibe una petición para realizar una operación sobre un objeto concreto es responsable de conseguir la cooperación de otros gestores de réplicas en el grupo que tienen copias de ese objeto. Los diferentes esquemas de replicación tienen reglas distintas relativas

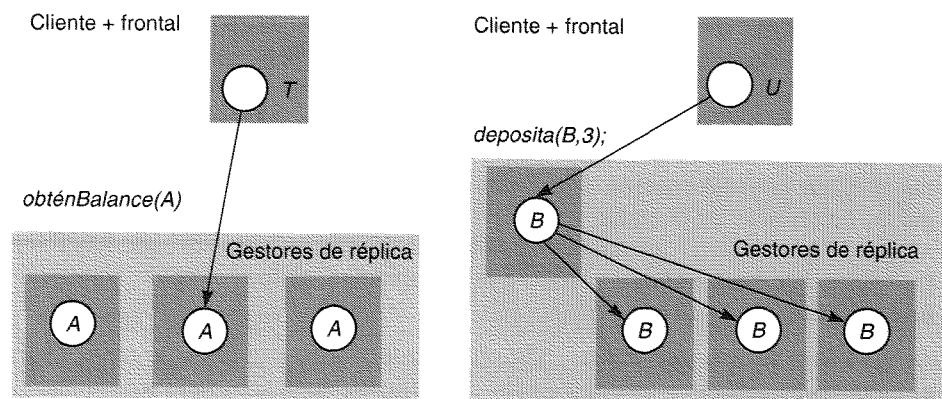


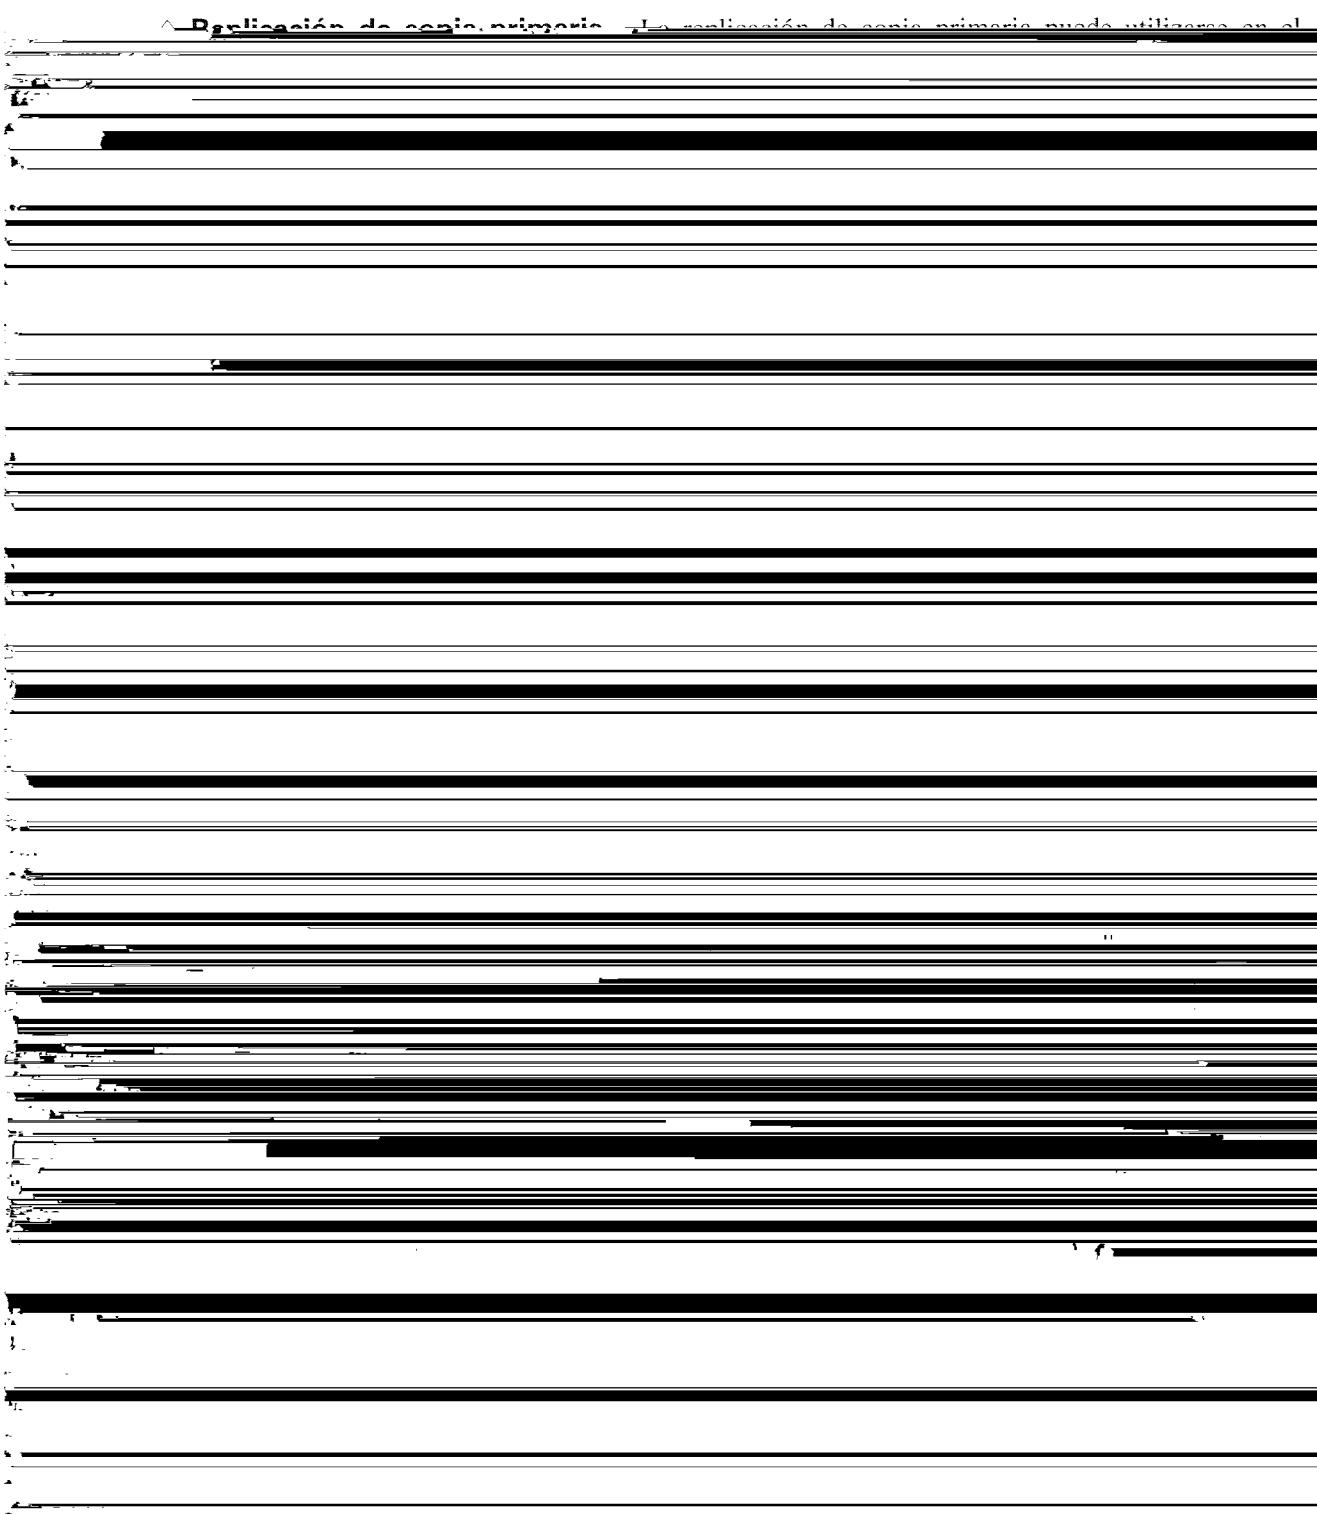
Figura 14.10. Transacciones sobre datos replicados.

a cuántos gestores de réplicas de un grupo son necesarios para completar con éxito una operación. Por ejemplo, en el esquema *uno lee/todos escriben*, una petición *lee* puede ser realizada por un único gestor de réplicas, mientras que una petición *escribe* debe ser llevada a cabo por todos los gestores de réplicas en el grupo, como se muestra en la Figura 14.10 (puede haber diferentes números de réplicas de los distintos objetos). Los esquemas de consenso con quórum se diseñan para reducir el número de gestores de réplicas que deben realizar operaciones de actualización, pero a cambio incrementan el número de gestores de réplicas requeridos para realizar las operaciones de *sólo lectura*.

Otro asunto a tratar es si el gestor de réplicas contactado por un frontal debería aplazar el paso de peticiones de actualización a otros gestores de réplica dentro del grupo hasta que la transacción se haya consumido (conocida como *aproximación perezosa* a la propagación de actualizaciones); o, por el contrario, si los gestores de réplicas deberían enviar cada petición de actualización a todos los gestores de réplicas necesarios dentro de la transacción antes de consumarla (lo que se conoce como la *aproximación ansiosa* o *acuciante*). La *aproximación perezosa* es una alternativa atractiva ya que reduce la cantidad de comunicación entre los gestores de réplicas que tiene lugar antes de responder al cliente que está haciendo la actualización. Sin embargo, también hay que considerar el control de concurrencia. Algunas veces, la *aproximación perezosa* se utiliza con la replicación de copia primaria (véase más adelante), donde un único gestor de réplicas primario secuencia las transacciones. No obstante, si varias transacciones distintas pueden intentar acceder a los mismos objetos en distintos gestores de réplicas dentro de un grupo entonces, para asegurar que las transacciones son secuenciadas correctamente en todos los gestores de réplicas del grupo, cada gestor de réplicas necesita conocer las peticiones atendidas por los otros. En este caso, la *aproximación ansiosa* es la única viable.

◊ **Protocolo de consumación en dos fases.** Este protocolo se convierte en un protocolo de consumación en dos fases anidado en dos niveles. Al igual que antes, el coordinador de una transacción se comunica con los trabajadores. Pero, si bien el coordinador o uno de los trabajadores es un gestor de réplicas, se comunicará con los otros gestores de réplicas a los cuales les pasó peticiones durante la transacción.

Esto es, en la primera fase, el coordinador envía el mensaje *puedoConsumir?* a los trabajadores, que lo pasan a los otros gestores de réplicas y recogen sus respuestas antes de responder al coordinador. En la segunda fase, el coordinador envía la solicitud *Consuma* o *Aborta*, que se pasa a los miembros de los grupos de los gestores de réplicas.



◇ **Replicación de copia primaria.** La replicación de copia primaria puede utilizarse en el

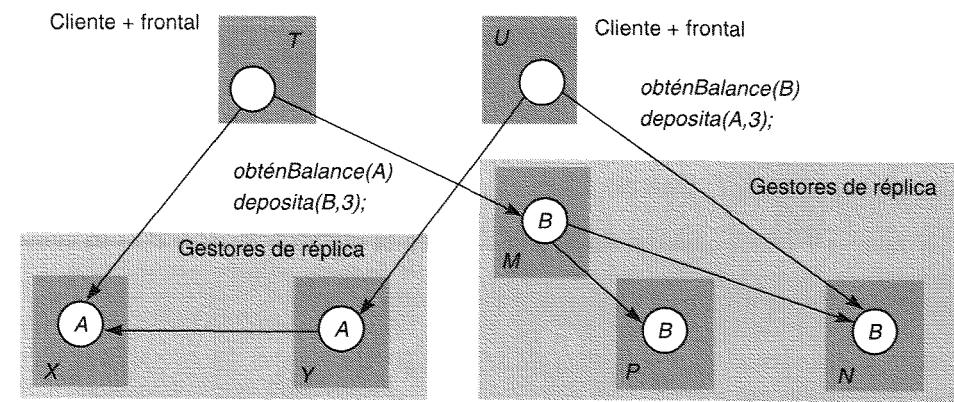


Figura 14.11. Copias disponibles.

recupera el estado consumido de los objetos desde un archivo de recuperación. Los frontales utilizan timeouts para decidir que un gestor de réplicas no está actualmente disponible. Cuando un cliente hace una petición a un gestor de réplicas que se ha caído, el frontal contempla un timeout y reintenta la petición en otro gestor de réplicas del grupo. Si la petición es recibida por un gestor de réplicas en el cual el objeto está desfasado porque el gestor de réplicas no se ha recuperado totalmente de un fallo, éste rechaza la petición y el frontal reintenta la petición en otro gestor de réplicas del grupo.

La secuenciabilidad de *una copia* requiere que las caídas y recuperaciones sean secuenciadas con respecto a las transacciones. Una transacción observa que ha ocurrido un fallo una vez que ha finalizado o antes de que comience, en función de si puede acceder a un objeto o no. La secuenciabilidad de *una copia* no se consigue cuando transacciones distintas realizan observaciones sobre fallos que entran en conflicto.

Considérese el caso de la Figura 14.11, donde el gestor de réplicas X falla justo después de que la transacción T haya realizado la operación *obténBalance*, y el gestor de réplicas N falla justo después de que U haya realizado la misma operación. Supóngase que ambos gestores de réplicas fallan antes de que T y U hayan realizado las operaciones de *deposita*. Esto implica que el *deposita* de T se realizará desde los gestores de réplicas M y P, y que el *deposita* de U será realizado en el gestor de réplicas Y. Desafortunadamente, el control de concurrencia sobre A en el gestor de réplicas X no evita que la transacción U actualice A en el gestor de réplicas Y. Ni el control de concurrencia sobre B en el gestor de réplicas N evita que la transacción T actualice B en los gestores de réplicas M y P.

Esto va en contra del requisito de secuenciabilidad de *una copia*. Si estas operaciones tuviesen que ser realizadas sobre copias individuales de los objetos, podrían ponerse en serie bien como la transacción T antes que la U o como la transacción U antes que la T. Esto aseguraría que una de las transacciones leerá el valor fijado por la otra. El control de concurrencia local sobre copias de objetos no es suficiente para asegurar la secuenciabilidad de *una copia* en el esquema de replicación de copias disponibles.

Ya que las operaciones *escribe* se dirigen a todas las copias disponibles, el control de concurrencia local asegura que las escrituras que entran en conflicto sobre un conjunto están secuenciadas. Por el contrario, una operación *lee* por parte de una transacción y una *escribe* por parte de otra pueden no afectar necesariamente a la misma copia de un objeto. Por lo tanto, el esquema requiere control de concurrencia adicional para evitar las dependencias que formen un ciclo, entre una operación *lee* en una transacción y una operación *escribe* de otra. Tales dependencias no pueden surgir si los fallos y las recuperaciones de las réplicas de objetos se secuencian con respecto a las transacciones.

◊ **Validación local.** El procedimiento adicional de control de concurrencia se conoce como validación local. El procedimiento de validación local se diseña para asegurar que no parezca ocurrir ningún evento asociado a un fallo o a una recuperación durante el desarrollo de una transacción. En nuestro ejemplo, ya que T ha leído de un objeto en X , el fallo en X debe ocurrir tras T . De forma similar, ya que T observa el fallo de N cuando intenta actualizar el objeto, el fallo de N debe producirse antes que T . Esto es:

N falla $\rightarrow T$ lee el objeto A en X ; T escribe en el objeto B en M y $P \rightarrow$ se consuma $T \rightarrow X$ falla

También se puede argumentar para la transacción U que:

X falla $\rightarrow U$ lee el objeto B en N ; U escribe en el objeto A en $Y \rightarrow$ se consuma $U \rightarrow N$ falla

El procedimiento de validación local asegura que no pueden ocurrir secuencias incompatibles tales. Antes de que se consume una transacción se comprueba cualquier fallo (y recuperación) de gestores de réplicas de objetos a los que ha accedido. En el ejemplo, la transacción T comprobaría que N está aún indisponible y que X, M y P están todavía disponibles. Si fuese ése el caso, puede consumarse T . Esto implica que X falla tras ser validado por T y antes de ser validado U . Dicho de otra forma, la validación de U ocurre tras la validación de T . La validación de U falla porque N ya ha fallado.

En el momento en que una transacción ha observado un fallo, el procedimiento de validación local intenta comunicarse con los gestores de réplicas fallidos para asegurarse de que no se han recuperado. La otra parte de la validación local, que está comprobando que los gestores de réplicas no han fallado mientras se accedía a los objetos, puede combinarse con el protocolo de consumo en dos fases.

Los algoritmos para copias disponibles no pueden utilizarse en entornos en los cuales los gestores de réplicas que están operando son incapaces de comunicarse entre ellos.

14.5.3. PARTICIONES EN LA RED

Los esquemas de replicación han de tener en cuenta la posibilidad de que se produzcan particiones en la red. Una partición en la red separa un grupo de gestores de réplicas en dos o más subgrupos, de tal forma que los miembros de cada subgrupo pueden comunicarse entre ellos, pero los miembros de distintos subgrupos no pueden comunicarse. Por ejemplo, en la Figura 14.12 los gestores de réplicas que reciben la petición *deposita* no pueden enviarla a los gestores de réplicas que reciben la petición *extrae*.

Los esquemas de replicación se diseñan bajo la suposición de que las particiones serán finalmente reparadas. Por lo tanto, los gestores de réplicas dentro de una partición individual deben asegurarse de que cualesquier peticiones que ejecuten durante una partición no harán inconsistentes al conjunto de réplicas cuando se repare la partición.

Davidson y otros [1985] discuten muchas aproximaciones distintas, que categorizan bien como optimistas o bien como pesimistas en lo que respecta a la probabilidad de que ocurran inconsistencias. Los esquemas optimistas no limitan la disponibilidad durante una partición, mientras que los esquemas pesimistas sí que lo hacen.

Los esquemas optimistas permiten las actualizaciones en todas las particiones, lo que puede llevar a inconsistencias entre particiones, que han de resolverse cuando se repare la partición. Un ejemplo de esta aproximación es una variante del algoritmo de copias disponibles en el cual se permiten las actualizaciones dentro de las particiones y, una vez que la partición haya sido reparada, se validan dichas actualizaciones (se aborta cualquier actualización que rompa el criterio de capacidad de secuenciación para *una copia*).

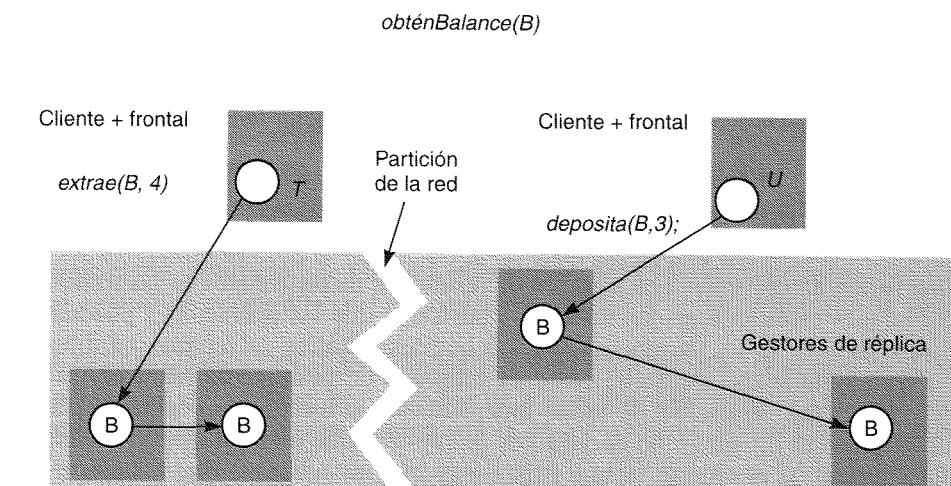


Figura 14.12. Partición de la red.

La aproximación pesimista limita la disponibilidad incluso cuando no hay particiones, pero evita las inconsistencias que ocurren mientras hay particiones. Cuando se repara la partición, todo lo que se necesita hacer es actualizar las copias de los objetos. La aproximación de consenso con quórum es pesimista. Permite actualizaciones en una partición que tenga la mayoría de sus gestores de réplicas y propaga las actualizaciones a los otros gestores de réplicas cuando se repara la partición.

14.5.4. COPIAS DISPONIBLES CON VALIDACIÓN

El algoritmo de copias disponibles se aplica dentro de cada partición. Esta aproximación optimista mantiene el nivel normal de disponibilidad para las operaciones *lee*, incluso durante las particiones. Cuando ésta se repara, se validan las transacciones que pudiesen estar en conflicto y que tuvieron lugar dentro de las particiones separadas. Si falla la validación, deben darse algunos pasos para salvar las inconsistencias. Si no hubiese habido partición, se retrasaría o abortaría una de las transacciones de un par que haya entrado en conflicto. Desafortunadamente, como hubo una partición, al par de transacciones en conflicto se les ha permitido consumirse en particiones diferentes. La única elección posible tras este suceso es que se aborde una de ellas. Esto requiere hacer cambios en los objetos y, en algunos casos, compensar sus efectos en el mundo real, como por ejemplo gestionar descubiertos en cuentas bancarias. La aproximación optimista sólo es factible en aplicaciones donde pueden realizarse dichas acciones compensatorias.

Se pueden utilizar vectores de versiones para validar conflictos entre pares de operaciones *escribe*. Dichos vectores se usan en el sistema de archivos Coda y se describen en la Sección 14.4.3. La aproximación no puede detectar conflictos de lectura-escritura pero funcionan bien en los sistemas de archivos, donde las transacciones tienden a acceder a un único archivo y los conflictos de lectura-escritura no son importantes. No es adecuada para las aplicaciones tales como el ejemplo del banco que se comentó antes, donde sí que son importantes dichos conflictos.

Davidson [1984] utilizó los *grafos de precedencia* para detectar inconsistencias entre particiones. Cada partición mantiene un registro histórico de los objetos afectados por las operaciones *lee* y *escribe* de las transacciones. Este registro se utiliza para construir un grafo de precedencia cuyos nodos son las transacciones y cuyos arcos representan los conflictos entre las operaciones *lee* y

se establezca un quórum. Las actualizaciones especificadas en la operación *escribe* son entonces aplicadas por cada gestor de réplicas en el quórum de escritura, se incrementa el número de versión y se informa al cliente de la finalización de la escritura.

Los archivos en los restantes gestores de réplicas disponibles se actualizan a continuación realizando la operación *escribe* como una tarea en segundo plano. Cualquier gestor de réplicas, cuya copia del archivo tenga un número de versión más antiguo que el usado por el quórum de escritura, actualizará dicha copia reemplazando el archivo completo por una obtenida de un gestor de réplicas actualizado.

En el esquema de replicación de Gifford, puede utilizarse el bloqueo de lectura/escritura en dos fases para el control de concurrencia. La indagación preliminar sobre el número de versión que se hace para obtener el quórum de lectura, L , provoca que se establezcan bloqueos de lectura en cada gestor de réplicas contactado. Cuando se aplica una operación *escribe* al quórum de escritura, E , se establece un bloqueo de escritura en cada uno de los gestores de réplicas involucrados (los bloqueos se aplican con la misma granularidad que la de los números de versión). Los bloqueos aseguran la secuenciabilidad de *una copia* ya que cualquier quórum de lectura se solapa con algún quórum de escritura y dos quórum de escritura cualesquiera se solaparán.

◊ **Configurabilidad de los grupos de gestores de réplicas.** Una propiedad importante del algoritmo de votación ponderada es que los grupos de gestores de réplicas puedan ser configurados para proporcionar características distintas de rendimiento y fiabilidad. Una vez que se establece la fiabilidad y el rendimiento generales de un grupo de gestores de réplicas mediante su configuración de votos, la fiabilidad y el rendimiento de las operaciones *escribe* pueden aumentarse disminuyendo E y, de forma similar, disminuyendo L para las operaciones de *lee*.

El algoritmo puede, además, permitir la utilización de copias de archivos en los servidores o en discos locales en los computadores de los clientes. Estas copias locales se consideran como *representantes débiles* y se les asignan cero votos. Esto asegura que no se les incluirá en ningún quórum. Una operación *lee* puede realizarse en cualquier copia actualizada una vez que se ha obtenido un quórum de lectura. En consecuencia, puede llevarse a cabo una operación *lee* en la copia local del archivo si ésta está al día. Los representantes débiles pueden utilizarse para acelerar las operaciones *lee*.

◊ **Un ejemplo del trabajo de Gifford.** Gifford proporciona tres ejemplos que muestran el abanico de propiedades que pueden conseguirse asignando pesos a los distintos gestores de réplicas en un grupo y asignando L y E de forma apropiada. A continuación se reproducen los ejemplos de Gifford, que se basan en la tabla próxima. Las probabilidades de bloqueo dan una indicación de la probabilidad de que no pueda obtenerse un quórum cuando se realiza una petición *lee* o *escribe*. Se calculan suponiendo que hay una probabilidad de 0,01 de que cualquier gestor de réplicas no se encuentre disponible en el momento de la petición.

El ejemplo 1 está configurado para un archivo con una tasa alta de *lectura/escritura* en una aplicación con distintos representantes débiles y un único gestor de réplicas. La replicación se utiliza para mejorar el rendimiento del sistema, no su fiabilidad. Existe en la red local un gestor de réplicas al que se puede acceder en 75 milisegundos. Dos clientes han decidido tener representantes débiles en sus discos locales, a los que pueden acceder en 65 milisegundos, produciendo una menor latencia y menor tráfico en la red.

El ejemplo 2 está configurado para un archivo con una tasa moderada de *lectura/escritura*, al que se accede fundamentalmente desde una red local. Al gestor de réplicas en la red local se le asignan dos votos y a los gestores de réplicas en las redes remotas se les asigna un voto a cada uno. Las lecturas pueden satisfacerse utilizando sólo el gestor de réplicas local, pero las escrituras deben acceder al gestor de réplicas local y a uno de los gestores de réplicas remotos. El archivo permanecerá disponible en el modo de *sólo lectura* si falla el gestor de réplicas local. Los clientes podrían crear representantes débiles para tener una menor latencia en las lecturas.

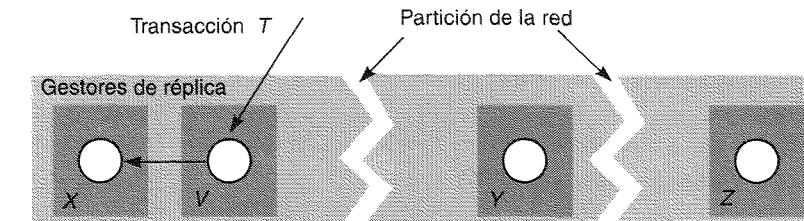
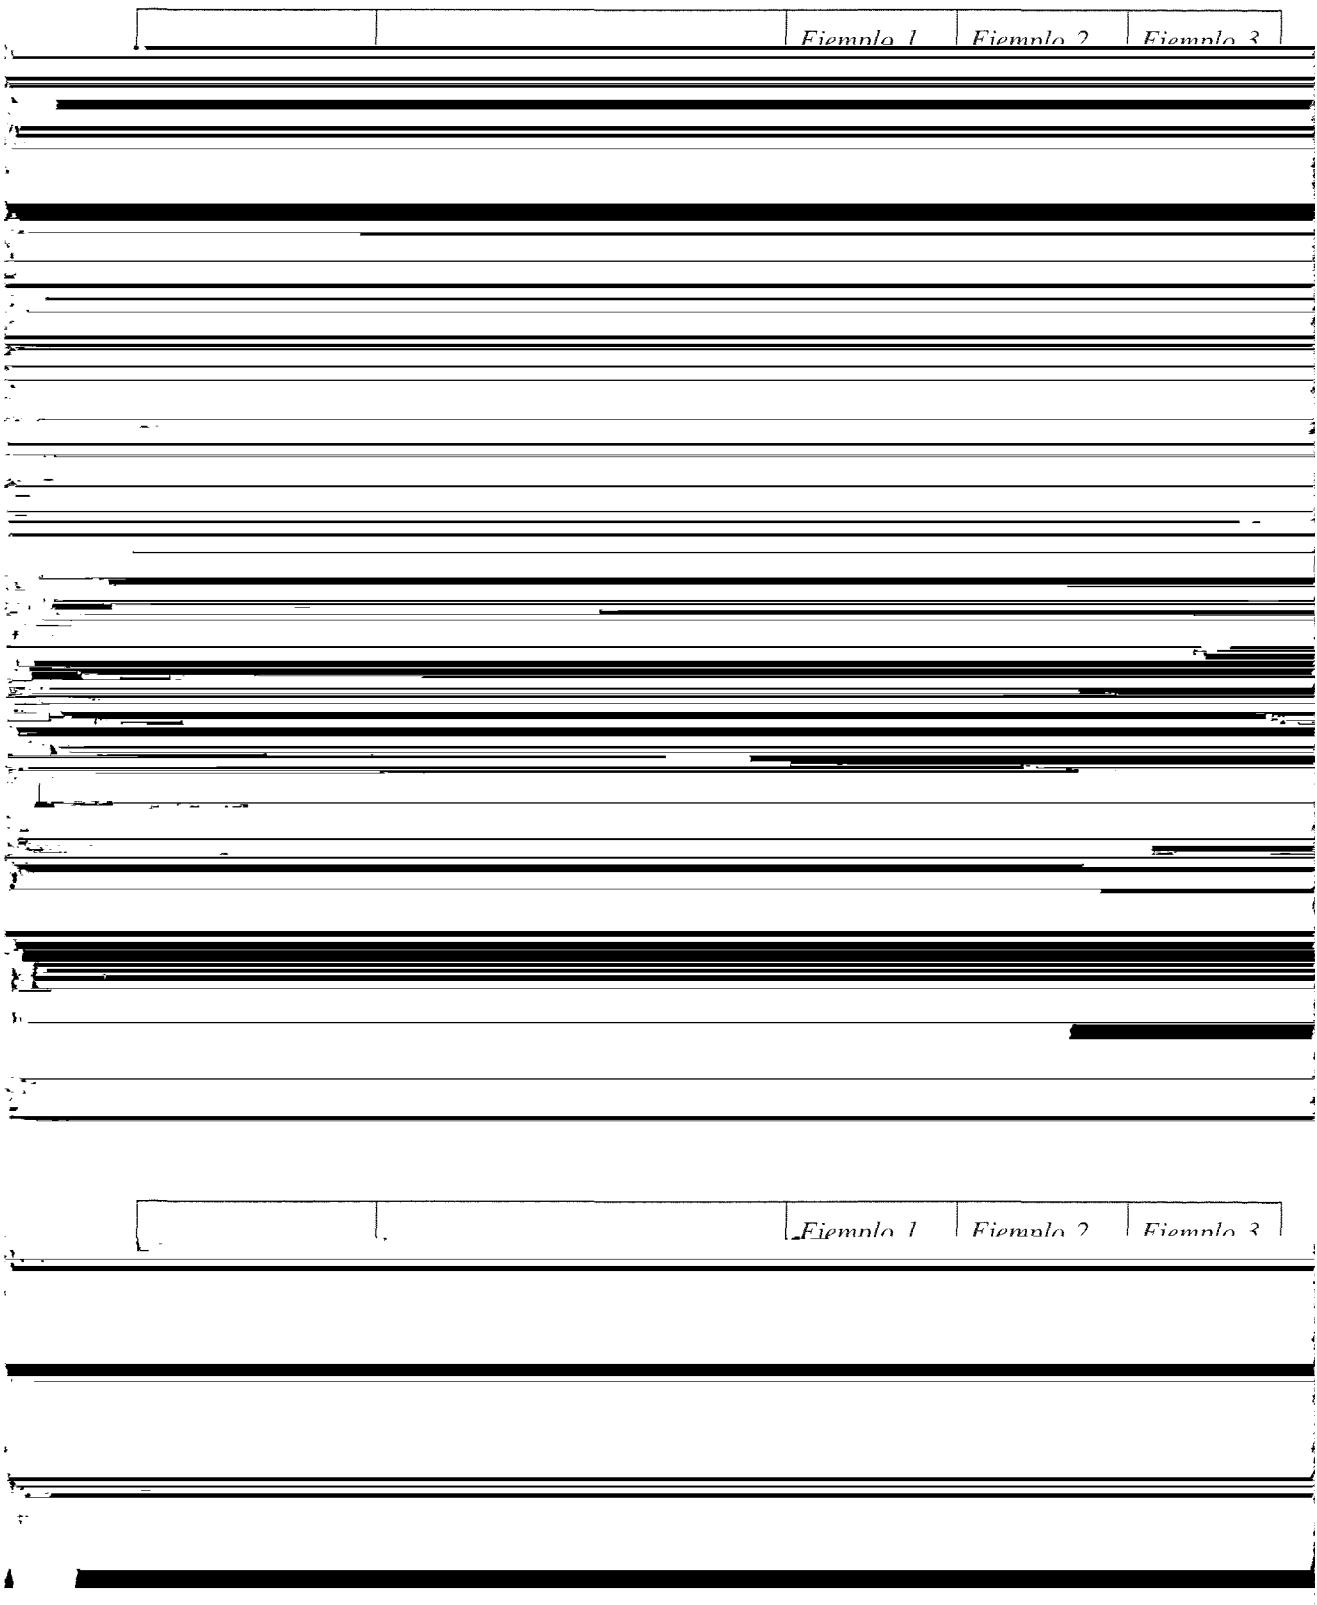


Figura 14.13. Dos particiones en la red.

particiones virtuales son similares a las vistas de grupo, que se presentaron en la Sección 14.2.2. Una transacción puede operar en una partición virtual si contiene suficientes gestores de réplicas para tener un quórum de lectura y un quórum de escritura para los objetos a los que accede. En este caso, la transacción utiliza el algoritmo de copias disponibles. Éste tiene la ventaja de que las operaciones de *lee* siempre necesitan acceder solamente a una copia individual de un objeto y puede mejorar el rendimiento eligiendo la copia *más cercana*. Si un gestor de réplicas falla y la partición virtual cambia a lo largo de una transacción, dicha transacción aborta. Esto asegura la secuenciabilidad de *una copia* porque todas las transacciones que sobreviven son capaces de observar en el mismo orden los fallos y las recuperaciones de los gestores de réplicas.

Cuandoquiera que un miembro de una partición virtual detecta que no puede acceder a uno de los otros miembros (por ejemplo, cuando no reciben acuse de recibo de una operación *escribe*), intenta crear una nueva partición virtual con una vista para obtener una partición virtual con quórum de lectura y escritura.

Supongamos, por ejemplo, que se tienen cuatro gestores de réplicas *V*, *X*, *Y* y *Z*, cada uno de los cuales tiene un voto, y que los quórum de lectura y escritura son $L = 2$ y $E = 3$. Inicialmente, todos los gestores pueden contactar unos con otros. Mientras se mantengan en contacto, pueden usar el algoritmo de las copias disponibles. Por ejemplo, una transacción *T* que consta de una operación *lee* seguida de *escribe* efectuará *lee* en un único gestor de réplicas (por ejemplo, *V*) y la operación de *escribe* en los cuatro.

Supóngase que la transacción *T* comienza realizando su *lee* en *V* en un instante en el que *V* está todavía en contacto con *X*, *Y* y *Z*. Ahora, supóngase que se produce una partición en la red, como en la Figura 14.13, en la cual *V* y *X* están en una parte e *Y* y *Z* están en otra diferente. Entonces, cuando la transacción *T* intenta aplicar su *escribe*, *V* se dará cuenta de que no puede contactar con *Y* y *Z*.

Cuando un gestor de réplicas no puede contactar con otros gestores con los que previamente podía contactar, sigue intentándolo hasta que puede crear una nueva partición virtual. Por ejemplo, *V* seguirá intentando contactar con *Y* y *Z* hasta que una o ambas contesten, como por ejemplo en la Figura 14.14 cuando se puede acceder a *Y*. El grupo de gestores de réplicas *V*, *X* e *Y* conforman una partición virtual, ya que son suficientes para formar quórum de lectura y escritura.

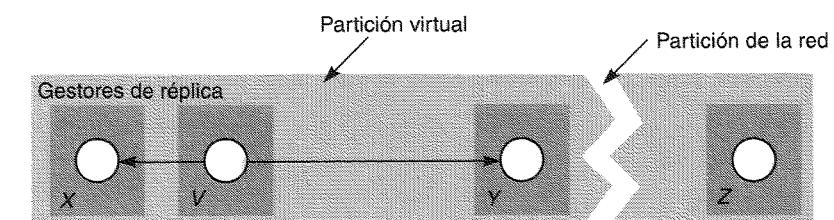


Figura 14.14. Partición virtual.

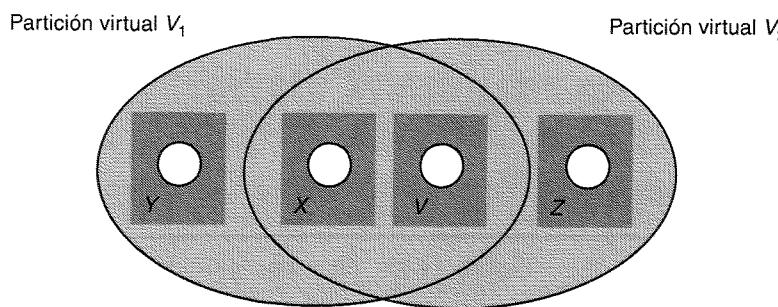


Figura 14.15. Dos particiones virtuales que se solapan.

Cuando se crea una nueva partición virtual durante una transacción que ha realizado una operación en uno de los gestores de réplicas (como la transacción T), la transacción debe ser abortada. Además, las réplicas dentro de una nueva partición virtual deben actualizarse copiándolas desde otras réplicas. Los números de versión pueden utilizarse como en el algoritmo de Gifford para determinar qué copias están actualizadas. Es esencial que todas las réplicas estén actualizadas porque las operaciones de *lee* se realizan en cualquier réplica individual.

◊ **Implementación de las particiones virtuales.** Una partición virtual tiene un tiempo de creación, un conjunto de miembros potenciales y un conjunto de miembros reales. Los tiempos de creación son marcas temporales lógicas. Los miembros reales de una partición virtual en particular comparten la misma idea en lo que se refiere a su tiempo de creación y a su pertenencia (una *vista* compartida de los gestores de réplicas con los cuales se pueden comunicar). Por ejemplo, en la Figura 14.14 los miembros potenciales son V, X, Y, Z y los miembros reales son V, X e Y .

La creación de una nueva partición virtual se consigue mediante un protocolo cooperativo efectuado por aquellos miembros potenciales accesibles por los gestores de réplicas que lo iniciaron. Varios gestores de réplicas pueden intentar crear una nueva partición virtual simultáneamente. Por ejemplo, supóngase que los gestores de réplicas Y y Z , que se muestran en la Figura 14.13, continúan haciendo intentos de contactar con los otros, y pasado un rato se repara parcialmente la partición de la red, de tal modo que Y no puede comunicarse con Z , pero los dos grupos V, X, Y y V, X, Z pueden comunicarse entre ellos. Entonces, existe el riesgo de que pudieran crearse dos particiones virtuales solapadas, tales como V_1 y V_2 que se muestran en la Figura 14.15.

Considérese el efecto de ejecutar diferentes transacciones en dos particiones virtuales. La operación *lee* de la transacción en V, X, Y podría aplicarse en el gestor de réplicas Y , en cuyo caso su bloqueo de lectura no entrará en conflicto con bloqueos de lectura fijados por una operación *escribir* por parte de una transacción en la otra partición virtual. Las particiones virtuales solapadas van en contra de la secuenciabilidad de *una copia*.

La intención del protocolo es crear nuevas particiones virtuales de modo consistente, incluso si se producen particiones reales durante la ejecución del protocolo. El protocolo de creación de nuevas particiones virtuales tiene dos fases, como se muestra en la Figura 14.16.

Un gestor de réplica que contesta *Sí* en la Fase 1 no pertenece a una partición virtual hasta que reciba el correspondiente mensaje de *Confirmación* en la Fase 2.

En nuestro ejemplo anterior, los gestores de réplicas Y y Z que se muestran en el Figura 14.13 intentan crear, cada uno, una partición virtual, y el que tenga la marca temporal lógica más grande será el que al final lo consiga.

Éste es un método eficaz cuando no se producen particiones habitualmente. Cada transacción utiliza el algoritmo de copias disponibles dentro de una partición virtual.

Fase 1:

- El iniciador manda una petición *Unirse* a cada miembro potencial. El argumento de *Unirse* es una marca temporal lógica propuesta para la nueva partición virtual.
- Cuando un gestor de réplicas recibe una petición de *Unirse* compara la marca temporal lógica propuesta con la de su partición virtual actual.
 - Si la marca temporal lógica propuesta es mayor accede a la unión y contesta *Sí*.
 - Si es menor, rechaza la unión y contesta *No*.

Fase 2:

- Si el iniciador ha recibido el número suficiente de respuestas *Sí* como para tener quórum para *escritura* y de *lectura*, puede completar la creación de la nueva partición virtual enviando mensajes de *Confirmación* a los sitios que acceden a unirse. Se envían como argumentos la marca temporal de creación y la lista de los miembros actuales.
- Los gestores de réplicas que reciben el mensaje de *Confirmación* se unen a la nueva partición virtual y graban su marca temporal de creación y la lista de los miembros actuales.

Figura 14.16. Creación de una partición virtual.

14.6. RESUMEN

La replicación de objetos es un medio importante de conseguir servicios con buen rendimiento, alta disponibilidad y tolerancia a fallos en sistemas distribuidos. Se han descrito arquitecturas para servicios en los cuales los gestores de réplicas almacenan las réplicas de los objetos, y en los cuales los frontales hacen transparente la replicación. Los clientes, frontales y los gestores de réplicas pueden ser procesos separados o residir en el mismo espacio de direcciones.

El capítulo comenzó describiendo un modelo de sistema en el cual cada objeto lógico se implementa por medio de un conjunto de réplicas físicas. Frecuentemente, las actualizaciones de estas réplicas pueden realizarse de forma apropiada mediante la comunicación en grupo. Se extendió el concepto de comunicación en grupo para incluir los servicios de pertenencia a grupo y la comunicación mediante vistas síncronas.

Se definieron la linealizabilidad y la consistencia secuencial como criterios de corrección para los servicios tolerantes a fallos. Estos criterios expresan cómo los servicios han de proporcionar el equivalente a una única imagen del conjunto de objetos lógicos, incluso cuando dichos objetos se replican. El criterio con más significado práctico es la consistencia secuencial.

En la replicación pasiva (primario-respaldo), la tolerancia a fallos se consigue dirigiendo todas las peticiones a través de gestores de réplicas distinguidos y disponiendo de un gestor de réplicas de respaldo que asumirá el papel si otro falla. En la replicación activa, todos los gestores de réplicas procesan todas las peticiones de forma independiente. Ambas formas de replicación puede implementarse de forma conveniente utilizando la comunicación en grupo.

A continuación se estudiaron los servicios con alta disponibilidad. Tanto el sistema cotilla como el de Bayou permiten que sus clientes realicen actualizaciones sobre las réplicas locales mientras existe una partición. En ambos sistemas, los gestores de réplicas se intercambian actualizaciones cuando vuelven a encontrarse conectados. El sistema cotilla proporciona su mayor disponibilidad a costa de una consistencia causal relajada. El Bayou proporciona unas mayores garantías de consistencia eventuales, utilizando una detección automática de conflictos y la técnica de transformación operacional para resolver dichos conflictos. Coda es un sistema de archivos con alta disponibilidad, que utiliza vectores de versiones para detectar actualizaciones que potencialmente pueden entrar en conflicto.

Finalmente, se consideró las prestaciones de las transacciones en presencia de datos replicados.

Finalmente, se consideró las prestaciones de las transacciones en presencia de datos replicados.

ciones permiten los fallos en los gestores de réplicas y las particiones en la red. Las técnicas de copias disponibles, quórum con consenso y particiones virtuales permiten que las operaciones den-

- 14.10. Explique por qué el permitir que los respaldos procesen operaciones de lectura en un sistema de replicación pasiva lleva a ejecuciones consistentes secuencialmente en lugar de lìnealizables.
- 14.11. ¿Podría utilizarse la arquitectura cotilla para un juego de computador distribuido como el que se describió en el Ejercicio 14.3?
- 14.12. En la arquitectura cotilla, ¿por qué un gestor de réplicas necesita mantener tanto una marca temporal de la *réplica como una marca temporal del «valor»?*
- 14.13. En un sistema cotilla, un frontal tiene un vector de marcas temporales (3, 5, 7), que representa los datos que ha recibido por parte de los miembros de un grupo de tres gestores de réplicas. Los tres gestores de réplicas tienen como vectores de marcas temporales (5, 2, 8), (4, 5, 6) y (4, 5, 8), respectivamente. ¿Qué gestor (o gestores) de réplicas podrían satisfacer, inmediatamente, una pregunta por parte de un frontal y cuál sería la marca temporal resultante en el frontal? ¿Cuál podría incorporar una actualización, inmediatamente, por parte del frontal?
- 14.14. Explíquese por qué haciendo que algunos gestores de réplicas sean de *sólo lectura* se mejora el rendimiento de la arquitectura cotilla.
- 14.15. Escriba un pseudocódigo para los procedimientos de chequeo de consistencia y fusión (tal y como los usa Bayou) apropiados para una simple aplicación de reserva de habitaciones.
- 14.16. En Coda, ¿por qué es necesario, algunas veces, que los usuarios intervengan manualmente en el proceso de actualización de copias de un archivo en múltiples servidores?
- 14.17. Diseñe un esquema para integrar dos réplicas de un directorio de un sistema de archivos que fueron sometidas a actualizaciones separadas durante la operación sin conexión. Utilice o bien una aproximación de transformación operacional como en Bayou, o proponga una solución para el sistema Coda.
- 14.18. Se aplica replicación por copias disponibles a los ítems *A* y *B* con réplicas A_x, A_y y B_m, B_n . Las transacciones *T* y *U* se definen como:

$$T: \text{Lee}(A); \text{Escribe}(B, 44).$$

$$U: \text{Lee}(B); \text{Escribe}(A, 55),$$

Muestre un entrelazado de *T* y *U*, asumiendo que se aplican bloqueos en dos fases a las réplicas. Explique por qué los bloqueos por sí solos no pueden asegurar la secuenciabilidad de *una copia* si una de las réplicas fallas durante la progresión de *T* y *U*. Explique, con referencia a este ejemplo, cómo la validación local asegura la secuenciabilidad sobre una copia.
- 14.19. En los servidores *X*, *Y* y *Z*, los cuales mantienen réplicas de los datos *A* y *B*, se usa la replicación con consenso con quórum de Gifford. Los valores iniciales de todas las réplicas de *A* y *B* son 100, y los votos para *A* y *B* son 1 en cada servidor *X*, *Y* y *Z*. También se tiene $L=E=2$, tanto para *A* como para *B*. Un cliente lee el valor de *A* y entonces lo escribe en *B*.
 - (i) En el momento en el que el cliente realiza estas operaciones, una partición separa los servidores *X* e *Y* de *Z*. Describase los quórum obtenidos y las operaciones que tienen lugar si el cliente puede acceder a los servidores *X* e *Y*.
 - (ii) Describase los quórum obtenidos y las operaciones que tienen lugar si el cliente puede acceder sólo al servidor *Z*.
 - (iii) La partición se repara y a continuación se produce otra partición, de tal modo que *X* y *Z* son separadas de *Y*. Describanse los quórum obtenidos y las operaciones que tienen lugar si el cliente puede acceder a los servidores *X* y *Z*.

SISTEMAS MULTIMEDIA DISTRIBUIDOS

15.1. Introducción

tienen lugar si el cliente puede acceder a los servidores X y Z .

- 15.1. Introducción
- 15.2. Características de los datos multimedia
- 15.3. Gestión de la calidad de servicio
- 15.4. Gestión de recursos

15.1. INTRODUCCIÓN

Los computadores modernos pueden manejar caudales de datos continuos (caudales), dependientes del tiempo como audio y vídeo digital. Esta capacidad ha conducido al desarrollo de aplicaciones multimedia distribuidas como bibliotecas de vídeo en red, telefonía sobre Internet y videoconferencia. Dichas aplicaciones son viables con las actuales redes y sistemas de propósito general, a pesar de que a menudo la calidad del audio y del vídeo resultante esté lejos de ser satisfactoria. Las aplicaciones más exigentes como la videoconferencia a gran escala, la televisión digital, y los sistemas de vigilancia están más allá de las capacidades de las redes y de los sistemas distribuidos actuales.

Las aplicaciones multimedia demandan la entrega a tiempo a los usuarios de caudales de datos multimedia. Los caudales de audio y vídeo se generan y se consumen en tiempo real, la entrega a tiempo de los elementos individuales (muestras de audio y marcos de vídeo) es esencial para la integridad de la aplicación. En resumen, los sistemas multimedia son sistemas de tiempo real: deben ejecutar tareas y entregar sus resultados de acuerdo con una planificación que es determinada externamente. El grado en el que esto se consigue por el sistema subyacente es conocido como la *calidad de servicio* (*quality of service*, QoS) de que disfruta una aplicación.

Aunque los problemas de diseño de los sistemas de tiempo real han sido estudiados antes de la llegada de los sistemas multimedia, y muchos sistemas de tiempo real han sido desarrollados con éxito (véase, por ejemplo, Kopetz y Verissimo [1993]), generalmente no han sido integrados en sistemas operativos y redes de propósito más general. La naturaleza de las tareas ejecutadas por los sistemas de tiempo real existentes, como los aeronáuticos, el control del tráfico aéreo, el control de procesos de fabricación y la conmutación telefónica, difiere de aquellas ejecutadas en las aplicaciones multimedia. Las primeras tratan generalmente con cantidades de datos pequeñas y en algunos casos tienen *tiempos límite estrictos*, pero el fallo en el cumplimiento de cualquiera de sus tiempos límite de entrega pueden acarrear consecuencias serias, e incluso desastrosas. En tales casos, la solución adoptada ha sido sobredimensionar los recursos de cómputo y reservarlos con una planificación fija que garantice que se cumplen siempre los requisitos del peor caso.

La reserva y la planificación de los recursos diseñadas para responder a las necesidades de las aplicaciones multimedia y otras similares se denomina *gestión de la calidad de servicio* (*QoS*). La mayoría de los sistemas operativos y de las redes no incluyen las capacidades de gestión de la QoS requeridas por las aplicaciones multimedia.

Las consecuencias de un fallo en el cumplimiento de los tiempos límite en las aplicaciones multimedia pueden ser serias, especialmente en entornos comerciales como servicios de vídeo bajo demanda, aplicaciones de conferencias de negocios y medicina remota, pero los requisitos difieren significativamente de los de las otras aplicaciones de tiempo real:

- Las aplicaciones multimedia son, a menudo, altamente distribuidas y operan sobre entornos de computación distribuida de propósito general. Compiten, por tanto, con otras aplicaciones distribuidas por el ancho de banda de la red y por los recursos de computación de las estaciones de trabajo de los usuarios y de los servidores.
- Los requisitos de recursos de las aplicaciones multimedia son dinámicos. Una videoconferencia puede necesitar más o menos ancho de banda dependiendo del aumento o de la disminución del número de conferenciantes. El uso de los recursos de cómputo en cada estación de trabajo de usuario también varía, ya que cambia, por ejemplo, el número de caudales de vídeo que debe mostrar. Las aplicaciones multimedia pueden suponer otras cargas variables o intermitentes. Por ejemplo, la celebración de una clase multimedia puede incluir una actividad de simulación con un uso intensivo del procesador.
- A menudo los usuarios desean equilibrar los costes en recursos de las aplicaciones multimedia con otras actividades. Pueden querer reducir sus peticiones de ancho de banda para el

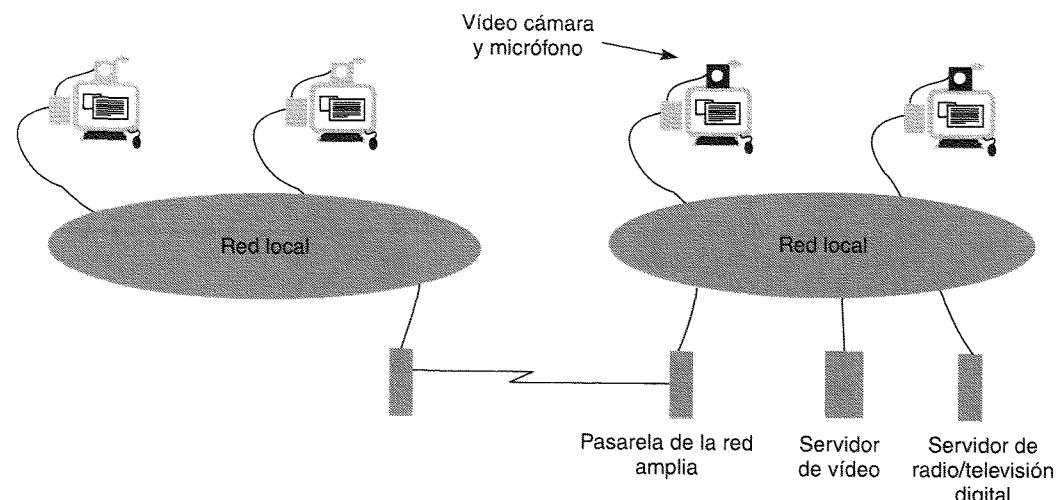


Figura 15.1. Un sistema distribuido multimedia.

vídeo en una aplicación de conferencia para permitir que se realice una conversación de audio separada, o pueden querer seguir programando o editando textos mientras están participando en la conferencia.

Los sistemas de gestión de la QoS están pensados para responder a todas estas necesidades, gestionando de forma dinámica los recursos disponibles y variando las reservas en respuesta a los cambios en la demanda y las prioridades de los usuarios. Un sistema de gestión de la QoS debe gestionar todos los recursos de cómputo y de comunicación necesarios para adquirir, procesar y transmitir caudales de datos multimedia, especialmente donde los recursos son compartidos entre diferentes aplicaciones.

La Figura 15.1 ilustra un sistema distribuido multimedia típico capaz de soportar una variedad de aplicaciones, como conferencias, acceso a secuencias almacenadas de vídeo y difusión de radio y televisión digitales. Los recursos requeridos para la gestión de esta QoS incluyen ancho de banda de la red, ciclos de procesador y capacidad de memoria. También hay que considerar el ancho de banda de disco en el servidor de vídeo. Adoptaremos el término genérico de *ancho de banda de los recursos* para referirnos a la capacidad de cualquier recurso hardware (red, procesador central, subsistema de disco) para transmitir o procesar datos multimedia.

En un sistema distribuido abierto, las aplicaciones multimedia pueden ser iniciadas y utilizadas sin anuncio previo. Pueden coexistir varias aplicaciones en la misma red e incluso en la misma estación de trabajo. Por lo tanto, la necesidad de la gestión de la QoS surge independientemente de la *cantidad total* de ancho de banda de los recursos o de la capacidad de la memoria de un sistema. Se necesita gestionar la QoS para *garantizar* que las aplicaciones serán capaces de obtener la cantidad de recursos necesaria en los momentos requeridos, incluso cuando otras aplicaciones estén compitiendo por esos recursos.

Se han desplegado algunas aplicaciones multimedia incluso en los computadores y redes actuales sin QoS y basadas en el principio del mejor esfuerzo. Entre ellas están:

Multimedia basado en web: estas aplicaciones proporcionan acceso según el mejor esfuerzo a caudales de audio y vídeo publicados en el Web. Han tenido éxito cuando existe poca o ninguna sincronización de los caudales de datos entre diferentes localizaciones. Sus prestaciones están restringidas por el limitado ancho de banda y por las latencias variables que se dan en las redes actuales y por la imposibilidad de los sistemas operativos actuales para soportar una pla-

nificación de tiempo real de los recursos. En el caso del audio y de las secuencias de audio y de vídeo de baja calidad, la utilización extensiva de almacenamiento en el destino para suavizar las variaciones en el ancho de banda y en la latencia hace que se puedan reproducir secuencias de vídeo de forma continua y sin sobresaltos, aunque existan un retardo desde el origen al destino de hasta varios segundos.

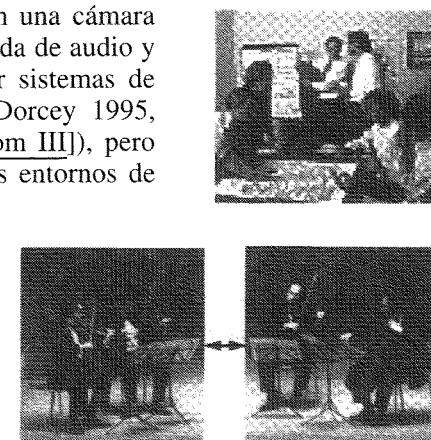
Telefonía de red y conferencias de audio: esta aplicación tiene unos requisitos de ancho de banda relativamente bajos, especialmente cuando se aplican técnicas de compresión eficientes. Aunque la naturaleza interactiva de la misma implica tiempos de ida y vuelta pequeños, algo que no siempre se puede conseguir.

Servicios de vídeo bajo demanda: éstos proporcionan vídeo en formato digital desde grandes sistemas de almacenamiento hasta la herramienta de visualización del usuario. Resultan satisfactorios cuando existe suficiente ancho de banda dedicado, y tanto el servidor como el cliente son computadores dedicados. También emplean una cantidad considerable de almacenamiento en el destino.

Las aplicaciones altamente interactivas plantean problemas mucho más graves. Muchas aplicaciones multimedia son cooperativas (involucran varios usuarios) y sincronizadas (requieren que las actividades de los usuarios estén coordinadas). Éstas abarcan un ancho espectro de contextos y escenarios de aplicación. Por ejemplo:

- Una simple videoconferencia involucra dos o más usuarios, cada uno utilizando una estación de trabajo equipada con una cámara de vídeo digital, un micrófono y posibilidades de salida de audio y vídeo. Existe software disponible para proporcionar sistemas de teleconferencia simples (por ejemplo: *CUSeeMe* [Dorcey 1995, www.cuseeme.com], *NetMeeting* [www.microsoft.com III]), pero sus prestaciones están severamente limitadas por los entornos de computación y de comunicaciones actuales.
- Posibilidades de ensayo y de ejecución que permite a músicos en diferentes ubicaciones tocar juntos [Konstantas y otros 1997]. Ésta es una aplicación multimedia particularmente demandante ya que las restricciones de sincronización son muy exigentes.

Las aplicaciones como éstas requieren:



Comutación con baja latencia: retardos de ida y vuelta < 100 milisegundos, de modo que la interacción entre los usuarios parezca que está sincronizada.

Estado de sincronización distribuida: si un usuario detiene un vídeo en un determinado marco, los otros usuarios deberían ver el vídeo parado en el mismo marco.

Sincronización de medios: todos los participantes en una actuación musical deberían escuchar la ejecución aproximadamente a la vez (Konstantas y otros [1997] identifica como requisito de sincronización un intervalo de 50 milisegundos). La banda sonora y el caudal de vídeo deberían mantener la *sincronización de labios*, por ejemplo, para un usuario haciendo comentarios en una reproducción de vídeo o en una sesión distribuida de *karaoke*.

Sincronización externa: en conferencias y en otras aplicaciones cooperativas, pueden existir datos activos en distintos formatos, tales como animaciones generadas por computador, datos CAD, pizarras electrónicas y documentos compartidos. Las actualizaciones de éstos deben ser distribuidas y suceder de forma que parezcan casi sincronizadas con los caudales multimedia dependientes del tiempo.

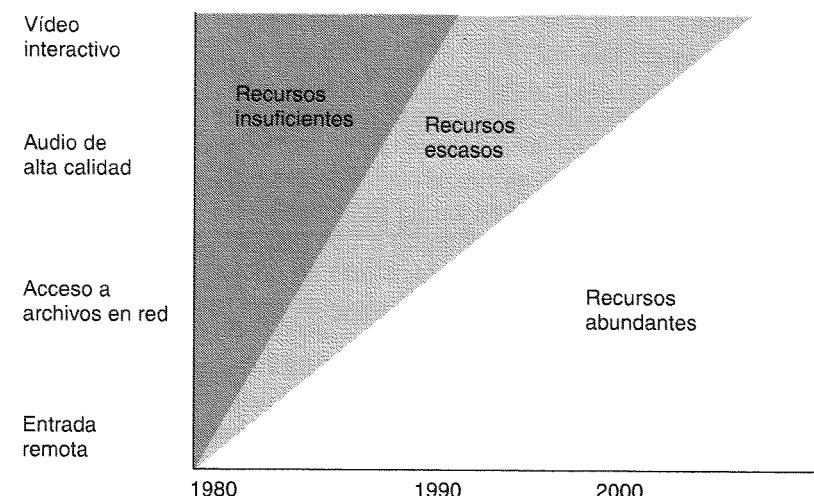


Figura 15.2. La ventana de la escasez para los recursos de cómputo y de comunicación.

Tales aplicaciones se ejecutarán satisfactoriamente sólo en sistemas que incluyan esquemas de gestión de la QoS rigurosos.

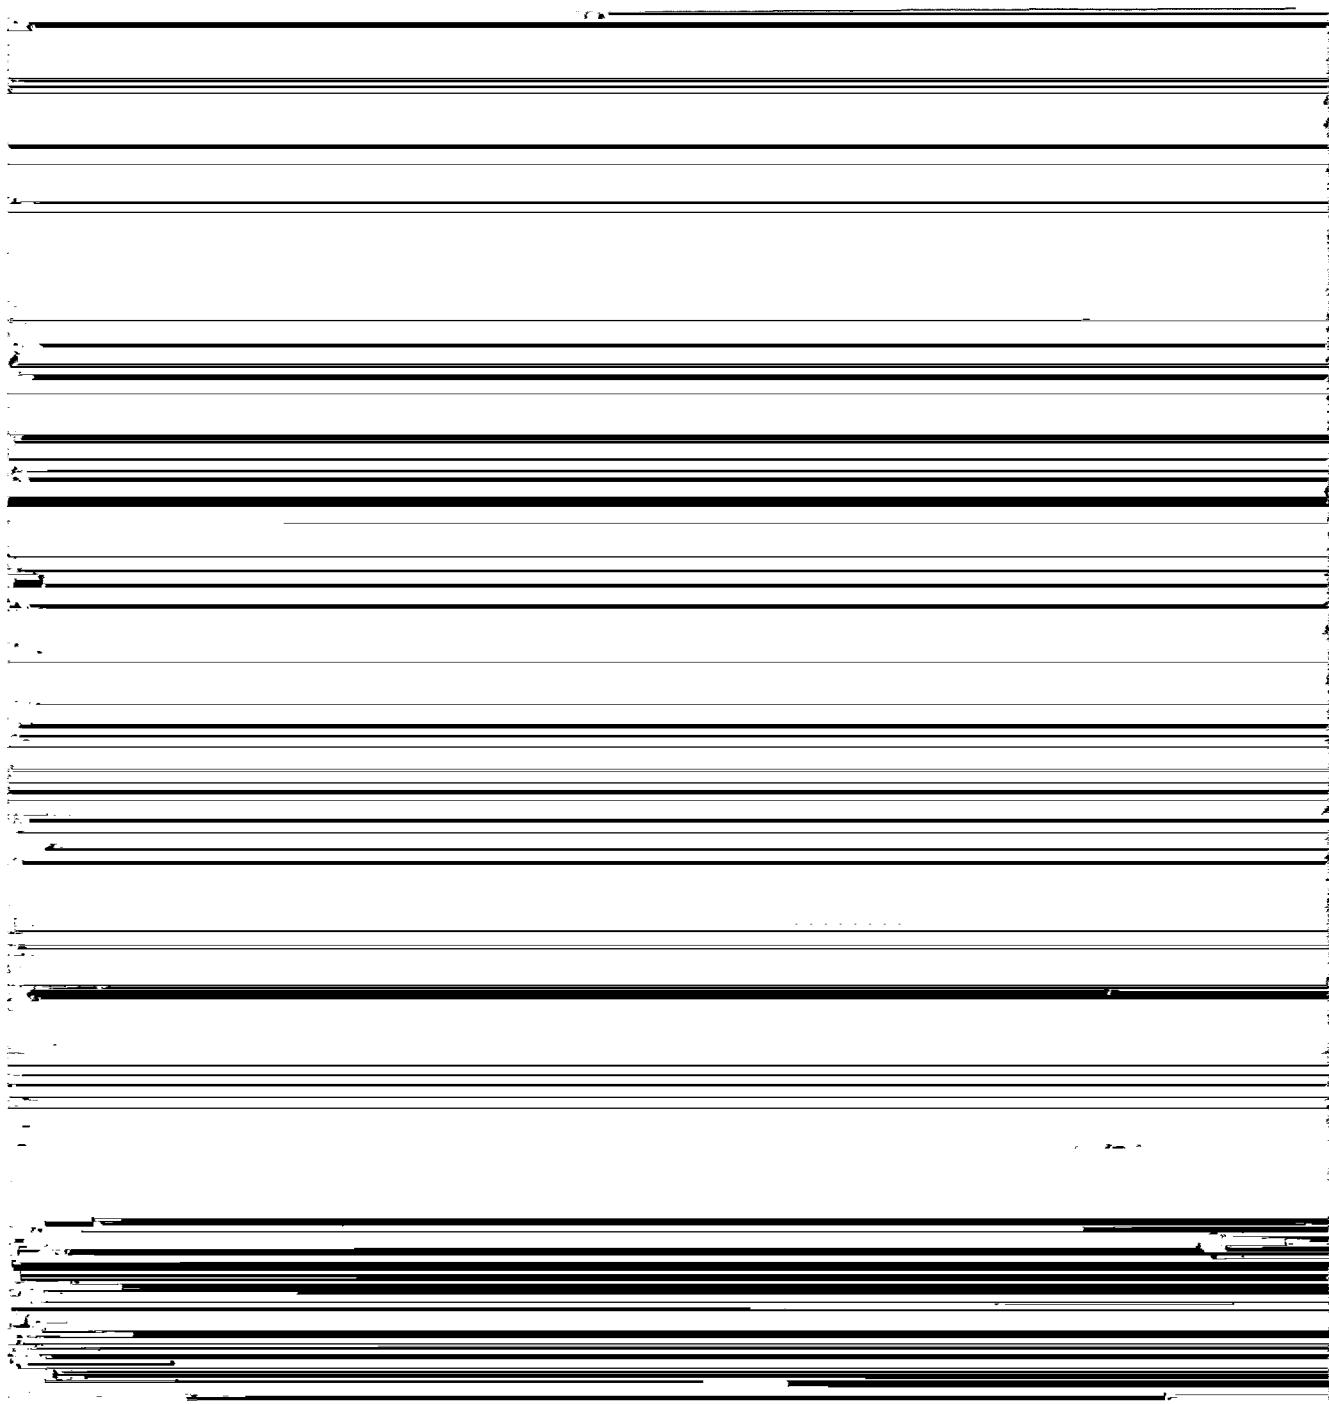
◊ **La ventana de la escasez.** Muchos de los computadores modernos proporcionan alguna capacidad para manejar datos multimedia, pero los recursos necesarios son muy limitados. Muchos sistemas limitan la cantidad y la calidad de los caudales que soportan, especialmente cuando se trata de trabajar con grandes caudales de audio y vídeo. Esta situación ha sido descrita como *la ventana de la escasez* [Anderson y otros 1990b]. Siempre que una cierta clase de aplicaciones cae dentro de esta ventana, un sistema necesita reservar y planificar sus recursos cuidadosamente para proporcionar el servicio deseado (véase la Figura 15.2). Antes de alcanzar la ventana de la escasez, un sistema tiene recursos insuficientes para ejecutar sus aplicaciones relevantes. Esta era la situación de las aplicaciones multimedia en la primera mitad de los años ochenta. Una vez que una clase de aplicaciones ha dejado la ventana de la escasez, las prestaciones del sistema son suficientes para proporcionar el servicio incluso bajo circunstancias adversas y sin mecanismos de adecuación.

Los avances en las prestaciones de los sistemas se han utilizado también para mejorar la calidad de los datos multimedia hasta incluir tasas de marcos mayores y mejor resolución en los caudales de vídeo o para soportar más medios de forma concurrente, por ejemplo en un sistema de videoconferencia. Pero las aplicaciones más demandantes, incluidas la realidad virtual y la manipulación de caudales en tiempo real (*efectos especiales*) pueden extender la ventana de la escasez casi indefinidamente.

En la Sección 15.2 revisamos las características de los datos multimedia. La Sección 15.3 describe diferentes aproximaciones a la reserva de recursos escasos de modo que se consiga una QoS, y la Sección 15.4 discute métodos para planificar esos recursos escasos. La Sección 15.5 discute métodos para optimizar el caudal de datos en los sistemas multimedia. La Sección 15.6 describe el servidor de vídeo Tiger, un sistema escalable de bajo coste para la entrega de secuencias almacenadas de vídeo a un gran número de usuarios concurrentemente.

15.2. CARACTERÍSTICAS DE LOS DATOS MULTIMEDIA

Nos hemos referido a los datos de audio y vídeo como continuos y dependientes del tiempo. ¿Cómo podemos definir sus características de forma más precisa? El término *continuo* se refiere a



representaciones y estándares de medios, y la página web de Gibbs y Szentivanyi [multimedia index] es una fuente útil de referencias a documentación sobre los estándares multimedia actuales.

Aunque el uso de audio y vídeo comprimido disminuye las necesidades de ancho de banda de las redes de comunicación, impone cargas adicionales en los recursos de procesamiento tanto en origen como en el destino. Esto se ha proporcionado, a menudo, con el uso de hardware de propósito especial para procesar y entregar información audio y vídeo, los codificadores/decodificadores (*codecs*) de vídeo y audio que se encuentran en las tarjetas de vídeo en los computadores personales. Pero el incremento en la potencia de los computadores personales y las arquitecturas multiprocesador hacen probable que mucho de este trabajo se pueda realizar utilizando filtros software de codificación y decodificación. Esta aproximación aporta más flexibilidad, con una mejor adaptación a formatos específicos de aplicación, lógicas de aplicación de propósito especial y el manejo simultáneo de varios caudales multimedia.

El método de compresión utilizado por el formato de vídeo MPEG es asimétrico, con un algoritmo de compresión complejo y otro sencillo de descompresión. Esto tiende a facilitar su uso en conferencias, donde la compresión es realizada a menudo por un *codec* (codificador descodificador) hardware pero la descompresión de los diferentes caudales que llegan a los computadores de los usuarios se realiza por software, haciendo posible que el número de participantes en la conferencia pueda variar sin depender del número de codecs presentes en cada computador de usuario.

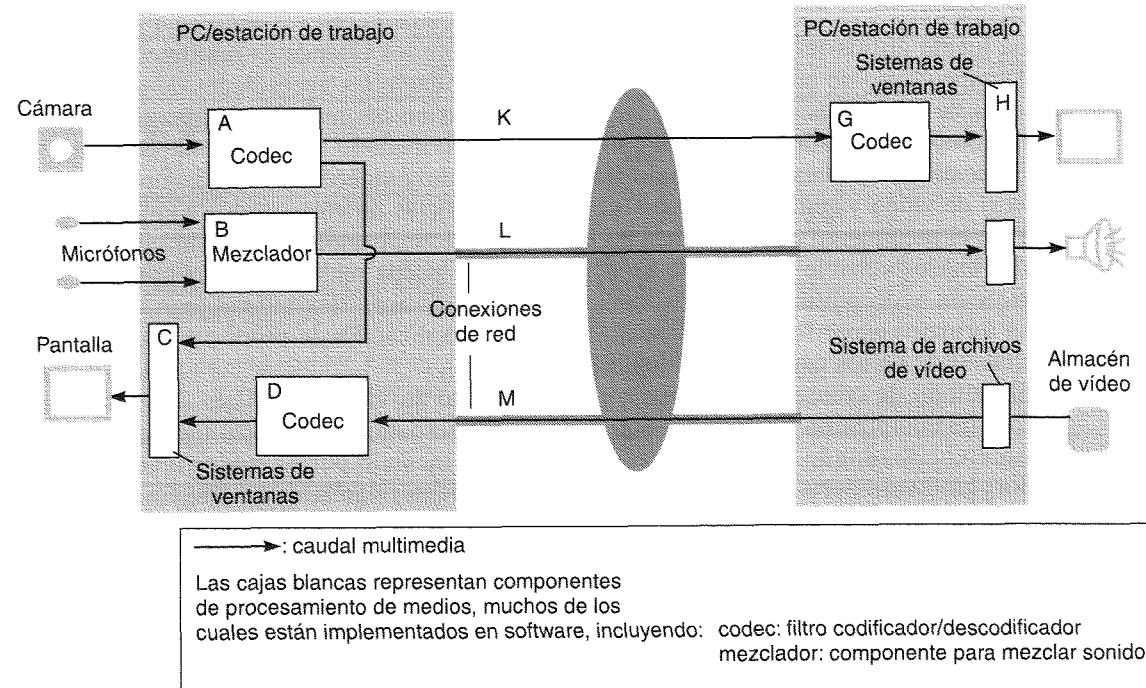
15.3. GESTIÓN DE LA CALIDAD DE SERVICIO

Cuando las aplicaciones multimedia corren sobre redes de computadores personales, compiten por los recursos en las estaciones de trabajo que ejecutan esas aplicaciones (ciclos de procesador, ciclos de bus, capacidad de búferes) y en las redes (enlaces de transmisión, comutadores, pasarelas). Las estaciones de trabajo y las redes pueden tener que soportar varias aplicaciones multimedia y convencionales a la vez. Existe competencia entre las aplicaciones multimedia y las convencionales, entre diferentes aplicaciones multimedia e incluso entre los caudales multimedia de las aplicaciones individuales.

El uso concurrente de los recursos físicos por una variedad de tareas hace tiempo que es posible con los sistemas operativos multitarea y las redes compartidas. En los sistemas operativos multitarea, el procesador central es reservado para las tareas individuales (o procesos) según un esquema de planificación de ronda (*round robin*) u otro que reparte los recursos de procesamiento según el principio del *mejor esfuerzo* entre todas las tareas que compiten por el procesador central.

Las redes están diseñadas para hacer posible que sean intercalados mensajes de diferentes fuentes, de modo que existan muchos canales de comunicación virtuales sobre los mismos canales físicos. La tecnología predominante en las redes de área local, Ethernet, gestiona el medio de transmisión compartido según el *mejor esfuerzo*. Cualquier nodo puede utilizar el medio de transmisión cuando está en silencio. Pero se pueden producir colisiones de paquetes, y cuando esto es así, los nodos emisores esperan una cantidad de tiempo aleatorio para evitar la repetición de la colisión. Las colisiones casi son inevitables cuando la red está muy cargada, y este esquema no proporciona garantías respecto al ancho de banda o la latencia en esas condiciones.

La característica clave de estos esquemas de reserva de recursos es que gestionan los incrementos de la demanda asignando los recursos disponibles durante menos tiempo a las tareas en competencia. El método de ronda y otros basados en el mejor esfuerzo para compartir los ciclos del procesador y el ancho de banda de la red no pueden satisfacer los requisitos de las aplicaciones multimedia. Como hemos visto, el procesamiento y la transmisión de los caudales multimedia a tiempo es crucial. La entrega con retraso no tiene valor. Para conseguir la entrega a tiempo, las



aplicaciones necesitan garantizar que los recursos necesarios serán reservados y planificados en los instantes oportunos.

La gestión y la reserva de los recursos que proporciona tales garantías se denomina *gestión de la calidad de servicio*. La Figura 15.4 muestra los componentes de la infraestructura de una aplicación de conferencia simple ejecutándose sobre dos computadores personales, utilizando compresión de datos y conversión de formatos. Las cajas blancas representan componentes software cuyos requisitos de recursos pueden afectar a la calidad de servicio de la aplicación.

La figura muestra la arquitectura abstracta más utilizada en el software multimedia, en la que caudales de elementos de datos (marcos de vídeo, muestras de sonido) que fluyen continuamente son procesados por una colección de procesos y transferidos entre los procesos por conexiones entre procesos. Los procesos producen, transforman y consumen caudales de datos multimedia continuos. Las conexiones enlazan los procesos en una secuencia entre una *fuente* de elementos de datos a un *destino*, en el cual son reproducidos o consumidos. Las conexiones entre los procesos se pueden implementar mediante conexiones de red o mediante transferencias en memoria cuando los procesos residen en la misma máquina. Para que los elementos de datos multimedia lleguen a tiempo a su destino, cada proceso debe reservar el tiempo de CPU, la capacidad de memoria y el ancho de banda adecuados para ejecutar sus tareas asignadas y debe ser planificado para utilizar esos recursos de forma lo suficientemente frecuente como para poder entregar a tiempo los datos en su caudal al siguiente proceso.

En la Figura 15.5 mostramos los requisitos de recursos de los principales componentes software y de las conexiones de red de la Figura 15.4 (observe que las letras relacionan los componentes en estas dos figuras). Obviamente, los recursos requeridos sólo pueden ser garantizados si existe un componente responsable de la reserva y de la planificación de esos recursos. Nos referiremos a ese componente como el *gestor de la calidad de servicio*.

Componente		Ancho de banda	Latencia	Tasa de pérdidas	Recursos requeridos
Cámara	Salida:	10 marcos/segundo, vídeo calidad baja 640 × 480 × 16 bits	—	Cero	—
A Codec	Entrada:	10 marcos/segundo, vídeo calidad baja	Interactiva	Baja	10 ms CPU cada 100 ms; 10 Mbytes RAM
B Mezclador	Salida: Entrada: Salida:	caudal MPEG-1 audio 2 × 44 kbps audio 1 × 44 kbps	Interactiva	Muy baja	1 ms CPU cada 100 ms; 1 Mbytes RAM
H Sistema de ventanas	Entrada: Salida:	varias búfer de 50 marcos/segundo	Interactiva	Baja	5 ms CPU cada 100 ms; 5 Mbytes RAM
K Conexión de red	Entrada/Salida:	caudal MPEG-1, aprox. 1,5 Mbps	Interactiva	Baja	1,5 Mbps, protocolo de caudales con pocas pérdidas
L Conexión de red	Entrada/Salida:	audio 44 kbps	Interactivo	Muy baja	44 kbps, protocolo de caudales con pocas pérdidas

Figura 15.5. Especificación de la QoS para los componentes de la aplicación mostrada en la Figura 15.4.

La Figura 15.6 muestra las responsabilidades del gestor de la QoS en forma de diagrama de caudal. En las siguientes dos subsecciones describimos las dos principales subtareas del gestor de la QoS:

Negociación de la calidad de servicio: la aplicación indica sus requisitos de recursos al gestor de la QoS. El gestor de la QoS evalúa la posibilidad de satisfacer los requisitos a partir de la base de datos de recursos disponibles y de los recursos comprometidos actualmente, dando una respuesta positiva o negativa. Si es negativa, la aplicación puede ser reconfigurada para utilizar menos recursos y el proceso se repite.

Control de admisión: si el resultado de la evaluación de los recursos ha sido positivo, se reservan los recursos requeridos y se da a la aplicación un *contrato de recursos*, que establece los recursos que han sido reservados. El contrato incluye un límite de tiempo. Entonces la aplicación está autorizada para ejecutarse. Si cambia sus requisitos de recursos debe notificarlo al gestor de la QoS. Si los requisitos disminuyen, los recursos liberados pasan a la base de datos de recursos disponibles. Si se incrementan, se establece una nueva ronda de negociación y de control de admisión.

En lo que resta de sección describimos con detalle las técnicas para llevar a cabo estas subtareas. Por supuesto, mientras una aplicación se está ejecutando, existe la necesidad de ajuste fino en la planificación de los recursos como el tiempo de procesador y el ancho de banda de red para asegurarse que los procesos de tiempo real reciben a tiempo los recursos reservados. Las técnicas para conseguir esto se describen en la Sección 15.4.

15.3.1. NEGOCIACIÓN DE LA CALIDAD DE SERVICIO

Para negociar la QoS entre una aplicación y el sistema que la soporta, una aplicación debe especificar sus necesidades de QoS al gestor de la QoS. Esto se realiza mediante la transmisión de un conjunto de parámetros. Tres parámetros son de principal interés cuando se trata de procesar y transportar caudales de datos multimedia: *ancho de banda*, *latencia* y *tasa de pérdidas*.

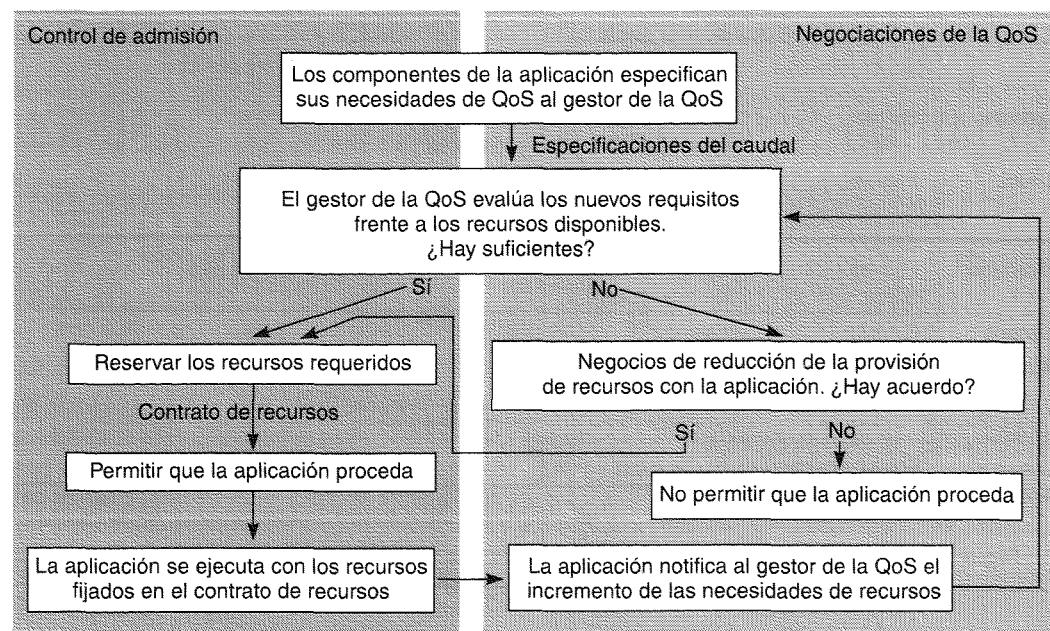


Figura 15.6. Tareas del gestor de la QoS.

Ancho de banda: El ancho de banda de un caudal o componente multimedia es la tasa a la que los datos fluyen a través de él.

Latencia: La latencia es el tiempo requerido por un elemento de datos individual para moverse a través de un caudal desde un origen a un destino. Esta puede variar dependiendo del volumen de otros datos en el sistema y de otras características de la carga del sistema. Esta variación se denomina fluctuación (*jitter*); formalmente, la fluctuación es la primera derivada de la latencia.

Tasa de pérdidas: Como la entrega tardía de los datos multimedia no tiene sentido, los elementos de datos serán desechados cuando sea imposible entregarlos antes de su tiempo de entrega planeado. En un entorno de QoS perfectamente gestionado, esto nunca debería suceder, pero hasta ahora, existen pocos entornos de ese tipo, por las razones expuestas anteriormente. Por lo tanto, los costos en recursos para garantizar la entrega a tiempo de todos los elementos multimedia es a menudo inaceptable; esto implica probablemente la reserva de unos recursos que excederían las necesidades medias para poder tratar adecuadamente los picos ocasionales. La alternativa adoptada es aceptar cierta tasa de pérdida de datos (marcos de vídeo o muestras de audio desecharadas). La proporción aceptable se mantiene normalmente baja; algo más de un 1% y mucho menor para aplicaciones de calidad crítica.

Se pueden utilizar estos tres parámetros:

1. Para describir las características de un caudal multimedia en un entorno particular. Por ejemplo, un caudal de vídeo puede requerir un ancho de banda medio de 1,5 Mbps, y como está siendo utilizado en una aplicación de conferencia necesita ser transferido con un retardo de 150 ms como mucho para evitar los huecos en la conversación. Los algoritmos de descompresión utilizados en el destino deben producir imágenes aceptables con una tasa de pérdidas de un marco cada 100.
2. Para describir las capacidades de los recursos para transportar un caudal. Por ejemplo, una red puede proporcionar conexiones de 64 kbps de ancho de banda, sus algoritmos de ges-

tión de las colas garantizan retardos menores de 10 ms, y el sistema de transmisión puede garantizar una tasa de pérdidas menores de 1 en 10^6 .

Estos parámetros son interdependientes. Por ejemplo:

- La tasa de pérdidas en los sistemas modernos casi nunca depende de los errores en los bits causados por ruido o mal funcionamiento; depende del desbordamiento del búfer y de los datos dependientes del tiempo que llegan tarde. Por lo tanto, cuanto mayor sea el ancho de banda y menor el retardo, más fácil será tener una tasa de errores baja.
- Cuando menor sea el ancho de banda comparado con su carga, más mensajes se acumularán en la entrada y se necesitarán búferes mayores para evitar las pérdidas. Cuanto mayores sean los búferes, más tendrán que esperar los mensajes para ser tratados, por lo que el retardo será mayor.

◇ **Especificación de los parámetros de la QoS para caudales.** Los valores de los parámetros de la QoS se pueden fijar explícitamente (por ejemplo para el caudal de salida de la cámara de la Figura 15.4 podríamos requerir: *ancho de banda*: 50 Mbps, *retardo*: 150 ms, *pérdidas*: < 1 marco en 10^3) o de forma implícita (por ejemplo el ancho de banda del caudal de entrada a la conexión de red K es el resultado de aplicar la compresión MPEG-1 a la salida de la cámara).

Pero el caso más común es que tengamos que especificar un valor y un rango de variación permitida. Vamos a considerar este requisito para cada uno de los parámetros:

Ancho de banda: La mayoría de las técnicas de compresión de vídeo producen un caudal de marcos de diferentes tamaños dependiendo del contenido original del vídeo. Para MPEG, la relación de compresión media está entre 1:50 y 1:100, pero variará dinámicamente dependiendo del contenido; por ejemplo, el mayor ancho de banda requerido se dará cuando el contenido cambie lo más rápidamente posible. Debido a esto, a menudo es útil fijar los parámetros de la QoS como valores mínimo, medio y máximo, dependiendo del tipo de régimen de gestión de la QoS que sea utilizado.

Otro problema que surge en la especificación del ancho de banda es la caracterización de sus ráfagas (*burstiness*). Considérense tres caudales de 1 Mbps. Un caudal transmite un marco de 1 Mbit cada segundo, el segundo es un caudal asincrónico de elementos de animación generados por computador con un ancho de banda medio de 1 Mbps, y el tercero envía una muestra de sonido de 100-bit cada microsegundo. Aunque los tres caudales requieren el mismo ancho de banda, sus patrones de tráfico son muy diferentes.

Un modo de tratar las irregularidades es definir un parámetro de ráfaga además de la tasa y el tamaño de los marcos. El parámetro de ráfaga especifica el número máximo de elementos de datos que pueden llegar temprano, esto es, antes de su instante de llegada establecido. El modelo de *llegada lineal de procesos* (*linear-bounded arrival processes*, LBAP) utilizado en Anderson [1993] define el número máximo de mensajes en un caudal durante cualquier intervalo de tiempo t como $Rt + B$, donde R es la tasa y B es el tamaño máximo de ráfaga. La ventaja de utilizar este modelo es que refleja adecuadamente las características de las fuentes multimedia: los datos multimedia leídos de disco se entregan habitualmente en grandes bloques, y los datos recibidos de las redes llegan, a menudo, bajo la forma de pequeños paquetes. En este caso, el parámetro de ráfaga define la cantidad de espacio necesario en el búfer para evitar pérdidas.

Latencia: Algunos requisitos de tiempo en multimedia son producto del caudal en sí mismo: si los marcos de un caudal no se procesan a la misma tasa a la que llegan, se van a acumular en la entrada y pueden desbordar la capacidad del búfer. Para evitar esto, un marco no debe permanecer en el búfer por término medio más de $1/R$, donde R es la tasa de marcos de un caudal, o se acumulará el trabajo pendiente. Si se acumula el trabajo, la cantidad y el tamaño de la información pendiente de procesar afectará al retardo máximo del caudal entre extremos, a lo que hay que añadir los tiempos de propagación y de procesamiento.

Otros requisitos de latencia surgen del entorno de la aplicación. En aplicaciones de conferencia, los participantes tienen que enviar datos en tiempo real. Los sistemas de videoconferencia tienen que enviar imágenes en tiempo real. Los sistemas de videoconferencia tienen que enviar imágenes en tiempo real.

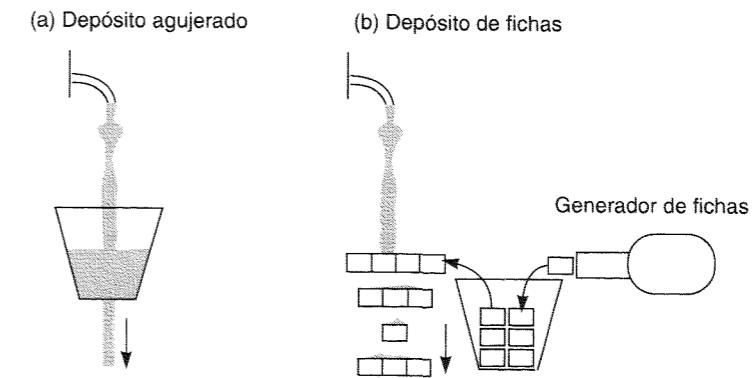


Figura 15.7. Algoritmos de moldeado de tráfico.

fija. Estas fijas se recogen en un depósito de tamaño B . Sólo se puede enviar datos de tamaño S si existen S fichas en el depósito. El proceso emisor elimina entonces esas S fichas. El algoritmo del depósito de fichas asegura que en cualquier intervalo de tiempo t la cantidad de datos enviados no será mayor que $Rt + B$. Es, por lo tanto, una implementación del modelo LBAP.

En un sistema de depósito de fichas sólo se pueden dar picos elevados de tamaño B cuando un caudal ha estado inactivo durante un rato. Para evitar estas ráfagas, se puede colocar un simple depósito agujereado detrás del depósito de fichas. La tasa del caudal F de este depósito debe ser significativamente mayor que R para que este esquema tenga sentido. Su único propósito es romper las ráfagas realmente grandes.

◊ **Especificaciones del caudal.** Una colección de parámetros del caudal es conocida generalmente como una *especificación del caudal*. Existen varios ejemplos de especificaciones de caudal y todas son similares. En RFC 1363 de Internet [Partridge 1992], las especificaciones del caudal se definen como once valores numéricos de 16-bit (Figura 15.8), que reflejan los parámetros de la QoS discutidos arriba del siguiente modo:

	Versión del protocolo
Ancho de banda:	Unidad máxima de transmisión
	Tasa del depósito de fichas
	Tamaño del depósito de fichas
	Tasa máxima de transmisión
Retraso:	Retardo mínimo sensible
	Variación máxima del retardo
Pérdida:	Sensibilidad a la pérdida
	Sensibilidad a las pérdidas en ráfaga
	Intervalo de pérdidas
	Garantía de calidad

Figura 15.8. Especificaciones del flujo del RFC 1363.

La cantidad de transmisión máxima y la tasa de transmisión máxima determinan el ancho de banda que una aplicación puede usar. La velocidad de transmisión máxima es la velocidad a la cual una aplicación puede enviar datos. La tasa de transmisión máxima es la velocidad a la cual una aplicación puede enviar datos en un período de tiempo dado. El ancho de banda es la cantidad de datos que una aplicación puede enviar en un período de tiempo dado.

La cantidad de transmisión máxima y la tasa de transmisión máxima determinan el ancho de banda que una aplicación puede usar. La velocidad de transmisión máxima es la velocidad a la cual una aplicación puede enviar datos. La tasa de transmisión máxima es la velocidad a la cual una aplicación puede enviar datos en un período de tiempo dado. El ancho de banda es la cantidad de datos que una aplicación puede enviar en un período de tiempo dado.

vierte en el menor ancho de banda disponible para todos los destinos, el retardo será el mayor de todos los destinos y la tasa de pérdida la mayor de todos los destinos. Éste es el procedimiento practicado por los protocolos de negociación iniciados por el emisor como SRP, ST-II y RCAP [Banerjea y Mah 1991].

En situaciones con destinos heterogéneos, normalmente no resulta apropiado asignar un valor en el peor caso común a todos los destinos. En su lugar, cada destino debería recibir la mejor QoS posible. Esto sugiere un proceso de negociación iniciado por el receptor, en lugar del orientado al emisor. El protocolo RSVP [Zhang y otros 1993] es un protocolo alternativo de negociación de la QoS en el cual los destinos se conectan a los caudales. Las fuentes comunican la existencia de caudales y sus características inherentes a todos los destinos. Los destinos pueden conectarse entonces al nodo más cercano a través del cual pase el caudal y derivar datos desde ahí. Para conseguir datos con la QoS apropiada, pueden tener que utilizar técnicas como el filtrado (discutido en la Sección 15.5).

15.3.2. CONTROL DE ADMISIÓN

El control de admisión regula el acceso a los recursos para evitar la sobrecarga de los recursos y para proteger los recursos de solicitudes que no se pueden satisfacer. Esto implica rechazar peticiones de servicio en las que los requisitos de recursos de un nuevo caudal multimedia violarían las garantías de QoS actuales.

Un esquema de control de admisión se basa en algún conocimiento sobre la capacidad total del sistema y la carga generada por cada aplicación. La especificación de los requisitos de ancho de banda de una aplicación puede reflejar la cantidad máxima de ancho de banda que una aplicación puede llegar a necesitar, el mínimo ancho de banda necesario para trabajar o un valor promedio entre ambos. En consecuencia, un esquema de control de admisión puede basar sus reservas de recursos en cualquiera de estos valores.

Para aquellos recursos en los que hay un único gestor, el control de admisión es directo. Los recursos que tienen puntos de acceso distribuidos, tales como muchas redes de área local, necesitan o una entidad de control de admisión centralizada o un algoritmo de control de admisión distribuido que evite admisiones concurrentes conflictivas. El arbitraje del bus en las estaciones de trabajo entra dentro de esta categoría; sin embargo, incluso los sistemas multimedia que ejecutan reserva extensiva de ancho de banda no controlan la admisión en el bus, ya que el ancho de banda del bus no se considera en la ventana de escasez.

◊ **Reserva del ancho de banda.** Una forma habitual de asegurar un cierto nivel de QoS para un caudal multimedia es reservar una porción de ancho de banda para uso exclusivo. Si se trata de cumplir los requisitos de un caudal en todo momento, se necesita realizar la reserva para su ancho de banda máximo. Éste es el único modo posible para proporcionar QoS garantizada a una aplicación, siempre que no se den fallos catastróficos en el sistema. Se utiliza en aplicaciones que no se pueden adaptar a distintos niveles de QoS o que se vuelven inservibles cuando se producen descensos en la calidad. Ejemplos de esto son algunas aplicaciones médicas (un síntoma puede aparecer en un vídeo de rayos x justo en el instante en el que los marcos del vídeo fueron desechados) y grabaciones de vídeo (donde los marcos desechados producen un vacío en la grabación que será observable siempre que se reproduzca el vídeo).

La reserva basada en los requisitos máximos es directa: cuando se controla el acceso a una red con un cierto ancho de banda B , se pueden admitir caudales multimedia s de ancho de banda b_s siempre que $\sum b_s \leq B$. Así, una red token ring de 16 Mb/s puede soportar hasta 10 caudales de vídeo digital de 1,5 Mb/s cada uno.

Desafortunadamente, los cálculos de capacidad no siempre son tan simples como en el caso del ancho de banda de una red. Para reservar ancho de banda de CPU del mismo modo se necesita

conocer el perfil de ejecución de cada proceso de aplicación. Los tiempos de ejecución, sin embargo, dependen del procesador utilizado y a menudo no se pueden determinar con precisión. Aunque existen varias propuestas para el cálculo automático del tiempo de ejecución [Mok 1985, Kopetz y otros 1989], ninguna de ellas ha sido utilizada de forma generalizada. Los tiempos de ejecución son determinados generalmente a partir de medidas con amplios márgenes de error y portabilidad limitada.

Para las codificaciones de medios típicas como MPEG, el ancho de banda consumido realmente por una aplicación es significativamente menor que el ancho de banda máximo. Las reservas basadas en los requisitos máximos pueden conducir, por lo tanto, a desperdiciar ancho de banda: las peticiones de nuevas admisiones son rechazadas aunque podrían ser satisfechas con el ancho de banda reservado, pero no utilizado en la realidad por las aplicaciones existentes.

◊ **Multiplexación estadística.** Dada la potencial infrautilización que se puede producir, es común sobreestimar la reserva de recursos. Las garantías resultantes, a menudo llamadas garantías estadísticas o blandas para distinguirlas de las deterministas o duras presentadas anteriormente, son únicamente válidas con alguna probabilidad (normalmente alta). Las garantías estadísticas tienden a proporcionar una utilización mejor de los recursos ya que no consideran el peor caso. Pero como cuando la reserva de recursos está basada en requisitos mínimos o promedios, picos de carga simultáneos pueden producir caídas en la calidad de servicio; las aplicaciones tienen que ser capaces de manejar estas caídas.

La multiplexación estadística está basada en la hipótesis de que para un gran número de caudales el ancho de banda agregado requerido permanece casi constante, independientemente del ancho de banda de los caudales individuales. Esto supone que cuando un caudal envía una gran cantidad de datos, también existirá otro que envía una pequeña cantidad de datos y que los requisitos generales se equilibran. Esto, sin embargo, es cierto únicamente para caudales no correlacionados.

Como han mostrado los experimentos [Leland y otros 1993], el tráfico multimedia en un entorno típico no obedece a esta hipótesis. Dado un gran número de caudales a ráfagas, el tráfico agregado también tendrá ráfagas. A este fenómeno se le ha aplicado el término *autosimilaridad*, indicando que el tráfico agregado muestra semejanza con los caudales individuales de los que se compone.

15.4. GESTIÓN DE RECURSOS

Para proporcionar un cierto nivel de QoS a una aplicación, un sistema no sólo necesita tener recursos suficientes (prestaciones), sino que necesita poner esos recursos a disposición de la aplicación cuando sean necesarios (planificación o *scheduling*).

15.4.1. PLANIFICACIÓN DE RECURSOS

Los procesos necesitan tener recursos asignados de acuerdo con su prioridad. Un planificador de recursos determina la prioridad de un proceso basándose en ciertos criterios. Los planificadores de CPU tradicionales de los sistemas de tiempo compartido basan sus asignaciones de prioridad en la capacidad de respuesta y en la imparcialidad: las tareas con una entrada/salida intensa obtienen una prioridad alta para garantizar una rápida respuesta a las peticiones de los usuarios, las tareas asociadas a la CPU reciben una prioridad baja y en general, los procesos con igual prioridad son tratados de la misma manera.

Ambos criterios siguen siendo válidos en los sistemas multimedia, pero la existencia de tiempos límite de entrega de los elementos de datos multimedia modifican la naturaleza del problema

de la planificación. Los algoritmos de planificación de tiempo real se pueden aplicar a este problema como se trata más adelante. Como los sistemas multimedia tienen que gestionar medios tanto continuos como discretos, se presenta el desafío de proporcionar suficiente servicio a los caudales dependientes del tiempo sin causar la inanición de las aplicaciones que acceden a medios discretos y de otras aplicaciones interactivas.

Los métodos de planificación tienen que ser aplicados a (y coordinarse para) todos los recursos que afectan a las prestaciones de las aplicaciones multimedia. En un escenario típico, un caudal multimedia será recuperado de un disco y enviado a través de la red a otra estación, donde es sincronizado con un caudal de otra fuente y finalmente será mostrado. Los recursos necesarios en el ejemplo comprenden el disco, la red, la CPU, la memoria y el ancho de banda del bus de todos los sistemas involucrados.

◊ **Planificación imparcial.** Si varios caudales compiten por el mismo recurso, se hace necesario considerar un reparto equitativo y prevenir qué caudales con comportamiento anómalo tomen demasiado ancho de banda. Una aproximación directa para asegurar la equidad es aplicar una planificación de ronda a todos los caudales de la misma clase. Mientras que este método fue introducido por Nagle [1987] basándose en paquetes, en Demers y otros [1989] se utiliza basándose en bits, lo que proporciona una mayor equidad con respecto a los tamaños y a los tiempos de llegada variables de los paquetes. Estos métodos se conocen como encolado justo.

Los paquetes no se pueden enviar bit a bit, pero dada una cierta tasa de envío de marcos se puede calcular para cada paquete cuándo debiera haber sido enviado completamente. Si las transmisiones de paquetes se ordenan basándonos en este cálculo, se consigue casi el mismo comportamiento que con la ronda actual basada en bits, excepto que cuando se envía un paquete grande, puede bloquear la transmisión de un paquete más pequeño, que podría haber sido preferido bajo un esquema bit a bit. Sin embargo, los paquetes no se retardan más que el tiempo máximo de transmisión de paquetes.

Todos los esquemas de ronda básicos asignan el mismo ancho de banda a cada caudal. Para tomar en cuenta los anchos de banda de cada uno de los caudales, se puede extender el esquema bit a bit de forma que en algunos casos se puedan enviar un número de bits por ciclo. Este método se llama encolado justo ponderado.

◊ **Planificación de tiempo real.** Se han desarrollado varios algoritmos de planificación de tiempo real para responder a las necesidades de planificación de aplicaciones como procesos de control en la industria aeronáutica. Suponiendo que los recursos de CPU no han sido sobreasignados (lo que es tarea del gestor de la QoS), los algoritmos de planificación asignarán intervalos de tiempo de CPU a un conjunto de procesos de modo que se asegure que completan sus tareas a tiempo.

Los métodos de planificación de tiempo real tradicionales se ajustan muy bien a los modelos de caudales multimedia continuos. El planificador *el más próximo tiempo límite de entrega primero*, (*earliest-deadline-first*, EDF) se ha convertido en sinónimo de estos métodos. Un planificador EDF utiliza un tiempo de entrega límite asociado con cada elemento de trabajo para determinar el siguiente ítem a procesar: el ítem con el tiempo de entrega límite más cercano será el siguiente. En las aplicaciones multimedia, identificamos cada elemento entrante como un elemento de trabajo. El planificador EDF ha demostrado ser óptimo para reservar un recurso único basándose en criterios de tiempo: si existe una planificación que cumpla todos los requisitos temporales, la planificación EDF la encontrará [Dertouzos 1974].

La planificación EDF necesita una sola decisión de planificación por mensaje (o lo que es lo mismo, por elemento multimedia). Podría ser más eficiente basar la planificación en los elementos que existen por un tiempo más largo. La planificación de tasa monótona (*rate-monotonic*), RM, es una técnica prominente de planificación en tiempo real que consigue eso con procesos periódicos. Los caudales reciben prioridades dependiendo de su tasa: cuando mayor la tasa de elementos de trabajo que tenga un caudal, mayor será la prioridad asignada al caudal. La planificación RM se ha

mostrado óptima en situaciones en las que se utiliza menos del 69 por ciento del ancho de banda [Liu y Layland 1973]. Utilizándolo como un esquema de reserva, el ancho de banda remanente podría ser asignado a las aplicaciones que no sean de tiempo real.

Para tratar con las ráfagas de tráfico de tiempo real, los métodos básicos de planificación de tiempo real deberían ajustarse para distinguir entre elementos de trabajo críticos respecto al tiempo y aquellos que no lo son. En Govindan y Anderson [1991] se presenta una planificación *tiempo entrega límite/trabajo adelantado*. Dicha planificación permite que los mensajes de un caudal continuo lleguen antes de tiempo en ráfagas, pero aplica la planificación EDF a los mensajes sólo cuando se cumple su tiempo de llegada normal.

15.5. ADAPTACIÓN DE CAUDALES

Cuando no se puede garantizar una cierta QoS o sólo se puede garantizar con una cierta probabilidad, una aplicación necesita adaptarse a niveles de QoS cambiantes, ajustando sus prestaciones de manera acorde. Para los caudales multimedia continuos, los ajustes se traducen en diferentes niveles de calidad en la presentación de los medios.

La forma más simple de ajuste es desechar elementos de información. Esto es fácilmente realizable en los caudales de audio, donde las muestras son independientes unas de otras, pero pueden ser detectadas inmediatamente por el que escucha. Desechar en un caudal de vídeo codificado en Motion JPEG, donde cada marco es independiente, es más tolerable. Los mecanismos de codificación como MPEG, donde la interpretación de un marco depende de los valores de varios marcos adyacentes, son menos robustos frente a las omisiones: necesitan más tiempo para recuperarse de los errores y el mecanismo de codificación puede amplificar los errores.

Si hay un ancho de banda insuficiente y los datos no son desechados, el retardo de un caudal se incrementará en el tiempo. Para las aplicaciones no interactivas esto puede ser aceptable, aunque pueda conducir eventualmente a desbordamientos del búfer ya que los datos se acumulan entre el origen y el destino. Para conferencias y otras aplicaciones interactivas, los retardos incrementales no son aceptables, o deben existir sólo en un período corto de tiempo. Si un caudal va detrás de su tiempo de reproducción, debería aumentarse su tasa de reproducción hasta alcanzar su planificación prevista: mientras un caudal esté retrasado, sus marcos deberían ser procesados y deberían salir tan pronto estén disponibles.

15.5.1. ESCALADO

Si la adaptación se produce en el destino de un caudal, no se reducirá la carga de cualquier cuello de botella del sistema, y la situación de sobrecarga continuará. Para resolver esta contención, será útil adaptar el caudal al ancho de banda disponible en el sistema antes de que entre en cuello de botella de recurso. Esto se conoce como escalado.

El escalado se aplica mejor cuando se muestran caudales vivos. Para caudales almacenados, la facilidad para obtener un caudal de menor grado dependerá del método de codificación utilizado. El escalado puede ser demasiado engorroso si se tiene que descomprimir el caudal entero y codificarlo otra vez para dicho propósito. Los algoritmos de escalado son dependientes del medio, aunque la aproximación general del escalado es siempre la misma: obtener una muestra de calidad inferior de la señal dada. Para información de audio, tales muestrazos de calidad inferior se pueden conseguir reduciendo las tasas de muestreo. También se pueden conseguir desechar un canal de una transmisión estéreo. Como muestra este ejemplo, diferentes métodos de escalado pueden servir para diferentes niveles de detalle.

Para vídeo, los siguientes métodos de escalado son apropiados:

Escalado temporal: reduce la resolución del caudal de vídeo en el dominio del tiempo decrementando el número de marcos de vídeo enviados dentro de un intervalo de tiempo. El escalado temporal es la mejor elección para los caudales de vídeo en los que los marcos son autocontenidos y se pueden acceder de forma independiente. Las técnicas de compresión delta son más difíciles de manejar ya que no todos los marcos pueden ser desechados fácilmente. Por lo tanto, el escalado temporal es más adecuado para caudales Motion JPEG que para MPEG.

Escalado espacial: reduce el número de píxeles (puntos de la imagen) de cada imagen en el caudal de vídeo. Para el escalado espacial, la disposición jerárquica resulta ideal, porque el vídeo comprimido está disponible inmediatamente en varias resoluciones. Por lo tanto, el vídeo puede ser transferido sobre la red utilizando diferentes resoluciones sin almacenar cada imagen antes de transmitirla finalmente. JPEG y MPEG-2 soportan diferentes resoluciones espaciales de las imágenes y son adecuados para este tipo de escalado.

Escalado en frecuencia: modifican el algoritmo de compresión aplicado a una imagen. Esto produce una cierta pérdida de calidad, pero en una imagen típica, se puede incrementar significativamente la compresión antes de que la reducción de calidad se vuelva visible.

Escalado en amplitud: reduce la profundidad de color para cada píxel de imagen. Este método de escalado se utiliza en las codificaciones H.261 para conseguir que las imágenes lleguen a una tasa constante cuando los contenidos varían.

Escalado en el espacio del color: reduce el número de entradas en el espacio del color. Una forma de realizarlo es pasando una imagen en color a otra en escala de grises.

Se puede utilizar una combinación de estos métodos si fuera necesario.

Un sistema para efectuar escalado está compuesto por un monitor de procesos en el destino y un proceso de escalado en el origen. El monitor lleva cuenta de los tiempos de llegada de los mensajes de un caudal. Los mensajes retrasados son una indicación de la existencia de un cuello de botella en el sistema. El monitor envía un mensaje de disminuir la escala a la fuente y entonces la fuente reduce el ancho de banda del caudal. Después de un período de tiempo, la fuente aumenta la escala otra vez. Si el cuello de botella todavía existiera, el monitor volvería a detectar el retraso y mandaría disminuir la escala [Delgrossi y otros 1993]. Un problema en los sistemas de escalado es evitar las operaciones de aumento de escala innecesarias y prevenir las oscilaciones en el sistema.

15.5.2. FILTRADO

Como el escalado modifica el caudal en el origen, no siempre resulta adecuado para las aplicaciones que involucran varios receptores: cuando el cuello de botella se produce en la ruta a un destino, este destino envía un mensaje al origen para disminuir la escala, y a partir de este momento todos los receptores recibirán un caudal de menor calidad, aunque alguno de ellos no hubiera tenido problemas para manejar el caudal original.

El filtrado es un método que proporciona la QoS mejor posible a cada destino aplicando escalado en cada nodo representativo en el camino desde el origen a cada destino (véase la Figura 15.9). El protocolo RSVP [Zhang y otros 1993] es un ejemplo de protocolo de negociación que soporta filtrado. El filtrado requiere que un caudal sea descompuesto en un conjunto de subcaudales jerárquicos, cada uno añadiendo un nivel superior de calidad. La capacidad de los nodos de un camino determina el número de subcaudales que recibe un destino. Los demás subcaudales serán filtrados en nodos lo más cercanos posible al origen (quizás incluso en el mismo origen) para evitar la transferencia de datos que serán desechados después. Un subcaudal no es filtrado en un nodo intermedio si existe mas allá un camino que puede soportar el caudal entero.

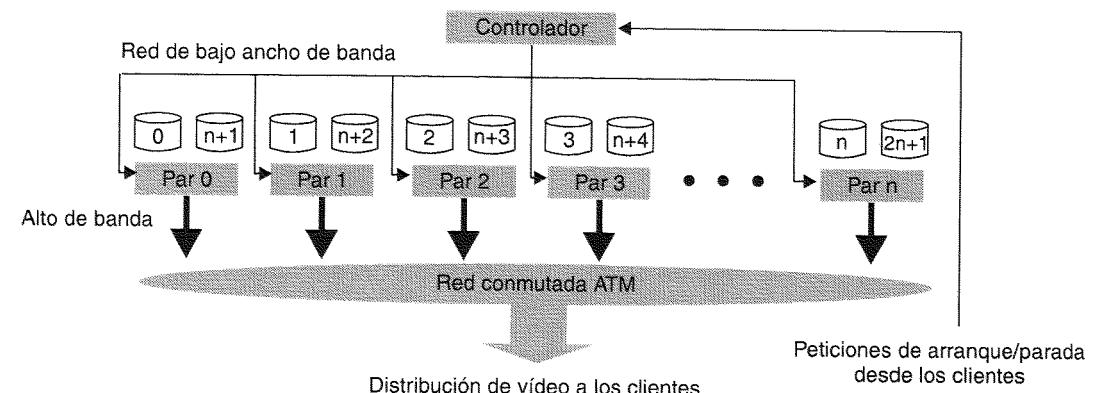
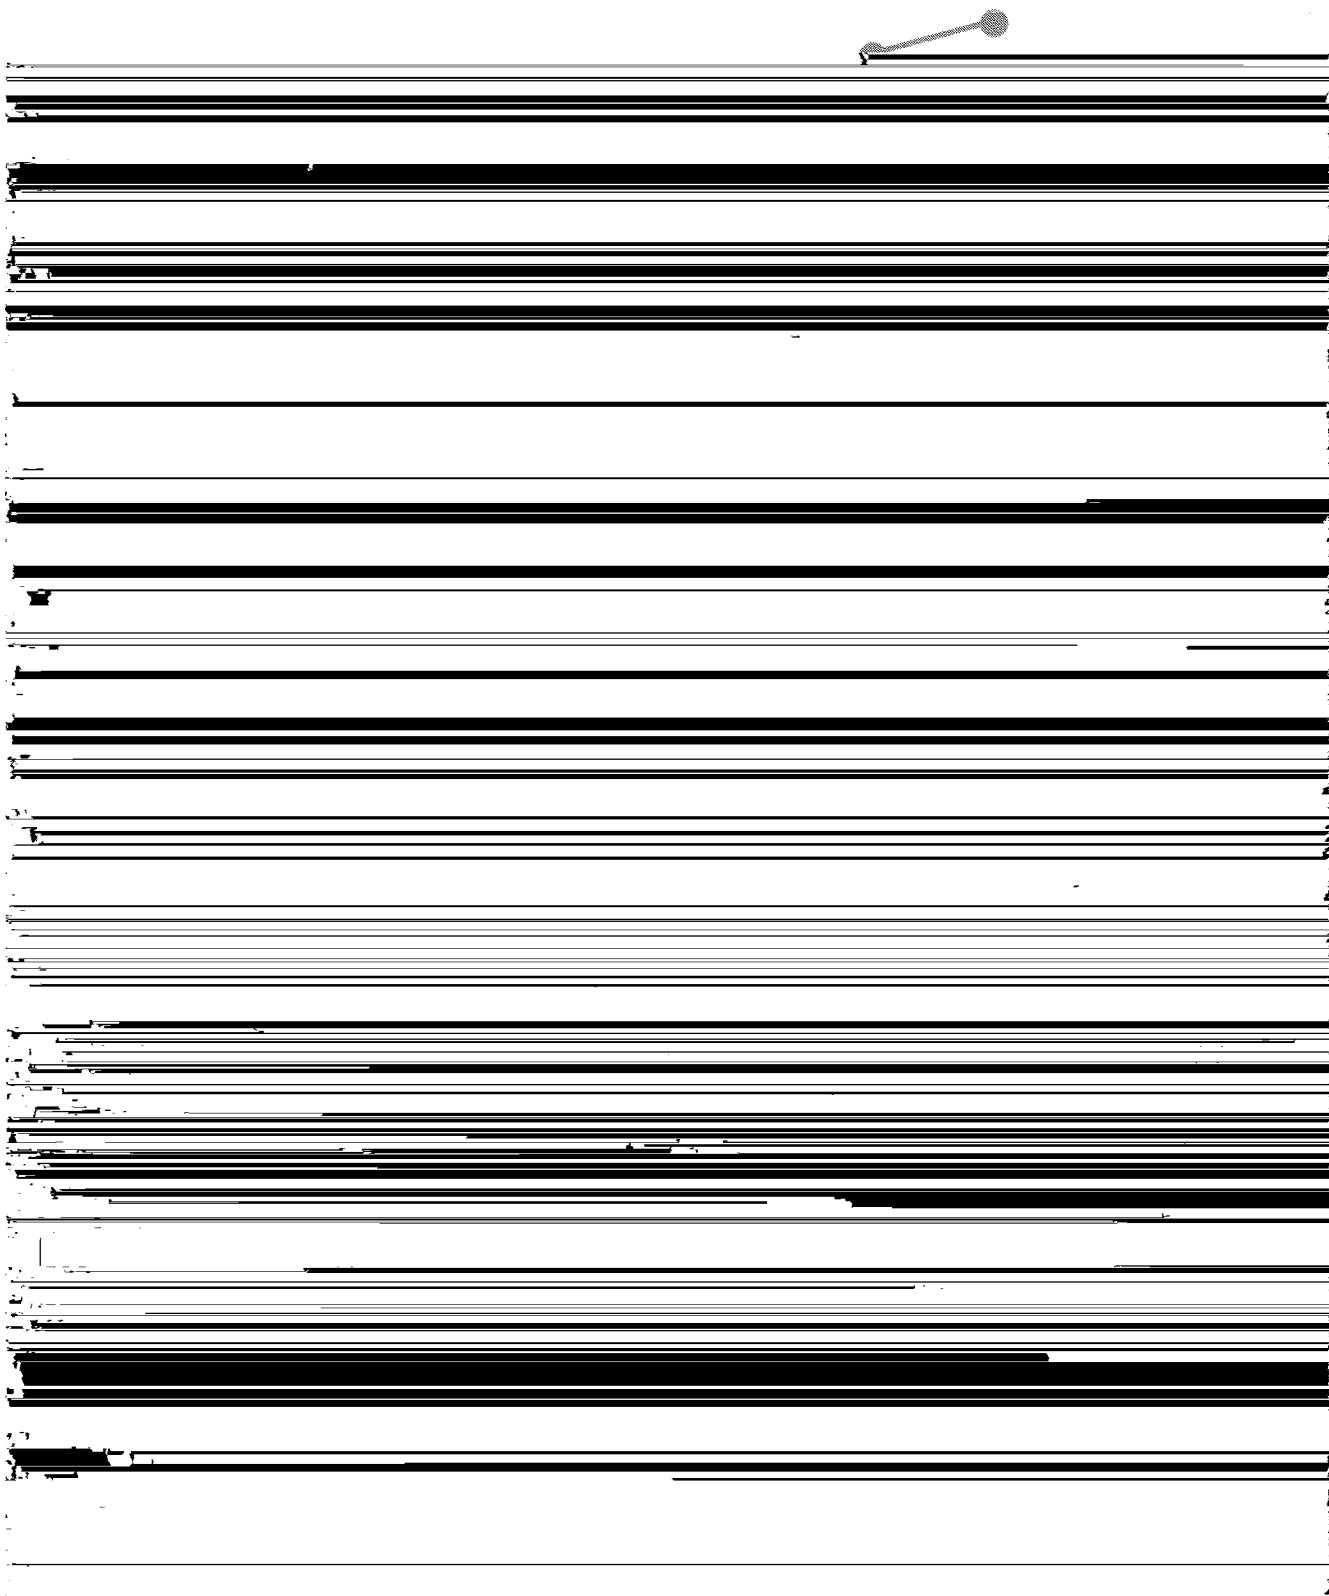


Figura 15.10. Configuración hardware del servidor de vídeo Tiger.

pados con tarjetas de red Ethernet y ATM. El *controlador* es otro PC. No está involucrado en la gestión de datos multimedia y únicamente es responsable de la gestión de las peticiones de los clientes y de la gestión de la planificación del trabajo en los pares.

◊ **Organización del almacenamiento.** La clave en el diseño es la distribución de los datos de vídeo entre los discos de los pares para hacer posible que comparten la carga. Cualquier solución basada en el uso de un único disco para almacenar cada película es difícil que consiga el objetivo, ya que la carga puede implicar la aportación de múltiples caudales de la misma película así como caudales de distintas películas. En su lugar, las películas se almacenan en una representación de franjas a lo largo de todos los discos. Esto conduce a un modelo de fallos en el cual la pérdida de un disco o de un par produce un hueco vacío en la secuencia de cada película. Esto se puede solucionar con un esquema de almacenamiento reflejado, que replica los datos, y por un mecanismo de tolerancia a fallos, según se describe más abajo.

Franjas: Una película se divide en *bloques* (trozos de vídeo de igual tiempo de reproducción, generalmente alrededor de 1 segundo, ocupando 0,5 Mbytes), y el conjunto de bloques que componen una película (normalmente unos 7.000 para una película de dos horas) se almacena en discos de distintos pares según la secuencia indicada por los números de los discos de la Figura 15.10. Una película puede comenzar en cualquier disco. Cuando se alcanza el disco de mayor numeración, la película *da la vuelta* de modo que el siguiente bloque está almacenado en el disco 0 y el proceso continúa.

Espejado: El esquema de reflejado divide cada bloque en varias porciones, llamadas *secundarias*. Esto asegura que cuando un par falla, la carga extra de proporcionar los datos de los bloques del par caído se reparte entre varios de los pares restantes, y no sólo en uno de ellos. El número de secundarios por bloque está determinado por un *factor de disociación*, *d*, con valores típicos en el rango de 4 a 8. Los secundarios de un bloque almacenado en el disco *i* son almacenados en los discos del *i* + 1 al *i* + *d*. Hay que destacar que si hay más de *d* pares, ninguno de esos discos estará en el mismo par que el disco *i*. Con un factor de disociación de 8, aproximadamente 7/8 de la capacidad de proceso y del ancho de banda de los pares se puede reservar para las tareas libres de fallos. El 1/8 restante de sus recursos deberían ser suficientes para servir los secundarios cuando sea necesario.

◊ **Planificación distribuida.** El corazón del diseño de Tiger es la planificación de la carga de trabajo para los pares. La planificación está organizada según una lista de *ranuras*, donde cada ranura representa el trabajo que se debe realizar para reproducir un bloque de una película; esto es,

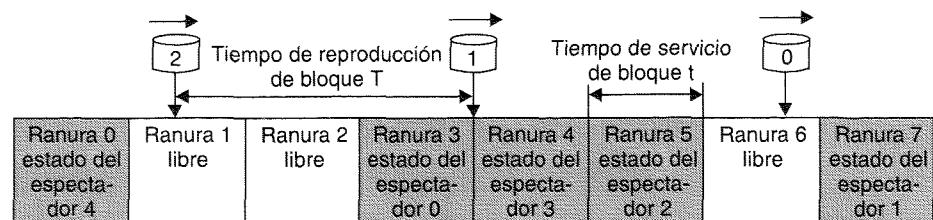


Figura 15.11. Planificación del servidor Tiger.

para leerlo del disco relevante y transferirlo a la red ATM. Hay exactamente una ranura para cada cliente potencial que reciba una película (llamado *espectador*), y cada ranura ocupada representa un espectador recibiendo un caudal de vídeo en tiempo real. El estado de reproducción está representado en el planificador por:

- La dirección del computador cliente.
- La identidad del archivo que se está reproduciendo.
- La posición del espectador en el archivo (el siguiente bloque que hay que entregar al caudal).
- La número de secuencia de reproducción (a partir de la cual se calcula el tiempo de entrega del siguiente bloque).
- Alguna información sobre la reserva.

La planificación se ilustra en la Figura 15.11. El *tiempo de reproducción del bloque T* es el tiempo que será necesario para que un reproductor muestre un bloque en el computador cliente, normalmente es de alrededor de un segundo y se supone que es el mismo para todas las películas almacenadas. El servidor Tiger debe, por lo tanto, mantener un intervalo de tiempo T entre los instantes de entrega de los bloques de cada caudal, con un salto admisible determinado por el almacenamiento disponible en los computadores clientes.

Cada par mantiene un apuntador a la planificación por cada disco que controla. Durante el tiempo de reproducción de cada bloque debe procesar todas las ranuras con números de bloque que caigan en los discos que controla y cuyos tiempos de entrega estén dentro del tiempo de reproducción de bloque actual. Los pasos que siguen los pares para procesar las ranuras en tiempo real son:

1. Leer el siguiente bloque del almacenamiento del par.
2. Empaquetar el bloque con la dirección del computador cliente y entregarlo al controlador de la red ATM del par.
3. Actualizar el estado de reproducción indicando el siguiente número de bloque y número de secuencia de reproducción y pasar la ranura actualizada al siguiente par.

Se supone que estas acciones ocupan un tiempo máximo t , conocido como *tiempo de servicio de bloque*. Como se puede observar en la Figura 15.11, t es substancialmente menor que el tiempo de reproducción de bloque. El valor de t está determinado por el ancho de banda del disco o de la red, dependiendo de cuál sea el más pequeño. (Los recursos de procesamiento en un par son adecuados para ejecutar el trabajo planificado para todos los discos a él conectados a él.) Cuando un par ha completado las tareas planificadas para el tiempo de reproducción de bloque actual, estará disponible para las tareas no planificadas hasta el comienzo del siguiente tiempo de reproducción. En la práctica, los discos no proporcionan bloques con un retardo fijo, y para subsanar esta entrega irregular la lectura en el disco se inicia al menos un tiempo de servicio de bloque antes de que el bloque sea necesario para empaquetar y entregar.

Un disco puede manejar la carga de servir T/t caudales, y los valores de T y de t generalmente dan un valor > 4 para esta relación. Esto y el número de discos en el sistema entero determinan el

número de espectadores que puede servir un sistema Tiger. Por ejemplo, un sistema Tiger con cinco pares y tres discos en cada par entregará aproximadamente 70 caudales de vídeo simultáneos.

◊ **Tolerancia a fallos.** Dado que los archivos de todas las películas se hallan repartidos sobre todos los discos en el sistema Tiger, el fallo de cualquier componente (disco o par) podría producir un interrupción en el servicio a todos los clientes. El diseño de Tiger remedia esto recuperando los datos de las copias secundarias reflejadas cuando un bloque primario no está disponible ya sea por un fallo del disco o del par correspondiente. Hay que recordar que los bloques secundarios son de menor tamaño que los primarios en una proporción dada por el factor de disociación d , y que los secundarios están distribuidos de modo que se almacenan en discos de distintos pares.

Cuando un disco o un par falla, la planificación se modifica por un par adyacente para indicar varios *estados de reproducción reflejados*, representando una carga de trabajo para los d discos que albergan los secundarios para esas películas. Un estado de reproducción reflejado es similar a un estado de reproducción pero con números de bloque y requisitos de sincronización distintos. Debido a que esta carga de trabajo extra es compartida entre d discos y d pares, puede ser soportada sin interrumpir las tareas de las otras ranuras, gracias a que hay una pequeña cantidad de espacio libre en la planificación. El fallo de un par es equivalente al fallo de todos los discos que contiene y se gestiona de un modo similar.

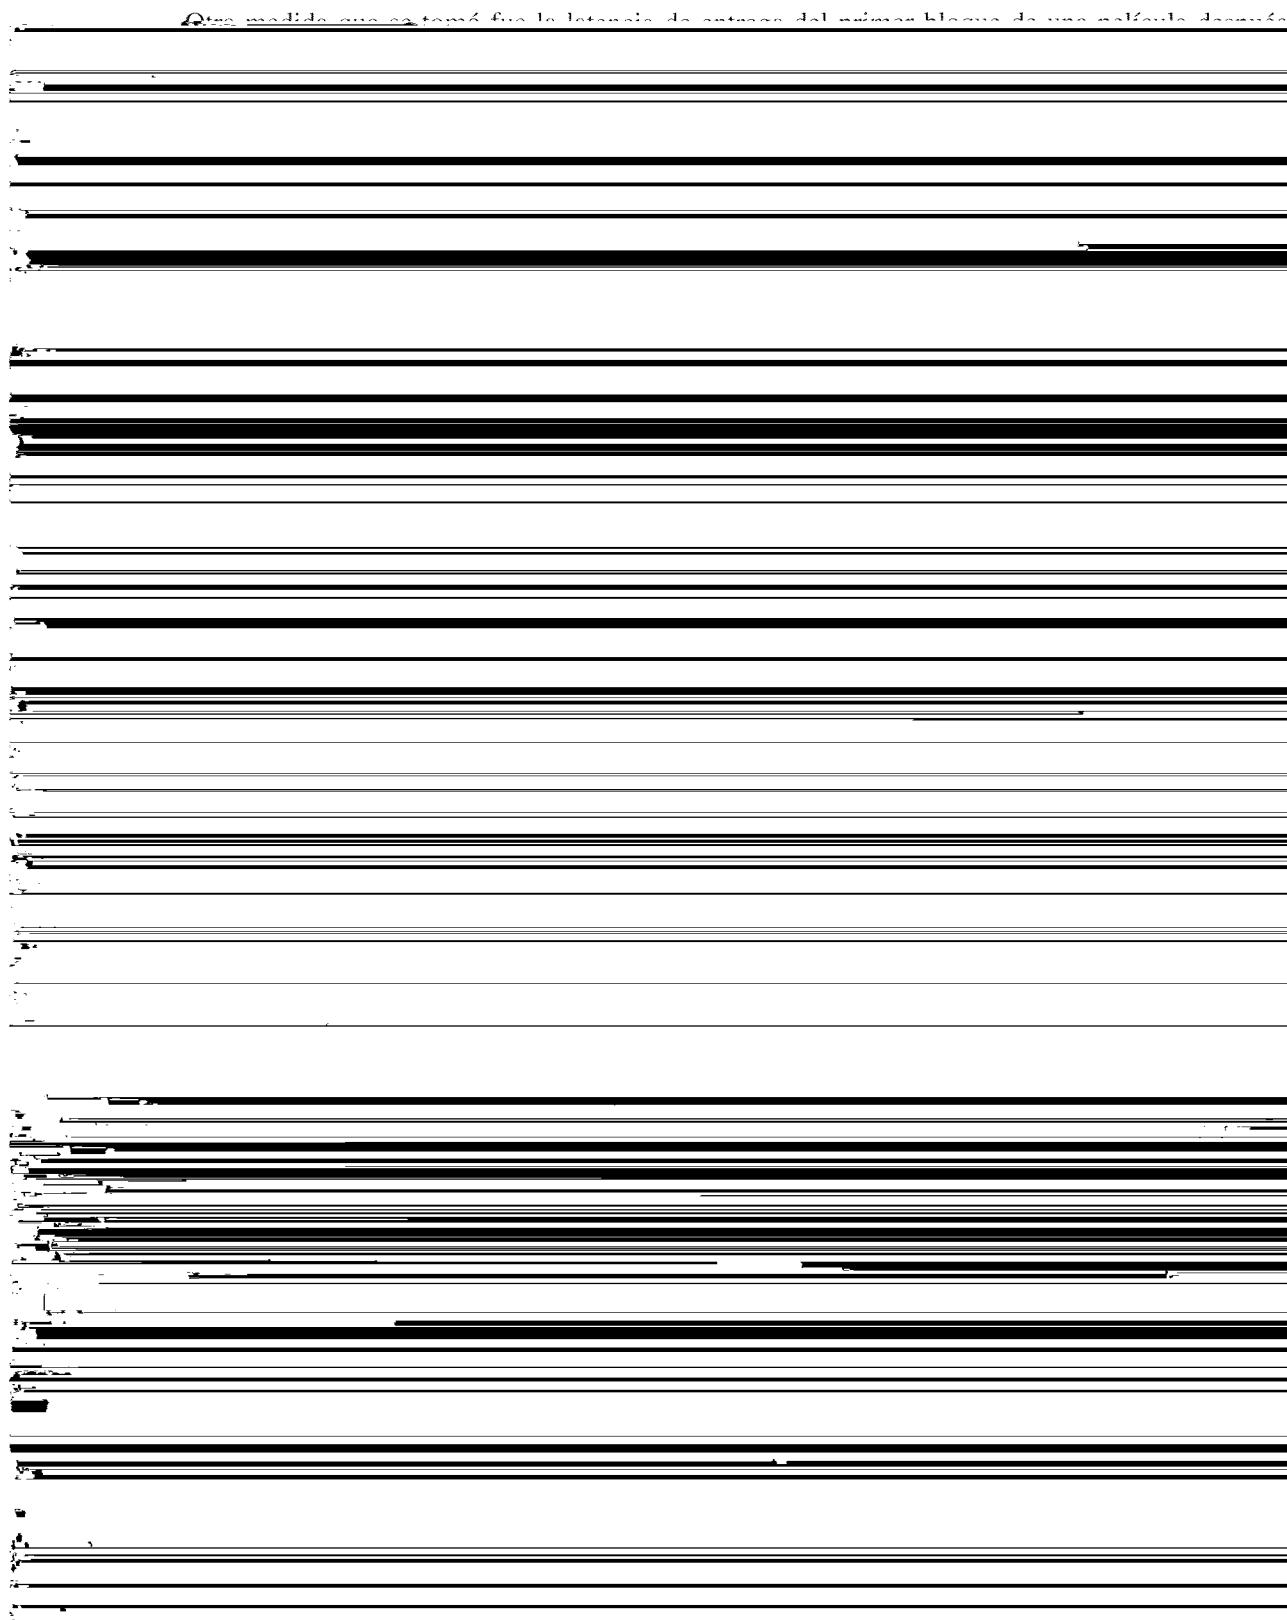
◊ **Soporte de red.** Los bloques de cada película son simplemente pasados a la red ATM por los pares que los contienen, junto con la dirección del cliente. Se confía en la QoS garantizada por los protocolos de red ATM (véase la Sección 3.5.3) para que la entrega de los bloques a los clientes se haga en secuencia y a tiempo. El cliente necesita suficiente espacio de almacenamiento para almacenar dos bloques primarios, uno que se está reproduciendo en la pantalla del cliente y el otro que está llegando por la red. Cuando los bloques primarios están siendo servidos, el cliente necesita comprobar el número de secuencia de cada bloque que llega y pasárselo al gestor de la reproducción. Cuando se sirven secundarios, los d pares responsables de entregar los secundarios del bloque disociado mandan sus secundarios a la red en secuencia, y es responsabilidad del cliente recogerlos y ensamblarlos en su espacio de almacenamiento.

◊ **Otras funciones.** Hemos descrito las actividades críticas respecto al tiempo de un servidor Tiger. Los requisitos de diseño incluían la consideración de las funciones de avance rápido y de rebobinado. Estas funciones implican la entrega de alguna fracción de bloques de la película al cliente de forma que se dé la impresión visual aportada por los reproductores de vídeo clásicos. Esto se realiza por los pares en tiempo fuera de la planificación y según el mejor esfuerzo posible.

Las tareas restantes incluyen la gestión y distribución de la planificación y la gestión de la base de datos de películas, borrado de las antiguas y escritura de las nuevas en los discos, y mantenimiento del índice de películas.

En la implementación inicial del servidor Tiger, la gestión y distribución de la planificación era realizada por el computador controlador. Pero como esto constituye un punto único de fallo y un potencial cuello de botella en las prestaciones, la gestión de la planificación se rediseñó como un algoritmo distribuido [Bolosky y otros 1997]. La gestión de la base de datos de películas se lleva a cabo por los pares en el tiempo no planificado en respuesta a comandos del controlador.

◊ **Prestaciones y escalabilidad.** El prototipo inicial fue desarrollado en 1994 y utilizó cinco PCs Pentium a 133 MHz, cada uno de ellos equipado con 48 Mbytes de RAM y tres discos SCSI de 2 Gbytes y un controlador de red ATM, corriendo sobre Windows NT. Esta configuración fue medida sobre una carga de clientes simulada. Cuando se servía películas a 68 clientes sin fallos en el sistema Tiger, la entrega de datos era perfecta; no se perdieron bloques ni se entregaron tarde a los clientes. Con un par caído (y por lo tanto tres discos) el servicio fue mantenido con una tasa de pérdidas de tan sólo 0,02 por ciento, dentro de los objetivos de diseño.



- 15.2. Internet actualmente no ofrece ninguna posibilidad de reserva de recursos ni de gestión de la calidad del servicio. ¿Cómo consiguen una calidad aceptable las aplicaciones existentes de audio y vídeo basadas en Internet? ¿Qué limitaciones imponen a las aplicaciones multimedia las soluciones que adoptan?
- 15.3. Explique las diferencias entre las tres formas de sincronización (estado distribuido síncrono, sincronización de medios, sincronización externa) que pueden necesitarse en las aplicaciones multimedia distribuidas. Sugiera mecanismos por los que cualquiera de ellas pueda ser conseguida, por ejemplo en una aplicación de videoconferencia.
- 15.4. Esboce el diseño de un gestor de QoS que posibilite que computadoras conectadas por una red ATM soporten varias aplicaciones multimedia concurrentes. Defina un API para su gestor de QoS, dando las operaciones principales con sus argumentos.
- 15.5. Para especificar las necesidades de componentes software que procesen datos multimedia, necesitamos estimar sus cargas de procesamiento. ¿Cómo se puede obtener esta información sin un esfuerzo excesivo?
- 15.6. ¿Cómo hace el sistema Tiger para soportar un gran número de clientes todos solicitando la misma película en instantes de tiempo aleatorios?
- 15.7. La planificación del servidor Tiger es potencialmente una estructura de datos que cambia frecuentemente, pero cada par necesita una representación actualizada de las porciones que está gestionando actualmente. Sugiera un mecanismo para la distribución de la planificación entre los pares.
- 15.8. Cuando el sistema Tiger trabaja con un disco caído o con un par caído, los bloques de datos secundarios se utilizan para sustituir a los primarios perdidos. Los bloques secundarios son n veces más pequeños que los primarios (donde n es el factor de disociación), ¿cómo hace el sistema para acomodarse a la variabilidad en el tamaño del bloque?

MEMORIA COMPARTIDA DISTRIBUIDA

- 16.1. Introducción
- 16.2. Cuestiones de diseño e implementación
- 16.3. Consistencia secuencial e Ivy
- 16.4. Liberación de consistencia y Munin
- 16.5. Otros modelos de consistencia
- 16.6. Resumen

En este capítulo se describe la memoria compartida distribuida (*Distributed Shared Memory*, DSM), una abstracción utilizada para la compartición de datos entre procesos en computadores que no comparten su memoria física. La motivación de DSM consiste en poder utilizar un modelo de programación de memoria compartida, que tiene algunas ventajas sobre los modelos basados en mensajes. Por ejemplo, en DSM los programadores no tienen que empaquetar los datos para su envío.

El principal problema en las implementaciones DSM es cómo conseguir mantener unas buenas prestaciones a medida que crece el número de computadores del sistema. Los accesos a DSM implican la utilización potencial de la red de comunicaciones. Los procesos que compiten para acceder a los mismos datos o a datos cercanos pueden generar un gran número de operaciones de comunicación. La cantidad de operaciones de comunicación está muy relacionada con el modelo de consistencia en un sistema DSM; éste es el modelo que determina cuál de los múltiples datos escritos deberá devolverse cuando el proceso lee desde una cierta posición DSM.

En este capítulo se discuten cuestiones de diseño de DSM, como el modelo de consistencia, y cuestiones de implementación, como cuál de las copias de un mismo dato son invalidadas o actualizadas cuando el dato es modificado. Los protocolos de invalidación se estudian con mayor nivel de detalle. Finalmente se describe la consistencia relajada (*release*), un modelo de consistencia relativamente débil, adecuado para múltiples propósitos y poco costoso en su implementación.

La importancia de DSM ha crecido junto con el desarrollo de los multiprocesadores de memoria compartida (véase la Sección 6.3). Una gran parte de la investigación se ha orientado al desarrollo de algoritmos adaptados para la computación paralela en ese tipo de multiprocesadores. En el nivel de arquitectura del hardware, los desarrollos incluyen estrategias de memoria caché e interconexiones rápidas procesador-memoria con el objetivo de maximizar el número de procesadores que pueden ser conectados manteniéndose la productividad y minimizando las latencias de accesos a memoria [Dubois y otros 1988]. Si los procesadores se conectan a los módulos de memoria mediante bus común, el límite práctico oscila entre diez y veinte procesadores antes de que las prestaciones se degraden de forma drástica debido a la contención en el bus. Los procesadores que comparten memoria se agrupan normalmente de cuatro en cuatro, compartiendo cada grupo un módulo de memoria sobre un bus en un único circuito impreso. Se construyen de esta forma multiprocesadores con hasta 64 procesadores en arquitectura de *Memoria de Acceso No Uniforme (Non-Uniform Memory Access, NUMA)*. Se trata de una arquitectura jerárquica en la que las placas de cuatro procesadores se conectan entre sí utilizando un switch de altas prestaciones o un bus de alto nivel. En una arquitectura NUMA, los procesadores ven un único espacio de direcciones que contiene toda la memoria de todos los circuitos. Sin embargo, la latencia de acceso para la memoria dentro del mismo circuito es menor que la de acceso a un módulo de memoria de una tarjeta diferente, de ahí el nombre de la arquitectura.

En los *multiprocesadores de memoria distribuida* los procesadores no comparten memoria pero se conectan mediante una red de muy altas prestaciones. Estos multiprocesadores, al igual que en los sistemas distribuidos de propósito general, pueden escalar hasta un número mucho mayor de procesadores o computadores que los 64 de los multiprocesadores de memoria compartida. Una cuestión central perseguida por la comunidad investigadora de multiprocesadores y DSM, es si la inversión en conocimiento sobre algoritmos de memoria compartida y el software asociado puede ser directamente transferida a una arquitectura de memoria distribuida más escalable.

16.1.1. DSM FRENTE A PASO DE MENSAJES

Como mecanismo de comunicación, DSM es comparable con los sistemas de paso de mensajes en lugar de con la comunicación basada en peticiones y respuestas, ya que su aplicación concreta al procesamiento paralelo impone el uso de comunicación asíncrona. Los sistemas de programación DSM y de paso de mensajes pueden compararse de la siguiente forma:

Modelo de programación: en el modelo de paso de mensajes, las variables deben empaquetarse desde un cierto proceso, transmitirse y desempaquetarse sobre variables en el proceso receptor. Por el contrario, con memoria compartida, los procesos involucrados comparten directamente las variables, de forma que el empaquetamiento no es necesario (incluso cuando se trata de punteros a variables compartidas) y por lo tanto no son necesarias operaciones de comunicación separadas. La mayor parte de las implementaciones permiten nombrar y acceder a las variables almacenadas en DSM de forma similar a las variables no compartidas. Un aspecto favorable a los sistemas de paso de mensajes es que permiten que los procesos se comuniquen mientras se protegen entre ellos al disponer de espacios de direcciones privados, mientras que los procesos compartiendo DSM pueden, por ejemplo, provocar fallos entre ellos mediante la alteración errónea de los datos. Es más, el empaquetamiento en los sistemas de paso de mensajes entre computadores heterogéneos, resuelve las diferencias en la representación de los datos; pero, ¿cómo puede compartirse memoria entre computadores que, por ejemplo, representan los enteros de forma diferente?

La sincronización entre procesos se consigue, en el modelo de mensajes, mediante las propias primitivas de paso de mensajes, utilizando técnicas como la implementación del servidor

Middleware: algunos lenguajes del tipo de Orca [Bal y otros 1990] y middleware como Linda [Carriero y Gelernter 1989] junto con sus derivados JavaSpaces [java.sun.com VI] y TSpaces [Wyckoff y otros 1998] proporcionan DSM sin necesidad de soporte hardware o de paginación, de una forma independiente de la plataforma. En este tipo de implementación, la compartición se implementa mediante la comunicación entre instancias del nivel de soporte de usuario en los clientes y los servidores. Los procesos realizan llamadas a este nivel cuando acceden a datos en DSM. Las instancias de este nivel en las diferentes computadoras acceden a los datos locales y se intercambian información siempre que sea necesario para el mantenimiento de la consistencia.

Este capítulo se ha enfocado a la utilización del software para implementar DSM sobre computadores estándar. Incluso con soporte hardware, se pueden utilizar técnicas software de alto nivel para minimizar la cantidad de comunicación entre componentes de una implementación DSM.

La aproximación basada en páginas tiene la ventaja de que no impone una estructura particular en la DSM, que se muestra como una secuencia de bytes. Inicialmente permite que los programas diseñados para multiprocesadores de memoria compartida se ejecuten en computadores sin memoria compartida, con muy poca o ninguna adaptación. Los micronúcleos como Mach y Chorus proporcionan soporte nativo para DSM (y otras abstracciones de memoria; los recursos de memoria virtual en Mach serán descritos en el Capítulo 18). Actualmente, los sistemas DSM basados en páginas son implementados en su mayor parte en el nivel de usuario debido a su mayor flexibilidad. La implementación utiliza el soporte del núcleo para los manejadores de fallos de las páginas de nivel de usuario. UNIX y algunas variantes de Windows proporcionan esta posibilidad. Los microprocesadores con espacios de direcciones de 64-bits amplían el ámbito de los sistemas DSM basados en páginas mediante la relajación de las restricciones en la gestión del espacio de direcciones [Bartoli y otros 1993].

En el ejemplo de la Figura 16.2 aparecen dos programas en C, *Lector* y *Escritor*, que se comu-

```
#include "world.h"
struct compartida { int a, b; };

Programa Escritor:
main()
{
    struct compartida *p;
    methersetup(); /* Inicialización del sistema Mether */
    p = (struct compartida *)METHERBASE;
    /* estructura de overlay en el segmento METHER */
    /* inicialización a cero de los campos de la estructura */
    /* actualización continua de los campos de la estructura */
    p->a=p->b=0;
    while (TRUE){
        p->a=p->a+1;
        p->b=p->b-1;
    }
}
Programa Lector:
main()
{
    struct compartida *p;
    methersetup();
    p=(struct compartida *)METHERBASE;
    while(TRUE){ /* lectura de los campos una vez por segundo */
        printf("a=%d, b=%d\n", p->a, p->b);
        sleep(1);
    }
}
```

Figura 16.2. Programa en el sistema Mether.

nican a través de la DSM basada en páginas proporcionadas por el sistema Mether [Minnich y Farber 1989]. *Escrivtor* actualiza dos campos de una estructura asociada al principio de un segmento DSM en Mether (comenzando en la dirección METHERBASE) y *Lector*, imprime periódicamente los valores que lee de esos dos campos.

No existen operaciones especiales en los dos programas anteriores; se compilan para generar instrucciones máquina que acceden al rango común de direcciones de memoria virtual (comenzando a partir de METHERBASE). Mether se ejecutó en estaciones de trabajo convencionales Sun interconectadas por una red.

La aproximación del middleware es muy diferente a la utilización de hardware especializado y paginación ya que no está pensado para utilizar código existente de memoria compartida. Su importancia estriba en que nos permite el desarrollo de abstracciones de mayor nivel sobre objetos compartidos, en lugar de hacerlo sobre posiciones de memoria compartidas.

16.2. CUESTIONES DE DISEÑO E IMPLEMENTACIÓN

En esta sección se discuten las opciones de diseño e implementación relativas a las principales características de un sistema DSM. Es decir, se discute la estructura de los datos gestionados en DSM; el modelo de sincronización utilizado para acceder a DSM de forma consistente desde el nivel de aplicación; el modelo de consistencia de DSM, encargado de gobernar la consistencia de datos accedidos desde diferentes computadores; las opciones de actualización para la comunicación de valores escritos en diferentes computadores; la granularidad de la compartición en una implementación DSM; y el problema del *thrashing* (fustigamiento).

16.2.1. ESTRUCTURA

En el Capítulo 14 estudiamos sistemas que replicaban una colección de objetos como diarios y archivos. Estos sistemas permiten a los programas cliente realizar operaciones sobre los objetos como si existiera únicamente una copia de cada objeto, aunque en realidad están accediendo a réplicas físicas diferentes. Estos sistemas ofrecen garantías acerca de hasta qué punto se permite que se diferencien los objetos.

Un sistema DSM es equivalente a estos sistemas de replicación. Cada proceso de aplicación dispone de una abstracción de una colección de objetos, pero en este caso la *colección* tiene un aspecto muy parecido al que ofrece la memoria. Es decir, los objetos pueden ser direccionados de una u otra forma. Las diferentes aproximaciones de DSM difieren entre sí en qué es lo que consideran un *objeto* y en cómo se direccionan los objetos. Consideramos tres aproximaciones, que tienen una visión de DSM como formada por, respectivamente, una secuencia contigua de bytes, objetos de nivel de lenguaje o datos inmutables.

◇ **Orientada a byte.** Este tipo de DSM se utiliza como la memoria virtual ordinaria, es decir, como una cadena de bytes contiguos. Es la visión del sistema Mether explicada previamente. También es la imagen proporcionada por muchos otros sistemas DSM, incluyendo Ivy, que será descrito en la Sección 16.3. Permite que las aplicaciones (y las implementaciones de los lenguajes) almacenen cualquier tipo de estructura de datos sobre la memoria compartida. Los objetos compartidos son posiciones de memoria direccionables directamente (en la práctica, las posiciones de memoria pueden ser palabras multi-byte en lugar de bytes individuales). Las únicas operaciones permitidas

sobre esos objetos son *lee* (o LOAD) y *escribe* (o STORE). Si x e y son dos posiciones de memoria, las dos operaciones tienen la siguiente notación:

$L(x)a$ – una operación de *lectura* del valor a desde la posición x .

$E(x)b$ – una operación de *escritura* que almacena el valor b en la posición x .

Un ejemplo de ejecución es $E(x)1, L(x)2$. Este proceso escribe el valor 1 en la posición x y lee el valor 2 desde la misma posición. Otro proceso debe haber sido el encargado de escribir el valor 2 en la posición compartida.

◇ **Orientado a objetos.** La memoria compartida se estructura como una colección de objetos de nivel de lenguaje, como pilas o diccionarios, con una semántica de mayor nivel que la simple de *lectura/escritura* de variables. Los contenidos de la memoria compartida se modifican únicamente mediante invocaciones sobre dichos objetos y nunca a través del acceso directo a sus variables miembro. Una ventaja de esta visión de la memoria es que la semántica de objetos puede utilizarse para forzar la consistencia. La visión de DSM proporcionada por Orca es la de una colección de objetos compartidos en los que automáticamente se serializan las operaciones simultáneas realizadas sobre cualquiera de ellos.

◇ **Datos inmutables.** En este caso DSM se muestra como una colección de datos inmutables que los procesos pueden leer, sumar y eliminar. Algunos ejemplos son Agora [Bisiani y Forin 1988] y, más importante, Linda y sus derivados, TSpaces y JavaSpaces.

Los sistemas de tipo Linda proporcionan al programador una colección de tuplas llamado *espacio de tuplas*. Una tupla está formada por una secuencia de uno o más campos de datos con tipo, como $\langle \text{«tino}, 1958 \rangle$, $\langle \text{«teo}, 1964 \rangle$ y $\langle 4, 9.8, \text{«Sí} \rangle$. En el mismo espacio de tuplas puede existir cualquier combinación de tipos de tuplas. Los procesos comparten los datos mediante el acceso al mismo espacio de tuplas: sitúan las tuplas en el espacio utilizando la operación *escribe* y las leen o extraen utilizando las operaciones *lee* o *toma*. La operación *escribe* añade una tupla sin afectar al resto de tuplas existentes en el espacio. La operación *lee* devuelve el valor de una tupla sin afectar al contenido del espacio de tuplas. La operación *toma* también devuelve una tupla, pero la elimina del espacio.

Cuando se lee o se toma una tupla desde su espacio, un proceso proporciona una especificación de tuplas y el espacio devuelve cualquiera que cumpla dicha especificación (se trata de una variante del direccionamiento asociativo). Para permitir que los procesos sincronicen sus actividades, las operaciones *lee* y *toma* se bloquean hasta que se encuentre la tupla dentro del espacio. Una especificación de tupla está formada por el número de campos y los valores o tipos de los campos solicitados. Por ejemplo, $\text{toma}(\langle \text{String, integer} \rangle)$ podría extraer tanto $\langle \text{«tino}, 1958 \rangle$ como $\langle \text{«teo}, 1964 \rangle$; $\text{toma}(\langle \text{String, 1958} \rangle)$ extraería únicamente $\langle \text{«tino}, 1958 \rangle$.

En Linda no se permite el acceso directo a las tuplas en un espacio de tuplas y los procesos las deben reemplazar en lugar de modificarlas. Sea, por ejemplo, un conjunto de procesos que accede a un contador compartido en un espacio de tuplas. El valor actual del contador (64) está en la tupla $\langle \text{«contador}, 64 \rangle$. Para incrementar el contador en un espacio de tuplas *misTups* se debe ejecutar el siguiente fragmento de código:

```
<s, contador> := misTups.take(<«contador», integer>);
misTups.write(<«contador», contador + 1>);
```

El lector deberá comprobar que las condiciones de carrera no pueden ocurrir, ya que *toma* extrae la tupla contador del espacio de tuplas.

16.2.2. MODELO DE SINCRONIZACIÓN

Muchas aplicaciones aplican restricciones sobre los valores almacenados en la memoria compartida. Esto ocurre tanto en aplicaciones basadas en DSM como en las mismas aplicaciones escritas para multiprocesadores de memoria compartida (o para cualquier programa concurrente que comparte datos, como los núcleos de los sistemas operativos y los servidores multi-hilo). Por ejemplo, si a y b son dos variables almacenadas en DSM, una restricción puede ser que siempre se cumpla $a = b$. Si dos o más procesos ejecutan el siguiente fragmento de código:

```
a := a + 1;
b := b + 1;
```

entonces se puede llegar a una situación inconsistente. Supóngase que a y b se han inicializado a cero y que el proceso 1 incrementa a . Antes de que pueda incrementar b , el proceso 2 pone un 2 en a y un 1 en b . La restricción ha dejado de cumplirse. La solución consiste en convertir este fragmento de código en una sección crítica: sincronizar los procesos para asegurar que sólo uno de ellos puede estar a la vez ejecutándola.

Para poder utilizar DSM se debe construir un servicio de sincronización distribuida que incluya construcciones familiares como bloqueos y semáforos. Incluso cuando DSM se estructura como un conjunto de objetos, la implementación de estos objetos depende de la sincronización. Las construcciones de sincronización se implementan utilizando paso de mensajes (véase el Capítulo 11 para una descripción de un servidor de bloqueos distribuido). Las instrucciones máquina especiales del tipo de *testAndSet* (comprueba y escribe), utilizadas para la sincronización en multiprocesadores de memoria compartida, se pueden aplicar a sistemas DSM basados en páginas, pero su operación en el caso distribuido puede ser muy ineficiente. Las implementaciones de DSM utilizan la sincronización a nivel de aplicación para reducir la cantidad de transmisión de actualización. DSM incluye la sincronización como un componente integrado.

16.2.3. MODELO DE CONSISTENCIA

Tal y como fue descrito en el Capítulo 14, la cuestión de la consistencia adquiere importancia en los sistemas DSM que replican el contenido de la memoria compartida mediante su almacenamiento en las cachés de computadores separados. En la terminología utilizada en el Capítulo 14, cada proceso tiene un gestor de réplicas local, el cual está encargado de mantener copias en caché para los objetos. En la mayor parte de las implementaciones, los datos se leen desde las réplicas locales por cuestiones de eficiencia, pero las actualizaciones deben propagarse al resto de gestores de réplica.

El gestor de réplica local se implementa mediante una combinación del middleware (el nivel DSM en tiempo de ejecución en cada proceso) y del núcleo. Es normal que el middleware realice la mayor parte del procesamiento DSM. Incluso en las implementaciones de DSM basadas en páginas, el núcleo normalmente proporciona únicamente una correspondencia de páginas básica, el manejo de fallos de página y los mecanismos de comunicación, mientras que el middleware es responsable de implementar las políticas de compartición de páginas. Si los segmentos DSM son persistentes, entonces uno o más servidores de almacenamiento (por ejemplo, servidores de archivos) actuarán también como gestores de réplicas.

Además de la gestión de la caché, una implementación DSM puede almacenar las actualizaciones y reducir los costes de comunicación mediante la propagación de múltiples actualizaciones a la vez. Una aproximación similar se estudió sobre la arquitectura de cotilleo (*gossip*) en el Capítulo 14.

Un modelo de *consistencia de memoria* [Mosberger 1993] especifica las garantías de consistencia que un sistema DSM realiza sobre los valores que los procesos leen desde los objetos, dado que en realidad acceden sobre una réplica de cada objeto y que múltiples procesos pueden actualizar los objetos. Téngase en cuenta que esto es diferente de la noción de consistencia de alto nivel y dependiente de aplicación, ya discutida en el apartado de sincronización de aplicaciones.

Cheriton [1985] describe cómo diferentes formas de DSM pueden tener previsto que un determinado nivel de inconsistencia pueda ser aceptable. Por ejemplo, DSM puede utilizarse para almacenar la carga de diferentes computadores en una cierta red para que los clientes puedan seleccionar, para ejecutar sus aplicaciones, el computador más descargado. Puesto que esta información es, por su propia naturaleza, muy inexacta en escalas de tiempo relativamente pequeñas, sería un desperdicio gastar recursos en el mantenimiento continuo de la consistencia para todos los computadores del sistema.

Sin embargo, la mayor parte de las aplicaciones tienen requisitos de consistencia muy estrictos. Es preciso proporcionar a los programadores un modelo que se ajuste razonablemente al comportamiento que la memoria debería tener. Antes de describir los requisitos de consistencia de memoria en mayor detalle será útil estudiar un ejemplo.

Sea una aplicación en la que dos procesos acceden a dos variables, a y b (véase la Figura 16.3), cuyo valor inicial es cero. El proceso 2 incrementa a y b , en ese orden. El proceso 1 lee los valores de b y a depositándolos sobre las variables locales br y ar , en ese orden. Fíjese en que no existe sincronización a nivel de aplicación. De forma intuitiva el proceso 1 espera encontrar una de las siguientes combinaciones de valores, en función del momento en el que las operaciones de lectura hayan sido aplicadas sobre a y b (implícito en las sentencias $br := b$ y $ar := a$) relativo a la ejecución del proceso 2: $ar = 0, br = 0$; $ar = 1, br = 0$; $ar = 1, br = 1$. En otras palabras, la condición $ar \geq br$ se debería cumplir siempre y el proceso 1 debería imprimir *OK*. Sin embargo, una cierta implementación DSM puede enviar las actualizaciones de a y b fuera de orden al gestor de réplicas del proceso 1, en cuyo caso la combinación $ar = 0, br = 1$ podría ocurrir.

La reacción inmediata del lector respecto a este ejemplo será, probablemente, considerar que la implementación DSM, que cambia el orden de las dos actualizaciones, es incorrecta. Si el proceso 1 y el proceso 2 se ejecutan juntos en un computador con un único procesador, podríamos suponer que el subsistema de memoria está averiado. Sin embargo, para el caso distribuido se puede tratar de una implementación correcta de un modelo de consistencia más débil del que muchos de nosotros suponemos de forma intuitiva, pero que en cualquier caso puede ser útil y es relativamente eficiente.

Mosberger [1993] realiza un bosquejo de un conjunto de modelos que han sido pensados para multiprocesadores de memoria compartida y sistemas DSM software. Los principales modelos de consistencia que se pueden implementar en la práctica en sistemas DSM son la consistencia secuencial y los modelos basados en consistencia débil.

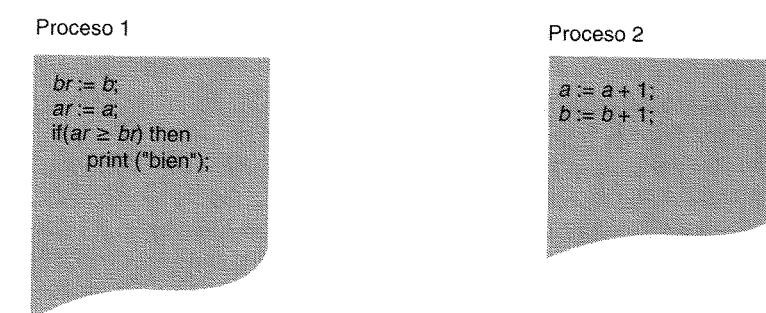


Figura 16.3. Dos procesos accediendo a variables compartidas.

La principal cuestión que se plantea al caracterizar un modelo particular de consistencia de memoria es: cuando se realiza un acceso de lectura sobre una posición de memoria, ¿qué accesos de escritura a esa posición son candidatos para que sus valores sean proporcionados a la lectura? En el extremo más débil, la respuesta es: cualquier escritura que haya sido iniciada antes que la lectura. Este modelo se podría obtener si se permitiera a los gestores de réplica retrasar la propagación de las actualizaciones a sus parejas de forma indefinida. Es demasiado débil para ser útil.

En el extremo más fuerte, todos los valores que se escriban aparecen disponibles de forma instantánea a todos los procesos: una lectura devuelve el valor escrito más reciente, respecto al instante en el que se realiza la lectura. Se trata de una definición problemática en dos sentidos. En primer lugar, ni las escrituras ni las lecturas se realizan en un instante temporal único, de forma que el significado de *más reciente* no siempre es claro. Cada tipo de acceso tiene un punto de inicio bien definido, pero se completa en un cierto instante posterior (por ejemplo, después de que se haya enviado un mensaje). En segundo lugar, en el Capítulo 10 se mostró que existen límites acerca de con qué proximidad se pueden sincronizar de relojes en un sistema distribuido. De forma que no es siempre posible determinar de forma exacta si un evento ocurrió antes que otro.

En cualquier caso, este modelo ha sido especificado y estudiado. El lector puede haberlo reconocido: es lo que llamamos secuenciación en el Capítulo 14. La secuenciación es más conocida como *consistencia atómica* en la literatura DSM. Volveremos a plantear la definición de secuenciación realizada en el Capítulo 14.

Se dice que un servicio de objetos compartidos replicados es secuenciable si *para cualquier ejecución* existe un entrelazado de las series de operaciones iniciadas por todos los clientes que satisfacen los dos criterios siguientes:

- L1: La secuencia de operaciones entrelazada cumple la especificación de una (única) copia correcta de los objetos.
- L2: El orden de las operaciones en el entrelazado es consistente con los instantes reales en los que las operaciones ocurrieron en la ejecución actual.

Se trata de una definición genérica que se aplica a cualquier sistema que contenga objetos replicados compartidos. Al estar tratando con memoria compartida, podemos ahora ser más explícitos. Sea el caso más simple en el que la memoria compartida se estructura como un conjunto de variables que pueden ser leídas o escritas. Todas las operaciones son de lectura y de escritura, y para ellas introdujimos una notación en la Sección 16.2.1: la lectura del valor a desde la variable x se indica como $L(x)a$; la escritura del valor b sobre la variable x se indica como $E(x)b$. Podemos ahora expresar el primer criterio, L1, en términos de variables (objetos compartidos):

- L1': La secuencia entrelazada de operaciones es tal que si $L(x)a$ ocurre en la secuencia, entonces o bien la última operación de escritura que ocurre antes que ella en la secuencia entrelazada es $E(x)a$, o bien no ocurre ninguna operación de escritura antes que ella y a es el valor inicial de x .

Este criterio se ajusta a nuestra intuición de que una variable puede ser cambiada únicamente por una operación de escritura. El segundo criterio de serialización, L2, no cambia.

◇ **Consistencia secuencial.** La secuenciación es demasiado estricta en la mayor parte de las ocasiones. El modelo de memoria más fuerte para DSM que se usa en la práctica es el de *consistencia secuencial* [Lamport 1979], explicado en el Capítulo 14. Adaptaremos a continuación la definición realizada en el Capítulo 14 para el caso particular de variables compartidas.

Un sistema DSM se dice que es secuencialmente consistente si *para cualquier ejecución* existe algún entrelazado de las series de operaciones realizadas por todos los procesos que satisface los dos siguientes criterios:

- SC1: La secuencia entrelazada de operaciones es tal que si $L(x)a$ ocurre en la secuencia, entonces o bien la última operación de escritura que ocurrió antes en la secuencia entrelaza-

zada fue $E(x)a$, o bien no ha ocurrido ninguna operación de escritura antes que ella y a es el valor inicial de x .

- SC2: El orden de las operaciones en el entrelazado es consistente con el orden de programa en el que dichas operaciones fueron ejecutadas por cada cliente individual.

El criterio SC1 es el mismo que el L1'. El criterio SC2 se refiere al orden de programa en lugar de referirse al orden temporal, que es el que hace posible implementar la consistencia secuencial.

La condición puede ser retomada de la siguiente forma: existe un entrelazado virtual para todas las operaciones de *lectura* y *escritura* de los procesos sobre una única imagen virtual de la memoria; en este entrelazado se mantiene el orden de programa de cada proceso individual y cada proceso siempre lee el último valor escrito dentro del entrelazado.

En una ejecución real, las operaciones de memoria pueden ser solapadas y algunas actualizaciones pueden ser ordenadas de forma diferente en diferentes procesos, siempre que las limitaciones de la definición no dejen de cumplirse. Fíjese que, para satisfacer las condiciones de la consistencia secuencial, se deben tener en cuenta las operaciones de memoria sobre el sistema DSM completo y no únicamente las operaciones desde cada posición individual.

La combinación $ar = 0$, $br = 1$ en el ejemplo anterior puede no ocurrir bajo la consistencia secuencial, ya que el proceso 1 estaría leyendo valores que entrarían en conflicto con el orden de programa del proceso 2. En la Figura 16.4 se muestra un ejemplo de entrelazado de los accesos a memoria de un proceso en una ejecución con consistencia secuencial. Una vez más, mientras que aquí se muestra un entrelazado real de las operaciones de lectura y escritura, la definición únicamente estipula que la ejecución debe producirse *como si* se realizara dicho entrelazado estricto.

Los sistemas DSM con consistencia secuencial se pueden implementar utilizando un único servidor para gestionar todos los datos compartidos y haciendo que todos los procesos envíen las solicitudes de lectura y escritura al servidor, que las ordena de forma global. Esta arquitectura es demasiado ineficiente para una implementación DSM por lo que a continuación se describen algunos medios prácticos para conseguir la consistencia secuencial. En cualquier caso, se trata de un modelo cuya implementación es muy costosa.

◇ **Coherencia.** Una reacción al coste de la consistencia secuencial consiste en buscar un modelo más débil pero con sus propiedades bien definidas. La *coherencia* es un ejemplo de una forma más débil de consistencia. Bajo la coherencia, cada proceso llega a acuerdos sobre el orden de las operaciones de *escritura* sobre la misma posición, pero no acuerdan necesariamente el orden de las operaciones de *escritura* sobre posiciones diferentes. Se puede pensar en la coherencia como una forma de consistencia secuencial realizada posición a posición. Los sistemas DSM coherentes pueden implementarse mediante un protocolo para implementar la consistencia secuencial aplicado de forma separada a cada unidad de datos replicados (por ejemplo, a cada página). El ahorro se

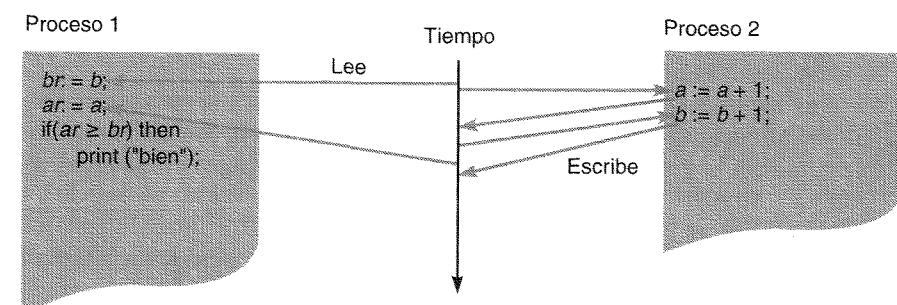


Figura 16.4. Entrelazado bajo la consistencia secuencial.

produce del hecho de que los accesos a dos páginas diferentes se hacen de forma independiente y no existe retardo entre ellos al aplicarse el protocolo de forma separada a ambos.

◊ **Consistencia débil.** Dubois y otros [1988] desarrollaron un modelo de consistencia débil en un intento de evitar los costes de la consistencia secuencial en los multiprocesadores, pero conservando el efecto de esta consistencia secuencial. Este modelo aprovecha el conocimiento de las operaciones de sincronización para relajar la consistencia de memoria, mientras se muestra al programador para implementar una consistencia secuencial (al menos, bajo ciertas condiciones que superan los objetivos de este libro). Por ejemplo, si el programador utiliza un bloqueo para implementar una sección crítica, entonces un sistema DSM puede asumir que ningún otro proceso puede acceder a los datos accedidos bajo la exclusión mutua. Será por lo tanto redundante que un sistema DSM propague las actualizaciones de dichos datos antes que el proceso deje la sección crítica. A pesar de que se mantienen valores *inconsistentes* durante algún tiempo para los datos, durante ese tiempo dichos datos no son utilizados; la ejecución aparenta ser secuencialmente consistente. Adve y Hill [1990] describen una generalización de esta idea llamada ordenamiento débil: «(Un sistema DSM) está ordenado débilmente respecto a un modelo de sincronización si y sólo si aparenta ser secuencialmente consistente para el software que aplica el modelo de sincronización.» En la Sección 16.4 se describe la consistencia relajada (*release*), la cual es un desarrollo de la consistencia débil.

16.2.4. OPCIONES DE ACTUALIZACIÓN

Para la propagación de las actualizaciones realizadas desde un cierto proceso sobre varios otros se han desarrollado dos posibles opciones: escritura actualizante y escritura invalidante. Ambos se pueden aplicar a varios modelos de consistencia DSM, incluyendo la consistencia secuencial. En detalle las opciones se describen así:

Escritura actualizante: las actualizaciones de un proceso se realizan de forma local y se envían por multidifusión a todos los gestores de réplica que posean una copia del dato, los cuales modifican inmediatamente el dato leído por los procesos locales (véase la Figura 16.5). Los procesos leen las copias locales de los datos, sin necesidad de comunicación. Además de permitir múltiples lectores, varios procesos pueden escribir el mismo dato de forma simultánea; esto se conoce como *compartición de múltiples lectores/múltiples escritores*. El modelo de consistencia de memoria implementado en la escritura actualizante depende de varios factores, siendo el principal la propiedad de ordenamiento de la multidifusión. Se puede conseguir la consistencia secuencial mediante la utilización de multidifusiones totalmente ordenadas (véase el Capítulo 11 para una definición de las multidifusiones totalmente ordenadas), que no terminan hasta que el mensaje de actualización haya sido entregado localmente. Se consigue así que todos los procesos acuerden el orden de las actualizaciones. El conjunto de lecturas que se realizan entre dos actualizaciones consecutivas está bien definido y su ordenamiento es independiente de la consistencia secuencial.

Las lecturas son baratas en los sistemas de escritura actualizante. Sin embargo, en el Capítulo 11 se mostró que los protocolos de multidifusión ordenada son relativamente caros de implementar en software. Orca utiliza escritura actualizante a través del protocolo de multidifusión de Amoeba [Kaashoek y Tanenbaum 1991] (véase www.cdk3.net/coordination), que utiliza el soporte hardware para implementar la multidifusión. Munin soporta la escritura actualizante como una opción. En la arquitectura multiprocesador PLUS se utiliza un protocolo de escritura actualizante soportado mediante hardware especializado.

Escritura invalidante: está implementada normalmente en la forma de *compartición de múltiples lectores/un único escritor*. En cualquier instante, una cierta posición puede ser accedida

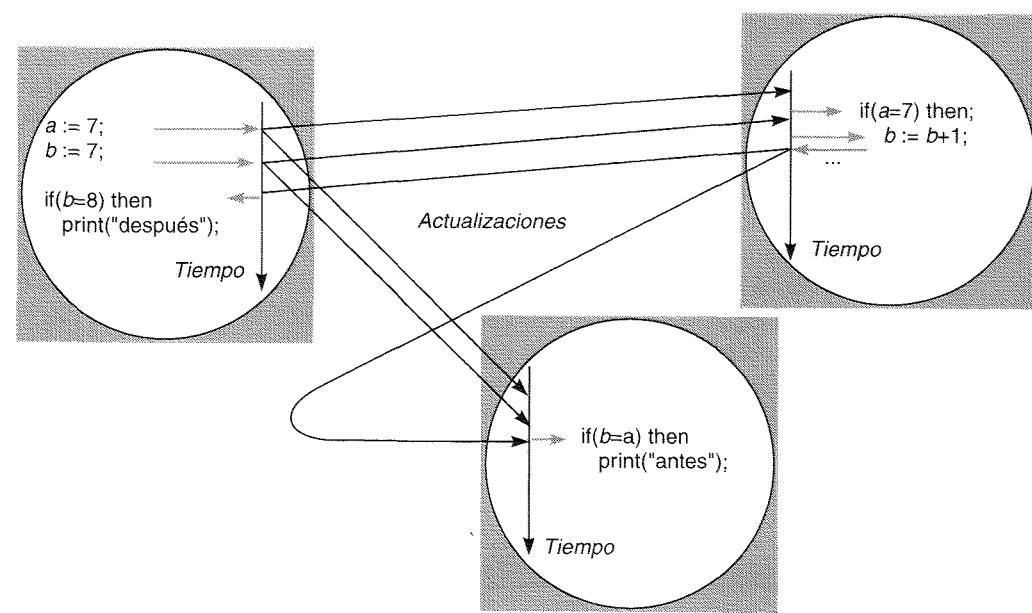


Figura 16.5. DSM utilizando escritura actualizante.

para lectura por uno o más procesos, o bien puede ser leída y escrita por un único proceso. Una posición que está siendo utilizada en modo de sólo lectura puede ser copiada a cualquier otro proceso. Cuando un proceso intenta escribir sobre ella, en primer lugar se envía un mensaje multidifusión a todas sus copias para invalidarlas y se espera el reconocimiento de esta operación antes de que la escritura tenga lugar; el resto de los procesos están por lo tanto prevenidos para no leer datos viejos (es decir, datos que no están actualizados). Cualquier proceso que esté intentando acceder al dato se bloquea hasta que la escritura termine. Finalmente, el control se transfiere desde el proceso escritor, y se puedan realizar otros accesos una vez que la actualización haya sido enviada. El resultado es que se procesan todos los accesos al dato mediante una política del tipo primero en llegar, primero en ser servido. Lamport [1979] demostró que, con este esquema, se consigue consistencia secuencial. Veremos en la Sección 16.4 que en la consistencia relajada, las invalidaciones pueden ser retrasadas.

En el esquema de invalidación, las actualizaciones únicamente se propagan cuando los datos son leídos y además se pueden realizar varias actualizaciones consecutivas sin necesidad de realizar ninguna comunicación. Como contrapartida, se deben invalidar todas las copias de sólo lectura antes de que se pueda realizar una escritura. Esto puede ser potencialmente caro en el esquema de múltiples lectores/un único escritor. Sin embargo, si la relación lectura/escritura es suficientemente alta, el paralelismo que se obtiene permitiendo múltiples lectores simultáneos amortiza su coste. Cuando la relación lecturas/escrituras es relativamente baja, un esquema de tipo único lector/único escritor puede ser más apropiado: es decir, como máximo un proceso en cada instante puede obtener acceso de sólo lectura.

16.2.5. GRANULARIDAD

Una cuestión relacionada con la estructura de DSM es la granularidad de la partición. Teóricamente, todos los procesos comparten el contenido completo del DSM. Sin embargo, según se van

ejecutando los programas que comparten DSM, únicamente ciertas partes de los datos son en reali-

dad compartidas y únicamente durante ciertos períodos de la ejecución. Para una implementación

16.2.6. THRASHING (FUSTIGAMIENTO)

Un problema potencial de los protocolos de escritura invalidante es el thrashing. Se dice que un sistema DSM está en thrashing cuando realiza un gasto desmesurado de tiempo en la invalidación y transferencia de datos compartidos en comparación con el tiempo empleado por los procesos de aplicación en la realización de trabajo útil. Ocurre cuando varios procesos compiten por el mismo dato o bien por datos que están bajo compartición falsa. Si, por ejemplo, un proceso lee de forma repetida el mismo dato que otro proceso está actualizando regularmente, entonces el dato será continuamente transferido desde el escritor e invalidado en el lector. Éste es un ejemplo de patrón de compartición para el que la escritura invalidante es menos apropiada que la escritura actualizante. En la siguiente sección se describe la aproximación Mirage al thrashing, en la que los computadores *poseen* las páginas durante un período de tiempo mínimo; en la Sección 16.4 se describió cómo Munin permite al programador declarar patrones de acceso al sistema DSM de forma que se pueden elegir opciones de actualización que se adapten al patrón de compartición de cada dato y se evite así el thrashing.

16.3. CONSISTENCIA SECUENCIAL EN IVY

En esta sección se describen métodos para implementar sistemas DSM basados en páginas con consistencia secuencial. La descripción se basa en Ivy [Li y Hudak 1989] como caso de estudio.

16.3.1. EL MODELO DE SISTEMA

El modelo básico a considerar es aquel en el que una colección de procesos comparten un segmento de DSM (véase la Figura 16.7). El segmento se hace corresponder sobre el mismo rango de direcciones en cada proceso, de forma que sobre él se pueden almacenar valores de punteros significativos. Los procesos se ejecutan en computadores equipados con unidades de gestión de memoria paginada. Asumiremos que únicamente hay un proceso que accede al segmento DSM en cada computador. En realidad puede haber varios procesos de ese tipo en cada computador. Sin embargo, esos procesos podrían entonces compartir las páginas directamente (el mismo marco de página puede aparecer en las tablas de páginas de diferentes procesos). La única complicación sería la de coordinar el envío y la propagación de actualizaciones a una página cuando dos o más procesos locales acceden a ella. En esta descripción se ignoran este tipo de detalles.

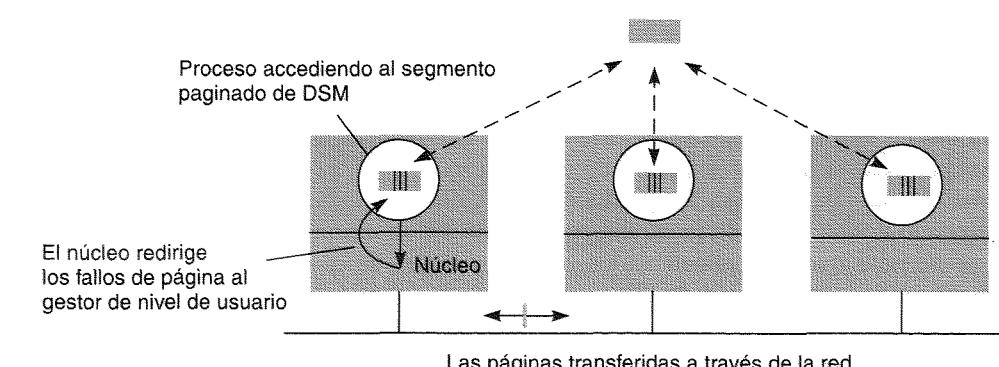


Figura 16.7. Modelo del sistema de un DSM basado en páginas.

La paginación es transparente a los componentes de la aplicación dentro de los procesos; ellos pueden leer y escribir de forma lógica cualquier posición sobre DSM. Sin embargo, para mantener la consistencia secuencial, el soporte en tiempo de ejecución de DSM restringe los permisos de acceso a páginas cuando se procesan lecturas y escrituras. La unidad de gestión de memoria paginada permite configurar los permisos de acceso a los datos de una página a *ninguno, sólo lectura o lectura escritura*. Si un proceso trata de saltarse los permisos de acceso actuales, se dispara un fallo de página en lectura o escritura, en función del tipo de acceso. El núcleo redirige el fallo de página a un manejador especificado por el nivel de soporte en tiempo de ejecución de DSM para cada proceso. El manejador de fallos de página (que se ejecuta de forma transparente a la aplicación) realiza un procesamiento especial del mencionado fallo de página, según se describe a continuación, antes de devolver el control a la aplicación. En sistemas DSM primitivos, como Ivy, el propio núcleo realiza gran parte del procesamiento. Explicaremos cómo los propios procesos realizan la gestión de los fallos de página y la comunicación consiguiente. En la actualidad, estas funciones son realizadas por una combinación del nivel en tiempo de ejecución de DSM en el proceso y del núcleo. Normalmente, el módulo de DSM insertado en el proceso contiene la mayor parte de la funcionalidad de forma que pueda ser modificada y ajustada sin tener que afrontar los problemas asociados con la alteración del núcleo.

En esta descripción no se tendrá en cuenta el procesamiento de fallo de página que debe realizarse como parte de una implementación típica de memoria virtual. Aparte del hecho de que los segmentos DSM compiten con otros segmentos por los marcos de páginas, las implementaciones son independientes.

◇ **El problema de la escritura actualizante.** En la sección anterior se perfilaron las principales alternativas de implementación de la escritura actualizante y de la escritura invalidante. En la práctica, si el sistema DSM está basado en páginas, la escritura actualizante sólo se usa si las escrituras pueden ser almacenadas en búferes. Esto se debe a que la gestión estándar de fallos de página no se adapta bien al procesamiento aislado de cada escritura a una página.

Para entender esto, supongamos que cada actualización deba ser enviada vía multidifusión a todas las copias y supongamos también que una página ha sido protegida contra escritura. Cuando un proceso intenta escribir en la página, se genera un fallo de página y se invoca a una rutina de gestión. Este gestor debería, inicialmente, examinar la instrucción que provocó el fallo para determinar el valor y la dirección que estaba siendo escrita y a continuación realizar una multidifusión de la actualización antes de restablecer el acceso de la escritura y devolver el control a la instrucción que generó el fallo.

Sin embargo, ahora que el acceso de escritura ha sido restablecido, las siguientes actualizaciones no generarán un fallo de página. Para provocar que cada acceso de escritura genere un fallo de página, será necesario que el manejador de fallos de página configure el proceso en modo TRAZA, de forma que en el procesador se activará una excepción de este tipo después de cada instrucción. El manejador de la excepción TRAZA debería desactivar los permisos de escritura de la página y desactivar el modo TRAZA. Todos los pasos anteriores deberán repetirse cuando ocurra el siguiente fallo en escritura. Claramente este método tiende a ser muy caro ya que podrían ocurrir muchas excepciones durante la ejecución de un proceso.

En la práctica, la escritura actualizante se utiliza en las implementaciones basadas en páginas, pero sólo donde se deja a la página con permisos de escritura después de un fallo de páginas inicial y se permite que se realicen varias escrituras antes de que la página actualizada sea propagada. Munin utiliza esta técnica de almacenamiento de escrituras. Para mejorar la eficiencia, Munin intenta evitar la propagación de la página completa, propagando únicamente la parte que haya sido modificada. Cuando un proceso realiza un primer intento de escritura sobre una página, Munin gestiona el fallo de páginas realizando una copia de la página y guardando la copia antes de habilitar el acceso de escritura. Posteriormente, cuando Munin está dispuesto para propagar la página,

compara la página actualizada con la copia original y codifica las actualizaciones en forma de conjunto de diferencias entre las dos páginas. Estas diferencias a menudo ocupan mucho menos espacio que la página completa. Los procesos receptores regeneran la página actualizada partiendo de la copia antes de actualizar y del conjunto de diferencias.

16.3.2. INVALIDACIÓN DE ESCRITURA

Los algoritmos basados en invalidaciones utilizan la protección de páginas para forzar la consistencia en la compartición de datos. Cuando un proceso está actualizando una página, tiene localmente los permisos de lectura y escritura sobre dicha página; el resto de procesos no tienen permisos de acceso sobre la página. Cuando uno o más procesos están leyendo una página, sólo tienen permiso de lectura; el resto de procesos no tienen permiso de acceso (a pesar de que puedan adquirir los permisos de lectura). No son posibles otras combinaciones. Un proceso con la versión actualizada de una página p es marcado como su *propietario* y esto se indica mediante la notación $\text{propietario}(p)$. Se trata del único escritor o bien de uno de los lectores. Al conjunto de procesos que tienen una copia de una cierta página p se le denomina *conjunto de copia* y se utiliza la notación $\text{conjuntocopia}(p)$ para referirse a ellos.

Las transiciones de estado posibles se muestran en la Figura 16.8. Cuando un proceso P_w intenta escribir sobre una página p sobre la que o no tiene acceso o sólo tiene acceso de lectura, se genera un fallo de página. El manejador de fallos de página realiza los siguientes pasos:

- Si el procesador P_w no tienen una copia actualizada de la página, se le transfiere.
- Se invalidan el resto de copias: los permisos de acceso a las páginas se modifican para impedir el acceso de los miembros de $\text{conjuntocopia}(p)$.
- $\text{conjuntocopia}(p) := \{P_w\}$.
- $\text{propietario}(p) := P_w$.
- El soporte en tiempo de ejecución de P_w sitúa la página con permisos de lectura y escritura en la posición correspondiente en su espacio de direcciones y reinicia la instrucción que generó el fallo.

Nótese que dos o más procesos con copias de sólo lectura pueden generar fallos de escritura de forma más o menos simultánea. Una copia de sólo lectura de una página puede quedar caducada cuando la propiedad sea finalmente cedida. Para detectar si la copia actual de sólo lectura de una página está o no caducada, se asocia un número de secuencia a cada página, el cual se incrementa cada vez que la propiedad es transferida. Un proceso que solicita acceso de escritura inserta en la solicitud el número de secuencia de su copia de sólo lectura, si posee uno. El propietario actual

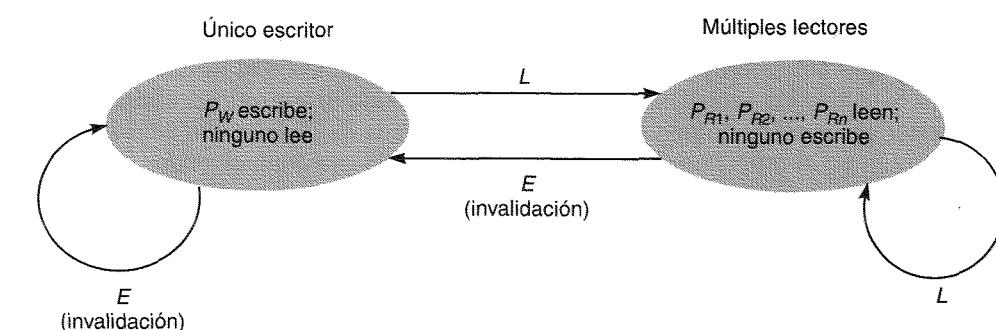


Figura 16.8. Transiciones de estado bajo invalidación de escritura.

utiliza este número para decidir si la página ha sido modificada y por lo tanto es necesario enviarla. Este esquema es descrito por Kessler y Livny [1989] bajo el nombre de *algoritmo astuto*.

Cuando un proceso P_R intenta leer una página p sobre la que no tiene permisos de acceso, se genera un fallo de página en lectura. El manejador de fallos realiza los siguientes pasos:

- La página es copiada desde $proprietario(p)$ hasta P_R .
- Si el propietario actual es un único escritor, entonces éste mantiene la propiedad de p y se colocan sus permisos de acceso en sólo lectura. La retención de los derechos de acceso en lectura es deseable en el caso que el proceso intente leer la página posteriormente, se habrá retenido una versión actualizada de la página. Sin embargo, al ser el propietario deberá gestionar las solicitudes que se reciban sobre la página, incluso si no se vuelve a utilizar de nuevo. Por lo tanto se puede considerar que en lugar de reducir los derechos de acceso sería más apropiado simplemente prohibirlos y transferir la propiedad a P_R .
- $conjuntocopia(p) := conjuntocopia(p) \cup \{P_R\}$.
- El nivel de soporte de sistema DSM en P_R sitúa la página con permisos de sólo lectura en la posición adecuada en su espacio de direcciones y reinicia la instrucción que generó el fallo.

Es posible que se genere un segundo fallo de página durante los algoritmos de transición que se acaban de describir. Para que las transiciones se realicen de forma consistente, cualquier nueva solicitud sobre la página no será procesada hasta que la transición actual se haya completado.

La descripción que se acaba de proporcionar se ha centrado en la explicación de *qué* debe hacerse. A continuación se estudia el problema de *cómo* implementar de forma eficiente el gestor de fallos de página.

16.3.3. PROTOCOLOS DE INVALIDACIÓN

Quedan por resolver dos problemas importantes en un protocolo que implemente el esquema de invalidación:

1. Cómo localizar el $proprietario(p)$ para una cierta página p .
2. Dónde almacenar $conjuntocopia(p)$.

Li y Hudak [1989] describen varias arquitecturas y protocolos para Ivy, que realizan diferentes aproximaciones sobre los problemas mencionados. La más simple que describiremos es el algoritmo mejorado de gestión centralizada. En esta solución, se utiliza un único servidor, llamado gestor, para almacenar la dirección (dirección de nivel de transporte) del $proprietario(p)$ para cada página p . El gestor podría ser uno de los procesos que ejecutan la aplicación o bien cualquier otro proceso. En este algoritmo el conjunto $conjuntocopia(p)$ se almacena en $proprietario(p)$. Es decir, se almacenan los identificadores y las direcciones de transporte de los miembros de $conjuntocopia(p)$.

Tal y como se puede observar en la Figura 16.9, cuando ocurre un fallo de página el proceso local (al que nos referiremos como *cliente*) envía un mensaje al gestor contenido el número de página y el tipo de acceso solicitado (lectura o lectura-escritura). El cliente espera una respuesta. El gestor procesa la solicitud realizando una búsqueda de la dirección de $proprietario(p)$ y reenviando la solicitud al propietario. Si se trata de un fallo de escritura, el gestor configura al cliente como nuevo propietario. Las siguientes solicitudes se insertan en una cola en el cliente a la espera de que éste complete la transferencia de la propiedad sobre él mismo.

El anterior propietario envía la página al cliente. En el caso de un fallo en escritura, también envía el conjunto de copia de la página. El cliente realiza la invalidación cuando recibe el conjunto de copia. Envía una solicitud multidifusión a los miembros del conjunto de copia, y espera el reconocimiento desde todos los procesos para considerar que la invalidación se ha completado. La multidifusión no necesita ser ordenada. El anterior propietario no necesita ser incluido en la lista

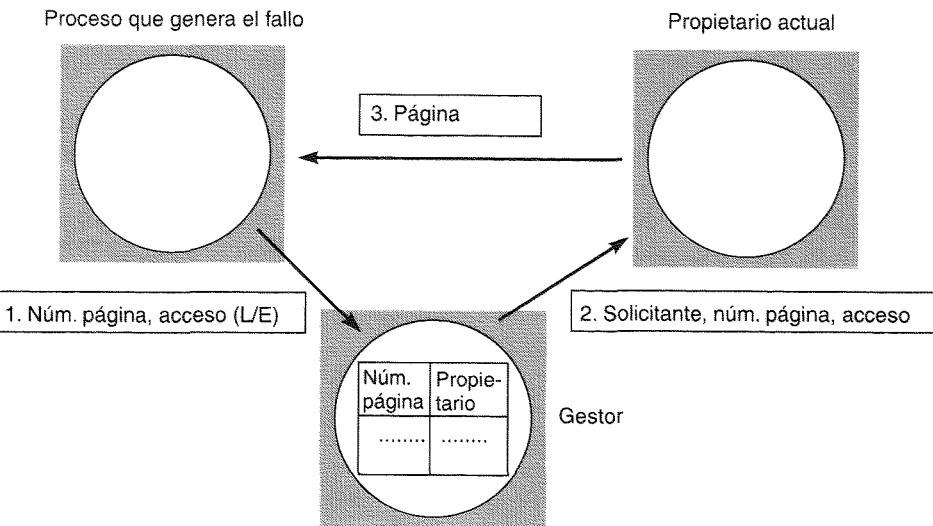


Figura 16.9. Gestor central y mensajes asociados.

de destinatarios, al haberse invalidado a sí mismo. Los detalles de la gestión del conjunto de copia se dejan al lector, que deberá consultar los algoritmos de invalidación generales ya explicados.

El gestor es un cuello de botella para las prestaciones y un punto de fallo crítico. Li y Hudak sugirieron tres alternativas para que la carga de la gestión de páginas fuera dividida entre computadores: gestión de páginas distribuida fija, gestión distribuida basada en multidifusión y gestión distribuida dinámica. En la primera alternativa, se utilizan múltiples gestores, cada uno con funcionalidad equivalente al gestor centralizado ya descrito, pero dividiendo de forma estática las páginas entre ellos. Por ejemplo, cada gestor podría manejar sólo aquellas páginas cuyos números de página estén dentro de un cierto rango de valores. Los clientes calculan el número hash de la página que se necesita y utilizan una tabla de configuración predeterminada para buscar la dirección del gestor correspondiente.

Este esquema debería mejorar en general el problema de la carga, pero tiene la desventaja de que una correspondencia fija de las páginas sobre los gestores puede no ser factible. Si los procesos no acceden a las páginas de forma uniforme, algunos gestores estarán más cargados que otros. Describimos a continuación la gestión basada en multidifusión y la gestión distribuida dinámica.

◇ **Uso de la multidifusión para localizar el propietario.** La multidifusión puede utilizarse para eliminar completamente al gestor. Cuando se genera un fallo en un proceso, éste envía una multidifusión con su solicitud de página al resto de los procesos. Sólo contesta el proceso que posea la página. Se debe tener cuidado para garantizar el comportamiento correcto si los clientes solicitan la misma página de forma simultánea: cada cliente debe terminar obteniendo la página, incluso si su multidifusión se ha realizado durante la transferencia de la propiedad.

Considérense dos clientes C_1 y C_2 que utilizan multidifusión para localizar una página cuyo propietario es O . Supongamos que O recibe la solicitud de C_1 en primer lugar y le transfiere la propiedad. Antes de que la página llegue, la solicitud de C_2 llega a O y a C_1 . O descartará la solicitud de C_2 ya que ha dejado de poseer la página. Li y Hudak consideraron que C_1 debería retrasar el procesamiento de la solicitud de C_2 hasta que haya obtenido la página ya que en otro caso debería descartar dicha solicitud al no ser el propietario y la solicitud de C_2 se perdería. Sin embargo, queda todavía un problema sin resolver. La solicitud de C_1 ha sido almacenada mientras tanto en una cola en C_2 . Después de que C_1 haya finalmente proporcionado a C_2 la página, C_2 recibirá y procesará la solicitud de C_1 , la cual ahora es obsoleta!

Una solución consiste en utilizar multidifusión totalmente ordenada, de forma que los clientes puedan descartar de forma segura aquellas solicitudes que llegan antes que la suya (además de al resto de los procesos las solicitudes son enviadas a ellos mismos). Otra solución, basada en una multidifusión sin orden más barata, pero que utiliza mayor ancho de banda, consiste en asociar a cada página un vector de marcas temporales, con una entrada por cada proceso (véase el Capítulo 10 para una descripción de los vectores de marcas temporales). La marca de tiempo se transfiere junto con la propiedad de una página. Cuando un proceso obtiene la propiedad, incrementa su entrada en el vector de marcas temporales. Cuando un proceso solicita la propiedad, inserta en la solicitud la última marca temporal que mantiene para esa página. En nuestro ejemplo, C_2 debería descartar la solicitud de C_1 ya que la entrada de C_1 en la marca temporal de la solicitud es menor que la marca que llegó con la página.

Independientemente de que se utilice una multidifusión ordenada o desordenada, este esquema tiene las desventajas típicas de los sistemas basados en multidifusión: los procesos que no poseen una cierta página son interrumpidos con mensajes irrelevantes, desperdiциando tiempo de procesamiento.

16.3.4. UN ALGORITMO DE GESTIÓN DISTRIBUIDA DINÁMICO

Li y Hudak propusieron el algoritmo de gestión distribuida dinámico, que permite que la propiedad de una página se transfiera entre procesos pero utiliza un método alternativo a la multidifusión para localizar al propietario de una página. La idea se basa en la división de las sobrecargas de localización de páginas entre aquellos computadores que acceden a ellas. Para cada página p , cada proceso mantiene una marca del propietario actual de la página, que en realidad es el propietario probable de p o $\text{proprietarioProbable}(p)$. Inicialmente a cada proceso se le proporcionan las localizaciones exactas para las páginas. Sin embargo, estos valores son meros *indicios*, ya que las páginas se transfieren entre los nodos en cualquier momento. Como ocurre en los algoritmos anteriores, la propiedad se transfiere sólo cuando ocurre un fallo en escritura.

El propietario de una página es localizado siguiendo una cadena de marcas que son actualizadas al nuevo propietario cuando la página es transferida entre computadores. La longitud de la cadena, es decir, el número de mensajes de reenvío que son necesarios para localizar al propietario, amenaza con crecer de forma indefinida. El algoritmo resuelve este problema mediante la actualización inmediata de las marcas según vayan estando disponibles los valores más actualizados. El procedimiento para actualizar las marcas y reenviar las solicitudes es el siguiente:

- Cuando un proceso transfiere la propiedad de una página p a otro proceso, marca como nuevo $\text{proprietarioProbable}(p)$ al receptor de la página.
- Cuando un proceso gestiona una solicitud de invalidación para una página p , marca como nuevo $\text{proprietarioProbable}(p)$ al solicitante.
- Cuando un proceso que ha solicitado acceso de lectura a una página p la recibe, marca como nuevo $\text{proprietarioProbable}(p)$ al nodo que se la proporcionó.
- Cuando un proceso recibe una solicitud para una página p de la que no es propietario, reenvía la solicitud al $\text{proprietarioProbable}(p)$ y marca como nuevo $\text{proprietarioProbable}(p)$ al solicitante.

Las primeras tres actualizaciones son una consecuencia del protocolo en lo que se refiere a la transferencia de la propiedad de la página y la obtención de copias de sólo lectura. La actualización cuando se reenvía una solicitud se justifica en que, para las solicitudes de escritura, el solicitante será pronto el propietario, incluso si no lo es actualmente. De hecho, en el algoritmo de Li y Hudak, la actualización de $\text{proprietarioProbable}$ se realiza tanto si la solicitud es para acceso de lectura como si lo es para escritura. Volveremos sobre este punto pronto.

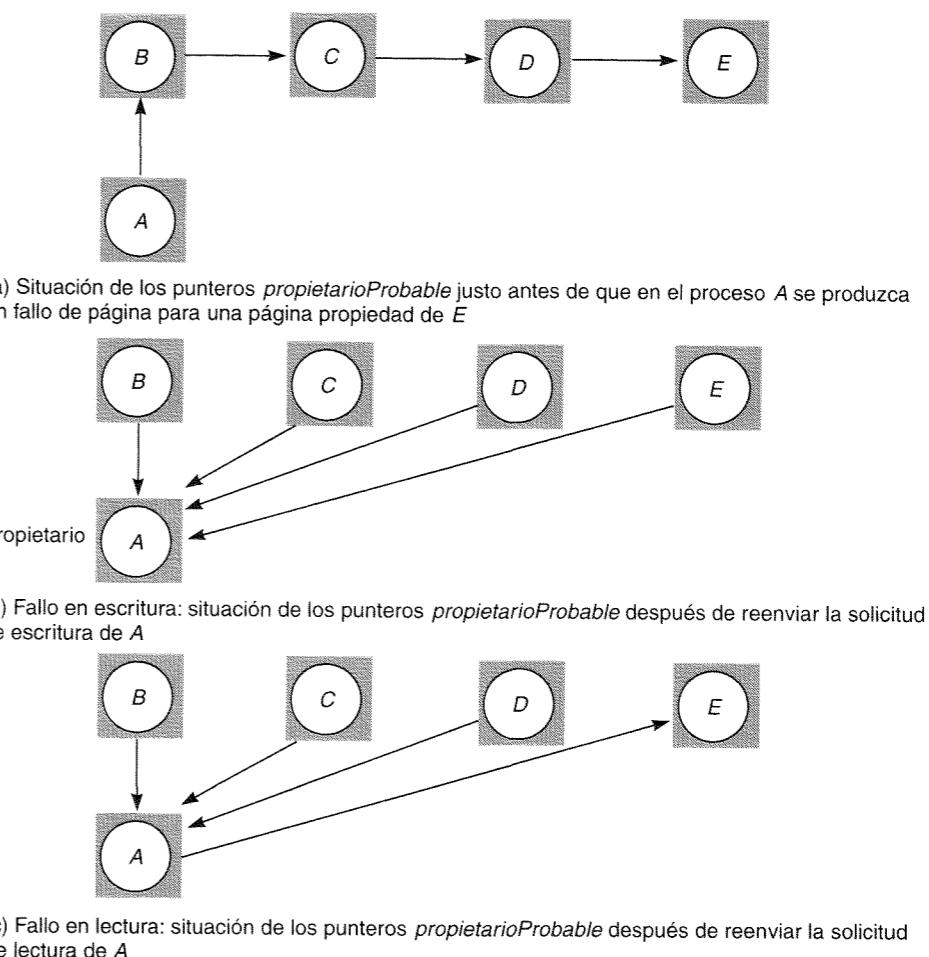


Figura 16.10. Actualizaciones de los punteros *proprietarioProbable*.

En la Figura 16.10 ((a) y (b)) se ilustran los punteros de *proprietarioProbable* antes y después de que en el proceso A se produzca un fallo de página en escritura. El puntero *proprietarioProbable* de A para la página apunta inicialmente a B. Los procesos B, C y D reenvían la solicitud a E siguiendo sus propios punteros *proprietarioProbable*; después de eso, todos los punteros apuntan a A como resultado de las reglas de actualización descritas. El resultado una vez gestionado el fallo es claramente mejor que antes de hacerlo: la cadena de punteros ha desaparecido.

Sin embargo, si en A se produce un fallo de lectura, entonces el proceso B se comporta mejor (dos pasos en lugar de tres para apuntar a E), la situación de C no cambia (dos pasos) pero para D la situación empeora ya que necesita dos pasos en lugar de uno (véase la Figura 16.10(c)). Para investigar el efecto en las prestaciones de esta táctica es necesario realizar simulaciones.

El tamaño medio de las cadenas de punteros puede ser controlado además difundiendo periódicamente a todos los procesos la localización del propietario actual. Esto provoca que todas las cadenas pasen a tener tamaño 1.

Li y Hudak describen los resultados de la simulaciones que realizaron para investigar la eficacia de sus actualizaciones de punteros. Eligieron de forma aleatoria los procesos que generaban fallos de entre 1.024 procesadores y encontraron que el número medio de mensajes necesarios para

conseguir el propietario de una página fue de 2,34 si las difusiones de anuncio de la posición del propietario se realizaban cada 256 fallos y de 3,64 si las difusiones se realizaban cada 1.024 fallos. Estos valores se muestran aquí únicamente a modo de ilustración: en Li y Hudak [1989] se muestra un conjunto completo de resultados. Nótese que un sistema DSM que utiliza un gestor central necesita dos mensajes para conseguir el propietario de una página.

Finalmente, Li y Hudak describen una optimización que potencialmente consigue realizar la invalidación de forma más eficiente y reduce el número de mensajes necesarios para manejar un fallo de página en lectura. En lugar de tener que obtener una copia de la página desde su nodo propietario, un cliente puede obtener una copia de cualquier proceso con una copia válida. Existe la posibilidad de que un cliente que está intentando localizar el propietario en la cadena de punteros encuentre antes un nodo con una copia válida.

Esto se realiza bajo la condición de que los procesos mantengan un registro de clientes a los que han cedido una copia de una página de su propiedad. El conjunto de procesos que poseen copias de sólo lectura de una página forma un árbol cuya raíz es el propietario, con cada nodo apuntando a los nodos hijo, los cuales obtuvieron copias de él. La invalidación de una página comienza en el propietario y avanza hacia abajo a través del árbol. Cuando un nodo recibe un mensaje de invalidación, lo reenvía a sus hijos además de invalidar su propia copia. El efecto en su conjunto es el de que algunas invalidaciones se realizan en paralelo. Esto puede reducir el tiempo global necesario para invalidar una página, especialmente en un entorno sin soporte hardware para la multidifusión.

16.3.5. THRASHING

Se puede argumentar que es responsabilidad del programador evitar el thrashing. El programador debería anotar las posiciones de sus datos para ayudar al soporte DSM a minimizar tanto el número de veces que se copian las páginas como el número de transferencias de propiedad. Esta última aproximación es discutida en la siguiente sección en el contexto del sistema DSM Munin.

Mirage [Fleisch y Popek 1989] adopta una aproximación al thrashing transparente a los programadores. Mirage asocia cada página con un pequeño intervalo de tiempo. Una vez que un proceso ha accedido a una página, se le permite retener el acceso para el intervalo dado, que puede ser considerado como un intervalo de tiempo. Cualquier otra solicitud realizada sobre la página durante dicho intervalo de tiempo es rechazada. Una desventaja obvia de este esquema es que resulta muy difícil elegir la longitud del intervalo de tiempo. Si el sistema utiliza una longitud de tiempo elegida de forma estática, ese valor puede ser inapropiado en muchos casos. Por ejemplo un proceso podría escribir una página una única vez y no volver a acceder a ella; el resto de procesos tendrían entre tanto el acceso prohibido a dicha página. Análogamente, el sistema podría ceder a otro proceso el acceso a la página antes de acabar de usarla.

Un sistema DSM podría elegir el tamaño del intervalo de tiempo de forma dinámica. Un posible punto de partida para su elección podría ser la observación de los accesos sobre la página (utilizando los bits de *referencia* de la unidad de gestión de memoria). Otro factor que podría considerarse es el tamaño de la cola de procesos que esperan por la página.

16.4. LIBERACIÓN DE CONSISTENCIA Y MUNIN

Los algoritmos de la sección anterior fueron diseñados para conseguir la consistencia secuencial en sistemas DSM. La ventaja de la consistencia secuencial es que el sistema DSM se comporta de la forma que sus programadores esperan que lo haga una memoria compartida. Su desventaja es el

coste de implementación. Los sistemas DSM a menudo necesitan utilizar multidifusión en sus implementaciones, tanto si se basan en escritura actualizante como en invalidación de escritura (aunque para la invalidación sea suficiente una multidifusión desordenada). La búsqueda del propietario de una página tiende a ser cara: un gestor central que conoce la ubicación del propietario de cada página se convierte en un cuello de botella; las secuencias de punteros implican, de media, la necesidad de más mensajes. Además, los algoritmos basados en invalidaciones pueden sufrir de thrashing.

La consistencia relajada fue utilizada por primera vez en el multiprocesador Dash, el cual realiza una implementación hardware de DSM basada en un protocolo de invalidación de escritura [Lenoski y otros 1992]. Munin y Treadmarks [Keleher y otros 1992] utilizan una implementación software. La consistencia relajada es más débil que la consistencia secuencial y más barata en su implementación, pero conserva una semántica razonable que resulta tratable para los programadores.

La consistencia relajada se basa en la reducción de las sobrecargas de DSM explotando el hecho de que los programadores utilizan objetos de sincronización, como semáforos, bloqueos y barreras. Una implementación DSM puede utilizar el conocimiento del acceso a estos objetos para permitir que la memoria sea inconsistente en determinados puntos, pero asegurando la consistencia a nivel de aplicación mediante la utilización de estos objetos de sincronización.

16.4.1. ACCESOS A MEMORIA

Para comprender la consistencia relajada (o cualquier otro modelo de memoria que utilice la sincronización) comenzamos realizando una clasificación de los accesos a memoria en función de su papel, si existe, en la sincronización. Además estudiaremos cómo los accesos a memoria se pueden realizar de forma asíncrona para mejorar las prestaciones y proporcionaremos un modelo operacional sencillo de cómo se producen los accesos a memoria.

Tal y como hemos mencionado previamente, las implementaciones DSM para sistemas distribuidos de propósito general pueden utilizar, por razones de eficiencia, paso de mensajes en lugar de variables compartidas para implementar la sincronización. Sin embargo, resultará útil mantener en mente la sincronización basada en variables compartidas para la siguiente discusión. El pseudo-código que aparece a continuación implementa bloqueos utilizando la operación *testAndSet* sobre variables. La función *testAndSet* pone la variable lock a 1 y devuelve 0 si valía previamente cero; en otro caso devuelve 1. Esto lo hace de forma atómica.

```
adquiereBloqueo(var int bloqueo): // bloqueo se pasa por referencia
    while (testAndSet(bloqueo) = 1)
        skip;
    liberaBloqueo(var int bloqueo): // bloqueo se pasa por referencia
        lock := 0;
```

◇ **Tipos de accesos a memoria.** La principal distinción se realiza entre accesos *competitivos* y accesos *no competitivos* (ordinarios). Dos accesos son competitivos si:

- Pueden ocurrir de forma concurrente (no se fuerza el mantenimiento de un orden entre ellos).
- Al menos uno de ellos es una *escritura*.

Por lo tanto dos operaciones de *lectura* no pueden nunca ser competitivas; una *lectura* y una *escritura* sobre la misma posición realizadas por dos procesos que se sincronizan entre las operaciones (y por lo tanto las ordenan) no son competitivas.

Además dividimos los accesos competitivos entre accesos de *sincronización* y de *no sincronización*:

- Los accesos de sincronización son operaciones de *lectura* o *escritura* que contribuyen a la sincronización.
- Los accesos de no sincronización son operaciones de *lectura* o de *escritura* concurrentes pero que no contribuyen a la sincronización.

La operación de *escritura* implícita en *bloqueo* := 0 dentro de *liberaBloqueo* (arriba) es un acceso de sincronización. También lo es la operación de *lectura* implícita en *testAndSet*.

Los accesos de sincronización son competitivos, ya que los procesos que potencialmente necesitan sincronizarse acceden a variables de sincronización de forma concurrente y deben actualizarlas: las operaciones de *lectura* por sí solas no permiten conseguir la sincronización. Pero no todos los accesos competitivos son accesos de sincronización ya que existen algunos tipos de algoritmos paralelos en los que los procesos realizan accesos competitivos a variables compartidas simplemente para actualizar y leer resultados de otro y no para sincronizar.

Los accesos de sincronización también se dividen en accesos de *adquisición* y accesos de *liberación*, en función de su papel en el bloqueo potencial del proceso que realiza el acceso o en el desbloqueo de otros procesos.

◇ **Realización de operaciones asíncronas.** En la descripción de la implementación DSM con consistencia secuencial, se explicó que las operaciones de memoria pueden sufrir retardos significativos. Existen varios tipos de operaciones asíncronas que permiten incrementar la velocidad a la que se ejecutan los procesos, a pesar de los mencionados retardos. En primer lugar, las operaciones de *escritura* pueden implementarse de forma asíncrona. Un valor escrito es almacenado en un búfer antes de ser propagado y los efectos de la *escritura* se observan con posterioridad desde otros procesos. En segundo lugar, las implementaciones de DSM pueden realizar de forma anticipada la búsqueda de valores con anticipación a su lectura, evitándose así la parada de un proceso cuando necesita dichos valores. En tercer lugar, los procesadores pueden ejecutar las instrucciones fuera de orden. Mientras se espera la finalización del acceso a memoria actual, se puede iniciar la siguiente instrucción, siempre que ésta no dependa de la actual.

A la vista de las operaciones asíncronas que se acaban de presentar, distinguiremos entre el punto en el que una operación de *lectura* o *escritura* es iniciada (cuando el proceso comienza la ejecución de la operación) y el punto en el que la instrucción es *efectuada* o completada.

Supondremos que nuestro DSM es, al menos, coherente. Como se explicó en la Sección 16.2.3, esto significa que cada proceso está de acuerdo en el orden de las operaciones de *escritura* sobre una misma posición. Dada esta suposición, podemos hablar de forma no ambigua del orden de las operaciones de *escritura* sobre una cierta posición.

En un sistema de memoria compartida distribuida, podemos dibujar un diagrama temporal para cualquier operación de memoria *o* que ejecute el proceso *P* (véase la Figura 16.11).

Decimos que una operación de *escritura* *E(x)v* se ha realizado con respecto al proceso *P* si desde ese punto las operaciones de *lectura* de *P* devuelven el valor *v* escrito por la operación de *escritura*, o bien el valor escrito por alguna operación posterior sobre *x* (nótese que otra operación puede escribir el mismo valor *v*).

De forma similar, decimos que una operación de *lectura* *L(x)v* se ha realizado con respecto al proceso *P* cuando ninguna *escritura* posterior iniciada sobre la misma posición pueda proporcionar

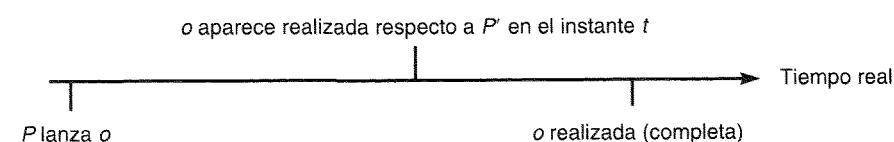


Figura 16.11. Diagrama temporal de una operación de *lectura* o *escritura* sobre DSM.

el valor *v* que *P* lee. Por ejemplo, *P* puede haber obtenido mediante prebúsqueda el valor que necesita *leer*.

Finalmente, se dice que la operación *o* se ha *realizado* si lo ha hecho respecto a todos los procesos.

16.4.2. CONSISTENCIA RELAJADA

Los requisitos que pretendemos cumplir son:

- Preservar la semántica de sincronización de objetos del tipo de bloqueos y barreras.
- Mejorar las prestaciones, para lo cual se permite un cierto grado de asincronía en las operaciones de memoria.
- Limitar el solapamiento entre los accesos a memoria para garantizar ejecuciones cuyos resultados sean equivalentes a los obtenidos con consistencia secuencial.

La memoria con consistencia relajada se ha diseñado para satisfacer estos requisitos. Gharachorloo y otros [1990] definen la consistencia relajada de la siguiente forma:

- CR1: Antes de permitir que una operación ordinaria de *lectura* o *escritura* se realice respecto a cualquier otro proceso, deben haberse realizado todos los accesos de *adquisición* previos.
- CR2: Antes de permitir que una operación de *liberación* sea realizada con respecto a cualquier otro proceso, deben haberse realizado todas las operaciones ordinarias de *lectura* y *escritura* previas.
- CR3: Las operaciones de *adquisición* y *liberación* son secuencialmente consistentes entre ellas.

CR1 y CR2 garantizan que, cuando se haya realizado una liberación, ningún otro proceso que haya adquirido un bloqueo pueda leer versiones caducadas de los datos modificados por el proceso que realiza la liberación. Esto coincide con las expectativas de los programadores ya que cuando, por ejemplo, se libera un bloqueo, eso implica que un proceso ha terminado de modificar los datos dentro de la sección crítica.

El soporte en tiempo de ejecución de DSM sólo podrá forzar la consistencia relajada si es consciente de los accesos de sincronización. Por ejemplo, en Munin, el programador se ve forzado a utilizar las primitivas propias de Munin *acquireLock* (adquiere bloqueo), *releaseLock* (libera bloqueo) y *waitAtBarrier* (espera en la barrera). (Una barrera es un objeto de sincronización que bloquea cada uno de los procesos de un conjunto hasta que todos ellos hayan llegado a ella; entonces todos los procesos continúan.) Un programa debe utilizar la sincronización para asegurar que las actualizaciones se hacen visibles al resto de procesos. Dos procesos que comparten DSM pero no utilizan nunca objetos de sincronización pueden que nunca vean las actualizaciones que realizan entre ellos si la implementación garantiza estrictamente las condiciones expuestas previamente.

Nótese que el modelo de consistencia relajada permite que una implementación realice algunas operaciones asíncronas. Por ejemplo, un proceso necesita no ser bloqueado cuando realiza actualizaciones dentro de una sección crítica. Sus actualizaciones tampoco necesitan propagarse hasta que deja la sección crítica mediante la liberación del bloqueo. Además las actualizaciones pueden recolectarse y ser enviadas en un único mensaje. Únicamente la actualización final a cada dato debe ser enviada.

Considérense los procesos de la Figura 16.12, los cuales adquieren y liberan un bloqueo para acceder a una pareja de variables *a* y *b* (*a* y *b* son inicializadas a cero). El proceso 1 actualiza *a* y *b* bajo condiciones de exclusión mutua, de forma que el proceso 2 no puede leer *a* y *b* al mismo tiempo y por lo tanto para él se cumplirá que *a* = *b* = 0 o bien *a* = *b* = 1. Las secciones críticas

Proceso 1:

```
adquiereBloqueo(); // entra a la sección crítica
```

```
adquiereBloqueo(); // entra a la sección crítica
a:=a+1;
b:=b+1;
liberaBloqueo() // sale de la sección crítica
```

Proceso 2:

- El programador puede realizar anotaciones que asocien un bloqueo con ciertos conjuntos de datos. En este caso, el soporte en tiempo de ejecución de DSM puede propagar las actualizaciones relevantes en el mismo mensaje utilizado para transferir el bloqueo al proceso en espera, asegurando que el receptor del bloqueo tiene copias de los datos que necesita antes de utilizarlos.

Keleher y otros [1992] describen una alternativa a la aproximación *impaciente* de Munin, es decir, al envío de información de actualización o invalidación el mismo instante de la liberación. En su lugar, esta implementación *débil* realiza dicho envío únicamente cuando dicho bloqueo es adquirido a continuación. Además, envía esta información sólo a los procesos que adquieran el bloqueo y la inserta en el mensaje que sirve para conceder la adquisición de bloqueo. Es innecesario hacer visible las actualizaciones a los otros procesos hasta que ellos adquieran, por turno, el bloqueo.

◊ **Anotaciones de compartición.** Munin implementa diferentes protocolos de consistencia aplicados con una granularidad a nivel de datos individuales. Los protocolos están parametrizados según las siguientes opciones:

- Protocolo de escritura actualizante o de invalidación de escritura.
- Que puedan o no existir de forma simultánea varias copias de un dato modificable.
- Que se retarden o no las actualizaciones o las invalidaciones (por ejemplo, bajo la consistencia relajada).
- Que los datos tengan o no un propietario fijo, al que se deben enviar todas las actualizaciones.
- Que el mismo dato pueda o no ser modificado concurrentemente por varios escritores.
- Que los datos puedan o no ser compartidos por un conjunto fijo de procesos;
- Que los datos puedan o no ser modificados.

Estas opciones son elegidas en función de la naturaleza de los datos y de sus patrones de compartición entre procesos. El programador puede elegir de forma explícita qué opciones usar para cada dato. Sin embargo, Munin proporciona un conjunto pequeño, estándar de anotaciones válidas para una gran variedad de aplicaciones y datos para que el programador las aplique sobre los datos; cada una de estas anotaciones supone una elección adecuada de los parámetros. Son las siguientes:

Sólo lectura: después de la inicialización no se realizan actualizaciones y el dato puede ser copiado libremente.

Migratorio: los procesos realizan por turno varios accesos al dato, siendo al menos uno de ellos una actualización. Por ejemplo, el dato puede ser accedido dentro de una sección crítica. Munin siempre proporciona los accesos de lectura y escritura juntos en dicho objeto, incluso cuando un proceso genera un fallo de lectura. Esto ahorra el procesamiento de los fallos de escritura posteriores.

Escritura compartida: varios procesos actualizan simultáneamente la misma variable (por ejemplo, un array) de forma que esta anotación es una declaración por parte del programador de que los procesos no actualizan las mismas partes de la variable. Esto significa que Munin puede evitar la compartición falsa pero debe propagar sólo aquellas palabras del dato que cada proceso está actualizando actualmente. Para conseguirlo, Munin realiza una copia de la página (dentro de un gestor de fallos de escritura) justo antes de que sea actualizada localmente. Sólo las diferencias entre las dos versiones de la página son enviadas en una actualización.

Productor-consumidor: el dato es compartido por un conjunto fijo de procesos, siendo actualizado sólo por uno de ellos. Como ya se explicó anteriormente en la discusión del thrashing, en este caso es más apropiado un protocolo de escritura actualizante. Además, las actualizaciones pueden ser retrasadas utilizando el modelo de consistencia relajada, suponiendo que el proceso utiliza bloqueos para sincronizar su acceso.

Reducción: el dato siempre es modificado siguiendo la secuencia de bloqueo, lectura, actualización y desbloqueo. Por ejemplo, un mínimo global en una computación paralela debe ser localizado y modificado atómicamente si es mayor que el mínimo local. Estas variables son almacenadas y modificadas atómicamente.

632 Sistemas distribuidos

Reducción: el dato siempre es modificado siguiendo la secuencia de bloqueo, lectura, actualización y desbloqueo. Por ejemplo, un mínimo global en una computación paralela debe ser localizado y modificado atómicamente si es mayor que el mínimo local. Estas variables son almacenadas y modificadas atómicamente.

enlaza a un objeto de sincronización, como por ejemplo un bloqueo, que gobierna el acceso a dicha variable. El primer proceso que adquiera el bloqueo tiene garantizada la lectura del valor más reciente de la variable. Un proceso que quiera escribir en la variable debe obtener primero el correspondiente bloqueo en modo *exclusivo*, de forma que dicho proceso sea el único capaz de acceder a la variable. Varios procesos podrán leer de forma concurrente la variable manteniendo el bloqueo en modo no exclusivo. Midway evita la tendencia a la compartición falsa de la consistencia relajada, pero a costa de incrementar la complejidad de la programación.

Consistencia de ámbito: este modelo de memoria [Iftode y otros 1996] trata de simplificar el modelo de programación de la consistencia *entry*. En la consistencia de ámbito, las variables se asocian con objetos de sincronización de forma automática en su mayor parte, en lugar de depender del programador para la asociación explícita de bloqueos a variables. Por ejemplo, el sistema puede monitorizar qué variables son actualizadas en una sección crítica.

Consistencia débil: la consistencia débil [Dubois y otros 1988] no distingue entre los accesos de sincronización *adquiere* y *libera*. Asegura que todos los accesos ordinarios previos se completan antes que lo haga *cualquiera* de los dos tipos de accesos de sincronización.

◊ **Discusión.** La consistencia relajada y algunos de los modelos de consistencia más débiles que la secuencial parecen ser los más prometedores para DSM. No parece muy significativa la desventaja del modelo de consistencia relajada consistente en que las operaciones de sincronización necesiten ser conocidas por el soporte en tiempo de ejecución de DSM, siempre y cuando las operaciones de sincronización proporcionadas por el sistema sean suficientemente potentes para cubrir las necesidades de los programadores.

Es importante darse cuenta de que, bajo los modelos híbridos, la mayor parte de los programadores no están forzados a tener en cuenta la semántica del modelo de consistencia de memoria utilizado, siempre que sincronicen los accesos a sus datos de forma adecuada. Pero existe el peligro general en los diseños DSM de pedir al programador que realice múltiples anotaciones a su programa para conseguir una ejecución eficiente. Esto incluye tanto anotaciones para asociar datos con objetos de sincronización como las anotaciones de compartición usadas en Munin. Se supone que una de las ventajas de la programación de memoria compartida sobre el paso de mensajes debería ser su relativa comodidad.

16.6. RESUMEN

En este capítulo se ha descrito y justificado el concepto de memoria compartida distribuida como una abstracción de la memoria compartida que sirve de alternativa a la comunicación basada en mensajes en un sistema distribuido. El objetivo principal de DSM es el procesamiento paralelo y la compartición de los datos. Se ha demostrado que sus prestaciones son comparables a las del paso de mensajes para ciertas aplicaciones paralelas, pero es difícil conseguir una implementación eficiente y sus prestaciones dependen en gran medida de las aplicaciones.

Este capítulo se ha centrado en las implementaciones software de DSM (en particular aquellas basadas en el subsistema de memoria virtual) con un cierto soporte del hardware.

Las principales cuestiones de diseño e implementación son la estructura de DSM, la forma de sincronizar las aplicaciones, el modelo de consistencia de memoria, la utilización de protocolos de escritura actualizante o de invalidación de escritura, la granularidad de la compartición y el thrashing.

DSM puede estructurarse como una serie de bytes, como una colección de objetos compartidos o como una colección de datos inmutables como las tuplas.

Las aplicaciones en DSM necesitan la sincronización para cumplir los requisitos de consistencia específicos de la aplicación. Para este propósito utilizan objetos como los bloqueos, implementados utilizando paso de mensajes por razones de eficiencia.

El modelo de consistencia más estricto implementado en los sistemas DSM es la consistencia secuencial. Debido a su coste, se han desarrollado otros modelos de consistencia más débiles, como la coherencia y la consistencia relajada. La consistencia relajada permite a la implementación utilizar los objetos de sincronización para conseguir mayor eficiencia sin romper las restricciones de consistencia del nivel de aplicación. Se han mencionado brevemente otros modelos de consistencia, incluyendo la consistencia de entrada, la de ámbito y la débil, todas ellas basadas en la sincronización.

Los protocolos de escritura actualizante son aquellos en los que las actualizaciones de los datos son propagadas a todas sus copias. Normalmente son implementadas en hardware, a pesar de que también existen implementaciones software que utilizan multidifusiones totalmente ordenadas. Los protocolos de invalidación de escritura evitan la lectura de datos no válidos mediante la invalidación de todas las copias cuando los datos son actualizados. Estos protocolos se adaptan mejor a los sistemas DSM basados en páginas, para los que la escritura actualizante puede ser una opción costosa.

La granularidad de DSM modifica la probabilidad de contención entre procesos con compartición falsa de datos ya que dichos datos están contenidos en la misma unidad de compartición (una página, por ejemplo). También afecta al coste por byte de la transferencia de actualizaciones entre computadores.

El thrashing puede ocurrir cuando se utiliza invalidación de escritura. Consiste en la transferencia repetida de datos entre procesos competidores a costa del progreso de la aplicación. Este efecto puede ser reducido mediante la sincronización a nivel de aplicación, permitiendo a los computadores retener una página durante una mínima cantidad de tiempo, o mediante el etiquetado de los datos de forma que las lecturas y las escrituras sean concedidas conjuntamente.

En este capítulo se han descrito los tres principales protocolos de invalidación de escritura de Ivy para DSM basada en páginas, que tratan el problema de la gestión del conjunto de copias de una página y de la localización de su propietario. Se trata del protocolo de gestión central, en el que un único proceso almacena la dirección del propietario actual de cada página; el protocolo basado en la multidifusión para localizar el propietario actual de una página; y el protocolo de gestión distribuida dinámica, que envía cadenas de punteros para localizar al propietario actual de una página.

Munin es un ejemplo de implementación de la consistencia relajada. Implementa una consistencia relajada impaciente caracterizada porque la propagación de los mensajes de actualización o invalidación se realiza tan pronto como el bloqueo es liberado. Existen otras implementaciones más débiles que propagan sólo aquellos mensajes que son solicitados. Munin permite a los programadores anotar sus datos para seleccionar aquellas opciones de protocolo que mejor se adapten, dada la forma en la que se comparten.

EJERCICIOS

- 16.1. Explique las diferentes razones que justifiquen si los sistemas DSM son viables o no en sistemas cliente-servidor.
 - 16.2. Discuta qué es más apropiado para aplicaciones tolerantes a fallos, si el paso de mensaje o DSM.
 - 16.3. ¿Cómo resolvería el problema de diferentes representaciones de datos para una implementación DSM basada en middleware sobre computadores heterogéneos? ¿Cómo se abordaría el problema en una implementación basada en páginas? ¿Su solución puede extenderse a punteros?
 - 16.4. ¿Por qué razón se podría querer implementar un sistema DSM basado en páginas a nivel de usuario y qué se necesita para conseguirlo?

16.5. ¿Cómo implementaría un semáforo utilizando un espacio de tuplas?

16.18. Muestre que la siguiente historia no tiene consistencia causal:

$$\begin{array}{ll} P_1: & E(a)0; E(a)1 \\ P_2: & L(a)1; E(b)2 \\ P_3: & L(b)2; L(a)0 \end{array}$$

16.19. ¿Qué ventaja puede obtener una implementación DSM si conoce la asociación entre datos y objetos de sincronización? ¿Cuál es la desventaja de realizar dicha asociación de forma explícita?

17

- El modelo de objeto que ofrece CORBA.
- El lenguaje de definición de interfaz y su correspondencia sobre el lenguaje de implementación.

Los otros aspectos de la programación sobre CORBA son similares a los que se discutieron en el Capítulo 5. En particular, el programador define interfaces remotas para los objetos remotos y después usa un compilador de interfaces para producir cada proxy y cada esqueleto correspondiente. Aunque en CORBA, el proxy se genera en el lenguaje del cliente y el esqueleto en el lenguaje del servidor. Utilizando el ejemplo de un tablero simple, presentado en la Sección 5.5, mostraremos cómo escribir una especificación IDL y cómo construir los programas cliente y servidor.

◊ **El modelo de objetos de CORBA.** El modelo de objetos de CORBA es similar al que se describió en la Sección 5.2, aunque los clientes no son objetos necesariamente; un cliente podrá ser cualquier programa que envíe mensajes de petición a los objetos remotos y reciba las respuestas. El término *objeto CORBA* se emplea para referirse a los objetos remotos. Así, un objeto CORBA implementa una interfaz de un IDL, tiene una referencia a un objeto remoto y es capaz de responder a las invocaciones de los métodos en su interfaz del IDL. Se puede implementar un objeto CORBA en un lenguaje que no sea orientado al objeto, por ejemplo sin el concepto de clase. Dado que los lenguajes de implementación pueden tener diferentes nociones de clase, o incluso ninguna en absoluto, el concepto de clase no existe en CORBA. Es así que no se pueden definir clases en CORBA IDL, lo que quiere decir que no podemos pasar instancias de clases como argumento. Sin embargo, sí se pueden pasar como argumentos estructuras de datos de varios tipos y de complejidad arbitraria.

◊ **CORBA IDL.** Una interfaz CORBA IDL especifica un nombre y un conjunto de métodos que podrán utilizar los clientes. La Figura 17.1 muestra dos interfaces de nombre *Forma* (en la línea 3) y *ListaForma* (en la línea 5), que son las versiones IDL de las interfaces definidas en la Figura 5.11. Éstas vienen precedidas de las definiciones de dos *estructuras* (*struct*), que que se emplean como tipos de los parámetros en la definición de los métodos. Adviértase que *ObjetoGrafico* se define como un *struct*, mientras que en el ejemplo en Java RMI era una clase. Un componente cuyo tipo sea un *struct* posee un conjunto de campos que contienen valores de diversos tipos, como las variables de instancia de un objeto, pero no posee métodos. Habrá más sobre IDL en la Sección 17.2.3.

Parámetros y resultados en CORBA IDL: Cada parámetro se marca como de entrada o de salida, o ambos, mediante las palabras clave *in*, *out* o *inout*. La Figura 5.2 muestra un ejemplo simple del uso de estas palabras clave. En la Figura 17.1, en la línea 7, el parámetro de *nuevaForma* es un parámetro *in* que indica que el argumento debería pasarse desde el cliente al servidor en el mensaje de petición. El valor de retorno proporciona un parámetro *out* adicional; si no hubiera parámetro *out* se indicaría como *void*.

Los parámetros podrán ser de uno cualquiera de los tipos primitivos, como *long* y *boolean*, o de uno de los tipos construidos como un *struct* o un *array*. Los tipos primitivos y estructurados se describen en mayor detalle en la Sección 17.2.3. Nuestro ejemplo muestra las definiciones de dos *struct* en las líneas 1 y 2. Las secuencias y las cadenas se definen mediante *typedef*, como se ve en la línea 4, que muestra una secuencia de elementos de tipo *Forma* de longitud 100. La semántica de paso de parámetros es como sigue:

Paso de objetos CORBA: cualquier parámetro cuyo tipo esté especificado mediante el nombre de una interfaz IDL, tal como el valor de vuelta *Forma* en la línea 7, es una referencia a un objeto CORBA y se pasa el valor de una referencia a un objeto remoto.

Paso de tipos primitivos y construidos de CORBA: los argumentos de tipo primitivo y construido se copian y se pasan por valor. En el destino, se crea un nuevo valor en el proceso

```
struct Rectangulo{
    long anchura;
    long altura;
    long x;
    long y;
};

struct ObjetoGrafico {
```

1

2

◊ **Pseudo objetos CORBA.** Las implementaciones de CORBA proporcionan algunas interfaces sobre las funciones del ORB que los programadores necesitan conocer. Éstas se denominan pseudo-objetos dado que no pueden utilizarse como si fueran objetos CORBA; por ejemplo, no pueden pasarse como argumentos en una RMI. Tienen interfaces IDL y vienen implementadas en bibliotecas. Para nuestro ejemplo sencillo, la relevante es:

- ORB es el nombre de una interfaz que representa la funcionalidad del ORB a la que necesitan acceder los programadores. Ésta incluye:
 - El método *init*, que deberá llamarse para inicializar el ORB.
 - El método *connect*, que se emplea para registrar objetos CORBA con el ORB.
 - Otros métodos, que permiten conversiones entre referencias a objetos remotos y cadenas de texto.

17.2.1. EJEMPLO DE CLIENTE Y SERVIDOR CORBA

Esta sección apunta las etapas necesarias al producir programas cliente y servidor que emplean las interfaces IDL *Forma* y *ListaForma* que se muestran en la Figura 17.1. Se sigue con una discusión sobre devoluciones de llamada en CORBA. Se emplea Java como lenguaje para el cliente y el servidor, pero la aproximación es similar para los otros lenguajes. El compilador de interfaz *idltojava* se aplica a las interfaces CORBA para generar los siguientes elementos:

- Cada interfaz Java equivalente. Por ejemplo, en la Figura 17.2 se muestra la interfaz Java para *ListaForma*.
- Un esqueleto de servicio para cada interfaz IDL. Los nombres de las clases esqueleto terminan en *ImplBase*, por ejemplo *_ListaFormaImplBase*.
- Una clase proxy o un resguardo de cliente, una por cada interfaz IDL. Los nombres de estas clases terminan en *Stub*, por ejemplo *_ListaFormaStub*.
- Una clase Java para cada construcción *struct* definida con las interfaces IDL. En nuestro ejemplo, se generan las clases *Rectangulo* y *ObjetoGrafico*. Cada una de estas clases contiene una declaración de una variable de instancia para cada campo del correspondiente *struct* y un par de constructores, aunque ningún método más.
- Clases denominadas ayudantes y propietarios, para cada uno de los tipos definidos en la interfaz IDL. Una clase ayudante contiene el método *narrow*, que se emplea para convertir a partir de una referencia dada a un objeto hacia la clase a la que pertenece, que estará en un punto más bajo de la jerarquía de clases. Por ejemplo, el método *narrow* en *FormaHelper* convierte hacia la clase *Forma*. La clase propietario trata con los argumentos de carácter *out* y *inout*, los cuales no se corresponden directamente con Java. Véase el Ejercicio 17.9 para un ejemplo del uso de propietarios.

◊ **Programa servidor.** El programa servidor deberá contener implementaciones de una o más interfaces IDL. Para un servidor escrito en un lenguaje orientado al objeto como Java o C++, estas implementaciones vienen dadas en las clases sirvientes. Los objetos CORBA son instancias de las clases sirvientes.

```
public interface Listaforma extends org.omg.CORBA.Object {
    Forma nuevaForma(ObjetoGrafico g) throws ListaFormaPackage.ExcepcionLlena;
    Forma [] todasFormas();
    int dameVersion();
}
```

Figura 17.2. Interfaz Java *ListaForma* generado por *idltojava* de la interfaz CORBA *ListaForma*.

```

import org.omg.CORBA.*;
class SirvienteListaForma extends _ListaFormaImplBase {
    ORB elORB;
    private Forma laLista[];
    private int version;
    private static int n=0;
    private SirvienteListaForma(ORB orb){
        elOrb=orb;
        // inicialización de las otras variables de instancia
    }
    public Forma nuevaForma(ObjetoGrafico g) throws ListaFormaPackage.ExcepcionLlena{
        version++;
        Forma f=new SirvienteForma(g, version);
        if(n>=100) throw new ListaFormaPackage.ExcepcionLlena();
        laLista[n++]=f;
        elOrb.connect(f);
        return s;
    }
    public Forma[] todasFormas(){...}
    public int dameVersion(){...}
}

```

Figura 17.3. Clase *SirvienteListaForma* del programa servidor para la interfaz CORBA *ListaForma*.

Cuando un servidor crea una instancia de una clase sirviente, deberá registrarla frente al ORB, que convierte la instancia en un objeto CORBA y le da una referencia a un objeto remoto. A menos que se haya hecho esto, no podrá recibir invocaciones remotas. Los lectores que hayan estudiado el Capítulo 5 cuidadosamente se darán cuenta de que al registrar el objeto se registra en el equivalente CORBA de la tabla de objetos remotos.

En nuestro ejemplo, el servidor contiene las implementaciones de las interfaces *Forma* y *ListaForma* en forma de dos clases sirvientes, junto con una clase servidora que contiene una sección de *inicialización* en su método *main*.

Las clases sirvientes: cada clase sirviente extiende la clase esqueleto correspondiente e implementa los métodos de una interfaz IDL empleando las signaturas de los métodos que se definen en la interfaz Java equivalente. La clase sirviente que implementa la interfaz *ListaForma* se denomina *SirvienteListaForma*, aunque podría haberse elegido cualquier otro nombre. Su diseño se muestra en la Figura 17.3. Consideré el método *nuevaForma* en la línea 1, que es un método factoría puesto que crea objetos *Forma*. Para hacer de un objeto *Forma* un objeto CORBA, se registra frente al ORB por medio de su método *connect*, como se muestra en la línea 2. Las versiones completas de la interfaz IDL y de las clases del cliente y del servidor se encuentran disponibles en cdk3.net/corba.

El servidor: el método *main* de la clase del servidor *ServidorListaForma* se muestra en la Figura 17.4. Primero crea e inicializa el ORB (véase la línea 1). Posteriormente crea una instancia de *SirvienteListaForma*, que no es más que un objeto Java (véase la línea 2). Lo convierte en un objeto CORBA al registrarlo frente al ORB (véase la línea 3). Tras esto, obtiene una referencia al Servicio de Nombres (véase la línea 4) e invoca la operación *rebind* para registrar al servidor frente al Servicio de Nombres (véase la línea 7). Es entonces cuando espera las peticiones de los clientes.

Los servidores al hacer uso del Servicio de Nombres primero obtienen un contexto de nominación raíz (véase la línea 4), después crean un *NameComponent* (véase la línea 5), definen una ruta

```

import org.omg.CosNaming.*;
import org.omg.CosNaming.NamingcontextPackage.*;
import org.omg.CORBA.*;
public class ServidorListaForma {
    public static void main(String args[]) {
        try{
            ORB orb = ORB.init(args, null);
            SirvienteListaForma formaRef = new SirvienteListaForma(orb)
            orb.connect(formaRef);
            org.omg.CORBA.Object objRef =
                orb.resolve_initial_references("NameService");
            NamingContext ncRef = NamingContextHelper.narrow(objRef);
            NameComponent nc = new NameComponent("ListaForma", "");
            NameComponent ruta[] = {nc};
            ncRef.rebind(ruta, formaRef);
            java.lang.Object sincr = new java.lang.Object();
            synchronized(sincr) { sincr.wait();}
        } catch (Exception e) {...}
    }
}

```

Figura 17.4. Clase Java *ServidorListaForma*.

(véase la línea 6) y finalmente emplean el método *rebind* (véase la línea 7) para registrar el nombre y la referencia al objeto remoto. Los clientes llevan a cabo los mismos pasos pero emplean el método *resolve* según se muestra en la Figura 17.5, en la línea 2.

◊ **El programa cliente.** En la Figura 17.5 se muestra un ejemplo de un programa cliente. Crea e inicializa un ORB (véase la línea 1), entonces contacta con el Servicio de Nombres para obtener una referencia al objeto remoto *ListaForma* mediante su método *resolve* (véase la línea 2). Tras ello, invoca su método *todasFormas* (véase la línea 3) para conseguir una secuencia de referencias a objetos remotos de todas las *Formas* que posee el servidor en la actualidad. Despues invoca el método *dameTodoEstado* (véase la línea 4), dándole como argumento la referencia al primer objeto remoto de la secuencia obtenida; el resultado se proporciona como una instancia de la clase *ObjetoGrafico*.

El método *dameTodoEstado* parece contradecir nuestra afirmación anterior de que no es posible pasar objetos por valor en CORBA, dado que tanto el cliente como el servidor trabajan con instancias de la clase *ObjetoGrafico*. Sin embargo, no hay tal contradicción: el objeto CORBA devuelve un elemento *struct*, y los clientes que emplearan otro lenguaje diferente también lo verían de forma diferente. O por ejemplo, en el lenguaje C++ el cliente lo vería también como un *struct*. Incluso en Java, la clase generada *ObjetoGrafico* es más parecida a un *struct* dado que no posee métodos.

Los programas cliente deberían atrapar siempre las excepciones CORBA *SystemExceptions*, que informan de los errores debidos a la distribución (véase la línea 5). Los programas cliente también deberían atrapar las excepciones definidas en la interfaz IDL, tales como *ExcepcionLlena* que lanza el método *nuevaForma*.

Este ejemplo ejemplifica el uso de la operación *narrow*: la operación *resolve* del Servicio de nombres devuelve un valor del tipo *Object*; este tipo se restringe para adecuarse al tipo concreto requerido: *ListaForma*.

◊ **Devoluciones de llamada.** Las devoluciones de llamada (*retrollamadas*) pueden implementarse en CORBA de modo similar a la descrita para Java RMI en la Sección 5.5.1. Por ejemplo la interfaz *RetrollamadaTablero* podría definirse como sigue:

```

import org.omg.CosNaming.*;
import org.omg.CosNaming.NamingcontextPackage.*;
import org.omg.CORBA.*;
public class ClienteListaForma{
    public static void main(String args[]) {
        try{
            ORB orb = ORB.init(args, null);
            org.omg.CORBA.Object objRef=
                orb.resolve_initial_references("NameService");
            NamingContext ncRef = NamingContextHelper.narrow(objRef);
            NameComponent nc = new NameComponent("ListaForma", "");
            NameComponent ruta []={ nc };
            ListaForma listaFormaRef =
                ListaFormaHelper.narrow(ncRef.resolve(ruta));
            Forma[] listaF = listaFormaRef.todasFormas();
            ObjetoGrafico g = listaF[0].dameTodoEstado();
        } catch (org.omg.CORBA.SystemException e) {...}
    }
}

```

Figura 17.5. Programa cliente Java para las interfaces CORBA *Forma* y *ListaForma*.

```

interface retrollamadaTablero {
    oneway void retrollamada(in int version);
};

```

Esta interfaz se implementa como un objeto CORBA por parte del cliente, permitiendo que el servidor envíe al cliente un número de versión cuando se añadan objetos nuevos. Pero antes de que el servidor pueda hacer esto, el cliente necesita informar al servidor de la referencia a este objeto remoto. Para posibilitar esto, la interfaz *ListaForma* requiere métodos adicionales tales como *registra* y *desregistra*, como sigue:

```

int registra(in RetrollamadaTablero retrollamada);
void desregistra(in int idRetrollamada);

```

Después de que el cliente haya obtenido una referencia al objeto *ListaForma* y creado una instancia de *RetrollamadaTablero*, emplea el método *registra* de *ListaForma* para informar al servidor de que está interesado en recibir retrollamadas. El objeto *ListaForma* del servidor es el responsable de mantener una lista de clientes interesados y de notificar a todos ellos cada vez que se incrementa el número de versión al añadir un objeto nuevo. El método *retrollamada* se declara como *oneway* de modo que el servidor pueda utilizar llamadas asíncronas para evitar retrasos cuando notifica a cada cliente.

17.2.2. LA ARQUITECTURA DE CORBA

La arquitectura está diseñada para dar soporte al papel de un intermediario de peticiones de objetos que permita que los clientes invoquen métodos en objetos remotos, donde tanto los clientes como los servidores puedan implementarse en variedad de lenguajes de programación. Los componentes principales de la arquitectura CORBA se muestran en la Figura 17.6.

Al comparar esta figura con la Figura 5.6 advertimos que la arquitectura CORBA contiene tres componentes mayores: el adaptador de objeto, el repositorio de implementación y el repositorio de interfaz.

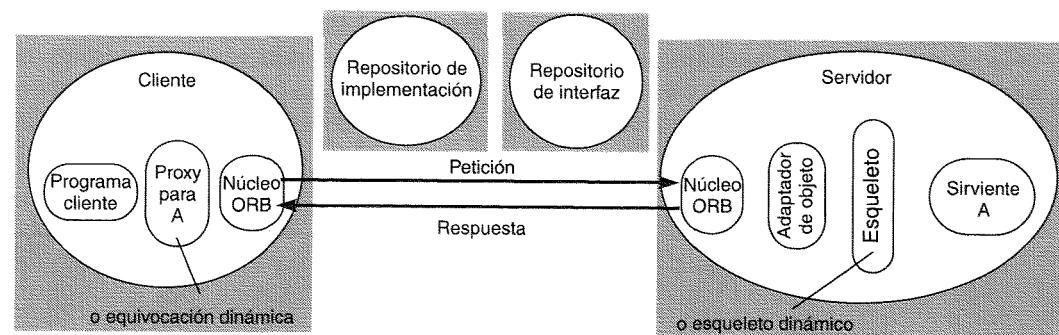


Figura 17.6. Componentes principales de la arquitectura CORBA.

CORBA distingue entre invocaciones estáticas y dinámicas. Las invocaciones estáticas se emplean cuando se conoce en tiempo de compilación la interfaz remota del objeto CORBA, lo que permite emplear un resguardo de cliente y un esqueleto de servidor. Si la interfaz remota no es conocida en tiempo de compilación, debe emplearse una invocación dinámica. La mayoría de los programadores prefieren emplear la invocación estática porque proporciona un modelo de programación más natural.

A continuación, discutiremos los componentes de la arquitectura, dejando para el final aquellos relacionados con la invocación dinámica.

◇ **El núcleo de ORB.** El papel del núcleo de ORB es similar al del módulo de comunicación de la Figura 5.6. Además, un núcleo de ORB proporciona una interfaz que incluye lo siguiente:

- Operaciones que permiten su arranque y parada.
- Operaciones para la conversión entre referencias a objetos remotos y cadenas de texto.
- Operaciones para obtener listas de argumentos para las llamadas que emplean invocación dinámica.

◇ **Adaptador de objeto.** El papel de un *adaptador de objeto* es servir de puente sobre el hueco que media entre los objetos con interfaces IDL y las interfaces del lenguaje de programación de las correspondientes clases sirviente. Este papel también cubre la existente entre la referencia remota y los módulos de despacho en la Figura 5.6. Un adaptador de objeto tiene los siguientes cometidos:

- Crea referencias a objetos remotos para los objetos CORBA.
- Despacha cada RMI vía un esqueleto hacia el sirviente apropiado.
- Activa objetos.

Un adaptador de objeto da a cada objeto CORBA un único *nombre de objeto*, que forma parte de su referencia a objeto remoto. Cada vez que se activa un objeto se empleará este mismo nombre. El nombre de objeto puede venir especificado por el programa de aplicación o ser generado por el adaptador de objeto. Cada objeto CORBA se registra frente a su adaptador de objeto, que puede mantener una tabla a objetos remotos que relaciona los nombres de objetos CORBA con sus sirvientes.

Cada adaptador de objeto tiene su propio nombre, que también forma parte de las referencias a objeto remoto de todos los objetos CORBA que gestiona. También este nombre puede venir especificado por el programa de aplicación o generarse automáticamente. El estándar CORBA 2.2 para los adaptadores de objetos se denomina Adaptador de Objetos Portables (*Portable Object Adapter*, POA). Se dice que es portable porque permite lanzar aplicaciones y sirvientes sobre cualquier ORB producido por desarrolladores diferentes [Vinoski 1998].

◇ **Esqueletos.** Las clases esqueleto se generan en el lenguaje del servidor mediante un compilador de IDL. Igual que antes, las invocaciones de métodos remotos se despachan mediante el esqueleto apropiado a un sirviente concreto, y el esqueleto desempaquetá los argumentos desde los mensajes de petición y empaquetá las excepciones y los resultados en mensajes de respuesta.

◇ **Resguardo/proxy del cliente.** Se encuentran en el lenguaje del cliente. La clase de un proxy (para los lenguajes orientados al objeto) o un conjunto de procedimientos de resguardo (para los lenguajes procedimentales) se genera desde una interfaz IDL mediante un compilador de IDL para el lenguaje del cliente. Igual que antes, cada resguardo/proxy empaquetá los argumentos de los mensajes de invocación y desempaquetá las excepciones y los resultados de las respuestas.

◇ **Repositorio de implementación.** Cada repositorio de implementación es responsable de activar los servidores registrados bajo demanda y localizar los servidores que están en ejecución en cada momento. Para hacer referencia a los servidores, cuando se registran y se activan se emplea el nombre del adaptador del objeto.

Un repositorio de implementación almacena la correspondencia de los nombres de ciertos adaptadores de objetos con las rutas de los archivos que contienen los objetos de la implementación. Los objetos de la implementación y los nombres del adaptador de objetos se registran usualmente frente al repositorio de implementación cuando se instalan los programas servidores. Cuando se activan las implementaciones de los objetos en los servidores, se añade a la relación el nombre del computador y el número de puerto donde se ubica el servidor.

Entrada del repositorio de implementación:

Nombre de adaptador de objeto	Ruta de la implementación de objeto	Nombres host y número de puerto del servidor
-------------------------------	-------------------------------------	--

No todos los objetos CORBA necesitan ser activados bajo demanda. Algunos objetos, por ejemplo los objetos de retrollamada creados por los clientes, se lanzan una vez y dejan de existir cuando ya no se necesitan. Éstos no utilizan el repositorio de implementación.

Un repositorio de implementación permite almacenar generalmente cierta información extra sobre cada servidor, por ejemplo, información de control de acceso sobre quién está capacitado para activarlo o para invocar sus operaciones. Es posible replicar información en los repositorios de implementación para proporcionar disponibilidad o tolerancia a fallos.

◇ **Repositorio de interfaz.** El papel del repositorio de interfaz es proporcionar información sobre las interfaces IDL registradas a los clientes y a los servidores que lo requieran. Para una interfaz de un cierto tipo puede aportar los nombres de los métodos y para cada método los nombres y los tipos de los argumentos y las excepciones. Así, el repositorio de interfaz añade posibilidades de reflexión a CORBA. Suponga que un programa cliente recibe una referencia remota a un nuevo objeto CORBA. Suponga también que el cliente no tiene un proxy para él; entonces se podrá consultar al repositorio de interfaz sobre los métodos del objeto y los tipos de los parámetros que requiere.

El compilador de IDL asigna un identificador de tipo único a cada tipo IDL de cada interfaz que compila. En las referencias a objetos remotos se incluye un identificador de tipo para los objetos CORBA de ese tipo. Este identificador se denomina ID del repositorio porque puede usarse como clave para las interfaces IDL registradas en el repositorio de interfaz.

Aquellas aplicaciones que utilicen la invocación estática (ordinaria) con resguardos de cliente y esqueletos del IDL no necesitan un repositorio de interfaz. No todos los ORB proporcionan un repositorio de interfaz.

◇ **Interfaz de invocación dinámica.** En algunas aplicaciones, puede que un cliente sin la clase proxy apropiada necesite invocar un método de un objeto remoto. Por ejemplo, un visualizador puede necesitar mostrar información sobre todos los objetos CORBA disponibles en los diferentes servidores de un sistema distribuido. No es razonable que tal programa tenga que enlazar un proxy para cada uno de estos objetos, y más concretamente si se tiene en cuenta que se pueden añadir más objetos nuevos según transcurre el tiempo en el sistema. CORBA no permite cargar clases de proxy en tiempo de ejecución como en Java RMI. La alternativa de CORBA es la interfaz de invocación dinámica.

Ésta permite que los clientes realicen invocaciones dinámicas sobre objetos remotos CORBA. Se emplea cuando no es práctico emplear proxies. El cliente puede obtener la información necesaria sobre los métodos disponibles para un objeto CORBA dado desde el repositorio de interfaz. El cliente puede utilizar esta información para construir una invocación con los argumentos apropiados y enviarla al servidor.

◇ **Interfaz de esqueleto dinámica.** Ésta permite a un objeto CORBA aceptar invocaciones sobre una interfaz para la que no hay un esqueleto, posiblemente porque no se conocía el tipo de su interfaz en tiempo de compilación. Cuando un esqueleto dinámico recibe una invocación, inspecciona los contenidos de la petición para descubrir el objeto destino, el método que se invoca y los argumentos. A continuación invoca sobre el objetivo.

◇ **Código de legado.** El término *código de legado* se refiere al código existente que no fue diseñado previendo los objetos distribuidos. Se puede convertir un fragmento de código de legado en un objeto CORBA definiendo una interfaz IDL para él y proporcionando la implementación de un adaptador de objeto y los esqueletos.

17.2.3. LENGUAJE DE DEFINICIÓN DE INTERFAZ DE CORBA

El Lenguaje de Definición de Interfaz (*Interface Definition Language*) de CORBA, IDL, ofrece mecanismos para definir módulos, interfaces, tipos, atributos y signaturas de métodos. Hemos mostrado ejemplos de todo lo anterior, excepto módulos, en las Figuras 5.2 y 17.1. IDL tiene las mismas reglas léxicas que C++ pero tiene palabras adicionales para dar soporte a la distribución, por ejemplo *interface*, *any*, *attribute*, *in*, *out*, *inout*, *readonly* y *raises*. También proporciona las posibilidades de preprocesamiento estándar de C++. Véase, por ejemplo, el *typedef* para *Todo* en la Figura 17.7. La gramática de IDL es un subconjunto de ANSI C++ con constructores adicionales para soportar signaturas de métodos. Aquí mostramos sólo un breve panorama de IDL. En Baker [1997] y Henning y Vinoski [1999] se da una interesante visión de conjunto y muchos ejemplos. La especificación completa se encuentra disponible en [OMG 1997d].

◇ **Módulos IDL.** La construcción módulo permite agrupar en unidades lógicas las interfaces y otras definiciones de tipo IDL. *module* define un alcance léxico, que previene la colisión de los nombres definidos en el interior de un módulo con los nombres definidos fuera de él. Por ejemplo, las definiciones de las interfaces *Forma* y *ListaForma* podrían pertenecer a un módulo denominado *Tablero*, como se indica en la Figura 17.7.

◇ **Interfaces IDL.** Como ya se vio, una interfaz IDL describe los métodos disponibles en los objetos CORBA que implementan esa interfaz. Podrían diseñarse clientes de un objeto CORBA partiendo del único conocimiento de esta interfaz IDL. Estudiando nuestros ejemplos, los lectores verán que una interfaz define un conjunto de operaciones y atributos y depende generalmente de un conjunto de tipos definidos con ésta. Por ejemplo, la interfaz *ListaPersona* de la Figura 5.2 define un atributo y tres métodos y depende del tipo *Persona*.

```

módulo Tablero {
    struct Rectangulo{
        ...;
    };
    struct ObjetoGrafico {
        ...;
    };
    interface Forma {
        ...;
    };
    typedef secuencia <Forma, 100> Todo;
    interface ListaForma {
        ...;
    };
};

```

Figura 17.7. Módulo IDL de *Tablero*.

◇ **Métodos IDL.** La forma general de la firma de un método es:

```
[oneway] <tipo_devuelto> <nombre_método> (parámetro1, ..., parámetroL)
[raises (excep1, ..., excepN)] [contexto (nombre1, ..., nombreM)]
```

donde las expresiones entre corchetes son opcionales. Como ejemplo de un método que contenga sólo las partes necesarias, considere:

```
void damePersona(in string nombre, out Persona p);
```

Según se explicó en la Sección 17.2, los parámetros se etiquetan como *in*, *out* o *inout*, donde el valor de un parámetro *in* se pasa desde el cliente al objeto CORBA invocado y el valor de un parámetro *out* se devuelve desde el objeto CORBA invocado hacia el cliente. Los parámetros etiquetados como *inout* se emplean raramente, e indican que su valor puede pasarse en ambas direcciones. El tipo de valor devuelto puede especificarse como *void* si no se devuelve ningún valor.

La expresión *oneway* indica que el cliente que invoca el método no se bloqueará mientras el objeto destino lleva a cabo el método. Además, las invocaciones *oneway* se realizan con la semántica de llamadas *pudiera ser*. En la sección 17.2.1 vimos el siguiente ejemplo:

```
oneway void retrollamada(in int version);
```

En este ejemplo, donde el servidor llama al cliente cada vez que se añade una nueva forma, la pérdida ocasional de una petición no es un problema para el cliente, dado que la llamada indica exactamente que es improbable que se pierdan el número de la última versión y las llamadas subsiguientes.

La expresión opcional *raises* indica excepciones definidas por el usuario que pueden lanzarse para terminar la ejecución del método. Por ejemplo, considere el siguiente ejemplo de la Figura 17.1:

```
exception ExpcionLlena{ };
Forma nuevaForma(in ObjetoGrafico g) raises (ExpcionLlena);
```

El método *nuevaForma* especifica mediante la expresión *raises* que puede lanzar una excepción llamada *ExpcionLlena*, definida dentro de la interfaz *ListaForma*. En nuestro ejemplo, la excepción no contiene variables. Sin embargo, pueden definirse excepciones que contengan variables, por ejemplo:

```
exception ExpcionLlena( ObjetoGrafico g );
```

Tipo	Ejemplos	Uso
sequence	typedef sequence <Forma, 100> Todo; typedef sequence <Forma> Todo; secuencias de Formas con límite y sin límite	Define un tipo para una secuencia de longitud variable de elementos de un tipo IDL especificado. Puede especificarse una talla superior límite.
string	string nombre; typedef string <8> CadenaCorta; secuencias de caracteres con límite y sin límite	Define secuencias de caracteres, terminadas en el carácter nulo. Puede especificarse una talla superior límite.
array	typedef octet idUnico[12]; typedef ObjetoGrafico OG[10][8];	Define un tipo para una secuencia multidimensional de talla fija de elementos de un tipo IDL especificado.
record	struct ObjetoGrafico { string tipo; Rectangulo enmarcado; boolean estaRelleno; };	Define un tipo para un registro que contiene un grupo de entidades relacionadas. Cada <i>struct</i> se pasa por valor en los argumentos y en los resultados.
enumerated	enum Arbitr (Exp, Numero, Nombre);	El tipo enumerado en IDL hace corresponder un nombre de tipo sobre un pequeño conjunto de valores enteros.
union	union Exp switch (Arbitr) case Exp: string voto; case Numero: long n; case Nombre: string s; };	La unión IDL discriminada permite pasar como argumento uno de un conjunto de tipos dado. La cabecera está parametrizada por un <i>enum</i> , que especifica qué miembro está en uso.

Figura 17.8. Tipos IDL construidos.

Cuando se lanza una excepción que contiene variables, el servidor puede utilizar las variables para devolver información al cliente acerca del contexto de la excepción.

CORBA puede producir también excepciones de sistema sobre los problemas con los servidores, tales como estar demasiado ocupados o la imposibilidad de ser activados, problemas con la comunicación y problemas del lado del cliente. Los programas cliente deberían gestionar las excepciones de usuario y de sistema. La expresión opcional *context* se utiliza para aportar relaciones entre cadenas de nombres y cadenas de texto de valores. Vea Baker [1997] para una explicación de *context*.

◇ **Tipos IDL.** IDL soporta quince tipos primitivos, que incluyen *short* (16 bits), *long* (32 bits), *unsigned short*, *unsigned long*, *float* (32 bits), *double* (64 bits), *char*, *boolean* (TRUE, FALSE), *octet* (8 bits), y *any* (que podrá representar cualquier tipo primitivo o construido). Mediante la palabra clave *const*, es posible declarar constantes de la mayoría de los tipos primitivos y constantes de cadenas de texto. IDL proporciona un tipo especial llamado *Object*, cuyos valores son referencias a objetos remotos. Si un parámetro o el resultado es de tipo *Object*, entonces el argumento correspondiente podría referirse a cualquier objeto CORBA.

Los tipos IDL construidos se describen en la Figura 17.8, siendo que todos ellos se pasan por valor como argumentos y como resultados. Todas las cadenas o secuencias que se empleen como argumentos deben definirse en un *typedef*. Ninguno de los tipos de datos primitivos o construidos podrán contener referencias.

◇ **Atributos.** Las interfaces IDL pueden tener tanto atributos como métodos. Los atributos son como los campos de clase públicos en Java. Los atributos se pueden definir como *readonly* (sólo

como los campos de clase públicos en Java. Los atributos se pueden definir como *readonly* (sólo

lectura) allá donde se necesite. Los atributos son privados a los objetos CORBA, pero se genera un

pasar por valor objetos no-CORBA. Un *valuetype* es un *struct* con signaturas de métodos adicionales (como las de una interfaz). Los argumentos y resultados *valuetype* se pasan por valor; esto es, se pasa el estado al lugar remoto y se emplea para producir un nuevo objeto en el destino. Los métodos de este nuevo objeto pueden ser invocados localmente, provocando que su estado pueda diferir del estado del objeto original. El pasar la implementación de los métodos no es algo sencillo, dado que el cliente y el servidor pueden usar lenguajes diferentes. Sin embargo, si el cliente y el servidor están implementados en Java, el código podrá descargarse. Para ser implementado en C++, el código requerido deberá estar ya presente tanto en el cliente como en el servidor.

RMI asíncrono: El RMI síncrono de CORBA se adapta bien para su uso en entornos donde los clientes pueden quedar desconectados temporalmente (como por ejemplo un cliente que use un computador portátil en un tren). La especificación de mensajería de CORBA [OMG 1998d] propone una forma alternativa de RMI para abastecer a aquellos clientes susceptibles de desconectarse temporalmente. Por ejemplo, permite que las peticiones viajen mediante un agente intermediario, que se asegura que se lleva a cabo la petición y si es necesario almacena la respuesta. Además, la semántica de invocación de RMI tiene dos variantes nuevas: *callback*, en la que un cliente pasa una referencia a una devolución de llamada con la invocación, de modo que el servidor pueda devolver la llamada con los resultados; y *polling*, en la que el servidor devuelve un objeto *valuetype* que puede utilizarse para sondear o esperar por la respuesta.

17.2.4. REFERENCIAS A OBJETOS REMOTOS EN CORBA

CORBA 2.0 especifica un formato para las referencias a objetos remotos que es adecuada para su uso tanto si el objeto es activable remotamente como si no. Las referencias que utilizan este formato se denominan referencias a objetos remotos interoperables (IOR, *interoperable object reference*). La siguiente figura se basa en Henning [1998] y contiene el detalle del IOR:

Formato de IOR

Nombre de tipo de interfaz IDL	Protocolo y dirección detallada			Clave de objeto	
Identificador de repositorio de interfaz	IOP	Nombre de dominio del host	Número de puerto	Nombre de adaptador	Nombre de objeto

- El primer campo de un IOR especifica el nombre de tipo de la interfaz IDL del objeto CORBA. Observe que si el ORB tiene un repositorio de interfaz, este nombre de tipo es también el identificador de la interfaz IDL en el repositorio de interfaz.
- El segundo campo especifica el protocolo de transporte y los detalles necesarios para que ese protocolo de transporte identifique al servidor. En concreto, el protocolo Internet Inter-ORB (IIOP) emplea TCP/IP, en el que la dirección del servidor consta de un nombre de dominio de la máquina y un número de puerto.
- El tercer campo es empleado por el ORB para identificar un objeto CORBA. Consta del nombre de un adaptador de objeto en el servidor y el nombre de objeto de un objeto CORBA especificado por el adaptador de objeto.

El *IOR transitorio* de un objeto CORBA dura sólo el tiempo en que dura el proceso que lo aloja, mientras que un *IOR persistente* perdura entre las activaciones de los objetos CORBA. Un IOR transitorio contiene los detalles de las direcciones del servidor que contiene el objeto CORBA,

mientras que un IOR persistente contendrá los detalles de las direcciones del repositorio de implementación.

mientras que un IOR persistente contendrá los detalles de las direcciones del repositorio de implementación.

cliente acceda a éste cuando retorna la invocación. También tiene métodos para transmitir el argumento entre el servidor y el cliente.

A pesar de que las implementaciones en C++ de CORBA pueden gestionar parámetros *out* e *inout* de una forma bastante natural, los programadores de C++ padecen un diferente conjunto de problemas con los parámetros, relacionado con la gestión del almacenamiento. Estas penalidades aparecen cuando se pasan como argumentos referencias a objetos y entidades de longitud variable como las cadenas de texto o las secuencias.

Por ejemplo, en Orbix [Baker 1997] el ORB mantiene contadores de referencias a objetos remotos y proxy y los libera cuando no se necesitan más. Proporciona a los programadores métodos para liberarlos o duplicarlos. Cuando un método del servidor ha acabado su ejecución, los argumentos *out* y los resultados se liberan y el programador deberá duplicarlos si aún los necesitará. Por ejemplo, un sirviente C++ que implementara la interfaz *ListaForma* necesitará duplicar las referencias devueltas por el método *todasFormas*. Las referencias a objeto pasadas a los clientes deberán liberarse cuando no se vayan a necesitar. Las mismas reglas se aplican a los parámetros de longitud variable.

En general, los programadores que utilicen IDL no sólo tendrán que aprender la notación IDL en sí, sino que también tendrán que comprender cómo se correlacionan sus parámetros con los parámetros del lenguaje de implementación.

7.3. SERVICIOS DE CORBA

CORBA incluye especificaciones para los servicios que pudieran necesitarse en los objetos distribuidos. En concreto, el Servicio de Nombres es una parte esencial para cualquier ORB, como ya se vio en nuestro ejemplo de programación en esta sección. En el lugar web de OMG en [www.omg.org] se puede encontrar un índice de la documentación de estos servicios. Los servicios de CORBA se describen en Orfali y otros [1996] e incluyen los siguientes:

Servicio de Nombres: el Servicio de Nombres de CORBA se detalla en la Sección 17.3.1.

Servicio de Eventos y Servicio de Notificación: el Servicio de Eventos de CORBA (*Event Service*) se discute en la Sección 17.3.2 y el Servicio de Notificación (*Notification Service*) en la Sección 17.3.3.

Servicio de Seguridad: el Servicio de Seguridad de CORBA (*Security Service*) se discute en la Sección 17.3.4.

Servicio de Comercio: en contraste con el Servicio de Nombres que permite buscar los objetos CORBA por nombre, el Servicio de Comercio (*Trading Service*) permite que sean localizados por sus atributos (es un servicio de directorio). Su base de datos contiene una relación de tipos de servicio y sus atributos asociados con referencias a objetos remotos de objetos CORBA. Este tipo del servicio es un nombre, y cada atributo es un par nombre-valor. Los clientes hacen consultas especificando restricciones sobre los valores de los atributos, y sus preferencias del orden en que quieren recibir las ofertas concordantes. Los servidores de comercio pueden formar federaciones en las que no sólo emplean sus propias bases de datos sino que también realizan consultas en representación del cliente de alguna otra. Para una descripción detallada del Servicio de Comercio, véase Henning y Vinoski [1999].

Servicio de Transacciones y Servicio de Control de Concurrencia: el Servicio de Transacción de Objetos (*Object Transaction Service*) permite que los objetos distribuidos CORBA participen en transacciones tanto sencillas como anidadas. El cliente especifica una transacción como una secuencia de llamadas RMI, que comienzan por *begin* (comenzar) y terminan por *commit* (consumir) o *rollback* (abortar, retractar). El ORB adhiere un identificador de transacción a



```

struct NameComponent { string id; string clase; };
typedef sequence <NameComponent> Name;
interface NamingContext {
    void bind(in Name n, in Object obj);
        enlaza el nombre dado y la referencia al objeto remoto en mi contexto.
    void unbind(in Name n);
        elimina un enlace existente con el nombre dado.
    void bind_new_context(in Name n);
        crea un nuevo contexto de nominación y lo enlaza con un nombre dado en mi contexto.
    Object resolve(in Name n);
        busca el nombre en mi contexto y devuelve su referencia a objeto remoto.
    void list(in unsigned long cuantos, out BindingList le, out BindingIterator ie);
        devuelve los nombres de los enlaces en mi contexto.
};

```

Figura 17.10. Parte de la interfaz IDL *NamingContext* del Servicio de Nombres de CORBA.

asociar un nombre tanto con una referencia a un objeto para un objeto CORBA en una aplicación como con otro contexto en el servicio de nombres. Los contextos pueden estar anidados para proporcionar un espacio de nombres jerárquico, como se muestra en la Figura 17.9, en la que se muestran los objetos CORBA al modo habitual, y los contextos de nominación como óvalos sencillos. El grafo de la izquierda muestra una entrada para el objeto *ListaForma* que se describió en el ejemplo de programación de la Sección 17.2.1.

Un *contexto inicial de nominación* proporciona una raíz para un conjunto de enlaces. Observe que más de un contexto inicial de nominación podrá apuntar sobre el mismo grafo. En la práctica, cada instancia de un ORB tiene un único contexto inicial de nominación, pero los servidores de nombres asociados con diferentes ORB pueden formar federaciones, como se describirá más tarde en esta sección. Los programas cliente y servidor solicitan el contexto inicial de nominación desde el ORB, como se muestra en la Figura 17.5, invocando su método *resolve_initial_references*, dándole «*NameService*» como argumento. El ORB devuelve una referencia a un objeto del tipo *NamingContext* (véase la Figura 17.10). Éste se refiere al contexto inicial del servidor de nombres para ese ORB. Dado que puede haber varios contextos iniciales, los objetos no tienen nombres absolutos: los nombres siempre se interpretan con respecto a un contexto inicial de nominación.

Se puede resolver cualquier nombre con uno o más componentes, comenzando en cualquier contexto de nominación. Para resolver un nombre con varios componentes, el servicio de nombres busca en el contexto de arranque por un enlace que concuerde con el primer componente. Si tal enlace existe, será bien una referencia a un objeto remoto o una referencia a otro contexto de nominación. Si el resultado es un contexto de nominación, se resuelve el segundo nombre en ese contexto. El procedimiento se repite hasta que se hayan resuelto todos los componentes del nombre y se obtenga una referencia a un objeto remoto, a menos que falle la concordancia por el camino.

Los nombres que emplea el Servicio de Nombres de CORBA son del tipo *NameComponent*, y constan de dos cadenas, una para el *nombre* y otra para la *clase* del objeto. El campo *clase* proporciona un solo atributo cuyo uso se previó para las aplicaciones y puede contener cualquier información descriptiva de utilidad; no es interpretado por el Servicio de Nombres.

A pesar de que a los objetos CORBA se les dan nombres jerárquicos por parte del Servicio de Nombres, estos nombres no pueden expresarse como rutas similares a las de los archivos en UNIX. Así, en la Figura 17.9, no podemos hacer referencia al objeto del extremo de la derecha como */V/T*. Esto es así porque los nombres pueden contener cualquier carácter, lo que elimina la posibilidad de contar con un delimitador.

contextos en su espacio de nombres si proveen servidores de nombres remotos con referencias remotas a ellos.

La implementación Java del Servicio de Nombres de CORBA es muy simple y se la denomina transitoria porque almacena todos sus enlaces en memoria volátil. Cualquier implementación sería debería, al menos, conservar en archivos copias de sus grafos de nominación. Tal y como hemos visto en el estudio de DNS, se puede proporcionar replicación para proporcionar una mejor disponibilidad.

17.3.2. SERVICIO DE EVENTOS DE CORBA

La especificación del Servicio de Eventos de CORBA define interfaces que permiten a los objetos de interés, denominados *proveedores (supplier)*, comunicar notificaciones a sus subscriptores, llamados *consumidores (consumer)*. Las notificaciones se comunican como argumentos o resultados de invocaciones síncronas ordinarias de métodos remotos CORBA. Las notificaciones pueden propagarse tanto *impulsadas (push)* por el proveedor hacia el consumidor como *extraídas (pull)* por parte del consumidor desde el proveedor. En el primer caso, el consumidor implementa la interfaz *PushConsumer* que incluye un método *push* que toma cualquier tipo de dato CORBA como argumento. Los consumidores registran sus referencias a objetos remotos con los proveedores. Los proveedores invocan el método *push*, pasando una notificación como argumento. En el segundo caso, el proveedor implementa la interfaz *PullSupplier*, que incluye un método *pull* que recibe cualquier tipo de dato CORBA como valor de retorno. Los proveedores registran sus referencias a objetos remotos frente a los consumidores. Los consumidores invocan el método *pull* y reciben como resultado una notificación.

La notificación en sí misma se transmite como un argumento o resultado cuyo tipo es *any*, que indica que los objetos que intercambian notificaciones deben haberse puesto de acuerdo sobre los contenidos de las notificaciones. Los programadores de aplicaciones, sin embargo, podrán definir sus propias interfaces IDL con notificaciones de cualquier tipo deseado.

Los *canales de eventos* son objetos CORBA que pueden emplearse para permitir que múltiples proveedores se comuniquen con múltiples consumidores de modo asíncrono. Un canal de eventos actúa como un búfer entre los proveedores y los consumidores. También puede multidifundir las notificaciones a los consumidores. La comunicación vía canal de eventos podrá ser mediante impulsión o mediante extracción. Es posible mezclar ambos estilos; por ejemplo, los proveedores podrán impulsar notificaciones hacia el canal y los consumidores podrán extraer notificaciones de él.

Cuando una aplicación distribuida necesita emplear notificaciones asíncronas, crea un canal de eventos, que es un objeto CORBA cuya referencia a objeto remoto podrá ser aportada a los componentes de la aplicación a través del Servicio de Nombres o mediante un RMI. Los procesos proveedores en la aplicación ofrecen ellos mismos las suscripciones obteniendo *los proxy de consumidor* desde el canal de eventos y conectando los proveedores a ellos pasándoles sus referencias a objetos remotos. Los procesos consumidores de la aplicación se suscriben a las notificaciones obteniendo *los proxy de proveedor* del canal de notificación y conectando los consumidores a ellos. Los proxy de proveedor y consumidor se encuentran disponibles tanto en el estilo de impulsión como en el de extracción. Cuando un proveedor genera una notificación usando el estilo de interacción por impulsión, llama al método *push* del proxy de un consumidor por impulsión. La notificación pasa a través del canal y se entrega a los proxy de los consumidores, que las pasa a los consumidores, como se indica en la Figura 17.11. Si los consumidores emplean el estilo de interacción por extracción, llamarán al método *pull* del proxy de un proveedor por extracción.

La presencia de proxy de proveedores y proxy de consumidores hace posible construir cadenas de canales de eventos en las que cada canal suministra notificaciones que serán consumidas por el



Figura 17.11. Canales de eventos en CORBA.

siguiente canal. Los canales de eventos en el modelo CORBA son similares a los observadores definidos en la Figura 5.10. Éstos pueden programarse para llevar a cabo algunos de los papeles de los observadores que se discutieron en la Sección 5.4. Sin embargo, las notificaciones no conllevan forma alguna de identificadores, y así los patrones de reconocimiento o de filtrado de notificaciones deberán basarse en la información de tipo puesta en las notificaciones por la aplicación.

En Farley [1998] se proporciona una explicación más detallada del Servicio de Eventos de CORBA y un bosquejo de sus interfaces principales. La especificación completa del Servicio de Eventos de CORBA está en [OMG 1997c]. A pesar de ello, la especificación no muestra cómo crear un canal de eventos ni cómo solicitar la fiabilidad que se requiere de él.

17.3.3. SERVICIO DE NOTIFICACIÓN DE CORBA

El Servicio de Notificación de CORBA [OMG 1998c] extiende el Servicio de Eventos de CORBA, conservando todas sus características, incluyendo canales de eventos, consumidores de eventos y proveedores de eventos. El servicio de eventos no proporciona ningún soporte para el filtrado de eventos o para especificar requisitos de reparto. Sin el uso de filtros, todos los consumidores conectados a un canal tendrán que recibir las mismas notificaciones que cualquier otro. Y sin la posibilidad de especificar requisitos de reparto, todas las notificaciones que se envíen a través de este canal tendrán las garantías de reparto incluidas en la implementación.

El servicio de notificación añade las siguientes nuevas funciones:

- Las notificaciones se pueden definir como estructuras de datos. Esto es una mejora de la utilidad limitada que proporcionaban las notificaciones en el servicio de eventos, cuyo tipo sólo podía ser *any* o un tipo especificado por el programador de la aplicación.
- Los consumidores de eventos pueden usar filtros que especifican exactamente en qué eventos están interesados. Los filtros pueden adherirse a cada proxy de un canal. Cada proxy dirigirá las notificaciones a los consumidores de eventos según las restricciones especificadas en los filtros, en términos de los contenidos de cada notificación.
- Los proveedores de eventos poseen mecanismos para descubrir en qué eventos están interesados los consumidores. Esto les permite generar sólo aquellos eventos que requieran los consumidores.
- Los consumidores de eventos pueden descubrir los tipos de eventos que ofrecen los proveedores en un canal, lo que les permite suscribirse a nuevos eventos según se hagan disponibles.
- Es posible configurar las propiedades de un canal, un proxy o un evento particular. Estas propiedades incluyen la confiabilidad del reparto de eventos, la prioridad de los eventos, el ordenamiento requerido (por ejemplo, FIFO o por prioridad) y la política para descartar eventos almacenados.
- Como extra adicional se da un repositorio de tipos de eventos. Proporciona acceso a la estructura de eventos, lo que le hace conveniente para definir restricciones de filtrado.

El tipo Evento Estructura presentado por el servicio de notificación proporciona una estructura de datos en la que encajan una gran variedad de tipos de notificación diferentes. Se pueden definir filtros en términos de las componentes de un tipo de Evento Estructurado. Un evento estructurado consta de una cabecera de evento y un cuerpo de evento. La cabecera contiene:

Tipo de dominio	Tipo de evento	Nombre de evento	Requisito
«casa»	«alarma antirrobo»	«21 marzo, 2 pm»	«prioridad», 1.000

El tipo de dominio se refiere al dominio de definición (por ejemplo, «finanzas», «hotel» u «hogar»). El tipo de evento categoriza el tipo del evento de modo único dentro del dominio (por ejemplo, «cotización stock», «hora desayuno», «alarma antirrobo»). El nombre de evento identifica de modo único la instancia específica del evento que está siendo transmitido. El resto de la cabecera contiene una lista de pares <nombre, valor>, proyectadas para ser usadas al especificar la fiabilidad y otros requisitos sobre el reparto de eventos.

El cuerpo de un evento estructurado contiene la siguiente información:

Parte filtrable			
Nombre, valor	Nombre, valor	Nombre, valor	Resto
«campana», «sonando»	«puerta», «abierta»	«gato», «fuera»	

La primera parte del cuerpo del evento contiene una secuencia de pares <nombre, valor> proyectadas para su uso por los filtros. Se espera que diferentes áreas de la industria definan estándares para los pares <nombre, valor> que se usan en la parte filtrable del cuerpo del evento; al definir los filtros se emplearán los mismos nombres y valores. Quizás cuando la alarma antirrobo se apague, el evento pueda incluir el estado de la campana de alarma, si la puerta principal está abierta y la situación del gato. El resto del cuerpo del evento está propuesto para transmitir datos referentes a un evento particular; por ejemplo, cuando la alarma antirrobo se apague, pudiera contener una fotografía digital del interior de las estancias.

Los objetos filtro se emplean desde los proxy para realizar decisiones sobre si encaminar o no cada notificación. Un filtro se diseña como una colección de restricciones, cada una de las cuales es una estructura con dos componentes:

- Una lista de estructuras de datos, cada una de las cuales indica un tipo de evento en términos de su nombre de dominio y tipo de evento, por ejemplo «hogar», «alarma antirrobo». La lista incluye todos los tipos de eventos a los que se pueda aplicar la restricción.
- Una cadena de texto que contiene una expresión booleana que incluye los tipos de eventos listados anteriormente. Por ejemplo:

```
(«domain type» == «hogar» && «event type» == «alarma antirrobo») &&
(«campana» != «sonando» !! «puerta» == «abierta»)
```

Nuestro ejemplo emplea una sintaxis informal. La especificación del servicio de notificación incluye la definición de un lenguaje de restricciones, que es una extensión del lenguaje de restricciones empleado por el Servicio de Comercio.

17.3.4. SERVICIO DE SEGURIDAD DE CORBA

17.3.4. SERVICIO DE SEGURIDAD DE CORBA

- pales (esto es, certificados confirmando sus derechos); la delegación de credenciales está soportada en los términos de la Sección 7.2.5.
- Se puede aplicar control de acceso a los objetos CORBA cuando reciben invocaciones remotas. Los derechos de acceso se pueden especificar, por ejemplo, mediante listas de control de acceso (ACL).
 - Auditoría de las invocaciones a métodos remotos por parte de los servidores.
 - Medios para el no repudio. Cuando un objeto lleva a cabo una invocación remota en nombre

17.4. RESUMEN

El principal componente de CORBA es el Intermediario de Peticiones de Objetos (*Object Request Broker*) u ORB, que permite que clientes escritos en un lenguaje invoquen operaciones de objetos remotos (denominados objetos CORBA) escritos en otro lenguaje. CORBA trata otros aspectos de la heterogeneidad como sigue:

- El protocolo General Inter-ORB (GIOP) de CORBA incluye una representación externa de datos llamada CDR, que hace posible que los clientes y los servidores se comuniquen independientemente de su hardware. También especifica una forma estándar para las referencias a objetos remotos.
- GIOP también incluye una especificación para las operaciones de un protocolo petición-respuesta que pueda ser usado independientemente del sistema operativo subyacente.
- El protocolo Internet Inter-ORB (IIOP) implementa el protocolo petición-respuesta sobre TCP/IP. Las referencia a objetos remotos IIOP incluyen el nombre de dominio y el número de puerto de un servidor.

Un objeto CORBA implementa las operaciones de una interfaz IDL. Todo lo que los clientes necesitan saber para acceder a un objeto CORBA es el conjunto de operaciones disponible en su interfaz. El programa cliente accede a los objetos CORBA vía proxy o resguardo, que se generan automáticamente desde sus interfaces IDL hacia el lenguaje del cliente. Los esqueletos del servidor para los objetos CORBA se generan automáticamente desde sus interfaces IDL hacia el lenguaje del servidor. El adaptador de objeto es un componente importante de los servidores CORBA. Su papel es crear referencias a objetos remotos y relacionar referencias a objetos remotos de los mensajes de petición con las implementaciones de los objetos CORBA.

La arquitectura de CORBA permite activar los objetos CORBA bajo demanda. Esto se logra mediante un componente denominado repositorio de implementación, que aloja una base de datos de las implementaciones indexadas por sus nombres de adaptadores de objeto. Cuando un cliente invoca un objeto CORBA, puede activarse si fuera necesario para llevar a cabo la invocación. Un repositorio de interfaz es una base de datos de definiciones de interfaces IDL indexada por un ID de repositorio, que está incluida en un IOR. Se puede utilizar un repositorio de interfaz para obtener información sobre los métodos de la interfaz de un objeto CORBA para permitir la invocación dinámica de métodos.

Los servicios CORBA proporcionan funcionalidades sobre RMI, que pudieran necesitarse en las aplicaciones distribuidas, permitiéndolas utilizar servicios adicionales como servicios de nombres y de directorio, notificaciones de eventos, transacciones o seguridad según se deseé.

EJERCICIOS

- 17.1. La Bolsa de Tareas es un objeto que almacena pares de clave, valor. Una clave es una cadena de texto y un valor es una secuencia de bytes. Su interfaz proporciona los siguientes métodos remotos:

parSalida: con dos parámetros con los que el cliente especifica que se almacene una clave y un valor.

parEntrada: cuyo primer parámetro permite que el cliente especifique una *clave* de un par que se eliminará de la Bolsa de Tareas. El *valor* del par se devuelve al cliente vía un segundo parámetro. Si no existe el par correspondiente, se lanza una excepción.

leePar: es lo mismo que *parEntrada* excepto que el par permanece en la Bolsa de Tareas.

Utilice CORBA IDL para definir la interfaz de la Bolsa de Tareas. Defina una excepción

reas.

Utilice CORBA IDL para definir la interfaz de la Bolsa de Tareas. Defina una excepción que pueda lanzarse cuando no pueda llevarse a cabo cualquiera de las operaciones. Su excepción debe indicar el número del problema y una cadena de

- 17.13. Discuta las funciones del repositorio de implementación desde el punto de vista de la escalabilidad y la tolerancia a fallos.
- 17.14. ¿Hasta qué punto se pueden migrar objetos CORBA de un servidor a otro?
- 17.15. Discuta los beneficios y desventajas de los nombres bipartitos o *NameComponent* en el Servicio de Nombres de CORBA.
- 17.16. Dé un algoritmo que describa cómo se resuelve un nombre multiparte en el Servicio de Nombres de CORBA. Un programa cliente necesita resolver un nombre multiparte con componentes «A», «B» y «C», relativos a un contexto inicial de nominación. ¿Cómo se especificarían los argumentos para la operación *resolve* en el servicio de nombres?
- 17.17. Una empresa virtual consta de un conjunto de compañías que cooperan una con otra para sacar adelante un proyecto concreto. Cada compañía desea proporcionar a las otras compañías acceso sólo a los objetos CORBA relevantes al proyecto. Describa una forma apropiada de agrupar o federar sus Servicios de Nombres de CORBA.
- 17.18. Discuta cómo utilizar proveedores y consumidores conectados directamente a un Servicio de Eventos de CORBA en el contexto de una aplicación de tablero compartido. Las interfaces *PushConsumer* y *PushSupplier* están definidas en IDL como sigue:

```
interface PushConsumer {
    void push(in any datos) raises (Disconnected);
    void disconnect_push_consumer();
}
interface PushSupplier {
    void disconnect_push_supplier();
}
```

Tanto el proveedor como el consumidor pueden decidir terminar la comunicación de eventos llamando a *disconnect_push_supplier()* o a *disconnect_push_consumer()* respectivamente.

- 17.19. Describa cómo interponer un Canal de Eventos entre el proveedor y los consumidores en su solución al Ejercicio 17.18. Un canal de eventos tiene la siguiente interfaz IDL:

```
interface EventChannel {
    consumerAdmin for_consumers();
    SupplierAdmin for_suppliers();
};
```

donde las interfaces *SupplierAdmin* y *ConsumerAdmin*, que permiten que el proveedor y el consumidor obtengan cada proxy se definen en IDL como sigue:

```
interface SupplierAdmin {
    ProxyPushConsumer obtain_push_consumer();
    ...
};
interface ConsumerAdmin {
    ProxyPushSupplier obtain_push_supplier();
    ...
};
```

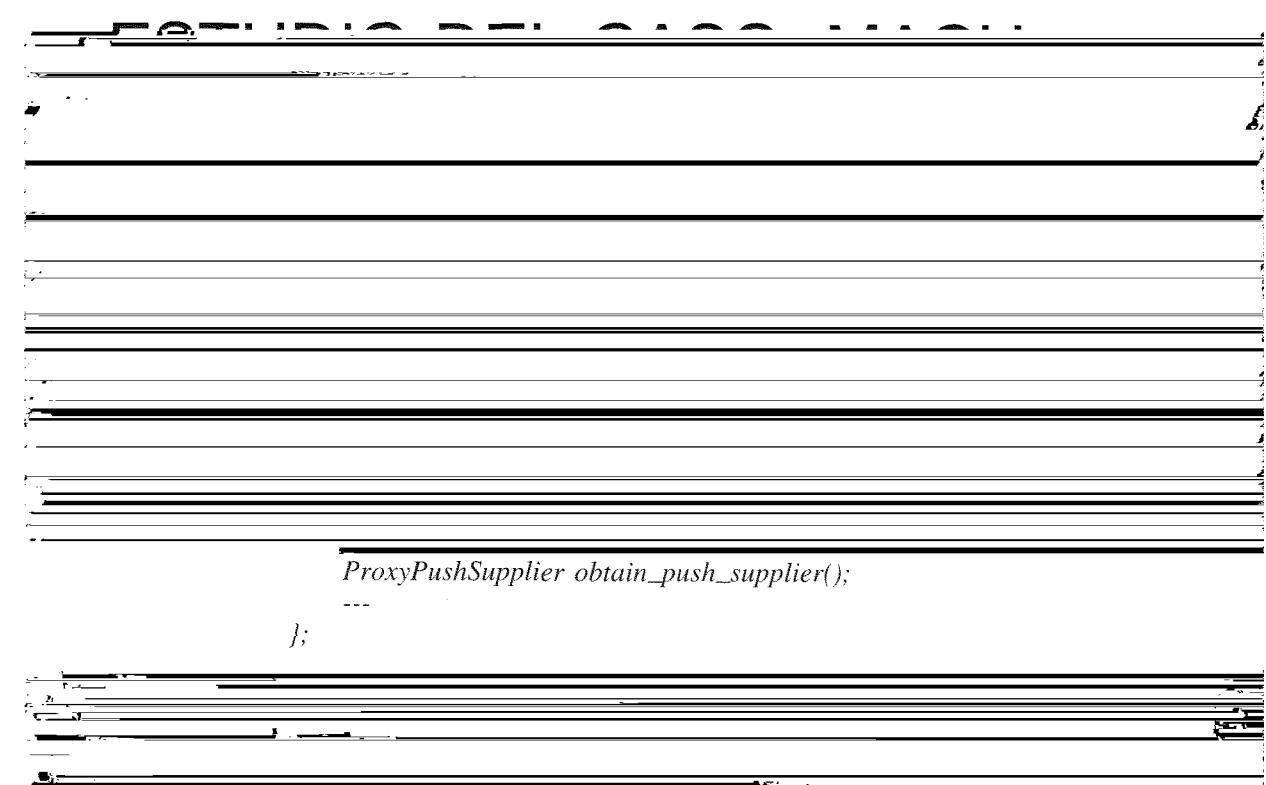
La interfaz para el proxy del consumidor y el proxy del proveedor se definen en IDL como sigue:

```
interface ProxyPushConsumer : PushConsumer{
    void connect_push_supplier(in PushSupplier proveedor)
        raises (AlreadyConnected);
};

interface ProxyPushSupplier : PushSupplier{
    void connect_push_consumer(in PushConsumer consumidor)
        raises (AlreadyConnected);
};
```

¿Cuál es la ventaja de usar el canal de eventos?

18



18.1. INTRODUCCIÓN

El proyecto Mach [Acetta y otros 1986, Loepere 1991, Boykin y otros 1993] estaba asentado en la Universidad Carnegie-Mellon en USA hasta 1994. Allí continuó su desarrollo hacia un núcleo en tiempo real [Lee y otros 1996], y su desarrollo fue continuado por grupos de la Universidad de Utah y la Fundación para el Software Abierto (*Open Software Foundation*, OSF). El proyecto Mach fue el sucesor de otros dos proyectos, RIG [Rashid 1986] y Accent [Rashid y Robertson 1981, Rashid 1985, Fitzgerald y Rashid 1986]. RIG fue desarrollado en la Universidad de Rochester en la década de los años setenta, y Accent fue desarrollado en Carnegie-Mellon durante la primera mitad de la década de los años ochenta. A diferencia de sus predecesores, RIG y Accent, el proyecto Mach nunca tuvo como objetivo el desarrollo de un sistema operativo distribuido completo. En vez de esto, el núcleo Mach se desarrolló para proporcionar una compatibilidad directa con UNIX BSD. Fue diseñado para proporcionar recursos avanzados que complementaran los de UNIX y que permitiera a una implementación UNIX proliferar sobre una red de multiprocesadores y computadores monoprocesador. Desde el principio, la intención de los diseñadores fue la de implementar la mayor parte de UNIX mediante procesos de nivel de usuario.

A pesar de estas intenciones, la versión 2.5 de Mach, la primera de las dos principales versiones, incluía todo el código de compatibilidad con UNIX dentro del propio núcleo. Se ejecutaba, entre otros computadores, en SUN-3, IBM RT PC, sistemas uniprocesadores y multiprocesadores VAX y en los multiprocesadores Encore Multimax y Sequent. Desde 1989, Mach 2.5 fue incorporado como la tecnología base para OSF/1, el rival propuesto por la Fundación para el Software Abierto para competir contra System V Release 4 como versión estándar de UNIX para la industria. Una versión más antigua de Mach se utilizó como base para el sistema operativo de la estación de trabajo NeXT.

A partir de la versión 3.0 del núcleo Mach se eliminó el código UNIX, con todo, ésta es la versión que estudiaremos. Más recientemente, Mach 3.0 es la base de la implementación de MkLinux, una variante del sistema operativo Linux para computadores Power Macintosh [Morin 1997]. La versión 3.0 del núcleo Mach también se ejecuta en PCs basados en Intel x86. Funcionaba en las series de computadores DECstation 3100 y 5000, algunos computadores basados en el Motorola 88000 y SUN SPARCStations; se emprendieron versiones para IBM RS6000, la Arquitectura de Precisión (*Precision Architecture*, PA) de Hewlett-Packard y Alpha de Digital Equipment Corporation.

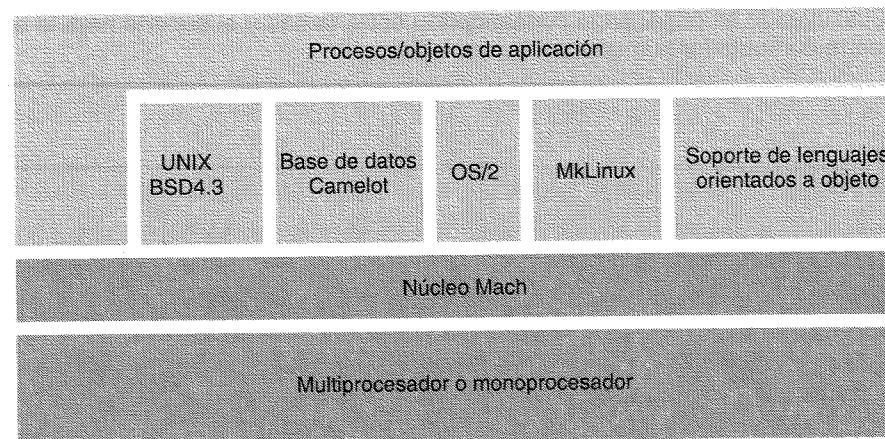


Figura 18.1. Mach proporciona soporte a sistemas operativos, bases de datos y otros subsistemas.

La versión 3.0 de Mach se utiliza como soporte para la construcción de emulaciones de sistemas operativos, sistemas de base de datos, sistemas de soporte de lenguajes en tiempo de ejecución y otros tipos de software de sistema que llamaremos subsistemas (véase la Figura 18.1).

La emulación de sistemas operativos convencionales permite ejecutar binarios ya existentes desarrollados para ellos. Además se pueden desarrollar nuevas aplicaciones para dichos sistemas operativos convencionales. Al mismo tiempo, se puede desarrollar middleware y aplicaciones que aprovechen las ventajas de la distribución; y se pueden crear versiones distribuidas de las implementaciones de los sistemas operativos convencionales. Surgen dos cuestiones importantes en la emulación de los sistemas operativos. La primera es que las emulaciones distribuidas no pueden ser completamente exactas debido a los nuevos modos de fallo que aparecen con la distribución. La segunda, es la cuestión todavía sin resolver de si se pueden conseguir niveles de prestaciones aceptables para que su utilización sea generalizada.

18.1.1. OBJETIVOS Y PRINCIPALES CARACTERÍSTICAS DEL DISEÑO

Los principales objetivos y características de diseño de Mach son los siguientes:

Operación multiprocesador: Mach fue diseñado para ejecutarse en un multiprocesador de memoria compartida de forma que tanto los hilos del núcleo como los hilos en modo usuario pueden ejecutarse en cualquier procesador. Mach proporciona un modelo multi-hilo para procesos de usuario, con entornos de ejecución llamados *tareas*. Para permitir la ejecución paralela en un multiprocesador de memoria compartida, la planificación de los hilos es prioritaria, o apropiativa, tanto si pertenecen a las mismas como a diferentes tareas.

Extensión transparente para operar en red: para permitir que los programas distribuidos se extiendan de forma transparente sobre mono y multiprocesadores en una red, Mach ha adoptado un modelo de comunicación independiente de la ubicación usando puertos como destino de la comunicación. Sin embargo, el núcleo de Mach ha sido diseñado para ser 100 % independiente de redes concretas. El diseño de Mach confía en procesos servidores de red de nivel de usuario para el envío de mensajes de forma transparente sobre la red (véase la Figura 18.2). Se trata de una decisión de diseño polémica dados los costes del cambio de contexto, que examinamos en el Capítulo 6. Sin embargo, permite una absoluta flexibilidad en el control de la política de comunicación de la red.

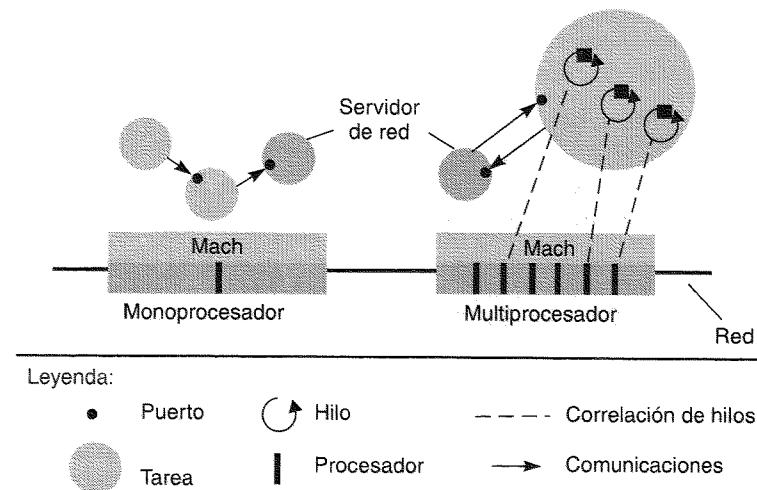


Figura 18.2. Tareas, hilos y comunicación en Mach.

Servidores de nivel de usuario: Mach implementa un modelo basado en objetos en el que los recursos se gestionan o bien por el núcleo, o bien mediante servidores cargados dinámicamente. Inicialmente sólo se permitían servidores de nivel de usuario, pero posteriormente se adaptó Mach para acomodar servidores en el espacio de direcciones del núcleo. Tal y como ya hemos mencionado, un objetivo primordial fue el de implementar la mayor parte de los recursos de UNIX desde el nivel de usuario, a la vez que se proporcionaba compatibilidad binaria con sistemas UNIX existentes. Con la excepción de algunos recursos gestionados por el núcleo, los recursos son accedidos de forma uniforme mediante paso de mensajes, independientemente de cómo sean gestionados. A cada recurso le corresponde un puerto gestionado por un servidor. El Generador de Interfaz de Mach (*Mach Interface Generator*, MiG) se desarrolló para generar enlaces RPC utilizados para ocultar los accesos basados en mensajes del nivel de lenguaje [Draves y otros 1989].

Emulación de sistema operativo: para dar soporte a la emulación de nivel de usuario de UNIX y otros sistemas operativos, Mach permite la redirección transparente de las llamadas al sistema operativo sobre llamadas a una biblioteca de emulación y de ahí hacia los servidores del sistema operativo del nivel de usuario; a esta técnica se le conoce como *trampolining*. También se incluye la posibilidad de permitir que las excepciones del tipo de violaciones del espacio de direcciones que ocurren en las tareas de aplicación sean gestionadas por servidores. En www.cdk3.net/oss se pueden encontrar los casos de estudio de emulaciones UNIX bajo Mach y Chorus.

Implementación de memoria virtual flexible: se realizó un gran esfuerzo en la mejora de la memoria virtual para dotar a Mach de la posibilidad de emular sistemas UNIX y dar soporte a otros subsistemas. Para ello se realizó una aproximación flexible a la distribución del espacio de direcciones de un proceso. Mach soporta un espacio de direcciones grande y disperso, con capacidad potencial para contener múltiples regiones. Por ejemplo, tanto los mensajes como los archivos abiertos pueden aparecer como regiones de memoria virtual. Las regiones pueden ser privadas a una tarea, compartidas entre tareas o copiadas desde regiones sobre otras tareas. El diseño incluye el uso de técnicas de correlación de memoria, principalmente la *copia en escritura*, para evitar la copia de datos cuando, por ejemplo, se pasan mensajes entre tareas. Finalmente, Mach se diseñó para permitir que fueran los servidores, en lugar del propio núcleo, los que implementaran el almacenamiento secundario para las páginas de memoria virtual. Las regiones pueden correlacionarse con datos gestionados por los servidores llamados *paginadores externos*. Estos datos correlacionados (*mapped*) pueden residir en cualquier abstracción de un recurso de memoria, desde memoria compartida distribuida hasta archivos.

Portabilidad: Mach fue diseñado para ser portable sobre varias plataformas hardware. Por esta razón, se trató de aislar, tanto como fue posible, el código dependiente de la máquina. Por ejemplo, el código de memoria virtual fue dividido en una parte dependiente de la máquina y otra independiente de la máquina [Rashid y otros 1988].

18.1.2. REPASO DE LAS PRINCIPALES ABSTRACCIONES DE MACH

Se pueden resumir las diferentes abstracciones proporcionadas por el núcleo de Mach de la siguiente forma (todas ellas serán descritas en detalle posteriormente en este capítulo):

Tareas: una tarea en Mach es un entorno de ejecución. Básicamente está compuesto por un espacio de direcciones protegido y una colección de habilitaciones *gestionadas por el núcleo* que se utilizan para el acceso a los puertos.

Hilos: las tareas pueden contener múltiples hilos. Los hilos que pertenecen a una misma tarea se pueden ejecutar en paralelo sobre diferentes procesadores en un multiprocesador de memoria compartida.

Puertos: un puerto en Mach es un canal de comunicaciones *uno a uno* y unidireccional con una cola de mensajes asociada. Los puertos no son accesibles directamente por el programador de Mach y tampoco forman parte de una tarea. En su lugar, el programador dispone de apuntadores a *derechos de puerto*. Se trata de habilitaciones para el envío de mensajes a un puerto o para la recepción de mensajes desde un puerto.

Conjuntos de puertos: un conjunto de puertos es una colección de derechos de recepción de puertos, locales a una cierta tarea. Se utilizan para recibir mensajes desde cualquier puerto de entre una colección de ellos. Los conjuntos de puertos no deben confundirse con los *grupos de puertos*; estos últimos son destinos de multidifusión y en Mach no están implementados.

Mensajes: un mensaje en Mach puede contener derechos de puerto además de datos. El núcleo utiliza técnicas de gestión de memoria para transferir de forma eficiente los datos de los mensajes entre las tareas.

Dispositivos: ciertos servidores como los servidores de archivos que se ejecutan a nivel de usuario deben poder acceder a los dispositivos. Para ello el núcleo exporta una interfaz de bajo nivel sobre los dispositivos.

Objeto de memoria: cada región del espacio de direcciones virtuales de una tarea Mach se corresponde con un objeto de memoria. Se trata de un objeto que normalmente está implementado fuera del propio núcleo pero que es accedido por éste cuando realiza operaciones de paginación en la gestión de la memoria virtual. Un objeto de memoria es una instancia de un tipo abstracto de datos que incluye operaciones de búsqueda y almacenamiento de datos que se emplean cuando los hilos generan faltas de página en el intento de hacer referencia a direcciones en la región correspondiente.

Objeto de memoria caché: para cada objeto correlacionado en memoria existe un objeto gestionado por el núcleo que contiene una caché de páginas residentes en la memoria principal para la correspondiente región. A esto se le llama objeto de memoria caché. Da soporte a las operaciones necesarias para el paginador externo encargado de implementar el objeto de memoria.

Estudiaremos a continuación las principales abstracciones. La abstracción de dispositivo se omite en interés de la brevedad.

18.2. PUERTOS, NOMBRES Y PROTECCIÓN

Mach asocia recursos individuales con puertos. Para acceder a un recurso se envía un mensaje sobre el puerto correspondiente. En Mach, se presupone que los servidores manejarán, por lo general, múltiples puertos: uno por cada recurso. Un único servidor UNIX utiliza alrededor de 2.000 puertos [Draves 1990]. Por lo tanto la creación y gestión de estos puertos debe ser barata.

El problema de la protección de un recurso frente a accesos ilegales se equipara al de la protección del correspondiente puerto frente a envíos ilegales. En Mach esto se consigue mediante el control que realiza el núcleo sobre la adquisición de habilitaciones para el puerto y también por el control de los mensajes realizado por el servidor de red.

La habilitación de un puerto tiene un campo que especifica los derechos de acceso sobre el puerto pertenecientes a la tarea que lo posee. Existen tres tipos diferentes de derechos de puerto. Los *derechos de envío* permiten a los hilos dentro de la tarea que los posee el envío de mensajes al

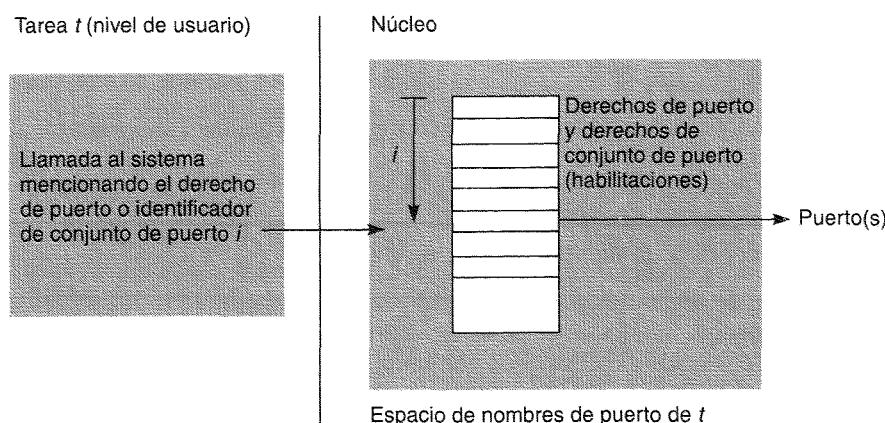


Figura 18.3. Un espacio de nombres de puerto de una tarea.

puerto correspondiente. Una forma más restringida son los *derechos de un solo envío*, que permiten el envío de tan sólo un mensaje, después de lo cual los derechos son destruidos automáticamente por el núcleo. Esta forma restringida permite, por ejemplo, que un cliente obtenga una respuesta desde un servidor sabiendo que el servidor no le enviará más mensajes (y por lo tanto protegiéndole de servidores erróneos); además, se libera al servidor de la tarea de eliminar los derechos de envío recibidos desde los clientes. Finalmente los *derechos de recepción* permiten a los hilos de una tarea recibir mensajes desde la cola de mensajes del puerto. En cada momento sólo una tarea puede poseer los derechos de recepción, mientras que un número variable de tareas pueden poseer los derechos de envío o de *un solo envío*. Mach soporta sólo la comunicación *muchos a uno*: la multidifusión no aparece implementada directamente en el núcleo.

En el momento de su creación a cada tarea se la proporciona un *derecho de puerto de inicio*, que es un derecho de envío que sirve para obtener servicios de otras tareas. Una vez creada, los hilos pertenecientes a la tarea adquieren más derechos de puerto ya sea mediante su creación o mediante su recepción a través de mensajes.

Los derechos de puerto de Mach se almacenan en el núcleo y son protegidos por él (véase la Figura 18.3). Las tareas nombran los derechos de puerto mediante identificadores locales válidos únicamente en el *espacio de nombres de puerto* local a la tarea. Esto permite al equipo de desarrollo del núcleo elegir representaciones eficientes para estas habilitaciones (tales como punteros a colas de mensajes) y elegir nombres locales de tipo entero a conveniencia del núcleo para permitir búsquedas fácilmente la habilitación dado el nombre. De hecho, análogamente a los descriptores de archivo de UNIX, los identificadores locales son enteros utilizados para indexar una tabla del núcleo que contiene las habilitaciones de la tarea.

El esquema de nombres y protección de Mach permite un acceso rápido a las colas de mensajes locales dado un identificador de usuario. Como contrapartida a esta ventaja está el gasto realizado por el núcleo al procesar todos los derechos transmitidos en los mensajes entre tareas. Como mínimo, los derechos de envío deben tener asociado un nombre local en el espacio de nombres de la tarea receptora, junto con espacio en sus tablas del núcleo. Hay que resaltar que, en un entorno seguro, la transmisión de derechos de puerto a través de los servidores de red requiere su encriptación como media de protección frente a ataques de seguridad como las escuchas no autorizadas [Sansom y otros 1986].

18.3. TAREAS E HILOS

Una tarea es un entorno de ejecución: las propias tareas no pueden realizar ninguna acción; únicamente lo pueden realizar sus hilos. Sin embargo, por comodidad, a veces nos referiremos a tareas realizando acciones cuando en realidad nos referimos a los hilos dentro de la tarea. Los principales recursos asociados directamente con una tarea son su espacio de direcciones, sus hilos, sus derechos de puerto, sus conjuntos de puertos y el espacio de nombres local en el que se buscan los derechos de puerto y los conjuntos de puertos. Examinaremos el mecanismo de creación de una tarea nueva y todo lo relacionado con la gestión de tareas y la ejecución de sus hilos.

◇ **Creación de una nueva tarea.** La operación *fork* de UNIX crea un nuevo proceso copiando uno ya existente. El modelo de creación de procesos de Mach es una generalización del de UNIX. Las tareas son creadas con referencia a lo que llamaremos *tarea tipo* (no necesariamente la creadora). La nueva tarea reside en el mismo computador que la tarea tipo. Al no proporcionar Mach la posibilidad de migración de tareas, la única forma de establecer una tarea sobre un computador remoto es a través de otra tarea que ya resida allí. El nuevo derecho de puerto de inicio de la tarea se hereda de la tarea tipo y su espacio de direcciones puede estar vacío o bien ser heredado de la misma forma (la herencia del espacio de direcciones se discute posteriormente en la subsección de memoria virtual de Mach). Una tarea recién creada no tiene hilos. En su lugar, el creador de la tarea solicita la creación de un hilo dentro de la tarea hijo. Posteriormente podrán crearse otros hilos a partir de los hilos existentes dentro de la tarea. En la Figura 18.4 aparecen algunas de las llamadas de Mach relacionadas con la creación de tareas e hilos.

◇ **Invocación de operaciones del núcleo.** Cuando se crea una tarea o hilo en Mach se le asigna un denominado *puerto del núcleo*. Las llamadas al sistema de Mach se dividen entre las implementadas directamente como trampas (*traps*) y las implementadas mediante paso de mensajes a los puertos del núcleo. Este último método tiene la ventaja de permitir operaciones con transparencia de red sobre tareas e hilos que pueden ser remotos o locales. Un servicio del núcleo gestiona recursos del núcleo de la misma forma en que un servidor de nivel de usuario maneja otros recursos. Cada tarea tiene derechos de envío sobre su puerto del núcleo, lo que la permite invocar operaciones por sí misma (como la creación de un nuevo hilo). Cada uno de los servicios del núcleo accedido mediante paso de mensajes tiene una definición de interfaz. Las tareas acceden a esos servicios mediante procedimientos de resguardo, los cuales se generan de sus definiciones de interfaz mediante el Generador de Interfaz de Mach.

`task_create(tarea_padre, hereda_memoria, hijo_tarea)`

tarea_padre es la tarea utilizada como tarea tipo en la creación, *hereda_memoria* especifica si el hijo debe heredar el espacio de direcciones de su padre o bien se le debe asignar un espacio de direcciones vacío, *tarea_hijo* es el identificador de la nueva tarea.

`thread_create(padre_tarea, hijo_hilo)`

tarea_padre es la tarea en la que se quiere crear el nuevo hilo, *hilo_hijo* es el identificador del nuevo hilo. El hilo creado no tiene estado de ejecución y está suspendido.

`thread_set_state(hilo, aroma, nuevo_estado, contador)`

hilo es el identificador del hilo al que se quiere proporcionar un estado de ejecución, *aroma* especifica la arquitectura de la máquina, *nuevo_estado* especifica el estado (el contador de programa y el puntero de pila, por ejemplo), *contador* es la talla del estado.

`thread_resume(hilo)`

Se utiliza para reanudar el hilo suspendido identificado por *hilo*.

Figura 18.4. Creación de tareas e hilos.

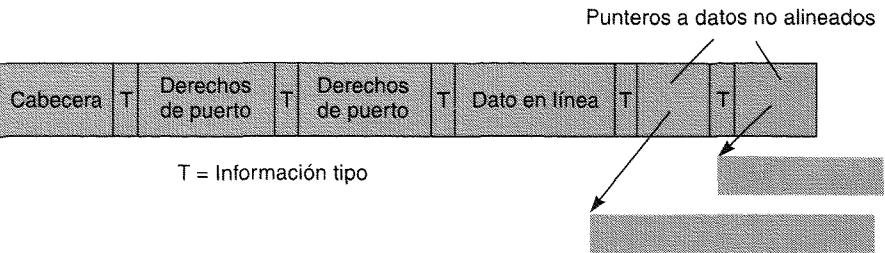


Figura 18.5. Un mensaje en Mach conteniendo derechos sobre puerto y datos no alineados.

Un identificador de operación: identifica una operación (procedimiento) en la interfaz de servicio que sólo puede ser interpretada por las aplicaciones.

Tamaño de los datos extra: a continuación de la cabecera aparece una lista de tamaño variable de datos tipados. No existe límite para su tamaño, excepto el número de bits del campo y el tamaño total del espacio de direcciones.

Cada ítem en la lista consecutiva a la cabecera del mensaje puede ser uno de los siguientes (pueden aparecer en cualquier orden dentro del mensaje):

Datos de mensaje tipado: individuales, datos en línea etiquetados con su tipo;

Derechos de puerto: referidos a sus identificadores locales;

Punteros a datos no alineados: datos que residen en un bloque de memoria separado y no contiguo.

Los mensajes en Mach están formados por una cabecera de tamaño fijo y múltiples bloques de datos de tamaño variable, algunos de los cuales pueden estar *no alineados* (es decir en bloques separados). Sin embargo, cuando se envían mensajes con datos no alineados, el núcleo (no la tarea receptora) escoge la ubicación de los datos recibidos en el espacio de direcciones de la tarea receptora. Se trata de un efecto colateral de la técnica de la *copia en escritura* utilizada para transferir estos datos. Las regiones de memoria virtual extra recibidas en un mensaje que no se vayan a usar más deben ser liberadas de forma explícita por la tarea receptora. Al ser los costes de las operaciones de memoria virtual superiores a los coste de la copia de datos para pequeñas cantidades de datos, se supone que sólo se envían de modo no alineado grandes cantidades de datos.

La ventaja de permitir múltiples componentes de datos en los mensajes consiste en que posibilita al programador la asignación de memoria de forma separada para los datos y para los metadatos. Por ejemplo, un servidor de archivos puede asignar bajo petición un bloque de disco desde su caché. En lugar de copiar el bloque en el búfer del mensaje, de forma contigua a la cabecera, los datos pueden ser tomados directamente desde donde residen mediante la inserción de un puntero en el mensaje de respuesta. Se trata de una variante de la *E/S de acopio disperso (scatter-gather I/O)*, en la que los datos son leídos o escritos desde múltiples ubicaciones del espacio de direcciones del invocador mediante una llamada al sistema. Las llamadas al sistema *readv* y *writev* de UNIX actúan de esta forma [Leffler y otros 1989].

El tipo de cada elemento de datos en un mensaje Mach es especificado por el emisor (medianamente, por ejemplo, ASN.1). Esto permite a los servidores de red de nivel de usuario empaquetar los datos con formato estándar, cuando se transmiten sobre la red. Sin embargo, este esquema de empaquetamiento tiene peores prestaciones en comparación con el empaquetamiento y desempaquetamiento realizado por los procedimientos de resguardo generados desde las definiciones de la interfaz. Los procedimientos de resguardo conocen los tipos de datos implicados, no necesitan in-

eluirlos en los mensajes y pueden empaquetarlos directamente en el mensaje (véase la Sección 18.4.2).

eluirlos en los mensajes y pueden empaquetarlos directamente en el mensaje (véase la Sección 18.4.2).

18.4.2. PUERTOS

Un puerto en Mach tiene una cola de mensajes cuyo tamaño puede ser cambiado dinámicamente por la tarea con los derechos de recepción. Esta posibilidad permite a los receptores implementar cierta forma de control de flujo. Cuando se utiliza un derecho de envío normal, un hilo que intente enviar un mensaje a un puerto cuya cola de mensajes esté llena se bloqueará hasta que haya espacio disponible. Cuando un hilo utiliza un derecho de *un solo envío*, el receptor siempre inserta en la cola el mensaje, aunque la cola de mensajes esté llena. Al utilizarse el derecho de *un solo envío*, se sabe que no habrá más mensajes desde dicho emisor. Los hilos del servidor pueden evitar la espera enviando derechos de *un solo envío* en sus respuestas a los clientes.

◇ **Envío de derechos de puerto.** Cuando los derechos de envío de un puerto se insertan en un mensaje, el receptor los adquiere sobre el mismo puerto. Sin embargo, cuando lo que se transmite son los derechos de recepción son desasignados automáticamente de la tarea que los emite. La

sobre un conjunto de puertos, el núcleo devuelve un mensaje que fue entregado a algún miembro del conjunto. También devuelve el identificador de los derechos de recepción del puerto para que el hilo pueda realizar el correspondiente tratamiento del mensaje.

Los conjuntos de puertos son útiles ya que normalmente un servidor debe proporcionar servicio a mensajes de clientes que llegan por todos los puertos y en cualquier instante. El intento de recibir un mensaje desde un puerto cuya cola de mensajes está vacía provoca la detención del hilo y esta espera se mantiene aunque desde otro puerto se reciba posteriormente un mensaje. La asignación de un hilo a cada puerto resuelve este problema pero no es factible para servidores con un número grande de puertos ya que los hilos son recursos más caros que los puertos. Mediante la asociación de puertos en conjuntos de puertos, puede utilizarse un único hilo para dar servicio a los mensajes entrantes sin temor a perder ninguno de ellos. Además este hilo se inmovilizará si no hay mensajes disponibles desde ningún puerto del conjunto, evitando esperas activas en las que el hilo sondea los puertos hasta que llega de un mensaje por alguno de ellos.

18.4.3. MACH_MSG

La llamada al sistema *Mach_msg* es extremadamente complicada ya que proporciona tanto servicios de paso de mensajes asíncrono como interacciones de tipo petición-respuesta. Únicamente proporcionaremos una breve descripción de su semántica. La llamada completa es como sigue:

mach_msg(cabecera_msg, opción, tam_envío, tam_recep, nombre_recep, timeout, notifica)

cabecera_msg es un puntero a una cabecera de mensajes común para los mensajes de envío y recepción, *opción* indica si es un envío, una recepción o ambos, *tam_envío* y *tam_recep* son los tamaños de los búferes de mensajes de envío y recepción, *nombre_recep* especifica los derechos de recepción del puerto o conjunto de puertos (si se recibe un mensaje), *timeout* pone un límite al tiempo total para el envío y/o recepción de un mensaje, *notifica* proporciona derechos de puerto que utiliza el núcleo para enviar mensajes de notificación bajo circunstancias excepcionales.

Mach_msg tanto envía un mensaje, como lo recibe o ambas cosas. Es una única llamada al sistema que utilizan los clientes para enviar un mensaje de petición y recibir una respuesta, y los servidores para responder al último cliente y recibir el siguiente mensaje de petición. Otro beneficio de la utilización de llamadas de envío/recepción combinadas es que para el caso de un cliente y servidor ejecutándose en el mismo computador la implementación puede utilizar una optimización llamada *planificación con traspaso*. Consiste en que cuando una tarea va a inmovilizarse una vez que ha enviado un mensaje a otra tarea, dona el resto de su intervalo de tiempo de ejecución (*timeslice*) al hilo de la otra tarea. Esto es más barato que ir a la cola de hilos PREPARADOS para seleccionar el siguiente a ejecutar.

Los mensajes enviados por el mismo hilo se entregan en el orden de envío, siendo esta entrega fiable. Por lo menos, esto se garantiza cuando los mensajes se envían entre tareas bajo un mismo núcleo, incluso cuando no hay espacio en el búfer. Cuando los mensajes se transmiten a través de la red a un computador independiente, se utiliza la semántica de entrega *como máximo una vez*.

El *timeout* es útil en situaciones en las que no es deseable que un hilo se inmovilice indefinidamente, por ejemplo en espera de un mensaje que puede no llegar nunca, o esperando por espacio en una cola sobre un puerto de servidor erróneo.

18.5. IMPLEMENTACIÓN DE LA COMUNICACIÓN

Uno de los aspectos más interesantes de la implementación del sistema de comunicación en Mach es la utilización de servidores de red de nivel de usuario. Los servidores de red (*netmsgservers* en la literatura de Mach), uno por computador, son colectivamente responsables de extender la semántica de comunicación local sobre toda la red. Esto incluye preservar, en la medida de lo posible, las garantías de reparto y hacer que la comunicación sobre la red sea transparente. También incluye la realización y monitorización de las transferencias de derechos de puertos. En concreto, los servidores de red son los responsables de la protección de los puertos frente a accesos ilegales y del mantenimiento de la privacidad de los mensajes enviados por la red. Los detalles completos de cuestiones del tratamiento de Mach de la protección están disponibles en Sansom y otros [1986].

18.5.1. GESTIÓN TRANSPARENTE DE MENSAJES

Debido a que los puertos son siempre locales al núcleo de Mach, es necesario añadir una abstracción impuesta de forma externa, el *puerto de red*, utilizada para enviar los mensajes de red. Un puerto de red es un identificador de canal globalmente único gestionado exclusivamente por los servidores de red y que éstos asocian a cada único puerto Mach en cada momento. Los servidores de red poseen los derechos de envío y recepción sobre los puertos de red, de la misma forma que las tareas poseen los derechos de envío y recepción sobre los puertos Mach.

En la Figura 18.6 aparece una descripción de la transmisión de un mensaje entre tareas localizadas en diferentes computadores. Los derechos de la tarea emisora se refieren a los puertos locales, sobre los cuales el servidor de red local dispone de los derechos de recepción. En la figura, el identificador local del servidor de red para los derechos de recepción es 8. El servidor de red en el computador emisor utiliza este identificador para buscar una entrada en una tabla de puertos de red para los que tiene derechos de envío. Esta tabla proporciona un puerto y sugiere una dirección de red. A continuación envía el mensaje, al que se añade el puerto de red, al servidor de red de la dirección indicada en la tabla. Allí este servidor de red local extrae el puerto de red y lo utiliza para buscar en una tabla de puerto de red para los que tiene derechos de recepción. Si encuentra

una entrada válida (el puerto de red podría haber sido reasignado a otro núcleo), entonces esa entrada contiene el identificador de los derechos de envío a un puerto local en Mach. El servidor de red reenvía el mensaje utilizando estos derechos, consiguiendo así enviar el mensaje al puerto apropiado. El proceso completo realizado por los servidores de red es transparente tanto para el emisor como para el receptor.

¿Cómo se establecen las tablas mostradas en la Figura 18.6? El servidor de red de un computador recién inicializado se enrôle en un protocolo de inicialización, por el cual se obtienen derechos de envío sobre los servicios de toda red. Considerese que ocurre después de esto, cuando se transfiere entre servidores de red un mensaje que contiene derechos de puerto. Estos derechos están tipados de modo que los servidores de red pueden seguirles la pista. Si una tarea emite los derechos de envío de un puerto local, el servidor de red local crea un identificador de puerto de red y una entrada en la tabla para el puerto local (si no existía ninguna) y enlaza el identificador al mensaje que envía. El servidor de red receptor también crea una entrada en la tabla si no existe ninguna.

La situación se vuelve más complicada cuando se transmiten los derechos de recepción. Este caso es un ejemplo en el que se necesita transparencia en la migración: los clientes deben ser capaces de enviar mensajes al puerto mientras éste está migrando. En primer lugar, el servidor de red local en el emisor adquiere los derechos de recepción. Todos los mensajes destinados al puerto, locales y remotos, comienzan llegando a este servidor. A continuación emplea un protocolo por el que se transfieren consistentemente los derechos de recepción al servidor de red destino.

La principal cuestión relativa a esta transferencia de derechos es cómo conseguir que los mensajes enviados al puerto ahora lleguen al computador a la que se han transferido los derechos de recepción. Una posibilidad sería que Mach siguiera la pista de todos los servidores de red que dispusieran de los derechos de envío sobre un cierto puerto de red, y notificar directamente a dichos servidores en el momento en que los derechos de recepción hubieran sido transferidos. Este esquema se rechazó por su coste de gestión. Una alternativa más barata sería utilizar un medio de difusión (*broadcast*) hardware que difunda el cambio de ubicación a todos los servidores de red. Sin embargo, este servicio de broadcast no es fiable y no está disponible en todas las redes. En su lugar, la responsabilidad de localizar un puerto de red se asignó a los servidores de red que disponen de los derechos de envío sobre dicho puerto.

Recuerde que un servidor de red utiliza una indicación de ubicación cuando reenvía un mensaje a otro servidor de red. Las posibles respuestas son:

- el puerto está aquí:* el destino dispone de los derechos de recepción;
- el puerto está muerto:* el puerto ha sido eliminado;
- el puerto no está aquí, está transferido:* los derechos de recepción fueron transferidos a una cierta dirección;
- el puerto no está aquí, lo desconozco:* no existe información sobre el puerto de red;
- no hay respuesta:* el computador destino no responde.

Si se devuelve una dirección de reenvío, el servidor de red emisor envía el mensaje a dicha dirección; sin embargo se trata sólo de una sugerencia que puede ser inexacta. Si en algún punto el emisor se queda sin direcciones de reenvío, entonces recurre a la difusión. En este tipo de algoritmos de localización, y en concreto cuando se utilizan sobre una WAN, las dos principales cuestiones de diseño son cómo manejar las cadenas de direcciones de reenvío y qué hacer cuando un computador que contiene una dirección de reenvío falla. El empleo de direcciones de reenvío sobre una WAN se describe en Black y Artsy [1990].

Una segunda cuestión para conseguir la transparencia en la migración es cómo sincronizar la entrega de los mensajes. Mach garantiza que dos mensajes enviados por el mismo hilo son entregados en el mismo orden. ¿Cómo puede garantizarse esto mientras los derechos de recepción están siendo transmitidos? Si esto no se resuelve correctamente un mensaje podría ser entregado por el

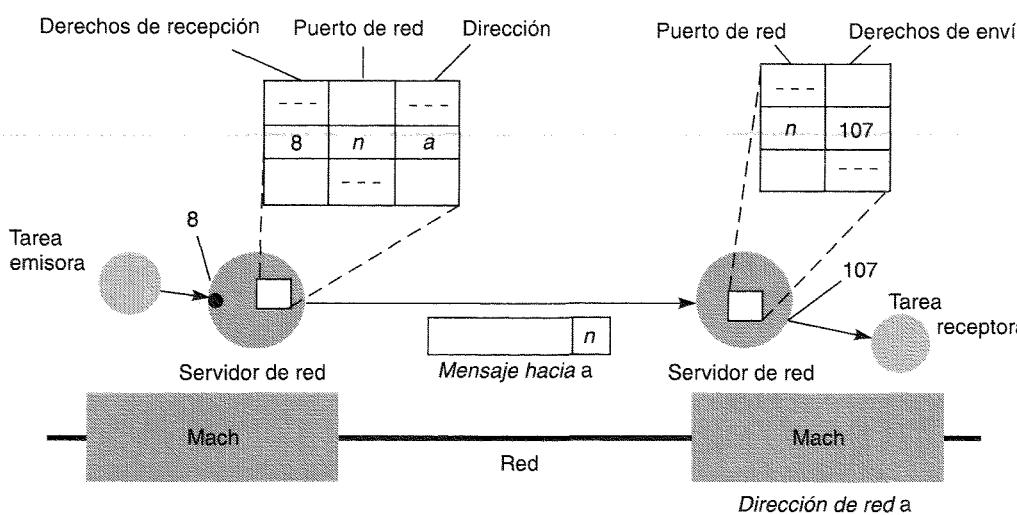


Figura 18.6. Comunicación de red en Mach.

nuevo servidor de red antes de que se haya redirigido un mensaje anterior almacenado en la cola

nuevo servidor de red antes de que se haya redirigido un mensaje anterior almacenado en la cola del computador original. El servidor de red puede conseguir esto reteniendo la entrega de todos los mensajes en el computador origen hasta que todos los mensajes almacenados en la cola hayan sido

18.5.2. EXTENSIBILIDAD: PROTOCOLOS Y GESTORES DE DISPOSITIVOS

◊ **Protocolos de transporte.** A pesar de que inicialmente la intención era conseguir que pudiera usarse una amplia variedad de protocolos de transporte mediante la ejecución de los servidores de red en el espacio de usuario, en el momento en que se escribe este libro los servidores de red de Mach de usados ampliamente usan únicamente TCP/IP como protocolo de transporte. Esto fue impulsado, en parte por la compatibilidad con UNIX, y en parte al ser seleccionado por la Universidad Carnegie-Mellon dada la complejidad de su red, que contiene más de 1.700 computadores, alrededor de 500 de ellos ejecutando Mach. Se ajustó TCP/IP para conseguir robustez de forma bastante eficiente sobre dicha red. Sin embargo, por motivos de prestaciones, esto puede no ser apropiado en una LAN donde predominan las interacciones petición-respuesta. Discutiremos las prestaciones de las comunicaciones en Mach en la Sección 18.6.

◊ **Gestores de dispositivos de red del nivel de usuario.** Algunos servidores de red proporcionan sus propios gestores de dispositivos (*drivers*) de red a nivel de usuario. Su objetivo es acelerar los accesos a la red. El situar los drivers en el nivel de usuario es, además de un método para mejorar la flexibilidad, una forma de compensar la degradación de prestaciones debida a la utilización de servidores de red al nivel de usuario. El núcleo exporta una abstracción para cada dispositivo, que incluye una operación para proyectar los registros de control del dispositivo sobre el espacio de usuario. Para el caso de una Ethernet, tanto los registros como los búferes de paquetes utilizados por el controlador pueden correlacionarse dentro el espacio de direcciones del servidor de red. Además, el núcleo ejecuta un código especial para despertar el hilo de nivel de usuario

Estas propiedades incluyen los permisos de accesos (lectura/escritura/ejecución), y también la elongabilidad. Por ejemplo se permite que las regiones de pila crezcan hacia direcciones bajas; y los montones (*heaps*) puedan crecer hacia las altas. El modelo utilizado por Mach es similar.

A pesar de ello, la visión del espacio de direcciones en Mach es la de una colección de grupos de páginas contiguas que se nombran mediante sus direcciones, en lugar de regiones identificables separadamente. Consecuentemente, la protección en Mach se aplica a las páginas en lugar de a las regiones. Las llamadas al sistema de Mach se refieren a direcciones y tamaños en lugar de usar identificadores de región. Por ejemplo, Mach no *hace crecer la región de pila*. En su lugar se asignan algunas páginas justo por debajo de las que están siendo utilizadas para la pila. Sin embargo, en la mayoría de los casos estas diferencias no son demasiado importantes.

Llamaremos región a una colección contigua de páginas con propiedades comunes a la región. Como hemos visto, Mach soporta un gran número de regiones, que pueden usarse para múltiples fines como almacenar datos o proyectar archivos en memoria.

Las regiones pueden crearse mediante cualquiera de las siguientes formas:

- Pueden ser asignadas de forma explícita mediante una llamada a *vm_allocate*. Las regiones creadas con *vm_allocate* están puestas a cero por defecto.
- Puede crearse una región en asociación con un *objeto de memoria*, utilizando *vm_map*.
- Pueden asignarse regiones a tareas recién creadas a través de la declaración (mejor dicho, la declaración y la de sus contenidos) como herencia desde una tarea tipo, utilizando *vm_inherit* aplicado a la región de la tarea tipo.
- Pueden asignarse automáticamente regiones en el espacio de direcciones de una tarea como efecto colateral del paso de mensajes.

Todas las regiones pueden establecer permisos de lectura/escritura/ejecución, mediante *vm_protect*. Pueden copiarse regiones dentro de las tareas mediante *vm_copy*, y otras tareas podrán leer o modificar los contenidos mediante *vm_read* y *vm_write*. Cualquier región previamente asignada puede ser liberada usando *vm_deallocate*.

Describiremos ahora la aproximación de Mach para la implementación de la operación UNIX *fork* y los aspectos relativos a la memoria virtual del paso de mensajes, incorporados en Mach para permitir la compartición de memoria cuando resulte conveniente.

18.6.2. COMPARTICIÓN DE MEMORIA: HERENCIA Y PASO DE MENSAJES

Mach permite una generalización de la semántica de UNIX *fork* mediante el mecanismo de *herencia de memoria*. Hemos visto que cada tarea se crea desde otra tarea, que actúa como plantilla. Una región heredada desde una tarea tipo contiene el mismo rango de direcciones y su memoria puede ser:

Compartida: secundada por la misma memoria.

Copiada: almacenada en una zona de memoria copiada de la memoria de la tarea tipo en el mismo instante en que se creó la región.

También es posible, rechazar la herencia de cierta región que no sea necesaria en el hijo.

Para el caso de *fork* en UNIX, el texto del programa de la tarea tipo se hereda y se comparte con la tarea hija. Lo mismo ocurre para una región que contiene código de biblioteca compartida. Sin embargo, la pila y el montón del se heredan mediante copias de las regiones de la tarea tipo. Además, si se solicita a la tarea tipo que comparta con su hijo cierta región de datos (operación permitida en UNIX System V), podrá configurarse esta región como heredada para compartir.

Los datos de los mensajes no alineados se transfieren entre las tareas con un método similar a la herencia con copia. Mach crea una región en el espacio de direcciones del receptor, y sus conte-

pidos iniciales son una copia de la región que contiene los datos no alineados del emisor. Al con-



lizar la *copia en escritura*). La columna *Crear región* indica el tiempo necesario para crear una región inicializada a cero (pero a la que no se accede). El resto de columnas proporcionan los tiempos medidos en los experimentos en los que una región existente fue copiada en otra utilizando la *copia en escritura*. Estos valores incluyen el tiempo necesario para la creación de la región copia, la copia de datos en modificación y la destrucción de la región copia. Para cada tamaño de región, se proporcionan valores asociados a diferentes cantidades de datos modificados en la región fuente.

Si comparamos los tiempos para una región con tamaño de una página, existe una sobrecarga de $4,82 - 2,7 = 2,12$ milisegundos debidos a la página que se está escribiendo, de los cuales 1,4 milisegundos pueden asignarse a la copia de la página; los restantes 0,72 milisegundos se emplean en la gestión del fallo en escritura y las modificaciones de las estructuras internas de datos de gestión de la memoria virtual. Para el envío de un mensaje de tamaño 8 kilobytes entre dos tareas locales, el envío de datos no alineados (es decir, la utilización de la *copia en escritura*) no parece tener una clara ventaja sobre el envío alineado, en el que simplemente se copia. Las transferencias alineadas implican la realización de dos copias (usuario-núcleo y núcleo-usuario) por lo que se necesitará algo más de 2,8 milisegundos para las dos. Sin embargo, en el peor caso no alineado, el coste es significativamente mayor. Por otra parte, la transmisión de un mensaje no alineado de tamaño 256 kilobytes es mucho menos cara que la transmisión alineada si se mantiene la suposición ya mencionada; e incluso en el peor caso, 66,4 milisegundos es menos que $2 \times 44,8$ milisegundos que son los necesarios para copiar 256 kilobytes de datos alineados hacia y desde el núcleo.

Como apunte final sobre las técnicas de memoria virtual para la copia y la compartición de datos, nótese que la especificación de los datos implicados debe realizarse cuidadosamente. A pesar de no haberlo mencionado hasta este momento, un usuario puede especificar regiones mediante rangos de direcciones que no comiencen ni terminen en fronteras de páginas. Sin embargo, en Mach es obligado compartir memoria a nivel de página. Todos los datos dentro de las páginas involucradas pero no especificados por los usuarios serán en cualquier caso copiados entre las tareas. Éste es un ejemplo de lo que se conoce como *compartición falsa* (véase también la discusión sobre la granularidad de los datos compartidos en el Capítulo 16).

18.6.4. PAGINADORES EXTERNOS

En la línea de la filosofía de micronúcleo, el núcleo de Mach no soporta directamente archivos o cualquier otra abstracción de almacenamiento externo. En su lugar asume que dichos recursos son implementados por paginadores (*pgers*) externos. Al igual que Multics [Organick 1972], Mach ha elegido el modelo de acceso correlacionado para objetos de memoria. En lugar de acceder a los datos utilizando explícitamente operaciones *lee* y *escribe*, el programador sólo necesita acceder directamente a las correspondientes posiciones de memoria virtual. Una ventaja del acceso correlacionado es su uniformidad: se presenta al programador un único modelo de acceso a los datos, en lugar de dos. Sin embargo, la cuestión de si el acceso correlacionado es preferible a la utilización de operaciones explícitas es compleja en cuanto a sus ramificaciones, especialmente las asociadas a las prestaciones, por lo que no intentaremos aquí tratar con ella. Nos concentraremos ahora en los aspectos distribuidos de la implementación de memoria virtual de Mach. Ésta consta primordialmente del protocolo entre el núcleo y un paginador externo necesario para gestionar la correspondencia de los datos almacenados por este último.

Mach permite, mediante la llamada a *vm_map*, asociar una región con datos contiguos que arrancan de cierta posición de un objeto de almacenamiento. Esta asociación implica que los accesos de lectura a direcciones de la región se satisfacen con datos almacenados en el objeto de memoria, y los datos de la región modificados por accesos de escritura se propagan al objeto de almacenamiento. En general, el objeto de memoria se manejado desde un paginador externo, a pesar de que existe un paginador por defecto, implementado por el propio núcleo. El objeto de memoria

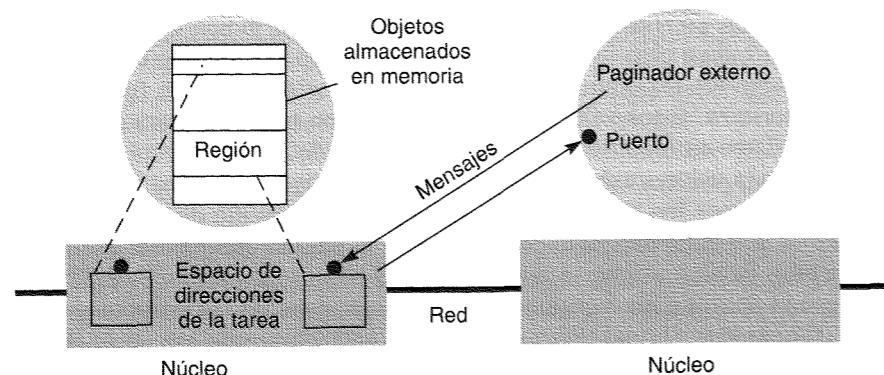


Figura 18.8. Pagenador externo.

está representado por los derechos de envío a un puerto utilizado por el pagenador externo, el cual satisface las peticiones concernientes al objeto de memoria provenientes del núcleo.

Para cada objeto de memoria correlacionado, el núcleo gestiona un recurso local llamado *objeto cacheado en memoria* (véase la Figura 18.8). En esencia se trata de una lista de páginas que contienen datos respaldados por el correspondiente objeto de memoria.

Las funciones de un pagenador externo son (a) almacenar los datos desalojados por el núcleo desde su caché de páginas, (b) proporcionar los datos de las páginas según los vaya solicitando el núcleo, y (c) imponer las limitaciones de consistencia asociadas a la abstracción del recurso de memoria subyacente para el caso en que el recurso de memoria sea compartido y varios núcleos puedan mantener de forma simultánea varios objetos almacenados en memoria para el mismo objeto de memoria.

Los principales componentes del protocolo de paso de mensajes entre el núcleo (N) y el pagenador externo (PE) se resumen en la Figura 18.9. Cuando se invoca a *vm_map*, el núcleo local contacta con el pagenador externo utilizando el derecho de envío del puerto asociado al objeto de memoria proporcionado en la llamada *vm_map*, enviándole un mensaje de tipo *memory_object_init*. El núcleo inserta en este mensaje los derechos de envío, los cuales son utilizados por el pagenador externo para controlar el objeto almacenado en memoria. También declara el tamaño y la posición de los datos solicitados al objeto de memoria, y el tipo de acceso (lectura/escritura). El pagenador externo responde con un mensaje de tipo *memory_object_set_attributes*, que indica al núcleo que el pagenador está preparado para gestionar solicitudes de datos y proporciona información adicional sobre los requisitos del pagenador en relación con el objeto de memoria. Cuando un pagenador externo recibe un mensaje *memory_object_init*, es capaz de determinar si necesita o no implementar un protocolo de consistencia, ya que todos los núcleos que quieren acceder al correspondiente objeto de memoria deben enviar este mensaje.

18.6.5. GESTIÓN DE ACCESOS A UN OBJETO DE MEMORIA

Comenzaremos analizando el caso en el que un objeto de memoria no sea compartido (sólo está correlacionado en un computador). Para ser más concretos, utilizaremos un archivo como objeto de memoria. Suponiendo que no se realiza prebúsqueda de los datos del archivo desde el pagenador externo, todas las páginas en la región correlacionada con este archivo se protegen inicialmente por el hardware frente a todos los accesos, al no existir ningún dato del archivo. Cuando un hilo intenta leer una de las páginas de la región, se genera un fallo de página. El núcleo busca el derecho de envío del puerto asociado al objeto de memoria correspondiente a la región correlacionada y envía

Evento	Emisor	Mensaje
<i>vm_map</i> invocado por la tarea	N → PE PE → N PE → N	<i>memory_object_init</i> <i>memory_object_set_attributes</i> , o <i>memory_object_data_error</i>
Faltas de página de la tarea al no existir un marco de página	N → PE PE → N PE → N	<i>memory_object_data_request</i> <i>memory_object_data_provided</i> , o <i>memory_object_data_unavailable</i>
El núcleo escribe una página modificada sobre almacenamiento persistente	N → PE	<i>memory_object_data_write</i>
El pagenador externo ordena al núcleo escribir una página/poner permisos de acceso	PE → N N → PE	<i>memory_object_lock_request</i> <i>memory_object_lock_completed</i>
Faltas de página de la tarea al no existir suficientes datos	N → PE PE → N	<i>memory_object_data_unlock</i> <i>memory_object_lock_request</i>
El objeto de memoria deja de estar mapeado	N → PE	<i>memory_object_terminate</i>
Pagenador externo retira un objeto de memoria	PE → N N → PE	<i>memory_object_destroy</i> <i>memory_object_terminate</i>

Figura 18.9. Mensajes del pagenador externo.

un mensaje *memory_object_data_request* al pagenador externo (que es, en nuestro ejemplo, un servidor de archivos). Si todo se realiza correctamente, el pagenador externo responde con los datos de la página, utilizando un mensaje *memory_object_data_provided*.

Cuando el archivo de datos es modificado por el computador que lo ha correlacionado, a veces el núcleo necesitará escribir la página desde su objeto almacenado en memoria. Para ello envía un mensaje de tipo *memory_object_data_write* al pagenador externo en el que se inserta la página de datos. Las páginas modificadas se transmiten al pagenador externo como en efecto colateral del reemplazo de páginas (cuando el núcleo necesita espacio para otra página). Además, el núcleo puede decidir la escritura de la página en el almacenamiento de respaldo (aunque la deja en la caché de memoria) para garantizar su persistencia. Por ejemplo, las implementaciones de UNIX escriben en disco los datos modificados normalmente cada 30 segundos, en caso de un fallo del sistema. Algunos sistemas operativos permiten a los programas controlar la seguridad de sus datos mediante una operación *flush* sobre un archivo abierto, el cual provoca que todas las páginas modificadas sean escritas en el archivo para el momento en que haya vuelto la llamada.

Los diferentes tipos de recursos de memoria pueden tener diferentes garantías de persistencia. El propio pagenador externo puede solicitar al núcleo, mediante un mensaje de tipo *memory_object_lock_request*, que los datos modificados en cierto rango sean enviados al pagenador para su consumación sobre el almácén permanente de acuerdo con estas garantías. Cuando el núcleo haya completado las acciones solicitadas, envía al pagenador externo un mensaje *memory_object_lock_completed*. (El pagenador externo necesita este mensaje porque no puede saber qué páginas han sido modificadas y requieren serle enviadas.)

Observe que todos los mensajes que estamos describiendo son enviados asíncronamente, incluso si se generan en una combinación petición-respuesta. Esto ocurre, en primer lugar, para que los hilos no sean suspendidos y puedan realizar otras tareas después del envío de las solicitudes. Además, un hilo no queda colgado cuando ha enviado una solicitud a un pagenador externo o núcleo

que resulta que ha fallado (o cuando el núcleo envía una solicitud a un paginador externo erróneo que no responde). Finalmente, un paginador externo puede utilizar el protocolo de mensajes asíncrono basado en mensajes para implementar una política de prebúsqueda de páginas. Puede enviar datos de páginas en mensajes *memory_object_data_provided* a los objetos cacheados en memoria anticipándose a su utilización, en lugar de esperar que se genere un fallo de páginas y se soliciten los datos.

◊ **Gestión de accesos compartidos a un objeto de memoria.** Supongamos, según nuestro ejemplo, que varias tareas residentes en diferentes computadores correlacionan un mismo archivo. Si la correlación se realiza únicamente para lectura en todas las regiones que lo usan, no existe problema de consistencia y las solicitudes a las páginas de los archivos pueden satisfacerse inmediatamente. Sin embargo, si al menos una tarea correlaciona el archivo para su escritura, entonces el paginador externo (es decir, el servidor de archivos) debe implementar un protocolo para asegurar que las tareas no lean versiones inconsistentes de la misma página.

Se invita al lector a traducir el protocolo de escritura invalidante para obtener consistencia secuencial, descrito en el Capítulo 16, sobre mensajes enviados entre el núcleo de Mach y los paginadores externos.

13.7. RESUMEN

El núcleo de Mach se ejecuta tanto en computadores multiprocesador como monoprocesador conectados por redes. Fue diseñado para facilitar la evolución de los nuevos sistemas distribuidos manteniendo la compatibilidad con UNIX. Muy recientemente, se ha utilizado el micronúcleo Mach 3.0 como base de la implementación MkLinux del sistema operativo Linux.

El núcleo de Mach es complejo en sí mismo y esto se debe en parte a lo sofisticado de algunas de las posibilidades que es capaz de emular. La interfaz del núcleo está formada por varios cientos de llamadas, siendo muchas de ellas simplemente resguardos que únicamente invocan a llamadas al sistema del tipo *mach_msg*. Un sistema operativo como UNIX no puede ser emulado utilizando únicamente paso de mensajes. Se necesita una gestión de memoria virtual sofisticada, proporcionada por Mach. El modelo de tareas e hilos de Mach y la integración de la gestión de memoria virtual con la comunicación representan una mejora considerable sobre las posibilidades básicas de UNIX, incorporando lecciones aprendidas de los intentos de implementación de servidores UNIX. Su modelo de comunicación entre tareas es funcionalmente rico y extremadamente complejo en su semántica. Sin embargo, debe tenerse presente que sólo unos pocos programadores de sistema necesitarán utilizarlos en su forma más cruda: por ejemplo, sobre este modelo de comunicación se proporcionan canalizaciones de UNIX y llamadas a procedimientos remotos.

A pesar de que el núcleo de Mach se considera a menudo un micronúcleo, su tamaño ronda los 500 kilobytes de código y datos (incluyendo un porcentaje sustancial de código de gestores de dispositivos). Los micronúcleos posteriores, llamados de segunda generación, proporcionan una gestión de la memoria y de la comunicación entre procesos más sencilla.

Los micronúcleos de segunda generación con comunicación entre procesos optimizada superan las prestaciones de Mach en la emulación de UNIX. Por ejemplo, los diseñadores del micronúcleo L4 [Hartig y otros 1997] informan que su implementación de nivel de usuario de Linux es sólo entre un 5 % y un 10 % más lenta que la implementación nativa de Linux sobre la misma máquina. Como contrapunto, indican que la emulación de nivel de usuario de MkLinux para Linux en Mach 3.0 proporciona de media un 50 % de degradación de prestaciones respecto a una implementación de Linux nativa en dicha máquina.

La filosofía de Mach de proporcionar toda la funcionalidad extendida en el nivel de usuario ha sido finalmente abandonada y se permitió que los servidores residieran en el núcleo [Condict y

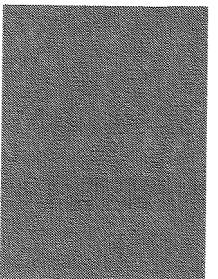
otros 1994]. Sin embargo, Hartig y otros indican que incluso la emulación de MkLinux a nivel de núcleo es alrededor de un 30 % más lenta que el Linux nativo.

A pesar de estas limitaciones de prestaciones en la emulación de UNIX, Mach, junto con Chorus, es un diseño innovador que sigue siendo relevante. Ambos continúan utilizándose y son una referencia inestimable para los desarrollos de arquitecturas de núcleo. El lector puede encontrar información adicional acerca del diseño del núcleo en www.cdk3.net/oss: Amoeba, Chorus y la emulación de UNIX sobre Mach y Chorus.

EJERCICIOS

- 18.1. ¿En qué se diferencia un núcleo diseñado para operar sobre multiprocesadores de otro pensado sólo para computadores monoprocesador?
- 18.2. Defina (a nivel binario) la emulación de un sistema operativo. ¿Por qué se considera deseable y, en caso de que lo sea, por qué no se realiza de forma rutinaria?
- 18.3. Explique por qué se asocian tipos a los contenidos de los mensajes en Mach.
- 18.4. Discuta si la habilidad del núcleo de Mach para monitorizar el número de derechos de envío sobre un cierto puerto debería extenderse a la red.
- 18.5. ¿Por qué se proporcionan en Mach conjuntos de puertos cuando también existen los hilos?
- 18.6. ¿Por qué existe en Mach una única llamada al sistema (*mach_msg*) para las comunicaciones? ¿Cómo se utiliza desde los clientes y los servidores?
- 18.7. ¿Qué diferencia existe entre un puerto de red y un puerto (local)?
- 18.8. Un servidor Mach gestiona múltiples recursos *thingumajig*.
 - (i) Discuta las ventajas e inconvenientes de las siguientes asociaciones:
 - a) Un único puerto con todos los thingumajigs.
 - b) Un único puerto para cada thingumajig.
 - c) Un puerto por cada cliente.
 - (ii) Un cliente proporciona un identificador thingumajig al servidor, el cual responde con un derecho de puerto. ¿Qué tipo de derecho de puerto debería enviar el servidor al cliente? Explique por qué el identificador del servidor para el derecho de puerto y el del cliente pueden ser diferentes.
 - (iii) Un cliente thingumajig reside en un computador distinto a la del servidor. Explique detalladamente cómo consigue el cliente llegar a poseer el derecho de puerto que le habilita para comunicarse con el servidor, aunque el núcleo de Mach sólo pueda transmitir derechos de puerto entre tareas locales.
 - (iv) Explique la secuencia de eventos de comunicación que tienen lugar en Mach cuando el cliente envía un mensaje solicitando una operación sobre un thingumajig, asumiendo de nuevo que el cliente y el servidor residen en computadores diferentes.
- 18.9. Una tarea Mach en una máquina A envía un mensaje a otra tarea en una máquina diferente B. ¿Cuántas transiciones de dominio ocurren y cuántas veces se copian los contenidos del mensaje si éste está alineado en la página?
- 18.10. Diseñe un protocolo para conseguir transparencia en la migración de puertos.
- 18.11. ¿Cómo puede un gestor de dispositivo, como un gestor de red, operar a nivel de usuario?

- 18.12.** Explique dos tipos de compartición de regiones utilizados por Mach en la emulación de la llamada al sistema UNIX *fork*, suponiendo que el hijo se ejecuta en el mismo computador. Un proceso hijo puede invocar de nuevo a *fork*. Explique cómo esto origina un problema de implementación y sugiera una solución.
- 18.13.**
- (i) ¿Es necesario que el núcleo elija el rango de direcciones de un mensaje recibido cuando se utiliza *copia en escritura*?
 - (ii) ¿Utiliza Mach la *copia en escritura* para el envío de mensajes a destinos remotos?
 - (iii) Una tarea envía un mensaje de 16 kilobytes de forma asíncrona a una tarea local en una máquina de 10 MIPS, 32 bits y tamaño de página de 8 kilobytes. Compare los costes de (1) copia simple de los datos del mensaje (sin usar *copia en escritura*) (2) el mejor caso usando *copia en escritura* y (3) el peor caso usando *copia en escritura*. Realice las siguientes suposiciones:
- La creación de una región vacía de tamaño 16 kilobytes cuesta 1.000 instrucciones.
 - La gestión de un fallo de páginas y la asignación de una nueva página en la región necesita 100 instrucciones.
- 18.14.** Resuma las razones para la existencia de los paginadores externos.
- 18.15.** Un archivo es abierto y correlacionado al mismo tiempo por dos tareas que residen en máquinas sin memoria física compartida. Discuta el problema de consistencia que surge de dicha situación. Diseñe un protocolo utilizando los mensajes del paginador externo de Mach que asegure la consistencia secuencial para los contenidos del archivo (véase el Capítulo 16).



REFERENCIAS

REFERENCIAS EN LÍNEA

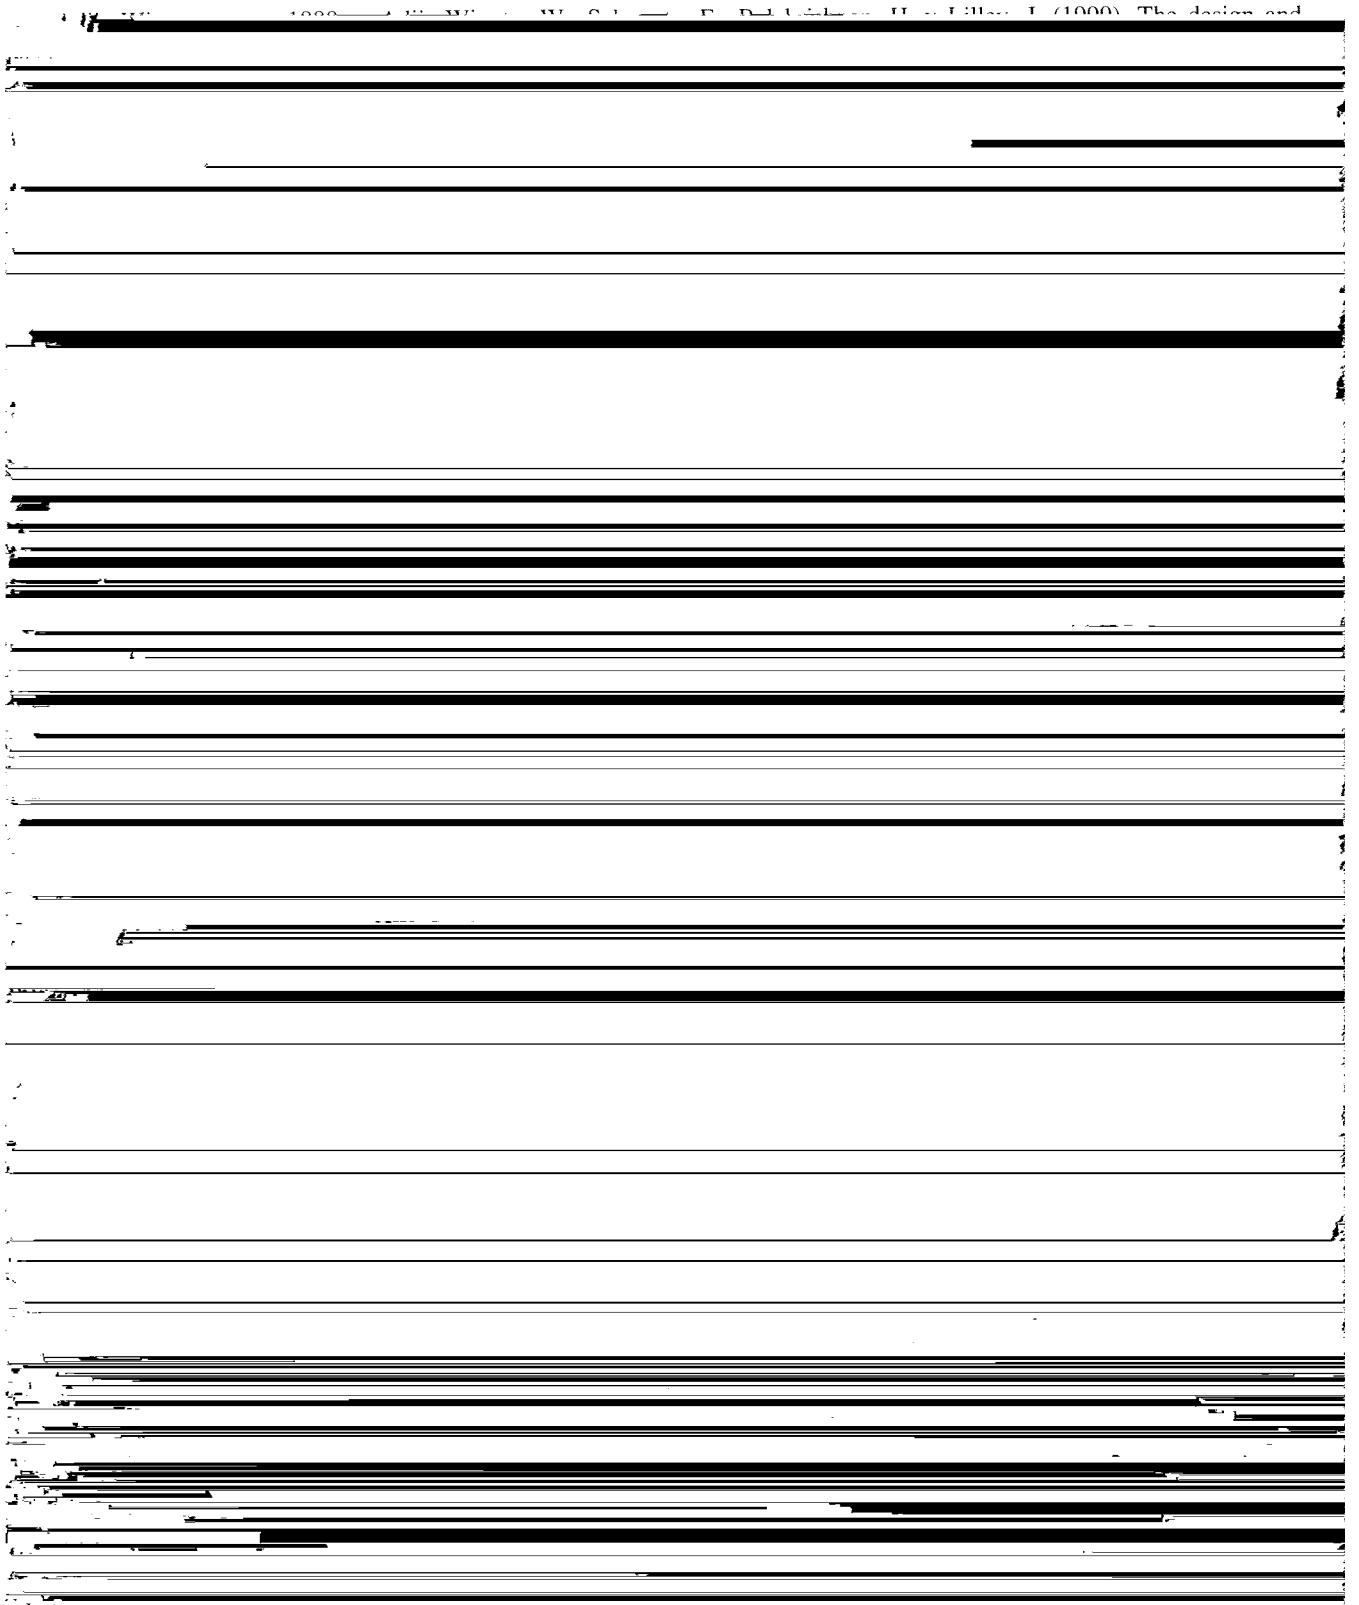
La lista de referencias en línea en www.cdk3.net/refs proporciona enlaces a los siguientes tipos de referencia:

- Enlaces a versiones en línea de los artículos publicados. La entrada en la lista impresa de referencias se marca con el símbolo [www](#) para indicar que el material está disponible en el Web a través de nuestra lista de referencias en línea.
- Enlaces a documentos que existen únicamente en el Web. Éstos están identificados por una etiqueta subrayada, por ejemplo, [www.omg.org](#) o [Linux AFS](#) y también están marcados con el símbolo [www](#) en la lista de referencias impresa que se presenta a continuación.

Los enlaces conducen al documento en sí o a una página de índice que contiene un enlace a documento. Las referencias a los RFC hacen alusión a las series de estándares y especificaciones de Internet llamadas «request for comments» que se encuentran disponibles en el *Internet Engineering Task Force*, en www.ietf.org/frc/ y en otros sitios bien conocidos.

El material en línea escrito o editado por los autores para completar este libro se referencia en el libro por [www.cdk3.net](#), pero no se incluye en la lista de referencias. Por ejemplo, [www.cdk3.net/ip](#) se refiere a material adicional sobre comunicación entre procesos que se encuentra en nuestras páginas web.

- | | |
|---|---|
| <p>Abadi y Gordon 1999</p> <p>Abadi y otros 1998</p> <p>Abrossimov y otros 1989</p> <p>Accetta y otros 1986</p> | <p>Abadi, M. y Gordon, A. D. (1999). A calculus for cryptographic protocols: The spi calculus. <i>Information and Computation</i>, vol. 148, n.º 1, pp. 1-70, enero.</p> <p>Abadi, M., Birrell, A. D., Stata, R. y Wobber, E. P (1998). Secure Web tunneling. En <i>Proceedings 7th International World Wide Web Conference</i>, pp. 531-9. Elsevier, en <i>Computer Networks and ISDN Systems</i>, volumen 30, n.º 1-7.</p> <p>Abrossimov, V., Rozier, M. y Shapiro, M. (1989). Generic virtual memory management for operating system kernels. <i>Proceedings of 12th ACM Symposium on Operating System Principles</i>, pp. 123-36, diciembre.</p> <p>Accetta, M., Baron, R., Golub, D., Rashid, R., Tevanian, A. y Young, M. (1986). Mach: A new kernel foundation for UNIX development. En <i>Proceedings Summer 1986 USENIX Conference</i> pp. 93-112.</p> |
|---|---|



- Balakrishnan y otros 1996
Balakrishnan, H., Padmanabhan, V., Seshan, S. y Katz, R. (1996). A Comparison of Mechanisms for Improving TCP Performance over Wireless Links. *Proceedings of the ACM SIGCOMM '96 Conference*, pp. 256-69.
- Banerjea y Mah 1991
Banerjea, A. y Mah, B.A. (1991). The real-time channel administration protocol. *Second International Workshop on Network and Operating System Support for Digital Audio and Video*, Heidelberg.
- Baran 1964
Baran, P. (1964). *On Distributed Communications*. Research Memorandum RM-3420-PR, Rand Corporation.
- Barborak y otros 1993
Barborak, M., Malek, M. y Dahbura, A. (1993). The consensus problem in fault-tolerant computing. *ACM Computing Surveys*, vol. 25, n.º 2, pp. 171-220.
- Barghouti y Kaiser 1991
Barghouti, N. S. y Kaiser G. E. (1991). Concurrency control in advanced database applications. *Computing Surveys*, vol. 23, n.º 3, pp. 269-318.
- Bartoli y otros 1993
Bartoli, A., Mullender, S. J. y van der Valk, M. (1993). Wide-address spaces – exploring the design space. *ACM Operating Systems Review*, vol. 27, n.º 1, pp. 11-17.
- Bates y otros 1996
Bates, J., Bacon, J., Moody, K. y Spiteri, M. (1996). Using events for the scalable federation of heterogeneous components, *European SIGOPS Workshop*.
- Bell y LaPadula 1975
Bell, D. E. y LaPadula, L. J. (1975). *Computer Security Model: Unified Exposition and Multics Interpretation*, Mitre Corporation, 1975.
- Bellman 1957
Bellman, R. E. (1957). *Dynamic Programming*. Princeton, NJ: Princeton University Press.
- Bellovin y Merritt 1990
Bellovin, S. M. y Merritt, M. (1990). Limitations of the Kerberos authentication system. *ACM Computer Communications Review*, vol. 20, n.º 5, pp. 119-32.
- Berners-Lee 1991
Berners-Lee, T. (1991). World Wide Web Seminar.
- Berners-Lee 1999
Berners-Lee, T. (1999). *Weaving The Web*. HarperCollins.
- Bernstein y otros 1980
Bernstein, P. A., Shipman, D. W. y Rothnie, J. B. (1980). Concurrency control in a system for distributed databases (SDD-1). *ACM Transactions Database Systems*, vol. 5, n.º 1, pp. 18-51.
- Bernstein y otros 1987
Bernstein, P., Hadzilacos, V. y Goodman, N. (1987). *Concurrency Control and Recovery in Database Systems*. Reading, Mass.: Addison-Wesley.
- Bershad y otros 1990
Bershad, B., Anderson, T., Lazowska, E. y Levy, H. (1990). Lightweight remote procedure call. *ACM Transactions Computer Systems*, vol. 8, n.º 1, pp. 37-55.
- Bershad y otros 1991
Bershad, B., Anderson, T., Lazowska, E. y Levy, H. (1991). User-level interprocess communication for shared memory multiprocessors. *ACM Transactions Computer Systems*, vol. 9, n.º 2, pp. 175-198.
- Bershad y otros 1993
Bershad, B., Zekauskas, M. y Sawdon, W. (1993). The Midway distributed shared memory system. En *Proceedings IEEE COMPCON Conference*, IEEE, pp. 528-37.
- Bershad y otros 1995
Bershad, B., Savage, S., Pardyak, P., Sirer, E., Fiuczynski, M., Becker, D., Chambers, C. y Eggers, S. (1995). Safety and performance in the SPIN operating system. *Proceedings of the 15th ACM Symposium on Operating Systems Principles*, pp. 267-84.
- Bhatti y Friedrich 1999
Bhatti, N. y Friedrich, R. (1999). *Web Server Support for Tiered Services*. Hewlett-Packard Corporation Technical Report HPL-1999-160.
- Birman 1993
Birman, K. P. (1993). The process group approach to reliable distributed computing. *Comms. ACM*, vol. 36, n.º 12, pp. 36-53.
- Birman 1996
Birman, K. P. (1996). *Building Secure and Reliable Network Applications*. Greenwich, CT: Manning.
- Birman y Joseph 1987a
Birman, K. P. y Joseph, T. A. (1987). Reliable communication in the presence of failures. *ACM Transactions Computer Systems*, vol. 5, n.º 1, pp. 47-76.

- Birman y Joseph 1987b
Birman, K., y Joseph, T. (1987). Exploiting virtual synchrony in distributed systems. En *Proceedings 11th ACM Symposium on Operating Systems Principles*, pp. 123-38.
- Birman y otros 1991
Birman, K. P., Schiper, A. y Stephenson, P. (1991). Lightweight causal and atomic group multicast. *ACM Transactions Computer Systems*, vol. 9, n.º 3, pp. 272-314.
- Birrell y otros 1995
Birrell, A., Nelson, G. y Owicki, S. (1993). Network objects. En *Proceedings 14th ACM Symposium on Operating Systems Principles*, pp. 217-30.
- Birrell y Needham 1980
Birrell, A. D. y Needham, R. M. (1980). A universal file server. *IEEE Transactions Software Engineering*, vol. SE-6, n.º 5, pp. 450-3.
- Birrell y Nelson 1984
Birrell, A. D. y Nelson, B. J. (1984). Implementing remote procedure calls. *ACM Transactions Computer Systems*, vol. 2, pp. 39-59.
- Birrell y otros 1982
Birrell, A. D., Levin, R., Needham, R. M. y Schroeder, M. D. (1982). Grapevine: an exercise in distributed computing. *Comms. ACM*, vol. 25, n.º 4, pp. 260-73.
- Bisiani y Forin 1988
Bisiani, R. y Forin, A. (1988). Multilanguage parallel programming of heterogeneous machines. *IEEE Transactions Computers*, vol. 37, n.º 8, pp. 930-45.
- Bisiani y Ravishankar 1990
Bisiani, R. y Ravishankar, M. (1990). Plus: a distributed shared memory system. En *Proceedings 17th International Symposium on Computer Architecture*, pp. 115-24.
- Black 1990
Black, D. (1990). Scheduling support for concurrency and parallelism in the Mach operating system, *IEEE Computer*, vol. 23, n.º 5, pp. 35-43.
- Black y Artsy 1990
Black, A. y Artsy, Y. (1990). Implementing location independent invocation, *IEEE Transactions Parallel and Distributed Systems*, vol. 1, n.º 1.
- Blair y Stefani 1997
Blair, G. S. y Stefani, J.-B. (1997). *Open Distributed Processing and Multimedia*. Harlow, England: Addison-Wesley.
- Blakley 1999
Blakley, R. (1999). *CORBA Security – An Introduction to Safe Computing with Objects*. Reading, Mass.: Addison-Wesley.
- Bolosky y otros 1996
Bolosky, W., Barrera, J., Draves, R., Fitzgerald, R., Gibson, G., Jones, M., Levi, S., Myhrvold, N. y Rashid, R. (1996). The Tiger video fileserver, *6th NOSSDAV Conference*, Zushi, Japón, abril.
- Bolosky y otros 1997
Bolosky, W., Fitzgerald, R. y Douceur, J. (1997). Distributed schedule management in the Tiger video fileserver, *16th ACM Symposium on Operating System Principles*, pp. 212-23, St. Malo, Francia, octubre.
- Bonnaire y otros 1995
Bonnaire, X., Baggio, A. y Prun, D. (1995). Intrusion free monitoring: an observation engine for message server based applications. En *Proceedings of the 10th International Symposium on Computer and Information Sciences (ISCIS X)*, pp. 541-48.
- Borenstein y Freed 1993
Borenstein, N. y Freed, N. (1993). *MIME (Multipurpose Internet Mail Extensions) Part One: Mechanisms for Specifying and Describing the Format of Internet Message Bodies*, septiembre. Internet RFC 1521.
- Bowman y otros 1990
Bowman, M., Peterson, L. y Yeatts, A. (1990). Univers: an attribute-based name server. *Software-Practice y Experience*, vol. 20, n.º 4, pp. 403-24.
- Box 1998
Box, D. (1998). *Essential COM*. Reading, Mass: Addison-Wesley.
- Boykin y otros 1993
Boykin, J., Kirschen, D., Langerman, A. y LoVerso, S. (1993). *Programming under Mach*. Reading, Mass.: Addison-Wesley.
- Buford 1994
Buford, J. K. (1994). *Multimedia Systems*. Addison-Wesley.
- Burns y Wellings 1998
Burns, A. y Wellings, A. (1998). *Concurrency in Ada*, Cambridge University Press.
- Burrows y otros 1989
Burrows, M., Abadi, M. y Needham, R. (1989). *A logic of authentication*. Technical Report 39, Palo Alto, Calif.: Digital Equipment Corporation Systems Research Center.
- Burrows y otros 1990
Burrows, M., Abadi, M. y Needham, R. (1990). A logic of authentication. *ACM Transactions Computer Systems*, vol. 8, pp. 18-36.
- Bush 1945
Bush, V. (1945). As we may think. *The Atlantic Monthly*, julio.

- Callaghan, B. (1996). *WebNFS Client Specification*, Internet RFC 2054, octubre.

- Callaghan, B. (1996). *WebNFS Client Specification*, Internet RFC 2054, octubre.

- Cheriton 1985 Cheriton, D. R. (1985). Preliminary thoughts on problem-oriented shared memory: a decentralized approach to distributed systems. *ACM Operating Systems Review*, vol. 19, n.º 4, pp. 26-33.
- Cheriton 1986 Cheriton, D. R. (1986). VMTP: A protocol for the next generation of communication systems. En *Proceedings SIGCOMM '86 Symposium on Communication Architectures and Protocols*, ACM, pp. 406-15.
- Cheriton y Mann 1989 Cheriton, D. y Mann, T. (1989). Decentralizing a global naming service for improved performance and fault tolerance. *ACM Transactions Computer Systems*, vol. 7, n.º 2, pp. 147-83.
- Cheriton y Skeen 1993 Cheriton, D. y Skeen, D. (1993). Understanding the limitations of causally and totally ordered communication. En *Proceedings 14th ACM Symposium on Operating System Principles*, diciembre, pp. 44-57.
- Cheriton y Zwaenepoel 1985 Cheriton, D. R. y Zwaenepoel, W. (1985). Distributed process groups in the V kernel. *ACM Transactions Computer Systems*, vol. 3, n.º 2, pp. 77-107.
- Cheswick y Bellovin 1994 Cheswick, E. R. y Bellovin, S. M. (1994). *Firewalls and Internet Security*. Reading, Mass.: Addison-Wesley.
- Choudhary y otros 1989 Choudhary, A., Kohler, W., Stankovic, J. y Towsley, D. (1989). A modified priority based probe algorithm for distributed deadlock detection and resolution. *IEEE Transactions Software Engineering*, vol. 15, n.º 1.
- Clark 1982 Clark, D. D. (1982). *Window and Acknowledgement Strategy in TCP*, Internet RFC 813. [www](#)
- Comer 1991 Comer, D. E. (1991). *Internetworking with TCP/IP, Volume 1: Principles, Protocols and Architecture*. Segunda edición. Englewood Cliffs, NJ: Prentice-Hall.
- Comer 1995 Comer, D. E. (1995). *The Internet Book*. Englewood Cliffs, NJ: Prentice-Hall.
- Condict y otros 1994 Condict, M., Bolinger, D., McManus, E., Mitchell, D. y Lewontin, S. (1994). *Microkernel modularity with integrated kernel performance*. Technical report, OSF Research Institute, Cambridge, Mass, abril.
- Coulouris y otros 1998 Coulouris, G. F., Dollimore, J. B. y Roberts, M. (1998). Role and task-based access control in the PerDiS groupware platform. *Third ACM Workshop on Role-Based Access Control*, George Mason University, Washington DC, octubre 22-23. [www](#)
- Cristian 1989 Cristian, F. (1989). Probabilistic clock synchronization. *Distributed Computing*, vol. 3, pp. 146-58.
- Cristian 1991a Cristian, F. (1991). Understanding fault-tolerant distributed systems. *Comms. ACM*, vol. 34, n.º 2.
- Cristian 1991b Cristian, F. (1991). Reaching agreement on processor group membership in synchronous distributed systems. *Distributed Computing*, Springer Verlag, vol. 4, pp 175-87.
- Cristian y Fetzer 1994 Cristian, F., y Fetzer, C. (1994). Probabilistic Internal Clock Synchronization. En *Proceedings 13th Symposium on Reliable Distributed Systems*, IEEE Computer Society Press, octubre 25-27, pp. 22-31.
- Crow y otros 1997 Crow, B., Widjaja, I., Kim, J. y Sakai, P. (1997). IEEE 802.11 Wireless local area networks. *IEEE Communications Magazine*, septiembre, 1997, pp. 116-26.
- cryptography.org North American Cryptography Archives. [www](#)
- Curtin y Dolske 1998 Kurtin, M. y Dolski, J. (1998). A brute force search of DES Keyspace. ;login: – the Newsletter of the USENIX Association, mayo. [www](#)
- Custer 1998 Custer, H. (1998). *Inside Windows NT*, segunda edición. Microsoft Press.
- Czerwinski y otros 1999 Czerwinski, S., Zhao, B., Hodes, T., Joseph, A. y Katz, R. (1999). An architecture for a secure discovery service. En *Proceedings Fifth Annual International Conference on Mobile Computing and Networks*.

- Dasgupta y otros 1991 Dasgupta, P., LeBlanc Jr., R. J. Ahamad, M. y Ramachandran, U. (1991). The Clouds distributed operating system. *IEEE Computer*, vol. 24, n.º 11, pp. 34-44.
- Davidson 1984 Davidson, S. B. (1984). Optimism and consistency in partitioned database systems. *ACM Transactions Database Systems*, vol. 9, n.º 3, pp. 456-81.
- Davidson, S. B., García-Molina, H. y Skeen, D. (1985). Consistency in partitioned networks. *Computing Surveys*, vol. 17, n.º 3, pp. 341-70.
- Digital Equipment Corporation. (1990). *In Memoriam: J. C. R. Licklider 1915-1990*, Technical Report 61, DEC Systems Research Center. [www](#)
- Delgrossi, L., Halstrick, C., Hehmann, D., Herrtwich, R. G., Krone, O., Sandvoss, J. y Vogt, C. (1993). Media scaling for audiovisual communication with the Heidelberg transport system. *ACM Multimedia '93*, Anaheim, Calif.
- Demers, A., Keshav, S., Shenker, S. (1989). Analysis and simulation of a fair queueing algorithm. *ACM SIGCOMM '89*.
- Denning, D. y Denning, P. (1977). Certification of programs for secure information flow. *Comms. ACM*, vol. 20, n.º 7, pp. 504-13.
- Dertouzos, M. L. (1974). Control robotics – the procedural control of physical processes. *IFIP Congress*.
- Dierks,T. y Allen, C. (1999). *The TLS Protocol Version 1.0*, Internet RFC 2246. [www](#)
- Diffie, W. (1988). The first ten years of public-key cryptography. *Proceedings of the IEEE*, vol. 76, n.º 5, mayo 1988, pp. 560-77.
- Diffie, W. y Hellman, M. E. (1976). New directions in cryptography. *IEEE Transactions Information Theory*, vol. IT-22, pp. 644-54.
- Kahn, D. y Landau, S. (1998). *Privacy on the Line*. Cambridge, Mass: MIT Press.
- Dijkstra, E. W. (1959). A note on two problems in connection with graphs. *Numerische Mathematic*, vol. 1, pp. 269-71.
- Dolev, D. y Malki, D. (1996). The Transis approach to high availability cluster communication. *Comms. ACM*, vol. 39, n.º 4, pp. 64-70.
- Dolev, D. y Strong, H. (1983). Authenticated algorithms for byzantine agreement. *SIAM Journal of Computing*, vol. 12, n.º 4, pp. 656-66.
- Dolev, D., Halpern, J., y Strong, H. (1986). On the possibility and impossibility of achieving clock synchronization. *Journal of Computing Systems Science* 32, 2 (abril), pp. 230-50.
- Dorcey, T. (1995) CU-SeeMe Desktop Video Conferencing Software, *Connexions*, vol. 9, no. 3 (marzo).
- Douceur, J.R. y Bolosky, W. (1999). Improving responsiveness of a stripe-scheduled media server. SPIE Proceedings, vol. 3.654. *Multimedia Computing and Networking*. pp. 192- 203. [www](#)
- Douglis, F. y Ousterhout, J. (1991). Transparent process migration: design alternatives and the Sprite implementation, *Software – Practice and Experience*, vol. 21, n.º 8, pp. 757-89.
- Draves, R. (1990). A revised IPC interface, In *Proceedings USENIX Mach Workshop*, pp. 101-21, octubre.
- Draves, R. P., Jones, M. B. y Thompson, M. R. (1989). *MIG – the Mach Interface Generator*. Technical Report, Dept. of Computer Science, Carnegie-Mellon University.
- Druschel, P. y Peterson, L. (1993). Fbufs: a high-bandwidth cross-domain transfer facility. En *Proceedings 14th ACM Symposium on Operating System Principles*, pp. 189-202.
- Dubois, M., Scheurich, C. y Briggs, F. A. (1988). Synchronization, coherence and event ordering in multiprocessors. *IEEE Computer*, vol. 21, n.º 2, pp. 9-21.

- Dwork y otros 1988 Dwork, C., Lynch, N. y Stockmeyer, L. (1988). Consensus in the presence of partial synchrony. *Journal of the ACM*, vol. 35, n.º 2, pp. 288-323.
- Eager y otros 1986 Eager, D., Lazowska, E. y Zahorjan, J. (1986). Adaptive load sharing in homogeneous distributed systems. *IEEE Transactions on Software Engineering*, vol. SE-12, n.º 5, pp. 662-675.
- EFF 1998 Electronic Frontier Foundation (1998). *Cracking DES, Secrets of Encryption Research, Wiretap Politics & Chip Design*. Sebastopol Calif.: O'Reilly & Associates.
- Eisler y otros 1997 Eisler, M., Chiu, A. y L. Ling, L. (1997). *RPCSEC—GSS Protocol Specification*. Sun Microsystems. Internet RFC 2203, septiembre.
- El Abbadi y otros 1985 El Abbadi, A., Skeen, D. y Cristian, C. (1985). An efficient fault-tolerant protocol for replicated data management. En *4th Annual ACM SIGACT/SIGMOD Symposium on Principles of Data Base Systems*, Portland, Ore.
- Ellis y otros 1991 Ellis, C., Gibbs, S. y Rein, G. (1991). Groupware – some issues and experiences. *Comms. ACM*, vol. 34, n.º 1, pp. 38-58.
- Ellison 1996 Ellison, C. (1996). Establishing identity without certification authorities. En *6th USENIX Security Symposium*, San José, julio 22-25.
- Ellison y otros 1999 Ellison, C., Frantz, B., Lampson, B., Rivest, R., Thomas, B. y Ylonen, T. (1999). *SPKI Certificate Theory*. Internet RFC 2693, septiembre.
- Farley 1998 Farley, J. (1998). *Java Distributed Computing*. Cambridge, Mass: O'Reilly.
- Farrow 2000 Farrow, R. (2000). Distributed denial of service attacks – how Amazon, Yahoo, eBay and others were brought down. *Network Magazine*, abril.
- Ferrari y Verma 1990 Ferrari, D. y Verma, D. (1990). A scheme for real-time channel establishment in wide-area networks. *IEEE Journal on Selected Areas in Communications*, vol. 8, n.º 4.
- Ferreira y otros 2000 Ferreira, P., Shapiro, M., Blondel, X., Fambon, O., García, J., Kloostermann, S., Richer, N., Roberts, M., Sandakly, F., Couloris, G., Dollimore, J., Guedes, P., Hagimont, D. y Krakowiak, S. (2000). PerDiS: Design, Implementation, and Use of a PERsistent DIstributed Store. En *LNCS 1752: Advances in Distributed Systems*. Springer-Verlag Berlin, Heidelberg, New York, pp. 427-53.
- Fidge 1991 Fidge, C. (1991). Logical Time in Distributed Computing Systems. *IEEE Computer*, vol. 24, n.º 8, pp. 28-33.
- Fielding y otros 1999 Fielding, R., Gettys, J., Mogul, J. C., Frystyk, H., Masinter, L., Leach, P. y Berners-Lee T. (1999). *Hypertext Transfer Protocol – HTTP/1.1*. Internet RFC 2616.
- Fischer 1983 Fischer, M. (1983). The Consensus Problem in Unreliable Distributed Systems (a Brief Survey). En M. Karpinsky, ed., *Foundations of Computation Theory*, vol. 158 of *Lecture Notes in Computer Science*, Springer-Verlag, pp. 127-140. Yale University Technical Report YALEU/DCS/TR- 273.
- Fischer y Lynch 1982 Fischer, M. y Lynch, N. (1982). A lower bound for the time to assure interactive consistency. *Inf. Process. Letters*, vol. 14, n.º 4, junio, pp. 183-6.
- Fischer y Michael 1982 Fischer, M. J. y Michael, A. (1982). Sacrificing Serializability to Attain High Availability of Data in an Unreliable Network. En *Proceedings Symposium on Principles of Database Systems*, ACM, pp. 70-5.
- Fischer y otros 1985 Fischer, M., Lynch, N. y Paterson, M. (1985). Impossibility of distributed consensus with one faulty process. *Journal of the ACM*, vol. 32, n.º 2, abril, pp. 374-82.
- Fitzgerald y Rashid 1986 Fitzgerald, R. y Rashid, R. F. (1986). The integration of virtual memory management and interprocess communication in Accent. *ACM Transactions Computer Systems*, vol. 4, n.º 2, pp. 147-77.
- Flanagan 1997 Flanagan, D. (1997). *Java in a Nutshell*. Cambridge, England: O'Reilly.
- Fleisch y Popek 1989 Fleisch, B. y Popek, G. (1989). Mirage: a coherent distributed shared memory design. En *Proceedings 12th ACM Symposium on Operating System Principles*, diciembre, pp. 211-23.
- Floyd 1986 Floyd, R. (1986). *Short term file reference patterns in a UNIX environment*. Technical Rep. TR 177, Rochester, NY: Dept. of Computer Science, University of Rochester.
- Floyd y Johnson 1993 Floyd, S. y Jacobson, V. (1993). The Synchronization of Periodic Routing Messages. *ACM Sigcomm '93 Symposium*.
- Floyd y otros 1997 Floyd, S., Jacobson, V., Liu, C., McCanne, S. y Zhang, L. (1997). A Reliable Multicast Framework for Lightweight Sessions and Application Level Framing. *IEEE/ACM Transactions on Networking*, vol. 5, n.º 6, pp. 784-803.
- Ford y Fulkerson 1962 Ford, L. R. y Fulkerson, D. R. (1962). *Flows in Networks*. Princeton, NJ: Princeton University Press.
- Fox y otros 1997 Fox, A., Gribble, S., Chawathe, Y., Brewer, E. y Gauthier, P. (1997). Cluster-based scalable network services. *Proceedings of the 16th ACM Symposium on Operating Systems Principles*, pp. 78-91.
- Garay y Moses 1993 Garay, J., y Moses, Y. (1993). Fully polynomial Byzantine agreement in $t + 1$ rounds. En *Proceedings 25th ACM symposium on theory of computing*, ACM Press, pp. 31-41, mayo.
- García-Molina 1982 García-Molina, H. (1982). Elections in Distributed Computer Systems. *IEEE Transactions on Computers*, vol. C-31, n.º 1, pp. 48-59.
- García-Molina y Spauster 1991 García-Molina, H. y Spauster, A. (1991). Ordered and Reliable Multicast Communication. *ACM Transactions Computer Systems*, vol. 9, n.º 3, pp. 242-71.
- Garfinkel, S. (1994). *PGP: Pretty Good Privacy*, O'Reilly.
- Gharachorloo, K., Lenoski, D., Laudon, J., Gibbons, P., Gupta, A. y Hennessy, J. (1990). Memory Consistency and Event Ordering in Scalable Shared-Memory Multiprocessors. En *Proceedings 17th. Annual International Symposium on Computer Architecture*, Mayo, pp. 15-26.
- Gibbs y Tsichritzis 1994 Gibbs, S. J. y Tsichritzis, D. C. (1994). *Multimedia Programming*. Addison-Wesley.
- Gifford 1979 Gifford, D. K. (1979). Weighted voting for replicated data. En *Proceedings 7th Symposium on Operating Systems Principles*, ACM, pp. 150-62.
- Glassman y otros 1995 Glassman, S., Manasse, M., Abadi, M., Gauthier, P. y Sobalvarro, P. (1995). The Millennium Protocol for Inexpensive Electronic Commerce. *Fourth International WWW Conference*, diciembre.
- Gokhale y Schmidt 1996 Gokhale, A. y Schmidt, D. (1996). Measuring the Performance of Communication Middleware on High-Speed Networks. *Proceedings of SIGCOMM '96*, ACM, pp. 306-17.
- Golding y Long 1993 Golding, R. y Long, D. (1993). *Modeling replica divergence in a weak-consistency protocol for global-scale distributed databases*. Technical report UCSC-CRL-93-09, Computer and Information Sciences Board, University of California, Santa Cruz.
- Gong 1989 Gong, L. (1989). A Secure Identity-Based Capability System. En *Proceedings of the IEEE Symposium on Security and Privacy*, Oakland, Calif., mayo, pp. 56-63.
- Goodman 1989 Goodman, J. (1989). *Cache Consistency and Sequential Consistency*. Technical Report 61, SCI Committee.
- Gordon 1984 Gordon, J. (1984). *The Story of Alice and Bob*.
- Govindan y Anderson 1991 Govindan, R. y Anderson, D.P. (1991). Scheduling and IPC Mechanisms for Continuous Media. *ACM Operating Systems Review*, vol. 25, n.º 5, pp. 68-80.
- Gray 1978 Gray, J. (1978). Notes on database operating systems. En *Operating Systems: an Advanced Course. Lecture Notes in Computer Science*, vol. 60, pp. 394-481, Springer-Verlag.

Jordan 1996 Jordan, M. (1996). Early Experiences with Persistent Java. En *Proceedings first international conference on distributed systems and applications*, pp. 1-10.

Jordan 1996 Jordan, M. (1996). Early Experiences with Persistent Java. En *Proceedings first international conference on distributed systems and applications*, pp. 1-10.

- Kopetz y Verissimo 1993 Kopetz, H. y Verissimo, P. (1993). Real Time and Dependability Concepts. en Mullender ed, *Distributed Systems*, segunda edición, Addison-Wesley.
- Kopetz y otros 1989 Kopetz, H., Damm, A., Koza, C., Mulazzani, M., Schwabl, W., Senft, C. y Zainlinger, R. (1989). Distributed Fault-Tolerant Real-Time Systems – The MARS Approach. *IEEE Micro*, vol. 9, n.º 1.
- Kshemkalyani y Singhal 1991 Kshemkalyani, A. y Singhal, M. (1991). Invariant-Based Verification of a Distributed Deadlock Detection Algorithm. *IEEE Transactions on Software Engineering*, vol. 17, n.º 8, agosto.
- Kshemkalyani y Singhal 1994 Kshemkalyani, A. y Singhal, M. (1994). On Characterisation and Correctness of Distributed Deadlock detection, *Journal of Parallel and Distributed Computing*, vol. 22, pp. 44-59.
- Kung y Robinson 1981 Kung, H. T. y Robinson, J. T. (1981). Optimistic methods for concurrency control. *ACM Transactions on Database Systems*, vol. 6, n.º 2, pp. 213-26.
- Kurose y Ross 2000 Kurose, J. F. y Ross, K. W. (2000). *Computer Networking: A Top-Down Approach Featuring the Internet*, Addison Wesley Longman.
- Ladin y otros 1992 Ladin, R., Liskov, B., Shrira, L. y Ghemawat, S. (1992). Providing Availability Using Lazy Replication. *ACM Transactions on Computer Systems*, vol. 10, n.º 4, pp. 360-91.
- Lai 1992 Lai, X. (1992). On the Design and Security of Block Ciphers, *ETH Series in Information Processing*, vol. 1, Konstanz: Hartung-Gorre Verlag.
- Lai y Massey 1990 Lai, X. y Massey, J. (1990). A proposal for a new Block Encryption Standard. *Advances in Cryptology-Eurocrypt '90*, En *Proceedings*, Springer-Verlag, pp. 389-404.
- Lamport 1978 Lamport, L. (1978). Time, clocks and the ordering of events in a distributed system. *Comms. ACM*, vol. 21, n.º 7, pp. 558-65.
- Lamport 1979 Lamport, L. (1979). How to Make a Multiprocessor Computer that Correctly Executes Multiprocess Programs. *IEEE Transactions Computers*, vol. C-28, n.º 9, pp. 690-1.
- Lamport 1986 Lamport, L. (1986). On interprocess communication, parts I and II. *Distributed Computing*, vol. 1, n.º 2, pp. 77-101.
- Lamport y otros 1982 Lamport, L., Shostak, R. y Pease, M. (1982). Byzantine Generals Problem. *ACM Transactions Programming Languages and Systems*, vol. 4, n.º 3, pp. 382-401.
- Lampson 1971 Lampson, B. (1971). Protection. En *Proceedings 5th Princeton Conference on Information Sciences and Systems*, Princeton, p. 437. Reeditado en *ACM Operating Systems Review*, vol. 8, n.º 1, enero, p. 18.
- Lampson 1981a Lampson, B. W. (1981). Atomic Transactions. En *Distributed systems: Architecture and Implementation. Lecture Notes in Computer Science* 105, pp. 254-9. Berlin: Springer-Verlag.
- Lampson 1986 Lampson, B. W. (1986). Designing a Global Name Service. En *Proceedings 5th ACM Symposium Principles of Distributed Computing*, pp. 1-10, agosto.
- Lampson, B. W., Abadi, M., Burrows, M. y Wobber, E. (1992). Authentication in Distributed Systems: Theory and Practice. *ACM Transactions on Computer Systems*, vol. 10, n.º 4, pp. 265-310.
- Lea y otros 1993 Lea, R., Jacquemot, C. y Pillevesse, E. (1993). COOL: system support for distributed programming. *Comms. ACM*, vol. 36, n.º 9, pp. 37-46.
- Leach y otros 1983 Leach, P. J., Levine, P. H., Douros, B. P., Hamilton, J. A., Nelson, D. L. y Stumpf, B. L. (1983). The architecture of an integrated local network. *IEEE J. Selected Areas in Communications*, vol. SAC-1, n.º 5, pp. 842-56.
- Lee y Thekkath 1996 Lee, E. K. y Thekkath, C. A. (1996). Petal: Distributed Virtual Disks, en *Proc. 7th Intl. Conf. on Architectural Support for Prog. Langs. and Operating Systems*, octubre, pp. 84-96.

- Lee y otros 1996 Lee C., Rajkumar, R. y Mercer C. (1996). Experiences with Processor Reservation and Dynamic QOS in Real-Time Mach. En *Proceedings Multimedia Japan '96*.
- Leffler y otros 1989 Leffler, S., McKusick, M., Karels, M. y Quartermain J. (1989). *The Design and Implementation of the 4.3 BSD UNIX Operating System*. Reading, Mass: Addison-Wesley.
- Leiner 1997 Leiner, B. M., Cerf, V. G., Clark, D. D., Kahn, R. E., Kleinrock, L., Lynch, D. C., Postel, J., Roberts, L. G. y Wolff, S. (1997). A Brief History of the Internet, *Comms. ACM*, vol. 40, n.º 1, febrero, pp. 102-108. [www](#)
- Leland y otros 1993 Leland, W. E., Taqqu, M. S., Willinger, W. y Wilson, D. V. (1993). On the Self-Similar Nature of Ethernet Traffic. *ACM SIGCOMM '93*, San Francisco.
- Lenoski y otros 1992 Lenoski, D., Laudon, J., Gharachorloo, K., Weber, W. D., Gupta, A., Hennessy, J., Horowitz, M. y Lam, M. S. (1992). The Stanford Dash multiprocessor. *IEEE Computer*, vol. 25, n.º 3, pp. 63-79.
- Leslie y otros 1996 Leslie, I., McAuley, D., Black, R., Roscoe, T., Barham, P., Evers, D., Fairbairns, R. y Hyden, E. (1996). The design and implementation of an operating system to support distributed multimedia applications, *ACM Journal of Selected Areas in Communication*, vol. 14, n.º 7, pp. 1280-97.
- Li y Hudak 1989 Li, K. y Hudak, P. (1989). Memory Coherence in Shared Virtual Memory Systems. *ACM Transactions on Computer Systems*, vol. 7, n.º 4, pp. 321-59.
- Liedtke 1996 Liedtke, J. (1996). Towards real microkernels, *Comms. ACM*, vol. 39, n.º 9, pp. 70-7. [www](#)
- Linux AFS
- Lipton y Sandberg 1988 Lipton, R. y Sandberg, J. (1988). *PRAM: A scalable shared memory*. Technical Report CS-TR-180-88, Princeton University.
- Liskov 1988 Liskov, B. (1988). Distributed programming in Argus. *Comms. ACM*, vol. 31, n.º 3, pp. 300-12.
- Liskov 1993 Liskov, B. (1993). Practical uses of synchronized clocks in distributed systems, *Distributed Computing*, vol. 6, n.º 4, pp. 211-19.
- Liskov y Scheifler 1982 Liskov, B. y Scheifler, R. W. (1982). Guardians and actions: linguistic support for robust, distributed programs. *ACM Transactions Programming Languages and Systems*, vol. 5, n.º 3, pp. 381-404.
- Liskov y Shrira 1988 Liskov, B. y Shrira, L. (1988). Promises: Linguistic Support for Efficient Asynchronous Procedure Calls in Distributed Systems. En *Proceedings SIGPLAN '88 Conference Programming Language Design and Implementation*. Atlanta.
- Liskov y otros 1991 Liskov, B., Ghemawat, S., Gruber, R., Johnson, P., Shrira, L., Williams, M. (1991). Replication in the Harp File System. En *Proceedings 13th ACM Symposium on Operating System Principles*, pp. 226-38.
- Liu y Albitz 1998 Liu, C. y Albitz, P. (1998). *DNS and BIND*, tercera edición. O'Reilly.
- Liu y Layland 1973 Liu, C. L. y Layland, J. W. (1973). Scheduling Algorithms for Multiprogramming in a Hard Real-Time Environment. *Journal of the ACM*, vol. 20, n.º 1.
- Loepere 1991 Loepere, K. (1991). *Mach 3 Kernel Principles*. Open Software Foundation and Carnegie-Mellon University.
- Lundelius y Lynch 1984 Lundelius, J. y Lynch, N. (1984). An Upper and Lower Bound for Clock Synchronization. *Information and Control* 62, 2/3 (agosto/septiembre), pp. 190-204.
- Lynch 1996 Lynch, N. (1996). *Distributed Algorithms*, Morgan Kaufmann.
- Ma 1992 Ma, C. (1992). *Designing a Universal Name Service*. Technical Report 270, University of Cambridge.
- Macklem 1994 Macklem, R. (1994). Not Quite NFS: Soft Cache Consistency for NFS. *Proceedings of the Winter '94 USENIX Conference*, San Francisco, Ca., enero, pp. 261-278. [www](#)

- Maekawa 1985 Maekawa, M. (1985). A Algorithm for Mutual Exclusion in Decentralized Systems. *ACM Transactions on Computer Systems*, vol. 3, n.º 2, pp. 145-159.
- Maffeis 1995 Maffeis, S. (1995). Adding group communication and fault tolerance to CORBA. En *Proceedings of the 1995 USENIX conference on object-oriented technologies*.
- Malkin 1993 Malkin, G. (1993). *RIP Version 2 – Carrying Additional Information*, Internet RFC 1388. [www](#)
- Marsh y otros 1991 Marsh, B., Scott, M., LeBlanc, T. y Markatos, E. (1991). First-class User-level Threads. En *Proceedings 13th ACM Symposium on Operating System Principles*, pp. 110-21.
- Marzullo y Neiger 1991 Marzullo, K., y Neiger, G. (1991). Detection of global state predicates, In *Proceedings 5th International Workshop on Distributed Algorithms*, Toug, S., Spirakis, P. y Kirousis, L., eds, Springer-Verlag, pp. 254-72.
- Mattern 1989 Mattern, F. (1989). Virtual Time and Global States in Distributed Systems, In *Proceedings Workshop on Parallel and Distributed Algorithms*. Cosnard, M. y otros (eds), Amsterdam: North-Holland, pp. 215-26.
- MBone Software Archives
- McGraw y Felden 1999 McGraw, G. y Felden, E. (1999). *Securing Java*. John Wiley & Sons. [www](#)
- Melliar-Smith y otros 1990 Melliar-Smith, P., Moser, L. y Agrawala, V. (1990). Broadcast Protocols for Distributed Systems. *IEEE Transactions on Parallel and Distributed Systems*, vol. 1, n.º 1, pp. 17-25.
- Menezes 1993 Menezes, A. (1993). *Elliptic Curve Public Key Cryptosystems*, Kluwer Academic Publishers. [www](#)
- Menezes y otros 1997 Menezes, A., van Oorschot, O. y Vanstone, S. (1997). *Handbook of Applied Cryptography*. CRC Press. [www](#)
- Metcalfe y Boggs 1976 Metcalfe, R. M. y Boggs, D. R. (1976). Ethernet: distributed packet switching for local computer networks. *Comms. ACM*, vol. 19, pp. 395-403.
- Mitchell 1995 Handley, M.. *The sdr Session Directory*. [www](#)
- Mills 1995 Mills, D. (1995). Improved Algorithms for Synchronizing Computer Network Clocks, *IEEE Transactions Networks*, junio, pp. 245-54.
- Milojicic y otros 1999 Milojicic, J., Dougulis, F. y Wheeler, R. (1999). *Mobility, Processes, Computers and Agents*, Reading: Addison-Wesley.
- Minnich y Farber 1989 Minnich, R. y Farber, D. (1989). The Mether System: a Distributed Shared Memory for SunOS 4.0. En *Proceedings Summer 1989 Usenix Conference*.
- Mitchell y Dion 1982 Mitchell, J. G. y Dion, J. (1982). A comparison of two network-based file servers. *Comms. ACM*, vol. 25, n.º 4, pp. 233-45.
- Mitchell y otros 1992 Mitchell, C. J., Piper, F. y Wild, P. (1992). Digital Signatures. En *Contemporary Cryptology*. Simmons, G. J. ed., New York: IEEE Press.
- Mogul 1994 Mogul, J. D. (1994). Recovery in Spritely NFS, *Computing Systems*, vol. 7, n.º 2.
- Mok 1985 Mok, A. K. (1985). SARTOR – A Design Environment for Real-Time Systems. *Ninth IEEE COMP-SAC*.
- Morin 1997 Morin, R. (ed.) (1997). *MkLinux: Microkernel Linux for the Power Macintosh*. Prime Time Freeware.
- Morris y otros 1986 Morris, J., Satyanarayanan, M., Conner, M. H., Howard, J. H., Rosenthal, D. S. y Smith, F. D. (1986). Andrew: a distributed personal computing environment. *Comms. ACM*, vol. 29, n.º 3, pp. 184-201.
- Mosberger 1993 Mosberger, D. (1993). *Memory Consistency Models*. Technical Report 93/1 1, University of Arizona.

ty of Arizona.

- OMG 1997e Object Management Group, (1997). *Object Transaction Service Specification*. Framingham, Mass: OMG. [www](#)
- OMG 1998a Object Management Group (1998). *CORBA/IOP 2.3.1 Specification*. Framingham, Mass: OMG. [www](#)
- OMG 1998b Object Management Group (1998). *CORBA Security Service Specification*. Framingham, Mass: OMG. [www](#)
- OMG 1998c Object Management Group (1998). *Notification service Specification*. Framingham, Mass: OMG. Technical report telecom/98-06-15. [www](#)
- OMG 1998d Object Management Group (1998). *CORBA Messaging*. Framingham, Mass: OMG. [www](#)
- OMG 1998e Object Management Group(1998). *Objects by Value*. Framingham, Mass: OMG. [www](#)
- Omidyar y Aldridge 1993 Omidyar, C. G. y Aldridge, A. (1993). Introduction to SDH/SONET. *IEEE Communications Magazine*, vol. 31, pp. 30-3, septiembre.
- Oppen y Dalal 1983 Oppen, D. C. y Dalal Y. K. (1983). The Clearinghouse: a decentralized agent for locating named objects in a distributed environment. *ACM Trans. on Office Systems*, vol. 1, pp. 230-53.
- Orfali y otros 1996 Orfali, R., Harkey, D. y Edwards, J. (1996). *The Essential Distributed Objects Survival Guide*. New York: Wiley.
- Organick 1972 Organick, E. I. (1972). *The MULTICS System: An Examination of its Structure*. Cambridge, Mass: MIT Press.
- Orman y otros 1993 Orman, H., Menze, E., O'Malley, S. y Peterson, L. (1993). A fast and general implementation of Mach IPC in a Network. En *Proceedings Third USENIX Mach Conference*, abril.
- OSF 1997 *Introduction to OSF DCE*. The Open Group. [www](#)
- Ousterhout y otros 1985 Ousterhout, J., Da Costa, H., Harrison, D., Kunze, J., Kupfer, M. y Thompson, J. (1985). A Trace-driven analysis of the UNIX 4.2 BSD file system. En *10th ACM Symposium Operating System Principles*.
- Ousterhout y otros 1988 Ousterhout, J., Cherenson, A., Douglis, F., Nelson, M. y Welch, B. (1988). The Sprite Network Operating System. *IEEE Computer*, vol. 21, n.º 2, pp. 23-36.
- Parker 1992 Parker, B. (1992). *The PPP AppleTalk Control Protocol (ATCP)*. Internet RFC 1378. [www](#)
- Parrington y otros 1995 G. D. Parrington, S. K. Shrivastava, Wheater, S.M. y Little, M. C. (1995). The Design and Implementation of Arjuna, *USENIX Computing Systems Journal*, vol. 8, n.º 3.
- Partridge 1992 Partridge, C. (1992). *A Proposed Flow Specification*. Internet RFC 1363. [www](#)
- Patterson y otros 1988 Patterson, D., Gibson, G y Katz, R. (1988). A Case for Redundant Arrays of Interactive Disks, *ACM International Conf. on Management of Data (SIGMOD)*, pp. 109-116, mayo.
- Pease y otros 1980 Pease, M., Shostak, R. y Lamport, L.(1980). Reaching agreement in the presence of faults. *Journal of the ACM*, vol. 27, n.º 2, abril, pp. 228-34.
- Pedone y Schiper 1999 Pedone, F. y Schiper, A. (1999). Generic Broadcast. En *Proceedings of the 13th International Symposium on Distributed Computing (DISC '99)*, septiembre. [www](#)
- Petersen y otros 1997 Petersen, K., Spreitzer, M., Terry, D., Theimer, M. y Demers, A. (1997). Flexible update propagation for weakly consistent replication. *Proceedings of the 16th ACM Symposium on Operating Systems Principles*, pp. 288-301.
- Peterson 1988 Peterson, L. (1988). The Profile Naming Service. *ACM Transactions Computer Systems*, vol. 6, n.º 4, pp. 341-64.
- Peterson y otros 1989 Peterson, L. L., Buchholz, N. C. y Schlichting, R. D. (1989). Preserving and Using Context Information in Interprocess Communication. *ACM Transactions on Computer Systems*, vol. 7, n.º 3, pp. 217-46.

- Pike y otros 1993
Pike, R., Presotto, D., Thompson, K., Trickey, H. y Winterbottom, P. (1993). The Use of Name Spaces in Plan 9. *Operating Systems Review*, vol. 27, n.º 2, abril 1993, pp. 72-76.
- Popek y Walker 1985
Popek, G. y Walker, B. (eds.). (1985). *The LOCUS Distributed System Architecture*. Cambridge Mass: MIT Press.
- Postel 1981a
Postel, J. (1981). *Internet Protocol*. Internet RFC 791.
- Postel 1981b
Postel, J. (1981). *Transmission Control Protocol*. Internet RFC 793.
- Powell 1991
Powell, D. (ed.) (1991). *Delta-4: a Generic Architecture for Dependable Distributed Computing*. Berlin and New York: Springer-Verlag.
- Preneel y otros 1998
Preneel, B., Rijmen, V. y Bosselaers, A. (1998). Recent developments in the design of conventional cryptographic algorithms, In Computer Security and Industrial Cryptography, State of the Art and Evolution, *Lecture Notes in Computer Science*, n.º 1528, Springer-Verlag, pp. 106-131.
- privacy.nb.ca
International Cryptography Freedom.
- Radia y otros 1993
Radia, S., Nelson, M. y Powell, M. (1993). *The Spring Naming Service*. Technical Report 93-16, Sun Microsystems Laboratories, Inc.
- Rashid 1985
Rashid, R. F. (1985). Network operating systems. En Local Area Networks: An Advanced Course, *Lecture Notes in Computer Science*, 184, Springer-Verlag, pp. 314-40.
- Rashid 1986
Rashid, R. F. (1986). From RIG to Accent to Mach: the evolution of a network operating system. En *Proceedings of the ACM/IEEE Computer Society Fall Joint Conference*, ACM, noviembre.
- Rashid y Robertson 1981
Rashid, R. y Robertson, G. (1981). Accent: a communications oriented network operating system kernel. *ACM Operating Systems Review*, vol. 15, n.º 5, pp. 64-75.
- Rashid y otros 1988
Rashid, R., Tevanian Jr, A., Young, M., Golub, D., Baron, R., Black, D., Bolosky, W. J. y Chew, J. (1988). Machine-Independent Virtual Memory Management for Paged Uniprocessor and Multiprocessor Architectures. *IEEE Transactions Computers*, vol. 37, n.º 8, pp. 896-907.
- Raynal 1988
Raynal, M. (1988). *Distributed Algorithms and Protocols*. Wiley.
- Raynal 1992
Raynal, M. (1992). About Logical Clocks for Distributed Systems. *ACM Operating Systems Review*, vol. 26, n.º 1, pp. 41-8.
- Raynal y Singhal 1996
Raynal, M. y Singhal, M. (1996). Capturing Causality in Distributed Systems. *IEEE Computer*, febrero, pp. 49-56.
- Redmond 1997
Redmond, F. E. (1997). *DCOM: Microsoft Distributed Component Model*. IDG Books Worldwide.
- Reed 1983
Reed, D. P. (1983). Implementing atomic actions on decentralized data. *ACM Transactions on Computer Systems*, vol. 1, n.º 1, pp. 3-23.
- Ricart y Agrawala 1981
Ricart, G. y Agrawala, A. K. (1981). An optimal algorithm for mutual exclusion in computer networks. *Comms. ACM*, vol. 24, n.º 1, pp. 9-17.
- Richardson y otros 1998
Richardson, T., Stafford-Fraser, Q., Wood, K. R. y Hopper, A. (1998). Virtual Network Computing, *IEEE Internet Computing*, vol. 2, n.º 1, enero/febrero, pp. 33-8.
- Ritchie 1984
Ritchie, D. (1984). A Stream Input Output System. *AT&T Bell Laboratories Technical Journal*, vol. 63, n.º 8, pt. 2, pp. 1897-910.
- Rivest 1992
Rivest, R. (1992). *The MD5 Message-Digest Algorithm*. Internet RFC 1321.
- Rivest y otros 1978
Rivest, R. L., Shamir, A. y Adelman, L. (1978). A method of obtaining digital signatures and public key cryptosystems. *Comms. ACM*, vol. 21, n.º 2, pp. 120-6.
- Rodrigues y otros 1998
Rodrigues, L., Guerraoui, R., y Schiper, A. (1998). Scalable Atomic Multicast. En *Proceedings IEEE IC3N '98*. Technical Report 98/257. École polytechnique fédérale de Lausanne.

- Rose 1992
Rose, M. T. (1992). *The Little Black Book: Mail Bonding with OSI Directory Services*. Englewood Cliffs, NJ: Prentice-Hall.
- Rosenblum y Ousterhout 1992
Rosenblum, M. y Ousterhout, J. (1992). The Design and Implementation of a Log-Structured File System, *ACM Transactions on Computer Systems*, vol. 10, n.º 1, febrero, pp. 26-52.
- Rosenblum y Wolf 1997
Rosenblum, D. S. y Wolf, A. L. (1997). A Design Framework for Internet-Scale Event Observation and Notification. En *Proceedings sixth European Software Engineering Conference/ACM SIGSOFT Fifth Symposium on the Foundations of Software Engineering*, Zurich, Switzerland.
- Rowley 1998
Rowley, A. (1998). *A Security Architecture for Groupware*, Doctoral Thesis, Queen Mary and Westfield College, University of London.
- Rozier y otros 1988
Rozier, M., Abrossimov, V., Armand, F., Boule, I., Gien, M., Guillemont, M., Herrman, F., Kaiser, C., Langlois, S., Leonard, P. y Neuhauser, W. (1988). Chorus Distributed Operating Systems. *Computing Systems Journal*, vol. 1, n.º 4, pp. 305-70.
- Rozier, M., Abrossimov, V., Armand, F., Boule, I., Gien, M., Guillemont, M., Herrman, F., Kaiser, C., Langlois, S., Leonard, P. y Neuhauser, W. (1990). *Overview of the Chorus Distributed Operating System*. Technical Report CS/TR-90-25.1, Chorus Systèmes, France.
- Saltzer y otros 1984
Saltzer, J. H., Reed, D. P. y Clarke, D. (1984). End-to-End Arguments in System Design, *ACM Transactions on Computer Systems* vol. 2, n.º 4, pp. 277-88.
- Sandberg 1987
Sandberg, R. (1987). *The Sun Network File System: Design, Implementation and Experience*. Technical Report. Mountain View Calif.: Sun Microsystems.
- Sandberg 1985
Sandberg, R., Goldberg, D., Kleiman, S., Walsh, D. y Lyon, B. (1985). The Design and Implementation of the Sun Network File System. En *Proceedings Usenix Conference*, Portland, Ore.
- Sandhu y otros 1996
Sandhu, R., Coyne, E., Felstein, H. y Youman, C. (1996). Role-Based Access Control Models, *IEEE Computer*, vol. 29, n.º 2, febrero.
- Sane y otros 1990
Sane, A., MacGregor, K. y Campbell, R. (1990). Distributed Virtual Memory Consistency Protocols: Design and Performance. *Second IEEE Workshop on Experimental Distributed Systems*, pp. 91-6, octubre.
- Sansom 1986
Sansom, R. D., Julin, D. P. y Rashid, R. F. (1986). *Extending a capability based system into a network environment*. Technical Report CMU-CS-86-116, Carnegie-Mellon University.
- Santifaller 1991
Santifaller, M. (1991). *TCP/IP and NFS, Internetworking in a Unix Environment*. Reading, Mass: Addison-Wesley.
- Satyanarayanan 1981
Satyanarayanan, M. (1981). A study of file sizes and functional lifetimes. En *Proceedings 8th ACM Symposium on Operating System Principles*, Asilomar, Calif.
- Satyanarayanan 1989
Satyanarayanan, M. (1989). Distributed File Systems. En *Distributed Systems, an Advanced Course*, (Mullender, S. ed.), segunda edición, Wokingham: ACM Press/Addison-Wesley, pp 353-83.
- Satyanarayanan 1989
Satyanarayanan, M. (1989). Integrating Security in a Large Distributed System. *ACM Transactions on Computer Systems*, vol. 7, n.º 3, pp. 247-80.
- Satyanarayanan y otros 1990
Satyanarayanan, M., Kistler, J. J., Kumar, P., Okasaki, M. E., Siegel, E. H. y Steere, D. C. (1990). Coda: A Highly Available File System for a Distributed Workstation Environment. *IEEE Transactions on Computers*, vol. 39, n.º 4, pp. 447-59.
- Saunders 1987
Saunders, B. (1987). The Information Structure of Distributed Mutual Exclusion Algorithms. *ACM Transactions on Computer Systems*, vol. 3, n.º 2, pp. 145-59.
- Scheifler y Gettys 1986
Scheifler, R. W. y Gettys, J. (1986). The X window system. *ACM Transactions on Computer Graphics*, vol. 5, n.º 2, pp. 76-109.

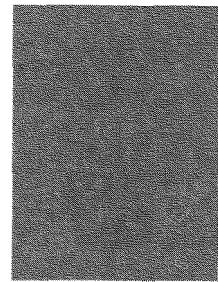
puter Graphics, vol. 5, n.º 2, pp. 76-109.

- Srikanth y Toueg 1987
 Srinivasan 1995a
 Srinivasan 1995b
 Srinivasan y Mogul 1989
 Stallings 1998a
 Stallings 1998b
 Stallings 1999
 Steiner y otros 1988
 Stelling y otros 1998
 Stoll 1989
 Stone 1993
 Sun 1989
 Sun y Ellis 1998
 Tanenbaum 1992
 Tanenbaum 1996
 Tanenbaum y van Renesse 1985
 Tanenbaum y otros 1990
 Terry y otros 1995
TFCC
 Thayer 1998
 Thekkath y otros 1997
 Tokuda y otros 1990
- Srikanth, T. y Toueg, S. (1987). Optimal Clock Synchronization. *Journal ACM*. 34, 3 (julio), pp. 626-45.
 Srinivasan, R. (1995). *RPC: Remote Procedure Call Protocol Specification Version 2*. Sun Microsystems. Internet RFC 1831, agosto. [www](#)
 Srinivasa, R. (1995). *XDR: External Data Representation Standard*. Sun Microsystems. RFC 1832. Network Working Group, agosto. [www](#)
 Srinivasan, V. y Mogul, J. D. (1989). Spritely NFS: Experiments with Cache-Consistency Protocols, *12th ACM Symposium on Operating System Principles*, Litchfield Park, Az., diciembre, pp. 45-57.
 Stallings, W. (1998). *High Speed Networks – TCP/IP and ATM Design Principles*. Upper Saddle River, NJ: Prentice-Hall.
 Stallings, W. (1998). *Operating Systems*, tercera edición. Prentice-Hall International.
 Stallings, W. (1999). *Cryptography and Network Security – Principles and Practice*, segunda edición, Upper Saddle River, NJ: Prentice-Hall.
 Steiner, J., Neuman, C. y Schiller, J. (1988). Kerberos: an authentication service for open network systems. En *Proceedings Usenix Winter Conference*, Berkeley: Calif.
 Stelling, P., Foster, I., Kesselman, C., Lee, C. y von Laszewski, G. (1998). A Fault Detection Service for Wide Area Distributed Computations, *Proceedings 7th IEEE Symposium on High Performance Distributed Computing*, pp. 268-78.
 Stoll, C. (1989). *The Cuckoo's Egg: Tracking a Spy Through a Maze of Computer Espionage*. New York: Doubleday.
 Stone, H. (1993). *High-performance Computer Architecture*, tercera edición. Addison-Wesley. [AAAAAA](#)
 Sun Microsystems Inc. (1989). *NFS: Network File System Protocol Specification*. Internet RFC 1094. [www](#)
 Sun, C. y Ellis, C. (1998). Operational transformation in real-time group editors: issues, algorithms, and achievements. *Proceedings Conference on Computer Supported Cooperative Work Systems*, ACM Press, pp. 59- 68.
 Tanenbaum, A. S. (1992). *Modern Operating Systems*. Englewood Cliffs, NJ: Prentice-Hall.
 Tanenbaum, A. S. (1996). *Computer Networks*, tercera edición. Prentice-Hall International.
 Tanenbaum, A. y van Renesse, R. (1985). Distributed Operating Systems, *Computing Surveys*, ACM, vol. 17, n.º 4, pp. 419-70.
 Tanenbaum, A. S., van Renesse, R., van Staveren, H., Sharp, G., Mullender, S., Jansen, J. y van Rossum, G. (1990). Experiences with the Amoeba Distributed Operating System. *Comms. ACM*, vol. 33, n.º 12, pp. 46-63.
 Terry, D., Theimer, M., Petersen, K., Demers, A., Spreitzer, M. y Hauser, C. (1995). Managing update conflicts in Bayou, a weakly connected replicated storage system. *Proceedings of the 15th ACM Symposium on Operating Systems Principles*, pp. 172-183.
IEEE Task Force on Cluster Computing. [www](#)
 Thayer, R. (1998). *IP Security Document Roadmap*, Internet RFC 2411, noviembre. [www](#)
 Thekkath, C. A., Mann, T. y Lee, E. K. (1997). Frangipani: A Scalable Distributed File System, En *Proc. 16th ACM Symposium on Operating System Principles*, St. Malo, Francia, octubre, pp. 224-237. [www](#)
 Tokuda, H., Nakajima, T. y Rao, P. (1990). Real-time Mach: towards a predictable real-time system. En *Proceedings USENIX Mach Workshop*, pp. 73-82, octubre.

time system. En *Proceedings USENIX Mach Workshop*, pp. 73-82, octubre.

- Wobber y otros 1994
 Wuu y Bernstein 1984
www.bluetooth.com
www.bxa.doc.gov
www.cdk3.net
www.citrix.com
www.cooltown.hp.com
www.cren.net
www.cuseeme.com
www.doi.org
www.handle.net
www.iana.org
www.ietf.org
www.isoc.org
www.microsoft.com
www.microsoft.com I
www.microsoft.com II
www.microsoft.com III
www.mids.org
www.millicent.com
www.omg.org
www.opengroup.org
www.openssl.org
www.pgp.com
www.reed.com
www.rsasecurity.com
www.rsasecurity.com I
www.rsasecurity.com II
www.rtj.org
www.spec.org
www.upnp.com
www.verisign.com
www.w3.org I
www.w3.org II
www.w3.org III
www.w3.org IV
www.w3.org V
- Wobber, E., Abadi, M., Burrows, M. y Lampson, B. (1994). Authentication in the Taos operating system. *ACM Transactions Computer Systems*. 12, 1 (febrero), pp. 3-32. [www](#)
- Wuu, G. T. y Bernstein, A. J. (1984). Efficient Solutions to the Replicated Log and Dictionary Problems. *ACM Proceedings Third Annual Symposium Principles of Distributed Computing*, pp. 233-42.
- The Official Bluetooth SIG Website.* [www](#)
- Bureau of Export Administration, US Department of Commerce, *Commercial Encryption Export Controls*. [www](#)
- Coulouris, G., Dollimore, J. y Kindberg, T. (Eds), *Distributed Systems, Concepts and Design: Supporting material*. [www](#)
- Citrix Corporation. *Server-based Computing White Paper*. [www](#)
- Hewlett-Packard Corporation, *CoolTown nomadic computing project pages*. [www](#)
- Corporation for Research and Educational Networking, *CERN Certificate Authority*. [www](#)
- CU-SeeMe Networks Inc, *Home page*. [www](#)
- International DOI Foundation, *Pages on digital object identifiers*. [www](#)
- Handle system, *Home page*. [www](#)
- Internet Assigned Numbers Authority, *IANA Home Page*. [www](#)
- Internet Engineering Task Force, *Internet RFC Index Page*. [www](#)
- Robert Hobbes Zakon. *Hobbes' Internet Timeline*. [www](#)
- Microsoft Corporation, *NetShow Theater Server Web Page*. [www](#)
- Microsoft Corporation, *Active Directory Services*. [www](#)
- Microsoft Corporation, *Windows 2000 Kerberos Authentication, White Paper*. [www](#)
- Microsoft Corporation, *NetMeeting home page*. [www](#)
- Matrix Information and Directory Services Inc. *Internet Performance*. [www](#)
- Compaq Corporation, *Millicent MicroCommerce system*. [www](#)
- Object Management Group, *Index to CORBA services*. OMG: Framingham, Mass. [www](#)
- Open Group, *Portal to the World of DCE*. [www](#)
- OpenSSL Project, *OpenSSL: The Open Source toolkit for SSL/TLS*. [www](#)
- PGP Home*. [www](#)
- Read, D. P. (2000). *The End of the End-to-End Argument*. [www](#)
- RSA Security Inc., *Home page*. [www](#)
- RSA Corporation (1997). *DES Challenge*. [www](#)
- RSA Corporation (1999). *RSA Factoring Challenge*. [www](#)
- Real-Time for Java TM Experts Group*. [www](#)
- SPEC SFS97 Benchmark*. [www](#)
- Universal Plug and Play home page*. [www](#)
- Verisign Inc., *Home page*. [www](#)
- World Wide Web Consortium, *Home page*. [www](#)
- World Wide Web Consortium, *Pages on the HyperText Markup Language*. [www](#)
- World Wide Web Consortium, *Pages on Naming and Addressing*. [www](#)
- World Wide Web Consortium, *Pages on the HyperText Transfer Protocol*. [www](#)
- World Wide Web Consortium, *Pages on the Resource Description Framework and other metadata schemes*. [www](#)

www.w3.org	VI	www.w3.org	VI
www.w3.org	VII	www.w3.org	VII
www.wapforum.org		www.wapforum.org	
www.wlana.com		www.wlana.com	
Wyckoff y otros 1998		Wyckoff, P., McLaughry, S., Lehman, T. y Ford, D. (1998). T Spaces. <i>IBM Systems Journal</i> , vol. 37, n.º 3.	
Zhang y otros 1993		Zhang, L., Deering, S. E., Estrin, D., Shenker, S. y Zappala, D. (1993). RSVP – A New Resource Reservation Protocol. <i>IEEE Network Magazine</i> , vol. 9, n.º 5.	
Zimmermann 1995		Zimmermann, P. R. (1995). <i>The Official PGP User's Guide</i> , Cambridge, Mass.: MIT Press.	



ÍNDICE ALFABÉTICO

A

aborta, 450
abortion en cascada o encadenado, 456
acceso
 control de, 250-252
 derechos de, 54
 lista de control de, 251
 transparencia, véase transparencia de acceso
ACID, propiedades, 449
ack-implosion, 417
activa, replicación, véase replicación activa
activación, véase objeto, activación
activador, véase objeto, activador
activo, objeto, véase objeto activo
actualización
 perdida, 451
 propagación diferida o perezosa, 565
acuerdo
 de la entrega por multidifusión, 417
 en el consenso y problemas relacionados, 429-430
 problemas, 428
 uniforme, 420
adaptador de objeto, 645
AES (Advanced Encryption Standard), 261
agente móvil, 35
alcanzabilidad, 384
aleatoriedad, 438
algoritmo
 de encriptación triple-DES, 271
 de estado de enlace, 80
 de Nagle, 99
 de rutado por distancia entre vectores, 78
 del depósito agujereado, 590
 alias, véase suplantación
 almacenamiento de objetos persistentes
 Java persistente, 293

sistema Khazana, 293
sistema PerDiS, 293
al-menos-una-vez, semántica de invocación, véase
invocación, semántica
Amoeba
 protocolo de multidifusión, 424
 servidor de ejecución, 203
ancho de banda
Andrew, Sistema de Archivos (AFS), 316-325
 en DCE/DFS, 328
 para Linux, 299
 prestaciones, 325
 soporte de área extensa, 325
anti-entropía, protocolo, véase protocolo anti-entropía
API de Java
 DatagramPacket, 123
 DatagramSocket, 123
 InetAddress, 121
 MulticastSocket, 145
 ServerSocket, 127
 Socket, 127
aplicación
 de telefonía en red, 582
 nivel de, véase niveles
Apollo Domain, 606
Applet, 14
 hilos en, 212
archivo
 correlacionado en memoria, 202
 de recuperación, 513-524
 reorganización, 517
 indexados por posición, véase correlacionado en
 memoria
 replicado, 557
ARP (protocolo de resolución de direcciones), véase
 protocolo ARP

arquitectura
cotilla (de cotilleo), 545-554
mensaje cotilla, 547

almacenamiento de objetos persistentes
Java persistente, 293

de procesamiento simétrico, 197
asíncrona
comunicación, véase comunicación asíncrona
invocación, véase invocación asíncrona
operación, 224-226
RMI, en CORBA, véase CORBA
asíncrono, sistema distribuido, 47-48
ataque
de denegación de servicio, 18
véase seguridad, ataque
ATM (Asynchronous Transfer Mode), 67, 112-114
atómica
consistencia, véase consistenciaatómica
protocolo de consumación, véase protocolode
consumaciónatómica
transacción, véase transacción
atomicidad del fallo, 513
atrapar excepción, véase excepción, atrapar
audio, aplicación de conferencia, 582
autenticación, 246-248
servicio de, 275
servidor de, 273
autentificación, véase autenticación
autoridad de certificación, 270

B
backbone, véase troncal
balance de carga, 42
Bayou, 554-556
chequeo de dependencia, 555
procedimiento de fusión, 555
Bellman-Ford, protocolo de rutado de, véase protocolo,
Bellman-Ford
big-endian, ordenamiento, véase ordenamiento de bits

en transacciones
anidadas, 465
distribuidas, véase transacciones distribuidas,

ARP (protocolo de resolución de direcciones), véase
protocolo ARP

implementación, 463
jerárquico, 470-471
lectura-escritura, 461
promoción, 462
provocando interbloqueos, véase interbloqueo
reglas de operaciones conflictivas, 460-461
tiempo de espera límite, 469
BlueTooth, red inalámbrica, véase red inalámbrica
Bridge, 83
broadcast, véase difusión global

C

caché, 33
coherencia de archivos en, 561
empleo de,
de archivos
completos, 317
en el cliente, 311
en el servidor, 311
escritura a través (directa) de archivo, 311
procedimiento de validación, 312
caja de arena, modelo de protección, 239
calidad de servicio, 42
gestión de, 585-594
negociación de, 587-593
parámetros de, 587
callback, véase devolución de llamada
cambio de contexto, 209
camino virtual (en redes ATM), 112
canal
fiable, 401
seguro, 57
virtual (en redes ATM), 112

DNS (Sistema de Nombres de Dominio), 346-352
Ethernet, 105-109
GNS (Servicio de Nombres Global), 356-359
Gossip, arquitectura, 545-554
Invocación de métodos remotos en Java,
182-190
Ivy, 622-626
Kerberos, 275-280
LAN inalámbrica IEEE 802.11, 109-112
Mach, 665-685
Millicent, protocolo, 284-287
Munin, 630-632
Needham-Schroeder, protocolo, 273-275
NFS (Network File System), 305-316
NTP (Network Time Protocol), 375-377
SSL (Secure Sockets Layer), 280-284
Sun RPC, 173-175
X.500, Servicio de directorio, 359-363
catálogo (suite) de cifrado, 282
caudal
adaptación de, 596
multimedia, 584
anchos de banda usuales, 583
ráfagas de carga, 589
caudales de datos
isócronos, 584
temporizados, 584
véase red, caudales de datos
causal, consistencia, véase consistencia causal
CDR, véase CORBA Common Data Representation
certificado, 248-250
autoridad, véase autoridad de certificación
formato estándar X.509, 269
Chorus, 229
CIDR (rutado entre dominios sin clase), 93
cifrador
de bloque, 256-257
de encadenamiento de bloques, 256
de flujo, 257
circuito virtual, 76
clave
de sesión, 246
pública, 245
certificado de, 249
criptografía de, 261-264
privada, 245
cliente
ligero (delgado), 36
servidor
comunicación, 135-143
modelo, 32
variaciones, 34-40
clientes, 8
cluster de computadores, 203
Coda, sistema de archivos, 556-563

disponible (AVSG), 557
vector de versión (CVV), 558
grupo de volúmenes de almacenamiento
(VSG), 557
codec (codificador/descodificador), 585
código
de autenticación de mensaje (MAC), 266
descargado, 14
móvil, 35
amenazas a la seguridad, 240
coherencia de la memoria compartida distribuida,
615-616
cola de retención, 420
comercio electrónico, necesidades de seguridad, 241
commit, véase consumado
como-máximo-una-vez, semántica de invocación, véase
invocación, semántica
compactación automática de memoria, 160-161
distribuida, 171-172
en Java, 171
utilización de concesiones, 172
en un sistema de objetos distribuido, 163
local, 160
compartición
de carga, 207
de recursos, 7-8
falsa, 618
competencia de accesos a memoria, 627
compresión, 584
de datos para multimedia, 584
computación
independiente de posición, 6
móvil, 5-7
nómada, 6
ubícuo, 6
computadora de red, 36
comunicación
asíncrona, 119
cliente-servidor, 135-143
de grupo, 143-147
en grupo virtualmente síncrona, 537
entre procesos
características, 119
en UNIX, 147-150
fiable, 53
integridad, 54
síncrona, 119
soporte del sistema operativo para la, 216-223
validez, 54
concentrador, 83
Ethernet, 83
concesiones, 187
en compactación automática de memoria
distribuida en Jini, véase Jini
para devoluciones de llamada, 187

conurrencia, 21-22
 control de, 451-455
 comparación de métodos, 483
 con bloqueos, véase actualización de bloques
 perdidos
 en el servicio de control de concurrencia de CORBA, 462
 en transacciones distribuidas, 503-506
 operaciones conflictivas, 453
 optimista, véase optimista, control de concurrencia
 por ordenamiento de marcas temporales, véase ordenamiento por marcas temporales
 recuperación inconsistente, 452
 reglas de conflicto de operaciones, 453
 de actualizaciones sobre archivos, 297
 conectar y ejecutar, universal, véase plug and play universal
 conexión persistente, 141
 confusión (en criptografía), 258
 conmutación
 de paquetes, red de, véase red, conmutación
 operaciones de, 544
 conmutador Ethernet, 83
 consenso, 428-438
 con relación a otros problemas, 431
 en un sistema síncrono, 432
 por quorum, 570-572
 resultado de imposibilidad para un sistema asíncrono, 436
 consistencia
 atómica, 614
 causal, 632
 de admisión, 632
 de alcance, 633
 de datos
 compartidos, 613
 replicados, 529
 de procesador, 632
 débil, 633
 interactiva, 431
 secuencial, 540
 de la memoria compartida distribuida, 615
 consumado, 449
 contexto de nombres (nominación), 343
 control
 de admisión, 593-594
 de congestión, véase red, control de congestión
 de flujo, 99
 cookie, 308
 copia
 en escritura, 204
 en Mach, 680-681
 primaria, 316
 CORBA

arquitectura, 644-647
 adaptador de objeto, 645
 esqueleto, 646
 intermediario de petición de objetos (ORB), 645
 proxy, 646
 caso de estudio, véase casos de estudio, CORBA
 CDR (Common Data Representation), 130-132
 correspondencia con el lenguaje, 652
 ejemplo de cliente y servidor, 641-644
 empaquetado, 132
 extensiones, 650
 objetos por valor, 650
 RMI asíncrono, 651
 interfaz
 de esqueleto dinámico, 647
 de invocación dinámica, 647
 intermediario de petición de objetos (ORB), 646
 invocación de método remoto, 638-644
 asíncrona, 651
 devolución de llamada, véase devolución de llamada
 lenguaje de definición de interfaces, 647-651
 atributo, 649
 herencia, 650
 interfaz, 647
 método, 648
 módulo, 647
 parámetros y resultados, 639
 pseudo-objeto, 641
 tipo, 649
 marshalling, véase CORBA, empaquetado
 modelo de objeto, 639
 protocolo
 general Inter-ORB (GIOP), 638
 interoperable Inter-ORB (IIOP), 638
 referencia
 a objeto remoto, véase CORBA, IOR
 interoperable de objeto (IOR), 651
 persistente, 652
 transitoria, 652
 repositorio
 de implementación, 646
 de interfaz, 651
 servicios, 653-660
 de control de concurrencia, 653
 de eventos, 657-658
 de intercambio (comercio), 653
 de nombres, 654-657
 de notificación, 658-659
 de objetos persistentes, 654
 de seguridad, 660
 de transacciones, 653
 correlacionador de puertos, véase también enlazador, portmapper
 cortafuegos, 254

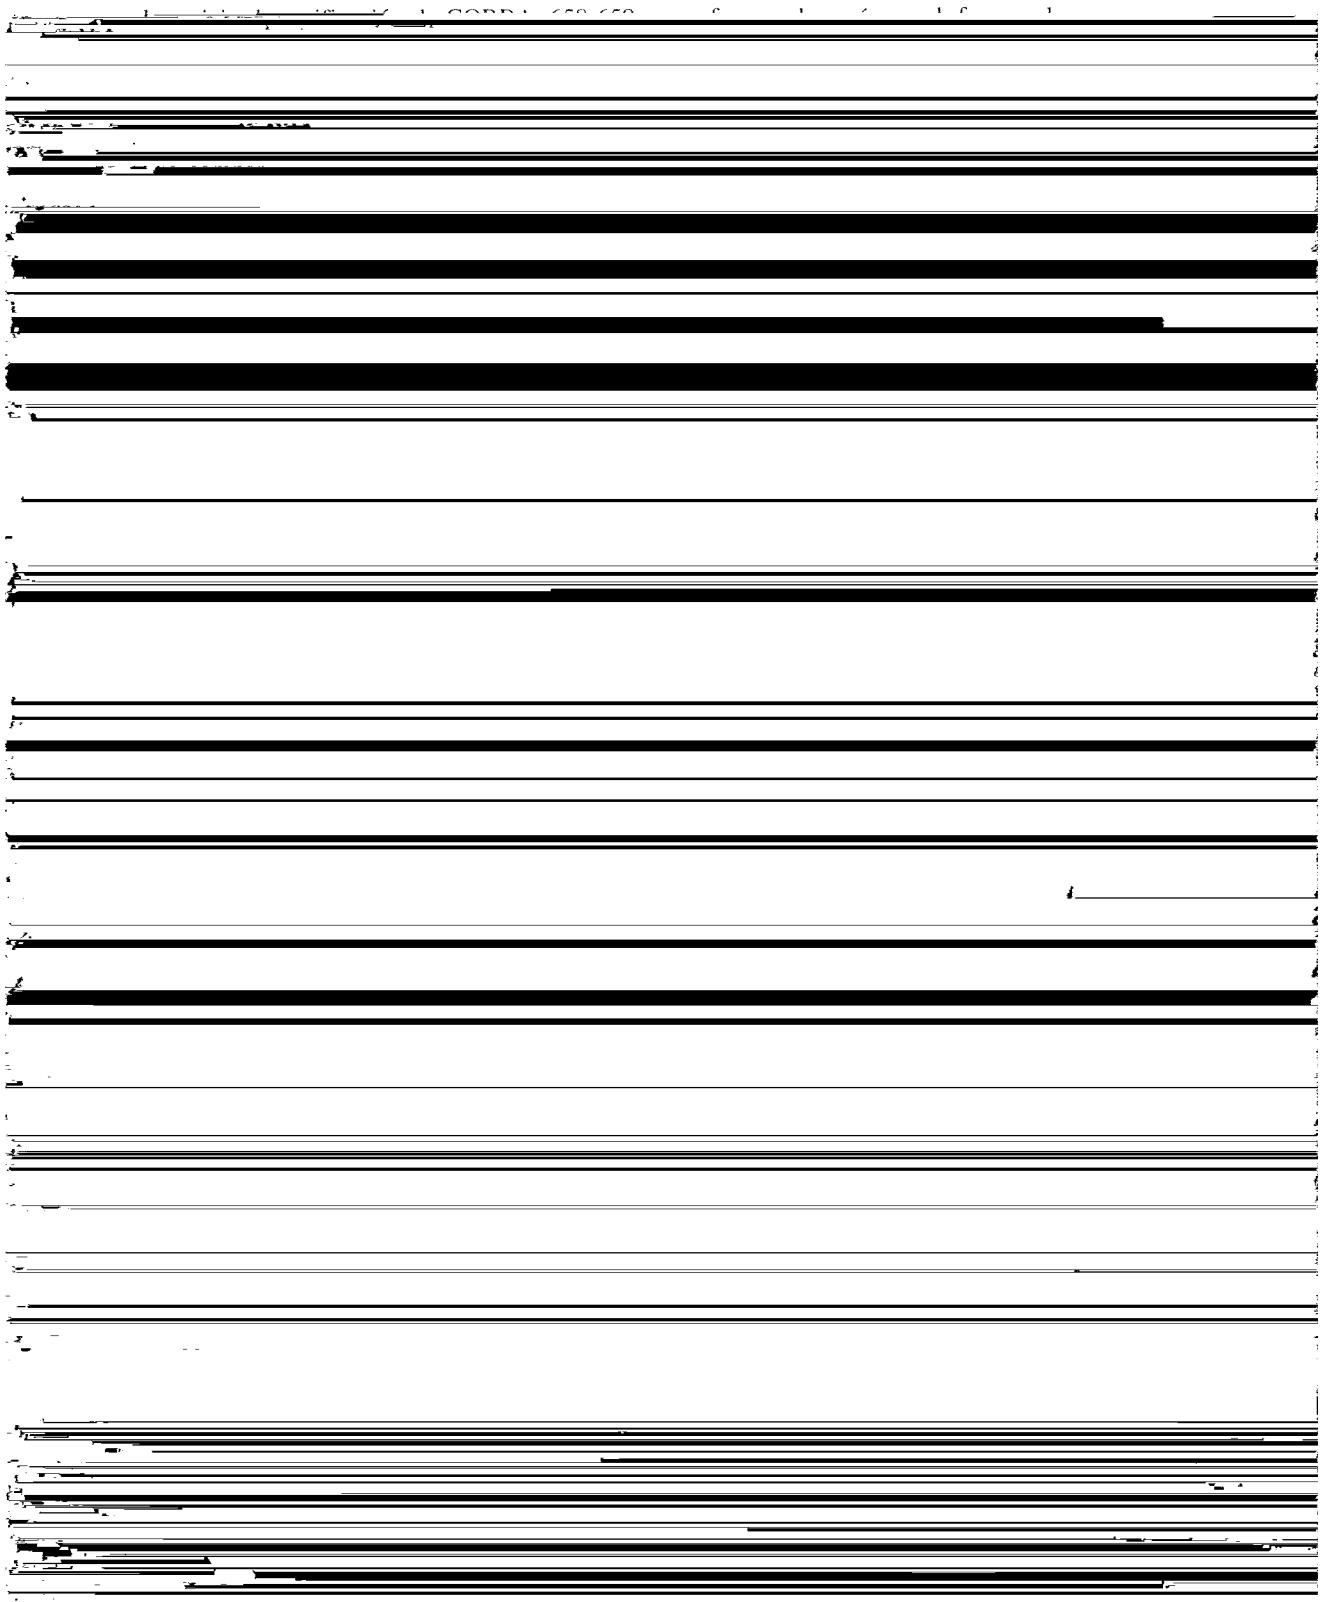
corte, 382
 consistente, 382
 frontera, 383
 credenciales, 252-254
 criptografía, 254-264
 asimétrica, 255
 prestaciones de los algoritmos, 271
 simétrica, 255
 y política, 271
 CSMA/CA, véase red, CSMA/CA
 CSMA/CD, véase red, CSMA/CD

D

datagrama, 76
 delegación (de derechos), 253
 denegación de servicio, 57
 depuración de programas distribuidos, 382
 DES (Data Encryption Standard), 259
 desafío de autenticación, 247
 descarga de código en Java RMI, véase Java, RMI,
 descarga de clases
 descubrimiento, servicio, véase servicio de descubrimiento
 desempaquetado, 130
 detección
 de colisiones, 107
 de fallo, 20
 detector de fallo, 401-403
 para resolver el consenso, 437
 determinación de terminación, 381
 devolución de llamada
 en invocación de métodos remotos en CORBA, 644
 Java, 187
 promesa de, 321
 difusión
 (en criptografía), 256
 global, 415
 dirección
 de Internet, API de Java, 121
 de socket, véase socket
 de transporte, 75
 disponibilidad, 21
 dispositivos móviles, 37
 distribuidor, 168
 DNS, véase Sistema de Nombres de Dominio
 dominio
 de nombres, 341
 de protección, 250
 dos-fases, protocolo de consumación en, véase protocolo de consumaciónatómica
 DSL (línea de subscriptor digital), 67
 DSM, véase memoria compartida distribuida

E

ejecución, una, 384
 ejecuciones estrictas, 456
 elección, 411-415
 algoritmo del abusón, 413
 para procesos en un anillo, 411
 empaquetado, 130
 emulación de un sistema operativo, 228
 encaminador, véase router
 encapsulación, 72
 encriptación, 56
 por curvas elípticas, 263
 enemigo, 55
 amenazas de seguridad por un, 56
 enlace
 de datos, nivel de, véase niveles
 de un socket, 147
 enlaces (vínculos), 9
 enlazador, 169
 portmapper, 175
 rmiregistry, 184
 enmascaramiento de fallo, 20
 ensamblado de paquetes, 74
 entorno de ejecución, 200
 envío no bloqueante, 120
 equidad, condición de, 404
 equivalencia secuencial, 452
 escalabilidad, 19-20
 escritura prematura, 456
 espacio
 de direcciones, 199
 herencia, 204
 región, 201
 compartida, 202
 suplantación, 211
 de nombres, 340
 de tuplas, 611
 especificación de caudal, 591
 espontánea, red, 37-40
 esqueleto, 168
 en CORBA
 estado
 de transacción, 514
 global, 381-389
 consistente, 384
 estable, 384
 instantánea, 385-389
 predicado, 384
 estándares IEEE 802, 104
 Ethernet, 105-109
 evento, 175-182
 anunciante, 179
 concurrencia, 378-379
 en el servicio de eventos de CORBA, 657-658



- heterogeneidad, 15
 servicio de nombres, 342
híbrido
 modelo de consistencia de memoria, *véase* modelo de consistencia de memoria híbrido
 protocolo criptográfico, *véase* protocolo criptográfico híbrido
hilo, 205-216
 arquitectura multi-hilo, 207
 asociación de trabajadores, 207
 C, 210
 comparación con proceso, 208
 conmutación entre, 209
 coste de creación, 210
 de nivel de núcleo, 214
 en el cliente, 208
 en el servidor, 206
 en un multiprocesador, 208
 implementación, 213-216
 Java, 210-211
 planificación, 213
 POSIX, 210
 programación con, 210-211
 recibe bloqueante, 120
 sincronización, 212
historial, 369
 de operaciones del servidor en petición-respuesta, 138
 global, 384
histórico
 almacén de archivo estructurado en, 329
 registro, 515-518
HTML, 11
HTTP, 14
 prestaciones de, 221
 sobre una conexión persistente, 225
hub
 Ethernet, *véase* concentrador Ethernet
- I**
- IANA (Internet Assigned Numbers Authority), 75
IDEA (International Data Encryption Algorithm), 261
identificador, 336
 de grupo de archivo, 305
 único de archivo (UFID), 300
IDL, *véase* lenguaje de definición de interfaz
IIOP (protocolo interoperable Inter-ORB), *véase* CORBA, IIOP
 inalámbrica, red, *véase* red, inalámbrica
 inanición, 404
 i-nodo, número, *véase* número de i-nodo
 integridad
 de la entrega por multidifusión, 417
 de las comunicaciones fiables, 53
 en el consenso y los problemas relacionados, 429-430
 intenciones, lista de, 514
 interacción, modelo de, 45-50
 interbloqueo, 466-469
 con bloqueos lectura-escritura, 466
 definición, 467
 detección, 468
 distribuido, 506-513
 caza de arcos, 509-511
 prioridades de trasacciones, 511
 interbloqueos fantasma, 508
 grafo espera-por, 467
 prevención, 468
 tiempos límite de espera, 469
 interconexión de sistemas abiertos, *véase* Modelo de Referencia OSI
interfaz, 155-157
 de red, nivel de, *véase* niveles del servicio, 158
 en un sistema distribuido, 157
 lenguaje de definición, *véase* lenguaje de definición de interfaz
 remota, 158
 en Java RMI, 182
 intermediario de petición de objetos (ORB), *véase* CORBA
Internet, 3
 estadísticas de tráfico, 64
 Protocol, *véase* IP
 protocolos de encaminado, 91
 interredes, 81-84
 interrupción
 interna de llamada al sistema, 199
 software, 209
Intranet, 4
 invoca una operación, 8
invocación
 de métodos remotos, 8
 caso de estudio Java, 182-190
 CORBA, *véase* CORBA
 distribuidor, 168
 esqueleto, 168
 filtrado de duplicados, 164
 implementación, 166-171
 módulo
 de comunicación, 167
 de referencia remota, 167
 nula, 218
 paso de parámetros y de resultados en Java, 183
 prestaciones de, *véase* invocación, mecanismo de proxy, 167
 reintento de mensaje de petición, 164
 retransmisión de respuestas, 164

semántica, 164
transparencia, 165
mecanismo de, 196
asíncrona, 224
persistente, 225
dentro de un computador, 222-223
latencia, 218
planificación y comunicación como parte la, 196
prestaciones, 217-223
soporte del sistema operativo, 216-226
tasa de productividad, 219
semántica de
al menos una vez, 165
como máximo una vez, 165
pudiera ser, 164
IOR, *véase* CORBA, referencia interoperable de objeto IP, 89-97
API, 119-128
direcciónamiento, 86-89
multidifusión, 144-146
API de Java, 144
asignación de direcciones, 145
modelo de fallo, *véase* modelo de fallo de la multidifusión IP
router, 144
trucado, 90
IPC, *véase* comunicación entre procesos
IPv4, 86
IPv6, 93-96
ISDN, 81
ISIS, 537
isócronos, caudales de datos, *véase* caudales de datos isócronos
Ivy, 622-626

J

Java
hilo, *véase* hilo, Java
invocación de métodos remotos (RMI), 182-190
devolución de llamada, *véase* devolución de llamada
descarga de clases, 184
diseño e implementación, 188-189
empleo de la reflexión, 188
excepción, 166
interfaz remota, 182
paso de parámetros y resultados, 183
programa cliente, 186
programa servidor, 184
RMiregistry, 184
reflexión, 133
seguridad en, 240
serialización de objetos, 132-134

Jini
concesiones, 172
especificación de eventos distribuidos, 180-182
servicio de descubrimiento, 353-356
concesiones, 356
jitter, *véase* fluctuación

K

Kerberos, 275-280
autenticación para NFS, 313

L

L4, micronúcleo, 230
Lamport, marca temporal, *véase* marca temporal, Lamport
LAN
inalámbrica IEEE 802.11, *véase* red, LAN
inalámbrica IEEE 802.11
véase red, área local
lanza excepción, 160
latencia, 46
LBAP, *véase* modelo de llegada lineal de procesos
LDAP, *véase* protocolo de acceso a directorio de peso ligero
lectura sucia, 455
lenguaje de definición de interfaz, 157
CORBA, *véase* CORBA, lenguaje de definición de interfaz
ejemplo
CORBA IDL, 159
Sun RPC, 173
liberación de consistencia, 626-632
Linda, 611
linealizabilidad, 539
linealización, 384
little-endian, ordenamiento, *véase* ordenamiento de bits llamada
a procedimiento remoto, 172-175
de peso ligero, 222
con cola, 226
nulo, 218
prestaciones de, *véase* invocación, mecanismo de protocolos de intercambio, 139
hacia atrás, *véase* upcall

M

MAC, *véase* código de autenticación de mensaje
Mach, 665-686
comunicación, 672-675
en red, 676-678

conjunto de puertos, 669
derecho de puerto, 669
gestión de memoria, 678-684
memoria virtual, 668
mensaje, 669
nominación, 669
objeto de memoria caché, 669
paginador externo, 681-682
puerto, 669
de red, 677
servidor de red, 677
tarea, 668
MAN, *véase* red, área metropolitana
máquina
de estado, 531
virtual, 16
marca temporal
de Lamport, 379
vectorial, 380
ordenamiento de, 476-482
conflictos de operaciones, 477
en transacciones distribuidas, 504
multiversión, 480-481
regla de escritura, 477
regla de lectura, 478
máxima unidad de transferencia (MTU), 106
MD5, algoritmo de resumen de mensajes, 269
mecanismo de seguridad, *véase* seguridad
memoria
compartida distribuida, 605-636
cuestiones de diseño e implementación, 610-619
datos inmutables alojados en, 611
escritura
actualizante, 616
invalidante, 616
gestor
centralizado, 623
distribuido, 624-626
granularidad, 617-618
modelo
de consistencia, 612-616
de sincronización, 612
opciones de actualización, 616-617
orientada
a bytes, 610
al objeto, 611
thrashing (fustigamiento), 619
virtual
en Mach, 678-684
paginador externo, 681-681
mensaje
de petición, 139
de respuesta, 139
perdida, 138
destino de, 120

metadatos, 295
método factoría, 168
micrónucleo, 227-228
comparación con el núcleo monolítico, 229
Middleware, 16
soporte del sistema operativo para el, 195
y heterogeneidad, 157
migración de proceso, *véase* proceso, migración
Millicent, protocolo, *véase* protocolo Millicent
mime, tipo, 141
mobileIP, *véase* red, mobileIP
modelo
de consistencia de memoria
híbrido, 632
uniforme, 632
de fallo, 50-54
de la multidifusión IP, 145
de TCP, 127
de transacciones, 446
de UDP, 123
del protocolo
de consumación atómica, 496
de petición-respuesta, 138
de interacción, 45-50
de llegada lineal de procesos (LBAP), 589
de objetos distribuidos, *véase* objeto, modelo de referencia OSI, 73
de seguridad, 54-58, *véase* seguridad fundamental, 44-48
modelos
arquitectónicos, 28-44
fundamentales, 44-58
modo
supervisor, 199
usuario, 199
módulo de referencia remota, *véase* invocación de métodos remotos
moldeado del tráfico (para datos multimedia), 590
móvil, computación, *véase* computación móvil
MPEG, compresión, 589
de vídeo, 584
MTU, *véase* máxima unidad de transferencia
multicast, *véase* multidifusión
multidifusión, 415-428
atómica, 421
básica, 417
de grupo, 144, 415
fiable, 417-421
IP, *véase* IP, multidifusión
no fiable, 145
ordenado, 421-428
para datos
con alta disponibilidad, 143
replicados, 147
para grupos solapados, 427

para notificación de eventos, 143
 para servicios de descubrimiento, 143
 para tolerancia a fallos, 143
 reparto ordenado
 causalmente, 421
 en forma FIFO, 421
 totalmente, 421
 multimedia
 aplicaciones, 112
 basada en web, 582
 multiprocesador
 memoria
 compartida, 197
 NUMA (Acceso a Memoria No Uniforme), 607
 distribuida, 607
 soporte de Mach para, 666
 Munin, 630-632

N

navegación
 por multidifusión, 344
 controlada por servidor, 344
 Needham-Schroeder, protocolo, 273-275
 Nemesis, 229
 netmsgserver, *véase* Mach, servidor de red
 Network
 File System (NFS), 305-316
 autenticación Kerberos, 313
 automounter, 310
 mejoras, 326
 montado estático y flexible, 309
 prestaciones, 314
 pruebas de laboratorio, 314
 servicio de montado, 307
 Spritley NFS, 326
 VFS (sistema de archivos virtual), 306
 v-nodo, 306
 WebNFS, 327
 Information Service (NIS), 542
 NIS, *véase* Network Information Service
 niveles (capas), *véase* también protocolos
 de aplicación, 72
 de enlace de datos, 74
 de interfaz de red, 74
 de presentación, 74
 de red, 74
 de sesión, 74
 de transporte, 74
 físico, 73
 NNTP, 84
 no repudio, 242
 nombre, 336

componente, 340
 de host, 338
 no ligado, 340
 puro, 336
 prefijo, 340
 nonce, *véase* ocasión
 notas históricas
 aparición de la criptografía moderna, 237
 redes, 62
 seguridad, evolución de las necesidades de, 236
 sistemas de archivos distribuidos, 292
 notificación, *véase* evento, notificación
 NQNFS (Not Quite NFS), 327
 NTP (Network Time Protocol), 375-377
 núcleo, 199
 monolítico, 227
 número de i-nodo, 306

O

objeto, 40
 activación de, 169
 activo, 169
 CORBA, *véase* CORBA
 de memoria, *véase* Mach, objeto de memoria
 distribuido, 161
 comunicación, 159-172
 modelo, 161
 factoría, 168
 interfaz, 40
 modelo de, 159
 pasivo, 169
 persistente, 169
 en el servicio de objetos persistentes de
 CORBA, 654
 protección, 54
 referencia a, 160
 referencia remota, 162
 remoto, 162
 ubicación, 170
 ocasión, 274
 ocurrió antes, 378
 OMG (Object Management Group), 638
 open system, *véase* sistema abierto
 openness, *véase* extensibilidad
 operación
 atómica, 444
 idempotente, 138
 multidifunde, 143
 operaciones
 conflictivas, *véase* concurrencia, control de
 sobre archivos en
 el modelo de servicio
 de archivos plano, 300

de directorio, 304
 un servidor NFS, 308
 UNIX, 296
 optimista, control de concurrencia, 472-476
 comparación de la validación hacia delante y hacia
 atrás, 476
 en transacciones distribuidas, 505
 fase de actualización, 473
 fase de trabajo, 473
 inanición, 476
 validación, 473
 hacia atrás, 474
 hacia delante, 475
 orca, 609
 ordenamiento
 causal, 378
 de la gestión de peticiones, 532
 del reparto por multidifusión, 421
 de bits
 big-endian, 129
 little-endian, 129
 del emisor, 121
 FIFO
 de la entrega por multidifusión, 420
 de la gestión de peticiones, 532
 total, 369
 de la entrega por multidifusión, 421
 de la gestión de peticiones, 532
 OSI Modelo de Referencia, *véase* Modelo de
 Referencia OSI

P

paginador externo, 681-682
 paquetes, *véase* red, paquetes
 parámetros de entrada y de salida, 157
 partición de red, 401
 primaria, 534
 virtual, 572-575
 pasarela, *véase* gateway
 paso de mensajes, 118
 Petal, sistema de disco virtual distribuido, 331
 petición-respuesta, protocolo de, 136-137
 damePetición, 136
 empleo de TCP, 139
 envíaRespuesta, 136
 hazOperación, 136
 historia de operaciones del servidor, 138
 mensaje de, 137
 de respuesta perdidos, 138
 petición duplicado, 138
 modelo de fallo, 138
 tiempo límite de espera, 138
 Plan 9, 343

planificación
 apropiativa, 213
 de recursos por el mejor esfuerzo, 585
 de tiempo real, 595
 no apropiativa, 213
 planificador, activación, 215
 plataforma, 195
 de computación fiable, 243
 plug and play universal, 353
 política de seguridad, *véase* seguridad
 POP, 84
 port mapper, *véase* correlacionador de puertos
 POTS (antiguo sistema telefónico simple), 70
 PPP, 86
 presentación, nivel de, *véase* niveles
 Pretty Good Privacy (PGP), 272
 primer camino abierto más corto, 91
 principal, 54
 procesador virtual, 214
 proceso, 199-216
 amenazas a, 55
 correcto, 402
 coste de creación, 210
 creación, 202-205
 de nivel de usuario, 199
 ligero de Solaris, 214
 migración, 204
 multi-hilo, 200
 promedio de tolerancia a fallos, 374
 promesa, 225
 de devolución de llamada, *véase* devolución de
 llamada
 propagación de actualizaciones ansiosa o impaciente,
 565
 propiedad
 de seguridad, 385
 de uniformidad, 420
 protección, 198-199
 por el núcleo, 199
 y lenguaje de tipos seguro, 199
 protocolo, 71-77
 anti-entropía, 554
 ARP, 90
 Bellman-Ford, protocolos de rutado, 78
 composición dinámica, 217
 conjunto de, 73
 criptográfico híbrido, 264
 de acceso a directorio de peso ligero, 363
 de consumaciónatómica, 465-503
 modelo de fallo, *véase* también modelo de fallo
 en dos fases, 496-499
 acciones de tiempo de espera límite, 497
 prestaciones, 498
 recuperación, 520-523
 transacción distribuida, 499-503

consumación jerárquica, 501
consumación plana, 502

FTP, 74
HTTP, 74
IP, 74
IPv4, 86
IPv6, 86
mobileIP, 96-97
niveles (capas), véase también niveles
NNTP, 84
pila de, 73
POP, 84
PPP, 86
simple de servicio de descubrimiento, 353
SMTP, 8
soporte del sistema operativo para los, 217
SSL, 74
TCP, 86
TCP/IP, 84
transporte, 74
UDP, 86
WAP, 85

Proxy, 167
en CORBA, 645
publica-suscribe, 176
pudiera ser, semántica de invocación, véase invocación, semántica
puente, véase bridge
puerto, 75
de servidor, 122
en Mach, véase Mach, puerto
punto de control, establecimiento de, 517

Q

QoS, véase calidad de servicio

R

RAID (conjuntos redundantes de discos asequibles), 330
RAM encauzada, 632
RDSI, véase ISDN
Real Time Transport Protocol (RTP), 70
realización, de accesos a memoria, 628
recolección de basura, véase compactación automática de memoria
reconocimiento negativo, 419
recuperación, 513-523
abortos encadenados 456
de un aborto, 455
del protocolo de consumación en dos fases, 520-523
desde un fallo, 21

ejecuciones estrictas, 456
escritura prematura, 456
estado de transacción, 514
históricos, 515-518
inconsistente, 452
lectura sucia, 455
lista de intenciones, 514
transacciones anidadas, 521
versiones sombra, 518-519

recurso, 2
ancho de banda, 581
invocación sobre un, 196

red
ancho de banda total del sistema, 63
área
extensa, 66
local, 66
metropolitana, 67
ATM (Asynchronous Transfer Mode), 112-114
BlueTooth, red inalámbrica, 67
bridge, 83
comutación
de circuitos, 70
de paquetes, 70
control de congestión, 80
CSMA/CA, 111
CSMA/CD, 106
de área local, véase red, área local
dirección de transporte, 75
ensamblado de paquetes, 74
estándares, 104
Ethernet, 105-109
flujos de datos, 69
frame relay, 71
gateway, 68
inalámbrica, 67
Internet, 84-104
LAN inalámbrica IEEE 802.11, 109-112
latencia, 63
multidifusión IP, 83
nivel de, véase niveles
paquetes, 69
parámetros de prestaciones, 63
privada virtual (VPN), 103
protocolo, véase protocolo
puerto, 75
requisitos, 63-65
de escalabilidad, 64
de fiabilidad, 64
de seguridad, 64
router, 82
rutado, 77-80
tasa de transferencia de datos, 63
TCP/IP, 84
túneles, 83

WaveLAN, 104
redundancia, 21
referencia a objeto remoto (ROID), 162
en CORBA, 651
reflexión en Java, 134
RMI, 188
región, véase espacio de direcciones
registrar el interés, 176
reloj
acuerdo, 371
del computador, 369
deriva, 370
erróneo, 372
exactitud, 371
global, 2
lógico, 379
matriz de, 381
monotonicidad, 371
precisión, 371
resolución, 370
sesgo, 370
sincronización, véase sincronización de relojes
vector de, 380

replicación, 527-577
activa, 543-545
consenso del quórum, 570-572
copias disponible, 566-568
con validación, 568-570
de archivos, 297
partición virtual, 572-575
pasiva, véase replicación primario-respaldo
primario-respaldo, 541-543
transaccional, 563-567
transparencia, 529

repositorio
de implementación en CORBA, véase CORBA
de interfaz, en CORBA, véase CORBA, repositorio de interfaz
representación externa de datos, 128-135
requisitos de diseño, 41
resguardo, procedimiento de, 172
en CORBA, 645
resolución de nombres, 336
Resource Reservation Protocol (RSVP), 70
respuesta, mensaje de, 138
resumen de un mensaje, 247
retransmisión de tramas, véase red, frame relay
retrollamada, véase devolución de llamada
RFC, 17
RIP
(protocolo de información de router), 80-1, 80-2, 91
RMI, véase invocación de métodos remotos
RMIREGISTRY, 184

Router 81, 82
RPC
de peso ligero, 222
protocolos de intercambio de, 139
véase llamada a procedimiento remoto
RR, 139
RRA, 139
RSA, algoritmo de encriptación de clave pública, 262
RSVP, protocolo para reserva del ancho de banda, 593
rutado, véase red, rutado

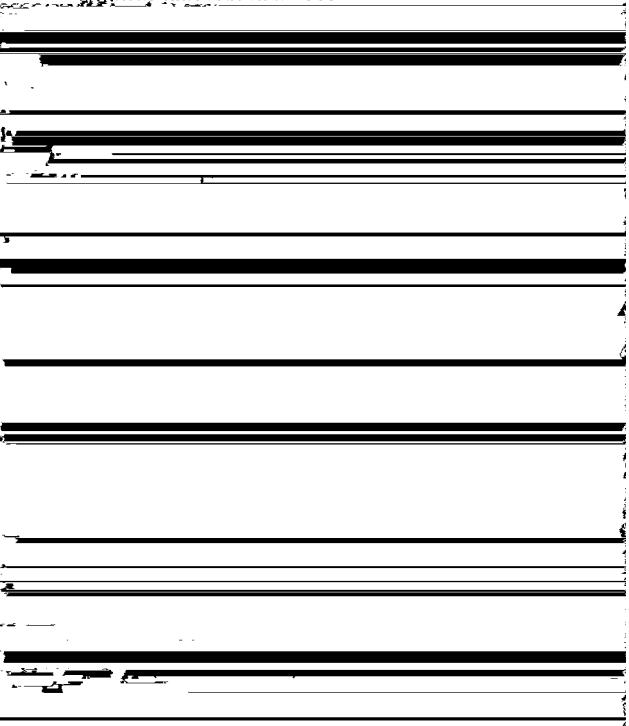
S

sala de contratación, 177
scrip, véase vale
sección crítica, 403
secuenciabilidad de una copia, 563
secuenciador, 424
Secure Sockets Layer (SSL), 280-284
seguridad, 18
«Alice y Bob», nombres para los protagonistas, 238
amenazas
desde el código móvil, 239
fugas, modificación, vandalismo, 238
ataque
del cumpleaños, 268
del hombre entre medias, 239
por denegación de servicio, 239
por fisingo, 239
por fuerza bruta, 255
por modificación de mensaje, 239
por retransmisión, 239
por suplantación, 238
por texto en claro escogido, 263
en el servicio de seguridad de CORBA, 660
en Java, 239
guías de diseño, 242
mecanismo de, 236
modelo de, 54-58
modelos de fuga de información, 240
plataforma de computación fiable, 244
política de, 236
Transmission Layer Security (TLS), véase Secure Sockets Layer, 280
semántica de actualización, 298
serialización, 132
de objetos en Java, véase Java
servicio, 8
con alta disponibilidad, 545-563
de archivos planos, 300
de descubrimiento, 352
alcance, 353
búsqueda, 353
Jini, 354-356

- Ticket
 de autenticación, 246
 Granting Service (TGS), 276
 tiempo, 367-381
 Atómico Internacional, 370
 de ejecución, para datos multimedia, 69
 lógico, 49
 Universal Coordinado (UTC), 371
 tiempos de espera límite, 50
 Tiger, servidor de archivos de vídeo, 598
 TLS, véase Secure Sockets Layer
 timeouts, véase tiempos de espera límite
 tolerancia a fallos, 21
 totalmente ordenada, multidifusión, véase multidifusión
 Trampolining, 668
 transacción, 447-459
 aborta, 448
 abortaTransacción, 450
 abreTransacción, 450
 ACID, propiedades, 449
 anidada, 457-459
 bloqueo, 465
 protocolo de consumación en dos fases, 499-503
 acciones por timeout, 503
 recuperación, 521
 cierraTransacción, 450
 con datos replicados, 563-575
 consuma, 449
 control de concurrencia, véase control de concurrencia
 distribuida
 anidada, 492
 control de concurrencia, 503-506
 bloqueo, 503
 optimista, 505
 por ordenamiento de marcas temporales, 504
 coordinador, 493-495
 plana, 492
 protocolo de consumación
 atómica, 495-503
 en dos fases, véase protocolo de consumación atómica, en dos fases
 en una fase, 495
 en el servicio de transacciones de CORBA, 653
 equivalencia serie, 452
 modelo de fallo, 446
 recuperación, véase recuperación
 transferencia de estado, 536
 transformación operacional, 555
 transición de dominio, 210
 Transmission Layer Security, véase Secure Sockets Layer
 transparencia, 22-24
 de acceso, 22
 de concurrencia, 22
 de escalado, 23
 de invocación a método remoto, 165
 de movilidad, 22
 de prestaciones, 22
 de red, 23
 de replicación, 22
 de ubicación, 22
 en el middleware, 156
 frente a fallo, 22
 transporte, nivel de, véase niveles
 troncal, 90
 túnel web, 254
 Tunneling, 83
- U**
- UDP, 122-125
 API
 de Java, 123-125
 de UNIX, 148
 empleo de, 123
 modelo de fallo, 123
 para la comunicación petición-respuesta, 221
 UFID, véase identificador único de archivo
 Uniform Resource
 Characteristic, 338
 Identifier, 338
 Locator, 338
 Name, 338
 Universal Transfer Format, 133
 UNIX
 i-nodo, 306
 llamadas al sistema
 accept, 150
 bind, 148
 connect, 150
 exec, 202
 fork, 202
 listen, 150
 read, 150
 recvfrom, 148
 sendto, 148
 socket, 148
 write, 150
 señal, 209
 Upcall, 215
 URC, véase Uniform Resource Characteristic
 URI, véase Uniform Resource Identifier
 URL, véase Uniform Resource Locator
 URN, véase Uniform Resource Name
 UTC, véase Tiempo Universal Coordinado
 UTF, véase Universal Transfer Format

W

V, sistema
ejecución remota, 203



WAN, *véase* red, área extensa
WAP (Wireless Application Protocol), *véase*
protocolo
WaveLan, *véase* red
Web, *véase* World Wide Web
empleo de caché en, 43
WebNFS, *véase* Network File System
WLAN (red de área local inalámbrica), *véase* red,
inalámbrica
World Wide Web, 8-15
WPAN (red de área personal inalámbrica), *véase* red,
inalámbrica

X

X.500, servicio de directorio, 359-363
árbol de información de directorio, 359
LDAP, 363
X.509, certificado, *véase* certificado
XDR, *véase* Sun RPC, representación externa de
datos
xFS, sistema de archivo sin servidor, *véase* sistema de
archivo sin servidor xFS